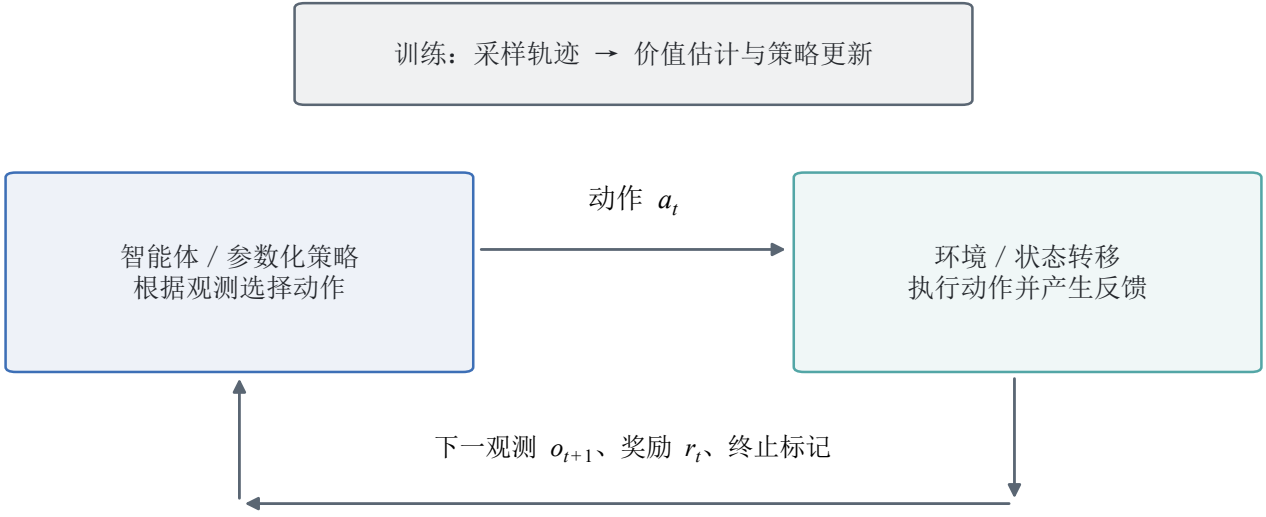
训练：采样轨迹 → 价值估计与策略更新
智能体 / 参数化策略
根据观测选择动作
动作 a_t
环境 / 状态转移
执行动作并产生反馈
下一观测 o_{t+1}、奖励 r_t、终止标记