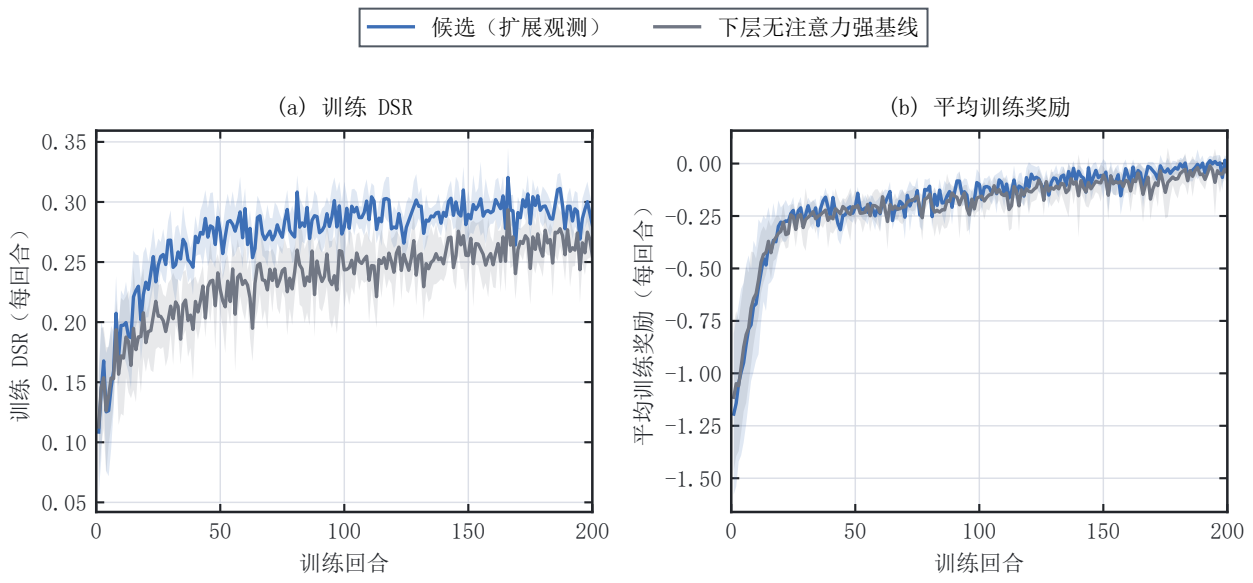
候选（扩展观测）
下层无注意力强基线
(a) 训练 DSR
训练 DSR（每回合）
0.35
0.30
0.25
0.20
0.15
0.10
0.05
0
50
100
150
200
训练回合
(b) 平均训练奖励
平均训练奖励（每回合）
0.00
−0.25
−0.50
−0.75
−1.00
−1.25
−1.50
0
50
100
150
200
训练回合