

中山大學

SUN YAT-SEN UNIVERSITY

中山大学专业硕士学位论文

面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

专　　业：　YOUR_SPECIALITY

学位申请人：　YOUR_NAME

指 导 教 师：　YOUR_SUPERVISOR 教授

论文答辩委员会主席：_____

论文答辩委员会成员：_____

_____

_____

_____

2026 年 10 月

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：　　年　　月　　日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：　　导师签名：

日期：　　年　　月　　日　　日期：　　年　　月　　日

论文题目：面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

专　　业：YOUR_SPECIALITY
硕 士 生：YOUR_NAME
指导教师：YOUR_SUPERVISOR 教授

摘　要

无人机（UAV）集群为动态地面请求提供时限计算服务时，需要协调空中平台的空间部署与机载资源分工。单机覆盖与计算、缓存能力有限，协同机动增加的接纳需求又可能加剧执行节点的资源竞争。本文以应急场景中的临时空地服务为应用动机，采用动态请求驱动的移动边缘计算模型，研究“集群飞向哪里、任务交给谁执行、如何连接机动与分配”三个任务规划问题。自然覆盖条件下，请求须先进入物理服务范围，再经过计算任务分配按时完成。本文以全部实际生成服务请求为分母定义端到端截止期满足率（DSR），并报告接纳率、接纳后质量、UAV 能耗、公平性、宏基站（MBS）依赖与计算开销。

首先，建立自然覆盖仿真与分层决策模型，在保持 100 m 物理服务半径不变的条件下，研究上层 Attention-MAPPO 对感知范围内尚未覆盖需求的预动作观测，结合邻机与用户信息形成需求感知的协同轨迹决策。独立确认中，扩展观测候选的 DSR 从 0.2444 增至 0.2793，增加接纳的同时揭示接纳后资源竞争。其次，在固定轨迹与历史状态下，针对跨机任务迁移通过最终批量算力共享影响其他请求的现象，研究整体重评估的 MC-ITR 计算任务分配。主配置每快照平均超时数由迭代对照的 2.228 降至 2.055；历史候选轨迹上的桥接进一步显示质量余量，但其分配能耗和完整调用时间较高，故作为离线诊断，未直接接入在线系统。

在此基础上，构建 SF-HLM 的分层协同决策：冻结需求感知轨迹上层，独立学习下层配额搜索并结合条件化负载匹配。对自然接纳请求构建请求–节点二部图，固定节点配额后通过容量槽指派生成完整分配，CompleteQuotaPPO 在有限匹配预算内选择配额迁移与停止动作，并结合共同质量掩码、普通修复、能耗筛选和最好方案保留。上层按各 UAV 的观测分散推理，下层集中调度当前请求批次，保持原环境时序与奖励。五架 UAV、一百个地面用户设备（UE）主场景的十个独立训练块与五个配对工作负载确认表明，主线 DSR 为 34.244%，相对贪心修复、原冻结和原适配学习下层修复，分别提高 1.423、2.008 和 2.192 个百分

点。相对相同学习上层加逐请求随机卸载及全随机，分别提高 10.604 和 18.816 个百分点，支持完整下层优化包与完整系统的服务收益。

共享强框架下的配额随机搜索 DSR 为约 34.100%，学习搜索额外增量约为 0.143 个百分点，其统计敏感性与较高软件开销需要同时解释。主线各块隔离 p95 软件调用时间的均值约为 109.24 ms。冻结策略的 UE 数量与 UAV 算力九格评价、固定潜在请求分母复核以及快照预算诊断进一步检验了结果边界。现有证据支持简化二维运动及既定信息条件下的集群任务层服务规划优势，未建立注意力结构的独立最优性或实际飞行部署效果。本文为进一步计入运动执行、信息上报与协调成本的无人机集群任务规划提供了可复核的模型和方法依据。

关键词：无人机集群，协同轨迹规划，计算任务分配，
多智能体强化学习，负载匹配

Title: Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

Major: YOUR_SPECIALITY
Name: YOUR_NAME
Supervisor: Prof. YOUR_SUPERVISOR

ABSTRACT

An unmanned aerial vehicle (UAV) swarm providing deadline-constrained computation services must coordinate spatial deployment with the use of onboard resources. Individual coverage, computation, and caching capacity are limited, while admitting more demand through cooperative movement can increase execution-node contention. Motivated by temporary air–ground services in emergency settings, this thesis uses a dynamic-request mobile edge computing model to study three task-planning questions: where the swarm should move, which nodes should execute the tasks, and how to connect movement with allocation. Under natural coverage-based admission, requests must enter the physical service area before they can be allocated for timely completion. The end-to-end deadline satisfaction rate (DSR) uses all actually generated service requests as its denominator. Admission, conditional completion, UAV energy, fairness, macro base station (MBS) dependence, and computation cost are also reported.

First, a hierarchical simulation model is established to study pre-action observation of uncovered demand with an Attention-MAPPO upper layer, without changing the 100-m physical service radius. Neighbor and user information support demand-aware cooperative trajectory decisions. Independent confirmation increases DSR from 0.2444 to 0.2793, while revealing the resource pressure associated with increased admission. Second, the fixed-snapshot MC-ITR solver reevaluates the complete assignment after a candidate migration to account for the effects of inter-UAV task transfers on other requests through batch-shared computation. It reduces the main-setting mean deadline misses per snapshot from 2.228 for an iterative comparator to 2.055. A bridge on snapshots from a historical candidate policy identifies further assignment-quality headroom, accompanied by higher assignment energy and full-path computation time. MC-ITR therefore remains an offline diagnostic and is not directly integrated into the online sys-

tem.

The resulting SF-HLM hierarchy combines a frozen demand-aware trajectory upper layer with independently learned quota search and conditional load matching in the lower layer. Admitted requests and execution nodes form a bipartite graph. For a fixed node-quota vector, capacity-slot assignment produces a complete placement; Complete-QuotaPPO selects quota transfers and a stop action within a finite matching budget. A common quality mask, ordinary repair, energy screening, and best-solution retention support execution. Upper-layer inference is decentralized according to each UAV's observations, whereas the lower layer centrally schedules the current request batch, preserving the original environment timing and reward. In the main setting with five UAVs and 100 user devices (UEs), confirmation over ten independent training blocks and five paired workloads yields a DSR of 34.244%. Gains over greedy repair, the frozen original learned lower layer with repair, and its adapted counterpart are 1.423, 2.008, and 2.192 percentage points, respectively. Gains over per-request random offloading with the same learned upper layer and over fully random control are 10.604 and 18.816 percentage points, supporting the benefits of the complete lower-layer optimization package and the complete system.

Quota-random search within the same strong framework already reaches approximately 34.100% DSR. The additional learned-search gain is approximately 0.143 percentage points and requires interpretation alongside its statistical sensitivity and higher software cost. The mean of the block-level isolated p95 software-call times is approximately 109.24 ms. Nine frozen-policy UE-count and UAV-compute settings, a common potential-request denominator check, and snapshot budget diagnostics further assess the scope of the results. The evidence supports a swarm task-level service-planning advantage under the simplified planar-motion model and evaluated information conditions. It does not establish isolated attention-architecture optimality or effectiveness in flight deployment. The findings provide a reproducible model and methodological basis for UAV swarm task planning that further accounts for motion execution, reporting, and coordination costs.

KEY WORDS: UAV swarm, cooperative trajectory planning, computation task allocation,
multi-agent reinforcement learning, load matching

目　录

第 1 章　绪论 1
1.1　研究背景与意义 1
1.2　国内外研究现状 4
1.3　关键研究问题与技术路线 9
1.4　研究内容与主要贡献 10
1.5　论文组织结构 11
1.6　本章小结 12
第 2 章　相关技术与理论基础 13
2.1　无人机集群任务规划与协同服务基础 13
2.2　无人机辅助移动边缘计算基础 16
2.3　马尔可夫决策过程与长期目标 20
2.4　策略梯度与 Actor–Critic 推导 22
2.5　时序差分与广义优势估计 25
2.6　近端策略优化与动作概率一致性 27
2.7　多智能体协作与 MAPPO 29
2.8　注意力聚合与图表示 31
2.9　指派匹配与配额条件化优化 34
2.10　随机实验与证据解释基础 35
2.11　本章小结 36
第 3 章　自然覆盖约束下无人机集群的需求感知协同轨迹决策 37
3.1　研究动机与评价口径 37
3.2　系统几何、动作应用与单时隙时序 39
3.3　请求、通信、缓存与能量模型 44
3.4　上层 Dec-POMDP 与注意力策略实现 49
3.5　预接纳需求观测设计 54
3.6　瓶颈诊断、独立确认与机制解释 56
3.7　本章小结 62
第 4 章　考虑跨机资源竞争的截止期优先计算任务分配 63
4.1　固定快照问题与受控比较范围 63

4.2 全批次执行、缓存与分配代价 64
4.3 严格字典序目标与共同基线 68
4.4 MC-ITR 搜索过程与可证性质 71
4.5 Exact-Small 与反事实评价协议 74
4.6 实验设计、主结果与代价解释 76
4.7 敏感性、精确检查与搜索完成情况 79
4.8 历史学习轨迹桥接与本章小结 83

第 5 章 无人机集群协同轨迹与计算任务分配的分层决策 85
5.1 研究问题与方法总体设计 85
5.2 移动前请求建模与负载相关预测 88
5.3 配额分解与条件化字典序匹配 90
5.4 有限预算配额搜索与二部图策略 93
5.5 教师初始化、配额 PPO 与分层训练 98
5.6 独立确认设计与统计方法 102
5.7 主场景性能与完整下层优化包的收益 106
5.8 完整框架与学习机制的分层解释 114
5.9 冻结策略的负载与算力稳健性 116
5.10 固定快照、共同 MBS 与时间预算诊断 119
5.11 研究联系、适用条件与本章小结 122

第 6 章 总结与展望 125
6.1 研究总结 125
6.2 综合认识与适用范围 127
6.3 后续研究方向 128
6.4 本章小结 129

参考文献 130

致谢 132

在读期间取得的科研成果 133

插图目录

图 2.1 终端、边缘与中心服务之间的通用层次关系示意 16
图 2.2 UAV 作为覆盖节点、中继与移动边缘服务器的应用关系示意 18
图 2.3 强化学习中的状态、动作、奖励与环境转移关系 20

图 3.1 系统总体布局与自然覆盖接纳示意。三角形为 UAV，实线圆为 100 m 服务覆盖范围，虚线圆为其中一架 UAV 的 460 m 感知范围；绿色圆点为被覆盖 UE，红色叉为未被覆盖 UE，其请求本时隙不被接纳。图中位置为示意性布局，非真实轨迹快照 40
图 3.2 覆盖半径与感知半径的几何关系 41
图 3.3 单时隙内的请求执行与轨迹应用时序。两层动作由当前观测计算；请求按移动前几何执行，上层轨迹动作随后应用并影响下一时隙覆盖 ... 43
图 3.4 上层 Attention-MAPPO 的网络与训练结构。实线为前向信息流，虚线为仅训练时使用的集中式评价与参数更新；执行阶段每架 UAV 仅用自身局部观测 52
图 3.5 原观测与扩展观测的槽位填充规则对照（同一几何示意）。原观测仅含已覆盖 UE，扩展观测以距离顺序补入感知范围内尚未接纳的 UE；图为规则示意，非注意力权重或真实记录 55
图 3.6 主场景实际生成服务请求的结果构成（下层无注意力强基线，瓶颈诊断批次，25 个评估单元的计数汇总） 57
图 3.7 独立确认实验的训练曲线（10 个训练种子的均值 ± 标准差）：(a) 训练 DSR；(b) 平均训练奖励 59
图 3.8 独立确认实验中候选相对强基线的逐训练种子 DSR 差值（每个种子为 5 个工作负载差值的平均；区间为配对 t 95% 区间） 60
图 3.9 确认实验中接纳率与接纳后按时完成率的配对比较（每点为一个训练种子下五个配对工作负载的均值）。两因子反向变化，DSR 增益来自接纳因子 60

图 4.1 批量算力共享与迁移外部影响的机制示例（构造参数：$F_u = 60\,\mathrm{GHz}$，$L_m = 2 \times 10^6$ 字节，$\omega_m = 2000$ 周期/字节，$\kappa = 10^{-27}$；数值按式 (4.5) 计算，非实验测量） 66

图 4.2 MC-ITR 算法流程。两个出口对应不同结论强度：无改善退出时可验证单请求迁移邻域局部最优；预算退出时不作此声称 72
图 4.3 固定快照主配置下四种卸载方法的超时数、分配能耗与搜索耗时（柱为十个工作负载种子均值，散点为逐种子值） 77
图 4.4 各方法相对 Iterative-Base 的每快照超时数配对差值（十个工作负载种子；区间为 5000 次重抽样的 95% bootstrap 区间）。散点、均值虚线与阴影区间描述该固定快照批次中的工作负载配对差异 78
图 4.5 UE 数量变化下四种方法的超时数与分配能耗（误差线为十个工作负载种子的逐项 95% t 区间，非同时覆盖） 79
图 4.6 UAV 算力倍率变化下四种方法的超时数与分配能耗（误差线口径同图 4.5） 80
图 4.7 Exact-Small 配置的快照构成与各方法逐分量均值。(a) 600 个快照的构成；(b)-(d) 三 UE 小规模下 MC-ITR、Greedy、Iterative 与穷举精确解的逐分量均值相同，仅 Heuristic-Control 存在差距 81
图 4.8 2026-09-28 历史覆盖观测候选轨迹的快照桥接（400 个快照；反事实不回写）。该候选不是最新 SF-HLM，快照来源与计时口径亦不同于本章主实验 83

图 5.1 无人机集群 SF-HLM 分层架构与移动前决策时序。冻结上层按局部需求及邻机观测准备轨迹动作，下层集中分配已接纳计算任务；当前请求先依据当前几何执行，随后应用轨迹动作形成下一时隙位置 86
图 5.2 固定配额的容量槽展开与请求匹配。示意图用于解释算法结构，不是实测任务分配 91
图 5.3 请求–执行节点二部图、当前与最好状态编码及配额动作头。非法边和填充请求在消息聚合中屏蔽 95
图 5.4 共同基座、下层训练图与独立确认的数据划分。图中回合是环境交互，配额 PPO 更新是固定训练图上的搜索训练 99
图 5.5 共同基座与配额策略的实际训练记录。前四面板依次为基座平均步奖励、基座 DSR、配额 PPO 损失和价值损失：细线为十块原始曲线，粗线和带分别为块间均值与正负一个标准差；未平滑。后两面板为每块一次教师监督损失记录和样本数；未保存逐轮损失，故不绘制教师收敛曲线。环境回合、优化更新与训练块横轴分别对应不同阶段 102

图 5.6　预选首确认回合的集群空间机动记录。上排为两方法五机轨迹，灰点仅表示初始 UE 位置，虚线为终点 100 m 服务圆；下排为逐机实际水平航程与最小机间距。200 m 间距线是既定几何约束；本图只描述各方法一个回合 …… 107
图 5.7　代表确认回合第 500 步上层 actor 的实际前向注意力记录。权重说明该状态下的信息聚合，不作为注意力贡献的独立因果证明 …… 108
图 5.8　最新冻结协议下八种方法的 DSR 比较。六个核心方法与两种随机补充分开标识；统计单位为十个模型/随机流配对块 …… 110
图 5.9　SF-HLM 相对三个主对手的十训练块配对差。每个块先合并五工作负载、六回合的请求计数 …… 110
图 5.10　生成请求的互斥结果分解与接纳后完成率。三种结果按同块计数计算后平均，条件完成率以接纳请求为分母 …… 111
图 5.11　真实 UAV 机队能耗与 MBS 依赖。能耗为 J/步，MBS 比例为 MBS 请求数除以接纳请求数；未计 MBS 全网费用 …… 113
图 5.12　块级公平性与隔离完整软件 p95。p95 先在每块全部调用上计算，再展示十块分布及其均值 …… 114
图 5.13　学习相对启发式和强配额随机的机制差。强随机共享初始化、修复、匹配、最好保留和相同调用预算 …… 115
图 5.14　SF-HLM 冻结策略在 UE 数量与 UAV 算力九格中的 DSR（左）和接纳后按时完成率（右）。主格引用独立确认，其他格不重新训练；数值为十块均值 …… 117
图 5.15　九格学习相对三个主对手的 DSR 差。八个新格的二十四项比较统一 Holm 校正，主格保留原确认族 …… 118
图 5.16　四百固定快照的自由与共同 MBS 数量诊断。两面板分别报告自由和固定共同 MBS 数量下每快照的实际超时均值；反事实分配不回写环境，描述性均值未画误差线 …… 120
图 5.17　软墙钟预算的真实质量、时间与超限率。原子匹配与完整路径开销可能越界，所有越界样本均保留 …… 121
图 5.18　确认评估环境步中的匹配调用与终止行为。调用包含初始匹配及失败候选，空批次纳入统计，停止不消耗一次匹配调用 …… 122

图 5.19　SF-HLM 十个确认训练块的计算任务执行分工。比例分母为每块本机、协作 UAV 与 MBS 三分支计数总和；显示全部训练块及等权块均值，不设置误差线或显著性检验 …… 124

附表目录

表 3.1　主场景仿真参数 49
表 3.2　上层单智能体观测构成（原观测；扩展观测见第 3.5 节） 50
表 3.3　上层 MAPPO 主要超参数 54
表 3.4　覆盖观测两阶段实验协议 58
表 3.5　独立确认实验的主场景结果（10 个新训练种子 × 5 个新工作负载） 59

表 4.1　自身改善与系统超时变化的构造例（非实验数据） 68
表 4.2　四种卸载方法的差异 70
表 4.3　单请求局部最优不蕴含全局最优的离散构造 73
表 4.4　固定快照主配置的卸载方法比较（十个工作负载种子均值） 77
表 4.5　各变体配置中 MC-ITR 相对 Iterative-Base 的每快照超时数差值 80

表 5.1　最终确认方法的在线合同 87
表 5.2　已确认配额策略的训练设置 101
表 5.3　SF-HLM 独立确认的数据与模型分割 103
表 5.4　完整下层与学习机制对照的组成 104
表 5.5　一百 UE 主场景的服务指标（先合并块内请求计数，再跨块平均） 109
表 5.6　三个预定主对照的配对 DSR 差值与真实 UAV 能耗比 109
表 5.7　主场景 UAV 资源代价、公平性和完整软件时间 112
表 5.8　学习配额主线在九格冻结评价中的 DSR 117

符号说明

N, M	UAV 数量与 UE 数量
H, τ, T	UAV 飞行高度、时隙时长与 episode 时隙数
$\mathbf{q}_u(t)$	UAV u 在时隙 t 的水平位置
$\mathbf{w}_m(t)$	地面 UE m 在时隙 t 的水平位置
$\mathbf{p}_u(t)$, $\mathbf{p}_m(t)$	UAV 与 UE 的三维位置
$v_{\max}$, $d_{\min}$	UAV 最大速度与机间最小安全距离
R_c, R_s	UAV 物理服务覆盖半径与需求感知半径
G, A, S	评估单元内实际生成、自然接纳、按时完成的服务请求数
DSR	端到端截止期满足率，S/G
J, c_m	Jain 公平性指数与 UE m 的累计服务覆盖量
g, R	链路信道功率增益与传输速率（bit/s）
P^{comm}	通信发射功率
σ^2	噪声功率
B^{edge}	UE-UAV 接入链路带宽
B^{inter}	UAV 间链路带宽
B^{backhaul}	UAV-MBS 回传链路带宽
$B_{\max}$, B_{low}	UE 电池容量与低电量阈值
β	请求流行度 Zipf 指数
$\mathcal{M}_t$, $\mathcal{J}$	时隙 t 的自然接纳服务请求集合与执行节点集合
$\mathcal{C}_m$	请求 m 的合法执行节点集合
$\mathbf{a}$, x_{mj}	请求分配向量与请求 m 分配到节点 j 的二元指示
L_m, C_m	请求 m 的输入字节数与所需 CPU 总周期
ω_m	请求 m 每字节所需 CPU 周期数，$C_m = \omega_m L_m$
B_s	服务程序 s 的字节数
F_u, F_{mbs}	UAV u 与 MBS 的计算能力（周期/s）
N_j, f_{mj}	分配到节点 j 的最终请求数与请求分得的计算频率

T_m, D_m	请求 m 的完成时延与截止时间
T_m^{tx}	请求传输时延，$8L_m/R$
T_m^{cmp}, E_m^{cmp}	请求计算时延与计算能耗
κ	动态 CPU 功耗模型的有效芯片电容系数
E_{assign}	卸载分配相关的非飞行 UAV 能耗
s_t, O_t	强化学习完整状态与上层 UAV 联合观测
$o_{u,t}$, $a_{u,t}$	UAV u 的局部预动作观测与连续原始动作提案
$a_{u,t}^{\mathrm{exec}}$	环境映射后的 UAV 执行动作
π_θ, V_ϕ	参数化策略与价值估计网络
θ, ϕ	策略参数与价值网络参数
r_t, G_t	即时奖励与从时隙 t 开始的折扣回报
V_t^π, Q_t^π	状态值函数与动作值函数
A_t^π, $\widehat{A}_t$	真实优势函数与优势估计
γ	回报折扣因子
λ_{GAE}	广义优势估计的多步混合系数
b_t, c_t	价值自举掩码与优势递推连接掩码
ρ_t, ε	PPO 新旧动作概率比率与裁剪系数
Q, K, V	注意力查询、键与值矩阵（本体按上下文区分值函数）
d_k	单个注意力头的键向量维度

第 1 章　绪论

1.1　研究背景与意义

1.1.1　无人机集群协同任务规划与空地服务需求

无人机集群通过多个空中平台的机动与分工，共同完成单个平台难以独立承担的区域任务。集群能力既取决于每架飞行器的运动和载荷能力，也取决于成员如何选择服务位置、交换任务并使用有限资源。Chung 等的航空集群综述将轨迹生成、任务分配和分布式感知等列为相关研究内容，并指出空中平台的运动特性为协同设计带来额外要求[1]。因此，面向航空航天任务的集群协同可以从任务规划层展开：在给定平台和运动约束下，研究多机应部署到哪些位置、如何形成任务分工，以及这种分工能否改善集体任务完成效果。

应急场景中的临时空地服务为上述问题提供了应用动机。当地面设备分散移动、任务需求发生变化时，搭载通信与计算载荷的无人机可以将服务能力带到需求附近。多个平台需要分担空间部署和计算处理任务，避免仅由个别平台接纳大量请求而其他平台资源无法被使用。本文据此研究动态地面请求驱动的集群计算服务；仿真中明确建模的是用户移动、请求生成、通信、缓存与计算过程，并未设置灾情演化、搜救目标发现或巡检航线等特定任务流程。应用动机用于说明服务需求，实验结论则依据实际采用的请求与环境模型。

本文中的无人机（Unmanned Aerial Vehicle，UAV）同时承担移动接入节点和计算执行节点的角色，地面用户设备（User Equipment，UE）产生具有截止时间的请求，宏基站（Macro Base Station，MBS）提供另一条执行路径。移动边缘计算（Mobile Edge Computing，MEC）将计算和存储能力部署到接近数据产生位置的网络边缘，为这种计算任务载荷提供了技术基础[2]。请求需要经历接入、数据传输、程序获取和计算等环节，空中平台的位置则决定部分请求能否进入这一流程。由此，MEC 对应集群所承担的服务任务，而集群协同轨迹规划与计算任务分配对应本文的主要决策问题。

空地服务能力具有明确的空间依赖性。固定服务器的算力即使充足，也需要用户连接到可用接入点；无人机的机动性使接入节点的位置可以成为决策变量。UAV 辅助通信研究讨论了覆盖、部署、轨迹与能量之间的联系[3-4]。在本文的计算服务场景中，空间错配具有两种表现：用户距离服务 UAV 过远，请求不能被接纳；请求虽然进入覆盖，却集中到少数执行节点并竞争计算和缓存资源。前者需要集群改变未来的空间部署，后者需要调整当前批次的任务分工。只报告已接

纳请求的平均时延，容易遗漏未接纳需求，难以解释集群整体服务效果。

集群空间部署同时影响跨机资源协作。某架 UAV 接纳较多请求后，可以将部分计算任务交给其他具有可用能力的 UAV；若协作链路较弱或必要程序未缓存，迁移又会增加传输和获取时延。MBS 能够补充执行能力，其使用比例也影响对空中集群独立服务能力的解释。任务目的地还会改变当前能耗和缓存状态，进而影响后续观测与动作。因此，本文把多机位置、任务接纳和执行负载视为相互联系的任务规划变量，通过长期交互仿真评价整体效果，并用固定状态实验识别分配环节的质量余量。

本文的集群协同限定在任务规划层。仿真采用固定高度下的二维运动、单步位移限制和位置修复，Actor 根据各 UAV 允许的观测输出机动方向，下层调度器集中处理当前请求批次。邻机状态进入上层决策，任务也能够在机间迁移，由此形成空间部署与计算分工两类协作。研究未包含姿态控制、编队参考队形、六自由度动力学或实际飞行试验；轨迹规划效果应在所用简化运动与信息条件下解释。这样的层次划分使研究问题与现有实现对应，也为后续衔接航空器执行控制提供明确接口。

1.1.2 自然覆盖条件下的服务评价问题

本文关注具有明确物理服务半径的自然覆盖接纳系统。只有在当前时隙位于某架 UAV 覆盖范围内的服务请求，才能被接纳并进入卸载决策。服务半径以外的请求不会因为某个卸载动作选择了 MBS 或协作 UAV 而自动被处理。这一定义使覆盖成为任务执行的前提：卸载策略能够重新分配已接纳请求，但不能替代缺失的 UE-UAV 接入链路。若仿真把所有未覆盖请求强制关联到某架 UAV，再计算卸载成功率，就改变了原有物理接纳条件，所得指标不能直接解释自然覆盖系统的服务能力。

为同时评价覆盖与处理质量，本文以全部实际生成服务请求中的按时完成比例定义端到端截止期满足率（Deadline Satisfaction Rate，DSR）。设一个评估单元内实际生成、自然接纳和在截止时间前完成的请求总数分别为 G、A 和 S，在 $G > 0$ 且 $A > 0$ 时有

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A} = \text{接纳率} \times \text{接纳后按时完成率}. \tag{1.1}$$

这一计数恒等式把端到端质量分为两个环节。轨迹与需求观测主要影响请求是否进入覆盖；卸载与资源竞争主要影响已接纳请求能否及时完成。不过，两环节在闭环系统中仍会互相影响，式 (1.1) 是统计分解，而不是两个独立组件收益可以直接相加的因果公式。

覆盖扩展可能带来新的服务压力。轨迹策略看到更多未覆盖需求后，能够主动移动并提高接纳比例；如果随后接纳的请求计算量更高，或者集中到原本已经繁忙的执行节点，接纳后的完成比例可能下降。此时，判断方法是否有效需要观察 S/G 的最终变化，不能只看覆盖率上升，也不能因为接纳后质量下降便忽略端到端成功数增加。反过来，如果卸载策略仅处理较少但容易的请求，接纳后成功率可能很高，端到端服务率却未必理想。本文把这两种情况放在统一的请求计数框架内解释。

DSR 的分母还需要与环境行为一致。本文 UE 电池状态会影响实际服务请求与能量请求的生成类别，因此不同策略的实际服务请求总数可能有轻微差异。预先配对外生随机流，能够减少用户移动和潜在需求差异带来的干扰，但不自动保证策略相关的实际分母完全相同。本文保留实际生成服务请求作为预定主指标，并以共同潜在服务请求为固定分母进行敏感性分析。这样既避免事后更换主评价目标，也检查分母变化是否解释了观察到的优势。

1.1.3　集群空间部署与计算任务分工的研究意义

从集群任务规划角度看，轨迹决策改变未来的服务条件，计算任务分配利用当前已经形成的服务条件。UAV 接近某些 UE 可以提高接纳机会，但同时可能远离其他需求区域或协作节点；任务转移到算力较高的 UAV 可以降低计算时延，却可能增加传输时延、程序获取和分配能耗。这类取舍要求策略考虑多个平台和多个请求之间的关系，使空间机动服务于集体任务目标。UAV 位置或轨迹与资源分配的联合优化研究也体现了这一联系[5-6]。本文进一步以任务是否被接纳、是否按时完成解释轨迹规划与跨机分工各自发挥作用的环节。

从航空平台资源使用角度看，多机数量增加并不意味着服务能力可以线性增长。机间几何条件影响任务传输，缓存差异影响程序可用性，计算共享决定各请求的执行速度，机动又需要付出飞行能耗。因而，集群评价应同时观察服务成功、UAV 能耗、分工方式和对地面 MBS 的依赖。本文将这些指标并列报告，避免仅以更多任务转移到地面执行解释全部集群收益。现有能耗模型描述运动与服务的消耗；尚未设置 UAV 有限电池和返航约束，因此其能耗结果也不直接等同于任务续航时间。

从算法角度看，问题同时包含连续轨迹动作、离散请求目的地和时序状态变化。随着请求数增加，所有请求目的地组合形成的动作空间迅速扩大；与此同时，一个节点的最终负载又会影响被分配到该节点的全部请求。若使用单一网络同时输出轨迹与完整分配，训练可能面临动作尺度不同、回报来源混合和组合可

行性处理困难。分层决策能够把位置控制与分配求解的作用分开描述，但分层本身不保证两层能够形成最优协同，也不意味着上下层都需要相同的网络结构。

从研究方法角度看，UAV-MEC 算法的性能评价应区分长期闭环结果与固定状态下的求解能力。固定快照实验能够控制位置、请求和历史状态，直接观察某个分配求解器的质量；闭环实验则把分配对电池、缓存、后续观测和轨迹的影响保留下来。前者便于分析批量外部影响和局部搜索性质，后者回答整套方法是否提高长期服务表现。本文同时使用这两种证据，但保持其统计单位与结论边界，避免把固定快照的成功数改善当作长期 DSR 增益。

1.2 国内外研究现状

1.2.1 集群协同覆盖与需求驱动的空间规划

无人机集群规划需要把整体任务目标转化为各平台的空间行动与资源分工。航空集群研究同时涉及轨迹生成、任务分配和协同信息使用，各层之间需要符合平台与任务条件[1]。对于本文的空地计算服务，整体目标是动态请求的按时完成，空间行动则影响请求能否进入物理覆盖。因而，轨迹规划既要关注用户位置，也要关注请求的时间要求和服务负载；停留在用户密集区域不必然对应最高的截止期成功比例。

覆盖指标应与所承担的任务对应。本文关心一个服务请求在产生时是否处于可用 UAV 的服务范围内，以及接纳后能否按时完成。单次位置布局下的几何覆盖面积，或 UAV 轨迹访问过的区域面积，可以描述空间活动，却不能直接代替这种请求级指标。若用户和请求随时间变化，即使两条轨迹经过相近位置，也可能接纳不同的任务集合。因此，本文把自然覆盖接纳写入环境转移，并以实际请求计数连接空间规划和任务执行。

协同覆盖还取决于策略允许使用的信息。UAV 只观察已关联用户时，未覆盖需求难以直接进入其动作依据；引入感知范围内的待接纳需求后，集群可以据此调整未来位置。但扩大观测不是扩大物理服务半径，其上报及时性和获取成本也属于另外的信息条件。本文第三章研究的是在既定信息假设下，需求可见性如何影响协同机动与接纳效果；它保留对实际部署信息来源和同信息架构对照的独立检查要求。

机间几何约束与协同规划效果也应区分。在本文采用的几何中，100 m 服务半径与 200 m 最小机间距使满足该距离条件的覆盖圆内部不重叠。因此，不能将覆盖重叠减少归因于策略学习。可检验的规划收益是需求与服务位置是否更匹

配、接纳机会如何变化，以及接纳后负载是否能够得到合理处理。这一问题定义把空间部署、需求观测和服务完成连接起来，而不预设形成固定编队或全时通信连通性的要求。

1.2.2　协同计算任务分配与模型驱动资源优化

任务分配需要明确被分配的对象、执行主体和评价目标。Skaltsis 等综述了 UAV 任务分配中的多类方法，重点比较计算复杂度、最优性和可扩展性，并讨论通信方式与不确定性的影响[7]。这些维度为本文提供了评价框架：质量更好的分配需要与求解开销一起报告，集中处理所需的信息不能被省略，少量 UAV 上的结果也不能自动外推到大规模集群。本文的任务对象是已经自然接纳的不可拆分计算请求，执行主体为五架 UAV 与一个 MBS；“计算任务分配”具体对应请求执行位置选择，而不是搜索目标或航路点的指派。

模型驱动方法首先把通信速率、计算时延、能量或覆盖条件写成目标与约束，再根据变量结构采用交替优化、连续近似、离散搜索或博弈求解。其优点是能够明确给出信息条件和约束含义，并在满足特定假设时分析子问题性质。UAV 辅助通信综述指出，部署与轨迹会同时影响覆盖、链路质量和飞行成本[3-4]；在 MEC 场景中，还需要加入执行节点的计算和缓存条件。因此，模型是否准确描述了业务竞争，往往与求解器本身同样重要。

连续优化适合功率、带宽、频率或位置等变量，但任务目的地与缓存选择通常具有离散性质。研究者常在固定部分变量时处理另一部分，再循环更新。该做法可以降低每个子问题的求解难度，也便于用约束表达服务要求；其代价是整体问题的非凸性和离散耦合仍可能保留。对一个子问题获得精确解，并不意味着整套联合问题获得全局最优解。对于在线场景，还必须衡量重新求解的时间是否与请求截止期和决策时隙相匹配。

博弈方法则强调不同参与者的利益与响应。Yuan、Xie 和 Tan 的研究把基站、UAV 和用户的计算资源交互表述为多层 Stackelberg 博弈，并通过各层效用和响应选择卸载策略[8]。曾耀平等在 UAV 部署与卸载联合问题中，将 UAV 与 UE 的交互表述为领导者和追随者结构，结合联盟形成与势博弈分析[9]。这些方法说明分层结构可以来自参与者之间的决策顺序与利益关系。本文的上下层则是同一协作系统中的轨迹与请求分配模块，其共享服务目标，不能因为同样存在“两层”便直接继承上述博弈的均衡结论。

缓存与卸载的联合设计进一步说明，仅按链路和算力选择节点可能不足。王义君等研究微云、边缘和本地组成的多层结构，通过协同缓存自适应的分层多元

宇宙优化算法处理卸载、资源配置及动态时延–能耗权衡[10]。该工作的服务缓存与节点选择设计，为本文考虑程序获取代价提供了相关背景；其细粒度部分卸载假设与本文不可拆分请求不同，数值结果不能直接移植。李侍阳和朱晓荣针对无人机巡检中的感知与 AI 任务，将多维资源优化拆分为若干子问题并交替求解[11]，表明服务目标与任务结构改变时，合适的优化变量和分解方式也会改变。

对于本文，模型驱动方法最直接的启示是显式检查分配外部影响。若 UAV 以最终批量请求数均分算力，迁移一个请求会改变迁入与迁出节点上其他请求的计算频率和完成时间。只计算被迁移请求自身时延的局部规则，可能忽略多个请求同时跨越截止期的变化。第四章因此以整个分配的目标重评估为基础研究 MC-ITR，而不是假定逐请求代价可以无条件相加。该求解器用于明确质量余量和计算代价，不承担本文第五章的实时学习式下层。

1.2.3 动态机动与资源决策中的深度强化学习

深度强化学习（Deep Reinforcement Learning，DRL）把神经网络表示与交互式决策结合，用参数化策略或值函数近似复杂状态下的长期行为。DQN 的研究说明深度网络能够从高维输入中学习动作价值[12]；策略梯度和 Actor–Critic 方法则直接优化动作分布，为连续控制提供了基本工具[13-14]。这些经典算法为 UAV 位置、资源配置和任务调度提供了可采用的优化方式，但算法在一般基准上的有效性不是 UAV-MEC 特定服务协议下的性能证明。

将资源管理表述为强化学习问题，需要同时确定状态、动作、奖励和环境转移。当前链路速率、节点位置与负载提供即时决策依据；电池、缓存和移动状态又使当前动作影响后续回报。在这种情况下，网络前向决策可以在训练之后提供较快的动作生成，而较高的交互采样与训练计算被转移到离线阶段。比较学习式与在线搜索方法时，既应报告在线推理时间，也应说明训练数据与离线教师的额外开销，不能把离线优化计算忽略后宣称总体计算成本完全等同。

连续控制和离散选择需要不同的动作表示。轨迹控制可以由 Gaussian 等连续分布生成方向或位移；请求执行位置可以由分类分布生成离散选择。对大批量请求逐项独立采样虽然容易实现，却未必捕捉最终负载之间的耦合。一种处理办法是把连续与离散决策分开学习；另一种是用优化模块把网络提出的结构化变量转化为完整方案。本文采用后者处理第五章的配额搜索：策略选择节点任务数量的迁移方向，再由条件化匹配生成实际分配。学习模块和求解模块的作用必须分别评价。

Li 等针对多 UAV 辅助 MEC 中的不完整信道信息与任务复杂度估计误差，

联合考虑轨迹、任务划分和通信计算资源，提出使用 Beta 分布的多智能体 PPO 框架[15]。这项研究的中心问题是通信与计算不确定性下的鲁棒设计，并不是本文自然覆盖接纳分母或不可拆分批量请求问题。其 Beta 分布处理有界动作的思路，也不能等价于本文先保存 Gaussian 原始提案、再由环境执行裁剪的实现。明确这种动作概率与执行动作的差别，有助于避免把一篇相关论文的设计直接当成本项目已实现的机制。

Tao 等研究 UAV 辅助 MEC 中在线服务选择、任务卸载、计算频率、轨迹和悬停安排的联合决策[16]。其中服务程序选择体现了缓存与业务处理之间的联系，在线决策依据当前请求和资源状态进行。本文同样关注程序可用性与请求时序，但使用多 UAV 的自然接纳规则，并以截止期成功比例评价整个服务流程。不同文献使用能效、加权能量、平均时延或服务质量等目标，各自在对应定义下成立；不能仅因均称“联合优化”就把排名拼成一条普遍结论。

学习式方法还受到观测设计限制。网络只能根据实际输入产生策略，注意力或更深的模型不能从没有提供的请求特征中恢复真实需求。如果上层只看到已经关联的用户，它的轨迹控制就可能缺少覆盖外需求的直接信号。扩展观测能够改变决策信息，但也改变方法的信息条件。因此，本文先研究需求可见性与端到端服务的联系，再通过同信息替代结构和冻结策略对照检查组件贡献。观察到整套方法优势之后，仍需要区分“看到了不同信息”与“在相同信息上用了更好的网络”。

1.2.4　多智能体协作与集中训练分散执行

多智能体强化学习（Multi-Agent Reinforcement Learning，MARL）考虑多个决策主体的交互。当 UAV 共同服务一个区域时，一架 UAV 的位置变化可以改变邻机的覆盖边界与可用协作链路；某节点接纳或转入的请求又会占用共享资源。从单个智能体看，其他策略的变化使经验数据的生成过程不断变化；从整体看，联合状态和联合动作仍可以在适当假设下构成马尔可夫决策过程。因而，多智能体学习的困难在于协作、部分可观测和训练非平稳性，不能简单表述成“多智能体系统不具备马尔可夫性”。

集中式训练分散式执行（Centralized Training with Decentralized Execution，CTDE）在训练阶段使用更完整的信息估计价值或构造梯度，而在执行阶段让每个 Actor 根据其允许的局部观测选择动作。MADDPG 采用集中 Critic 处理多智能体动作相关性[17]；MAPPO 将 PPO 的策略更新方式用于协作多智能体任务，并系统研究了其在基准环境中的表现[18]。这些方法提供了利用训练阶段信息改善

估计的路径，但 CTDE 不是执行阶段获取全局信息的许可证，也不自动解决信用分配。

对于同类型 UAV，策略参数共享可以减少重复参数，并让不同 UAV 的经验共同更新一套网络。共享参数与动作相同是两回事：各 UAV 输入的位置、能量、邻居和用户不同，产生的动作分布也不同。价值网络可以对联合观测建模，并为每个 UAV 输出一个价值估计；这与把所有智能体直接压缩成一个统一标量 Critic 的实现不同。本文上层采用共享 Actor 与联合观测 Critic，第二章据此给出与代码相容的 MAPPO 描述，而不把一种教科书式结构预设为唯一实现。

除 Actor–Critic 方法外，值分解通过约束联合价值的组合形式支持分散选择。VDN 与 QMIX 分别使用加性分解和单调混合等结构[19-20]。这些结构有助于从团队价值中学习个体决策，但也带来特定表达约束和动作类型要求。本文轨迹采用连续方向动作，卸载又包含批量组合结构，因此选择 MAPPO 作为上层学习基础，并通过独立求解模块处理下层分配。该选择来自问题结构与已有实现，不意味着其他 MARL 路线已经在相同协议下被排除。

Hady 等关于资源分配优化的 MARL 综述讨论了多智能体学习在网络资源问题中的方法分类与应用条件[21]。综合这类研究，可以从三个层面审视协作方法：策略执行需要什么信息，训练阶段使用了什么额外信息，评价是否把共享数据或工作负载误当独立重复。本文使用训练块作为学习方法统计重复，以配对工作负载减少环境差异，并在主性能、机制检验与快照诊断之间保持清楚的比较对象。

1.2.5 注意力聚合与结构化优化的作用

注意力机制通过查询与键之间的相似度生成权重，并对值向量加权聚合。Transformer 的缩放点积与多头结构为这一表示方式提供了经典形式[22]。在多 UAV 场景中，自身状态可以作为查询，邻居 UAV 与 UE 槽位作为被聚合元素，使输出随位置、需求和邻居关系变化。这样能够显式表达元素之间的相对关系，也便于对空槽位使用掩码。但注意力仍依赖输入特征、训练信号与模型容量，其结构能力不能直接写成 DSR 必然提高的定理。

注意力和信息预算应分别讨论。若一个 Actor 得到未覆盖 UE 的请求、电量和位置，而另一个 Actor 只能看到已关联 UE，则两者比较同时包含输入信息差异。即便前者使用注意力，观察到的优势也不足以证明优势完全来自注意力架构。相反，同信息条件下注意力与 MLP 的差值区间跨零，也只能说明这次实验没有确认结构增益，不能证明所有场景中注意力无效。本文第三章以覆盖观测为

研究中心，保留同信息对照的证据边界。

对于卸载，结构化优化提供了与直接动作输出互补的思路。已接纳请求与执行节点形成二部关系，各边包含合法性、传输代价、计算负载和程序条件。固定节点配额之后，最终计算共享条件可以被写入边成本，再通过指派生成完整方案；改变配额则继续探索不同负载状态。这样的分解把“节点接多少任务”和“具体哪些任务去这些节点”区分开，为学习搜索提供了较紧凑的控制对象。条件化子问题的可求解性不等于原整体问题全局最优，也不等于能耗筛选之后仍保持无条件最优性。

本文第五章的学习配额搜索建立在较强的共享框架上。普通修复、质量掩码、条件化匹配、能耗筛选与最好方案保留本身就可能带来明显收益，因此使用强配额随机与启发式配额搜索对照是必要的。与逐请求随机卸载相比的提升回答完整下层优化包是否有用；与共享框架下配额随机相比的提升才更接近学习搜索的额外贡献。这种比较层次能够突出方法有效的部分，同时避免把整个优化包的收益全部归给 PPO。

1.3　关键研究问题与技术路线

本文的中心问题是：当地面任务需求随位置和时间变化、单机覆盖与机载资源有限时，无人机集群如何通过协同轨迹规划和计算任务分工，使更多请求在截止时间内完成？这一问题可以按决策过程分为三个环节。首先，集群飞向哪里，轨迹策略是否能够依据当前可获得的需求和邻机信息主动改善接纳机会；其次，任务交给谁执行，已接纳请求的最终负载如何影响整个批次的截止期质量，固定快照中是否存在可利用的分配余量；最后，如何连接空间部署和任务执行，在不改变物理接纳规则的前提下，较快的学习配额搜索能否形成长期闭环服务收益。这三项问题分别由第三、第四和第五章回答，并共享请求生成、接纳与成功计数的基本语义。

技术路线从环境语义开始，而不是从网络模块堆叠开始。本文先确认覆盖外请求不会被强制执行，统一字节与比特转换、最终批量算力共享、缓存更新和时隙决策顺序；再分析上层观测与服务失败构成，研究扩展需求观测；随后固定位置与历史状态，通过 MC-ITR 检查请求迁移的整体效果；最后采用冻结学习式上层与独立训练的完整配额 PPO 搜索，评估端到端 DSR、资源指标和软件开销。这一路线使方法修改能够与对应证据逐项关联。

在算法设计上，本文保留集群空间机动与计算任务分配的层次区分。上层由共享 Attention-MAPPO Actor 根据各机预动作观测给出二维方向动作，执行时

由原环境处理速度、边界与机间位置修复；训练使用联合观测 Critic，策略执行按各 UAV 的输入分散进行。下层集中使用当前几何和请求批次进行跨节点调度，不把 UAV 执行新轨迹动作后的链路错误地用于处理当前请求。最新 SF-HLM 主线冻结确认块的上层基座，使用二部图表示和 CompleteQuotaPPO 独立学习配额搜索；其分层协同来自机动部署与批量执行的功能连接，未采用上下层联合重训，也未将 MC-ITR 接入在线系统。

在评价设计上，本文把独立训练、配对负载和快照反事实分别使用。学习方法的训练块反映模型训练变化，负载与评估回合用于更稳定地估计每个块的性能；非学习随机方法没有训练种子，其配对随机流块不伪装成独立训练。固定快照比较控制几何和请求，但不把反事实分配回写到原闭环环境。由此得到的模型差异、工作负载差异与求解器差异可以分别解释，避免增加重复数量时夸大统计确定性。

1.4 研究内容与主要贡献

本文围绕五架 UAV、一百个 UE 和一个 MBS 的动态空地服务仿真主场景，形成以下三项相互关联的研究内容与贡献。

1. **自然覆盖约束下的需求感知集群空间规划**。建立实际生成、自然接纳和截止期成功的统一计数口径，明确接纳率与接纳后质量共同决定端到端 DSR。在物理服务半径不变的条件下，将感知范围内未覆盖需求纳入上层预动作观测，结合邻机与 UE 的注意力聚合研究协同轨迹决策，并使用独立确认与固定潜在分母复核支持对应结论。这一内容将空间部署的效果具体落实到请求接纳与完成，说明需求可见性对集群服务规划的作用，同时保留观测信息条件与注意力结构贡献的区别。
2. **考虑跨机资源竞争的截止期优先计算任务分配**。在给定位置、请求和历史状态下，以超时数、归一化时延和分配能耗的字典序目标研究 MC-ITR。每次候选迁移重新评价整个批次，明确任务迁入和迁出如何通过最终批量算力共享改变其他请求的完成时间。通过主配置、敏感性、小规模一致性检查以及共享轨迹快照桥接，量化跨机分配的质量余量与完整计算代价。这一内容把机载资源竞争作为集群任务分工的核心约束，并为在线方法设计提供诊断依据。
3. **冻结轨迹上层与学习配额匹配的分层协同决策**。对已接纳请求构建请求–节点关系，把计算任务分配分解为配额搜索和配额条件下的指派。结合共同质量掩码、普通修复、能耗筛选与最好方案保留，使用独立训练的

CompleteQuotaPPO 选择配额迁移和停止动作，在有限匹配预算内生成可执行分配；上层保持冻结需求感知策略和原环境语义。在十个独立训练块与五个配对工作负载上进行确认，主线 DSR 为 34.244%，相对贪心修复、原冻结与原适配学习下层修复分别提高 1.423、2.008 与 2.192 个百分点。全随机、相同学习上层加逐请求随机卸载、启发式配额与强配额随机分别检验完整系统、下层优化包和学习搜索增量，冻结策略的 UE 与算力九格复验检查场景依赖性。共享强框架上的学习增量较小，结合其统计敏感性和软件耗时解释，不将完整框架收益全部归于学习组件。

这些贡献共同形成从集群空间部署、跨机批量分配到在线闭环表现的论证链。本文没有将不同接纳协议、不同训练阶段或不同源码版本的绝对指标直接合并，也没有以单个最佳种子代表平均效果。现有结果支持特定仿真与信息条件下的集群服务方法优势，不能单独证明注意力架构优于所有替代结构，或者证明真实通信部署中的收益。任务层协同效果也不等同于编队稳定性或飞行动力学可行性。这些层次与边界使方法可以被复现、比较和继续改进，而不影响对已证实收益的清楚呈现。

1.5　论文组织结构

第一章从无人机集群协同任务规划与临时空地服务需求出发，综合协同覆盖、计算任务分配与学习决策的相关研究，提出空间部署和机载负载耦合下的研究问题、技术路线及三项贡献。

第二章说明集群任务规划的层次、简化运动与机间协作关系，介绍 UAV-MEC 的通信、计算、缓存与评价基础，推导马尔可夫决策过程、值函数、策略梯度、带终止处理的广义优势估计和 PPO 裁剪目标，进而说明 MAPPO、注意力聚合与指派匹配的基本原理，为后续算法建立统一符号和理论基础。

第三章研究自然覆盖约束下无人机集群的需求感知协同轨迹决策，建立动态请求、几何运动约束与上层观测模型，通过服务失败分解、训练动态与独立确认分析需求可见性对集群接纳和端到端服务的影响。

第四章研究考虑跨机资源竞争的截止期优先计算任务分配，在固定轨迹快照中给出 MC-ITR 的批量外部影响、字典序目标、搜索流程和有限终止性质，并报告不同负载、算力与共享快照上的质量、能耗和求解开销。

第五章研究无人机集群协同轨迹与计算任务分配的分层决策，描述 SF-HLM 的冻结轨迹上层、条件化匹配与 CompleteQuotaPPO 搜索，进行独立确认、随机补充、同预算机制比较与冻结策略稳健性评价，并通过集群机动、任务分工、软

件计时和快照诊断解释完整方法的性能与代价。

第六章归纳需求感知空间规划、跨机资源分配和完整在线协同的主要发现，说明现有信息与仿真假设的适用范围，并提出飞行动力学、通信受限协同、平台故障、续航约束和跨场景评价等后续研究方向。

1.6 本章小结

本章将无人机集群协同规划具体化为两个连续的服务环节：集群通过空间机动形成自然覆盖接纳机会，再通过计算任务分工与资源使用按时完成请求。相关工作说明协同轨迹、任务分配与学习决策具有多种可行建模方式，也提示规划结构、信息条件与实测性能应分别论证。本文据此采用需求观测研究、固定快照诊断和完整方法确认相结合的技术路线，后续章节在同一任务与服务语义下逐步说明方法设计、公式推导和实验依据。

第 2 章　相关技术与理论基础

本章为无人机集群协同轨迹规划与计算任务分配建立共同的系统概念与数学基础。首先从集群任务规划的层次关系出发，说明简化机动约束、空间部署和机载资源分工如何连接，再介绍 UAV-MEC 中通信、计算、缓存和自然接纳的联系。随后从有限时域马尔可夫决策过程推导值函数与策略梯度，给出带终止处理的广义优势估计和近端策略优化，并介绍多智能体协作、MAPPO、注意力聚合，以及第五章使用的二部图与条件化指派。通用理论说明算法形式及成立条件；本文的网络结构、超参数和性能结论分别由后续章节的实现与实验证据确定。

2.1　无人机集群任务规划与协同服务基础

2.1.1　任务分工、轨迹规划与飞行执行的层次关系

无人机集群通过多个空中平台共同承担任务，研究内容包括任务分配、轨迹规划、信息交互和飞行控制等相互联系的环节[1]。任务分配确定哪些平台承担哪些工作，轨迹规划确定平台如何到达或保持有利位置，飞行执行将规划指令转化为实际运动。各层面对的时间尺度、状态信息和可行性条件不同：任务分配需要理解任务价值及资源需求，轨迹规划需要处理空间关系和机动限制，飞行执行还需要满足飞行器动力学与控制约束。区分这些层次有助于准确界定算法解决的航空集群问题。

本文聚焦任务层与规划层之间的协同。空中平台通过改变服务位置接纳地面计算请求，再通过机载计算、跨 UAV 协作和 MBS 支持完成请求。任务具有输入数据量、服务类别、截止时间和执行资源需求；其分配是在已接纳请求与执行节点之间建立对应关系。无人机任务分配文献包含多种任务类型和约束[7]，本文采用其中明确的计算服务任务，未把地面请求改写为需要无人机实体到访的侦察目标或运输订单。因此，服务覆盖承担任务接入功能，执行节点选择承担资源分工功能，两者共同决定集群的时限服务能力。

从规划对象看，第三章研究多机如何依据需求选择下一时隙的空间部署，第四章研究给定空间部署下如何调整任务执行分工，第五章连接这两个决策过程并检验闭环服务表现。这里的“集群协同”体现为多个 UAV 的位置与资源决策服务于共同的请求完成目标。任务层的协同无需预设固定编队形状；本文没有为 UAV 指定领航者、队形参考或编队稳定性目标，后续分析也不以保持特定队形作为性能指标。

2.1.2 二维机动模型与离散空间可行性

为了把注意力集中在任务需求与空间部署之间的联系，本文采用固定高度下的二维运动描述。UAV u 的水平位置为 $\mathbf{q}_u(t) \in \mathbb{R}^2$，高度保持 $H = 100\,\mathrm{m}$；时隙长度为 $\Delta t = 1\,\mathrm{s}$，最大运动速度为 $v_{\max} = 15\,\mathrm{m/s}$。在 $700 \times 700\,\mathrm{m}^2$ 场地中，环境保留 50 m 的边界距离，因而离散水平位置范围为 $\mathcal{Q} = [50\,\mathrm{m}, 650\,\mathrm{m}]^2$。五架 UAV 的位置更新满足

$$\mathbf{q}_u(t+1) = \mathbf{q}_u(t) + \boldsymbol{\delta}_u(t), \qquad \|\boldsymbol{\delta}_u(t)\|_2 \leqslant v_{\max}\Delta t = 15\,\mathrm{m}, \qquad \mathbf{q}_u(t+1) \in \mathcal{Q}. \quad (2.1)$$

$\boldsymbol{\delta}_u(t)$ 的单位为 m，表示修复后的实际位移。它与网络输出的无量纲动作提案不同；时隙平均速度模长是 $\|\boldsymbol{\delta}_u(t)\|_2/\Delta t$。这一量纲关系使轨迹长度、单步机动与能耗结算可以使用同一实际位移。

环境另要求离散位置之间满足最小水平间距 $d_{\min} = 200\,\mathrm{m}$。以联合位置集合表示，可行区域为

$$\mathcal{Q}_{\mathrm{joint}} = \left\{(\mathbf{q}_1, \cdots, \mathbf{q}_N) : \mathbf{q}_u \in \mathcal{Q},\ \|\mathbf{q}_u - \mathbf{q}_v\|_2 \geqslant d_{\min},\ \forall u \neq v\right\}. \quad (2.2)$$

各机独立输出提案并不保证联合位置属于该集合。实际执行先限制提案位移并裁剪边界，再有限次调整冲突位置，同时重新检查运动预算；若仍有间距冲突，则把相应 UAV 回退至原位置，并继续传播回退直至得到可行离散状态。由此产生的悬停属于执行映射的一部分，需要保留在轨迹和能耗记录中。实现对最终离散状态采用 $10^{-3}\,\mathrm{m}$ 数值容差。该过程是对离散位置的环境可行性修复，不是对非凸可行集求最近点的精确投影，也不构成连续飞行轨迹上的避碰或稳定性证明。

模型没有显式描述加速度、转弯半径、姿态和风场。式 (2.1) 所能支持的是具有位移预算的空间部署决策，而非满足完整飞行动力学的控制器。保持高度并限制步长，可以简化需求变化与机动选择的关系；若面向真实飞行执行，还需把规划位移交给满足具体飞行器约束的轨迹生成与跟踪模块，并重新评估执行误差对覆盖和截止期服务的影响。

2.1.3 服务覆盖、邻机关系与空间资源耦合

服务覆盖与需求观测具有不同作用。本文的物理服务半径为 $R_{\mathrm{cov}} = 100\,\mathrm{m}$，请求只有进入 UAV 的服务范围才被自然接纳；允许的感知范围为 $R_{\mathrm{sense}} = 460\,\mathrm{m}$，使轨迹策略可以使用服务范围之外的部分需求信息。邻机关系也按该感知距离筛选，由

$$\mathcal{N}_u(t) = \{v \neq u : \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2 \leqslant R_{\mathrm{sense}}\} \quad (2.3)$$

形成随位置变化的邻居集合。各 UAV 高度相同，因此 UAV 间三维距离等于水平距离。式 (2.3) 定义模型允许进入观测的邻机关系，不包含消息排队、丢包或链路连通性保证；这些信息如何在实际系统中获取仍取决于通信协议。

最小机间距满足 $d_{\min} = 2R_{\mathrm{cov}}$，使不同 UAV 的圆形覆盖内部在规定离散状态下不重叠。因此，本文轨迹优化的重点是把有限服务区域部署到有需求的位置，而不是通过学习消除本已受几何约束限制的覆盖重叠。某架 UAV 移动会改变其后续可接纳需求、与其他 UAV 的协作距离以及相应传输代价；其他 UAV 的移动也会改变整个机群的空间服务配置。评价时必须保留未覆盖请求，才能衡量这类空间协同是否转化为任务接纳改善。

空间部署的收益还取决于执行资源。服务位置更接近高需求区域，可能接纳更多请求，同时让接纳节点的共享算力承担更大批量。跨 UAV 转移能够重新分担计算负载，却需要额外传输，并可能因目标节点缺少服务文件而增加准备时间。于是，集群规划面对的是位置、任务集合和资源分工的时序耦合：机动改变可服务请求集合，任务分配改变节点负载与缓存状态，后续状态再影响下一次机动决策。本文用“接纳率 × 接纳后按时完成率”解释这一服务链条，具体计数与推导在第三章展开。

2.1.4　分散式轨迹决策与集中任务调度

本文采用上层分散式 Actor 与下层集中批量调度相结合的组织形式。上层每架 UAV 根据自身、允许邻机和允许用户特征产生动作提案，训练时联合观测 Critic 为各机提供价值估计。共享 Actor 参数使多架 UAV 使用同一决策规则，但不同观测仍可形成不同机动提案。这里的局部观测是仿真按信息合同提供的输入，不能把“Actor 分散执行”自动解释为信息无需上报或获取成本为零。

下层的 MC-ITR 快照求解和 SF-HLM 配额匹配均需要汇总当前请求与执行节点资源，评价一个完整分配。SF-HLM 的配额策略对请求–节点图执行集中搜索，与上层多个 UAV 分别采样动作的主体不同。因而本文的集群协同需要集中任务协调条件，尚未实现所有环节完全分布式自治。该架构利用两类决策的结构差异：位置规划适合通过多智能体局部输入输出组织，批量任务分配则通过共同负载状态识别跨请求影响。

在当前时序中，请求接纳和执行使用已有位置，随后应用机动动作形成后续位置。上层应从未来需求接纳及状态变化评价当前机动，而下层处理当前已经接纳的请求。第五章继续固定已学习上层，单独训练配额策略；上下层在环境运行中形成反馈联系，但没有据此宣称已经完成两层联合重训。明确这一结构后，强

化学习、注意力和匹配理论分别对应空间部署、信息聚合与任务资源分工，后续数学推导可以在同一集群任务规划框架中理解。

2.2 无人机辅助移动边缘计算基础

2.2.1 网络层次与请求执行位置

移动边缘计算把部分计算与存储能力部署在接近用户的位置，形成终端、边缘节点与中心服务之间的协作[2]。请求的完成过程包含数据进入、必要程序准备、计算执行和结果返回。改变计算位置可以减少某些处理环节的时间，也可能增加无线传输或回传成本。因此，“边缘更近”与“请求更快完成”不是同义关系，需要把完整路径上的代价写入评价。图 2.1 给出通用层次关系；本文进一步用移动 UAV 作为可接纳请求的空中边缘节点。

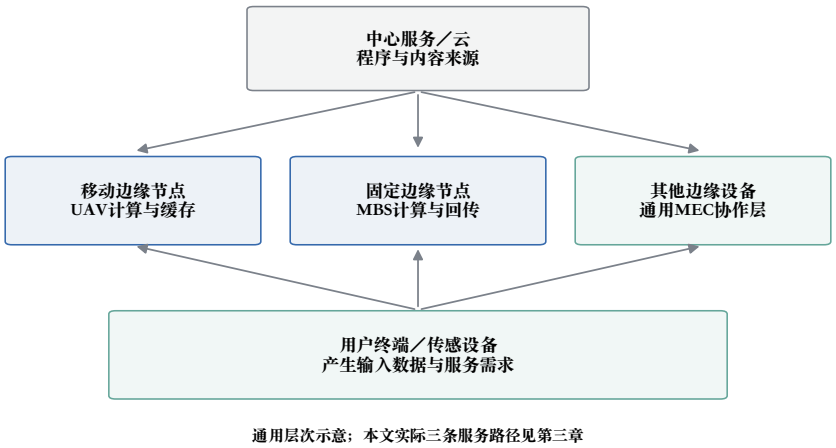


图 2.1 终端、边缘与中心服务之间的通用层次关系示意

本研究中的“本地执行”具有明确含义。通用 MEC 文献中的本地常指 UE 在自身处理器上计算，本文请求被 UAV 自然接纳之后，下层动作中的本地指接纳 *UAV* 本地计算。另两个类别是转移给协作 UAV 和卸载到 MBS。三类执行位置共享同一接纳前提，不能把选择 MBS 解释为 UE 无需进入 UAV 覆盖范围便直接得到服务。后续卸载比较均以已接纳请求为输入，而端到端 DSR 仍保留未接纳请求在分母中的影响。

设一个时隙的接纳服务请求集合为 $\mathcal{M}_t$，执行节点集合为 $\mathcal{J}$。请求 m 的输入字节数为 L_m，所需 CPU 总周期为 C_m，截止时间为 D_m，服务类别为 $s(m)$。若服务类型决定每字节所需周期数 ω_m，则

$$C_m = \omega_m L_m. \tag{2.4}$$

L_m 与 C_m 描述不同负担：较大的输入数据主要增加传输，较大的计算周期主要

增加处理时间；二者的比例不同，最合适的执行节点也可能不同。本文任务不可拆分，每个请求最终选择一个执行节点；部分卸载模型允许数据切分或并行子任务，属于另一种协议，不能与本文直接混用。

2.2.2　位置相关的无线通信与量纲转换

UAV 的水平位置记为 $\mathbf{q}_u(t)$，地面 UE 的水平位置记为 $\mathbf{w}_m(t)$。在 UAV 高度为 H_u 的几何模型下，UE 与 UAV 的三维距离为

$$d_{mu}(t) = \sqrt{\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2^2 + H_u^2}. \tag{2.5}$$

距离变化会影响信道功率增益，进而影响数据进入与任务转移的时延。UAV 辅助通信可以采用不同的传播模型[4]；本文后续仿真使用明确的自由空间路径损耗假设，不把地形遮挡、实测衰落或现实部署可靠性自动包含在该模型中。

在一个理想噪声受限链路中，带宽为 B、发送功率为 P、信道功率增益为 g、接收噪声功率为 σ^2 时，常用速率表达为

$$R = B \log_2 \left(1 + \frac{Pg}{\sigma^2}\right). \tag{2.6}$$

这里 B 的单位为 Hz，R 的单位为 bit/s。若输入数据以 byte 记录，数据传输时间必须使用

$$T_m^{\mathrm{tx}} = \frac{8L_m}{R}, \qquad E_m^{\mathrm{tx}} = PT_m^{\mathrm{tx}}. \tag{2.7}$$

因子 8 来自一个字节包含八个比特。遗漏该转换会把传输时间缩小八倍，从而同时改变截止期判断、能耗和卸载偏好。本文所有请求大小与链路速率均按此量纲关系处理；程序下载的字节数同样需要转换。

式 (2.6) 是瞬时链路模型。若多个请求共享带宽，必须由具体调度规则给出每个请求使用的有效速率；若传输包含多个顺序环节，则总时间是各段时间之和，而不是只取最强链路的速率。协作卸载可能同时包含 UE 到接纳 UAV 的接入、UAV 间传输和计算结果返回。MBS 卸载还可能包含回传。后续章节以环境实际执行路径为准计算总时延，不能以一个简化链路公式替代未计入的处理环节。

移动带来的通信改善与飞行成本也需要共同考虑。UAV 更接近某一热点可能提高接入速率和接纳比例，但移动同时消耗能量，并改变与其他节点的距离。一个位置对当前请求有利，不一定对后续请求或协作链路有利。轨迹控制因此具有跨时隙性质，而不仅是逐时隙寻找最短通信距离。图 2.2 用通用示意说明 UAV 的通信角色；本文具体关注其中移动边缘服务和多节点协作的部分。

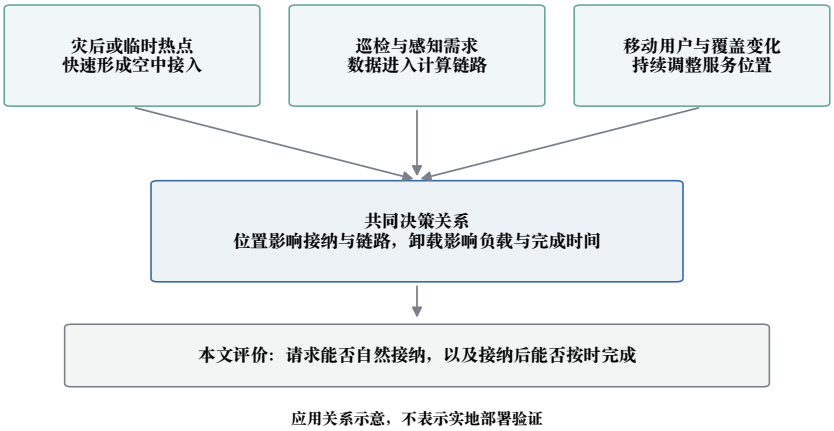


图 2.2　UAV 作为覆盖节点、中继与移动边缘服务器的应用关系示意

2.2.3　批量计算共享与缓存代价

计算节点的处理能力记为 F_j，单位为 CPU 周期每秒。对于分给节点 j 的最终批量请求数 N_j，若该节点采用等份共享，则每个请求分配的计算频率为 $f_{mj} = F_j/N_j$。请求 m 在节点 j 的计算时间为

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{f_{mj}} = \frac{C_m N_j}{F_j}, \qquad N_j \geqslant 1. \tag{2.8}$$

该式仅用于实际分配到节点的请求，不对 $N_j = 0$ 的空节点进行除法。本文 UAV 使用最终批量共享语义；MBS 的计算能力按环境协议处理，并不套用 UAV 的 F_j/N_j 规则。不同类型节点的差别需要在成本模型中显式保留。

采用动态 CPU 功耗模型时，处理器在频率 f 下的功率可写为 $P^{\mathrm{cmp}} = \kappa f^3$，其中 κ 为有效芯片电容系数。完成 C_m 个周期需要 C_m/f 的时间，故

$$E_{mj}^{\mathrm{cmp}} = \kappa f_{mj}^3 \frac{C_m}{f_{mj}} = \kappa C_m f_{mj}^2 = \kappa C_m \left(\frac{F_j}{N_j}\right)^2. \tag{2.9}$$

这个推导同时解释了负载对时延和模型能耗的不同影响：共享请求增多时，单请求计算时间随 N_j 增长，单请求动态能耗随 N_j^{-2} 下降。它不意味着增加负载在所有能源模型中都有利，而是本项目指定频率共享与动态功耗关系的结果。

设一个请求从 UAV i 迁往 UAV j。迁移不仅改变该请求的链路和处理时间，还把 N_i 减一、N_j 加一，因此改变两个节点上其他请求的 f_{mi} 或 f_{mj}。若这些请求接近截止时间，单次迁移可能使多个请求同时成功或失败。于是，整个分配的代价一般不能表示为一组与其他分配无关的固定单请求代价。这一批量外部影响是第四章整体重评估与第五章配额条件化匹配的共同动机。

缓存引入另一项执行条件。设服务程序 s 的字节数为 B_s，节点 j 对该程序的缓存指示为 $z_{js} \in \{0,1\}$。当 $z_{js} = 0$ 时，执行请求可能需要获取程序，典型顺

序下载时间为 $8B_s/R_j^{\mathrm{fetch}}$。如果程序已缓存，则相应获取环节可以减少。缓存容量约束可以一般地表示为

$$\sum_s z_{js} B_s \leqslant K_j, \tag{2.10}$$

其中 K_j 是节点存储容量。该式描述通用容量限制；后续实际缓存替换与提交规则以仿真实现为准。当前请求使用的缓存状态与本时隙末更新后的状态不能混淆，否则相当于提前使用未来信息。

2.2.4　覆盖、接纳与端到端指标

在水平服务半径 R_c 的模型下，请求所在 UE 满足 $\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2 \leqslant R_c$，才可能由 UAV u 接纳。感知半径 R_s 则决定策略允许获得哪些需求信息，两者承担不同作用。扩大 R_s 可以改变观测，不能自动把 R_c 之外的请求纳入执行。本文使用 $R_c = 100\,\mathrm{m}$ 与 $R_s = 460\,\mathrm{m}$，后续观测实验保持物理接纳半径不变。

设评估单元的成功数为 S、接纳数为 A、实际生成数为 G。当分母非零时，DSR、接纳率与条件完成率分别为 S/G、A/G 和 S/A。聚合多个时隙时，应先合并相应计数，再计算这些比值。例如，$\sum_t S_t / \sum_t G_t$ 一般不等于 $\frac{1}{T}\sum_t S_t/G_t$，因为后者给予每个时隙相同权重，前者给予每个请求相同权重。按训练块合并请求后再跨块平均，也与直接把全部块请求混为一个比值不同。本文根据预定协议使用对应聚合方式，并在图表中说明统计单位。

公平性需要说明它评价的是哪一种累计量。对于非负的每 UE 累计服务覆盖量 c_m，Jain 指数为

$$J = \frac{\left(\sum_{m=1}^{M} c_m\right)^2}{M \sum_{m=1}^{M} c_m^2}. \tag{2.11}$$

当所有 c_m 相同且至少一个非零时，$J = 1$；服务集中到少数 UE 时，该值下降。全部为零时公式的分母也为零，需要明确环境的约定，不能自行补出公平性的正面结论。本文公平性反映指定累计覆盖变量的均衡程度，不等于所有 UE 的截止期成功机会完全相同。

能源统计也必须保持主体一致。UAV 总能耗可以包含飞行、悬停、无线充电、服务计算、通信、回传或程序获取，以及内容处理等环节。分配能耗只覆盖其中与任务执行位置有关的非飞行部分。比较固定快照求解器时，位置固定，分配能耗便于观察卸载代价；比较闭环方法时，则应报告 UAV 总能耗。用前者替代后者，或把未计入的 MBS 能耗当作已经包含，会改变评价含义。

2.3 马尔可夫决策过程与长期目标

2.3.1 状态、动作与转移的定义

强化学习通过环境交互优化行为策略，其核心是动作对未来状态与回报的影响[23]。在离散时隙 t，智能体获得输入，选择动作 a_t，环境产生奖励 r_t 并转移到下一状态。图 2.3 展示基本交互关系。这里的奖励是训练信号，评价指标则是研究要报告的量；二者可以相关，但一个多项加权奖励的改善不自动证明每一项评价指标均改善。

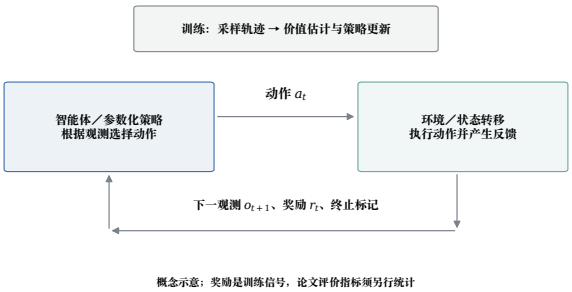


图 2.3 强化学习中的状态、动作、奖励与环境转移关系

一个有限时域 MDP 可记为 $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma, T)$：$\mathcal{S}$ 为状态空间，$\mathcal{A}$ 为动作空间，$P(s' \mid s, a)$ 为转移分布，r 为奖励机制，ρ_0 为初始状态分布，$\gamma \in [0, 1)$ 为折扣因子，T 为时域长度。状态包含预测下一步所需的信息，马尔可夫条件为

$$P(s_{t+1} \mid s_0, a_0, \cdots, s_t, a_t) = P(s_{t+1} \mid s_t, a_t). \tag{2.12}$$

若请求过程显式依赖时隙序号，有限时域状态还可包含时间。该条件属于环境状态层面，并不要求每个 UAV 的局部观测都能恢复完整状态。

策略 $\pi_\theta(a \mid s)$ 给出状态下的动作概率或概率密度，参数为 θ。离散动作满足概率和为一，连续动作密度在动作空间上积分为一。为简化记号，本章写作 $\sum_a$ 的表达在连续情形对应积分。需要动作合法性掩码时，策略的有效支持集随状态改变；只要在相同状态上比较旧、新策略，并正确保存采样时掩码，仍可以按相同支持计算概率比。若修改了动作语义或合法集合，则不能不加检查地复用原有比率。

UAV-MEC 的完整状态可以包括 UAV 与 UE 位置、能量、缓存、当前请求及运行阶段。执行策略通常只获得经过筛选和固定槽位编码的局部观测 $o_{u,t}$。相同观测可能对应不同的完整状态，因此其决策更接近部分可观测问题。使用历史 $h_{u,t} = (o_{u,0}, a_{u,0}, \cdots, o_{u,t})$ 可以提供额外信息；使用有限窗口或循环网络是近似处理方式，不能凭网络输入维度就宣称完全可观测。本文上层以当前预动作观测为输入，其适用信息合同由第三章明确给出。

2.3.2　折扣回报与值函数

为避免与请求生成计数 G 混淆，本章用 $\mathcal{G}_t$ 表示从时隙 t 开始的折扣回报：

$$\mathcal{G}_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k, \qquad \mathcal{G}_T = 0. \tag{2.13}$$

折扣因子决定未来奖励的相对权重。γ 接近一时，较远未来对当前动作更重要；较小的 γ 更强调近期效果。有限时域目标可在 $\gamma = 1$ 时定义，但后文涉及无限时域有界值与收缩性质时使用 $\gamma < 1$。本文实际超参数属于实验配置，不从数学定义推导其最优数值。

有限时域状态值与动作值分别为

$$V_t^{\pi}(s) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s], \tag{2.14}$$

$$Q_t^{\pi}(s,a) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s, a_t = a]. \tag{2.15}$$

V_t^{π} 对策略实际选择的动作取平均，Q_t^{π} 则固定当前动作后再遵循策略。有限时域下，即使状态相同，剩余时间不同也可以使价值不同，因此保留下标 t。若把时间并入状态，可使用不带显式时间下标的记号。神经网络 Critic 的输出是这些量的估计，不能预先当作真实期望。

从式 (2.13) 分离第一项得到 $\mathcal{G}_t = r_t + \gamma \mathcal{G}_{t+1}$。对下一状态和下一动作依次取条件期望，得到 Bellman 关系

$$Q_t^{\pi}(s,a) = \bar{r}(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{t+1}^{\pi}(s'), \tag{2.16}$$

$$V_t^{\pi}(s) = \sum_{a} \pi(a \mid s) Q_t^{\pi}(s,a), \qquad V_T^{\pi}(s) = 0, \tag{2.17}$$

其中 $\bar{r}(s,a)$ 为给定状态与动作的奖励期望。若奖励同时依赖下一状态，该期望包含对 s' 的积分。Bellman 关系连接当前奖励和未来价值，不要求即时奖励就是最终性能指标，也不意味着可以忽略请求执行后的状态变化。

优势函数定义为

$$A_t^{\pi}(s,a) = Q_t^{\pi}(s,a) - V_t^{\pi}(s). \tag{2.18}$$

它表示相对于当前策略在该状态的平均行为，特定动作的长期回报差异。由 V_t^{π} 的定义可得

$$\sum_{a} \pi(a \mid s) A_t^{\pi}(s,a) = 0. \tag{2.19}$$

正优势动作相对平均更好，负优势动作相对平均更差；“更好”是给定奖励与策略的比较，不能直接翻译成每个物理指标都变好。后续 Actor 更新使用估计优势，需要考虑 Critic 误差和采样波动。

2.3.3 动态规划性质与函数近似的边界

在已知模型的有限时域问题中，最优值可从终端条件向前递推：

$$V_t^*(s) = \max_a \left\{ \bar{r}(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{t+1}^*(s') \right\}. \tag{2.20}$$

该关系要求能够表示和计算状态、动作及转移。当联合动作数量巨大或转移模型复杂时，递推本身并不提供低成本的实际求解途径。深度强化学习通过样本与函数近似处理这些难点，其性质与已知有限表格模型中的精确动态规划不同。

对于有界奖励、平稳策略和无限折扣时域，定义策略 Bellman 算子 $\mathcal{T}^\pi$。任取两个有界函数 V, W，由于概率加权不会放大最大绝对差，有

$$|(\mathcal{T}^\pi V)(s) - (\mathcal{T}^\pi W)(s)| \leqslant \gamma \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s,a) |V(s') - W(s')| \tag{2.21}$$

$$\leqslant \gamma \|V - W\|_\infty, \tag{2.22}$$

从而 $\|\mathcal{T}^\pi V - \mathcal{T}^\pi W\|_\infty \leqslant \gamma \|V - W\|_\infty$。这一收缩性质解释精确策略评价的唯一固定点，但不保证使用神经网络、有限样本与并行策略更新的 MAPPO 必然收敛。论文应把可证明的算子性质与训练曲线描述分开。

实际 Actor–Critic 训练会改变策略，因此 Critic 的目标也随之变化。即使网络在某次更新中更贴近采样目标，也不等于接近全局最优策略。对 UAV-MEC，还存在部分可观测、环境状态编码、奖励尺度和随机需求等因素。本文采用固定预算、最后检查点、独立训练块与配对评估来检验最终行为，不用一条看似平滑的回报曲线替代最终策略验证。

2.4 策略梯度与 Actor–Critic 推导

2.4.1 轨迹概率与似然比求导

策略梯度直接优化参数化动作分布，适用于无法方便枚举全部动作的情形[13]。记一条交互轨迹为 $\xi = (s_0, a_0, r_0, \cdots, s_T)$，策略目标为

$$J(\theta) = \mathbb{E}_{\xi \sim p_\theta} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \tag{2.23}$$

假设初始分布和环境转移不直接依赖 θ，且可交换求导与积分。轨迹概率中与策略相关的部分来自各时隙动作概率，因此

$$p_\theta(\xi) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t \mid s_t) P(s_{t+1}, r_t \mid s_t, a_t), \tag{2.24}$$

$$\nabla_\theta \log p_\theta(\xi) = \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t). \tag{2.25}$$

第二式利用了环境项导数为零的条件。若环境本身也由同一参数控制，需要加入相应导数，不能沿用这里的简单形式。仿真奖励可以是随机量，只要其生成分布属于固定的环境条件即可。

令 $R(\xi) = \sum_t \gamma^t r_t$。使用 $\nabla p_\theta = p_\theta \nabla \log p_\theta$，得到

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\xi) R(\xi) \, \mathrm{d}\xi \tag{2.26}$$

$$= \mathbb{E}_{p_\theta} \left[R(\xi) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]. \tag{2.27}$$

这一表达不需要对环境转移求导。即使动作执行包含离散请求分配、位置裁剪或缓存更新，只要轨迹来自已定义的参数化策略和环境映射，也可以通过采样概率的导数构造估计。神经网络的可微性用于计算策略参数导数，并不要求仿真物理过程本身可微。

2.4.2　因果性与回报到达估计

完整轨迹回报包含动作之前的奖励，但当前动作不可能改变已经发生的事件。为形式化这一点，记动作前历史为 $\mathcal{H}_t$，对于 $k < t$，r_k 在给定 $\mathcal{H}_t$ 后已确定。对当前动作的条件期望满足

$$\mathbb{E}_{a_t \sim \pi_\theta} \left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) \mid \mathcal{H}_t \right] = \sum_a \nabla_\theta \pi_\theta(a \mid s_t) = \nabla_\theta 1 = 0. \tag{2.28}$$

所以式 (2.27) 中每个动作之前的奖励项，其梯度期望为零。删去这些只增加估计波动的项后，有

$$\nabla_\theta J(\theta) = \mathbb{E}_{p_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \sum_{k=t}^{T-1} \gamma^k r_k \right] \tag{2.29}$$

$$= \mathbb{E}_{p_\theta} \left[\sum_{t=0}^{T-1} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) \mathcal{G}_t \right]. \tag{2.30}$$

式中保留 γ^t，因为目标从时隙零开始折扣，而 $\mathcal{G}_t$ 从当前时隙开始折扣。若省略该因子，应说明采用了另一种采样加权或近似目标，不能在同一个有限时域证明中悄然改变定义。

再对固定 s_t, a_t 之后的未来轨迹取期望，可将 G_t 替换为 $Q_t^{\pi_\theta}(s_t, a_t)$：

$$\nabla_\theta J(\theta) = \mathbb{E}_{p_\theta}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) Q_t^{\pi_\theta}(s_t, a_t)\right]. \tag{2.31}$$

这就是有限时域策略梯度的基本形式。对于部分可观测策略，只要把策略条件改为其可用历史或观测，同样可以从轨迹概率推导得分函数估计；动作价值的条件期望也应随之调整，不能把局部观测当作未经验证的完整马尔可夫状态。

该推导给出期望梯度，而实际训练只拥有有限条轨迹。估计的方差可能来自随机请求、初始位置、策略采样和长期状态传播。UAV 轨迹的一个动作可能影响多个未来时隙的接纳条件，直接用整段回报更新会较为嘈杂。Actor–Critic 因此引入价值网络和优势估计，以在可控偏差与方差之间构造更有效的训练信号。

2.4.3 基线不偏性与优势形式

取一个只依赖动作前信息、而不依赖当前采样动作的基线 $b_t(s_t)$。利用式 (2.28)，其对梯度的期望贡献为

$$\mathbb{E}\left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) b_t(s_t) \mid s_t\right] \tag{2.32}$$

$$= b_t(s_t) \sum_a \pi_\theta(a \mid s_t) \nabla_\theta \log \pi_\theta(a \mid s_t) \tag{2.33}$$

$$= b_t(s_t) \nabla_\theta \sum_a \pi_\theta(a \mid s_t) = 0. \tag{2.34}$$

因此，从回报或动作值中减去该基线，不改变理想策略梯度的期望。连续动作使用积分得到相同结论。若基线由神经网络估计，Actor 更新时把它作为固定训练信号处理；不能把对基线参数的导数混入上述似然比证明。动作相关基线则不直接满足该恒等式，除非另有校正项。

选择 $b_t(s) = V_t^\pi(s)$，可以把动作值换成优势：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A_t^\pi(s_t, a_t)\right]. \tag{2.35}$$

这使 Actor 依据相对于状态平均表现的差异学习，减少一些由状态好坏本身造成的波动。价值函数是常用基线，但并不在所有条件下等于方差最小的基线；后者还与梯度向量的尺度有关。因此，本文只使用其不偏性和实用估计作用，不把它描述成普遍最优的方差消除方案。

Critic 用参数 ϕ 近似 V_t^π，训练目标可以来自实际回报或多步自举。若目标记为 $\widehat{V}_t$，基本均方损失为

$$L_V(\phi) = \frac{1}{2}\mathbb{E}\left[(V_\phi(s_t) - \widehat{V}_t)^2\right]. \tag{2.36}$$

Actor 与 Critic 的作用不同：前者优化动作概率，后者拟合用于估计的目标。Critic 损失降低可以意味着拟合更好，但不保证 Actor 的最终 DSR 上升；反过来，价值目标随策略变化时，损失短期升高也不必然代表策略性能恶化。后续训练图须按各自物理含义解释。

2.5　时序差分与广义优势估计

2.5.1　一步时序差分与多步自举

一步时序差分（Temporal Difference，TD）将当前奖励与下一状态价值组成目标。对非终止转移定义

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t). \tag{2.37}$$

如果 V_ϕ 等于真实策略值，给定当前状态和动作的 δ_t 条件期望就是 A_t^π，因为式 (2.16) 的未来期望恰好给出动作值。若 Critic 不准确，TD 目标会包含自举误差；其代价是偏差，优点是无需等待完整回合结束即可获得训练信号。

在不存在中间终止的 n 步窗口内，多步目标与优势估计可以写成

$$\widehat{V}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l r_{t+l} + \gamma^n V_\phi(s_{t+n}), \tag{2.38}$$

$$\widehat{A}_t^{(n)} = \widehat{V}_t^{(n)} - V_\phi(s_t) = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}. \tag{2.39}$$

最后一个等号来自相邻价值项的消去：$\gamma V(s_{t+1})$ 与下一项中的 $-\gamma V(s_{t+1})$ 相抵，依次只留下窗口末端的自举值。n 增大时使用更多真实奖励，通常减少对近端 Critic 的依赖，但也引入更多随机未来变化；这构成多步估计的基本取舍。

真正终止和采样截断不能混为一类。真正终止表示目标任务已经结束，之后没有应计入回报的状态价值；采样截断只表示当前缓冲区或记录窗口到此结束，环境过程可能继续。如果为了收集固定长度 rollout 而截断，却把后续价值强行设为零，会系统性改变窗口末端的估计。另一方面，若一个回合按任务定义在第 T 步结束，则该有限时域终点本身可以是真正终止，不应因为代码称其为 time limit 就机械地自举。

2.5.2　GAE 的加权推导

广义优势估计（Generalized Advantage Estimation，GAE）将多步优势进行指数加权[24]。设当前非终止窗口剩余 K 步，$\lambda_{\mathrm{GAE}} \in [0, 1]$，有限窗口的加权形式

为

$$\widehat{A}_t^{\mathrm{GAE}} = (1-\lambda_{\mathrm{GAE}}) \sum_{n=1}^{K-1} \lambda_{\mathrm{GAE}}^{n-1} \widehat{A}_t^{(n)} + \lambda_{\mathrm{GAE}}^{K-1} \widehat{A}_t^{(K)}. \tag{2.40}$$

最后一项吸收窗口之后的剩余权重，使有限混合的权重和为一。若遗漏这一项，估计在有限窗口中会发生额外缩放。$\lambda_{\mathrm{GAE}} = 0$ 时只保留一步估计，$\lambda_{\mathrm{GAE}} = 1$ 时只保留最长窗口的多步估计，端点按相应极限理解。

将式 (2.39) 代入上述混合，观察 δ_{t+l} 的系数：它出现在所有 $n \geqslant l+1$ 的估计中，因此对应权重为

$$\gamma^l \left[(1-\lambda_{\mathrm{GAE}}) \sum_{n=l+1}^{K-1} \lambda_{\mathrm{GAE}}^{n-1} + \lambda_{\mathrm{GAE}}^{K-1} \right] \tag{2.41}$$

$$= \gamma^l \lambda_{\mathrm{GAE}}^l. \tag{2.42}$$

从而得到常用的残差和形式

$$\widehat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{K-1} (\gamma \lambda_{\mathrm{GAE}})^l \delta_{t+l}. \tag{2.43}$$

这一推导说明 GAE 的两个衰减来源：γ 来自优化目标对未来的折扣，λ_{GAE} 来自估计器对较长残差链的权重。它们不能互相替代，也不是物理请求截止时间的同义参数。

若 $\lambda_{\mathrm{GAE}} = 1$，窗口内残差累加后得到实际折扣奖励加末端自举值，再减当前价值；若窗口在真实终端结束，末端价值为零，便得到回报减基线。若 $\lambda_{\mathrm{GAE}} < 1$，中间价值估计更明显地进入结果，可能降低方差，也可能保留价值近似偏差。因而，GAE 不是无条件消除偏差的技巧，应与 Critic 精度、窗口长度和任务随机性一起理解。

2.5.3 终止掩码与递推实现

为兼容不同边界，定义自举掩码 b_t 与递推连接掩码 c_t。$b_t = 0$ 表示该转移真正终止，否则为一；$c_t = 1$ 表示缓冲区下一条记录属于同一连续轨迹、可以继续累计其优势，否则为零。相应 TD 残差与反向递推为

$$\delta_t = r_t + \gamma b_t V_\phi(s_{t+1}) - V_\phi(s_t), \tag{2.44}$$

$$\widehat{A}_t = \delta_t + \gamma \lambda_{\mathrm{GAE}} c_t \widehat{A}_{t+1}. \tag{2.45}$$

在真实终端，$b_t = c_t = 0$；在仅因采样长度而截断的末端，可以取 $b_t = 1, c_t = 0$，用截断前的实际后继状态估计价值，但不跨到下一批未知记录递推；在正常连续转移中二者均为一。价值自举与优势连接的分工避免了跨回合泄漏。

递推展开为

$$\widehat{A}_t = \sum_{l=0}^{K-1} (\gamma\lambda_{\mathrm{GAE}})^l \left(\prod_{i=0}^{l-1} c_{t+i} \right) \delta_{t+l}, \tag{2.46}$$

空乘积取一。只要某个连接掩码为零，后续残差对当前优势的贡献就停止。实现时通常从缓冲区末端向前扫描，维护一个累计量；真正终止状态的后继值为零，截断状态则应使用结束前真实 observation，而不是 reset 之后的新回合初始 observation。

GAE 计算完成后，可以用 $\widehat{V}_t = V_{\phi_{\mathrm{old}}}(s_t) + \widehat{A}_t$ 形成 Critic 目标。该目标与采样时价值一同固定，避免在多个 PPO epoch 内目标随正在更新的网络任意变化。优势标准化常用于改善优化尺度，但标准化不把随机环境变为确定环境，也不保证减少每一次更新的估计误差。本文使用相应实现与针对性验证确保终止、回报和概率记录一致，不以算法名称替代这些边界检查。

2.6　近端策略优化与动作概率一致性

2.6.1　重要性比率与旧策略采样

策略梯度的期望由当前策略产生，但一次交互采样后，策略更新会使缓冲区来自旧策略 $\pi_{\theta_{\mathrm{old}}}$。对于固定状态 s，若新策略支持集包含于旧策略有效支持集，则

$$\mathbb{E}_{a\sim\pi_\theta}[f(s,a)] = \mathbb{E}_{a\sim\pi_{\theta_{\mathrm{old}}}}\left[\rho_\theta(s,a) f(s,a)\right], \qquad \rho_\theta(s,a) = \frac{\pi_\theta(a \mid s)}{\pi_{\theta_{\mathrm{old}}}(a \mid s)}. \tag{2.47}$$

该恒等式只校正固定状态下动作分布的变化，并未自动校正新策略产生的状态分布。因此，直接在旧 rollout 上使用一次动作比率，是局部代理目标的构造，不是完整新策略回报的无偏估计。若对整条轨迹做完全重要性校正，需要多个时隙比率乘积，通常会产生较大方差。

PPO 使用旧策略状态动作样本与固定优势，构造可重复优化的目标[25]。为了数值稳定，概率比率通常由 log probability 之差计算：

$$\rho_t(\theta) = \exp\left[\log \pi_\theta(a_t \mid s_t) - \log \pi_{\theta_{\mathrm{old}}}(a_t \mid s_t)\right]. \tag{2.48}$$

旧概率必须对应实际采样时的策略参数、观测、动作和掩码，不能在更新过程中用新网络重新计算后冒充旧概率。首次更新之前，旧、新网络相同，合法样本的比率应接近一；这可以作为概率记录一致性的一个诊断，而不是最终性能证据。

2.6.2 裁剪目标及其分段含义

设裁剪系数为 $\varepsilon > 0$，PPO 的裁剪代理目标为

$$L_{\text{clip}}(\theta) = \mathbb{E}_{\text{old}}\left[\min\left(\rho_t(\theta)\widehat{A}_t, \text{clip}(\rho_t(\theta), 1-\varepsilon, 1+\varepsilon)\widehat{A}_t\right)\right]. \tag{2.49}$$

优势在 Actor 更新时视为固定。取最小值的目的，是在动作概率朝有利方向变化过多时移除进一步增加代理收益的激励，而不是把所有比率数值直接投影到指定区间。

对于单个样本，令 $\ell(\rho, \widehat{A})$ 为括号内的量。根据优势符号，有

$$\ell(\rho, \widehat{A}) = \begin{cases} \widehat{A}\min(\rho, 1+\varepsilon), & \widehat{A} \geqslant 0, \\ \widehat{A}\max(\rho, 1-\varepsilon), & \widehat{A} < 0. \end{cases} \tag{2.50}$$

当 $\widehat{A} > 0$ 时，增加动作概率能提高代理收益，但比率超过 $1+\varepsilon$ 后这一项进入平台；当 $\widehat{A} < 0$ 时，降低动作概率有利，但比率低于 $1-\varepsilon$ 后平台阻止该项继续受益。若变化方向使样本表现更差，目标仍保留惩罚。这是裁剪和最小操作必须共同出现的原因。

PPO 裁剪不能保证所有动作的概率比率始终位于区间内。共享网络的一次更新会同时改变许多未被采样动作的概率，也会受到其他样本和熵项的梯度影响。即使某个样本项进入平台，该动作仍可能因其他梯度变化。因而，裁剪目标不是严格的 KL 散度约束，也不提供无条件单调性能提升。实际实现还可监测近似 KL、裁剪比例和梯度范数，以发现更新过大或数值异常，但监测本身不等于理论约束被满足。

策略熵可以作为探索项。离散分布的熵为

$$\mathcal{H}(\pi) = -\sum_{a \in \mathcal{A}(s)} \pi(a \mid s)\log\pi(a \mid s). \tag{2.51}$$

常用 Actor 目标为最大化 $L_{\text{clip}} + c_H\mathbb{E}[\mathcal{H}]$，其中 $c_H \geqslant 0$。Critic 则最小化均方或相应裁剪值损失。熵项鼓励动作分布保持一定分散度，但更高熵不意味着物理随机策略更好；训练中的探索与评价时的动作使用规则需要分别说明。

2.6.3 连续提案、执行映射与离散掩码

对于二维轨迹，Actor 可输出均值 $\boldsymbol{\mu}_\theta(o)$ 与标准差 $\boldsymbol{\sigma}_\theta(o)$，从对角 Gaussian 分布采样原始动作 a。其 log probability 为

$$\log\pi_\theta(a \mid o) = -\frac{1}{2}\sum_{d=1}^{2}\left[\frac{(a_d - \mu_d)^2}{\sigma_d^2} + 2\log\sigma_d + \log(2\pi)\right]. \tag{2.52}$$

如果环境把原始动作裁剪、缩放或进行边界与碰撞消解，实际执行动作是 $a^{\text{exec}} = \mathcal{E}(s, a)$。该映射可以多对一，并不保持 Gaussian 密度。策略梯度仍可针对原始提

案策略定义，把执行映射视为环境的一部分；前提是 PPO 保存并比较同一个原始 a 的采样概率。

将裁剪后的 a^{exec} 重新代入原始 Gaussian 密度，并把它当作原始动作概率，会改变采样对象。特别是多个超出边界的提案被映射到同一边界值时，执行动作分布不再是原 Gaussian。本文后续算法描述以原始提案和原始 log probability 为准，执行可行性由环境映射处理。这种记录方法确保概率比率的含义一致，但不说明策略网络本身满足所有几何约束。

对于离散卸载或配额迁移，设网络 logits 为 z_a，状态对应的合法动作掩码为 $M_a \in \{0,1\}$，则掩码后的分布为

$$\pi_\theta(a \mid s, \boldsymbol{M}) = \frac{M_a \exp(z_a)}{\sum_b M_b \exp(z_b)}. \tag{2.53}$$

实现需要保证至少存在一个合法动作，例如协议允许的保底动作或停止动作，否则分母为零。非法动作概率为零，合法动作之间重新归一化。训练使用采样时的 $\boldsymbol{M}$，不能在一个已改变负载的搜索状态上重建掩码后拿来比较原动作概率。

动作掩码屏蔽物理或协议不可行选择，而能耗筛选、最好方案保留或普通修复是另外的操作。它们可以改变最终执行分配，却不应事后改写策略曾采样的配额动作或其概率。第五章因此区分当前搜索状态、策略提案、候选分配和最好保留分配；这一分工既有利于处理有限预算搜索，也使 PPO rollout 对应明确的训练过程。

2.7　多智能体协作与 MAPPO

2.7.1　联合状态与局部观测

协作多智能体问题可以用分散式部分可观测马尔可夫决策过程描述。设智能体集合为 $\mathcal{U} = \{1, \cdots, N\}$，联合状态为 s_t，局部观测由 $o_{u,t} = \mathcal{O}_u(s_t)$ 或对应观测分布生成，联合动作为 $\boldsymbol{a}_t = (a_{1,t}, \cdots, a_{N,t})$。环境根据整个联合动作转移，并返回团队奖励或各智能体奖励。全局转移满足马尔可夫性时，从局部观测出发的单个智能体仍可能面对部分可观测问题；如果其他策略同步更新，其经验的生成过程还会出现训练非平稳性[26]。

条件独立的分散式 Actor 可以把联合策略因子化为

$$\boldsymbol{\pi}_\theta(\boldsymbol{a}_t \mid \boldsymbol{h}_t) = \prod_{u=1}^{N} \pi_{\theta_u}(a_{u,t} \mid h_{u,t}), \tag{2.54}$$

其中 $h_{u,t}$ 是各智能体允许使用的历史，当前观测策略是其特例。条件独立指给定各自输入后的动作采样方式，并不意味着动作对环境的影响独立。多架 UAV 的

动作可以通过覆盖边界、最小间距和共享计算资源发生强耦合。

联合动作空间随智能体数量变化。若每个智能体有 K 个离散动作，联合动作数是 K^N；连续动作则形成更高维联合空间。参数共享不改变这种环境组合结构，但可以减少模型中重复的可训练参数。同类型 UAV 共享 θ 时，不同局部状态仍产生不同分布；其经验共同贡献梯度。若异质节点承担不同功能，是否共享、是否引入身份或能力特征需要根据具体实现决定，而不是将参数共享作为所有 MARL 方法的必选条件。

训练非平稳性的原因可以写得更具体。对固定智能体 u，其看到的有效转移包含其他智能体策略的平均：

$$P_u^{\pi_{-u}}(s' \mid s, a_u) = \sum_{\boldsymbol{a}_{-u}} \pi_{-u}(\boldsymbol{a}_{-u} \mid \boldsymbol{h}_{-u}) P(s' \mid s, a_u, \boldsymbol{a}_{-u}). \tag{2.55}$$

当 π_{-u} 变化时，该有效过程变化。全局状态转移模型未必因此失去马尔可夫性，但单个策略从旧样本中估计当前环境的难度增加。集中训练能够使用更多信息缓解估计困难，却不能保证完全消除这种变化或信用分配问题。

2.7.2 CTDE 与联合观测价值网络

CTDE 区分训练信息与执行信息。训练时 Critic 可以访问联合观测、全局状态或规定的协作信息；执行时 Actor 必须使用其信息合同允许的输入。MADDPG 与 MAPPO 分别展示了集中价值估计用于多智能体训练的不同方式[17-18]。这一范式不意味着现实系统可以免费获得联合状态，也不意味着所有策略输出都属于分散式执行。若在线模块要汇总当前请求后求解一次中央分配，就应明确其集中协调需求。

本文上层的联合观测记为 $O_t = (o_{1,t}, \cdots, o_{N,t})$，共享 Critic 的输出形式为

$$\boldsymbol{V}_\phi(O_t) = (V_{\phi,1}(O_t), \cdots, V_{\phi,N}(O_t)) \in \mathbb{R}^N. \tag{2.56}$$

每个 UAV 获得对应价值估计，网络通过联合输入建模相互关系。共享参数不要求输出只有一个全局标量，也不要求每个输出使用完全相同的局部回报。实际奖励是否共享、价值目标如何生成，需要与 rollout 数据结构一致。第三章说明本文上层输入和训练设置，第五章配额策略则以一个完整请求图作为集中搜索状态，其动作主体与上层多 UAV Actor 不同。

团队奖励下，因子化策略的 log probability 满足

$$\nabla_\theta \log \boldsymbol{\pi}_\theta(\boldsymbol{a} \mid \boldsymbol{h}) = \sum_{u=1}^{N} \nabla_\theta \log \pi_\theta(a_u \mid h_u) \tag{2.57}$$

（共享参数时）。代入策略梯度，可把各 UAV 的得分函数贡献相加。价值基线可以利用动作之前的联合信息，只要在对应条件下不依赖当前被求导动作，就保留

基线不偏性的基本逻辑。实际按智能体划分的优势是近似估计，集中 Critic 提供训练信号，不构成对个体因果贡献的精确分解。

2.7.3　MAPPO 的局部比率与更新流程

MAPPO 采用 PPO 类代理目标训练协作策略[18]。对于每个 UAV 的样本，定义局部比率

$$\rho_{u,t}(\theta) = \frac{\pi_\theta(a_{u,t} \mid o_{u,t})}{\pi_{\theta_{\text{old}}}(a_{u,t} \mid o_{u,t})}. \tag{2.58}$$

常用的共享 Actor 代理目标在智能体与时隙上平均：

$$L_{\text{MAPPO}}(\theta) = \frac{1}{NT} \sum_{u,t} \min\left(\rho_{u,t}\widehat{A}_{u,t}, \text{clip}(\rho_{u,t}, 1-\varepsilon, 1+\varepsilon)\widehat{A}_{u,t}\right). \tag{2.59}$$

其中 T 在此表示采样批次包含的时隙数，实际实现还会对批次和有效样本作平均。各智能体价值目标来自对应回报和联合 Critic，Actor 则分别以局部观测重算提案概率。

联合策略概率比率为 $\rho_{\text{joint},t} = \prod_u \rho_{u,t}$。逐智能体裁剪式 (2.59) 与先计算联合比率再裁剪不是同一个目标；即使每个局部比率靠近一，多个比率的乘积也可能明显变化。因此，不能把局部裁剪描述成联合策略 KL 的硬上界。共享参数更新还会同时影响所有 UAV，这要求控制 epoch、学习率和 minibatch 等配置，并观察实际训练行为。

一次完整训练循环包括固定当前策略采集 rollout，保存每个 UAV 的局部观测、原始动作、log probability、价值估计、奖励和边界标记；利用同一采样批次计算 GAE 与 Critic 目标；在旧概率保持不变的条件下进行多个优化 epoch；更新完成后再采集下一批经验。这样可以把旧策略采样与当前优化区分开。若上下层都学习，改变另一层会改变环境反馈，因此还需要定义更新顺序和策略冻结条件。本文最新主线冻结上层基座，避免把额外下层训练误写成已验证的两层联合重训。

2.8　注意力聚合与图表示

2.8.1　查询、键和值的计算

注意力把元素间的相关性转化为聚合权重[22]。设查询、键和值矩阵分别为 $Q \in \mathbb{R}^{n_q \times d_k}$、$K \in \mathbb{R}^{n_k \times d_k}$ 和 $V \in \mathbb{R}^{n_k \times d_v}$，缩放点积注意力为

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}} + M\right)V. \tag{2.60}$$

M 为加性掩码，合法项为零，非法项在数学表达中为负无穷；softmax 沿键的维度计算。每一行权重非负且和为一，因此输出是值向量的加权组合。查询与键决定权重，值承担被聚合的信息，三者的功能不同。

缩放因子的作用可以从点积方差说明。假设各 q_i, k_i 零均值、方差为一，同一维度内 q_i 与 k_i 相互独立，且不同维度的变量对 (q_i, k_i) 相互独立，则

$$\mathrm{Var}(q^{\mathsf{T}}k) = \mathrm{Var}\left(\sum_{i=1}^{d_k} q_i k_i\right) = d_k. \tag{2.61}$$

因此除以 $\sqrt{d_k}$ 后，点积标准差的量级不再随维度平方根增大。对于 softmax 权重 α_i，其导数 $\partial\alpha_i/\partial z_j = \alpha_i(\mathbb{I}\{i=j\} - \alpha_j)$；若 logits 差距过大，权重可能过早接近零或一，导数变小。缩放改善这种数值量级，但真实特征并不必然独立同分布，故它是合理的结构设计，不是避免所有饱和的保证。

多头注意力使用不同投影建立多个表示子空间：

$$H_h = \mathrm{Att}(QW_h^Q, KW_h^K, VW_h^V), \tag{2.62}$$

$$\mathrm{MHA}(Q,K,V) = \mathrm{Concat}(H_1, \cdots, H_H)W^O. \tag{2.63}$$

式中的 H 在此表示注意力头数，仅在本小节使用；几何高度仍写为 H_u。如果总隐空间为 d 且每头等宽，单头键维度为 $d_k = d/H$，缩放分母应使用单头的 $\sqrt{d/H}$。本文上层 $d = 64$、头数为 8 时，单头宽度为 8，不能误用 $\sqrt{64}$ 作为每头点积的分母。

2.8.2 局部查询、掩码与排列性质

在 UAV 上层观测中，自身状态经过嵌入后可作为查询，邻居 UAV 和 UE 槽位分别提供键和值。邻居表示包含协作几何关系，UE 表示包含位置、请求和能量等允许信息，两个聚合结果再与自身特征融合。固定槽位中的空元素需要掩码，否则补零槽位也会参与归一化，影响有效元素权重。注意力改变的是聚合方式，并未自动减少原始观测维度，也没有自动增加感知范围。

全空键集合是一个必须处理的边界。若一行所有 logits 都为负无穷，softmax 的归一化不再有有效分母。实现可以为这种情况定义零上下文或专门空状态，并让后续网络识别“没有可见元素”。该约定应与训练和执行一致，避免出现 NaN 后再把结果无条件修成任意数值。实际 UAV 的邻居或 UE 槽位数量变化时，掩码和有效计数同样需要对应，不应把填充容量误认为实际用户数量。

对于固定查询的纯加权聚合，若键和值同时按同一置换矩阵 P 重排，$K' = PK, V' = PV$，则

$$\mathrm{softmax}(QK'^{\mathsf{T}})V' = \mathrm{softmax}(QK^{\mathsf{T}})P^{\mathsf{T}}PV = \mathrm{softmax}(QK^{\mathsf{T}})V. \tag{2.64}$$

这里省略缩放和同步重排的掩码以突出排列关系。该性质要求不额外引入与序号相关的编码；完整系统还包含排序、截断、分组和其他特征，因此不能从这一局部式子推断整个策略对所有观测处理均排列不变。UE 选择规则本身可能决定哪些需求进入有限槽位，是第三章观测研究的重要部分。

一个自身查询聚合 n 个元素时，注意力权重计算约为 $O(nd_k)$；若对全部元素使用自注意力，则点积关系数量约为 n^2。线性投影、网络宽度、多个头和实际批次还带来其他成本。本文不从这类运算量估计直接推出软件实时性，而在第五章测量完整策略调用。相同地，权重热图可以描述某次输入的聚合分布，却不能单独说明该元素对最终 DSR 的因果贡献。

2.8.3　请求–节点二部图与消息传递

请求卸载可以表示成二部图 $\mathcal{G} = (\mathcal{M}, \mathcal{J}, \mathcal{E})$。请求节点携带数据大小、计算周期和截止时间等特征，执行节点携带能力、当前负载和配额等特征；边 (m, j) 描述请求与节点之间的合法性、通信条件、缓存信念和预测处理代价。与把全部信息平铺成一个长向量相比，二部关系保留了“某个请求在哪个节点执行”的具体结构，但其性能仍取决于特征与训练。

一种通用消息传递写法为

$$\boldsymbol{h}_m^{(l+1)} = f_{\mathcal{M}}\left(\boldsymbol{h}_m^{(l)}, \sum_{j:(m,j)\in\mathcal{E}} g_{\mathcal{M}}(\boldsymbol{h}_m^{(l)}, \boldsymbol{h}_j^{(l)}, \boldsymbol{e}_{mj})\right), \tag{2.65}$$

$$\boldsymbol{h}_j^{(l+1)} = f_{\mathcal{J}}\left(\boldsymbol{h}_j^{(l)}, \sum_{m:(m,j)\in\mathcal{E}} g_{\mathcal{J}}(\boldsymbol{h}_m^{(l)}, \boldsymbol{h}_j^{(l)}, \boldsymbol{e}_{mj})\right). \tag{2.66}$$

f 与 g 是可学习映射，聚合也可以使用均值或注意力。这里给出表示原理，不把该通用形式当作第五章所有层的逐行实现。第五章将根据 CompleteQuotaPPO 的实际编码说明请求、节点、边及当前/最好状态如何输入网络。

对配额搜索，当前分配与最好保留分配承担不同作用。前者决定下一次迁移从哪里出发，后者决定最终执行什么方案；若只编码最好状态，策略可能无法判断当前配额的可迁移范围。剩余预算与停止动作也会影响决策目标：同一个请求图在搜索早期与预算耗尽前的最优选择可能不同。完整搜索状态需要包含协议要求的信息，不能只在论文中画一张二部图便假定搜索过程天然满足马尔可夫性。

2.9 指派匹配与配额条件化优化

2.9.1 不可拆分请求的指派形式

设 $x_{mj} \in \{0,1\}$ 表示请求 m 是否分配给节点 j，每个已接纳请求必须有一个目的地，且只能使用合法边。对于给定节点配额 N_j，约束为

$$\sum_{j \in \mathcal{C}_m} x_{mj} = 1, \qquad \sum_{m \in \mathcal{M}} x_{mj} = N_j, \qquad \sum_{j} N_j = |\mathcal{M}|. \tag{2.67}$$

$\mathcal{C}_m$ 表示请求的合法目的地集合，与 CPU 周期 C_m 区分。若某配额导致合法边无法形成完整指派，则该条件化问题不可行，需要按搜索协议拒绝候选或使用保底方案；不能用丢弃难请求的方式悄然恢复可行性。

在 N_j 固定后，式 (2.8) 的节点共享频率已经确定，可将预测时延与能耗写成给定条件下的边代价 $c_{mj}(\boldsymbol{N})$。把节点 j 展开成 N_j 个槽位，每个槽位继承相同的合法边及成本，问题转化为请求与槽位的一一指派：

$$\min_{x} \sum_{m,j} c_{mj}(\boldsymbol{N}) x_{mj} \quad \text{满足式 (2.67).} \tag{2.68}$$

该转化解决的是给定配额、给定预测模型下的子问题。原完整分配还需要选择配额，其边成本随配额改变；因此，条件化指派的精确性不能直接升级成原组合问题的全局最优性。

2.9.2 截止期优先的代价编码

若首要目标是减少预测超时，其次降低预测能耗，可以构造有界的字典序编码。设请求数为 n，每条合法边的缩放能耗 $\widetilde{E}_{mj} \in [0,1]$，定义

$$c_{mj} = (n+1)\mathbb{I}\{\widehat{T}_{mj} > D_m\} + \widetilde{E}_{mj}. \tag{2.69}$$

任意完整指派的缩放总能耗介于零与 n 之间。若一种指派比另一种少一个预测超时，其超时代价至少减少 $n+1$；即使能耗项增加到允许最大差 n，总编码代价仍下降至少一。因此，最小化该代价先最小化预测超时数，再在相同超时数中比较缩放能耗。

上述优先性依赖缩放区间确实有界，而且同一条件化问题内保持一致。若改用无界能耗或为不同候选任意更换尺度，就不能继续使用同一证明。真实截止期成功还可能受缓存信念与实际执行差异影响，因此 $\widehat{T}$ 的优先优化不等于真实成功数必然改善。本文在快照与闭环评价中核对预测和实际结果，并报告偏差，而不把预测目标当作实验成功的替代指标。

共同贪心参照下的能耗上限属于候选筛选条件。先对某配额求出无能耗约束的最佳指派，再检查其是否低于上限，并不等价于直接求解带能耗约束的全局

最优指派；如果该指派被拒绝，仍可能存在该配额下另一种较高超时代价但满足能耗上限的方案。第五章因此把匹配求解与能耗筛选分别说明，不赋予二者组合未经证明的最优保证。

2.9.3　配额搜索、最好保留与有限预算

配额迁移保持总请求数不变。若从节点 i 向节点 j 转移 k 个任务，候选满足

$$N_i' = N_i - k, \qquad N_j' = N_j + k, \qquad N_h' = N_h\ (h \neq i, j), \qquad N_i' \geqslant 0. \tag{2.70}$$

策略只提出负载数量的变化，实际请求身份由条件化匹配决定。这比直接枚举每个请求的全部目的地组合紧凑，但并未消除配额组合空间，也不保证有限预算能找到最优配额。不同的步长、入口、去重和停止条件决定搜索行为，应通过同预算对照评价。

最好方案保留允许搜索访问合法但较差的中间状态，同时防止最终执行方案被该状态直接替换。当前状态用于探索，最好状态按预定比较规则更新；预算耗尽或策略停止后执行保留方案。若初始方案合法，且更新只接受合法并满足筛选条件的完整分配，则该保留规则可以确保最终方案具有对应可行性。它保证的是协议维持的性质，而不是每个时隙的 DSR 都比其他算法高，也不是全局最优。

固定请求图内的搜索训练与长期环境训练的回报不同。搜索可以用候选预测目标或快照真实评价构造信号，长期闭环则还包含电池、缓存与未来轨迹变化。学习配额策略的额外收益必须在完整环境中确认；同时，它与随机配额策略共享的匹配、修复和保留框架应固定。这样才能把完整下层优化包有效与学习搜索有效分别检验，而不是让较弱随机动作承担所有机制解释。

2.10　随机实验与证据解释基础

强化学习实验的随机性来自模型初始化、策略采样和外生需求。独立训练块是不同训练过程产生的模型重复；同一模型上的多个工作负载、回合、时隙和请求则属于嵌套评价。增加这些评价可以更准确地估计该模型的行为，但不能把它们都视为独立训练样本。非学习方法没有训练模型，其随机流重复也需要按实际含义命名。本文以这种区分组织后续图表中的 n。

在预定配对设计中，先在训练块内聚合各方法对应的工作负载与回合，得到块级指标 $Y_{b,1}$ 和 $Y_{b,0}$，再计算差值 $d_b = Y_{b,1} - Y_{b,0}$。均值差与样本标准差为

$$\bar{d} = \frac{1}{n}\sum_{b=1}^{n} d_b, \qquad s_d^2 = \frac{1}{n-1}\sum_{b=1}^{n}(d_b - \bar{d})^2. \tag{2.71}$$

训练块配对 t 区间为 $\bar{d} \pm t_{0.975,n-1} s_d/\sqrt{n}$。其解释依赖独立块与相应统计假设；小

样本或临界结果还可以使用预定的符号翻转等敏感性检查。区间跨零表示当前数据未确认所述差异，不等于两个方法在所有条件下相同。

多个预定比较需要控制所使用的检验族。Holm 校正按 p 值由小到大依次比较 $\alpha/(m-i+1)$，在第一个未通过的位置停止后续拒绝，从而控制该族的家族错误率。主性能比较、机制比较和后来登记的新随机比较承担不同科学问题，应按原合同分别报告。不能事后把有利比较从原族拿出，或者只增加不影响结论的对手来改变校正结果。

固定检查点、预定评价协议和全部样本保留对于可靠比较同样重要。训练中间出现最高评价点，可能包含检查点筛选对评价负载的适配；若把它替换为正式主结果，需要另行定义筛选与独立确认。本文主线保持冻结模型、来源摘要与明确最后检查点，开发诊断用于方法选择，独立确认用于主要性能论证。训练曲线、快照改善和长期指标分别承担不同证据作用，不以任何单一图替代完整验证。

2.11 本章小结

本章从无人机集群的任务分工、轨迹规划与飞行执行层次出发，明确本文采用固定高度二维机动、离散位置可行性修复和集中任务协调的研究范围。空间部署影响后续请求接纳，批量执行影响机载资源状态，两者共同形成集群服务的时序耦合。在这一框架下，UAV-MEC 的位置相关通信、字节与比特转换、最终批量计算共享、缓存获取和自然接纳共同影响请求成功。随后推导有限时域值函数、Bellman 关系和策略梯度，证明动作无关基线在相应条件下不改变理想梯度期望，并给出 GAE 的多步混合、终止掩码与递推实现。PPO 的裁剪目标提供局部代理优化方式，其概率记录必须与原始提案和采样掩码一致，不能被描述为严格 KL 或收敛保证。

多智能体部分区分全局状态、局部观测与集中价值估计，说明共享 Actor 和联合观测多输出 Critic 的作用。注意力提供输入元素的加权聚合，二部图与条件化指派提供请求分配的结构表示，两者都需要通过具体协议与对照判断收益。以上基础为第三章需求观测、第四章批量迁移和第五章有限预算学习配额搜索提供了统一的理论语言，也为解释训练曲线、主比较与机制证据明确了条件。

第 3 章　自然覆盖约束下无人机集群的需求感知协同轨迹决策

3.1　研究动机与评价口径

3.1.1　从集群空间部署到可接纳需求

无人机集群承担地面计算服务时，机群空间部署决定哪些需求能够进入任务执行流程。用户设备只有进入某架无人机的服务范围，其请求才有机会上传、分配和执行。对于尚未被覆盖的请求，即使集群具有足够的总算力，任务分配层也没有可处理的输入。因此，上层轨迹决策需要安排有限的空中平台，使具有服务需求的用户进入可接纳区域，并结合邻机位置处理多机部署关系。本文把这一前置条件称为自然覆盖接纳：覆盖由真实位置和固定服务半径决定，不因请求紧急、无人机负载较低或宏基站算力充足而放宽。

在自然覆盖口径下，上层局部观测是否包含未接纳需求直接影响可学习的控制规律。若观测只列出已关联用户，策略可以比较这些用户的距离、请求大小和电量，却无法辨别附近未覆盖区域究竟存在高需求还是无人区域。低服务率的奖励能说明当前结果不理想，但不能单独提供应向何处移动的信息。这一信息缺口不同于网络容量不足：增加隐藏层或注意力头数并不会把被观测构造过程丢弃的用户重新送入网络。

本章研究固定服务半径下无人机集群的需求感知协同轨迹决策。首先建立与生产仿真一致的几何、通信、缓存、计算和能量模型，明确平台运动影响服务结果的时间路径；其次构造上层分散式部分可观测决策过程，说明 Attention-MAPPO 如何聚合邻机与地面需求信息，以及实际概率模型和训练目标；最后在不改变网络维度与物理接纳规则的条件下，把感知范围内尚未接纳的需求补入观测，并用探索与独立确认两阶段实验检验其作用。本章回答集群应如何依据需求调整空间部署，覆盖观测结果属于方法演进的阶段性证据，第五章进一步研究最新 SF-HLM 在冻结上层条件下的完整在线方法与端到端表现。

本文不以旧协议中的强制关联代替自然覆盖。强制关联会令未覆盖请求进入最近无人机的处理流程，从而消除“未接纳”这一失败类别。它改变了待优化问题，而不只是更换指标名称。在本文的现行协议中，未覆盖服务请求进入 DSR 分母但不进入卸载集合，轨迹控制必须通过改变后续位置改善接纳，不能依靠评估器补足覆盖。

3.1.2 统一计数与乘积分解

设一个评估单元内实际生成的服务请求总数为 G，自然覆盖接纳数为 A，满足自身截止时间的服务请求数为 S。计数满足 $0 \leqslant S \leqslant A \leqslant G$。对 $G > 0, A > 0$ 的单元，定义接纳率 $\alpha = A/G$、接纳后完成率 $\eta = S/A$，则

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A} = \alpha\eta. \tag{3.1}$$

分母为零时，对应比例按实验实现取零。$G - A$ 表示因覆盖不足而无法进入执行流程的请求数，$A - S$ 表示已经接纳但未按时完成的请求数。因此，总失败数可以不重不漏地分解为

$$G - S = (G - A) + (A - S). \tag{3.2}$$

这一分解把几何接纳与接纳后的传输计算质量放在同一计数框架内，避免只在已处理请求上报告较高成功率而忽略未覆盖需求。

统计汇总必须区分“单元内求比例”和“跨单元平均”。本文的确认实验先在每个“训练种子–工作负载”评估单元内累加六个回合的请求计数，再分别求 $S/G, A/G, S/A$，随后平均各单元比例。若以 i 标记单元，则平均端到端指标为 $\overline{\mathrm{DSR}} = I^{-1}\sum_i \alpha_i\eta_i$。一般有

$$\overline{\mathrm{DSR}} = \bar{\alpha}\bar{\eta} + \frac{1}{I}\sum_{i=1}^{I}(\alpha_i - \bar{\alpha})(\eta_i - \bar{\eta}), \tag{3.3}$$

而非直接等于两个平均因子的乘积。把所有单元的计数再次合并后求 $\sum_i S_i / \sum_i G_i$，则对应按生成请求数加权的指标，亦不能替代预定的等权单元均值。

比较候选方法和基线时，可在每一配对单元内进行精确的对称分解。以下标 c, b 标记两方法，记 $\Delta\alpha_i = \alpha_{c,i} - \alpha_{b,i}$、$\Delta\eta_i = \eta_{c,i} - \eta_{b,i}$，则

$$\Delta\mathrm{DSR}_i = \Delta\alpha_i \frac{\eta_{c,i} + \eta_{b,i}}{2} + \Delta\eta_i \frac{\alpha_{c,i} + \alpha_{b,i}}{2}. \tag{3.4}$$

证明只需展开右端，两个交叉乘积相消，剩下 $\alpha_{c,i}\eta_{c,i} - \alpha_{b,i}\eta_{b,i}$。该形式无需任选一个方法作为展开基点，两个项相加精确恢复单元差值；先配对分解再平均也精确恢复平均 DSR 差值。其用途是描述指标变化的来源，不能仅凭代数分解把接纳增加解释为已被唯一识别的因果机制。

3.1.3 电池定型与实际分母

实际生成服务请求数 G 存在轻微策略依赖性。仿真为每个用户先抽取潜在请求标识、输入大小、截止时间和优先级，再依据当前电池电量确定请求类别。电量低于阈值时，潜在服务或内容请求转为能量请求。因此，方法之间即使共享

相同的外生请求随机流，也可能因电池演化不同而产生不同的实际服务请求数。配对随机数控制了抽样过程，但并不使电池状态或实际分母完全相同。

本文保留预先规定的 S/G 为主指标，同时记录潜在服务请求数用于分母敏感性分析。使用共同潜在分母的复核，保留原运行中的成功计数，只改变统计分母；它并不等价于强制低电量用户继续上传服务的反事实仿真。第五章按相应归档协议报告该复核。本章明确分母边界的目的，是使覆盖、能量补给与业务生成之间的反馈可解释，防止把微小分母变化误写成完全独立于策略的业务常量。

3.2　系统几何、动作应用与单时隙时序

3.2.1　集群协同对象与规划层次

本文的协同对象是共同服务地面请求的五架无人机。各机的水平位置、关联用户、邻机状态和机载资源通过请求接纳与任务执行相互联系：一架无人机移动会改变后续服务对象和机间链路；一个请求跨机执行会改变目标节点的计算负载、缓存和能耗，进而影响后续观测。因此，集群轨迹规划需要以整体服务结果评价各机的动作，单机通信距离或当前关联用户数量不足以概括这一目标。

上层在规划层给出逐时隙的二维运动指令。五个 actor 根据各自定长局部观测推断动作，训练时的联合观测 critic 为其提供集群回报的评价；共享参数和邻机注意力提供协调信息的表达方式。环境随后对拟执行位移作确定性修复，处理区域与机间距约束。该结构采用协同决策与几何执行修复共同形成可执行位置序列，学习策略的原始输出本身不构成安全性证明。固定高度、速限和位置边界构成本文的简化运动模型，姿态、加速度和内环飞行控制由模型假设之外的执行层承担。

本章所谓轨迹规划，是在该简化模型中连续生成服务位置和运动指令，不要求五机保持预设编队形状。机间距、服务半径与感知半径承担不同职责：机间距限制平台相对位置，服务半径确定任务接纳资格，感知半径确定策略可用的信息。把三者区分开，才能判断观测改进是否改变了任务信息，而非放宽了运动或服务条件。

3.2.2　网络与自然覆盖模型

主场景含 $N = 5$ 架 UAV、$M = 100$ 个 UE 和一个 MBS。地面区域为 $[0, 700] \times [0, 700]\,\mathrm{m}^2$，UAV 保持 $H = 100\,\mathrm{m}$ 高度，MBS 固定于 $(350, 350, 30)\,\mathrm{m}$。记 UAV 水平位置为 $\mathbf{q}_u(t)$、UE 水平位置为 $\mathbf{w}_m(t)$，三维位置分别为 $\mathbf{p}_u(t) = (\mathbf{q}_u(t), H)$、$\mathbf{p}_m(t) = (\mathbf{w}_m(t), 0)$。覆盖判断使用水平距离，通信增益使用三维距离，这两个距

离不能混用。

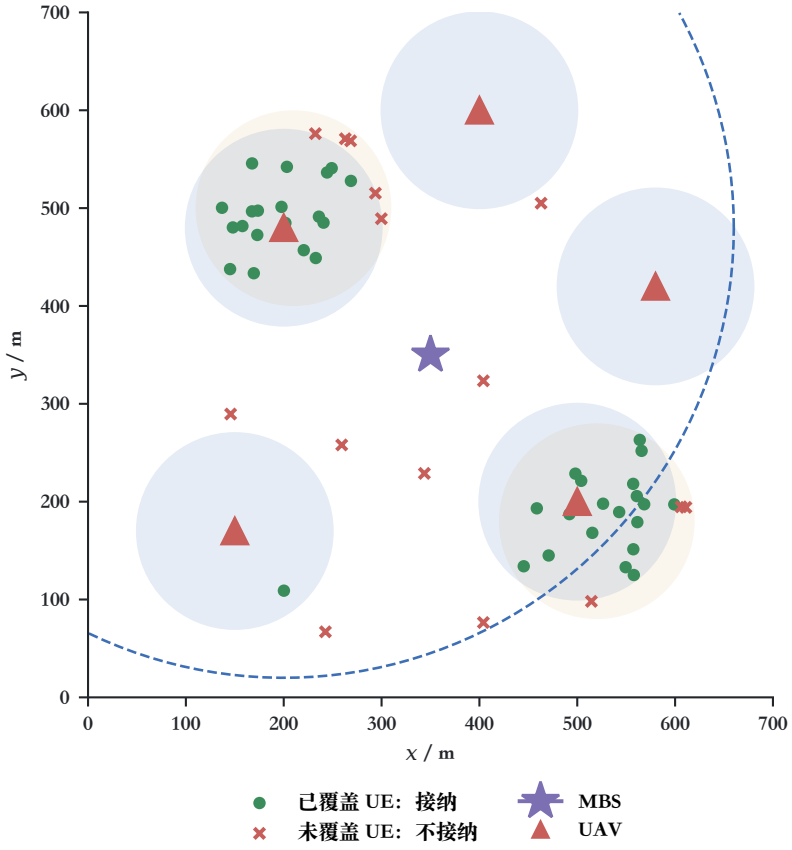


图 3.1　系统总体布局与自然覆盖接纳示意。三角形为 UAV，实线圆为 100 m 服务覆盖范围，虚线圆为其中一架 UAV 的 460 m 感知范围；绿色圆点为被覆盖 UE，红色叉为未被覆盖 UE，其请求本时隙不被接纳。图中位置为示意性布局，非真实轨迹快照

Figure 3.1　Schematic of the system layout and natural-coverage admission (illustrative positions, not a recorded trajectory snapshot)

用户 m 在时隙 t 的可覆盖无人机集合和接纳来源定义为

$$\mathcal{U}_m(t) = \{u : \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\| \leqslant R_c\}, \qquad u_m(t) = \arg\min_{u \in \mathcal{U}_m(t)} \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|, \tag{3.5}$$

其中 $R_c = 100\,\mathrm{m}$；$\mathcal{U}_m(t) = \varnothing$ 时不关联。该规则同时应用于服务、内容与能量请求，而非只对服务请求有效。服务接纳计数 A 只统计其中的服务请求，接入带宽的分配则统计关联的全部请求类型。若覆盖集合重叠，选择最近的覆盖 UAV，不以目标执行节点替代接纳来源。

邻居发现与扩展观测采用 $R_s = 460\,\mathrm{m}$ 的感知范围。UAV 之间按照三维距离判断邻居，由于各机高度一致，该距离等于水平机间距。UE 的预接纳可见范围与 100 m 的接纳范围分别定义。图 3.2 展示两种半径的关系：扩大可见信息不会立即赋予远处 UE 上传或计算资格，上层仍须用受速限约束的移动使其进入覆盖。

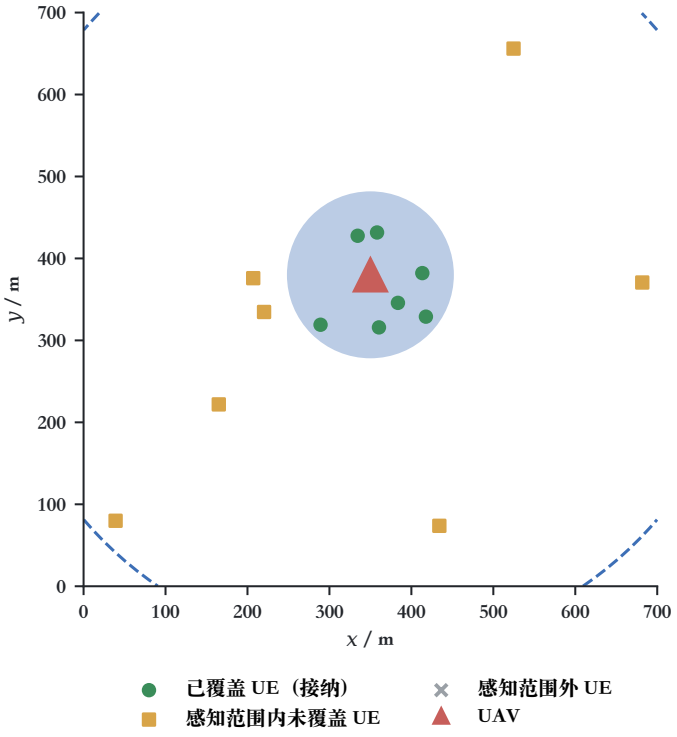


图 3.2　覆盖半径与感知半径的几何关系

Figure 3.2　Geometry of the coverage radius and the sensing radius

UAV 间最小水平间距为 $d_{\min} = 200\,\mathrm{m}$。它与服务直径相同，使满足该间距的部署中两覆盖圆的内部不相交、边界至多相切；这一几何关系由固定配置给定，不能作为学习策略减少覆盖重叠的证据。另一方面，机间距也限制了多机同时聚集到同一热点，轨迹策略需要在热点需求、稀疏用户和相对位置约束之间协调。该约束并未保证区域全覆盖，有限数量的覆盖圆仍可能留下大量未接纳需求。

用户移动采用随机航点模型。每时隙向当前航点推进，位移上限为 15 m；到达航点后可等待并生成下一航点。主场景中 85% 的用户围绕两个半径为 100 m、中心间距不小于 400 m 的热点分布，其余用户分布于区域内。热点结构使“平均向中心聚集”不必然有效：不同 UAV 需避免重复追踪同一需求，同时照顾感知范围内尚未接纳的用户。

3.2.3　原始概率动作与可执行位移

策略网络生成的随机变量和环境实际执行的动作不是同一个量。记原始动作 $\mathbf{z}_u \in \mathbb{R}^2$，训练阶段按二维正态分布采样；输入环境前逐坐标裁剪为 $\mathbf{a}_u = \mathrm{clip}(\mathbf{z}_u, -1, 1)$。环境进一步按向量模长映射位移：

$$\widetilde{\Delta\mathbf{q}}_u = v_{\max}\tau \min(\|\mathbf{a}_u\|, 1)\frac{\mathbf{a}_u}{\|\mathbf{a}_u\| + \epsilon_0}, \qquad v_{\max} = 15\,\mathrm{m/s},\ \tau = 1\,\mathrm{s}. \tag{3.6}$$

$\epsilon_0 > 0$ 是数值保护常量。当模长小于一时，位移近似与动作线性对应；当模长大于一时，只保留方向并饱和到最大移动距离。逐坐标裁剪并不能独立保证速度约束，因为 $(1,1)$ 的模长为 $\sqrt{2}$，故径向映射是必要步骤。

实际飞行位置同时满足边界、速度和机间距条件。环境采用的边界留白为服务半径的一半，故可行位置区域是 $\mathcal{Q} = [50\,\mathrm{m}, 650\,\mathrm{m}]^2$，而非整个地面服务区域。给定当前可行位置，下一位置应属于

$$\mathcal{F}(\mathbf{q}(t)) = \left\{ \{\mathbf{q}'_u\}_{u=1}^{N} : \ \mathbf{q}'_u \in \mathcal{Q},\ \|\mathbf{q}'_u - \mathbf{q}_u(t)\| \leqslant v_{\max}\tau,\ \|\mathbf{q}'_u - \mathbf{q}'_v\| \geqslant d_{\min}\ (u \neq v) \right\}. \tag{3.7}$$

其中机间距约束对应圆外区域，联合可行域一般非凸。本文的动作修复是实现中的有限迭代消解过程，不是对该非凸集合求得唯一的欧氏投影，也不声称修复位移全局最接近策略建议。

执行过程先将建议位置裁剪至边界，再投回以当前位置为中心、半径 $v_{\max}\tau$ 的速度圆。对距离不足的 UAV 对，沿连线方向各外推一半重叠量，随后再次检查边界和速度。该交替修复最多执行配置迭代数加二十轮，在主配置中合计四十轮。若仍有冲突，最终处理将涉及冲突的 UAV 回退至原位置悬停，并传播检查回退新引起的冲突，直到联合位置满足约束。初始位置由可行初始化保证，最终校验允许 10^{-3} m 数值容差。

边界与碰撞违例标记依据动作提出和修复过程记录，并不会因为最终位置已可行而清除。因此，动作修复检查离散时隙位置的几何可行性，违例惩罚仍指导策略减少对修复的依赖。例如，一架无人机在边界附近反复向外采样，虽会被截回边界，其奖励仍包含边界违例项。该检查针对相邻时隙记录的位置，不构成时隙内连续航迹避碰或飞行动力学可行性的证明。策略应学习合适的内部动作，而不把环境修复器当作无代价的控制替代。

3.2.4 请求执行先于轨迹移动

图 3.3 给出单时隙内的实现顺序。环境重置或上一时隙末生成当前请求，并按当前位置关联 UE、更新邻居和组装观测。两层策略从这一当前信息计算动作；进入环境步进后，先冻结移动前几何和缓存，解析整批服务请求的执行目标，预先计算最终节点负载，再执行服务请求和其他类型请求。此时所有上传、转发与回传速率均使用 $\mathbf{q}_u(t)$。

请求执行完成后，环境才应用已计算的上层轨迹动作，得到 $\mathbf{q}_u(t+1)$，并根据实际移动距离结算本时隙飞行、悬停和 WPT 能耗。随后计算奖励与指标，提交缓存变化、移动 UE、生成下一时隙请求和观测。因此，上层动作对当前奖励

存在即时能耗与违例路径，对覆盖和链路质量的主要作用则出现在下一时隙。这一时间关系可以概括为

$$\mathbf{b}(t) \longrightarrow \{T_m(t), E_m^{\text{assign}}(t)\}, \qquad \mathbf{a}(t) \longrightarrow \mathbf{q}(t+1) \longrightarrow \mathcal{U}_m(t+1), \tag{3.8}$$

其中 $\mathbf{b}(t)$ 为请求级卸载分配。当前时隙的接纳由 $\mathcal{U}_m(t)$ 决定，不因本时隙随后移动而追溯改变。即使策略看见距 UAV 120 m 的未接纳用户，并移动到更近位置，该用户本时隙请求也不会被补处理。

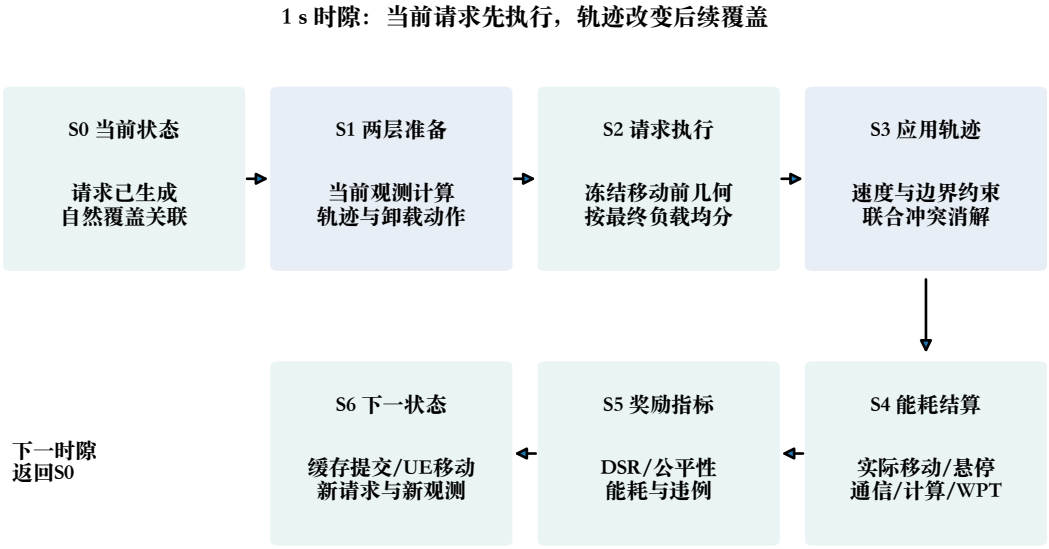


图 3.3　单时隙内的请求执行与轨迹应用时序。两层动作由当前观测计算；请求按移动前几何执行，上层轨迹动作随后应用并影响下一时隙覆盖

Figure 3.3　Decision and execution timeline within one slot, following the simulator implementation order

模型中的任务完成时延可以超过一个时隙，截止时间也可超过 1 s；但环境并未把未完成任务保留为跨时隙队列。它在本步计算每个当前请求的完整路径时延，并据此判断是否满足截止期，下一步生成新请求。于是，$T_m > \tau$ 表示该简化并发执行模型估计的完成时间超过时隙，不意味着后续状态保留了相同任务的剩余周期。全文的“负载”指当步最终分配的请求数，不能直接解释为持久队列长度。

3.3 请求、通信、缓存与能量模型

3.3.1 业务抽样与量纲约定

文件库含二十五类服务和五十个内容，共七十五个标识。总体流行度按 Zipf 分布生成，若标识 s 的流行度排名为 r_s，则

$$\Pr(s) = \frac{r_s^{-\beta}}{\sum_{k=1}^{75} r_k^{-\beta}}, \qquad \beta = 0.8. \tag{3.9}$$

排名与标识通过固定随机配置对应，不能假定服务编号越小就必然越热门。每个 UE 每步先抽取标识、整数输入字节数 $L_m \in [10^6, 5\times10^6)$、截止时间 $D_m \in [0.65, 2.10]$ s 和优先级 $p_m \in \{1,2,3\}$。这些抽样在低电量覆盖之前完成，因而配对方法消耗相同的潜在随机抽样次数。

当电量不低于 50 J 时，服务标识形成计算请求，内容标识形成内容请求；低电量时形成能量请求。内容请求不使用抽取的服务输入大小，而使用文件库中固定的内容文件大小。服务请求的 L_m 是用户输入，B_s 是执行服务所需的文件或镜像，两者分别抽样并具有不同通信路径。若把 B_s 当成 L_m，将混淆上传数据与缓存回源数据，也会错误估计缓存收益。

服务 s 的每字节 CPU 周期数 $\omega_s \in [1200, 2800)$ 固定，所需总周期为

$$C_m = \omega_s L_m. \tag{3.10}$$

C_m 的单位是周期；L_m, B_s 的单位是字节；无线速率 R 的单位是比特每秒。因此，通信必须使用 $8L_m/R$ 或 $8B_s/R$，而计算使用 C_m/f，不再乘八。本文以十进制 10^6 字节解释表中的 MB，不以二进制 MiB 替代实现值。

UAV 的总算力 F_u 从 $\{40, 45, \cdots, 85\}$ GHz 取值，存储容量从 $\{120, 121, \cdots, 179\}$ MB 取值。上述硬件、服务周期和文件大小由固定静态随机配置生成，不在每回合重抽。工作负载随机流用于请求，独立移动随机流用于位置与航点；训练随机性、请求随机性与硬件异质性属于不同层次，不应把三者都视为独立训练重复。

3.3.2 信道增益与带宽分配

无线链路使用自由空间平方距离衰减。对三维端点 $\mathbf{p}_i, \mathbf{p}_j$，有

$$g_{ij}(t) = \frac{G_0 g_0}{\|\mathbf{p}_i(t) - \mathbf{p}_j(t)\|^2 + \epsilon_0}, \qquad G_0 g_0 = 3.244132 \times 10^{-4}. \tag{3.11}$$

发射功率为 $P^{\mathrm{comm}} = 0.5\,\mathrm{W}$，噪声功率为 $\sigma^2 = 10^{-13}\,\mathrm{W}$，信噪比为 $P^{\mathrm{comm}} g_{ij}/\sigma^2$。对已关联用户，接入带宽在同一来源 UAV 的全部关联 UE 间等分：

$$R_{m,u}^{\mathrm{edge}}(t) = \frac{B^{\mathrm{edge}}}{n_u^{\mathrm{assoc}}(t)} \log_2\left(1 + \frac{P^{\mathrm{comm}} g_{m,u}(t)}{\sigma^2}\right), \qquad B^{\mathrm{edge}} = 40\,\mathrm{MHz}. \tag{3.12}$$

n_u^{assoc} 包含服务、内容及能量请求的关联用户。该数与最终计算负载 N_u 不同：服务可以迁往其他 UAV 或 MBS，内容与能量请求也不会加入 CPU 共享分母。关联为空时不存在需要计算接入速率的请求，不能在式中使用零分母。

机间与回传速率分别为

$$\begin{aligned} R_{u,v}^{\text{inter}} &= 20\times 10^6 \log_2\left(1+P^{\text{comm}} g_{u,v}/\sigma^2\right), \\ R_{u,\text{M}}^{\text{bh}} &= 0.75\times 10^6 \log_2\left(1+P^{\text{comm}} g_{u,\text{M}}/\sigma^2\right). \end{aligned} \tag{3.13}$$

这些链路在当前实现中使用整条配置带宽，不再按该链路传输数分割；也没有显式小尺度衰落、随机视距、同频干扰或额外回传排队项。噪声作为固定总功率参与各式，没有随接入子带宽重新缩放。本文分析的通信竞争主要来自接入关联数及有限回传速率，不能声称已模拟所有无线网络干扰。

以上公式显示覆盖增长与服务质量之间的一个结构性联系。在距离近似不变时，接纳更多用户令 n_u^{assoc} 增加，单用户接入速率按其倒数下降，输入上传时间近似成比例上升。同时，新增服务若在本机执行又会增大计算负载。因此，覆盖观测扩展可以提高接纳数，但并不自动保证新接纳请求按时完成。轨迹与卸载必须共同承担这一新增压力。

3.3.3　最终负载均分与三类服务路径

设当步已接纳服务集合为 $\mathcal{M}(t)$，请求 m 的来源为 $u=u_m(t)$、执行目标为 b_m。在解析全体目标后，UAV j 的最终负载为

$$N_j(\mathbf{b}) = \sum_{m\in\mathcal{M}(t)} \mathbf{1}[b_m=j], \qquad f_{m,j}=F_j/N_j(\mathbf{b}), \quad b_m=j. \tag{3.14}$$

同一节点的本地任务和其他来源迁入任务共同计数；迁往 MBS 的任务不计入任何 UAV 的分母。对实际在该节点执行的请求必有 $N_j\geqslant 1$。先确定目标、再冻结 N_j 的顺序避免“先执行的请求获得更大算力”这一非物理的遍历次序偏差。

记时隙开始的缓存状态为 $h_{j,s}(t)\in\{0,1\}$，其中 s 为服务标识。为简化书写，定义上传时间 $U_m=8L_m/R_{m,u}^{\text{edge}}$、服务文件回源时间 $V_{j,s}=8B_s/R_{j,\text{M}}^{\text{bh}}$ 和协作输入转发时间 $I_{m,u,v}=8L_m/R_{u,v}^{\text{inter}}$。三条实际执行路径的时延为

$$\begin{aligned} T_m^{\text{local}} &= U_m+(1-h_{u,s})V_{u,s}+C_mN_u/F_u, \\ T_m^{\text{coop}}(v) &= U_m+I_{m,u,v}+(1-h_{v,s})V_{v,s}+C_mN_v/F_v, \\ T_m^{\text{MBS}} &= U_m+8L_m/R_{u,\text{M}}^{\text{bh}}+C_m/F_{\text{M}}. \end{aligned} \tag{3.15}$$

MBS 总算力为 $F_{\text{M}}=200\,\text{GHz}$，实现中每个 MBS 任务均使用该值，不按 MBS 当步任务数均分。三条路径都先经来源 UAV 接入；“本地”指接纳 UAV 执行，不

指 UE 自身执行。当前模型没有服务结果下行时间，也没有把输入上传与 CPU 计算流水重叠。

计算能耗由等效动态功率 $P^{\mathrm{cmp}} = \kappa f^3$ 与执行时间 C_m/f 相乘得到：

$$E_m^{\mathrm{cmp}} = P^{\mathrm{cmp}} \frac{C_m}{f_{m,j}} = \kappa C_m f_{m,j}^2, \qquad \kappa = 10^{-27}. \tag{3.16}$$

这是按请求均分频率的简化模型，不是对真实多核硬件逐周期测量。共享频率下降会增加时延并降低该请求计算能耗，故“更低时延”与“更低能耗”不能同时从更多算力推得。第四章将进一步推导迁移引起的批量外部影响。

把除计算外的路径时间记为 T_m^{comm}，当目标为 UAV j 时，截止期条件可写成

$$T_m \leqslant D_m \quad \Longleftrightarrow \quad N_j \leqslant \frac{F_j(D_m - T_m^{\mathrm{comm}})}{C_m}, \qquad D_m \geqslant T_m^{\mathrm{comm}}. \tag{3.17}$$

右端是给定链路与缓存下该请求允许的节点负载预算，不是可独立分配给所有请求的容量。同节点请求具有不同 C_m, D_m，需要同时检查各自限制；当通信已用尽截止期时，增加 CPU 不能使该路径可行。该式解释了缓存命中和轨迹靠近的价值：它们通过压缩通信时间给计算释放截止期余量。

3.3.4 分配能耗与完整机队能耗

所有服务路径共有来源 UAV 接收输入能耗 $P^{\mathrm{rx}}U_m$，其中 $P^{\mathrm{rx}} = 0.1\,\mathrm{W}$。为研究执行目标选择的增量代价，定义分配因果能耗为对目标敏感的 UAV 通信与计算项：

$$\begin{aligned}
E_m^{\mathrm{assign,local}} &= (1 - h_{u,s})P^{\mathrm{bh,rx}}V_{u,s} + \kappa C_m (F_u/N_u)^2, \\
E_m^{\mathrm{assign,coop}} &= (P^{\mathrm{tx}} + P^{\mathrm{rx}})I_{m,u,v} + (1 - h_{v,s})P^{\mathrm{bh,rx}}V_{v,s} + \kappa C_m (F_v/N_v)^2, \\
E_m^{\mathrm{assign,MBS}} &= P^{\mathrm{bh,tx}} 8L_m / R_{u,\mathrm{M}}^{\mathrm{bh}}.
\end{aligned} \tag{3.18}$$

$P^{\mathrm{tx}} = P^{\mathrm{bh,tx}} = 0.5\,\mathrm{W}$，$P^{\mathrm{rx}} = P^{\mathrm{bh,rx}} = 0.1\,\mathrm{W}$。协作传输由发送与接收两架 UAV 分别承担能耗，所以机队口径必须计入两端；MBS 计算能耗由地面电源承担，不计入 UAV 能耗。UE 上传能耗属于 UE 电池变化，也不混入机队能耗。

若 E^{content} 汇总内容请求导致的 UAV 通信能耗，E_u^{motion} 和 E_u^{WPT} 分别为机动与补能能耗，则完整当步机队能耗为

$$E^{\mathrm{fleet}} = \sum_{m \in \mathcal{M}} P^{\mathrm{rx}} U_m + \sum_{m \in \mathcal{M}} E_m^{\mathrm{assign}} + E^{\mathrm{content}} + \sum_{u=1}^{N} (E_u^{\mathrm{motion}} + E_u^{\mathrm{WPT}}). \tag{3.19}$$

第四章只比较固定快照的 $\sum_m E_m^{\mathrm{assign}}$，排除了共同输入接收、内容、飞行、悬停和 WPT。上层奖励与完整在线评价使用 E^{fleet}。两种量都以焦耳计，却回答不同问题：前者衡量改变分配的代价，后者衡量整套 UAV 运行代价。

3.3.5　内容服务与缓存状态更新

内容请求只传输文件，不消耗服务 CPU 周期。对文件 s、来源 UAV u，本地、协作和 MBS 获取的完成时间分别为

$$\begin{aligned} T_m^{\text{content,local}} &= (1-h_{u,s})8B_s/R_{u,\text{M}}^{\text{bh}} + 8B_s/R_{m,u}^{\text{edge}}, \\ T_m^{\text{content,coop}} &= (1-h_{v,s})8B_s/R_{v,\text{M}}^{\text{bh}} + 8B_s/R_{v,u}^{\text{inter}} + 8B_s/R_{m,u}^{\text{edge}}, \\ T_m^{\text{content,MBS}} &= 8B_s/R_{u,\text{M}}^{\text{bh}} + 8B_s/R_{m,u}^{\text{edge}}. \end{aligned} \tag{3.20}$$

对应 UAV 发射和接收能耗仍按功率乘持续时间累计，用户仅支付内容接收能耗。协作内容路径的输入方向是邻机向来源机发送文件，与服务请求由来源机转发输入的方向不同。

缓存命中使用时隙开始冻结的二值状态 $h_{j,s}(t)$。即便同一时隙较早执行的请求已取回文件，之后的请求也不会立即获得新的命中状态；当步多个相同缺失请求仍分别承担回源时延。实际取回的文件先进入待提交集合，在本步末统一尝试写入缓存。协作服务把镜像缓存到执行 UAV；MBS 执行服务不会顺带使来源 UAV 缓存该镜像。协作内容在邻机取回或持有文件，来源机也实际接收文件，因而可在相应节点形成待提交项。

每个 UAV 记录当步文件请求频次 $\nu_{u,s}(t)$，并以指数移动平均更新热度：

$$H_{u,s}(t+1) = \beta_c \nu_{u,s}(t) + (1-\beta_c) H_{u,s}(t), \qquad \beta_c = 0.75, \qquad \chi_{u,s}(t+1) = H_{u,s}(t+1)/B_s. \tag{3.21}$$

待提交文件按单位大小热度 $\chi_{u,s}$ 降序尝试放入剩余存储，平局按文件编号确定；这一阶段不任意替换已缓存文件。每五十步的周期刷新则重置缓存集合，按同一顺序重新填充，并在遇到首个无法放入的文件时停止。该规则是实现中的容量受限启发式，不是背包精确最优解；周期刷新也没有另计预取网络时延或能耗，不能据此声称已建立完整的缓存填充通信协议。

卸载决策前的邻机缓存只能用估计信念表示。启发式上下文对邻机文件命中的估计为

$$\widehat{h}_{v,s} = \left[1 + \exp\left(\gamma_c \left(r_s - \frac{S_v^{\text{cache}}}{\overline{B}}\right)\right)\right]^{-1}, \qquad \gamma_c = 0.5, \tag{3.22}$$

其中 S_v^{cache} 为容量、$\overline{B}$ 为文件平均大小。估计式可用于动作特征与质量筛选，实际执行式 (3.15) 使用冻结的真实二值缓存。把 $1-\widehat{h}$ 的期望回源代价写成实际实现中的路径，会夸大模型的信息一致性，也会抹去预测与真实执行的差异。

3.3.6 UE 电池、无线补能与 UAV 机动能耗

记 UE 电量为 $B_m^{\mathrm{bat}}(t)$，本步发射与接收持续时间为 $T_m^{\mathrm{UE,tx}}, T_m^{\mathrm{UE,rx}}$，采集能量为 E_m^{harv}，则

$$B_m^{\mathrm{bat}}(t+1) = \mathrm{clip}_{[0,B_{\max}]}\left[B_m^{\mathrm{bat}}(t) - P^{\mathrm{static}}\tau - P^{\mathrm{UE,tx}}T_m^{\mathrm{UE,tx}} - P^{\mathrm{UE,rx}}T_m^{\mathrm{UE,rx}} + E_m^{\mathrm{harv}}\right]. \tag{3.23}$$

$B_{\max} = 500\,\mathrm{J}$，$P^{\mathrm{static}} = 0.01\,\mathrm{W}$，$P^{\mathrm{UE,tx}} = 0.5\,\mathrm{W}$，$P^{\mathrm{UE,rx}} = 0.1\,\mathrm{W}$。服务请求支付上传能耗，内容请求支付下行接收能耗，能量请求获得采集项；未关联 UE 在本步仅扣除静态项。初始电量在 300 至 500 J 间抽样。低电量比例在本步结算之后统计，以反映通信和补能对下一步请求定型的影响。

关联的能量请求采用简化 WPT 模型：

$$E_m^{\mathrm{harv}} = \eta_{\mathrm{W}} P^{\mathrm{W}} G_{\mathrm{W}} g_{u,m} \tau, \qquad \eta_{\mathrm{W}} = 0.8,\ P^{\mathrm{W}} = 50\,\mathrm{W},\ G_{\mathrm{W}} = 5\times 10^5. \tag{3.24}$$

G_{W} 是等效采集增益，不能据此反推出未建模的天线阵列或真实设备效率。只要 UAV u 本步存在至少一个关联能量请求，它便支付一次 $P^{\mathrm{W}}\tau$，即

$$E_u^{\mathrm{WPT}} = P^{\mathrm{W}}\tau\,\mathbf{1}[\text{UAV } u \text{ 存在关联能量请求}]. \tag{3.25}$$

多名能量用户分别获得式 (3.24) 的采集量，但实现不把 UAV 发射能耗乘以能量用户数。该并行补能简化必须与上述公式共同使用。

机动能耗按修复后的实际位移而非原始动作结算。设 $d_u = \|\mathbf{q}_u(t+1) - \mathbf{q}_u(t)\|$，则

$$t_u^{\mathrm{move}} = \frac{d_u}{v_{\max}}, \qquad t_u^{\mathrm{hover}} = \max(\tau - t_u^{\mathrm{move}}, 0), \qquad E_u^{\mathrm{motion}} = 300 t_u^{\mathrm{move}} + 150 t_u^{\mathrm{hover}}. \tag{3.26}$$

由速度约束可知 $t_u^{\mathrm{move}} \leqslant \tau$，故悬停时间非负。该模型在满速移动与悬停间线性分配时间，没有额外旋翼诱导功率、加速度或转弯阻力项。UAV 没有像 UE 一样的剩余电池状态和硬能量终止预算；“节约 UAV 能耗” 是奖励与评价目标，不能写成满足 UAV 电池续航约束的证明。

3.3.7 公平性、时延与参数口径

环境的公平性统计覆盖全部请求类型。令 $K_m(t)$ 为至今用户被接纳且请求完成时延不超过时隙时长的次数，$c_m(t) = K_m(t)/t$。服务请求以其任务截止时间判断 DSR，但公平性使用统一的 τ 门槛；能量请求的时延按零处理，关联后也能

增加该计数。于是 Jain 指数为

$$J(t)=\begin{cases}\dfrac{(\sum_m c_m(t))^2}{M\sum_m c_m^2(t)}, & \sum_m c_m^2(t)>0,\\ 0, & \sum_m c_m^2(t)=0.\end{cases} \tag{3.27}$$

非零时有 $1/M \leqslant J \leqslant 1$。上界由柯西–施瓦茨不等式得到；下界在仅一个用户取得非零计数时达到。该指标反映累计成功服务的均衡，而非仅服务请求的公平性，也不是当前覆盖面积的均衡。

奖励中的时延汇总包含全部 UE：已关联 UE 采用实际请求时延，未关联 UE 记 $T^{\mathrm{pen}}=20\,\mathrm{s}$ 的非服务惩罚。归一化分母为 MT^{pen}，而非实际服务请求数。这样，未接纳内容或能量请求也会影响上层信号。DSR 和 MBS 依赖则仅以服务请求计数定义。并行记录这些口径可以避免把“时延变小”误解成所有服务任务的条件平均时延都下降。

表 3.1　主场景仿真参数

Table 3.1　Simulation parameters of the main setting

参数	取值	参数	取值
区域尺寸	$700\,\mathrm{m}\times 700\,\mathrm{m}$	时隙时长 τ	1 s
UAV 数量 N / UE 数量 M	5 / 100	episode 步数 T	1000
UAV 高度 H	100 m	UAV 最大速度 $v_{\max}$	15 m/s
最小机间距 $d_{\min}$	200 m	UE 时隙位移上限	15 m
覆盖半径 R_c	100 m	感知半径 R_s	460 m
UAV 计算能力	$40, 45, \cdots, 85$ GHz	UAV 缓存容量	$120, 121, \cdots, 179$ MB
MBS 计算能力	200 GHz	MBS 位置	$(350, 350, 30)$ m
飞行/悬停功率	300 / 150 W	WPT 功率 / 效率	50 W / 0.8
服务/内容数	25 / 50	Zipf 指数 β	0.8
请求输入大小	$1\sim 5$ MB	截止时间	$0.65\sim 2.10$ s
每字节周期数	$1200\sim 2800$	请求优先级	$\{1, 2, 3\}$
电池容量 $B_{\max}$ / 阈值 B_{low}	500 / 50 J	UE 静态功耗	0.01 W
接入带宽 B^{edge}	40 MHz	机间带宽 B^{inter}	20 MHz
回传带宽 B^{backhaul}	0.75 MHz	发射功率 / 噪声	0.5 W / 10^{-13} W
热点数量 / 半径	2 / 100 m	热点内 UE 比例	85%

3.4　上层 Dec-POMDP 与注意力策略实现

3.4.1　分散观测与集中训练的职责

上层建模为 $\langle \mathcal{I}, \mathcal{S}, \{\mathcal{O}_u\}, \{\mathcal{Z}_u\}, P, \{r_u\}, \gamma\rangle$ 的 Dec-POMDP。$\mathcal{I}$ 是 UAV 智能体集合，状态含所有位置、缓存、电量、请求和统计量，局部观测由感知范围与固定槽位决定，$\mathcal{Z}_u=\mathbb{R}^2$ 是原始随机动作空间。状态转移同时受卸载执行、轨迹修复、用户移动和下一请求生成影响。不同 UAV 的移动会改变联合几何及下一步

各自接纳集合，而非显式改变未建模的无线干扰。

共享策略以局部观测执行，集中价值网络在训练时看到同一时刻所有 UAV 的局部观测联合。这里的集中信息并不是任意完整物理状态：实现中的价值调用使用联合观测张量，接口传入的另一个状态参数未作为额外特权输入。若某未接纳 UE 不在任何局部槽位中，价值网络也不会自动恢复其详细请求。CTDE 可以利用联合信息减小价值估计的不确定性，但不能弥补观测生成阶段的全部信息缺失。

3.4.2 定长观测与两个不同容量

自身观测含归一化水平位置与七十五维缓存占用，共七十七维；邻机至多四槽，每槽含按 R_s 归一化的二维相对位置；UE 至多三十槽，每槽为二维相对位置和六个业务、电量特征。单槽可写成

$$\mathbf{x}_{u,m} = \left[\frac{\mathbf{w}_m - \mathbf{q}_u}{700}, \frac{\mathrm{type}_m}{2}, \frac{L_m}{5\times 10^6}, \frac{s_m}{75}, \frac{D_m}{2.10}, \frac{p_m}{3}, \frac{B_m^{\mathrm{bat}}}{500} \right], \tag{3.28}$$

其中类型、大小、编号按实现使用相应请求字段，非服务请求的截止时间和优先级置零。三组拼接维度为 $77 + 4\times 2 + 30\times 8 = 325$。空槽全零，按槽内特征绝对值之和大于 10^{-5} 判定非空，并生成注意力掩码。

表 3.2　上层单智能体观测构成（原观测；扩展观测见第 3.5 节）

Table 3.2　Composition of the upper-layer single-agent observation

观测组	内容	维度	说明
自身状态	二维位置、缓存向量	77	2 + 75 维
邻居 UAV	相对位置	$4\times 2 = 8$	感知范围内至多 4 架
UE 槽位	相对位置、请求特征、电量	$30\times 8 = 240$	固定槽位、零填充加掩码
合计		325	

三十槽是上层可见信息容量，不是下层能接纳或执行的服务任务上限。当前主配置的下层为每 UAV 预留一百个请求槽，每槽十四维，再加五维来源特征，共 $5 + 100\times 14 = 1405$ 维；卸载动作有七个编号，分别为本地、MBS 和五架 UAV 的协作目标，其中自身协作编号被掩蔽。超过上层三十槽的真实已接纳请求仍可进入下层执行，不会因为上层看不到而被丢弃。把两个容量混为一谈会高估观测覆盖，也会低估批量竞争。

固定槽位保证同一配置下的输入形状一致，注意力聚合能适应实际非空槽数变化，但不能据此声称输入维度与任意 UAV/UE 数量无关。节点数改变会修改邻机容量，UE 数较小时也可能改变上层槽数，下层容量随 UE 总数配置变化。跨规模泛化需要相应模型和训练协议的验证，不能从网络采用注意力直接推得。

3.4.3　共享奖励及归一化

定义当步全局质量项

$$r^{\text{shared}} = W_{\text{fair}} J - W_{\text{lat}} \bar{T} - W_{\text{energy}} \bar{E} - W_{\text{off}} \rho_{\text{off}} + W_{\text{dsr}} S/G - 0.5\rho_{\text{MBS}}, \tag{3.29}$$

其中 $\bar{T} = \sum_m T_m^{\text{metric}}/(20M + \epsilon_0)$、$\bar{E} = E^{\text{fleet}}/(5000N + \epsilon_0)$，$\rho_{\text{off}}$ 是结算后电量低于阈值的 UE 比例，ρ_{MBS} 是回传 MBS 的服务请求数除以 G。权重为 $1, 1, 0.5, 5, 1$，依次对应公平、时延、能耗、低电量和 DSR。归一化参考是尺度设置而非硬上界，能耗项没有强行裁到 $[0, 1]$。

每架 UAV 的最终奖励还包含自身违例惩罚和统一缩放：

$$r_u = 0.1 \left[r^{\text{shared}} - 10\mathbf{1}[\text{boundary}_u] - 10\mathbf{1}[\text{collision}_u] \right]. \tag{3.30}$$

因局部违例不同，各机奖励不必完全相同。质量项鼓励联合服务，局部惩罚则把建议动作的不可行性归因给相关 UAV。奖励系数在候选与对照间固定，本章不把权重搜索作为观测方法的性能来源。

奖励与论文主指标也不等价。较高奖励可能来自公平性或低电量改善，而不必来自 DSR；反之，扩大接纳可能降低未服务时延惩罚，却让已接纳请求竞争更激烈。因此，实验同时报告 DSR、两个分解因子、机队能耗和公平性，不能用奖励曲线替代截止期表现。这种区分也为第五章研究服务反馈与卸载质量的耦合提供了依据。

3.4.4　多头交叉注意力的实际前向计算

三类原始特征分别通过线性层、层归一化和 ReLU 嵌入到六十四维。以自身嵌入 $\mathbf{e}_u$ 为查询，分别对邻机与 UE 集合执行交叉注意力。每组注意力有八个头，每头维度 $d_h = 64/8 = 8$。对于第 h 个头和非空目标 i，有

$$\mathbf{Q}_u^h = \mathbf{e}_u W_Q^h, \quad \mathbf{K}_i^h = \mathbf{e}_i W_K^h, \quad \mathbf{V}_i^h = \mathbf{e}_i W_V^h, \quad a_{u,i}^h = \frac{\exp(\mathbf{Q}_u^h (\mathbf{K}_i^h)^\top / \sqrt{8})}{\sum_{k \in \mathcal{V}_u} \exp(\mathbf{Q}_u^h (\mathbf{K}_k^h)^\top / \sqrt{8})}. \tag{3.31}$$

$\mathcal{V}_u$ 为当前非空槽集合，空槽在 softmax 前被屏蔽。前向所用的缩放是每头维度的平方根 $\sqrt{8}$，不是总嵌入维度的平方根 $\sqrt{64}$。若需要解释注意力权重，提取过程应复现这一实际前向缩放与掩码，不能用另一个温度的事后权重当作策略真正使用的权重。

每头上下文为 $\mathbf{c}_u^h = \sum_i a_{u,i}^h \mathbf{V}_i^h$，八头拼接再经输出投影。自身、邻机上下文和 UE 上下文拼成一百九十二维，经 $192 \to 128 \to 64$ 的融合网络得到策略特征。邻机聚合为轨迹协调提供相对几何线索，UE 聚合为需求筛选提供输入；其权重

反映模型内部聚合，不自动等价于用户重要性的因果解释。目标全为空时实现对上下文作特殊处理，输出投影仍可有可学习偏置，故不能笼统断言最终模块特征恒为零。

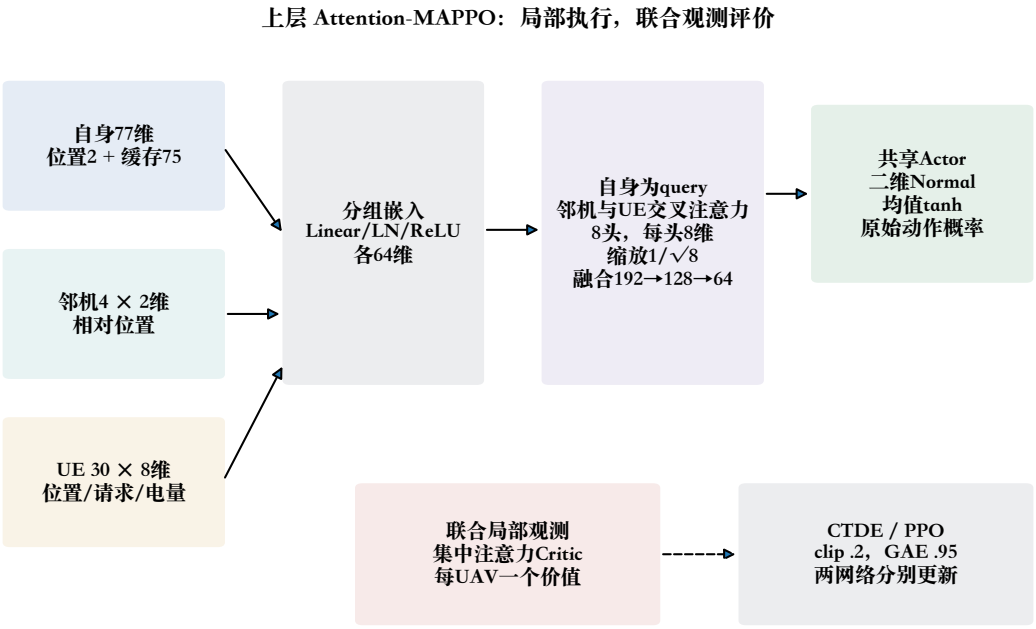


图 3.4　上层 Attention-MAPPO 的网络与训练结构。实线为前向信息流，虚线为仅训练时使用的集中式评价与参数更新；执行阶段每架 UAV 仅用自身局部观测

Figure 3.4　Network and training structure of the upper-layer Attention-MAPPO

集中价值网络的处理与 actor 不同。它先把每架 UAV 的完整三百二十五维观测编码为六十四维嵌入，再在联合观测上计算智能体间注意力，屏蔽自身对自身的注意项。自身嵌入与其他 UAV 上下文拼接为一百二十八维，经价值头输出每架 UAV 的标量估计 $V_{\phi,u}(\mathbf{o})$。这种联合评价利用其他智能体的信息解释共同奖励，而执行时 actor 仍只需自身局部观测。共享参数提升样本利用率，但五架 UAV 在同一环境内的轨迹相关性不会因此变成五次独立实验。

3.4.5　正态策略、原始动作概率与 PPO

策略头给出 $\boldsymbol{\mu}_\theta(o_u) = \tanh(W\mathbf{f}_u + \mathbf{b})$，以及两个可学习、与状态无关的对数标准差。对数标准差限制在 $[-20, 2]$，$\boldsymbol{\sigma} = \exp(\mathrm{clip}(\log\boldsymbol{\sigma}, -20, 2))$。原始二维动作采用独立正态分布：

$$\begin{aligned} \mathbf{z}_u &\sim \mathcal{N}(\boldsymbol{\mu}_\theta(o_u), \mathrm{diag}(\boldsymbol{\sigma}^2)), \\ \log\pi_\theta(\mathbf{z}_u \mid o_u) &= -\sum_{k=1}^{2}\left[\frac{(z_{u,k}-\mu_{u,k})^2}{2\sigma_k^2} + \log\sigma_k + \frac{1}{2}\log(2\pi)\right]. \end{aligned} \tag{3.32}$$

均值的 tanh 不会把随机样本限制在 $[-1, 1]$。这是普通正态策略加执行裁剪，不是对采样变量整体作 tanh 变换的压缩正态策略。因此，缓冲区保留原始 $\mathbf{z}_u$ 和对

应原始对数概率，PPO 比率在这一空间计算；不应添加压缩正态的雅可比项，也不应拿裁剪后的动作代替原始动作重算概率。

将裁剪与几何修复视为确定性环境映射，可以得到一个以原始动作驱动的有效决策过程。多个原始动作可能映射到同一执行位移，故饱和区的探索效率可能较低，但这不改变实现中的概率定义。确定性评估使用均值并裁剪后执行，结果对应不同于训练随机采样的评估策略，实验协议应固定是否启用探索。

对采集的每个智能体序列，用终止掩码 d_t 计算时序差分与 GAE：

$$\delta_{u,t} = r_{u,t} + \gamma(1-d_t)V_{\phi,u}(\mathbf{o}_{t+1}) - V_{\phi,u}(\mathbf{o}_t), \qquad \widehat{A}_{u,t} = \delta_{u,t} + \gamma\lambda_{\mathrm{GAE}}(1-d_t)\widehat{A}_{u,t+1}. \tag{3.33}$$

$\gamma = 0.99$、$\lambda_{\mathrm{GAE}} = 0.95$。递推展开得到后续 TD 残差的折扣和，终止位置不向下一回合引导。缓冲区先形成回报目标 $\widehat{R}_{u,t} = \widehat{A}^{\mathrm{raw}}_{u,t} + V^{\mathrm{old}}_{u,t}$，再对 actor 使用的优势作整体均值和标准差归一化；若先归一化优势再构造回报，将改变 critic 的数值目标。

记新旧原始动作概率比为 $\rho_{u,t} = \exp(\log \pi_\theta(\mathbf{z}_{u,t} \mid o_{u,t}) - \log \pi_{\theta_{\mathrm{old}}}(\mathbf{z}_{u,t} \mid o_{u,t}))$，裁剪替代目标为

$$L^{\mathrm{CLIP}} = \widehat{\mathbb{E}}_{u,t}\left[\min\left(\rho_{u,t}\widehat{A}_{u,t}, \mathrm{clip}(\rho_{u,t}, 1-\varepsilon, 1+\varepsilon)\widehat{A}_{u,t}\right)\right], \qquad \varepsilon = 0.2. \tag{3.34}$$

正优势样本限制过度增大概率所能获得的收益，负优势样本限制过度减小概率所能获得的收益。裁剪作用于目标函数，不是强制所有更新后比率都在区间内，也不是硬 KL 约束。因此，本文采用 PPO 作为稳定训练组件，不声称由该目标证明每次更新的真实回报单调提高。

actor 最小化 $-L^{\mathrm{CLIP}} - \beta_H \overline{H}$，$\beta_H = 0.005$。实现将正态熵在批次及两个动作坐标上取平均，$\overline{H} = \frac{1}{2}\sum_{k=1}^{2}\frac{1}{2}\log(2\pi e\sigma_k^2)$；对数概率则在两个坐标上求和，二者约定不同。critic 使用裁剪值损失：

$$\begin{aligned} V_u^{\mathrm{clip}} &= V_u^{\mathrm{old}} + \mathrm{clip}(V_{\phi,u} - V_u^{\mathrm{old}}, -\varepsilon, \varepsilon), \\ L_V &= \frac{1}{2}\widehat{\mathbb{E}}_{u,t}\max\left[(V_{\phi,u} - \widehat{R}_{u,t})^2, (V_u^{\mathrm{clip}} - \widehat{R}_{u,t})^2\right]. \end{aligned} \tag{3.35}$$

两网络分别使用 Adam，学习率均为 3×10^{-4}，梯度范数上限为 0.5。每次收集一千步，以二百五十六小批量更新八轮，超参数见表 3.3。

本章的覆盖观测候选与强基线均采用无注意力请求级 MAPPO 下层，两层参数独立、在各自方法内训练。旧下层的质量掩码使用估计时延和算力份额筛选协作目标，允许估计协作时延达到截止期的 1.50 倍、相对最佳本地或 MBS 时延的 1.35 倍，并要求邻机算力份额比不低于 0.25；本地作为兜底，不保证按时完成。其违例驱动自适应惩罚不能视为已证明收敛的原始–对偶算法。第五章采用

表 3.3　上层 MAPPO 主要超参数

Table 3.3　Main hyperparameters of the upper-layer MAPPO

超参数	取值	超参数	取值
折扣因子 γ	0.99	GAE 系数 λ_{GAE}	0.95
裁剪系数 ε	0.2	熵系数	0.005
演员/评论家学习率	3×10^{-4}	梯度范数截断	0.5
rollout 长度	1000 步	更新轮数	8
小批量大小	256	注意力头数 / 嵌入维	8 / 64

算法 3.1　上层 Attention-MAPPO 的概率与执行一致训练流程

Input: 自然覆盖环境、训练种子、回合数 E、当前下层策略
Output: 共享 actor 参数 θ 与集中 critic 参数 ϕ

初始化网络、优化器和缓冲区;
for $e \leftarrow 1$ **to** E **do**
　重置环境，生成当前请求、接纳关系与观测 $\mathbf{o}_0$;
　for $t \leftarrow 0$ **to** 999 **do**
　　从局部观测采样原始动作 $\mathbf{z}_{u,t}$，保存其对数概率;
　　用联合观测计算 $V_{\phi,u}$，下层计算当前请求分配;
　　将 clip($\mathbf{z}_{u,t}, -1, 1$) 与分配交给环境;
　　环境先执行请求，再修复并应用位移，结算奖励并生成下一观测;
　　保存原始动作、旧值、奖励、终止掩码与观测;
　end
　依据式 (3.33) 形成原始优势及回报，再归一化 actor 优势;
　for $k \leftarrow 1$ **to** 8 **do**
　　以小批量 256 优化式 (3.34) 及式 (3.35);
　end
end

最新 SF-HLM 主线时，进一步按其冻结合同说明在线反馈与可行性机制，本章不把历史下层配置替代为未经该批次验证的新方法。

3.5　预接纳需求观测设计

3.5.1　缺失需求与局部可辨识性

原观测把三十个 UE 槽全部用于已经关联到自身的用户。若存在两个物理状态，其已关联用户、自身位置、缓存和邻机相同，而未覆盖用户分布不同，则原观测也相同。任何仅依赖该观测的确定性 actor 都会给出相同动作，随机 actor 也只能给出相同分布。由此可知，原观测不能针对这两个状态作需求方向上的区分；这种状态混叠是由输入定义造成的，不是优化器未充分训练所能彻底消除。

预接纳观测补入感知范围内但尚未被任何 UAV 接纳的用户，使策略在满足

容量限制时区分不同未服务需求分布。它提供的是当前请求和电量信息，作用于下一时隙移动。由于下一步用户继续移动、请求重新抽样，上层不应被理解为准确追赶同一个任务；当前未接纳需求同时也是用户空间位置、近期业务和能量状态的线索。历史确认实验检验的正是这种当前信息是否有助于长期接纳与服务。

3.5.2　确定性槽位填充与容量约束

扩展模式首先按距离升序保留自身已关联 UE，距离平局按用户编号确定；随后按距离升序补入 460 m 内尚未被任何 UAV 接纳的 UE，直到三十槽用满。已由其他 UAV 接纳的用户不作为未接纳需求重复补入。若已有三十名自身关联用户，则扩展模式没有额外槽位；若两组用户合计少于三十，则其余补零。该规则保持维度、特征归一化、掩码、actor 和 critic 完全相同，仅改变进入固定输入的用户集合。

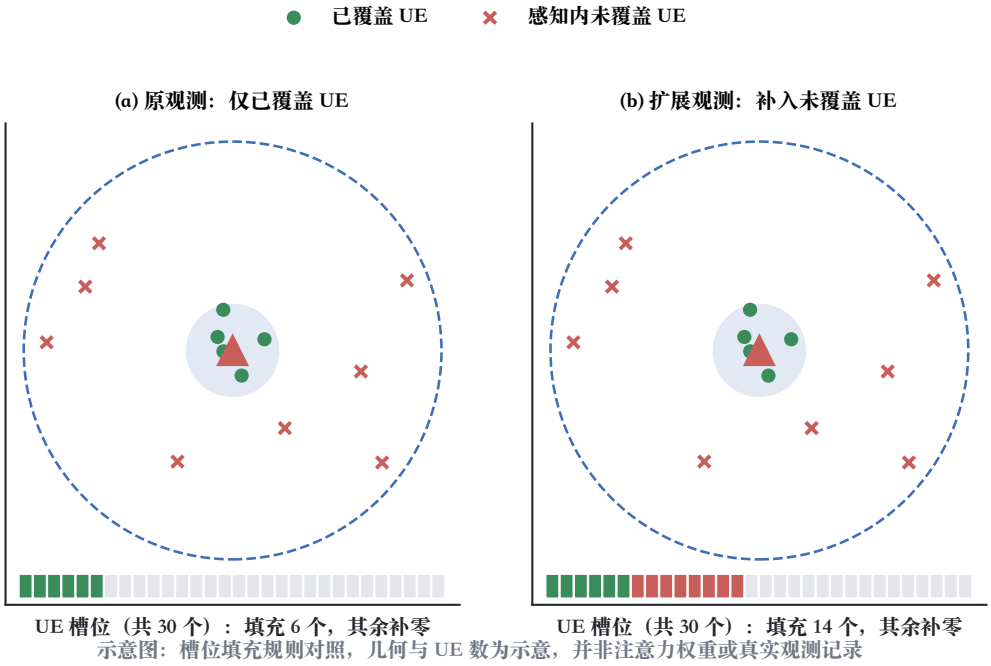


图 3.5　原观测与扩展观测的槽位填充规则对照（同一几何示意）。原观测仅含已覆盖 UE，扩展观测以距离顺序补入感知范围内尚未接纳的 UE；图为规则示意，非注意力权重或真实记录

Figure 3.5　Slot-filling rules of the original and the extended observation under the same illustrative geometry

以 $\mathcal{A}_u$ 标记自身关联用户、$\mathcal{V}_u^{\mathrm{un}}$ 标记感知范围内未接纳用户，槽位列表可表示为

$$\mathcal{L}_u = \mathrm{first}_{30}\left[\mathrm{sort}_{(d,\mathrm{id})}(\mathcal{A}_u) \,\|\, \mathrm{sort}_{(d,\mathrm{id})}(\mathcal{V}_u^{\mathrm{un}})\right]. \tag{3.36}$$

该排序服务于可重复输入与对现有功能的保护：原来用于自身业务的信息先进入，未覆盖信息使用剩余容量。它不意味着距离排序已经最优，也不保证截止期

更紧的用户优先可见。服务优先、信息裁剪等其他填充策略需要独立协议，本章不把它们的探索结果与当前确认数据混为同一方法。

一个构造的槽位例子可以说明改动范围。若当前自身关联十二名 UE、感知范围另有二十五名未接纳 UE，则原观测含十二个真实槽和十八个空槽；扩展观测仍保留原十二名，并补入最近十八名未接纳 UE，其余七名仍不可见。下层只处理自然接纳的真实服务集合，不会把新增十八个观测槽直接变成十八项卸载动作。若次步移动使部分用户进入服务圆，只有那时生成且被接纳的请求才能执行。

3.5.3 从观测信息到可实现收益

本章扩展观测假定决策前可获得未接纳 UE 的位置、当前请求字段和电量，并在历史确认协议中没有加入这些字段上报的额外时延、丢失与通信能耗。因此，本章可检验“在这些信息可用时，扩展输入能否改善服务”，不能单独证明在任何现实网络中无代价获得这些信息。感知半径是仿真中的可见性假设，不能直接等同于经实测验证的请求广播范围。

输入维度不变也不等于信息预算相同。基线的空槽含零信息，候选的非空槽含业务信息，尽管二者网络都接收三百二十五个数值。评价结构优势时需要把双方提供的信息统一；评价信息作用时则应保持网络与训练配置相同。本章后一种对照支持观测设计的价值，第五章依据最新协议评价 SF-HLM 的信息条件与下层学习机制，不能将本章相同网络下的结果写成注意力胜过所有同信息模型。

对信息延迟的逻辑影响也可以由时序分析得到。如果需求字段来自 $t-\ell$ 时刻，位置误差与业务更新都可能降低其对下一覆盖的指示作用；但是否使性能下降、下降多少，需要真实延迟或缺失实验，不能从观察半径直接计算。当前覆盖确认主要说明理想当前信息的作用，为随后研究信息可得性、同信息对照和在线质量反馈提供依据。

3.6 瓶颈诊断、独立确认与机制解释

3.6.1 由失败来源确定干预方向

自然覆盖修正版全量实验使用五个训练种子和十个工作负载。主场景的原完整双注意力方法 DSR 为 0.2428，无注意力下层变体为 0.2609，差值为 -1.81 个百分点，配对交叉 bootstrap 的 95% 区间为 $[-2.40, -1.17]$。这一结果使后续覆盖实验采用后者作为强基线，而不把下层注意力预设为优势。它属于该历史配置下的比较，不意味着注意力在一切卸载问题中无效，也不替代最新 SF-HLM 的

评价。

对强基线二十五个完整评估单元的描述性诊断发现，DSR 为 0.2459，未覆盖请求占全部实际生成服务请求的 48.14%，占失败请求的 63.84%。图 3.6 依式 (3.2) 把结果分为成功、已接纳超时和未接纳三类。该计数显示覆盖是值得优先干预的瓶颈，而非把所有失败都归为卸载策略错误。描述性比例只刻画该诊断批次，不能作为改变某一组件必然有效的因果证明。

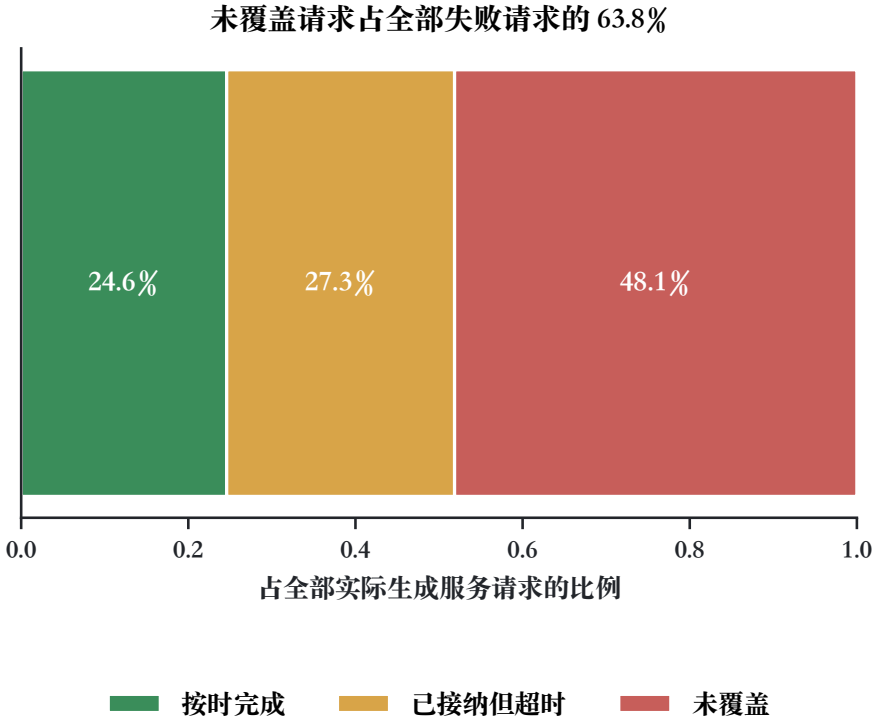


图 3.6　主场景实际生成服务请求的结果构成（下层无注意力强基线，瓶颈诊断批次，25 个评估单元的计数汇总）

Figure 3.6　Outcome composition of generated service requests in the main setting (strong baseline, diagnostic batch)

同一诊断在五十个冻结快照上用双步质量掩码局部搜索检验卸载余量，成功数由 362 增至 441，快照分母下提升 5.13 个百分点，同时分配能耗增加 22.86%。冻结快照搜索并不回写环境，且采用与在线学习不同的计算预算，因此该结果不能充作长期 DSR 提升或可部署策略上界。它给出的补充判断是：覆盖之外仍有质量余量，但改善质量可能需要更多能耗和计算。第三章优先处理需求不可见，第四章专门分析固定请求下的整体分配，第五章再研究在线协同。

3.6.2　探索与确认使用不同种子

覆盖观测实验采用两阶段协议。探索阶段为五个训练种子乘五个工作负载，候选和强基线共十次训练、五十个评估任务、三百个回合。其目的在于筛选观测方向，不能把筛选后最高结果当作独立确认。确认阶段使用全新的十个训练种子

和五个工作负载，两方法共二十次训练、一百个评估任务和六百个评估回合，每个检查点在每个工作负载上运行六回合。探索与确认的差别见表 3.4。

表 3.4　覆盖观测两阶段实验协议

Table 3.4　Two-stage protocol of the coverage-observation experiments

协议要素	探索性 pilot	独立确认
训练种子	5 个（与历史批次共用）	10 个（全新）
工作负载种子	5 个	5 个（全新）
每检查点评估	5 工作负载 × 6 episode	5 工作负载 × 6 episode
训练/评估规模	10 次训练 / 50 任务	20 次训练 / 100 任务 / 600 episode
方法差异	仅上层观测槽位填充规则；下层配置相同、分别训练	
统计单位	训练种子；工作负载配对	
结论用途	方向筛选，不独立支撑结论	本章主证据

一百个评估任务组成五十对方法配对单元，而不是一百对。对每个训练种子 k，先平均五个工作负载的 DSR 差值 $d_{k,w}$，得到 $d_k = 5^{-1}\sum_w d_{k,w}$；十个 d_k 才是主检验中的独立训练重复。工作负载、回合和单个请求嵌套于训练结果，不能把它们当成额外训练种子扩大样本量。对训练种子差值使用配对 t 区间：

$$\bar{d} \pm t_{0.975,9}\frac{s_d}{\sqrt{10}}, \qquad s_d^2 = \frac{1}{9}\sum_{k=1}^{10}(d_k - \bar{d})^2. \tag{3.37}$$

同时归档交叉重采样作为另一种不确定性评估，但正文主效应沿用预定的训练种子配对口径，不择取数值更有利的区间。

配对评估共享外生请求与移动随机流，有助于减少工作负载难度差异；两方法则各自训练，不能共享一个模型后仅在评估中修改观测来替代学习差异。代码内容摘要、协议与原始计数用于确认对应来源，任务验收通过说明运行和分析完整，不自动赋予主张更宽的适用范围。

3.6.3　确认结果及训练曲线的用途

探索阶段 DSR 差值为 +3.30 个百分点，交叉 bootstrap 95% 区间为 [+1.29, +5.33]，由此进入独立确认。确认结果见表 3.5：等权评估单元平均 DSR 从 0.2444 提高至 0.2793，差值 +3.49 个百分点，训练种子配对 95% 区间为 [+2.44, +4.54]。十个训练种子的差值均为正，五十个配对单元中四十九个为正。这说明结果不仅由一个特别有利的训练种子推动，也具有较一致的配对方向。

为说明不同汇总方式的量级，该确认批次基线累计生成服务 9,805,179 个、按时完成 2,395,429 个，候选相应为 9,804,541 和 2,738,233 个。合并计数所得 DSR 约为 0.24430 与 0.27928，与表中等权均值接近但不完全相同。主报告保留表中预定均值及配对区间；合并计数在此仅用于解释口径，并不增加一次独立证据。

表 3.5　独立确认实验的主场景结果（10 个新训练种子 × 5 个新工作负载）

Table 3.5　Main-setting results of the independent confirmation

指标	强基线（原观测）	候选（扩展观测）	配对差值 [95% 区间]
DSR S/G	0.2444	0.2793	+0.0349 [+0.0244,+0.0454][a]
接纳率 A/G	0.4996	0.6189	+0.1193
接纳后按时完成率 S/A	0.4919	0.4537	−0.0382 [−0.0752,−0.0012][a]
每评估单元的回合平均机队能耗差	候选相对基线		-3.50×10^6 J
Jain 公平性差	候选相对基线		+0.0786

[a] 以训练种子为独立单位的配对 t 区间。DSR 差值为本章主结论；接纳后完成率下降为机制分析指标，未单独作多重比较校正。先在每评估单元内汇总请求计数求比例，再平均 50 个单元；不以全部单元合并计数的比例替代本表均值。平均 DSR 不等于两个平均因子的乘积。

图 3.7 展示十个训练种子的均值和标准差，用于观察学习过程的走势与跨种子波动。标准差带不是均值置信区间，训练奖励也不是独立测试表现。曲线可提示观测改动在学习过程中持续产生差异，但不能仅凭平滑或末段平台宣称理论收敛、排除训练不稳定，或证明部署后性能保证。主结论依赖固定检查点后的配对评估，而非挑选曲线中最高的一段。

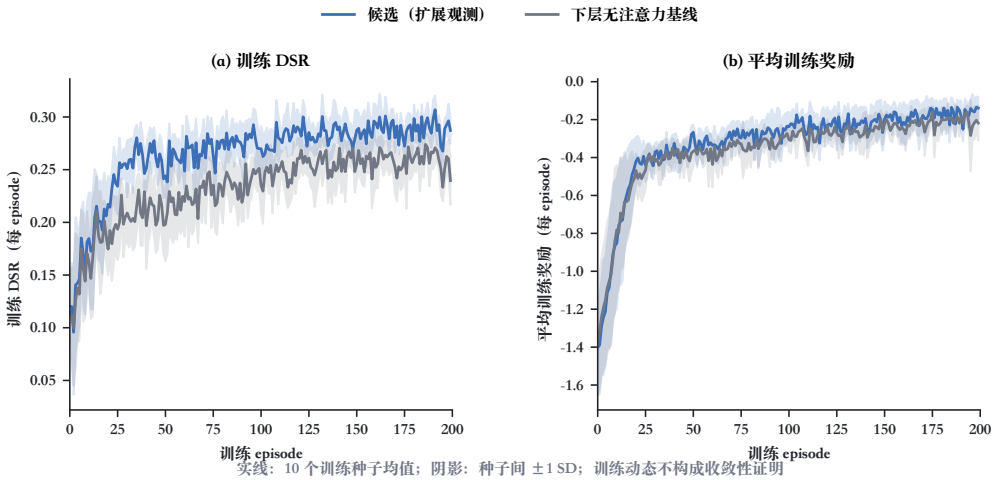


图 3.7　独立确认实验的训练曲线（10 个训练种子的均值 ± 标准差）：(a) 训练 DSR；(b) 平均训练奖励

Figure 3.7　Training curves of the independent confirmation (mean ± std over ten training seeds)

3.6.4　接纳扩展与接纳后质量的联合解释

候选的平均接纳率从 0.4996 提高至 0.6189，增加 11.93 个百分点；接纳后按时完成率从 0.4919 变为 0.4537，差值为 −3.82 个百分点，训练种子配对区间为 [−7.52, −0.12] 个百分点。图 3.9 按训练种子汇总五个工作负载展示两项指标，说明接纳扩大与条件质量变化方向不同。条件质量变化未单独作多重比较校正，应作为机制分析指标解释。

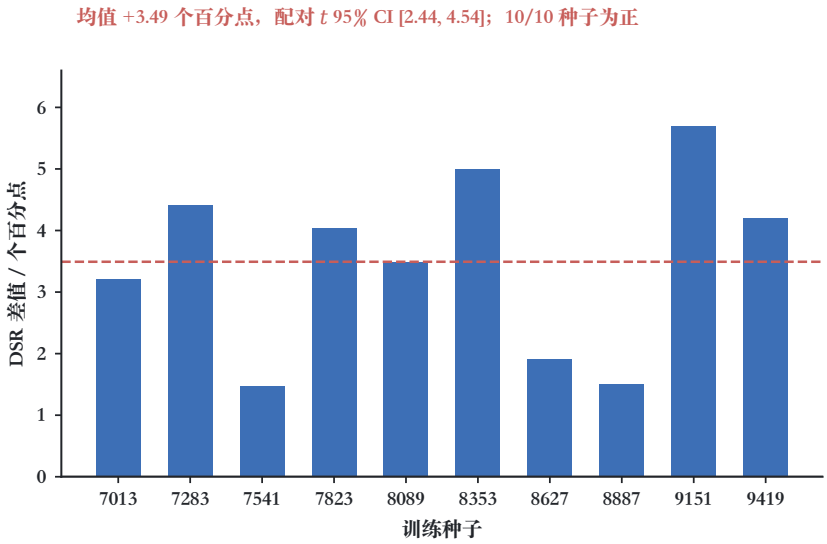


图 3.8　独立确认实验中候选相对强基线的逐训练种子 DSR 差值（每个种子为 5 个工作负载差值的平均；区间为配对 t 95% 区间）

Figure 3.8　Per-training-seed paired DSR differences of the candidate against the strong baseline

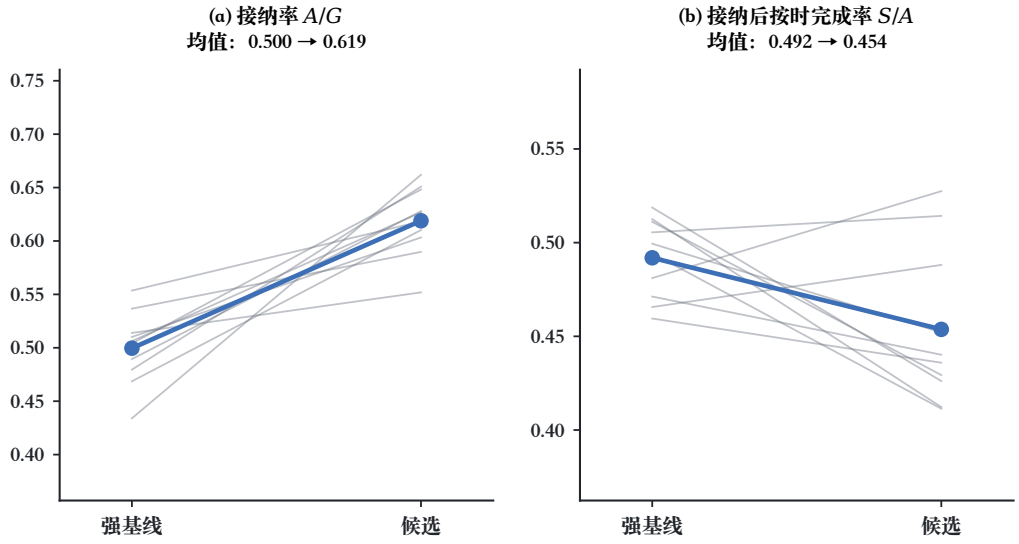


图 3.9　确认实验中接纳率与接纳后按时完成率的配对比较（每点为一个训练种子下五个配对工作负载的均值）。两因子反向变化，DSR 增益来自接纳因子

Figure 3.9　Paired comparison of the admission fraction and the deadline satisfaction among admitted requests

按式 (3.4) 在五十个配对单元内分解并平均，接纳变化项贡献约 +5.62 个百分点，接纳后质量变化项贡献约 −2.13 个百分点，两者合计 +3.49 个百分点。该结果比直接相乘表中均值更准确地说明端到端增益：扩大接纳带来的成功机会超过了条件质量下降的抵消。它不意味着每个新增请求都成功，也不意味着每个原有请求的时延都变差，后者需要逐请求反事实匹配，而当前方法运行中的轨迹和批量不同。

这种结果与系统模型相容。更多 UE 进入覆盖后，接入带宽被更多关联用户分摊，服务批次可能增加，缓存缺失和有限回传也可能成为更明显的瓶颈。上层把需求送入系统，下层还要在最终负载竞争下安排执行位置。因此，本章所建立的观测优势是增加可服务机会，进一步发挥这些机会依赖卸载质量。第五章在冻结既有上层策略的条件下研究 SF-HLM 的下层决策，避免把下层奖励或监督信号反馈成一个未经验证的新上层；其效果由最新独立实验决定，不能由本章代数分解提前推定。

机队能耗在同一确认批次中平均减少约 3.50×10^6 J，约为基线的 6.37%，公平性平均提高 0.0786。前者是评估单元内回合平均的完整机队能耗差，不是每请求节省的焦耳；后者采用包含全部请求类型的累计公平性口径。这两项描述性方向支持该主场景中接纳扩展没有伴随对应均值恶化，但不构成所有指标全面最优的结论，也不把未建模的信息上报能耗自动算作零代价优势。

3.6.5　本章证据支持的设计判断

本章确认实验在同一注意力结构与下层配置下比较观测内容，支持在一百 UE 主场景和当前信息假设下，把可见未接纳需求送入上层能提高端到端 DSR。由于网络保持相同，它明确定位了一个可实施的输入改动，避免将改进笼统归因于“更复杂的模型”。该优势具有清楚的触发条件：原输入存在空槽或容量可用于补充未接纳用户，且这些用户信息在决策前可用。

相同网络的对照没有识别注意力相对同信息非注意力模型的独立优势；理想信息协议也没有识别信息上报成本后的净收益。本文把这些问题交给相应协议处理，而不把未知因素当作已解决。已有阶段性结果最有价值的含义，是明确自然覆盖系统必须同时考察需求可见性、接纳率和接纳后质量，为下一章的分配质量研究和第五章的最新 SF-HLM 主线建立可检验的问题。

3.7 本章小结

本章在自然覆盖规则下建立了无人机集群协同轨迹决策的系统与学习模型。统一 $G/A/S$ 计数表明，端到端 DSR 由接纳与接纳后质量共同决定；通信、缓存、批量算力、UE 电池和机动结算的推导明确了空中平台部署与任务执行的耦合路径。上层动作采用原始正态概率与确定性执行修复，当前请求在移动前执行，轨迹主要影响下一时隙接纳。Attention-MAPPO 以定长局部观测执行、联合观测评价，为各机依据邻机与需求信息开展分散轨迹决策提供了训练框架。

在这一框架中，预接纳观测保持三十槽和物理半径不变，补入感知范围内尚未接纳的用户。独立确认支持主场景 DSR 增加 3.49 个百分点，其主要来源是接纳扩展，并伴随接纳后质量的稀释。由此，轨迹控制和卸载质量需要在共同系统模型下协同评价。第四章冻结请求与几何，在消除轨迹差异的条件下研究全批次分配的质量余量与代价；第五章按最新 SF-HLM 协议评价完整在线方法，不能把本章历史候选或第四章离线搜索直接当作最新策略的性能证据。

第 4 章　考虑跨机资源竞争的截止期优先计算任务分配

4.1　固定快照问题与受控比较范围

第三章研究无人机集群如何通过空间部署接纳地面需求，本章进一步研究集群如何分担已经接纳的计算任务。请求接入某架无人机后，其执行节点仍可选择来源本机、允许的协作无人机或地面 MBS。执行位置会改变回源、机间转发、机载计算负载和能耗。该问题不仅涉及为单个请求选择最快节点，还涉及选择后整批请求如何分享各机算力。一项迁移可能使目标请求提前完成，也可能同时使迁入节点上多个原有请求超时。因此，跨机任务分配需要在同一执行模型中考虑全批次影响。

这里的任务分配以不可拆分的计算请求为对象，关联无人机承担接纳与上传职责，执行节点承担计算职责。二者可以不同，因而集群具有在空间接入后继续协作分工的机会。不同无人机的算力、缓存与链路条件不同，地面 MBS 则作为六节点服务系统中的计算支撑。本章保持这些既有资源规则，研究任务从一个执行节点转移到另一个节点时的系统后果；这与为飞行器分配巡检航点、侦察目标或编队位置具有不同的任务语义。

本章固定 UAV 和 UE 的历史几何、当前缓存、电量、请求集合以及配置，对同一快照上的候选分配作独立反事实评价。每次评价从完全相同的状态开始，用生产环境执行整批请求，得到完成时延和 UAV 分配能耗。候选执行结果不回写用于采样的参考历史，下一快照仍来自同一参考控制轨迹。通过这一受控设计，可以把“选择了不同执行目标”与“经过不同历史已产生不同状态”区分开来。

固定快照的研究问题是：在自然接纳、最终批量负载均分的条件下，以减少超时请求为第一优先级的跨节点迁移搜索，能否比自身代价启发式给出更好的集群当步分工，以及这种质量余量需要多少能耗和求解时间。该问题与在线强化学习不同。在线下层必须在很短时间内从观测产生动作，且动作会通过缓存和 UE 电池影响后续运行；快照求解器可以对大量候选逐一重评估，却不会改变后续状态。本章方法据此定位为集群任务分配的受控分析与离线质量参照。

本章主实验的快照沿 Heuristic-Control 参考历史采集，不能视为第三章学习候选或最新 SF-HLM 的轨迹分布。第五章关注完整在线方法，第四章末另以历史学习轨迹快照进行桥接。两类快照保留各自来源，不把相同名称的指标直接拼接为同一批次结论。第四章实现采用 MC-ITR 单请求迁移搜索，没有拍卖、竞价或任务出价机制，也没有被接入最新在线策略作为每步下层。

4.1.1 变量、候选域与实际节点映射

设快照接纳服务集合为 $\mathcal{M}$，大小为 $K = |\mathcal{M}|$，请求按 UE 编号升序排列。全系统 UE 数仍记为 M，避免把快照活跃请求数与总人口混淆。请求 m 具有来源 UAV u_m、输入字节 L_m、服务文件字节 B_{s_m}、总 CPU 周期 $C_m = \omega_{s_m} L_m$、截止时间 D_m 和优先级字段 p_m。任务优先级提供给部分学习观测，但本章目标不按 p_m 加权；“截止期优先”指超时数在目标层级中优先，不能解释为优先级字段决定奖励权重。

每请求的候选集合记为 $\mathcal{C}_m$，包含来源本地、MBS 与硬可行邻机。分配向量 $\mathbf{a} = (a_1, \cdots, a_K)$ 属于

$$\mathcal{A} = \prod_{m \in \mathcal{M}} \mathcal{C}_m, \qquad |\mathcal{A}| = \prod_{m \in \mathcal{M}} |\mathcal{C}_m|. \tag{4.1}$$

使用花体 $\mathcal{C}_m$ 表示候选集，以区别总周期 C_m。实现动作编号为 0 本地、1 MBS、$2 + j$ 协作 UAV j；来源 UAV 自身的协作编号被排除，本地编号则映射到请求的来源。记 $d_m(a_m)$ 为动作对应的实际计算节点，则不同来源请求选择本地时可能到达不同 UAV，不能把动作编号零当作全系统同一个计算节点。

硬可行集合与学习策略的质量掩码不同。硬集合检查邻机可达、目标非自身、链路与算力等物理字段有效，本地和 MBS 保留为有效来源路径；邻机没有缓存也可通过回源取文件执行。本章枚举硬可行节点，不要求每条路径都预计满足截止期。若预先删除所有预计超时动作，会改变优化空间，并可能把估计误差当成严格物理约束；本章不采用这样的候选域。

4.2 全批次执行、缓存与分配代价

4.2.1 通信与真实缓存路径

第三章给出了移动前几何、信道和缓存模型，本章在同一规则下具体化分配评价。字节数据 L_m 在比特每秒速率 R 上传输的时间为

$$T_{\mathrm{tx}} = 8L_m / R. \tag{4.2}$$

输入上传以来源 UAV 的全部关联 UE 数分配接入带宽，分配目标不会更换上传来源或该分母。文件回源用 B_{s_m}，而非服务输入 L_m。因此，两个请求即使输入相同，服务文件大小、缓存位置和截止时间不同，也可能需要不同执行节点。

记 $U_m = 8L_m / R^{\mathrm{edge}}_{m,u_m}$，$V_{j,s} = 8B_s / R^{\mathrm{bh}}_{j,\mathrm{M}}$，$I_{m,u,v} = 8L_m / R^{\mathrm{inter}}_{u,v}$。缓存指示 $h_{j,s}$ 来

自快照起点真实状态，非命中概率。给定分配后，三类路径为

$$\begin{aligned} T_m(\text{local};\mathbf{a}) &= U_m + (1-h_{u_m,s_m})V_{u_m,s_m} + C_m N_{u_m}(\mathbf{a})/F_{u_m}, \\ T_m(\text{coop } \upsilon;\mathbf{a}) &= U_m + I_{m,u_m,\upsilon} + (1-h_{\upsilon,s_m})V_{\upsilon,s_m} + C_m N_\upsilon(\mathbf{a})/F_\upsilon, \\ T_m(\text{MBS};\mathbf{a}) &= U_m + 8L_m/R^{\text{bh}}_{u_m,\text{M}} + C_m/F_{\text{M}}. \end{aligned} \tag{4.3}$$

该式重申实际缓存与估计缓存的差别：Heuristic-Control 可以依据邻机命中概率预测路径，评价所有方法时则使用同一冻结真实缓存。不能把“期望缺失回源”写入本章实际生产执行时延。

各分配评价均冻结快照初始缓存，因此同批次较早发生的取文件不会立即改变后续请求的命中状态。若两项任务都需要某个起点未缓存的服务文件，它们在当前评价中各自支付回源项；待提交缓存只影响该私有副本步进后的状态，不影响其他候选评价。这一处理保证分配目标与请求遍历顺序不会偷偷改写待比较问题，也防止一项候选因先被评价而享有缓存优势。

4.2.2　节点最终负载与计算推导

生产执行先解析整批目标，再冻结 UAV 最终负载：

$$N_j(\mathbf{a}) = \sum_{m\in\mathcal{M}} \mathbf{1}[d_m(a_m) = j], \qquad \mathcal{M}_j(\mathbf{a}) = \{m : d_m(a_m) = j\}. \tag{4.4}$$

本地留存与协作迁入共同计入 N_j，协作迁出和 MBS 任务不计入。只要 $m \in \mathcal{M}_j$，便有 $N_j \geqslant 1$，每请求获得 $f_{m,j} = F_j/N_j$。由周期除以处理频率与动态功率积分得到

$$T^{\text{cmp}}_m = C_m N_j/F_j, \qquad E^{\text{cmp}}_m = \kappa C_m (F_j/N_j)^2, \qquad \kappa = 10^{-27}. \tag{4.5}$$

在 MBS 上，计算频率固定为 $F_{\text{M}} = 200\,\text{GHz}$，不随其任务数均分。UAV 与 MBS 的处理规则是仿真合同的一部分，本章没有另加 MBS 排队容量或 CPU 能耗目标。

算力均分是频率资源的简化分享，而非持续排队。每个请求具有不同计算周期，但均分份额不按输入大小加权；它们的计算时延因此可不同。时间超过时隙或截止期的请求仍会被本次评价计算完整路径，不保留到后续时隙排队。依据初始来源服务数预估的份额只用于启发式上下文，实际 $N_j(\mathbf{a})$ 必须在所有目标确定后重新计算。忽略这一步会令请求的结果依赖先后执行顺序，破坏公平比较。

4.2.3　迁移对未移动请求的外部影响

考虑把请求 m 从 UAV i 迁往 UAV j，迁移前负载为 $N_i = n_i \geqslant 1, N_j = n_j \geqslant 0$。对仍留在来源的请求 $k \neq m$，计算时延减少 C_k/F_i；对目标既有请求 ℓ，计算时

延增加 C_ℓ/F_j：

$$\Delta T_k^{\mathrm{cmp}} = -C_k/F_i, \quad k \in \mathcal{M}_i \setminus \{m\}; \qquad \Delta T_\ell^{\mathrm{cmp}} = C_\ell/F_j, \quad \ell \in \mathcal{M}_j. \tag{4.6}$$

这些请求的通信起点、执行节点与缓存不变，所以它们的完整时延变化也等于上述计算变化。被迁移请求则同时更换计算节点、通信路径和可能的回源项，不能只用 C_m/F_j 估计其收益。

对目标原有请求的计算能耗，在 $n_j > 0$ 时有

$$\frac{E_\ell^{\mathrm{cmp,new}}}{E_\ell^{\mathrm{cmp,old}}} = \left(\frac{n_j}{n_j+1}\right)^2. \tag{4.7}$$

迁入增加它们的完成时间，却降低其计算能耗；来源剩余请求则因获得更高频率而更快、但每请求计算能耗上升。这不是矛盾，而是式 (4.5) 中时延与频率倒数、能耗与频率平方的直接结果。是否降低整个系统能耗，要把两节点和通信变化一起计算。

图 4.1 给出算力 $F_u = 60\,\mathrm{GHz}$、输入 $L_m = 2\times10^6$ 字节、每字节 2000 周期的构造示例，总周期 $C_m = 4\times10^9$。当节点负载为二时，每请求获得 30 GHz，计算时间 0.133 s、能耗 3600 J；负载为四时，份额 15 GHz，计算时间 0.267 s、能耗 900 J。这里比较的是二请求与四请求批次，不能写成独占与二请求批次。两组值都由同一公式计算，不是额外实验测量。

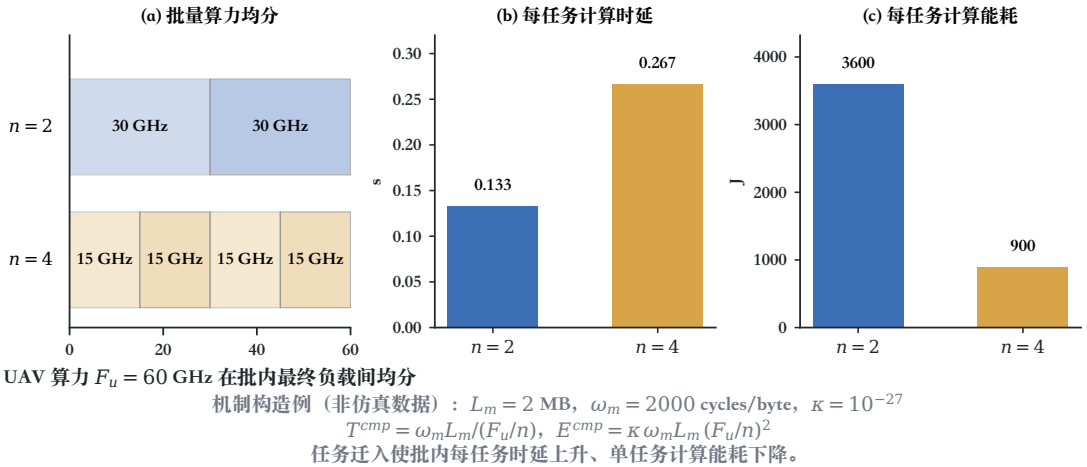


图 4.1　批量算力共享与迁移外部影响的机制示例（构造参数：$F_u = 60\,\mathrm{GHz}$，$L_m = 2\times10^6$ 字节，$\omega_m = 2000$ 周期/字节，$\kappa = 10^{-27}$；数值按式 (4.5) 计算，非实验测量）

Figure 4.1　Mechanism example of batch compute sharing and migration externality (constructed parameters, computed from Eq. (4.5))

若以 $Q_j = \sum_{m\in\mathcal{M}_j} C_m$ 表示节点周期总量，则 UAV 计算总能耗可写为

$$E_j^{\mathrm{cmp}} = \psi(F_j, Q_j, N_j), \qquad \psi(F,Q,n) = \begin{cases} \kappa F^2 Q/n^2, & n > 0, \\ 0, & n = 0,\ Q = 0. \end{cases} \tag{4.8}$$

因此，$i \to j$ 迁移的计算能耗变化为

$$\Delta E^{\mathrm{cmp}} = \psi(F_i, Q_i - C_m, n_i - 1) - \psi(F_i, Q_i, n_i) + \psi(F_j, Q_j + C_m, n_j + 1) - \psi(F_j, Q_j, n_j). \tag{4.9}$$

来源只含该请求时，其迁移后节点能耗按零定义；目标原为空时也使用零初值。该写法避免在空节点套用零分母公式，并把迁移导致的所有计算项一次计算清楚。

一个更细的结论是，增加请求不一定增加该节点总计算能耗。对非空目标，新增周期为 C_m 时，计算总能耗下降当且仅当

$$C_m < Q_j(2n_j + 1)/n_j^2. \tag{4.10}$$

该条件由 $(Q_j + C_m)/(n_j + 1)^2 < Q_j/n_j^2$ 展开得到。若全部请求周期相同，计算能耗按 $1/n_j$ 变化，新增并发请求会让理想均分模型中的节点计算能耗降低；但它们的时延同时增加，且还需通信。本文保留这一模型后果，不将其误写成真实硬件中任意增载都能节能的物理定律。

4.2.4　自身改善不等于系统改善的构造例

为说明截止期外部性，构造两个缓存均命中的 UAV，算力均为 40 GHz，每请求输入为 4×10^6 字节、每字节 2000 周期，故 $C_m = 8 \times 10^9$。把每请求的共同上传时间设为 0.30 s，一次协作输入转发设为 0.12 s。这些是用于推导的指定路径常数，不是主实验快照记录。迁移前来源有五请求、目标有三请求；其中待迁请求截止时间为 1.25 s，来源其余四请求为 1.70 s，目标三请求为 1.00 s，均处于现行截止时间范围。

迁移前来源任务时延为 $0.30 + 5 \times 0.20 = 1.30$ s，目标任务为 $0.30 + 3 \times 0.20 = 0.90$ s。待迁请求超时，其他七项均成功。迁移后两节点均为四请求：待迁请求多付转发，其时延为 $0.30 + 0.12 + 4 \times 0.20 = 1.22$ s，从超时变成功；来源其他任务变为 1.10 s，仍成功；目标三任务也变为 1.10 s，全部越过自身截止时间。表 4.1 汇总该反例。

该迁移使自身超时指示从一变零，却使系统超时数从一增至三。只依据自身字典序代价的迭代会把它视为优先改善，整体评价则应拒绝。这一构造证明的是判据之间存在逻辑差异，不表示每次自身迁移都产生负效应，也不直接量化主实验中有多少改善来自某种具体外部性。主实验的对照用于检验完整方法结果，构造例用于说明为何整体重评估是必要的算法设计。

表 4.1　自身改善与系统超时变化的构造例（非实验数据）

Table 4.1　Constructed example of own-request improvement and system deadline misses

请求组	数量	截止时间/s	迁移前时延/s	迁移后时延/s
待迁请求	1	1.25	1.30（超时）	1.22（成功）
来源其余请求	4	1.70	1.30	1.10
目标既有请求	3	1.00	0.90	1.10（超时）

4.2.5　分配因果能耗与共同项排除

本章能耗项定义为随卸载目标变化的 UAV 通信和计算代价：

$$
\begin{aligned}
E_m^{\mathrm{local}} &= (1-h_{u,s})P^{\mathrm{bh,rx}}V_{u,s} + \kappa C_m (F_u/N_u)^2,\\
E_m^{\mathrm{coop}} &= (P^{\mathrm{tx}}+P^{\mathrm{rx}})I_{m,u,v} + (1-h_{v,s})P^{\mathrm{bh,rx}}V_{v,s} + \kappa C_m (F_v/N_v)^2,\\
E_m^{\mathrm{MBS}} &= P^{\mathrm{bh,tx}} 8L_m/R_{u,\mathrm{M}}^{\mathrm{bh}}, \qquad E_{\mathrm{assign}} = \sum_{m\in\mathcal{M}} E_m^{a_m}.
\end{aligned}
\tag{4.11}
$$

其中 $u=u_m, s=s_m$，功率沿用第三章。协作能耗计入发送 UAV 和接收 UAV 两端；MBS 网格供电计算不计入机队。每个服务路径共有的来源 UAV 输入接收 $P^{\mathrm{rx}}U_m$ 被排除，不能把所有非飞行 UAV 能耗都统称为分配能耗。

固定轨迹下飞行、悬停和 WPT 不随服务分配变化，内容处理也不属于服务目标优化项。将这些共同项加入每个候选只会改变显示尺度，不改变同快照分配之间的能耗差，因此本章把它们与分配目标分开。UE 电池的上传消耗在快照中也不作为 UAV 能耗计入。完整运行能耗与分配能耗的联系在第三章式 (3.19) 中给出，二者比较时必须保持分母与求和范围一致。

本章归一化能耗为整个快照 $E_{\mathrm{assign}}/(25000\,\mathrm{J})$，不再除以 UAV 数。学习下层奖励中的机队平均归一化可使用 $N\times 25000\,\mathrm{J}$，上层则使用 $N\times 5000\,\mathrm{J}$，三者不是同一数值。这里的 25000 J 是固定参照，指标可以大于一，不是禁止超越的能量预算。以明确口径报告，可以解释后文 2.128 的意义，而不会把它误读为能耗百分比或超出电池容量。

4.3　严格字典序目标与共同基线

4.3.1　为何优先比较超时请求数

对于具有任务截止期的边缘服务，是否按时完成是离散的质量界限，而缩短已成功任务的时延只是连续改善。若把超时、平均时延和能耗直接作固定加权和，算法可能通过降低很多成功任务的能耗抵消一个新增超时，也可能因单位改变而改变偏好。本文的目标先满足截止期优先的设计意图，再在第一层相同时比

较其他代价。

严格字典序目标为

$$F(\mathbf{a}) = \Bigg(\sum_{m\in\mathcal{M}} \mathbf{1}[T_m(\mathbf{a}) > D_m], \\ \frac{1}{\max(K,1)} \sum_{m\in\mathcal{M}} \frac{T_m(\mathbf{a})}{\max(D_m, 10^{-9}\,\mathrm{s})}, \\ \frac{E_{\mathrm{assign}}(\mathbf{a})}{25000\,\mathrm{J}} \Bigg). \tag{4.12}$$

记三个分量为 F_1, F_2, F_3。对 $F(\mathbf{a}')$ 与 $F(\mathbf{a})$，从第一分量开始找到首个不相等的位置，该处较小者为较优分配。实现不取整、不设置字典序容差、不加 MBS 独立惩罚，也不将请求优先级乘入超时计数。$T_m = D_m$ 视为成功；空快照 $K = 0$ 时三个分量均为零。

例如，$(2, 0.91, 2.80)$ 比 $(3, 0.70, 1.20)$ 更优，因为少一个超时；在超时数同为二时，$(2, 0.89, 3.10)$ 又比 $(2, 0.91, 2.80)$ 更优；只有前两个分量完全相等，第三分量才决定顺序。这些示例是目标比较的构造数字，不是某次实验结果。它们说明字典序严格下降并不要求时延与能耗同时下降，更不支持把算法描述为所有指标一致改善。

第二分量使用每请求的 T_m/D_m，能区分在不同截止时间下的相对压力。它并非仅超时任务的平均延误，也不是所有请求共享一个截止阈值。对于同一快照，K 和能耗参照在方法间相同，对每一层乘以正数不会改变字典序排序；但跨快照平均 F_2, F_3 是结果汇总，不能理解为对整个历史一次性求得了字典序最优。

4.3.2　边际目标如何包含批量外部性

对 $i \to j$ 迁移，只有待迁请求以及两节点的原有任务计算负载发生变化。在快照通信固定的条件下，第二分量的精确变化可分解为

$$\Delta F_2 = \frac{1}{K}\left[\frac{\Delta T_m}{D_m} - \sum_{k\in\mathcal{M}_i\setminus\{m\}} \frac{C_k}{F_i D_k} + \sum_{\ell\in\mathcal{M}_j} \frac{C_\ell}{F_j D_\ell} \right], \qquad K > 0. \tag{4.13}$$

第一项是自身变化，后两项分别是来源释放和目标竞争的外部影响。若目的地是 MBS，不存在目标 UAV 均分外部项；若来源原为 MBS，也没有来源 UAV 释放项。实际评价器不依赖人工简化导数，而执行完整生产模型，但该式帮助解释为何仅计算自身代价一般不等于系统边际代价。

第一分量更加不平滑。对受影响集合 $\mathcal{H} = \{m\} \cup (\mathcal{M}_i \setminus \{m\}) \cup \mathcal{M}_j$，有

$$\Delta F_1 = \sum_{k\in\mathcal{H}} \left(\mathbf{1}[T_k + \Delta T_k > D_k] - \mathbf{1}[T_k > D_k] \right). \tag{4.14}$$

接近截止边界的原有请求，即使只延长很少时间，也可改变超时数；远离边界的请求延长相同时间则不改变第一层。单看目标平均负载或被迁移请求的时延，无法识别这种离散门槛。整体重评估把真实缓存、最终均分和每请求截止时间共同纳入判据。

第三分量变化由式 (4.9) 加上待迁请求通信及回源变化后除以固定参照得到。超时减少时，搜索可以接受该层上升；超时不变且归一化时延下降时，也可接受能耗上升。这种优先顺序是方法设计选择，优势应表述为给定截止期优先目标下的整体决策，而不能省略能耗代价后声称无条件多目标占优。

4.3.3 四种方法保持相同问题与初值

本章比较四个共享候选域和生产评价器的方法，见表 4.2。Heuristic-Control 按生产启发式构造执行目标，其上下文可使用估计缓存和初始来源负载，而完成结果仍按最终批量模型评估。它既提供参考历史，也作为固定快照上的简单对照。方法之间不更换通信模型、截止期、硬候选集合或缓存状态，避免用较有利的物理假设替代算法改进。

表 4.2 四种卸载方法的差异

Table 4.2 Differences among the four offloading methods

方法	初值	改进依据	终止与验证
Heuristic-Control	自身即初值	原启发式规则，不迭代	单次构造
Greedy-Single-Pass	Heuristic-Control	逐请求自身字典序代价	单轮顺序扫描
Iterative-Base	Greedy-Single-Pass	被迁移请求自身代价	自身无改善/环路/预算
MC-ITR	Greedy-Single-Pass	系统整体字典序目标	邻域无改善/预算退出

Greedy-Single-Pass 从启发式结果出发，按 UE 编号升序逐请求扫描候选节点。定义请求自身目标

$$f_m(\mathbf{a}) = \left(\mathbf{1}[T_m(\mathbf{a}) > D_m],\ T_m(\mathbf{a})/\max(D_m, 10^{-9}\,\mathrm{s}),\ E_m^{\mathrm{assign}}(\mathbf{a})/(25000\,\mathrm{J})\right). \quad (4.15)$$

每次只选 f_m 严格下降的目标并固定选择，完成一轮后不回看前面请求。各请求结果来自完整批量评价，所以它能知道自身在当前负载下的完成代价；它忽略的是评价产生的其他请求变化，而不是完全不使用共享算力模型。严格改善之外的平局保持当前选择。

Iterative-Base 从同一个贪心分配出发，重复枚举单请求迁移，筛选自身代价严格改善的选项，并按自身差值元组、请求编号和目标编号择优。自身变化可能使整体目标变差，且不同请求的自身改善不一定构成共同势函数。因此实现记录已访问分配，以无自身改善、环路守卫或轮数预算退出，不把其终止自动解释为

系统目标的邻域最优。

MC-ITR 也从同一贪心初值出发，但使用 $F(\mathbf{a})$ 的完整变化作判据。相同初值让比较集中于“自身改善”与“整体改善”的差别。不过，共享初值并不意味着两个算法遍历相同路径，它们可以到达不同局部解。理论上的严格下降只相对于 MC-ITR 的初值成立，不保证 MC-ITR 对任意快照都优于另外一个独立搜索终点，后者属于需用数据检验的比较。

4.4　MC-ITR 搜索过程与可证性质

4.4.1　完整单请求迁移邻域

对当前分配 $\mathbf{a}$，定义改变一个请求执行目标的邻域

$$\mathcal{N}_1(\mathbf{a}) = \{\mathbf{a}^{m\to c} : m \in \mathcal{M},\ c \in C_m \setminus \{a_m\}\}, \tag{4.16}$$

其中 $\mathbf{a}^{m\to c}$ 仅把第 m 个分量替换为 c。MC-ITR 每轮完整扫描该邻域，选择所有严格改善选项中系统目标最小的一个，平局按请求序号、目标编号确定。它是最佳改善搜索，区别于发现第一项改善就立即执行的首次改善策略。

每项候选评价均从快照的独立私有副本执行，不沿用上一候选产生的缓存、随机状态或其他累积变化。选定最佳迁移后再次评价，要求结果与扫描时元组完全相同，且仍严格优于当前目标；否则报告评价器不确定或非严格改善错误，不静默继续。这一步保证实际接受的迁移符合算法判据，但不能用少数重复检查证明任意外部随机评价都天然确定，确定性首先来自冻结状态与一致代码路径。

4.4.2　严格下降、有限终止及初值保证

① 命题一：每项接受迁移使系统字典序目标严格下降。

算法仅把满足 $F(\mathbf{a}') <_{\text{lex}} F(\mathbf{a})$ 且复核通过的候选写入当前解，因此接受后的目标严格更小。设第 r 次接受后的分配为 $\mathbf{a}^r$，则

$$F(\mathbf{a}^{r+1}) <_{\text{lex}} F(\mathbf{a}^r), \qquad F(\mathbf{a}^r) \leqslant_{\text{lex}} F(\mathbf{a}^0). \tag{4.17}$$

第一层为整数超时数，所以它不会在接受过程中增加；它不变时第二层必须下降或不变，前两层都不变时第三层下降。这是按层级的保证，不是三分量各自始终单调下降。

② 命题二：无预算限制且评价确定时，搜索在有限次接受后终止。

每请求候选集合有限且非空，$\mathcal{A}$ 因而有限。若某个分配重复访问，确定评价会给出相同目标；但由严格下降链的传递性，后一次目标必须比前一次更小，产生矛盾。所以接受的分配不重复，最多接受 $|\mathcal{A}| - 1$ 次迁移，随后必然无严格改

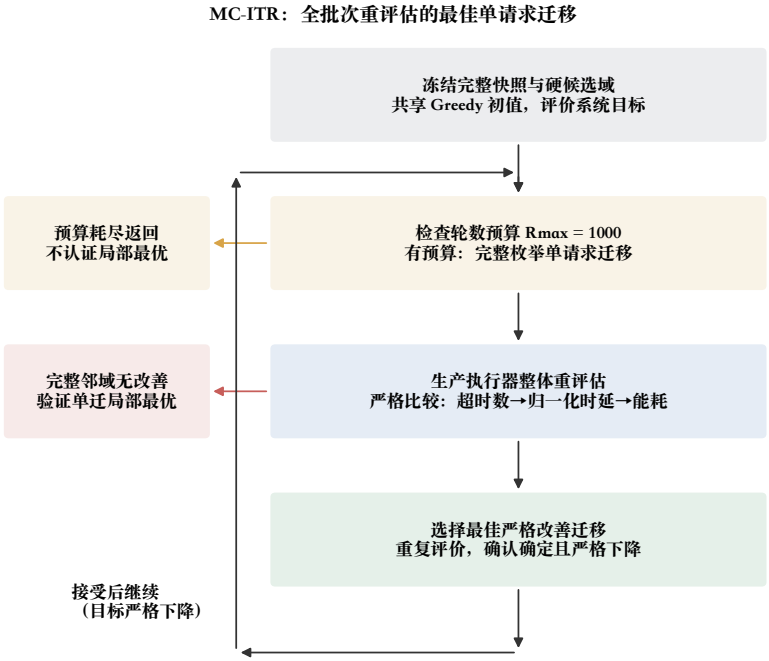


图 4.2　MC-ITR 算法流程。两个出口对应不同结论强度：无改善退出时可验证单请求迁移邻域局部最优；预算退出时不作此声称

Figure 4.2　Flowchart of MC-ITR with two distinct exits

算法 4.1　MC-ITR：全批次重评估的最佳单请求迁移搜索

Input: 固定快照、候选域 $\{C_m\}$、共同贪心初值 $\mathbf{a}^0$、轮数预算 $R_{\max} = 1000$

Output: 分配、目标、终止原因与局部最优验证标记

$\mathbf{a} \leftarrow \mathbf{a}^0$，$\mathbf{v} \leftarrow F(\mathbf{a})$;
for $r \leftarrow 1$ **to** $R_{\max}$ **do**
　best $\leftarrow \varnothing$;
　foreach $m \in \mathcal{M}$, $c \in C_m \setminus \{a_m\}$ **do**
　　从原快照评价 $\mathbf{v}' = F(\mathbf{a}^{m \to c})$;
　　if $\mathbf{v}' <_{\text{lex}} \mathbf{v}$ **then**
　　　用键 $(\mathbf{v}', m, c)$ 更新严格改善中的最优候选;
　　end
　end
　if best $= \varnothing$ **then**
　　return 当前分配，原因“邻域无改善”，验证标记为真;
　end
　重新评价最佳分配，检查元组相同且严格改善;
　接受最佳迁移并更新 $\mathbf{a}, \mathbf{v}$;
end
return 当前分配，原因“轮数预算”，验证标记为假;

善邻居。该上界可能很大，仅用于证明有限性，不能解释为实际运行高效。

引入有限 $R_{\max}$ 后，算法无论是否耗尽分配空间都在有限轮内返回。轮数预算与收敛出口的意义不同：预算给计算量上限，无改善出口给局部搜索完成条件。即便最后一轮已经碰巧到达局部最优，若未扫描该新状态的完整邻域，程序仍不能把预算返回的标记改为已验证。特别地，$R_{\max}=0$ 只评价并返回初值，不检查邻域；不能利用初值可能较好而声称局部最优。

③ 命题三：无改善出口认证单请求邻域的弱局部最优。

在某轮完成全部候选评价且未发现严格改善时，返回解 $\mathbf{a}^*$ 满足

$$F(\mathbf{a}^*) \leqslant_{\text{lex}} F(\mathbf{a}'), \qquad \forall \mathbf{a}' \in \mathcal{N}_1(\mathbf{a}^*). \tag{4.18}$$

证明来自完整枚举与无改善条件。允许邻居具有完全相同目标，因此是不存在严格更优邻居的局部最优，而非唯一最优。该命题依赖候选域完整、评价确定、没有提前截断邻域，以及终止原因为无改善；触发轮数上限时不适用。

MC-ITR 相对于自身贪心初值的非劣保证来自式 (4.17)。它不能扩展成对 Heuristic-Control 初值的普遍保证，因为贪心阶段只看自身目标，可能使系统目标变差；也不能扩展成对 Iterative-Base 的逐快照普遍占优，两者停在不同解上。主实验的平均超时改善来自受控数据，并非把局部下降定理错误外推所得。

4.4.3　局部最优为何仍可不同于全局最优

一个最小离散例子说明单请求邻域的局限。设两个请求各有两个执行编号 $0,1$，构造目标如表 4.3。初始 $(0,0)$ 的超时数为一，两个单迁邻居 $(0,1),(1,0)$ 的超时数均为二，故搜索没有可接受单迁；但同时改动两项到 $(1,1)$ 可令超时数为零。该表是搜索性质的抽象构造，非实际系统某个快照的测量。

表 4.3　单请求局部最优不蕴含全局最优的离散构造

Table 4.3　Discrete construction separating one-request local and global optima

分配	$(0,0)$	$(0,1)$	$(1,0)$	$(1,1)$
构造字典序目标	$(1,1.00,1)$	$(2,1.20,1)$	$(2,1.20,1)$	$(0,0.80,1)$
初始解邻域关系	初值	单请求迁移	单请求迁移	两请求联合迁移

只要存在需要协同调整才能改善的分配，单迁搜索就可能停住。真实批量问题具有来源释放、目标竞争和缓存路径改变等耦合，也没有使局部等于全局的已证明凸性或交换结构。加入二请求交换或多迁邻域可改变可达局部解，但会增加评价量并构成新算法。本章不在已有实现之外补写这样的功能，也不把冻结快照局部解称为主配置全局最优或在线策略的严格上界。

4.4.4 评价量、复杂度与实际调用开销

令平均候选数为 $\bar{c} = K^{-1}\sum_m |C_m|$。每轮不同单请求迁移数为

$$H = \sum_m (|C_m| - 1) = K(\bar{c} - 1). \tag{4.19}$$

主配置中每请求至多本地、MBS 和另外四架 UAV，共六种硬候选，故 $H \leqslant 5K$。这说明单轮候选数随活跃请求数线性增加，不说明整个算法耗时线性，因为每候选评价要处理完整批次和环境状态，接受轮数也依赖问题实例。

若实际扫描 R 轮、接受 r_{acc} 项迁移，搜索核心评价量为

$$Q_{\mathrm{eval}} = 1 + RH + r_{\mathrm{acc}}, \qquad 0 \leqslant r_{\mathrm{acc}} \leqslant R \leqslant R_{\max}. \tag{4.20}$$

起始的一次为初值目标，每轮完整邻域贡献 H 次，每项接受迁移再贡献一次确定性复核。无改善出口一般还含最后一轮的完整扫描，不能把接受次数当作扫描轮数。该式描述搜索函数本身，不包括共享初值构造及结果打包所需的额外调用。

设一次完整生产评价成本为 C_{eval}，则主要时间复杂度为 $O(RK(\bar{c} - 1)C_{\mathrm{eval}})$。$C_{\mathrm{eval}}$ 包含私有环境重建、解析全批目标、服务与其他请求处理及指标计算，随总用户数和数据结构规模变化，不可直接视为单位常数时间的单请求代价。空间包括快照、候选域和搜索轨迹；穷举解空间虽然用于有限性证明，但 MC-ITR 不需要把全部分配同时存储。

实现中的四方法评价路径也影响实测时间。自身代价基线可复用有限容量的候选评价缓存，MC-ITR 核心按未缓存的生产评价作完整扫描和复核。共享的贪心初始化不计入两个迭代方法的本章搜索计时。故 wall time 比较描述实际实现的调用成本，不能仅根据差值断言慢的原因只来自更多轮数、只来自整体数学目标，或推断更换语言、硬件后必定仍有同一差距。

4.5 Exact-Small 与反事实评价协议

4.5.1 完整穷举参照的定义

Exact-Small 在完整 $\mathcal{A}$ 上穷举，每个分配交给相同生产评价器，取字典序最小目标，平局按分配向量编号确定。由于枚举了所有硬可行分配，只要空间大小不超过事先预算、所有评价有效且枚举完成，便可认证该固定快照的全局最优：

$$\mathbf{a}^{\mathrm{ex}} \in \arg\min_{\mathbf{a}\in\mathcal{A}}{}_{\mathrm{lex}} \; F(\mathbf{a}). \tag{4.21}$$

冻结实验计划的枚举预算为 10^4 个分配。空间超过预算时，在评价前标记跳过，不从已枚举的子集结果宣称精确完成。通用函数默认预算与实验覆盖值可能不

同，正文以实际冻结运行计划为准。

穷举时间为 $O(|\mathcal{A}|C_{\mathrm{eval}})$，候选数乘积使大批次难以使用。三 UE 配置从整个环境规模上定义小问题，而不是从一百 UE 快照中删掉大多数任务。后者会改变最终均分 N_j、接入关联数及请求间外部性，剩余任务的目标已不同，不能作为原大问题的精确验证。Exact-Small 的作用是核验小规模实现与比较逻辑，不证明大问题搜索没有全局差距。

4.5.2　快照冻结与无副作用执行

快照保存完整环境状态、请求索引、来源映射和硬候选域，并记录配置摘要。请求索引按 UE 编号升序保持搜索一致，下层执行槽位则按原环境的来源距离及用户编号映射回去，不能把搜索列表序号直接当成下层槽号。配置摘要检查保证评价时没有悄然更换 CPU、带宽或接纳规则；私有复制保证候选之间不共享可变缓存与统计量。

评价时从序列化快照重建私有环境，注入显式卸载分配，采用统一固定移动动作，执行一个生产环境步。为了保留当前请求记录，评价器阻止该私有步末的新请求覆盖，但当前请求处理、缓存提交及其他私有更新仍按生产路径进行。它们的结果只用于该候选，不回写参考历史，也不传给下一候选。执行中如果发生卸载回退，评价器拒绝把它当作原目标分配的有效结果。

分配能耗通过生产执行的请求记录累计，不另建一套只对 MC-ITR 有利的能量公式。所有服务目标先解析，所有最终负载再冻结，之后请求逐个执行。该设计让评价结果反映完整批量外部性，同时减少两套数学模型随维护逐渐偏离的风险。本章的推导用于解释该统一模型，而不是绕过它以解析近似值替代主结果。

4.5.3　可重复性应检查什么

固定快照的可重复性包括输入、代码配置和评价顺序。相同分配重复评价应得到同一有限目标；候选域应非空，所有返回动作应属于相应硬集合；超时数应为非负整数，时延与分配能耗应为非负有限数。贪心与迭代方法的初值应确实相同，MC-ITR 每个接受目标应严格下降，无改善标记应对应完整邻域检查。精确参照必须先核对空间大小与完成标记，不能把 “运行未报错” 替代为最优性验证。

上述检查解决实现与协议一致性，不自动证明论文效应。一个算法可以通过所有调用与格式检查，却在目标上不优于基线；一个小例找到精确解，也不能替

代多负载工作负载上的实际效果。因而本章把算法性质、实现验证和实验比较分开：性质由假设与逻辑支撑，验证说明实现遵守合同，性能则由后文配对结果支撑。

4.6 实验设计、主结果与代价解释

4.6.1 410 个评估单元的组成

主配置为五 UAV、一百 UE。负载敏感性使用六十、八十、一百二十、一百四十 UE，算力敏感性使用主配置 UAV 算力的 $0.6, 0.8, 1.2, 1.4$ 倍，其他协议保持对应冻结设置；再加三 UE Exact-Small，共十种配置。每配置十个工作负载，每工作负载六回合，每回合在 $0, 100, \cdots, 900$ 步采集十快照，因而每配置六百快照，总计六千快照。

九个正常规模配置各比较四个方法，构成 $9 \times 10 \times 4 = 360$ 个“配置–工作负载–方法”单元；Exact-Small 配置包含第五个穷举方法，构成 $1 \times 10 \times 5 = 50$ 单元，两部分合计四百一十。该计数说明评估完整性，不把同快照重复评价的四或五个方法当作独立状态。空接纳快照保留，其目标为零，反映自然覆盖参考历史中确实可能没有待卸载服务。

对每个工作负载种子，先求其六十个快照的指标平均，再在十个工作负载之间比较。主要指标为每快照平均超时数、平均 F_2、平均归一化分配能耗和平均搜索耗时。对于方法 c 和参照 b，设种子 w 的快照平均差为

$$d_w = \frac{1}{60} \sum_{h=1}^{60} \left(Y_{c,w,h} - Y_{b,w,h} \right), \qquad \bar{d} = \frac{1}{10} \sum_{w=1}^{10} d_w. \tag{4.22}$$

置信区间以这十个工作负载配对单元作五千次 bootstrap，而不是对六千个有序历史快照直接作独立抽样。相邻快照共享历史，回合与请求也嵌套于工作负载，不能扩大独立重复数。

第四章不训练新的学习模型，因此这里的独立单位是工作负载种子，不能套用第三、五章训练种子检验的叙述。敏感性设置重新采样各自参考历史并重新求解，比较的是该配置下的求解器，而非固定学习检查点的跨场景泛化。所报告区间描述对应配置的差值不确定性，不是对所有未测试场景同时成立的保证。

4.6.2 主配置的截止期优势

表 4.4 与图 4.3 给出一百 UE 主配置结果。MC-ITR 每快照平均超时数为 2.055，低于 Iterative-Base 的 2.228、Greedy-Single-Pass 的 2.243 和 Heuristic-Control 的 2.908。共同贪心初值之后的整体重评估，因而在该批次取得了更好的第一优

先级结果。相对迭代基线的 0.173 个请求差值约为其平均超时数的 7.8%；这一相对量由表中均值计算，不表示所有快照都减少相同比例。

表 4.4　固定快照主配置的卸载方法比较（十个工作负载种子均值）

Table 4.4　Offloading methods on the fixed-snapshot main setting

方法	每快照平均超时数 ↓	归一化分配能耗	搜索耗时/s
Heuristic-Control	2.908	1.278	0.103
Greedy-Single-Pass	2.243	1.814	0.941
Iterative-Base	2.228	1.872	1.970
MC-ITR	2.055	2.128	2.574

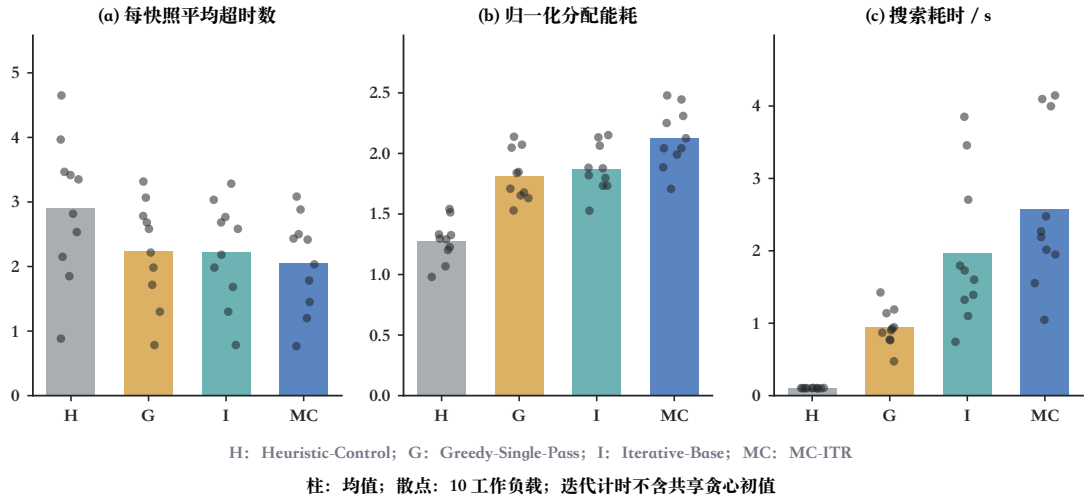
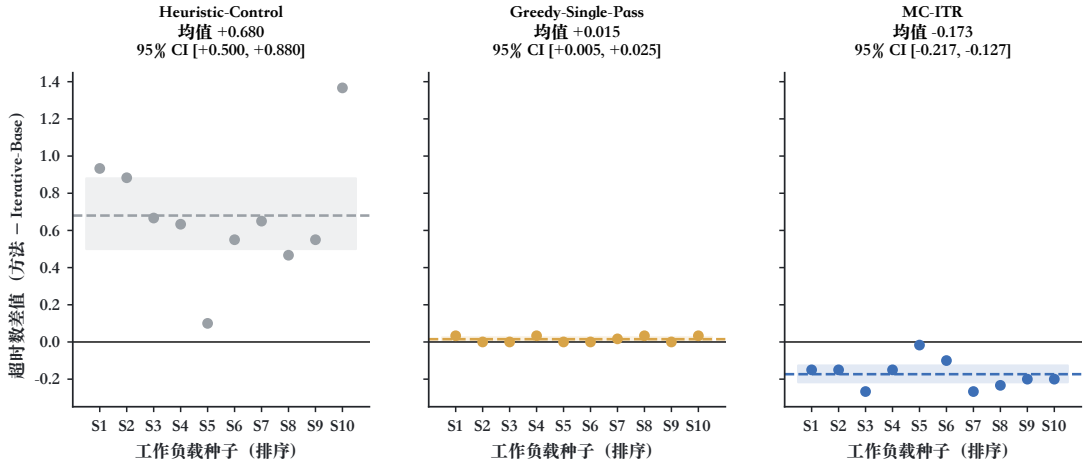


图 4.3　固定快照主配置下四种卸载方法的超时数、分配能耗与搜索耗时（柱为十个工作负载种子均值，散点为逐种子值）

Figure 4.3　Deadline misses, assignment energy and solver time of the four methods on the main setting

与 Iterative-Base 的配对差值为 -0.173，95% bootstrap 区间 $[-0.217, -0.127]$，十个工作负载的方向均为负。与 Greedy-Single-Pass 的差值为 -0.188，区间 $[-0.233, -0.137]$；与 Heuristic-Control 的差值为 -0.853，区间 $[-1.068, -0.643]$。图 4.4 展示配对方向与区间，使不同方法面对同一难度状态的比较更直接。该结果支持的是每快照平均超时数量的改善，不能换算成未经闭环运行验证的端到端 DSR 提升。

主结果的解释与方法机制一致：整体判据允许接受自身未明显改善却能释放其他紧迫任务算力的迁移，也拒绝自身变好但令更多邻机任务超时的迁移。这两种可能性由批量推导与构造例说明。现有汇总数据并未逐项统计所有接受迁移的类别，因此不能声称量化识别了各类机制贡献比例；直接得到的数据结论是完整 MC-ITR 相对这些对照的平均截止期表现。



S1-S10：42、84、126、168、210、252、294、336、378、420；阴影：5000 次 bootstrap 的95%区间

图 4.4　各方法相对 Iterative-Base 的每快照超时数配对差值（十个工作负载种子；区间为 5000 次重抽样的 95% bootstrap 区间）。散点、均值虚线与阴影区间描述该固定快照批次中的工作负载配对差异

Figure 4.4　Paired per-snapshot deadline-miss differences against Iterative-Base

4.6.3　第二、第三目标的联合报告

归一化时延方面，MC-ITR 减 Iterative-Base 的均值为 +0.0004，区间 $[-0.0019, +0.0031]$ 跨零。它说明该批次没有明确识别整体均值变化方向，不等价于时延非劣的正式证明，也不能写成减少超时没有时延代价。字典序允许以第二层上升换第一层改善，故此处结果应按实际区间解释，而不与理论性质混淆。

归一化分配能耗方面，MC-ITR 为 2.128，高于 Iterative-Base 的 1.872，差值 +0.256，区间 $[+0.214, +0.298]$。按固定能量参照换算，对应每快照平均约 6400 J 的分配能耗增量，约为该参照方法均值的 13.7%。这一换算来自目标归一化定义，不是新的能耗实验。由于共同输入接收及机动等项未纳入，该百分比不能直接作为完整机队能耗增幅。

截止期优先的目标在资源紧张时可能把更多任务安排到成本更高但及时的路径，或者通过降低某节点负载提高其剩余任务份额，造成计算能耗上升。上述机制提供对观测能耗变化的解释，但具体原因仍由逐分配路径记录决定。论文据此把减少超时作为本章清晰优势，同时把能量增量视为实现该优势的实际代价，避免用“字典序能耗最小化”掩盖在高优先级变化时允许发生的能耗上升。

4.6.4　搜索时间与在线预算

MC-ITR 平均搜索耗时为 2.574 s，Iterative-Base 为 1.970 s，Greedy-Single-Pass 为 0.941 s，Heuristic-Control 为 0.103 s。两个迭代方法的计时不含共同 Greedy 初始化；表中 Greedy 自身值也不能机械加到每个方法的平均值后替代另一次完整

路径实测，因为具体调用、缓存和记录阶段不同。它们首先说明本章实际实现为获得整体分配质量进行了更多生产评价。

仿真时隙为一秒，但离线评价的 wall time 并未作为任务通信或计算时延的一部分加进 T_m。所以，快照方法的截止期结果不能解释成“等待两秒多求解后仍满足原截止时间”的真实在线流程。若要在线部署，需要把求解、信息收集和下发延迟纳入新的运行协议，或使用蒸馏、候选裁剪等近似机制另行验证。本章当前实现承担质量参照，而第五章的学习下层承担有限在线调用预算。

4.7　敏感性、精确检查与搜索完成情况

4.7.1　负载与算力变化

图 4.5、图 4.6 展示正常规模九种配置的结果，表 4.5 汇总 MC-ITR 与 Iterative-Base 的配对超时差。九种包含一个主配置和八个敏感性配置，不能称为九个额外敏感性变体。各差值区间均低于零，支持所测试范围内平均方向一致；这是一组逐配置结果，未声称同时区间覆盖或未测试负载的普遍有效性。

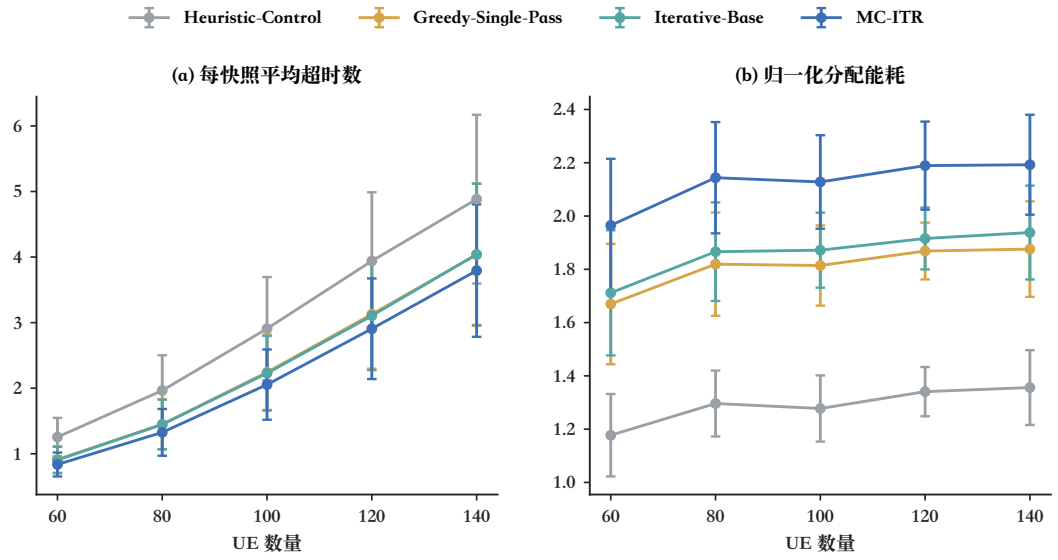


图 4.5　UE 数量变化下四种方法的超时数与分配能耗（误差线为十个工作负载种子的逐项 95% t 区间，非同时覆盖）

Figure 4.5　Sensitivity to the UE count

UE 数从六十增加到一百四十时，平均超时差依次为 −0.068, −0.120, −0.173, −0.198, −0.248。主系统有限覆盖和计算资源面对更高人口，可能出现更多活跃服务竞争与截止门槛，因此整体重评估的绝对余量增加与模型预期相容。不过，UE 总数不直接等于每快照接纳请求数，快照难度

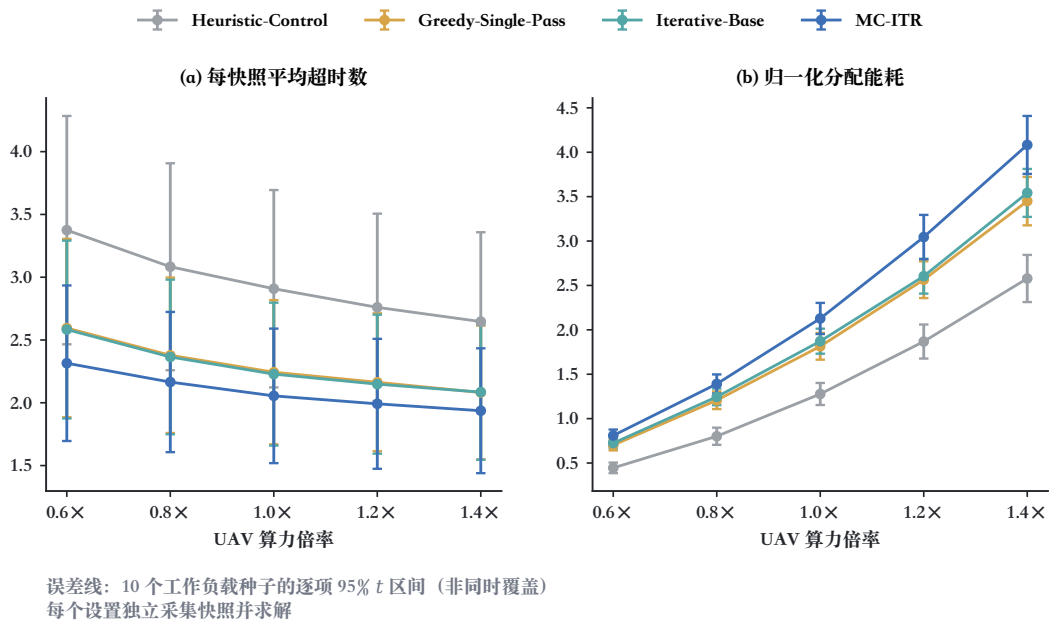


图 4.6　UAV 算力倍率变化下四种方法的超时数与分配能耗（误差线口径同图 4.5）

Figure 4.6　Sensitivity to the UAV compute capacity scale

表 4.5　各变体配置中 MC-ITR 相对 Iterative-Base 的每快照超时数差值

Table 4.5　Paired deadline-miss difference (MC-ITR minus Iterative-Base) across variants

变体	超时数差值 [95% 区间]	MC-ITR 搜索耗时/s
主配置（100 UE，标准算力）	−0.173 [−0.217,−0.127]	2.574
UE 60	−0.068 [−0.097,−0.042]	0.747
UE 80	−0.120 [−0.147,−0.092]	1.416
UE 120	−0.198 [−0.255,−0.142]	4.092
UE 140	−0.248 [−0.312,−0.183]	5.793
算力 0.6 倍	−0.268 [−0.348,−0.193]	2.744
算力 0.8 倍	−0.200 [−0.252,−0.147]	2.475
算力 1.2 倍	−0.157 [−0.207,−0.108]	2.599
算力 1.4 倍	−0.148 [−0.205,−0.102]	2.557

也随参考轨迹和请求类型改变；不能仅据这一序列证明改善幅度严格由人口单一因素决定。

算力为 0.6 倍时差值为 −0.268，0.8 倍为 −0.200，标准为 −0.173，1.2 倍为 −0.157，1.4 倍为 −0.148。算力缩小时，相同 C_m 的计算时间和迁移外部变化 C_m/F_j 增大，更容易触及截止边界；较高算力则减轻该部分竞争。各配置仍有负向差值，说明改善不限于单一算力点，但不能外推为任意算力下都有效，更不能把该固定快照现象替代为 SF-HLM 的跨场景学习结果。

能耗与算力敏感性应共同解释。式 (4.5) 中固定负载的能耗与算力平方正相关，而时延与算力反比；不同方法又会改变节点负载。因而曲线中的能耗趋势不是简单的“算力越大越省电”。本章使用统一功率模型和任务集合比较，保留这种质量与能量的相互作用，不用单项敏感性曲线宣称全部资源扩容都能降低系统代价。

4.7.2　Exact-Small 检查能验证到何处

三 UE 验证配置包含六百快照，其中五百一十三为空，八十三有单请求，四个有双请求，空快照比例 85.5%。图 4.7 展示这一分布以及方法的三个目标均值。小规模枚举器在完整硬可行域完成穷举，MC-ITR 的平均超时数 0.025、归一化时延 0.0608、归一化分配能耗 0.1542 与精确参照逐项相同；Greedy 与 Iterative 的对应均值也相同。

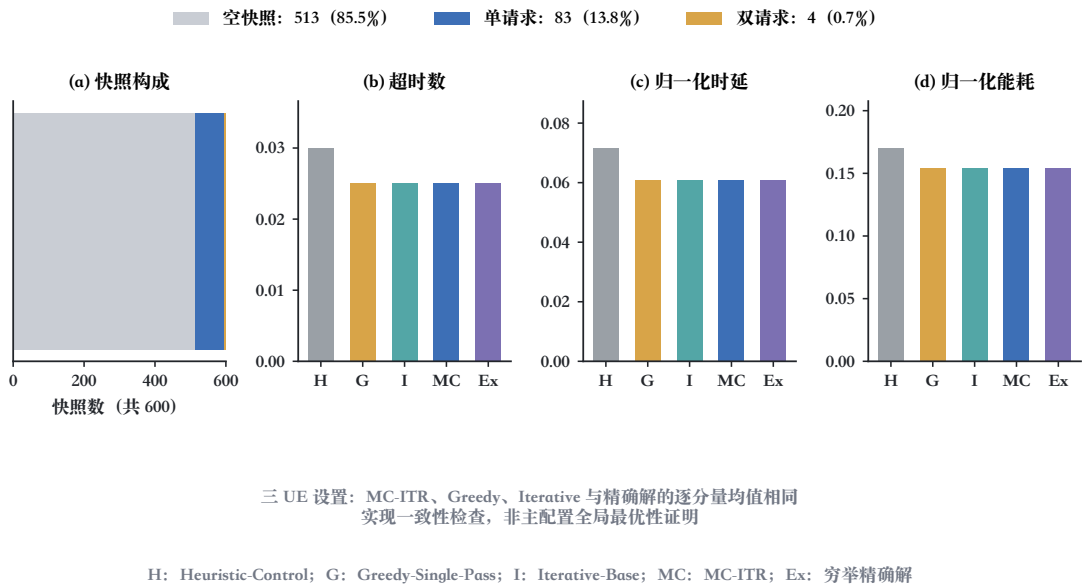


图 4.7　Exact-Small 配置的快照构成与各方法逐分量均值。(a) 600 个快照的构成；(b)-(d) 三 UE 小规模下 MC-ITR、Greedy、Iterative 与穷举精确解的逐分量均值相同，仅 Heuristic-Control 存在差距

Figure 4.7　Snapshot composition and per-component means on the Exact-Small setting

空快照的所有方法目标天然为 $(0,0,0)$，所以大量空状态会稀释非空差异。单请求快照没有同节点其他服务的批量外部性，最佳自身选择与全局选择接近同一个问题；仅四个双请求快照才可能体现更复杂的耦合。由此，该配置对评价和比较逻辑有价值，却不具备区分高维搜索能力的充分难度。均值相同也应与逐快照完成标记和精确比较记录结合，不能只看保留四位小数的柱图就推断每个解向量完全相同。

精确最优目标不必对应唯一分配。多个节点路径可以给出同样目标，算法与穷举采用不同确定性平局规则时，可得到不同分配向量但相同最优代价。实现核验应比较目标与硬可行性，再明确是否要求相同分配；不能将目标一致误写成所有动作逐项一致。本章只利用现有完整小规模参照支持实现一致性，不借此声称主配置达到全局最优。

MC-ITR 在此配置平均求解时间为 8.2 ms，穷举为 5.2 ms。当非空空间极小，完整邻域扫描、接受复核和框架调用可比直接枚举更费时，局部搜索不必在最小问题上最快。两者相同量级也不能外推大问题，穷举的分配空间随请求数呈乘积增长，只有明确空间预算下的完成才具备精确意义。

4.7.3 搜索完成标记与规模代价

归档结果显示，十种配置的 MC-ITR 邻域局部最优验证比例均为 100%，本批次没有轮数预算退出。该事实意味着每快照都经过无改善出口的完整邻域检查，符合命题三的条件。它不意味着已证明在任意更大请求规模下预算仍足够，也不能从完成比例推导具体接受轮数远低于预算；后者需要逐轮轨迹统计。

平均搜索时间在六十 UE 时为 0.747 s，八十 UE 时为 1.416 s，主配置为 2.574 s，一百二十 UE 为 4.092 s，一百四十 UE 为 5.793 s。实际耗时随规模明显上升，但这几个点不能确立渐近阶数。活跃任务数、每项候选数量、改善轮数、生产步评价规模以及缓存命中都可能参与变化，不能直接拟合一个幂律后替代算法复杂度证明。

比主配置迭代基线多花的时间也没有唯一的“轮数更多”解释。整体评价、复核、基线缓存复用与完整环境复制都属于实际代码路径。要进一步优化实现，应依据逐阶段 profiling 或候选复用率，而不凭均值推定瓶颈。本章保留实测时间作为应用边界，当前完成状态只认证既定搜索完成与质量，不为实时部署背书。

4.8　历史学习轨迹桥接与本章小结

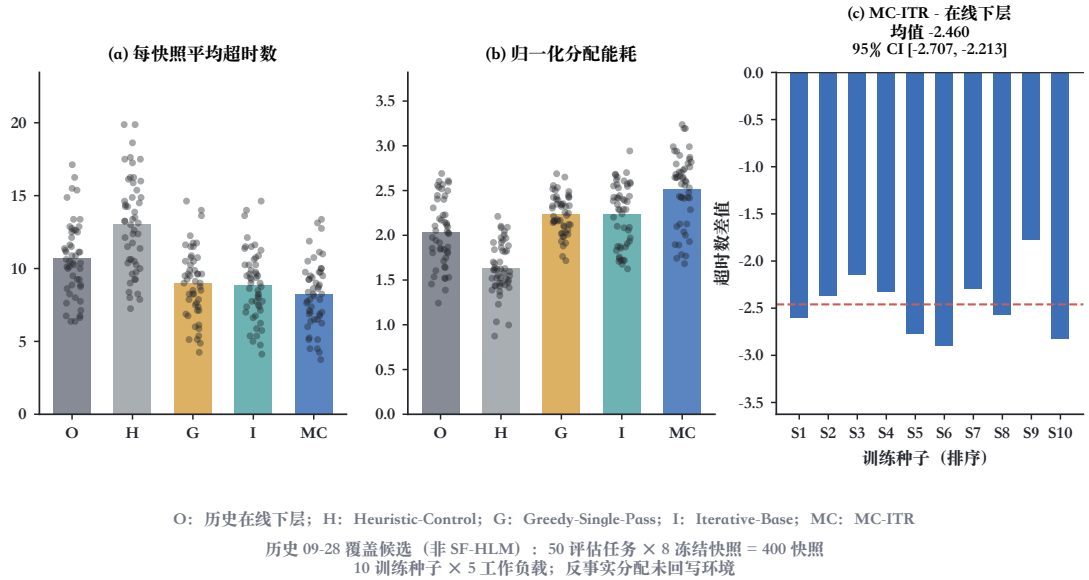
4.8.1　桥接设计与来源限定

为检验离线分配分析在学习轨迹上是否仍有质量余量，2026-09-28 桥接实验从当时覆盖观测候选的十个训练种子和五个工作负载中选取五十个在线评估任务，共采集四百个冻结快照。在相同快照上比较原在线学习下层与 MC-ITR，反事实分配仍不回写环境。这里的历史覆盖候选是上层扩展观测加既有无注意力下层，不是最新 SF-HLM；保留该来源是理解结果的必要条件。

该桥接更换的是快照分布，仍保持同快照候选之间的请求、缓存和最终负载模型一致。它回答“这批学习轨迹状态上是否存在离线分配改善空间”，而非“把 MC-ITR 接入闭环后长期运行会提高多少”。一旦写回反事实分配，后续缓存、电池、请求定型及上层观测可能变化，原来的轨迹不再保持，长期 DSR 需要新的闭环运行才能确定。

4.8.2　质量余量与完整调用时间

图 4.8 给出历史桥接结果。MC-ITR 每快照平均超时 8.235，原在线下层为 10.695，配对差 −2.460，以训练种子为独立重复的 95% 配对 t 区间为 $[-2.707, -2.213]$，十个种子的差均为负。归一化分配能耗分别为 2.519 和 2.035，MC-ITR 约高 23.8%。这支持给定历史轨迹下的分配质量余量，并表明改善仍附带分配能耗代价。



O：历史在线下层；H：Heuristic-Control；G：Greedy-Single-Pass；I：Iterative-Base；MC：MC-ITR

历史 09-28 覆盖候选（非 SF-HLM）：50 评估任务 × 8 冻结快照 = 400 快照
10 训练种子 × 5 工作负载；反事实分配未回写环境

图 4.8　2026-09-28 历史覆盖观测候选轨迹的快照桥接（400 个快照；反事实不回写）。该候选不是最新 SF-HLM，快照来源与计时口径亦不同于本章主实验

Figure 4.8　Bridge comparison on frozen snapshots from candidate trajectories

完整 MC-ITR 调用含贪心初值，平均 20.751 s；在线下层平均调用约 0.012 s。桥接时间与本章主实验 2.574 s 的计时口径不同，快照分布和请求规模也不同，不能通过二者之差估算贪心初始化时间。该量级对照说明，在这批状态上以完整离线搜索获取额外质量，与在线学习的快速推断承担不同职责。它不证明 MC-ITR 是严格全局最优上界，也不把该批次的调用耗时比自动推广为硬件无关常数。

桥接统计使用十训练种子，每个种子内汇总五个工作负载；本章主快照实验则使用十工作负载种子。两者独立单位不同，不能把四百快照或五十任务当成五十次独立训练，亦不能合并两批次的区间以增加样本。该历史分析为后续在线下层改进提供参照，最新 SF-HLM 的结果必须在其自身冻结协议与独立评估中建立。

4.8.3 本章结论与后续在线方法的关系

本章以固定历史状态为条件，建立了机载批量算力均分下的截止期优先计算任务分配问题。跨机迁移外部性推导说明，自身请求改善与集群整批目标改善一般不同；MC-ITR 因而完整枚举单请求迁移，并用生产执行模型重评估系统字典序目标。在评价确定、候选完整且无预算退出时，算法有限终止并认证单请求邻域局部最优；该性质不蕴含主配置全局最优。

四百一十个评估单元支持该方法在主配置及八个敏感性配置中减少平均超时请求，同时报告更高分配能耗和秒级搜索代价。Exact-Small 对小规模评价与比较逻辑提供一致性检查，历史学习轨迹桥接进一步刻画在线下层与离线搜索之间的质量余量。第五章在保持其最新冻结上层和信息协议的条件下评价 SF-HLM 在线下层，承担长期闭环与可用决策预算的问题；本章 MC-ITR 继续作为分析参照，不作为已经接入在线系统的性能组成。

第 5 章　无人机集群协同轨迹与计算任务分配的分层决策

5.1　研究问题与方法总体设计

5.1.1　从覆盖接纳到批量服务质量

第三章解决集群轨迹策略能否看见尚未进入服务半径的需求，第四章进一步说明，给定位置与已接纳请求后，跨机批量算力竞争仍会限制截止期满足情况。本章研究两者形成的完整在线过程：集群通过需求感知的协同机动形成服务机会后，如何在有限计算预算内组织各节点执行计算任务，使更多请求在截止时间内完成。为此，本文采用面向可服务覆盖的分层学习与负载匹配方法，沿用实验中的方法标识 SF-HLM。上层使用第三章的覆盖需求 Attention-MAPPO，下层将节点负载配额搜索与条件化请求匹配结合，并用二部图策略网络学习配额迁移顺序。本章所有主结果均对应经过独立确认的最终候选，即*冻结覆盖需求上层与学习配额匹配下层*。

这一区分对应两个相互联系但不同的困难。第一，未进入物理服务范围的请求无法由卸载算法补救，轨迹策略必须及时感知未接纳需求。第二，进入服务范围并不意味着请求一定能按时完成；一个节点接收更多任务会摊薄每个任务的算力，迁移一个任务还会影响迁入与迁出节点上其他任务。若每个请求仅按自身当前预测时延独立选择节点，最终形成的批量负载可能与选择时的局部预测不一致。因而，本章并不把覆盖量最大化直接等同于端到端服务优化，而是把覆盖形成的请求集合与该集合的负载组织一起考察。

设一段评估过程实际生成 G 个服务请求，其中 A 个被自然覆盖接纳，S 个按时完成。其端到端截止期满足率仍按第三章的定义计算：

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A}. \tag{5.1}$$

式 (5.1) 给出方法设计的直接依据：上层负责形成服务机会，下层负责利用服务机会。上层观测范围为 460 m，物理接纳半径保持 100 m；扩大观测没有放宽物理服务范围。下层也不通过删除困难请求提高指标，所有已接纳请求都必须分配到质量掩码允许的执行目标，未接纳或超时请求均保留在 DSR 的统计中。

5.1.2　最终方法的组成与信息流

图 5.1 展示无人机集群的分层在线结构。五架 UAV 的轨迹决策仍由 Attention-MAPPO 实现，各 actor 根据所供给的局部需求与邻机观测准备二维动作；训练共同基座后，上层参数在下层训练、独立确认和冻结策略复验期间保

持不变。下层协调器集中收集当前已接纳请求的允许目标及预测信息，先以共同贪心和普通修复生成合法保底，再由图策略网络选择节点间的整数配额迁移，最后在给定配额下求解条件匹配。该结构以分散轨迹推断组织机群空间部署，以集中批量调度组织计算任务分工，两类决策共同影响服务过程。

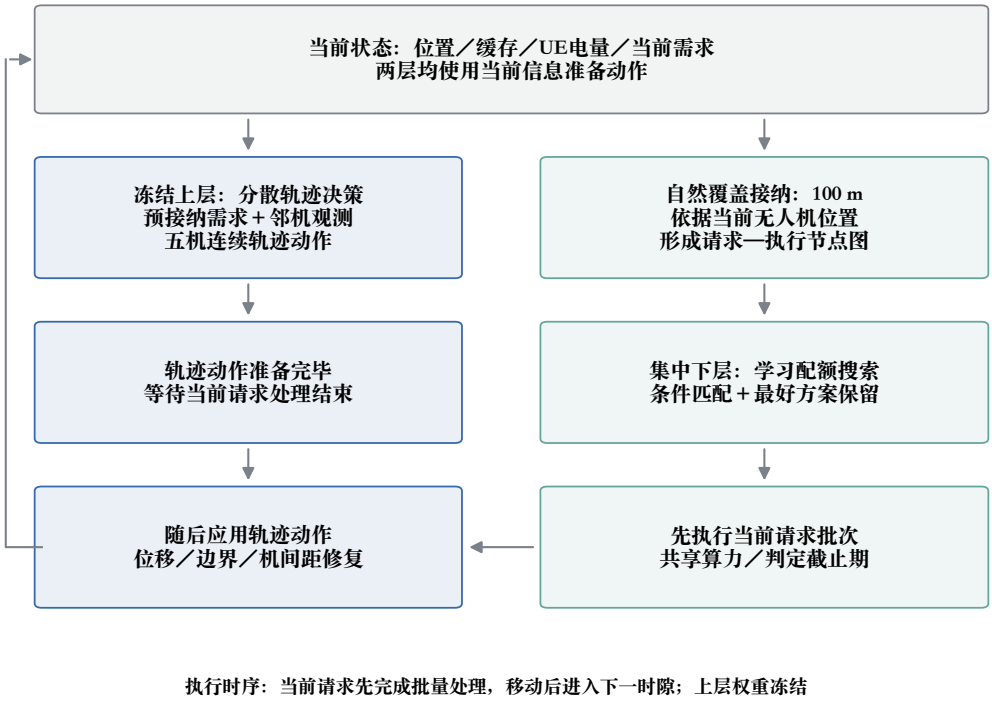


图 5.1　无人机集群 SF-HLM 分层架构与移动前决策时序。冻结上层按局部需求及邻机观测准备轨迹动作，下层集中分配已接纳计算任务；当前请求先依据当前几何执行，随后应用轨迹动作形成下一时隙位置

Figure 5.1　Hierarchical SF-HLM architecture for UAV swarm services: decentralized frozen trajectory inference and centralized task allocation, with request execution before movement

本章方法的接口由三个对象组成：请求行、配额向量和分配向量。请求行包含请求标识、源 UAV、截止时间、输入字节数、所需 CPU 周期，以及每个允许执行目标的时延与能耗预测量。配额向量记录六个执行节点最终接收的请求数量；分配向量则为每个请求给出一个允许动作。两种表示不能互相替代：相同配额可以对应许多不同分配，而相同节点数量只有在进一步决定哪些请求进入该节点后才能计算准确的批量目标。SF-HLM 的核心是先学习如何调整配额，再对该配额下的具体请求分配进行条件求解。

集中协调器使用的是移动前已经产生的信息，包括当前位置、当前请求及源节点可用的缓存信念。源 UAV 可以读取自身缓存，对邻机缓存使用其已有信念；搜索器不读取邻机缓存真值，不查询未来请求，不调用真实执行环境评价搜索候选。实际环境仅在最终动作确定后执行，得到的真实时延与能耗用于评估和

闭环状态演化。预测目标与真实结果因而有明确的职责边界，避免把仿真执行器当作搜索时可调用的完美信息预言器。

5.1.3　空间部署与计算分工的协同关系

两层分解对应不同的决策对象。轨迹层改变五架无人机的未来服务位置，进而改变后续可接纳请求、邻机关系及链路；任务层在当前已经形成的接纳集合中选择计算执行节点，进而改变各机批量负载、缓存与能耗。一次地面请求在空间上由来源 UAV 接纳，在计算上可以由另一架 UAV 执行，因此“谁覆盖需求”与“谁执行任务”相互联系但不要求相同。MBS 是既有系统中的地面计算支撑，其使用量属于集群协作结果需要同时报告的资源指标。

这种协同通过环境闭环发生，而非依赖上下层同时更新参数。最新协议先训练需求感知轨迹基座，再冻结上层训练与确认配额匹配下层。下层执行改变后续状态，固定参数的上层仍会对不同状态产生不同动作。故相同上层参数下出现不同轨迹，并不意味着重新训练了轨迹策略；它反映计算分工通过状态反馈影响后续空间部署。实验分别检验完整框架、学习选择增量、MBS 依赖与软件调用预算，使集群服务收益和获得收益所需资源具有同一证据口径。

表 5.1　最终确认方法的在线合同

Table 5.1　Online contract of the confirmed method

环节	固定定义
上层	覆盖需求 Attention-MAPPO；五个二维动作；最终确认期间参数冻结
请求接纳	100 m 自然覆盖；未接纳请求计入实际生成服务请求分母
执行节点	五个 UAV 与一个 MBS；任务不可拆分；MBS 不按批量任务数共享算力
共同保底	逐请求贪心初始化，至多 128 次普通修复候选评价
配额搜索	STOP 或节点间转移 1/2/4 个请求；共 91 个动作
条件匹配	包含初始匹配在内至多 16 次；固定配额下优化预测超时数与分配能耗
能耗筛选	同状态原始贪心预测分配能耗的 1.05 倍；搜索后筛选
策略网络	两层、宽度 128 的请求–节点二部图 MLP 消息传递
参数学习	5 轮教师监督预训练；100 次 PPO 更新，每次 32 图、8 轮更新

5.1.4 本章研究假设与验证层级

方法验证分为完整下层优化包、共享强框架上的学习增量和冻结策略跨场景表现三个层级。完整下层优化包包括贪心、修复、能耗筛选、配额搜索、条件匹配和最好方案保留；其比较对象是同上层的逐请求随机卸载以及已有学习下层。学习增量则要求启发式和随机对照也使用相同初始化、匹配器、普通修复、能耗参照与调用上限，只改变配额动作选择方式。跨场景表现进一步检验已确认权重在 UE 数量和 UAV 算力变化后是否仍能工作。这三个问题使用不同对照，避免用容易战胜的随机策略代替严格的机制验证。

实现开发过程中还考察过服务压力反馈、临界配额动作、多入口搜索及分组策略梯度，但最终确认未采用这些扩展。服务压力上层适配没有达到事先固定的晋级条件，因此本章的主方法不包含反馈残差训练，也不把反馈协同列为已验证贡献。最终网络版本的关键变化是严格校验输入元数据、分别编码当前与最好搜索状态，以及固定采样时动作掩码；其算法仍是 1/2/4/STOP 配额 PPO。以最终生效的接口描述方法，比把所有开发尝试并列为算法组件更有利于复现。

5.2 移动前请求建模与负载相关预测

5.2.1 请求集合、执行节点与质量掩码

在时隙 t，令已接纳服务请求集合为 $\mathcal{R}_t$，其规模为 R_t。为简化记号，本节省略 t。执行节点集合记作 $\mathcal{J} = \{0, 1, \cdots, 4, 5\}$，前五个编号对应 UAV，编号 5 对应 MBS。请求 m 具有输入大小 L_m、单位字节 CPU 周期数 ω_m、总计算周期 $C_m = \omega_m L_m$ 和截止时间 $D_m > 0$。服务类型索引记为 σ_m，其源 UAV 记作 u_m，允许执行节点集合记为 $\mathcal{J}_m \subseteq \mathcal{J}$。

允许集合由已有质量感知掩码生成，包含当前环境允许的本地、MBS 或协作动作。协调器将源 UAV 的动作编号映射为全局执行节点编号，以统一来自不同源节点的请求：源节点的动作 0 表示本地，而在全局表示中本地对应 u_m；动作 1 对应 MBS；协作动作对应目标 UAV 的全局编号。若不先完成这一步，来自不同 UAV 的两个“本地动作”可能被误计为同一节点，从而破坏配额守恒和算力共享计算。

请求按照 UE 标识固定排序，保证同一个批次的贪心、匹配、学习和随机对照使用相同顺序。排序本身不是性能优势来源，其作用是明确算法输入并使保存、恢复和逐步重放具有可比较性。协调器对所有已接纳请求建立合法目标，不对请求作额外截断；若批次为空，直接返回空分配、零匹配调用和原上层轨迹动

作。

令 $x_{mj} \in \{0,1\}$ 表示请求 m 是否被分配给节点 j。合法分配需满足

$$\sum_{j\in\mathcal{J}_m} x_{mj} = 1, \qquad x_{mj} = 0 \quad (j \notin \mathcal{J}_m), \qquad N_j = \sum_{m\in\mathcal{R}} x_{mj}. \tag{5.2}$$

其中 N_j 是节点的最终配额。式 (5.2) 同时表达不可拆分与完整分配：一个请求只能选择一个节点，每个已接纳请求都有去向。质量掩码限制允许目标，但并不保证最终共享负载下全部请求按时完成，这正是后续优化仍有必要的原因。

5.2.2　通信路径与预测量的分离

设请求 m 到其源 UAV 的上传速率为 R_m^{up}，源到目标 UAV j 的速率为 $R_{u_m,j}$，目标 j 到 MBS 的回传速率为 R_j^{bh}。字节到比特的转换必须显式保留：

$$T_m^{\mathrm{up}} = \frac{8L_m}{R_m^{\mathrm{up}}}, \qquad T_{mj}^{\mathrm{hop}} = \frac{8L_m}{R_{u_m,j}}, \qquad T_{mj}^{\mathrm{fetch}} = (1-p_{mj})\frac{8B_{\sigma_m}}{R_j^{\mathrm{bh}}}. \tag{5.3}$$

B_{σ_m} 是服务文件大小，区别于任务输入 L_m；p_{mj} 是源节点关于执行节点服务缓存的信念。本地目标的 p_{mj} 取源节点自身缓存状态，协作目标取已有邻机缓存信念。T_{mj}^{hop} 仅在 $j \neq u_m$ 且目标为 UAV 时存在。上传链路沿用当前接纳关系和当前带宽共享规则，不能以待执行轨迹移动后的距离重算当前请求上传时间。

为使负载搜索与匹配使用同一模型，将每条合法边归纳为四个非负预测量 $b_{mj}, w_{mj}, e_{mj}, c_{mj}$。对 UAV 目标，定义

$$\begin{aligned} b_{mj} &= T_m^{\mathrm{up}} + T_{mj}^{\mathrm{hop}} + T_{mj}^{\mathrm{fetch}}, & w_{mj} &= \frac{C_m}{F_j}, \\ e_{mj} &= P_{\mathrm{bh,rx}} T_{mj}^{\mathrm{fetch}} + (P_{\mathrm{u,tx}} + P_{\mathrm{u,rx}}) T_{mj}^{\mathrm{hop}}, & c_{mj} &= \kappa C_m F_j^2. \end{aligned} \tag{5.4}$$

本地执行时令转发项为零。这里的 e_{mj} 只计 UAV 侧与分配相关的通信能耗，任务输入从 UE 上传的 UE 侧发射能耗不混入 UAV 分配能耗；来源 UAV 的共同输入接收能耗也排除，因为它不随卸载目标改变。F_j 为目标 UAV 的可用计算能力，κ 为计算能耗系数。所有合法边使用相同来源的物理参数与缓存信念，不为学习组构造更有利的预测器。

对 MBS，设源 UAV 回传任务的时间为 T_m^{bh}，MBS 算力为 F_{MBS}，则

$$b_{m5} = T_m^{\mathrm{up}} + T_m^{\mathrm{bh}} + \frac{C_m}{F_{\mathrm{MBS}}}, \quad w_{m5} = c_{m5} = 0, \quad e_{m5} = P_{\mathrm{bh,tx}} T_m^{\mathrm{bh}}. \tag{5.5}$$

MBS 计算时间直接进入 b_{m5}，没有再乘配额 N_5。因此 MBS 配额决定哪些请求走回传路径，不改变本实验规定的 MBS 单请求计算能力。该非共享规则是冻结物理模型的一部分，并不意味着现实基站总有无限并行处理能力。

5.2.3 最终负载共享下的时延与能耗

若 UAV j 最终收到 $N_j \geqslant 1$ 个请求，每个请求分得 F_j/N_j 的算力。将其代入计算时间和计算能耗模型，可以逐项得到

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{F_j/N_j} = \frac{C_m}{F_j} N_j, \qquad E_{mj}^{\mathrm{cmp}} = \kappa C_m (F_j/N_j)^2 = \frac{\kappa C_m F_j^2}{N_j^2}. \tag{5.6}$$

进而，合法边在给定最终配额下的预测完成时延与 UAV 分配能耗为

$$\widehat{T}_{mj}(N_j) = b_{mj} + w_{mj} N_j, \qquad \widehat{E}_{mj}(N_j) = e_{mj} + \frac{c_{mj}}{N_j^2}. \tag{5.7}$$

对于配额为零的节点，矩阵构造以 $\max(N_j, 1)$ 避免除零，但该节点不展开容量槽，所以没有请求实际被分配过去；MBS 在计算上述矩阵时统一使用有效负载 1，与式 (5.5) 一致。这个数值处理没有给空节点虚构请求，也没有改变守恒条件。

式 (5.7) 显示，增加一个任务会使节点上每个请求的预测计算时延增加 w_{mj}，而计算能耗项随负载平方下降。该模型中“把任务分散到更多节点”并不必然降低 UAV 计算能耗，因为更高的单请求算力份额可能增加平方能耗；同时，集中负载也可能降低能耗却增加超时。时延与能耗的这种结构性权衡使仅最小化单请求时延、仅最小化能耗或仅均衡任务数量都不足以直接解决截止期满足问题。

设分配 $\mathbf{x}$ 的预测超时数、预测分配能耗和平均归一化时延分别为

$$\begin{aligned} M(\mathbf{x}) &= \sum_{m,j} x_{mj} \mathbf{1}\{\widehat{T}_{mj}(N_j) > D_m\}, \\ E(\mathbf{x}) &= \sum_{m,j} x_{mj} \widehat{E}_{mj}(N_j), \\ Q(\mathbf{x}) &= \frac{1}{\max(R, 1)} \sum_{m,j} x_{mj} \frac{\widehat{T}_{mj}(N_j)}{D_m}. \end{aligned} \tag{5.8}$$

普通修复使用 (M, E, Q) 的字典序比较；条件匹配与配额搜索的最好方案更新主要比较 (M, E)。Q 作为普通修复的同超时、同能耗次级判别，不能被写成匹配器同时最优的第三个目标。所有截止期判断均采用严格大于号：恰好达到截止时间的请求计为按时。

5.3 配额分解与条件化字典序匹配

5.3.1 配额空间与分配空间的关系

若每个请求最多有六个合法执行目标，直接分配空间至多包含 6^R 个组合。SF-HLM 首先考虑整数配额空间

$$\mathcal{N}_R = \left\{ \mathbf{n} \in \mathbb{Z}_{\geqslant 0}^6 : \sum_{j=0}^{5} N_j = R \right\}, \qquad |\mathcal{N}_R| = \binom{R+5}{5}. \tag{5.9}$$

这个数量是忽略质量掩码后的配额数上界；掩码会排除某些无法由合法请求组成的配额。配额表示保留了算力共享所需的关键统计量，使负载相关项在给定 $\mathbf{N}$ 后成为已知常数。与此同时，它没有强迫同样大小的任务交换身份，也没有按配额均匀随机分配请求，具体任务依然交由条件匹配选择。

配额分解的作用并非声称整个问题已变为低复杂度精确问题。式 (5.9) 仍随批量规模增长，在线预算不允许穷举。其实际优势是把复杂的两种决策分开：图策略在配额层选择值得尝试的负载组织，确定性匹配器在该组织内利用请求差异寻找分配。学习器不必逐个生成全部请求的完整组合，也不必从回报中独立重新学习指派求解器已经能够表达的条件最优结构。

5.3.2　容量槽展开与合法指派

给定配额 $\mathbf{N}$，将每个节点 j 展开为 N_j 个容量槽。全部槽的集合为 $\mathcal{S}(\mathbf{N})$，大小恰好为 R；槽 s 对应的执行节点记为 $j(s)$。令 $y_{ms} \in \{0,1\}$ 表示请求 m 是否占据槽 s，则条件匹配满足

$$\sum_{s\in\mathcal{S}} y_{ms} = 1, \qquad \sum_{m\in\mathcal{R}} y_{ms} = 1, \qquad y_{ms} = 0 \quad \big(j(s) \notin \mathcal{J}_m\big). \tag{5.10}$$

同一节点的容量槽具有相同边成本，但分别只能接收一个请求。由一一指派得到的分配自动满足式 (5.2)，且每个节点最终恰好接收 N_j 个请求。图 5.2 展示配额、容量槽与请求身份的关系。

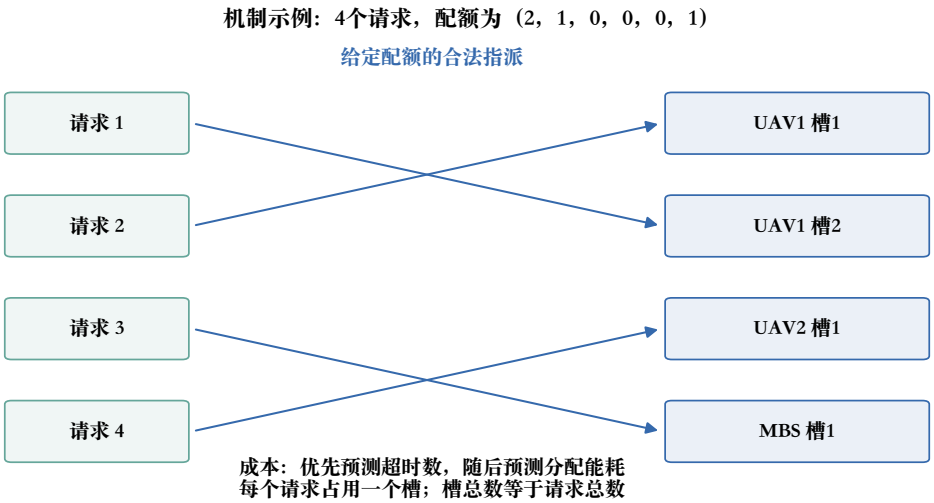


图 5.2　固定配额的容量槽展开与请求匹配。示意图用于解释算法结构，不是实测任务分配
Figure 5.2　Capacity-slot expansion and request assignment under fixed quotas; a conceptual illustration

条件匹配的基本可行性不能只由每个节点各自的合法请求数判断。例如，两

个节点各有足够的合法边，但这些边可能都来自同一小部分请求，从而不能同时填满全部槽。严格可行性需由完整指派求解确认：非法边使用无穷成本，若不存在全合法的一一指派则该配额不可行。实现采用 SciPy 线性指派接口[27]；其求解器采用修改的 Jonker–Volgenant 方法，矩形指派的实现背景见文献[28]。返回后再次检查每条边合法性与节点数量守恒。求解器判断不可行时，搜索记录这次调用并保留已有最好方案，不能把失败调用从预算中删去。

5.3.3 字典序目标的标量化与严格等价性

给定 $\mathbf{N}$，先计算全部合法边的预测能耗，令

$$E_{\max}(\mathbf{N}) = \max_{m,j:\, j\in\mathcal{J}_m} \widehat{E}_{mj}(N_j), \qquad \widetilde{E}_{mj} = \frac{\widehat{E}_{mj}(N_j)}{\max(E_{\max}, \epsilon_E)}. \tag{5.11}$$

实现用极小正数 ϵ_E 防止所有能耗为零时除零。合法边能耗非负且 $\widetilde{E}_{mj} \leqslant 1$，因此任何完整合法指派的归一化能耗和均处于 $[0, R]$。构造容量槽成本

$$C_{ms} = (R+1)\mathbf{1}\{\widehat{T}_{m,j(s)}(N_{j(s)}) > D_m\} + \widetilde{E}_{m,j(s)}, \tag{5.12}$$

非法边成本为无穷。线性指派求解

$$\min_{\mathbf{y}} \sum_{m,s} C_{ms} y_{ms} \quad \text{满足式 (5.10).} \tag{5.13}$$

权重 $R+1$ 随当前批量规模确定，不使用任意调试的超时惩罚常数。

下面说明式 (5.13) 与固定配额下的 (M, E) 字典序最小化等价。任取两个完整合法指派 $\mathbf{y}^a, \mathbf{y}^b$，若 $M_a \geqslant M_b + 1$，其标量目标差满足

$$C_a - C_b = (R+1)(M_a - M_b) + \widetilde{E}_a - \widetilde{E}_b \geqslant (R+1) - R = 1 > 0. \tag{5.14}$$

因此，无论能耗怎样变化，多一个预测超时的分配都不可能取得更小的标量成本。若 $M_a = M_b$，标量目标只比较归一化能耗；固定配额内归一化比例相同，故该比较与原始能耗大小完全一致。这证明求解器首先最小化预测超时数，再在最少超时的分配中最小化预测分配能耗。

这个证明的适用条件需要与算法接口一起理解。它只对给定配额、固定预测信息、合法指派域成立；没有证明配额搜索已找到全局最优配额，也没有把缓存信念预测转化为真实时延保证。能耗上限没有进入线性指派的约束，而是在求解后筛选。如果固定配额下超时最少的解超过能耗上限，算法会拒绝该候选，并不继续求解该配额下所有受限可行指派。因此，SF-HLM 不是含能耗侧约束的全局精确算法；条件最优性是明确、有限但可利用的结构性质。

5.3.4　预测能耗参照与保底方案

先按固定请求顺序构造原始贪心分配 $\mathbf{x}^{\mathrm{g}}$。处理一个请求时，贪心按已分配目标数估计加入后的自身时延，依次以自身时延、自身分配能耗和动作编号决胜。共同能耗参照由该原始贪心的最终批量重评估确定：

$$E_{\mathrm{cap}} = 1.05E(\mathbf{x}^{\mathrm{g}}). \tag{5.15}$$

普通修复、配额学习、启发式和强随机均使用同一状态下的这个上限。它不是各方法自己的初始分配乘 1.05，从而避免某个方法由于初始方案能耗偏高而获得更宽松的筛选空间。

普通修复以一次请求迁移为邻域，在最多 128 次候选评价内寻找字典序改进。若已有学习下层提出的初始分配超出共同上限，先回到原始贪心，再开展修复；若未超限则从其提案出发。配额方法从共同贪心加修复的保底进入，并对该保底配额作一次条件匹配。候选只有在合法且预测分配能耗不超过 E_{cap} 时才能成为当前搜索状态；最好方案由所有已接受方案中的 (M, E) 决定。

这样可以给出一项逐调用可检查的不变量：最终执行分配完整且质量合法，预测分配能耗不超过共同上限；最好预测目标不会比共同保底更差。该不变量针对预测量而非真实机队总能耗。真实缓存、请求成功判定和其他闭环作用仍由环境决定，飞行、悬停和无线能量传输也不包含在 $E(\mathbf{x})$ 内。论文中的真实能耗优势必须由完整评估计数支持，不能由式 (5.15) 直接推出。

5.4　有限预算配额搜索与二部图策略

5.4.1　当前状态、最好状态与动作空间

搜索的内部步号记为 ℓ，区别于环境时隙 t。一个环境时隙内可以进行若干次配额迁移，但只有最终保留的分配进入环境。当前配额、当前分配与其预测目标分别记为 $\mathbf{N}^{(\ell)}, \mathbf{x}^{(\ell)}, F^{(\ell)}$；最好分配与目标记为 $\mathbf{x}^{*(\ell)}, F^{*(\ell)}$。允许搜索经过比最好方案更差的当前方案，使策略能够跨越只接受即时改进的局部限制；实际执行则不受这些较差中间方案直接影响。

完整搜索过程的状态可写为

$$S_\ell = (\mathcal{R}, \mathbf{N}^{(\ell)}, \mathbf{x}^{(\ell)}, \mathbf{x}^{*(\ell)}, \mathcal{V}_\ell, B_\ell), \tag{5.16}$$

其中 $\mathcal{V}_\ell$ 是已尝试配额集合，B_ℓ 是剩余调用预算，请求行中的预测量在本次搜索内固定。条件匹配与访问集合更新在此完整状态下定义转移。策略实际读取其二部图编码和有效动作掩码，而不是逐项展开全部访问历史；掩码反映当前动作合

法性，不能据此声称图编码包含未来掩码变化的全部信息。本文采用这一可计算的策略观测训练有限搜索，不依赖图编码必为完整状态充分统计量的理论假设。

配额动作集合为

$$\mathcal{A} = \{\mathrm{STOP}\} \cup \{(i, j, k) : i, j \in \mathcal{J},\ i \neq j,\ k \in \{1, 2, 4\}\}, \qquad |\mathcal{A}| = 91. \tag{5.17}$$

转移动作仅改变节点任务数量：

$$\mathbf{N}' = \mathbf{N}^{(\ell)} - k\mathbf{e}_i + k\mathbf{e}_j. \tag{5.18}$$

这里的“转移 k 个任务”是配额变动，不是预先指定 k 个请求的身份。新配额的具体分配重新由条件匹配给出，可能改变多个请求的目标。因此，一次配额动作能够触发批量重组，而不是仅对一个被选中的任务作局部替换。

有效动作掩码同时要求 $N_i \geqslant k$、新配额没有访问过、各节点配额不大于其合法边数。最后一项只是必要条件，完整可行性由匹配求解检查。STOP 始终有效，使没有可行迁移时策略也能合法终止。失败的匹配配额同样加入访问集合，避免重复耗费预算。采样时掩码属于保存的搜索状态，重算概率时不得根据更新后的访问集合重新生成它。

初始条件匹配占用一次调用，整个搜索最多 16 次匹配，因此普通非空批次最多再尝试 15 次配额迁移。策略可以提前 STOP，也可能因为调用预算耗尽而终止；空批次不消耗匹配预算。搜索预算是求解器调用数，而不是动作数、成功迁移数或模型前向次数。该定义使不可行候选与超能耗候选也承担实际计算费用，便于与启发式和强随机保持共同预算。

5.4.2 请求、边与节点特征

图 5.3 表示每个搜索状态的二部图。请求是左侧节点，六个执行节点是右侧节点，质量合法动作构成边。请求输入保留截止时间、计算量、输入大小和源节点；边输入描述请求放在该目标后的预测路径和负载；节点输入同时描述当前与最好方案的服务压力。区分当前与最好状态很重要：如果只编码最好方案，策略无法知道自己正在从哪个较差入口继续迁移；如果只编码当前方案，又无法知道已经保留的执行质量和剩余改进空间。

请求特征 $\mathbf{v}_m \in \mathbb{R}^4$ 为

$$\mathbf{v}_m = \left[\min(D_m, 10),\ \frac{\log(1 + C_m)}{30},\ \frac{\log(1 + L_m)}{20},\ \frac{u_m}{5}\right]. \tag{5.19}$$

秒、CPU 周期和字节数各自在进入网络前作固定尺度变换。变换用来控制数值范围，不改变指派预测器使用的原始量。尤其是网络中截止时间截断到 10 的表示，不意味着真实截止时间判断也被截断。

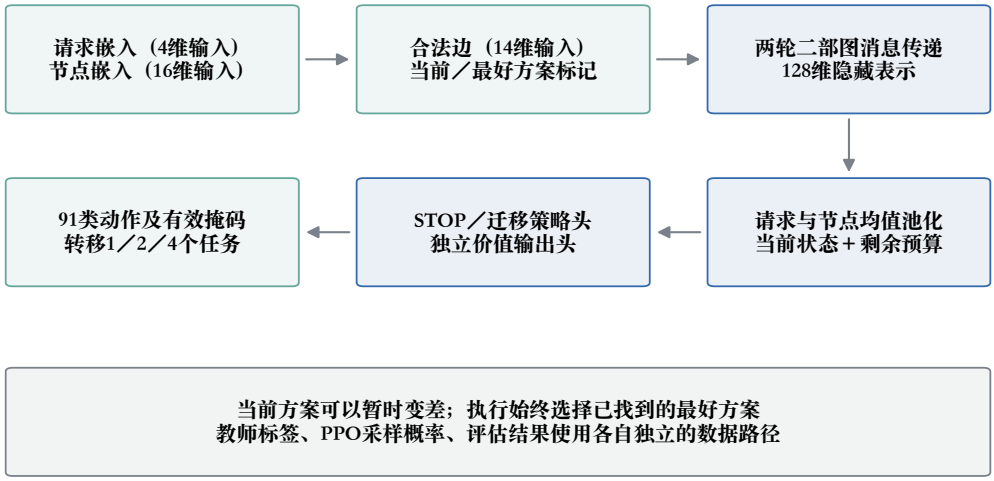


图 5.3　请求–执行节点二部图、当前与最好状态编码及配额动作头。非法边和填充请求在消息聚合中屏蔽

Figure 5.3　Request–execution-node graph, current/best state encoding and quota action heads

合法边 $\mathbf{z}_{mj} \in \mathbb{R}^{14}$ 的前十二项依次为：b_{mj}/D_m、w_{mj}/D_m、$\log(1+e_{mj})/20$、$\log(1+c_{mj})/30$、当前 N_j/R、截断后的 $\widehat{T}_{mj}/D_m$、归一化截止期余量、允许负载阈值的归一化值、MBS 标记、缓存信念、目标容量的对数表示和源节点标记。最后两项为当前分配与最好分配是否经过该边的二元标记。非法边的特征置零，并在后续聚合中屏蔽。负载阈值来自 $(D_m - b_{mj})/\max(w_{mj}, 10^{-12})$，只作为网络观测特征；最终方法没有把临界阈值扩展为新的动作集合。

令请求在指定分配中的归一化余量为 $m_m = 1 - \widehat{T}_m/D_m$。每个节点的六项服务摘要为：接收数量占批次比例、节点内预测超时比例、平均余量、最小余量、释放一个请求可能救回的请求数占批次比例、节点分配能耗占参照比例。释放救回的判定为

$$b_{mj} + w_{mj}\max(N_j - 1, 1) \leqslant D_m < b_{mj} + w_{mj}N_j, \tag{5.20}$$

且只对 UAV 目标计算。摘要既描述节点已经承担的请求，也提示减少该节点负载可能影响的其他请求；它没有读取真实执行成功标签。

当前与最好方案分别生成六项摘要，拼接当前配额比例、剩余匹配预算比例、当前和最好预测超时占批次比例，得到 $\mathbf{u}_j \in \mathbb{R}^{16}$。所有比例在空批次处理时采用正分母保护；空节点摘要为零。平均和最小余量截断到 $[-10, 1]$，边时延比上限为 10，容许负载特征截断到 $[-1, 2]$。这些固定处理约束输入数值而不改变真实请求数量、目标可行性或实际性能评价。

5.4.3 两层消息传递与置换结构

分别用 MLP 将请求、节点与边特征映射为 $h = 128$ 维嵌入，记为 $\mathbf{h}_m^{(0)}, \mathbf{g}_j^{(0)}, \mathbf{e}_{mj}$。每个 MLP 由线性层、LayerNorm、ReLU 和输出线性层组成。两轮消息传递中，第 q 层合法边消息为

$$\mathbf{m}_{mj}^{(q)} = \psi_q\big([\mathbf{h}_m^{(q)}, \mathbf{g}_j^{(q)}, \mathbf{e}_{mj}]\big), \qquad j \in \mathcal{J}_m. \tag{5.21}$$

ψ_q 在所有合法边共享参数，非法边消息恒为零。请求侧和节点侧各按合法邻居取均值，并分别更新：

$$\begin{aligned} \overline{\mathbf{m}}_m^{(q)} &= \frac{\sum_{j\in\mathcal{J}_m} \mathbf{m}_{mj}^{(q)}}{\max(|\mathcal{J}_m|, 1)}, & \mathbf{h}_m^{(q+1)} &= \rho_q([\mathbf{h}_m^{(q)}, \overline{\mathbf{m}}_m^{(q)}]), \\ \overline{\mathbf{m}}_j^{(q)} &= \frac{\sum_{m:\, j\in\mathcal{J}_m} \mathbf{m}_{mj}^{(q)}}{\max(|\{m : j \in \mathcal{J}_m\}|, 1)}, & \mathbf{g}_j^{(q+1)} &= \nu_q([\mathbf{g}_j^{(q)}, \overline{\mathbf{m}}_j^{(q)}]). \end{aligned} \tag{5.22}$$

$q = 0, 1$，两层使用各自参数。批量训练时，请求图填充到同一批中的最大请求数；填充请求嵌入与消息均屏蔽，均值分母只计算真实合法邻居。

完成两层更新后，对真实请求取均值 $\overline{\mathbf{h}}$，对六个节点取均值 $\overline{\mathbf{g}}$。转移动作 (i, j, k) 的分数由源节点、目的节点、请求池化表示和迁移量独热编码构成：

$$z_{ijk} = f_{\text{move}}([\mathbf{g}_i^{(2)}, \mathbf{g}_j^{(2)}, \overline{\mathbf{h}}, \text{onehot}(k)]), \qquad z_{\text{stop}} = f_{\text{stop}}([\overline{\mathbf{h}}, \overline{\mathbf{g}}]). \tag{5.23}$$

价值头也以 $[\overline{\mathbf{h}}, \overline{\mathbf{g}}]$ 为输入。掩码后的 logits 形成分类分布，训练时采样，正式评估取最大分数动作。将请求排序更换为另一个一致排列时，共享边函数与均值聚合在数学结构上保持请求置换不变；源编号、节点身份和质量合法域依然是显式输入，因此不应进一步声称算法对任意节点重编号天然不变。

这一网络用消息传递表达“同一个请求的替代目标”和“同一个节点上可竞争请求”的关系。它不采用多头注意力加权聚合，下层所有合法邻居的消息使用均值。上层 Attention 与下层二部图 MLP 因而应在结构图、算法名称和贡献解释中分开。可变请求数量由图表示和填充掩码处理，而六节点动作头保持固定，这使模型在冻结跨 UE 数量评价时无需增加动作维数。

5.4.4 搜索奖励与最好方案不变量

一次非停止迁移后，令最好预测超时与能耗从 $(M_{\ell-1}^*, E_{\ell-1}^*)$ 更新到 (M_ℓ^*, E_ℓ^*)，训练奖励定义为

$$r_\ell = M_{\ell-1}^* - M_\ell^* + 0.1\frac{E_{\ell-1}^* - E_\ell^*}{\max(E_{\text{cap}}, 10^{-12})} - 0.001. \tag{5.24}$$

奖励评价保留的最好方案，而非较差当前方案；一次没有改进的匹配尝试仍得到 -0.001 的计算惩罚。STOP 奖励为零。预测超时减少具有主要作用，能耗项在共

同上限下表达较小的平滑偏好，调用惩罚为节约搜索提供信号。这个搜索奖励服务于单时隙组合求解，与环境中的轨迹奖励和真实 DSR 是不同对象。

采用无折扣的有限搜索回报，若本次搜索进行了 L 次非停止迁移，式 (5.24) 的差分项可望远镜求和：

$$\sum_{\ell=1}^{L} r_\ell = M_0^* - M_L^* + 0.1\frac{E_0^* - E_L^*}{\max(E_{\mathrm{cap}}, 10^{-12})} - 0.001L. \tag{5.25}$$

0 对应完成共同保底与初始匹配后的状态，初始匹配本身不产生一次迁移奖励。因此，训练在已有保底质量上权衡进一步改善与额外尝试，不奖励重复返回同一配额，也不把较差中间状态的真实执行结果回流到环境。

算法 5.1　SF-HLM 单时隙配额搜索与条件匹配

Input: 移动前请求行、质量合法域、冻结图策略 π_θ；匹配预算 16，普通修复预算 128
Output: 全部已接纳请求的合法分配

构造原始贪心 $\mathbf{x}^{\mathrm{g}}$ 并计算 $E_{\mathrm{cap}} = 1.05E(\mathbf{x}^{\mathrm{g}})$;
在共同上限内普通修复，初始化当前与最好分配;
根据保底配额执行初始条件匹配，计入一次匹配调用;
若候选合法、低于上限且目标更好，更新保留方案;
while 批次非空、匹配调用未耗尽且搜索未停止 **do**
    编码当前/最好二部图及采样时掩码;
    由图策略选择 STOP 或配额迁移 (i, j, k);
    if 选择 *STOP* **then**
        终止搜索;
    else
        生成守恒配额，登记访问并计入一次匹配调用;
        求解该配额的条件字典序匹配;
        若匹配合法且满足共同能耗上限，更新当前方案;
        若当前方案优于保留目标，更新最好方案;
    end
end
将最好方案映射回各源 UAV 的请求动作，输出完整分配;

5.4.5　计算量、终止条件与实现校验

在稠密表示下，固定配额的容量槽成本矩阵为 $R \times R$。常规指派算法的量级可按 $O(R^3)$ 讨论，矩阵存储为 $O(R^2)$；实际 SciPy 实现和稀疏合法结构会影响常数。图网络每轮沿至多 $6R$ 条请求–节点边传播，六节点和宽度固定时，其关于请求数的计算量近似线性，但 MLP 前向与张量构造具有实际开销。在线总时间还包括观测准备、普通修复、至多 16 次匹配、动作映射与消息序列化，不能只用一次网络前向的时间代表完整方法。

调用预算给出有限终止性，而不是全局收敛证明。每次有效非停止搜索尝试

增加调用数，访问去重避免重复配额，STOP 可提前结束；因此在给定预算下总会返回保底或更好的预测方案。可行配额空间未遍历时没有全局最优承诺。原子匹配调用不能在任意时刻无损中断，墙钟预算因此是软截止；这一点将在时间预算实验中实测报告。

实现校验覆盖输入非负有限性、请求完整性、动作合法性、配额守恒、采样时掩码、初始匹配计费和最终能耗参照。恢复文件还保存模型、优化器、采图随机状态、环境状态及结果摘要，评估前后核验模型指纹。串行与并行采样使用相同策略版本和轨迹种子，按任务标识汇总后更新，不能让并发数改变科研样本的定义。这些校验保证对比实际执行了同一算法合同；它们本身不替代性能实验。

5.5 教师初始化、配额 PPO 与分层训练

5.5.1 从训练轨迹采集请求图

下层训练以共同基座产生的环境和独立下层训练负载为起点，上层保持冻结。每个训练块额外采集 25 个完整回合，每回合 1000 步，在 $0, 125, 250, 375, 500, 625, 750, 875$ 八个预定时刻记录移动前请求图，得到 200 个图实例，空批次也保留。采图期间使用共同贪心修复策略，不依据未来独立确认结果选择“更容易学习”或“更能体现优势”的快照。图数据只记录允许的观测预测信息，教师和 PPO 搜索都在这些固定输入上运行。

这一步将环境交互与组合搜索训练分开。采图给出下层可能面对的请求规模、截止期、链路和缓存信念，随后可在同一图上重复运行短的配额搜索轨迹。重复搜索不是额外的环境 episode，也不是独立训练重复；它是提高固定训练数据利用率的优化计算。图实例来自训练负载，开发评价和独立确认负载不回流采图、教师或梯度更新。图分布仍受共同基座和采集策略影响，因此这种训练不等价于在所有可能状态上完成了策略优化。

图 5.4 显示基座训练、下层图采集、教师初始化、PPO 搜索和独立评价的先后关系。训练分割不只区分随机种子数字，还区分数据用途：基座负载生成轨迹控制的训练状态，下层负载生成组合搜索图，确认负载只用于固定最后模型的评价。模型文件和协议摘要把这三类数据的联系锁定下来，使读者可以追溯每个结果使用的共同上层和对应下层检查点。

5.5.2 即时教师与独立监督损失

随机初始化的配额策略需要从大量无改善迁移和非法候选中学习，有限匹配预算下直接优化可能较难发现有用方向。本文先使用训练图上的即时改进教

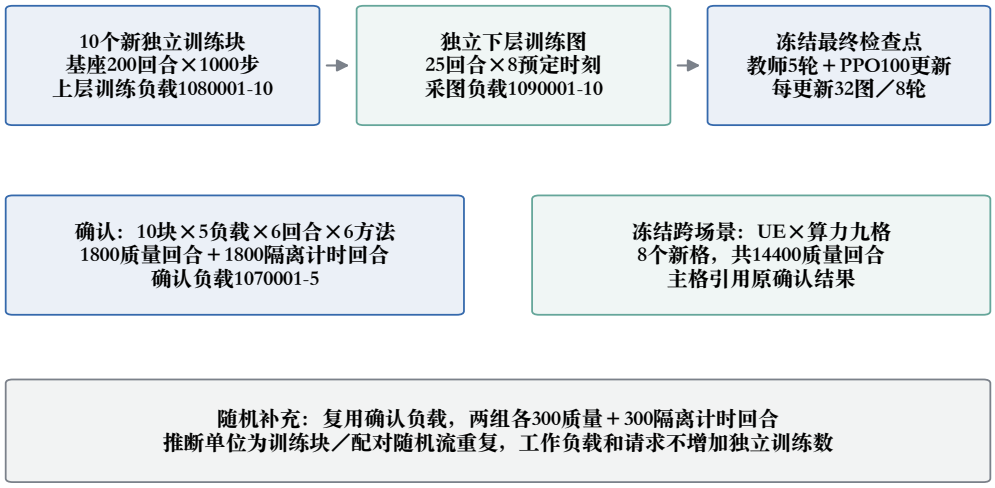


图 5.4　共同基座、下层训练图与独立确认的数据划分。图中回合是环境交互，配额 PPO 更新是固定训练图上的搜索训练

Figure 5.4　Data split for shared foundations, lower-layer training graphs and independent confirmation

师提供可执行的动作示例。教师从同一共同保底和初始匹配出发，对当前有效迁移逐一尝试条件匹配，在合法且满足能耗上限的候选中选择优于当前目标的动作；没有找到即时改进时标记 STOP。教师总匹配预算为 128，包括初始匹配、试探候选和被选中迁移，不能把教师评价当作免费的真值查询。

教师标签是其实际找到的动作，并非穷举配额空间的全局最优标签。即时改进教师也不一定能发现需要先经过较差状态的多步路径；这一限制说明监督阶段的作用是提供初始搜索偏好，而不是替代后续强化学习。每条样本保存当时的当前/最好图、有效动作集合和教师动作。对样本集 $\mathcal{D}_{\mathrm{T}}$，监督损失为

$$\mathcal{L}_{\mathrm{BC}}(\theta) = -\frac{1}{|\mathcal{D}_{\mathrm{T}}|} \sum_{(s,a^{\mathrm{T}})\in\mathcal{D}_{\mathrm{T}}} \log \pi_\theta(a^{\mathrm{T}} \mid s). \tag{5.26}$$

预训练进行 5 轮，小批量为 64，梯度范数上限为 0.5。动作概率仅在样本保存的合法掩码内归一化。教师损失独立优化，不把教师动作伪装为当前策略采样，不向 PPO 的旧动作概率或优势估计中混入监督样本。

监督初始化之后，策略通过自身采样的搜索轨迹学习长期搜索回报。由于最终方法允许经过较差但可行的当前状态，PPO 在有限范围内具有超越即时教师路径的机会。不过，“具有机会”是设计性质，是否带来超越强随机的增量仍需第 5.8 节的对照验证，不能仅由网络存在或训练损失降低推出。

5.5.3 有限搜索轨迹的优势估计

第 k 次 PPO 更新前，冻结一个策略版本，并从本块训练图中抽取 32 个实例，为每图采集一条最多 16 次匹配的搜索轨迹。采集完成后按任务标识汇总，随后才开始更新。采样保存状态 s_ℓ、原动作 a_ℓ、旧对数概率、价值估计 $V_\phi(s_\ell)$、奖励及终止标记。模型载入后使用轨迹种子重新设定随机状态，避免首次加载与模型缓存命中产生不同样本。

令 $d_\ell^{\text{end}} \in \{0,1\}$ 为搜索终止标记，优势估计采用 GAE[24]：

$$\delta_\ell = r_\ell + \gamma(1 - d_\ell^{\text{end}})V_\phi(s_{\ell+1}) - V_\phi(s_\ell), \qquad \gamma = 1, \tag{5.27}$$

$$\widehat{A}_\ell = \delta_\ell + \gamma\lambda(1 - d_\ell^{\text{end}})\widehat{A}_{\ell+1}, \qquad \lambda = 0.95, \qquad \widehat{R}_\ell = \widehat{A}_\ell + V_\phi(s_\ell). \tag{5.28}$$

搜索终点下一状态价值取零，递推在每条图轨迹边界停止。$\gamma = 1$ 对应最多十余步的有限预算求解，而不是无限时域控制；它保留式 (5.25) 中改善与调用开销的完整权衡。价值训练目标使用未标准化的 $\widehat{R}_\ell$，策略梯度使用本次采样记录内标准化的优势。

标准化写作

$$\widetilde{A}_\ell = \frac{\widehat{A}_\ell - \overline{A}}{\max(\text{std}(\widehat{A}), 10^{-6})}. \tag{5.29}$$

若某批图没有有效搜索记录，则跳过参数更新而不是制造奖励或动作。不同图可以有不同请求数和搜索长度；填充处理的是图张量，不增加真实优势样本。请求数、搜索步或教师标签数也不能计为独立训练单位。

5.5.4 裁剪策略目标与概率一致性

配额 PPO 采用分类动作分布，其新旧策略概率比为

$$\rho_\ell(\theta) = \exp\left[\log \pi_\theta(a_\ell \mid s_\ell) - \log \pi_{\text{old}}(a_\ell \mid s_\ell)\right]. \tag{5.30}$$

裁剪目标沿用 PPO 的有限更新思想[25]：

$$\mathcal{L}_{\text{policy}} = -\mathbb{E}_\ell\left[\min\left(\rho_\ell \widetilde{A}_\ell, \text{clip}(\rho_\ell, 0.8, 1.2)\widetilde{A}_\ell\right)\right] - 0.005\,\mathbb{E}_\ell[\mathcal{H}(\pi_\theta(\cdot \mid s_\ell))]. \tag{5.31}$$

价值损失为

$$\mathcal{L}_{\text{value}} = \frac{1}{2}\mathbb{E}_\ell\left[(V_\phi(s_\ell) - \widehat{R}_\ell)^2\right]. \tag{5.32}$$

共享图编码器与动作、价值头一起最小化两项之和，Adam 学习率为 3×10^{-4}，每次采样执行 8 个 epoch、小批量 64，总计 100 次 PPO 更新，梯度范数裁剪为 0.5。最终确认使用第 100 次更新后的最后检查点，没有从开发或确认曲线中挑选最高 DSR 时刻。

PPO 的概率一致性在带访问去重的搜索中尤为重要。同一个配额在轨迹前段可能未访问、后段已经访问；如果训练时重算访问集合，动作分布的归一化域会改变，概率比就不再对应原采样策略。本方法把采样时掩码和当前/最好图作为不可变记录保存，并在首次梯度更新前检验重算概率比接近 1。并行轨迹来自相同冻结参数，教师标签不进入这些记录，从而使比值检验具有清楚的含义。

表 5.2　已确认配额策略的训练设置

Table 5.2　Training settings of the confirmed quota policy

参数	数值	参数	数值
隐藏宽度	128	消息传递层数	2
请求/边/节点维数	4/14/16	动作数	91
每块采图回合	25	每块训练图数	200
教师总匹配预算/图	128	监督预训练轮数	5
PPO 更新次数	100	每更新采样图数	32
PPO epoch	8	监督/PPO 小批量	64
学习率	3×10^{-4}	梯度范数上限	0.5
PPO 裁剪范围	[0.8, 1.2]	熵系数	0.005
折扣因子	1	GAE 参数	0.95
在线匹配调用上限	16	普通修复候选上限	128

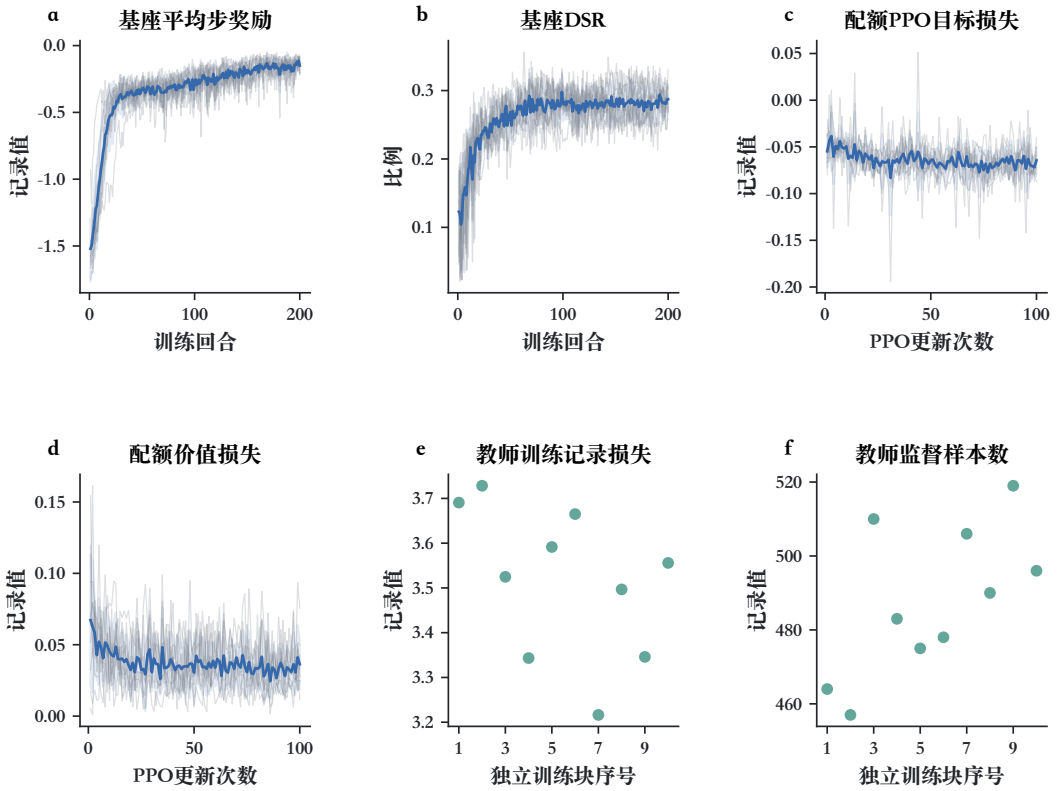
5.5.5　共同基座与交互、教师计算预算

每个独立训练块先重新训练覆盖需求分层基座 200 个回合，每回合 1000 步。共同基座包含上层与原学习下层的最后参数、优化器与约束状态；确认中的六种下层方法从同一个上层基座出发。配额下层再使用 25 个回合采图及离线监督/PPO 计算；原适配学习下层则在冻结上层后继续训练 75 个回合，并恢复原优化器及 DSR、MBS 约束状态。原冻结学习组保留基座下层，贪心、启发式和强随机不进行额外模型训练。

协议同时登记 50 个冻结采集回合的数据机会，冻结方法复用不可变采集记录。复用有助于明确各组面对的数据条件，但不能把同一记录的多个引用说成多个方法各自新增的环境交互。教师的匹配调用和网络优化计算也不因为环境步数相同就消失。因此，本文将共同基座、独有采图、适配交互、复用记录和离线求解分别说明，不声称六组总训练计算严格相等。比较要回答在这些固定训练合同下方法的实际表现，而不是每个训练步骤都完全等算力的架构竞赛。

图 5.5 分别给出共同基座的环境回合曲线和配额策略的搜索训练曲线。前者

反映覆盖轨迹基座随环境交互的变化，后者反映固定训练图上监督与 PPO 优化过程；横轴、奖励定义和检查点含义不同，不把它们拼成一条联合端到端收敛曲线。训练损失或奖励趋稳可以帮助诊断数值运行，独立确认的服务指标才用于判断方法效果。



前四面板：全部10块原始曲线；粗线为均值，带为块间±1 SD；未平滑
后两面板：每块一次教师监督记录；未保存逐轮损失，不构造教师收敛曲线

图 5.5　共同基座与配额策略的实际训练记录。前四面板依次为基座平均步奖励、基座 DSR、配额 PPO 损失和价值损失：细线为十块原始曲线，粗线和带分别为块间均值与正负一个标准差；未平滑。后两面板为每块一次教师监督损失记录和样本数；未保存逐轮损失，故不绘制教师收敛曲线。环境回合、优化更新与训练块横轴分别对应不同阶段

Figure 5.5　Actual training records of the foundation and quota policy; curves show ten blocks, and teacher panels show one recorded summary per block

5.6　独立确认设计与统计方法

5.6.1　场景、种子分割与最后检查点

主场景沿用五架 UAV、一百 UE、一个 MBS 和 700 m × 700 m 区域，通信、请求生成、能量动态、自然接纳和环境奖励均保持冻结定义。方法开发使用五个历史训练块；最终确认换用十个未参与开发模型选择的训练块，并单独设置基座训练、下层训练和确认负载。冻结候选、分析族和晋级门槛后才执行确认，不能

因确认结果不理想而换检查点或补入新模块。

表 5.3　SF-HLM 独立确认的数据与模型分割

Table 5.3　Data and model split for independent SF-HLM confirmation

用途	固定设置
独立训练块	1060001–1060010，共 10 块
基座训练负载	1080001–1080010，与各训练块一一对应
下层采图/适配负载	1090001–1090010，与各训练块一一对应
配额下层初始化	1100001–1100010，与各训练块一一对应
确认工作负载	1070001–1070005，全部方法配对复用
评价长度	每块每负载 6 回合，每回合 1000 步
模型选择	基座训练与配额更新均固定最后检查点
六方法质量评价	$6 \times 10 \times 5 \times 6 = 1800$ 回合
独立软件计时	另 1800 回合，在预留物理核心重放同一策略

所有学习、贪心、启发式和强配额随机方法在同一训练块内复用共同上层参数，工作负载与初始外生流配对。不同卸载会改变后续能量、缓存和观测，因此即使上层参数相同，长期轨迹也可能分化；本章评价是闭环运行，不是冻结几何下的反事实分配。配对只要求潜在请求、外生随机序列和模型对应关系按协议一致，并不要求每个时隙状态或生成服务请求分母完全相同。

完整确认完成 4390 个登记任务，包括共同基座、原下层适配、采图、教师合并、配额训练、冻结采集、质量评价和隔离计时。逐任务摘要与检查点合同核验完成，质量回合共 180 万个环境步。质量评价与计时回合的分配和真实物理计数相同；隔离计时是性能测量的重放，不是额外训练重复。恢复执行保留所有已完成结果，计时调度问题和重测记录不改变算法、种子、样本或科研门槛。

5.6.2　六个核心对照与两种补充随机策略

表 5.4 区分下层优化包与学习机制对照。启发式按当前合法目标的预测截止期风险选择配额迁移；强配额随机在有效迁移中随机选择，两者都拥有共同保底、条件匹配、最好保留和 16 次调用上限。它们不能与“每请求随机选一个目标”混为同一种随机基线。

原学习下层训练保存其原始提案和采样概率，修复后的执行动作不伪装为原策略采样动作。原适配组恢复基座优化器与自适应约束状态，使其对照包含继续学习已有下层的机会。两种原学习组都经过相同共同能耗参照与普通修复，因此主差值比较的是配额匹配下层与已有学习提案加修复的完整方法，而不是

表 5.4　完整下层与学习机制对照的组成

Table 5.4　Components of complete lower-layer and learning-mechanism controls

方法	下层与比较用途
学习配额搜索	二部图 PPO 选择配额迁移，条件匹配；最终候选
启发式配额搜索	相同强框架与预算，按预测风险选择迁移；学习机制对照
强配额随机搜索	相同强框架与预算，在有效迁移中随机；严格学习增量对照
贪心＋普通修复	原始贪心后做最多 128 次普通修复；主要实用对照
原冻结学习下层＋修复	基座请求级 MAPPO 提案后共同修复；主要学习对照
原适配学习下层＋修复	冻结上层后继续 75 回合原下层训练，再共同修复
相同上层＋逐请求随机卸载	共同质量掩码内逐请求均匀随机；移除整个下层优化包
全随机（质量掩码内）	二维轨迹在 $[-1,1]^2$ 独立均匀采样，卸载逐请求随机

未经修复的弱实现。

补充随机评价在确认之后登记，复用十套冻结模型和五个已用确认负载，每新方法 300 个质量回合及 300 个隔离计时回合。它们保持质量掩码、自然接纳和原物理规则，但移除贪心初始化、普通修复、条件匹配、配额搜索、最好保留与方法特有的预测能耗筛选。该筛选是算法组件而非物理约束，移除它没有改变环境的物理合法域。这两个对照分别解释完整系统和完整下层优化包的收益，不能代替共享强框架上的学习检验。

5.6.3　请求计数聚合与十个独立统计单位

令 $b = 1, \cdots, 10$ 为独立训练块，$w = 1, \cdots, 5$ 为工作负载，$e = 1, \cdots, 6$ 为评估回合，$t = 1, \cdots, 1000$ 为时隙。对方法 a，先合并同一块的全部请求计数：

$$G_b^a = \sum_{w,e,t} G_{bwet}^a, \qquad A_b^a = \sum_{w,e,t} A_{bwet}^a, \qquad S_b^a = \sum_{w,e,t} S_{bwet}^a. \tag{5.33}$$

再定义块级指标

$$D_b^a = \frac{S_b^a}{G_b^a}, \qquad a_b^a = \frac{A_b^a}{G_b^a}, \qquad q_b^a = \frac{S_b^a}{A_b^a}, \qquad D_b^a = a_b^a q_b^a. \tag{5.34}$$

主场景各块均有非零生成与接纳计数。通用实现用正分母保护处理空统计单元，但不把没有请求的空单元解释为 100% 服务成功。

方法的描述均值是 $\overline{D}^a = 10^{-1} \sum_b D_b^a$。这使每个独立模型块的权重相同，不让生成请求稍多的块获得更大统计权重。它也不同于先求每回合比率再平均，因为后者会让请求较少的回合与请求较多的回合占相同权重。本文使用请求计数汇总的定义，并在表、图和差值检验中保持一致。

跨块均值一般不满足 $\overline{D}=\overline{a}\,\overline{q}$，其差为

$$\overline{D}-\overline{a}\,\overline{q}=\frac{1}{10}\sum_{b=1}^{10}(a_b-\overline{a})(q_b-\overline{q}). \tag{5.35}$$

因此，展示平均接纳率和平均接纳后完成率有助于解释方向，却不能用两均值乘积反算报告的 DSR。图中的精确分解优先使用同块计数；若展示跨块均值，应同时保留各块指标而不是把舍入误差或块间协变误判为计数错误。

训练块是主推断单位。五工作负载和六回合改善块内估计，单个请求提供服务计数，都不扩充独立训练样本数。强随机搜索在每块对应同一个学习上层，并具有独立策略随机流，因此其变化包含共同模型和策略随机性。全随机没有训练过程，补充评价的十个块只是与十套模型配对的独立随机流重复，不应称作十个全随机训练种子。

5.6.4　配对区间、多重比较与预定门槛

候选 a 与对手 c 的块级差值为 $\Delta_b=D_b^a-D_b^c$。其均值、标准差与双侧 95% 配对 t 区间为

$$\overline{\Delta}=\frac{1}{10}\sum_b\Delta_b,\quad s_\Delta^2=\frac{1}{9}\sum_b(\Delta_b-\overline{\Delta})^2,\quad \mathrm{CI}_{95}=\overline{\Delta}\pm t_{0.975,9}\frac{s_\Delta}{\sqrt{10}}. \tag{5.36}$$

$t_{0.975,9}$ 约为 2.262。检验以模型块差值为数据，不以数百万请求计算一个人为极窄的区间。论文报告百分点，内部差值采用 $[0,1]$ 比例；从 0.01423 转为 1.423 个百分点时乘 100，不能称 1.423% 相对提升。

主检验族在确认前固定为学习相对贪心修复、原冻结学习修复和原适配学习修复三项。学习相对启发式与强随机属于独立的两项机制族。每族内部按 Holm 方法校正：将 K 个原始双侧 p 值升序排列，计算

$$p_{(i)}^{\mathrm{Holm}}=\min\left\{1,\max_{h\leqslant i}(K-h+1)p_{(h)}\right\}. \tag{5.37}$$

族的划分由问题而不是结果决定。两种新随机补充的学习对照另组成预先登记的新族，旧机制检验不因补充的巨大差值而重新选择校正范围。

每个主比较须同时满足：DSR 均值增益至少 1 个百分点、配对区间下界为正、Holm 校正 $p<0.05$、真实 UAV 总能耗的块级比值平均不超过 1.05，以及候选每块完整软件 p95 小于 1 s。能耗比定义为

$$\overline{\eta}_{a/c}=\frac{1}{10}\sum_b\frac{E_b^a}{E_b^c}. \tag{5.38}$$

它不同于两个能耗均值的比。能耗筛选约束预测分配能耗，验收门槛检查真实机队总能耗，两者是互补条件。统计通过也不自动意味着达到预定实用增益，跨场景评价会同时报告这两种判断。

对学习–强随机的小差值，进一步保留精确符号翻转敏感性检验。十块配对差值形成 2^{10} 种符号组合，用均值绝对值与观测值比较，考察结论对小样本分布假设的敏感性。该检验仍依赖配对差值在零假设下可交换符号的条件，也不是通用因果检验；它的价值在于没有选择性地删除与参数检验不完全一致的证据。

5.6.5 能耗、公平性、MBS 与完整软件计时

真实能耗 E_b^a 汇总五架 UAV 的飞行与作业等全部环境记录，再除以块内 30000 个时隙得到 J/步。该量不包括 MBS 计算、真实部署的新增控制通信和获取大范围需求信息的全部费用，所以 UAV 节能与全网节能是不同主张。公平性按第三章 Jain 指数逐时隙计算，再在块内平均；MBS 占比为块内送往 MBS 的请求数除以已接纳服务请求数。MBS 分母是接纳数，不是全部生成数。

完整软件时间从移动前输入准备开始，包含观测构造、两层策略推理、共同保底、配额搜索、匹配、动作映射及逻辑消息编码，排除环境物理仿真和结果落盘。先在各训练块 30000 次策略调用上计算 p95，再跨块平均；每块最大 p95 单独用于预定门槛。隔离计时在预留物理核心运行，与共享集群上的质量评估计时区分。相同模型和外生流重放保证时间测量不改变动作及质量，硬件和软件测量条件限制其可外推范围。

逻辑上传、下载字节以当前请求行、动作与摘要的序列化记录为依据，支持审计协调信息规模，但字节数不是通信时延或能耗的实测值。本章确认没有把理想协调转化为真实网络部署证明。后续若加入通信费用，需要在截止期判定前和奖励计算前分别计入相应延迟、能耗，并将其作为新物理协议评价，而不是在现有主结果上补一个未验证常数。

5.7 主场景性能与完整下层优化包的收益

5.7.1 代表轨迹与实际注意力记录

先以一个事先固定的评估实例展示集群在线运行形态：取首个确认训练块 1060001、首个工作负载 1070001、第 0 回合，绘制学习配额与贪心修复的五机轨迹、实际航程和最小机间距，如图 5.6。两方法起始外生条件和冻结上层参数相同，但下层执行影响电量、缓存和后续观测，轨迹随闭环状态演化可以不同。选择首实例而不是视觉上最有利的轨迹，有助于把运行示例与全样本性能推断分开。

逐机航程由实际位置差累加，即 $\ell_u = \sum_{t=0}^{T-1} \|\mathbf{q}_u(t+1) - \mathbf{q}_u(t)\|_2$，其中 $T = 1000$，ℓ_u 的单位为 m；它不使用网络原始动作模长代替执行位移。该回合中，

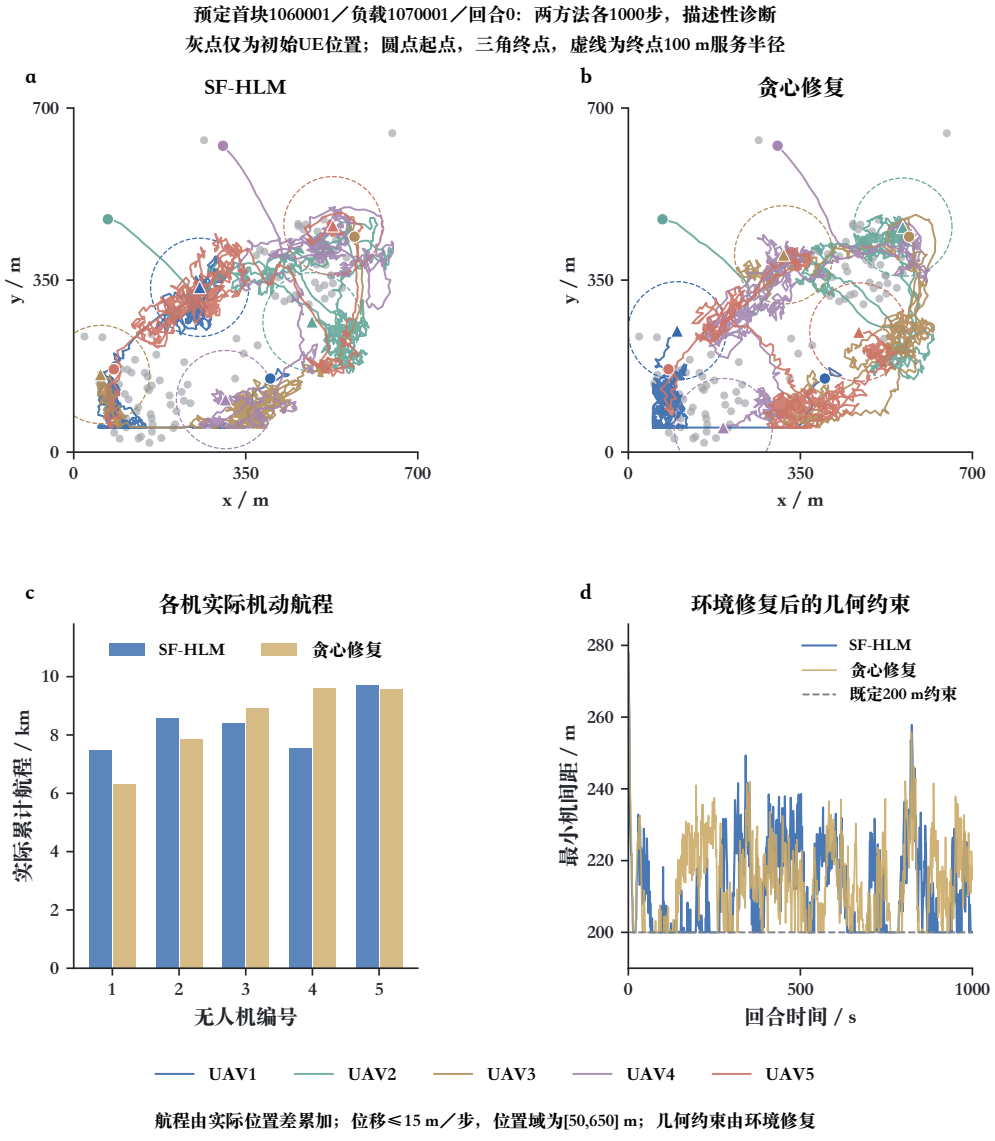


图 5.6　预选首确认回合的集群空间机动记录。上排为两方法五机轨迹，灰点仅表示初始 UE 位置，虚线为终点 100 m 服务圆；下排为逐机实际水平航程与最小机间距。200 m 间距线是既定几何约束；本图只描述各方法一个回合

Figure 5.6　Swarm trajectories, per-UAV horizontal path lengths and minimum separation in one preselected episode per method; UE markers show initial positions only

SF-HLM 五机航程之和约为 41.664 km，贪心修复约为 42.291 km。这些数值描述预选实例的机动分工，不代表全评估总体中的航程差异。最小机间距按 $d_*(t) = \min_{u<v} \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2$ 逐步计算；两方法的实际位置记录连续，最大单步位移不超过 15 m，最小间距为 200 m，核验采用 10^{-6} m 浮点容差。该结果检查的是修复后的离散位置，而不是学习策略独立提供的连续飞行避碰能力。

轨迹图中的地面散点是初始位置，不能用于计算用户移动后的动态覆盖率；终点服务圆用于说明当时 UAV 的服务几何。总体接纳优势仍由完整评估计数支持。图 5.7 进一步展示同一代表回合第 500 步的实际策略前向注意力，用当前输入及实际模型权重重算并记录，区别于独立构造的示意注意力或不参与 actor 决策的旧诊断接口。图中的权重用于查看策略在该状态下怎样聚合可见邻居与需求信息。

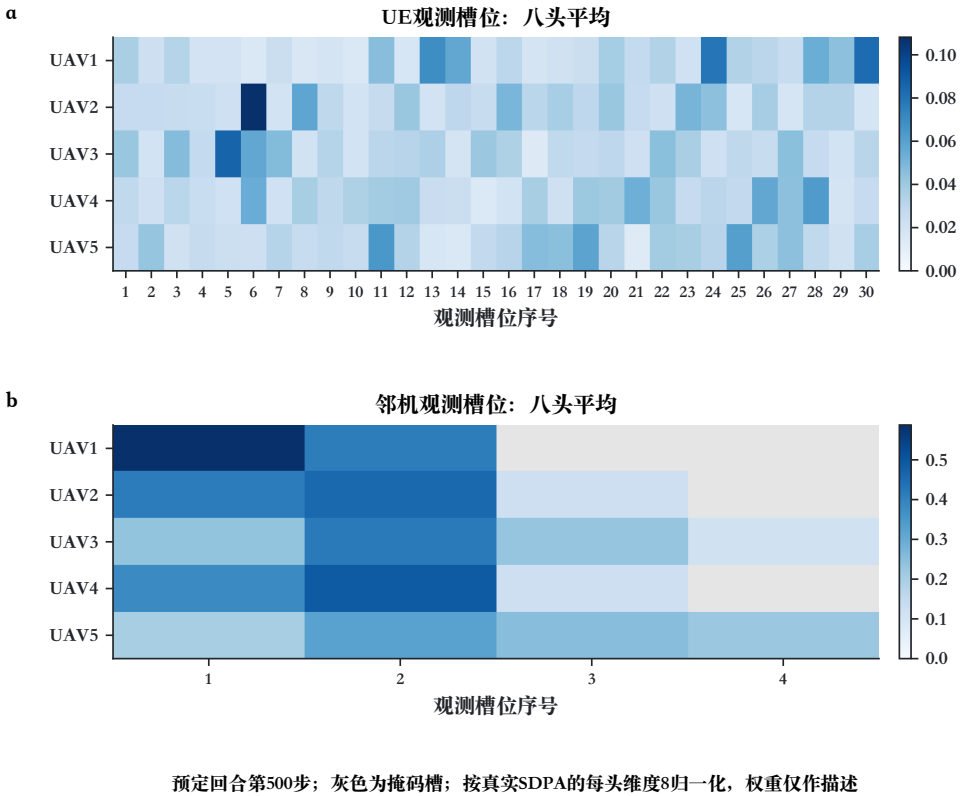


图 5.7　代表确认回合第 500 步上层 actor 的实际前向注意力记录。权重说明该状态下的信息聚合，不作为注意力贡献的独立因果证明

Figure 5.7　Actual upper-actor attention at step 500 of the representative episode; a descriptive forward-pass diagnostic

注意力可视化与统计性能互相补充：前者检查模型确实使用了所描述的前向路径，后者检验整套策略在独立训练块上的服务效果。本章核心六组共享冻结上层，所以这些比较不能单独识别上层注意力与无注意力架构的差值。上层观测

与结构的证据来自第三章，本章重点是相同覆盖基座上的下层组织能力，避免用漂亮的权重图替代对照实验。

5.7.2　八种方法的截止期满足表现

表 5.5 和图 5.8 汇总最新确认及补充随机评价。前六组属于正式六方法确认，后两组是相同冻结模型与已用确认负载上的补充评价；二者使用相同实际生成服务请求分母和块级计数汇总。主方法 DSR 为 34.244%，在本表八个方法中具有最高描述均值。该比较不把第三章或早期完整方法批次的绝对数值拼入，避免源码、训练负载和协议差异被误认为算法配对增益。

表 5.5　一百 UE 主场景的服务指标（先合并块内请求计数，再跨块平均）
Table 5.5　Service metrics in the 100-UE setting, obtained from within-block request counts and between-block averaging

方法	DSR/%	接纳率/%	接纳后完成率/%
学习配额搜索	**34.244**	57.339	59.819
启发式配额搜索	33.475	57.342	58.472
强配额随机搜索	34.100	57.379	59.517
贪心＋普通修复	32.821	57.367	57.305
原冻结学习下层＋修复	32.236	57.375	56.309
原适配学习下层＋修复	32.052	57.383	55.953
全随机（质量掩码内）	15.428	33.797	45.673
相同上层＋逐请求随机卸载	23.640	57.431	41.222

学习相对贪心修复的主增益为 1.423 个百分点，相对原冻结、原适配学习修复分别为 2.008 和 2.192 个百分点，完整区间与校正检验列于表 5.6. 三项差值均在十个训练块上同向为正；图 5.9 展示这些块级配对差，说明均值优势并非由单个异常训练块独自支撑。三项均达到预定 1 个百分点实用目标，区间下界为正，并通过三比较 Holm 校正。

表 5.6　三个预定主对照的配对 DSR 差值与真实 UAV 能耗比
Table 5.6　Paired DSR effects and actual UAV energy ratios for the three prespecified primary controls

学习减对手	差值/百分点	95% 区间/百分点	Holm p	能耗比
贪心＋普通修复	+1.423	[1.258, 1.587]	2.22×10^{-8}	0.9094
原冻结学习＋修复	+2.008	[1.808, 2.208]	8.92×10^{-9}	0.9656
原适配学习＋修复	+2.192	[1.903, 2.481]	3.46×10^{-8}	0.9803

两个已有学习下层均经过共同修复，原适配组还获得了继续学习的机会，因

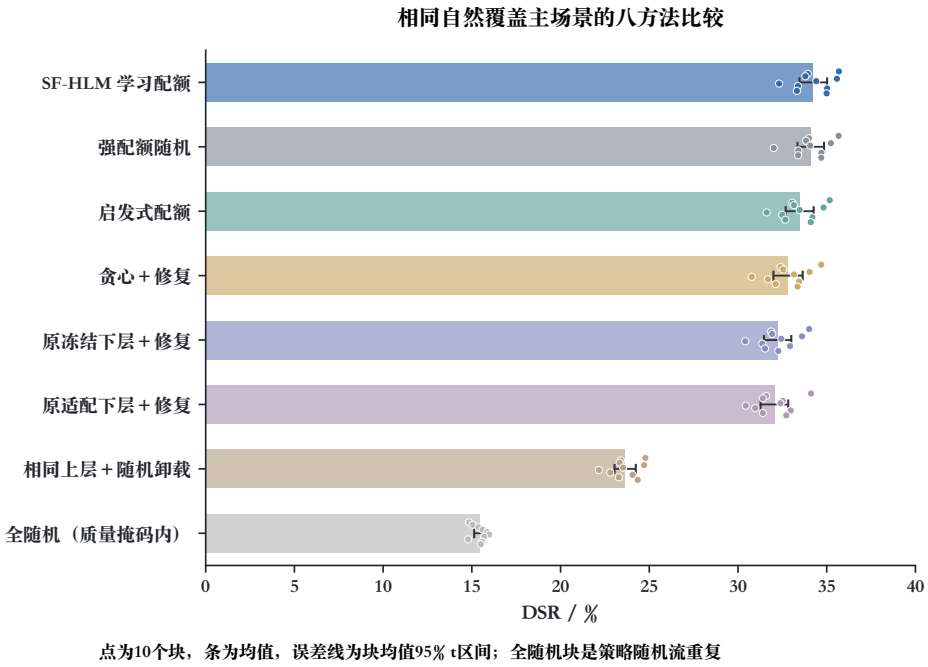


图 5.8　最新冻结协议下八种方法的 DSR 比较。六个核心方法与两种随机补充分开标识；统计单位为十个模型/随机流配对块

Figure 5.8　DSR comparison of eight methods under the latest frozen protocol, with core and supplementary controls identified

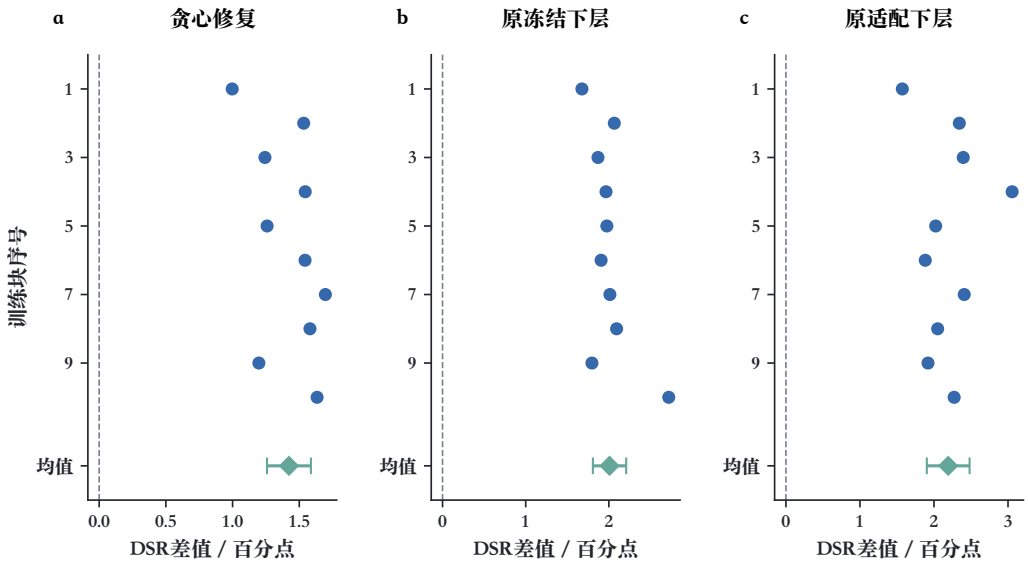


图 5.9　SF-HLM 相对三个主对手的十训练块配对差。每个块先合并五工作负载、六回合的请求计数

Figure 5.9　Per-training-block DSR differences against the three primary controls, based on pooled requests within each block

此该结果支持配额匹配下层优于这些固定合同下的原请求级学习方案。它没有证明所有请求级强化学习都弱于配额学习，也没有证明本章网络在相同总教师计算预算下必然优于所有替代网络。直接可支持的结论是：在所评估的一百 UE 仿真主场景、十个独立训练基座和已固定训练流程中，SF-HLM 对三个预定实用对手的端到端 DSR 有稳定正增益。

5.7.3　接纳与接纳后质量的请求计数分解

核心六方法的平均接纳率均约为 57.3%，差异较小；学习主线相对贪心的接纳率为 57.339% 对 57.367%，接纳后按时完成率则为 59.819% 对 57.305%。这与同覆盖基座下改善已接纳请求批量组织的设计相符。闭环状态仍可能分化，因此不能把平均接纳接近解释为所有时隙完全相同的请求集合，但结果表明主增益不是通过强行增加接纳分母获得。

图 5.10 将生成请求分为未接纳、接纳后超时与按时完成三个互斥部分。块内占比分别为 $(G-A)/G$、$(A-S)/G$ 和 S/G，相加为 1；跨块平均保持该线性恒等式。主线中三个部分约为 42.661%、23.095% 和 34.244%。同上层逐请求随机卸载的按时完成率仅为 41.222%，而接纳率仍为 57.431%，显示进入服务范围后的执行质量构成主要差距。

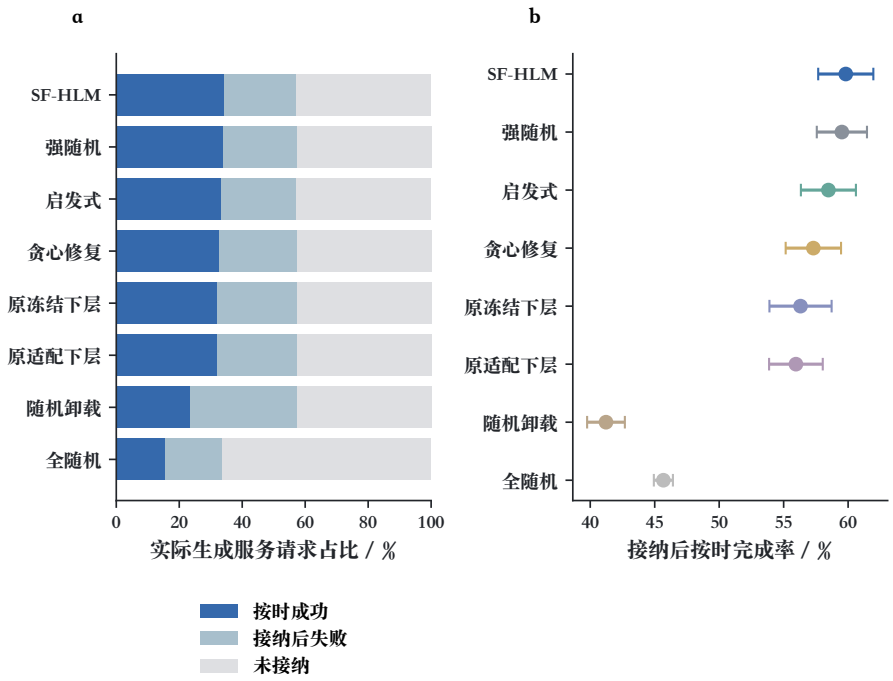


图 5.10　生成请求的互斥结果分解与接纳后完成率。三种结果按同块计数计算后平均，条件完成率以接纳请求为分母

Figure 5.10　Mutually exclusive request outcomes and deadline completion conditional on admission

全随机接纳率为 33.797%，明显低于采用学习上层的策略组，反映完整系统在形成服务机会方面的收益。保留学习上层之后，随机卸载的接纳后质量仍远低于配额匹配。这两个对照有助于解释覆盖与服务质量各自的作用，但不是固定状态下可相加的因果分解：全随机改变运动，随机卸载改变能量和后续观测，二者的状态轨迹不同。本文使用分解描述实际结果，不把 18.816 个百分点机械拆成几个独立组件贡献。

5.7.4 UAV 能耗与 MBS 依赖

表 5.7 和图 5.11 同时报告 UAV 机队能耗与 MBS 占比。主线真实 UAV 能耗为 30394.4 J/步，低于贪心修复的 33419.9 J/步；按块能耗比平均计，降低约 9.06%。相对原冻结与原适配学习修复，块级能耗比为 0.9656 与 0.9803。因此三个主比较的 DSR 改善没有以超过预定机队能耗门槛为代价。

表 5.7 主场景 UAV 资源代价、公平性和完整软件时间

Table 5.7 UAV resource costs, fairness and full-policy software timing in the main setting

方法	UAV 能耗/(J/步)	MBS 占比/%	公平性	块 p95 均值/ms
学习配额搜索	30394.4	9.83	0.9239	109.24
启发式配额搜索	31854.7	2.42	0.9209	78.16
强配额随机搜索	30123.1	8.17	0.9216	73.47
贪心＋普通修复	33419.9	2.92	0.9212	17.59
原冻结学习下层＋修复	31484.7	3.07	0.9207	17.19
原适配学习下层＋修复	31010.1	4.14	0.9208	17.17
全随机（质量掩码内）	59649.6	29.65	0.7874	4.70
相同上层＋随机卸载	57503.7	29.45	0.9208	6.57

另一方面，主线送往 MBS 的接纳请求占比为 9.83%，高于贪心的 2.92% 和启发式的 2.42%。在当前非共享 MBS 计算规则下，改变哪些请求进入 MBS 会释放 UAV 算力，并改变 UAV 计算与转发能耗。这是算法可以利用的资源分配条件，也是解释 UAV 节能时必须报告的资源迁移。因此，主线的 UAV 能耗下降不能直接写成全网能耗下降，也不能在方法优势表中删除 MBS 依赖列。

逐请求随机卸载的 MBS 占比接近 29.5%，却同时具有较低 DSR 和较高 UAV 能耗，说明 MBS 比例本身不是充分的性能解释。请求身份、回传路径、UAV 剩余批量和质量掩码共同影响结果。后续共同 MBS 数量快照诊断将进一步控制这一维度，检验配额匹配在固定 MBS 使用数量时仍有多少单步质量余量。

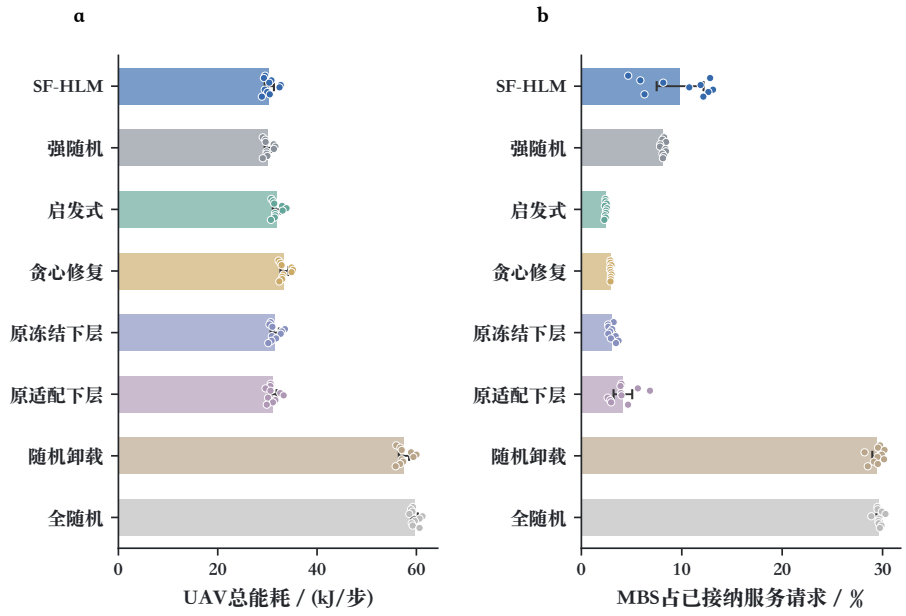


图 5.11　真实 UAV 机队能耗与 MBS 依赖。能耗为 J/步，MBS 比例为 MBS 请求数除以接纳请求数；未计 MBS 全网费用

Figure 5.11　Actual UAV fleet energy per step and MBS fraction among admitted requests, excluding whole-network MBS costs

5.7.5　公平性、计算费用与可执行性

学习主线公平性均值为 0.9239，核心六方法约在 0.9207 至 0.9239 范围；全随机为 0.7874。图 5.12 展示公平性和隔离软件 p95。主线在共享上层组中保持较高的描述公平性，同时完整软件 p95 的块均值为 109.24 ms，各块为约 103–114 ms，最大为 114.343 ms，均小于预定 1 s 阈值。该结果证明在本次隔离测量条件下，完整在线调用满足协议时间门槛。

主线比强配额随机的 73.47 ms、启发式的 78.16 ms 和贪心修复的 17.59 ms 更慢。二部图推理虽然可能减少实际匹配次数，额外前向计算仍构成净费用；因此少用求解调用不等于更短墙钟时间。相对于两个弱随机参照，主线的巨大服务提升也伴随更高软件成本。公平性和软件时间各自回答服务分布与执行负担问题，不能只选择其中较有利的一项宣称全指标优势。

完整软件时间没有计入真实网络传输、MBS 排队或未建模的需求感知费用，也不构成所有硬件上的实时保障。在本章范围内，更合适的表述是“在规定服务器隔离测量条件下满足预定软件时间门槛”，而不是“已经可直接部署于任何 UAV”。实用价值来自可复现的服务增益、明确的计算预算及已测时间水平共同成立。

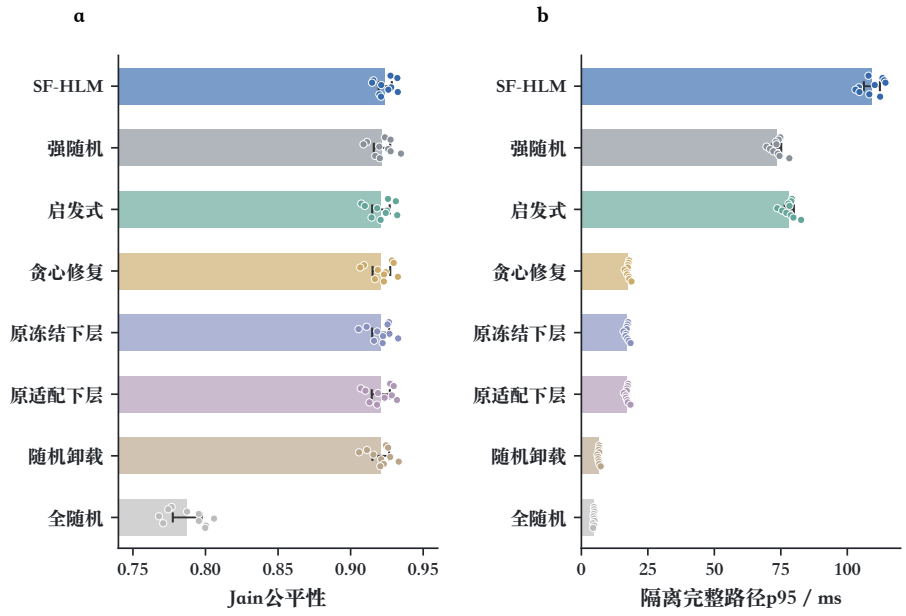


图 5.12　块级公平性与隔离完整软件 p95。p95 先在每块全部调用上计算，再展示十块分布及其均值

Figure 5.12　Block-level fairness and isolated full-policy p95, computed within each block before summarizing

5.8　完整框架与学习机制的分层解释

5.8.1　完整系统与完整下层优化包

补充随机评价显示，学习主线相对全随机 DSR 高 18.816 个百分点，95% 配对区间为 [17.840, 19.791]；相对相同上层逐请求随机卸载高 10.604 个百分点，区间为 [10.376, 10.832]。两项十块均为正，新两比较 Holm 校正通过，精确符号翻转 $p = 0.001953$。对应真实 UAV 能耗块级比为 0.5095 与 0.5284，即平均分别降低约 49.0% 和 47.2%。

这组结果表明，与不组织批量卸载的随机决策相比，完整优化包能显著利用已形成的服务机会，同时减少随机资源分配带来的 UAV 能耗。在两组共有的质量合法域下，优化包进一步使用共同贪心、普通修复、预测能耗筛选、条件指派以及最好保留。相对逐请求随机的 10.604 个百分点改善属于这一完整包，不能全数记到图 PPO 的名下。对毕业论文的贡献表述应突出“配额分解与条件匹配组成的在线优化框架”，再单独报告学习策略在这个框架上带来的增量。

全随机没有训练种子，其十个块是独立随机动作流与十套学习基座的配对重复。区间反映给定五个确认工作负载上模型和随机策略变化，不证明所有地理分布或请求类型下均有相同效应。补充评价也没有生成新的学习模型，因此应与正式十新训练块确认区分；其作用是补足解释层次，不能增加主确认的独立训练

样本数。

5.8.2　相同强框架上的学习配额增量

共享强框架中，启发式 DSR 为 33.475%，强配额随机为 34.100%，学习为 34.244%。学习相对启发式差 0.769 个百分点，95% 区间 $[0.670, 0.868]$，机制族 Holm $p = 5.56 \times 10^{-8}$。这说明按图状态学习的配额选择优于本实验采用的风险排序启发式。该判断限定于所定义的启发式，不把一个启发式的结果外推为所有手工搜索规则都不能达到同样质量。

图 5.13 展示学习相对两个强框架对照的块级差。学习相对强随机的平均增量仅为 0.143 个百分点，区间为 $[0.006, 0.281]$；十块中六块正向，原预定机制族 Holm $p = 0.0422$。参数区间与校正检验达到原协议门槛，但精确符号翻转敏感性检验 $p \approx 0.0605$。两种推断在临界小效应上并不完全一致，应保留这种不确定性，而不是用弱随机对照的大效应掩盖它。

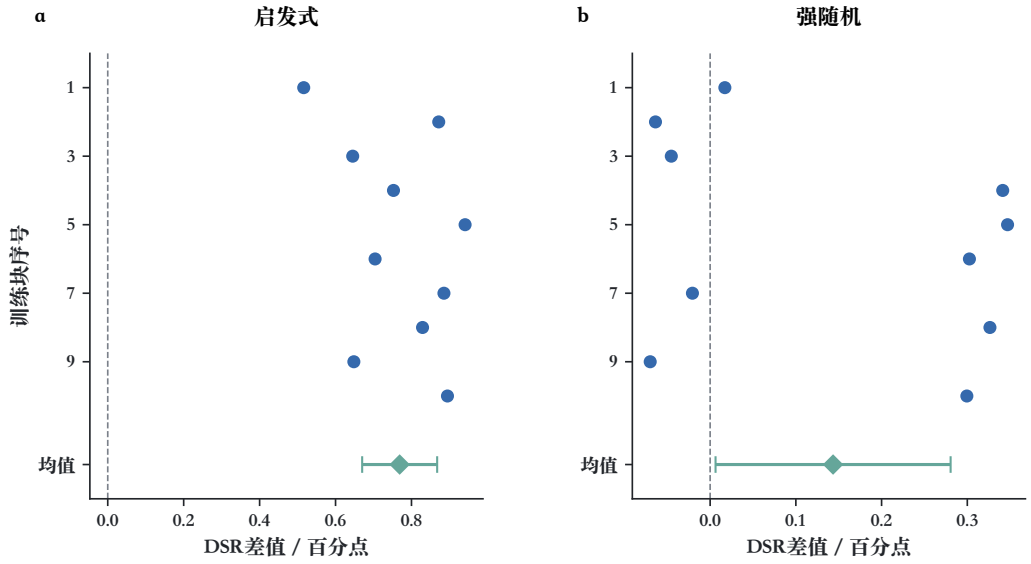


图 5.13　学习相对启发式和强配额随机的机制差。强随机共享初始化、修复、匹配、最好保留和相同调用预算

Figure 5.13　Mechanism differences against heuristic and strong random quota search sharing the same optimization framework

强随机在相同调用预算内已能取得接近学习的质量，显示条件匹配、共同保底与最好保留本身具有较强作用。学习配额的额外收益目前较小，并且完整时间更长、相对强随机 UAV 能耗块级比为 1.0089。因此已建立的主要实用优势是对贪心与已有请求级学习修复的稳定改善；“学习显著加速搜索”或“学习全面压倒强随机”不是本章结论。这个区分不削弱完整方法的主比较，而是准确划定了可归因于参数学习的部分。

5.8.3 预测误差与实际服务验证

学习主线每步预测超时数减实际接纳后超时数的均值为 −0.304 个请求，平均绝对误差为 0.366；贪心相应值约为 −0.209 和 0.321。负偏差说明观测预测总体上略低估真实超时，可能涉及缓存信念与真实状态的差别及执行细节。本文没有把预测器视为真实时延保证，所有 DSR 结果均由生产环境的按时完成计数计算。

误差统计与条件最优证明并不矛盾。指派在给定预测量下精确优化，描述的是求解结构；预测量与实际执行之间仍存在误差，描述的是模型真实性。二者需要分别检查。如果只报告预测超时减少，可能把更乐观的预测当成性能提高；本章逐步重放实际计数，并在固定快照诊断中通过独立环境副本评价实际结果，使搜索时没有接触的执行真值用于最终验证。

5.8.4 固定潜在服务请求分母复核

相同外生随机流下，低电量 UE 会将潜在服务请求改为能量请求，因此实际生成服务请求分母有轻微策略依赖性。六个核心方法在全部确认回合中的潜在服务请求总数均为 11397280。保持原成功数不变，以共同潜在请求为分母，学习 DSR 均值为 34.235%，强配额随机为 34.091%；学习相对贪心的增益为 1.421 个百分点，与预定实际分母下 1.423 的方向和量级一致。

这项复核表明，主场景的轻微分母内生性不能解释三个主比较中的服务增益。它没有令低电量 UE 继续产生服务请求，也没有重新运行改变请求生成规则的环境，因此不是反事实物理实验。预定实际分母 DSR 仍为主指标，固定潜在分母作为敏感性结果同时提供，避免事后改换较有利的指标。

5.9 冻结策略的负载与算力稳健性

5.9.1 九格设置与冻结评价

独立确认完成后，冻结十套基座和配额最后检查点，在 60/100/140 UE 与 0.6/1.0/1.4 倍 UAV 算力的九格上评价。每格保持原五负载、六回合和六种核心方法，主格直接引用原 1800 回合，八个新格共完成 14400 个质量回合。权重、优化器、奖励、MBS 算力与自然接纳保持不变，只按协议调整 UE 数和 UAV 算力。这是固定策略面对新负载与资源规模的复验，不是各格重新训练后的场景适应比较。

上层输入槽位固定为训练时的 30 个 UE；需求超过槽位时遵循原排序与容

量规则，不扩大网络。图下层使用实际请求数，原固定尺寸 MLP 下层则沿用填充与分块推理，不能通过增加网络尺寸给其追加未训练参数。各格方法使用相同改变后的物理环境。新格复用了原训练块与确认负载，因此没有形成另一套独立训练确认；其结论是原冻结策略在规定格点上的表现。

表 5.8　学习配额主线在九格冻结评价中的 DSR

Table 5.8　DSR of the learned quota method across the nine frozen-policy settings

UE 数量	0.6 倍算力/%	1.0 倍算力/%	1.4 倍算力/%
60	44.430	48.961	50.746
100	29.736	34.244	36.349
140	22.142	26.259	28.263

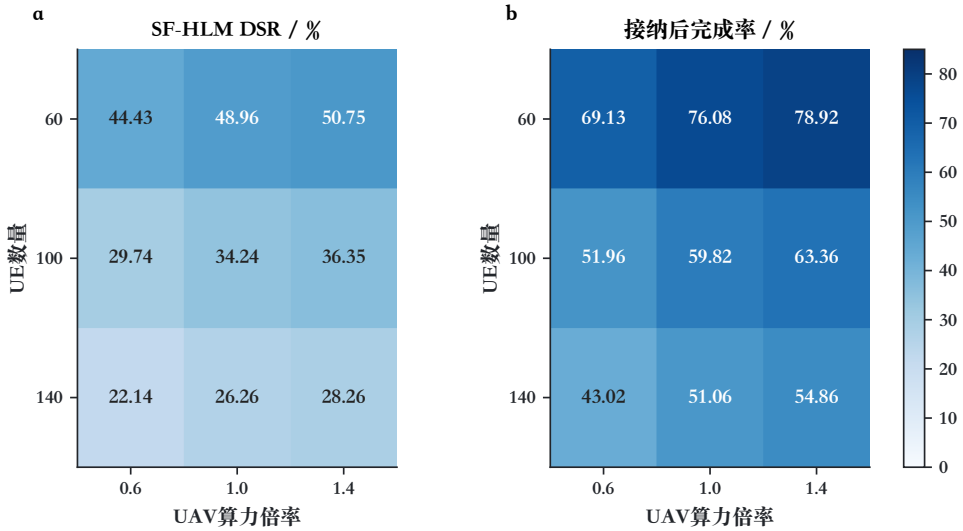


图 5.14　SF-HLM 冻结策略在 UE 数量与 UAV 算力九格中的 DSR（左）和接纳后按时完成率（右）。主格引用独立确认，其他格不重新训练；数值为十块均值

Figure 5.14　DSR and conditional completion rate of the frozen SF-HLM policy across nine UE/compute settings; cells show ten-block means

表 5.8 和图 5.14 显示，增加 UE 数量时 DSR 下降，提高 UAV 算力时 DSR 上升。相同覆盖范围和计算节点需服务更多请求，且上层可见需求槽位固定，高负载同时加剧接纳与服务质量压力；增加算力能减轻部分计算瓶颈，却不能消除未接纳和通信路径限制。因此，算力提高到 1.4 倍时 DSR 仍明显低于 100%，不能将剩余失败都归因于下层计算不足。

5.9.2 相对三个主对手的格点差值

八个新格中学习相对贪心、原冻结学习和原适配学习的 24 项比较形成一个 Holm 主族，全部通过校正。图 5.15 给出格点配对均值差；下文同时报告代表格点的逐项 95% 配对 t 区间，完整格点结果保存在冻结实验归档中。相对贪心的增益从 0.667 到 2.219 个百分点，相对原冻结学习从 1.310 到 3.086，相对原适配学习从 1.460 到 3.410。该结果支持主线对这些对手的优势在所考察负载与算力组合中保持正向。

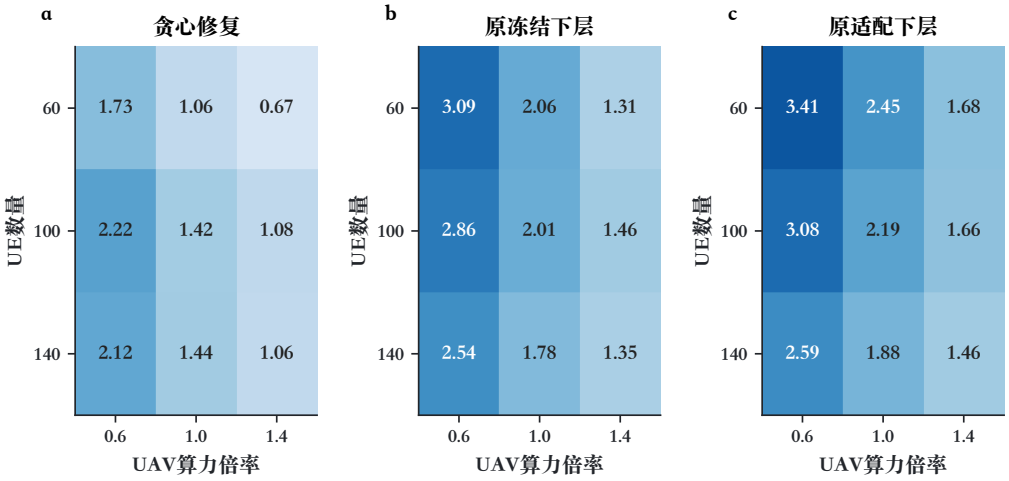


图 5.15 九格学习相对三个主对手的 DSR 差。八个新格的二十四项比较统一 Holm 校正，主格保留原确认族

Figure 5.15 DSR differences against three primary controls across nine settings, with the new 24-comparison Holm family separated from nominal confirmation

低算力与高负载下，贪心修复的局部选择更容易形成截止期敏感的批量，配额匹配的改善较明显。例如 100 UE/0.6 算力下学习 DSR 为 29.736%，贪心为 27.517%，差 2.219 个百分点，区间 [2.051, 2.387]；140 UE/0.6 算力差 2.125，区间 [1.931, 2.318]。在 60 UE/1.4 算力下，学习为 50.746%，贪心为 50.078%，差 0.667，区间 [0.493, 0.842]。后者虽然统计正向，却低于主确认事先采用的 1 个百分点实用目标，应如实保留。

真实 UAV 能耗比同样随格点变化。学习相对贪心的块级比约为 0.876–0.939，各新格均低于 1；相对原适配学习在 60 UE/0.6 算力约为 1.0078，没有节能但仍低于 1.05 门槛。能耗还受算力平方项影响，提高计算能力可以改善时间，却可能增加实际计算能耗。因而格点分析同时报告服务率和资源费用，而不把更高算力下的 DSR 变化写成免费的性能改善。

5.9.3　强框架机制的场景依赖

学习相对启发式与强随机的八格共 16 项比较另组成 Holm 机制族，其中 8 项通过：学习相对启发式在七个新格通过，相对强随机仅在 140 UE/0.6 算力通过。该格学习–强随机差约 0.355 个百分点，区间 $[0.150, 0.560]$，Holm $p = 0.0317$。其他格不能仅因未校正区间下界为正而宣称机制已稳定成立。

在 60 UE/1.4 算力格，强随机为 50.772%，略高于学习 50.746%；差值约 −0.026 个百分点且区间跨零。该结果与主场景学习增量较小的观察一致：强匹配框架已经能较充分地利用宽裕资源时，固定学习策略没有显示额外稳定优势。它不意味着学习在所有场景无效，而是说明需要根据负载与算力条件评价增量，不能把相对三主对手的跨格稳定性自动转化成相对强随机的架构优越性。

跨格结果也没有验证需求信息的部署可得性。所有格点沿用理想协调和原观测合同，没有增加请求上报丢失、延迟或字段失真。因此已完成的冻结策略稳健性消除了“只有单一 UE/算力格完成比较”的缺口，但仍保留通信实现条件和未测试分布的边界。

5.10　固定快照、共同 MBS 与时间预算诊断

5.10.1　相同状态下的真实执行复核

闭环比较能够判断长期服务表现，但不同下层引起的状态分化使逐步机制较难直接控制。为此，从已确认学习主线的十块轨迹中，对五个负载的前两个回合分别在 0/250/500/750 步采集移动前快照，共 400 个，包括空请求批次。每个快照保留相同几何、请求和历史状态，以及观测缓存信念与私有执行状态两个用途不同的副本。算法只读取观测预测行，最终候选则由独立环境副本评价实际超时和分配能耗；反事实结果不回写主线轨迹。

每块含 40 个快照，先在块内平均，再以十个基座作配对分析。自由 MBS 的普通调用合同下，学习、启发式、强随机和贪心每快照实际超时数分别为 10.2925、10.6450、10.3700 和 10.8275。学习–贪心差为 −0.5350 个请求，区间 $[-0.6837, -0.3863]$；学习–强随机为 −0.0775，区间 $[-0.1989, 0.0439]$。这说明共同状态下相对贪心有质量余量，相对强随机的差仍较小且不确定。

5.10.2　保持共同 MBS 请求数量

以每快照原始贪心的 MBS 请求数量为共同参照，要求初始化、修复、配额掩码、条件匹配和保底均保持这一数量，只允许改变哪些请求使用 MBS。

图 5.16 对照自由和固定 MBS 结果。在固定数量下，四方法平均 MBS 请求数均为 0.6950，学习、强随机和贪心实际超时分别为 10.4075、10.4050 和 10.7875。学习–贪心仍为 −0.3800，区间 [−0.5044, −0.2556]；学习–强随机为 +0.0025，区间 [−0.0919, 0.0969]。

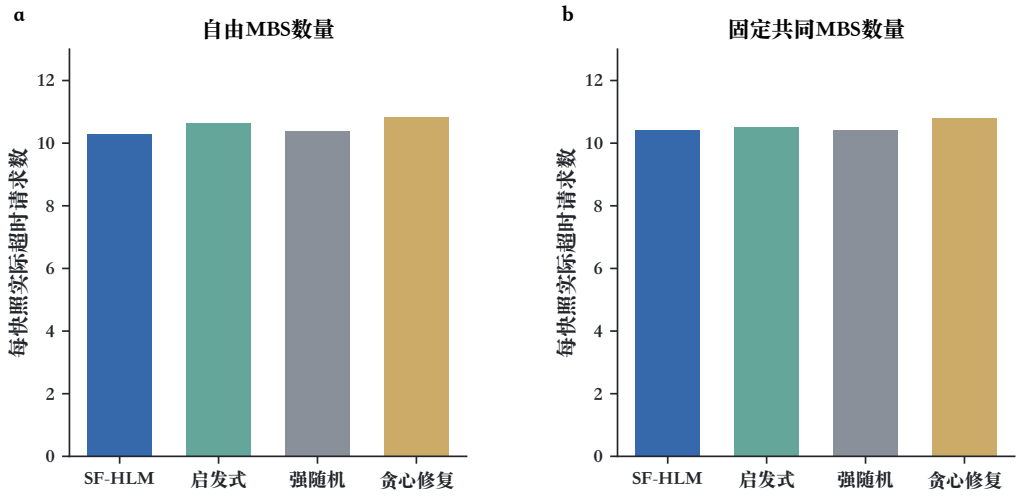


图 5.16　四百固定快照的自由与共同 MBS 数量诊断。两面板分别报告自由和固定共同 MBS 数量下每快照的实际超时均值；反事实分配不回写环境，描述性均值未画误差线

Figure 5.16　Mean actual deadline misses with free and common MBS counts on 400 snapshots; descriptive means without closed-loop write-back

固定 MBS 下学习的实际分配能耗为每快照 29619.2 J，强随机为 29202.0 J，贪心为 31637.5 J。因此，SF-HLM 的固定状态收益不能简化为“只需增加 MBS 比例”，因为固定 MBS 时相对贪心仍能减少超时和分配能耗；也不能说学习的额外机制完全独立于 MBS 使用，因为学习相对强随机的微小自由差在固定数量下没有保留。这个诊断限定的是相同快照上的分配解释，没有把固定 MBS 数量接入长期闭环，不提供该新约束下的端到端 DSR。

5.10.3　软墙钟预算下的质量与超限

在同一组快照施加 20/50/100 ms 全路径软预算，时间从输入准备开始，包含模型推理、初始化、普通修复、搜索匹配、动作映射和消息编码。输入准备消耗先从搜索可用时间扣除；预算不足时保留合法保底。各档仍保持原在线最多 16 次条件匹配与 128 次普通评价，不为了时间曲线将模型的预算特征改成未经训练的无限调用值。

图 5.17 同时展示实际超时、完整时间和预算超限比例。学习在三档每快照实际超时分别为 10.6725、10.4250 和 10.3000，相应均值时间约为 22.17、43.65 和 62.92 ms。时间预算放宽后，质量接近普通合同的 10.2925；但该变化是同快照诊

断，不代表重新训练了时间感知策略，也不构成对所有输入都单调改善的证明。

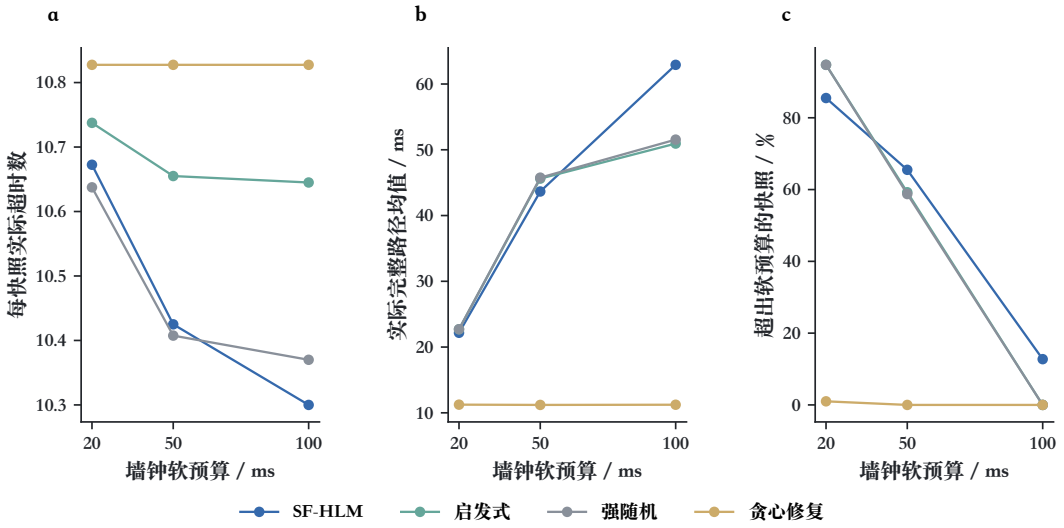


图 5.17　软墙钟预算的真实质量、时间与超限率。原子匹配与完整路径开销可能越界，所有越界样本均保留

Figure 5.17　Actual quality, time and overrun rates under soft wall-clock budgets, with all overruns retained

学习三档超限快照比例为 85.5%、65.5% 和 12.75%，最大超限约 7.33、7.06 和 6.19 ms。原子匹配开始前可以检查时间，但不能保证一次求解在剩余时间内完成，动作映射与序列化也继续消耗时间。因而“设置 20 ms 预算”与“所有调用不超过 20 ms”是不同条件。报告实际越界比强制中断求解器后只保留成功结果更能反映完整方法代价。

5.10.4　匹配调用与停止行为

图 5.18 展示 SF-HLM 在十个训练块、共 300000 个确认评估环境步中的调用预算使用与终止记录，包含空请求批次，平均每步使用 11.737 次匹配。另在普通固定快照诊断协议下，学习平均使用 11.255 次匹配，启发式 16.000，强随机 15.990；两组记录的统计对象不同，应分别解释。预算包含初始匹配，不能把调用数理解为额外迁移数。学习可在保留当前最好方案后提前 STOP，而强随机按有效非停止动作继续直到无可尝试动作或调用耗尽。停止动作与调用惩罚共同给出节约求解机会，但实际学习前向开销仍使完整软件时间高于强随机。

该记录解释了学习策略怎样使用预算，而不是把提前停止直接认定为优越性。普通快照中学习完整平均时间约 63.30 ms，强随机约 51.53 ms；两者的 p95 约为 105.24 与 74.85 ms。这与全部确认调用中的隔离时间排序一致，显示判断搜索效率需要同时观察求解次数、推理费用和实际质量，单一计数不能替代全路径测量。

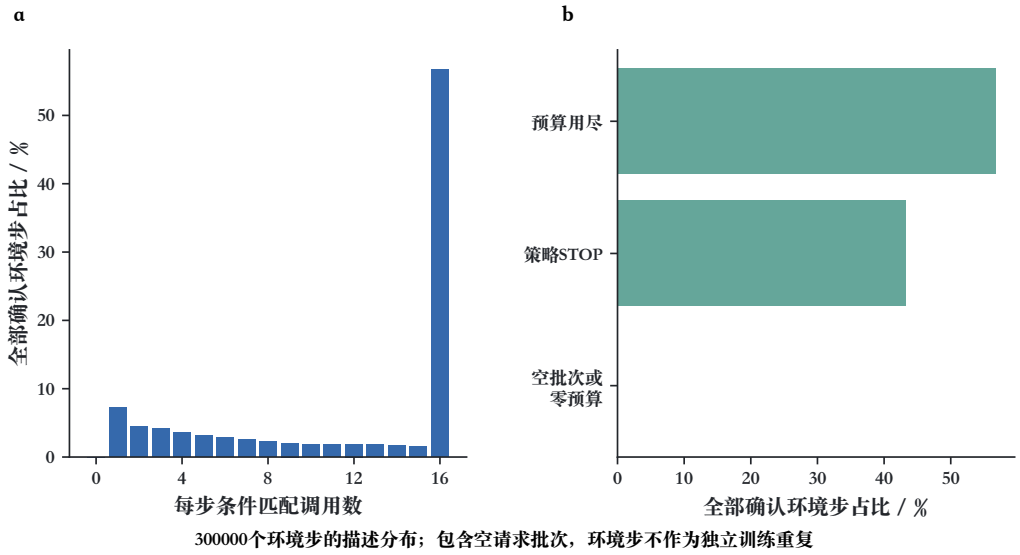


图 5.18　确认评估环境步中的匹配调用与终止行为。调用包含初始匹配及失败候选，空批次纳入统计，停止不消耗一次匹配调用

Figure 5.18　Matching-call usage and termination behavior across confirmation evaluation steps, including initialization, failed candidates and empty batches

5.11　研究联系、适用条件与本章小结

5.11.1　与第四章固定快照求解的联系

第四章 MC-ITR 研究固定状态下的真实批量分配优化，本章研究观测预测条件下的有限预算在线决策。两章共享不可拆分请求和批量算力竞争的物理动机，但求解接口、目标次序、信息条件与时间预算不同。MC-ITR 没有接入 SF-HLM 在线执行，本章也没有把其真实快照执行评价当作配额搜索教师。

此前第四–五章桥接在另一冻结协议的候选轨迹上完成，表明离线快照搜索具有接纳后服务质量余量，同时付出分配能耗和计算时间代价。该历史证据可以解释本章为何重视低预算卸载组织，不能与最新 34.244% DSR 直接拼接成 MC-ITR 接入后的长期增益，也不能用不同测量条件的时间比宣称本方法相对其固定倍数加速。两章的连接在问题结构与质量–计算权衡，而不是同一个算法的先后版本。

5.11.2　主要贡献与仍需验证的条件

本章建立了三项彼此支撑的结果：配额固定后，可用严格字典序标量化得到预测超时优先的条件匹配；有限预算搜索通过共同保底与最好保留始终输出完整合法分配；在独立训练块上，完整下层相对三种预定实用对手取得稳定服务增益，并在规定隔离时间内满足软件门槛。冻结跨场景复验进一步说明该优势在所测试 UE 与算力格点上保持正向。其技术意义是把已经能够确定性求解的指派结

构交给求解器，把有限学习能力集中用于节点负载组织。

需要区分这些已成立结论与开放问题。强框架随机已接近学习质量，说明框架中的确定性部分承担重要作用；学习增量小且具有场景依赖。服务压力反馈未晋级，不能说本章已经证明上下层共同重训更有效。理想协调与大范围需求信息的实际获取条件仍待费用和信息受损协议验证，UAV 节能也不能外推成全网净节能。这些条件限定方法可推广的范围，但不改变本次冻结协议中三个主比较的方向。

后续最有判别力的工作是比较同信息预算下的强方法，并把请求上报延迟、缺失与协调开销纳入环境；这样可以判断现有收益在减少观测完整性或增加通信费用后还剩多少。若继续改善学习配额，应优先使新增特征或教师在共享强框架上产生可独立确认的增量，而不是仅增加结构复杂度。任何新候选都应重新冻结设计和模型选择规则，不能替换已确认模型后继续使用原独立确认名义。

5.11.3　集群计算任务的执行分工

集群协作除空间机动之外，还体现在已接纳计算请求的执行分工。图 5.19 从 SF-HLM 的十个确认训练块原始记录中，分别累加来源本机、其他 UAV 和 MBS 三条服务执行分支的计数。每块包含五个工作负载、每负载六个回合，分支标识取自环境的服务卸载记录；这里的“本机”指请求接纳 UAV，而非 UE 自身处理器。“协作 UAV”指另一个允许执行目标，MBS 则是地面计算支撑。

记块 k 的三类计数为 $n_{k,\mathrm{L}}$、$n_{k,\mathrm{C}}$ 和 $n_{k,\mathrm{M}}$，本图的分母明确取 $n_k = n_{k,\mathrm{L}} + n_{k,\mathrm{C}} + n_{k,\mathrm{M}}$，各分支比例为 $\rho_{k,j} = n_{k,j}/n_k$。三类比例在块内之和为一，统计对象是已记录的执行分支，不是按时成功请求或各 UAV 的单机负载。跨块摘要采用 $10^{-1}\sum_k \rho_{k,j}$；将全部计数池化得到的 $\sum_k n_{k,j}/\sum_k n_k$ 属于另一种加权方式，不代替图中的块均值。

按等权块均值，本机、协作 UAV 和 MBS 的执行比例依次约为 45.054%、45.112% 和 9.834%。三分支总计记录 6 533 312 次，其中本机 2 945 929 次、协作 UAV 2 946 812 次、MBS 640 571 次；池化比例依次约为 45.091%、45.104% 和 9.805%。该分布说明跨 UAV 执行在这批已记录计算请求中占据较大部分，空间接纳平台与计算执行平台确实可以分离。它没有识别单独关闭跨机协作后的性能效应，也不能由较低 MBS 比例推断无需地面支持。协作分支还包含传输与资源竞争代价，服务质量与能耗仍需结合前述独立比较解释。

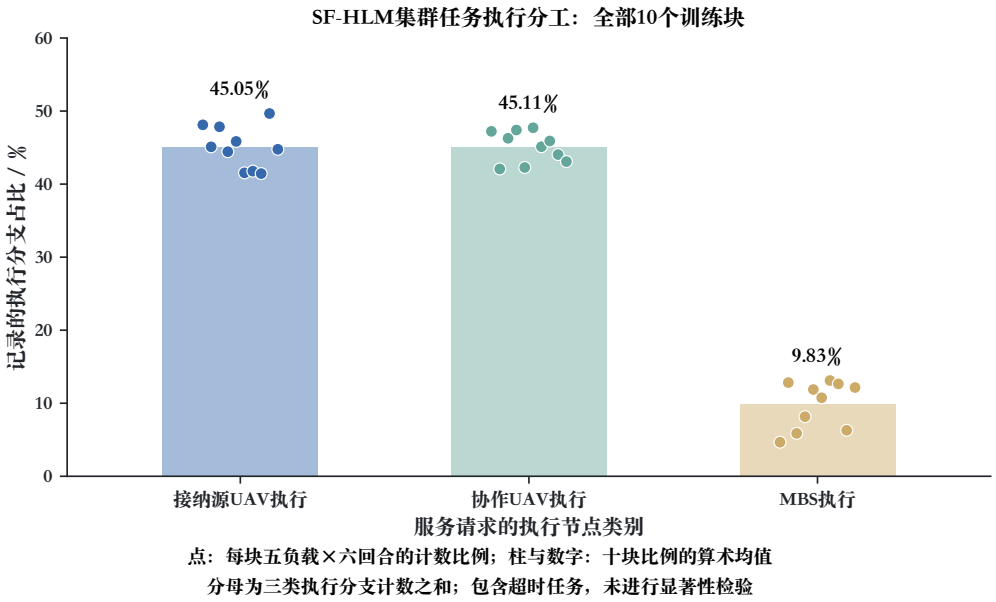


图 5.19　SF-HLM 十个确认训练块的计算任务执行分工。比例分母为每块本机、协作 UAV 与 MBS 三分支计数总和；显示全部训练块及等权块均值，不设置误差线或显著性检验
Figure 5.19　Computation-task execution branches across all ten SF-HLM confirmation blocks, normalized by each block's three-branch total; descriptive block fractions and their arithmetic means

5.11.4　本章小结

本章把无人机集群的需求感知空间部署与跨节点计算任务分工连接起来，形成冻结上层、学习配额和条件匹配的 SF-HLM 在线方法。上层分散轨迹推断与下层集中批量分配具有清楚的输入、输出和训练阶段，任务执行通过状态反馈影响后续机动。详细推导了移动前时延与分配能耗预测、整数配额守恒、容量槽指派、字典序等价性、二部图消息传递和配额 PPO；共同贪心参照、能耗筛选与最好保留明确了有限预算方法的输出性质。独立确认表明，该方法相对贪心修复和两种原学习修复具有端到端 DSR 优势，真实 UAV 能耗与完整软件时间同时达到预定门槛。

补充随机、冻结九格、共同 MBS 和软墙钟诊断进一步区分完整优化框架的收益、学习选择的额外贡献及其资源代价。完整下层对逐请求随机具有较大改善，而共享强框架上的学习增量较小；更高 MBS 依赖与额外推理时间需要和 UAV 节能一起报告。由此，本章形成的是有明确信息条件、实测预算和独立重复支持的仿真方法结论，为后续验证通信可得性和部署费用提供可复现基础。

第 6 章　总结与展望

6.1　研究总结

本文面向具有截止时间的地面计算服务，研究无人机集群如何通过协同空间部署接纳动态需求，并通过跨节点计算任务分配提高按时完成比例。空中平台的位置决定请求能否进入服务流程，机载计算、缓存及协作传输决定接纳后的执行质量。围绕这两个相互联系的环节，本文以统一请求计数为基础，依次研究需求感知协同轨迹决策、固定快照跨机任务分配和 SF-HLM 完整在线方法，形成从空间服务瓶颈到批量资源耦合再到分层决策验证的技术路线。

本文的研究对象属于无人机集群任务规划与资源分工。机动决策使多个服务区域随需求调整，任务分配使多个执行节点分担接纳负载，共同服务于时限完成目标。MEC 为这种协同提供了具有明确输入、截止时间和资源消耗的任务模型。本文在固定高度二维运动与规定信息条件下检验方法，不将应急服务这一应用动机等同于已完成灾害场景验证，也不把任务层协同扩展为飞行动力学或编队稳定性的研究结论。

6.1.1　需求感知的集群空间部署与服务接纳

本文把实际生成、自然接纳和按时完成的服务请求记为 G、A 和 S，以 S/G 定义端到端 DSR，同时报告 A/G 与 S/A。这一口径把未覆盖请求的损失纳入评价，使轨迹控制与卸载质量能够在同一个服务成功链条内解释。它也避免了只看接纳后完成率时忽略覆盖盲区的问题。对于多个时隙、工作负载或训练块，本文按照预定计数和聚合层次计算指标，而不直接相乘三个跨单元均值。

第三章的服务失败分析显示，未覆盖需求构成主场景中重要的失败来源。扩展上层预动作观测后，轨迹策略能够看到感知范围内尚未接纳的用户，其物理服务半径仍为 100 m。独立确认中，候选 DSR 从 0.2444 增至 0.2793，提升约 3.49 个百分点，并在十个训练种子上保持同向。接纳增加的同时，接纳后完成质量发生变化，这使“更多覆盖”与“更好的服务”之间的联系成为后续卸载研究的直接动机。固定潜在服务请求分母复核也表明，轻微实际分母变化未解释该批次的主增益。

这项研究把轨迹规划的依据从已接纳用户扩展到允许观测的尚未接纳需求，使集群空间部署能够面向后续服务机会进行调整。邻机与用户注意力组织可变的空间交互信息，位移、边界和间距修复保证规定离散状态中的几何可行性。需

求信息扩展同时改变了信息条件；同信息预算的探索性替代结构比较尚未确认独立注意力优势，因此本文把需求可见性、网络聚合和环境执行约束分别解释。这种区分保留了空间部署改善的证据，也使后续结构比较能够围绕相同信息条件进行。

6.1.2 跨机计算任务分工与批量资源耦合

第四章针对给定集群位置、请求和历史状态研究 MC-ITR，把跨机任务分工写成具有批量外部影响的分配问题。最终批量均分算力使一个请求迁移能够改变两个节点上其他请求的完成时间，因此逐请求自身代价不足以完整描述迁移影响。MC-ITR 对候选迁移重新评价整个分配，并按超时数、归一化时延与分配能耗的字典序比较接受严格改善。有限分配空间与严格改善保证相应搜索按无改善或预算条件终止，其性质属于固定快照求解过程；完整邻域扫描无改善时才认证相应邻域局部最优。

主配置中，MC-ITR 每快照平均超时数为 2.055，低于 Iterative-Base 的 2.228；九个主场景、UE 和算力变体的配对结果支持其质量改善。小规模穷举用于实现一致性检查，不能被外推为主配置全局最优证明。在历史候选轨迹产生的共享快照上，MC-ITR 相对在线下层平均每快照少 2.460 个超时请求，说明这些状态中仍存在可利用的分配余量。

固定快照实验同时测量了代价。共享轨迹桥接中，MC-ITR 分配能耗约增加 23.8%，含贪心初值的完整调用路径平均约 20.751 s。这项结果为较快的近似优化提供了设计依据，但反事实分配未回写环境，不能与第五章长期 DSR 直接相加。本文没有将 MC-ITR 接入在线下层，而是用其揭示的批量结构指导后续条件化匹配与有限预算搜索。

6.1.3 协同轨迹与计算任务分配的分层决策

第五章提出并验证 SF-HLM 的当前主线实现，连接需求感知的集群空间部署与接纳后的计算资源分工。给定执行节点配额后，把自然接纳请求分配到容量槽位，通过条件化指派处理请求身份与最终共享算力之间的关系；CompleteQuotaPPO 再选择配额迁移与停止动作。共同质量掩码、普通修复、能耗筛选和最好方案保留构成可执行优化框架，使有限预算中的搜索能够保留已发现的完整方案。该主线采用冻结学习式上层和独立训练的配额策略，保持原自然接纳和物理执行语义。

十个独立训练块与五个配对工作负载的确认中，学习配额搜索的 DSR 为

34.244%，相对贪心加普通修复、原冻结学习下层加修复、原适配学习下层加修复，分别提高 1.423、2.008 和 2.192 个百分点。相对相同学习上层加逐请求随机卸载与全随机，差值分别为 10.604 和 18.816 个百分点。这些对照分别说明完整下层优化包与完整系统相对随机决策的收益，不能全部归因于配额 PPO。候选接纳后按时完成率为约 59.82%，表明下层质量是最新主线的重要增益环节。

共享强框架下，配额随机搜索已经达到约 34.100% DSR，学习搜索的额外差值约为 0.143 个百分点。原配对区间为约 $[0.006, 0.281]$ 个百分点，机制族 Holm 校正通过，而精确符号翻转敏感性结果接近临界。因此，学习额外收益应按较小效应解释，同时保留强框架本身的主要贡献。主线各块隔离 p95 软件调用时间的均值约为 109.24 ms，高于强配额随机的约 73.47 ms；服务质量提升与软件开销必须共同呈现。

6.2　综合认识与适用范围

本文的方法组织体现了无人机集群规划中的两个互补方向：轨迹策略面对尚未接纳的需求，改变未来空间服务条件；结构化下层面对已经接纳的请求，协调当前跨节点资源竞争。前者依赖允许的预动作信息，后者依赖当前请求、节点和预测模型。闭环中缓存与能量会让二者继续互相影响，因此本文把 DSR 分解作为解释框架，而不主张各组件收益可以独立相加。最新确认是完整方法的实验结论，固定快照和开发消融用于解释其结构与边界。

集群协调采用上层分散式决策与下层集中调度相结合的方式。每架 UAV 的 Actor 使用按信息合同提供的局部观测，下层则汇总当前请求和节点能力形成完整任务分配。这种组织体现了空间部署与计算分工的协同，但仍需要集中协调条件。当前五机仿真没有检验大规模集群的通信扩展性，也没有把 460 m 感知邻居关系作为持续通信连通性证明。200 m 最小间距属于既定离散几何约束，不能被解释为学习方法独立获得的连续飞行安全能力。

冻结策略稳健性评价已经覆盖 60/100/140 UE 与 0.6/1.0/1.4 UAV 算力的九格设置，不再属于尚未完成的工作。这些评价检验相同冻结模型面对负载与算力变化的表现，不等于各场景重新训练后的最优适配。完整下层优化与强配额随机之间的差异仍依赖场景，不能由主场景小幅正效应推断所有变体均有显著学习优势。固定 MBS 配额和墙钟预算的快照诊断则进一步明确了匹配行为和计算限制，但不替代长期闭环比较。

现有研究采用仿真信息与理想协调条件，预接纳需求上报、通信排队、消息失真以及实测网络时延尚未被最新确认结果覆盖。软件计时包含协议规定的观

测准备、推理与搜索路径，但不包含未建模的现实传输等待。UAV 能耗统计也不等于全系统能源足迹。本文结论因此限定为当前仿真、信息合同与冻结配置下的性能，不据此宣称所有指标全面最优或已经满足真实部署要求。

6.3 后续研究方向

首先，可把任务层机动决策与具有飞行动力学约束的轨迹执行连接。当前位移模型限制速度模长、边界和离散机间距，但没有描述加速度、转向、姿态及环境扰动。后续需要检查这些约束如何改变可到达服务位置，并把轨迹跟踪误差纳入覆盖判定。在相同请求与资源条件下，比较理想位置更新和动力学可执行轨迹的接纳率、按时完成率及实际飞行能耗，可以判断现有任务层收益在执行约束下保留多少。连续避碰能力也应由对应轨迹验证与控制分析确认。

其次，可在明确通信协议下研究预接纳信息与集群协调信息的可获得性。现有策略看到感知范围内的位置、请求和电量，后续应分别设置请求上报延迟、字段缺失、更新频率和控制消息代价，并在截止期判定与 UAV 能耗结算之前计入相应成本。下层集中调度还应计入请求汇总与分配下发的时延，检查信息陈旧时的可行性与回退行为。所有方法应使用相同信息条件和回退规则，使性能差异能够对应算法而不是隐含信息优势。该试验属于新物理或观测协议，需要独立冻结配置与评价，不能把理想协调结果直接延伸为部署结论。

再次，可研究平台失效与有限续航条件下的集群任务重分工。当前研究记录 UAV 飞行与任务执行能耗，尚未通过有限机载电池状态决定返航、退出服务或续航终止。后续应明确各机剩余能源、返航保留量和失效时刻，在执行节点不可用时重新确定配额、任务映射和空间部署，并记录任务丢失与恢复时间。固定故障流和相同电池预算下的比较，能够检验现有层次结构是否支持能力变化后的服务恢复；这种能力不能由当前平均能耗较低或任务迁移收益直接推断。

在决策模型方面，可扩大同信息结构比较与场景训练设计。第三章已有同信息替代结构的探索性证据，后续可以用新的训练块和负载进行确认，检查注意力聚合、需求排序与观测容量各自的作用。对于 UE 与算力变化，也应区分冻结策略泛化和重新训练适配：前者关注已有模型是否仍可用，后者关注在新场景下投入额外训练能达到什么表现。这样的分开设计能够为模型选择和集群服务预算提供更清楚的依据。

在任务调度方面，可研究更有效的有限预算搜索。当前强配额随机已具有较高服务质量，说明条件化匹配与保留框架提供了坚实基座；学习策略的下一步应针对请求临界程度、负载变化和调用成本形成更准确的停止与入口选择。在相同

匹配预算和墙钟预算下，比较不同学习信号与教师路径，报告在线收益以及离线标注成本。任何由开发结果筛选的新策略，应使用新的独立确认，而不直接替换当前主结果。

上述扩展还可以结合传播遮挡、请求依赖和缓存不确定性，逐步检验更丰富的物理与业务条件。扩展模型时应保持单位、时序与成功计数一致，并继续保留强非学习对照。实际执行轨迹、注意力权重和搜索过程的可视化可以帮助解释行为，但应来自冻结模型与完整记录，不能替代独立性能检验。对于应急临时服务等应用，还需使用相应的地理环境、任务流和平台参数独立验证，才能把本文的仿真服务收益转化为具有明确机动、能源与信息成本的集群系统设计依据。

6.4　本章小结

本文完成了面向时限服务的无人机集群需求感知协同轨迹决策、跨机批量任务分配和最新 SF-HLM 分层方法的研究。独立确认支持完整下层优化包在当前主场景中提高端到端 DSR，强随机对照则限定了学习搜索额外贡献的幅度。由此形成的任务规划思路是在规定机动与信息条件下，让空间部署改善服务接纳，再让跨节点资源分工改善接纳后的执行质量。后续研究围绕动力学可执行性、通信条件、平台失效与有限续航进一步检验这一思路，并继续保持已有方法、数据和主结果的可追溯性。

参考文献

[1] Chung S J, Paranjape A A, Dames P, et al. A survey on aerial swarm robotics[J]. IEEE Transactions on Robotics, 2018, 34(4): 837-855.

[2] Mao Y, You C, Zhang J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2322-2358.

[3] Zeng Y, Zhang R, Lim T J. Wireless communications with unmanned aerial vehicles: opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.

[4] Mozaffari M, Saad W, Bennis M, et al. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.

[5] Hu X, Wong K K, Yang K, et al. UAV-assisted relaying and edge computing: Scheduling and trajectory optimization[J]. IEEE Transactions on Wireless Communications, 2019, 18(10): 4738-4752.

[6] Yu Z, Gong Y, Gong S, et al. Joint task offloading and resource allocation in UAV-enabled mobile edge computing[J]. IEEE Internet of Things Journal, 2020, 7(4): 3147-3159.

[7] Skaltsis G M, Shin H S, Tsourdos A. A review of task allocation methods for UAVs[J]. Journal of Intelligent & Robotic Systems, 2023, 109(4): 76.

[8] Yuan X, Xie Z, Tan X. Computation offloading in UAV-enabled edge computing: A Stackelberg game approach[J]. Sensors, 2022, 22(10): 3854.

[9] 曾耀平, 李怀, 陈世森, 等. 无人机部署与卸载策略优化[J]. 浙江大学学报（工学版）, 2026, 60(8): 1686-1696.

[10] 王义君, 王雅出, SHAHD Batool, 等. 无人机辅助动态权重边缘计算卸载策略研究[J]. 电子与信息学报, 2026, 48(7): 3071-3083.

[11] 李侍阳, 朱晓荣. 面向感知与 AI 协同任务的无人机巡检多维资源联合优化算法[J]. 电子与信息学报, 2026, 48(5): 2166-2177.

[12] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[13] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256.

[14] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning [A]. 2015.

[15] Li B, Yang R, Liu L, et al. Robust computation offloading and trajectory optimization for multi-uav-assisted mec: A multi-agent drl approach[J]. IEEE Internet of Things Journal, 2024, 11

(3): 4775-4786.

[16] Tao Y, Kuang Z, Hou F, et al. Online service selection and task offloading in UAV-assisted MEC via deep reinforcement learning[J]. IEEE Transactions on Cognitive Communications and Networking, 2026, 12: 4159-4173.

[17] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 6379-6390.

[18] Yu C, Velu A, Vinitsky E, et al. The surprising effectiveness of PPO in cooperative multi-agent games[C]. Advances in Neural Information Processing Systems: Vol. 35. 2022: 24611-24624.

[19] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-agent learning based on team reward[C]. Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems. 2018: 2085-2087.

[20] Rashid T, Samvelyan M, Schroeder de Witt C, et al. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning[C]. Proceedings of Machine Learning Research: Vol. 80 Proceedings of the 35th International Conference on Machine Learning. 2018: 4295-4304.

[21] Hady M A, Hu S, Pratama M, et al. Multi-agent reinforcement learning for resources allocation optimization: A survey[J]. Artificial Intelligence Review, 2025, 58(11): 354.

[22] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 5998-6008.

[23] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. MIT press, 2018.

[24] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[A]. 2015.

[25] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017.

[26] Gronauer S, Diepold K. Multi-agent deep reinforcement learning: A survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.

[27] Virtanen P, Gommers R, Oliphant T E, et al. SciPy 1.0: Fundamental algorithms for scientific computing in Python[J]. Nature Methods, 2020, 17(3): 261-272.

[28] Crouse D F. On implementing 2D rectangular assignment algorithms[J]. IEEE Transactions on Aerospace and Electronic Systems, 2016, 52(4): 1679-1696.

致谢

在此感谢导师的悉心指导，感谢实验室同学的帮助，感谢家人的支持。

在读期间取得的科研成果