

中山大學
SUN YAT-SEN UNIVERSITY

中山大学专业硕士学位论文

面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

专　　业：YOUR_SPECIALITY

学位申请人：YOUR_NAME

指 导 教 师：YOUR_SUPERVISOR 教授

论文答辩委员会主席：_____

论文答辩委员会成员：_____

_____

_____

_____

2026 年 11 月

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：　　年　　月　　日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：　　导师签名：

日期：　　年　　月　　日　　日期：　　年　　月　　日

论文题目：面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

专　　业：YOUR_SPECIALITY
硕 士 生：YOUR_NAME
指导教师：YOUR_SUPERVISOR 教授

摘　要

无人机（UAV）集群为动态地面需求提供时限计算服务时，需要协调空间覆盖、跨节点分工与有限传输计算资源。轨迹策略若看不到尚未接纳的需求，难以及时形成服务机会；增加接纳又可能加剧批量资源竞争与跨时隙排队。本文以临时空地计算服务为应用动机，围绕需求感知轨迹、固定快照任务分配和动态排队联合控制开展研究。以全部实际生成请求为分母定义端到端截止期满足率（DSR），并通过接纳率与接纳后完成率分解其变化。

首先，在含服务程序缓存与最终批量算力均分的自然覆盖协议下，保持 100 m 物理服务半径不变，将感知范围内尚未覆盖需求纳入 Attention-MAPPO 的预动作观测。独立确认中，扩展观测候选 DSR 从 0.2450 增至 0.2735（提升 2.85 个百分点，训练种子配对 95% 区间为 [+1.65, +4.06] 个百分点），说明需求可见性能够改善指定主场景的接纳与服务。其次，针对跨机任务迁移通过最终批量共享算力影响其他请求的现象，提出按超时数与平均归一化时延两层字典序整体重评估的 MC-ITR 固定快照求解方法。主配置每快照平均超时数由迭代对照的 2.215 降至 2.045；扩展观测候选轨迹的冻结快照桥接进一步显示每快照平均减少 2.633 个超时请求的分配质量余量，同时伴随较高搜索开销。MC-ITR 未作为后续动态排队方法的在线模块或蒸馏教师。

进一步，在独立的跨时隙动态排队协议中，研究上传、转发和先占式最早截止期优先（EDF）计算跨时隙保留进度时的轨迹与卸载联合控制。结合释放时间工作保守串联排队近似，构建候选级双分支等变策略，通过两轮数据聚合蒸馏规划知识，再利用完整环境轨迹与共同随机数下的短视界反事实辅助评分进行 PPO 微调。该辅助评分与真实轨迹奖励分别定义，不将混合更新视为标准在策略 GRPO。测试提供零在线 Engine 前瞻策略，以及学习先验同时参与候选筛选和评分的神经引导 Top-6 MPC。

三个固定父谱系、八个新工作负载与两个动作流构成 816 个配对确认回合。

联合微调 DSR 为 48.74%，相对从零冷启动策略（44.25%）提高 4.49 个百分点，相对蒸馏学生初值（48.04%）提高 0.70 个百分点（31 项比较 Bonferroni 校正区间为 [+0.39, +0.98] 个百分点）；受控反事实开关消融表明，无反事实辅助的纯暖启动 PPO-GAE 达到 48.05%（较冷启动提高 3.80 个百分点），短视界反事实辅助进一步贡献 0.69 个百分点的净增量。在暖启动内部，双分支耦合相对真去耦微调（48.41%）与无期望向量微调（48.63%）的全程 DSR 差值分别为 +0.33 与 +0.11 个百分点（95% 区间跨零），但将已接纳任务条件完成率提升至 93.83%（描述性提升 +0.89 与 +0.57 个百分点）。微调 Top-6 MPC 全程 DSR 达 49.31%，相对指定在线规划基线（48.56%）提高 0.75 个百分点（校正区间为 [+0.25, +1.42] 个百分点）。两种控制方式平均决策耗时分别为 0.520 秒和 0.722 秒，低于基线 1.602 秒，但尾延迟仍超过一秒。单时隙批量共享协议与跨时隙动态排队协议的绝对指标不能直接拼接。本文据此形成从需求可见性、批量资源竞争到动态排队控制的分层证据，为进一步纳入信息成本与决策延迟的集群服务方法提供基础。

关键词：无人机集群，协同轨迹规划，任务卸载，动态排队，强化学习

Title: Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

Major: YOUR_SPECIALITY
Name: YOUR_NAME
Supervisor: Prof. YOUR_SUPERVISOR

ABSTRACT

A UAV swarm providing deadline-constrained computation services must coordinate spatial coverage, task offloading, and limited communication and computing resources. A trajectory policy that cannot observe unadmitted demand may miss service opportunities, whereas admitting more requests can increase batch contention and persistent queues. Motivated by temporary air–ground computation services, this thesis studies demand-aware trajectories, fixed-snapshot allocation, and joint control under dynamic queues. End-to-end deadline satisfaction rate (DSR) uses all actually generated requests as its denominator and is decomposed into admission and conditional completion.

First, under the natural-coverage batch-service protocol with service caching and equal batch compute sharing, uncovered demand within the sensing range is included in the pre-action observations of Attention-MAPPO while retaining the 100-m service radius. Independent confirmation increases DSR from 0.2450 to 0.2735 (+2.85 percentage points, 95% paired t CI [+1.65, +4.06]) in the specified main setting. Second, the fixed-snapshot MC-ITR method reevaluates complete assignments under a strict two-level lexicographic objective of deadline misses and mean normalized latency to account for the effects of task migration on other requests through batch-shared computing. It reduces mean deadline misses from 2.215 for an iterative comparator to 2.045. Frozen shared-trajectory snapshots from the extended-observation candidate identify further allocation headroom (-2.633 deadline misses per snapshot), accompanied by higher search cost. MC-ITR is neither an online component nor the distillation teacher of the subsequent dynamic-queue method.

An independent dynamic-queue protocol is then used to study joint trajectory and offloading control when upload, forwarding, and preemptive earliest-deadline-first

(EDF) computing retain progress across slots. Coupled with a release-time work-conserving tandem-queue approximation, a two-branch candidate-equivariant policy first acquires planning knowledge through two rounds of data aggregation and distillation. Complete environment trajectories and short-horizon counterfactual scores under common random numbers then support PPO fine-tuning. Counterfactual scores are distinguished from actual trajectory rewards, and the mixed update is not interpreted as standard on-policy GRPO. Evaluation considers a policy without online Engine lookahead and a neural-guided Top-6 MPC in which the learned prior affects both candidate selection and scoring.

Confirmation comprises 816 paired evaluation episodes across three fixed parent lineages, eight new workloads, and two action streams. Joint fine-tuning achieves 48.74% DSR, improving over cold-start training (44.25%) by 4.49 percentage points and over its distilled student initialization (48.04%) by 0.70 percentage points (interval corrected across 31 comparisons: [+0.39, +0.98] percentage points). Controlled ablation of the counterfactual auxiliary term shows that pure warm-start PPO-GAE without counterfactual rollouts reaches 48.05% (+3.80 percentage points over cold start), while short-horizon counterfactual assistance contributes the remaining +0.69 percentage points. Within warm-start fine-tuning, overall DSR differences against truly decomposed fine-tuning (48.41%) and expectation-ablated fine-tuning (48.63%) are +0.33 and +0.11 percentage points (with 95% CIs crossing zero), accompanied by descriptive improvements of +0.89 and +0.57 percentage points in conditional completion rate among admitted tasks (reaching 93.83%). Fine-tuned Top-6 MPC achieves 49.31% DSR, exceeding the specified online planner (48.56%) by 0.75 percentage points (corrected interval: [+0.25, +1.42]). Mean decision times are 0.520 and 0.722 seconds, compared with 1.602 seconds for the planner, although tail latencies still exceed one second. Because the single-slot batch protocol and the multi-slot dynamic-queue protocol use distinct execution semantics, their absolute results cannot be pooled across chapters. These findings provide bounded evidence connecting demand visibility, batch contention, and dynamic-queue control, and a basis for studying reporting costs and decision delays.

KEY WORDS: UAV swarm, cooperative trajectory planning, task offloading, dynamic queues, reinforcement learning

目　录

第 1 章　绪论 1
1.1　研究背景与意义 1
1.2　国内外研究现状 4
1.3　关键研究问题与技术路线 9
1.4　研究内容与主要贡献 10
1.5　论文组织结构 11
1.6　本章小结 12
第 2 章　相关技术与理论基础 13
2.1　无人机集群任务规划与协同服务基础 13
2.2　无人机辅助移动边缘计算基础 16
2.3　马尔可夫决策过程与长期目标 20
2.4　策略梯度与 Actor–Critic 推导 22
2.5　时序差分与广义优势估计 25
2.6　近端策略优化与动作概率一致性 27
2.7　多智能体协作与 MAPPO 29
2.8　注意力聚合与图表示 31
2.9　批量字典序重评估与跨时隙串联排队建模基础 34
2.10　随机实验与证据解释基础 36
2.11　本章小结 37
第 3 章　自然覆盖约束下无人机集群的需求感知协同轨迹决策 38
3.1　研究动机与评价口径 38
3.2　系统几何、动作应用与单时隙时序 40
3.3　请求、通信、缓存与计算模型 44
3.4　上层 Dec-POMDP 与注意力策略实现 49
3.5　预接纳需求观测设计 54
3.6　瓶颈诊断、独立确认与机制解释 56
3.7　本章小结 61
第 4 章　考虑跨机资源竞争的截止期优先计算任务分配 63
4.1　固定快照问题与受控比较范围 63

4.2 全批次执行、缓存与计算外部性 64
4.3 严格字典序目标与共同基线 67
4.4 MC-ITR 搜索过程与可证性质 69
4.5 Exact-Small 与反事实评价协议 73
4.6 实验设计、主结果与代价解释 75
4.7 敏感性、精确检查与搜索完成情况 78
4.8 候选学习轨迹桥接与本章小结 82

第 5 章 动态排队服务中的规划蒸馏与反事实辅助协同控制 84
5.1 研究问题与协议边界 84
5.2 动态服务系统与候选动作建模 85
5.3 规划知识蒸馏与候选级联合策略 88
5.4 环境交互与反事实辅助 PPO 微调 91
5.5 零在线前瞻与神经引导 Top-6 MPC 94
5.6 实验设置与确认结果 95
5.7 讨论与本章小结 104

第 6 章 总结与展望 105
6.1 研究总结 105
6.2 综合认识与适用范围 107
6.3 后续研究方向 107
6.4 本章小结 108

参考文献 109

致谢 113

在读期间取得的科研成果 114

插图目录

图 2.1 终端、边缘与中心服务之间的通用层次关系示意 16
图 2.2 UAV 作为覆盖节点、中继与移动边缘服务器的应用关系示意 18
图 2.3 强化学习中的状态、动作、奖励与环境转移关系 20

图 3.1 系统总体布局与自然覆盖接纳示意。三角形为 UAV，实线圆为 100 m 服务覆盖范围，虚线圆为其中一架 UAV 的 460 m 感知范围；绿色圆点为被覆盖 UE，红色叉为未被覆盖 UE，其请求本时隙不被接纳。图中位置为示意性布局，非真实轨迹快照 41
图 3.2 覆盖半径与感知半径的几何关系 42
图 3.3 单时隙内的请求执行与轨迹应用时序。两层动作由当前观测计算；请求按移动前几何执行，上层轨迹动作随后应用并影响下一时隙覆盖 ... 44
图 3.4 上层 Attention-MAPPO 的网络与训练结构。实线为前向信息流，虚线为仅训练时使用的集中式评价与参数更新；执行阶段每架 UAV 仅用自身局部观测 52
图 3.5 原观测与扩展观测的槽位填充规则对照（同一几何示意）。原观测仅含已覆盖 UE，扩展观测以距离顺序补入感知范围内尚未接纳的 UE；图为规则示意，非注意力权重或真实记录 55
图 3.6 主场景实际生成服务请求的结果构成（下层无注意力强基线，瓶颈诊断批次，25 个评估单元的计数汇总） 57
图 3.7 独立确认实验的训练曲线（10 个训练种子的均值 ± 标准差）：(a) 训练 DSR；(b) 平均训练奖励 59
图 3.8 独立确认实验中候选相对强基线的逐训练种子 DSR 差值（每个种子为 5 个工作负载差值的平均；区间为配对 t 95% 区间） 60
图 3.9 确认实验中接纳率与接纳后按时完成率的配对比较（每点为一个训练种子下五个配对工作负载的均值）。两因子反向变化，DSR 增益来自接纳因子 60

图 4.1 批量算力共享与迁移外部影响的机制示例（构造参数：$F_u = 60\,\mathrm{GHz}$，$L_m = 2 \times 10^6$ 字节，$\omega_m = 2000$ 周期/字节，$D_m = 0.25\,\mathrm{s}$；数值按式 (4.5) 计算，非实验测量） 66

图 4.2　MC-ITR 算法流程。两个出口对应不同结论强度：无改善退出时可验证单请求迁移邻域局部最优；预算退出时不作此声称 …… 70
图 4.3　固定快照主配置下四种卸载方法的超时数、平均归一化时延与搜索耗时（柱为十个工作负载种子均值，散点为逐种子值） …… 76
图 4.4　各方法相对 Iterative-Base 的每快照超时数配对差值（十个工作负载种子；区间为 5000 次重抽样的 95% bootstrap 区间）。散点、均值虚线与阴影区间描述该固定快照批次中的工作负载配对差异 …… 77
图 4.5　UE 数量变化下四种方法的超时数与平均归一化时延（误差线为十个工作负载种子的逐项 95% t 区间，非同时覆盖） …… 78
图 4.6　UAV 算力倍率变化下四种方法的超时数与平均归一化时延（误差线口径同图 4.5） …… 79
图 4.7　Exact-Small 配置的快照构成与各方法逐分量均值。(a) 600 个快照的构成；(b)-(c) 三 UE 小规模下 MC-ITR 与穷举精确解逐快照目标完全一致，Greedy 与 Iterative 超时数相同而平均归一化时延高 3.33×10^{-5}（四位小数舍入后同为 0.0608），Heuristic-Control 存在明显差距 …… 81
图 4.8　第三章扩展观测候选轨迹的快照桥接（400 个快照；反事实不回写）。该候选不是第五章的动态排队联合策略，快照来源与计时口径亦不同于本章主实验 …… 83

图 5.1　动态排队协议的期望到达率与排空阶段。阴影标出 50–100 s 高峰窗口；200 s 后停止生成请求，并继续结算未完成队列。曲线表示预设期望强度，不是观测流量拟合 …… 86
图 5.2　训练方案的验证 DSR 曲线。各点来自三个父谱系的验证汇总，轮次 0 为各方案自身初值；验证工作负载与确认集独立。曲线比较整体流程，不是匹配初始化与辅助计算预算后的单因素试验 …… 97
图 5.3　全部十七个评估臂的确认集 DSR。彩色或深色菱形为池化计数比率，灰色圆、方、三角分别为三个固定父谱系的比率。灰点展示谱系间差异，不是独立重训的置信区间；每臂为 48 个配对评估回合 …… 99
图 5.4　主比较及两项补充比较的全程 DSR 配对差。前八行为原主检验族，末两行用于限定在线替代与 MPC 内部增量。线段统一为 31 项 DSR 比较的 Bonferroni 区间，蓝色表示区间完全高于零；区间条件于三个固定父谱系 …… 101

图 5.5　主要控制方式的请求结局与阶段差异。（a）按生成请求池化的三类结局，未接纳请求同样计入分母；（b）按到达时刻区分高峰与非高峰请求的 DSR，任务结算包含后续排空。六种方法用于说明服务构成，完整十七臂结果见表 5.4；本图为描述性结果，不作新的多重检验声明　102
图 5.6　七种主要控制方式的决策耗时。（a）本轮评估记录的均值与 p95；（b）超过 1 秒的决策比例。数据来自完整调用路径，非隔离硬件时延基准。较低均值不能消除超时风险，且仿真未把墙钟等待加入任务期限演化　103

附表目录

表 2.1　全文两套互补实验协议的设计逻辑与语义对照 35

表 3.1　主场景仿真参数 48
表 3.2　上层单智能体观测构成（原观测；扩展观测见第 3.5 节） 49
表 3.3　上层 MAPPO 主要超参数 53
表 3.4　覆盖观测两阶段实验协议 58
表 3.5　独立确认实验的主场景结果（10 个新训练种子 × 5 个新工作负载） 59

表 4.1　自身改善与系统超时变化的构造例（非实验数据） 67
表 4.2　四种卸载方法的差异 69
表 4.3　单请求局部最优不蕴含全局最优的离散构造 72
表 4.4　固定快照主配置的卸载方法比较（十个工作负载种子均值） 76
表 4.5　各变体配置中 MC-ITR 相对 Iterative-Base 的每快照超时数差值 79

表 5.1　第三、四章与本章的协议和证据边界 85
表 5.2　候选级双分支联合策略与价值网络的特征张量构成 88
表 5.3　冷启动与蒸馏暖启动微调的冻结训练参数 93
表 5.4　动态排队确认集的全部十七个评估臂 98
表 5.5　关键比较的全程 DSR 配对差与置信区间 98
表 5.6　蒸馏热启动微调中反事实辅助项的受控消融对比（相同蒸馏起点与 48 个盲测确认回合，每臂 252,024 个生成请求） 100
表 5.7　主要控制方式的平均耗时、尾延迟与前瞻计数 103

符号说明

$\mathcal{U}$, N	无人机（UAV）集合与数量（主配置 $N = 5$）
M	地面用户设备（UE）总数量（主配置 $M = 100$；第四章敏感性含 $60 \sim 140$ 及 3）
H, τ, T	UAV 固定飞行高度（100 m）、时隙长度（1 s）与回合步数（第三章 $T = 1000$；第五章到达窗口 200 s）
$\mathbf{q}_u(t)$, $\mathbf{w}_m(t)$	UAV u 与地面 UE m 在时隙 t 的二维水平坐标（m）
$\mathbf{p}_u(t)$, $\mathbf{p}_m(t)$	UAV u 与地面 UE m 在时隙 t 的三维空间坐标（m）
$v_{\max}$, $d_{\min}$	UAV 最大水平飞行速度（15 m/s）与机间最小水平安全间距（200 m）
R_c, R_s	UAV 自然覆盖服务半径（100 m）与需求/邻机感知半径（460 m）
G, A, S	评估单元内实际生成、自然覆盖接纳、在截止期前完成的服务请求计数
DSR, α, η	端到端截止期满足率（S/G）、自然接纳率（A/G）与接纳后条件完成率（S/A）
J, $c_m(t)$	Jain 公平性指数与 UE m 的累计历史达标服务覆盖频率
$g_{ij}(t)$, R, σ^2	三维无线链路功率增益、可达传输速率（bit/s）与加性白高斯噪声功率（10^{-13} W）
P^{comm}, $G_0 g_0$	无线发射功率（0.5 W）与单位距离自由空间信道参考增益常数（3.244132×10^{-4}）
B^{edge}, B^{inter}, B^{bh}	边缘接入带宽（40 MHz）、机间协作带宽（20 MHz）与回传带宽（0.75 MHz）
β	服务与内容流行度 Zipf 分布偏斜指数（$\beta = 0.8$）
F_u, F_{M}	UAV u（$[75, 60, 70, 85, 50]$ GHz）与宏基站

	（200 GHz）的计算频率容量
S_u^{cache}, B_s	UAV u 的机载缓存容量（$[158, 171, 148, 134, 162]$ MB）与文件 s 的字节大小
L_m, C_m, ω_s	服务请求 m 的输入数据字节数、所需总 CPU 周期数与每字节周期密度（$C_m = \omega_s L_m$）
T_m, D_m	请求 m 的端到端完成时延与截止时间预算（Deadline）
U_m, $I_{m,u,v}$, $V_{j,s}$	接入上传时间、机间协作输入转发时间与缓存未命中时的服务程序回源下载时间
$h_{j,s}(t)$, $\widehat{h}_{v,s}$	节点 j 对文件 s 的二值真实缓存命中指示与基于容量的邻机缓存命中概率信念
$\mathcal{M}(t)$, $\mathcal{J}$	时隙 t 自然接纳的服务请求集合与执行节点集合
b_m, a_m, C_m	请求 m 的目标执行节点分配变量与硬可行候选节点集合
$N_j(\mathbf{b})$, $f_{m,j}$	单时隙协议中分配至 UAV j 的最终批量请求数与等份共享计算频率 $F_j/N_j(\mathbf{b})$
$o_{u,t}$, $\mathbf{o}_t$	第三章上层单 UAV 定长局部观测（295 维，含 4 邻机槽与 30 用户槽）与五机联合观测
$\mathbf{o}_u^{\text{offload}}$, $\mathbf{o}_u^{\text{low}}$, $\mathbf{r}_{u,m}$	第三章下层单 UAV 卸载观测（1405 维）、五维来源特征与百槽十四维请求特征
π_θ, V_ϕ, V_ψ	参数化策略网络（Actor）与集中式状态价值网络（Critic）
r_u, r_t^{low}	第三章上层含违例惩罚的个体轨迹奖励与下层含自适应违例乘子的团队卸载奖励
λ_{dsr}, λ_{mbs}	第三章下层针对条件完成率目标与 MBS 负载上限的自适应惩罚乘子
γ, λ_{GAE}, ε	强化学习折扣因子、广义优势估计（GAE）平滑系数与 PPO 裁剪系数
$\mathbf{Q}_u^h$, $\mathbf{K}_i^h$, $\mathbf{V}_i^h$, d_h	多头交叉注意力第 h 头的查询、键、值向量与

	单头维度（$d_h = 8$）
$F(\mathbf{a}) = (F_1(\mathbf{a}), F_2(\mathbf{a}))$	第四章 MC-ITR 的严格二元字典序目标（超时请求总数 F_1 与平均归一化时延 F_2）
$\mathcal{N}_1(\mathbf{a})$, $R_{\max}$	第四章单请求迁移邻域集合与局部搜索最大迭代轮数预算
$\mathcal{K}(s)$, $\mathcal{M}(s)$	第五章动态排队协议下的候选分配方案集合（$K = 4$）与候选五机联合位移集合（$M = 6$）
k_{safe}, $R_{\text{rescue}}(s, m)$	第五章保守回退安全分配方案与待接纳紧急需求的空间救援评分
$\tilde{r}_{n,j}$, $\tilde{C}_j(\tau)$	第五章释放时间串联排队近似中的任务 CPU 释放时刻与节点 j 的就绪任务集合
$\widehat{C}(s, k, m)$, $\widehat{O}(s, k, m)$	释放时间串联排队近似输出的预计可按时完成量与预计排队溢出量
$\mathbf{c}(s)$, $\mathbf{a}_k$, $\mathbf{m}_{km}$, $\mathbf{x}_V(s)$	第五章公共上下文（14 维）、分配特征（14 维）、运动特征（16 维）与价值网络输入（34 维）
$\boldsymbol{\phi}_{km}$, $\mathbf{C}_{\text{upper}}(s, k)$	第五章运动核心交互四维特征向量与上层运动分支加权的期望反馈向量
$q_T(k, m \mid s)$, $Q_{\text{cf}}(s, k, m)$	第五章三步规划教师软目标分布与共同随机数（CRN）三步反事实分支评分
$\boldsymbol{\Phi}_{\text{pre}}(s_t)$, $\boldsymbol{\Phi}_{\text{post}}(s_t^+)$	第五章动作前/后基于释放时间近似的任务完成与负载越界状态势函数
$\tilde{p}(k, m)$, $J(s, k, m)$	第五章神经引导 Top-6 MPC 的熵校准提议先验与三步克隆前瞻综合评分

第 1 章　绪论

1.1　研究背景与意义

1.1.1　无人机集群协同任务规划与空地服务需求

无人机集群通过多个空中平台的机动与分工，共同完成单个平台难以独立承担的区域任务。集群能力既取决于每架飞行器的运动和载荷能力，也取决于成员如何选择服务位置、交换任务并使用有限资源。Chung 等的航空集群综述将轨迹生成、任务分配和分布式感知等列为相关研究内容，并指出空中平台的运动特性为协同设计带来额外要求[1]。因此，面向航空航天任务的集群协同可以从任务规划层展开：在给定平台和运动约束下，研究多机应部署到哪些位置、如何形成任务分工，以及这种分工能否改善集体任务完成效果。

应急场景中的临时空地服务为上述问题提供了应用动机。当地面设备分散移动、任务需求发生变化时，搭载通信与计算载荷的无人机可以将服务能力带到需求附近。多个平台需要分担空间部署和计算处理任务，避免仅由个别平台接纳大量请求而其他平台资源无法被使用。本文据此研究动态地面请求驱动的集群计算服务；仿真中明确建模的是用户移动、请求生成、通信、缓存与计算过程，并未设置灾情演化、搜救目标发现或巡检航线等特定任务流程。应用动机用于说明服务需求，实验结论则依据实际采用的请求与环境模型。

本文中的无人机（Unmanned Aerial Vehicle，UAV）同时承担移动接入节点和计算执行节点的角色，地面用户设备（User Equipment，UE）产生具有截止时间的请求，宏基站（Macro Base Station，MBS）提供另一条执行路径。移动边缘计算（Mobile Edge Computing，MEC）将计算和存储能力部署到接近数据产生位置的网络边缘，为这种计算任务载荷提供了技术基础[2]。请求需要经历接入、数据传输、程序获取和计算等环节，空中平台的位置则决定部分请求能否进入这一流程。由此，MEC 对应集群所承担的服务任务，而集群协同轨迹规划与计算任务分配对应本文的主要决策问题。

空地服务能力具有明确的空间依赖性。固定服务器的算力即使充足，也需要用户连接到可用接入点；无人机的机动性使接入节点的位置可以成为决策变量。UAV 辅助通信研究讨论了覆盖、部署、轨迹与能量之间的联系[3-4]。在本文的计算服务场景中，空间错配具有两种表现：用户距离服务 UAV 过远，请求不能被接纳；请求虽然进入覆盖，却集中到少数执行节点并竞争计算和缓存资源。前者需要集群改变未来的空间部署，后者需要调整当前批次的任务分工。只报告已接

纳请求的平均时延，容易遗漏未接纳需求，难以解释集群整体服务效果。

集群空间部署同时影响跨机资源协作。某架 UAV 接纳较多请求后，可以将部分计算任务交给其他具有可用能力的 UAV；若协作链路较弱或必要程序未缓存，迁移又会增加传输和获取时延。MBS 能够补充执行能力，其使用比例也影响对空中集群独立服务能力的解释。任务目的地还会改变当前节点负载和缓存状态，进而影响后续观测与动作。因此，本文把多机位置、任务接纳和执行负载视为相互联系的任务规划变量，通过长期交互仿真评价整体效果，并用固定状态实验识别分配环节的质量余量。

本文的集群协同限定在任务规划层。仿真采用固定高度下的二维运动、单步位移限制和位置修复，Actor 根据各 UAV 允许的观测输出机动方向，下层调度器集中处理当前请求批次。邻机状态进入上层决策，任务也能够在机间迁移，由此形成空间部署与计算分工两类协作。研究未包含姿态控制、编队参考队形、六自由度动力学或实际飞行试验；轨迹规划效果应在所用简化运动与信息条件下解释。这样的层次划分使研究问题与现有实现对应，也为后续衔接航空器执行控制提供明确接口。

1.1.2 自然覆盖条件下的服务评价问题

本文关注具有明确物理服务半径的自然覆盖接纳系统。只有在当前时隙位于某架 UAV 覆盖范围内的服务请求，才能被接纳并进入卸载决策。服务半径以外的请求不会因为某个卸载动作选择了 MBS 或协作 UAV 而自动被处理。这一定义使覆盖成为任务执行的前提：卸载策略能够重新分配已接纳请求，但不能替代缺失的 UE-UAV 接入链路。若仿真把所有未覆盖请求强制关联到某架 UAV，再计算卸载成功率，就改变了原有物理接纳条件，所得指标不能直接解释自然覆盖系统的服务能力。

为同时评价覆盖与处理质量，本文以全部实际生成服务请求中的按时完成比例定义端到端截止期满足率（Deadline Satisfaction Rate，DSR）。设一个评估单元内实际生成、自然接纳和在截止时间前完成的请求总数分别为 G、A 和 S，在 $G > 0$ 且 $A > 0$ 时有

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A} = \text{接纳率} \times \text{接纳后按时完成率}. \tag{1.1}$$

这一计数恒等式把端到端质量分为两个环节。轨迹与需求观测主要影响请求是否进入覆盖；卸载与资源竞争主要影响已接纳请求能否及时完成。不过，两环节在闭环系统中仍会互相影响，式 (1.1) 是统计分解，而不是两个独立组件收益可以直接相加的因果公式。

覆盖扩展可能带来新的服务压力。轨迹策略看到更多未覆盖需求后，能够主动移动并提高接纳比例；如果随后接纳的请求计算量更高，或者集中到原本已经繁忙的执行节点，接纳后的完成比例可能下降。此时，判断方法是否有效需要观察 S/G 的最终变化，不能只看覆盖率上升，也不能因为接纳后质量下降便忽略端到端成功数增加。反过来，如果卸载策略仅处理较少但容易的请求，接纳后成功率可能很高，端到端服务率却未必理想。本文把这两种情况放在统一的请求计数框架内解释。

DSR 的分母还需要与环境行为一致。在本文的统一外生随机流标准仿真中，每个 UE 的请求生成完全由按工作负载种子分配的独立外生随机流驱动。预先配对外生随机流，能够保证候选与基线方法在相同工作负载下具有严格一致的实际生成服务请求序列和分母 G。本文以实际生成服务请求作为预定主指标，既避免事后更换主评价目标，也保证配对比较直接反映按时完成请求数的差异。

1.1.3　集群空间部署与计算任务分工的研究意义

从集群任务规划角度看，轨迹决策改变未来的服务条件，计算任务分配利用当前已经形成的服务条件。UAV 接近某些 UE 可以提高接纳机会，但同时可能远离其他需求区域或协作节点；任务转移到算力较高的 UAV 可以降低计算时延，却可能增加传输时延和程序获取开销。这类取舍要求策略考虑多个平台和多个请求之间的关系，使空间机动服务于集体任务目标。UAV 位置或轨迹与资源分配的联合优化研究也体现了这一联系[5-6]。本文进一步以任务是否被接纳、是否按时完成解释轨迹规划与跨机分工各自发挥作用的环节。

从航空平台资源使用角度看，多机数量增加并不意味着服务能力可以线性增长。机间几何条件影响任务传输，缓存差异影响程序可用性，计算共享决定各请求的执行速度，机动又受到速度、边界和最小安全间距约束。因而，集群评价应同时观察服务成功、系统时延、分工方式和对地面 MBS 的依赖。本文将这些指标并列报告，避免仅以更多任务转移到地面执行解释全部集群收益。

从算法角度看，问题同时包含连续轨迹动作、离散请求目的地和时序状态变化。随着请求数增加，所有请求目的地组合形成的动作空间迅速扩大；与此同时，一个节点的最终负载又会影响被分配到该节点的全部请求。若使用单一网络同时输出轨迹与完整分配，训练可能面临动作尺度不同、回报来源混合和组合可行性处理困难。分层决策能够把位置控制与分配求解的作用分开描述，但分层本身不保证两层能够形成最优协同，也不意味着上下层都需要相同的网络结构。

从研究方法角度看，UAV-MEC 算法的性能评价应区分长期闭环结果与固定

状态下的求解能力。固定快照实验能够控制位置、请求和历史状态，直接观察某个分配求解器的质量；闭环实验则把分配对缓存、后续观测和轨迹的影响保留下来。前者便于分析批量外部影响和局部搜索性质，后者回答整套方法是否提高长期服务表现。本文同时使用这两种证据，但保持其统计单位与结论边界，避免把固定快照的成功数改善当作长期 DSR 增益。

1.2 国内外研究现状

1.2.1 集群协同覆盖与需求驱动的空间规划

无人机集群规划需要把整体任务目标转化为各平台的空间行动与资源分工。航空集群研究同时涉及轨迹生成、任务分配和协同信息使用，各层之间需要符合平台与任务条件[1]。在无人机辅助边缘计算场景中，空间位置部署与轨迹规划直接决定了地面用户的接入信道条件与服务覆盖范围[7-8]。对于本文的空地计算服务，整体目标是动态请求的按时完成，空间行动则影响请求能否进入物理覆盖。因而，轨迹规划既要关注用户位置，也要关注请求的时间要求和服务负载；停留在用户密集区域不必然对应最高的截止期成功比例。

覆盖指标应与所承担的任务对应。本文关心一个服务请求在产生时是否处于可用 UAV 的服务范围内，以及接纳后能否按时完成。单次位置布局下的几何覆盖面积，或 UAV 轨迹访问过的区域面积，可以描述空间活动，却不能直接代替这种请求级指标。若用户和请求随时间变化，即使两条轨迹经过相近位置，也可能接纳不同的任务集合。因此，本文把自然覆盖接纳写入环境转移，并以实际请求计数连接空间规划和任务执行。

协同覆盖还取决于策略允许使用的信息。UAV 只观察已关联用户时，未覆盖需求难以直接进入其动作依据；引入感知范围内的待接纳需求后，集群可以据此调整未来位置。但扩大观测不是扩大物理服务半径，其上报及时性和获取成本也属于另外的信息条件。本文第三章研究的是在既定信息假设下，需求可见性如何影响协同机动与接纳效果；它保留对实际部署信息来源和同信息架构对照的独立检查要求。

机间几何约束与协同规划效果也应区分。在本文采用的几何中，100 m 服务半径与 200 m 最小机间距使满足该距离条件的覆盖圆内部不重叠。因此，不能将覆盖重叠减少归因于策略学习。可检验的规划收益是需求与服务位置是否更匹配、接纳机会如何变化，以及接纳后负载是否能够得到合理处理。这一问题定义把空间部署、需求观测和服务完成连接起来，而不预设形成固定编队或全时通信

连通性的要求。

1.2.2　协同计算任务分配与模型驱动资源优化

任务分配需要明确被分配的对象、执行主体和评价目标。Skaltsis 等综述了 UAV 任务分配中的多类方法，重点比较计算复杂度、最优性和可扩展性，并讨论通信方式与不确定性的影响[9]。这些维度为本文提供了评价框架：质量更好的分配需要与求解开销一起报告，集中处理所需的信息不能被省略，少量 UAV 上的结果也不能自动外推到大规模集群。本文的任务对象是已经自然接纳的不可拆分计算请求，执行主体为五架 UAV 与一个 MBS；“计算任务分配”具体对应请求执行位置选择，而不是搜索目标或航路点的指派。

模型驱动方法首先把通信速率、计算时延、能量或覆盖条件写成目标与约束，再根据变量结构采用交替优化、连续近似、离散搜索或博弈求解。其优点是能够明确给出信息条件和约束含义，并在满足特定假设时分析子问题性质。UAV 辅助通信综述指出，部署与轨迹会同时影响覆盖、链路质量和飞行成本[3-4]；在 MEC 场景中，还需要加入执行节点的计算和缓存条件。因此，模型是否准确描述了业务竞争，往往与求解器本身同样重要。

连续优化适合功率、带宽、频率或位置等变量，但任务目的地与缓存选择通常具有离散性质。围绕多无人机辅助 MEC 的时延最小化、能耗控制与轨迹资源联合分配，已有工作广泛采用块坐标下降、连续凸近似与交替优化框架求解耦合子问题[10-15]。研究者常在固定部分变量时处理另一部分，再循环更新。该做法可以降低每个子问题的求解难度，也便于用约束表达服务要求；其代价是整体问题的非凸性和离散耦合仍可能保留。对一个子问题获得精确解，并不意味着整套联合问题获得全局最优解。对于在线场景，还必须衡量重新求解的时间是否与请求截止期和决策时隙相匹配。

博弈方法则强调不同参与者的利益与响应。Yuan、Xie 和 Tan 的研究把基站、UAV 和用户的计算资源交互表述为多层 Stackelberg 博弈，并通过各层效用和响应选择卸载策略[16]。曾耀平等在 UAV 部署与卸载联合问题中，将 UAV 与 UE 的交互表述为领导者和追随者结构，结合联盟形成与势博弈分析[17]。这些方法说明分层结构可以来自参与者之间的决策顺序与利益关系。本文的上下层则是同一协作系统中的轨迹与请求分配模块，其共享服务目标，不能因为同样存在“两层”便直接继承上述博弈的均衡结论。

缓存与卸载的联合设计进一步说明，仅按链路和算力选择节点可能不足。王义君等研究微云、边缘和本地组成的多层结构，通过协同缓存自适应的分层多元

宇宙优化算法处理卸载、资源配置及动态时延–能耗权衡[18]。该工作的服务缓存与节点选择设计，为本文考虑程序获取代价提供了相关背景；其细粒度部分卸载假设与本文不可拆分请求不同，数值结果不能直接移植。李侍阳和朱晓荣针对无人机巡检中的感知与 AI 任务，将多维资源优化拆分为若干子问题并交替求解[19]，表明服务目标与任务结构改变时，合适的优化变量和分解方式也会改变。

对于本文，模型驱动方法最直接的启示是显式检查分配外部影响。若 UAV 以最终批量请求数均分算力，迁移一个请求会改变迁入与迁出节点上其他请求的计算频率和完成时间。只计算被迁移请求自身时延的局部规则，可能忽略多个请求同时跨越截止期的变化。第四章因此以整个分配的目标重评估为基础研究 MC-ITR，而不是假定逐请求代价可以无条件相加。该求解器用于明确质量余量和计算代价，不承担本文第五章的实时学习式下层。

1.2.3 动态机动与资源决策中的深度强化学习

深度强化学习（Deep Reinforcement Learning，DRL）把神经网络表示与交互式决策结合，用参数化策略或值函数近似复杂状态下的长期行为。DQN 的研究说明深度网络能够从高维输入中学习动作价值[20]；策略梯度和 Actor–Critic 方法则直接优化动作分布，为连续控制提供了基本工具[21-22]。这些经典算法为 UAV 位置、资源配置和任务调度提供了可采用的优化方式，但算法在一般基准上的有效性不是 UAV-MEC 特定服务协议下的性能证明。

将资源管理表述为强化学习问题，需要同时确定状态、动作、奖励和环境转移。当前链路速率、节点位置与负载提供即时决策依据；缓存和移动状态又使当前动作影响后续回报。在这种情况下，网络前向决策可以在训练之后提供较快的动作生成，而较高的交互采样与训练计算被转移到离线阶段。比较学习式与在线搜索方法时，既应报告在线推理时间，也应说明训练数据与离线教师的额外开销，不能把离线优化计算忽略后宣称总体计算成本完全等同。

连续控制和离散选择需要不同的动作表示。轨迹控制可以由 Gaussian 等连续分布生成方向或位移；请求执行位置可以由分类分布生成离散选择。近年来，深度强化学习与多智能体强化学习已被广泛引入无人机辅助边缘计算的动态卸载与轨迹控制中[23-27]。对大批量请求逐项独立采样虽然容易实现，却未必捕捉最终负载之间的耦合。一种处理办法是在单时隙框架下将连续轨迹控制与离散请求分配分层组织，并在固定快照下通过整批重评估显式刻画跨机负载外部性（第四章 MC-ITR）；另一种是在跨时隙持续排队协议下构造候选等变的分配–运动双分支联合策略 $\pi_\theta(k, m \mid s) = p_a(k \mid s)\, p_m(m \mid s, k)$，由分配分支对结构化候选

卸载方案打分，再由运动分支在所选方案条件与运动期望反馈下选择协同位移（第五章）。学习模块和规划模块的作用必须分别评价。

Li 等针对多 UAV 辅助 MEC 中的不完整信道信息与任务复杂度估计误差，联合考虑轨迹、任务划分和通信计算资源，提出使用 Beta 分布的多智能体 PPO 框架[28]。这项研究的中心问题是通信与计算不确定性下的鲁棒设计，并不是本文自然覆盖接纳分母或不可拆分批量请求问题。其 Beta 分布处理有界动作的思路，也不能等价于本文先保存 Gaussian 原始提案、再由环境执行裁剪的实现。明确这种动作概率与执行动作的差别，有助于避免把一篇相关论文的设计直接当成本项目已实现的机制。

Tao 等研究 UAV 辅助 MEC 中在线服务选择、任务卸载、计算频率、轨迹和悬停安排的联合决策[29]。其中服务程序选择体现了缓存与业务处理之间的联系，在线决策依据当前请求和资源状态进行。本文同样关注程序可用性与请求时序，但使用多 UAV 的自然接纳规则，并以截止期成功比例评价整个服务流程。不同文献使用能效、加权能量、平均时延或服务质量等目标，各自在对应定义下成立；不能仅因均称“联合优化”就把排名拼成一条普遍结论。

学习式方法还受到观测设计限制。网络只能根据实际输入产生策略，注意力或更深的模型不能从没有提供的请求特征中恢复真实需求。如果上层只看到已经关联的用户，它的轨迹控制就可能缺少覆盖外需求的直接信号。扩展观测能够改变决策信息，但也改变方法的信息条件。因此，本文先研究需求可见性与端到端服务的联系，再通过同信息替代结构和冻结策略对照检查组件贡献。观察到整套方法优势之后，仍需要区分“看到了不同信息”与“在相同信息上用了更好的网络”。

1.2.4　多智能体协作与集中训练分散执行

多智能体强化学习（Multi-Agent Reinforcement Learning，MARL）考虑多个决策主体的交互。当 UAV 共同服务一个区域时，一架 UAV 的位置变化可以改变邻机的覆盖边界与可用协作链路；某节点接纳或转入的请求又会占用共享资源。从单个智能体看，其他策略的变化使经验数据的生成过程不断变化；从整体看，联合状态和联合动作仍可以在适当假设下构成马尔可夫决策过程。因而，多智能体学习的困难在于协作、部分可观测和训练非平稳性，不能简单表述成“多智能体系统不具备马尔可夫性”。

集中式训练分散式执行（Centralized Training with Decentralized Execution，CTDE）在训练阶段使用更完整的信息估计价值或构造梯度，而在执行阶段让每

个 Actor 根据其允许的局部观测选择动作。MADDPG 采用集中 Critic 处理多智能体动作相关性[30]；MAPPO 将 PPO 的策略更新方式用于协作多智能体任务，并系统研究了其在基准环境中的表现[31]。这些方法提供了利用训练阶段信息改善估计的路径，但 CTDE 不是执行阶段获取全局信息的许可证，也不自动解决信用分配。

对于同类型 UAV，策略参数共享可以减少重复参数，并让不同 UAV 的经验共同更新一套网络。共享参数与动作相同是两回事：各 UAV 输入的位置、缓存、邻居和用户不同，产生的动作分布也不同。价值网络可以对联合观测建模，并为每个 UAV 输出一个价值估计；这与把所有智能体直接压缩成一个统一标量 Critic 的实现不同。本文上层采用共享 Actor 与联合观测 Critic，第二章据此给出与代码相容的 MAPPO 描述，而不把一种教科书式结构预设为唯一实现。

除 Actor–Critic 方法外，值分解通过约束联合价值的组合形式支持分散选择。VDN 与 QMIX 分别使用加性分解和单调混合等结构[32-33]。这些结构有助于从团队价值中学习个体决策，但也带来特定表达约束和动作类型要求。本文轨迹采用连续方向动作，卸载又包含批量组合结构，因此选择 MAPPO 作为上层学习基础，并通过独立求解模块处理下层分配。该选择来自问题结构与已有实现，不意味着其他 MARL 路线已经在相同协议下被排除。

Hady 等关于资源分配优化的 MARL 综述讨论了多智能体学习在网络资源问题中的方法分类与应用条件[34]。综合这类研究，可以从三个层面审视协作方法：策略执行需要什么信息，训练阶段使用了什么额外信息，评价是否把共享数据或工作负载误当独立重复。本文使用训练块作为学习方法统计重复，以配对工作负载减少环境差异，并在主性能、机制检验与快照诊断之间保持清楚的比较对象。

1.2.5 注意力聚合与结构化优化的作用

注意力机制通过查询与键之间的相似度生成权重，并对值向量加权聚合。Transformer 的缩放点积与多头结构为这一表示方式提供了经典形式[35]，近期多智能体强化学习与空地边缘计算研究也进一步利用注意力机制或状态过滤聚合动态邻机与任务特征[36-38]。在多 UAV 场景中，自身状态可以作为查询，邻居 UAV 与 UE 槽位作为被聚合元素，使输出随位置、需求和邻居关系变化。这样能够显式表达元素之间的相对关系，也便于对空槽位使用掩码。但注意力仍依赖输入特征、训练信号与模型容量，其结构能力不能直接写成 DSR 必然提高的定理。

注意力和信息预算应分别讨论。若一个 Actor 得到未覆盖 UE 的请求和位置，

而另一个 Actor 只能看到已关联 UE，则两者比较同时包含输入信息差异。即便前者使用注意力，观察到的优势也不足以证明优势完全来自注意力架构。相反，同信息条件下注意力与 MLP 的差值区间跨零，也只能说明这次实验没有确认结构增益，不能证明所有场景中注意力无效。本文第三章以覆盖观测为研究中心，保留同信息对照的证据边界。

对于卸载与持续排队控制，结构化重评估与候选级联合建模提供了与逐请求独立采样互补的思路。在单时隙批量算力均分协议中，已接纳请求与执行节点之间的每次单请求重分配都会改变迁出与迁入节点上同批其余任务的共享算力分母，因此第四章通过候选迁移下的全批次二元字典序重评估精确刻画跨机负载外部性。在跨时隙持续排队协议中，第五章进一步构造基于释放时间工作守恒串联排队近似的多策略候选池，并通过候选等变的双分支网络与 4×6 交互矩阵 $\mathbf{C}_{\mathrm{upper}}[k,m]$ 对候选分配方案 k 与候选联合运动 m 进行联合建模。局部重评估或候选池近似的可求解性不等于原整体问题全局最优。

持续到达使结构化分配进一步面对跨时隙排队：本次动作会改变残留工作和后续服务位置，快照内较好的方案不一定形成较好的闭环策略。策略蒸馏可以把较昂贵策略的偏好转移到学生[39]，数据聚合则关注学生运行后诱导的状态分布[40]。本文第五章据此在独立动态排队协议中研究规划知识蒸馏、环境交互与反事实辅助 PPO，以及不同在线前瞻预算。完整方案收益与具体组件净作用分别检验，不把标准 PPO、蒸馏或数据聚合本身作为本文原创。

1.3　关键研究问题与技术路线

本文的中心问题是：当地面计算需求随空间和时间变化、单机覆盖与资源有限时，无人机集群如何通过协同轨迹与任务分工，使更多请求在截止前完成？这一问题分为三个层次。首先，需求可见性能否帮助轨迹形成服务机会；其次，给定快照中跨机批量资源竞争是否留下可利用的分配余量；最后，当传输和计算进度跨时隙保留时，如何把规划知识转化为较快的联合策略，并由环境交互继续改善。三项问题分别由第三、第四和第五章回答，共享生成、接纳与成功计数语义，但不预设相同的单时隙或跨时隙执行协议。

技术路线先区分模型与统计语义。第三、四章沿用含缓存与最终批量共享算力的单时隙执行环境，先检验预接纳需求观测，再用 MC-ITR 分析最终批量共享算力下的快照分配。第五章另建动态排队协议，在固定 UE 几何、不可变来源与目标和 EDF 计算下保留服务进度，采用规划蒸馏与反事实辅助 PPO 研究持续控制。MC-ITR 不作为第五章在线模块或教师，不同协议的绝对指标不直接拼接。

在算法设计上，第三章采用共享 Attention-MAPPO Actor 与联合观测 Critic，第四章采用集中快照搜索。第五章则构建集中候选级分配与运动双分支策略，通过方案条件化及运动期望反馈表达决策关联，先蒸馏已有三步规划器，再用完整真实轨迹及预测到达下的反事实辅助评分更新。其测试方式包括零在线 Engine 前瞻和神经引导 Top-6 MPC。这里的联合策略采用候选级分配与运动双分支结构，不是直接复用第三章的上下层分离网络。

在评价设计上，第三章的训练种子确认、第四章的固定快照配对与第五章的固定父谱系工作负载推断分别报告。第五章使用三个固定父谱系、八个新工作负载和两个动作流，共 816 个配对确认回合，区间不包含上游模型重新训练的不确定性。真实轨迹奖励、反事实分支评分和 MPC 目标分别定义，完整微调方案、耦合开关和同框架学习先验的比较也分别解释。计算开销同时报告均值与尾延迟，不把在线前瞻计数为零等同于零计算成本。

1.4 研究内容与主要贡献

本文围绕五架 UAV、一百个 UE 和一个 MBS 的计算服务系统，形成三项相互联系但证据协议分别明确的研究内容与贡献。

1. **自然覆盖约束下的需求感知集群空间规划**。建立实际生成、自然接纳和截止期成功的统一计数口径，明确接纳率与接纳后质量共同决定端到端 DSR。在物理服务半径不变的条件下，将感知范围内未覆盖需求纳入上层预动作观测，结合邻机与 UE 的注意力聚合研究协同轨迹决策，并使用探索与独立确认两阶段实验支持对应结论。这一内容将空间部署的效果具体落实到请求接纳与完成，说明需求可见性对集群服务规划的作用，同时保留观测信息条件与注意力结构贡献的区别。
2. **考虑跨机资源竞争的截止期优先计算任务分配**。在给定位置、请求和历史状态下，以超时数和平均归一化时延的严格二元字典序目标研究 MC-ITR。每次候选迁移重新评价整个批次，明确任务迁入和迁出如何通过最终批量算力共享改变其他请求的完成时间。通过主配置、敏感性、小规模一致性检查以及共享轨迹快照桥接，量化跨机分配的质量余量与完整计算代价。这一内容把机载资源竞争作为集群任务分工的核心约束，并为在线方法设计提供诊断依据。
3. **规划知识蒸馏与反事实辅助的动态排队联合控制**。在独立动态排队协议中，以候选级双分支策略连接卸载方案与机群运动，通过两轮数据聚合蒸馏规划知识，并利用完整环境轨迹与共同随机数下的短视界反事实评分辅

助 PPO 微调。真实轨迹奖励与辅助评分分开建模，测试采用零在线 Engine 前瞻策略或学习先验参与筛选及评分的 Top-6 MPC。在 48 个盲测确认回合（每方案 252,024 个生成任务）上，两轮规划蒸馏学生（48.04%）相对无协调启发式（44.30%）提升 3.74 个百分点；受控反事实消融表明，从同一蒸馏起点（48.04%）出发，纯在策略 PPO-GAE 微调（cf = 0）DSR 为 48.05%（相对从头强化学习 44.25% 提升 3.80 个百分点，但相对蒸馏起点仅 +0.01 个百分点），而引入共同随机数短视界反事实组辅助项（cf = 1.25）后联合微调策略 DSR 达 48.74%（相对 cf = 0 提升 0.69 个百分点，相对蒸馏学生提升 0.70 个百分点，全 31 项比较 Bonferroni 校正区间 [+0.39, +0.98]）；结合神经引导 Top-6 MPC 后 DSR 达 49.31%，相对摊销规划基线提高 0.75 个百分点且单步平均耗时降低 38.6%。在同样启用反事实辅助的微调组内部，联合微调相对解耦微调（+0.33 个百分点）与去期望反馈变体（+0.11 个百分点）的全集 DSR 区间跨零，同时伴随已接纳任务条件完成率 +0.89 与 +0.57 个百分点的描述性改善。当前证据支持规划蒸馏热启动、反事实辅助微调与神经引导 MPC 完整流水线的服务与计算效率优势，同时如实界定热启动微调内部架构耦合的统计边界。

这些贡献共同形成从集群空间部署、跨机批量分配到在线闭环表现的论证链。本文没有将不同接纳协议、不同训练阶段或不同源码版本的绝对指标直接合并，也没有以单个最佳种子代表平均效果。现有结果支持特定仿真与信息条件下的集群服务方法优势，不能单独证明注意力架构优于所有替代结构，或者证明真实通信部署中的收益。任务层协同效果也不等同于编队稳定性或飞行动力学可行性。这些层次与边界使方法可以被复现、比较和继续改进，而不影响对已证实收益的清楚呈现。

1.5　论文组织结构

第一章从无人机集群协同任务规划与临时空地服务需求出发，综合协同覆盖、计算任务分配与学习决策的相关研究，提出空间部署和机载负载耦合下的研究问题、技术路线及三项贡献。

第二章说明集群任务规划的层次、简化运动与机间协作关系，介绍 UAV-MEC 的通信、计算、缓存与评价基础，推导马尔可夫决策过程、值函数、策略梯度、带终止处理的广义优势估计和 PPO 裁剪目标，进而说明 MAPPO、注意力聚合、批量字典序重评估与跨时隙串联排队候选建模的基本原理，并对照全文两套互补实验协议的设计边界，为后续算法建立统一符号和理论基础。

第三章研究自然覆盖约束下无人机集群的需求感知协同轨迹决策，建立动态请求、几何运动约束与上层观测模型，通过服务失败分解、训练动态与独立确认分析需求可见性对集群接纳和端到端服务的影响。

第四章研究考虑跨机资源竞争的截止期优先计算任务分配，在固定轨迹快照中给出 MC-ITR 的批量外部影响、严格二元字典序目标、搜索流程和有限终止性质，并报告不同负载、算力与共享快照上的质量、归一化时延和求解开销。

第五章研究动态排队服务中的规划蒸馏与反事实辅助协同控制，明确其与第三、四章的执行协议边界，依次给出候选级联合策略、规划教师与两轮数据聚合、完整轨迹 PPO 和反事实辅助评分，以及零在线前瞻与神经引导 Top-6 MPC。采用固定父谱系下的新负载确认，报告服务质量、消融边界、平均计算成本与尾延迟。

第六章总结需求感知轨迹、快照任务分配和动态排队控制的主要发现，区分已验证收益与未分离机制，讨论信息获取、模型误差、决策等待和真实飞行执行等后续研究。

1.6 本章小结

本章将无人机集群协同规划具体化为两个连续的服务环节：集群通过空间机动形成自然覆盖接纳机会，再通过计算任务分工与资源使用按时完成请求。相关工作说明协同轨迹、任务分配与学习决策具有多种可行建模方式，也提示规划结构、信息条件与实测性能应分别论证。本文据此采用需求观测研究、固定快照诊断和完整方法确认相结合的技术路线，后续章节在明确各自执行协议的前提下，逐步说明方法设计、公式推导和实验证据。

第 2 章　相关技术与理论基础

本章为无人机集群协同轨迹规划与计算任务分配建立共同的系统概念与数学基础。首先从集群任务规划的层次关系出发，说明简化机动约束、空间部署和机载资源分工如何连接，再介绍 UAV-MEC 中通信、计算、缓存和自然接纳的联系。随后从有限时域马尔可夫决策过程推导值函数与策略梯度，给出带终止处理的广义优势估计和近端策略优化，并介绍多智能体协作、MAPPO、注意力聚合，以及批量字典序重评估、跨时隙串联排队近似与候选级双分支联合策略基础，最后对照全文两套互补实验协议的设计边界。通用理论说明算法形式及成立条件；本文的网络结构、超参数和性能结论分别由后续章节的实现与实验证据确定。

2.1　无人机集群任务规划与协同服务基础

2.1.1　任务分工、轨迹规划与飞行执行的层次关系

无人机集群通过多个空中平台共同承担任务，研究内容包括任务分配、轨迹规划、信息交互和飞行控制等相互联系的环节[1]。任务分配确定哪些平台承担哪些工作，轨迹规划确定平台如何到达或保持有利位置，飞行执行将规划指令转化为实际运动。各层面对的时间尺度、状态信息和可行性条件不同：任务分配需要理解任务价值及资源需求，轨迹规划需要处理空间关系和机动限制，飞行执行还需要满足飞行器动力学与控制约束。区分这些层次有助于准确界定算法解决的航空集群问题。

本文聚焦任务层与规划层之间的协同。空中平台通过改变服务位置接纳地面计算请求，再通过机载计算、跨 UAV 协作和 MBS 支持完成请求。任务具有输入数据量、服务类别、截止时间和执行资源需求；其分配是在已接纳请求与执行节点之间建立对应关系。无人机任务分配文献包含多种任务类型和约束[9]，本文采用其中明确的计算服务任务，未把地面请求改写为需要无人机实体到访的侦察目标或运输订单。因此，服务覆盖承担任务接入功能，执行节点选择承担资源分工功能，两者共同决定集群的时限服务能力。

从规划对象看，第三章研究多机如何依据需求选择下一时隙的空间部署，第四章研究给定空间部署下如何调整任务执行分工，第五章连接这两个决策过程并检验闭环服务表现。这里的“集群协同”体现为多个 UAV 的位置与资源决策服务于共同的请求完成目标。任务层的协同无需预设固定编队形状；本文没有为 UAV 指定领航者、队形参考或编队稳定性目标，后续分析也不以保持特定队

形作为性能指标。

2.1.2 二维机动模型与离散空间可行性

本节先介绍第三、四章的原协议。为了把注意力集中在任务需求与空间部署之间的联系，该协议采用固定高度下的二维运动描述。UAV u 的水平位置为 $\mathbf{q}_u(t) \in \mathbb{R}^2$，高度保持 $H = 100\,\mathrm{m}$；时隙长度为 $\Delta t = 1\,\mathrm{s}$，最大运动速度为 $v_{\max} = 15\,\mathrm{m/s}$。在 $700 \times 700\,\mathrm{m}^2$ 场地中，环境保留 50 m 的边界距离，因而离散水平位置范围为 $\mathcal{Q} = [50\,\mathrm{m}, 650\,\mathrm{m}]^2$。五架 UAV 的位置更新满足

$$\mathbf{q}_u(t+1) = \mathbf{q}_u(t) + \boldsymbol{\delta}_u(t), \qquad \|\boldsymbol{\delta}_u(t)\|_2 \leqslant v_{\max}\Delta t = 15\,\mathrm{m}, \qquad \mathbf{q}_u(t+1) \in \mathcal{Q}. \quad (2.1)$$

$\boldsymbol{\delta}_u(t)$ 的单位为 m，表示修复后的实际位移。它与网络输出的无量纲动作提案不同；时隙平均速度模长是 $\|\boldsymbol{\delta}_u(t)\|_2/\Delta t$。这一量纲关系使轨迹长度、单步机动与覆盖转移结算可以使用同一实际位移。

环境另要求离散位置之间满足最小水平间距 $d_{\min} = 200\,\mathrm{m}$。以联合位置集合表示，可行区域为

$$\mathcal{Q}_{\mathrm{joint}} = \left\{(\mathbf{q}_1, \cdots, \mathbf{q}_N) : \mathbf{q}_u \in \mathcal{Q},\ \|\mathbf{q}_u - \mathbf{q}_v\|_2 \geqslant d_{\min},\ \forall u \neq v\right\}. \quad (2.2)$$

各机独立输出提案并不保证联合位置属于该集合。实际执行先限制提案位移并裁剪边界，再有限次调整冲突位置，同时重新检查运动预算；若仍有间距冲突，则把相应 UAV 回退至原位置，并继续传播回退直至得到可行离散状态。由此产生的悬停属于执行映射的一部分，需要保留在轨迹记录中。实现对最终离散状态采用 $10^{-3}\,\mathrm{m}$ 数值容差。该过程是对离散位置的环境可行性修复，不是对非凸可行集求最近点的精确投影，也不构成连续飞行轨迹上的避碰或稳定性证明。

模型没有显式描述加速度、转弯半径、姿态和风场。式 (2.1) 所能支持的是具有位移预算的空间部署决策，而非满足完整飞行动力学的控制器。保持高度并限制步长，可以简化需求变化与机动选择的关系；若面向真实飞行执行，还需把规划位移交给满足具体飞行器约束的轨迹生成与跟踪模块，并重新评估执行误差对覆盖和截止期服务的影响。

2.1.3 服务覆盖、邻机关系与空间资源耦合

服务覆盖与需求观测具有不同作用。本文的物理服务半径为 $R_{\mathrm{cov}} = 100\,\mathrm{m}$，请求只有进入 UAV 的服务范围才被自然接纳；允许的感知范围为 $R_{\mathrm{sense}} = 460\,\mathrm{m}$，使轨迹策略可以使用服务范围之外的部分需求信息。邻机关系也按该感知距离筛选，由

$$\mathcal{N}_u(t) = \{v \neq u : \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2 \leqslant R_{\mathrm{sense}}\} \quad (2.3)$$

形成随位置变化的邻居集合。各 UAV 高度相同，因此 UAV 间三维距离等于水平距离。式 (2.3) 定义模型允许进入观测的邻机关系，不包含消息排队、丢包或链路连通性保证；这些信息如何在实际系统中获取仍取决于通信协议。

最小机间距满足 $d_{\min} = 2R_{\mathrm{cov}}$，使不同 UAV 的圆形覆盖内部在规定离散状态下不重叠。因此，本文轨迹优化的重点是把有限服务区域部署到有需求的位置，而不是通过学习消除本已受几何约束限制的覆盖重叠。某架 UAV 移动会改变其后续可接纳需求、与其他 UAV 的协作距离以及相应传输代价；其他 UAV 的移动也会改变整个机群的空间服务配置。评价时必须保留未覆盖请求，才能衡量这类空间协同是否转化为任务接纳改善。

空间部署的收益还取决于执行资源。服务位置更接近高需求区域，可能接纳更多请求，同时让接纳节点的共享算力承担更大批量。跨 UAV 转移能够重新分担计算负载，却需要额外传输，并可能因目标节点缺少服务文件而增加准备时间。于是，集群规划面对的是位置、任务集合和资源分工的时序耦合：机动改变可服务请求集合，任务分配改变节点负载与缓存状态，后续状态再影响下一次机动决策。本文用“接纳率 × 接纳后按时完成率”解释这一服务链条，具体计数与推导在第三章展开。

2.1.4　分散式轨迹决策与集中任务调度

第三、四章的原分层系统采用上层分散式 Actor 与下层集中批量调度相结合的组织形式。上层每架 UAV 根据自身、允许邻机和允许用户特征产生动作提案，训练时联合观测 Critic 为各机提供价值估计。共享 Actor 参数使多架 UAV 使用同一决策规则，但不同观测仍可形成不同机动提案。这里的局部观测是仿真按信息合同提供的输入，不能把“Actor 分散执行”自动解释为信息无需上报或获取成本为零。

第四章的 MC-ITR 需要汇总当前请求与执行节点资源，评价完整分配。第五章另采用集中候选级联合策略，根据公开队列状态选择卸载方案和五机运动，与第三章多个 UAV 的分散 Actor 主体不同。因此本文没有实现所有环节完全分布式自治。各章采用集中协调或局部观测的具体范围，需要分别说明，不能用第三章 CTDE 直接描述第五章的执行方式。

第三、四章中，请求接纳和当前执行使用已有位置，随后应用机动动作形成后续位置。第五章采用独立动态排队协议，先加入到达并完成自然接纳，再选择新请求分配及联合运动，在一个宏步的线性路径上推进传输与计算。后者允许服务进度跨步保留，并在全路径上检查几何可行性，其具体状态转移边界在第五章

定义，不能沿用原批量共享算力模型解释。

2.2 无人机辅助移动边缘计算基础

2.2.1 网络层次与请求执行位置

移动边缘计算把部分计算与存储能力部署在接近用户的位置，形成终端、边缘节点与中心服务之间的协作[2,41-43]。请求的完成过程包含数据进入、必要程序准备、计算执行和结果返回。改变计算位置可以减少某些处理环节的时间，也可能增加无线传输或回传成本。因此，“边缘更近”与“请求更快完成”不是同义关系，需要把完整路径上的代价写入评价。图 2.1 给出通用层次关系；本文进一步用移动 UAV 作为可接纳请求的空中边缘节点。

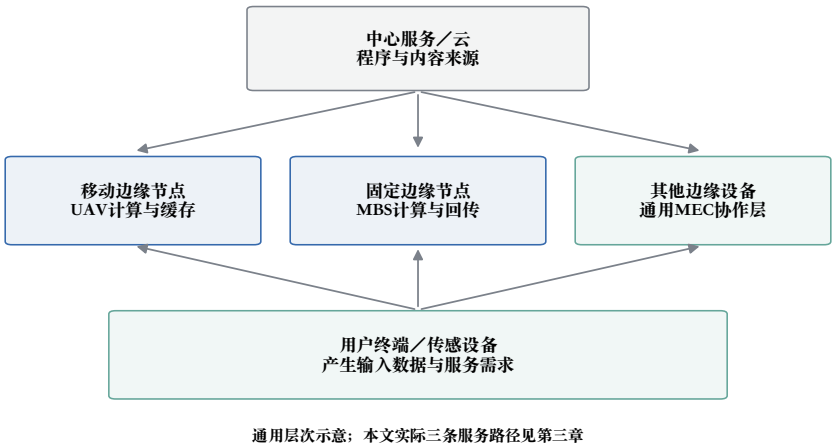


图 2.1 终端、边缘与中心服务之间的通用层次关系示意

Figure 2.1 Schematic of the general three-tier relationship among terminal devices, edge nodes, and central cloud services

本研究中的“本地执行”具有明确含义。通用 MEC 文献中的本地常指 UE 在自身处理器上计算，本文请求被 UAV 自然接纳之后，下层动作中的本地指接纳 *UAV* 本地计算。另两个类别是转移给协作 UAV 和卸载到 MBS。三类执行位置共享同一接纳前提，不能把选择 MBS 解释为 UE 无需进入 UAV 覆盖范围便直接得到服务。后续卸载比较均以已接纳请求为输入，而端到端 DSR 仍保留未接纳请求在分母中的影响。

设一个时隙的接纳服务请求集合为 $\mathcal{M}_t$，执行节点集合为 $\mathcal{J}$。请求 m 的输入字节数为 L_m，所需 CPU 总周期为 C_m，截止时间为 D_m，服务类别为 $s(m)$。若服务类型决定每字节所需周期数 ω_m，则

$$C_m = \omega_m L_m. \tag{2.4}$$

L_m 与 C_m 描述不同负担：较大的输入数据主要增加传输，较大的计算周期主要

增加处理时间；二者的比例不同，最合适的执行节点也可能不同。本文任务不可拆分，每个请求最终选择一个执行节点；部分卸载模型允许数据切分或并行子任务，属于另一种协议，不能与本文直接混用。

2.2.2　位置相关的无线通信与量纲转换

UAV 的水平位置记为 $\mathbf{q}_u(t)$，地面 UE 的水平位置记为 $\mathbf{w}_m(t)$。在 UAV 高度为 H_u 的几何模型下，UE 与 UAV 的三维距离为

$$d_{mu}(t) = \sqrt{\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2^2 + H_u^2}. \tag{2.5}$$

距离变化会影响信道功率增益，进而影响数据进入与任务转移的时延。UAV 辅助通信可以采用不同的传播模型[4]；在本文设定的固定飞行高度 $H_u = 100\,\mathrm{m}$ 与自然覆盖半径 $R_c = 100\,\mathrm{m}$ 下，已接纳地面用户与服务 UAV 之间的仰角满足 $\theta_{\mathrm{elev}} = \arctan(H_u/d_{\mathrm{2D}}) \geqslant 45^\circ$。在开阔或郊区应急场景的高仰角空对地链路中，视距（Line-of-Sight，LoS）分量占主导地位，因此本文后续仿真采用确定性自由空间路径损耗基准，以便受控剥离空间部署、需求观测与跨机计算竞争的作用，避免随机小尺度衰落与阴影遮挡混淆算法决策差异；地形遮挡、概率非视距衰落与实测信道波动不自动包含在该基准模型中。

在一个理想噪声受限链路中，带宽为 B、发送功率为 P、信道功率增益为 g、接收噪声功率为 σ^2 时，常用速率表达为

$$R = B \log_2 \left(1 + \frac{Pg}{\sigma^2}\right). \tag{2.6}$$

这里 B 的单位为 Hz，R 的单位为 bit/s。若输入数据以 byte 记录，数据传输时间必须使用

$$T_m^{\mathrm{tx}} = \frac{8L_m}{R}. \tag{2.7}$$

因子 8 来自一个字节包含八个比特。遗漏该转换会把传输时间缩小八倍，从而同时改变截止期判断和卸载偏好。本文所有请求大小与链路速率均按此量纲关系处理；程序下载的字节数同样需要转换。

式 (2.6) 是瞬时链路模型。若多个请求共享带宽，必须由具体调度规则给出每个请求使用的有效速率；若传输包含多个顺序环节，则总时间是各段时间之和，而不是只取最强链路的速率。协作卸载可能同时包含 UE 到接纳 UAV 的接入、UAV 间传输和计算结果返回。MBS 卸载还可能包含回传。后续章节以环境实际执行路径为准计算总时延，不能以一个简化链路公式替代未计入的处理环节。

移动带来的局部通信改善与全局空间配置也需要共同考虑。UAV 更接近某

一热点可能提高接入速率和接纳比例，但移动同时改变其覆盖范围以及与其他节点的协作距离。一个位置对当前请求有利，不一定对后续请求或协作链路有利。轨迹控制因此具有跨时隙性质，而不仅是逐时隙寻找最短通信距离。图 2.2 用通用示意说明 UAV 的通信角色；本文具体关注其中移动边缘服务和多节点协作的部分。

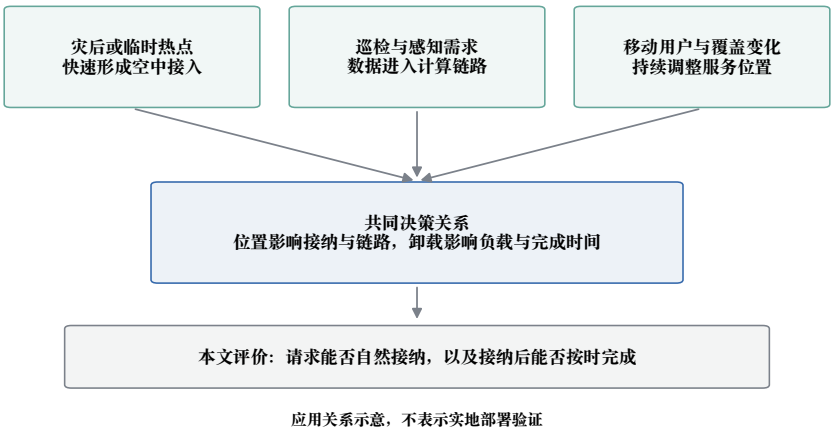


图 2.2　UAV 作为覆盖节点、中继与移动边缘服务器的应用关系示意

Figure 2.2　Schematic of UAV applications as coverage nodes, relays, and mobile edge servers

2.2.3　批量计算共享与缓存代价

计算节点的处理能力记为 F_j，单位为 CPU 周期每秒。对于分给节点 j 的最终批量请求数 N_j，若该节点采用等份共享，则每个请求分配的计算频率为 $f_{mj} = F_j/N_j$。请求 m 在节点 j 的计算时间为

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{f_{mj}} = \frac{C_m N_j}{F_j}, \qquad N_j \geqslant 1. \tag{2.8}$$

该式仅用于实际分配到节点的请求，不对 $N_j = 0$ 的空节点进行除法。本文 UAV 使用最终批量共享语义；MBS 的计算能力按环境协议处理，并不套用 UAV 的 F_j/N_j 规则。不同类型节点的差别需要在成本模型中显式保留。

设一个请求从 UAV i 迁往 UAV j。迁移不仅改变该请求的链路和处理时间，还把 N_i 减一、N_j 加一，因此改变两个节点上其他请求的 f_{mi} 或 f_{mj}。若这些请求接近截止时间，单次迁移可能使多个请求同时成功或失败。于是，整个分配的代价一般不能表示为一组与其他分配无关的固定单请求代价。这一批量外部影响是第四章整体重评估的动机；第五章改用 EDF 持续队列后，需要按其就绪顺序和剩余工作重新描述资源竞争。

缓存引入另一项执行条件。设服务程序 s 的字节数为 B_s，节点 j 对该程序的缓存指示为 $z_{js} \in \{0,1\}$。当 $z_{js} = 0$ 时，执行请求可能需要获取程序，典型顺

序下载时间为 $8B_s/R_j^{\mathrm{fetch}}$。如果程序已缓存，则相应获取环节可以减少。缓存容量约束可以一般地表示为

$$\sum_s z_{js} B_s \leqslant K_j, \tag{2.9}$$

其中 K_j 是节点存储容量。该式描述通用容量限制；后续实际缓存替换与提交规则以仿真实现为准。当前请求使用的缓存状态与本时隙末更新后的状态不能混淆，否则相当于提前使用未来信息。

2.2.4　覆盖、接纳与端到端指标

在水平服务半径 R_c 的模型下，请求所在 UE 满足 $\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2 \leqslant R_c$，才可能由 UAV u 接纳。感知半径 R_s 则决定策略允许获得哪些需求信息，两者承担不同作用。扩大 R_s 可以改变观测，不能自动把 R_c 之外的请求纳入执行。本文使用 $R_c = 100\,\mathrm{m}$ 与 $R_s = 460\,\mathrm{m}$，后续观测实验保持物理接纳半径不变。

设评估单元的成功数为 S、接纳数为 A、实际生成数为 G。当分母非零时，DSR、接纳率与条件完成率分别为 S/G、A/G 和 S/A。聚合多个时隙时，应先合并相应计数，再计算这些比值。例如，$\sum_t S_t / \sum_t G_t$ 一般不等于 $\frac{1}{T}\sum_t S_t/G_t$，因为后者给予每个时隙相同权重，前者给予每个请求相同权重。按训练块合并请求后再跨块平均，也与直接把全部块请求混为一个比值不同。本文根据预定协议使用对应聚合方式，并在图表中说明统计单位。

公平性需要说明它评价的是哪一种累计量。对于非负的每 UE 累计服务覆盖量 c_m，Jain 指数为

$$J = \frac{\left(\sum_{m=1}^{M} c_m\right)^2}{M \sum_{m=1}^{M} c_m^2}. \tag{2.10}$$

当所有 c_m 相同且至少一个非零时，$J = 1$；服务集中到少数 UE 时，该值下降。全部为零时公式的分母也为零，需要明确环境的约定，不能自行补出公平性的正面结论。本文公平性反映指定累计覆盖变量的均衡程度，不等于所有 UE 的截止期成功机会完全相同。

时延统计也必须保持归一化口径一致。单请求的完成时延 T_m 与其个体截止期 D_m 的比值 T_m/D_m 反映了相对紧迫程度：比较固定快照求解器时，位置与接纳集合固定，平均归一化时延便于在相同超时数下区分资源调度的时延余量；比较闭环方法时，则需同时报告接纳率、条件按时完成率与全集 DSR，避免将较小接纳子集上的低时延误读为整体服务改善。

2.3 马尔可夫决策过程与长期目标

2.3.1 状态、动作与转移的定义

强化学习通过环境交互优化行为策略，其核心是动作对未来状态与回报的影响[44-46]。在离散时隙 t，智能体获得输入，选择动作 a_t，环境产生奖励 r_t 并转移到下一状态。图 2.3 展示基本交互关系。这里的奖励是训练信号，评价指标则是研究要报告的量；二者可以相关，但一个多项加权奖励的改善不自动证明每一项评价指标均改善。

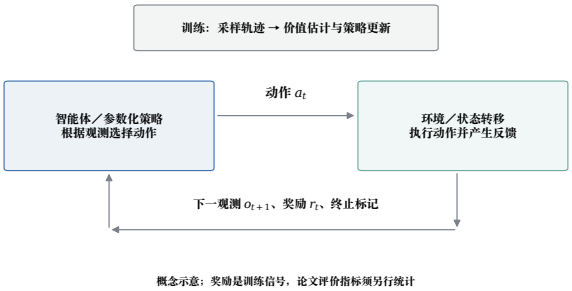


图 2.3 强化学习中的状态、动作、奖励与环境转移关系
Figure 2.3 Interaction framework among state, action, reward, and environment transition in reinforcement learning

一个有限时域 MDP 可记为 $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma, T)$：$\mathcal{S}$ 为状态空间，$\mathcal{A}$ 为动作空间，$P(s' \mid s, a)$ 为转移分布，r 为奖励机制，ρ_0 为初始状态分布，$\gamma \in [0, 1)$ 为折扣因子，T 为时域长度。状态包含预测下一步所需的信息，马尔可夫条件为

$$P(s_{t+1} \mid s_0, a_0, \cdots, s_t, a_t) = P(s_{t+1} \mid s_t, a_t). \tag{2.11}$$

若请求过程显式依赖时隙序号，有限时域状态还可包含时间。该条件属于环境状态层面，并不要求每个 UAV 的局部观测都能恢复完整状态。

策略 $\pi_\theta(a \mid s)$ 给出状态下的动作概率或概率密度，参数为 θ。离散动作满足概率和为一，连续动作密度在动作空间上积分为一。为简化记号，本章写作 $\sum_a$ 的表达在连续情形对应积分。需要动作合法性掩码时，策略的有效支持集随状态改变；只要在相同状态上比较旧、新策略，并正确保存采样时掩码，仍可以按相同支持计算概率比。若修改了动作语义或合法集合，则不能不加检查地复用原有比率。

UAV-MEC 的完整状态可以包括 UAV 与 UE 位置、缓存、当前请求及运行阶段。执行策略通常只获得经过筛选和固定槽位编码的局部观测 $o_{u,t}$。相同观测可能对应不同的完整状态，因此其决策更接近部分可观测问题。使用历史 $h_{u,t} = (o_{u,0}, a_{u,0}, \cdots, o_{u,t})$ 可以提供额外信息；使用有限窗口或循环网络是近似处理方式，不能凭网络输入维度就宣称完全可观测。本文上层以当前预动作观测为输入，其

适用信息合同由第三章明确给出。

2.3.2　折扣回报与值函数

为避免与请求生成计数 G 混淆，本章用 $\mathcal{G}_t$ 表示从时隙 t 开始的折扣回报：

$$\mathcal{G}_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k, \qquad \mathcal{G}_T = 0. \tag{2.12}$$

折扣因子决定未来奖励的相对权重。γ 接近一时，较远未来对当前动作更重要；较小的 γ 更强调近期效果。有限时域目标可在 $\gamma = 1$ 时定义，但后文涉及无限时域有界值与收缩性质时使用 $\gamma < 1$。本文实际超参数属于实验配置，不从数学定义推导其最优数值。

有限时域状态值与动作值分别为

$$V_t^{\pi}(s) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s], \tag{2.13}$$

$$Q_t^{\pi}(s,a) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s, a_t = a]. \tag{2.14}$$

V_t^{π} 对策略实际选择的动作取平均，Q_t^{π} 则固定当前动作后再遵循策略。有限时域下，即使状态相同，剩余时间不同也可以使价值不同，因此保留下标 t。若把时间并入状态，可使用不带显式时间下标的记号。神经网络 Critic 的输出是这些量的估计，不能预先当作真实期望。

从式 (2.12) 分离第一项得到 $\mathcal{G}_t = r_t + \gamma \mathcal{G}_{t+1}$。对下一状态和下一动作依次取条件期望，得到 Bellman 关系

$$Q_t^{\pi}(s,a) = \bar{r}(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{t+1}^{\pi}(s'), \tag{2.15}$$

$$V_t^{\pi}(s) = \sum_{a} \pi(a \mid s) Q_t^{\pi}(s,a), \qquad V_T^{\pi}(s) = 0, \tag{2.16}$$

其中 $\bar{r}(s,a)$ 为给定状态与动作的奖励期望。若奖励同时依赖下一状态，该期望包含对 s' 的积分。Bellman 关系连接当前奖励和未来价值，不要求即时奖励就是最终性能指标，也不意味着可以忽略请求执行后的状态变化。

优势函数定义为

$$A_t^{\pi}(s,a) = Q_t^{\pi}(s,a) - V_t^{\pi}(s). \tag{2.17}$$

它表示相对于当前策略在该状态的平均行为，特定动作的长期回报差异。由 V_t^{π} 的定义可得

$$\sum_{a} \pi(a \mid s) A_t^{\pi}(s,a) = 0. \tag{2.18}$$

正优势动作相对平均更好，负优势动作相对平均更差；“更好”是给定奖励与策略的比较，不能直接翻译成每个物理指标都变好。后续 Actor 更新使用估计优势，需要考虑 Critic 误差和采样波动。

2.3.3 动态规划性质与函数近似的边界

在已知模型的有限时域问题中，最优值可从终端条件向前递推：

$$V_t^*(s) = \max_a \left\{ \bar{r}(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{t+1}^*(s') \right\}. \tag{2.19}$$

该关系要求能够表示和计算状态、动作及转移。当联合动作数量巨大或转移模型复杂时，递推本身并不提供低成本的实际求解途径。深度强化学习通过样本与函数近似处理这些难点，其性质与已知有限表格模型中的精确动态规划不同。

对于有界奖励、平稳策略和无限折扣时域，定义策略 Bellman 算子 $\mathcal{T}^\pi$。任取两个有界函数 V, W，由于概率加权不会放大最大绝对差，有

$$|(\mathcal{T}^\pi V)(s) - (\mathcal{T}^\pi W)(s)| \leqslant \gamma \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s,a) |V(s') - W(s')| \tag{2.20}$$

$$\leqslant \gamma \|V - W\|_\infty, \tag{2.21}$$

从而 $\|\mathcal{T}^\pi V - \mathcal{T}^\pi W\|_\infty \leqslant \gamma \|V - W\|_\infty$。这一收缩性质解释精确策略评价的唯一固定点，但不保证使用神经网络、有限样本与并行策略更新的 MAPPO 必然收敛。论文应把可证明的算子性质与训练曲线描述分开。

实际 Actor–Critic 训练会改变策略，因此 Critic 的目标也随之变化。即使网络在某次更新中更贴近采样目标，也不等于接近全局最优策略。对 UAV-MEC，还存在部分可观测、环境状态编码、奖励尺度和随机需求等因素。本文采用固定预算、最后检查点、独立训练块与配对评估来检验最终行为，不用一条看似平滑的回报曲线替代最终策略验证。

2.4 策略梯度与 Actor–Critic 推导

2.4.1 轨迹概率与似然比求导

策略梯度直接优化参数化动作分布，适用于无法方便枚举全部动作的情形[21]。记一条交互轨迹为 $\xi = (s_0, a_0, r_0, \cdots, s_T)$，策略目标为

$$J(\theta) = \mathbb{E}_{\xi \sim p_\theta} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \tag{2.22}$$

假设初始分布和环境转移不直接依赖 θ，且可交换求导与积分。轨迹概率中与策略相关的部分来自各时隙动作概率，因此

$$p_\theta(\xi) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t \mid s_t) P(s_{t+1}, r_t \mid s_t, a_t), \tag{2.23}$$

$$\nabla_\theta \log p_\theta(\xi) = \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t). \tag{2.24}$$

第二式利用了环境项导数为零的条件。若环境本身也由同一参数控制，需要加入相应导数，不能沿用这里的简单形式。仿真奖励可以是随机量，只要其生成分布属于固定的环境条件即可。

令 $R(\xi) = \sum_t \gamma^t r_t$。使用 $\nabla p_\theta = p_\theta \nabla \log p_\theta$，得到

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\xi) R(\xi) \, \mathrm{d}\xi \tag{2.25}$$

$$= \mathbb{E}_{p_\theta} \left[R(\xi) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]. \tag{2.26}$$

这一表达不需要对环境转移求导。即使动作执行包含离散请求分配、位置裁剪或缓存更新，只要轨迹来自已定义的参数化策略和环境映射，也可以通过采样概率的导数构造估计。神经网络的可微性用于计算策略参数导数，并不要求仿真物理过程本身可微。

2.4.2　因果性与回报到达估计

完整轨迹回报包含动作之前的奖励，但当前动作不可能改变已经发生的事件。为形式化这一点，记动作前历史为 $\mathcal{H}_t$，对于 $k < t$，r_k 在给定 $\mathcal{H}_t$ 后已确定。对当前动作的条件期望满足

$$\mathbb{E}_{a_t \sim \pi_\theta} \left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) \mid \mathcal{H}_t \right] = \sum_a \nabla_\theta \pi_\theta(a \mid s_t) = \nabla_\theta 1 = 0. \tag{2.27}$$

所以式 (2.26) 中每个动作之前的奖励项，其梯度期望为零。删去这些只增加估计波动的项后，有

$$\nabla_\theta J(\theta) = \mathbb{E}_{p_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \sum_{k=t}^{T-1} \gamma^k r_k \right] \tag{2.28}$$

$$= \mathbb{E}_{p_\theta} \left[\sum_{t=0}^{T-1} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) \mathcal{G}_t \right]. \tag{2.29}$$

式中保留 γ^t，因为目标从时隙零开始折扣，而 $\mathcal{G}_t$ 从当前时隙开始折扣。若省略该因子，应说明采用了另一种采样加权或近似目标，不能在同一个有限时域证明中悄然改变定义。

再对固定 s_t, a_t 之后的未来轨迹取期望，可将 G_t 替换为 $Q_t^{\pi_\theta}(s_t, a_t)$：

$$\nabla_\theta J(\theta) = \mathbb{E}_{p_\theta}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) Q_t^{\pi_\theta}(s_t, a_t)\right]. \tag{2.30}$$

这就是有限时域策略梯度的基本形式。对于部分可观测策略，只要把策略条件改为其可用历史或观测，同样可以从轨迹概率推导得分函数估计；动作价值的条件期望也应随之调整，不能把局部观测当作未经验证的完整马尔可夫状态。

该推导给出期望梯度，而实际训练只拥有有限条轨迹。估计的方差可能来自随机请求、初始位置、策略采样和长期状态传播。UAV 轨迹的一个动作可能影响多个未来时隙的接纳条件，直接用整段回报更新会较为嘈杂。Actor–Critic 因此引入价值网络和优势估计，以在可控偏差与方差之间构造更有效的训练信号。

2.4.3 基线不偏性与优势形式

取一个只依赖动作前信息、而不依赖当前采样动作的基线 $b_t(s_t)$。利用式 (2.27)，其对梯度的期望贡献为

$$\mathbb{E}\left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) b_t(s_t) \mid s_t\right] \tag{2.31}$$

$$= b_t(s_t) \sum_a \pi_\theta(a \mid s_t) \nabla_\theta \log \pi_\theta(a \mid s_t) \tag{2.32}$$

$$= b_t(s_t) \nabla_\theta \sum_a \pi_\theta(a \mid s_t) = 0. \tag{2.33}$$

因此，从回报或动作值中减去该基线，不改变理想策略梯度的期望。连续动作使用积分得到相同结论。若基线由神经网络估计，Actor 更新时把它作为固定训练信号处理；不能把对基线参数的导数混入上述似然比证明。动作相关基线则不直接满足该恒等式，除非另有校正项。

选择 $b_t(s) = V_t^\pi(s)$，可以把动作值换成优势：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A_t^\pi(s_t, a_t)\right]. \tag{2.34}$$

这使 Actor 依据相对于状态平均表现的差异学习，减少一些由状态好坏本身造成的波动。价值函数是常用基线，但并不在所有条件下等于方差最小的基线；后者还与梯度向量的尺度有关。因此，本文只使用其不偏性和实用估计作用，不把它描述成普遍最优的方差消除方案。

Critic 用参数 ϕ 近似 V_t^π，训练目标可以来自实际回报或多步自举。若目标记为 $\widehat{V}_t$，基本均方损失为

$$L_V(\phi) = \frac{1}{2}\mathbb{E}\left[(V_\phi(s_t) - \widehat{V}_t)^2\right]. \tag{2.35}$$

Actor 与 Critic 的作用不同：前者优化动作概率，后者拟合用于估计的目标。Critic 损失降低可以意味着拟合更好，但不保证 Actor 的最终 DSR 上升；反过来，价值目标随策略变化时，损失短期升高也不必然代表策略性能恶化。后续训练图须按各自物理含义解释。

2.5　时序差分与广义优势估计

2.5.1　一步时序差分与多步自举

一步时序差分（Temporal Difference，TD）将当前奖励与下一状态价值组成目标。对非终止转移定义

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t). \tag{2.36}$$

如果 V_ϕ 等于真实策略值，给定当前状态和动作的 δ_t 条件期望就是 A_t^π，因为式 (2.15) 的未来期望恰好给出动作值。若 Critic 不准确，TD 目标会包含自举误差；其代价是偏差，优点是无需等待完整回合结束即可获得训练信号。

在不存在中间终止的 n 步窗口内，多步目标与优势估计可以写成

$$\widehat{V}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l r_{t+l} + \gamma^n V_\phi(s_{t+n}), \tag{2.37}$$

$$\widehat{A}_t^{(n)} = \widehat{V}_t^{(n)} - V_\phi(s_t) = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}. \tag{2.38}$$

最后一个等号来自相邻价值项的消去：$\gamma V(s_{t+1})$ 与下一项中的 $-\gamma V(s_{t+1})$ 相抵，依次只留下窗口末端的自举值。n 增大时使用更多真实奖励，通常减少对近端 Critic 的依赖，但也引入更多随机未来变化；这构成多步估计的基本取舍。

真正终止和采样截断不能混为一类。真正终止表示目标任务已经结束，之后没有应计入回报的状态价值；采样截断只表示当前缓冲区或记录窗口到此结束，环境过程可能继续。如果为了收集固定长度 rollout 而截断，却把后续价值强行设为零，会系统性改变窗口末端的估计。另一方面，若一个回合按任务定义在第 T 步结束，则该有限时域终点本身可以是真正终止，不应因为代码称其为 time limit 就机械地自举。

2.5.2　GAE 的加权推导

广义优势估计（Generalized Advantage Estimation，GAE）将多步优势进行指数加权[47]。设当前非终止窗口剩余 K 步，$\lambda_{\mathrm{GAE}} \in [0, 1]$，有限窗口的加权形式

为

$$\widehat{A}_t^{\mathrm{GAE}} = (1-\lambda_{\mathrm{GAE}}) \sum_{n=1}^{K-1} \lambda_{\mathrm{GAE}}^{n-1} \widehat{A}_t^{(n)} + \lambda_{\mathrm{GAE}}^{K-1} \widehat{A}_t^{(K)}. \tag{2.39}$$

最后一项吸收窗口之后的剩余权重，使有限混合的权重和为一。若遗漏这一项，估计在有限窗口中会发生额外缩放。$\lambda_{\mathrm{GAE}} = 0$ 时只保留一步估计，$\lambda_{\mathrm{GAE}} = 1$ 时只保留最长窗口的多步估计，端点按相应极限理解。

将式 (2.38) 代入上述混合，观察 δ_{t+l} 的系数：它出现在所有 $n \geqslant l+1$ 的估计中，因此对应权重为

$$\gamma^l \left[(1-\lambda_{\mathrm{GAE}}) \sum_{n=l+1}^{K-1} \lambda_{\mathrm{GAE}}^{n-1} + \lambda_{\mathrm{GAE}}^{K-1} \right] \tag{2.40}$$

$$= \gamma^l \lambda_{\mathrm{GAE}}^l. \tag{2.41}$$

从而得到常用的残差和形式

$$\widehat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{K-1} (\gamma \lambda_{\mathrm{GAE}})^l \delta_{t+l}. \tag{2.42}$$

这一推导说明 GAE 的两个衰减来源：γ 来自优化目标对未来的折扣，λ_{GAE} 来自估计器对较长残差链的权重。它们不能互相替代，也不是物理请求截止时间的同义参数。

若 $\lambda_{\mathrm{GAE}} = 1$，窗口内残差累加后得到实际折扣奖励加末端自举值，再减当前价值；若窗口在真实终端结束，末端价值为零，便得到回报减基线。若 $\lambda_{\mathrm{GAE}} < 1$，中间价值估计更明显地进入结果，可能降低方差，也可能保留价值近似偏差。因而，GAE 不是无条件消除偏差的技巧，应与 Critic 精度、窗口长度和任务随机性一起理解。

2.5.3 终止掩码与递推实现

为兼容不同边界，定义自举掩码 b_t 与递推连接掩码 c_t。$b_t = 0$ 表示该转移真正终止，否则为一；$c_t = 1$ 表示缓冲区下一条记录属于同一连续轨迹、可以继续累计其优势，否则为零。相应 TD 残差与反向递推为

$$\delta_t = r_t + \gamma b_t V_\phi(s_{t+1}) - V_\phi(s_t), \tag{2.43}$$

$$\widehat{A}_t = \delta_t + \gamma \lambda_{\mathrm{GAE}} c_t \widehat{A}_{t+1}. \tag{2.44}$$

在真实终端，$b_t = c_t = 0$；在仅因采样长度而截断的末端，可以取 $b_t = 1, c_t = 0$，用截断前的实际后继状态估计价值，但不跨到下一批未知记录递推；在正常连续转移中二者均为一。价值自举与优势连接的分工避免了跨回合泄漏。

递推展开为

$$\widehat{A}_t = \sum_{l=0}^{K-1} (\gamma\lambda_{\mathrm{GAE}})^l \left(\prod_{i=0}^{l-1} c_{t+i} \right) \delta_{t+l}, \tag{2.45}$$

空乘积取一。只要某个连接掩码为零，后续残差对当前优势的贡献就停止。实现时通常从缓冲区末端向前扫描，维护一个累计量；真正终止状态的后继值为零，截断状态则应使用结束前真实 observation，而不是 reset 之后的新回合初始 observation。

GAE 计算完成后，可以用 $\widehat{V}_t = V_{\phi_{\mathrm{old}}}(s_t) + \widehat{A}_t$ 形成 Critic 目标。该目标与采样时价值一同固定，避免在多个 PPO epoch 内目标随正在更新的网络任意变化。优势标准化常用于改善优化尺度，但标准化不把随机环境变为确定环境，也不保证减少每一次更新的估计误差。本文使用相应实现与针对性验证确保终止、回报和概率记录一致，不以算法名称替代这些边界检查。

2.6　近端策略优化与动作概率一致性

2.6.1　重要性比率与旧策略采样

策略梯度的期望由当前策略产生，但一次交互采样后，策略更新会使缓冲区来自旧策略 $\pi_{\theta_{\mathrm{old}}}$。对于固定状态 s，若新策略支持集包含于旧策略有效支持集，则

$$\mathbb{E}_{a\sim\pi_\theta}[f(s,a)] = \mathbb{E}_{a\sim\pi_{\theta_{\mathrm{old}}}}\left[\rho_\theta(s,a) f(s,a)\right], \qquad \rho_\theta(s,a) = \frac{\pi_\theta(a \mid s)}{\pi_{\theta_{\mathrm{old}}}(a \mid s)}. \tag{2.46}$$

该恒等式只校正固定状态下动作分布的变化，并未自动校正新策略产生的状态分布。因此，直接在旧 rollout 上使用一次动作比率，是局部代理目标的构造，不是完整新策略回报的无偏估计。若对整条轨迹做完全重要性校正，需要多个时隙比率乘积，通常会产生较大方差。

PPO 使用旧策略状态动作样本与固定优势，构造可重复优化的目标[48]。为了数值稳定，概率比率通常由 log probability 之差计算：

$$\rho_t(\theta) = \exp\left[\log \pi_\theta(a_t \mid s_t) - \log \pi_{\theta_{\mathrm{old}}}(a_t \mid s_t)\right]. \tag{2.47}$$

旧概率必须对应实际采样时的策略参数、观测、动作和掩码，不能在更新过程中用新网络重新计算后冒充旧概率。首次更新之前，旧、新网络相同，合法样本的比率应接近一；这可以作为概率记录一致性的一个诊断，而不是最终性能证据。

2.6.2 裁剪目标及其分段含义

设裁剪系数为 $\varepsilon > 0$，PPO 的裁剪代理目标为

$$L_{\text{clip}}(\theta) = \mathbb{E}_{\text{old}}\left[\min\left(\rho_t(\theta)\widehat{A}_t, \text{clip}(\rho_t(\theta), 1-\varepsilon, 1+\varepsilon)\widehat{A}_t\right)\right]. \tag{2.48}$$

优势在 Actor 更新时视为固定。取最小值的目的，是在动作概率朝有利方向变化过多时移除进一步增加代理收益的激励，而不是把所有比率数值直接投影到指定区间。

对于单个样本，令 $\ell(\rho, \widehat{A})$ 为括号内的量。根据优势符号，有

$$\ell(\rho, \widehat{A}) = \begin{cases} \widehat{A}\min(\rho, 1+\varepsilon), & \widehat{A} \geqslant 0, \\ \widehat{A}\max(\rho, 1-\varepsilon), & \widehat{A} < 0. \end{cases} \tag{2.49}$$

当 $\widehat{A} > 0$ 时，增加动作概率能提高代理收益，但比率超过 $1+\varepsilon$ 后这一项进入平台；当 $\widehat{A} < 0$ 时，降低动作概率有利，但比率低于 $1-\varepsilon$ 后平台阻止该项继续受益。若变化方向使样本表现更差，目标仍保留惩罚。这是裁剪和最小操作必须共同出现的原因。

PPO 裁剪不能保证所有动作的概率比率始终位于区间内。共享网络的一次更新会同时改变许多未被采样动作的概率，也会受到其他样本和熵项的梯度影响。即使某个样本项进入平台，该动作仍可能因其他梯度变化。因而，裁剪目标不是严格的 KL 散度约束，也不提供无条件单调性能提升。实际实现还可监测近似 KL、裁剪比例和梯度范数，以发现更新过大或数值异常，但监测本身不等于理论约束被满足。

策略熵可以作为探索项。离散分布的熵为

$$\mathcal{H}(\pi) = -\sum_{a \in \mathcal{A}(s)} \pi(a \mid s)\log\pi(a \mid s). \tag{2.50}$$

常用 Actor 目标为最大化 $L_{\text{clip}} + c_H\mathbb{E}[\mathcal{H}]$，其中 $c_H \geqslant 0$。Critic 则最小化均方或相应裁剪值损失。熵项鼓励动作分布保持一定分散度，但更高熵不意味着物理随机策略更好；训练中的探索与评价时的动作使用规则需要分别说明。

2.6.3 连续提案、执行映射与离散掩码

对于二维轨迹，Actor 可输出均值 $\boldsymbol{\mu}_\theta(o)$ 与标准差 $\boldsymbol{\sigma}_\theta(o)$，从对角 Gaussian 分布采样原始动作 a。其 log probability 为

$$\log\pi_\theta(a \mid o) = -\frac{1}{2}\sum_{d=1}^{2}\left[\frac{(a_d - \mu_d)^2}{\sigma_d^2} + 2\log\sigma_d + \log(2\pi)\right]. \tag{2.51}$$

如果环境把原始动作裁剪、缩放或进行边界与碰撞消解，实际执行动作是 $a^{\text{exec}} = \mathcal{E}(s, a)$。该映射可以多对一，并不保持 Gaussian 密度。策略梯度仍可针对原始提

案策略定义，把执行映射视为环境的一部分；前提是 PPO 保存并比较同一个原始 a 的采样概率。

将裁剪后的 a^{exec} 重新代入原始 Gaussian 密度，并把它当作原始动作概率，会改变采样对象。特别是多个超出边界的提案被映射到同一边界值时，执行动作分布不再是原 Gaussian。本文后续算法描述以原始提案和原始 log probability 为准，执行可行性由环境映射处理。这种记录方法确保概率比率的含义一致，但不说明策略网络本身满足所有几何约束。

对于离散卸载或候选级方案选择，设网络 logits 为 z_a，状态对应的合法动作掩码为 $M_a \in \{0,1\}$，则掩码后的分布为

$$\pi_\theta(a \mid s, \boldsymbol{M}) = \frac{M_a \exp(z_a)}{\sum_b M_b \exp(z_b)}. \tag{2.52}$$

实现需要保证至少存在一个合法动作，例如协议允许的保底动作或停止动作，否则分母为零。非法动作概率为零，合法动作之间重新归一化。训练使用采样时的 $\boldsymbol{M}$，不能在一个已改变负载的状态上重建掩码后拿来比较原动作概率。

动作掩码屏蔽物理或协议不可行选择，而候选可行性检查、最好方案保留或普通修复是另外的操作。它们可以改变最终执行分配，却不应事后改写策略曾采样的离散动作或其概率。对于任何包含候选池或搜索模块的策略，应区分策略提案、候选评价和最终执行动作。第五章进一步区分真实采样轨迹与反事实辅助条目，不因二者都使用裁剪形式就赋予它们相同的抽样解释。

2.7　多智能体协作与 MAPPO

2.7.1　联合状态与局部观测

协作多智能体问题可以用马尔可夫博弈或分散式部分可观测马尔可夫决策过程描述[49-50]。设智能体集合为 $\mathcal{U} = \{1, \cdots, N\}$，联合状态为 s_t，局部观测由 $o_{u,t} = \mathcal{O}_u(s_t)$ 或对应观测分布生成，联合动作为 $\boldsymbol{a}_t = (a_{1,t}, \cdots, a_{N,t})$。环境根据整个联合动作转移，并返回团队奖励或各智能体奖励。全局转移满足马尔可夫性时，从局部观测出发的单个智能体仍可能面对部分可观测问题；如果其他策略同步更新，其经验的生成过程还会出现训练非平稳性[51-52]。

条件独立的分散式 Actor 可以把联合策略因子化为

$$\boldsymbol{\pi}_\theta(\boldsymbol{a}_t \mid \boldsymbol{h}_t) = \prod_{u=1}^{N} \pi_{\theta_u}(a_{u,t} \mid h_{u,t}), \tag{2.53}$$

其中 $h_{u,t}$ 是各智能体允许使用的历史，当前观测策略是其特例。条件独立指给定各自输入后的动作采样方式，并不意味着动作对环境的影响独立。多架 UAV 的

动作可以通过覆盖边界、最小间距和共享计算资源发生强耦合。

联合动作空间随智能体数量变化。若每个智能体有 K 个离散动作，联合动作数是 K^N；连续动作则形成更高维联合空间。参数共享不改变这种环境组合结构，但可以减少模型中重复的可训练参数。同类型 UAV 共享 θ 时，不同局部状态仍产生不同分布；其经验共同贡献梯度。若异质节点承担不同功能，是否共享、是否引入身份或能力特征需要根据具体实现决定，而不是将参数共享作为所有 MARL 方法的必选条件。

训练非平稳性的原因可以写得更具体。对固定智能体 u，其看到的有效转移包含其他智能体策略的平均：

$$P_u^{\pi_{-u}}(s' \mid s, a_u) = \sum_{\boldsymbol{a}_{-u}} \pi_{-u}(\boldsymbol{a}_{-u} \mid \boldsymbol{h}_{-u}) P(s' \mid s, a_u, \boldsymbol{a}_{-u}). \tag{2.54}$$

当 π_{-u} 变化时，该有效过程变化。全局状态转移模型未必因此失去马尔可夫性，但单个策略从旧样本中估计当前环境的难度增加。集中训练能够使用更多信息缓解估计困难，却不能保证完全消除这种变化或信用分配问题。

2.7.2 CTDE 与联合观测价值网络

CTDE 区分训练信息与执行信息。训练时 Critic 可以访问联合观测、全局状态或规定的协作信息；执行时 Actor 必须使用其信息合同允许的输入。MADDPG 与 MAPPO 分别展示了集中价值估计用于多智能体训练的不同方式[30-31]。这一范式不意味着现实系统可以免费获得联合状态，也不意味着所有策略输出都属于分散式执行。若在线模块要汇总当前请求后求解一次中央分配，就应明确其集中协调需求。

本文上层的联合观测记为 $O_t = (o_{1,t}, \cdots, o_{N,t})$，共享 Critic 的输出形式为

$$\boldsymbol{V}_\phi(O_t) = (V_{\phi,1}(O_t), \cdots, V_{\phi,N}(O_t)) \in \mathbb{R}^N. \tag{2.55}$$

每个 UAV 获得对应价值估计，网络通过联合输入建模相互关系。共享参数不要求输出只有一个全局标量，也不要求每个输出使用完全相同的局部回报。实际奖励是否共享、价值目标如何生成，需要与 rollout 数据结构一致。第三章说明本文上层输入和训练设置，第五章则使用公开队列和候选特征作集中联合决策，其动作主体与第三章多 UAV Actor 不同。

团队奖励下，因子化策略的 log probability 满足

$$\nabla_\theta \log \boldsymbol{\pi}_\theta(\boldsymbol{a} \mid \boldsymbol{h}) = \sum_{u=1}^{N} \nabla_\theta \log \pi_\theta(a_u \mid h_u) \tag{2.56}$$

（共享参数时）。代入策略梯度，可把各 UAV 的得分函数贡献相加。价值基线可以利用动作之前的联合信息，只要在对应条件下不依赖当前被求导动作，就保留

基线不偏性的基本逻辑。实际按智能体划分的优势是近似估计，集中 Critic 提供训练信号，不构成对个体因果贡献的精确分解。

2.7.3　MAPPO 的局部比率与更新流程

MAPPO 采用 PPO 类代理目标训练协作策略[31]。对于每个 UAV 的样本，定义局部比率

$$\rho_{u,t}(\theta) = \frac{\pi_\theta(a_{u,t} \mid o_{u,t})}{\pi_{\theta_{\text{old}}}(a_{u,t} \mid o_{u,t})}. \tag{2.57}$$

常用的共享 Actor 代理目标在智能体与时隙上平均：

$$L_{\text{MAPPO}}(\theta) = \frac{1}{NT} \sum_{u,t} \min\left(\rho_{u,t}\widehat{A}_{u,t}, \text{clip}(\rho_{u,t}, 1-\varepsilon, 1+\varepsilon)\widehat{A}_{u,t}\right). \tag{2.58}$$

其中 T 在此表示采样批次包含的时隙数，实际实现还会对批次和有效样本作平均。各智能体价值目标来自对应回报和联合 Critic，Actor 则分别以局部观测重算提案概率。

联合策略概率比率为 $\rho_{\text{joint},t} = \prod_u \rho_{u,t}$。逐智能体裁剪式 (2.58) 与先计算联合比率再裁剪不是同一个目标；即使每个局部比率靠近一，多个比率的乘积也可能明显变化。因此，不能把局部裁剪描述成联合策略 KL 的硬上界。共享参数更新还会同时影响所有 UAV，这要求控制 epoch、学习率和 minibatch 等配置，并观察实际训练行为。

一次完整训练循环包括固定当前策略采集 rollout，保存每个 UAV 的局部观测、原始动作、log probability、价值估计、奖励和边界标记；利用同一采样批次计算 GAE 与 Critic 目标；在旧概率保持不变的条件下进行多个优化 epoch；更新完成后再采集下一批经验。这样可以把旧策略采样与当前优化区分开。若上下层都学习，改变另一层会改变环境反馈，因此还需要定义更新顺序和训练协议。本文第三章在单时隙执行环境内按固定顺序同步更新上下层参数，第五章则在独立动态排队协议中采用单网络双分支联合策略并通过规划蒸馏与 PPO 微调统一训练，避免把不同章节的训练机制混写。

2.8　注意力聚合与图表示

2.8.1　查询、键和值的计算

注意力把元素间的相关性转化为聚合权重[35]。设查询、键和值矩阵分别为 $Q \in \mathbb{R}^{n_q \times d_k}$、$K \in \mathbb{R}^{n_k \times d_k}$ 和 $V \in \mathbb{R}^{n_k \times d_v}$，缩放点积注意力为

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + M\right)V. \tag{2.59}$$

M 为加性掩码，合法项为零，非法项在数学表达中为负无穷；softmax 沿键的维度计算。每一行权重非负且和为一，因此输出是值向量的加权组合。查询与键决定权重，值承担被聚合的信息，三者的功能不同。

缩放因子的作用可以从点积方差说明。假设各 q_i, k_i 零均值、方差为一，同一维度内 q_i 与 k_i 相互独立，且不同维度的变量对 (q_i, k_i) 相互独立，则

$$\mathrm{Var}(q^{\mathsf{T}}k) = \mathrm{Var}\left(\sum_{i=1}^{d_k} q_i k_i\right) = d_k. \tag{2.60}$$

因此除以 $\sqrt{d_k}$ 后，点积标准差的量级不再随维度平方根增大。对于 softmax 权重 α_i，其导数 $\partial\alpha_i/\partial z_j = \alpha_i(\mathbb{I}\{i=j\} - \alpha_j)$；若 logits 差距过大，权重可能过早接近零或一，导数变小。缩放改善这种数值量级，但真实特征并不必然独立同分布，故它是合理的结构设计，不是避免所有饱和的保证。

多头注意力使用不同投影建立多个表示子空间：

$$H_h = \mathrm{Att}(QW_h^Q, KW_h^K, VW_h^V), \tag{2.61}$$

$$\mathrm{MHA}(Q,K,V) = \mathrm{Concat}(H_1, \cdots, H_H)W^O. \tag{2.62}$$

式中的 H 在此表示注意力头数，仅在本小节使用；几何高度仍写为 H_u。如果总隐空间为 d 且每头等宽，单头键维度为 $d_k = d/H$，缩放分母应使用单头的 $\sqrt{d/H}$。本文上层 $d = 64$、头数为 8 时，单头宽度为 8，不能误用 $\sqrt{64}$ 作为每头点积的分母。

2.8.2 局部查询、掩码与排列性质

在 UAV 上层观测中，自身状态经过嵌入后可作为查询，邻居 UAV 和 UE 槽位分别提供键和值[53]。邻居表示包含协作几何关系，UE 表示包含位置与请求等允许信息，两个聚合结果再与自身特征融合。固定槽位中的空元素需要掩码，否则补零槽位也会参与归一化，影响有效元素权重。注意力改变的是聚合方式，并未自动减少原始观测维度，也没有自动增加感知范围。

全空键集合是一个必须处理的边界。若一行所有 logits 都为负无穷，softmax 的归一化不再有有效分母。实现可以为这种情况定义零上下文或专门空状态，并让后续网络识别“没有可见元素”。该约定应与训练和执行一致，避免出现 NaN 后再把结果无条件修成任意数值。实际 UAV 的邻居或 UE 槽位数量变化时，掩码和有效计数同样需要对应，不应把填充容量误认为实际用户数量。

对于固定查询的纯加权聚合，若键和值同时按同一置换矩阵 P 重排，$K' = PK, V' = PV$，则

$$\mathrm{softmax}(QK'^{\mathsf{T}})V' = \mathrm{softmax}(QK^{\mathsf{T}})P^{\mathsf{T}}PV = \mathrm{softmax}(QK^{\mathsf{T}})V. \tag{2.63}$$

这里省略缩放和同步重排的掩码以突出排列关系。该性质要求不额外引入与序号相关的编码；完整系统还包含排序、截断、分组和其他特征，因此不能从这一局部式子推断整个策略对所有观测处理均排列不变。UE 选择规则本身可能决定哪些需求进入有限槽位，是第三章观测研究的重要部分。

一个自身查询聚合 n 个元素时，注意力权重计算约为 $O(nd_k)$；若对全部元素使用自注意力，则点积关系数量约为 n^2。线性投影、网络宽度、多个头和实际批次还带来其他成本。本文不从这类运算量估计直接推出软件实时性，而在第五章测量完整策略调用。相同地，权重热图可以描述某次输入的聚合分布，却不能单独说明该元素对最终 DSR 的因果贡献。

2.8.3　候选等变编码与分配–运动双分支交互表示

当决策空间由一组离散候选分配方案 $\mathcal{K}(s) = \{1, \cdots, K\}$ 与一组离散候选联合运动方案 $\mathcal{M}(s) = \{1, \cdots, M\}$ 组成时，若把所有候选特征按固定顺序拼接为单一长向量再输入全连接层，网络参数会与候选槽位编号绑定，破坏候选集合的置换等变性。为保持候选顺序无关的结构归纳偏置，可以使用共享权重的逐候选打分网络（Candidate-Equivariant Scoring Network）。设公共排队状态上下文为 $\mathbf{c}(s)$，第 k 个候选分配方案的特征为 $\mathbf{a}_k(s)$，第 (k, m) 对方案组合的运动与交互特征为 $\mathbf{m}_{km}(s)$，定义共享映射 g_θ 与 h_θ：

$$z_k^{\text{base}}(s) = g_\theta\big([\mathbf{c}(s),\, \mathbf{a}_k(s)]\big), \qquad k \in \mathcal{K}(s), \tag{2.64}$$

$$\mathbf{C}_{\text{upper}}[k, m](s) = h_\theta\big([\mathbf{c}(s),\, \mathbf{a}_k(s),\, \bar{\mathbf{m}}_k(s),\, \mathbf{m}_{km}(s)]\big), \qquad (k, m) \in \mathcal{K}(s) \times \mathcal{M}(s), \tag{2.65}$$

其中 $\bar{\mathbf{m}}_k(s) = \frac{1}{M} \sum_{m'=1}^{M} \mathbf{m}_{km'}(s)$ 为给定分配方案 k 下各候选运动特征的均值上下文。由于 g_θ 与 h_θ 对每个候选索引共享参数，若对候选集合 $\mathcal{K}(s)$ 或 $\mathcal{M}(s)$ 施加任意排列，输出打分向量与交互矩阵 $\mathbf{C}_{\text{upper}} \in \mathbb{R}^{K \times M}$ 的对应行列严格按相同排列变换。

在此基础上，联合策略可分解为先选分配候选 k、再在所选分配方案条件下选择联合运动 m 的链式双分支结构：

$$\pi_\theta(k, m \mid s) = p_a(k \mid s)\, p_m(m \mid s, k), \tag{2.66}$$

其中运动分支分布为 $p_m(m \mid s, k) = \text{softmax}_m(\mathbf{C}_{\text{upper}}[k, m])$，而分配分支的最终 logit 融合了在该分配方案下后续运动分支的期望交互反馈：

$$z_k(s) = z_k^{\text{base}}(s) + \eta_{\text{fb}} \sum_{m=1}^{M} p_m(m \mid s, k)\, \mathbf{C}_{\text{upper}}[k, m](s). \tag{2.67}$$

当 $\eta_{\mathrm{fb}}=1$ 且保留 $\mathbf{a}_k(s)$ 条件输入时，分配分支在评价方案 k 时能够感知该分配在后续可用运动下的期望服务表现（完整联合策略）；若令 $\eta_{\mathrm{fb}}=0$，则退化为无运动期望反馈的单向条件化策略；若进一步消去运动分支中的 $\mathbf{a}_k(s)$ 条件输入，则退化为完全解耦的独立双分支策略 $p_a(k\mid s)p_m(m\mid s)$。第五章在此统一表示框架下严格对比完整联合、去期望反馈与完全解耦三类结构。

2.9 批量字典序重评估与跨时隙串联排队建模基础

2.9.1 单时隙批量算力共享下的外部性与字典序重评估

在第三、四章的单时隙批量算力共享协议中，设当步自然接纳的服务请求集合为 $\mathcal{M}_t$，每个请求 $m\in\mathcal{M}_t$ 选择执行节点 $b_m\in\mathcal{J}=\{1,\cdots,N,\mathrm{MBS}\}$。对于任意完整分配向量 $\mathbf{b}=(b_m)_{m\in\mathcal{M}_t}$，分配到 UAV $j\in\{1,\cdots,N\}$ 的最终任务数为 $N_j(\mathbf{b})=\sum_{m\in\mathcal{M}_t}\mathbb{I}\{b_m=j\}$。根据式 (2.8)，若将单个请求 $m^\star$ 从原目标节点 $j=b_{m^\star}$ 迁移至新候选节点 $j'=b'_{m^\star}$，产生的新分配向量 $\mathbf{b}'$ 会使原节点负载变为 $N_j(\mathbf{b}')=N_j(\mathbf{b})-1$、新节点负载变为 $N_{j'}(\mathbf{b}')=N_{j'}(\mathbf{b})+1$。因此，同批次内所有满足 $b_m\in\{j,j'\}$ 的其他请求 $m\neq m^\star$ 的实际计算完成时间都会随分母改变而同步移动：

$$\Delta T_m^{\mathrm{cmp}}(\mathbf{b}\to\mathbf{b}')=\begin{cases}-\dfrac{C_m}{F_j}, & m\neq m^\star,\ b_m=j\in\{1,\cdots,N\},\\[2mm] +\dfrac{C_m}{F_{j'}}, & m\neq m^\star,\ b_m=j'\in\{1,\cdots,N\},\\[2mm] 0, & \text{其他情形.}\end{cases}\tag{2.68}$$

式 (2.68) 表明，单次迁移对整批超时数的影响不仅取决于被迁移请求 $m^\star$ 自身是否跨越 $D_{m^\star}$，还取决于原节点 j 上是否有原本超时的紧迫请求因负载减轻而挽回成功，以及新节点 j' 上是否有原本按时完成的边缘请求因负载增加而被挤出截止期。因此，整批分配质量无法写成与他请求无关的静态单请求边权之和。

2.9.2 截止期优先的严格二元字典序准则

为在固定快照下直接对齐端到端 DSR 的分子，定义完整分配 $\mathbf{b}$ 的超时请求总数 $M_{\mathrm{miss}}(\mathbf{b})$ 与平均归一化时延 $\bar{\tau}_{\mathrm{norm}}(\mathbf{b})$：

$$M_{\mathrm{miss}}(\mathbf{b})=\sum_{m\in\mathcal{M}_t}\mathbb{I}\big\{T_m(\mathbf{b})>D_m\big\},\qquad \bar{\tau}_{\mathrm{norm}}(\mathbf{b})=\frac{1}{|\mathcal{M}_t|}\sum_{m\in\mathcal{M}_t}\frac{T_m(\mathbf{b})}{D_m}.\tag{2.69}$$

候选分配 $\mathbf{b}'$ 严格优于当前分配 $\mathbf{b}$（记作 $\mathcal{L}(\mathbf{b}')\prec_{\mathrm{lex}}\mathcal{L}(\mathbf{b})$）当且仅当：

$$\Big(M_{\mathrm{miss}}(\mathbf{b}')<M_{\mathrm{miss}}(\mathbf{b})\Big)\ \vee\ \Big(M_{\mathrm{miss}}(\mathbf{b}')=M_{\mathrm{miss}}(\mathbf{b})\ \wedge\ \bar{\tau}_{\mathrm{norm}}(\mathbf{b}')<\bar{\tau}_{\mathrm{norm}}(\mathbf{b})-\epsilon_{\mathrm{tie}}\Big),\tag{2.70}$$

其中 $\epsilon_{\text{tie}} > 0$ 为浮点平局容差。与将超时数与时延线性加权的目标不同，严格二元字典序准则保证任何以增加超时请求数为代价换取其余简单请求更低时延的迁移均被拒绝，而在超时数相同时进一步压缩归一化时延，为紧迫任务释放计算余量。第四章据此构建最坏违例驱动的迭代任务重分配（MC-ITR）算法。

2.9.3　跨时隙持续队列、释放时间串联近似与两套互补实验协议

当未完成任务的传输与计算工作量跨时隙持续保留时，系统从单时隙批量结算扩展为多时隙排队网络。每个被自然接纳的任务 j 依次经历“无线接入上传 →（跨机转发）→ 目标节点最早截止期优先（EDF）计算”两个串联阶段。精确模拟未来多步轨迹下的微观时隙交错排队开销较高，因此在构建候选卸载方案与短期前瞻评价时，可采用**释放时间工作守恒串联排队近似（Release-Time Work-Conserving Tandem-Queue Approximation）**：第一阶段按冻结链路速率与先到先服务（FCFS）共享带宽计算每个任务的通信完成时刻（即计算阶段释放时刻 $\tilde{r}_j^{\text{cpu}}$）；第二阶段在各执行节点上，将已有计算积压与在窗口内释放的新任务按截止期 d_j 升序（EDF）排列，递推估计各任务的近似完成时刻 $\tilde{t}_j^{\text{done}}$ 与截止期松弛度。第五章将该解析近似用于构造多策略候选分配池与规划教师前瞻，并在真实环境中通过精确微步离散事件排队完成闭环验证。

表 2.1　全文两套互补实验协议的设计逻辑与语义对照

Table 2.1　Comparison of design logic and operational semantics between the two complementary experimental protocols across chapters

对比维度	协议 I：单时隙批量结算与缓存耦合协议（第三、四章）	协议 II：跨时隙持续 EDF 排队控制协议（第五章）
核心科学问题	剥离跨时隙队列积压干扰，诊断**未覆盖需求可见性**对空间接纳的净效应（第三章），以及**单步批量算力竞争**下的跨机重分配质量余量（第四章）。	在传输与计算进度跨时隙保留的持续排队条件下，检验**规划知识蒸馏、反事实辅助微调与神经引导 MPC** 的闭环协同控制收益。
任务生命周期与队列保留	单时隙内完成完整路径时延结算与截止期判定；未完成工作量不跨时隙累积为持久队列。	接入上传、跨机转发与计算剩余工作量均跨时隙持久保留，直至任务完成或超过绝对截止期 d_j 后作为过期任务清除。
计算资源竞争机制	最终批量等份共享：$f_{m,j} = F_j / N_j(\mathbf{b})$，体现同批次任务数外部性。	持续工作守恒最早截止期优先（EDF）排队调度，体现跨时隙积压与释放时间耦合。
业务类型与缓存动态	25 类服务与 50 类内容混合（Zipf $\beta = 0.8$），含二值缓存命中、回源下载与 GDSF 周期更新。	纯计算服务请求流（时变热点驱动到达，180 宏步、每宏步 5 个微时隙），聚焦通信–计算串联排队耦合。
地面用户与空间运动	100 个移动 UE（随机航点模型），5 架 UAV 离散位置经 40 轮交替几何消解与悬停回退。	100 个固定位置 UE（含时变热点到达率），5 架 UAV 沿宏步线性插值全路径检查边界与 200 m 机间距。
跨章桥接与证据边界	第四章第 4.8.1 节在第三章冻结策略的真实轨迹快照上评估 MC-ITR；两章绝对 DSR 不与第五章直接拼接。	独立设立 17 组对照方案与 816 个盲测确认回合；绝对 DSR（约 44% ∼ 49%）仅在协议 II 内部配对比较。

表 2.1 总结了本文第三、四章（协议 I）与第五章（协议 II）两套互补实验

协议的设计边界。之所以不在第三、四章直接引入跨时隙持久队列，是因为在持久积压下，上一时隙遗留的排队时延会与当前时隙的覆盖接纳及当步算力分配混杂，难以单独识别预接纳观测对空间覆盖的因果贡献，也无法在干净的同批次算力共享条件下分离单步组合重分配的理论余量；反之，在第三、四章分别查明“空间接纳瓶颈”与“跨机负载外部性”之后，第五章进一步进入更具挑战性的跨时隙持续排队协议，检验候选级联合控制流水线在持久队列动态下的端到端有效性。两套协议共享“生成 G、自然接纳 A、按时完成 S”的顶层计数分解恒等式，但在各自冻结的协议边界内独立开展配对统计推断。

2.10 随机实验与证据解释基础

强化学习实验的随机性来自模型初始化、策略采样和外生需求。独立训练块是不同训练过程产生的模型重复；同一模型上的多个工作负载、回合、时隙和请求则属于嵌套评价。增加这些评价可以更准确地估计该模型的行为，但不能把它们都视为独立训练样本。非学习方法没有训练模型，其随机流重复也需要按实际含义命名。本文以这种区分组织后续图表中的 n。

在预定配对设计中，先在训练块内聚合各方法对应的工作负载与回合，得到块级指标 $Y_{b,1}$ 和 $Y_{b,0}$，再计算差值 $d_b = Y_{b,1} - Y_{b,0}$。均值差与样本标准差为

$$\bar{d} = \frac{1}{n}\sum_{b=1}^{n} d_b, \qquad s_d^2 = \frac{1}{n-1}\sum_{b=1}^{n}(d_b - \bar{d})^2. \tag{2.71}$$

训练块配对 t 区间为 $\bar{d} \pm t_{0.975,n-1} s_d/\sqrt{n}$。其解释依赖独立块与相应统计假设；小样本或临界结果还可以使用预定的符号翻转等敏感性检查。区间跨零表示当前数据未确认所述差异，不等于两个方法在所有条件下相同。

多个预定比较需要控制所使用的检验族。Holm 校正按 p 值由小到大依次比较 $\alpha/(m-i+1)$，在第一个未通过的位置停止后续拒绝，从而控制该族的家族错误率。主性能比较、机制比较和后来登记的新随机比较承担不同科学问题，应按原合同分别报告。不能事后把有利比较从原族拿出，或者只增加不影响结论的对手来改变校正结果。

固定检查点、预定评价协议和全部样本保留对于可靠比较同样重要。训练中间出现最高评价点，可能包含检查点筛选对评价负载的适配；若把它替换为正式主结果，需要另行定义筛选与独立确认。本文主线保持冻结模型、来源摘要与明确最后检查点，开发诊断用于方法选择，独立确认用于主要性能论证。训练曲线、快照改善和长期指标分别承担不同证据作用，不以任何单一图替代完整验证。

2.11　本章小结

本章从无人机集群的任务分工、轨迹规划与飞行执行层次出发，明确本文采用固定高度二维机动、离散位置可行性修复和集中任务协调的研究范围。空间部署影响后续请求接纳，批量执行影响机载资源状态，两者共同形成集群服务的时序耦合。在这一框架下，UAV-MEC 的位置相关通信、字节与比特转换、最终批量计算共享、缓存获取和自然接纳共同影响请求成功。随后推导有限时域值函数、Bellman 关系和策略梯度，证明动作无关基线在相应条件下不改变理想梯度期望，并给出 GAE 的多步混合、终止掩码与递推实现。PPO 的裁剪目标提供局部代理优化方式，其概率记录必须与原始提案和采样掩码一致，不能被描述为严格 KL 或收敛保证。

多智能体部分区分全局状态、局部观测与集中价值估计，说明共享 Actor 和联合观测多输出 Critic 的作用。注意力提供输入元素的加权聚合，候选等变打分、批量二元字典序重评估与跨时隙释放时间串联排队近似则分别为两套实验协议下的任务分配与协同控制提供结构表示，均需要通过具体协议与受控对照判断收益。以上基础为第三章需求观测、第四章批量迁移和第五章规划蒸馏与反事实辅助 PPO 提供了统一的理论语言，也为解释训练曲线、主比较与机制证据明确了条件。

第 3 章　自然覆盖约束下无人机集群的需求感知协同轨迹决策

3.1　研究动机与评价口径

3.1.1　从集群空间部署到可接纳需求

无人机集群承担地面计算服务时，机群空间部署决定哪些需求能够进入任务执行流程。用户设备只有进入某架无人机的服务范围，其请求才有机会上传、分配和执行。对于尚未被覆盖的请求，即使集群具有足够的总算力，任务分配层也没有可处理的输入。因此，上层轨迹决策需要安排有限的空中平台，使具有服务需求的用户进入可接纳区域，并结合邻机位置处理多机部署关系。本文把这一前置条件称为自然覆盖接纳：覆盖由真实位置和固定服务半径决定，不因请求紧急、无人机负载较低或宏基站算力充足而放宽。

在自然覆盖口径下，上层局部观测是否包含未接纳需求直接影响可学习的控制规律。若观测只列出已关联用户，策略可以比较这些用户的距离与请求特征，却无法辨别附近未覆盖区域究竟存在高需求还是无人区域。低服务率的奖励能说明当前结果不理想，但不能单独提供应向何处移动的信息。这一信息缺口不同于网络容量不足：增加隐藏层或注意力头数并不会把被观测构造过程丢弃的用户重新送入网络。

本章研究固定服务半径下无人机集群的需求感知协同轨迹决策。首先建立与生产仿真一致的几何、通信、缓存和计算模型，明确平台运动影响服务结果的时间路径；其次构造上层分散式部分可观测决策过程，说明 Attention-MAPPO 如何聚合邻机与地面需求信息，以及实际概率模型和训练目标；最后在不改变网络维度与物理接纳规则的条件下，把感知范围内尚未接纳的需求补入观测，并用探索与独立确认两阶段实验检验其作用。本章回答集群应如何依据需求调整空间部署，覆盖观测结果属于方法演进的阶段性证据，第五章则在独立的动态排队服务协议中进一步研究基于规划知识蒸馏与反事实辅助 PPO 的完整在线联合控制方法与端到端表现。

本文不以旧协议中的强制关联代替自然覆盖。强制关联会令未覆盖请求进入最近无人机的处理流程，从而消除“未接纳”这一失败类别。它改变了待优化问题，而不只是更换指标名称。在本文的现行协议中，未覆盖服务请求进入 DSR 分母但不进入卸载集合，轨迹控制必须通过改变后续位置改善接纳，不能依靠评估器补足覆盖。

3.1.2　统一计数与乘积分解

设一个评估单元内实际生成的服务请求总数为 G，自然覆盖接纳数为 A，满足自身截止时间的服务请求数为 S。计数满足 $0 \leqslant S \leqslant A \leqslant G$。对 $G > 0, A > 0$ 的单元，定义接纳率 $\alpha = A/G$、接纳后完成率 $\eta = S/A$，则

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A} = \alpha\eta. \tag{3.1}$$

分母为零时，对应比例按实验实现取零。$G - A$ 表示因覆盖不足而无法进入执行流程的请求数，$A - S$ 表示已经接纳但未按时完成的请求数。因此，总失败数可以不重不漏地分解为

$$G - S = (G - A) + (A - S). \tag{3.2}$$

这一分解把几何接纳与接纳后的传输计算质量放在同一计数框架内，避免只在已处理请求上报告较高成功率而忽略未覆盖需求。

统计汇总必须区分“单元内求比例”和“跨单元平均”。本文的确认实验先在每个“训练种子–工作负载”评估单元内累加六个回合的请求计数，再分别求 $S/G, A/G, S/A$，随后平均各单元比例。若以 i 标记单元，则平均端到端指标为 $\overline{\mathrm{DSR}} = I^{-1}\sum_i \alpha_i\eta_i$。一般有

$$\overline{\mathrm{DSR}} = \bar{\alpha}\bar{\eta} + \frac{1}{I}\sum_{i=1}^{I}(\alpha_i - \bar{\alpha})(\eta_i - \bar{\eta}), \tag{3.3}$$

而非直接等于两个平均因子的乘积。把所有单元的计数再次合并后求 $\sum_i S_i / \sum_i G_i$，则对应按生成请求数加权的指标，亦不能替代预定的等权单元均值。

比较候选方法和基线时，可在每一配对单元内进行精确的对称分解。以下标 c, b 标记两方法，记 $\Delta\alpha_i = \alpha_{c,i} - \alpha_{b,i}$、$\Delta\eta_i = \eta_{c,i} - \eta_{b,i}$，则

$$\Delta\mathrm{DSR}_i = \Delta\alpha_i\frac{\eta_{c,i} + \eta_{b,i}}{2} + \Delta\eta_i\frac{\alpha_{c,i} + \alpha_{b,i}}{2}. \tag{3.4}$$

证明只需展开右端，两个交叉乘积相消，剩下 $\alpha_{c,i}\eta_{c,i} - \alpha_{b,i}\eta_{b,i}$。该形式无需任选一个方法作为展开基点，两个项相加精确恢复单元差值；先配对分解再平均也精确恢复平均 DSR 差值。其用途是描述指标变化的来源，不能仅凭代数分解把接纳增加解释为已被唯一识别的因果机制。

3.1.3　外生请求流与配对分母一致性

仿真为每个用户分配独立的随机数生成器，按时隙依次抽取请求标识、输入大小、截止时间和优先级，直接根据标识所属范围定型为计算服务请求或内容请求。由于请求生成过程完全由工作负载种子驱动的外生随机流决定，不依赖历史

轨迹或缓存演化，在相同工作负载种子下评估的任意两个策略均面对严格一致的实际生成服务请求序列与分母 G。

本文以预先规定的 S/G 为端到端主指标。配对外生随机流保证了候选方法与基线方法在同一评估单元内的分母 G 完全相同，使 DSR 差值直接对应按时完成请求数的差异，避免因策略演化改变业务生成过程而引入分母偏移。

3.2 系统几何、动作应用与单时隙时序

3.2.1 集群协同对象与规划层次

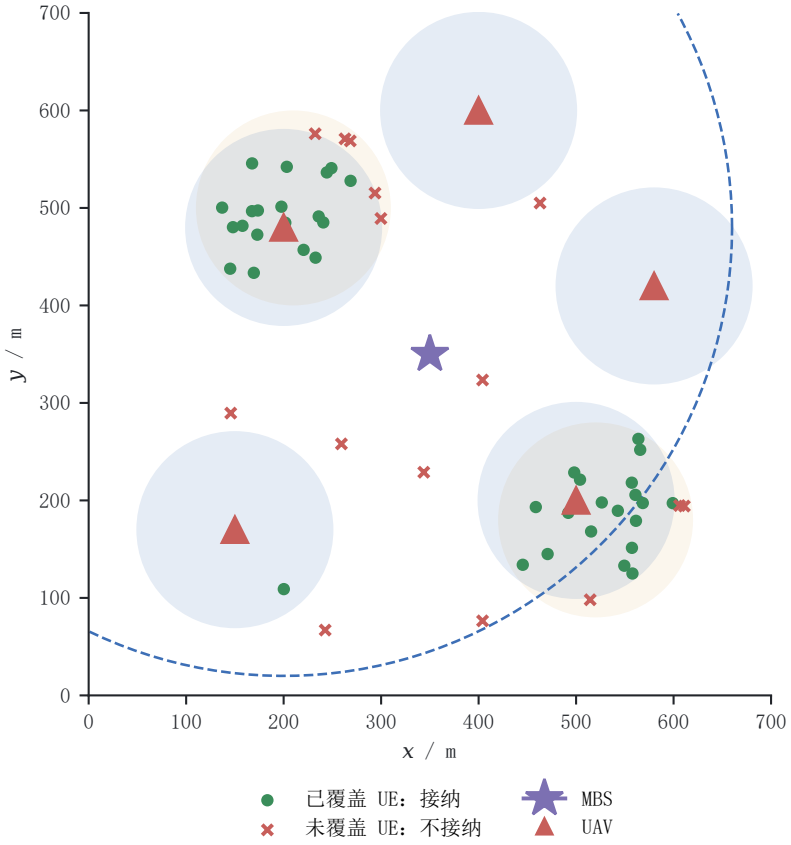
本文的协同对象是共同服务地面请求的五架无人机。各机的水平位置、关联用户、邻机状态和机载资源通过请求接纳与任务执行相互联系：一架无人机移动会改变后续服务对象和机间链路；一个请求跨机执行会改变目标节点的计算负载和缓存，进而影响后续观测。因此，集群轨迹规划需要以整体服务结果评价各机的动作，单机通信距离或当前关联用户数量不足以概括这一目标。

上层在规划层给出逐时隙的二维运动指令。五个 actor 根据各自定长局部观测推断动作，训练时的联合观测 critic 为其提供集群回报的评价；共享参数和邻机注意力提供协调信息的表达方式。环境随后对拟执行位移作确定性修复，处理区域与机间距约束。该结构采用协同决策与几何执行修复共同形成可执行位置序列，学习策略的原始输出本身不构成安全性证明。固定高度、速限和位置边界构成本文的简化运动模型，姿态、加速度和内环飞行控制由模型假设之外的执行层承担。

本章所谓轨迹规划，是在该简化模型中连续生成服务位置和运动指令，不要求五机保持预设编队形状。机间距、服务半径与感知半径承担不同职责：机间距限制平台相对位置，服务半径确定任务接纳资格，感知半径确定策略可用的信息。把三者区分开，才能判断观测改进是否改变了任务信息，而非放宽了运动或服务条件。

3.2.2 网络与自然覆盖模型

主场景含 $N = 5$ 架 UAV、$M = 100$ 个 UE 和一个 MBS。地面区域为 $[0, 700] \times [0, 700]\,\mathrm{m}^2$，UAV 保持 $H = 100\,\mathrm{m}$ 高度，MBS 固定于 $(350, 350, 30)\,\mathrm{m}$。记 UAV 水平位置为 $\mathbf{q}_u(t)$、UE 水平位置为 $\mathbf{w}_m(t)$，三维位置分别为 $\mathbf{p}_u(t) = (\mathbf{q}_u(t), H)$、$\mathbf{p}_m(t) = (\mathbf{w}_m(t), 0)$。覆盖判断使用水平距离，通信增益使用三维距离，这两个距离不能混用。



实线圆：100 m服务范围；虚线弧：460 m感知范围；橙色区域：热点

图 3.1　系统总体布局与自然覆盖接纳示意。三角形为 UAV，实线圆为 100 m 服务覆盖范围，虚线圆为其中一架 UAV 的 460 m 感知范围；绿色圆点为被覆盖 UE，红色叉为未被覆盖 UE，其请求本时隙不被接纳。图中位置为示意性布局，非真实轨迹快照

Figure 3.1　Schematic of the system layout and natural-coverage admission (illustrative positions, not a recorded trajectory snapshot)

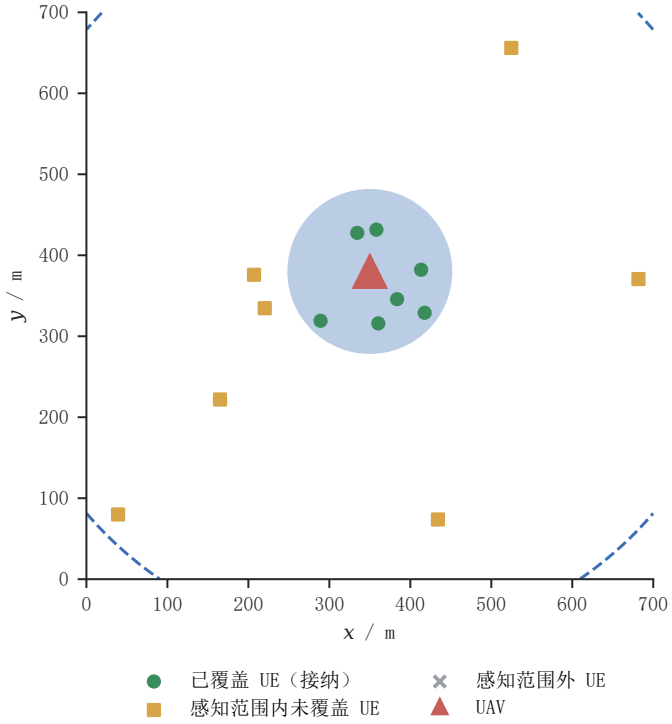
用户 m 在时隙 t 的可覆盖无人机集合和接纳来源定义为

$$\mathcal{U}_m(t)=\{u:\|\mathbf{w}_m(t)-\mathbf{q}_u(t)\|\leqslant R_c\},\qquad u_m(t)=\arg\min_{u\in\mathcal{U}_m(t)}\|\mathbf{w}_m(t)-\mathbf{q}_u(t)\|,\tag{3.5}$$

其中 $R_c=100\,\mathrm{m}$；$\mathcal{U}_m(t)=\varnothing$ 时不关联。该规则同时应用于服务与内容请求，而非只对服务请求有效。服务接纳计数 A 只统计其中的服务请求，接入带宽的分配则统计关联的全部请求类型。若覆盖集合重叠，选择最近的覆盖 UAV，不以目标执行节点替代接纳来源。

邻居发现与扩展观测采用 $R_s=460\,\mathrm{m}$ 的感知范围。UAV 之间按照三维距离判断邻居，由于各机高度一致，该距离等于水平机间距。UE 的预接纳可见范围与 100 m 的接纳范围分别定义。图 3.2 展示两种半径的关系：扩大可见信息不会立即赋予远处 UE 上传或计算资格，上层仍须用受速限约束的移动使其进入覆盖。

UAV 间最小水平间距为 $d_{\min}=200\,\mathrm{m}$。它与服务直径相同，使满足该间距的



实线圆：100 m 接纳范围；虚线弧：460 m 感知范围（与地图边界相交）

图 3.2　覆盖半径与感知半径的几何关系

Figure 3.2　Geometry of the coverage radius and the sensing radius

部署中两覆盖圆的内部不相交、边界至多相切；这一几何关系由固定配置给定，不能作为学习策略减少覆盖重叠的证据。另一方面，机间距也限制了多机同时聚集到同一热点，轨迹策略需要在热点需求、稀疏用户和相对位置约束之间协调。该约束并未保证区域全覆盖，有限数量的覆盖圆仍可能留下大量未接纳需求。

用户移动采用随机航点模型。每时隙向当前航点推进，位移上限为 15 m；到达航点后可等待并生成下一航点。主场景中 85% 的用户围绕两个半径为 100 m、中心间距不小于 400 m 的热点分布，其余用户分布于区域内。热点结构使“平均向中心聚集”不必然有效：不同 UAV 需避免重复追踪同一需求，同时照顾感知范围内尚未接纳的用户。

3.2.3　原始概率动作与可执行位移

策略网络生成的随机变量和环境实际执行的动作不是同一个量。记原始动作 $\mathbf{z}_u \in \mathbb{R}^2$，训练阶段按二维正态分布采样；输入环境前逐坐标裁剪为 $\mathbf{a}_u = \mathrm{clip}(\mathbf{z}_u, -1, 1)$。环境进一步按向量模长映射位移：

$$\widetilde{\Delta\mathbf{q}}_u = v_{\max}\tau \min(\|\mathbf{a}_u\|, 1)\frac{\mathbf{a}_u}{\|\mathbf{a}_u\| + \epsilon_0}, \qquad v_{\max} = 15\,\mathrm{m/s},\ \tau = 1\,\mathrm{s}. \tag{3.6}$$

$\epsilon_0 > 0$ 是数值保护常量。当模长小于一时，位移近似与动作线性对应；当模长大于一时，只保留方向并饱和到最大移动距离。逐坐标裁剪并不能独立保证速度约束，因为 $(1,1)$ 的模长为 $\sqrt{2}$，故径向映射是必要步骤。

实际飞行位置同时满足边界、速度和机间距条件。环境采用的边界留白为服务半径的一半，故可行位置区域是 $\mathcal{Q} = [50\,\mathrm{m}, 650\,\mathrm{m}]^2$，而非整个地面服务区域。给定当前可行位置，下一位置应属于

$$\mathcal{F}(\mathbf{q}(t)) = \left\{ \{\mathbf{q}'_u\}_{u=1}^{N} : \ \mathbf{q}'_u \in \mathcal{Q},\ \|\mathbf{q}'_u - \mathbf{q}_u(t)\| \leqslant v_{\max}\tau,\ \|\mathbf{q}'_u - \mathbf{q}'_v\| \geqslant d_{\min}\ (u \neq v) \right\}. \tag{3.7}$$

其中机间距约束对应圆外区域，联合可行域一般非凸。本文的动作修复是实现中的有限迭代消解过程，不是对该非凸集合求得唯一的欧氏投影，也不声称修复位移全局最接近策略建议。

执行过程先将建议位置裁剪至边界，再投回以当前位置为中心、半径 $v_{\max}\tau$ 的速度圆。对距离不足的 UAV 对，沿连线方向各外推一半重叠量，随后再次检查边界和速度。该交替修复最多执行配置迭代数加二十轮，在主配置中合计四十轮。若仍有冲突，最终处理将涉及冲突的 UAV 回退至原位置悬停，并传播检查回退新引起的冲突，直到联合位置满足约束。初始位置由可行初始化保证，最终校验允许 10^{-3} m 数值容差。

边界与碰撞违例标记依据动作提出和修复过程记录，并不会因为最终位置已可行而清除。因此，动作修复检查离散时隙位置的几何可行性，违例惩罚仍指导策略减少对修复的依赖。例如，一架无人机在边界附近反复向外采样，虽会被截回边界，其奖励仍包含边界违例项。该检查针对相邻时隙记录的位置，不构成时隙内连续航迹避碰或飞行动力学可行性的证明。策略应学习合适的内部动作，而不把环境修复器当作无代价的控制替代。

3.2.4　请求执行先于轨迹移动

图 3.3 给出单时隙内的实现顺序。环境重置或上一时隙末生成当前请求，并按当前位置关联 UE、更新邻居和组装观测。两层策略从这一当前信息计算动作；进入环境步进后，先冻结移动前几何和缓存，解析整批服务请求的执行目标，预先计算最终节点负载，再执行服务请求和其他类型请求。此时所有上传、转发与回传速率均使用 $\mathbf{q}_u(t)$。

请求执行完成后，环境才应用已计算的上层轨迹动作，得到 $\mathbf{q}_u(t+1)$。随后计算奖励与指标，提交缓存变化、移动 UE、生成下一时隙请求和观测。因此，上层动作对当前奖励存在即时违例惩罚路径，对覆盖和链路质量的主要作用则出

现在下一时隙。这一时间关系可以概括为

$$\mathbf{b}(t) \longrightarrow \{T_m(t)\}, \qquad \mathbf{a}(t) \longrightarrow \mathbf{q}(t+1) \longrightarrow \mathcal{U}_m(t+1), \tag{3.8}$$

其中 $\mathbf{b}(t)$ 为请求级卸载分配。当前时隙的接纳由 $\mathcal{U}_m(t)$ 决定，不因本时隙随后移动而追溯改变。即使策略看见距 UAV 120 m 的未接纳用户，并移动到更近位置，该用户本时隙请求也不会被补处理。

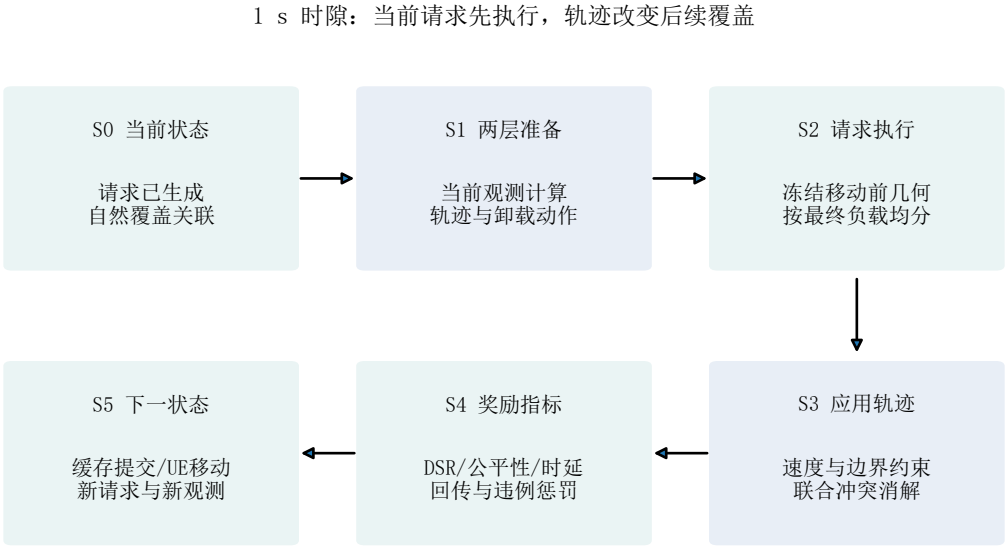


图 3.3　单时隙内的请求执行与轨迹应用时序。两层动作由当前观测计算；请求按移动前几何执行，上层轨迹动作随后应用并影响下一时隙覆盖

Figure 3.3　Decision and execution timeline within one slot, following the simulator implementation order

模型中的任务完成时延可以超过一个时隙，截止时间也可超过 1 s；但环境并未把未完成任务保留为跨时隙队列。它在本步计算每个当前请求的完整路径时延，并据此判断是否满足截止期，下一步生成新请求。于是，$T_m > \tau$ 表示该简化并发执行模型估计的完成时间超过时隙，不意味着后续状态保留了相同任务的剩余周期。全文的“负载”指当步最终分配的请求数，不能直接解释为持久队列长度。

3.3　请求、通信、缓存与计算模型

3.3.1　业务抽样与量纲约定

文件库含二十五类服务和五十个内容，共七十五个标识。总体流行度按 Zipf 分布生成，若标识 s 的流行度排名为 r_s，则

$$\Pr(s) = \frac{r_s^{-\beta}}{\sum_{k=1}^{75} r_k^{-\beta}}, \qquad \beta = 0.8. \tag{3.9}$$

排名与标识通过固定随机配置对应，不能假定服务编号越小就必然越热门。每个 UE 每步抽取标识、整数输入字节数 $L_m \in [10^6, 5\times10^6)$、截止时间 $D_m \in [0.65, 2.10]$ s 和优先级 $p_m \in \{1,2,3\}$。配对方法消耗完全相同的外生随机抽样序列。

当抽取的标识属于服务集合时形成计算服务请求，属于内容集合时形成内容请求。内容请求不使用抽取的服务输入大小，而使用文件库中固定的内容文件大小。服务请求的 L_m 是用户输入，B_s 是执行服务所需的文件或镜像，两者分别抽样并具有不同通信路径。若把 B_s 当成 L_m，将混淆上传数据与缓存回源数据，也会错误估计缓存收益。

服务 s 的每字节 CPU 周期数 $\omega_s \in [1200, 2800)$ 固定，所需总周期为

$$C_m = \omega_s L_m. \tag{3.10}$$

C_m 的单位是周期；L_m, B_s 的单位是字节；无线速率 R 的单位是比特每秒。因此，通信必须使用 $8L_m/R$ 或 $8B_s/R$，而计算使用 C_m/f，不再乘八。本文以十进制 10^6 字节解释表中的 MB，不以二进制 MiB 替代实现值。

UAV 的总算力 F_u 从 $\{40, 45, \cdots, 85\}$ GHz 取值，存储容量从 $\{120, 121, \cdots, 179\}$ MB 取值。在静态硬件随机种子（SEED = 42）下，五架 UAV 的固定算力向量与缓存容量向量分别为

$$\mathbf{F}_{\mathrm{UAV}} = [75,\ 60,\ 70,\ 85,\ 50]\,\mathrm{GHz}, \qquad \mathbf{S}_{\mathrm{cap}} = [158,\ 171,\ 148,\ 134,\ 162]\,\mathrm{MB}. \tag{3.11}$$

上述硬件、服务周期和文件大小由固定静态随机配置生成，不在每回合重抽。工作负载随机流用于请求，独立移动随机流用于位置与航点；训练随机性、请求随机性与硬件异质性属于不同层次，不应把三者都视为独立训练重复。

3.3.2　信道增益与带宽分配

无线链路使用自由空间平方距离衰减。对三维端点 $\mathbf{p}_i, \mathbf{p}_j$，有

$$g_{ij}(t) = \frac{G_0 g_0}{\|\mathbf{p}_i(t) - \mathbf{p}_j(t)\|^2 + \epsilon_0}, \qquad G_0 g_0 = 3.244132 \times 10^{-4}. \tag{3.12}$$

发射功率为 $P^{\mathrm{comm}} = 0.5\,\mathrm{W}$，噪声功率为 $\sigma^2 = 10^{-13}\,\mathrm{W}$，信噪比为 $P^{\mathrm{comm}} g_{ij}/\sigma^2$。对已关联用户，接入带宽在同一来源 UAV 的全部关联 UE 间等分：

$$R^{\mathrm{edge}}_{m,u}(t) = \frac{B^{\mathrm{edge}}}{n^{\mathrm{assoc}}_u(t)} \log_2\left(1 + \frac{P^{\mathrm{comm}} g_{m,u}(t)}{\sigma^2}\right), \qquad B^{\mathrm{edge}} = 40\,\mathrm{MHz}. \tag{3.13}$$

n^{assoc}_u 包含服务及内容请求的关联用户。该数与最终计算负载 N_u 不同：服务可以迁往其他 UAV 或 MBS，内容请求也不会加入 CPU 共享分母。关联为空时不存在需要计算接入速率的请求，不能在式中使用零分母。

机间与回传速率分别为

$$\begin{aligned} R_{u,v}^{\text{inter}} &= 20\times 10^{6}\log_2\left(1+P^{\text{comm}}g_{u,v}/\sigma^2\right), \\ R_{u,\text{M}}^{\text{bh}} &= 0.75\times 10^{6}\log_2\left(1+P^{\text{comm}}g_{u,\text{M}}/\sigma^2\right). \end{aligned} \tag{3.14}$$

这些链路在当前实现中使用整条配置带宽，不再按该链路传输数分割；也没有显式小尺度衰落、随机视距、同频干扰或额外回传排队项。噪声作为固定总功率参与各式，没有随接入子带宽重新缩放。本文分析的通信竞争主要来自接入关联数及有限回传速率，不能声称已模拟所有无线网络干扰。

以上公式显示覆盖增长与服务质量之间的一个结构性联系。在距离近似不变时，接纳更多用户令 n_u^{assoc} 增加，单用户接入速率按其倒数下降，输入上传时间近似成比例上升。同时，新增服务若在本机执行又会增大计算负载。因此，覆盖观测扩展可以提高接纳数，但并不自动保证新接纳请求按时完成。轨迹与卸载必须共同承担这一新增压力。

3.3.3 最终负载均分与三类服务路径

设当步已接纳服务集合为 $\mathcal{M}(t)$，请求 m 的来源为 $u=u_m(t)$、执行目标为 b_m。在解析全体目标后，UAV j 的最终负载为

$$N_j(\mathbf{b})=\sum_{m\in\mathcal{M}(t)}\mathbf{1}[b_m=j],\qquad f_{m,j}=F_j/N_j(\mathbf{b}),\quad b_m=j. \tag{3.15}$$

同一节点的本地任务和其他来源迁入任务共同计数；迁往 MBS 的任务不计入任何 UAV 的分母。对实际在该节点执行的请求必有 $N_j\geqslant 1$。先确定目标、再冻结 N_j 的顺序避免“先执行的请求获得更大算力”这一非物理的遍历次序偏差。

记时隙开始的缓存状态为 $h_{j,s}(t)\in\{0,1\}$，其中 s 为服务标识。为简化书写，定义上传时间 $U_m=8L_m/R_{m,u}^{\text{edge}}$、服务文件回源时间 $V_{j,s}=8B_s/R_{j,\text{M}}^{\text{bh}}$ 和协作输入转发时间 $I_{m,u,v}=8L_m/R_{u,v}^{\text{inter}}$。三条实际执行路径的时延为

$$\begin{aligned} T_m^{\text{local}} &= U_m+(1-h_{u,s})V_{u,s}+C_mN_u/F_u, \\ T_m^{\text{coop}}(v) &= U_m+I_{m,u,v}+(1-h_{v,s})V_{v,s}+C_mN_v/F_v, \\ T_m^{\text{MBS}} &= U_m+8L_m/R_{u,\text{M}}^{\text{bh}}+C_m/F_{\text{M}}. \end{aligned} \tag{3.16}$$

MBS 总算力为 $F_{\text{M}}=200\,\text{GHz}$，实现中每个 MBS 任务均使用该值，不按 MBS 当步任务数均分。三条路径都先经来源 UAV 接入；“本地”指接纳 UAV 执行，不指 UE 自身执行。当前模型没有服务结果下行时间，也没有把输入上传与 CPU 计算流水重叠。

把除计算外的路径时间记为 T_m^{comm}，当目标为 UAV j 时，截止期条件可写成

$$T_m\leqslant D_m\quad\Longleftrightarrow\quad N_j\leqslant\frac{F_j(D_m-T_m^{\text{comm}})}{C_m},\qquad D_m\geqslant T_m^{\text{comm}}. \tag{3.17}$$

右端是给定链路与缓存下该请求允许的节点负载预算，不是可独立分配给所有请求的容量。同节点请求具有不同 C_m, D_m，需要同时检查各自限制；当通信已用尽截止期时，增加 CPU 不能使该路径可行。该式解释了缓存命中和轨迹靠近的价值：它们通过压缩通信时间给计算释放截止期余量。

3.3.4　内容服务与缓存状态更新

内容请求只传输文件，不消耗服务 CPU 周期。对文件 s、来源 UAV u，本地、协作和 MBS 获取的完成时间分别为

$$\begin{aligned} T_m^{\text{content,local}} &= (1-h_{u,s})8B_s/R_{u,\text{M}}^{\text{bh}} + 8B_s/R_{m,u}^{\text{edge}}, \\ T_m^{\text{content,coop}} &= (1-h_{v,s})8B_s/R_{v,\text{M}}^{\text{bh}} + 8B_s/R_{v,u}^{\text{inter}} + 8B_s/R_{m,u}^{\text{edge}}, \\ T_m^{\text{content,MBS}} &= 8B_s/R_{u,\text{M}}^{\text{bh}} + 8B_s/R_{m,u}^{\text{edge}}. \end{aligned} \tag{3.18}$$

协作内容路径的输入方向是邻机向来源机发送文件，与服务请求由来源机转发输入的方向不同。

缓存命中使用时隙开始冻结的二值状态 $h_{j,s}(t)$。即便同一时隙较早执行的请求已取回文件，之后的请求也不会立即获得新的命中状态；当步多个相同缺失请求仍分别承担回源时延。实际取回的文件先进入待提交集合，在本步末统一尝试写入缓存。协作服务把镜像缓存到执行 UAV；MBS 执行服务不会顺带使来源 UAV 缓存该镜像。协作内容在邻机取回或持有文件，来源机也实际接收文件，因而可在相应节点形成待提交项。

每个 UAV 记录当步文件请求频次 $\nu_{u,s}(t)$，并以指数移动平均更新热度：

$$H_{u,s}(t+1) = \beta_c \nu_{u,s}(t) + (1-\beta_c) H_{u,s}(t), \qquad \beta_c = 0.75, \qquad \chi_{u,s}(t+1) = H_{u,s}(t+1)/B_s. \tag{3.19}$$

待提交文件按单位大小热度 $\chi_{u,s}$ 降序尝试放入剩余存储，平局按文件编号确定；这一阶段不任意替换已缓存文件。每五十步的周期刷新则重置缓存集合，按同一顺序重新填充，并在遇到首个无法放入的文件时停止。该规则是实现中的容量受限启发式，不是背包精确最优解；周期刷新也没有另计预取网络时延，不能据此声称已建立完整的缓存填充通信协议。

卸载决策前的邻机缓存只能用估计信念表示。启发式上下文对邻机文件命中的估计为

$$\widehat{h}_{v,s} = \left[1 + \exp\left(\gamma_c \left(r_s - \frac{S_v^{\text{cache}}}{\overline{B}}\right)\right)\right]^{-1}, \qquad \gamma_c = 0.5, \tag{3.20}$$

其中 S_v^{cache} 为容量、$\overline{B}$ 为文件平均大小。估计式可用于动作特征与质量筛选，实际执行式 (3.16) 使用冻结的真实二值缓存。把 $1-\widehat{h}$ 的期望回源代价写成实际实

现中的路径，会夸大模型的信息一致性，也会抹去预测与真实执行的差异。

3.3.5 公平性、时延与参数口径

环境的公平性统计覆盖全部请求类型。令 $K_m(t)$ 为至今用户被接纳且请求完成时延不超过时隙时长的次数，$c_m(t) = K_m(t)/t$。服务请求以其任务截止时间判断 DSR，但公平性使用统一的 τ 门槛。于是 Jain 指数为

$$J(t) = \begin{cases} \dfrac{(\sum_m c_m(t))^2}{M \sum_m c_m^2(t)}, & \sum_m c_m^2(t) > 0, \\ 0, & \sum_m c_m^2(t) = 0. \end{cases} \tag{3.21}$$

非零时有 $1/M \leqslant J \leqslant 1$。上界由柯西–施瓦茨不等式得到；下界在仅一个用户取得非零计数时达到。该指标反映累计成功服务的均衡，而非仅服务请求的公平性，也不是当前覆盖面积的均衡。

奖励中的时延汇总包含全部 UE：已关联 UE 采用实际请求时延，未关联 UE 记 $T^{\text{pen}} = 20\,\text{s}$ 的非服务惩罚。归一化分母为 MT^{pen}，而非实际服务请求数。这样，未接纳内容请求也会影响上层信号。DSR 和 MBS 依赖则仅以服务请求计数定义。并行记录这些口径可以避免把“时延变小”误解成所有服务任务的条件平均时延都下降。

表 3.1 主场景仿真参数

Table 3.1 Simulation parameters of the main setting

参数	取值	参数	取值
区域尺寸	700 m × 700 m	时隙时长 τ	1 s
UAV 数量 N / UE 数量 M	5 / 100	episode 步数 T	1000
UAV 高度 H	100 m	UAV 最大速度 $v_{\max}$	15 m/s
最小机间距 $d_{\min}$	200 m	UE 时隙位移上限	15 m
覆盖半径 R_c	100 m	感知半径 R_s	460 m
UAV 计算能力 $\mathbf{F}_{\text{UAV}}$	[75, 60, 70, 85, 50] GHz	UAV 缓存容量 $\mathbf{S}_{\text{cap}}$	[158, 171, 148, 134, 162] MB
MBS 计算能力	200 GHz	MBS 位置	(350, 350, 30) m
服务/内容数	25 / 50	Zipf 指数 β	0.8
请求输入大小	1 ∼ 5 MB	截止时间	0.65 ∼ 2.10 s
每字节周期数	1200 ∼ 2800	请求优先级	{1, 2, 3}
接入带宽 B^{edge}	40 MHz	机间带宽 B^{inter}	20 MHz
回传带宽 B^{backhaul}	0.75 MHz	发射功率 / 噪声	0.5 W / 10^{-13} W
热点数量 / 半径	2 / 100 m	热点内 UE 比例	85%

3.4　上层 Dec-POMDP 与注意力策略实现

3.4.1　分散观测与集中训练的职责

上层建模为 $\langle \mathcal{I}, \mathcal{S}, \{\mathcal{O}_u\}, \{\mathcal{Z}_u\}, P, \{r_u\}, \gamma \rangle$ 的 Dec-POMDP。$\mathcal{I}$ 是 UAV 智能体集合，状态含所有位置、缓存、请求和统计量，局部观测由感知范围与固定槽位决定，$\mathcal{Z}_u = \mathbb{R}^2$ 是原始随机动作空间。状态转移同时受卸载执行、轨迹修复、用户移动和下一请求生成影响。不同 UAV 的移动会改变联合几何及下一步各自接纳集合，而非显式改变未建模的无线干扰。

共享策略以局部观测执行，集中价值网络在训练时看到同一时刻所有 UAV 的局部观测联合。这里的集中信息并不是任意完整物理状态：实现中的价值调用使用联合观测张量，接口传入的另一个状态参数未作为额外特权输入。若某未接纳 UE 不在任何局部槽位中，价值网络也不会自动恢复其详细请求。CTDE 可以利用联合信息减小价值估计的不确定性，但不能弥补观测生成阶段的全部信息缺失。

3.4.2　定长观测与两个不同容量

自身观测含归一化水平位置与七十五维缓存占用，共七十七维；邻机至多四槽，每槽含按 R_s 归一化的二维相对位置；UE 至多三十槽，每槽为二维相对位置和五个业务特征。单槽可写成

$$\mathbf{x}_{u,m} = \left[\frac{\mathbf{w}_m - \mathbf{q}_u}{700},\ \mathrm{type}_m,\ \frac{L_m}{5\times 10^6},\ \frac{s_m}{75},\ \frac{D_m}{2.10},\ \frac{p_m}{3} \right], \tag{3.22}$$

其中类型、大小、编号按实现使用相应请求字段，非服务请求的截止时间和优先级置零。三组拼接维度为 $77 + 4\times 2 + 30\times 7 = 295$。空槽全零，按槽内特征绝对值之和大于 10^{-5} 判定非空，并生成注意力掩码。

表 3.2　上层单智能体观测构成（原观测；扩展观测见第 3.5 节）

Table 3.2　Composition of the upper-layer single-agent observation

观测组	内容	维度	说明
自身状态	二维位置、缓存向量	77	2 + 75 维
邻居 UAV	相对位置	$4\times 2 = 8$	感知范围内至多 4 架
UE 槽位	相对位置、请求特征	$30\times 7 = 210$	固定槽位、零填充加掩码
合计		295	

三十槽是上层可见信息容量，不是下层能接纳或执行的服务任务上限。上层自身关联 UE 槽位按与 UAV u 的水平欧氏距离升序填入（平局按 UE 编号升序），在主场景五机均匀分担与最小机间距约束下，单机当步实际关联用户

数远低于三十槽上限，确认实验中未发生自身已关联用户的截断丢失。当前主配置的下层为每 UAV 预留 $M_{\max}^{\text{low}} = 100$ 个请求槽（并在环境构造时通过断言 $|\mathcal{A}_u^{\text{srv}}(t)| \leqslant M_{\max}^{\text{low}}$ 保证零截断），每槽十四维，再加五维来源特征，拼接为 $\mathbf{o}_u^{\text{offload}} = [\mathbf{o}_u^{\text{low}}, \mathbf{r}_{u,1}, \cdots, \mathbf{r}_{u,100}] \in \mathbb{R}^{1405}$。具体而言，五维来源特征与第 m 个已接纳服务请求的十四维槽特征分别为

$$\begin{aligned}
\mathbf{o}_u^{\text{low}} &= \left[\frac{x_u}{700}, \frac{y_u}{700}, \frac{|\mathcal{A}_u^{\text{srv}}(t)|}{100}, \frac{|\mathcal{N}_u(t)|}{4}, \frac{\log_{10}\max(R_{u,\text{M}}^{\text{bh}}, \epsilon_0)}{10}\right] \in \mathbb{R}^5, \\
\mathbf{r}_{u,m} &= \left[1, \frac{L_m}{5\times 10^6}, \frac{s_m}{25}, \frac{D_m}{2.10}, \frac{p_m}{3}, h_{u,s_m}, \mathbf{1}[\mathcal{N}_u^{\text{coop}} \neq \varnothing], \frac{|\mathcal{A}_u^{\text{srv}}(t)|}{100}, \right. \\
&\qquad \left. \tilde{\tau}_{m,\text{loc}}, \tilde{\tau}_{m,\text{coop}}, \tilde{\tau}_{m,\text{MBS}}, \frac{\max_{v\in\mathcal{N}_u} \hat{f}_v}{F_{\max}^{\text{UAV}}}, \frac{x_m - x_u}{700}, \frac{y_m - y_u}{700}\right] \in \mathbb{R}^{14},
\end{aligned} \tag{3.23}$$

其中 $\tilde{\tau}_{m,\cdot} = \text{clip}(\widehat{T}_{m,\cdot}/D_m, 0, 10)/10$ 为截断归一化的三类路径预测时延与截止期比值，$\hat{f}_v = F_v/(|\mathcal{A}_v^{\text{srv}}(t)| + 1)$ 为邻机边际可用算力份额，$F_{\max}^{\text{UAV}} = 85\,\text{GHz}$。下层卸载动作空间含七个离散编号，分别为本地执行（0）、MBS 卸载（1）和五架 UAV 的协作目标（$2 + v$），其中自身协作编号 $2 + u$ 被硬掩码屏蔽。超过上层三十槽的真实已接纳请求仍可进入下层执行，不会因为上层看不到而被丢弃。把两个容量混为一谈会高估观测覆盖，也会低估批量竞争。

固定槽位保证同一配置下的输入形状一致，注意力聚合能适应实际非空槽数变化，但不能据此声称输入维度与任意 UAV/UE 数量无关。节点数改变会修改邻机容量，UE 数较小时也可能改变上层槽数，下层容量随 UE 总数配置变化。跨规模泛化需要相应模型和训练协议的验证，不能从网络采用注意力直接推得。

3.4.3 共享奖励及归一化

定义当步全局质量项

$$r^{\text{shared}} = W_{\text{fair}} J - W_{\text{lat}} \bar{T} + W_{\text{dsr}} S/G - 0.5\rho_{\text{MBS}}, \tag{3.24}$$

其中 $\bar{T} = \sum_m T_m^{\text{metric}}/(20M + \epsilon_0)$，$\rho_{\text{MBS}}$ 是回传 MBS 的服务请求数除以 G。权重为 $1, 1, 1$，依次对应公平、时延和 DSR。归一化参考是尺度设置而非硬上界。

每架 UAV 的最终奖励还包含自身违例惩罚和统一缩放：

$$r_u = 0.1\left[r^{\text{shared}} - 10\mathbf{1}[\text{boundary}_u] - 10\mathbf{1}[\text{collision}_u]\right]. \tag{3.25}$$

因局部违例不同，各机奖励不必完全相同。质量项鼓励联合服务，局部惩罚则把建议动作的不可行性归因给相关 UAV。奖励系数在候选与对照间固定，本章不把权重搜索作为观测方法的性能来源。

奖励与论文主指标也不等价。较高奖励可能来自公平性或未服务惩罚改善，

而不必来自 DSR；反之，扩大接纳可能降低未服务时延惩罚，却让已接纳请求竞争更激烈。因此，实验同时报告 DSR、两个分解因子、系统时延和公平性，不能用奖励曲线替代截止期表现。这种区分也为第五章研究服务反馈与卸载质量的耦合提供了依据。

3.4.4　多头交叉注意力的实际前向计算

三类原始特征分别通过线性层、层归一化和 ReLU 嵌入到六十四维。以自身嵌入 $\mathbf{e}_u$ 为查询，分别对邻机与 UE 集合执行交叉注意力。每组注意力有八个头，每头维度 $d_h = 64/8 = 8$。对于第 h 个头和非空目标 i，有

$$\mathbf{Q}_u^h = \mathbf{e}_u W_Q^h, \quad \mathbf{K}_i^h = \mathbf{e}_i W_K^h, \quad \mathbf{V}_i^h = \mathbf{e}_i W_V^h, \quad a_{u,i}^h = \frac{\exp(\mathbf{Q}_u^h (\mathbf{K}_i^h)^\top / \sqrt{8})}{\sum_{k \in \mathcal{V}_u} \exp(\mathbf{Q}_u^h (\mathbf{K}_k^h)^\top / \sqrt{8})}. \tag{3.26}$$

$\mathcal{V}_u$ 为当前非空槽集合，空槽在 softmax 前被屏蔽。前向所用的缩放是每头维度的平方根 $\sqrt{8}$，不是总嵌入维度的平方根 $\sqrt{64}$。若需要解释注意力权重，提取过程应复现这一实际前向缩放与掩码，不能用另一个温度的事后权重当作策略真正使用的权重。

每头上下文为 $\mathbf{c}_u^h = \sum_i a_{u,i}^h \mathbf{V}_i^h$，八头拼接再经输出投影。自身、邻机上下文和 UE 上下文拼成一百九十二维，经 $192 \to 128 \to 64$ 的融合网络得到策略特征。邻机聚合为轨迹协调提供相对几何线索，UE 聚合为需求筛选提供输入；其权重反映模型内部聚合，不自动等价于用户重要性的因果解释。目标全为空时实现对上下文作特殊处理，输出投影仍可有可学习偏置，故不能笼统断言最终模块特征恒为零。

集中价值网络的处理与 actor 不同。它先把每架 UAV 的完整二百九十五维观测编码为六十四维嵌入，再在联合观测上计算智能体间注意力，屏蔽自身对自身的注意项。自身嵌入与其他 UAV 上下文拼接为一百二十八维，经价值头输出每架 UAV 的标量估计 $V_{\phi,u}(\mathbf{o})$。这种联合评价利用其他智能体的信息解释共同奖励，而执行时 actor 仍只需自身局部观测。共享参数提升样本利用率，但五架 UAV 在同一环境内的轨迹相关性不会因此变成五次独立实验。

3.4.5　正态策略、原始动作概率与 PPO

策略头给出 $\boldsymbol{\mu}_\theta(o_u) = \tanh(W\mathbf{f}_u + \mathbf{b})$，以及两个可学习、与状态无关的对数标准差。对数标准差限制在 $[-20, 2]$，$\boldsymbol{\sigma} = \exp(\mathrm{clip}(\log \boldsymbol{\sigma}, -20, 2))$。原始二维动作采

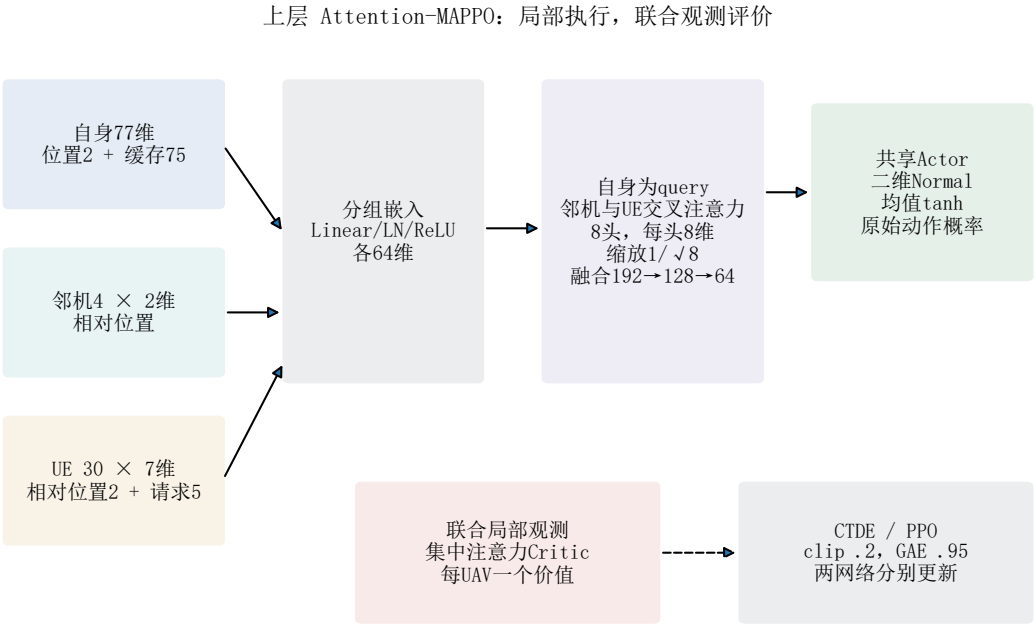


图 3.4　上层 Attention-MAPPO 的网络与训练结构。实线为前向信息流，虚线为仅训练时使用的集中式评价与参数更新；执行阶段每架 UAV 仅用自身局部观测

Figure 3.4　Network and training structure of the upper-layer Attention-MAPPO

用独立正态分布：

$$\begin{aligned}\mathbf{z}_u &\sim \mathcal{N}(\boldsymbol{\mu}_\theta(o_u), \mathrm{diag}(\boldsymbol{\sigma}^2)),\\ \log \pi_\theta(\mathbf{z}_u \mid o_u) &= -\sum_{k=1}^{2}\left[\frac{(z_{u,k}-\mu_{u,k})^2}{2\sigma_k^2} + \log\sigma_k + \frac{1}{2}\log(2\pi)\right].\end{aligned} \tag{3.27}$$

均值的 tanh 不会把随机样本限制在 $[-1,1]$。这是普通正态策略加执行裁剪，不是对采样变量整体作 tanh 变换的压缩正态策略。因此，缓冲区保留原始 $\mathbf{z}_u$ 和对应原始对数概率，PPO 比率在这一空间计算；不应添加压缩正态的雅可比项，也不应拿裁剪后的动作代替原始动作重算概率。

将裁剪与几何修复视为确定性环境映射，可以得到一个以原始动作驱动的有效决策过程。多个原始动作可能映射到同一执行位移，故饱和区的探索效率可能较低，但这不改变实现中的概率定义。确定性评估使用均值并裁剪后执行，结果对应不同于训练随机采样的评估策略，实验协议应固定是否启用探索。

对采集的每个智能体序列，用终止掩码 d_t 计算时序差分与 GAE：

$$\delta_{u,t} = r_{u,t} + \gamma(1-d_t)V_{\phi,u}(\mathbf{o}_{t+1}) - V_{\phi,u}(\mathbf{o}_t), \qquad \widehat{A}_{u,t} = \delta_{u,t} + \gamma\lambda_{\mathrm{GAE}}(1-d_t)\widehat{A}_{u,t+1}. \tag{3.28}$$

$\gamma = 0.99$、$\lambda_{\mathrm{GAE}} = 0.95$。递推展开得到后续 TD 残差的折扣和，终止位置不向下一回合引导。缓冲区先形成回报目标 $\widehat{R}_{u,t} = \widehat{A}^{\mathrm{raw}}_{u,t} + V^{\mathrm{old}}_{u,t}$，再对 actor 使用的优势作整体均值和标准差归一化；若先归一化优势再构造回报，将改变 critic 的数值目标。

记新旧原始动作概率比为 $\rho_{u,t}=\exp(\log\pi_\theta(\mathbf{z}_{u,t}\mid o_{u,t})-\log\pi_{\theta_{\text{old}}}(\mathbf{z}_{u,t}\mid o_{u,t}))$，裁剪替代目标为

$$L^{\text{CLIP}}=\widehat{\mathbb{E}}_{u,t}\left[\min\left(\rho_{u,t}\widehat{A}_{u,t},\,\text{clip}(\rho_{u,t},1-\varepsilon,1+\varepsilon)\widehat{A}_{u,t}\right)\right],\qquad \varepsilon=0.2. \tag{3.29}$$

正优势样本限制过度增大概率所能获得的收益，负优势样本限制过度减小概率所能获得的收益。裁剪作用于目标函数，不是强制所有更新后比率都在区间内，也不是硬 KL 约束。因此，本文采用 PPO 作为稳定训练组件，不声称由该目标证明每次更新的真实回报单调提高。

actor 最小化 $-L^{\text{CLIP}}-\beta_H\overline{H}$，$\beta_H=0.005$。实现将正态熵在批次及两个动作坐标上取平均，$\overline{H}=\frac{1}{2}\sum_{k=1}^{2}\frac{1}{2}\log(2\pi e\sigma_k^2)$；对数概率则在两个坐标上求和，二者约定不同。critic 使用裁剪值损失：

$$\begin{aligned}V_u^{\text{clip}}&=V_u^{\text{old}}+\text{clip}(V_{\phi,u}-V_u^{\text{old}},-\varepsilon,\varepsilon),\\ L_V&=\frac{1}{2}\widehat{\mathbb{E}}_{u,t}\max\left[(V_{\phi,u}-\widehat{R}_{u,t})^2,(V_u^{\text{clip}}-\widehat{R}_{u,t})^2\right].\end{aligned} \tag{3.30}$$

两网络分别使用 Adam，学习率均为 3×10^{-4}，梯度范数上限为 0.5。每次收集一千步，以二百五十六小批量更新八轮，超参数见表 3.3。

表 3.3　上层 MAPPO 主要超参数

Table 3.3　Main hyperparameters of the upper-layer MAPPO

超参数	取值	超参数	取值
折扣因子 γ	0.99	GAE 系数 λ_{GAE}	0.95
裁剪系数 ε	0.2	熵系数	0.005
演员/评论家学习率	3×10^{-4}	梯度范数截断	0.5
rollout 长度	1000 步	更新轮数	8
小批量大小	256	注意力头数 / 嵌入维	8 / 64

本章的覆盖观测候选与强基线均采用无注意力请求级 MAPPO 下层，两层参数独立、在各自方法内训练。在当步存在已接纳服务请求（$A_t>0$）时，下层共享团队奖励 r_t^{low} 与每轮 rollout 结束后的自适应违例乘子更新定义为

$$\begin{aligned}r_t^{\text{low}}&=w_{\text{dsr}}^{\text{low}}\frac{S_t}{A_t}-w_{\text{lat}}^{\text{low}}\frac{\sum_{m\in\mathcal{M}(t)}T_m(t)}{A_tT^{\text{pen}}}-w_{\text{mbs}}^{\text{low}}\rho_{\text{MBS},t}^{\text{low}}\\&\quad-\lambda_{\text{dsr}}\max\left(0,\text{DSR}_{\text{target}}^{\text{low}}-\frac{S_t}{A_t}\right)-\lambda_{\text{mbs}}\max\left(0,\rho_{\text{MBS},t}^{\text{low}}-\eta_{\text{MBS}}^{\max}\right),\\ \lambda_{\text{dsr}}&\leftarrow\text{clip}\big(\lambda_{\text{dsr}}+\alpha_\lambda\bar{v}_{\text{dsr}},\,0,\,\lambda_{\max}\big),\qquad \lambda_{\text{mbs}}\leftarrow\text{clip}\big(\lambda_{\text{mbs}}+\alpha_\lambda\bar{v}_{\text{mbs}},\,0,\,\lambda_{\max}\big),\end{aligned} \tag{3.31}$$

其中 $w_{\text{dsr}}^{\text{low}}=3.40$，$w_{\text{lat}}^{\text{low}}=4.0$，$w_{\text{mbs}}^{\text{low}}=0.35$，$\rho_{\text{MBS},t}^{\text{low}}$ 为已接纳服务请求中卸载至 MBS 的比例，$\text{DSR}_{\text{target}}^{\text{low}}=0.18$，$\eta_{\text{MBS}}^{\max}=0.03$，$\alpha_\lambda=0.1$，$\lambda_{\max}=10.0$，$\bar{v}_{\text{dsr}},\bar{v}_{\text{mbs}}$ 为单个 rollout 窗口内的平均违例量（当 $A_t=0$ 时 $r_t^{\text{low}}=0$）。下层的质量掩码使

算法 3.1　上层 Attention-MAPPO 的概率与执行一致训练流程

Input: 自然覆盖环境、训练种子、回合数 E、当前下层策略
Output: 共享 actor 参数 θ 与集中 critic 参数 ϕ

初始化网络、优化器和缓冲区;
for $e \leftarrow 1$ **to** E **do**
  重置环境，生成当前请求、接纳关系与观测 $\mathbf{o}_0$;
  for $t \leftarrow 0$ **to** 999 **do**
    从局部观测采样原始动作 $\mathbf{z}_{u,t}$，保存其对数概率;
    用联合观测计算 $V_{\phi,u}$，下层计算当前请求分配;
    将 $\mathrm{clip}(\mathbf{z}_{u,t}, -1, 1)$ 与分配交给环境;
    环境先执行请求，再修复并应用位移，结算奖励并生成下一观测;
    保存原始动作、旧值、奖励、终止掩码与观测;
  end
  依据式 (3.28) 形成原始优势及回报，再归一化 actor 优势;
  for $k \leftarrow 1$ **to** 8 **do**
    以小批量 256 优化式 (3.29) 及式 (3.30);
  end
end

用估计时延和算力份额筛选协作目标，允许估计协作时延达到截止期的 1.50 倍、相对最佳本地或 MBS 时延的 1.35 倍，并要求邻机算力份额比不低于 0.25；本地作为兜底，不保证按时完成。其违例驱动自适应惩罚属于启发式乘子调节，不能视为已证明收敛的原始–对偶算法。第五章转向独立的动态排队服务协议时，进一步按其跨时隙进度保留与规划蒸馏框架说明在线决策与可行性机制，本章不把当前单时隙下层配置替代为未经该批次验证的新方法。

3.5　预接纳需求观测设计

3.5.1　缺失需求与局部可辨识性

原观测把三十个 UE 槽全部用于已经关联到自身的用户。若存在两个物理状态，其已关联用户、自身位置、缓存和邻机相同，而未覆盖用户分布不同，则原观测也相同。任何仅依赖该观测的确定性 actor 都会给出相同动作，随机 actor 也只能给出相同分布。由此可知，原观测不能针对这两个状态作需求方向上的区分；这种状态混叠是由输入定义造成的，不是优化器未充分训练所能彻底消除。

预接纳观测补入感知范围内但尚未被任何 UAV 接纳的用户，使策略在满足容量限制时区分不同未服务需求分布。它提供的是当前位置和请求信息，作用于下一时隙移动。由于下一步用户继续移动、请求重新抽样，上层不应被理解为准确追赶同一个任务；当前未接纳需求同时也是用户空间位置与近期业务分布的线索。确认实验检验的正是这种当前信息是否有助于长期接纳与服务。

3.5.2　确定性槽位填充与容量约束

扩展模式首先按距离升序保留自身已关联 UE，距离平局按用户编号确定；随后按距离升序补入 460 m 内尚未被任何 UAV 接纳的 UE，直到三十槽用满。已由其他 UAV 接纳的用户不作为未接纳需求重复补入。若已有三十名自身关联用户，则扩展模式没有额外槽位；若两组用户合计少于三十，则其余补零。该规则保持维度、特征归一化、掩码、actor 和 critic 完全相同，仅改变进入固定输入的用户集合。

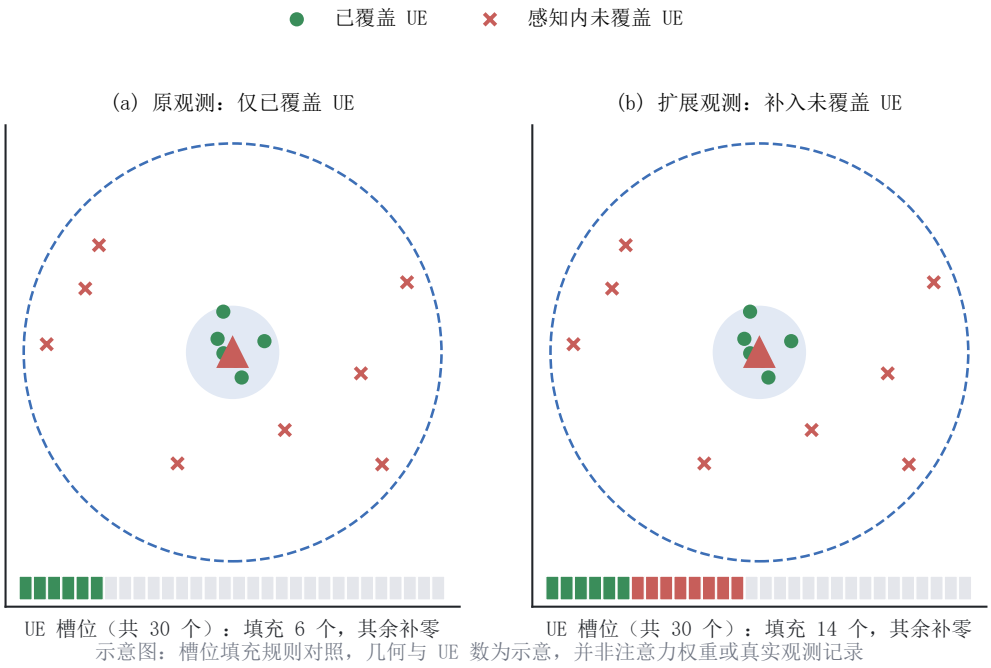


图 3.5　原观测与扩展观测的槽位填充规则对照（同一几何示意）。原观测仅含已覆盖 UE，扩展观测以距离顺序补入感知范围内尚未接纳的 UE；图为规则示意，非注意力权重或真实记录

Figure 3.5　Slot-filling rules of the original and the extended observation under the same illustrative geometry

以 $\mathcal{A}_u$ 标记自身关联用户、$\mathcal{V}_u^{\mathrm{un}}$ 标记感知范围内未接纳用户，槽位列表可表示为

$$\mathcal{L}_u = \mathrm{first}_{30}\left[\mathrm{sort}_{(d,\mathrm{id})}(\mathcal{A}_u) \,\|\, \mathrm{sort}_{(d,\mathrm{id})}(\mathcal{V}_u^{\mathrm{un}})\right]. \tag{3.32}$$

该排序服务于可重复输入与对现有功能的保护：原来用于自身业务的信息先进入，未覆盖信息使用剩余容量。它不意味着距离排序已经最优，也不保证截止期更紧的用户优先可见。服务优先、信息裁剪等其他填充策略需要独立协议，本章不把它们的探索结果与当前确认数据混为同一方法。

一个构造的槽位例子可以说明改动范围。若当前自身关联十二名 UE、感知范围另有二十五名未接纳 UE，则原观测含十二个真实槽和十八个空槽；扩展观测仍保留原十二名，并补入最近十八名未接纳 UE，其余七名仍不可见。下层只

处理自然接纳的真实服务集合，不会把新增十八个观测槽直接变成十八项卸载动作。若次步移动使部分用户进入服务圆，只有那时生成且被接纳的请求才能执行。

3.5.3 从观测信息到可实现收益

本章扩展观测假定决策前可获得未接纳 UE 的位置与当前请求字段，并在确认协议中没有加入这些字段上报的额外时延与丢失。因此，本章可检验“在这些信息可用时，扩展输入能否改善服务”，不能单独证明在任何现实网络中无代价获得这些信息。感知半径是仿真中的可见性假设，不能直接等同于经实测验证的请求广播范围。

输入维度不变也不等于信息预算相同。基线的空槽含零信息，候选的非空槽含业务信息，尽管二者网络都接收二百九十五个数值。评价结构优势时需要把双方提供的信息统一；评价信息作用时则应保持网络与训练配置相同。本章后一种对照支持观测设计的价值，第五章在独立的动态排队协议中评价候选级联合策略的信息条件与学习机制，不能将本章相同网络下的结果写成注意力胜过所有同信息模型。

对信息延迟的逻辑影响也可以由时序分析得到。如果需求字段来自 $t-\ell$ 时刻，位置误差与业务更新都可能降低其对下一覆盖的指示作用；但是否使性能下降、下降多少，需要真实延迟或缺失实验，不能从观察半径直接计算。当前覆盖确认主要说明理想当前信息的作用，为随后研究信息可得性、同信息对照和在线质量反馈提供依据。

3.6 瓶颈诊断、独立确认与机制解释

3.6.1 由失败来源确定干预方向

自然覆盖基准全量实验使用五个训练种子和十个工作负载。主场景的原完整双注意力方法 DSR 为 0.2390，无注意力下层变体为 0.2507，差值为 -1.16 个百分点，配对交叉 bootstrap 的 95% 区间为 $[-1.99, -0.43]$。这一结果使后续覆盖实验采用后者作为强基线，而不把下层注意力预设为优势。它属于该批次配置下的比较，不意味着注意力在一切卸载问题中无效，也不替代第五章动态排队方法的评价。

对强基线二十五个完整评估单元的描述性诊断发现，DSR 为 0.2396，未覆盖请求占全部实际生成服务请求的 52.13%，占失败请求的 68.55%。图 3.6 依式 (3.2) 把结果分为成功、已接纳超时和未接纳三类。该计数显示覆盖是值得优先干预的

瓶颈，而非把所有失败都归为卸载策略错误。描述性比例只刻画该诊断批次，不能作为改变某一组件必然有效的因果证明。

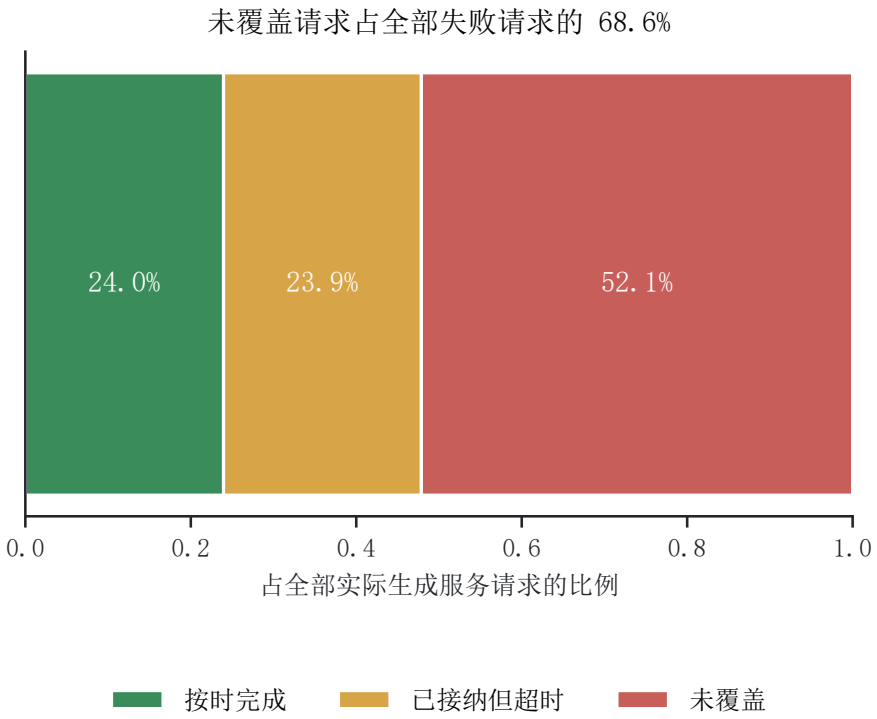


图 3.6　主场景实际生成服务请求的结果构成（下层无注意力强基线，瓶颈诊断批次，25 个评估单元的计数汇总）

Figure 3.6　Outcome composition of generated service requests in the main setting (strong baseline, diagnostic batch)

同一诊断在五十个冻结快照上用双步质量掩码局部搜索检验卸载余量，成功数由 339 增至 396，在 1540 个快照生成请求分母下提升 3.70 个百分点。冻结快照搜索并不回写环境，且采用与在线学习不同的计算预算，因此该结果不能充作长期 DSR 提升或可部署策略上界。它给出的补充判断是：覆盖之外仍有分配质量余量，但改善质量需要跨请求协同重评估。第三章优先处理需求不可见，第四章专门分析固定请求下的整体分配，第五章再研究跨时隙排队协同。

3.6.2　探索与确认使用不同种子

覆盖观测实验采用两阶段协议。探索阶段为五个训练种子乘五个工作负载，候选和强基线共十次训练、五十个评估任务、三百个回合。其目的在于筛选观测方向，不能把筛选后最高结果当作独立确认。确认阶段使用全新的十个训练种子和五个工作负载，两方法共二十次训练、一百个评估任务和六百个评估回合，每个检查点在每个工作负载上运行六回合。探索与确认的差别见表 3.4。

一百个评估任务组成五十对方法配对单元，而不是一百对。对每个训练种子 k，先平均五个工作负载的 DSR 差值 $d_{k,w}$，得到 $d_k = 5^{-1}\sum_w d_{k,w}$；十个 d_k 才是

表 3.4　覆盖观测两阶段实验协议

Table 3.4　Two-stage protocol of the coverage-observation experiments

协议要素	探索性 pilot	独立确认
训练种子	5 个（探索批次）	10 个（全新）
工作负载种子	5 个	5 个（全新）
每检查点评估	5 工作负载 × 6 episode	5 工作负载 × 6 episode
训练/评估规模	10 次训练 / 50 任务	20 次训练 / 100 任务 / 600 episode
方法差异	仅上层观测槽位填充规则；下层配置相同、分别训练	
统计单位	训练种子；工作负载配对	
结论用途	方向筛选，不独立支撑结论	本章主证据

主检验中的独立训练重复。工作负载、回合和单个请求嵌套于训练结果，不能把它们当成额外训练种子扩大样本量。对训练种子差值使用配对 t 区间：

$$\bar{d} \pm t_{0.975,9}\frac{s_d}{\sqrt{10}}, \qquad s_d^2 = \frac{1}{9}\sum_{k=1}^{10}(d_k - \bar{d})^2. \tag{3.33}$$

同时归档交叉重采样作为另一种不确定性评估，但正文主效应沿用预定的训练种子配对口径，不择取数值更有利的区间。

配对评估共享外生请求与移动随机流，有助于减少工作负载难度差异；两方法则各自训练，不能共享一个模型后仅在评估中修改观测来替代学习差异。代码内容摘要、协议与原始计数用于确认对应来源，任务验收通过说明运行和分析完整，不自动赋予主张更宽的适用范围。

3.6.3　确认结果及训练曲线的用途

探索阶段 DSR 由 0.2396 提升至 0.2738，差值为 +3.43 个百分点，交叉 bootstrap 95% 区间为 [+1.20, +5.76]，由此进入独立确认。确认结果见表 3.5：等权评估单元平均 DSR 从 0.2450 提高至 0.2735，差值 +2.85 个百分点，训练种子配对 95% 区间为 [+1.65, +4.06]（交叉 bootstrap 95% 区间为 [+1.49, +3.98]）。十个训练种子中九个差值为正，五十个配对单元中四十二个为正。这说明结果不仅由单一训练种子推动，在多组独立训练重复上也具有一致的改善方向。

为说明不同汇总方式的量级，该确认批次中基线与候选在配对外生流下累计生成的服务请求数完全相同，均为 9,805,180 个；基线累计接纳 4,671,766 个、按时完成 2,401,441 个，候选累计接纳 5,636,432 个、按时完成 2,683,032 个。合并计数所得 DSR 分别为 0.24492 与 0.27363（差值 +2.87 个百分点），与表中等权均值高度一致。主报告保留表中预定均值及配对区间；合并计数在此仅用于核对分母一致性与口径，并不增加一次独立证据。

图 3.7 展示十个训练种子的均值和标准差，用于观察学习过程的走势与跨种

表 3.5　独立确认实验的主场景结果（10 个新训练种子 × 5 个新工作负载）

Table 3.5　Main-setting results of the independent confirmation

指标	强基线（原观测）	候选（扩展观测）	配对差值 [95% 区间]
DSR S/G	0.2450	0.2735	+0.0285 [+0.0165,+0.0406][a]
接纳率 A/G	0.4769	0.5751	+0.0982 [+0.0538,+0.1426][a]
接纳后按时完成率 S/A	0.5170	0.4786	−0.0385 [−0.0804,+0.0035][a]
每生成服务请求惩罚系统时延 / s	33.73	28.15	−5.58 [−8.03,−3.12][a]
Jain 公平性	0.8665	0.9210	+0.0544 [+0.0361,+0.0728][a]

[a] 以训练种子为独立单位的配对 t 区间。DSR 差值为本章主结论；接纳后完成率与辅助指标用于机制分析，未单独作多重比较校正。先在每评估单元内汇总请求计数求比例，再平均 50 个单元；由于跨评估单元存在协方差项（式 (3.3)），单元平均比值满足 $\bar{\alpha}\bar{\eta} = 0.4769 \times 0.5170 = 0.2466 \neq 0.2450$（强基线）及 $0.5751 \times 0.4786 = 0.2752 \neq 0.2735$（候选），而在全集累计计数下乘积恒等式严格成立（见正文计数核对）。

子波动。标准差带不是均值置信区间，训练奖励也不是独立测试表现。曲线可提示观测改动在学习过程中持续产生差异，但不能仅凭平滑或末段平台宣称理论收敛、排除训练不稳定，或证明部署后性能保证。主结论依赖固定检查点后的配对评估，而非挑选曲线中最高的一段。

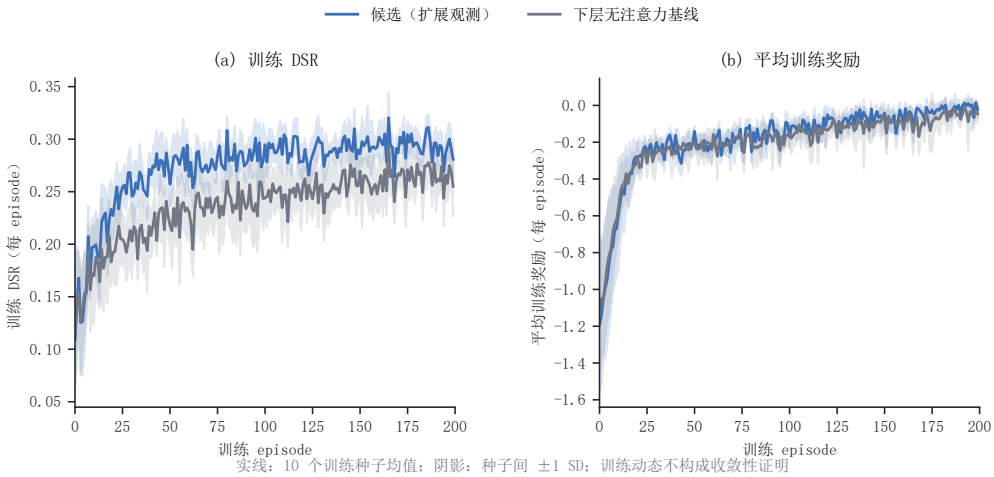


图 3.7　独立确认实验的训练曲线（10 个训练种子的均值 ± 标准差）：(a) 训练 DSR；(b) 平均训练奖励

Figure 3.7　Training curves of the independent confirmation (mean ± std over ten training seeds)

3.6.4　接纳扩展与接纳后质量的联合解释

候选的平均接纳率从 0.4769 提高至 0.5751，增加 9.82 个百分点（十个训练种子差值均为正，配对 t 区间为 $[+5.38, +14.26]$ 个百分点）；接纳后按时完成率从 0.5170 变为 0.4786，差值为 −3.85 个百分点，训练种子配对区间为 $[-8.04, +0.35]$ 个百分点。图 3.9 按训练种子汇总五个工作负载展示两项指标，说明接纳扩大与条件质量变化方向不同。条件质量变化未单独作多重比较校正，应作为机制分析

均值 +2.85 个百分点，配对 t 95% CI [1.65, 4.06]；9/10 种子为正

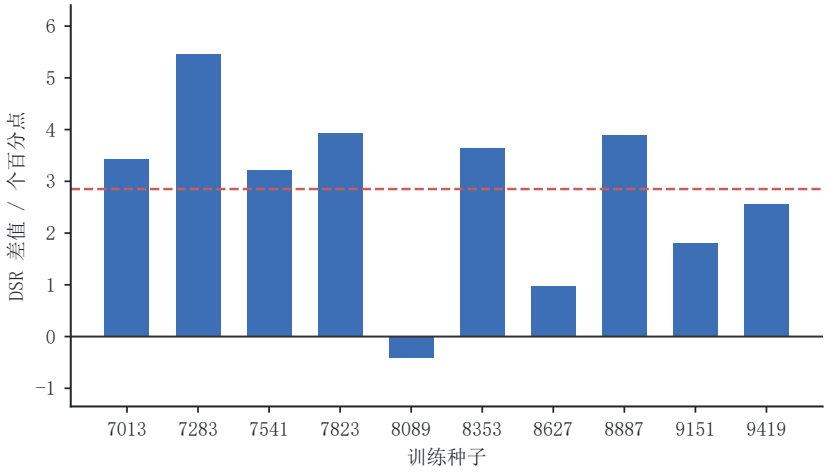
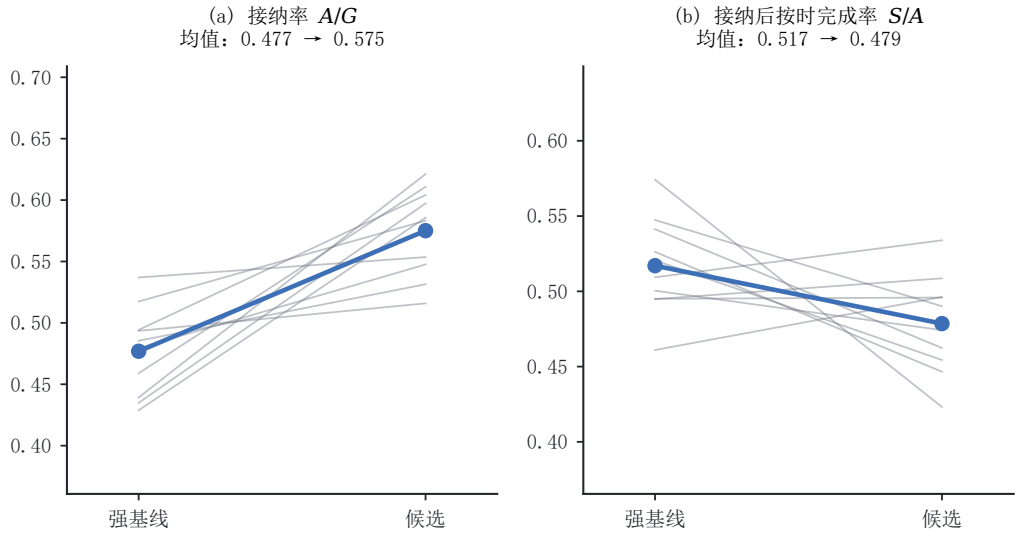


图 3.8　独立确认实验中候选相对强基线的逐训练种子 DSR 差值（每个种子为 5 个工作负载差值的平均；区间为配对 t 95% 区间）

Figure 3.8　Per-training-seed paired DSR differences of the candidate against the strong baseline

指标解释。



灰线：10 个训练种子各自的配对连接（每种取 5 个工作负载均值）；蓝线：种子均值

图 3.9　确认实验中接纳率与接纳后按时完成率的配对比较（每点为一个训练种子下五个配对工作负载的均值）。两因子反向变化，DSR 增益来自接纳因子

Figure 3.9　Paired comparison of the admission fraction and the deadline satisfaction among admitted requests

按式 (3.4) 在五十个配对单元内分解并平均，接纳变化项贡献约 +4.87 个百分点，接纳后质量变化项贡献约 −2.02 个百分点，两者合计 +2.85 个百分点。该结果比直接相乘表中均值更准确地说明端到端增益：扩大接纳带来的成功机会超过了条件质量稀释的抵消。它不意味着每个新增请求都成功，也不意味着每个原有请求的时延都变差，后者需要逐请求反事实匹配，而当前方法运行中的轨迹

和批量不同。

这种结果与系统模型相容。更多 UE 进入覆盖后，接入带宽被更多关联用户分摊，服务批次可能增加，缓存缺失和有限回传也可能成为更明显的瓶颈。上层把需求送入系统，下层还要在最终负载竞争下安排执行位置。因此，本章所建立的观测优势是增加可服务机会，进一步发挥这些机会依赖卸载质量。

每生成服务请求的惩罚系统时延在同一确认批次中由 33.73 s 降至 28.15 s，平均减少 5.58 s（配对 t 区间为 $[-8.03, -3.12]$ s，十个训练种子均下降）；Jain 公平性由 0.8665 提高至 0.9210，平均提高 0.0544（配对 t 区间为 $[+0.0361, +0.0728]$，十个训练种子均提升）。前者反映更多请求进入覆盖后显著减少了未服务惩罚时延的累计，后者反映累计服务覆盖在用户间的均衡程度提升。这两项描述性结果支持该主场景中接纳扩展同时改善了系统综合时延与覆盖公平性，但不构成所有指标全面最优的结论。

3.6.5　本章证据支持的设计判断

本章确认实验在同一注意力结构与下层配置下比较观测内容，支持在一百 UE 主场景和当前信息假设下，把可见未接纳需求送入上层能提高端到端 DSR。由于网络保持相同，它明确定位了一个可实施的输入改动，避免将改进笼统归因于“更复杂的模型”。该优势具有清楚的触发条件：原输入存在空槽或容量可用于补充未接纳用户，且这些用户信息在决策前可用。

相同网络的对照没有识别注意力相对同信息非注意力模型的独立优势；理想信息协议也没有识别信息上报成本后的净收益。本文把这些问题交给相应协议处理，而不把未知因素当作已解决。已有阶段性结果最有价值的含义，是明确自然覆盖系统必须同时考察需求可见性、接纳率和接纳后质量，为下一章的分配质量研究和第五章的跨时隙排队控制建立可检验的问题。

3.7　本章小结

本章在自然覆盖规则下建立了无人机集群协同轨迹决策的系统与学习模型。统一 $G/A/S$ 计数表明，端到端 DSR 由接纳与接纳后质量共同决定；通信、缓存、批量算力和机动结算的推导明确了空中平台部署与任务执行的耦合路径。上层动作采用原始正态概率与确定性执行修复，当前请求在移动前执行，轨迹主要影响下一时隙接纳。Attention-MAPPO 以定长局部观测执行、联合观测评价，为各机依据邻机与需求信息开展分散轨迹决策提供了训练框架。

在这一框架中，预接纳观测保持三十槽和物理半径不变，补入感知范围内尚

未接纳的用户。独立确认支持主场景 DSR 增加 2.85 个百分点，其主要来源是接纳率提升 9.82 个百分点，并伴随接纳后质量的轻微稀释。由此，轨迹控制和卸载质量需要在共同系统模型下协同评价。第四章冻结请求与几何，在消除轨迹差异的条件下研究全批次分配的质量余量与计算代价；第五章按动态排队协议评价跨时隙联合控制，不能把本章单步批量结果或第四章离线搜索直接当作跨时隙排队策略的性能证据。

第 4 章　考虑跨机资源竞争的截止期优先计算任务分配

4.1　固定快照问题与受控比较范围

第三章研究无人机集群如何通过空间部署接纳地面需求，本章进一步研究集群如何分担已经接纳的计算任务。请求接入某架无人机后，其执行节点仍可选择来源本机、允许的协作无人机或地面 MBS。执行位置会改变回源、机间转发和机载计算负载。该问题不仅涉及为单个请求选择最快节点，还涉及选择后整批请求如何分享各机算力。一项迁移可能使目标请求提前完成，也可能同时使迁入节点上多个原有请求超时。因此，跨机任务分配需要在同一执行模型中考虑全批次影响。

这里的任务分配以不可拆分的计算请求为对象，关联无人机承担接纳与上传职责，执行节点承担计算职责。二者可以不同，因而集群具有在空间接入后继续协作分工的机会。不同无人机的算力、缓存与链路条件不同，地面 MBS 则作为六节点服务系统中的计算支撑。本章保持这些既有资源规则，研究任务从一个执行节点转移到另一个节点时的系统后果；这与为飞行器分配巡检航点、侦察目标或编队位置具有不同的任务语义。

本章固定 UAV 和 UE 的历史几何、当前缓存、请求集合以及配置，对同一快照上的候选分配作独立反事实评价。每次评价从完全相同的状态开始，用生产环境执行整批请求，得到各请求的完成时延与截止期满足结果。候选执行结果不回写用于采样的参考历史，下一快照仍来自同一参考控制轨迹。通过这一受控设计，可以把“选择了不同执行目标”与“经过不同历史已产生不同状态”区分开来。

固定快照的研究问题是：在自然接纳、最终批量负载均分的条件下，以减少超时请求为第一优先级的跨节点迁移搜索，能否比自身代价启发式给出更好的集群当步分工，以及这种质量余量需要多少归一化时延代价和求解时间。该问题与在线强化学习不同。在线下层必须在很短时间内从观测产生动作，且动作会通过缓存更新影响后续运行；快照求解器可以对大量候选逐一重评估，却不会改变后续状态。本章方法据此定位为集群任务分配的受控分析与离线质量参照。

本章主实验的快照沿 Heuristic-Control 参考历史采集，不能视为第三章学习候选或第五章动态排队策略的轨迹分布。第五章关注独立协议下的持续队列控制，第四章末另以历史学习轨迹快照进行桥接。两类快照保留各自来源，不把相同名称的指标直接拼接为同一批次结论。第四章实现采用 MC-ITR 单请求迁移

搜索，没有拍卖、竞价或任务出价机制，也没有被接入第五章策略作为每步下层。

4.1.1 变量、候选域与实际节点映射

设快照接纳服务集合为 $\mathcal{M}$，大小为 $K = |\mathcal{M}|$，请求按 UE 编号升序排列。全系统 UE 数仍记为 M，避免把快照活跃请求数与总人口混淆。请求 m 具有来源 UAV u_m、输入字节 L_m、服务文件字节 B_{s_m}、总 CPU 周期 $C_m = \omega_{s_m} L_m$、截止时间 D_m 和优先级字段 p_m。任务优先级提供给部分学习观测，但本章目标不按 p_m 加权；“截止期优先”指超时数在目标层级中优先，不能解释为优先级字段决定奖励权重。

每请求的候选集合记为 $\mathcal{C}_m$，包含来源本地、MBS 与硬可行邻机。分配向量 $\mathbf{a} = (a_1, \cdots, a_K)$ 属于

$$\mathcal{A} = \prod_{m \in \mathcal{M}} \mathcal{C}_m, \qquad |\mathcal{A}| = \prod_{m \in \mathcal{M}} |\mathcal{C}_m|. \tag{4.1}$$

使用花体 $\mathcal{C}_m$ 表示候选集，以区别总周期 C_m。实现动作编号为 0 本地、1 MBS、$2 + j$ 协作 UAV j；来源 UAV 自身的协作编号被排除，本地编号则映射到请求的来源。记 $d_m(a_m)$ 为动作对应的实际计算节点，则不同来源请求选择本地时可能到达不同 UAV，不能把动作编号零当作全系统同一个计算节点。

硬可行集合与学习策略的质量掩码不同。硬集合检查邻机可达、目标非自身、链路与算力等物理字段有效，本地和 MBS 保留为有效来源路径；邻机没有缓存也可通过回源取文件执行。本章枚举硬可行节点，不要求每条路径都预计满足截止期。若预先删除所有预计超时动作，会改变优化空间，并可能把估计误差当成严格物理约束；本章不采用这样的候选域。

4.2 全批次执行、缓存与计算外部性

4.2.1 通信与真实缓存路径

第三章给出了移动前几何、信道和缓存模型，本章在同一规则下具体化分配评价。字节数据 L_m 在比特每秒速率 R 上传输的时间为

$$T_{\mathrm{tx}} = 8L_m/R. \tag{4.2}$$

输入上传以来源 UAV 的全部关联 UE 数分配接入带宽，分配目标不会更换上传来源或该分母。文件回源用 B_{s_m}，而非服务输入 L_m。因此，两个请求即使输入相同，服务文件大小、缓存位置和截止时间不同，也可能需要不同执行节点。

记 $U_m = 8L_m/R^{\text{edge}}_{m,u_m}$，$V_{j,s} = 8B_s/R^{\text{bh}}_{j,\text{M}}$，$I_{m,u,v} = 8L_m/R^{\text{inter}}_{u,v}$。缓存指示 $h_{j,s}$ 来自快照起点真实状态，非命中概率。给定分配后，三类路径为

$$\begin{aligned} T_m(\text{local};\mathbf{a}) &= U_m + (1-h_{u_m,s_m})V_{u_m,s_m} + C_m N_{u_m}(\mathbf{a})/F_{u_m}, \\ T_m(\text{coop } v;\mathbf{a}) &= U_m + I_{m,u_m,v} + (1-h_{v,s_m})V_{v,s_m} + C_m N_v(\mathbf{a})/F_v, \\ T_m(\text{MBS};\mathbf{a}) &= U_m + 8L_m/R^{\text{bh}}_{u_m,\text{M}} + C_m/F_{\text{M}}. \end{aligned} \tag{4.3}$$

该式重申实际缓存与估计缓存的差别：Heuristic-Control 可以依据邻机命中概率预测路径，评价所有方法时则使用同一冻结真实缓存。不能把“期望缺失回源”写入本章实际生产执行时延。

各分配评价均冻结快照初始缓存，因此同批次较早发生的取文件不会立即改变后续请求的命中状态。若两项任务都需要某个起点未缓存的服务文件，它们在当前评价中各自支付回源项；待提交缓存只影响该私有副本步进后的状态，不影响其他候选评价。这一处理保证分配目标与请求遍历顺序不会偷偷改写待比较问题，也防止一项候选因先被评价而享有缓存优势。

4.2.2　节点最终负载与计算推导

生产执行先解析整批目标，再冻结 UAV 最终负载：

$$N_j(\mathbf{a}) = \sum_{m\in\mathcal{M}} \mathbf{1}[d_m(a_m) = j], \qquad \mathcal{M}_j(\mathbf{a}) = \{m : d_m(a_m) = j\}. \tag{4.4}$$

本地留存与协作迁入共同计入 N_j，协作迁出和 MBS 任务不计入。只要 $m \in \mathcal{M}_j$，便有 $N_j \geqslant 1$，每请求获得 $f_{m,j} = F_j/N_j$。由计算周期除以处理频率得到

$$T^{\text{cmp}}_m = C_m N_j/F_j. \tag{4.5}$$

在 MBS 上，计算频率固定为 $F_{\text{M}} = 200\,\text{GHz}$，不随其任务数均分。UAV 与 MBS 的处理规则是仿真合同的一部分，本章没有另加 MBS 排队容量限制。

算力均分是频率资源的简化分享，而非持续排队。每个请求具有不同计算周期，但均分份额不按输入大小加权；它们的计算时延因此可不同。时间超过时隙或截止期的请求仍会被本次评价计算完整路径，不保留到后续时隙排队。依据初始来源服务数预估的份额只用于启发式上下文，实际 $N_j(\mathbf{a})$ 必须在所有目标确定后重新计算。忽略这一步会令请求的结果依赖先后执行顺序，破坏公平比较。

4.2.3　迁移对未移动请求的外部影响

考虑把请求 m 从 UAV i 迁往 UAV j，迁移前负载为 $N_i = n_i \geqslant 1, N_j = n_j \geqslant 0$。对仍留在来源的请求 $k \neq m$，计算时延减少 C_k/F_i；对目标既有请求 ℓ，计算时

延增加 C_ℓ/F_j：

$$\Delta T_k^{\mathrm{cmp}} = -C_k/F_i, \quad k \in \mathcal{M}_i \setminus \{m\}; \qquad \Delta T_\ell^{\mathrm{cmp}} = C_\ell/F_j, \quad \ell \in \mathcal{M}_j. \tag{4.6}$$

这些请求的通信起点、执行节点与缓存不变，所以它们的完整时延变化也等于上述计算变化。被迁移请求则同时更换计算节点、通信路径和可能的回源项，不能只用 C_m/F_j 估计其收益。

图 4.1 给出算力 $F_u = 60\,\mathrm{GHz}$、输入 $L_m = 2\times10^6$ 字节、每字节 2000 周期、参考截止时间 $D_m = 0.25\,\mathrm{s}$ 的构造示例，总周期 $C_m = 4\times10^9$。当节点负载为二时，每请求获得 30 GHz，计算时间 0.133 s，归一化时延比 $T_m^{\mathrm{cmp}}/D_m = 0.533 \leqslant 1$；负载增至四时，份额降为 15 GHz，计算时间升至 0.267 s，归一化时延比 $T_m^{\mathrm{cmp}}/D_m = 1.067 > 1$，越过截止期阈值。这里比较的是二请求与四请求批次，两组值都由式 (4.5) 直接计算，用于直观展示算力稀释如何将原本可行的同节点任务推过截止时间边界。

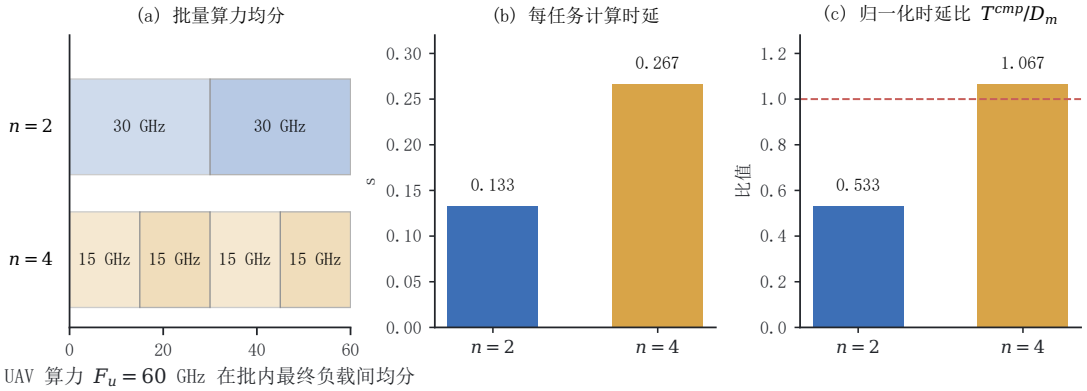


图 4.1　批量算力共享与迁移外部影响的机制示例（构造参数：$F_u = 60\,\mathrm{GHz}$，$L_m = 2\times10^6$ 字节，$\omega_m = 2000$ 周期/字节，$D_m = 0.25\,\mathrm{s}$；数值按式 (4.5) 计算，非实验测量）

Figure 4.1　Mechanism example of batch compute sharing and migration externality (constructed parameters, computed from Eq. (4.5))

4.2.4　自身改善不等于系统改善的构造例

为说明截止期外部性，构造两个缓存均命中的 UAV，算力均为 40 GHz，每请求输入为 4×10^6 字节、每字节 2000 周期，故 $C_m = 8\times10^9$。把每请求的共同上传时间设为 0.30 s，一次协作输入转发设为 0.12 s。这些是用于推导的指定路径常数，不是主实验快照记录。迁移前来源有五请求、目标有三请求；其中待迁请求截止时间为 1.25 s，来源其余四请求为 1.70 s，目标三请求为 1.00 s，均处于现行截止时间范围。

迁移前来源任务时延为 $0.30 + 5\times0.20 = 1.30\,\mathrm{s}$，目标任务为 $0.30 + 3\times0.20 = 0.90\,\mathrm{s}$。待迁请求超时，其他七项均成功。迁移后两节点均为四请求：待迁请求多

付转发，其时延为 $0.30+0.12+4\times0.20=1.22\,\mathrm{s}$，从超时变成功；来源其他任务变为 1.10 s，仍成功；目标三任务也变为 1.10 s，全部越过自身截止时间。表 4.1 汇总该反例。

表 4.1　自身改善与系统超时变化的构造例（非实验数据）

Table 4.1　Constructed example of own-request improvement and system deadline misses

请求组	数量	截止时间/s	迁移前时延/s	迁移后时延/s
待迁请求	1	1.25	1.30（超时）	1.22（成功）
来源其余请求	4	1.70	1.30	1.10
目标既有请求	3	1.00	0.90	1.10（超时）

该迁移使自身超时指示从一变零，却使系统超时数从一增至三。只依据自身字典序代价的迭代会把它视为优先改善，整体评价则应拒绝。这一构造证明的是判据之间存在逻辑差异，不表示每次自身迁移都产生负效应，也不直接量化主实验中有多少改善来自某种具体外部性。主实验的对照用于检验完整方法结果，构造例用于说明为何整体重评估是必要的算法设计。

4.3　严格字典序目标与共同基线

4.3.1　为何优先比较超时请求数

对于具有任务截止期的边缘服务，是否按时完成是离散的质量界限，而缩短已成功任务的时延只是连续改善。若把超时计数和平均时延直接作固定加权和，算法可能通过压缩多个成功任务的时延抵消一个新增超时，也可能因权重尺度改变而改变偏好。本文的目标先满足截止期优先的设计意图，再在第一层相同时比较归一化时延代价。

严格二元字典序目标为

$$F(\mathbf{a})=\Big(\sum_{m\in\mathcal{M}}\mathbf{1}[T_m(\mathbf{a})>D_m],\ \frac{1}{\max(K,1)}\sum_{m\in\mathcal{M}}\frac{T_m(\mathbf{a})}{\max(D_m,10^{-9}\,\mathrm{s})}\Big). \tag{4.7}$$

记两个分量为 F_1,F_2。对 $F(\mathbf{a}')$ 与 $F(\mathbf{a})$，先比较第一分量 F_1（超时数），较小者为较优分配；仅当第一分量完全相等时，再比较第二分量 F_2（平均归一化时延）。实现不取整、不设置字典序容差、不加 MBS 独立惩罚，也不将请求优先级乘入超时计数。$T_m=D_m$ 视为成功；空快照 $K=0$ 时两个分量均为零。

例如，$(2,0.91)$ 比 $(3,0.70)$ 更优，因为少一个超时；在超时数同为二时，$(2,0.89)$

又比 $(2, 0.91)$ 更优。这些示例是目标比较的构造数字，不是某次实验结果。它们说明字典序严格下降并不要求超时数与平均归一化时延同时下降，更不支持把算法描述为所有指标一致改善。

第二分量使用每请求的 T_m/D_m，能区分在不同截止时间下的相对压力。它并非仅超时任务的平均延误，也不是所有请求共享一个截止阈值。对于同一快照，K 在方法间相同，对每一层乘以正数不会改变字典序排序；但跨快照平均 F_2 是结果汇总，不能理解为对整个历史一次性求得了字典序最优。

4.3.2 边际目标如何包含批量外部性

对 $i \to j$ 迁移，只有待迁请求以及两节点的原有任务计算负载发生变化。在快照通信固定的条件下，第二分量的精确变化可分解为

$$\Delta F_2 = \frac{1}{K}\left[\frac{\Delta T_m}{D_m} - \sum_{k\in\mathcal{M}_i\setminus\{m\}} \frac{C_k}{F_i D_k} + \sum_{\ell\in\mathcal{M}_j} \frac{C_\ell}{F_j D_\ell}\right], \qquad K > 0. \tag{4.8}$$

第一项是自身变化，后两项分别是来源释放和目标竞争的外部影响。若目的地是 MBS，不存在目标 UAV 均分外部项；若来源原为 MBS，也没有来源 UAV 释放项。实际评价器不依赖人工简化导数，而执行完整生产模型，但该式帮助解释为何仅计算自身代价一般不等于系统边际代价。

第一分量更加不平滑。对受影响集合 $\mathcal{H} = \{m\} \cup (\mathcal{M}_i \setminus \{m\}) \cup \mathcal{M}_j$，有

$$\Delta F_1 = \sum_{k\in\mathcal{H}} \left(\mathbf{1}[T_k + \Delta T_k > D_k] - \mathbf{1}[T_k > D_k]\right). \tag{4.9}$$

接近截止边界的原有请求，即使只延长很少时间，也可改变超时数；远离边界的请求延长相同时间则不改变第一层。单看目标平均负载或被迁移请求的时延，无法识别这种离散门槛。整体重评估把真实缓存、最终均分和每请求截止时间共同纳入判据。超时减少时，搜索可以接受第二层归一化时延上升；超时不变时，则要求第二层归一化时延严格下降。这种优先顺序是方法设计选择，优势应表述为给定截止期优先目标下的整体决策。

4.3.3 四种方法保持相同问题与初值

本章比较四个共享候选域和生产评价器的方法，见表 4.2。Heuristic-Control 按生产启发式构造执行目标，其上下文可使用估计缓存和初始来源负载，而完成结果仍按最终批量模型评估。它既提供参考历史，也作为固定快照上的简单对照。方法之间不更换通信模型、截止期、硬候选集合或缓存状态，避免用较有利的物理假设替代算法改进。

Greedy-Single-Pass 从启发式结果出发，按 UE 编号升序逐请求扫描候选节

表 4.2　四种卸载方法的差异

Table 4.2　Differences among the four offloading methods

方法	初值	改进依据	终止与验证
Heuristic-Control	自身即初值	原启发式规则，不迭代	单次构造
Greedy-Single-Pass	Heuristic-Control	逐请求自身字典序代价	单轮顺序扫描
Iterative-Base	Greedy-Single-Pass	被迁移请求自身代价	自身无改善/环路/预算
MC-ITR	Greedy-Single-Pass	系统整体字典序目标	邻域无改善/预算退出

点。定义请求自身目标

$$f_m(\mathbf{a}) = \left(\mathbf{1}[T_m(\mathbf{a}) > D_m],\ T_m(\mathbf{a})/\max(D_m, 10^{-9}\,\mathrm{s})\right). \tag{4.10}$$

每次只选 f_m 严格下降的目标并固定选择，完成一轮后不回看前面请求。各请求结果来自完整批量评价，所以它能知道自身在当前负载下的完成代价；它忽略的是评价产生的其他请求变化，而不是完全不使用共享算力模型。严格改善之外的平局保持当前选择。

Iterative-Base 从同一个贪心分配出发，重复枚举单请求迁移，筛选自身代价严格改善的选项，并按自身差值元组、请求编号和目标编号择优。自身变化可能使整体目标变差，且不同请求的自身改善不一定构成共同势函数。因此实现记录已访问分配，以无自身改善、环路守卫或轮数预算退出，不把其终止自动解释为系统目标的邻域最优。

MC-ITR 也从同一贪心初值出发，但使用 $F(\mathbf{a})$ 的完整变化作判据。相同初值让比较集中于“自身改善”与“整体改善”的差别。不过，共享初值并不意味着两个算法遍历相同路径，它们可以到达不同局部解。理论上的严格下降只相对于 MC-ITR 的初值成立，不保证 MC-ITR 对任意快照都优于另外一个独立搜索终点，后者属于需用数据检验的比较。

4.4　MC-ITR 搜索过程与可证性质

4.4.1　完整单请求迁移邻域

对当前分配 $\mathbf{a}$，定义改变一个请求执行目标的邻域

$$\mathcal{N}_1(\mathbf{a}) = \{\mathbf{a}^{m\to c} : m \in \mathcal{M},\ c \in C_m \setminus \{a_m\}\}, \tag{4.11}$$

其中 $\mathbf{a}^{m\to c}$ 仅把第 m 个分量替换为 c。MC-ITR 每轮完整扫描该邻域，选择所有严格改善选项中系统目标最小的一个，平局按请求序号、目标编号确定。它是最佳改善搜索，区别于发现第一项改善就立即执行的首次改善策略。

每项候选评价均从快照的独立私有副本执行，不沿用上一候选产生的缓存、

随机状态或其他累积变化。选定最佳迁移后再次评价，要求结果与扫描时元组完全相同，且仍严格优于当前目标；否则报告评价器不确定或非严格改善错误，不静默继续。这一步保证实际接受的迁移符合算法判据，但不能用少数重复检查证明任意外部随机评价都天然确定，确定性首先来自冻结状态与一致代码路径。

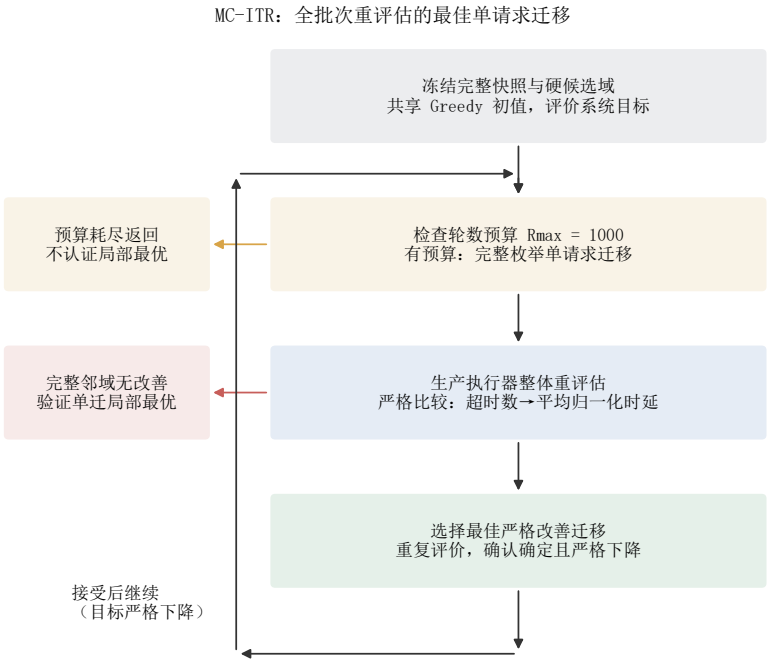


图 4.2　MC-ITR 算法流程。两个出口对应不同结论强度：无改善退出时可验证单请求迁移邻域局部最优；预算退出时不作此声称

Figure 4.2　Flowchart of MC-ITR with two distinct exits

4.4.2　严格下降、有限终止及初值保证

① 命题一：每项接受迁移使系统字典序目标严格下降。

算法仅把满足 $F(\mathbf{a}') <_{\text{lex}} F(\mathbf{a})$ 且复核通过的候选写入当前解，因此接受后的目标严格更小。设第 r 次接受后的分配为 $\mathbf{a}^r$，则

$$F(\mathbf{a}^{r+1}) <_{\text{lex}} F(\mathbf{a}^r), \qquad F(\mathbf{a}^r) \leqslant_{\text{lex}} F(\mathbf{a}^0). \tag{4.12}$$

第一层为整数超时数，所以它不会在接受过程中增加；它不变时第二层必须严格下降。这是按层级的保证，不是两分量各自始终单调下降。

② 命题二：无预算限制且评价确定时，搜索在有限次接受后终止。

每请求候选集合有限且非空，$\mathcal{A}$ 因而有限。若某个分配重复访问，确定评价会给出相同目标；但由严格下降链的传递性，后一次目标必须比前一次更小，产生矛盾。所以接受的分配不重复，最多接受 $|\mathcal{A}| - 1$ 次迁移，随后必然无严格改善邻居。该上界可能很大，仅用于证明有限性，不能解释为实际运行高效。

算法 4.1　MC-ITR：全批次重评估的最佳单请求迁移搜索

Input: 固定快照、候选域 $\{C_m\}$、共同贪心初值 $\mathbf{a}^0$、轮数预算 $R_{\max} = 1000$
Output: 分配、目标、终止原因与局部最优验证标记

$\mathbf{a} \leftarrow \mathbf{a}^0$，$\mathbf{v} \leftarrow F(\mathbf{a})$;
for $r \leftarrow 1$ **to** $R_{\max}$ **do**
　best $\leftarrow \varnothing$;
　foreach $m \in \mathcal{M}$, $c \in C_m \setminus \{a_m\}$ **do**
　　从原快照评价 $\mathbf{v}' = F(\mathbf{a}^{m\to c})$;
　　if $\mathbf{v}' <_{\text{lex}} \mathbf{v}$ **then**
　　　用键 $(\mathbf{v}', m, c)$ 更新严格改善中的最优候选;
　　end
　end
　if best $= \varnothing$ **then**
　　return 当前分配，原因“邻域无改善”，验证标记为真;
　end
　重新评价最佳分配，检查元组相同且严格改善;
　接受最佳迁移并更新 $\mathbf{a}, \mathbf{v}$;
end
return 当前分配，原因“轮数预算”，验证标记为假;

引入有限 $R_{\max}$ 后，算法无论是否耗尽分配空间都在有限轮内返回。轮数预算与收敛出口的意义不同：预算给计算量上限，无改善出口给局部搜索完成条件。即便最后一轮已经碰巧到达局部最优，若未扫描该新状态的完整邻域，程序仍不能把预算返回的标记改为已验证。特别地，$R_{\max} = 0$ 只评价并返回初值，不检查邻域；不能利用初值可能较好而声称局部最优。

③ **命题三：无改善出口认证单请求邻域的弱局部最优**。

在某轮完成全部候选评价且未发现严格改善时，返回解 $\mathbf{a}^*$ 满足

$$F(\mathbf{a}^*) \leqslant_{\text{lex}} F(\mathbf{a}'), \qquad \forall \mathbf{a}' \in \mathcal{N}_1(\mathbf{a}^*). \tag{4.13}$$

证明来自完整枚举与无改善条件。允许邻居具有完全相同目标，因此是不存在严格更优邻居的局部最优，而非唯一最优。该命题依赖候选域完整、评价确定、没有提前截断邻域，以及终止原因为无改善；触发轮数上限时不适用。

MC-ITR 相对于自身贪心初值的非劣保证来自式 (4.12)。它不能扩展成对 Heuristic-Control 初值的普遍保证，因为贪心阶段只看自身目标，可能使系统目标变差；也不能扩展成对 Iterative-Base 的逐快照普遍占优，两者停在不同解上。主实验的平均超时改善来自受控数据，并非把局部下降定理错误外推所得。

4.4.3 局部最优为何仍可不同于全局最优

一个最小离散例子说明单请求邻域的局限。设两个请求各有两个执行编号 $0,1$，构造目标如表 4.3。初始 $(0,0)$ 的超时数为一，两个单迁邻居 $(0,1),(1,0)$ 的超时数均为二，故搜索没有可接受单迁；但同时改动两项到 $(1,1)$ 可令超时数为零。该表是搜索性质的抽象构造，非实际系统某个快照的测量。

表 4.3 单请求局部最优不蕴含全局最优的离散构造

Table 4.3 Discrete construction separating one-request local and global optima

分配	$(0,0)$	$(0,1)$	$(1,0)$	$(1,1)$
构造字典序目标	$(1,1.00)$	$(2,1.20)$	$(2,1.20)$	$(0,0.80)$
初始解邻域关系	初值	单请求迁移	单请求迁移	两请求联合迁移

只要存在需要协同调整才能改善的分配，单迁搜索就可能停住。真实批量问题具有来源释放、目标竞争和缓存路径改变等耦合，也没有使局部等于全局的已证明凸性或交换结构。加入二请求交换或多迁邻域可改变可达局部解，但会增加评价量并构成新算法。本章不在已有实现之外补写这样的功能，也不把冻结快照局部解称为主配置全局最优或在线策略的严格上界。

4.4.4 评价量、复杂度与实际调用开销

令平均候选数为 $\bar{c} = K^{-1}\sum_m |C_m|$。每轮不同单请求迁移数为

$$H = \sum_m (|C_m| - 1) = K(\bar{c} - 1). \tag{4.14}$$

主配置中每请求至多本地、MBS 和另外四架 UAV，共六种硬候选，故 $H \leqslant 5K$。这说明单轮候选数随活跃请求数线性增加，不说明整个算法耗时线性，因为每候选评价要处理完整批次和环境状态，接受轮数也依赖问题实例。

若实际扫描 R 轮、接受 r_{acc} 项迁移，搜索核心评价量为

$$Q_{\mathrm{eval}} = 1 + RH + r_{\mathrm{acc}}, \qquad 0 \leqslant r_{\mathrm{acc}} \leqslant R \leqslant R_{\max}. \tag{4.15}$$

起始的一次为初值目标，每轮完整邻域贡献 H 次，每项接受迁移再贡献一次确定性复核。无改善出口一般还含最后一轮的完整扫描，不能把接受次数当作扫描轮数。该式描述搜索函数本身，不包括共享初值构造及结果打包所需的额外调用。

设一次完整生产评价成本为 C_{eval}，则主要时间复杂度为 $O(RK(\bar{c}-1)C_{\mathrm{eval}})$。$C_{\mathrm{eval}}$ 包含私有环境重建、解析全批目标、服务与其他请求处理及指标计算，随总用户数和数据结构规模变化，不可直接视为单位常数时间的单请求代价。空间

包括快照、候选域和搜索轨迹；穷举解空间虽然用于有限性证明，但 MC-ITR 不需要把全部分配同时存储。

实现中的四方法评价路径也影响实测时间。自身代价基线可复用有限容量的候选评价缓存，MC-ITR 核心按未缓存的生产评价作完整扫描和复核。共享的贪心初始化不计入两个迭代方法的本章搜索计时。故 wall time 比较描述实际实现的调用成本，不能仅根据差值断言慢的原因只来自更多轮数、只来自整体数学目标，或推断更换语言、硬件后必定仍有同一差距。

从算法机制与工程实现区分角度看，本章 2.880 s 的单快照耗时主要来自为确保“位级精确（bit-exact）无近似偏差”而在每次候选评价中重建私有环境副本并执行完整 `env.step` 的软件开销，而非单请求邻域搜索本身的数学复杂度下界。事实上，由于时隙开始时位置与二值缓存 $h_{j,s}(t)$ 已冻结，每个请求在各候选节点上的非计算通信时延 $T^{\mathrm{comm}}_{m,j}$ 在单快照内为常数；当候选迁移仅将请求 $m^{\star}$ 从节点 $j = a_{m^{\star}}$ 移至节点 $j' = c$ 时，仅有满足 $a_m \in \{j, j'\}$ 的同节点请求发生计算时间增量变化（即式 (2.68)）。若采用预计算 $T^{\mathrm{comm}}_{m,j}$ 并仅增量更新受影响节点任务完成时间的解析增量评价器，单次候选迁移评价仅需 $O(N_j(\mathbf{a}) + N_{j'}(\mathbf{a}))$ 次浮点运算，百请求规模下单快照约 150 ∼ 200 次候选评价的纯算术耗时低于 1 ms。本章之所以坚持调用完整私有环境步进，是为了将 MC-ITR 作为严格对齐生产仿真器的离线诊断基准，彻底排除解析增量公式与仿真器边界处理不一致的隐患。

4.5　Exact-Small 与反事实评价协议

4.5.1　完整穷举参照的定义

Exact-Small 在完整 $\mathcal{A}$ 上穷举，每个分配交给相同生产评价器，取字典序最小目标，平局按分配向量编号确定。由于枚举了所有硬可行分配，只要空间大小不超过事先预算、所有评价有效且枚举完成，便可认证该固定快照的全局最优：

$$\mathbf{a}^{\mathrm{ex}} \in \arg\min_{\mathbf{a}\in\mathcal{A}}{}_{\mathrm{lex}} \; F(\mathbf{a}). \tag{4.16}$$

冻结实验计划的枚举预算为 10^4 个分配。空间超过预算时，在评价前标记跳过，不从已枚举的子集结果宣称精确完成。通用函数默认预算与实验覆盖值可能不同，正文以实际冻结运行计划为准。

穷举时间为 $O(|\mathcal{A}|C_{\mathrm{eval}})$，候选数乘积使大批次难以使用。三 UE 配置从整个环境规模上定义小问题，而不是从一百 UE 快照中删掉大多数任务。后者会改变最终均分 N_j、接入关联数及请求间外部性，剩余任务的目标已不同，不能作为

原大问题的精确验证。Exact-Small 的作用是核验小规模实现与比较逻辑，不证明大问题搜索没有全局差距。

4.5.2 快照冻结与无副作用执行

快照保存完整环境状态、请求索引、来源映射和硬候选域，并记录配置摘要。请求索引按 UE 编号升序保持搜索一致，下层执行槽位则按原环境的来源距离及用户编号映射回去，不能把搜索列表序号直接当成下层槽号。配置摘要检查保证评价时没有悄然更换 CPU、带宽或接纳规则；私有复制保证候选之间不共享可变缓存与统计量。

评价时从序列化快照重建私有环境，注入显式卸载分配，采用统一固定移动动作，执行一个生产环境步。为了保留当前请求记录，评价器阻止该私有步末的新请求覆盖，但当前请求处理、缓存提交及其他私有更新仍按生产路径进行。它们的结果只用于该候选，不回写参考历史，也不传给下一候选。执行中如果发生卸载回退，评价器拒绝把它当作原目标分配的有效结果。

超时数与归一化时延通过生产执行的请求记录统计，不另建一套只对 MC-ITR 有利的近似公式。所有服务目标先解析，所有最终负载再冻结，之后请求逐个执行。该设计让评价结果反映完整批量外部性，同时减少两套数学模型随维护逐渐偏离的风险。本章的推导用于解释该统一模型，而不是绕过它以解析近似值替代主结果。

4.5.3 可重复性应检查什么

固定快照的可重复性包括输入、代码配置和评价顺序。相同分配重复评价应得到同一有限目标；候选域应非空，所有返回动作应属于相应硬集合；超时数应为非负整数，平均归一化时延应为非负有限数。贪心与迭代方法的初值应确实相同，MC-ITR 每个接受目标应严格下降，无改善标记应对应完整邻域检查。精确参照必须先核对空间大小与完成标记，不能把“运行未报错”替代为最优性验证。

上述检查解决实现与协议一致性，不自动证明论文效应。一个算法可以通过所有调用与格式检查，却在目标上不优于基线；一个小例找到精确解，也不能替代多负载工作负载上的实际效果。因而本章把算法性质、实现验证和实验比较分开：性质由假设与逻辑支撑，验证说明实现遵守合同，性能则由后文配对结果支撑。

4.6　实验设计、主结果与代价解释

4.6.1　410 个评估单元的组成

主配置为五 UAV、一百 UE。负载敏感性使用六十、八十、一百二十、一百四十 UE，算力敏感性使用主配置 UAV 算力的 0.6, 0.8, 1.2, 1.4 倍，其他协议保持对应冻结设置；再加三 UE Exact-Small，共十种配置。每配置十个工作负载，每工作负载六回合，每回合在 $0, 100, \cdots, 900$ 步采集十快照，因而每配置六百快照，总计六千快照。

九个正常规模配置各比较四个方法，构成 $9 \times 10 \times 4 = 360$ 个“配置–工作负载–方法”单元；Exact-Small 配置包含第五个穷举方法，构成 $1 \times 10 \times 5 = 50$ 单元，两部分合计四百一十。该计数说明评估完整性，不把同快照重复评价的四或五个方法当作独立状态。空接纳快照保留，其目标为零，反映自然覆盖参考历史中确实可能没有待卸载服务。

对每个工作负载种子，先求其六十个快照的指标平均，再在十个工作负载之间比较。主要指标为每快照平均超时数 F_1、平均归一化时延 F_2 和平均搜索耗时。对于方法 c 和参照 b，设种子 w 的快照平均差为

$$d_w = \frac{1}{60} \sum_{h=1}^{60} \left(Y_{c,w,h} - Y_{b,w,h} \right), \qquad \bar{d} = \frac{1}{10} \sum_{w=1}^{10} d_w. \tag{4.17}$$

置信区间以这十个工作负载配对单元作五千次 bootstrap，而不是对六千个有序历史快照直接作独立抽样。相邻快照共享历史，回合与请求也嵌套于工作负载，不能扩大独立重复数。

第四章不训练新的学习模型，因此这里的独立单位是工作负载种子，不能套用第三、五章训练种子检验的叙述。敏感性设置重新采样各自参考历史并重新求解，比较的是该配置下的求解器，而非固定学习检查点的跨场景泛化。所报告区间描述对应配置的差值不确定性，不是对所有未测试场景同时成立的保证。

4.6.2　主配置的截止期优势

表 4.4 与图 4.3 给出一百 UE 主配置结果。MC-ITR 每快照平均超时数为 2.045，低于 Iterative-Base 的 2.215、Greedy-Single-Pass 的 2.227 和 Heuristic-Control 的 2.888。共同贪心初值之后的整体重评估，因而在该批次取得了更好的第一优先级结果。相对迭代基线的 0.170 个请求差值约为其平均超时数的 7.7%；这一相对量由表中均值计算，不表示所有快照都减少相同比例。

与 Iterative-Base 的配对差值为 -0.170，95% bootstrap 区间 $[-0.222, -0.122]$，十个工作负载的方向均为负。与 Greedy-Single-Pass 的差值为 -0.182，区间

表 4.4　固定快照主配置的卸载方法比较（十个工作负载种子均值）

Table 4.4　Offloading methods on the fixed-snapshot main setting

方法	每快照平均超时数 ↓	平均归一化时延 F_2	搜索耗时/s
Heuristic-Control	2.888	0.886	0.121
Greedy-Single-Pass	2.227	0.677	1.083
Iterative-Base	2.215	0.674	2.347
MC-ITR	2.045	0.673	2.880

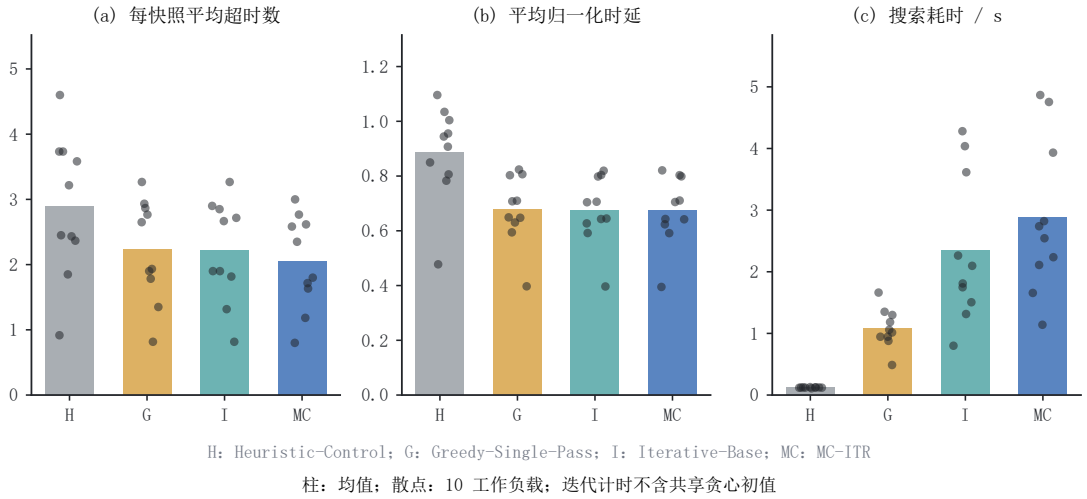


图 4.3　固定快照主配置下四种卸载方法的超时数、平均归一化时延与搜索耗时（柱为十个工作负载种子均值，散点为逐种子值）

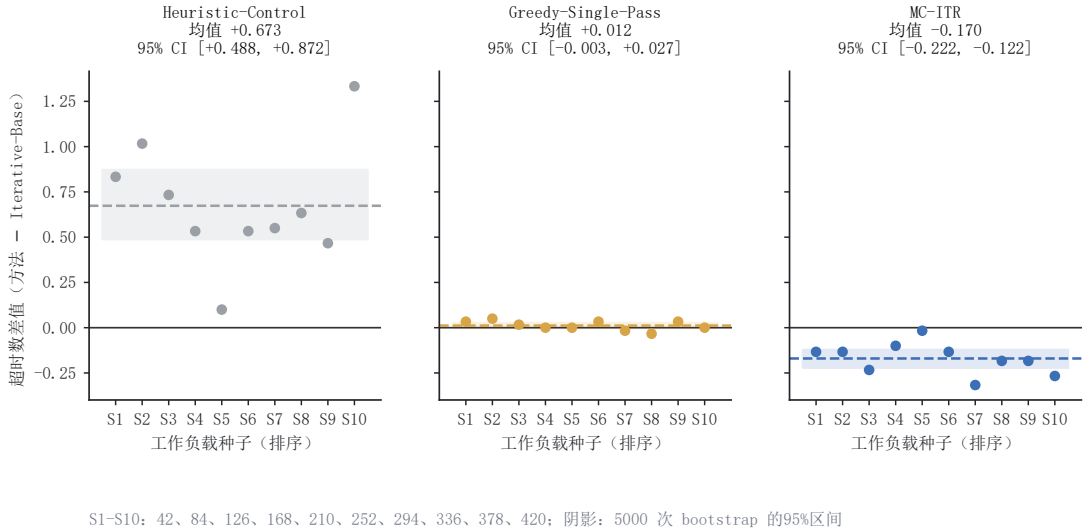
Figure 4.3　Deadline misses, mean normalized latency and solver time of the four methods on the main setting

$[-0.228, -0.133]$；与 Heuristic-Control 的差值为 -0.843，区间 $[-1.065, -0.628]$。图 4.4 展示配对方向与区间，使不同方法面对同一难度状态的比较更直接。该结果支持的是每快照平均超时数量的改善，不能换算成未经闭环运行验证的端到端 DSR 提升。

主结果的解释与方法机制一致：整体判据允许接受自身未明显改善却能释放其他紧迫任务算力的迁移，也拒绝自身变好但令更多邻机任务超时的迁移。这两种可能性由批量推导与构造例说明。现有汇总数据并未逐项统计所有接受迁移的类别，因此不能声称量化识别了各类机制贡献比例；直接得到的数据结论是完整 MC-ITR 相对这些对照的平均截止期表现。

4.6.3　次级归一化时延目标的联合报告

平均归一化时延 F_2 方面，MC-ITR 为 0.6734，Iterative-Base 为 0.6736，两者差值的均值为 -0.0002，95% bootstrap 区间 $[-0.0014, +0.0011]$ 跨零；MC-ITR 相



S1–S10：42、84、126、168、210、252、294、336、378、420；阴影：5000 次 bootstrap 的95%区间

图 4.4　各方法相对 Iterative-Base 的每快照超时数配对差值（十个工作负载种子；区间为 5000 次重抽样的 95% bootstrap 区间）。散点、均值虚线与阴影区间描述该固定快照批次中的工作负载配对差异

Figure 4.4　Paired per-snapshot deadline-miss differences against Iterative-Base

对 Greedy-Single-Pass（0.6770）的差值为 −0.0036，区间 [−0.0051, −0.0019]；相对 Heuristic-Control（0.8858）的差值为 −0.2124，区间 [−0.2493, −0.1743]。相对于 Iterative-Base 跨零的次级目标差值仅说明该批次中未检出两者整体平均归一化时延的显著差异，不等价于逐请求时延完全相同，也不能作为时延非劣的正式统计证明。

这一现象与两层字典序目标 $F(\mathbf{a}) = (F_1(\mathbf{a}), F_2(\mathbf{a}))$ 的设计机制相容。当第一优先级超时数 F_1 严格减少时，字典序判据允许接受将某个原超时任务迁往其他节点、使其压线满足截止期（$T_m/D_m \leqslant 1$）或略微提升非超时同批任务共享时延（仍保持不超时）的迁移；而在超时数 F_1 不变的候选之间，判据严格偏向更低的平均归一化时延 F_2。两种方向相反的效应在主配置样本上相互抵消，因此本批次中 MC-ITR 在显著减少超时任务数的同时，未检出整体平均归一化时延相对 Iterative-Base 的显著变化（但不能据此断言减少超时必然不产生时延代价）。

4.6.4　搜索时间与在线预算

MC-ITR 平均搜索耗时为 2.880 s，Iterative-Base 为 2.347 s，Greedy-Single-Pass 为 1.083 s，Heuristic-Control 为 0.121 s。两个迭代方法的计时不含共同 Greedy 初始化；表中 Greedy 自身值也不能机械加到每个方法的平均值后替代另一次完整路径实测，因为具体调用、缓存和记录阶段不同。它们首先说明本章实际实现为获得整体分配质量进行了更多生产评价。

仿真时隙为一秒，但离线评价的 wall time 并未作为任务通信或计算时延的

一部分加进 T_m。所以，快照方法的截止期结果不能解释成“等待两秒多求解后仍满足原截止时间”的真实在线流程。若要在线部署，需要把求解、信息收集和下发延迟纳入新的运行协议，或使用蒸馏、候选裁剪等近似机制另行验证。本章当前实现承担质量参照，而第五章的学习策略承担有限在线调用预算。

4.7 敏感性、精确检查与搜索完成情况

4.7.1 负载与算力变化

图 4.5、图 4.6 展示正常规模九种配置的结果，表 4.5 汇总 MC-ITR 与 Iterative-Base 的配对超时差。九种包含一个主配置和八个敏感性配置，不能称为九个额外敏感性变体。各差值区间均低于零，支持所测试范围内平均方向一致；这是一组逐配置结果，未声称同时区间覆盖或未测试负载的普遍有效性。

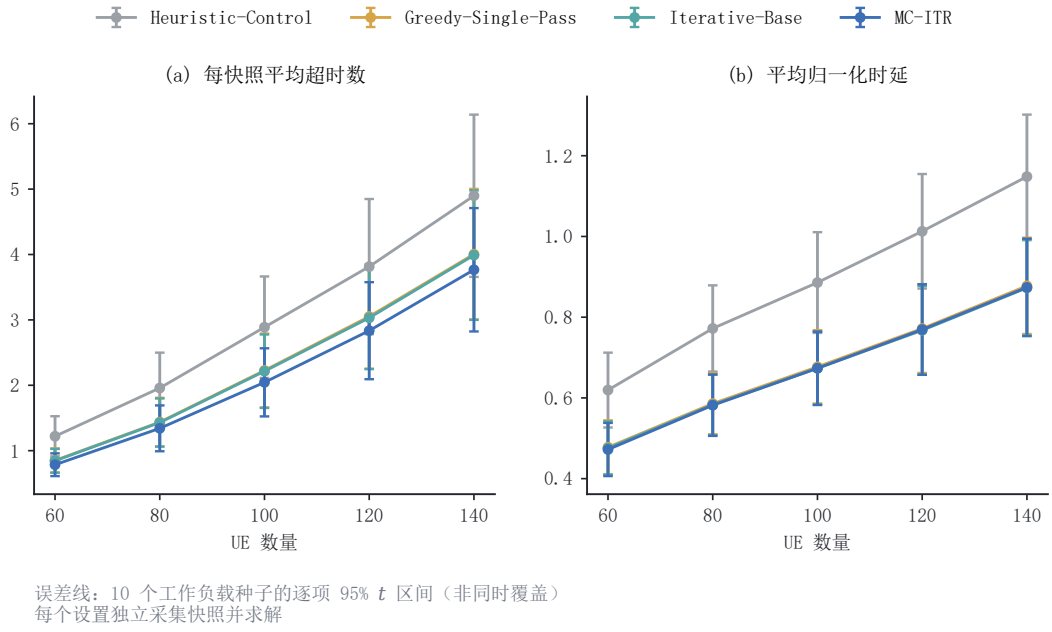
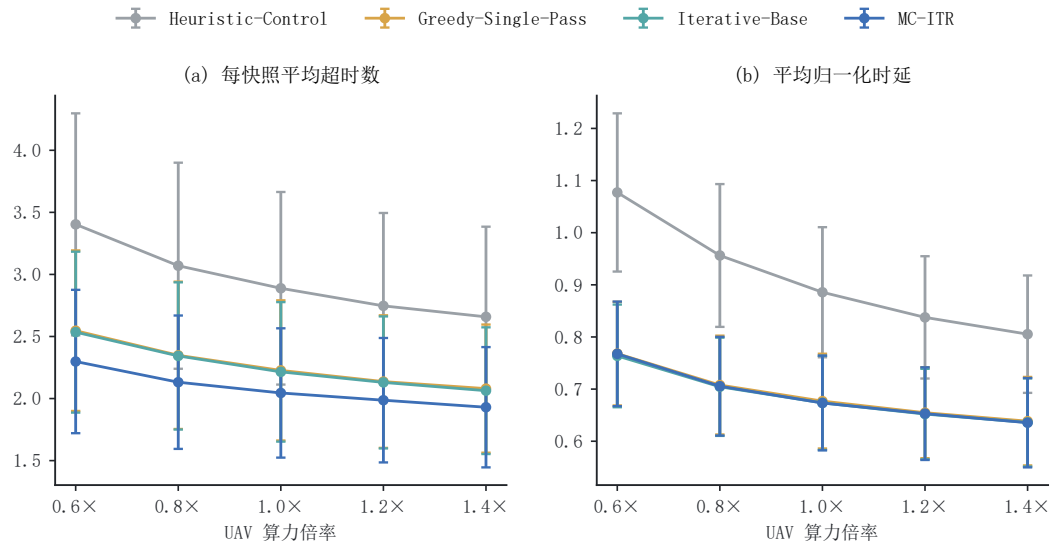


图 4.5 UE 数量变化下四种方法的超时数与平均归一化时延（误差线为十个工作负载种子的逐项 95% t 区间，非同时覆盖）

Figure 4.5 Sensitivity to the UE count

UE 数从六十增加到一百四十时，平均超时差依次为 −0.060, −0.088, −0.170, −0.197, −0.223。主系统有限覆盖和计算资源面对更高人口，可能出现更多活跃服务竞争与截止门槛，因此整体重评估的绝对余量增加与模型预期相容。不过，UE 总数不直接等于每快照接纳请求数，快照难度也随参考轨迹和请求类型改变；不能仅据这一序列证明改善幅度严格由人口单一因素决定。

算力为 0.6 倍时差值为 −0.237，0.8 倍为 −0.212，标准为 −0.170，1.2 倍为



误差线：10 个工作负载种子的逐项 95% t 区间（非同时覆盖）
每个设置独立采集快照并求解

图 4.6　UAV 算力倍率变化下四种方法的超时数与平均归一化时延（误差线口径同图 4.5）

Figure 4.6　Sensitivity to the UAV compute capacity scale

表 4.5　各变体配置中 MC-ITR 相对 Iterative-Base 的每快照超时数差值

Table 4.5　Paired deadline-miss difference (MC-ITR minus Iterative-Base) across variants

变体	超时数差值 [95% 区间]	MC-ITR 搜索耗时/s
主配置（100 UE，标准算力）	−0.170 [−0.222,−0.122]	2.880
UE 60	−0.060 [−0.078,−0.042]	0.836
UE 80	−0.088 [−0.120,−0.062]	1.625
UE 120	−0.197 [−0.242,−0.148]	4.595
UE 140	−0.223 [−0.263,−0.177]	6.598
算力 0.6 倍	−0.237 [−0.308,−0.165]	2.784
算力 0.8 倍	−0.212 [−0.273,−0.153]	2.754
算力 1.2 倍	−0.143 [−0.188,−0.103]	2.804
算力 1.4 倍	−0.133 [−0.173,−0.093]	2.704

-0.143, 1.4 倍为 -0.133。算力缩小时, 相同 C_m 的计算时间和迁移外部变化 C_m/F_j 增大，更容易触及截止边界；较高算力则减轻该部分竞争。各配置仍有负向差值，说明改善不限于单一算力点，但不能外推为任意算力下都有效，更不能把该固定快照现象替代为第五章动态排队策略的跨场景学习结果。

归一化时延与算力敏感性也呈现一致规律：当算力倍率从 0.6 增至 1.4 时，MC-ITR 的平均归一化时延由 0.768 单调下降至 0.636；当 UE 数从 60 增至 140 时，平均归一化时延由 0.472 上升至 0.874。这直接反映了式 (4.5) 中单任务计算时延与批内负载 N_u 正相关、与节点算力 F_u 反相关的物理关系。

4.7.2 Exact-Small 检查能验证到何处

三 UE 验证配置包含六百快照，其中五百一十一为空，八十二有单请求，七个有多请求，空快照比例 85.2%。图 4.7 展示这一分布以及方法的两个目标分量均值。小规模枚举器在完整硬可行域完成穷举，MC-ITR 在全部六百个快照上的两项目标与穷举精确参照逐快照完全一致（差值为 0，平均超时数均为 0.025，平均归一化时延均为 0.06080）；Greedy-Single-Pass 与 Iterative-Base 的平均超时数同为 0.025，但平均归一化时延比精确解高 3.33×10^{-5}（95% bootstrap 区间 $[0, +9.99\times10^{-5}]$），仅在四位小数舍入后同样显示为 0.0608；Heuristic-Control（超时数 0.030、归一化时延 0.0717）则存在明显差距。

空快照的所有方法目标天然为 $(0, 0)$，所以大量空状态会稀释非空差异。若仅在 89 个非空快照子集（占 14.83%，含 82 个单请求快照与 7 个多请求快照）上条件汇总，MC-ITR 与穷举精确解的条件平均超时数均为 $15/89 = 0.16854$，条件平均归一化时延均为 0.40989（差值严格为 0）。单请求快照没有同节点其他服务的批量外部性，最佳自身选择与全局选择接近同一个问题；仅 7 个多请求快照（$|\mathcal{M}| \geqslant 2$）真正触发同节点算力分母竞争。在这 7 个存在跨请求耦合的多请求快照上，MC-ITR 在全部 7/7 个快照中与穷举精确解取得完全相同的字典序目标，并相对 Greedy-Single-Pass 与 Iterative-Base 将多请求子集上的条件平均归一化时延降低 2.85×10^{-3}（折算至全部 600 个快照恰为 $7\times2.85\times10^{-3}/600 = 3.33\times10^{-5}$）。由此，该配置对评价和比较逻辑有价值，却因自然覆盖下三 UE 同时接纳多请求的概率较低而不具备区分大规模高维搜索能力的充分难度。图表阅读也应与逐快照完成标记和条件子集精确差值记录结合，不能只看保留四位小数的全集柱高就将舍入后相同的数值误判为完全相等。

精确最优目标不必对应唯一分配。多个节点路径可以给出同样目标，算法与穷举采用不同确定性平局规则时，可得到不同分配向量但相同最优代价。实现核

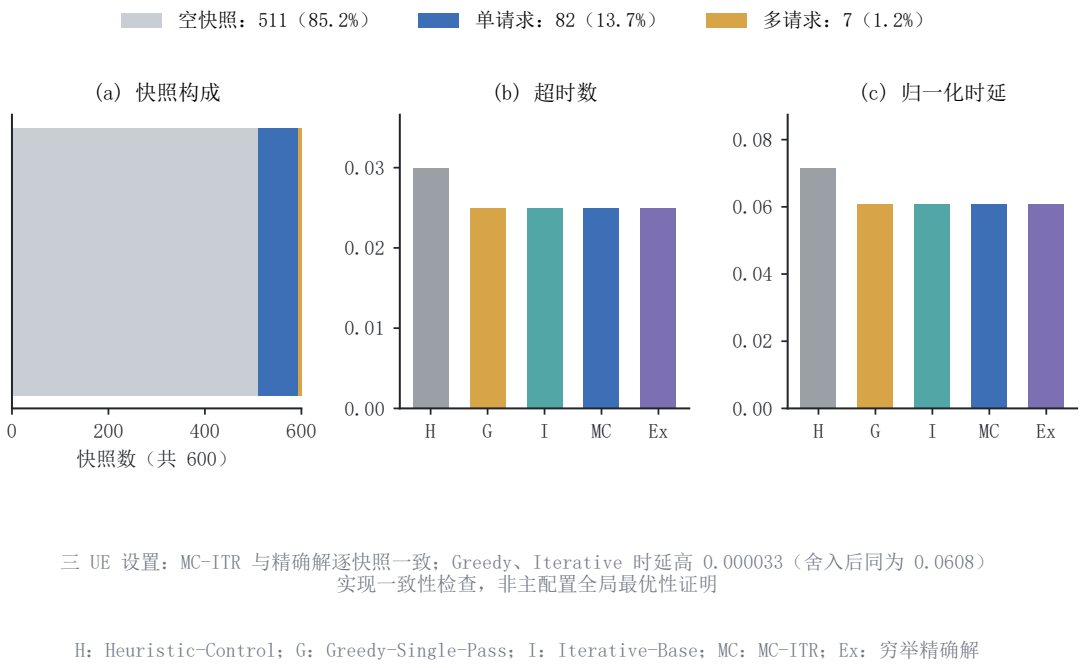


图 4.7　Exact-Small 配置的快照构成与各方法逐分量均值。(a) 600 个快照的构成；(b)-(c) 三 UE 小规模下 MC-ITR 与穷举精确解逐快照目标完全一致，Greedy 与 Iterative 超时数相同而平均归一化时延高 3.33×10^{-5}（四位小数舍入后同为 0.0608），Heuristic-Control 存在明显差距

Figure 4.7　Snapshot composition and per-component means on the Exact-Small setting

验应比较目标与硬可行性，再明确是否要求相同分配；不能将目标一致误写成所有动作逐项一致。本章只利用现有完整小规模参照支持实现一致性，不借此声称主配置达到全局最优。

MC-ITR 在此配置平均求解时间为 9.2 ms，穷举为 5.9 ms。当非空空间极小，完整邻域扫描、接受复核和框架调用可比直接枚举更费时，局部搜索不必在最小问题上最快。两者相同量级也不能外推大问题，穷举的分配空间随请求数呈乘积增长，只有明确空间预算下的完成才具备精确意义。

4.7.3　搜索完成标记与规模代价

归档结果显示，十种配置的 MC-ITR 邻域局部最优验证比例均为 100%，本批次没有轮数预算退出。该事实意味着每快照都经过无改善出口的完整邻域检查，符合命题三的条件。它不意味着已证明在任意更大请求规模下预算仍足够，也不能从完成比例推导具体接受轮数远低于预算；后者需要逐轮轨迹统计。

平均搜索时间在六十 UE 时为 0.836 s，八十 UE 时为 1.625 s，主配置为 2.880 s，一百二十 UE 为 4.595 s，一百四十 UE 为 6.598 s。实际耗时随规模明显上升，但这几个点不能确立渐近阶数。活跃任务数、每项候选数量、改善轮数、生产步评价规模以及缓存命中都可能参与变化，不能直接拟合一个幂律后替代算法复杂

度证明。

比主配置迭代基线多花的时间也没有唯一的“轮数更多”解释。整体评价、复核、基线缓存复用与完整环境复制都属于实际代码路径。要进一步优化实现，应依据逐阶段 profiling 或候选复用率，而不凭均值推定瓶颈。本章保留实测时间作为应用边界，当前完成状态只认证既定搜索完成与质量，不为实时部署背书。

4.8 候选学习轨迹桥接与本章小结

4.8.1 桥接设计与来源限定

为检验离线分配分析在扩展观测轨迹上是否仍有质量余量，桥接实验从第三章扩展观测候选的十个训练种子和五个工作负载中选取五十个在线评估任务，共采集四百个冻结快照。在相同快照上比较原在线学习下层与 MC-ITR，反事实分配仍不回写环境。这里的轨迹来源是第三章上层扩展观测加既有无注意力下层，不是第五章的动态排队联合策略；保留该来源是理解结果的必要条件。

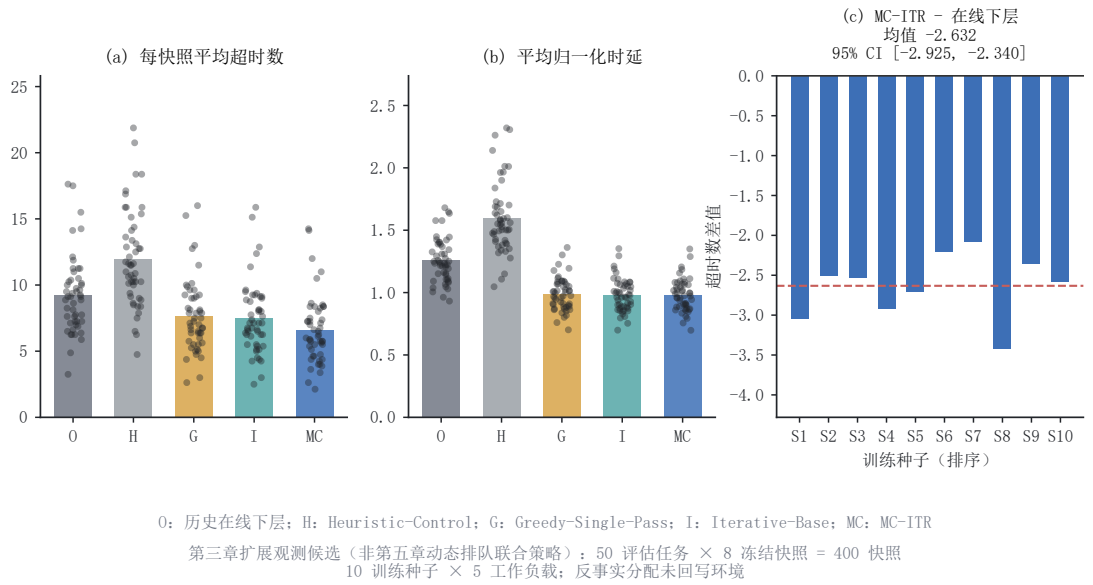
该桥接更换的是快照分布，仍保持同快照候选之间的请求、缓存和最终负载模型一致。它回答“这批学习轨迹状态上是否存在离线分配改善空间”，而非“把 MC-ITR 接入闭环后长期运行会提高多少”。一旦写回反事实分配，后续缓存、请求定型及上层观测可能变化，原来的轨迹不再保持，长期 DSR 需要新的闭环运行才能确定。

4.8.2 质量余量与完整调用时间

图 4.8 给出桥接实验结果。MC-ITR 每快照平均超时 6.605，原在线下层为 9.238，配对差 -2.633，以训练种子为独立重复的 95% 配对 t 区间为 $[-2.925, -2.340]$，十个种子的差均为负。平均归一化时延分别为 0.980 和 1.259，MC-ITR 相对在线下层降低 0.278（95% 配对 t 区间 $[-0.304, -0.253]$）。这支持给定候选学习轨迹下的显著离线分配质量余量。

完整 MC-ITR 调用含贪心初值，平均 21.876 s（其中搜索核心耗时平均 17.571 s）；在线分层策略单步调用（含上下层前向推理与动作掩码构造）平均约 0.0056 s。桥接时间与本章主实验 2.880 s 的计时口径不同，快照分布和请求规模也不同（第三章扩展观测使每快照接纳请求增多），不能通过二者之差估算贪心初始化时间。该量级对照说明，在这批状态上以完整离线搜索获取额外质量，与在线学习的快速推断承担不同职责。它不证明 MC-ITR 是严格全局最优上界，也不把该批次的调用耗时比自动推广为硬件无关常数。

桥接统计使用十训练种子，每个种子内汇总五个工作负载；本章主快照实验



O：历史在线下层；H：Heuristic-Control；G：Greedy-Single-Pass；I：Iterative-Base；MC：MC-ITR

第三章扩展观测候选（非第五章动态排队联合策略）：50 评估任务 × 8 冻结快照 = 400 快照
10 训练种子 × 5 工作负载；反事实分配未回写环境

图 4.8　第三章扩展观测候选轨迹的快照桥接（400 个快照；反事实不回写）。该候选不是第五章的动态排队联合策略，快照来源与计时口径亦不同于本章主实验

Figure 4.8　Bridge comparison on frozen snapshots from candidate trajectories

则使用十工作负载种子。两者独立单位不同，不能把四百快照或五十任务当成五十次独立训练，亦不能合并两批次的区间以增加样本。该分析为后续在线策略改进提供参照，第五章采用不同的持续队列协议，其结果必须在相应冻结协议和独立负载评估中建立。

4.8.3　本章结论与后续在线方法的关系

本章以固定历史状态为条件，建立了机载批量算力均分下的截止期优先计算任务分配问题。跨机迁移外部性推导说明，自身请求改善与集群整批目标改善一般不同；MC-ITR 因而完整枚举单请求迁移，并用生产执行模型重评估系统两层字典序目标。在评价确定、候选完整且无预算退出时，算法有限终止并认证单请求邻域局部最优；该性质不蕴含主配置全局最优。

四百一十个评估单元支持该方法在主配置及八个敏感性配置中减少平均超时请求，同时报告次级归一化时延和秒级搜索代价。Exact-Small 对小规模评价与比较逻辑提供一致性检查，候选学习轨迹桥接进一步刻画在线下层与离线搜索之间的质量余量。第五章转向独立的动态排队服务协议，通过规划蒸馏、环境交互与反事实辅助 PPO 研究联合控制和决策预算。该协议使用跨时隙进度与 EDF 计算；本章 MC-ITR 继续作为快照分析参照，既不接入其在线系统，也不作为其蒸馏教师。

第 5 章　动态排队服务中的规划蒸馏与反事实辅助协同控制

5.1　研究问题与协议边界

5.1.1　从批量分配到跨时隙排队

第三章说明需求可见性如何影响无人机集群的覆盖接纳，第四章进一步刻画给定位置与请求集合时的批量资源竞争。对于连续到达的计算服务，当前位置和本次分配还会改变后续传输、CPU 排队与截止期损失。若只评价当前批次，可能偏好立即增加接纳，却没有为已接纳请求保留足够的传输与执行机会。本章因此研究突发请求驱动的动态排队服务，重点考察如何把已有规划知识转化为较快的联合控制策略，以及环境交互能否继续改善蒸馏得到的策略初值。

为隔离跨时隙传输与计算的影响，本章采用独立的动态排队服务协议。该协议保留五架 UAV、一百个 UE、一个 MBS、100 m 物理服务半径及规定机动范围，但采用固定 UE 几何、可跨时隙保留的请求进度和节点 EDF 执行。它不是第三、四章含服务程序缓存与最终批量算力均分模型的直接延长。不能用本章 DSR 的绝对值与前两章作直接数值比较，也不能将单时隙批量评价与跨时隙排队评价混同。

本章提出的具体方法由三个环节构成。首先，以有限候选规划器提供监督目标，通过两轮数据聚合获得联合策略的蒸馏初值。其次，在完整环境轨迹上训练价值网络，并把共同随机数下的短视界反事实评分作为 Actor 辅助更新信号，进行联合 PPO 微调。最后，根据在线计算预算，使用零在线 Engine 前瞻策略直接选择联合动作，或使用学习先验引导 Top-6 候选的三步 MPC。前者仍需候选生成与解析排队特征计算，后者还需环境克隆前瞻；两者都在后续实验中测量完整决策调用的墙钟耗时。

本章检验两个主要问题：完整微调方案能否改善蒸馏学生初值，学习引导 Top-6 MPC 能否相对指定在线规划基线改善服务质量与平均计算成本。跨层条件化和期望向量是所设计策略的组成部分，其独立性能贡献另用匹配消融考察，不预设所有组件均有显著收益。PPO、广义优势估计和数据聚合分别沿用已有方法思想[40,47-48]，本章的贡献定位于该排队任务下的联合表示、训练组合与控制方式。

5.1.2　与第三、四章的联系及区别

表 5.1 将章节联系落实到模型和证据层面。三章共同关注请求如何进入服务以及能否按时完成，但分别回答需求观测、固定快照分配和持续排队控制问题。第四章的 MC-ITR 既没有作为本章在线下层，也没有用作本章蒸馏教师。历史共享快照桥接仍是第四章协议下的离线分配比较，不能与本章闭环增益相加。

表 5.1　第三、四章与本章的协议和证据边界

Table 5.1　Protocol and evidence boundaries across Chapters 3–5

项目	第三、四章	本章
研究对象	需求感知轨迹；固定快照批量分配	突发到达下的跨时隙联合控制
执行模型	原通信、缓存与最终批量共享算力	上传、转发和 EDF 计算的持续队列
UE 与请求	原用户移动、服务与内容请求机制	固定 UE 几何，带属性的时隙泊松计算请求
进度跨步	单时隙内完成接纳与结算，不保留跨步队列	上传、转发与计算进度跨时隙保留，含排空结算
控制策略	Attention-MAPPO；MC-ITR 快照求解	候选级联合策略、反事实辅助 PPO、Top-6 MPC
可比较范围	各自协议内的配对对照	相同排队协议和确认工作负载内的对照

5.2　动态服务系统与候选动作建模

5.2.1　突发到达、任务属性与完整结算

每个评估回合包含 200 s 的请求生成阶段，宏决策步长为 1 s。每个工作负载固定一组 UE 位置和空间需求热点演化，任务可以在同一 UE 同一时隙重复产生。时隙泊松批次的期望总到达率为

$$\lambda(t)=\begin{cases}15, & 0\leqslant t<50,\\ 60, & 50\leqslant t<100,\\ 15, & 100\leqslant t<200,\\ 0, & t\geqslant 200.\end{cases}\tag{5.1}$$

图 5.1 展示该负载设计。它是合成业务协议，不是应急现场的实测流量记录。任务输入大小在 1.5×10^6 至 3.0×10^6 bytes 之间取整数，计算密度在 500 至 1000 cycles/bit 之间取整数。令输入比特数为 b_n、计算密度为 ω_n，则计算量 $c_n=b_n\omega_n$。期限相对到达时刻在 $[2,3]$ s 内生成。

停止到达后仍继续选择动作并推进系统，直到请求全部完成或过期。冻结实现对宏步起点采用 $t\leqslant 204$ 的保护检查，实际终止由队列是否为空决定。该处理

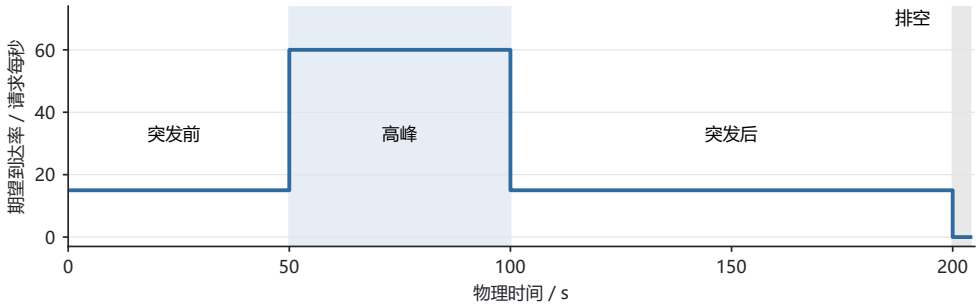


图 5.1　动态排队协议的期望到达率与排空阶段。阴影标出 50–100 s 高峰窗口；200 s 后停止生成请求，并继续结算未完成队列。曲线表示预设期望强度，不是观测流量拟合

Figure 5.1　Prespecified arrival intensity and the post-arrival drain stage

使最后阶段产生的请求也获得完整结算，避免只在 $t < 200$ 统计成功而截断晚到请求。训练经验同样保留排空步自身的状态、动作、旧策略概率和奖励，而不是把排空阶段收益事后合并到最后一个活跃步。

设回合生成、接纳、按时完成的请求数分别为 G, A, S，主指标定义为

$$\mathrm{DSR} = \frac{S}{G}, \qquad P_{\mathrm{adm}} = \frac{A}{G}, \qquad P_{\mathrm{done|adm}} = \frac{S}{A}, \qquad \mathrm{DSR} = P_{\mathrm{adm}} P_{\mathrm{done|adm}}. \tag{5.2}$$

该恒等式只在使用同一组请求计数时成立。分阶段结果按请求到达时间归入突发前、高峰和突发后队列，完成时刻可以晚于所属窗口；非高峰汇总突发前和突发后两组。所有实际生成请求都进入分母，包括一直未被接纳而过期的请求。完整排空后 $G = S + E$，其中 E 为过期请求数。

5.2.2　不可变关联与传输–计算串联队列

请求 n 的运行状态包含到达时刻 a_n、绝对截止时刻 d_n、来源 UAV、执行节点，以及剩余上传量、转发量和计算周期。未覆盖请求处于等待状态，若在截止前进入服务范围，才由最近 UAV 首次接纳；首次来源确定后不再切换。控制器只对新接纳且尚未分配的请求选择执行目标，目标一旦确定也不再迁移。因而，当前动作不能任意重排历史任务的执行节点，只能影响新分配和后续服务几何。

每个任务依次经历等待覆盖、UE 上传、必要的 UAV 间转发或 MBS 回传、目标节点计算。上传或转发因失去连接而暂停时，已完成进度保留；通信完成后才释放到 CPU 队列。记节点 j 的就绪任务集合为 $\mathcal{C}_j(\tau)$，其执行规则为

$$n_j^*(\tau) = \arg\min_{n \in \mathcal{C}_j(\tau)} (d_n, \mathrm{uid}_n), \qquad f_n(\tau) = F_j \mathbf{1}\{n = n_j^*(\tau)\}. \tag{5.3}$$

这里 EDF 表示最早截止期优先，同期限按任务标识排序，允许新就绪的更早截止任务抢占。UAV 算力依次为 $(75, 60, 70, 85, 50) \times 10^9$ cycles/s，MBS 为 200×10^9

cycles/s。式 (5.3) 与第四章按最终批量均分算力的模型不同，不能混用其负载预测或局部最优性质。

通信速率按几何关系和香农型链路模型计算。每个 UE 同时上传其最紧迫任务，同一来源 UAV 下活跃 UE 共享上传带宽；协作链路与回传链路分别在活跃有向节点对之间共享资源。覆盖半径为 100 m，感知与 UAV 协作距离均为 460 m。上传、协作与回传带宽分别为 40、20 和 0.75 MHz。发送功率作为链路信噪比与速率模型的固定参数。

UAV 保持 100 m 高度，水平位置位于 $[50, 650]^2\ \mathrm{m}^2$，每步位移模长至多 15 m。执行器沿线性运动路径检查 200 m 最小机间距，并在覆盖或协作接触边界、任务完成和截止事件处结算。该检查针对本章的理想线性位移模型，不包含飞行动力学、姿态和控制误差。

5.2.3　可用信息、候选库与状态特征

控制器观察当前 UAV 位置、已接纳任务的剩余服务状态，以及机群感知范围内 UE 的待接纳请求。它使用历史可见到达计数估计需求强度，不读取随后真实发生的请求批次。执行时采用集中候选级决策：候选卸载方案给出本步新请求的目标节点，候选运动给出五架 UAV 的联合位移。这里的上下层指分配与运动两个决策分支，不是直接复用第三章的分散 Attention-MAPPO。

记候选分配集合为 $\mathcal{K}(s)$（容量 $K = 4$）、候选运动集合为 $\mathcal{M}(s)$（容量 $M = 6$），联合动作是 $(k, m) \in \mathcal{K}(s) \times \mathcal{M}(s)$。具体而言，每个宏步的四个候选分配方案 $k \in \{1, \cdots, 4\}$ 分别由上游冻结分配提议器的贪心主方案、按预计释放后负载平衡的 EDF 分配方案、协作分流缓解方案以及保守回退安全方案 k_{safe}（优先将高溢出风险请求导向轻载本地或 MBS）构成；六个候选联合运动方案 $m \in \{1, \cdots, 6\}$ 分别由当前位置保持（悬停）、活跃热点质心追踪方向、待接纳紧急需求救援方向（最大化待接纳任务的加权紧迫度覆盖增益 $R_{\mathrm{rescue}}(s, m)$）、高负载节点分散方向以及两个上游轨迹模型提议方向经全路径线性插值几何可行性（边界 $[50, 650]^2\ \mathrm{m}^2$ 与机间距 $d_{\min} = 200\ \mathrm{m}$）投影修复后构成。实验中固定的三个“父谱系”（`parent_idx` $\in \{0, 1, 2\}$）对应三组由不同随机种子独立训练并冻结的上游轨迹与分配基础检查点对，后续所有候选级蒸馏学生与强化学习微调策略均分别在这三个固定父谱系提供的候选接口上独立训练与配对评估。本章研究该结构化有限候选集上的选择，未声称覆盖所有连续轨迹及离散分配。初始先验选择器虽然没有训练本章新增的选择网络，仍依赖这些上游学习模型与启发式，不能视为完全不含先验知识的随机系统。

分配特征 $\mathbf{a}_k \in \mathbb{R}^{14}$ 包含节点计算负载、可完成量、溢出风险、转发比例及先验信息；运动特征 $\mathbf{m}_{km} \in \mathbb{R}^{16}$ 结合覆盖救援、预测到达服务能力、排队风险、位移和方案依赖信息；上下文 $\mathbf{c} \in \mathbb{R}^{14}$ 汇总历史到达估计和当前队列压力。表 5.2 给出了四组输入特征张量的具体维度构成。特征通过解析评价获得，无需为每个候选克隆执行 Engine，但并非没有在线计算成本。

表 5.2　候选级双分支联合策略与价值网络的特征张量构成

Table 5.2　Feature tensor specification for the candidate-level dual-branch joint policy and value network

张量符号	作用范围	维度	具体特征分量定义
$\mathbf{c}(s)$	公共状态上下文	14	当前时隙进度、三步滑窗到达率估计 $\hat{\lambda}_{\text{win3}}$、全网总等待/上传/转发/CPU 排队任务数与剩余周期、五架 UAV 平均负载率与最大负载率、拥塞指示器 $P(s)$
$\mathbf{a}_k(s)$	第 k 个候选分配	14	方案 k 下预计可按时完成量 $\widehat{C}_k$、预计溢出量 $\widehat{O}_k$、五机最大与标准差计算负载 ℓ_u、本地/协作/MBS 分配占比、转发带宽占用率、上游分配对数先验 $\log p_a^0(k \mid s)$
$\mathbf{m}_{km}(s)$	第 (k,m) 候选运动	16	前 4 维核心交互特征 $\boldsymbol{\phi}_{km}$（规范化救援潜力 R_{rescue}、预测到达服务量、排队溢出风险 $\widehat{O}_{km}$、净服务评分）+ 8 维方案条件化通道（方案 k 与运动 m 耦合下的五机链路速率变化与释放时间偏移）+ 4 维运动先验与位移模长特征
$\mathbf{x}_V(s)$	集中价值网络输入	34	14 维公共上下文 $\mathbf{c}(s)$ + 候选分配特征的 6 维先验加权均值与 4 维极值 + 候选运动特征的 6 维先验加权均值与前 4 维核心交互量极值

5.3　规划知识蒸馏与候选级联合策略

5.3.1　考虑释放时间的排队近似

传输尚未完成的请求不能提前占用 CPU。若把按截止期排序的所有请求直接串行预约到节点时间线上，可能让未就绪任务挡住已经可计算的任务。为避免这一类跨阶段预约偏差，特征计算先估计上传与转发完成时刻，作为 CPU 释放时间 $\tilde{r}_{n,j}$，再在每个节点上对已经释放的任务进行工作守恒 EDF 推进。具体而言，对当前处于上传或转发阶段的任务 n（来源 UAV 为 u_n、目标执行节点为 j），第一阶段按候选运动 m 对应的代表性链路速率估计其到达目标节点 CPU 队列的释放时刻：

$$\tilde{r}_{n,j}(s,k,m) = t + \frac{b_n^{\text{up,rem}}}{\hat{R}_{n,u_n}^{\text{edge}}(s,m)} + \mathbf{1}\{j \neq u_n\}\frac{b_n^{\text{fwd,rem}}}{\hat{R}_{u_n,j}^{\text{inter/bh}}(s,m)}, \tag{5.4}$$

其中已处于目标节点 CPU 队列的任务释放时刻记为 $\tilde{r}_{n,j} = t$。第二阶段在每个执行节点 j 上维护就绪集合 $\tilde{\mathcal{C}}_j(\tau) = \{n : \tilde{r}_{n,j} \leqslant \tau,\ c_n^{\text{rem}}(\tau) > 0,\ \tau < d_n\}$，在相邻事件时刻 $\tau_e < \tau_{e+1}$（新任务释放 $\tilde{r}_{n,j}$、当前头部任务完成或截止期 d_n 到达）之间，

令最早截止任务 $n_j^*(\tau_e) = \arg\min_{n\in\tilde{C}_j(\tau_e)}(d_n, \mathrm{uid}_n)$ 以速率 F_j 推进剩余周期：

$$c_n^{\mathrm{rem}}(\tau_{e+1}) = c_n^{\mathrm{rem}}(\tau_e) - F_j(\tau_{e+1} - \tau_e)\mathbf{1}\{n = n_j^*(\tau_e)\}, \tag{5.5}$$

直至 c_n^{rem} 归零得到近似完成时刻 $\tilde{t}_{n,j}^{\mathrm{done}}$，或因 $\tau_{e+1} \geqslant d_n$ 计入近似过期。

该过程输出近似可完成量 $\widehat{C}(s,k,m)$ 和溢出量 $\widehat{O}(s,k,m)$，用于候选特征及后续状态势评价。输出可以包含实现中对三步窗口以外完成的折减，因而是评分特征，不是整数成功数的替代计数器。实际成功数始终由完整 Engine 执行记录确定。该近似还依赖代表性几何、带宽共享和等待请求接纳估计，不具有一般精确排队求解保证。

在 932 个验证动作对上，释放时间近似与三步 Engine 参照的相关系数为 0.9996，平均绝对误差（MAE）为 0.2758，均方根误差（RMSE）为 0.6444；旧单次 Lindley 近似对应相关系数 0.99963、MAE 0.2704、RMSE 0.6382。新近似从排队机制上修正了构造反例中“未就绪任务阻塞已就绪任务”的顺序偏差，但在该验证集上的总体回归误差与旧近似处于同一水平。因此，较高相关性只支持其在所检验状态上的数值接近性，不证明普遍优于旧近似，更不证明候选最优动作始终一致。

5.3.2　双分支联合分布与期望反馈

运动分支先对每个方案的候选运动评分。令 $p_m^0(m \mid s,k)$ 为正值先验，g_m 为带线性跳连的单隐层评分网络，则

$$p_{\theta_m}(m \mid s,k) = \mathrm{softmax}_m\left[\log p_m^0(m \mid s,k) + g_m([\mathbf{m}_{km}, \mathbf{a}_k, \mathbf{c}])\right]. \tag{5.6}$$

评分网络为 $g(\mathbf{x}) = \mathbf{x}^\top\mathbf{w} + \tanh(\mathbf{x}^\top W + \mathbf{b})^\top\mathbf{v}$，隐层宽度为 48。取运动特征前四维构成 $\boldsymbol{\phi}_{km}$，分别表示规范化救援潜力、预测到达服务量、排队溢出风险和净服务评分，定义

$$\mathbf{C}_{\mathrm{upper}}(s,k) = \sum_{m\in\mathcal{M}(s)} p_{\theta_m}(m \mid s,k)\boldsymbol{\phi}_{km}. \tag{5.7}$$

分配分支再使用该期望向量，构造

$$\begin{aligned} p_{\theta_a}(k \mid s) &= \mathrm{softmax}_k\left[\log p_a^0(k \mid s) + g_a([\mathbf{a}_k, \mathbf{C}_{\mathrm{upper}}(s,k), \mathbf{c}])\right], \\ \pi_\theta(k,m \mid s) &= p_{\theta_a}(k \mid s)p_{\theta_m}(m \mid s,k). \end{aligned} \tag{5.8}$$

两个分支输入维度分别为 32 和 44。分配概率对 $\mathbf{C}_{\mathrm{upper}}$ 的依赖，使分配损失可以沿式 (5.7) 回传到运动分支。它是一个明确的参数耦合设计，而不是关于该结构性能必然占优的理论保证。

严格去耦对照把全部八个方案相关运动通道以及方案特征按下层先验边缘化，运动先验也替换为 $\bar{p}_m^0(m \mid s) = \sum_k p_a^0(k \mid s)p_m^0(m \mid s,k)$，并令

$\mathbf{C}_{\text{upper}} = 0$，从而得到 $\pi(k, m \mid s) = p_a(k \mid s)p_m(m \mid s)$。独立性审计记录（`decomposed_independence_audit.json`）对保存的去耦蒸馏与去耦微调模型在验证状态集上逐状态检验表明，任意两个分配候选 $k, k' \in \mathcal{K}(s)$ 之间的运动分支条件分布最大 L_1 差异严格满足 $\max_{s,k,k'} \|p_{\theta_m}(\cdot \mid s, k) - p_{\theta_m}(\cdot \mid s, k')\|_1 = 0.0$。仅去掉期望向量的对照则保留 $p_m(m \mid s, k)$ 的方案条件化（仅令 $\mathbf{C}_{\text{upper}} = 0$），不能与严格去耦混称。

5.3.3 规划教师目标与两轮数据聚合

策略蒸馏将较昂贵策略的输出作为学生监督目标[39]。本章教师对候选联合动作执行既有三步规划评分，并结合预测到达服务能力、原排队近似、过载与救援规则形成 $Q_T(s, k, m)$。教师评分仍包含启发式修正；本节的释放时间近似主要用于新学生特征和状态势，不能据此宣称教师已被替换为精确排队求解器。

教师分布以方案和运动先验乘积为基准，按得分指数重加权：

$$\begin{aligned} u_T(s, k, m) &= \operatorname{clip}\left[\frac{Q_T(s, k, m) - Q_T^{\max}(s)}{\tau}, -60, 0\right], \\ q_T(k, m \mid s) &= \frac{p_T^0(k, m \mid s) \exp u_T(s, k, m)}{\sum_{k', m'} p_T^0(k', m' \mid s) \exp u_T(s, k', m')}, \qquad \tau = 0.015. \end{aligned} \tag{5.9}$$

学生最小化教师到学生的 KL 散度。联合蒸馏与去耦蒸馏使用相同联合目标，区别在学生表达结构，而非给联合学生更好的教师标签。

借鉴数据聚合思想[40]，第一轮在初始先验和均匀候选探索形成的轨迹上采集状态；第二轮由第一轮联合学生运行，补充其诱导状态上的教师标注，再聚合两轮训练集继续拟合。每轮最多 32 个训练 epoch、批大小 16、初始学习率 0.008，按验证集教师 KL 选择蒸馏检查点。该两轮方案用于减小监督状态分布与学生闭环状态之间的偏差，不直接继承一般 DAgger 理论所需条件下的全部性能保证。

蒸馏阶段允许调用教师规划器，测试时学生不调用教师。此处的收益首先是计算摊销：把训练时取得的候选偏好编码到学生分布。监督目标不能保证学生在长期闭环中最优，因此后续使用完整环境交互继续优化，而不把教师或学生初值当作性能上界。

5.4　环境交互与反事实辅助 PPO 微调

5.4.1　完整真实轨迹奖励与状态价值

真实环境轨迹按照所采样的联合动作执行分配及运动。令 ΔS_t、ΔE_t 和 ΔD_t 分别为一步新增成功、过期和断链事件数，冻结实现采用

$$r_t = \Delta S_t - 0.65\Delta E_t - 0.05\Delta D_t + \Phi_{\text{post}}(s_t^+) - \Phi_{\text{pre}}(s_t). \tag{5.10}$$

s_t 是动作前已加入本步到达并完成接纳的状态，s_t^+ 是本步执行后的状态，尚未加入下一步新到达。Φ_{pre} 只评价已接纳任务；Φ_{post} 还把新位置覆盖内的待接纳任务作虚拟本地接纳估计。两者均基于释放时间近似，其形式为

$$\Phi = 0.65\widehat{C} - 0.65\widehat{O} - 0.35\sum_{u=1}^{5}[\ell_u - 1]_+^2, \qquad \ell_u = \sum_{n\,\text{assigned to}\,u} \frac{c_n^{\text{rem}}}{F_u}. \tag{5.11}$$

动作前未分配的已接纳任务按来源本地处理，动作后的虚拟接纳也按本地处理；队列为空时该评分取零。式 (5.10) 的势差没有乘折扣因子，且前后评价对象不同。因此本章把它作为任务相关奖励塑形，不主张具有标准折扣势塑形的策略不变性。训练优化的折扣塑形回报与最终 DSR 也不完全相同，二者关系需由独立评估确认。

价值网络 V_ψ 的输入为 34 维，分别由 14 维上下文、分配特征的 6 维先验均值和 4 维最大值、运动特征的 6 维先验均值和前 4 维最大值组成；隐层宽度 48。对包括排空步的完整轨迹，使用 $\gamma = 0.85$、$\lambda_{\text{GAE}} = 0.90$ 计算[47]

$$\delta_t = r_t + \gamma V_\psi(s_{t+1}) - V_\psi(s_t), \qquad \widehat{A}_t = \delta_t + \gamma\lambda_{\text{GAE}}\widehat{A}_{t+1}, \qquad \widehat{R}_t = \widehat{A}_t + V_\psi(s_t). \tag{5.12}$$

真实终止处下一状态值和后续优势取零。Critic 用真实轨迹的 $\widehat{R}_t$ 训练，采用阈值 5 的 Huber 损失与参数正则；反事实评分不作为 Critic 标签。这一分离限制了辅助评分对价值拟合的直接影响，但不构成 GAE 估计无偏性的保证。

5.4.2　共同工作负载基线与短视界反事实评分

同一工作负载和时间下的两个动作流提供留一法辅助基线。对动作流 i，先计算

$$\widetilde{A}_{i,t} = \widehat{A}_{i,t} - \frac{0.5}{N_t - 1}\sum_{j\neq i}\widehat{A}_{j,t}, \quad N_t \geqslant 2, \tag{5.13}$$

再在更新数据中作均值–标准差规范化，并裁剪到 $[-4, 4]$。只存在一个流时不使用留一基线。Critic 更新后重新计算轨迹优势，再用于 Actor 更新。相同外生工作负载减少到达差异，但动作引起的状态分歧仍然保留。

微调期间每隔四个活跃步，从旧策略分布构建至多四个反事实联合动作。候选集合为已执行动作与确定性 Top-3 动作的并集；若不足四个，再抽取一个均匀随机索引加入集合，重复索引可能使集合仍不足四个。因此，它不是四个独立同分布的旧策略样本。

每个候选从同一个公开状态克隆 Engine，先执行该候选的一步分配和运动，再使用安全分配与零位移继续两步。两步未来到达由历史可见需求的三步滑窗估计生成，候选共享完全相同的预测批次，即共同随机数（CRN）。这里的未来是预测样本，不是实际工作负载的未来真值，后续控制也不是待训练联合策略的完整延续。

必须区分反事实评分与式 (5.10)。记克隆分支新增成功、过期、断链为 $\Delta S^{(3)}, \Delta E^{(3)}, \Delta D^{(3)}$，$U^{(3)} = \max(A^{(3)} - S^{(3)}, 0)$ 为克隆累计已接纳但未成功的计数，其中可能包括已过期任务；$R_{\text{rescue}}(s,m)$ 为运动救援价值。辅助评分是

$$Q_{\text{cf}}(s,k,m) = \Delta S^{(3)} - 0.65\Delta E^{(3)} - 0.05\Delta D^{(3)} - \eta(s)U^{(3)} + \zeta(s)R_{\text{rescue}}(s,m), \quad (5.14)$$

拥塞门控条件定义为当前规范化活跃队列压力 $P(s) > 0.85$ 或三步滑窗到达率估计 $\hat{\lambda}_{\text{win3}}(s) > 25.0\,\text{tasks/s}$：满足拥塞门控时取 $(\eta(s), \zeta(s)) = (0.45, 0)$ 以重点抑制队列积压溢出，否则取 $(0.15, 0.25)$ 以兼顾待接纳需求的空间救援。该评分不包含真实轨迹的前后势差，不能写成式 (5.10) 的三步累加回报。它是结合物理执行器与启发式末端项的模型辅助评分。

对当前候选组 $\mathcal{B}_t$，构建

$$\widehat{A}_{\text{cf}}(s,b) = \text{clip}\left(\frac{Q_{\text{cf}}(s,b) - \overline{Q}_{\mathcal{B}_t}}{\max(\text{std}_{b' \in \mathcal{B}_t} Q_{\text{cf}}(s,b'), 0.10)}, -3, 3\right). \quad (5.15)$$

评分无差异时不加入辅助样本。组中心化用于强调相同状态下的相对候选质量，不能将其解释为真实长期价值函数的无偏优势估计。

5.4.3 联合裁剪目标与训练组合

Actor 沿用 PPO 裁剪形式[48]。对联合动作 $b = (k,m)$，定义

$$\begin{aligned} \rho_\theta(s,b) &= \frac{\pi_\theta(b \mid s)}{\pi_{\text{old}}(b \mid s)}, \qquad \epsilon = 0.20, \\ \ell_{\text{clip}}(s,b,A) &= -\min\{\rho_\theta A, \text{clip}(\rho_\theta, 1-\epsilon, 1+\epsilon)A\}. \end{aligned} \quad (5.16)$$

真实轨迹条目使用规范化后的 $\widetilde{A}$，反事实条目使用 $1.25\widehat{A}_{\text{cf}}$。实现将两类条目合并后按批平均，同一状态可因多个辅助候选而重复出现。每个条目的损失还包含 $-\beta_H H(\pi_\theta)$、$\beta_{\text{KL}} D_{\text{KL}}(\pi_{\text{ref}} \| \pi_\theta)$ 与参数正则。微调以蒸馏初值作为参考锚点，冷启动以候选先验为锚点。

真实轨迹中的动作由旧策略采样，但反事实集合还包含确定性 Top-3，代码未为这种候选选取分布另作抽样修正。因此，本章将总体算法称为*环境交互与反事实辅助 PPO*，其中辅助项是一种偏置的模型辅助优化目标，不把整个混合更新称为标准在策略 GRPO，也不赋予其标准 PPO 的无偏策略梯度解释。其有效性以完整方案的闭环比较为依据。

表 5.3　冷启动与蒸馏暖启动微调的冻结训练参数

Table 5.3　Frozen configurations for scratch training and distilled warm-start fine-tuning

配置项	冷启动	暖启动微调
Actor 学习率	0.0035	0.0025
Critic 学习率	0.008	0.008
Actor / Critic epoch	6 / 10	4 / 8
批大小	32	64
熵系数 β_H	0.002	0.0005
KL 系数 β_{KL}	0.015	0.015
反事实间隔 / 优势权重	关闭 / 0	4 步 / 1.25
折扣 γ / GAE λ	0.85 / 0.90	0.85 / 0.90
更新轮次 / 每轮真实回合数	4 / 12	4 / 12

每个训练臂、每个父谱系执行四轮更新，每轮使用六个工作负载的两个动作流，共 12 条真实轨迹，累计 48 回合。反事实分支会增加额外训练计算，并不包含在 48 条真实轨迹的计数中。表 5.3 表明冷暖组同时改变初始化、辅助项、参考锚点和优化参数，比较所识别的是完整训练组合，而不是暖启动单因子的纯效应。耦合微调与无期望向量微调从相同联合蒸馏检查点开始，但策略结构开关仍可能使初始动作分布不同。

算法 5.1　规划蒸馏与环境交互、反事实辅助 PPO 微调

Input: 冻结候选提案器、评分器，训练与验证工作负载，联合策略结构
Output: 验证集选择的联合微调策略

在先验与探索轨迹采集状态，计算教师候选分布，训练第一轮学生;
由第一轮学生运行并补充教师标注，聚合两轮数据继续蒸馏;
复制蒸馏 Actor，初始化 Critic，固定蒸馏参考策略;
for *四轮 PPO 更新* **do**
    在六个训练工作负载及两个动作流上收集完整真实轨迹;
    保留活跃阶段和全部非空队列排空步的状态、动作、概率与奖励;
    每四个活跃步构建至多四个候选，以共享预测到达执行三步反事实评分;
    用真实轨迹 GAE 目标训练 Critic，重新计算规范化轨迹优势;
    合并真实条目和组相对辅助条目，更新联合 Actor;
    在独立验证工作负载上评估当前策略;
end
按各谱系验证 DSR 从严格正更新轮次中选择检查点，冻结后执行确认评估;

5.5 零在线前瞻与神经引导 Top-6 MPC

5.5.1 零在线 Engine 前瞻策略

第一种控制方式在当前观察上构建候选库与解析特征，按式 (5.8) 采样联合动作，并仅在实际环境中执行该动作。测试采样温度为 1.0，不为候选调用 Engine 克隆前瞻，也不重新查询离线教师。它把更多规划计算移到蒸馏和微调阶段，但仍执行上游网络、候选构造、安全启发式与释放时间排队近似，因此不能描述为只有一次纯神经网络前向计算。

第二种控制方式允许一定在线前瞻，把学习分布用于缩小候选搜索范围，并参与最终评分。两种方式共享任务语义和动作接口，提供不同的测试期开销选择；本章不设定未经测量的机载处理器算力，也不据仿真推断直接承诺硬实时控制。

5.5.2 熵校准先验与三步候选评价

令提议分布为 $p(k,m)$，首先计算其熵与幂次

$$\begin{aligned} H(p) &= -\sum_{k,m} p(k,m)\log p(k,m), \\ \alpha &= \min\{1, \max[0.25, H(p)/1.85]\}, \\ \tilde{p}(k,m) &= \frac{p(k,m)^{\alpha}}{\sum_{k',m'} p(k',m')^{\alpha}}. \end{aligned} \tag{5.17}$$

校准使用数值下界 10^{-12}。由于正幂保持概率顺序，它不改变非并列候选的 Top-6 排名，主要调整后续评分和并列选择所使用的先验强度。不能把熵校准本身解释为引入新的候选搜索能力。

选取 $\tilde{p}$ 最大的至多六个联合动作，分别从相同公开状态克隆 Engine，并共享由历史预测生成的两批未来到达。首步执行候选，随后两步采用安全分配和悬停。记分支成功数为 $S^{(3)}$，则最终评价为

$$J(s,k,m) = S^{(3)} - \eta(s)U^{(3)} + \zeta(s)R_{\text{rescue}}(s,m) + 0.65\log\tilde{p}(k,m). \tag{5.18}$$

评分按百分位精度四舍五入，最大分并列时按校准先验加权抽样。执行选中动作后，下一宏步用新观察重新构建候选并规划，而不是执行全部三步分支动作。

式 (5.18) 与训练辅助式 (5.14) 也不相同，前者没有额外显式过期、断链扣分，却包含校准先验项。先验不仅影响哪些动作进入 Top-6，还影响保留动作的最终排序。因此，同框架对照用于检验学习先验参与筛选与评分的整体贡献，不把差值单独解释为候选裁剪的因果效应。

算法 5.2　两种在线联合控制方式

Input: 当前公开状态，冻结学生或微调策略，控制方式
Output: 本步新请求分配及五机联合位移
构建合法分配与运动候选，计算解析特征和联合提议分布;
if 使用零在线 *Engine* 前瞻方式 **then**
    按温度 1.0 的联合分布采样一个动作;
else
    根据分布熵校准先验，保留至多六个联合候选;
    使用历史需求生成两批共享预测到达;
    对每个候选执行首步动作及两步安全分配、悬停的克隆评价;
    根据式 (5.18) 选取最终动作;
end
仅向实际服务环境提交本步动作，接收下一步观察;

5.5.3　同框架对照和计算口径

Top-6 MPC 设置三种提议来源：初始候选先验、联合蒸馏学生、联合微调策略。三者共用候选生成程序、预测随机数构造、三步评价和熵校准形式，分别记为先验、蒸馏和微调 Top-6 MPC。在线规划基线则使用原三步确定性规划与预测修正，候选救援门控和先验构造也与新 Top-6 路径存在差异。因此，后者是指定控制方案的整体参照，不是只改变搜索数量的一因子对照。

日志把在线规划基线的确定性 Engine 推进步数与 Top-6 的预测候选分支数分别记录。预测分支内部同样使用 Engine 克隆，不能因为其确定性计数栏为零就称为零仿真。只有候选选择方式中的零在线前瞻臂同时满足两类计数均为零。实际效率比较还需同时考虑候选生成、解析评分、网络和克隆评价的墙钟耗时。

5.6　实验设置与确认结果

5.6.1　数据划分、比较层级与统计单位

本章主证据采用冻结版本 `queued_joint_rl_v2_20261106`。蒸馏和 PPO 使用 940000–940011 的十二个训练工作负载，前后六个分组分别用于两轮蒸馏，PPO 轮次交替使用两个六负载组；验证集为 941000–941002。开发评估使用 951000–951003，冻结后的确认集为 955000–955007，三者不相互替代。模型检查点按验证结果选择，确认结果不用于选择迭代。

全部十七个评估臂在三个固定父谱系、八个确认工作负载和两个动作流上运行，共 816 个配对评估回合。每臂 48 回合，池化生成请求数均为 252024。父谱系表示固定的上游模型及其后续选择器，不把这些评估回合或请求当成 816 次或 25 万次独立训练重复。按功能设计，十七个评估臂分为五组：（1）**先验与单分支/事后拼接基线**（4 臂）：直接使用上游候选先验的“初始先验

选择器”（uncoordinated_init）、固定运动先验仅用 RL 训练分配分支的“仅下层 RL”（lower_only_rl）、固定分配先验仅用 RL 训练运动分支的“仅上层 RL”（upper_only_rl），以及将上述两个独立训练的单分支直接组合执行的“单层训练后拼接”（separate_concat_rl）；（2）**双分支冷启动 RL 组**（3 臂）：从候选先验出发直接执行 4 轮在策略 PPO-GAE 训练的“去耦冷启动 RL”（decomposed_rl）、“无期望向量冷启动 RL”（joint_no_expectation_rl）与“联合冷启动 RL”（joint_rl）；（3）**两轮规划蒸馏组**（3 臂）：通过两轮数据聚合最小化三步规划教师 KL 散度的“去耦蒸馏”（decomposed_distilled）、“无期望向量蒸馏”（joint_no_expectation_distilled）与“联合蒸馏”（joint_distilled）；（4）**蒸馏热启动反事实辅助微调组**（3 臂）：从对应蒸馏检查点出发，结合真实轨迹 GAE 与共同随机数短视界反事实辅助评分微调的“去耦微调”（decomposed_rl_finetuned）、“无期望向量微调”（joint_no_expectation_rl_finetuned）与“联合微调”（joint_rl_finetuned）；（5）**在线前瞻与神经引导 Top-6 MPC 组**（4 臂）：执行原三步确定性规划与预测修正的“在线规划基线”（quality_amortized），以及分别以初始先验、联合蒸馏和联合微调策略作为提议先验的“先验 Top-6 MPC”（prior_mpc）、“蒸馏 Top-6 MPC”（joint_distilled_mpc）与“微调 Top-6 MPC”（joint_rl_mpc）。各臂汇总指标见表 5.4。

全程 DSR 比较采用 10000 次配对分块 Bootstrap，重采样工作负载和动作流，并对三个固定父谱系的计数比率差求平均。该区间反映固定模型集合面对所评估外生负载的变化，没有重采样训练谱系，也没有估计重新训练上游模型的全部不确定性。确认前固定八项主比较，另披露全 31 项全程 DSR 比较的 Bonferroni 区间。接纳率、条件完成率和阶段指标作为解释性分析，其检验族不能自动等同于全程 DSR 的 31 项主口径。

冻结清单记录 15 个科学源码、6 个上游父检查点和 51 个本实验模型的摘要；确认回合携带相应清单标识及开始时间。清单标识不等同于每个回合文件均有确认前内容摘要，已有回放审计也不等同于本次重新逐步复现训练。配套图表从 816 份原始回合计数与确认统计生成，原始训练和实验结果未因写作而改动。图源与来源索引保存在 docs/figures/data/queued_joint_rl_20261106/。

5.6.2　验证曲线与全部评估臂

图 5.2 显示当前预算下不同训练方案的验证变化。联合微调的平均验证 DSR 从 47.63% 增至 48.37%，冷启动联合选择器则在约 44% 附近波动。曲线支持两套训练流程呈现不同效果，但它包含不同初值、辅助信号和优化参数，不能据此将冷启动表现归因于唯一的长时域信用分配瓶颈。仅四轮更新的验证走势也不构成一般收敛性证明。

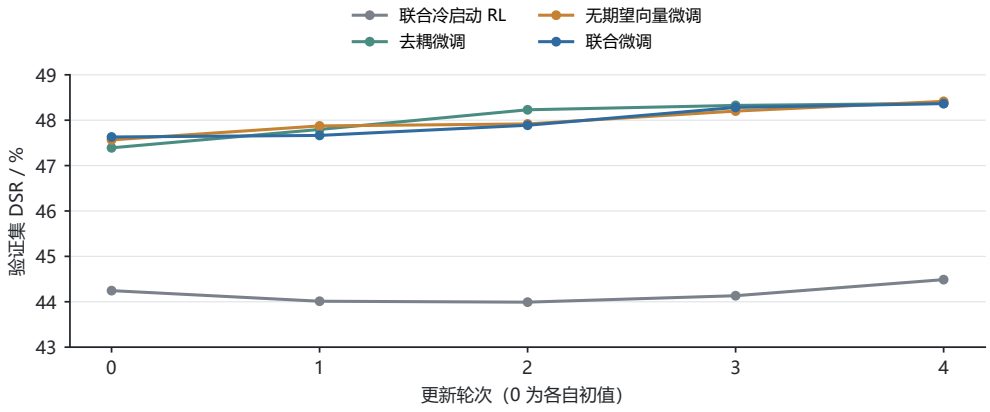


图 5.2　训练方案的验证 DSR 曲线。各点来自三个父谱系的验证汇总，轮次 0 为各方案自身初值；验证工作负载与确认集独立。曲线比较整体流程，不是匹配初始化与辅助计算预算后的单因素试验

Figure 5.2　Validation DSR across PPO updates for the evaluated training configurations

确认集的全部结果见表 5.4 和图 5.3。初始先验选择器 DSR 为 44.30%，联合冷启动为 44.25%，联合蒸馏为 48.04%，联合微调为 48.74%。同一候选控制接口下，蒸馏和完整微调方案取得更高服务成功率。由于初始先验也使用上游学习模型和安全启发式，这里的冷启动仅指本章新增选择器的训练起点，不是从原始观测到动作的全系统零知识学习。

5.6.3　完整微调改善蒸馏学生初值与反事实辅助受控消融

联合微调在确认集按时完成 122842 个请求，联合蒸馏为 121079 个，增加 1763 个。全程 DSR 差为 +0.70 个百分点，单比较 95% 区间为 [+0.51, +0.88]，主检验族（$M = 8$）Bonferroni 区间为 [+0.43, +0.96]，全 31 项 Bonferroni 区间为 [+0.39, +0.98] 个百分点；三个父谱系（$\texttt{parent_idx} = 0, 1, 2$）上联合微调 DSR 分别为 49.10%, 48.20%, 48.92%，联合蒸馏分别为 48.40%, 47.44%, 48.29%，逐谱系差值分别为 +0.70, +0.76, +0.64 个百分点，方向高度一致。该比较支持完整环境交互与反事实辅助 PPO 微调显著改善其蒸馏学生初值。

为严格分离“两轮规划蒸馏热启动”与“共同随机数（CRN）短视界反事

表 5.4　动态排队确认集的全部十七个评估臂

Table 5.4　All seventeen evaluation arms on the dynamic-queue confirmation set

方法	成功数	DSR/%	接纳率/%	条件完成率/%
初始先验选择器	111,646	44.30	51.22	86.48
仅下层 RL	110,397	43.80	50.81	86.21
仅上层 RL	111,825	44.37	52.18	85.04
单层训练后拼接	112,040	44.46	51.82	85.78
去耦冷启动 RL	111,328	44.17	52.02	84.92
无期望向量冷启动 RL	111,916	44.41	52.72	84.23
联合冷启动 RL	111,514	44.25	52.14	84.87
去耦蒸馏	120,865	47.96	52.84	90.76
无期望向量蒸馏	120,473	47.80	52.54	90.98
联合蒸馏	121,079	48.04	52.42	91.65
去耦微调	122,002	48.41	52.74	91.79
无期望向量微调	122,571	48.63	52.81	92.10
联合微调	122,842	48.74	52.58	92.69
在线规划基线	122,382	48.56	51.76	93.83
先验 Top-6 MPC	114,573	45.46	48.90	92.97
蒸馏 Top-6 MPC	123,753	49.10	51.60	95.17
微调 Top-6 MPC	124,280	49.31	51.38	95.98

每臂为三个固定父谱系、八个工作负载和两个动作流，共 48 回合、252024 个生成请求。表内为池化请求计数比率（满足精确计数恒等式 $S/G = (A/G) \times (S/A)$，例如联合微调 122,842/252,024 = (132,532/252,024) × (122,842/132,532) = 48.7422%，两位小数显示下 52.58% × 92.69% = 48.736% 的千分位尾差仅来自四舍五入显示）；请求与回合不作为独立训练重复。

表 5.5　关键比较的全程 DSR 配对差与置信区间

Table 5.5　Paired full-horizon DSR differences and confidence intervals

比较	检验族	差值	单比较 95% 区间	$M = 31$ 区间
联合微调相对联合蒸馏	主	+0.70	[+0.51, +0.88]	[+0.39, +0.98]
联合微调相对去耦微调	主	+0.33	[-0.08, +0.84]	[-0.29, +1.20]
联合微调相对无期望微调	主	+0.11	[-0.15, +0.41]	[-0.28, +0.66]
微调 MPC 相对在线规划	主	+0.75	[+0.41, +1.16]	[+0.25, +1.42]
联合微调相对在线规划	补	+0.18	[-0.17, +0.61]	[-0.31, +0.91]
微调 MPC 相对蒸馏 MPC	补	+0.21	[-0.06, +0.48]	[-0.23, +0.60]

单位均为百分点。主表示原八项主比较之一，补表示补充比较；最后一列采用全 31 项 DSR 比较的 Bonferroni 区间。Bootstrap 为 10000 次工作负载与动作流配对重采样，条件于三个固定父谱系。

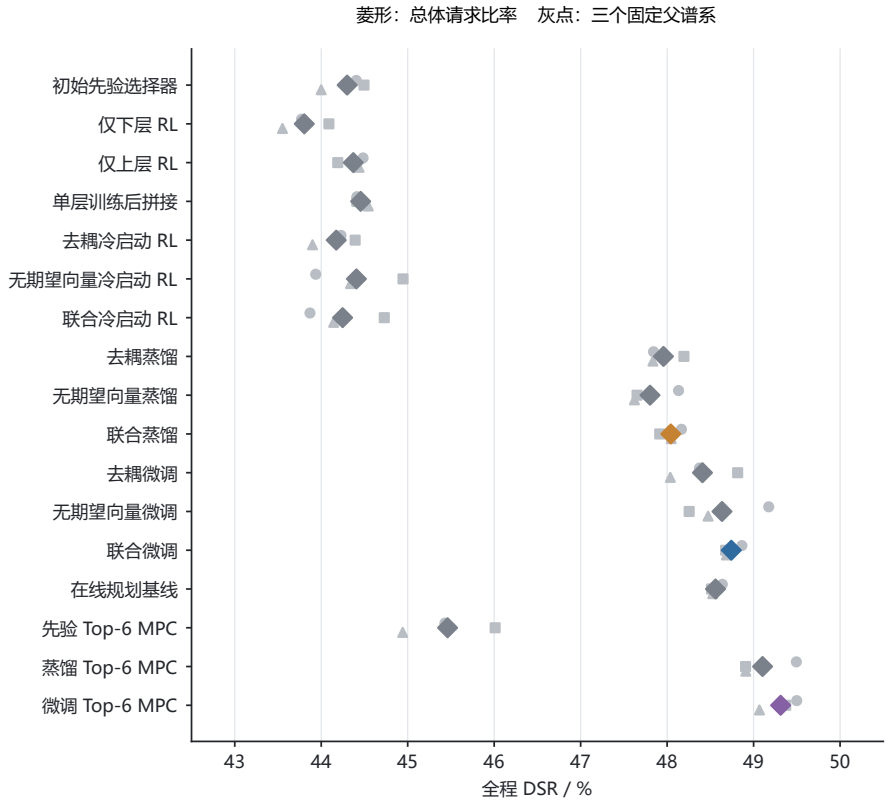


图 5.3　全部十七个评估臂的确认集 DSR。彩色或深色菱形为池化计数比率，灰色圆、方、三角分别为三个固定父谱系的比率。灰点展示谱系间差异，不是独立重训的置信区间；每臂为 48 个配对评估回合

Figure 5.3　Confirmation DSR for all seventeen arms with descriptive fixed-lineage values

实组辅助项”各自的贡献，表 5.6 给出了在完全相同的蒸馏学生起点（联合蒸馏 48.04%、去耦蒸馏 47.96%）、相同的 48 个确认回合（`955000--955007`，每臂 252,024 个生成任务）和相同 PPO-GAE 更新轮次下，关闭反事实辅助项（cf_stride = 0, $w_{\mathrm{cf}} = 0.0$，纯在策略 PPO-GAE 热启动微调，归档版本 `97b34d7`）与启用反事实辅助项（cf_stride = 4, $w_{\mathrm{cf}} = 1.25$，主版本 `241f9de`）的受控消融对比。

表 5.6 揭示了清晰的机制分解结论：

1. **规划蒸馏热启动是跨越冷启动探索瓶颈的主导因素：**在关闭反事实辅助项（cf = 0）的纯在策略 PPO-GAE 下，从联合蒸馏起点热启动的联合微调（48.05%）相对从头冷启动的联合 RL（44.25%）高出 +3.80 个百分点（95% CI [+3.23, +4.29]，三个父谱系差值分别为 +4.34, +3.24, +3.84 个百分点）。这证明在候选级 24 维乘积动作空间与跨时隙延迟反馈下，两轮规划蒸馏提供的结构化初始分布承担了 +4.49 个百分点总收益中的主体部分（+3.80 个百分点）。

表 5.6　蒸馏热启动微调中反事实辅助项的受控消融对比（相同蒸馏起点与 48 个盲测确认回合，每臂 252,024 个生成请求）

Table 5.6　Controlled ablation of the counterfactual auxiliary term in distilled warm-start PPO fine-tuning on the identical 48 confirmation episodes

微调策略臂	起点蒸馏 DSR	纯在策略 (cf = 0)	cf = 0 相对蒸馏	反事实微调 (cf = 1.25)	cf = 1.25 相对蒸馏	反事实净增益
去耦微调	47.96% (120,865)	47.92% (120,759)	−0.04 pp [−0.50, +0.42]	48.41% (122,002)	+0.45 pp [−0.02, +0.93]	+0.49 pp (+1,243)
无期望微调	48.04% (121,079)[a]	47.89% (120,701)	−0.15 pp [−0.42, +0.16]	48.63% (122,571)	+0.59 pp [+0.35, +0.80]	+0.74 pp (+1,870)
联合微调	48.04% (121,079)	48.05% (121,100)	+0.01 pp [−0.33, +0.34]	48.74% (122,842)	+0.70 pp [+0.51, +0.88]	+0.69 pp (+1,742)

[a] 无期望向量微调与联合微调从同一联合蒸馏检查点（48.04%）热启动出发，仅在微调与执行时关闭 $\mathbf{C}_{\text{upper}}$ 期望反馈分支。纯在策略微调（cf = 0）下联合微调相对联合冷启动 RL（44.25%）提升 +3.80 个百分点（95% CI [+3.23, +4.29]，$M = 8$ Bonferroni [+2.99, +4.45]），说明热启动初值贡献了 +4.49 个百分点总提升中的 +3.80 个百分点，而反事实辅助项贡献了继续超越蒸馏学生的 +0.69 个百分点关键增益。

2. **短视界反事实组辅助项是微调阶段显著超越静态蒸馏学生的必要驱动力：**当 cf = 0 时，仅靠单条真实采样轨迹的标量 GAE 回报更新，三种热启动微调策略的 DSR 分别为 47.92%、47.89% 和 48.05%，相对各自蒸馏起点的差值（$-0.04, -0.15, +0.01$ 个百分点）置信区间全部跨零（其中联合微调三个父谱系差值仅为 $+0.04, +0.05, -0.07$ 个百分点），即纯在策略 PPO-GAE 仅能维持蒸馏初值水平而无法有效发掘更优协同动作。引入每 4 步一次的共同随机数三步反事实组相对优势（cf = 1.25）后，去耦微调、无期望向量微调与联合微调分别额外多完成 1,243、1,870 和 1,742 个请求，DSR 分别提升 +0.49、+0.74 和 +0.69 个百分点，从而使联合微调相对蒸馏学生实现 +0.70 个百分点的全 31 项 Bonferroni 显著提升。其原因在于：在同一公开队列状态和共同随机到达序列下并行比对多个高先验候选的三步排队演化，消除了跨轨迹外生突发噪声对细粒度动作差异的掩盖。
3. **微调组内部双分支耦合结构的证据边界：**在同样启用蒸馏热启动与反事实辅助（cf = 1.25）的条件下，联合微调（48.74%）相对去耦微调（48.41%）高 +0.33 个百分点（95% CI [−0.08, +0.84]，三个父谱系差值为 $+0.25, +0.41, +0.34$ 个百分点），相对无期望向量微调（48.63%）高 +0.11 个百分点（95% CI [−0.15, +0.41]，三个父谱系差值为 $-0.31, +0.42, +0.21$ 个百分点）。表 5.5 与图 5.4 如实保留这些跨零结果，说明当规划蒸馏热启动与反事实组辅助同时在场时，候选分配特征与上层先验本身已捕获大部分负载结构，跨分支条件化与期望向量在全程 DSR 上仅提供边际正点估计而未达统计显著；与此同时，在已接纳任务条件完成率上，联合微调相对去耦微调与无期望向量微调分别高出 +0.89 个百分点（未校正 95% CI

[+0.41, +1.46]）和 +0.57 个百分点（未校正 95% CI [+0.02, +1.12]），体现了更审慎的高质量准入与执行协调倾向。

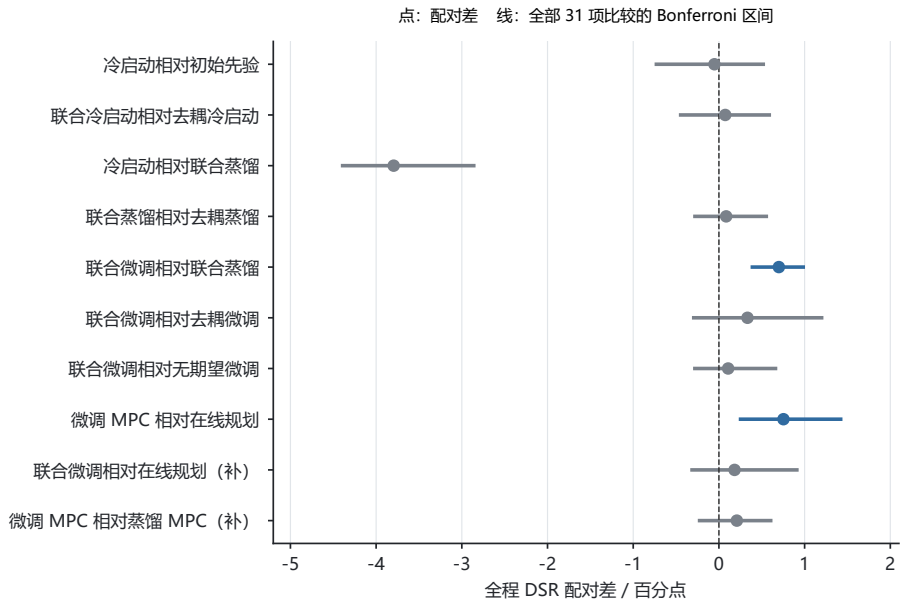


图 5.4　主比较及两项补充比较的全程 DSR 配对差。前八行为原主检验族，末两行用于限定在线替代与 MPC 内部增量。线段统一为 31 项 DSR 比较的 Bonferroni 区间，蓝色表示区间完全高于零；区间条件于三个固定父谱系

Figure 5.4　Paired full-horizon DSR effects with Bonferroni intervals across all 31 comparisons

5.6.4　神经引导 MPC 与在线规划参照

微调 Top-6 MPC 的 DSR 为 49.31%，在线规划基线为 48.56%；前者多完成 1898 个请求，差 0.75 个百分点，单比较 95% 区间 [+0.41, +1.16]，主检验族（$M = 8$）Bonferroni 区间 [+0.29, +1.35]，全 31 项区间 [+0.25, +1.42]；三个父谱系上微调 Top-6 MPC 的 DSR 分别为 49.70%, 48.77%, 49.47%，在线规划基线分别为 48.94%, 48.10%, 48.64%，逐谱系差值分别为 +0.76, +0.67, +0.83 个百分点。结合后文计算成本，这支持在本协议下采用学习引导的有限候选前瞻作为兼具更优服务质量与更低平均耗时的控制选择。

同框架下，先验 Top-6 MPC 为 45.46%，蒸馏 Top-6 MPC 为 49.10%，微调 Top-6 MPC 为 49.31%。学习先验相对初始先验带来较大整体收益，但微调相对蒸馏 MPC 的 0.21 个百分点差，其 95% 区间 [−0.06, +0.48] 跨零。因此不能把结果写成已证实的逐级显著提升，也不能由微调 MPC 相对旧规划基线显著更好，反推微调阶段对 MPC 的独立收益已确立。

零在线前瞻的联合微调相对在线规划基线高 0.18 个百分点，95% 区间为 [−0.168, +0.605]，不支持优效结论。该比较 90% 区间为 [−0.128, +0.523]，在 ±0.50

个百分点范围下未通过 TOST 等效判定；95% 区间下界高于 −0.50 个百分点，满足相应非劣效判定。在 ±0.75 个百分点范围下通过等效判定。这里明确给出容许界值的结果，不把界值视为已有业务标准，也不因选择一个可通过的界值就宣称工程等价已被普遍证明。

5.6.5 接纳与接纳后质量的共同变化

图 5.5 将主要控制方式的生成请求分为按时完成、接纳后失败和未接纳三类，并展示按到达阶段分组的 DSR。池化计数下，联合微调的接纳率为 52.58%（132,532/252,024），接纳后完成率为 92.69%（122,842/132,532，回合均值口径为 93.83%）；在线规划基线池化接纳率为 51.76%（130,434/252,024），池化接纳后完成率为 93.83%（122,382/130,434，精确值 93.8268%）。二者全程 DSR 接近时，联合微调接纳更多请求，而接纳后质量较低。这说明不能用其微小正向 DSR 点估计宣称所有服务质量指标均已改善。

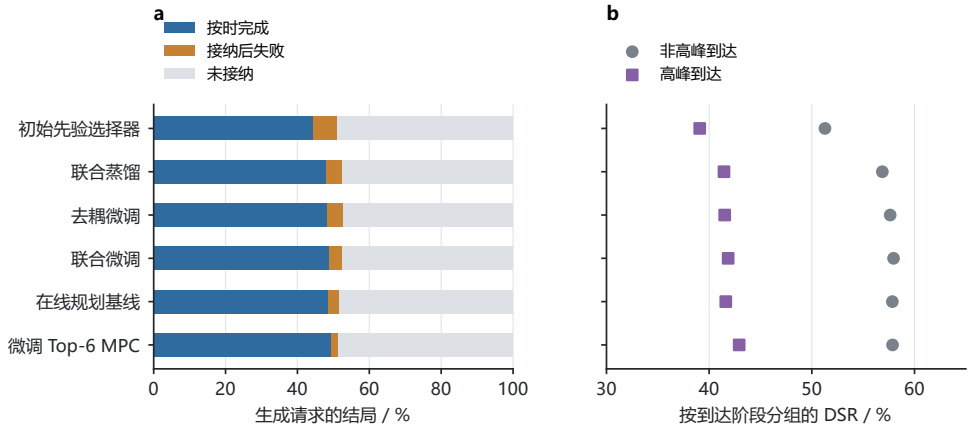


图 5.5 主要控制方式的请求结局与阶段差异。(a) 按生成请求池化的三类结局，未接纳请求同样计入分母；(b) 按到达时刻区分高峰与非高峰请求的 DSR，任务结算包含后续排空。六种方法用于说明服务构成，完整十七臂结果见表 5.4；本图为描述性结果，不作新的多重检验声明

Figure 5.5 Request outcomes and arrival-cohort DSR for six representative controls

联合微调相对去耦微调的全程条件完成率约高 0.89 个百分点，但两者接纳的并不是完全相同的请求群体。该比率可以提示准入与执行质量的取舍，不能直接解释为对相同任务的因果质量提升。高峰到达组在各控制方式下仍明显困难，说明学习改进未消除突发负载与有限物理资源之间的矛盾。

5.6.6　平均计算开销与尾延迟

表 5.7 和图 5.6 同时报告平均耗时与尾部行为。联合微调平均每步 0.520 秒，在线规划基线 1.602 秒，均值比约 3.08；微调 Top-6 MPC 为 0.722 秒，比基线约低 55%。在线规划基线累计记录 1664565 个确定性 Engine 步，联合微调两类在线前瞻计数均为零，微调 Top-6 MPC 记录 58173 个预测候选分支。

表 5.7　主要控制方式的平均耗时、尾延迟与前瞻计数

Table 5.7　Decision time, tail latency and lookahead counters

方法	均值/s	p95/s	> 1s/%	确定性步数	预测分支数
初始先验选择器	0.463	1.275	16.6	0	0
联合蒸馏	0.439	1.220	15.0	0	0
联合微调	0.520	1.297	16.9	0	0
先验 Top-6 MPC	0.692	2.166	24.3	0	58147
蒸馏 Top-6 MPC	0.711	2.196	24.4	0	58161
微调 Top-6 MPC	0.722	2.203	24.5	0	58173
在线规划基线	1.602	5.998	29.7	1664565	0

计时来自本轮评估记录，不是隔离硬件基准。预测分支使用 Engine 克隆推进，但记在预测分支计数中，不能把其确定性计数为零理解为没有仿真。物理环境未计入墙钟等待。

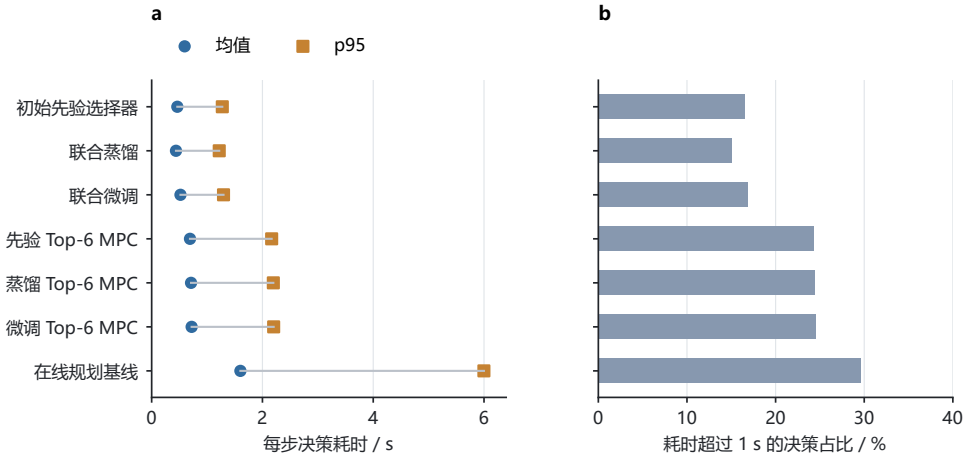


图 5.6　七种主要控制方式的决策耗时。(a) 本轮评估记录的均值与 p95；(b) 超过 1 秒的决策比例。数据来自完整调用路径，非隔离硬件时延基准。较低均值不能消除超时风险，且仿真未把墙钟等待加入任务期限演化

Figure 5.6　Mean, p95 and one-second exceedance of recorded decision time

联合微调与微调 Top-6 MPC 的 p95 分别为 1.297 秒和 2.203 秒，超过一秒的比例分别为 16.9% 和 24.5%。这些记录支持当前运行条件下的平均计算成本降低，但不支持硬实时部署。并行评估时的资源竞争、实现语言和硬件会影响墙钟

耗时，不能将均值比视为硬件无关的算法常数。物理仿真也未等待计算结束才推进请求，因此一旦把真实决策延迟加入系统，DSR 需要另行评估。

5.7 讨论与本章小结

本章结果支持一种把规划知识与环境交互分工使用的控制思路。蒸馏提供能够利用候选库的起点，完整微调方案进一步提高学生的闭环成功率；当允许在线推演时，学习先验与少量候选评价形成另一种性能和计算成本组合。它们的作用建立在当前候选支持、公开信息和动态排队协议上，不依赖把每个网络组件都解释为已经显著有效。

方法的限制也来自这些设计本身。教师及解析特征携带模型误差，反事实三步分支采用预测到达和固定延续策略，辅助评分与真实轨迹回报不一致，有限候选无法表达任意联合动作。通过相同蒸馏起点与相同确认回合下的受控反事实开关消融（cf = 0 对照 cf = 1.25），本章已明确验证：蒸馏热启动贡献了相对从头 RL 的 +3.80 个百分点基础提升，而短视界反事实辅助项贡献了相对纯在策略微调的 +0.69 个百分点增量，使策略显著超越静态蒸馏初值（+0.70 个百分点）；与此同时，在同样启用热启动与反事实辅助的微调组内部，跨层耦合与期望反馈相对去耦微调（+0.33 个百分点）和去期望向量微调（+0.11 个百分点）的全集 DSR 区间仍跨零（仅伴随条件完成率 +0.89 与 +0.57 个百分点的描述性改善）。后续若进一步研究反事实分支与真实环境采样之间的等效计算预算折算或跨层耦合在大候选池下的收益，仍需在新负载和更多独立训练谱系下开展针对性检验。

统计结论条件于三个固定父谱系和一个预定突发业务设置，尚未覆盖新父模型重训、不同突发形态或跨算力场景的普遍表现。零在线前瞻也依赖理想的状态收集和集中候选构造。信息上报延迟、字段缺失、控制等待和超时回退若进入环境，将改变可行性与服务结果，属于需要独立评价的新协议。

综上，本章完成了动态排队协议下的规划知识蒸馏、环境交互与反事实辅助 PPO 微调，以及零在线 Engine 前瞻和神经引导 Top-6 MPC 两种控制方式的构建与比较。确认结果支持完整微调方案改善蒸馏学生，支持学习引导 MPC 相对指定规划基线提高 DSR 并降低平均决策开销。与第三、四章结合时，这些结论说明从需求可见性、批量分配到持续排队控制的研究递进；它们不构成把不同协议数值拼接后的统一性能证明。

第 6 章　总结与展望

6.1　研究总结

本文面向具有截止期限的地面计算请求，研究无人机集群如何通过空间机动形成服务机会，并通过跨节点分工与动态控制利用这些机会。研究按需求可见性、固定快照批量资源竞争和跨时隙排队控制三个层次展开。三者共享实际生成、自然接纳与按时完成的请求语义，但采用的单时隙批量结算与跨时隙持续排队协议有所区别，因此分别建立性能结论，不把绝对指标合并成单一全系统收益。

6.1.1　需求感知的集群轨迹与自然接纳

第三章以全部实际生成服务请求为分母定义 DSR，并同时报告接纳率和接纳后完成率，使未覆盖需求的损失进入评价。在保持 100 m 服务半径的条件下，将允许感知范围内尚未覆盖 UE 的需求纳入上层预动作观测，通过 Attention-MAPPO 组织邻机与用户信息。独立确认中，候选 DSR 从 0.2450 增至 0.2735（提升 2.85 个百分点，训练种子配对 95% 区间为 [+1.65, +4.06] 个百分点），十个训练种子中九个为正，说明规定主场景下需求可见性与轨迹调整具有服务价值。

接纳增加同时改变接纳后的资源压力，因而覆盖改善不能替代执行质量评价。在配对外生流下，基线与候选的实际生成服务请求分母完全一致（均为 9,805,180 个）。该结果仍受预接纳信息可得性约束，同信息替代结构的探索性比较也没有确立独立注意力优势。本文据此将需求信息增量、聚合结构与物理执行约束分开解释。

6.1.2　固定快照中的跨机资源竞争与 MC-ITR

第四章在含服务程序缓存与最终批量共享算力的环境中固定位置、请求和历史状态，研究批量算力均分引起的迁移外部影响。MC-ITR 对每个候选分配重新评价整个批次，按超时数与平均归一化时延两层字典序接受严格改善。有限状态空间与严格改善保证相应搜索按无改善或预算条件终止，完整单请求邻域无改善时认证该邻域局部最优，不构成主配置全局最优证明。

主配置平均每快照超时数为 2.045，低于迭代对照 2.215；九个主场景、UE 与算力变体支持相应质量改善。第三章扩展观测候选轨迹的 400 个共享快照中，MC-ITR 平均每快照少 2.633 个超时请求，平均归一化时延降低 0.278，含贪心

初值的完整调用平均 21.876 秒。这些结果刻画离线分配余量及其搜索计算代价，反事实分配未回写环境，不能与后续闭环 DSR 相加。MC-ITR 未接入第五章在线策略，也不是其规划蒸馏教师。

6.1.3 规划蒸馏与反事实辅助动态排队控制

第五章采用独立的动态排队协议，研究突发请求到达、不可变来源与目标、断链进度保留和 EDF 计算共同作用下的联合控制。设计候选级分配与运动双分支策略，以方案条件化和运动期望反馈表达决策关联；通过两轮数据聚合蒸馏规划知识，再使用真实完整轨迹和 CRN 短视界反事实评分辅助 PPO 微调。真实轨迹奖励、辅助分支评分与在线 MPC 目标分别定义，Critic 仅使用真实轨迹 GAE 目标更新。

在三个固定父谱系、八个新工作负载和两个动作流构成的 816 个配对确认回合中，两轮规划蒸馏学生（48.04%）相对初始先验选择器（44.30%）提升 3.74 个百分点；联合微调 DSR 进一步提高至 48.74%，相对蒸馏学生初值提高 0.70 个百分点，全 31 项 DSR 比较的 Bonferroni 区间为 $[+0.39, +0.98]$ 个百分点。通过在完全相同的蒸馏起点与 48 个确认回合上开展反事实辅助开关的受控消融（$cf = 0$ 对照 $cf = 1.25$），本文明确分解出：在联合微调相对从头强化学习（44.25%）的 +4.49 个百分点总提升中，两轮规划蒸馏热启动（$cf = 0$ 时 DSR 为 48.05%）贡献了 +3.80 个百分点的基础收益，而共同随机数短视界反事实组辅助项（$cf = 1.25$）贡献了继续超越静态蒸馏学生的 +0.69 个百分点关键收益（去耦微调与无期望向量微调在启用反事实辅助后同样分别提升 +0.49 与 +0.74 个百分点）。与此同时，在同样启用热启动与反事实辅助的微调组内部，联合微调相对去耦微调（+0.33 个百分点，95% CI $[-0.08, +0.84]$）和切断期望向量微调（+0.11 个百分点，95% CI $[-0.15, +0.41]$）的全集 DSR 区间仍跨零，同时伴随已接纳任务条件完成率 +0.89 与 +0.57 个百分点的描述性改善，本文保留这一统计边界而不夸大微调内部架构耦合的独立主效应。

测试时，零在线 Engine 前瞻策略通过候选生成与解析特征直接选择动作；神经引导 Top-6 MPC 则使用学习先验参与候选筛选和最终评分。后者 DSR 为 49.31%，相对指定在线规划基线 48.56% 提高 0.75 个百分点，全 31 项区间为 $[+0.25, +1.42]$。但微调 MPC 相对蒸馏 MPC 的 0.21 个百分点差尚未显著。两种新控制方式的平均决策耗时分别为 0.520 秒和 0.722 秒，低于基线 1.602 秒，同时仍有 16.9% 和 24.5% 的决策超过一秒。因此，当前贡献是规定仿真内的规划计算摊销与性能改进，尚非硬实时或现实部署证明。

6.2　综合认识与适用范围

需求感知、资源分工与队列控制分别揭示了时限服务链条的不同限制。看见需求使轨迹有机会扩大接纳，完整分配评价识别批量外部影响，持续队列模型则把当前选择与后续资源占用联系起来。这些认识可以共同指导方法设计，但各章的数值增益不能独立相加。尤其第五章采用 EDF 计算与跨时隙进度保留，区别于第三、四章最终批量共享算力的单步执行模型。

协议边界需要保持明确。第三、四章采用单时隙内完成接纳与结算的批量共享算力模型，并包含服务程序缓存动态；第五章采用跨时隙保留传输与计算进度的持续队列模型。两类协议均聚焦于通信、计算与截止期服务指标，未建模机身推进能耗或电池电量耗尽退网。若将缓存机制与跨时隙排队协议整合，需要重新冻结目标、状态转移和计数规则后进行闭环评价。

信息与计算条件同样限制外推。第五章依赖集中收集的公开请求和剩余服务状态、冻结上游候选模型及安全启发式，有限候选集不覆盖任意动作。反事实未来由历史预测生成，其固定延续策略与真实学生后续动作不同。统计区间条件于三个固定父谱系，只反映所评估工作负载与动作流变化，不包含完整重新训练的不确定性。第三、四章的单时隙变体敏感性结果属于不同执行协议，不能替代第五章动态排队联合策略的跨场景验证。

本文的机动模型没有建立完整飞行动力学、姿态和扰动模型。第五章的线性全路径几何检查比只检验离散端点更具体，但仍不是飞行安全或稳定性证明。仿真也没有将消息收集、策略推理和实际控制等待写入请求截止期演化，因而平均软件耗时下降不能直接推出现实服务质量不变。

6.3　后续研究方向

首先，围绕反事实辅助计算预算与候选池规模开展进一步机制检验。第五章已通过相同蒸馏初值与相同确认回合下的受控消融（cf = 0 对照 cf = 1.25）证实反事实组辅助项相对纯在策略 PPO-GAE 提供 +0.69 个百分点的净增益；后续可进一步将三步反事实克隆分支消耗的仿真步折算为等量真实环境 rollout 步数，检验相同总仿真调用预算下模型辅助分支与纯环境交互的样本效率折中。对双分支耦合结构，也可在更大候选集合与新增独立训练谱系下继续检验方案条件化与运动期望反馈的适用边界。

其次，研究模型误差与负载变化。改变突发持续时间、幅度、空间热点与任务期限，分别检查需求估计、释放时间近似和固定三步延续产生的偏差。冻结模

型零样本评价与重新训练适配应分开报告；新增父谱系用于估计训练不确定性，不能以同一模型更多评估回合替代。对解析近似，应同时报告误差、候选排序和最终决策差异，避免仅用总体相关系数推断控制可靠性。

再次，将决策等待和信息成本写入环境。实际系统需要在请求收集、推理或前瞻超时后继续推进队列，明确旧动作保持、安全回退与异步更新规则，并测量计入等待后的 DSR。对 Top-6 MPC，可在相同候选与评分下改变前瞻预算，研究计算成本是否转化为服务净收益。零在线前瞻仍有解析计算，需在目标硬件上测量完整路径的尾延迟。

最后，可在新协议中重新引入能源、通信和飞行执行约束。应明确推进与通信能耗、剩余电量、返航保留和 UE 能量请求如何改变到达及接纳，统一记录任务损失与平台退出。对覆盖信息设置延迟或缺失，并将位置跟踪误差、传播遮挡和链路中断纳入执行，可检验当前理想协调结果在更实际条件下保留多少。上述扩展需要新的物理协议和独立实验，不能由现有 DSR 与轨迹长度直接推断。

6.4 本章小结

本文分别完成需求感知轨迹决策、固定快照截止期优先分配，以及规划蒸馏与反事实辅助动态排队控制的研究。已有证据说明，需求可见性、批量资源耦合和持续排队均会影响集群服务成功；合理利用规划知识并通过环境交互改善策略，能够在规定协议下形成有价值的服务与计算成本组合。进一步的机制、能量和部署结论，仍需在相应匹配对照及真实执行条件下建立。

参考文献

[1] Chung S J, Paranjape A A, Dames P, et al. A survey on aerial swarm robotics[J]. IEEE Transactions on Robotics, 2018, 34(4): 837-855.

[2] Mao Y, You C, Zhang J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2322-2358.

[3] Zeng Y, Zhang R, Lim T J. Wireless communications with unmanned aerial vehicles: opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.

[4] Mozaffari M, Saad W, Bennis M, et al. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.

[5] Hu X, Wong K K, Yang K, et al. UAV-assisted relaying and edge computing: Scheduling and trajectory optimization[J]. IEEE Transactions on Wireless Communications, 2019, 18(10): 4738-4752.

[6] Yu Z, Gong Y, Gong S, et al. Joint task offloading and resource allocation in UAV-enabled mobile edge computing[J]. IEEE Internet of Things Journal, 2020, 7(4): 3147-3159.

[7] Huang L, Bi S, Zhang Y J A. Drl based online offloading framework for uav-mec systems[J]. IEEE Transactions on Wireless Communications, 2021, 20(5): 3025-3039.

[8] Khurshid T, Ahmed W, Rehan M, et al. A DRL strategy for optimal resource allocation along with 3D trajectory dynamics in UAV-MEC network[J]. IEEE Access, 2023, 11: 54664-54678.

[9] Skaltsis G M, Shin H S, Tsourdos A. A review of task allocation methods for UAVs[J]. Journal of Intelligent & Robotic Systems, 2023, 109(4): 76.

[10] Zhou F, Wu Y, Hu R Q, et al. Latency optimization for UAV-assisted mobile edge computing [J]. IEEE Transactions on Communications, 2020, 68(9): 5721-5735.

[11] Zhang G, Shen Y, Yang K. Energy-efficient UAV-assisted mobile edge computing[J]. IEEE Transactions on Vehicular Technology, 2021, 70(8): 8234-8238.

[12] Hu X, Yang K, Zheng Z. UAV-assisted mobile edge computing: A joint trajectory and resource optimization approach[J]. IEEE Transactions on Wireless Communications, 2021, 20 (7): 4445-4458.

[13] Liu Y, Wang K, Pan C, et al. Energy-efficient resource allocation for UAV-assisted mobile edge computing[J]. IEEE Transactions on Communications, 2020, 68(11): 6963-6977.

[14] Wu Q, Zeng Y, Zhang R. Joint trajectory and communication design for multi-UAV enabled wireless networks[J]. IEEE Transactions on Wireless Communications, 2021, 20(3): 1735-1749.

[15] Bai T, Wang J, Ren Y, et al. Multi-agent reinforcement learning for UAV-assisted mobile edge computing[J]. IEEE Transactions on Wireless Communications, 2021, 20(12): 8184-8198.

[16] Yuan X, Xie Z, Tan X. Computation offloading in UAV-enabled edge computing: A Stackelberg game approach[J]. Sensors, 2022, 22(10): 3854.

[17] 曾耀平, 李怀, 陈世森, 等. 无人机部署与卸载策略优化[J]. 浙江大学学报（工学版）, 2026, 60(8): 1686-1696.

[18] 王义君, 王雅出, SHAHD Batool, 等. 无人机辅助动态权重边缘计算卸载策略研究[J]. 电子与信息学报, 2026, 48(7): 3071-3083.

[19] 李侍阳, 朱晓荣. 面向感知与 AI 协同任务的无人机巡检多维资源联合优化算法[J]. 电子与信息学报, 2026, 48(5): 2166-2177.

[20] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[21] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256.

[22] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning [C]. Proceedings of the International Conference on Learning Representations (ICLR). 2016.

[23] Shakarami A, Ghobaei-Arani M, Shahidinejad A. Beyond the edge: An advanced exploration of reinforcement learning for mobile edge computing, its applications, and future research trajectories[J]. IEEE Communications Surveys & Tutorials, 2024, 26(3): 1582-1636.

[24] 黄子祥, 张新有. 应急场景下多无人机协同辅助计算卸载策略[J]. 传感器与微系统, 2026, 45(5): 142-148.

[25] 尤昕阳, 李旭龙, 王浩彬, 等. 基于强化学习的多无人机协同 MEC 任务卸载方案[J]. 西安电子科技大学学报, 2026, 53(1): 116-128.

[26] De A, Aksaray D. Sample efficient multi-agent reinforcement learning with centralized training [C]. Proceedings of the IEEE Conference on Decision and Control. IEEE, 2020: 5958-5963.

[27] Guo Y, Liu J, Yu R, et al. Mappo-pis: A multi-agent proximal policy optimization method with prior intent sharing for cavs' cooperative decision-making[C]. Proceedings of the European Conference on Computer Vision (ECCV) Workshops. Springer, 2024: 245-262.

[28] Li B, Yang R, Liu L, et al. Robust computation offloading and trajectory optimization for multi-uav-assisted mec: A multi-agent drl approach[J]. IEEE Internet of Things Journal, 2024, 11 (3): 4775-4786.

[29] Tao Y, Kuang Z, Hou F, et al. Online service selection and task offloading in UAV-assisted MEC via deep reinforcement learning[J]. IEEE Transactions on Cognitive Communications and Networking, 2026, 12: 4159-4173.

[30] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive

environments[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 6379-6390.

[31] Yu C, Velu A, Vinitsky E, et al. The surprising effectiveness of PPO in cooperative multi-agent games[C]. Advances in Neural Information Processing Systems: Vol. 35. 2022: 24611-24624.

[32] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-agent learning based on team reward[C]. Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems. 2018: 2085-2087.

[33] Rashid T, Samvelyan M, Schroeder de Witt C, et al. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning[C]. Proceedings of Machine Learning Research: Vol. 80 Proceedings of the 35th International Conference on Machine Learning. 2018: 4295-4304.

[34] Hady M A, Hu S, Pratama M, et al. Multi-agent reinforcement learning for resources allocation optimization: A survey[J]. Artificial Intelligence Review, 2025, 58(11): 354.

[35] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 5998-6008.

[36] Zhang P, Li G. A cooperative dynamic target search approach for multi-uav systems utilizing the mappo algorithm[J]. Discover Artificial Intelligence, 2025, 5(1): 153.

[37] Li X, Zhang J. Context-aware communication for multi-agent reinforcement learning[C]. Proceedings of the 23rd International Conference on Autonomous Agents and Multiagent Systems (AAMAS). IFAAMAS, 2024: 1156-1164.

[38] Li X, Xue S, He Z, et al. Tmac: A transformer-based partially observable multi-agent communication method[J]. PeerJ Computer Science, 2025, 11.

[39] Rusu A A, Gomez Colmenarejo S, Gulcehre C, et al. Policy distillation[C]. Proceedings of the International Conference on Learning Representations (ICLR). 2016.

[40] Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning[C]. Proceedings of Machine Learning Research: Vol. 15 Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics. PMLR, 2011: 627-635.

[41] Shi W, Cao J, Zhang Q, et al. Edge computing: Vision and challenges[J]. IEEE Internet of Things Journal, 2016, 3(5): 637-646.

[42] Abbas N, Zhang Y, Taherkordi A, et al. Mobile edge computing: A survey[J]. IEEE Internet of Things Journal, 2018, 5(1): 450-465.

[43] Wang X, Han Y, Leung V C, et al. Convergence of edge computing and deep learning: A comprehensive survey[J]. IEEE Communications Surveys & Tutorials, 2020, 22(2): 869-904.

[44] Watkins C J, Dayan P. Q-learning[J]. Machine Learning, 1992, 8(3-4): 279-292.

[45] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436-444.

[46] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. MIT press, 2018.

[47] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[C]. Proceedings of the International Conference on Learning Representations (ICLR). 2016.

[48] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017.

[49] Littman M L. Markov games as a framework for multi-agent reinforcement learning[C]. Proceedings of the 11th International Conference on Machine Learning. Morgan Kaufmann, 1994: 157-163.

[50] Busoniu L, Babuska R, De Schutter B. A comprehensive survey of multiagent reinforcement learning[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part C, 2008, 38(2): 156-172.

[51] Oroojlooyjadid A, Hajinezhad D. A review of cooperative multi-agent deep reinforcement learning[J]. Applied Intelligence, 2023, 53(11): 13677-13722.

[52] Gronauer S, Diepold K. Multi-agent deep reinforcement learning: A survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.

[53] Rashid T, Farquhar G, Peng B, et al. Attention-based multi-agent reinforcement learning[C]. Proceedings of the 37th International Conference on Machine Learning. 2020: 7958-7968.

致谢

在此感谢导师的悉心指导，感谢实验室同学的帮助，感谢家人的支持。

在读期间取得的科研成果