

中山大學
SUN YAT-SEN UNIVERSITY

中山大学专业硕士学位论文

基于 Attention-MAPPO 的多无人机 MEC 轨迹与任务卸载协同优化方法

Attention-MAPPO Based Collaborative Trajectory and Task Offloading Optimization for Multi-UAV Mobile Edge Computing

专　　业：　计算机技术

学位申请人：　YOUR_NAME

指 导 教 师：　YOUR_SUPERVISOR 教授

论文答辩委员会主席：_____

论文答辩委员会成员：_____

_____

_____

_____

2026 年 7 月

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：　　年　　月　　日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：　　导师签名：

日期：　　年　　月　　日　　日期：　　年　　月　　日

论文题目：基于 Attention-MAPPO 的多无人机 MEC 轨迹与任务卸载协同优化方法

专　　业：计算机技术
硕 士 生：YOUR_NAME
指导教师：YOUR_SUPERVISOR 教授

摘　要

随着 5G 技术的快速发展和迭代，多无人机辅助移动边缘计算（Multi-UAV MEC）系统逐渐成为未来通信网络的重要组成部分。凭借灵活的机动部署、视距链路和按需覆盖等优势，无人机辅助边缘计算在应急通信、智慧城市、低空智能网络等场景中展现出巨大的应用潜力，可有效增强边缘覆盖、任务接入和协同计算能力。然而，多无人机 MEC 系统的优化仍然面临诸多挑战，包括无人机轨迹规划、请求级卸载决策、截止期约束、宏基站（MBS）回传负载以及终端设备能量动态等问题。由于无人机的飞行特性和无线信道环境的动态变化，传统的启发式优化算法难以高效应对这些复杂问题。近年来，多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）算法在解决复杂的协同决策问题中表现出色。因此，将 MARL 算法应用于多无人机 MEC 系统的轨迹与任务卸载协同优化研究，以提升系统服务质量、降低 UAV 侧能耗、改善用户公平性，具有重要的研究意义。

本文面向多无人机 MEC 系统中轨迹控制与任务卸载的强耦合问题，提出基于多智能体强化学习的双层协同优化框架。系统中，服务请求优先关联至自然覆盖范围内的 UAV；对于未被自然覆盖的请求，按照最近 UAV 原则完成关联，并在真实链路条件下进入后续处理流程。具体研究内容与贡献如下：

（1）针对连续轨迹控制与离散卸载决策联合学习导致训练复杂度高的问题，本文提出基于注意力机制的多智能体近端策略优化（Attention-MAPPO）双层框架。该框架将协同调度分解为上层轨迹控制和下层请求级卸载两个决策层：上层利用 Attention-MAPPO 建模无人机间协同关系并输出轨迹动作；下层利用约束注意力卸载 MAPPO，为每个有效服务请求选择本地 UAV、协作 UAV 或 MBS 执行。仿真结果表明，所提框架能够稳定收敛，并提升系统综合奖励。

（2）针对多 UAV 协同场景下不可行动作探索效率低、约束权衡难以刻画的问题，本文设计请求级质量感知动作掩码和拉格朗日约束机制。动作掩码在运行

时屏蔽明显不可行的协作 UAV 与 MBS 动作，减少无效探索；拉格朗日约束将截止时间满足率（deadline satisfaction rate, DSR）和 MBS 负载纳入可解释的软约束权衡。仿真结果表明，所提机制能够调节 MBS 依赖和协作卸载比例，并刻画 DSR、能耗与 MBS 负载之间的偏好关系。

（3）针对现有工作忽略终端设备能量动态、难以反映系统长期运行特性的问题，本文显式建模 UAV 飞行能耗、用户设备（user equipment, UE）电池动态和无线能量传输（wireless power transfer, WPT）机制。对比实验和参数敏感性实验表明，在统一的服务请求关联与处理流程下，所提框架取得最高服务公平性、最低 UAV 侧能耗和最低 MBS 负载比例，同时保持具有竞争力的 DSR；在不同 UE 负载和 UAV 算力条件下，该框架仍表现出稳定的能效、公平性与服务质量折中能力。

关键词：多无人机，移动边缘计算，轨迹优化，任务卸载，深度强化学习

Title：Attention-MAPPO Based Collaborative Trajectory and Task Offloading Optimization for Multi-UAV Mobile Edge Computing

Major: Computer Technology
Name: YOUR_NAME
Supervisor: Prof. YOUR_SUPERVISOR

ABSTRACT

With the rapid development and iteration of 5G technology, multi-UAV assisted mobile edge computing (Multi-UAV MEC) systems have gradually become an important component of future communication networks. With the advantages of flexible maneuvering deployment, line-of-sight links, and on-demand coverage, UAV-assisted edge computing has shown great application potential in scenarios such as emergency communications, smart cities, and low-altitude intelligent networks, which can effectively enhance edge coverage, task admission, and cooperative computing capabilities. However, the optimization of multi-UAV MEC systems still faces numerous challenges, including UAV trajectory planning, per-request offloading decisions, deadline constraints, macro base station (MBS) backhaul load, and terminal device energy dynamics. Due to the flight characteristics of UAVs and the dynamic changes of wireless channel environments, traditional heuristic optimization algorithms are difficult to efficiently address these complex problems. In recent years, multi-agent reinforcement learning (MARL) algorithms have shown excellent performance in solving complex collaborative decision-making problems. Therefore, applying MARL algorithms to the collaborative optimization of trajectory and task offloading in multi-UAV MEC systems, in order to improve system service quality, reduce UAV-side energy consumption, and enhance user fairness, has important research significance.

This paper proposes a hierarchical multi-agent reinforcement learning framework to address the strong coupling between trajectory control and task offloading in multi-UAV MEC systems. Service requests are first associated with UAVs that naturally cover them; requests outside natural coverage are associated with the nearest UAV and subsequently processed under the corresponding physical link conditions. The main contributions are as follows:

(1) To reduce the training complexity of jointly learning continuous trajectory control and discrete offloading decisions, this paper proposes an attention-based multi-agent proximal policy optimization (Attention-MAPPO) framework. The framework decomposes collaborative scheduling into an upper trajectory-control layer and a lower per-request offloading layer. The upper layer uses Attention-MAPPO to model inter-UAV coordination and generate trajectory actions, whereas the lower layer uses constrained attention offload MAPPO to select local UAV execution, cooperative UAV execution, or MBS execution for each valid service request. Simulation results show that the framework converges stably and improves the overall system reward.

(2) To improve exploration efficiency and characterize constraint trade-offs in multi-UAV collaboration, this paper designs a request-level quality-aware action mask and a Lagrange constraint mechanism. The action mask blocks clearly infeasible cooperative-UAV and MBS actions at runtime to reduce ineffective exploration. The Lagrange constraint incorporates deadline satisfaction rate (DSR) and MBS load into an interpretable soft-constraint trade-off. Simulation results show that these mechanisms regulate MBS dependence and cooperative offloading ratios, while characterizing the trade-off among DSR, energy consumption, and MBS load.

(3) To capture long-term operational characteristics neglected when terminal energy dynamics are ignored, this paper explicitly models UAV flight energy consumption, user equipment (UE) battery dynamics, and wireless power transfer (WPT). Comparative and sensitivity experiments show that, under a unified service-request association and processing procedure, the proposed framework achieves the highest service fairness, the lowest UAV-side energy consumption, and the lowest MBS load ratio while maintaining a competitive DSR. The framework further maintains a stable trade-off among energy efficiency, fairness, and service quality under varying UE loads and UAV computing capacities.

KEY WORDS: Multi-UAV, mobile edge computing, trajectory optimization, task offloading, deep reinforcement learning

目　录

第 1 章　绪论 1
1.1　研究背景与意义 1
1.2　国内外研究现状 2
1.3　研究内容及贡献 6
1.4　论文组织结构 6
1.5　本章小结 7
第 2 章　相关技术简介 8
2.1　无人机辅助移动边缘计算技术 8
2.2　多智能体强化学习技术 11
2.3　注意力机制 15
2.4　本章小结 16
第 3 章　无人机辅助 MEC 系统中的轨迹与任务卸载协同优化算法 17
3.1　系统模型与问题建模 17
3.2　基于 Attention-MAPPO 的双层协同优化算法 23
3.3　仿真设置与性能评估 29
3.4　本章小结 42
第 4 章　总结与展望 43
4.1　工作总结 43
4.2　未来展望 44
4.3　本章小结 44
参考文献 45
附录 A　补充材料 50
A.1　补充章节 50
致谢 51
在读期间取得的科研成果 52

插图目录

图 2.1 移动边缘计算三层架构示意图 9
图 2.2 UAV 辅助通信应用场景示意图 11
图 2.3 强化学习智能体与环境交互框架 12

图 3.1 多 UAV-MEC 系统架构 18
图 3.2 基于注意力机制的双层协同优化架构 24
图 3.3 主配置性能工作点与服务约束 34
图 3.4 固定 seed 示例下不同算法的无人机二维飞行轨迹对比 35
图 3.5 卸载分布对比 36
图 3.6 消融实验对比 37
图 3.7 综合对比方法的多指标比较 38
图 3.8 综合对比方法的服务表现与执行位置分布 39
图 3.9 不同地面节点数量下的三指标敏感性分析 40
图 3.10 不同 UAV 算力下的三指标敏感性分析 40
图 3.11 DSR 优先配置下的性能权衡 41

图 A.1 一个配有彩色表格的插图 50

附表目录

表 3.1　下层离散动作空间 25
表 3.2　仿真环境参数 30
表 3.3　算法训练参数 31
表 3.4　主配置策略组合 31
表 3.5　下层消融实验配置 32
表 3.6　主配置实验结果（均值 ± 标准差，$N = 30$） 33
表 3.7　主配置的自然覆盖与执行位置分布 33
表 3.8　下层模块消融实验结果（均值，$N = 30$） 36
表 3.9　端到端联合 MAPPO 评估结果 39
表 3.10　DSR 优先配置对比（均值 ± 标准差，$N = 30$） 41

符号说明

N	UAV 数量
M	UE 数量
H	UAV 飞行高度
τ	时间步时长
T	episode 总时间步数
R_c	UAV 覆盖半径
v_{max}	UAV 最大飞行速度
B_{max}	UE 电池容量
B_{low}	UE 电池临界阈值
P_{move}	UAV 飞行功率
P_{hover}	UAV 悬停功率
P_{wpt}	WPT 发射功率
f_{mbs}	MBS 计算能力
f_{uav}	UAV 计算能力
η	WPT 能量采集效率
β_0	参考距离 1m 时的信道功率增益
DSR	Deadline satisfaction rate
P_{nat}	自然覆盖服务比例
J	Jain 公平性指数
R_t	系统级综合奖励
R_{lower}	下层局部训练奖励
λ_{dsr}	DSR Lagrange 乘子
λ_{mbs}	MBS load Lagrange 乘子

第 1 章　绪论

1.1　研究背景与意义

无线通信在过去 30 年经历了飞速发展阶段，促进了社会和商业的发展，重塑了人们的生活方式。从 2G 时代开始采用数字信号，提供语音和短信服务，到 3G 技术使得移动网络支持更高速的数据传输，推动了智能手机和移动互联网的发展，再到 4G 网络大大提升了数据传输速度，支持高清视频、流媒体等应用。无线移动通信已经成为现代社会发展的重要支柱。

目前，第五代移动通信技术（The 5th Generation Mobile Communication Technology, 5G）的商用[1]，使得无线通信的发展已经迈入了一个崭新的阶段。国际电信联盟（International Telecommunication Union, ITU）为 5G 定义了三大应用场景：增强移动宽带（enhanced Mobile Broadband, eMBB）、超高可靠低时延通信（Ultra-Reliable and Low Latency Communication, URLLC）和海量机器类通信（massive Machine Type Communication, mMTC)[2]。其中，eMBB 主要关注提升用户的移动宽带体验，尤其是在高密度场景下；URLLC 主要针对那些对通信可靠性和延迟要求极高的应用场景；mMTC 则是针对大量低功耗、低成本设备的通信需求。

随着 5G 技术的快速发展和迭代，无人机（Unmanned Aerial Vehicle, UAV）辅助通信系统逐渐成为未来通信网络的重要组成部分[3-4]。无人机因其灵活性、低成本和高机动性，在多个领域展现出巨大的应用潜力，提供了广阔的发展前景，诸如在军事方面执行侦察任务，在自然灾害救灾方面提供紧急通信服务以及在工业物联网方面进行收集和传输物联网设备的数据等[5]。虽然无人机辅助通信在多种应用场景中展现出巨大潜力，但其在资源分配方面仍存在诸多待解难题。其中，频谱管理是关键问题之一。由于无人机数量不断增加，其频谱资源需求剧增，如何高效地分配有限的无线频谱以避免干扰、提高通信质量是当前研究的重点。其次，功率控制也是一个重要挑战。无人机通常依赖电池供电，而无线通信的功率消耗对无人机的续航时间影响极大，因此需要优化路径规划策略和功率分配策略，以在延长续航时间的同时确保通信质量。此外，在用户调度方面，随着无人机网络用户数量的增加，如何有效实现智能调度和用户接入，保障通信的公平性和稳定性，也是亟待解决的问题。

近年来，深度强化学习（Deep Reinforcement Learning, DRL）作为一种结合了深度学习和强化学习的先进技术，在解决复杂的决策问题中表现出色[6]。得

益于深度学习的特征提取能力和强化学习的决策能力，DRL 在诸如游戏、机器人控制、无线通信等多个领域取得了显著的成功[7-9]。无人机辅助通信系统在实时性、可靠性和覆盖范围等方面对资源管理提出了极高的要求。尤其是在大规模、多用户、高密度和快速变化的环境下，传统的资源分配方法如静态的频谱分配、固定功率控制等，往往无法满足无人机网络的实际需求。并且无人机的移动性和任务需求的变化使得其通信网络常常处于一个高度动态的状态。如何在有限的频谱资源和功率资源条件下，实现对无人机的公平和高效调度，是一个极具挑战性的任务。在资源分配和动态决策等问题上，DRL 展现出独特的优势，能够处理那些传统算法难以应对的复杂情境。鉴于无人机通信环境的高度动态性与资源优化问题的复杂性，引入深度强化化学习方法以实现资源的智能化分配，具有重要的研究价值和实际意义。

在多无人机 MEC 系统中，服务质量并不只由单一因素决定。无人机轨迹会影响 UE-UAV 链路速率、协作无人机可达性、UAV-MBS 回传质量以及区域覆盖公平性；请求卸载策略则会进一步决定任务时延、UAV 计算负载、UAV 侧能耗、宏基站负载和截止期满足率。因此，轨迹控制和任务卸载之间存在强耦合关系[10-11]。若只优化轨迹，系统可能获得较好的覆盖，却仍然将大量请求回退到 MBS；若只优化卸载，策略只能被动适应当前 UAV 分布，无法主动创造更好的协作机会。如何设计高效的多智能体强化学习模型，以增强 UAV 辅助通信的智能资源管理能力，是未来研究的重要方向之一。

1.2 国内外研究现状

随着无人机的迅速发展，特别是在 5G 及未来 6G 网络中，无人机辅助通信作为一种关键技术，受到了广泛关注[3-4]。在无人机辅助通信系统中，现有研究主要聚焦于无人机部署、轨迹优化、系统吞吐量提升及能量消耗控制等优化问题。针对资源分配与运动轨迹优化的联合优化问题，其本质可归类为具有高度非线性与组合特性的混合整数非线性规划（Mixed Integer Non-Linear Programming, MINLP）问题，常规优化方法难以在合理时间内获得全局最优解。

1.2.1 传统优化方法研究现状

目前，不同研究利用数学优化理论对该组合优化问题进行求解优化。Trotta 等人[12] 提出了一种基于博弈论与群体移动模型的空中网格网络部署方案，该方案考虑了无人机之间的协作程度，并制定了相应的充电调度策略。Lai 等人[13] 提出了一个适应性和公平部署无人机的方案，以解决无人机和用户之间关联的

不平衡问题。Wang 等人[14] 提出了一种集中式贪婪搜索方案，在不连续空间中启发式地获得无人机的最小数目及其次优位置，之后采用分布式运动算法使每架无人机能够在连续空间内自主控制其朝着最佳位置运动。Yang 等人[15] 研究了高密度区域的无人机流量卸载问题，通过基于泊松-均匀分布构建了异构流量的分布模型，并通过优化无人机的部署高度，将三维部署问题转化为二维部署问题，以缓解网络拥塞问题。Lee 等人[16] 基于竞争聚类与 Stackelberg 博弈，提出了一种无人机辅助 NB-IoT 系统的优化方法，实现了无人机位置调整与资源分配的联合优化。Kumar 等人[17] 研究了毫米波 UAV 网络中的动态资源分配问题，采用拉格朗日对偶分解方法求解全局最优解，并在计算复杂度较高的情况下，提出了一种收敛速度更快的次优解方案，在保证最低用户速率的前提下优化系统总吞吐量。

为进一步提高频谱资源利用率，部分研究将 NOMA 技术应用于无人机辅助通信系统。Duan 等人[18] 提出了一种基于 K-means 聚类与多对多匹配算法的多无人机辅助物联网 NOMA 资源分配方案，以提高上行链路传输效率。Qin 等人[19] 研究了 UAV 轨迹优化与资源分配的联合优化问题，提出了一种基于 C-NOMA 的异构 AGIN 架构，以提升系统吞吐量。Guo 等人[20] 研究了无人机辅助移动边缘计算系统（Mobile Edge Computing, MEC）中的 NOMA 资源管理问题，并利用逐次凸逼近（Successive Convex Approximations, SCA）解决轨迹和功率分配的联合优化问题，同时结合差分凸规划理论（the Difference of Convex Programming Theory）获得次优解。此外，部分研究针对无人机辅助 MEC 系统中的资源分配、轨迹设计、用户关联及动态任务卸载等优化问题展开了深入探索[10-11]。

上述对组合问题进行求解优化存在一定的局限性，在复杂的通信网络中，实时获取信道状态信息（Channel State Information, CSI）和无人机的实时位置，是不现实的[5]。基于博弈论的无人机网络部署方案需要无人机之间进行频繁的信息交互，这样使得信令开销过大导致能量消耗增加，进而影响 UAV 网络的持续运行能力。此外，基于启发式算法的无人机网络资源分配方案，求解过程需要进行多次迭代，并且随着无人机数量的增加，需要进行的迭代次数呈指数级增长，为了能够快速求解只能退而求得次优解。因此，在实际通信场景中，传统数学优化方法在 UAV 辅助通信资源分配中的适用性受限，其主要挑战包括计算复杂度高、全局状态信息难以获取及算法收敛速度较慢等。

1.2.2 深度强化学习方法研究现状

近年来，DRL 在复杂决策问题中的优越性促使研究者将其应用于 UAV 辅助通信网络资源管理问题。He 等人[21] 提出了一种基于 Q-learning 的无人机轨迹优化算法，以最优路径规划降低数据传输时延。Liu 等人[22] 在目标跟踪任务中将无人机路径规划建模为马尔可夫决策问题，并采用 DQN（Deep Q-Network, DQN）方法，以优化无人机的路径规划策略。Li 等人[5] 构建了两层深度强化学习框架，以优化无人机辅助无线传感器网络的数据采集效率。针对灾害环境下的应急通信，Kim 等人[23] 提出了一种基于 DQN 的无人机路径优化方案，以确保受灾用户能够在极端环境中与救援队实现高效通信。Li 等人[24] 提出了基于深度强化学习的均场博弈（Mean Field Games, MFG）算法，利用深度神经网络优化无人机的功率控制策略，以最小化干扰并提升能量效率。由于无人机间的信息交换难以实现、全局状态信息存在时延，Fan 等人[25] 提出了容迟多智能体深度强化学习（Delay-Tolerant Multi-Agent DRL, DT-MADRL）算法，以联合优化无人机的轨迹和传输控制策略。Ahmad 等人[26] 针对 B5G 无人机辅助通信系统，提出了一种高效的基于 DRL 的深度确定性策略梯度（Deep Deterministic Policy Gradient, DDPG）机制，实现以能量效率和平均吞吐量最大化为双重目标实现资源的最优分配。Ghomri 等人[27] 提出了一种基于最近策略优化（Proximal Policy Optimization, PPO）的 DRL 算法，以优化 NOMA-UAV 网络的能效（Energy Efficiency, EE）同时兼顾了远近公平性。

在 MEC 任务卸载与资源分配方面，Huang 等人[28] 提出了一种基于深度强化学习的在线卸载框架，优化无人机作为 MEC 服务器的任务调度。Khurshid 等人[29] 利用了一种基于连续动作空间的 DDPG 方法优化了 UAV-MEC 系统中无人机三维布局与任务卸载策略。Liu 等人[30] 研究了一种多维联合优化方法，涵盖无人机悬停点选择、任务收集时间比例、信道选择、任务卸载策略等，以提高 UAV 辅助 MEC 的效率。此外，部分研究结合智能反射面（Intelligent Reflecting Surface, IRS）技术，进一步提升无人机辅助 MEC 系统的通信性能[31]。

1.2.3 多智能体强化学习方法研究现状

多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）作为 DRL 的重要分支，在多无人机协同决策问题中展现出独特优势。与单智能体 DRL 相比，MARL 能够更好地建模多无人机之间的协作与竞争关系，实现更高效的资源分配和任务调度。

近年来，MARL 在无人机辅助通信领域的应用逐渐增多。Liu 等人[32] 提出

了基于 MARL 的多无人机协同优化框架，通过分布式决策实现全局最优。黄子祥等[33] 针对应急场景提出基于 MADRL 的多无人机协同计算卸载策略，联合优化卸载比例、飞行角度和速度，并使用 Jain 公平性指数衡量负载均衡。尤昕阳等[34] 提出基于柔性 Actor-Critic 的多无人机协同 MEC 任务卸载方案，联合决策任务卸载比例、无人机选择、传输功率与算力分配。王义君等[35] 提出基于协同缓存自适应的分层多元宇宙优化算法（CCAH-MVO），在三层网络架构下协同优化缓存、卸载和资源分配。曾耀平等[36] 采用 Stackelberg 博弈方法联合优化 UAV 部署和 UE 卸载策略。李侍阳等[37] 面向感知与 AI 协同任务，提出基于 MILP 和 SCA 的多维资源联合优化算法。

在 MARL 算法方面，MAPPO（Multi-Agent Proximal Policy Optimization）作为 PPO 的多智能体扩展，在多无人机协同任务中表现出色[38]。MAPPO 通过集中式训练分布式执行（Centralized Training with Decentralized Execution, CTDE）的范式，在训练阶段利用全局信息优化策略，在执行阶段仅依赖局部观测进行决策，有效平衡了全局最优与分布式执行的需求。

1.2.4　现有研究的局限性

综上所述，尽管目前国内外已有许多无人机辅助通信系统的研究，但仍然存在诸多问题亟待解决。首先，在动态环境与干扰较强的场景下，无人机辅助 MEC 系统中的计算卸载与资源分配联合优化问题尚未得到充分研究。其次，尽管深度强化学习在无人机辅助通信领域展现出巨大潜力，但在大规模无人机网络中的计算复杂度、泛化能力及实时决策能力仍面临挑战。此外，现有研究大多忽略终端设备的能量动态，导致系统长期运行不可持续。

具体而言，现有研究存在以下局限性：

1. **动作空间耦合问题**：在多无人机 MEC 系统中，连续轨迹控制与离散卸载决策的合并导致动作空间维度急剧增加，传统 DRL 方法难以有效处理这种混合动作空间。
2. **约束处理不足**：现有研究大多采用简单惩罚项处理约束，缺乏对约束违反程度的量化分析和可解释的约束权衡机制。
3. **能量动态忽略**：多数研究假设终端设备能量无限，忽略了 UE 电池动态和无线能量传输机制，导致系统长期运行不可持续。
4. **可解释性缺失**：深度强化学习模型的决策过程缺乏可解释性，难以分析无人机之间的协作关系和决策依据。

与上述工作不同，本文将强耦合的轨迹–卸载问题分解为可训练、可复现、

可解释的双层 MARL 决策过程，并显式建模终端设备能量动态。所提框架利用注意力机制建模无人机间协作关系，结合请求级质量感知动作掩码和拉格朗日软约束，在动态服务请求下协同优化 UAV 轨迹与任务卸载。

1.3 研究内容及贡献

本文的主要贡献如下：

1. 提出基于 Attention-MAPPO 的多 UAV MEC 轨迹与任务卸载协同优化框架，将轨迹控制和请求级卸载分解为上层 Attention-MAPPO 和下层约束注意力卸载 MAPPO 两个协同决策层。系统中的服务请求优先关联至自然覆盖范围内的 UAV；未被自然覆盖的请求按照最近 UAV 原则关联，并在真实链路条件下进入后续处理流程。
2. 设计请求级质量感知动作掩码，在运行时屏蔽明显不可行的协作 UAV 与 MBS 动作，以减少无效探索；通过消融实验分析该机制对协作卸载和 MBS 负载的影响。
3. 在下层奖励中引入拉格朗日软约束，将 DSR 和 MBS 负载纳入可解释的权衡过程；通过对比实验验证所提框架在服务公平性、UAV 侧能耗和 MBS 依赖方面的综合性能。
4. 在统一仿真条件下设置多种学习式与非学习式对比方法，并通过注意力机制分析、模块消融和参数敏感性实验，考察所提框架的作用机制、性能边界及适用范围。

此外，本文在系统模型中显式考虑 UAV 飞行能耗、UE 电池动态和 WPT 机制，并采用训练随机种子与工作负载随机种子的配对评估方式报告结果均值和波动范围。系统性能主要通过 DSR、UAV 侧能耗、服务公平性和 MBS 负载比例进行评价。

1.4 论文组织结构

本文其余部分组织如下：第 2 章介绍无人机辅助 MEC、多智能体强化学习和注意力机制等相关技术；第 3 章给出系统模型、问题建模、双层协同优化算法及实验结果分析；第 4 章总结全文并展望未来工作。

1.5　本章小结

本章介绍了本文的研究背景与意义，综述了国内外研究现状，总结了本文的主要贡献，并介绍了论文的组织结构。首先，从无线通信发展历程出发，分析了 5G 技术背景下无人机辅助通信系统的应用潜力和面临的挑战，包括频谱管理、功率控制、用户调度等问题，并阐述了深度强化学习在解决这些问题中的优势。然后，从传统优化方法、深度强化学习方法和多智能体强化学习方法三个角度综述了国内外研究现状，分析了现有研究在动作空间耦合、约束处理、能量动态和可解释性等方面的局限性。最后，提出了本文的研究内容和主要贡献，为后续章节的研究工作奠定了基础。

第 2 章　相关技术简介

本章系统阐述本文涉及的关键技术基础。首先介绍移动边缘计算的基本架构及任务卸载技术，再介绍无人机辅助通信与计算的应用场景，并分析多 UAV-MEC 系统中轨迹优化与任务卸载的联合决策复杂性；随后介绍强化学习与多智能体强化学习的基本理论，重点分析 MAPPO 算法的设计原理及其在大规模智能体系统中的局限性；最后阐述注意力机制如何解决上述局限，为后续章节提出的基于注意力机制的分层 MAPPO 方法奠定理论基础。

2.1　无人机辅助移动边缘计算技术

2.1.1　移动边缘计算概述

随着物联网和智能终端设备的快速发展，计算密集型和时延敏感型应用不断涌现，对网络服务的实时性和计算能力提出了更高要求。传统的云计算架构受限于核心网络与终端设备之间的物理距离，数据传输时延难以满足低时延应用的需求。为此，欧洲电信标准化协会（ETSI）于 2014 年提出了移动边缘计算（Mobile Edge Computing, MEC）的概念[39]，将计算和存储资源从云端下沉至网络边缘，使数据处理更加靠近终端用户。

MEC 的基本架构分为三层：终端设备层、边缘服务器层和云服务器层，如图 2.1 所示。终端设备层包括各类用户设备（User Equipment, UE），如智能手机、笔记本电脑、物联网传感器、监控摄像头等；边缘服务器层由部署在网络边缘的基站和边缘服务器（MEC）组成，通常与基站共址部署，提供本地化的计算和存储资源；云服务器层包含云数据中心，通过核心网络与边缘层连接，提供全局性的计算和存储资源。

在该架构下，MEC 系统的工作流程包括三个关键环节：（1）任务卸载，用户设备将计算任务通过无线链路发送至就近的边缘服务器执行；（2）结果返回，边缘服务器完成计算后将结果返回给用户设备；（3）云端协同，当边缘服务器资源不足或需要全局信息时，可与云数据中心进行协同处理。这种架构设计使得终端设备可将计算任务卸载至就近的边缘服务器执行，从而显著降低传输时延、节省终端能耗、减轻核心网络带宽压力[40]。

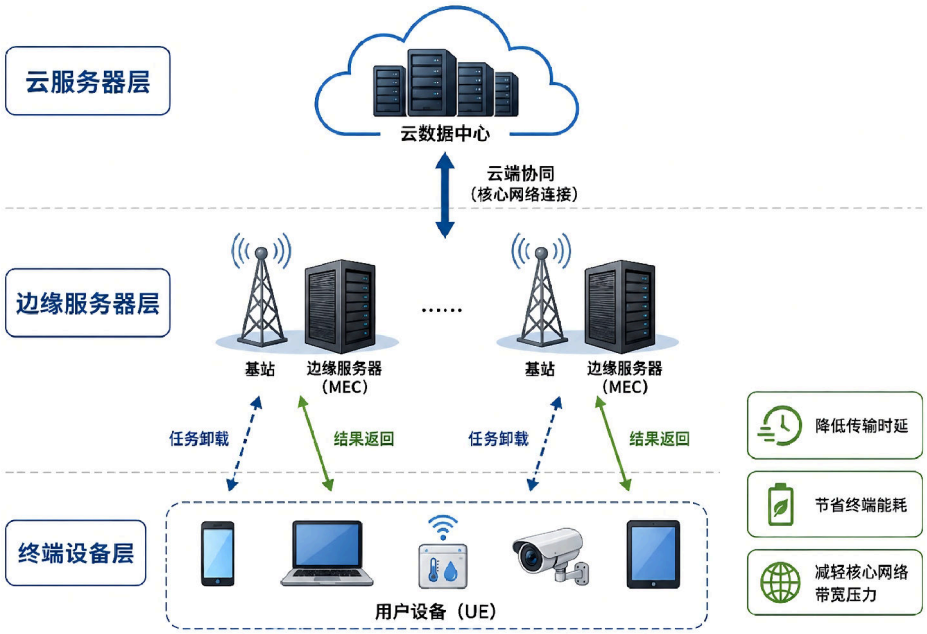


图 2.1　移动边缘计算三层架构示意图

2.1.2　任务卸载技术

任务卸载是 MEC 系统的核心技术之一，旨在将终端设备的计算任务部分或全部转移至边缘服务器执行[41]。根据卸载决策的粒度，任务卸载可分为二元卸载和部分卸载两种模式：二元卸载要求每个任务选择完全本地执行或完全卸载至边缘服务器；部分卸载则允许任务被分割为多个子任务，分别在本地和边缘服务器上并行执行。

任务卸载决策需综合考虑任务的计算量、数据量、时延要求、信道状态、边缘服务器的计算能力以及终端设备的能耗约束等因素[42]。典型的任务卸载优化问题通常需要在以下目标之间进行权衡：

（1）时延最小化。对于实时视频分析、增强现实等时延敏感型应用，最小化任务完成时间是首要目标。

（2）能耗最小化。终端设备通常由电池供电，在保证服务质量的前提下最小化终端能耗亦是重要的优化目标。

（3）时延-能耗联合优化。在实际应用中，时延和能耗往往需要同时考虑，通过加权和或约束优化的方式实现多目标平衡[43]。

在多 UAV-MEC 系统中，任务卸载决策更为复杂。每个地面用户的计算任务需决定卸载至哪架 UAV 或本地执行，同时 UAV 的飞行轨迹也会影响通信质量和卸载性能。因此，UAV 轨迹优化和任务卸载决策紧密耦合，需要联合优化才能达到系统整体最优[44]。近年来，基于深度强化学习的方法因其能够在动态环境中自适应地学习最优策略，已成为解决多 UAV-MEC 联合优化问题的主流方

法[45-46]。然而，多 UAV 系统本质上是一个多智能体决策问题——每架 UAV 需要根据自身观察和对其他 UAV 行为的预期来做出决策，这自然引出了多智能体强化学习的理论框架。

2.1.3 无人机辅助通信与计算

在这一背景下，无人机（Unmanned Aerial Vehicle, UAV）凭借灵活部署、按需覆盖与高机动性等优势，在辅助无线通信和边缘计算领域展现出显著的应用潜力[3]。与传统地面基站相比，UAV 具有以下优势：其一，UAV 可快速部署至目标区域，尤其适用于应急通信和临时热点覆盖场景[47]；其二，UAV 可通过调整飞行高度和位置优化与地面用户的视距（Line-of-Sight, LoS）链路质量，提供更可靠的通信服务[4]；其三，搭载计算资源的 UAV 可作为空中移动边缘服务器，为地面用户提供计算卸载服务[48]。

根据 UAV 在系统中承担的不同角色，UAV 辅助通信的应用场景可分为以下三类：

（1）UAV 作为空中基站。在地面基础设施受损或缺乏的场景下，UAV 可作为空中基站直接为地面用户提供通信服务。例如，在地震、洪水等自然灾害发生后，地面通信基础设施可能遭到严重破坏，此时 UAV 可快速升空建立应急通信网络，保障救援行动的通信需求[47]。

（2）UAV 作为中继节点。当源节点与目的节点之间存在障碍物或距离过远导致直接通信困难时，UAV 可充当中继节点转发数据，扩展网络覆盖范围。这种场景在城市峡谷、山区地形等复杂环境中尤为适用。

（3）UAV 作为移动边缘服务器。近年来，将 MEC 服务器搭载至 UAV 的研究受到广泛关注[48-49]。在该架构下，UAV 不仅提供通信服务，还可为地面用户的计算任务提供卸载执行服务。通过联合优化 UAV 的飞行轨迹和任务卸载策略，可同时优化系统的时延和能耗性能[50]。

上述应用场景可概括为图 2.2 所示的 UAV 辅助通信系统全景。在该系统中，宏基站作为中央通信枢纽，与各类 UAV 应用场景互联互通。UAV 既可独立承担特定任务，如大规模临时接入覆盖、物联网设备数据采集和移动边缘计算卸载，也可协同工作以实现中继转发和多机间通信。此外，UAV 还需同时服务于边缘用户和基站用户，体现了 UAV 辅助通信系统的多样性和复杂性。

多 UAV 协作的 MEC 系统进一步扩展了单 UAV 的服务能力。在多 UAV 场景下，每架 UAV 可覆盖不同区域或服务不同用户组，通过协同调度实现负载均衡和资源优化配置[51]。然而，多 UAV 系统也带来新的挑战，包括 UAV 间的干

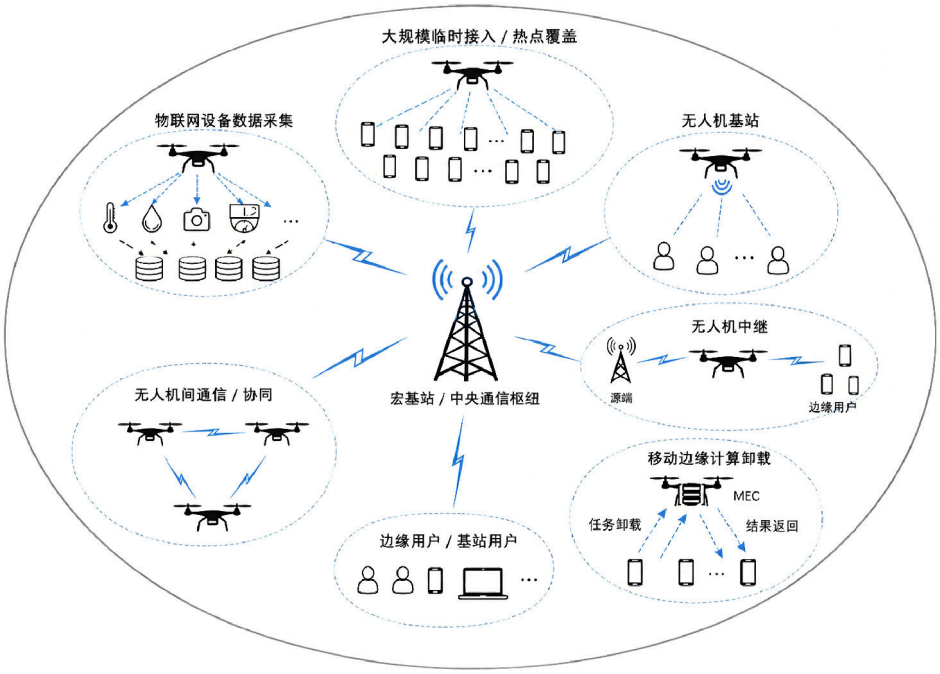


图 2.2　UAV 辅助通信应用场景示意图

扰管理、任务分配的协调优化以及轨迹的协同规划等。更为关键的是，UAV 轨迹优化与任务卸载决策是紧密耦合的：UAV 的位置影响通信质量，通信质量又决定卸载性能，而卸载决策反过来影响 UAV 的资源分配和后续轨迹规划。这种耦合关系使得多 UAV-MEC 系统的联合优化问题具有高维、非凸、动态等特征，传统优化方法难以有效求解，急需能够处理复杂决策问题的新方法。

2.2　多智能体强化学习技术

2.2.1　强化学习基础

强化学习（Reinforcement Learning, RL）作为机器学习的重要分支，旨在让智能体通过与环境交互学习最优行为策略[52]。如图 2.3 所示，在强化学习框架中，智能体在每个时间步 t 观察环境状态 s_t，根据当前策略选择一个动作 a_t 执行；环境接收该动作后转移至新状态，并向智能体反馈即时奖励信号 r_t。智能体的目标是通过不断试错学习，找到一个最优策略 π^*，使得长期交互过程中获得的累积折扣奖励最大化。

强化学习问题通常被建模为马尔可夫决策过程（Markov Decision Process, MDP），可用五元组 (S, A, P, R, γ) 描述[53]。其中，S 为状态空间，A 为动作空间，$P : S \times A \times S \to [0, 1]$ 为状态转移概率函数，$R : S \times A \to \mathbb{R}$ 为奖励函数，$\gamma \in [0, 1)$ 为折扣因子。MDP 的核心性质是马尔可夫性，即下一状态仅取决于当前状态和动作，与历史状态无关。

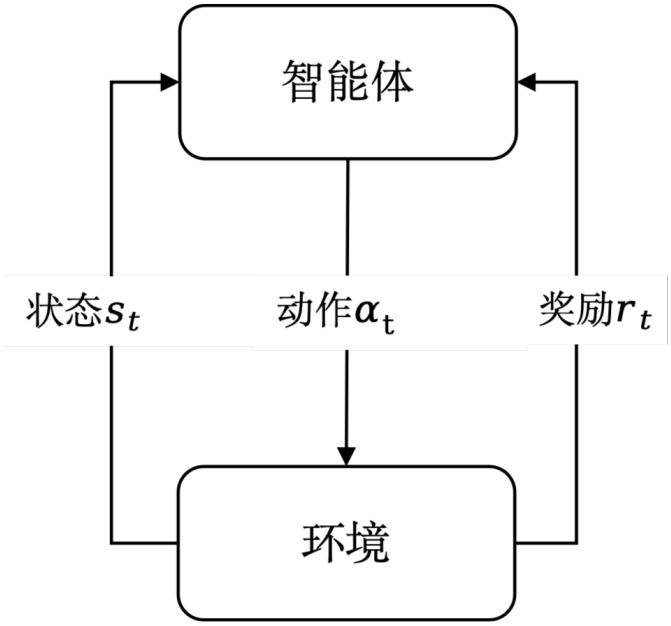


图 2.3　强化学习智能体与环境交互框架

根据学习方式的不同，强化学习算法可分为以下几类：

（1）基于值函数的方法。通过学习状态值函数 $V(s)$ 或状态-动作值函数 $Q(s,a)$ 间接求解最优策略。典型算法包括 Q-Learning[54] 和 SARSA 等。当状态空间较大或连续时，可使用深度神经网络近似值函数，如 DQN[6]。

（2）基于策略梯度的方法。直接参数化策略 $\pi_\theta(a|s)$，通过梯度上升优化策略参数 θ。REINFORCE 算法[55] 是策略梯度方法的经典代表，通过蒙特卡洛采样估计策略梯度。

（3）Actor-Critic 方法。结合值函数方法和策略梯度方法的优点，同时学习策略网络（Actor）和价值网络（Critic）。Actor 负责选择动作，Critic 负责评估动作的好坏，两者相互促进学习。典型算法包括 A2C、A3C 以及 DDPG[56] 等。

近端策略优化（Proximal Policy Optimization, PPO）[57] 是当前应用最广泛的策略梯度算法之一。PPO 通过引入截断的重要性采样比率限制策略更新幅度，从而保证训练稳定性。同时，PPO 使用广义优势估计（Generalized Advantage Estimation, GAE）[58] 平衡偏差和方差，进一步提升算法性能。

上述强化学习方法主要针对单智能体场景，即系统中仅有一个决策者与环境交互。然而，在多 UAV-MEC 系统中，每架 UAV 都是一个独立的决策主体，需要在考虑其他 UAV 行为的同时做出自身决策。这种多智能体决策场景需要将强化学习扩展到多智能体框架下，即多智能体强化学习。

2.2.2　多智能体强化学习概述

多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）是强化学习在多智能体系统中的自然扩展[59]。在多智能体环境中，多个智能体同时与环境交互，每个智能体的动作都会影响环境状态和其他智能体的观察。与单智能体强化学习相比，MARL 面临以下独特挑战：

（1）非平稳性。在多智能体学习过程中，每个智能体的策略都在不断更新，这意味着从单个智能体的视角来看，环境是动态变化的，不满足马尔可夫性质。这种非平稳性使得智能体难以收敛到稳定的最优策略。

（2）信用分配问题。在协作任务中，所有智能体共享同一个全局奖励，但如何将该奖励合理地分配给每个智能体是一个困难的问题。如果不能正确地分配信用，智能体将无法判断自身行为对团队目标的贡献。

（3）可扩展性问题。随着智能体数量的增加，联合状态空间和联合动作空间呈指数增长，导致学习算法难以在可接受的时间内收敛。

根据训练和执行方式的不同，MARL 算法可分为以下三类[60]：

（1）集中式训练集中式执行（CTCE）。在训练和执行阶段均使用全局信息，适用于完全可观察的环境。

（2）集中式训练分散式执行（CTDE）。在训练阶段可访问全局信息（如全局状态或其他智能体的动作），在执行阶段每个智能体仅根据自身观察做出决策。该范式在实践中应用最为广泛，代表性算法包括 MAPPO[38]、MADDPG[61]等。

（3）分散式训练分散式执行（DTDE）。每个智能体完全独立地学习和执行，不依赖全局信息。该方法的可扩展性最好，但学习效率通常较低。

在多 UAV-MEC 系统中，CTDE 范式具有天然的适配性。在训练阶段，系统可获取全局信息（如所有 UAV 的位置、所有用户的任务状态），这有助于训练出具有全局视野的价值网络；在执行阶段，每架 UAV 仅需根据自身观察（如邻居 UAV 的位置、关联用户的任务）即可独立决策，这符合实际部署中分布式执行的需求。因此，CTDE 范式成为多 UAV-MEC 系统中 MARL 算法设计的主流选择。

根据方法论的不同，MARL 算法还可分为值分解方法和 Actor-Critic 方法两大类。值分解方法，如 QMIX[62]和 VDN[63]，通过将全局 Q 函数分解为各智能体的局部 Q 函数来实现分散式执行。Actor-Critic 方法则为每个智能体维护独立的 Actor，同时使用共享的 Critic 提供全局价值评估。

2.2.3 MAPPO 算法介绍

MAPPO（Multi-Agent Proximal Policy Optimization）是 PPO 算法在多智能体协作场景下的扩展，由 Yu 等人[38]在 NeurIPS 2022 上系统验证了其有效性。研究表明，MAPPO 在多个主流多智能体基准任务上取得了与复杂离线策略算法相当甚至更优的性能，展现出" 令人惊讶的有效性"。

MAPPO 的核心架构遵循 CTDE 范式，包含以下关键设计：

（1）共享 Critic 网络。在训练阶段，所有智能体共享一个全局 Critic 网络，该网络以全局状态或所有智能体的联合观察作为输入，输出全局价值评估。共享 Critic 使得每个智能体能够获得全局视角的价值信息，有助于缓解信用分配问题。

（2）独立 Actor 网络。每个智能体拥有独立的 Actor 网络，该网络以智能体的局部观察作为输入，输出动作概率分布。在执行阶段，每个智能体仅需自身的 Actor 网络即可独立决策。

（3）截断重要性采样。MAPPO 继承 PPO 的截断机制，通过限制策略更新幅度保证训练稳定性。其优化目标为：

$$L(\theta) = \mathbb{E}\left[\min\left(\frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}A, \text{clip}\left(\frac{\pi_\theta(a|s)}{\pi_{\theta_{\text{old}}}(a|s)}, 1-\epsilon, 1+\epsilon\right)A\right)\right] \tag{2.1}$$

其中，A 为优势函数，ϵ 为截断参数。

MAPPO 的成功可归因于以下因素：PPO 的稳定性使训练过程不易崩溃；参数共享机制降低了样本复杂度；适当的超参数设置使 MAPPO 能在不同任务上表现出色。近年来，MAPPO 已被广泛应用于多 UAV 协作[64]、自动驾驶[65]等场景。在多 UAV-MEC 系统中，Zhao 等人[44]提出了基于 MAPPO 的鲁棒卸载方案，通过 Beta 分布策略处理计算和通信的不确定性。

然而，标准 MAPPO 在处理大规模智能体系统时仍面临以下挑战：

（1）观察空间维度爆炸。随着智能体数量增加，每个智能体的观察空间维度急剧增长（需包含自身状态、邻居 UAV 信息、关联用户信息等），导致策略网络难以有效学习。

（2）智能体间干扰问题。标准 MAPPO 的 Actor 网络独立处理每个智能体的观察，无法显式建模智能体之间的交互关系，导致在需要紧密协作的场景中性能受限。

（3）信息聚合效率低下。在大规模系统中，每个智能体需要处理大量冗余的观察信息，但并非所有信息都对决策同等重要，缺乏有效的信息筛选机制。

为解决这些问题，研究者提出了多种改进方案，如引入注意力机制的 A-

MAPPO[66]、支持意图共享的 MAPPO-PIS[65]等。其中，注意力机制因其能够自适应地关注最相关的智能体和环境元素，成为提升 MAPPO 在大规模系统中性能的有效途径。

2.3　注意力机制

针对上述 MAPPO 在大规模智能体系统中的局限性，注意力机制（Attention Mechanism）提供了一种有效的解决思路。该机制最初被提出用于解决序列到序列模型中的长距离依赖问题，允许模型在处理输入时自适应地关注最相关的部分[67]。在多智能体强化学习中，注意力机制可解决 MAPPO 的以下问题：

（1）降低观察空间维度。通过注意力权重，智能体可从大量观察信息中筛选出最相关的部分，降低有效观察维度。

（2）显式建模智能体交互。注意力权重直接反映了智能体之间的关注程度，为协作决策提供了显式的交互建模。

（3）提升信息聚合效率。注意力机制通过加权求和实现信息聚合，权重由查询和键的相似度决定，能够动态适应不同的决策场景。

注意力机制可理解为一种加权求和操作，其中权重反映了不同输入元素对当前输出的重要程度。

给定查询向量 Q、键向量 K 和值向量 V，缩放点积注意力的计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{2.2}$$

其中，d_k 为键向量的维度，用于缩放点积以防止梯度消失。通过计算查询与所有键的相似度，注意力机制能够动态地为不同的值分配不同的权重，从而实现对重要信息的选择性聚合。

多头注意力（Multi-Head Attention）进一步扩展了注意力机制的表达能力。它将查询、键和值分别通过 h 组不同的线性变换投影至不同子空间，在每个子空间中独立计算注意力，最后将所有头的输出拼接并通过线性变换得到最终结果：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \cdots, \text{head}_h)W^O \tag{2.3}$$

多头注意力使模型能够同时关注不同表示子空间中的信息，增强了模型的表达能力。

在多智能体强化学习中，注意力机制被广泛用于建模智能体之间的交互关系[68]。通过注意力机制，每个智能体可自适应地关注与其最相关的其他智能体

或环境元素，从而在复杂的多智能体环境中做出更合理的决策。例如，在 UAV-MEC 系统中，每架 UAV 需根据其他 UAV 的位置和任务状态调整自身的轨迹和卸载策略，注意力机制可帮助 UAV 动态识别和关注最相关的邻居信息[66]。

近年来，基于 Transformer 架构[67]的多智能体通信方法受到广泛关注。TGC-Net[69]使用 Transformer 建模智能体间的动态有向图通信，CACOM[70]利用注意力机制实现上下文感知的个性化消息生成，TMAC[71]则通过 Transformer 学习邻居智能体的消息特征。这些研究表明，注意力机制能够有效提升多智能体系统的协作性能。

2.4 本章小结

本章系统介绍了本文涉及的关键技术，并建立了它们之间的逻辑联系。在移动边缘计算方面，阐述了其三层架构及无人机辅助通信的三种角色，分析了任务卸载的优化目标，并指出多 UAV-MEC 系统中轨迹优化与任务卸载的联合决策复杂性。在强化学习方面，从单智能体强化学习出发，阐述了向多智能体强化学习扩展的必要性，介绍了 CTDE 范式与 MAPPO 算法，并分析了 MAPPO 在大规模智能体系统中的局限性。最后，阐述了注意力机制的基本原理及其如何解决 MAPPO 的上述局限。这些技术分析为后续章节提出的基于注意力机制的分层 MAPPO 方法奠定了理论基础，形成了” 场景需求 → 决策方法 → 技术创新” 的完整逻辑链条。

第 3 章　无人机辅助 MEC 系统中的轨迹与任务卸载协同优化算法

3.1　系统模型与问题建模

与传统地面 MEC 场景不同，多 UAV-MEC 系统中的服务性能不仅取决于任务是否卸载，还受到 UAV 空间位置、无线链路质量、UAV 间协作链路、MBS 回传负载以及 UE 电池状态等因素共同影响。因此，若仅独立优化轨迹或卸载决策，往往难以兼顾时延、能耗、覆盖公平性和长期服务连续性。为了提升多 UAV 辅助移动边缘计算（UAV-assisted mobile edge computing, UAV-MEC）系统在动态请求场景下的服务效率，本章针对 UAV 轨迹控制与地面用户任务卸载之间的强耦合关系，提出一种基于 Attention-MAPPO 的双层协同优化算法。该算法将连续轨迹控制与离散请求级卸载决策分解为上下两个协同决策层：上层负责根据 UAV 与用户状态调整 UAV 轨迹，下层负责在本地 UAV、协作 UAV 与 MBS 之间选择任务执行位置，从而降低直接联合建模带来的动作耦合复杂度。

3.1.1　网络与时隙模型

本文考虑一个由 N 架 UAV、M 个 UE 和一个宏基站（macro base station, MBS）构成的多 UAV-MEC 系统。所有 UAV 在相同固定高度 H 处飞行，因此轨迹控制仅考虑水平二维坐标；通信链路距离则根据通信双方的三维坐标计算。UAV 在给定二维区域内为地面用户提供通信覆盖、计算卸载和无线能量传输服务。每架 UAV 搭载有限的边缘计算资源，可为其覆盖范围内的 UE 执行计算任务；当 UAV 本地计算资源不足或协作执行更优时，请求也可被转发至其他 UAV 或 MBS 执行。MBS 作为远端稳定计算节点提供回退执行能力，但过度依赖 MBS 会增加回传链路负载并造成系统服务集中。因此，本文需要同时决定 UAV 的水平位置和服务请求的执行位置。

系统时间被划分为长度为 τ 的离散时隙，一个 episode 包含 T 个时隙。记第 n 个时隙 UAV i 的水平位置为 $\mathbf{q}_n^{(i)} = (x_n^{(i)}, y_n^{(i)})$，其中 $i \in \{0, 1, \cdots, N-1\}$。UAV 的覆盖半径为 R_c，最大飞行速度为 v_{max}，任意两架 UAV 之间需保持不低于 d_{min} 的安全间距。系统主要包含 UE-UAV 上行链路、UAV-UAV 协作链路和 UAV-MBS 回传链路，如图 3.1 所示。UAV 轨迹控制会改变 UE 与 UAV 的相对距离，进而影响链路速率、任务完成时延、终端能耗以及用户覆盖公平性。

为保证每个时隙生成的服务请求均进入后续处理流程，系统采用如下请求

关联规则：服务请求优先关联至自然覆盖范围内的 UAV；未被任一 UAV 自然覆盖的请求关联至距离最近的 UAV，并可由该 UAV 本地执行、转发至协作 UAV，或经回传链路卸载至 MBS。该关联规则不改变链路物理计算，UE–UAV 链路的传输速率、时延和能耗仍由实际通信距离决定。因此，请求关联仅保证请求进入处理流程，并不保证其满足截止时间约束。

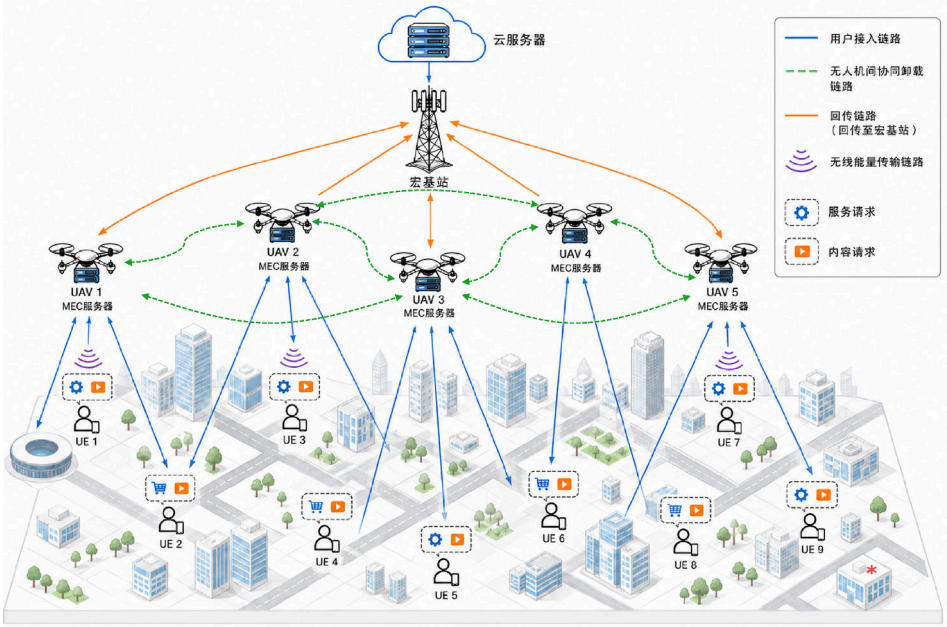


图 3.1　多 UAV-MEC 系统架构

Figure 3.1　Multi-UAV MEC system architecture

3.1.2　通信链路模型

在上述网络中，无线链路质量首先由通信距离决定。本文采用自由空间路径损耗模型描述视距（Line-of-Sight, LoS）信道。设 d 表示通信双方之间的三维欧氏距离，则距离为 d 时的信道增益定义为

$$g(d) = \frac{\beta_0}{d^2}, \tag{3.1}$$

其中 β_0 为参考距离处的信道功率增益。由于 UAV 在相同高度飞行，UAV-UAV 链路的三维距离退化为水平距离；而 UE-UAV 链路和 UAV-MBS 链路分别包含 UAV 高度差和 MBS 高度差。根据香农公式，若 UAV i 当前关联的 UE 集合为 $\mathcal{U}_i$，则 UE-UAV 接入链路采用带宽均分模型，其上行速率为

$$R_{u,i}^{ue-uav} = \frac{B_{edge}}{|\mathcal{U}_i|} \log_2 \left(1 + \frac{P^{comm} \cdot g(d_{u,i})}{\sigma^2} \right), \tag{3.2}$$

其中 B_{edge} 为 UE-UAV 接入带宽，P^{comm} 为通信发射功率。UAV-UAV 协作链路和 UAV-MBS 回传链路分别采用独立带宽 B_{inter} 和 $B_{backhaul}$：

$$\begin{aligned} R_{i,j}^{uav-uav} &= B_{inter}\log_2\left(1+\frac{P^{comm}\cdot g(d_{i,j})}{\sigma^2}\right), \\ R_{i,mbs}^{backhaul} &= B_{backhaul}\log_2\left(1+\frac{P^{comm}\cdot g(d_{i,mbs})}{\sigma^2}\right). \end{aligned} \tag{3.3}$$

在本文仿真实现中，三类通信链路采用相同的通信发射功率参数，链路差异主要由带宽、三维距离和信道增益共同决定。由于请求大小和文件大小以 bytes 记录，而链路速率以 bit/s 表示，传输大小为 D bytes 的数据所需时间统一为

$$T_{tx}=\frac{8\cdot D}{R}. \tag{3.4}$$

式中 8× 因子完成 bytes 到 bits 的单位转换。由此可见，UAV 轨迹不仅决定覆盖关系，也直接通过距离影响传输速率和后续服务时延。

3.1.3　请求生成与卸载决策

系统中共有 S 类服务和 K 类内容文件，分别记为服务集合 $\mathcal{S}=\{0,1,\cdots,S-1\}$ 和内容集合 $\mathcal{K}=\{S,S+1,\cdots,S+K-1\}$。总文件集合为 $\mathcal{F}=\mathcal{S}\cup\mathcal{K}$，且 $|\mathcal{F}|=S+K$。每个文件 $f\in\mathcal{F}$ 具有固定存储大小 L_f（bytes），其中 $L_f\in[L_{min},L_{max}]$；每个服务类型 $s\in\mathcal{S}$ 具有计算强度 ω_s（cycles/byte），取值范围为 $\omega_s\in[\omega_{min},\omega_{max}]$。

每个 UE 在每个时隙至多生成一个请求。若 UE 当前电池水平 B_{ue} 低于临界阈值 B_{low}，该 UE 优先生成能量请求，并暂停本轮服务请求以降低自身能耗；否则，UE 从 $\mathcal{F}$ 中按照 Zipf 分布选择一个文件或服务。设文件 f 的流行度排名为 $\mathrm{rank}(f)$，则其被选择的概率为

$$P(f)=\frac{1/\mathrm{rank}(f)^{\alpha}}{\sum_{f'=0}^{|\mathcal{F}|-1}1/\mathrm{rank}(f')^{\alpha}}, \tag{3.5}$$

其中 α 控制请求流行度的集中程度。若被选中的 ID 属于服务集合 $\mathcal{S}$，则生成计算密集型服务请求；若属于内容集合 $\mathcal{K}$，则生成内容请求。

一个服务请求形式化表示为

$$\mathcal{T}_m=\left(D_m,\omega_{s_m},T_m^{dl},p_m\right), \tag{3.6}$$

其中 $D_m\in[D_{min},D_{max}]$ 为输入数据量，ω_{s_m} 为服务类型 s_m 的计算强度，$T_m^{dl}\in[T_{dl}^{min},T_{dl}^{max}]$ 为截止时间，$p_m\in\mathcal{P}$ 为优先级。该服务请求所需 CPU 周期数为

$$C_m=\omega_{s_m}\cdot D_m\quad\text{(cycles)}. \tag{3.7}$$

内容请求不涉及计算卸载，仅需完成内容文件传输，可表示为

$$\mathcal{C}_m=(f_m,L_{f_m}), \tag{3.8}$$

其中 $f_m \in \mathcal{K}$ 为请求的内容文件 ID，L_{f_m} 为文件大小。

设 UAV i 在当前时隙关联的服务请求集合为 $\mathcal{M}_i$，且 $|\mathcal{M}_i| \leqslant M_i^{max}$。对于任意 $m \in \mathcal{M}_i$，系统需要为其选择执行位置，即离散卸载决策

$$a_m \in \mathcal{A} = \{0, 1, 2, \cdots, N+1\}. \tag{3.9}$$

其中 $a_m = 0$ 表示在当前 UAV 本地执行，$a_m = 1$ 表示通过回传链路卸载至 MBS 执行，$a_m = 2 + j$ 表示卸载至协作 UAV j 执行，$j \in \{0, 1, \cdots, N-1\}$。在实际执行中，当前 UAV 对应的协作动作可通过动作掩码屏蔽，因此下层策略的候选动作规模为 $N+2$。至此，轨迹变量决定 UE 与 UAV 的连接质量，而卸载变量决定任务的执行路径，二者共同影响服务时延和系统能耗。

3.1.4 时延与能耗模型

对于服务请求 $\mathcal{T}_m$，总处理时延由上行传输、可能的协作/回传传输、服务或文件获取以及计算执行共同构成。本文假设计算结果数据量远小于输入数据量，因此结果回传时延可忽略。若请求在当前 UAV 本地执行，则时延为

$$T_{local} = T_{tx}^{ue-uav} + T_{fetch}^{local} + T_{comp}^{uav} = \frac{8D_m}{R_{ue-uav}} + T_{fetch}^{local} + \frac{C_m}{f_{m,uav}}, \tag{3.10}$$

其中 R_{ue-uav} 为 UE-UAV 上行速率，$f_{m,uav}$ 为当前 UAV 分配给请求 m 的计算频率；当多个服务请求同时由同一 UAV 处理时，计算资源在请求之间共享。T_{fetch}^{local} 表示本地 UAV 未缓存对应服务或文件时从 MBS 获取资源产生的额外时延，缓存命中时该项为 0。

若请求卸载至协作 UAV 执行，则除 UE 到当前 UAV 的上行传输外，还需要经过 UAV-UAV 协作链路转发，其时延为

$$T_{coop} = \frac{8D_m}{R_{ue-uav}} + \frac{8D_m}{R_{uav-uav}} + T_{fetch}^{coop} + \frac{C_m}{f_{m,coop}}, \tag{3.11}$$

其中 $R_{uav-uav}$ 为 UAV 间协作链路速率，$f_{m,coop}$ 为协作 UAV 分配给该请求的计算频率，T_{fetch}^{coop} 为协作 UAV 未缓存所需资源时产生的额外获取时延。若请求卸载至 MBS 执行，则时延为

$$T_{mbs} = \frac{8D_m}{R_{ue-uav}} + \frac{8D_m}{R_{backhaul}} + \frac{C_m}{f_{mbs}}, \tag{3.12}$$

其中 $R_{backhaul}$ 为 UAV-MBS 回传链路速率，f_{mbs} 为 MBS 固定计算能力。本文忽略计算结果回传时延与 MBS 排队时延，将 MBS 作为稳定回退计算节点建模。

在能耗方面，UAV 侧能耗主要由计算、通信、飞行和 WPT 发射组成。计算能耗采用 CMOS 动态功耗模型估计：

$$E_{comp} = K_{cpu} \cdot C_m \cdot f^2, \tag{3.13}$$

其中 K_{cpu} 为 CPU 电容系数，f 为分配给该请求的实际执行频率。每架 UAV 的总计算能力记为 f_{uav}。通信能耗由通信功率与传输时长决定：

$$E_{comm} = P_{comm} \cdot T_{tx}. \tag{3.14}$$

其中 UE 发射功率记为 P_{ue}，UAV 通信发射功率、接收功率和 UAV-MBS 回传发射功率分别记为 P_{uav}^{tx}、P_{uav}^{rx} 和 P_{bh}^{tx}。

3.1.5　电池、无线能量传输与飞行能耗模型

由于本文关注长期服务连续性，仅考虑任务时延和 UAV 能耗是不够的。UE 电池状态会影响请求类型和离线率，而 UAV 轨迹移动本身也会消耗大量能量。因此，系统还需要描述 UE 电池动态、无线能量传输（wireless power transfer, WPT）和 UAV 飞行能耗。

每个 UE 配备容量为 B_{max} 的电池。每个时隙结束后，UE 电池状态更新为

$$\begin{aligned} B_{t+1} = \min\{B_{max}, \max(0,\, B_t - E_{static} - E_{tx} \cdot \mathbb{1}[\text{transmit}] \\ - E_{rx} \cdot \mathbb{1}[\text{receive}] + E_{harv})\}. \end{aligned} \tag{3.15}$$

其中 $E_{static} = P_{static} \cdot \tau$ 为待机能耗，$E_{tx} = P_{ue} \cdot T_{tx}$ 为发射能耗，E_{rx} 为接收内容或计算结果时产生的接收能耗，E_{harv} 为无线能量采集量。当 $B_{ue} < B_{low}$ 时，UE 进入离线状态，不再生成服务请求，而是产生紧急能量请求。系统离线率定义为

$$O = \frac{|\{ue \mid B_{ue} < B_{low}\}|}{M}. \tag{3.16}$$

UAV 可对覆盖范围内的低电量 UE 进行 WPT。单个 UE 在一个时隙内可采集的能量为

$$E_{harv} = \eta \cdot P_{wpt} \cdot G \cdot g(d) \cdot \tau, \tag{3.17}$$

其中 η 为能量采集效率，P_{wpt} 为 WPT 发射功率，G 为等效采集增益，$g(d)$ 为式 (3.1) 中的信道增益。

UAV 飞行能耗由移动时间和悬停时间共同决定。若 UAV 在当前时隙内移动距离为 d_{moved}，则飞行能耗为

$$E_{fly} = P_{move} \cdot t_{moving} + P_{hover} \cdot t_{hovering}, \tag{3.18}$$

$$t_{moving} = \frac{d_{moved}}{v_{max}}, \quad t_{hovering} = \tau - t_{moving}. \tag{3.19}$$

其中 P_{move} 和 P_{hover} 分别为 UAV 移动功率和悬停功率。综合上述各项，UAV 侧单步总能耗定义为

$$E_{total} = \sum_{i=0}^{N-1} \left(E_{fly}^{(i)} + E_{comp}^{(i)} + E_{comm}^{(i)} + E_{wpt}^{(i)} \right), \tag{3.20}$$

其中 $E_{wpt}^{(i)} = P_{wpt} \cdot \tau \cdot \mathbb{1}[\text{has energy request}]$ 表示 UAV i 在该时隙执行 WPT 时产生的发射能耗。至此，系统性能由时延、能耗、服务公平性和 UE 电池状态共同决定。

3.1.6 优化目标与约束条件

基于以上模型，本文目标是在动态请求到达、无线链路变化和 UE 电池演化的条件下，联合优化 UAV 轨迹控制策略 π^{upper} 与请求卸载策略 π^{lower}，使系统长期综合奖励最大化：

$$\max_{\pi^{upper},\pi^{lower}} \mathbb{E}\left[\sum_{t=0}^{T-1} \gamma^t R_t\right]. \tag{3.21}$$

其中 γ 为折扣因子，R_t 为第 t 个时隙的系统级综合奖励。考虑到本文同时关注覆盖公平性、时延、能耗、UE 离线率、截止时间满足率和 MBS 负载，奖励函数定义为

$$R_t = W_J \cdot J_t - W_L \cdot \bar{L}_t - W_E \cdot \bar{E}_t - W_O \cdot O_t + W_{DSR} \cdot DSR_t - W_M \cdot M_t. \tag{3.22}$$

式中，$J_t \in [0,1]$ 为 Jain 公平性指数，定义为 $J_t = \frac{(\sum_{i=1}^{M} x_i)^2}{M \sum_{i=1}^{M} x_i^2}$，其中 x_i 表示 UE i 的历史服务覆盖水平；该公平性指标用于衡量不同 UE 被成功服务的均衡程度，不等同于截止时间满足率。$\bar{L}_t$ 为以 $M \cdot T_{penalty}$ 归一化的系统时延，$T_{penalty}$ 为未服务请求惩罚时延；$\bar{E}_t$ 为以 $N \cdot E_{ref}$ 归一化的 UAV 侧能耗；O_t 为式 (3.16) 给出的 UE 离线率。

截止时间满足率（deadline satisfaction rate, DSR）刻画所有生成服务请求中被成功分配且满足截止时间约束的比例。以请求为统计单位时，DSR 定义为

$$DSR_t = \frac{|\{m \mid \mathcal{T}_m \in \mathcal{S},\ a_m \neq \varnothing,\ L_m \leqslant T_m^{dl}\}|}{|\{m \mid \mathcal{T}_m \in \mathcal{S}\}|}, \tag{3.23}$$

其中 L_m 为请求 m 的实际处理时延，$a_m \neq \varnothing$ 表示该请求已被分配执行。实验统计时，将同一评估单元内各时隙的满足截止时间请求数和生成服务请求数分别累加后计算 DSR，而不对各时隙 DSR 直接取平均。MBS 负载比例用于刻画系统对远端计算节点的依赖程度，定义为所有生成服务请求中最终由 MBS 处理的比例：

$$M_t = \frac{|\{m \mid \mathcal{T}_m \in \mathcal{S},\ a_m = 1\}|}{|\{m \mid \mathcal{T}_m \in \mathcal{S}\}|}. \tag{3.24}$$

其中 W_J、W_L、W_E、W_O、W_{DSR} 和 W_M 分别表示公平性、时延、能耗、离线率、截止时间满足率和 MBS 负载对应的奖励权重，各权重的具体取值见第 （1） 节仿真参数设置。当 UAV 发生碰撞或越界时，环境额外施加约束惩罚；为稳定 MARL 训练过程中的数值范围，可对最终奖励进行缩放处理。

上述优化问题需要满足以下约束。首先，UAV 必须始终位于服务区域内：

$$\mathbf{q}_n^{(i)} \in \left[\frac{R_c}{2}, W - \frac{R_c}{2}\right] \times \left[\frac{R_c}{2}, W - \frac{R_c}{2}\right], \quad \forall i \in \{0, 1, \cdots, N-1\},\ \forall n, \tag{3.25}$$

其中 W 为正方形服务区域的边长，$R_c/2$ 为边界缓冲距离，用于避免 UAV 覆盖区域过度越出服务区域。其次，任意时隙内 UAV 的位移不得超过最大飞行距离：

$$\|\mathbf{q}_{n+1}^{(i)} - \mathbf{q}_n^{(i)}\| \leqslant v_{max} \cdot \tau, \quad \forall i \in \{0, \cdots, N-1\},\ \forall n. \tag{3.26}$$

任意两架 UAV 之间还需满足安全间距约束：

$$\|\mathbf{q}_n^{(i)} - \mathbf{q}_n^{(j)}\| \geqslant d_{min}, \quad \forall i \neq j,\ i, j \in \{0, \cdots, N-1\},\ \forall n. \tag{3.27}$$

对于每个服务请求，其卸载动作必须属于离散动作空间：

$$a_m \in \{0, 1, 2, \cdots, N+1\}, \quad \forall m \in \mathcal{M}_i. \tag{3.28}$$

最后，为避免策略单纯追求能耗或短期奖励而牺牲服务质量，本文引入 DSR 与 MBS 负载软约束：

$$DSR_t \geqslant \delta_{dsr}, \tag{3.29}$$

$$M_t \leqslant \delta_{mbs}. \tag{3.30}$$

其中空间边界和动作空间约束通过环境裁剪与动作掩码直接执行；速度和安全间距约束通过动作幅值限制、碰撞检测与位置修正近似执行，并在发生边界或碰撞违反时引入额外惩罚。DSR 与 MBS 负载约束为软约束，在第 3.2.5 节中通过 Lagrange 机制转化为训练奖励中的约束惩罚项，并不构成逐时隙严格可行性保证。由此，本文问题可视为一个同时包含连续轨迹控制、离散请求卸载和长期服务质量约束的多智能体序列决策问题。

3.2　基于 Attention-MAPPO 的双层协同优化算法

3.2.1　整体框架

本文框架由两个协同 MARL 决策层组成：

- **上层 Attention-MAPPO**：每架 UAV 作为一个智能体，根据自身位置、邻居 UAV 状态、覆盖 UE 和请求负载信息输出二维连续轨迹动作。
- **下层约束注意力卸载 MAPPO**：每架 UAV 对当前关联的服务请求输出离散卸载动作；实际动作空间包括本地 UAV、MBS 和指定协作 UAV 三类执行位置。

在每个环境交互步中，系统按如下顺序执行：

1. 环境生成当前 UAV、UE、链路和请求状态
2. 下层读取请求级观测与动作掩码，输出卸载动作
3. 环境执行服务请求处理，统计时延、UAV 侧能耗、DSR、服务公平性和 MBS 负载
4. 上层输出轨迹动作，环境更新下一时刻位置

上述双层协同优化架构如图 3.2 所示。上层 Attention-MAPPO 通过多头交叉注意力机制建模 UAV 间和 UAV–UE 间的交互关系，输出连续轨迹动作；下层约束注意力卸载 MAPPO 基于请求级观测和质量感知动作掩码输出离散卸载决策，并通过拉格朗日机制协调 DSR 与 MBS 负载。

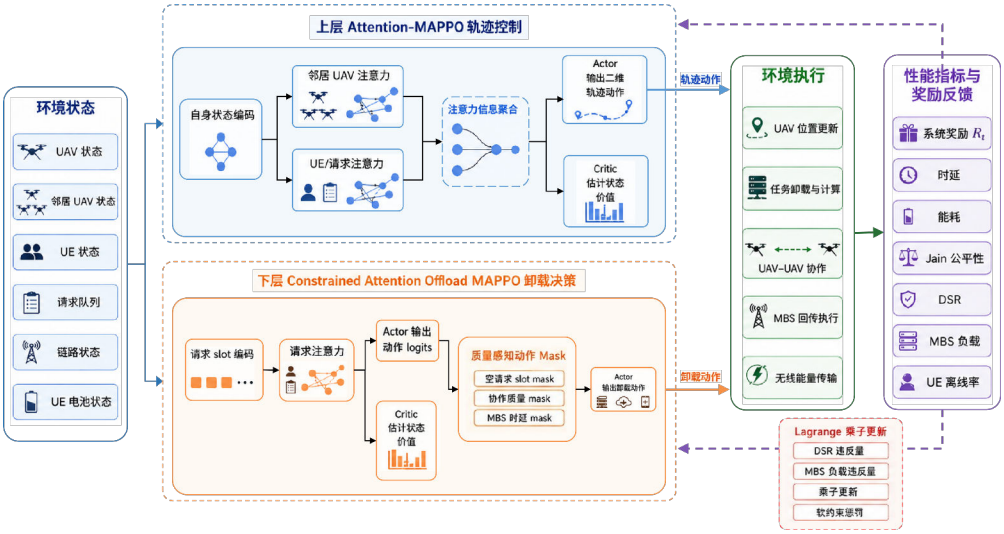


图 3.2　基于注意力机制的双层协同优化架构

Figure 3.2　Dual-layer collaborative optimization architecture based on attention mechanism

3.2.2　上层 attention-MAPPO 轨迹控制

上层将每架 UAV 作为一个 agent。第 i 架 UAV 的观测由自身状态、邻居 UAV 状态和覆盖 UE 状态三部分组成：

$$o_i^U = [s_i^{self}, S_i^{nbr}, S_i^{ue}] \tag{3.31}$$

其中 $s_i^{self} = [p_i, c_i]$ 包含 UAV 归一化二维位置 p_i 和缓存向量 c_i；$S_i^{nbr} = \{\Delta p_{ij} | j \in \mathcal{N}_i\}$ 包含邻居 UAV 相对位置；$S_i^{ue} = \{\Delta p_{ik}, r_k, b_k | k \in C_i\}$ 包含覆盖 UE 的相对位置、请求特征和电池状态。

具体地，首先将自身状态、邻居状态和 UE 状态分别编码为隐表示：

$$e_i = f_{self}(s_i^{self}), \quad h_{ij}^{nbr} = f_{nbr}(s_{ij}^{nbr}), \quad h_{ik}^{ue} = f_{ue}(s_{ik}^{ue}) \tag{3.32}$$

随后对邻居 UAV 集合和覆盖 UE 集合分别计算 scaled dot-product attention。

以邻居 UAV 集合为例：

$$Q_i = W_Q e_i, \quad K_{ij} = W_K h_{ij}^{nbr}, \quad V_{ij} = W_V h_{ij}^{nbr} \tag{3.33}$$

$$\alpha_{ij}^{nbr} = \mathrm{softmax}_j\left(\frac{Q_i K_{ij}^T}{\sqrt{d}}\right), \quad c_i^{nbr} = \sum_{j\in\mathcal{N}_i} \alpha_{ij}^{nbr} V_{ij} \tag{3.34}$$

对 UE 集合同理得到 c_i^{ue}。最终将自身表示、邻居上下文和 UE 上下文拼接后得到策略特征：

$$z_i = \mathrm{MLP}([e_i, c_i^{nbr}, c_i^{ue}]) \tag{3.35}$$

上层策略根据 z_i 输出 2D 方向向量，转换为飞行距离：

$$d_{moved} = \mathrm{clip}(||a||, 0, 1) \cdot v_{max} \cdot \tau \tag{3.36}$$

上层奖励为第 3.1.6 节定义的系统级综合奖励 R_t，所有 UAV 共享同一基础奖励值。训练采用 CTDE（Centralized Training Decentralized Execution）框架。

3.2.3　下层约束注意力卸载 MAPPO

下层同样采用多智能体建模。每架 UAV 对其当前关联的服务请求进行决策，最多处理 K 个请求槽。每个有效请求槽的离散动作空间如表 3.1 所示。

表 3.1　下层离散动作空间

Table 3.1　Lower-layer discrete action space

动作编号	动作含义	说明
0	当前 UAV 本地执行	在当前 UAV 本地执行
1	MBS 执行	通过回传链路卸载至宏基站
$2+j$	协作 UAV j 执行	选择编号为 j 的协作 UAV 执行，$j = 0, \cdots, N-1$

因此，下层策略的实际动作数为 $|A| = 2 + N$。

下层观测同样按 UAV 构造。第 i 架 UAV 的下层观测为：

$$o_i^L = [g_i^{self}, G_i^{req}] \tag{3.37}$$

其中 g_i^{self} 包含 UAV 归一化位置、当前服务请求队列比例、邻居数量比例和 UAV–MBS 回传速率；G_i^{req} 由最多 K 个请求槽组成。每个有效请求槽包含请求大小、请求编号、截止时间、优先级、本地缓存命中状态、协作可用性、本地队列长度、本地/协作/MBS 路径时延相对截止时间的截断比例、最佳协作 UAV 计算份额以及 UE–UAV 相对位置等特征。

下层策略利用请求注意力编码同一 UAV 内多个服务请求的相对重要性：先将 UAV 自身特征和各请求特征编码至隐空间，再对请求槽施加多头自注意力，最后为每个请求槽输出本地 UAV、MBS 或协作 UAV 的动作得分。价值网络基于集中式信息估计状态价值。下层学习策略仅针对服务请求生成卸载动作；内容请求和能量请求仍由环境中的缓存、下载和 WPT 逻辑处理。下层共享训练奖励函数为：

$$\begin{aligned} R_{lower} = {} & w_{succ} \cdot DSR + w_{coop} \cdot C_{ratio} - w_{dead} \cdot (1 - DSR) \\ & - w_{lat} \cdot \frac{L}{M \cdot T_{penalty}} - w_{en} \cdot \frac{E}{N \cdot E_{ref}^{offload}} - w_{mbs} \cdot M_{ratio} \\ & - \lambda_{dsr} \cdot \max(0, \tau_{dsr} - DSR) - \lambda_{mbs} \cdot \max(0, M_{ratio} - \tau_{mbs}). \end{aligned} \tag{3.38}$$

其中 w_{succ}、w_{coop}、w_{dead}、w_{lat}、w_{en} 和 w_{mbs} 分别为服务成功、协作卸载、截止时间未满足、时延、能耗和 MBS 负载对应的下层奖励权重，具体取值见表 3.3。

3.2.4 质量感知动作掩码

请求级动作掩码用于减少明显无效的探索：

空请求槽掩码：若某个请求槽没有真实服务请求，则该请求槽不产生卸载动作。

质量感知掩码：

- **协作动作掩码**：当不存在可用协作 UAV、协作路径时延过高（超过 $\theta_{deadline}$ 倍截止时间）、协作相对本地路径无明显优势（超过 $\theta_{latency}$ 倍本地时延）或协作计算份额过低（低于 θ_{share}）时，屏蔽协作动作。
- **MBS 动作掩码**：当 MBS 路径的估计时延超过归一化所用的截止时间截断阈值时，屏蔽 MBS 动作。

其中 $\theta_{deadline}$、$\theta_{latency}$、θ_{share} 以及 MBS 动作掩码的截止时间截断阈值均为动作掩码的实现参数。

3.2.5 Lagrange 约束机制

为显式控制 DSR 与 MBS 负载之间的权衡，本文引入 Lagrange 乘子 λ_{dsr} 和 λ_{mbs}：

$$P_t = \lambda_{dsr} \cdot \max(0, \tau_{dsr} - DSR_t) + \lambda_{mbs} \cdot \max(0, M_t - \tau_{mbs}) \tag{3.39}$$

其中 τ_{dsr} 和 τ_{mbs} 分别为 DSR 与 MBS 负载的软约束目标。拉格朗日乘子在

每个采样批次后更新：

$$\lambda_{dsr} \leftarrow \mathrm{clip}(\lambda_{dsr} + \eta_\lambda \cdot \bar{v}_{dsr}, 0, \lambda_{max}) \tag{3.40}$$

$$\lambda_{mbs} \leftarrow \mathrm{clip}(\lambda_{mbs} + \eta_\lambda \cdot \bar{v}_{mbs}, 0, \lambda_{max}) \tag{3.41}$$

其中 η_λ 为拉格朗日乘子学习率，λ_{max} 为乘子上界，$\bar{v}$ 为采样批次内的平均约束违反量。τ_{dsr}、τ_{mbs}、η_λ 和 λ_{max} 的具体取值见表 3.3。该机制通过提高违反约束时的惩罚权重，引导策略减少 DSR 不足和 MBS 负载超限，但属于训练目标中的软约束，并不构成严格可行性保证。

基于上述双层协同框架、注意力机制、质量感知动作掩码和拉格朗日约束机制，本文所提算法的完整训练流程如算法 3.1 所示。

3.2.6　奖励函数设计

本文统一采用线性归一化奖励函数。系统级综合奖励 R_t（第 3.1.6 节）直接使用归一化后的指标线性加权，下层共享训练奖励 R_{lower}（第 3.2.3 节）同样采用线性归一化形式。

归一化分母的设计如下：

- **Latency 归一化**：以 $M \cdot T_{penalty}$ 为分母，其中 $T_{penalty}$ 为未服务请求惩罚时延，因此归一化时延 $\bar{L} \in [0, 1]$ 表示当前总时延占最差情况的比例。
- **Energy 归一化**：系统级奖励使用 $N \cdot E_{ref}$ 为分母，其中 E_{ref} 为每架 UAV 单步参考能耗；下层奖励使用 $N \cdot E_{ref}^{offload}$，其中 $E_{ref}^{offload}$ 为下层每架 UAV 单步最大参考能耗。

本文采用线性归一化，以使各指标贡献在数值上可加、可比，并避免对数函数在接近零值时的数值不稳定性。该设计便于分析不同奖励权重下的策略行为。

3.2.7　复杂度分析

设 UAV 数量为 N，每架 UAV 的最大请求 slot 数为 K，下层动作数为 $|A| = N + 2$。若直接构建端到端联合 MAPPO，需要同时处理 N 个连续轨迹动作和最多 $N \times K$ 个请求级离散卸载动作；若显式枚举所有请求级卸载动作组合，其组合规模上界为 $|A|^{NK}$，并会带来严重的样本效率与 credit assignment 问题。该上界用于说明联合建模的组合规模压力，并不表示本文实现会枚举所有动作组合。本文采用双层分解后，上层只处理 N 个 UAV 的轨迹动作（连续 2D），下层只在每个 UAV 的 K 个请求 slot 上进行局部离散决策。attention 编码的主要计算量级为 $O(N^2)$ 或 $O(K^2)$。

算法 3.1　基于 Attention-MAPPO 的双层协同优化算法

Input: 训练回合数 E，每回合时隙数 T，采样轨迹长度 L，PPO 更新轮数 P，批大小 B

Output: 训练完成的上层策略 π^{upper} 和下层策略 π^{lower}

初始化上层 Attention-MAPPO 的 actor 参数 θ^U 和 critic 参数 ϕ^U;
初始化下层约束注意力卸载 MAPPO 的 actor 参数 θ^L 和 critic 参数 ϕ^L;
初始化 Lagrange 乘子 $\lambda_{dsr} \leftarrow 0$，$\lambda_{mbs} \leftarrow 0$;
初始化上层采样缓存 $\mathcal{B}^U$ 和下层采样缓存 $\mathcal{B}^L$;
重置环境并获取初始上层观测 o^U;
令更新次数 $N_{upd} = \lfloor ET/L \rfloor$;
for *update* $= 1, 2, \cdots, N_{upd}$ **do**
    清空 $\mathcal{B}^U$、$\mathcal{B}^L$ 以及当前 rollout 的约束违反量记录;
    for *step* $= 1, 2, \cdots, L$ **do**
        根据当前环境状态构造下层观测 o_i^L 和动作掩码 $\mathbf{m}_{i,k}$;
        for 每架 *UAV i* **do**
            下层 actor 根据 o_i^L 和 $\mathbf{m}_{i,k}$ 为每个有效请求槽输出卸载动作 $\mathbf{a}_i^L = \{a_{i,k}^L\}_{k=1}^K$;
        end
        根据当前环境状态构造上层观测 o_i^U;
        for 每架 *UAV i* **do**
            上层 actor 通过注意力机制聚合自身、邻居 UAV 以及 UE/请求状态信息;
            输出连续轨迹动作 $\mathbf{a}_i^U$，并根据速度约束转换为位移向量;
        end
        环境执行当前时隙交互：根据 $\mathbf{a}^L$ 处理服务请求，计算时延、能耗、DSR 和 MBS 负载；根据 $\mathbf{a}^U$ 更新 UAV 位置并生成下一时隙观测;
        计算系统奖励 R_t 和下层卸载奖励 R_{lower};
        将上层转移 $(o^U, \mathbf{a}^U, R_t, o^{U\prime})$ 存入 $\mathcal{B}^U$;
        将下层转移 $(o^L, \mathbf{a}^L, \mathbf{m}, R_{lower}, o^{L\prime})$ 存入 $\mathcal{B}^L$;
        记录当前时隙的 DSR 违反量和 MBS 负载违反量;
        if 当前 *episode* 达到 T 个时隙 **then**
            重置环境并开始新的 episode;
        end
    end
    计算上层和下层的 GAE 优势估计;
    for *PPO epoch* $= 1, 2, \cdots, P$ **do**
        从 $\mathcal{B}^U$ 采样 mini-batch，更新 θ^U 和 ϕ^U;
        从 $\mathcal{B}^L$ 采样 mini-batch，更新 θ^L 和 ϕ^L;
    end
    计算当前 rollout 的平均约束违反量 $\bar{v}_{dsr}$ 和 $\bar{v}_{mbs}$;
    更新 Lagrange 乘子：$\lambda_{dsr} \leftarrow \mathrm{clip}(\lambda_{dsr} + \eta_\lambda \bar{v}_{dsr}, 0, \lambda_{max})$;
    $\lambda_{mbs} \leftarrow \mathrm{clip}(\lambda_{mbs} + \eta_\lambda \bar{v}_{mbs}, 0, \lambda_{max})$;
end
return 训练完成的策略 $\pi^{upper}(\theta^U)$ 和 $\pi^{lower}(\theta^L)$;

3.3　仿真设置与性能评估

为验证所提双层 Attention-MAPPO 协同优化算法的有效性，本节在统一仿真环境和配对工作负载评估协议下围绕三个问题展开实验分析：第一，所提方法相对基础参考和学习式基线方法是否能够提升系统综合性能；第二，上层轨迹控制、下层卸载决策以及约束机制分别承担何种作用；第三，该方法在不同负载规模、算力条件和服务质量偏好下是否具有稳定的适用边界。因此，本节先给出主配置下的综合性能，再逐步分析模块贡献、行为机制、外部基线对比和参数敏感性，最后讨论服务质量偏好调整带来的 Energy-DSR-Fairness 权衡。

3.3.1　仿真环境、对比方法与评价指标

(1) 仿真环境与参数

本文在 Python 3.9.12 和 PyTorch 2.6.0 仿真平台上验证所提算法。系统环境包含多 UAV、UE 与 MBS 三类节点，并同时模拟通信链路、计算卸载、缓存获取、UE 电池演化和无线能量传输过程。主要仿真环境参数如表 3.2 所示。

本文算法训练参数如表 3.3 所示。主实验采用 3 个训练随机种子和 10 个工作负载随机种子；每个工作负载随机种子运行 6 个评估回合，并以每组（训练随机种子，工作负载随机种子）对应的回合均值作为统计单元，因此每个学习式策略共有 $N = 30$ 个统计样本。本文报告均值、标准差、95% 置信区间、配对差值、配对 t 检验和 Wilcoxon 符号秩检验结果。

(2) 对比方法

① 主配置策略组合

主配置策略组合用于验证双层结构的整体有效性，并拆分上层轨迹控制与下层卸载决策的贡献，如表 3.4 所示。

② 下层消融实验

下层消融实验用于分析请求注意力、质量感知动作掩码和拉格朗日约束三类组件的作用。实验以完整下层策略（`lower_full`，即 `att+lower`）为参考，如表 3.5 所示。

③ 综合对比方法

综合对比方法用于检验结论是否依赖单一参考策略，并进一步分析普通 MAPPO 和端到端联合 MAPPO 与本文双层结构的性能差异。除主配置策略组合外，本文设置普通 MAPPO 轨迹控制结合启发式卸载、端到端联合 MAPPO，以及随机策略（Random）、均匀策略（Uniform）、独立 PPO（IPPO）、普通 MAPPO（Vanilla MAPPO）、联合 MAPPO（Joint MAPPO）和本文方法（Proposed）。非学

表 3.2　仿真环境参数

Table 3.2　Simulation environment parameters

参数	数值
仿真区域	700 m × 700 m
UAV 数量 N / UE 数量 M / MBS 数量	5 / 100 / 1
MBS 位置	(350, 350, 30) m
UAV 飞行高度 H	100 m
时隙长度 τ / 回合长度 T	1 s / 1000 个时隙
最大飞行速度 v_{max}	15 m/s
UAV 覆盖半径 R_c / 感知范围	100 m / 460 m
最小 UAV 间距 d_{min}	200 m
UE-UAV / UAV-UAV / UAV-MBS 带宽	40 MHz / 20 MHz / 0.75 MHz
通信发射功率 P^{comm} / 噪声功率 σ^2	0.5 W / 10^{-13}
UAV 计算能力	$\{40, 45, \cdots, 85\} \times 10^9$ cycles/s
MBS 计算能力 f_{mbs}	200×10^9 cycles/s
服务类型数 / 内容文件数	25 / 50
服务请求截止时间	[0.65, 2.10] s
UE 电池容量 B_{max} / 低电量阈值 B_{low}	500 J / 50 J
UE 待机功耗 P_{static}	0.01 W
WPT 发射功率 / 采集效率 / 等效采集增益	50 W / 0.8 / 5×10^5
UAV 移动功率 P_{move} / 悬停功率 P_{hover}	300 W / 150 W
未服务惩罚时延 $T_{penalty}$	20 s
系统/下层参考能耗 E_{ref} / $E_{ref}^{offload}$	5000 J / 25000 J

表 3.3　算法训练参数

Table 3.3　Algorithm training parameters

参数	数值
训练随机种子	42, 84, 126
工作负载随机种子	42, 84, 126, 168, 210 252, 294, 336, 378, 420
训练回合数 / 每个工作负载评估回合数	200 / 6
MLP 隐层维度	128
注意力隐层维度 / 注意力头数	64 / 8
每架 UAV 最大请求槽数 K	30
优化器 / 学习率	Adam / 3×10^{-4}
PPO clip 系数 ϵ	0.2
折扣因子 γ / GAE 系数 λ	0.99 / 0.95
采样轨迹长度 / PPO 更新轮数 / 批大小	1000 / 8 / 256
熵系数	0.005
系统奖励权重	$W_J = 1.0$, $W_L = 1.0$, $W_E = 0.5$ $W_O = 5.0$, $W_{DSR} = 1.0$, $W_M = 0.5$
下层奖励权重	$w_{succ} = 0.4$, $w_{coop} = 0.08$, $w_{dead} = 3.0$ $w_{lat} = 4.0$, $w_{en} = 1.2$, $w_{mbs} = 0.35$
Lagrange 约束目标	$\tau_{dsr} = 0.18$, $\tau_{mbs} = 0.03$
Lagrange 学习率 / 乘子上界	0.1 / 10.0
MBS 掩码截止时间截断阈值	10
协作卸载掩码阈值	$\theta_{deadline} = 1.50$, $\theta_{latency} = 1.35$ $\theta_{share} = 0.25$

表 3.4　主配置策略组合

Table 3.4　Main-configuration strategy combinations

组合方案	轨迹控制	卸载策略	角色
unco+heuristic	非协同贪心策略	启发式卸载	基础参考
att+heuristic	Attention-MAPPO	启发式卸载	上层贡献
unco+lower	非协同贪心策略	下层 MAPPO	下层贡献
att+lower	Attention-MAPPO	下层 MAPPO	分别训练后组合
full hierarchical	Attention-MAPPO	下层 MAPPO	完整双层联合训练

表 3.5　下层消融实验配置

Table 3.5　Lower-layer ablation configurations

消融方法	注意力机制	质量感知掩码	Lagrange 约束
lower_full	是	是	是
lower_no_mask	是	否	是
lower_no_lagrange	是	是	否
lower_no_attention	否	是	是

习式方法以工作负载随机种子为统计单元；学习式方法沿用表 3.3 所示的训练与评估协议。

(3) 评估指标

本文使用以下评估指标：

- **系统奖励**（R_t）：第 3.1.6 节定义的系统级综合奖励
- **总时延**（L）：所有 UE 的总时延（含 $T_{penalty} = 20$s 未服务惩罚）
- **总能耗**（E）：UAV 侧总能耗（含飞行、悬停、计算、通信、WPT）
- **公平性**（J）：基于各 UE 的历史服务覆盖量计算 Jain 指数，衡量用户服务机会的均衡程度；该指标不等同于截止时间满足率
- **DSR**：截止时间满足率（deadline satisfaction rate），即统计单元内满足截止时间约束的服务请求数占全部生成服务请求数的比例
- **离线率**（O）：电池低于 B_{low} 的 UE 比例
- **执行位置分布**：由当前 UAV 本地执行、协作 UAV 执行和 MBS 执行的服务请求占全部生成服务请求的比例，用于描述卸载决策行为
- **MBS 负载比例**：由 MBS 执行的服务请求占全部生成服务请求的比例，用于衡量系统对远端计算资源的依赖程度

为综合衡量系统在能耗和服务质量维度的联合表现，本文补充采用有效能效（Effective Energy Efficiency, EEE）指标：

$$\mathrm{EEE} = \frac{N_{\text{deadline-satisfied}}}{E_{\text{total}}}, \tag{3.42}$$

其中 $N_{\text{deadline-satisfied}}$ 为满足截止时间约束的服务请求数，E_{total} 为 UAV 侧总能耗。EEE 表示单位能耗下有效完成的服务请求数，数值越高表示能耗与服务质量之间的折中越有利。

3.3.2　主配置下的综合性能与分层贡献分析

（1）综合性能对比

本小节比较三组主配置，用于分析上层轨迹控制、下层卸载决策和完整双层协同的分层贡献。所有方法均在相同的系统模型和请求关联规则下评估。统计单元为训练随机种子与工作负载随机种子的组合均值，$N = 30$。

表 3.6　主配置实验结果（均值 ± 标准差，$N = 30$）

Table 3.6　Main-configuration results (mean ± standard deviation, $N = 30$)

策略	Reward	Energy (M)	DSR	Fairness	MBS load
上层 + 启发式	-1344.4 ± 278.4	74.65 ± 7.76	**0.4957** ± 0.0319	0.9444 ± 0.0190	**2.38%** ± 0.43%
固定上层 + 下层	-8934.2 ± 367.6	72.72 ± 11.08	0.3977 ± 0.0545	0.7577 ± 0.0594	4.76% ± 3.21%
完整双层	**-1096.8** ± 292.8	**49.98** ± 4.71	0.3762 ± 0.0283	**0.9452** ± 0.0139	3.59% ± 4.19%

表 3.7 进一步给出自然覆盖比例与执行位置分布，用于反映不同策略的空间服务行为和卸载选择。

表 3.7　主配置的自然覆盖与执行位置分布

Table 3.7　Natural coverage and execution-location distribution of main configurations

策略	自然覆盖	本地 UAV 执行	协作 UAV 执行	MBS 执行
上层 + 启发式	50.22%	55.45%	42.17%	2.38%
固定上层 + 下层	19.98%	35.02%	60.22%	4.76%
完整双层	**52.21%**	55.60%	40.81%	3.59%

结果显示，三种配置对应不同的性能工作点。上层 + 启发式配置取得最高 DSR（0.4957）和最低 MBS 负载（2.38%），但 UAV 侧能耗为 74.65M，明显高于完整双层。固定上层 + 下层配置的协作执行比例最高（60.22%），但自然覆盖比例仅为 19.98%，系统奖励和公平性均较低，说明仅依赖下层卸载难以弥补轨迹策略带来的空间服务差异。完整双层配置的 DSR 并非最高，但其能耗最低（49.98M）、公平性最高（0.9452），并将 MBS 负载维持在 3.59%。因此，完整方法的优势在于能耗、公平性和 MBS 依赖之间的综合折中。

（2）分层贡献分析

本小节进一步拆分上层轨迹控制和下层卸载决策的作用。从表 3.6 和表 3.7 可以看出，上层轨迹策略主要决定自然覆盖水平和空间公平性：完整双层的自然覆盖服务比例为 52.21%，高于固定上层 + 下层配置的 19.98%，并将公平性

提升至 0.9452。下层卸载策略主要改变请求在本地、协作 UAV 与 MBS 之间的执行位置：固定上层 + 下层配置依赖 60.22% 的协作执行来弥补覆盖不足，而完整双层在保持 55.60% 本地执行和 40.81% 协作执行的同时，将 UAV 侧能耗降至 49.98M。该结果说明，上层并非单独追求最高 DSR，下层也并非单纯增加某一类卸载模式；二者共同形成的是低能耗、高公平性和低 MBS 依赖的稳定工作点。

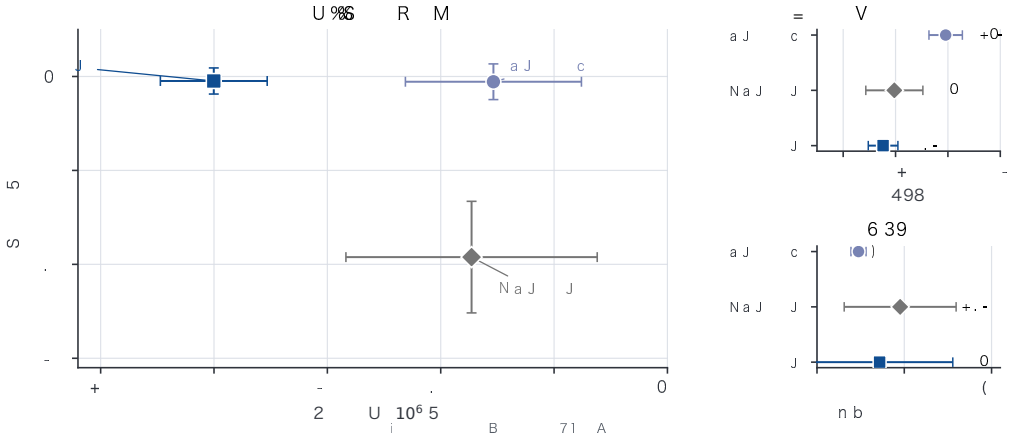


图 3.3　主配置性能工作点与服务约束

Figure 3.3　Performance trade-off and service constraints of main configurations

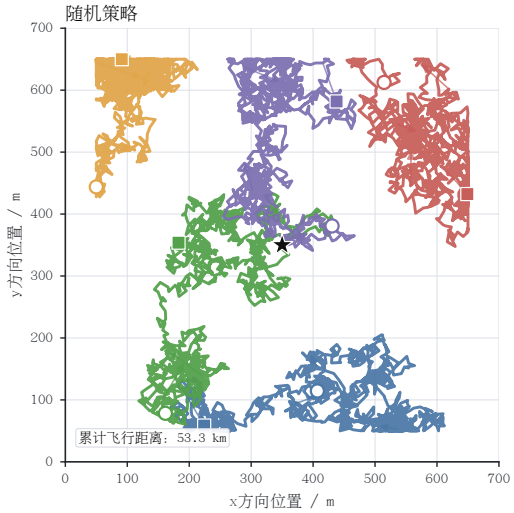
(3) 有效能效补充评价

有效能效 EEE 用于补充观察单位能耗下的有效服务产出。本文仍以 DSR、UAV 侧能耗和公平性作为核心性能指标：完整双层配置在 DSR 为 0.3762 时，将能耗控制在 49.98M，并取得 0.9452 的公平性。因此，EEE 用于辅助解释能耗与服务质量之间的折中，不替代各项指标的独立报告。

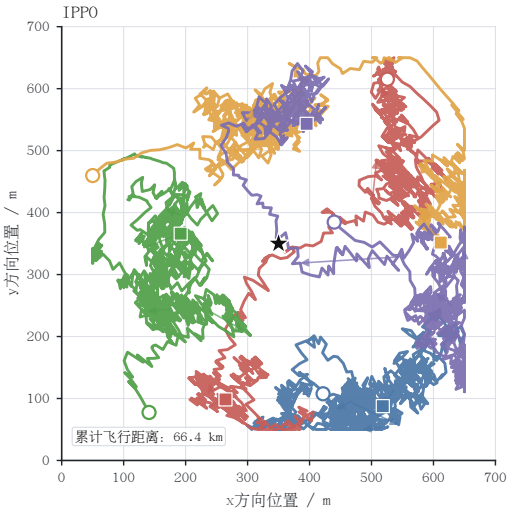
3.3.3　行为机制与模块消融分析

(1) 轨迹可视化分析

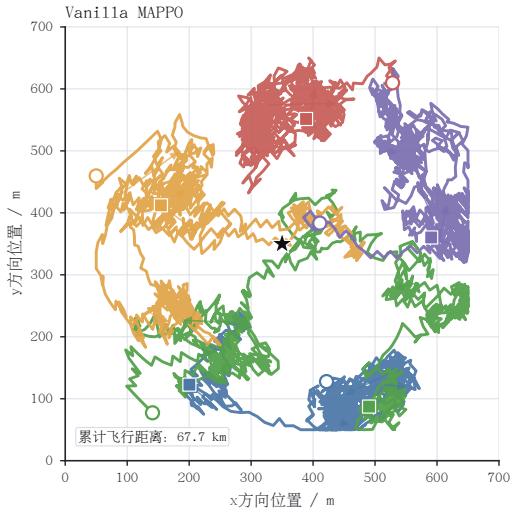
由于本文方法同时包含上层轨迹控制和下层请求级卸载决策，仅依赖表格指标难以直观展示不同策略在空间维度上的行为差异。考虑到评估过程中 UE 位置和请求状态会随时间变化，单一时刻的用户散点不能完整代表整个 episode 的服务需求分布。因此，图 3.4 仅展示同一评估场景下不同算法的无人机二维飞行轨迹，用于分析策略在空间移动模式和移动代价上的差异。该图基于训练随机种子 42 和工作负载随机种子 42 的第一个评估 episode 绘制，属于固定 seed 的行为案例而非总体性能统计。其中，彩色曲线表示 5 架无人机在整个评估 episode 中的水平飞行轨迹，空心圆表示轨迹记录中的首个位置，实心方块表示最后记录位置，箭头表示移动方向，黑色五角星表示宏基站位置。各子图左下角进一步给出了该 episode 内 5 架无人机的累计飞行距离。



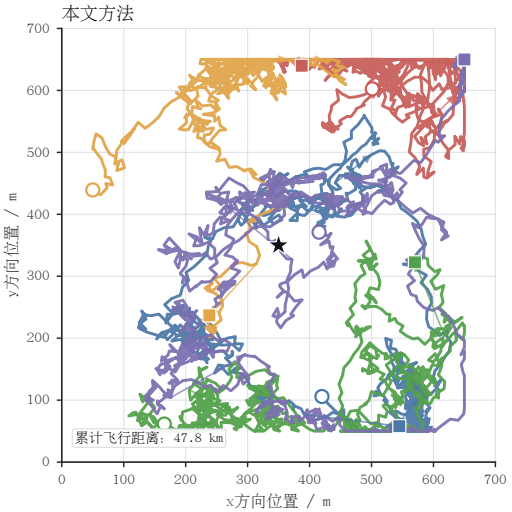
(a) 随机策略



(b) IPPO



(c) Vanilla MAPPO



(d) 本文方法

图 3.4　固定 seed 示例下不同算法的无人机二维飞行轨迹对比

Figure 3.4　Example two-dimensional UAV trajectories under different algorithms for a fixed seed

从图 3.4 可以看出，在同一评估场景下，随机策略的移动方向缺乏稳定目标，轨迹更多体现为无规则探索，各 UAV 之间缺乏协调，累计飞行距离约为 53.3 km。IPPO 和 Vanilla MAPPO 形成较明显的局部移动模式，累计飞行距离分别约为 66.4 km 和 67.7 km。相比之下，本文方法的累计飞行距离约为 47.8 km，低于 IPPO 和 Vanilla MAPPO，同时保持较低的 MBS 负载。

（2）卸载分布分析

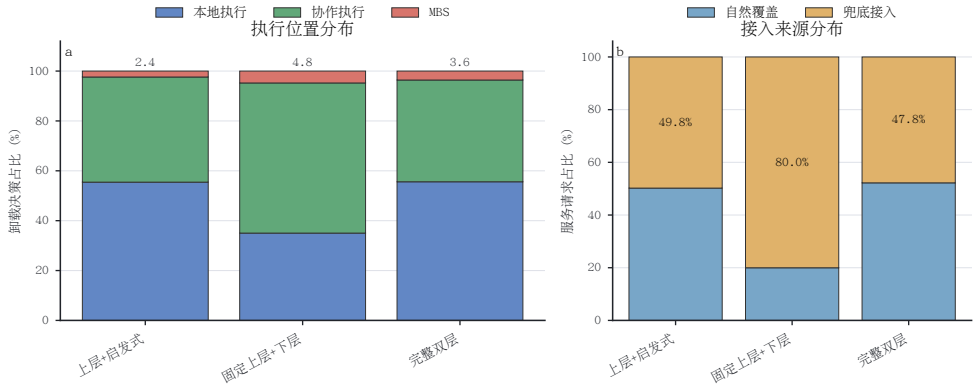


图 3.5　卸载分布对比

Figure 3.5　Offloading distribution comparison

图 3.5 展示了主配置下的执行位置分布。完整双层配置的本地 UAV 执行、协作 UAV 执行和 MBS 执行比例分别为 55.60%、40.81% 和 3.59%，说明其主要利用 UAV 侧的本地与协作资源完成服务处理，而非简单增加对 MBS 的依赖。相比之下，固定上层 + 下层配置的协作执行比例达到 60.22%，表明在自然覆盖较低时，下层策略更依赖协作执行。完整双层配置在保持较低 MBS 负载的同时，实现了本地与协作执行之间的较均衡分配，这与其能耗和公平性优势相一致。

（3）下层模块消融

表 3.8 给出了下层模块消融结果，用于分析各组件对卸载行为、MBS 依赖和截止时间满足情况的影响。

表 3.8　下层模块消融实验结果（均值，$N = 30$）

Table 3.8　Lower-layer ablation results (mean, $N = 30$)

消融	Reward	Energy (M)	DSR	Fairness	MBS load
lower_full	−8934.2	72.72	0.3977	0.7577	4.76%
no_mask	**−8816.4**	62.72	0.3884	0.7434	**0.03%**
no_lagrange	−8847.0	**53.16**	0.3403	0.6962	36.48%
no_attention	−8833.4	64.69	**0.4030**	0.7460	5.13%

消融结果表明，各模块改变的是卸载行为和约束权衡，而非同步提升所有

指标。移除拉格朗日软约束后，MBS 负载从 4.76% 大幅升至 36.48%，同时公平性降至 0.6962，说明该约束对抑制 MBS 依赖最关键。移除质量感知动作掩码后，MBS 负载接近于零，但 DSR 和公平性均未优于完整下层，说明过度限制 MBS 动作会压缩可行的卸载选择。移除请求注意力后，DSR 略高于完整下层（0.4030 对 0.3977），但公平性仍较低，说明注意力机制的贡献更偏向请求关系建模和服务均衡，而非保证 DSR 单项最高。综上，下层模块的作用在于约束 MBS 依赖，并调节本地、协作和 MBS 执行之间的分布。

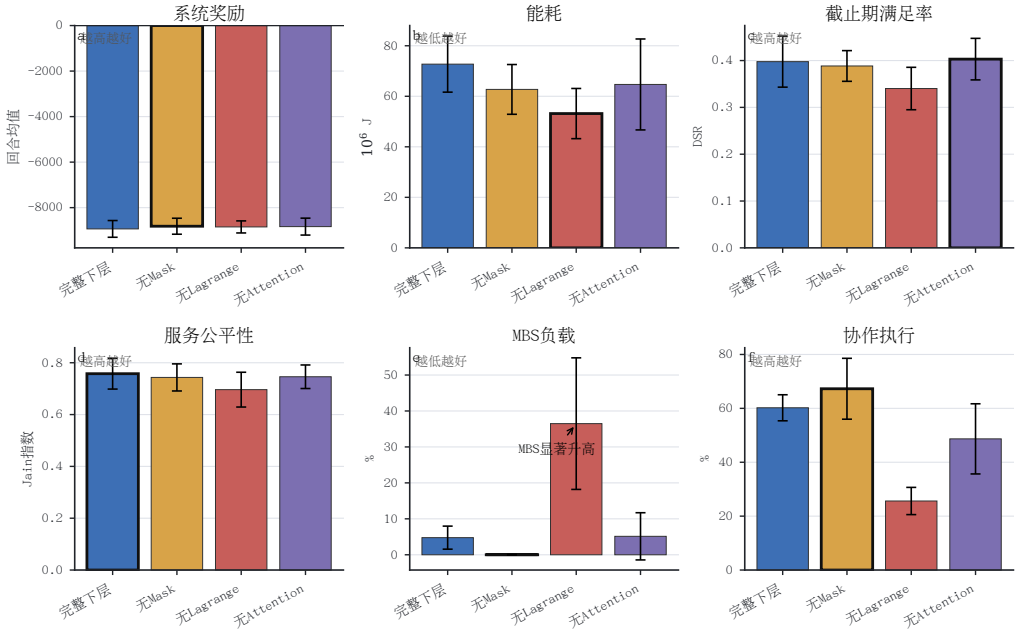


图 3.6　消融实验对比

Figure 3.6　Ablation experiment comparison

3.3.4　综合对比与端到端方法分析

(1) 综合对比实验

在主配置验证双层结构有效后，本节进一步比较学习式与非学习式方法。随机策略（Random）、均匀卸载策略（Uniform）、独立 PPO（IPPO）、普通 MAPPO（Vanilla MAPPO）、端到端联合 MAPPO（Joint MAPPO）和本文方法（Proposed）均在相同系统模型和评估协议下比较。学习式方法与本文方法按（训练随机种子，工作负载随机种子）配对；非学习式方法先对不同训练随机种子下的结果取均值，再按工作负载随机种子配对。

图 3.7 表明，本文方法的优势主要集中在系统公平性、能耗控制和较低的 MBS 依赖。本文方法的公平性为 0.9452，在所有方法中最高；相对 IPPO、Vanilla MAPPO、Joint MAPPO、Random 和 Uniform 分别提升约 4.70%、4.37%、19.86%、6.13% 和 9.86%。同时，本文方法的离线率为 2.25%，低于 IPPO、Vanilla MAPPO

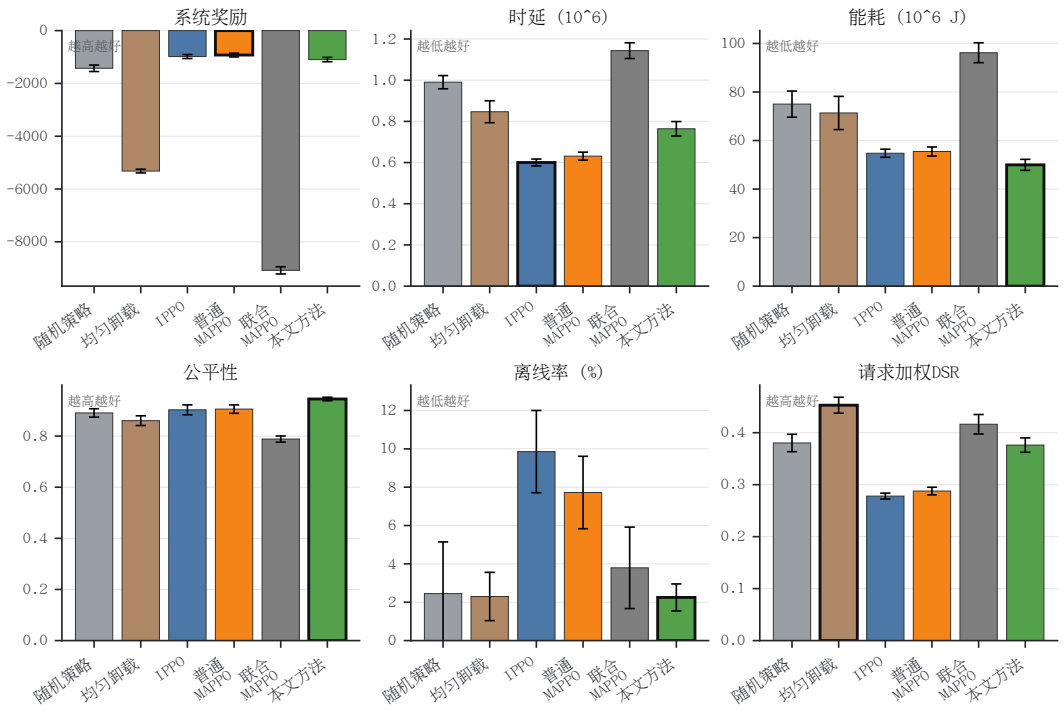


图 3.7　综合对比方法的多指标比较

Figure 3.7　Multi-metric comparison of benchmark methods

和 Joint MAPPO，并与随机和均匀策略处于相近水平。

在截止时间满足情况方面，本文方法的 DSR 为 0.3762，高于 IPPO（0.2780）和 Vanilla MAPPO（0.2878），与 Random（0.3802）接近，但低于 Joint MAPPO（0.4163）和 Uniform（0.4529）。这说明均匀策略或端到端策略能够通过更激进的卸载分配获得更高 DSR，但会付出更高能耗、更高 MBS 依赖或更低公平性的代价。能耗方面，本文方法的 UAV 侧能耗为 49.98M，低于 IPPO、Vanilla MAPPO、Joint MAPPO、Random 和 Uniform，分别降低约 8.73%、9.92%、48.04%、33.37% 和 29.96%。因此，本文方法的核心优势在于形成低能耗、高公平性和低 MBS 依赖的综合工作点，而非 DSR 单项最优。

图 3.8 进一步解释了上述优势的来源。本文方法的 MBS 负载比例为 3.59%，明显低于 IPPO 的 29.54%、Vanilla MAPPO 的 8.21%、Joint MAPPO 的 27.72%、Random 的 32.28% 和 Uniform 的 18.37%。同时，本文方法的本地 UAV 执行比例为 55.60%，协作 UAV 执行比例为 40.81%，说明其主要利用 UAV 侧的本地与协作资源完成服务处理，而非简单增加对 MBS 的依赖。综合来看，结果支持本文方法在公平性、能耗和 MBS 依赖之间取得较优折中。

（2）端到端联合 MAPPO 对比

端到端联合 MAPPO 用于分析为何不直接训练单一策略同时输出轨迹和卸载动作。该模型使用单一 MAPPO 策略网络同时输出 UAV 连续轨迹动作和请求

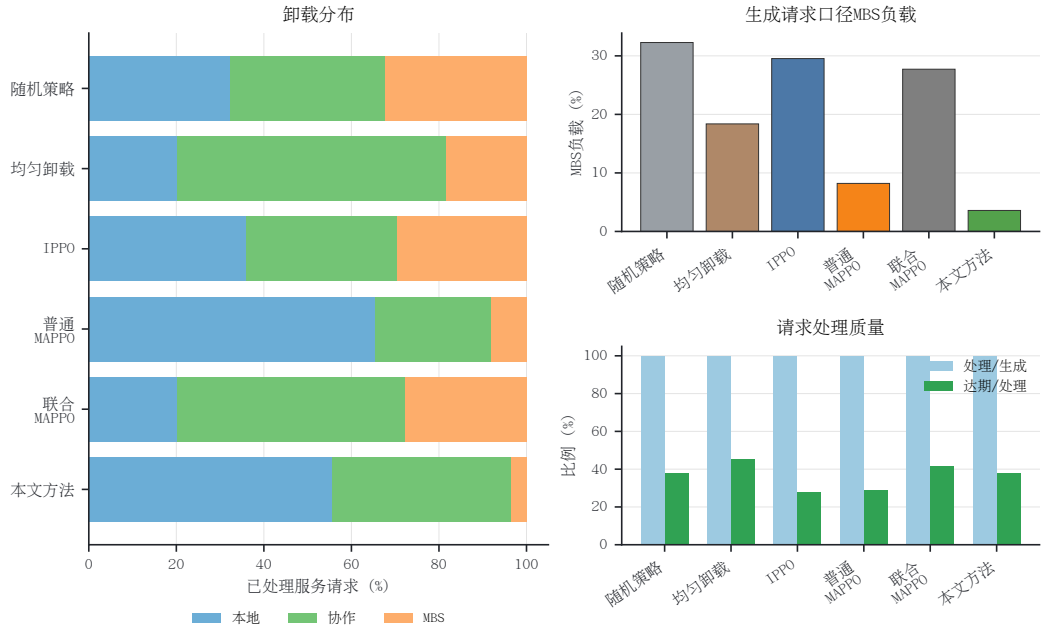


图 3.8　综合对比方法的服务表现与执行位置分布

Figure 3.8　Service performance and execution-location distribution of benchmark methods

级离散卸载动作，并使用联合观测和统一 PPO 更新，不复用已训练的上层或下层模型。表 3.9 给出该方法在统一评估协议下的结果。

表 3.9　端到端联合 MAPPO 评估结果

Table 3.9　End-to-end joint MAPPO evaluation results

策略	Reward	Latency	Energy (M)	DSR
joint end-to-end MAPPO	-9081.2 ± 190.5	1143570 ± 53368	96.18 ± 5.73	0.4163 ± 0.0262

端到端联合 MAPPO 的 DSR 为 0.4163，但其系统奖励为 -9081.2、UAV 侧能耗为 96.18M、公平性为 0.7885、MBS 负载比例为 27.72%，整体代价明显高于分层策略。该对比支持本文的结构选择：在相同训练预算下，将连续轨迹控制和请求级离散卸载直接合并到单一策略网络，虽可能提高部分截止时间指标，但会扩大联合动作空间并增加策略归因难度；双层分解通过明确模块分工，在能耗、MBS 负载、公平性和行为可解释性之间取得更稳定的综合表现。

3.3.5　参数敏感性与鲁棒性分析

(1) 地面节点数量敏感性

图 3.9 给出了不同地面节点数量（$M = 60, 80, 100, 120, 140$）下 DSR、有效能效和公平性的变化趋势。

从 DSR 看，随着 UE 数量增加，请求密度和资源竞争增强，三种方法的 DSR

均整体下降。启发式策略在 DSR 单项上最高，本文方法低于启发式但始终高于普通 MAPPO，例如在 $M = 140$ 时本文方法 DSR 为 0.2897，高于普通 MAPPO 的 0.2158。与此同时，本文方法在所有 UE 数量下均取得最高公平性，且在 $M \geqslant 100$ 的高负载场景下有效能效最高。该结果表明，本文方法在负载升高时并不追求 DSR 单项最优，而是保持更好的能效和服务公平性折中。

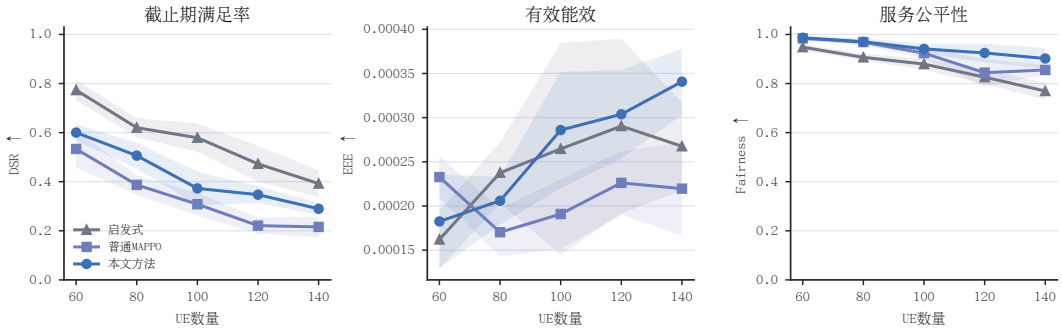


图 3.9　不同地面节点数量下的三指标敏感性分析

Figure 3.9　Three-metric sensitivity analysis under different UE counts

(2) UAV 算力敏感性

图 3.10 展示了 UAV CPU 缩放因子变化对 DSR、有效能效和公平性的影响。

结果显示，UAV 算力提升总体有利于截止时间满足，但不同策略的受益方式并不相同。启发式策略在 DSR 单项上仍较高；本文方法除 0.6× 低算力点外均高于普通 MAPPO，并在 1.0× 和 1.4× 下分别达到 0.4055 和 0.4072。有效能效方面，本文方法在全部算力设置下均高于普通 MAPPO，并在 1.2× 和 1.4× 高算力设置下超过启发式策略。公平性方面，本文方法在低至中等算力设置下领先，在高算力设置下仍保持较高水平。综合来看，算力敏感性实验进一步说明，本文方法的主要优势是能效、公平性和服务质量之间的折中，而非单独最大化 DSR。

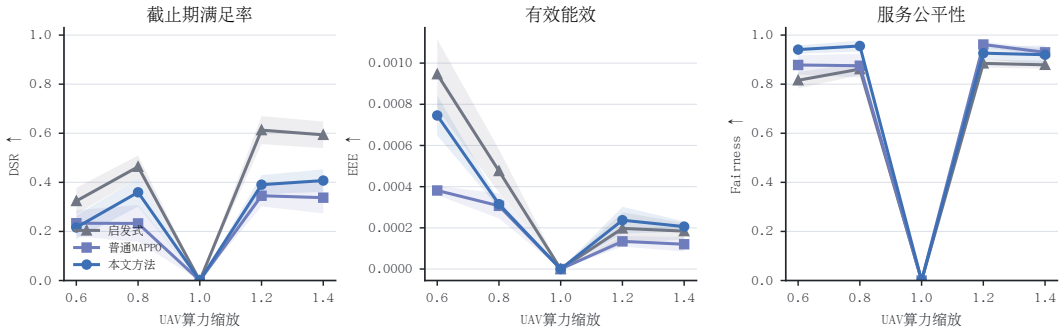


图 3.10　不同 UAV 算力下的三指标敏感性分析

Figure 3.10　Three-metric sensitivity analysis under different UAV computing capacities

3.3.6　服务质量偏好权衡

(1) DSR 优先配置实验

为进一步分析服务质量偏好调节的边界，本文比较基准完整双层配置与 DSR 优先配置。DSR 优先配置提高系统级 DSR 权重、降低能耗权重，并放宽下层 MBS 负载目标；其目的不是证明 DSR 必然提升，而是检验偏好调节能否在泛化评估中稳定改变性能工作点。

表 3.10　DSR 优先配置对比（均值 ± 标准差，$N = 30$）

Table 3.10　Comparison of the DSR-priority configuration (mean ± standard deviation, $N = 30$)

配置	Reward	Energy (M)	DSR	Fairness	MBS load
完整双层（基准配置）	-1096.8 ± 292.8	**49.98** ± 4.71	**0.3762** ± 0.0283	**0.9452** ± 0.0139	**3.59%** ± 4.19%
DSR 优先配置	**-972.0** ± 257.3	53.06 ± 9.16	0.3524 ± 0.0544	0.9321 ± 0.0188	23.05% ± 26.13%

表 3.10 和图 3.11 显示，DSR 优先配置虽然使系统奖励从 -1096.8 提升至 -972.0，但泛化评估中的 DSR 未稳定提升，反而从 0.3762 降至 0.3524；同时，MBS 负载从 3.59% 升至 23.05%，公平性从 0.9452 降至 0.9321。该结果说明，单纯提高 DSR 目标或放宽 MBS 目标可能推动策略更多依赖 MBS，但不一定带来稳定的截止时间满足收益。因此，服务质量偏好调节需要与轨迹覆盖、协作资源和 MBS 负载共同设计，不能仅依赖奖励权重放大。

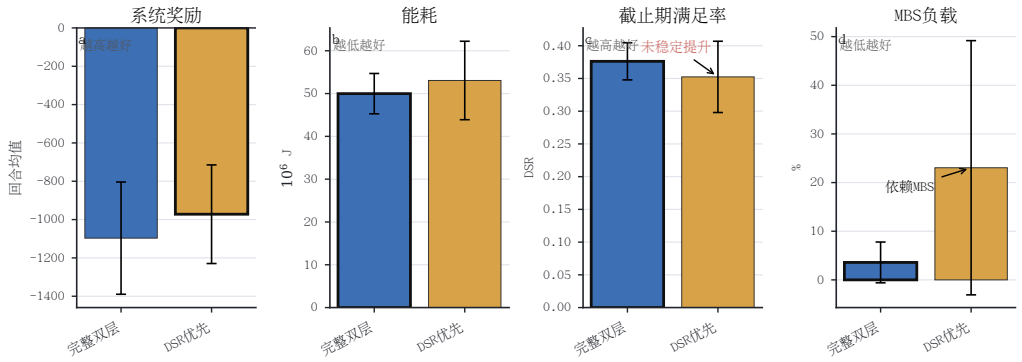


图 3.11　DSR 优先配置下的性能权衡

Figure 3.11　Performance trade-off under the DSR-priority configuration

综合主配置、模块消融、综合对比、参数敏感性和 DSR 优先配置结果可以看出，多 UAV-MEC 系统中的能耗、DSR、公平性和 MBS 依赖存在明显权衡。本文双层 MARL 框架并不追求所有单项指标同步最优，而是将系统推向低 UAV 能耗、高服务公平性和低 MBS 依赖的综合工作点。

3.3.7 方法特点与现有工作的比较

与现有单层端到端方法相比，本文将连续轨迹控制与离散请求级卸载分解为两个协同决策层，以降低直接联合建模的动作耦合复杂度，并增强策略行为的可解释性[33]。与基于 SAC 的联合优化方法相比，本文通过分层结构分别处理连续与离散决策，避免直接构造高维混合联合动作[34]。与基于博弈论的优化方法相比，本文的 MARL 在线执行主要依赖局部与邻居观测，适用于动态请求和链路状态持续变化的场景[36]。

3.4 本章小结

本章围绕无人机辅助 MEC 系统中的轨迹控制与任务卸载协同优化问题展开研究。首先建立由多 UAV、UE 和 MBS 组成的系统模型，给出通信链路、请求关联、计算时延、能耗、UE 电池和无线能量传输模型。随后，针对连续–离散混合、多智能体和动态约束并存的优化问题，设计基于 Attention-MAPPO 的双层协同优化算法：上层负责 UAV 轨迹控制，下层负责请求级卸载决策，并结合质量感知动作掩码和拉格朗日软约束调节策略行为。统一实验协议下的结果表明，本文方法取得最高公平性（0.9452）、最低 UAV 侧能耗（49.98M）和最低 MBS 负载比例（3.59%），同时保持 0.3762 的 DSR。上述结果说明，所提双层方法的主要优势在于公平性、能耗和 MBS 依赖之间的综合折中；敏感性实验进一步表明，该折中在 UE 负载和 UAV 算力变化下具有稳定性，但并不意味着所有单项服务质量指标均最优。

第 4 章　总结与展望

4.1　工作总结

本文提出基于 Attention-MAPPO 的多无人机 MEC 轨迹与任务卸载协同优化框架。该框架将轨迹控制和请求级卸载分解为两个协同决策层，以降低直接端到端联合动作建模的结构复杂度。系统中，服务请求优先关联至自然覆盖范围内的 UAV；未被自然覆盖的请求按照最近 UAV 原则关联，并在真实链路条件下进入后续处理流程。

本文的主要工作和贡献包括：

1. 提出了基于 Attention-MAPPO 的双层 MARL 框架，将轨迹控制与请求级卸载解耦为上层和下层两个协同决策层，降低动作空间复杂度。
2. 设计了质量感知动作掩码和拉格朗日约束机制，分别处理不可行动作屏蔽和 DSR-MBS 负载权衡问题。
3. 显式建模了 UAV 飞行能耗、UE 电池动态和 WPT 机制，并在系统模型中定义服务请求关联与处理流程。

实验结果表明：

1. 综合对比实验中，本文方法取得最高公平性（0.9452）、最低 UAV 侧能耗（49.98M）和最低 MBS 负载比例（3.59%），同时保持 0.3762 的 DSR，体现出低能耗、高公平性和低 MBS 依赖的综合折中优势。
2. 与 IPPO 和 Vanilla MAPPO 相比，本文方法的 DSR 更高且 MBS 依赖更低；与 Joint MAPPO 和 Uniform 相比，本文方法虽然不是最高 DSR，但能耗和 MBS 负载更低，公平性更高。
3. 主配置和模块消融结果表明，上层轨迹控制主要改善自然覆盖水平和空间公平性，下层请求级卸载主要调节本地、协作和 MBS 执行分布；拉格朗日软约束对抑制 MBS 依赖最为关键。
4. 端到端联合 MAPPO 的 DSR 为 0.4163，但其系统奖励、能耗、公平性和 MBS 负载均明显劣于分层策略，说明直接联合学习轨迹与卸载动作具有更高的综合代价。
5. 参数敏感性实验进一步显示，在 UE 数量和 UAV 算力变化下，本文方法通常保持高于普通 MAPPO 的 DSR 和有效能效，并在负载升高时维持较高公平性，验证了其作为综合折中策略的稳定性。

4.2 未来展望

本文工作仍可从以下方向进一步扩展：

1. 在更多 DSR 阈值和权重组合上进行细粒度 Pareto 扫描，以更好地理解 DSR、能耗和公平性之间的权衡关系。
2. 扩大各对比方法的训练随机种子与工作负载随机种子规模，以提高实验结论的统计可靠性。
3. 引入三维轨迹控制以更好地模拟真实部署环境，考虑 UAV 飞行高度的变化对通信和能耗的影响。
4. 研究更高效的 Lagrange 乘子自适应更新策略，以提高约束优化的收敛速度和稳定性。
5. 将服务缓存和内容分发纳入协同优化框架，实现轨迹、卸载、缓存和资源分配的全面协同优化。
6. 探索异构 UAV 场景，考虑不同类型 UAV 的计算能力、通信能力和能耗特性差异。
7. 研究动态拓扑下的多 UAV 协同问题，考虑 UAV 的加入和退出对系统性能的影响。

4.3 本章小结

本章总结了本文的研究工作和主要贡献，并展望了未来研究方向。首先回顾了基于 Attention-MAPPO 的双层 MARL 框架及其系统模型；随后总结了实验中体现出的公平性、能耗、MBS 负载和鲁棒性方面的综合折中优势；最后提出了细粒度 Pareto 扫描、三维轨迹控制、拉格朗日乘子自适应更新、服务缓存和内容分发协同优化等后续研究方向。

参考文献

[1] Ericsson. 5g radio access[J]. Ericsson White Paper, 2015.

[2] 3GPP. 5g system overview[J]. 3GPP Technical Report, 2020.

[3] Zeng Y, Zhang R, Lim T J. Wireless communications with unmanned aerial vehicles: opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.

[4] Mozaffari M, Saad W, Bennis M, et al. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.

[5] Li J, Gao Y, Yang K. Deep reinforcement learning for uav-assisted iot data collection[J]. IEEE Internet of Things Journal, 2020, 7(10): 10326-10339.

[6] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[7] Silver D, Huang A, Maddison C J, et al. Mastering the game of go with deep neural networks and tree search[J]. Nature, 2016, 529(7587): 484-489.

[8] Levine S, Finn C, Darrell T, et al. End-to-end training of deep visuomotor policies[J]. Journal of Machine Learning Research, 2016, 17(1): 1334-1373.

[9] Ye Q, Li B, Zhuang W. Deep reinforcement learning for resource management in network slicing[J]. IEEE Communications Magazine, 2020, 58(4): 88-93.

[10] Hu X, Wong K K, Yang K, et al. UAV-assisted relaying and edge computing: Scheduling and trajectory optimization[J]. IEEE Transactions on Wireless Communications, 2019, 18(10): 4738-4752.

[11] Yu Z, Gong Y, Gong S, et al. Joint task offloading and resource allocation in UAV-enabled mobile edge computing[J]. IEEE Internet of Things Journal, 2020, 7(4): 3147-3159.

[12] Trotta A, Di Felice M, Bedogni L, et al. Uav-bss deployment and charging scheduling for aerial mesh networks[J]. IEEE Transactions on Mobile Computing, 2018, 17(11): 2564-2579.

[13] Lai Z, Chen Z, Liu Y, et al. Adaptive and fair uav deployment for wireless networks[J]. IEEE Transactions on Wireless Communications, 2019, 18(10): 4782-4796.

[14] Wang L, Wang K, Pan C, et al. Centralized greedy search for uav deployment[J]. IEEE Transactions on Communications, 2019, 67(12): 8435-8449.

[15] Yang B, Xu C, Yang K. Uav traffic offloading in high-density areas[J]. IEEE Transactions on Vehicular Technology, 2019, 68(11): 11120-11134.

[16] Lee S, Kim S, Choi Y. Uav-assisted nb-iot optimization based on competitive clustering and stackelberg game[J]. IEEE Internet of Things Journal, 2020, 7(8): 7342-7355.

[17] Kumar S, Sharma S, Singh B. Dynamic resource allocation in millimeter wave uav networks [J]. IEEE Transactions on Wireless Communications, 2020, 19(7): 4735-4749.

[18] Duan R, Wang J, Jiang C, et al. Multi-uav assisted iot noma resource allocation based on k-means clustering[J]. IEEE Transactions on Vehicular Technology, 2020, 69(12): 15245-15259.

[19] Qin Z, Liu Y, Li Z, et al. Uav trajectory optimization and resource allocation based on c-noma [J]. IEEE Transactions on Communications, 2021, 69(3): 1735-1749.

[20] Guo H, Liu J, Zhang J. Noma resource management in uav-assisted mec systems[J]. IEEE Transactions on Wireless Communications, 2021, 20(4): 2456-2470.

[21] Yuan X, Xie Z, Tan X. Computation offloading in UAV-enabled edge computing: A Stackelberg game approach[J]. Sensors, 2022, 22(10): 3854.

[22] Liu L, Tian B, Zhao X, et al. UAV autonomous trajectory planning in target tracking tasks via a DQN approach[C]. Proceedings of the IEEE International Conference on Real-time Computing and Robotics (RCAR). IEEE, 2019: 277-282.

[23] Zhang T, Lei J, Liu Y, et al. Trajectory optimization for UAV emergency communication with limited user equipment energy: A Safe-DQN approach[J]. IEEE Transactions on Green Communications and Networking, 2021, 5(3): 1236-1247.

[24] Li Y, Zhang H, Peng M. Deep reinforcement learning based mean field games for uav power control[J]. IEEE Transactions on Wireless Communications, 2021, 20(8): 5142-5156.

[25] Hady M A, Hu S, Pratama M, et al. Multi-agent reinforcement learning for resources allocation optimization: A survey[J]. Artificial Intelligence Review, 2025, 58: 354.

[26] Li W, Li S, Shi H, et al. UAV-enabled fair offloading for MEC networks: A DRL approach based on actor-critic parallel architecture[J]. Applied Intelligence, 2024, 54: 3529-3546.

[27] Ghomri B I D, Bendimerad M Y, Bendimerad F T. DRL-driven optimization for energy efficiency and fairness in NOMA-UAV networks[J]. IEEE Communications Letters, 2024, 28(5): 1048-1052.

[28] Huang L, Bi S, Zhang Y J A. Drl based online offloading framework for uav-mec systems[J]. IEEE Transactions on Wireless Communications, 2021, 20(5): 3025-3039.

[29] Khurshid T, Ahmed W, Rehan M, et al. A DRL strategy for optimal resource allocation along with 3D trajectory dynamics in UAV-MEC network[J]. IEEE Access, 2023, 11: 54664-54678.

[30] Tao Y, Kuang Z, Hou F, et al. Online service selection and task offloading in UAV-assisted MEC via deep reinforcement learning[J]. IEEE Transactions on Cognitive Communications and Networking, 2026, 12: 4159-4168.

[31] Wu Q, Zhang R. Irs enhanced uav-assisted mec systems[J]. IEEE Transactions on Wireless Communications, 2021, 20(3): 1735-1749.

[32] 李静刘伟和, 张涛. 多智能体强化学习在无人机边缘计算中的应用综述[J]. 计算机科学,

2026.

[33] 黄子祥, 张新有. 应急场景下多无人机协同辅助计算卸载策略[J]. 传感器与微系统, 2026, 45(5): 142-148.

[34] 尤昕阳, 李旭龙, 王浩彬, 等. 基于强化学习的多无人机协同 MEC 任务卸载方案[J]. 西安电子科技大学学报, 2026, 53(1): 116-128.

[35] 王义君, 王雅出, Batool S, 等. 无人机辅助动态权重边缘计算卸载策略研究[J]. 电子与信息学报, 2026, 48(12).

[36] 曾耀平, 李怀, 陈世森, 等. 无人机部署与卸载策略优化[J]. 浙江大学学报（工学版）, 2026, 60(6): 1-11.

[37] 李侍阳, 朱晓荣. 面向感知与 AI 协同任务的无人机巡检多维资源联合优化算法[J]. 电子与信息学报, 2026, 48(12).

[38] Yu C, Velu A, Vinitsky E, et al. The surprising effectiveness of PPO in cooperative multi-agent games[J]. Advances in Neural Information Processing Systems, 2022, 35: 24611-24624.

[39] ETSI. Multi-access edge computing (mec): Framework and reference architecture[Z]. 2019.

[40] Mao Y, You C, Zhang J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2322-2358.

[41] Chen Y, Zhao J, Lu Y, et al. Task offloading strategies for mobile edge computing: A survey [J]. Journal of Systems Architecture, 2024, 155: 103236.

[42] Deng S, et al. Machine learning-based computation offloading in multi-access edge computing: A survey[J]. Journal of Systems Architecture, 2024, 148: 103057.

[43] Liu Y, Chen M, et al. Task offloading for multi-user mobile edge computing based on deep reinforcement learning[J]. IEEE Transactions on Vehicular Technology, 2024, 73(4): 5879-5893.

[44] Li B, Yang R, Liu L, et al. Robust computation offloading and trajectory optimization for multi-uav-assisted mec: A multi-agent drl approach[J]. IEEE Internet of Things Journal, 2024, 11 (3): 4775-4785.

[45] Liu J, et al. Gan-powered heterogeneous multi-agent reinforcement learning for uav-assisted task offloading[J]. Ad Hoc Networks, 2024, 155: 103398.

[46] Zhang W, et al. Task offloading and trajectory scheduling for uav-enabled mec networks: An madrl algorithm with prioritized experience replay[J]. Ad Hoc Networks, 2024, 156: 103424.

[47] Erdelj M, Natalizio E. Help is on the way: Uavs for disaster management[J]. IEEE Pervasive Computing, 2017, 16(4): 58-66.

[48] Hu X, Yang K, Zheng Z. UAV-assisted mobile edge computing: A joint trajectory and resource optimization approach[J]. IEEE Transactions on Wireless Communications, 2021, 20 (7): 4445-4458.

[49] Zhou F, Wu Y, Hu R Q, et al. Latency optimization for UAV-assisted mobile edge computing [J]. IEEE Transactions on Communications, 2020, 68(9): 5721-5735.

[50] Zhang G, Shen Y, Yang K. Energy-efficient UAV-assisted mobile edge computing[J]. IEEE Transactions on Vehicular Technology, 2021, 70(8): 8234-8238.

[51] Bai T, Wang J, Ren Y, et al. Multi-agent reinforcement learning for UAV-assisted mobile edge computing[J]. IEEE Transactions on Wireless Communications, 2021, 20(12): 8184-8198.

[52] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. MIT press, 2018.

[53] Kaelbling L P, Littman M L, Moore A W. Reinforcement learning: A survey[J]. Journal of Artificial Intelligence Research, 1996, 4: 237-285.

[54] Watkins C J, Dayan P. Q-learning[J]. Machine Learning, 1992, 8(3-4): 279-292.

[55] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256.

[56] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning [A]. 2015.

[57] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017.

[58] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[A]. 2015.

[59] Busoniu L, Babuska R, De Schutter B. A comprehensive survey of multiagent reinforcement learning[J]. IEEE Transactions on Systems, Man, and Cybernetics, Part C, 2008, 38(2): 156-172.

[60] Grönauer S, Diepold K. Multi-agent deep reinforcement learning: A survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.

[61] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 6379-6390.

[62] Rashid T, Samvelyan M, Schroeder C, et al. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning[C]. Proceedings of the 35th International Conference on Machine Learning. 2018: 4295-4304.

[63] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-agent learning[C]. Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems. 2018: 2085-2087.

[64] Zhang P, Li G. A cooperative dynamic target search approach for multi-uav systems utilizing the mappo algorithm[J]. Discover Artificial Intelligence, 2025, 5(1): 153.

[65] Guo Y, Liu J, Yu R, et al. Mappo-pis: A multi-agent proximal policy optimization method with

prior intent sharing for cavs' cooperative decision-making[C]. Proceedings of the European Conference on Computer Vision (ECCV) Workshops. Springer, 2024: 245-262.

[66] Li Z, et al. A-mappo: Attention-enhanced multi-agent proximal policy optimization[C]. Proceedings of the 2nd Aerospace Frontiers Conference (AFC). Springer, 2025: 281-292.

[67] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 5998-6008.

[68] Lin T, et al. Hgap: Boosting permutation invariant and permutation equivariant in multi-agent reinforcement learning via graph attention network[C]. Proceedings of the 41st International Conference on Machine Learning (ICML). 2024: 1-12.

[69] Liu Y, et al. Bridging training and execution via dynamic directed graph-based communication in cooperative multi-agent systems[A]. 2024.

[70] Li X, Zhang J. Context-aware communication for multi-agent reinforcement learning[C]. Proceedings of the 23rd International Conference on Autonomous Agents and Multiagent Systems (AAMAS). IFAAMAS, 2024: 1156-1164.

[71] Li X, Xue S, He Z, et al. Tmac: A transformer-based partially observable multi-agent communication method[J]. PeerJ Computer Science, 2025, 11.

附录 A　补充材料

A.1　补充章节

A.1.1　补充图

这是附录内容，应该用宋体小四号字体。



图 A.1　一个配有彩色表格的插图

致谢

在此感谢导师的悉心指导，感谢实验室同学的帮助，感谢家人的支持。

在读期间取得的科研成果