

中山大學
SUN YAT-SEN UNIVERSITY

中山大学专业硕士学位论文

面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

专　　业：YOUR_SPECIALITY

学位申请人：YOUR_NAME

指 导 教 师：YOUR_SUPERVISOR 教授

论文答辩委员会主席：_____

论文答辩委员会成员：_____

_____

_____

_____

2026 年 10 月

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：　　年　　月　　日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：　　导师签名：

日期：　　年　　月　　日　　日期：　　年　　月　　日

论文题目：面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

专　　业：YOUR_SPECIALITY
硕 士 生：YOUR_NAME
指导教师：YOUR_SUPERVISOR 教授

摘　　要

在应急救援与临时通信保障等动态空地服务场景中，无人机（UAV）集群作为空中移动边缘计算（MEC）节点，需协同规划空间机动轨迹与机载计算资源分工，以保障地面用户设备（UE）动态请求的按时完成。然而，受限于单机物理覆盖半径与机载计算、缓存容量，传统方法面临未覆盖需求感知缺失、跨机任务迁移引发批量算力竞争、以及在线调度算法自身耗时挤占任务截止期余量等严峻挑战。为此，本文面向自然覆盖接纳约束下的无人机集群时限计算服务，以全部实际生成请求为基准定义端到端截止期满足率（DSR = 接纳率 × 接纳后按时完成率），围绕“集群飞向哪里、任务交给谁执行、如何实现低开销在线闭环协同”三个核心问题开展深入研究。本文的主要工作与创新成果如下：

针对自然覆盖约束下未接纳需求不可见导致的空间部署盲区问题，提出了一种基于预接纳观测扩展的需求感知协同轨迹规划方法。基于集中式训练与分散式执行（CTDE）架构构建上层多智能体近端策略优化（Attention-MAPPO）网络，设计确定性距离排序的预接纳需求槽位填充机制，在不改变 100 m 物理服务半径的前提下，将 460 m 感知范围内的待接纳用户请求特征纳入局部观测；进而利用多头交叉注意力机制动态聚合邻机几何拓扑与地面需求分布，结合运动可行性修复输出协同机动指令。仿真结果表明，该方法有效消除了局部状态混叠，使集群服务接纳率由 49.96% 跃升至 61.89%，驱动端到端 DSR 由 24.44% 提升至 27.93%，同时机队平均能耗降低 6.37%、Jain 公平性指数提升 0.0786。

针对请求接纳扩展后机载批量算力均分引发的跨机迁移外部性问题，提出了一种基于全批次重评估的截止期优先计算任务分配方法（MC-ITR）。推导出单请求跨节点迁移对迁入与迁出节点存量任务完成时延及计算能耗的耦合影响机理，构建了依次以“超时请求数、平均归一化时延、分配因果能耗”为优先级的严格字典序优化目标。在此基础上，设计单请求迁移邻域全批次重评估搜索算法，并从理论上证明了算法的严格字典序单调下降性、有限步终止性及无改善退

出下的邻域局部最优性。在涵盖不同用户规模与算力倍率的 410 个受控评估单元中，MC-ITR 将主配置每快照平均超时请求数从启发式基线的 2.91 个和单请求迭代基线的 2.23 个显著降至 2.06 个，在需求感知学习轨迹快照上平均每快照减少 2.46 个超时任务，充分探明了跨机协同任务分工的质量优化空间。

针对组合优化搜索耗时难以满足高动态在线时限要求的问题，提出了一种计及决策开销的无人机集群分层服务决策框架。上层采用需求感知 Attention-MAPPO 策略生成协同机动动作；下层将高维离散卸载问题解耦为“节点级整数配额提议”与“请求级容量槽线性指派”，在仅需至多 10 次条件匹配的有限计算预算内高效压缩搜索空间。同时，设计了显式区分缓存命中与未命中分支的解析缓存混合评分函数，结合候选间能耗定价机制实现服务质量与资源消耗的动态权衡，并将单步完整软件求解耗时实时注入任务时延反馈与状态闭环演化。在 5 架无人机服务 100 个移动用户的闭环仿真中，所提分层方法的单次完整决策耗时均值仅为 17.72 ms（95% 分位数为 24.69 ms），计入真实求解延迟后的端到端 DSR 达到 33.76%，在满足机队能耗约束的前提下，较共同贪心修复基线和同框架二值评分策略分别显著提升 1.03 和 0.26 个百分点，验证了所提框架在在线时限服务中的高效性与鲁棒性。

关键词：无人机集群，协同轨迹规划，计算任务分配，
多智能体强化学习，负载匹配

Title: Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

Major: YOUR_SPECIALITY
Name: YOUR_NAME
Supervisor: Prof. YOUR_SUPERVISOR

ABSTRACT

In dynamic air-ground service scenarios such as emergency rescue and temporary communications, an unmanned aerial vehicle (UAV) swarm acting as aerial mobile edge computing (MEC) nodes must coordinate spatial trajectory planning with onboard computation resource allocation to guarantee the timely completion of deadline-constrained user equipment (UE) requests. However, constrained by limited physical coverage radii as well as finite onboard computation and caching capacities, conventional approaches face critical challenges: blindness to uncovered spatial demand, batch computation contention induced by cross-UAV task migration, and online scheduling latency that erodes request deadline margins. To address these challenges under natural coverage-based admission, this thesis defines the end-to-end deadline satisfaction rate (DSR $=$ admission rate $\times$ conditional completion rate) over all generated service requests, and systematically investigates three core problems: where the swarm should move, how admitted tasks should be allocated across execution nodes, and how to integrate movement with low-overhead online allocation. The main contributions of this thesis are summarized as follows:

To resolve spatial deployment blindness caused by the invisibility of uncovered demand under natural coverage constraints, a demand-aware cooperative trajectory planning method based on pre-admission observation expansion is proposed. Built upon the centralized training with decentralized execution (CTDE) paradigm and an attention-based multi-agent proximal policy optimization (Attention-MAPPO) network, a deterministic distance-ordered slot-filling mechanism is designed to incorporate uncovered UE requests within a 460 m sensing range into the local observation while retaining the 100 m physical service radius. Multi-head cross-attention is utilized to dynamically aggregate neighbor UAV topologies and ground demand distributions, generating fea-

sible cooperative movement actions. Simulation results demonstrate that the proposed method effectively eliminates partial-observability state aliasing, boosting the service admission rate from 49.96% to 61.89% and improving the end-to-end DSR from 24.44% to 27.93%, while simultaneously reducing average fleet energy consumption by 6.37% and increasing Jain's fairness index by 0.0786.

To address batch computation contention and cross-UAV migration externalities among admitted requests, a deadline-prioritized Multi-Candidate Iterative Task Reallocation (MC-ITR) method based on full-batch reevaluation is developed. By analytically characterizing how single-request migration alters computation shares, completion latencies, and energy costs of co-located tasks on both source and destination nodes, a strict lexicographic optimization objective prioritizing deadline misses, normalized latency, and assignment energy is formulated. The proposed MC-ITR algorithm searches single-request migration neighborhoods via full-batch reevaluation and is theoretically proven to guarantee strict lexicographic descent, finite termination, and local optimality upon non-improving termination. Across 410 controlled evaluation units spanning diverse UE densities and computation capacities, MC-ITR reduces the mean deadline misses per snapshot in the main setting from 2.91 (heuristic baseline) and 2.23 (iterative single-request baseline) to 2.06, and achieves an average reduction of 2.46 deadline misses per snapshot along demand-aware learned trajectories, quantifying the performance headroom of cooperative task allocation.

To bridge the gap between combinatorial allocation quality and strict online decision-time budgets, a cost-aware hierarchical service decision framework is proposed. Combining the demand-aware Attention-MAPPO trajectory policy in the upper layer with a structured lower-layer scheduler, the high-dimensional offloading problem is decomposed into node-level integer quota proposals and request-level capacity-slot linear assignments within a strict budget of at most 10 matching calls. Furthermore, an analytical cache-mixture scoring function is formulated to decouple cache-hit and cache-miss deadline branches, integrated with candidate-level energy pricing and closed-loop injection of actual software execution latency. In closed-loop evaluations with 5 UAVs serving 100 UEs, the hierarchical method achieves a mean full-call decision latency of only 17.72 ms (p95 = 24.69 ms) and attains a cost-aware end-to-end DSR of 33.76%, outperforming the greedy-repair baseline and the binary-scoring priced strategy by 1.03 and 0.26 percentage points, respectively, within prespecified fleet energy constraints.

KEY WORDS: UAV swarm, mobile edge computing, cooperative trajectory planning, computation task allocation, multi-agent reinforcement learning, quota matching.

KEY WORDS: UAV swarm, cooperative trajectory planning, computation task allocation,
multi-agent reinforcement learning, load matching

目　录

第 1 章　绪论 1
1.1　研究背景与意义 1
1.2　国内外研究现状 4
1.3　关键研究问题与技术路线 11
1.4　研究内容与主要贡献 11
1.5　论文组织结构 12
1.6　研究假设与适用范围 13
1.7　本章小结 14
第 2 章　相关技术与理论基础 15
2.1　无人机集群协同规划基础 15
2.2　无人机辅助移动边缘计算技术 17
2.3　多智能体深度强化学习基础 21
2.4　计算任务指派与组合优化基础 23
2.5　本章小结 24
第 3 章　自然覆盖约束下基于需求感知注意力的集群协同轨迹规划 26
3.1　系统模型与问题描述 26
3.2　基于需求感知注意力的协同轨迹规划方法 35
3.3　仿真实验与结果分析 42
3.4　本章小结 48
第 4 章　考虑跨机资源竞争的无人机集群截止期优先计算任务分配 50
4.1　问题描述与跨机迁移外部性分析 50
4.2　基于全批次重评估的 MC-ITR 任务分配算法 55
4.3　仿真实验与结果分析 59
4.4　本章小结 65
第 5 章　计及决策开销的无人机集群配额匹配与分层协同服务决策 67
5.1　研究问题与总体思路 67
5.2　分层结构与批量任务模型 69
5.3　缓存混合评分与条件匹配 71
5.4　有限匹配预算与能耗价格 74

5.5 实验协议与独立确认设计 76
5.6 服务收益、资源取舍与学习增量边界 78
5.7 本章小结 83

第 6 章 总结与展望 84
6.1 研究总结 84
6.2 综合认识与适用范围 86
6.3 后续研究方向 87
6.4 本章小结 87

参考文献 88

附录 A 原学习配额变体的模型与训练 92
A.1 配额分解与条件化字典序匹配 92
A.2 有限预算配额搜索与二部图策略 95
A.3 教师初始化、配额 PPO 与分层训练 99

附录 B 原十块确认、冻结九格及事后费用诊断 104
B.1 独立确认设计与统计方法 104
B.2 主场景性能与完整下层优化包的收益 108
B.3 完整框架与学习机制的分层解释 115
B.4 冻结策略的负载与算力稳健性 118
B.5 固定快照、共同 MBS 与时间预算诊断 120

附录 C 计费闭环确认与开发诊断的补充材料 125
C.1 数据划分、参数与运行条件 125
C.2 全部参照与固定潜在分母 125
C.3 复现入口与核验覆盖 126
C.4 历史缓存学习开发诊断与停止依据 126
C.5 当前解析方法的长回合与迁移开发补证 128
C.6 固定预算前缀的开发取舍与停止依据 131

致谢 133

在读期间取得的科研成果 134

插图目录

图 2.1 端–空–地三层协同移动边缘计算系统架构示意图 18
图 2.2 无人机辅助通信与计算卸载典型应用场景示意图 19
图 2.3 强化学习智能体与环境交互框架示意图 21

图 3.1 无人机集群自然覆盖与需求感知示意图 27
图 3.2 单时隙任务执行与轨迹更新时序图 28
图 3.3 服务覆盖半径与需求感知半径示意图 30
图 3.4 原始观测与扩展观测槽位对比图 37
图 3.5 Attention-MAPPO 网络结构图 38
图 3.6 服务请求执行结果构成 44
图 3.7 Attention-MAPPO 训练曲线 45
图 3.8 独立确认实验 DSR 配对差值 45
图 3.9 接纳率与接纳后完成率对比 47

图 4.1 批量算力共享与任务迁移影响示意图 52
图 4.2 MC-ITR 算法流程图 56
图 4.3 固定快照主配置下四种卸载方法性能对比 60
图 4.4 相对 Iterative-Base 的每快照超时数配对差值 61
图 4.5 终端用户数量对超时数与能耗的灵敏度分析 62
图 4.6 无人机计算能力对超时数与能耗的灵敏度分析 63
图 4.7 小规模配置下各算法与精确解性能对比 64
图 4.8 需求感知轨迹下的固定快照分配性能对比 65

图 5.1 解析分层决策架构与软件费用反馈时序图 68
图 5.2 基于固定配额的容量槽分配示意图 73
图 5.3 主候选相对各参照方法的计费 DSR 配对差值 79

图 A.1 固定配额容量槽展开与请求匹配示意图 93
图 A.2 请求–执行节点二部图与网络状态编码结构图 96
图 A.3 基座模型、下层训练图与独立确认数据集划分图 100
图 A.4 基座模型与配额策略训练收敛曲线 103

图 B.1 典型确认回合无人机集群空间机动轨迹图 108

图 B.2　典型时步上层网络注意力权重热力图 …… 109
图 B.3　主场景下八种方法 DSR 性能对比 …… 110
图 B.4　SF-HLM 相对三个主对照方法的逐块 DSR 配对差值 …… 111
图 B.5　服务请求执行结果分解与条件完成率对比 …… 112
图 B.6　无人机机队能耗与宏基站依赖度对比 …… 113
图 B.7　服务公平性与软件决策延迟分布对比 …… 115
图 B.8　学习机制相对启发式与随机搜索的配对性能差值 …… 116
图 B.9　九种参数配置下 SF-HLM 的服务指标表现 …… 119
图 B.10　九种参数配置下 SF-HLM 相对主对照方法的 DSR 差值 …… 120
图 B.11　宏基站协同模式对任务超时影响诊断图 …… 121
图 B.12　软时限预算下算法求解质量与超时率分析 …… 122
图 B.13　算法匹配调用次数与终止行为统计图 …… 123
图 B.14　调度延迟对算法服务性能影响的灵敏度分析 …… 124

图 C.1　冻结策略在五种开发场景下的迁移性能 …… 130
图 C.2　固定预算下求解质量、计算时间与能耗权衡分析 …… 132

附表目录

表 1.1 代表性相关研究与本文方法对比 10

表 3.1 上层单智能体观测空间维度构成 37
表 3.2 主场景系统与网络仿真参数设置 42
表 3.3 上层 Attention-MAPPO 关键训练超参数配置 42
表 3.4 预接纳观测两阶段评估协议对比 43
表 3.5 独立确认实验核心性能指标对比 46

表 4.1 自身改善与系统超时变化构造示例 54
表 4.2 四种计算卸载算法特性对比 55
表 4.3 单请求局部最优与全局最优抽象离散反例 58
表 4.4 固定快照主配置下卸载方法性能对比 60
表 4.5 各变体配置下 MC-ITR 相对基线超时数配对差值 62

表 5.1 计费闭环确认实验评估方法对比 77
表 5.2 计费 DSR 预定主比较结果 79
表 5.3 各方法服务质量与宏基站依赖度对比 80
表 5.4 各方法机队能耗、公平性与计算耗时对比 80

表 A.1 配额策略训练超参数配置 102

表 B.1 SF-HLM 独立确认实验数据与模型划分 104
表 B.2 下层与学习机制对照实验方法构成 105
表 B.3 100 用户主场景下各方法服务性能指标对比 110
表 B.4 三个主对照方法的 DSR 配对差值与能耗比对比 111
表 B.5 主场景下各方法资源开销、公平性与软件耗时对比 113
表 B.6 主场景下机队飞行与计算能耗构成 114
表 B.7 开发评估中 PPO 相对行为克隆算法的性能差值 118
表 B.8 不同用户规模与算力配置下 SF-HLM 的 DSR 表现 118
表 B.9 附加调度延迟及软件决策开销事后评估 124

表 C.1 计费确认实验全部参照方法的配对差值与能耗比 125
表 C.2 历史开发快照任务分配关系与性能差异分解 127
表 C.3 缓存学习开发支线状态与终止准则 127
表 C.4 基准价格下各开发模块性能对比 129

表 C.5　固定预算前缀下的计费闭环性能权衡 …… 131

符号说明

N, M	UAV 数量与 UE 数量
H, τ, T	UAV 飞行高度、时隙时长与 episode 时隙数
$\mathbf{q}_u(t)$	UAV u 在时隙 t 的水平位置
$\mathbf{w}_m(t)$	地面 UE m 在时隙 t 的水平位置
$\mathbf{p}_u(t)$, $\mathbf{p}_m(t)$	UAV 与 UE 的三维位置
$v_{\max}$, $d_{\min}$	UAV 最大速度与机间最小安全距离
R_c, R_s	UAV 物理服务覆盖半径与需求感知半径
G, A, S	评估单元内实际生成、自然接纳、按时完成的服务请求数
DSR	端到端截止期满足率，S/G
J, c_m	Jain 公平性指数与 UE m 的累计服务覆盖量
g, R	链路信道功率增益与传输速率（bit/s）
P^{comm}	通信发射功率
σ^2	噪声功率
B^{edge}	UE-UAV 接入链路带宽
B^{inter}	UAV 间链路带宽
B^{backhaul}	UAV-MBS 回传链路带宽
$B_{\max}$, B_{low}	UE 电池容量与低电量阈值
β	请求流行度 Zipf 指数
$\mathcal{M}_t$, $\mathcal{J}$	时隙 t 的自然接纳服务请求集合与执行节点集合
$\mathcal{C}_m$	请求 m 的合法执行节点集合
$\mathbf{a}$, x_{mj}	请求分配向量与请求 m 分配到节点 j 的二元指示
L_m, C_m	请求 m 的输入字节数与所需 CPU 总周期
ω_m	请求 m 每字节所需 CPU 周期数，$C_m = \omega_m L_m$
B_s	服务程序 s 的字节数
F_u, F_{mbs}	UAV u 与 MBS 的计算能力（周期/s）
N_j, f_{mj}	分配到节点 j 的最终请求数与请求分得的计算频率

T_m, D_m	请求 m 的完成时延与截止时间
T_m^{tx}	请求传输时延，$8L_m/R$
T_m^{cmp}, E_m^{cmp}	请求计算时延与计算能耗
κ	动态 CPU 功耗模型的有效芯片电容系数
E_{assign}	卸载分配相关的非飞行 UAV 能耗
s_t, O_t	强化学习完整状态与上层 UAV 联合观测
$o_{u,t}$, $a_{u,t}$	UAV u 的局部预动作观测与连续原始动作提案
$a_{u,t}^{\mathrm{exec}}$	环境映射后的 UAV 执行动作
π_θ, V_ϕ	参数化策略与价值估计网络
θ, ϕ	策略参数与价值网络参数
r_t, G_t	即时奖励与从时隙 t 开始的折扣回报
V_t^π, Q_t^π	状态值函数与动作值函数
A_t^π, $\widehat{A}_t$	真实优势函数与优势估计
γ	回报折扣因子
λ_{GAE}	广义优势估计的多步混合系数
b_t, c_t	价值自举掩码与优势递推连接掩码
ρ_t, ε	PPO 新旧动作概率比率与裁剪系数
Q, K, V	注意力查询、键与值矩阵（本体按上下文区分值函数）
d_k	单个注意力头的键向量维度
s_{mj}, p_{mj}	给定配额下的缓存混合成功分数与公开缓存命中信念
δ_0, c_t^{sw}	评分使用的名义软件费用与当次完整实测软件耗时
λ, E_{norm}	候选间能耗价格与开发阶段冻结的预测能耗归一化常数

第 1 章　绪论

1.1　研究背景与意义

1.1.1　无人机集群协同任务规划与空地服务需求

无人机集群通过多个空中平台的机动与分工，共同完成单个平台难以独立承担的区域任务。集群能力既取决于每架飞行器的运动和载荷能力，也取决于成员如何选择服务位置、交换任务并使用有限资源。Chung 等的航空集群综述将轨迹生成、任务分配和分布式感知等列为相关研究内容，并指出空中平台的运动特性为协同设计带来额外要求[1]。因此，面向航空航天任务的集群协同可以从任务规划层展开：在给定平台和运动约束下，研究多机应部署到哪些位置、如何形成任务分工，以及这种分工能否改善集体任务完成效果。

应急场景中的临时空地服务为上述问题提供了应用动机。当地面设备分散移动、任务需求发生变化时，搭载通信与计算载荷的无人机可以将服务能力带到需求附近。多个平台需要协同分担空间部署与计算处理任务，避免请求过度集中于个别平台而导致其他平台资源闲置。本文据此研究动态地面请求驱动的集群计算服务，仿真建模涵盖用户移动、请求生成、通信、缓存与计算全过程。

本文中的无人机（Unmanned Aerial Vehicle，UAV）同时承担移动接入节点和计算执行节点的角色，地面用户设备（User Equipment，UE）产生具有截止时间的请求，宏基站（Macro Base Station，MBS）提供另一条执行路径。移动边缘计算（Mobile Edge Computing，MEC）将计算和存储能力部署到接近数据产生位置的网络边缘，为这种计算任务载荷提供了技术基础[2]。请求需要经历接入、数据传输、程序获取和计算等环节，空中平台的位置则决定部分请求能否进入这一流程。由此，MEC 对应集群所承担的服务任务，而集群协同轨迹规划与计算任务分配对应本文的主要决策问题。

空地服务能力具有明确的空间依赖性。固定服务器的算力即使充足，也需要用户连接到可用接入点；无人机的机动性使接入节点的位置可以成为决策变量。UAV 辅助通信研究讨论了覆盖、部署、轨迹与能量之间的联系[3-4]。在本文的计算服务场景中，空间错配具有两种表现：用户距离服务 UAV 过远，请求不能被接纳；请求虽然进入覆盖，却集中到少数执行节点并竞争计算和缓存资源。前者需要集群改变未来的空间部署，后者需要调整当前批次的任务分工。只报告已接纳请求的平均时延，容易遗漏未接纳需求，难以解释集群整体服务效果。

集群空间部署同时影响跨机资源协作。某架 UAV 接纳较多请求后，可以将

部分计算任务交给其他具有可用能力的 UAV；若协作链路较弱或必要程序未缓存，迁移又会增加传输和获取时延。MBS 作为补充执行路径，与空中集群共同构成多层级计算服务体系。任务目的地还会改变当前能耗和缓存状态，进而影响后续观测与动作。因此，本文把多机位置、任务接纳和执行负载视为相互联系的任务规划变量，通过长期交互仿真评价整体效果，并以固定状态实验刻画分配环节的优化空间。

本文的集群协同聚焦任务规划层。仿真采用固定高度下的二维运动、单步位移限制和位置修复，Actor 根据各 UAV 允许的观测输出机动方向，下层调度器集中处理当前请求批次。邻机状态进入上层决策，任务也能够在机间迁移，由此形成空间部署与计算分工两类协作。这一层次划分使研究问题与现有实现对应，并为后续衔接航空器执行控制提供明确接口。

1.1.2 自然覆盖条件下的服务评价问题

本文关注具有明确物理服务半径的自然覆盖接纳系统。当前时隙位于 UAV 覆盖范围内的服务请求被接纳后，才能进入卸载决策；范围外请求计为未接纳。选择 MBS 或协作 UAV 作为执行目标，不影响请求的接纳状态。与强制关联全部请求的设置相比，自然覆盖将 UE–UAV 接入条件纳入优化问题，使轨迹决策承担改善后续接纳机会的作用。

为同时评价覆盖与处理质量，本文以全部实际生成服务请求中的按时完成比例定义端到端截止期满足率（Deadline Satisfaction Rate，DSR）。设一个评估单元内实际生成、自然接纳和在截止时间前完成的请求总数分别为 G、A 和 S，在 $G > 0$ 且 $A > 0$ 时有

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A} = \text{接纳率} \times \text{接纳后按时完成率}. \tag{1.1}$$

这一计数恒等式把端到端质量分为两个环节。轨迹与需求观测主要影响请求是否进入覆盖；卸载与资源竞争主要影响已接纳请求能否及时完成。两环节在闭环系统中存在耦合，式 (1.1) 提供统计分解以诊断各环节贡献，端到端性能则以 S/G 统一评价。

覆盖扩展在提高接纳机会的同时，揭示了跨节点资源竞争规律，构成了任务分工算法设计的直接物理动机。轨迹策略感知更多未覆盖需求后，可主动移动以提高接纳比例；当新增请求计算量较高或集中于繁忙节点时，接纳后完成率的变化由端到端指标统一衡量。因此，方法效果由端到端成功比例 S/G 评价，接纳率和接纳后完成率用于解释变化来源。该计数框架同时能够识别条件完成率虚高的情形，即仅处理少量低负载请求时接纳后完成率虽高、但端到端服务覆盖不

足。

DSR 的分母还需要与环境行为一致。本文 UE 电池状态会影响实际服务请求与能量请求的生成类别，因此不同策略的实际服务请求总数可能有轻微差异。预先配对外生随机流以控制用户移动与潜在需求差异，策略相关的实际分母残余差异通过敏感性分析量化。本文以实际生成服务请求作为主评价指标，并以共同潜在服务请求为固定分母开展敏感性分析。这一设计确保评价口径的先验确定性，并通过分母敏感性分析验证观测到的性能差异来源。

1.1.3　集群空间部署与计算任务分工的研究意义

从集群任务规划角度看，轨迹决策改变未来的服务条件，计算任务分配利用当前已经形成的服务条件。UAV 接近特定 UE 群可提高接纳机会，但空间部署的耦合效应意味着接近某一需求区域可能降低对其他区域或协作节点的服务邻近性；任务迁移至算力较高的 UAV 可降低计算时延，同时引入传输时延、程序获取与分配能耗等跨节点资源竞争代价。上述耦合效应揭示了多平台协同中空间部署与计算分工的相互制约规律，要求策略统筹考虑多个平台与多个请求之间的关系，使空间机动服务于集体任务目标。UAV 位置或轨迹与资源分配的联合优化研究也体现了这一联系[5-6]。本文进一步以任务是否被接纳、是否按时完成，界定轨迹规划与跨机分工各自发挥作用的环节。

集群服务能力由机间几何、程序缓存、计算共享与机动能耗等多重物理因素共同决定。为全面刻画空间部署与执行资源的整体权衡，本文的评价体系同时报告服务成功率、UAV 能耗、跨机任务分工及 MBS 依赖度四类指标。其中，能耗模型量化记录飞行运动与服务计算消耗，为多目标权衡分析提供数据基础。

从算法角度看，问题同时包含连续轨迹动作、离散请求目的地和时序状态变化。请求数增加时，目的地组合迅速扩大，一个节点的最终负载又影响分配到该节点的全部请求。单一网络同时输出轨迹与完整分配，面临连续与离散动作尺度异构、回报来源多元以及组合可行性约束等挑战。本文采用分层结构分别建模位置决策与批量分配，并通过闭环实验评价两类决策的协同效果。

从研究方法角度看，UAV-MEC 算法的性能评价应区分长期闭环结果与固定状态下的求解能力。固定快照实验能够控制位置、请求和历史状态，直接观察分配方案的优化质量；闭环实验则保留分配对电池、缓存、后续观测和轨迹的动态影响。前者便于分析批量外部影响和局部搜索性质，后者回答整套方法是否提高长期服务表现。本文同时采用这两种证据，并分别界定其统计单位与适用范围，确保快照诊断结论与闭环服务增益各自独立成立。

1.2 国内外研究现状

1.2.1 集群协同覆盖与需求驱动的空间规划

柴蓉等梳理多机协同自主任务规划中的知识表示、通感一体化、任务调度与航迹规划，说明集群任务执行涉及空间行动与资源组织等多个环节[7]。Zhang等针对异构多 UAV 的动态任务，联合考虑安全轨迹、任务调度与机载资源分配，以任务未完成率和能耗评价方法[8]。该工作考虑的异构性与安全控制为本文后续扩展提供参考；本文使用简化运动模型和离散位置修复，不能据此推断真实飞行安全。

无人机集群规划需要把整体任务目标转化为各平台的空间行动与资源分工。航空集群研究同时涉及轨迹生成、任务分配和协同信息使用，各层之间需要符合平台与任务条件[1]。对于本文的空地计算服务，整体目标是动态请求的按时完成，空间行动则影响请求能否进入物理覆盖。因而，轨迹规划既要关注用户位置，也要关注请求的时间要求和服务负载；停留在用户密集区域不必然对应最高的截止期成功比例。

本文以请求产生时的接纳及其截止期完成情况评价覆盖服务。几何覆盖面积和轨迹访问面积描述空间活动，请求级指标则保留用户移动与业务变化。两条轨迹即使经过相近位置，也可能服务不同任务集合，因而需按实际请求计数连接空间规划和执行效果。

协同覆盖还取决于策略允许使用的信息。UAV 只观察已关联用户时，未覆盖需求难以直接进入其动作依据；引入感知范围内的待接纳需求后，集群可以据此调整未来位置。但扩大观测不是扩大物理服务半径，其上报及时性和获取成本也属于另外的信息条件。本文第三章研究的是在既定信息假设下，需求可见性如何影响协同机动与接纳效果；它保留对实际部署信息来源和同信息架构对照的独立检查要求。

在 100 m 服务半径与 200 m 最小机间距下，可行部署的覆盖圆内部不重叠。这一配置使规划重点成为需求与服务位置的匹配，以及新增接纳后的负载组织。本文以接纳与截止期完成衡量空间部署收益。

1.2.2 协同计算任务分配与模型驱动资源优化

面向多 UAV 辅助 MEC，Sun 等联合优化卸载、计算资源与轨迹，以任务完成时延、UAV 能耗和卸载任务数量构造多目标问题[9]。Hao 等考虑任务优先级与二值卸载，联合处理轨迹和通信、计算资源，以时延与能耗构成长期系统收益[10]。两项研究表明任务服务与资源代价需要结合评价，但其卸载任务数量、优

先级及收益定义不能直接等同于本文的端到端 DSR 或超时数目标。

在地面异构边缘计算中，李小平等结合卸载和节点内调度，研究带不同截止期任务的总延迟时间[11]。徐渊博等依据通信条件与 UAV 资源设置任务接收阈值，以服务商收益和用户服务质量研究准入控制[12]。前者的调度目标与本文优先减少超时请求数不同；后者的阈值准入也不同于本文以物理覆盖为基础的自然接纳。

在缓存协同方面，Zhao 等联合研究 UAV 轨迹、任务卸载、任务缓存与迁移[13]；Sun 等面向工业信息物理系统联合考虑卸载、服务缓存、通信与计算资源及轨迹，以降低服务时延[14]。这两类缓存服务的对象及相应时延模型需要区分；本文的缓存混合评分针对自身规定的程序获取与预测条件，不直接继承上述工作的任务缓存模型。

Skaltsis 等综述 UAV 任务分配方法，比较计算复杂度、最优性与可扩展性，并讨论通信与不确定性条件[15]。本文据此明确计算请求、执行节点及截止期目标，在评价分配质量的同时报告求解开销和集中协调需求。

模型驱动方法首先把通信速率、计算时延、能量或覆盖条件写成目标与约束，再根据变量结构采用交替优化、连续近似、离散搜索或博弈求解。其优点是能够明确给出信息条件和约束含义，并在满足特定假设时分析子问题性质。UAV 辅助通信综述指出，部署与轨迹会同时影响覆盖、链路质量和飞行成本[3-4]；在 MEC 场景中，还需要加入执行节点的计算和缓存条件。因此，模型是否准确描述了业务竞争，往往与求解器本身同样重要。

连续优化适合功率、带宽、频率或位置等变量，但任务目的地与缓存选择通常具有离散性质。研究者常在固定部分变量时处理另一部分，再循环更新。该做法可以降低每个子问题的求解难度，也便于用约束表达服务要求；其代价是整体问题的非凸性和离散耦合仍可能保留。对一个子问题获得精确解，并不意味着整套联合问题获得全局最优解。对于在线场景，还必须衡量重新求解的时间是否与请求截止期和决策时隙相匹配。

博弈方法则强调不同参与者的利益与响应。Yuan、Xie 和 Tan 的研究把基站、UAV 和用户的计算资源交互表述为多层 Stackelberg 博弈，并通过各层效用和响应选择卸载策略[16]。曾耀平等在 UAV 部署与卸载联合问题中，将 UAV 与 UE 的交互表述为领导者和追随者结构，结合联盟形成与势博弈分析[17]。这些方法说明分层结构可以来自参与者之间的决策顺序与利益关系。本文的上下层则是同一协作系统中的轨迹与请求分配模块，其共享服务目标，不能因为同样存在“两层”便直接继承上述博弈的均衡结论。

缓存与卸载的联合设计进一步说明，仅按链路和算力选择节点可能不足。王义君等研究微云、边缘和本地组成的多层结构，通过协同缓存自适应的分层多元宇宙优化算法处理卸载、资源配置及动态时延–能耗权衡[18]。该工作的服务缓存与节点选择设计，为本文考虑程序获取代价提供了相关背景；其细粒度部分卸载假设与本文不可拆分请求不同，数值结果不能直接移植。李侍阳和朱晓荣针对无人机巡检中的感知与 AI 任务，将多维资源优化拆分为若干子问题并交替求解[19]，表明服务目标与任务结构改变时，合适的优化变量和分解方式也会改变。

对于本文，模型驱动方法最直接的启示是显式检查分配外部影响。若 UAV 以最终批量请求数均分算力，迁移一个请求会改变迁入与迁出节点上其他请求的计算频率和完成时间。只计算被迁移请求自身时延的局部规则，可能忽略多个请求同时跨越截止期的变化。第四章因此以整个分配的目标重评估为基础研究 MC-ITR，而不是假定逐请求代价可以无条件相加。该求解器用于明确质量余量和计算代价，不承担本文第五章的在线解析下层。

1.2.3 动态机动与资源决策中的深度强化学习

姜来为等综述了强化学习在 UAV 辅助 MEC 任务卸载中的应用，并讨论任务卸载设计因素与研究方向[20]。Zhang 等在多 UAV 协作 MEC 中将卸载、资源分配、机间迁移和轨迹规划分解为子问题，其中轨迹采用 MAPPO，目标是降低能耗并兼顾负载均衡[21]。本文同样区分轨迹与计算分工，但以自然接纳后的截止期服务为核心，并分别通过固定快照与计入软件耗时的闭环实验评价分配质量。

深度强化学习（Deep Reinforcement Learning，DRL）把神经网络表示与交互式决策结合，用参数化策略或值函数近似复杂状态下的长期行为。DQN 的研究说明深度网络能够从高维输入中学习动作价值[22]；策略梯度和 Actor–Critic 方法则直接优化动作分布，为连续控制提供了基本工具[23-24]。这些经典算法为 UAV 位置、资源配置和任务调度提供了可采用的优化方式，但算法在一般基准上的有效性不是 UAV-MEC 特定服务协议下的性能证明。

强化学习建模需明确状态、动作、奖励与转移。链路、位置和负载提供即时依据，电池、缓存与移动使动作影响后续回报。策略训练后可通过网络前向快速生成动作，交互采样和参数优化则发生在离线阶段。因此，方法成本需同时说明在线推理与训练数据、教师求解的开销。

连续控制和离散选择需要不同的动作表示。轨迹控制可以由 Gaussian 等连续分布生成方向或位移；请求执行位置可以由分类分布生成离散选择。对大批量

请求逐项独立采样虽然容易实现，却未必捕捉最终负载之间的耦合。一种处理办法是把连续与离散决策分开学习；另一种是用优化模块把网络提出的结构化变量转化为完整方案。本文第五章采用配额提议和条件化匹配生成完整任务分配，原学习配额变体另作补充。解析提议、匹配与学习模块的贡献需要分别评价。

Li 等针对多 UAV 辅助 MEC 中的不完整信道信息与任务复杂度估计误差，联合考虑轨迹、任务划分和通信计算资源，提出使用 Beta 分布的多智能体 PPO 框架[25]。该研究关注通信与计算不确定性下的鲁棒设计，采用有界动作分布。本文则研究自然覆盖下不可拆分请求的批量分配，并采用 Gaussian 原始提案与环境执行裁剪相结合的轨迹动作模型。两者的问题条件和动作概率定义各有侧重。

Tao 等研究 UAV 辅助 MEC 中在线服务选择、任务卸载、计算频率、轨迹和悬停安排的联合决策[26]。其中服务程序选择体现了缓存与业务处理之间的联系，在线决策依据当前请求和资源状态进行。本文同样关注程序可用性与请求时序，但使用多 UAV 的自然接纳规则，并以截止期成功比例评价整个服务流程。不同文献使用能效、加权能量、平均时延或服务质量等目标，各自在对应定义下成立；不能仅因均称“联合优化”就把排名拼成一条普遍结论。

学习式方法还受到观测设计限制。网络只能根据实际输入产生策略，注意力或更深的模型不能从没有提供的请求特征中恢复真实需求。如果上层只看到已经关联的用户，它的轨迹控制就可能缺少覆盖外需求的直接信号。扩展观测能够改变决策信息，但也改变方法的信息条件。因此，本文先研究需求可见性与端到端服务的联系，再通过同信息替代结构和冻结策略对照检查组件贡献。观察到整套方法优势之后，仍需要区分“看到了不同信息”与“在相同信息上用了更好的网络”。

1.2.4　多智能体协作与集中训练分散执行

多智能体强化学习（Multi-Agent Reinforcement Learning，MARL）研究多个决策主体的交互。UAV 位置改变覆盖和协作链路，转入任务改变节点共享负载。各策略更新使单个智能体面对的经验分布变化，联合状态与动作则在相应假设下构成马尔可夫过程。协作、部分可观测与训练非平稳性共同影响方法设计。

集中式训练分散式执行（Centralized Training with Decentralized Execution，CTDE）在训练阶段使用更完整的信息估计价值或构造梯度，执行阶段由各 Actor 根据允许的局部观测选择动作。MADDPG 采用集中 Critic 处理多智能体动作相关性[27]；MAPPO 将 PPO 用于协作多智能体任务，并研究其在基准环境中的表现[28]。CTDE 区分了训练与执行的信息需求，本文据此设计轨迹策略的局部输

入和联合价值估计。

同类型 UAV 共享策略参数，使各机经验共同更新网络；不同的位置、能量、邻居和用户观测仍可产生不同动作分布。本文上层采用共享 Actor 和联合观测多输出 Critic，以建模各机局部决策及联合价值。

除 Actor–Critic 外，值分解通过限定联合价值组合方式支持分散选择，VDN 和 QMIX 分别采用加性分解与单调混合[29-30]。不同结构具有相应表达能力与动作条件。本文采用连续轨迹动作与批量离散任务，选择 MAPPO 组织上层决策，以独立求解模块处理下层组合分配。

Hady 等关于资源分配优化的 MARL 综述讨论了多智能体学习在网络资源问题中的方法分类与应用条件[31]。综合这类研究，可以从三个层面审视协作方法：策略执行需要什么信息，训练阶段使用了什么额外信息，评价是否把共享数据或工作负载误当独立重复。本文使用训练块作为学习方法统计重复，以配对工作负载减少环境差异，并在主性能、机制检验与快照诊断之间保持清楚的比较对象。

1.2.5 注意力聚合与结构化优化的作用

注意力机制通过查询与键之间的相似度生成权重，并对值向量加权聚合。Transformer 的缩放点积与多头结构为这一表示方式提供了经典形式[32]。在多 UAV 场景中，自身状态可以作为查询，邻居 UAV 与 UE 槽位作为被聚合元素，使输出随位置、需求和邻居关系变化。这样能够显式表达元素之间的相对关系，也便于对空槽位使用掩码。注意力的实际收益取决于输入特征、训练信号与模型容量，其对 DSR 的影响由具体对照实验评价。

注意力和信息预算应分别讨论。若一个 Actor 得到未覆盖 UE 的请求、电量和位置，而另一个 Actor 只能看到已关联 UE，则两者比较同时包含输入信息差异。即便前者使用注意力，观察到的优势也不足以证明优势完全来自注意力架构。相反，同信息条件下注意力与 MLP 的差值区间跨零，也只能说明这次实验没有确认结构增益，不能证明所有场景中注意力无效。本文第三章以需求可见性为研究中心，并通过同信息对照评价结构作用。

对于卸载，结构化优化提供了与直接动作输出互补的思路。已接纳请求与执行节点形成二部关系，各边包含合法性、传输代价、计算负载和程序条件。固定节点配额之后，最终计算共享条件可以被写入边成本，再通过指派生成完整方案；改变配额则继续探索不同负载状态。这样的分解把“节点接多少任务”和“具体哪些任务去这些节点”区分开，为学习搜索提供了较紧凑的控制对象。条

件化子问题的可求解性不等于原整体问题全局最优，也不等于能耗筛选之后仍保持无条件最优性。

本文第五章在共同贪心修复、质量掩码、条件化匹配与预测能耗筛选基础上，采用解析缓存混合评分及候选间能耗价格，并将当次完整软件耗时计入服务判定。与同框架二值策略的比较检验完整解析策略的增益，强配额随机和近似缓存控制用于界定方法收益。原学习配额变体的较小增量及费用敏感性作为研究边界保留，不把匹配框架的效果归给 PPO。

1.2.6　最接近研究与本文的具体增量

多 UAV 的轨迹与卸载协同已有直接研究。Ju 等采用多智能体深度确定性策略梯度联合处理路径和任务卸载，考虑 UAV 负载及用户服务公平性，以能耗和计算表现评价系统[33]。这为多机资源分工提供了相关方法背景。本文进一步在规定的自然接纳规则下保留未接纳服务请求，通过 $G/A/S$ 计数分别观察接纳损失和接纳后超时，并把固定状态分配与长期状态反馈分开评价。

学习与匹配结合也已有明确先例。Wang 等研究多 UAV 的边缘计算与数据采集，将用户关联建模为具有外部性的一对多匹配，并与 SAC 的移动和功率决策结合，以缩减动作空间[34]。本文的匹配对象是已接纳请求的计算执行目标：先固定节点任务数，使最终共享负载成为条件参数，再用容量槽指派决定请求身份。因此，区别在于子问题的条件化方式、时限目标和有限预算实现，不能把“强化学习加匹配”本身作为独有贡献。

Sun 等提出的 TJCCT 在短时间尺度内结合计算资源议价与多对一卸载匹配，在长时间尺度内通过凸优化处理 UAV 轨迹[35]。其价格是移动设备购买计算资源的单价，并参与供需双方效用；本文的能耗价格在开发阶段冻结，只用于有限候选分配之间的选择。TJCCT 明确规定时隙与多个时隙组成的时段，本文则在每个决策步连接上层轨迹和下层分配，故仅称分层结构，不据此主张双时间尺度机制。张秋平等以情景感知组合多臂赌博机学习服务缓存需求，并以偏好双边匹配处理边缘设备间卸载[36]；其缓存放置决策和稳定匹配也分别区别于本文的公开缓存信念评分与固定配额标量成本指派。

Chen 和 Tian 提出的 NeuRewriter 使用 Actor–Critic 学习选择局部区域和改写规则，迭代改善组合解，应用包括在线作业调度和路径问题[37]。原 SF-HLM 学习配额变体延续学习搜索的基本思想，但将动作具体定义为节点配额迁移与停止，并由确定性条件匹配生成完整分配。表 1.1 汇总这些关系。文献比较用于定位问题与方法增量；不同接纳、资源和信息协议下的绝对指标不作直接排名。

表 1.1　代表性相关研究与本文方法对比

Table 1.1　Comparison of Representative Related Studies and This Work

研究	接纳与评价对象	资源耦合与决策对象	信息及搜索预算的对应关系
Ju 等[33]	多 UAV-MEC；关注系统能耗与计算表现	联合路径和卸载；考虑负载与服务公平性	公开摘要未给出与本文对应的预接纳字段及有限匹配预算；本文使用明确的自然接纳计数
Wang 等[34]	MEC 与数据采集联合系统；优化时延及采集量	有外部性的用户关联匹配，结合 SAC 移动与功率决策	关联匹配与本文计算执行目标不同；信息、任务及预算需按各自模型解释
TJCCT[35]	移动设备与服务器效用；不可拆分计算任务	短尺度资源议价与卸载匹配，长尺度轨迹凸优化	资源交易单价区别于本文候选能耗惩罚；时段更新规则也不同于本文逐步分层调用
Chen、Tian[37]	通用组合优化，含在线作业调度和路径任务	学习选择局部区域与改写规则，迭代改善已有解	不采用本文的空地需求观测和配额条件化指派；学习搜索思想为本文相关前序方法
本文	100 m 自然接纳；以全部实际生成服务请求计算 DSR	批量任务均分等效算力；整数配额与容量槽指派	460 m 预接纳观测；解析下层最多 10 次匹配、128 次普通修复评价；计入完整软件耗时，保留共享框架与近似控制

1.2.7　本文比较口径与相关方法的关系

已有轨迹与卸载联合优化、学习与匹配结合、定价匹配以及学习改写组合解的方法，为本文提供了建模和求解基础[33-35,37]。本文的具体问题是在自然覆盖接纳后，以最终批量共享算力和缓存预测组织任务，并将完整软件耗时纳入闭环服务评价。不同论文的任务生成、接纳规则、截止期及算力模型不同，不能直接依据绝对 DSR 排序；只有在同一冻结协议内的对照才支持本章所述方法比较。

第三章主要检验预接纳需求可见性，第四章刻画固定状态中的分配余量，第五章则确认有限预算解析分层方法的计费服务收益。注意力、学习搜索与匹配各有既有方法基础，本文不把组件名称组合本身作为首创性依据；主张落实到规定问题、实际执行路径及独立确认结果。

1.3　关键研究问题与技术路线

本文的中心问题是：当地面任务需求随位置和时间变化、单机覆盖与机载资源有限时，无人机集群如何通过协同轨迹规划和计算任务分工，使更多请求在截止时间内完成？这一问题可以按决策过程分为三个环节。首先，集群飞向哪里，轨迹策略是否能够依据当前可获得的需求和邻机信息主动改善接纳机会；其次，任务交给谁执行，已接纳请求的最终负载如何影响整个批次的截止期质量，固定快照中是否存在可利用的分配余量；最后，如何连接空间部署和任务执行，在不改变物理接纳规则的前提下，有限预算结构化任务分配在计入完整软件费用后能否保留闭环服务收益。这三项问题分别由第三、第四和第五章回答，并共享请求生成、接纳与成功计数的基本语义。

技术路线以自然覆盖和请求执行模型为基础。本文统一数据传输量纲、最终批量算力共享、缓存更新和时隙决策顺序，分析上层观测与服务失败构成，研究扩展需求观测；随后固定位置与历史状态，通过 MC-ITR 分析请求迁移的整体效果；最后结合固定参数的轨迹策略与解析缓存混合、条件匹配和候选间能耗价格，评估计费端到端 DSR 及资源与软件时间取舍。

在算法设计上，本文区分集群空间机动与计算任务分配。共享 Attention-MAPPO Actor 根据各机预动作观测给出二维方向动作，环境处理速度、边界与机间距约束，训练采用联合观测 Critic。下层集中使用移动前几何和当前请求批次进行跨节点调度。新解析方法保持各训练块的上层参数固定，通过公开配额提议、容量槽指派与候选价格组织任务，两类决策通过环境状态反馈形成协同；冻结参数并不固定后续轨迹。

在评价设计上，独立训练块反映模型训练变化，配对负载与评估回合用于估计各块性能；非学习方法以随机流重复进行配对评价。固定快照比较控制几何和请求，反事实分配只用于评价。上述设计分别刻画模型、工作负载和求解器差异，并保持相应的独立统计单位。

1.4　研究内容与主要贡献

本文围绕五架 UAV、一百个 UE 和一个 MBS 的动态空地服务仿真主场景，形成以下三项相互关联的研究内容与贡献。

1. **自然覆盖约束下的需求感知集群空间规划**。建立实际生成、自然接纳和截止期成功的统一计数口径，明确接纳率与接纳后质量共同决定端到端 DSR。在物理服务半径不变的条件下，将感知范围内未覆盖需求纳入上层预动作

观测，结合邻机与 UE 的注意力聚合研究协同轨迹决策，并使用独立确认与固定潜在分母复核支持对应结论。这一内容将空间部署的效果具体落实到请求接纳与完成，说明需求可见性对集群服务规划的作用，同时保留观测信息条件与注意力结构贡献的区别。

2. **考虑跨机资源竞争的截止期优先计算任务分配**。在给定位置、请求和历史状态下，以超时数、归一化时延和分配能耗的字典序目标研究 MC-ITR。每次候选迁移重新评价整个批次，明确任务迁入和迁出如何通过最终批量算力共享改变其他请求的完成时间。通过主配置、敏感性、小规模一致性检查以及共享轨迹快照桥接，量化跨机分配的质量余量与完整计算代价。这一内容把机载资源竞争作为集群任务分工的核心约束，并为在线方法设计提供诊断依据。
3. **计及决策开销的分层服务决策**。冻结需求感知轨迹上层，以下层解析缓存混合评分、有限预算条件匹配和开发阶段冻结的能耗价格组织已接纳请求。固定配额后作容量槽指派，价格只在已生成候选间选择，包含初始化在内最多 10 次匹配。逐次完整软件延迟进入当前请求反馈后继续闭环。在 100 UE 主场景的 20 个全新上层训练块上，计费 DSR 为 33.76188%，相对贪心修复和同框架二值价格策略分别提高 1.02828 与 0.26243 个百分点，两项预定主比较通过 Holm 双侧校正，并满足预定能耗及时间门槛。相对贪心机队能耗均值增加约 1.87%，MBS 依赖上升；与未加价混合及冷启动近似参照的差区间跨零。原 SF-HLM 学习配额变体保留为补充，PPO 独有增量不由新解析方法的收益证明。

上述研究形成从需求感知空间部署、跨机批量分配到在线闭环服务的论证链。各项结果按对应的接纳规则、训练设置和实验设计分别报告，支持简化二维运动与规定信息条件下的集群服务改进。信息获取与协调成本、飞行动力学以及同信息预算下的注意力结构贡献，构成进一步评价方法适用范围的研究问题。

1.5 论文组织结构

第一章从无人机集群协同任务规划与临时空地服务需求出发，综合协同覆盖、计算任务分配与学习决策的相关研究，提出空间部署和机载负载耦合下的研究问题、技术路线及三项贡献。

第二章说明集群任务规划的层次、运动约束与协同关系，建立 UAV-MEC 的通信、批量算力共享与服务缓存模型，阐明部分可观测马尔可夫决策过程、广义优势估计与 MAPPO 协同学习机制，进而给出交叉注意力聚合与字典序指派匹

配的数学基础，为后续算法提供统一的理论支撑。

第三章研究自然覆盖约束下无人机集群的需求感知协同轨迹决策，建立动态请求、几何运动约束与上层观测模型，通过服务失败分解、训练动态与独立确认分析需求可见性对集群接纳和端到端服务的影响。

第四章研究考虑跨机资源竞争的截止期优先计算任务分配，在固定轨迹快照中给出 MC-ITR 的批量外部影响、字典序目标、搜索流程和有限终止性质，并报告不同负载、算力与共享快照上的质量、能耗和求解开销。

第五章研究计及决策开销的无人机集群分层服务决策，介绍冻结需求感知上层、解析缓存混合评分、有限预算条件匹配与候选间能耗价格，在 20 个新上层训练块上确认计入完整软件耗时后的服务收益，同时报告机队能耗、MBS、公平性及时间取舍。原学习配额变体及旧协议结果移入补充附录。

第六章归纳需求感知空间规划、跨机资源分配和完整在线协同的主要发现，说明现有信息与仿真假设的适用范围，并提出飞行动力学、通信受限协同、平台故障、续航约束和跨场景评价等后续研究方向。

1.6　研究假设与适用范围

1.6.1　场景与运动模型

主场景为五架 UAV、100 个 UE 及一个 MBS 在 $700 \times 700\,\mathrm{m}^2$ 区域服务。论文没有验证更大机群的扩展性，不将结果直接外推为三至七架或十架以上均有效。轨迹采用固定高度二维位移，限制速度、区域边界及离散机间距；尚未建立姿态、加速度、风场和三维障碍模型，离散位置可行也不等于连续飞行安全。本文据此评价任务层空间部署，不给出真实空域或气象条件的安全认证。

1.6.2　资源、信息与费用模型

UAV 对最终批量请求均分等效算力，MBS 沿用非批量共享的单请求计算规则；任务完整分配到单节点。当前请求先按移动前几何自然接纳，再应用轨迹动作。未覆盖但已生成的服务请求仍计入 DSR 分母，感知范围内可见不等于已进入物理覆盖。公开缓存信念不等于真实命中，需求信息可得性按仿真观测合同规定。

能耗采用未标定具体芯片的等效频率及既有飞行、通信与作业模型。预测分配能耗、环境记录完整机队能耗和软件 CPU 物理能耗是不同对象，最后一项尚未纳入。第五章已将当次完整软件耗时加入当前服务反馈，计时来自规定高并发服务器；没有连续任务队列、真实控制通信及机载平台实测，不能由经验 p95 推

出硬实时性或续航收益。

1.6.3 统计范围与推广条件

各实验按对应冻结协议报告推断单位。第三章需求观测独立确认为十个训练种子，第四章固定快照比较以工作负载为统计单位，第五章新解析方法为二十个新上层训练块，原学习配额十块单列附录。请求、时步与评估回合不充作额外独立训练重复，不同方法与费用协议的数值也不合并。

原学习变体的九格使用 60/100/140 UE 及 0.6/1.0/1.4 倍 UAV 算力，不是新解析方法的泛化证据。新主方法的结论限于 100 UE 主场景及预定两主比较，并同时保留能耗、MBS 和近似参照边界。跨规模、跨资源、真实网络及连续队列中的有效性需要对应条件的独立验证。

1.7 本章小结

本章将无人机集群协同规划具体化为两个连续的服务环节：集群通过空间机动形成自然覆盖接纳机会，再通过计算任务分工与资源使用按时完成请求。相关工作说明协同轨迹、任务分配与学习决策具有多种可行建模方式，也提示规划结构、信息条件与实测性能应分别论证。本文据此采用需求观测研究、固定快照诊断和完整方法确认相结合的技术路线，后续章节在同一任务与服务语义下逐步说明方法设计、公式推导和实验依据。第 1.6 节的研究假设与适用范围声明为理解本文结论的边界条件提供了明确指引。

第 2 章　相关技术与理论基础

本章为无人机集群协同轨迹规划与机载计算任务分配建立系统物理模型与数学优化基础。面向空地协同边缘计算场景，首先界定多无人机协同任务规划的层次关系与二维运动学约束，阐明覆盖接纳与空间资源耦合的基本特征；随后系统介绍无人机辅助移动边缘计算（UAV-MEC）的分层架构，建立视距无线传输、批量算力共享、动态计算能耗及服务镜像缓存模型；接着系统阐述部分可观测马尔可夫决策过程（Dec-POMDP）、多智能体近端策略优化（MAPPO）及用于状态特征聚合的交叉注意力机制；最后介绍不可拆分计算任务指派模型、二部图匹配与字典序优化理论。本章重点阐述通用数学形式与物理成立条件，具体网络槽位结构、动作修复规则与求解算法分别由后续章节结合具体问题展开。

2.1　无人机集群协同规划基础

2.1.1　多无人机协同任务规划

无人机集群系统通过多个空中自主平台协同作业，能够在复杂与突发环境中执行大范围、高动态的信息保障与边缘计算服务。经典多无人机协同任务规划文献通常将系统逻辑划分为任务分配、轨迹规划与飞行控制三个基本层次[1]：

1. 任务分配层：面向宏观业务需求，综合考虑任务优先级、数据量、时延容限及平台执行能力，确定各空中节点承担的任务集合与资源配额[15]；
2. 轨迹规划层：在已知或预测的任务分布与环境约束下，为各无人机规划无碰撞、运动学可行且利于任务执行的空间位移路径；
3. 飞行控制层：依据轨迹规划层输出的位置或速度指令，通过底层飞控系统调节旋翼转速或舵面偏角，实现对期望轨迹的高精度动力学跟踪。

上述三个层次面对不同的物理时间尺度与信息粒度：飞行控制关注毫秒级的连续姿态与气动稳定性；轨迹规划面向秒级或分秒级的空间位移与几何拓扑重构；任务分配则在离散决策时隙内依据即时到达的业务负载实施离散资源调度。若将底层复杂的非线性飞行动力学直接与高层离散任务调度联合求解，将导致求解空间产生维度灾难。

因此，本文聚焦于任务分配层与轨迹规划层之间的双向协同。空中无人机通过动态调整水平几何位置接纳地面突发计算请求，再通过机载计算、跨机协作或基站卸载完成任务。地面服务请求包含输入数据量、服务类别、截止时间与资源需求，属于计算密集型任务。服务覆盖构成请求接纳的前提，执行节点决策承担

计算资源的分工，两者共同决定集群的时限服务能力。

针对这种时空耦合特性，本文采用上层分散式轨迹决策与下层集中式任务调度的分层协同架构。上层各机依据自身与局部感知信息自主决定机动位移，下层则在时隙内汇总接纳请求并统一优化任务分配。在应急或战术通信边缘计算场景中，空中节点间的连续通信带宽极为宝贵，分散式的上层轨迹决策允许无人机在有限的局部邻居通信下实现敏捷反应；而下层的集中任务分配则在接纳请求批次形成后，在有限的协作节点间进行全局时延与能耗的精细化折中。这里的“集群协同”体现为多个空中平台的位置与资源决策服务于共同的时限任务完成目标，无需预设固定编队形状，亦不设定领航者与刚性队形保持约束。

2.1.2 无人机轨迹规划与运动约束

为把研究重心聚焦于地面服务需求分布与空间机动选择之间的内在关联，本文采用固定飞行高度下的离散时隙二维运动学描述。考虑平坦开阔的任务区域，设定所有无人机保持在统一的安全巡航高度 H。该高度设定在工程上具有两方面合理性：一方面大幅简化了三维防撞搜索空间，消除了因垂直机动引起的气压与姿态剧烈扰动；另一方面在保证视距通信仰角的前提下，解耦了垂直升降能耗与水平服务覆盖机动。

设系统部署 N 架配备边缘计算服务器的旋翼无人机，无人机 $u \in \{1, \cdots, N\}$ 在离散时隙 t 的水平几何坐标记为 $\mathbf{q}_u(t) = [x_u(t), y_u(t)]^{\mathsf{T}} \in \mathbb{R}^2$。离散决策时隙长度为 Δt，无人机的最大允许水平飞行速度为 $v_{\max}$。在边长为 L_{area} 的正方形应急任务区域内，考虑周边障碍物及信号覆盖边界缓冲，定义无人机的水平可行几何空间为闭集 $\mathcal{Q} = [x_{\min}, x_{\max}] \times [y_{\min}, y_{\max}] \subset \mathbb{R}^2$。各无人机的位置更新方程满足

$$\mathbf{q}_u(t+1) = \mathbf{q}_u(t) + \boldsymbol{\delta}_u(t), \qquad \|\boldsymbol{\delta}_u(t)\|_2 \leqslant v_{\max}\Delta t, \qquad \mathbf{q}_u(t+1) \in \mathcal{Q}, \tag{2.1}$$

其中 $\boldsymbol{\delta}_u(t)$ 为时隙内无人机实际执行的水平位移矢量。位移矢量的模长 $\|\boldsymbol{\delta}_u(t)\|_2$ 直接反映了时隙平均飞行速度 $\|\boldsymbol{\delta}_u(t)\|_2/\Delta t$，并决定了该时隙内的机动飞行能耗。

为空中防撞与空域运行安全，系统要求任意两架无人机在任意时隙的水平投影之间必须保持最小安全间距 $d_{\min}$。整个集群的联合位置可行配置集定义为

$$\mathcal{Q}_{\text{joint}} = \left\{(\mathbf{q}_1, \cdots, \mathbf{q}_N) : \mathbf{q}_u \in \mathcal{Q},\ \|\mathbf{q}_u - \mathbf{q}_v\|_2 \geqslant d_{\min},\ \forall u \neq v\right\}. \tag{2.2}$$

在分散式决策架构中，各无人机独立根据神经网络策略输出连续动作提案。由于各机未执行集中式航迹仲裁，独立的动作提案组合并不天然保证联合位置落入可行集 $\mathcal{Q}_{\text{joint}}$ 中。实际系统必须在网络输出与物理执行之间构建环境可行性映射：先对越界的单机提案实施边界截断，再通过冲突消解规则对间距小于 $d_{\min}$ 的无人机执行位移衰减或位置回退。由此产生的悬停与实际位移严格记录于无

人机飞行轨迹与能耗账本中。该过程确保了仿真物理状态的严谨性，具体的防撞修正算法将在第三章结合上层策略实现展开。

2.1.3　协同覆盖与任务分工

在移动计算网络中，无人机的物理服务覆盖半径与信息感知范围承担完全不同的系统职能：

1. **物理服务覆盖半径 R_c**：取决于机载下行无线发射功率、地面终端天线增益与信道接收门限。仅当发出计算请求的地面终端位于至少一架无人机的水平覆盖圆域内（即水平距离小于等于 R_c）时，该请求才能被系统**自然接纳**（Natural Admission）；位于所有无人机覆盖范围外的请求因缺乏无线接入链路而直接判定未被接纳。
2. **最大感知半径 R_s**：反映了无人机通过周期性无线信标广播或低频控制信道所能感知的最大环境跨度。无人机 u 在时隙 t 的感知邻机集合定义为

$$\mathcal{N}_u(t) = \left\{ v \neq u : \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2 \leqslant R_s \right\}. \tag{2.3}$$

此外，感知范围内的未覆盖终端状态（如位置、能量、待处理任务特征）允许被无人机的上层观测槽位捕获，为轨迹决策提供前瞻性指引。

当系统设定的安全机间距满足 $d_{\min} \geqslant 2R_c$ 时，任意两架无人机在离散可行配置下的圆形物理服务覆盖区域在几何上严格不重叠。这一几何约束使得无人机集群的轨迹协同无法依赖“重叠覆盖以增强可靠性”的冗余模式，而必须将优化重心转向**如何引导有限的离散覆盖圆域在广阔任务区域内动态捕捉高密度的地面需求热点**。

空间部署收益与机载执行资源深度耦合：无人机移动接近高需求区域能够接纳更多地面请求，但也会使本地共享计算单元承担更高的并发负荷；跨机任务协同可以均衡负载，但引入了额外的机间传输时延与能耗开销。因此，集群规划面对的是空间机动、任务接入与计算分工的多阶段时序耦合过程，需要统一权衡空间覆盖质量与端到端任务执行质量。

2.2　无人机辅助移动边缘计算技术

2.2.1　UAV-MEC 系统架构

移动边缘计算（Mobile Edge Computing, MEC）通过在网络边缘部署具备计算、存储与通信能力的微型服务器，显著缩短了计算任务的端到端交互延迟[2]。在自然灾害救援或突发应急保障等地面基站退化场景中，无人机搭载轻量化低

功耗边缘计算模块组成空中移动服务器集群（UAV-MEC），具备广域机动部署、按需覆盖与灵活拓扑配置的独特优势。图 2.1 给出了端、空、地三层协同的系统架构示意。

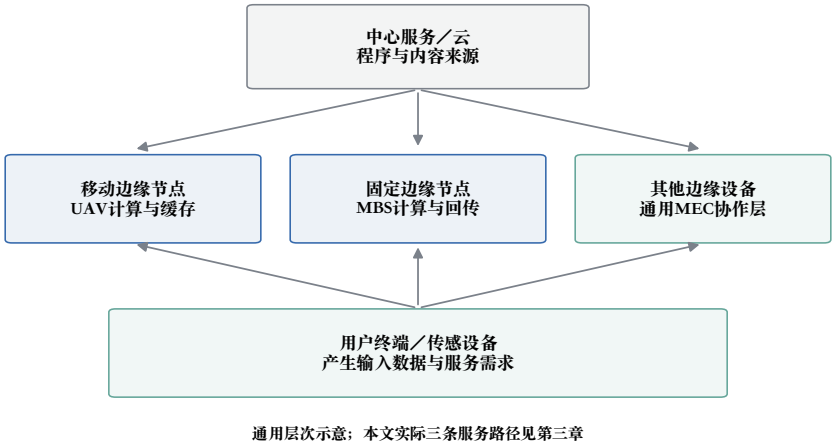


图 2.1　端–空–地三层协同移动边缘计算系统架构示意图

Figure 2.1　Three-Layer Cooperative UAV-MEC Architecture

在任一离散时隙 t 内，设地面被无人机集群自然接纳的计算服务请求集合为 $\mathcal{M}_t$，系统可调配的执行节点集合记为 $\mathcal{J} = \{\mathrm{UAV}_1, \cdots, \mathrm{UAV}_N, \mathrm{MBS}\}$，其中包含 N 架机载边缘计算节点及一个保留有限回传连通性的远端地面宏基站（MBS）。每个服务请求 $m \in \mathcal{M}_t$ 可形式化描述为四元组：

$$\mathrm{Req}_m = (L_m, C_m, D_m, s(m)), \tag{2.4}$$

其中 L_m 为任务输入数据量（单位：字节 Byte），C_m 为完成该计算任务所需的 CPU 总计算周期数，D_m 为任务的端到端最大容忍截止时间（Deadline），$s(m)$ 为执行该任务所需的服务程序镜像类别。若服务类型决定了单位数据量所需的计算密度为 ω_m（CPU 周期/字节），则任务总计算量满足

$$C_m = \omega_m L_m. \tag{2.5}$$

在实际边缘计算业务中，考虑任务强耦合性与通信重传开销，本文采用**不可拆分任务模型**（Atomic Task Model），即每个被接纳的请求必须完整地分配至单一计算节点独立执行，不允许跨节点细粒度切分或多机并行流水。根据任务分配目标，执行路径可分为三类：

1. **接入 UAV 本地执行**：请求直接在接入该终端的无人机处理器上运行，仅产生接入无线传输与机载计算时延，无需跨机转发；
2. **协作 UAV 协同执行**：接入无人机通过机间高速无线链路将任务转发至算力较充裕或已预载相应镜像的邻近无人机执行，计算结果原路或经短报文

返回；

3. **地面 MBS 远程执行**：接入无人机通过长距离无线回传链路将任务卸载至地面宏基站执行。基站算力充沛且预载全量镜像，但面临较长的无线回传往返时延。

所有执行路径的前提是请求首先被空中覆盖网络成功接纳。

2.2.2　无线通信与计算卸载模型

无人机与地面设备及基站之间的无线信道质量直接受三维空间几何拓扑主导[4]。设在时隙 t 内，无人机 u 的水平位置为 $\mathbf{q}_u(t) \in \mathbb{R}^2$，地面终端 m 的水平位置为 $\mathbf{w}_m(t) \in \mathbb{R}^2$，无人机飞行高度恒为 H。地面设备与无人机之间的三维空间直线欧氏距离为

$$d_{mu}(t) = \sqrt{\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2^2 + H^2}. \tag{2.6}$$

图 2.2 展示了无人机作为空中接入、中继协同与计算服务器的通信应用场景。

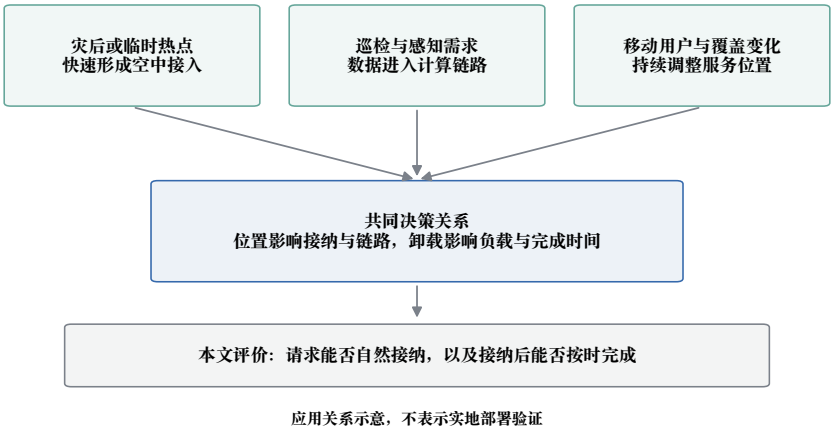


图 2.2　无人机辅助通信与计算卸载典型应用场景示意图

Figure 2.2　Typical Application Scenarios of UAV-Assisted Edge Computing

在飞行高度较高且地表建筑遮挡有限的开阔环境中，空地信道具有显著的视距传输（Line-of-Sight, LoS）主导特性。考虑自由空间路径损耗模型，信道参考功率增益与传输距离的平方成反比。根据香农定理，在信道带宽为 B、发射端发送功率为 P、等效信道增益为 g、加性高斯白噪声（AWGN）功率为 σ^2 时，理想链路的最大无差错传输速率（单位：bit/s）表达为

$$R = B \log_2 \left(1 + \frac{Pg}{\sigma^2}\right). \tag{2.7}$$

在计算网络卸载模型中，任务数据量通常以字节（Byte）度量。为确保物理量纲严格一致，必须进行字节到信道传输比特（$1\,\text{Byte} = 8\,\text{bit}$）的量纲转换。任

务输入数据 L_m 对应的链路无线传输时延 T_m^{tx} 与发射能耗 E_m^{tx} 为

$$T_m^{\mathrm{tx}} = \frac{8L_m}{R}, \qquad E_m^{\mathrm{tx}} = PT_m^{\mathrm{tx}}. \tag{2.8}$$

式 (2.8) 中的系数 8 具有关键的物理量纲意义：若忽略该量纲转换，将导致通信时延被机械低估 8 倍，严重失真地扭曲算法对本地计算与远程卸载的能耗及截止期取舍偏好。

2.2.3 计算资源共享与服务缓存

对于机载计算节点，设无人机 j 的总计算处理能力为 F_j（CPU 周期/秒）。当一个时隙内分配给无人机 j 的并发执行任务数为 N_j 时，本文采用批量算力均分模型（Batch-Shared Equal Computation），各任务均分节点的处理器算力资源，获得的等效服务频率为 $f_{mj} = F_j/N_j$。因此，任务 m 在节点 j 的实际计算时延为

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{f_{mj}} = \frac{C_m N_j}{F_j}, \quad N_j \geqslant 1. \tag{2.9}$$

采用动态 CMOS 功耗模型，处理器能耗正比于计算频率的平方。任务 m 在无人机 j 上的计算能耗表达为

$$E_{mj}^{\mathrm{cmp}} = \kappa f_{mj}^3 \frac{C_m}{f_{mj}} = \kappa C_m f_{mj}^2 = \kappa C_m \left(\frac{F_j}{N_j}\right)^2, \tag{2.10}$$

其中 κ 为与硬件芯片体系相关的有效电容系数。式 (2.9) 与 (2.10) 表明，节点并发任务数 N_j 增加会导致单任务时延线性上升，但计算能耗随之按二次方衰减。这一特性使单个任务的迁移产生跨机外部性（Migration Externality），影响目标节点上所有已有任务的完成时间。

服务缓存缓解了由于频繁向地面基站请求下载服务镜像所造成的时延瓶颈。设服务类型 s 的镜像大小为 B_s，节点 j 的缓存状态指示为 $z_{js} \in \{0, 1\}$。机载存储容量约束满足

$$\sum_s z_{js} B_s \leqslant K_j, \tag{2.11}$$

其中 K_j 为无人机 j 的机载缓存容量上限。命中缓存的任务无需产生回传检索时延，未命中任务则需计入镜像下载等待时间。

此外，为评估集群对不同地面用户服务机会的均衡性，采用 Jain 公平性指数：

$$J = \frac{\left(\sum_{m=1}^{M} c_m\right)^2}{M \sum_{m=1}^{M} c_m^2}, \tag{2.12}$$

其中 c_m 为地面终端 m 获得的累计服务覆盖量。当所有设备获得均等服务时 $J = 1$，服务出现严重倾斜时该值显著下降。

2.3　多智能体深度强化学习基础

2.3.1　马尔可夫决策过程与部分可观测性

强化学习通过智能体与动态环境的交互试错来寻找最优序贯决策策略[38]。图 2.3 给出了基本交互框架。针对多无人机集群协同，环境可建模为有限时域分散式部分可观测马尔可夫决策过程（Dec-POMDP），由元组 $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma, T)$ 定义。其中 $\mathcal{S}$ 为全局环境状态空间，$\mathcal{A} = \prod_{u=1}^{N} \mathcal{A}_u$ 为联合动作空间，$P(s' \mid s, \mathbf{a})$ 为状态转移概率，r 为奖励函数，ρ_0 为初始状态分布，$\gamma \in [0, 1)$ 为折扣因子，T 为单幕（Episode）时域长度。

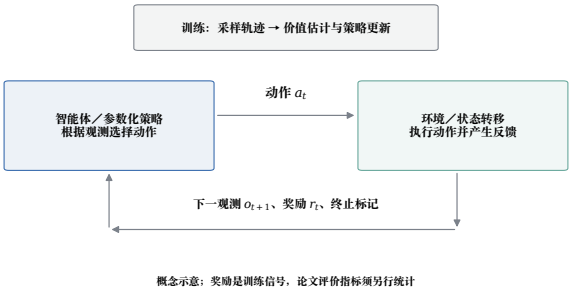


图 2.3　强化学习智能体与环境交互框架示意图

Figure 2.3　Interaction Framework between Reinforcement Learning Agent and Environment

环境全局状态转移满足马尔可夫性：

$$P(s_{t+1} \mid s_0, \mathbf{a}_0, \cdots, s_t, \mathbf{a}_t) = P(s_{t+1} \mid s_t, \mathbf{a}_t). \tag{2.13}$$

在部分可观测场景下，单架无人机 u 仅能获得局部观测 $o_{u,t} = \mathcal{O}_u(s_t)$。从时隙 t 开始的未来累计折扣回报定义为

$$\mathcal{G}_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k, \qquad \mathcal{G}_T = 0. \tag{2.14}$$

在策略 π 下，状态值函数 $V_t^{\pi}(s)$ 与动作值函数 $Q_t^{\pi}(s, \mathbf{a})$ 分别为回报在状态及动作下的条件期望：

$$V_t^{\pi}(s) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s], \tag{2.15}$$

$$Q_t^{\pi}(s, \mathbf{a}) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s, \mathbf{a}_t = \mathbf{a}]. \tag{2.16}$$

依据动态规划原理，二者满足 Bellman 期望方程：

$$Q_t^{\pi}(s, \mathbf{a}) = \bar{r}(s, \mathbf{a}) + \gamma \sum_{s'} P(s' \mid s, \mathbf{a}) V_{t+1}^{\pi}(s'), \tag{2.17}$$

$$V_t^{\pi}(s) = \sum_{\mathbf{a}} \pi(\mathbf{a} \mid s) Q_t^{\pi}(s, \mathbf{a}). \tag{2.18}$$

优势函数度量了特定动作相对于当前策略平均表现的超额收益：

$$A_t^{\pi}(s,\mathbf{a}) = Q_t^{\pi}(s,\mathbf{a}) - V_t^{\pi}(s). \tag{2.19}$$

2.3.2 近端策略优化与多智能体 PPO

策略梯度方法通过参数化策略网络 π_θ 直接优化期望回报 $J(\theta) = \mathbb{E}[\mathcal{G}_0]$[23]。引入状态值函数作为动作无关基线，策略梯度标准形式为

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_{t=0}^{T-1} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A_t^{\pi}(s_t,a_t)\right]. \tag{2.20}$$

Actor–Critic 架构利用参数为 ϕ 的 Critic 网络 V_ϕ 拟合状态值，训练目标为最小化均方估计误差：

$$L_V(\phi) = \frac{1}{2}\mathbb{E}\left[(V_\phi(s_t) - \widehat{V}_t)^2\right]. \tag{2.21}$$

为权衡优势估计的偏差与方差，广义优势估计（GAE）[39] 基于一步时序差分（TD）误差

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t), \tag{2.22}$$

通过参数 $\lambda_{\mathrm{GAE}} \in [0,1]$ 对多步残差进行指数衰减加权，得到优势估计量：

$$\widehat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{K-1} (\gamma\lambda_{\mathrm{GAE}})^l \delta_{t+l}. \tag{2.23}$$

近端策略优化（PPO）[40] 为防止策略单步更新步长过大导致训练崩塌，引入重要性采样比率

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\mathrm{old}}}(a_t \mid s_t)} = \exp\left[\log \pi_\theta(a_t \mid s_t) - \log \pi_{\theta_{\mathrm{old}}}(a_t \mid s_t)\right], \tag{2.24}$$

并构建带裁剪因子的悲观代理目标函数：

$$L_{\mathrm{clip}}(\theta) = \mathbb{E}_{\mathrm{old}}\left[\min\left(\rho_t(\theta)\widehat{A}_t,\ \mathrm{clip}(\rho_t(\theta), 1-\varepsilon, 1+\varepsilon)\widehat{A}_t\right)\right], \tag{2.25}$$

其中 $\varepsilon \in (0,1)$ 为裁剪阈值。该目标在优势为正时限制策略概率过增，在优势为负时限制策略概率过降，有效约束了新旧策略的分布偏离。

在多智能体协同领域，多智能体 PPO（MAPPO）[28] 采用集中训练分散执行（CTDE）框架[27,41]。执行时，各无人机仅依据局部观测 $o_{u,t}$ 通过参数共享的 Actor 独立生成机动动作；训练时，中央 Critic 网络获取全局联合观测 $O_t = (o_{1,t}, \cdots, o_{N,t})$，输出各无人机的联合价值估计：

$$\boldsymbol{V}_\phi(O_t) = (V_{\phi,1}(O_t), \cdots, V_{\phi,N}(O_t)) \in \mathbb{R}^N. \tag{2.26}$$

MAPPO 共享 Actor 的全局训练代理损失为所有智能体与批次时隙的平均：

$$L_{\mathrm{MAPPO}}(\theta)=\frac{1}{NT}\sum_{u=1}^{N}\sum_{t=0}^{T-1}\min\left(\rho_{u,t}(\theta)\widehat{A}_{u,t},\ \mathrm{clip}(\rho_{u,t}(\theta),1-\varepsilon,1+\varepsilon)\widehat{A}_{u,t}\right),\quad(2.27)$$

其中 $\rho_{u,t}(\theta)=\pi_\theta(a_{u,t}\mid o_{u,t})/\pi_{\theta_{\mathrm{old}}}(a_{u,t}\mid o_{u,t})$。CTDE 机制在训练期有效缓解了部分可观测性与环境非平稳性，而在执行期保持了完全去中心化的敏捷性。

2.3.3　注意力机制与特征聚合

注意力机制通过动态计算输入元素间的相关性生成加权聚合表征[32]。设查询、键与值矩阵分别为 $Q\in\mathbb{R}^{n_q\times d_k}$、$K\in\mathbb{R}^{n_k\times d_k}$ 和 $V\in\mathbb{R}^{n_k\times d_v}$，加性掩码为 M，缩放点积注意力定义为

$$\mathrm{Att}(Q,K,V)=\mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}}+M\right)V.\quad(2.28)$$

通过缩放因子 $1/\sqrt{d_k}$ 消除高维点积导致的梯度饱和。多头注意力（MHA）通过并行投影捕获不同子空间的特征关联：

$$\begin{aligned}H_h&=\mathrm{Att}(QW_h^Q,KW_h^K,VW_h^V),\\ \mathrm{MHA}(Q,K,V)&=\mathrm{Concat}(H_1,\cdots,H_H)W^O.\end{aligned}\quad(2.29)$$

在多无人机集群中，各无人机感知的邻机数量及地表用户数量随时间动态变化。交叉注意力为非定长拓扑观测的定长表征提供了理想架构：无人机将自身物理状态嵌入作为 Query，将感知范围内的邻居无人机及地面用户特征槽位分别作为 Key 与 Value，通过掩码 M 屏蔽未占用的无效填充槽位，实现对动态局部环境信息的排列不变性自适应聚合。

2.4　计算任务指派与组合优化基础

2.4.1　任务指派模型与容量约束

在特定时隙内，给定已接纳服务请求集合 $\mathcal{M}$ 与执行节点集合 $\mathcal{J}$，计算卸载决策可形式化为广义任务指派问题（Generalized Assignment Problem）。定义二元决策变量 $x_{mj}\in\{0,1\}$，表示请求 m 是否指派至节点 j 执行。

由于任务不可拆分且必须被处理，每个请求必须且仅能指派给一个合法目的地。对于给定的节点负载配额向量 $\mathbf{N}=(N_1,\cdots,N_{|\mathcal{J}|})$，系统需满足指派唯一性约束与节点容量约束：

$$\sum_{j\in\mathcal{C}_m}x_{mj}=1,\quad\forall m\in\mathcal{M},\qquad\sum_{m\in\mathcal{M}}x_{mj}=N_j,\quad\forall j\in\mathcal{J},\qquad\sum_{j\in\mathcal{J}}N_j=|\mathcal{M}|,\quad(2.30)$$

其中 $\mathcal{C}_m \subseteq \mathcal{J}$ 表示请求 m 的物理合法执行节点集合。当节点配额向量 $\mathbf{N}$ 固定时，各执行节点的算力分配与能耗模型随之确定，边指派代价记为 $c_{mj}(\mathbf{N})$。此时组合优化子问题转化为条件化线性指派模型：

$$\min_{x} \sum_{m\in\mathcal{M}} \sum_{j\in\mathcal{J}} c_{mj}(\mathbf{N}) x_{mj} \quad \text{满足式 (2.30).} \tag{2.31}$$

2.4.2 二部图匹配与最小代价指派

条件化线性指派模型具有特殊的图论对偶结构。将每个计算节点 $j \in \mathcal{J}$ 逻辑展开为 N_j 个虚拟执行槽位，每个槽位继承节点 j 的通信信道特征与共享算力单价。原问题等价转化为请求集合 $\mathcal{M}$ 与虚拟槽位集合 $\mathcal{S}$ 之间的赋权二部图完全匹配问题（Weighted Bipartite Matching）。

由于二部图指派约束矩阵具有全单模性（Totally Unimodular），线性规划松弛的最优解天然满足整数性条件。因此，该问题可在多项式时间复杂度内通过 Kuhn-Munkres（KM）算法、逐次最短路径法或拍卖算法（Auction Algorithm）严格求解全局最优指派方案，为大规模并发请求的快速精确分配奠定了算法基础。

2.4.3 字典序优化基础

在应急边缘计算场景中，任务的截止时间满足具有最高业务优先级，节能降耗属于次级优化目标。两类目标量纲不同且重要性呈严格层级关系，适用多目标字典序优化（Lexicographic Optimization）。

为将严格字典序优先级无缝嵌入线性指派模型中，本文构建基于大 M 尺度的有界复合代价编码。设当前已接纳请求总数为 $n = |\mathcal{M}|$，将各边预测执行能耗归一化为 $\widetilde{E}_{mj} \in [0,1]$，定义指派边权重为

$$c_{mj} = (n+1)\,\mathbb{I}\{\widehat{T}_{mj} > D_m\} + \widetilde{E}_{mj}, \tag{2.32}$$

其中 $\mathbb{I}\{\cdot\}$ 为示性函数，$\widehat{T}_{mj}$ 为预测完成时延。

由于归一化后的总分配能耗严格满足 $\sum_m \widetilde{E}_{mj} \in [0,n]$，任何减少一个超时任务所获得的代价降低（至少 $n+1$）都严格大于系统可能出现的最大总能耗增加量（至多 n）。因此，最小化式 (2.32) 保证在数学上严格优先最小化截止期违约任务数，仅在超时任务数相同的指派方案中寻优最低能耗解。

2.5 本章小结

本章系统建立了支撑无人机集群空地协同轨迹决策与计算任务分配的理论与方法基础，回答了三个核心理论问题：

1. **研究系统是什么**：界定了多无人机任务协同层次与二维离散机动边界，建立了兼具视距无线传输、批量算力均分外部性、动态计算能耗与服务缓存的 UAV-MEC 物理模型；
2. **上层轨迹策略基于什么算法**：阐明了部分可观测马尔可夫决策过程（Dec-POMDP）、广义优势估计（GAE）与近端策略优化（PPO）的基本数学推导，确立了集中训练分散执行（CTDE）下的多智能体 PPO（MAPPO）协同学习机制与自适应多头交叉注意力特征聚合结构；
3. **下层任务分配基于什么数学工具**：提出了不可拆分任务的广义指派模型与二部图匹配等价转化形式，给出了截止期严格优先的大 M 尺度字典序优化编码。

上述基础构成了全文学术分析的统一符号与数学语言，为第三章需求感知协同轨迹规划、第四章跨机资源竞争下的任务迁移以及第五章兼顾软件开销的分层协同设计提供了严密支撑。

第 3 章　自然覆盖约束下基于需求感知注意力的集群协同轨迹规划

3.1　系统模型与问题描述

3.1.1　系统场景与自然覆盖接纳模型

在无人机辅助移动边缘计算（UAV-assisted Mobile Edge Computing, UAV-MEC）系统中，无人机作为机动空中计算基站，能够快速部署到地面通信基础设施受限或动态高负荷的区域，为具有严格时限约束的地面用户设备（User Equipment, UE）提供计算任务卸载与内容分发服务。如图 3.1 所示，考虑由 $N = 5$ 架四旋翼无人机组成的无人机集群、固定位置的地面宏基站（Macro Base Station, MBS）以及分布于服务区域内的 $M = 100$ 个地面移动用户构成的分层边缘计算系统。地面服务区域设定为水平跨度为 $[0, 700]\times[0, 700]\,\mathrm{m}^2$ 的二维正方形区域，宏基站固定部署于该区域的中心坐标处，其三维空间坐标为 $\mathbf{p}_{\mathrm{M}} = (350, 350, 30)\,\mathrm{m}$。

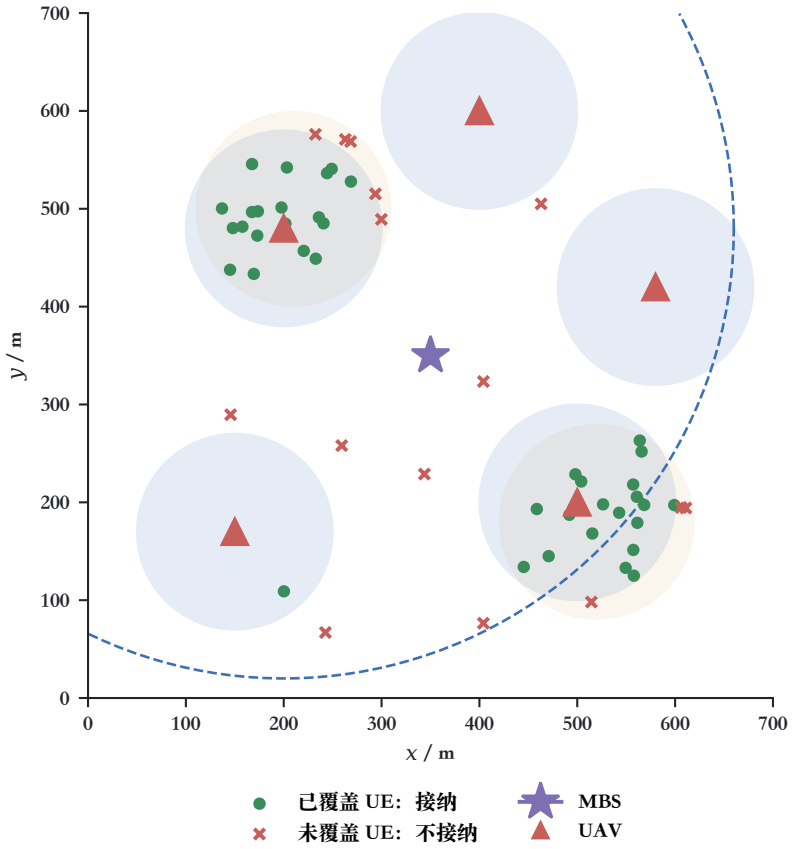
系统采用以 $\tau = 1\,\mathrm{s}$ 为离散时隙周期的同步控制与决策框架，总调度时限划分为 $T = 1000$ 个决策时隙，记时隙集合为 $\mathcal{T} = \{1, 2, \cdots, T\}$。在飞行高度层面，假定机群采用高度分层或防撞高度保持策略，五架无人机统一巡航在固定高度 $H = 100\,\mathrm{m}$ 的水平空域。在时隙 t，以 $\mathbf{q}_u(t) = (x_u(t), y_u(t)) \in \mathbb{R}^2$ 表示无人机 $u \in \mathcal{N} = \{1, \cdots, N\}$ 的水平坐标，其对应的三维空间坐标为 $\mathbf{p}_u(t) = (\mathbf{q}_u(t), H)$；地面用户 $m \in \mathcal{M} = \{1, \cdots, M\}$ 的水平坐标记为 $\mathbf{w}_m(t) = (x_m(t), y_m(t)) \in \mathbb{R}^2$，其三维空间坐标为 $\mathbf{p}_m(t) = (\mathbf{w}_m(t), 0)$。

地面用户的空间运动采用高斯随机航点模型（Random Waypoint Model）。主场景中 85% 的用户围绕两个热点区域聚集分布，各热点半径为 100 m，两热点中心间距不小于 400 m，其余 15% 的用户稀疏离散地分布在空域其他部分。在每个时隙内，用户向当前目标航点推进，时隙水平位移不超过 15 m；到达当前航点后，用户在设定时长内保持原地驻留，随后重新生成下一个目标航点。

地面用户在每个时隙内均具有潜在的服务需求。为真实刻画边缘应用特征，文件库中预设 25 类计算服务与 50 个内容文件，共计 75 个离散业务标识。总体流行度服从偏度系数为 $\beta = 0.8$ 的 Zipf 分布，各业务标识 $s \in \{1, \cdots, 75\}$ 的请求概率模型为：

$$\Pr(s) = \frac{r_s^{-\beta}}{\sum_{k=1}^{75} r_k^{-\beta}}, \qquad \beta = 0.8, \tag{3.1}$$

其中 r_s 为业务标识 s 在流行度降序排列中的名次。每个地面用户在每个时隙预



实线圆：100 m服务范围；虚线弧：460 m感知范围；橙色区域：热点

图 3.1　无人机集群自然覆盖与需求感知示意图

Figure 3.1　Schematic of Swarm Natural Coverage and Demand Sensing

注：实线圆表示 100 m 服务覆盖范围，虚线圆表示 460 m 感知范围；绿色圆点表示被接纳终端，红色叉号表示未接纳终端。

先独立抽取潜在请求标识 $s_m(t)$、任务输入数据量 $L_m(t) \in [10^6, 5\times10^6)$ 字节、任务执行截止时间 $D_m(t) \in [0.65, 2.10]$ s 以及请求优先级 $p_m(t) \in \{1,2,3\}$。

在请求生成与类型定型层面，用户设备的电池能量状态决定实际产生的业务类别。设用户 m 在时隙 t 开始时的剩余电池电量为 $B_m^{\mathrm{bat}}(t)$。当用户剩余电量不低于设定的安全能量阈值 $B_{\mathrm{low}} = 50$ J 时，若抽取的业务标识属于计算服务类，则生成计算卸载请求；若属于内容文件类，则生成内容分发请求。当剩余电量低于 50 J 时，出于终端续航保护机制，用户当前时隙的潜在业务请求自动转变为能量补充请求，等待来自空中的无线能量传输（Wireless Power Transfer, WPT）服务。

在无线接入层面，本文设定了严密的自然覆盖接纳（Natural-coverage Admission）准则：无人机向地面辐射的有效通信覆盖范围由机载天线的主瓣波束与物理发射功率决定，抽象为以无人机水平投影为圆心、半径为 $R_c = 100$ m 的水平覆盖圆。地面用户必须在物理上处于至少一架无人机的覆盖圆内部，其业务请求方可被该无人机物理层接收并纳入本时隙的接入与计算流程；若用户处于所

有无人机的物理覆盖圆之外，则其请求在当前时隙直接被视为无法进入服务流程的未接纳请求。对于时隙 t 的用户 m，其在几何上可关联的候选无人机集合 $\mathcal{U}_m(t)$ 以及唯一确定的服务接入无人机 $u_m(t)$ 形式化定义为：

$$\mathcal{U}_m(t) = \left\{ u \in \mathcal{N} : \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\| \leqslant R_c \right\}, \qquad u_m(t) = \arg\min_{u \in \mathcal{U}_m(t)} \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|, \tag{3.2}$$

当 $\mathcal{U}_m(t) = \varnothing$ 时，用户未被覆盖，记 $u_m(t) = \varnothing$。在重叠覆盖区域，用户依据水平欧氏距离就近接入最近的无人机。

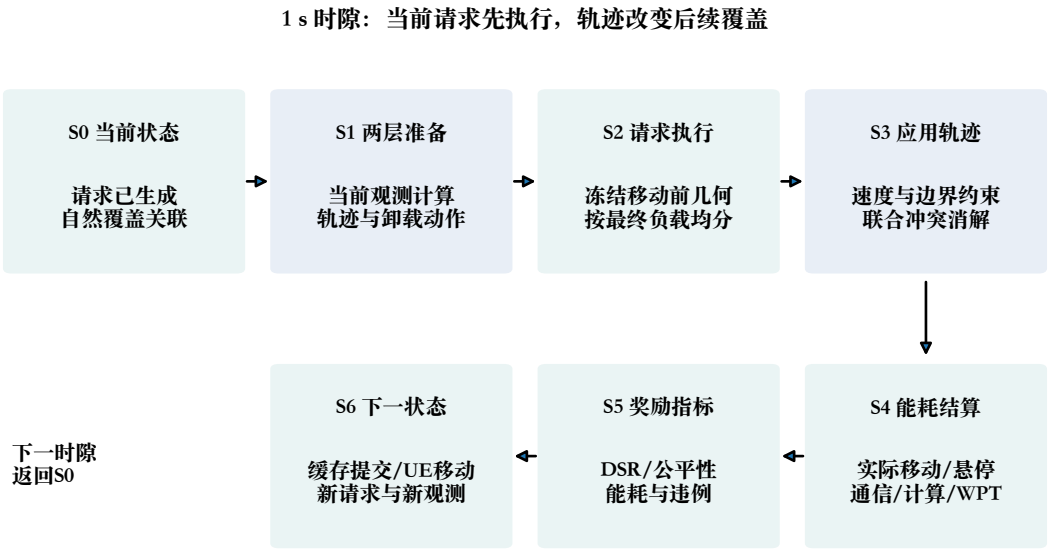


图 3.2　单时隙任务执行与轨迹更新时序图

Figure 3.2　Execution and Trajectory Update Timeline within a Single Slot

图 3.2 详细阐明了单时隙内部各阶段的严格执行因果与时序逻辑：

1. **时隙初状态冻结与观测装配**：在时隙 t 开始时，各节点维持上一时隙末的位置 $\mathbf{q}_u(t)$ 与缓存状态 $h_{u,s}(t)$，系统依据当前几何空间分布更新用户自然覆盖接纳关系 $\mathcal{U}_m(t)$；随后，上层轨迹规划策略与下层任务卸载策略基于该当前时隙信息装配各自观测并输出决策动作。
2. **移动前几何下的任务批次执行**：在进入物理步进执行阶段后，首先冻结移动前的通信几何拓扑与网络信道，下层策略确立全部已接纳任务的最终执行目标 $\mathbf{b}(t)$，并统一结算数据上传时延、协作回传时延、计算排队完成时延以及对应的通信与计算能耗。
3. **上层轨迹位移执行与状态演化**：在当前批次任务执行与能耗结算完成后，环境应用上层轨迹规划策略生成的动作指令，实施运动位移并更新无人机坐标至 $\mathbf{q}_u(t+1)$；随后结算平台飞行与悬停能耗，并在时隙末提交缓存替换项、驱动用户移动与电量更新，最终生成面向 $t+1$ 时隙的全新观测输入。

上述决策时序建立了明确的双层动作因果关系：

$$\mathbf{b}(t) \longrightarrow \{T_m(t), E_m^{\text{assign}}(t)\}, \qquad \mathbf{a}(t) \longrightarrow \mathbf{q}(t+1) \longrightarrow \mathcal{U}_m(t+1), \tag{3.3}$$

其中 $\mathbf{b}(t)$ 为当前批次服务任务的执行目标分配决策，$\mathbf{a}(t)$ 为机群协同轨迹位移指令。由此可见，上层轨迹动作并不追溯改变当前时隙已经确定的自然接纳集合 $\mathcal{U}_m(t)$，其核心物理功能在于驱动机群主动向地面高密度需求演化区域机动，从而直接优化下一时隙乃至长期的可接纳用户规模与空间信道增益。

3.1.2　无人机移动与通信模型

为实现机群的安全、平稳机动与协同覆盖，建立离散时间无人机运动学模型。在时隙 t，无人机 u 施加规划水平位移向量 $\Delta\mathbf{q}_u(t)$，其水平坐标演化方程为：

$$\mathbf{q}_u(t+1) = \mathbf{q}_u(t) + \Delta\mathbf{q}_u(t). \tag{3.4}$$

受机载动力学与驱动推力限制，无人机在单个时隙时长 $\tau = 1\,\text{s}$ 内的移动距离严格受限于最大平飞速度 $v_{\max} = 15\,\text{m/s}$，即满足速度模长约束 $\|\Delta\mathbf{q}_u(t)\| \leqslant v_{\max}\tau$。同时，为保障机载通信天线对地覆盖的主瓣增益并预留边界保护带，机群的可行飞行空域限制为 $\mathcal{Q} = [50\,\text{m}, 650\,\text{m}]^2$。此外，为空中防撞与飞行安全，任意两架无人机之间的最小水平防撞间距设定为 $d_{\min} = 200\,\text{m}$。

如图 3.3 所示，由于防撞间距 $d_{\min} = 200\,\text{m}$ 恰好等于单个无人机的物理覆盖直径 $2R_c$，这表明满足防撞安全约束的任意两架无人机的物理覆盖圆在空间上互不重叠，在边界处至多相切。这一物理约束从根本上避免了多架无人机盲目聚集于同一局部热点造成覆盖重叠与无线干扰，促使机群必须在空间拓扑上开展协同发散与多热点协同覆盖。

给定当前时隙的可行空间坐标 $\mathbf{q}(t) = \{\mathbf{q}_u(t)\}_{u=1}^{N}$，机群在下一时隙的联合物理可行部署集合 $\mathcal{F}(\mathbf{q}(t))$ 形式化定义为：

$$\mathcal{F}(\mathbf{q}(t)) = \left\{ \{\mathbf{q}'_u\}_{u=1}^{N} \,:\, \mathbf{q}'_u \in \mathcal{Q},\ \|\mathbf{q}'_u - \mathbf{q}_u(t)\| \leqslant v_{\max}\tau,\ \|\mathbf{q}'_u - \mathbf{q}'_v\| \geqslant d_{\min}\ (\forall u \neq v) \right\}. \tag{3.5}$$

在空天地无线通信层面，空对地（UAV-UE）、空对空（UAV-UAV）以及空对地回传（UAV-MBS）链路均建模为大尺度自由空间路径损耗模型。对于三维空间中位置坐标分别为 $\mathbf{p}_i$ 与 $\mathbf{p}_j$ 的两个通信收发端点，链路信道功率增益为：

$$g_{ij}(t) = \frac{G_0 g_0}{\|\mathbf{p}_i(t) - \mathbf{p}_j(t)\|^2 + \epsilon_0}, \qquad G_0 g_0 = 3.244132 \times 10^{-4}, \tag{3.6}$$

其中 $G_0 g_0$ 为参考距离 1 m 处的等效信道衰减系数，$\epsilon_0 = 10^{-6}$ 为避免分母为零的数值平滑常数。设各发送节点的通信发射功率统一设定为 $P^{\text{comm}} = 0.5\,\text{W}$，接收端加性高斯白噪声功率设定为 $\sigma^2 = 10^{-13}\,\text{W}$。

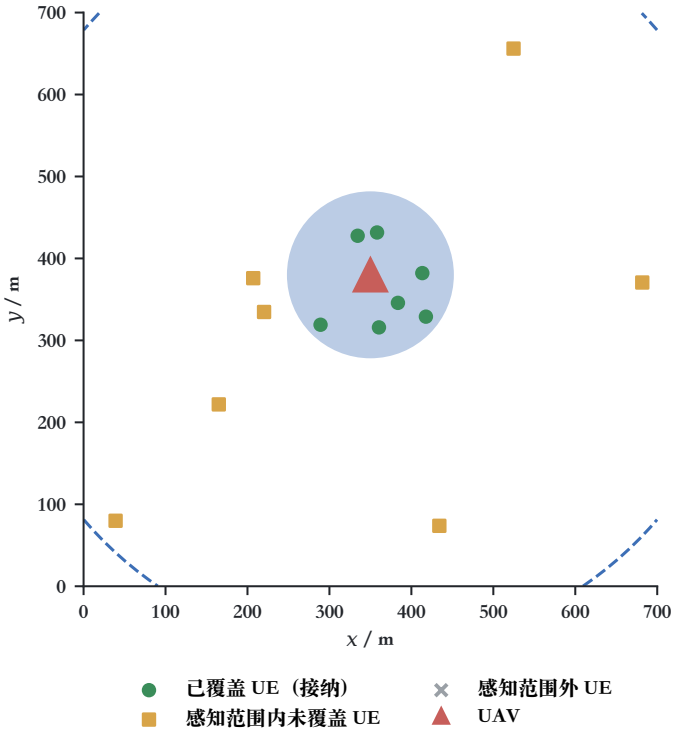


图 3.3　服务覆盖半径与需求感知半径示意图

Figure 3.3　Geometric Relationship between Coverage Radius and Sensing Radius

在无人机对地接入信道层面，系统为每个无人机分配独立且相互正交的接入频段，接入总带宽为 $B^{\mathrm{edge}} = 40\,\mathrm{MHz}$。在时隙 t，成功关联至无人机 u 的全部地面用户总数记为 $n_u^{\mathrm{assoc}}(t)$（包含服务请求、内容请求及能量请求）。为保障接入公平性与协议轻量化，接入带宽由该无人机覆盖下的全部关联用户等权时频均分。因此，用户 m 向接入无人机 $u = u_m(t)$ 上传任务数据的等效无线传输速率为：

$$R_{m,u}^{\mathrm{edge}}(t) = \frac{B^{\mathrm{edge}}}{n_u^{\mathrm{assoc}}(t)} \log_2\left(1 + \frac{P^{\mathrm{comm}} g_{m,u}(t)}{\sigma^2}\right), \qquad B^{\mathrm{edge}} = 40\,\mathrm{MHz}. \tag{3.7}$$

式 (3.7) 深刻反映了边缘接入中“覆盖扩展”与“通信拥塞”的内在权衡：当无人机通过轨迹机动覆盖更多地面用户时，关联用户数 n_u^{assoc} 的增加将导致单用户分配到的有效接入带宽反比衰减，进而延长输入数据的无线传输时延。这一通信瓶颈对协同轨迹规划提出了兼顾接入机会与接入质量的严苛要求。

在骨干通信与回传信道层面，无人机之间设有专用高速微波机间通信链路，系统预留机间带宽 $B^{\mathrm{inter}} = 20\,\mathrm{MHz}$，用于支持跨机协同计算任务的数据转发与结果回传；无人机与地面宏基站之间设有专用的无线回传（Backhaul）链路，带宽

配置为 $B^{\mathrm{bh}} = 0.75\,\mathrm{MHz}$。对应的香农信道容量分别为：

$$\begin{aligned} R_{u,v}^{\mathrm{inter}}(t) &= B^{\mathrm{inter}} \log_2\left(1 + \frac{P^{\mathrm{comm}} g_{u,v}(t)}{\sigma^2}\right), \\ R_{u,\mathrm{M}}^{\mathrm{bh}}(t) &= B^{\mathrm{bh}} \log_2\left(1 + \frac{P^{\mathrm{comm}} g_{u,\mathrm{M}}(t)}{\sigma^2}\right). \end{aligned} \tag{3.8}$$

3.1.3　任务执行与计算能耗模型

对于在时隙 t 成功接纳的计算服务请求集合 $\mathcal{M}(t) = \{m \in \mathcal{M} : u_m(t) \neq \varnothing$ 且$\mathrm{type}_m = \mathrm{service}\}$，服务标识 s_m 对应的任务计算工作量为：

$$C_m = \omega_{s_m} L_m, \tag{3.9}$$

其中 $\omega_s \in [1200, 2800)\,\mathrm{Cycles/Byte}$ 为各服务每字节所需的计算密度参数。

在任务卸载架构中，每个计算请求 m 经由接入无人机 $u = u_m(t)$ 上传后，存在三类互斥的执行路由路径，由卸载决策变量 $b_m \in \{u\} \cup (\mathcal{N} \setminus \{u\}) \cup \{\mathrm{M}\}$ 决定：

1. **本地接入无人机执行**（$b_m = u$）：任务输入直接在接入节点执行，省去跨机转发时延；
2. **机间协同无人机执行**（$b_m = v \in \mathcal{N} \setminus \{u\}$）：任务输入经由机间链路转发至临近空闲算力更充裕的无人机 v 执行；
3. **宏基站卸载执行**（$b_m = \mathrm{M}$）：任务经由无线回传链路发送至地面中心宏基站执行。

在计算服务执行前，执行节点需具备对应的服务应用程序镜像或环境依赖文件，其大小记为 B_s。以二值变量 $h_{j,s}(t) \in \{0, 1\}$ 表示无人机 j 在时隙初是否已成功缓存服务 s 的镜像文件。若缓存命中（$h_{j,s} = 1$），则直接调度 CPU 执行；若未命中（$h_{j,s} = 0$），该无人机必须首先通过无线回传链路从核心网下载该镜像文件，产生额外的回源时延 $V_{j,s} = 8B_s / R_{j,\mathrm{M}}^{\mathrm{bh}}$。

在计算资源分配层面，各无人机机载处理器的标称最大计算能力记为 $F_j \in \{40, 45, \cdots, 85\}\,\mathrm{GHz}$。在单时隙批次计算框架下，所有分配至无人机 j 执行的任务集合统一共享该处理器的全部算力资源。记在无人机 j 上执行的最终并发任务数为：

$$N_j(\mathbf{b}) = \sum_{m \in \mathcal{M}(t)} \mathbf{1}[b_m = j]. \tag{3.10}$$

当 $N_j(\mathbf{b}) \geqslant 1$ 时，各并发任务均分计算核心资源，分得的等效计算服务速率为 $f_{m,j} = F_j / N_j(\mathbf{b})$。对于卸载至宏基站的任务，宏基站配备性能极高的固定边缘服务器集群，总算力设为 $F_{\mathrm{M}} = 200\,\mathrm{GHz}$，为保障基站高并发处理能力，分配至宏基站的任务均获得等效峰值算力执行。

为简化数学书写，记任务上传时间为 $U_m = 8L_m/R^{\text{edge}}_{m,u_m}$，协作机间数据转发时间为 $I_{m,u,v} = 8L_m/R^{\text{inter}}_{u,v}$。三类执行路径的任务端到端完成时延解析模型表述为：

$$\begin{aligned} T_m^{\text{local}} &= U_m + (1-h_{u,s_m})V_{u,s_m} + \frac{C_m N_u}{F_u}, \\ T_m^{\text{coop}}(v) &= U_m + I_{m,u,v} + (1-h_{v,s_m})V_{v,s_m} + \frac{C_m N_v}{F_v}, \\ T_m^{\text{MBS}} &= U_m + \frac{8L_m}{R^{\text{bh}}_{u,\text{M}}} + \frac{C_m}{F_{\text{M}}}. \end{aligned} \tag{3.11}$$

将除计算执行阶段外的通信总时延记为 T_m^{comm}。当任务在无人机 j 上执行时，任务严格满足截止时限约束（$T_m \leqslant D_m$）的充要条件可解析转化为该节点允许并发承载的负载上限预算：

$$T_m \leqslant D_m \quad \Longleftrightarrow \quad N_j \leqslant \frac{F_j(D_m - T_m^{\text{comm}})}{C_m}, \qquad \text{当且仅当} D_m \geqslant T_m^{\text{comm}}. \tag{3.12}$$

式 (3.12) 直观展现了多维物理状态对服务质量的耦合影响：无人机靠近用户以提升接入速率、机间协同靠近以提升协同带宽，以及本地缓存命中消除回源时延，本质上均是通过大幅压缩通信时延 T_m^{comm}，从而为本地计算环节争取更充裕的时延容限，使节点能够并发容纳更多任务同时满足时限要求。

在系统能耗建模层面，计算与通信的物理能耗紧密关联。遵循 CMOS 芯片的动态功率模型，处理器的动态计算功率可表示为 $P^{\text{cmp}} = \kappa f^3$，其中 $\kappa = 10^{-27}$ 为芯片架构决定的开关电容系数。任务分配至无人机 j 执行所产生的动态计算能耗为：

$$E_m^{\text{cmp}} = P^{\text{cmp}} \frac{C_m}{f_{m,j}} = \kappa C_m f_{m,j}^2 = \kappa C_m \left(\frac{F_j}{N_j}\right)^2. \tag{3.13}$$

根据卸载决策目标的不同，各计算任务对机群引起的增量分配通信与计算能耗为：

$$\begin{aligned} E_m^{\text{assign,local}} &= (1-h_{u,s_m})P^{\text{bh,rx}}V_{u,s_m} + \kappa C_m (F_u/N_u)^2, \\ E_m^{\text{assign,coop}} &= (P^{\text{tx}} + P^{\text{rx}})I_{m,u,v} + (1-h_{v,s_m})P^{\text{bh,rx}}V_{v,s_m} + \kappa C_m (F_v/N_v)^2, \\ E_m^{\text{assign,MBS}} &= P^{\text{bh,tx}} \frac{8L_m}{R^{\text{bh}}_{u,\text{M}}}, \end{aligned} \tag{3.14}$$

其中机载无线发送功率为 $P^{\text{tx}} = P^{\text{bh,tx}} = 0.5\,\text{W}$，接收射频功率为 $P^{\text{rx}} = P^{\text{bh,rx}} = 0.1\,\text{W}$。

综合考虑接入数据接收能耗、内容分发能耗 E^{content}、平台机动飞行能耗 E_u^{motion} 以及无线供能能耗 E_u^{WPT}，机群在时隙 t 的单步完整全局运行能耗模型定

义为：

$$E^{\text{fleet}} = \sum_{m\in\mathcal{M}(t)} P^{\text{rx}} U_m + \sum_{m\in\mathcal{M}(t)} E_m^{\text{assign}} + E^{\text{content}} + \sum_{u=1}^{N} \left(E_u^{\text{motion}} + E_u^{\text{WPT}} \right). \quad (3.15)$$

其中，飞行与悬停机动能耗依据实际机动位移距离 $d_u = \|\mathbf{q}_u(t+1) - \mathbf{q}_u(t)\|$ 结算：

$$t_u^{\text{move}} = \frac{d_u}{v_{\max}}, \quad t_u^{\text{hover}} = \max(\tau - t_u^{\text{move}}, 0), \quad E_u^{\text{motion}} = 300 t_u^{\text{move}} + 150 t_u^{\text{hover}}, \quad (3.16)$$

式中 300 W 与 150 W 分别为无人机在满速水平机动和定点悬停状态下的基准气动功耗。若无人机当前关联有能量请求用户，机载专用供能天线启动无线充电，单步产生固定能耗 $E_u^{\text{WPT}} = P^{\text{W}}\tau = 50\,\text{J}$；受供用户据此获得能量补充 $E_m^{\text{harv}} = \eta_{\text{W}} P^{\text{W}} G_{\text{W}} g_{u,m} \tau$，进而驱动用户电池状态按物理充放电方程动态更新。

在缓存更新演化层面，每架无人机以滑动窗口统计各文件的请求频次 $\nu_{u,s}(t)$，按指数移动平均维护热度得分并在时隙末统一执行容量受限的缓存更新：

$$H_{u,s}(t+1) = \beta_c \nu_{u,s}(t) + (1-\beta_c) H_{u,s}(t), \qquad \beta_c = 0.75, \qquad \chi_{u,s}(t+1) = \frac{H_{u,s}(t+1)}{B_s}. \quad (3.17)$$

各机依据单位大小热度 $\chi_{u,s}$ 降序贪心缓存高价值文件，直至耗尽机载存储容量上限 S_u^{cache}。

3.1.4　评价指标与问题形式化

为严谨度量无人机集群对地面时限任务的服务保障能力，定义系统的核心端到端性能评价指标——截止期满足率（Deadline Satisfaction Rate, DSR）。在特定评估时间周期内，设地面用户实际生成的服务请求总数为 G，成功进入无人机自然覆盖范围并获得接入的请求总数为 A，而在其各自指定时限 D_m 内顺利执行完成的请求总数为 S。显然，这三项离散计数满足包含偏序关系 $0 \leqslant S \leqslant A \leqslant G$。据此，定义自然覆盖接纳率 α 以及接纳后按时完成率 η 为：

$$\alpha = \frac{A}{G}, \qquad \eta = \frac{S}{A}. \quad (3.18)$$

系统的端到端服务成功率 DSR 可以严格展开为接纳率与接纳后完成率的双因子乘积：

$$\text{DSR} = \frac{S}{G} = \frac{A}{G} \cdot \frac{S}{A} = \alpha \cdot \eta. \quad (3.19)$$

式 (3.19) 的乘积分解表明，端到端任务服务的失败总数 $G - S$ 可以无遗漏地分解为两类性质截然不同的物理成因：

$$G - S = (G - A) + (A - S), \quad (3.20)$$

其中第一项 $G - A$ 代表因空间覆盖盲区导致无法接纳的损失数，第二项 $A - S$ 代表虽然成功接入但因通信拥挤或算力不足导致计算超时的损失数。

除整体成功率外，系统兼顾长期运行中的跨用户服务公平性。引入 Jain 公平性指数（Jain's Fairness Index, JFI）：设 $K_m(t)$ 为用户 m 截止至时隙 t 累计成功获得按时服务的次数，定义相对服务率 $c_m(t) = K_m(t)/t$，则全网服务公平性定义为：

$$J(t) = \begin{cases} \dfrac{\left(\sum_{m=1}^{M} c_m(t)\right)^2}{M \sum_{m=1}^{M} c_m^2(t)}, & \sum_{m=1}^{M} c_m^2(t) > 0, \\ 0, & \sum_{m=1}^{M} c_m^2(t) = 0. \end{cases} \tag{3.21}$$

由柯西–施瓦茨不等式可知 $0 \leqslant J(t) \leqslant 1$。

在系统长期运行目标下，研究的核心问题是在保障无人机飞行物理约束的前提下，设计协同轨迹决策策略 π_θ，以最大化期望端到端截止期满足率，并兼顾机队运行能耗与服务公平性。该多目标协同优化问题形式化表述为：

$$\begin{aligned} \max_{\pi_\theta} \quad & \mathbb{E}_{\pi_\theta}\left[\frac{1}{T}\sum_{t=1}^{T}\left(\mathrm{DSR}(t) - \lambda_E E^{\mathrm{fleet}}(t) + \lambda_J J(t)\right)\right] \\ \text{s.t.} \quad & \mathbf{q}_u(t+1) = \mathbf{q}_u(t) + \Delta\mathbf{q}_u(t), \quad \forall u \in \mathcal{N}, t \in \mathcal{T}, \\ & \{\mathbf{q}_u(t+1)\}_{u=1}^{N} \in \mathcal{F}(\mathbf{q}(t)), \quad \forall t \in \mathcal{T}, \\ & \mathcal{U}_m(t) = \{u \in \mathcal{N} : \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\| \leqslant R_c\}, \quad \forall m \in \mathcal{M}, t \in \mathcal{T}, \\ & \Delta\mathbf{q}(t) \sim \pi_\theta(\cdot \mid \mathbf{o}(t)), \end{aligned} \tag{3.22}$$

其中 $\lambda_E, \lambda_J > 0$ 为能耗与公平性的权衡折算系数。

在上述优化框架中必须清楚厘定决策与环境状态边界：1. ** 决策控制量 **：上层强化学习策略输出的控制量严格限定为各无人机的水平间歇位移指令 $\Delta\mathbf{q}_u(t)$；2. ** 环境状态转移 **：下层卸载决策 $\mathbf{b}(t)$ 在移动前网络拓扑下由固定启发式分配策略根据估计通信时延和算力份额独立求得；地面用户的移动、请求到达以及电池充放电属于不可控的外生随机环境演化；3. ** 因果影响路径 **：轨迹动作 $\Delta\mathbf{q}(t)$ 决定无人机下一时隙的位置 $\mathbf{q}(t+1)$，从而直接改变下一时隙的覆盖集合 $\mathcal{U}_m(t+1)$ 与空天地信道增益。

由于端到端 DSR 具有复杂的延迟反馈与非线性比值特性，且系统具备部分可观测与多智能体协同特征，难以直接采用传统单步凸优化或离线混合整数非线性规划求解。为此，下一节将该问题转化为分散部分可观测马尔可夫决策过程，并提出基于需求感知注意力的协同轨迹规划方法。

3.2　基于需求感知注意力的协同轨迹规划方法

3.2.1　Dec-POMDP 协同决策建模

无人机集群在部分可观测空域中的分布式轨迹协同决策形式化为分散部分可观测马尔可夫决策过程（Decentralized Partially Observable Markov Decision Process, Dec-POMDP），由七元组 $\langle \mathcal{I}, S, \{\mathcal{O}_u\}, \{\mathcal{Z}_u\}, P, \{r_u\}, \gamma \rangle$ 描述：

- $\mathcal{I} = \{1, \cdots, N\}$ 为无人机智能体集合。
- S 为环境的全局物理真实状态空间，包含所有无人机与地面用户的三维空间坐标、各机载缓存状态向量、全部用户剩余电量以及全网并发生成的完整请求特征。
- $\mathcal{O}_u$ 为无人机 u 的局部观测空间，由自身机载传感信息以及局部通信范围内的环境信息组成。
- $\mathcal{Z}_u = \mathbb{R}^2$ 为无人机 u 的原始连续动作空间，表征水平面上的未受限机动指令采样向量。
- $P : S \times \mathcal{Z}_1 \times \cdots \times \mathcal{Z}_N \to \Delta(S)$ 为环境状态转移概率分布，由任务卸载执行、轨迹动作物理修复、用户自主游走以及新请求泊松到达共同驱动。
- $r_u : S \times \mathcal{Z} \to \mathbb{R}$ 为智能体 u 接收到的即时强化学习反馈奖励函数。
- $\gamma \in [0, 1)$ 为长期折现因子，本文取 $\gamma = 0.99$。

为引导分散部署的无人机集群在追求端到端 DSR 提升的同时兼顾机队能耗、服务公平性并抑制计算超时，设计了全局共享质量奖励项 r^{shared}：

$$r^{\text{shared}}(t) = W_{\text{fair}} J(t) - W_{\text{lat}} \bar{T}(t) - W_{\text{energy}} \bar{E}(t) - W_{\text{off}} \rho_{\text{off}}(t) + W_{\text{dsr}} \frac{S(t)}{G(t)} - 0.5 \rho_{\text{MBS}}(t), \tag{3.23}$$

各归一化因子的物理定义如下：

- $\bar{T}(t) = \sum_{m=1}^{M} T_m^{\text{metric}}(t) / (20M + \epsilon_0)$ 为全网时延惩罚项。对已关联用户 T_m^{metric} 取为真实完成时延，对未被覆盖的用户则施加 $T^{\text{pen}} = 20\,\text{s}$ 的未接纳超时惩罚；
- $\bar{E}(t) = E^{\text{fleet}}(t) / (5000N + \epsilon_0)$ 为基于参考基准无量纲化的单步机队总能耗；
- $\rho_{\text{off}}(t)$ 为结算后剩余电量跌破安全阈值 B_{low} 的低电量终端比例；
- $\rho_{\text{MBS}}(t)$ 为卸载回传至地面宏基站执行的任务占总生成请求的比例，用于抑制由于空中算力协调不力导致对地面骨干网的过度依赖；
- 权重系数经验设定为 $W_{\text{fair}} = 1, W_{\text{lat}} = 1, W_{\text{energy}} = 0.5, W_{\text{off}} = 5, W_{\text{dsr}} = 1$。

各智能体除了接收全局共享质量信号外，还需对自身的物理空间违例行为

承担明确的因果责任。智能体 u 的最终单步执行奖励 $r_u(t)$ 定义为：

$$r_u(t) = 0.1\left[r^{\text{shared}}(t) - 10\mathbf{1}[\text{boundary}_u] - 10\mathbf{1}[\text{collision}_u]\right], \tag{3.24}$$

其中 $\mathbf{1}[\text{boundary}_u]$ 与 $\mathbf{1}[\text{collision}_u]$ 分别为指示该智能体原始动作是否发生空域越界或与邻机发生间距冲突的指示函数。该奖励设计既保证了机群围绕全局服务效能开展协同探索，又通过负向惩罚迫使各智能体自主学习满足物理安全边界。

3.2.2 预接纳需求观测扩展机制

在传统的部分可观测设计中，无人机智能体的局部观测仅包含当前已经物理进入自身 $R_c = 100\,\text{m}$ 覆盖范围内的用户状态。然而，在自然覆盖机制下，这种输入设计面临着严重的信息盲区与状态混叠（State Aliasing）问题：若两个物理场景中无人机覆盖圆内部的已关联用户完全相同，但覆盖圆外部临近区域的需求分布截然不同（例如场景 A 外部存在密集的高负载热点，而场景 B 外部为空闲空域），在传统局部观测下，智能体接收到的特征向量完全一致。对于任何基于该观测的策略网络，其输出的机动动作概率分布必然完全相同。这意味着策略无法感知覆盖范围外的潜在需求分布，丧失了引导无人机主动向高需求聚集区机动的空间引导梯度。

为此，本章提出**预接纳需求观测扩展机制**。在保持上层策略网络输入维度和神经网络结构完全不变的前提下，利用无人机空空协同感知能力（感知半径 $R_s = 460\,\text{m}$），将空间中尚未被任何无人机接纳但处于感知范围内的潜在用户特征前瞻性地注入局部观测中。

如图 3.4 所示，单智能体的局部观测向量 $\mathbf{o}_u$ 保持固定 325 维定长格式，由三大结构化特征模块拼接构成：

1. **自身状态向量**（77 维）：包含无人机自身归一化二维水平位置 $\mathbf{q}_u/700$ 以及 75 维二值机载缓存状态指示向量 $\mathbf{h}_u$；
2. **邻居拓扑特征**（$4\times2=8$ 维）：感知范围内至多 4 架邻机相对于自身的二维相对水平坐标 $(\mathbf{q}_v - \mathbf{q}_u)/R_s$；
3. **用户需求特征槽位**（$30\times8=240$ 维）：固定设置 30 个用户特征槽位。单个槽位向量 $\mathbf{x}_{u,m}$ 由 8 维归一化特征构成：

$$\mathbf{x}_{u,m} = \left[\frac{\mathbf{w}_m - \mathbf{q}_u}{700},\ \frac{\text{type}_m}{2},\ \frac{L_m}{5\times10^6},\ \frac{s_m}{75},\ \frac{D_m}{2.10},\ \frac{p_m}{3},\ \frac{B_m^{\text{bat}}}{500}\right], \tag{3.25}$$

涵盖相对坐标、业务类型、数据大小、业务编号、时限要求、优先级以及电池电量。若对应槽位为空，则填充全零，并根据槽位绝对值和是否大于 10^{-5} 构造注意力前向掩码。

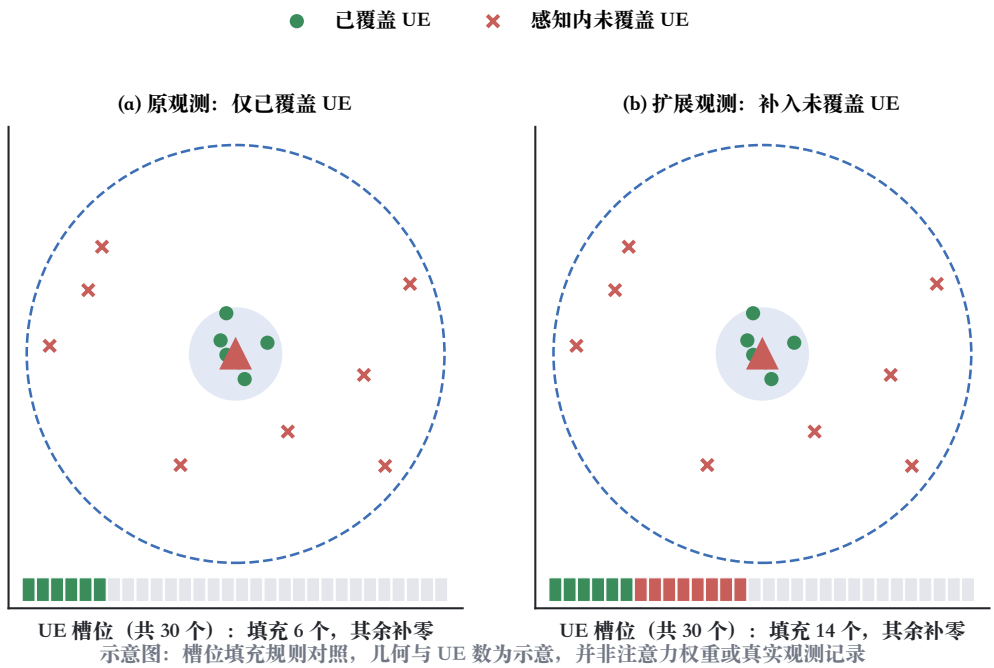


图 3.4　原始观测与扩展观测槽位对比图

Figure 3.4　Slot-Filling Comparison between Original and Extended Observations

表 3.1　上层单智能体观测空间维度构成

Table 3.1　Composition of Upper-Layer Single-Agent Observation Space

观测模块	物理特征内容	向量维度	构造与归一化说明
自身机载状态	自身二维水平坐标、机载缓存向量	$2+75=77$	坐标除以 700 m，缓存为 0/1 状态
邻居拓扑特征	协作感知内至多 4 架邻居相对位移	$4\times 2=8$	按感知半径 $R_s=460$ m 归一化
用户需求槽位	关联与预接纳用户需求及电量	$30\times 8=240$	固定 30 个槽位，全零填充并置注意力掩码
总计维度		325	输入形状固定，适配注意力网络

为确保观测构建的严格确定性与可复现性，扩展观测采用如下两阶段确定性排序与槽位填充算子：设 $\mathcal{A}_u$ 为当前物理关联至无人机 u 的用户集合，$\mathcal{V}_u^{\mathrm{un}}$ 为感知半径 $R_s=460$ m 内部且尚未被全网任何无人机覆盖的未接纳用户集合。最终注入 30 个用户观测槽位的有序列表 $\mathcal{L}_u$ 定义为：

$$\mathcal{L}_u=\mathrm{first}_{30}\left[\mathrm{sort}_{(d,\mathrm{id})}(\mathcal{A}_u)\,\|\,\mathrm{sort}_{(d,\mathrm{id})}(\mathcal{V}_u^{\mathrm{un}})\right], \tag{3.26}$$

其中 $\mathrm{sort}_{(d,\mathrm{id})}$ 表示首先以用户至无人机水平距离 $d=\|\mathbf{w}_m-\mathbf{q}_u\|$ 升序排序、距离相同则按用户固有编号递增平局决断的确定性排序算子；$\|$ 为列表拼接操作；first_{30} 截取前 30 个元素，不足 30 个则由空槽零填充。

该机制具有三个关键工程属性：

- **在网优先保障**：优先填满自身已关联用户 $\mathcal{A}_u$，保证网络不会因引入远端感知而牺牲对当前已接纳任务关键特征的感知；

- **物理覆盖边界严格不变**：预接纳用户的引入仅丰富了策略网络的“感知视野”，并未赋予这些远端用户在当前时隙上传数据的特权，其物理接纳门槛依然严格锁定为 $R_c = 100\,\mathrm{m}$；
- **网络架构严格兼容**：由于槽位数量固定为 30，策略网络输入维度恒定为 325 维，避免了随用户数量动态变化导致的神经网络维度伸缩问题。

3.2.3 多头注意力网络与协同决策架构

为在局部观测中高效解耦与自适应聚合邻机空间拓扑信息与地面海量需求特征，设计了基于多头交叉注意力（Multi-Head Cross-Attention, MCA）的 Actor 策略网络，如图 3.5 所示。

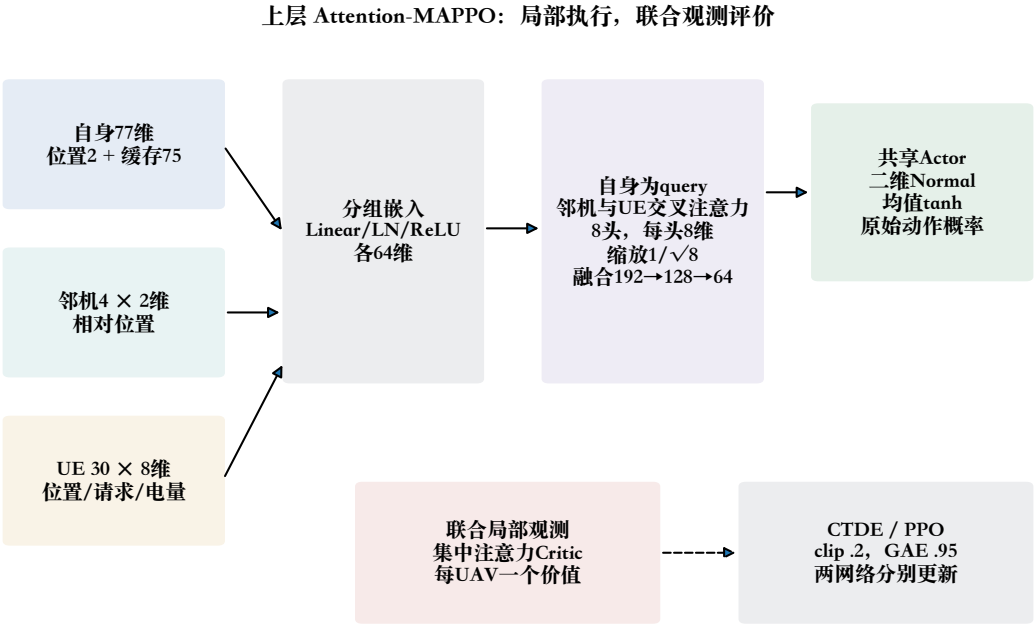


图 3.5 Attention-MAPPO 网络结构图

Figure 3.5 Network Architecture of Attention-MAPPO

注：实线表示前向推断信息流，虚线表示训练阶段集中式评价信息流。

在前向特征编码阶段，自身状态 $\mathbf{o}_u^{\mathrm{self}}$（77 维）、各有效邻机状态 $\mathbf{o}_{u,v}^{\mathrm{uav}}$（2 维）以及各有效用户槽位状态 $\mathbf{x}_{u,m}$（8 维）分别通过包含线性映射、层归一化（LayerNorm）与 ReLU 激活函数的独立编码器，映射为统一的 $d_{\mathrm{model}} = 64$ 维稠密特征向量，分别记为 $\mathbf{e}_u, \mathbf{e}_v, \mathbf{e}_m$。

以自身状态嵌入 $\mathbf{e}_u$ 作为查询（Query），分别针对邻机集合与地面用户需求槽位集合执行多头交叉注意力计算。以头数 $H = 8$ 为例，单头投影维度为 $d_h = d_{\mathrm{model}}/H = 8$。对于第 h 个注意力头以及目标实体 $i \in \mathcal{V}_u$（$\mathcal{V}_u$ 为非空邻机或

用户槽位集合），其查询、键（Key）与值（Value）表示为：

$$\mathbf{Q}_u^h = \mathbf{e}_u W_Q^h, \qquad \mathbf{K}_i^h = \mathbf{e}_i W_K^h, \qquad \mathbf{V}_i^h = \mathbf{e}_i W_V^h, \tag{3.27}$$

其中 $W_Q^h, W_K^h, W_V^h \in \mathbb{R}^{64\times 8}$ 为可学习参数矩阵。实体 i 分得的标量注意力权重 $a_{u,i}^h$ 经由 Scaled Dot-Product 与 Masked Softmax 计算：

$$a_{u,i}^h = \frac{\exp\left(\mathbf{Q}_u^h (\mathbf{K}_i^h)^\top / \sqrt{d_h}\right)}{\sum_{k\in\mathcal{V}_u} \exp\left(\mathbf{Q}_u^h (\mathbf{K}_k^h)^\top / \sqrt{d_h}\right)}. \tag{3.28}$$

第 h 头的加权上下文向量汇聚为 $\mathbf{c}_u^h = \sum_{i\in\mathcal{V}_u} a_{u,i}^h \mathbf{V}_i^h$。8 个头的上下文拼接后通过线性投影矩阵，分别输出邻机拓扑上下文表征 $\mathbf{c}_u^{\text{uav}}$（64 维）与用户需求上下文表征 $\mathbf{c}_u^{\text{ue}}$（64 维）。

在物理功能上，两大注意力分支具有清晰的分工：

- **邻机拓扑注意力**：自适应捕获邻机协同空间相对位移与潜在飞行冲突，为多机协同发散与防撞间距保持提供几何拓扑线索；
- **用户需求注意力**：从 30 个包含在网与未覆盖预接纳槽位中，自适应赋予高优先级、紧迫截止期或高聚集密度的未接纳热点区域更高的注意力权重，驱动特征表征向潜在需求质心聚焦。

最终，将自身特征 $\mathbf{e}_u$、邻机上下文 $\mathbf{c}_u^{\text{uav}}$ 与需求上下文 $\mathbf{c}_u^{\text{ue}}$ 拼接为 192 维融合特征向量，送入多层感知机（192 → 128 → 64）进一步提取抽象高层协同特征 $\mathbf{f}_u$。

在集中式训练评估阶段，为践行集中式训练与分布式执行（Centralized Training with Decentralized Execution, CTDE）范式，Critic 价值网络输入包含全网五架无人机的局部观测联合张量 $\mathbf{o} = [\mathbf{o}_1, \cdots, \mathbf{o}_N]$。Critic 采用智能体间交互注意力层，屏蔽自注意力后聚合协同全局特征，输出各机价值函数的标量基准估计 $V_{\phi,u}(\mathbf{o})$，以此大幅降低分布式强化学习中因环境非平稳性导致的回报估计方差。

3.2.4　Attention-MAPPO 训练与动作可行性处理

Actor 策略网络基于高层协同特征 $\mathbf{f}_u$，经由全连接层与 tanh 激活函数输出连续动作均值向量 $\boldsymbol{\mu}_\theta(\mathbf{o}_u) = \tanh(W_\mu \mathbf{f}_u + \mathbf{b}_\mu) \in (-1, 1)^2$；同时维护可学习且与状态解耦的对数标准差向量 $\log\boldsymbol{\sigma} \in [-20, 2]^2$。原始动作变量服从独立二维高斯分布采样：

$$\mathbf{z}_u \sim \mathcal{N}\left(\boldsymbol{\mu}_\theta(\mathbf{o}_u), \operatorname{diag}(\boldsymbol{\sigma}^2)\right). \tag{3.29}$$

其对应的原始对数采样概率为：

$$\log \pi_\theta(\mathbf{z}_u \mid \mathbf{o}_u) = -\sum_{k=1}^{2}\left[\frac{(z_{u,k}-\mu_{u,k})^2}{2\sigma_k^2} + \log\sigma_k + \frac{1}{2}\log(2\pi)\right]. \tag{3.30}$$

在实际物理环境中，高斯分布采样的原始未受限动作 $\mathbf{z}_u \in \mathbb{R}^2$ 并不能直接作为无人机飞控的位移指令执行。系统通过“坐标截断 → 径向模长缩放 → 交替几何投影”三级处理机制，将原始动作确定性地映射至可行位移集合 $\mathcal{F}(\mathbf{q}(t))$ 中：首先对动作做逐坐标截断 $\mathbf{a}_u = \mathrm{clip}(\mathbf{z}_u, -1, 1)$；随后通过径向非线性缩放算子，映射到满足最大平飞速度 $v_{\max}\tau$ 的物理速度圆内：

$$\widetilde{\Delta\mathbf{q}}_u = v_{\max}\tau \min(\|\mathbf{a}_u\|, 1)\frac{\mathbf{a}_u}{\|\mathbf{a}_u\| + \epsilon_0}. \tag{3.31}$$

随后，环境以建议位置 $\mathbf{q}_u(t) + \widetilde{\Delta\mathbf{q}}_u$ 为起点，实施多轮交替几何修复：依次执行区域边界框截断 $\mathcal{Q} = [50, 650]^2$、速度圆投影，并在检测到任意两机间距小于 $d_{\min} = 200\,\mathrm{m}$ 时沿中心连线实施对称外推。若交替修复达到 40 轮上限后仍存在潜在间距冲突，则强制冲突无人机回退至原位置保持悬停。修复完成后，记录越界和碰撞标志并计入即时奖励惩罚式 (3.24)，有效反哺策略抑制不可行探索。

在策略更新优化层面，对于各智能体收集的轨迹交互样本序列，计算时间差分（Temporal-Difference, TD）误差以及广义优势估计（Generalized Advantage Estimator, GAE）：

$$\begin{aligned} \delta_{u,t} &= r_{u,t} + \gamma(1-d_t)V_{\phi,u}(\mathbf{o}_{t+1}) - V_{\phi,u}(\mathbf{o}_t), \\ \widehat{A}_{u,t} &= \delta_{u,t} + \gamma\lambda_{\mathrm{GAE}}(1-d_t)\widehat{A}_{u,t+1}, \end{aligned} \tag{3.32}$$

其中 $\lambda_{\mathrm{GAE}} = 0.95$ 为 GAE 折扣衰减参数，d_t 为时隙终止标志掩码。

记重要性采样概率比为 $\rho_{u,t}(\theta) = \exp\Big(\log\pi_\theta(\mathbf{z}_{u,t} \mid \mathbf{o}_{u,t}) - \log\pi_{\theta_{\mathrm{old}}}(\mathbf{z}_{u,t} \mid \mathbf{o}_{u,t})\Big)$，Actor 策略网络的裁剪替代优化目标函数为：

$$L^{\mathrm{CLIP}}(\theta) = \widehat{\mathbb{E}}_{u,t}\left[\min\Big(\rho_{u,t}(\theta)\widehat{A}_{u,t},\ \mathrm{clip}(\rho_{u,t}(\theta), 1-\varepsilon, 1+\varepsilon)\widehat{A}_{u,t}\Big)\right], \qquad \varepsilon = 0.2. \tag{3.33}$$

结合策略熵正则项 $\overline{H}(\pi_\theta)$，Actor 总体最小化损失为 $-L^{\mathrm{CLIP}}(\theta) - \beta_H\overline{H}(\pi_\theta)$，其中熵系数取 $\beta_H = 0.005$。Critic 价值网络采用裁剪均方误差损失函数优化更新：

$$\begin{aligned} V_u^{\mathrm{clip}} &= V_u^{\mathrm{old}} + \mathrm{clip}\left(V_{\phi,u}(\mathbf{o}_t) - V_u^{\mathrm{old}}, -\varepsilon, \varepsilon\right), \\ L_V(\phi) &= \frac{1}{2}\widehat{\mathbb{E}}_{u,t}\left[\max\Big((V_{\phi,u}(\mathbf{o}_t) - \widehat{R}_{u,t})^2,\ (V_u^{\mathrm{clip}} - \widehat{R}_{u,t})^2\Big)\right], \end{aligned} \tag{3.34}$$

其中 $\widehat{R}_{u,t} = \widehat{A}_{u,t} + V_{u,t}^{\mathrm{old}}$ 为经验累积折现回报目标。完整的 Attention-MAPPO 算法训练流程如算法 3.1 所示。

算法 3.1　基于需求感知注意力的集群协同轨迹规划训练流程

Input: 自然覆盖仿真环境、训练随机种子、最大训练回合数 E、固定下层任务卸载策略

Output: Actor 共享策略参数 θ 与集中式 Critic 参数 ϕ

初始化 Actor 参数 θ、Critic 参数 ϕ、Adam 优化器以及经验重放缓冲区 $\mathcal{B}$;
for $e \leftarrow 1$ **to** E **do**
    重置仿真环境，生成初始用户位置、电量与首时隙服务请求，装配初始观测 $\mathbf{o}_1$;
    for $t \leftarrow 1$ **to** 1000 **do**
        各机根据局部观测 $\mathbf{o}_{u,t}$ 前向计算高斯分布参数，采样原始动作 $\mathbf{z}_{u,t}$ 并记录对数概率 $\log \pi_\theta(\mathbf{z}_{u,t} \mid \mathbf{o}_{u,t})$;
        Critic 利用联合观测 $\mathbf{o}_t$ 计算各机价值基准估计 $V_{\phi,u}(\mathbf{o}_t)$;
        固定下层任务卸载策略根据移动前网络拓扑解析已接纳服务分配 $\mathbf{b}(t)$;
        将动作截断值 $\mathrm{clip}(\mathbf{z}_{u,t}, -1, 1)$ 与卸载分配交付环境底层执行;
        环境先执行当前批次计算服务并结算时延能耗，随后执行式 (3.31) 径向缩放与几何交替修复施加物理位移，更新至 $\mathbf{q}(t+1)$;
        环境结算即时奖励 $r_{u,t}$、终止标志 d_t，更新用户电量、缓存并生成下一时隙观测 $\mathbf{o}_{t+1}$;
        将交互元组 $\langle \mathbf{o}_t, \mathbf{z}_t, r_t, \mathbf{o}_{t+1}, d_t, V_t \rangle$ 存入样本缓冲区 $\mathcal{B}$;
    end
    依据式 (3.32) 计算全序列的 GAE 优势值 $\widehat{A}_{u,t}$ 与回报目标 $\widehat{R}_{u,t}$，并执行优势归一化;
    for $k \leftarrow 1$ **to** 8 **do**
        从缓冲区 $\mathcal{B}$ 随机抽取大小为 256 的小批量样本;
        以 Adam 优化器分别更新 Actor 损失式 (3.33) 与 Critic 损失式 (3.34);
    end
    清空样本缓冲区 $\mathcal{B}$;
end

3.3 仿真实验与结果分析

3.3.1 实验环境设置与统计评价方法

为客观验证本文提出的预接纳需求感知协同轨迹规划方法的实际效能，在 Python 仿真平台上构建了高保真多智能体仿真测试环境。主场景的主要仿真参数如表 3.2 所示，上层 Attention-MAPPO 的核心超参数配置如表 3.3 所示。

表 3.2 主场景系统与网络仿真参数设置

Table 3.2 Simulation Parameters of Main System Setting

参数符号与名称	取值	参数符号与名称	取值
服务空域尺寸	$700\,\mathrm{m}\times 700\,\mathrm{m}$	决策时隙步长 τ	1 s
无人机数量 N / 地面用户数 M	5 / 100	单回合运行步数 T	1000
无人机巡航高度 H	100 m	最大平飞速度 $v_{\max}$	15 m/s
最小防撞间距 $d_{\min}$	200 m	用户单时隙最大位移	15 m
物理覆盖半径 R_c	100 m	协同感知半径 R_s	460 m
无人机算力集合 F_u	$\{40, 45, \cdots, 85\}$ GHz	机载缓存容量集合	$\{120, 121, \cdots, 179\}$ MB
宏基站中心算力 F_{M}	200 GHz	宏基站中心坐标	$(350, 350, 30)$ m
满速飞行 / 悬停功耗	300 W / 150 W	无线供能功率 / 转换效率	50 W / 0.8
服务 / 内容文件类别数	25 / 50	Zipf 流行度偏度 β	0.8
任务输入数据量 L_m	$1 \sim 5$ MB	任务截止时限 D_m	$0.65 \sim 2.10$ s
任务计算密度 ω_s	$1200 \sim 2800$ Cycles/Byte	任务优先级集合	$\{1, 2, 3\}$
用户电池容量 $B_{\max}$ / 门限	500 J / 50 J	用户静态能耗功耗	0.01 W
接入信道带宽 B^{edge}	40 MHz	机间协同带宽 B^{inter}	20 MHz
回传信道带宽 B^{bh}	0.75 MHz	发射功率 / 噪声功率	0.5 W / 10^{-13} W
热点数量 / 热点服务半径	2 / 100 m	热点聚集用户比例	85%

表 3.3 上层 Attention-MAPPO 关键训练超参数配置

Table 3.3 Key Training Hyperparameters of Upper-Layer Attention-MAPPO

超参数名称	设定数值	超参数名称	设定数值
强化学习折扣因子 γ	0.99	GAE 方差衰减系数 λ_{GAE}	0.95
PPO 替代目标裁剪阈值 ε	0.2	策略熵正则系数 β_H	0.005
Actor / Critic 初始学习率	3×10^{-4}	梯度全局范数截断阈值	0.5
样本收集 Rollout 步长	1000 步	单次采样更新轮数 Epochs	8
小批量随机梯度样本大小	256	注意力多头数 / 隐藏嵌入维数	8 / 64

性能评估采用两层聚合口径：评估单元内部按计数求比值，跨评估单元按等权求均值。评估单元定义为” 训练模型检查点 × 工作负载测试序列” 的配对测试实例，记测试集共含 I 个独立单元。在单元 $i \in \{1, \cdots, I\}$ 内，对 6 个测试回合的离散任务计数 G_i, A_i, S_i 聚合后，依式 (3.19) 得到单元级指标 $\alpha_i = A_i/G_i$、

$\eta_i = S_i/A_i$ 与 $\mathrm{DSR}_i = \alpha_i\eta_i$。跨单元等权平均端到端成功率为

$$\overline{\mathrm{DSR}} = \frac{1}{I}\sum_{i=1}^{I}\alpha_i\eta_i = \bar{\alpha}\bar{\eta} + \frac{1}{I}\sum_{i=1}^{I}(\alpha_i - \bar{\alpha})(\eta_i - \bar{\eta}), \tag{3.35}$$

其中 $\bar{\alpha} = \frac{1}{I}\sum_i \alpha_i, \bar{\eta} = \frac{1}{I}\sum_i \eta_i$ 分别为接纳率与完成率的跨单元算术均值。式 (3.35) 右端第二项为 α_i 与 η_i 的经验协方差：当高接纳率单元倾向于伴随较低完成率时，该项为负，使得 $\overline{\mathrm{DSR}} < \bar{\alpha}\bar{\eta}$。因此，仅报告 $\bar{\alpha}$ 与 $\bar{\eta}$ 的乘积将系统性高估真实平均成功率，本文所有跨单元聚合指标均直接对 DSR_i 等权平均。

实验评估采用两阶段协议（表 3.4）：探索性阶段以少量种子快速排查候选方案，独立确认阶段以全新种子验证结论的跨种子稳定性。独立确认阶段重新抽取 10 个训练随机种子与 5 个工作负载随机种子（均与探索性阶段无重叠），构成 $10 \times 5 = 50$ 个配对评估单元。

表 3.4　预接纳观测两阶段评估协议对比

Table 3.4　Two-Stage Evaluation Protocol of Coverage Observation Experiments

实验协议评估要素	探索性筛选实验	独立确认实验
策略训练独立随机种子	5 个	10 个（全新抽取，无重叠）
环境工作负载随机种子	5 个	5 个（全新抽取，无重叠）
单检查点测试评估规模	5 工作负载 × 6 episode	5 工作负载 × 6 episode
累计训练与测试规模	10 次训练 / 50 评估任务	20 次训练 / 100 评估任务 / 600 回合
对比方法唯一差异维度	仅改变上层观测槽位填充规则；下层架构及超参数完全相同且独立训练	
主统计推断单元	以 10 个训练随机种子平均差值为独立统计单元，配对 t 检验	
实验功能定位	快速排查与方案筛选	论文主要性能结论与统计置信度支撑

对于 10 个独立训练种子，记种子 k 在 5 个配对工作负载上的平均 DSR 差值为 d_k。以此 10 个差值样本计算均值 $\bar{d}$ 与样本方差 s_d^2，构造双侧配对 t 置信区间：

$$\bar{d} \pm t_{0.975,9}\frac{s_d}{\sqrt{10}}, \qquad s_d^2 = \frac{1}{9}\sum_{k=1}^{10}(d_k - \bar{d})^2. \tag{3.36}$$

3.3.2　传统局部观测瓶颈诊断

在自然覆盖基准下对传统局部观测方法（强基线）进行瓶颈诊断，共 25 个评估单元。基线方法的端到端平均 DSR 为 0.2459。

如图 3.6 所示，依据式 (3.20) 对所有未成功的服务请求进行因果解耦分类：在全网生成的全部计算请求中，成功进入服务流程但因通信或算力超时失败的请求数占总请求量的 27.27%；而处于所有无人机物理覆盖圆之外、因未被接纳而直接失败的请求数占比高达 48.14%。更为关键的是，在全网未成功处理的任务总数（即失败请求总量）中，**由于空间覆盖不足导致的未接纳请求占比高达** 63.84%，成为系统时限服务失败的绝对主导因素。

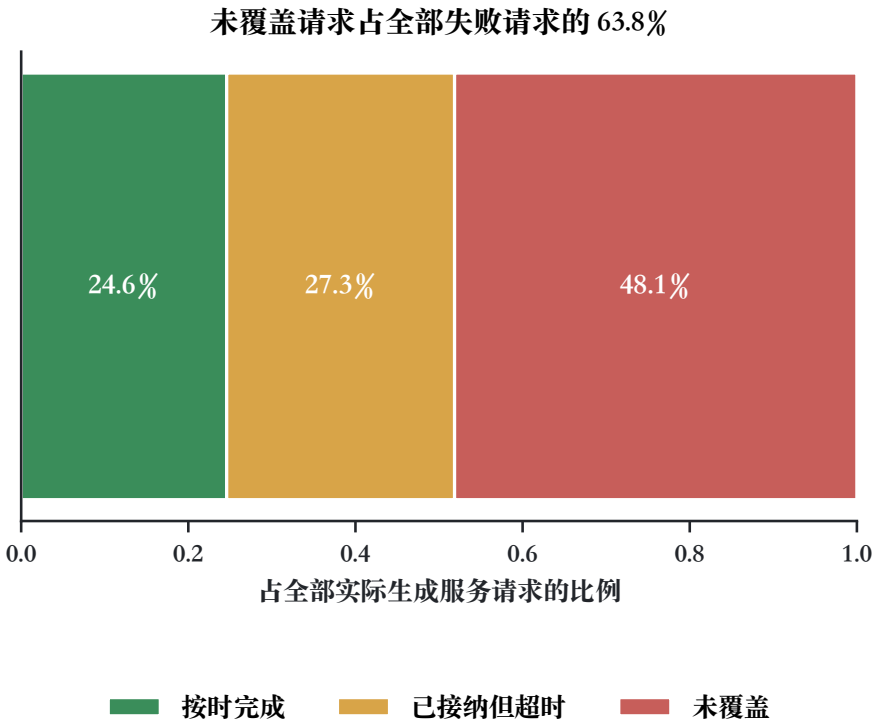


图 3.6　服务请求执行结果构成

Figure 3.6　Composition of Service Request Execution Outcomes

注：基于强基线瓶颈诊断批次中 25 个评估单元的统计汇总结果。

这一实证诊断有力证明：在自然覆盖约束的无人机边缘计算系统中，单纯通过下层调度策略优化算力分配或通信链路，其效能上限必然受制于极其有限的可接纳请求基数。由于传统局部观测对覆盖外需求完全处于盲区状态，机群无法自适应向地面高负载区域主动机动，导致大量计算资源闲置而覆盖外需求持续得不到接入。因此，打破局部观测的信息壁垒、赋予机群预接纳空间需求感知能力，构成了突破系统整体服务性能瓶颈的核心突破口。

3.3.3　独立确认实验结果

基于表 3.4 的独立确认协议，将需求感知扩展观测 Attention-MAPPO 方法与传统局部观测强基线进行配对比较。主场景的独立确认实验统计结果详见表 3.5。

实验数据表明，相较于传统局部观测基线，本文提出的需求感知扩展观测方法实现了端到端服务性能的显著跃升：系统的全局平均 DSR 从 0.2444 显著提升至 0.2793，取得了 +3.49 个百分点的绝对增益（相对提升幅度达 14.28%）；其以独立训练种子为样本的 95% 置信区间为 [+2.44%, +4.54%]，下界显著远离零点。在全部 10 个独立训练种子中，DSR 差值全部保持严格为正；在全部 50 个细粒度配对评估任务单元中，多达 49 个单元呈现正向性能增益。

图 3.7 展示了两种方法各 10 个独立训练种子的完整 200 回合训练过程，每

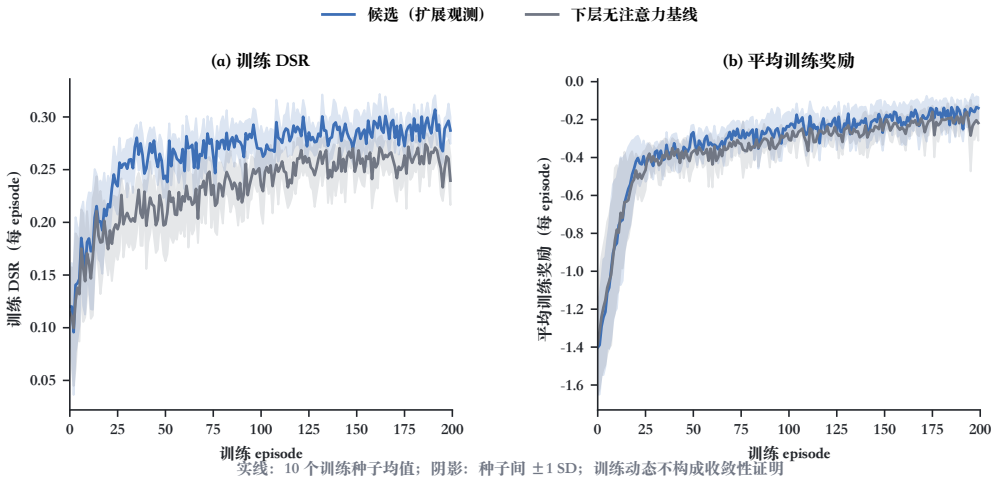


图 3.7　Attention-MAPPO 训练曲线

Figure 3.7　Training Curves of Attention-MAPPO

注：曲线与阴影区域分别表示 10 个独立训练种子的均值与标准差；(a) 训练 DSR 曲线；(b) 平均训练奖励曲线。

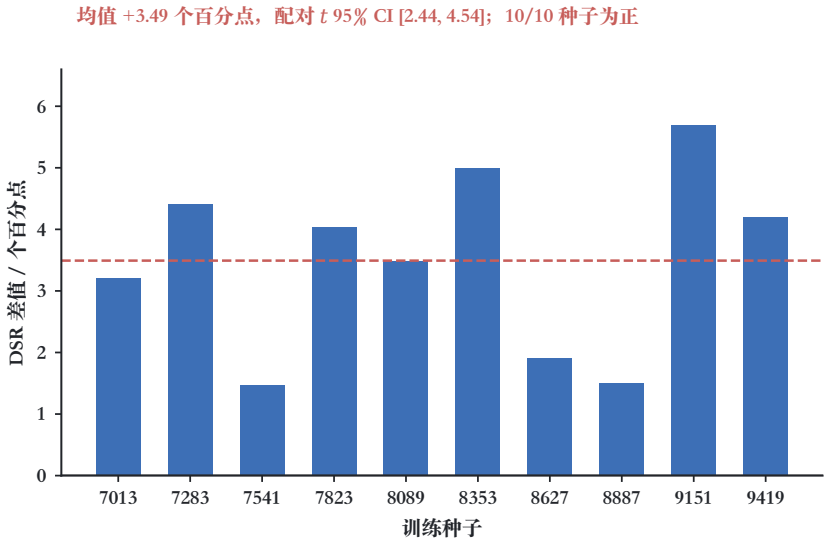


图 3.8　独立确认实验 DSR 配对差值

Figure 3.8　Paired DSR Differences across Seeds in Independent Confirmation Experiment

注：柱高表示各训练种子在 5 个配对工作负载上的平均 DSR 增益，红色虚线为跨种子均值。

表 3.5　独立确认实验核心性能指标对比
Table 3.5　Performance Comparison of Core Metrics in Independent Confirmation Experiment

核心评估指标	传统局部观测（强基线）	预接纳扩展观测（本文方法）	配对性能差值 [95% 置信区间]
端到端成功率 DSR = S/G	0.2444	0.2793	+0.0349 [+0.0244, +0.0454][a]
自然覆盖接纳率 $\alpha = A/G$	0.4996	0.6189	+0.1193
接纳后按时完成率 $\eta = S/A$	0.4919	0.4537	−0.0382 [−0.0752, −0.0012][a]
每单元单回合机队总能耗差	本文方法相对强基线净节能		-3.50×10^6 J
Jain 服务公平性指数差异	本文方法相对强基线净改善		+0.0786

[a] 表示以 10 个独立训练种子均值为统计样本计算的双侧配对 t 检验 95% 置信区间。表中数据均遵循先在每个评估单元内累计计数求比例、随后跨 50 个配对单元等权平均的严格统计口径。

回合包含 1000 个时隙。可以看到，相较于基线方法，扩展观测下的 Actor 在训练早期即展现出更陡峭的学习曲线，并以显著更小的跨种子方差收敛到更高的奖励水平。图 3.8 则进一步可视化了 10 个独立训练检查点配对差值的微观分布：10 个种子的配对差值全部为正，分布于约 +1.5 至 +5.7 个百分点之间（均值 +3.49 个百分点），充分排除了随机参数初始化波动带来的偶然性，证明了需求感知观测机制对协同轨迹策略学习的普适稳定性。

3.3.4　接纳扩展与接纳后质量机制分析

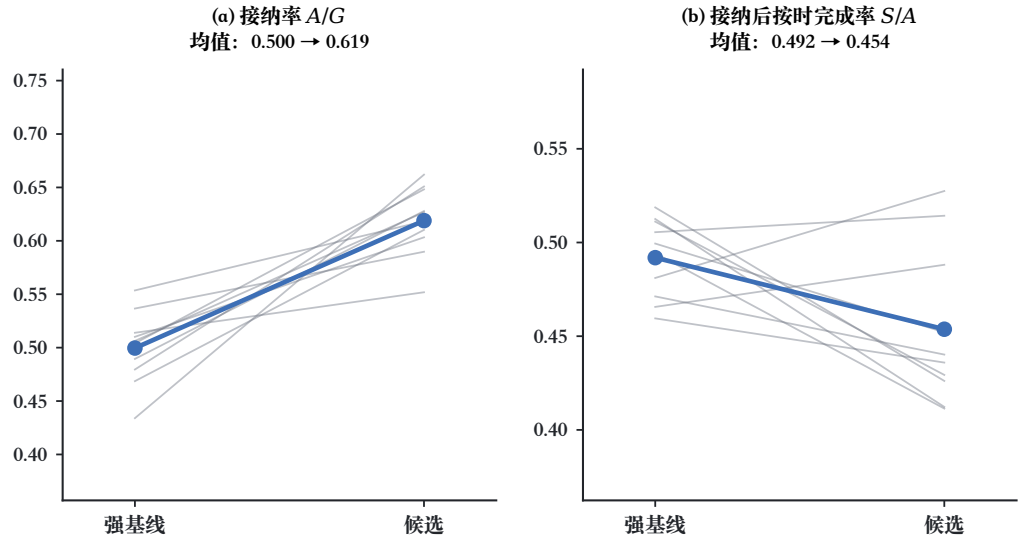
为深入揭示 DSR 取得 +3.49 个百分点增益背后的深层物理与系统机理，引入配对评估单元内的精确对称代数分解法。设候选方法与基线方法在配对单元 i 内的指标差值分别记为 $\Delta\alpha_i = \alpha_{c,i} - \alpha_{b,i}$ 与 $\Delta\eta_i = \eta_{c,i} - \eta_{b,i}$。通过在两方法的算术平均状态点展开，单元 DSR 差值可以精确恒等分解为：

$$\Delta\mathrm{DSR}_i = \underbrace{\Delta\alpha_i \frac{\eta_{c,i} + \eta_{b,i}}{2}}_{\text{接纳机会变动贡献项}} + \underbrace{\Delta\eta_i \frac{\alpha_{c,i} + \alpha_{b,i}}{2}}_{\text{条件完成质量变动贡献项}} . \tag{3.37}$$

展开式 (3.37) 右端，交叉乘积项严格抵消，两项代数和无残差恢复单元性能差值 $\alpha_{c,i}\eta_{c,i} - \alpha_{b,i}\eta_{b,i}$。

依据式 (3.37) 在全量 50 个配对评估单元中展开计算并平均，其分解结果具有极为深刻的物理内涵：

- **接纳率变动项贡献**：平均提供 +5.62 个百分点的正向增益。如表 3.5 所示，机群的物理服务接纳率 α 从 49.96% 大幅激增至 61.89%，净增长 11.93 个百分点。这证明预接纳需求观测扩展成功消除了局部盲区，引导机群高效向地面未覆盖热点机动，大幅扩大了可服务用户基数；
- **条件完成率变动项抵消**：平均产生 −2.13 个百分点的负向抵消。在成功接入的请求集合内部，按时完成率 η 从 49.19% 微跌至 45.37%（净变化 −3.82



灰线：10 个训练种子各自的配对连接（每种取 5 个工作负载均值）；蓝线：种子均值

图 3.9　接纳率与接纳后完成率对比

Figure 3.9　Comparison of Admission Rate and Conditional Completion Rate

个百分点）。

图 3.9 形象地刻画了这一反向演化动态：当预接纳感知驱动更多无人机覆盖地面高密度用户群后，单架无人机覆盖圆内的关联用户数显著上升，直接加剧了单节点内部两大资源的激烈竞争：一是根据式 (3.7)，有限接入带宽 B^{edge} 被更多用户时频分摊，导致单任务输入上传通信时延延长；二是根据式 (3.10)，更多本地任务涌入机载处理器，导致等效算力均分份额 $f_{m,j}$ 缩减，计算时延拉长。

接纳机会扩展贡献（+5.62 个百分点）超过并发拥塞折损（−2.13 个百分点），系统实现 +3.49 个百分点的端到端净增益。该分解揭示了增益的来源与代价，并指向后续章节的问题：本章的前瞻性协同轨迹规划解决了”进得来（接纳）”的物理瓶颈；接纳后加剧的并发计算与带宽竞争，由第四章跨机协同任务分配与第五章轨迹—卸载分层联合优化进一步化解。

3.3.5　机队能耗、服务公平性与适用边界

在实现端到端服务率提升的同时，系统在机队能耗控制与全网服务公平性方面亦展现出协同改善效益：

1. **机队运行能耗协同降低**：如表 3.5 所示，在单个评估单元（包含 6 个测试回合）内，本文方法相比基线平均节省机队总能耗 3.50×10^6 J，相对节能比例约为 6.37%。能耗的降低主要源于协同机动质量的提升：具备需求前瞻感知的机群能够更加有的放矢地向热点区域机动并平稳悬停服务，有效

避免了传统局部观测下由于目标缺失导致的多机盲目巡航与反复加减速机动；

2. **全网服务公平性显著提升**：全网 Jain 公平性指数由基线水平净提升 +0.0786。由于预接纳扩展机制在槽位填充中将协同感知范围内的远端低电量或未服务用户纳入输入特征，促使机群在空域部署上自适应兼顾散乱分布的边缘用户，有效缓解了算力向单一热点过度倾斜引发的马太效应。

在实际工程应用中，本文提出的需求感知协同轨迹规划方法具备明确的系统适用边界与前置物理假设：首先，该方法要求空域中存在可靠的空空协同通信机制，使无人机能够以一定的广播周期共享感知范围内的未接纳终端位置与请求元数据。该机制产生的轻量级信令开销在主实验中作为物理上层信令抽象保留，适用于通信条件较为稳定的无人机编队系统。其次，观测扩展的有效性依赖于地面存在动态需求非均匀聚集的时空特征。在用户极度稀疏或完全均匀分布的极端场景下，未接纳需求的空间导向性将被弱化。明确这些物理边界，有助于在更广泛的空天一体化计算网络中合理部署与评估本章方法。

3.4 本章小结

本章围绕时限边缘计算中无人机集群协同轨迹规划的自然覆盖接纳瓶颈，完成了从物理建模、问题形式化到方法设计与严密实验验证的系统性研究。

在建模层面，本章严密界定了由物理覆盖半径决定的自然覆盖接纳模型，明确了未覆盖请求在当前时隙无法被物理接入的根本限制，并确立了单时隙内移动前拓扑执行计算任务、轨迹动作驱动下一时隙覆盖演化的因果时序逻辑。通过细粒度瓶颈诊断，从实证角度首次确认：在传统局部观测策略下，覆盖盲区所引发的未接纳请求占全网失败总量的 63.84%，为后续将决策干预聚焦于上层轨迹感知提供了量化依据。

在方法层面，针对局部观测导致的状态混叠与需求盲区问题，本章提出预接纳需求观测扩展机制：在维持神经网络定长输入与计算复杂度完全不变的前提下，通过确定性槽位填充算子将协同感知范围内的未接纳需求前瞻性编码至决策输入，结合多头交叉注意力网络与交替几何投影动作修复算法，构建了兼顾全局效能探索与底层物理安全的 Attention-MAPPO 协同决策架构。

在验证层面，本章遵循严密的独立确认实验协议，测试结果证实本章方法将系统端到端 DSR 从 0.2444 显著提升至 0.2793，机队运行能耗同步降低 6.37%，服务公平性指数净提升 0.0786。通过对称代数分解进一步揭示了接纳机会扩展驱动整体性能跃升、伴生并发资源竞争加剧的深层物理机理，证明了前瞻感知对

突破自然覆盖约束的关键作用，并为第四章开展跨机任务协同精细化调度与第五章构建分层协同优化体系奠定了坚实基础。

第 4 章　考虑跨机资源竞争的无人机集群截止期优先计算任务分配

4.1　问题描述与跨机迁移外部性分析

第三章解决无人机集群通过空间部署接纳地面需求的问题，本章进一步研究已接纳计算任务在集群内部如何分担。请求接入某架无人机后，其执行节点仍可选择来源本机、允许的协作无人机或地面 MBS；本章沿用由 5 架无人机与 1 个地面 MBS 构成的六节点服务系统。执行位置会改变回源、机间转发、机载计算负载和能耗，因此跨机任务分配不仅涉及为单个请求选择最快节点，还涉及选择后整批请求如何分享各机算力：一项迁移可能使目标请求提前完成，也可能同时使迁入节点上多个原有请求超时。

这里的任务分配以不可拆分的计算请求为对象，关联无人机承担接纳与上传职责，执行节点承担计算职责。二者可以不同，因而集群具有在空间接入后继续协作分工的机会。不同无人机的算力、缓存与链路条件不同，地面 MBS 则作为六节点服务系统中的强算力支撑。本章保持这些既有资源规则，研究任务从一个执行节点转移到另一个节点时的系统后果；这与为飞行器分配巡检航点、侦察目标或编队位置具有不同的任务语义。

为在可控条件下比较不同分配方案，本章采用固定快照与反事实评价协议。固定快照指将某一时隙的 UAV 与 UE 历史几何、当前缓存、电量、请求集合及配置整体冻结；反事实评价指同一快照上的各候选分配均从完全相同的初始状态出发，由仿真环境执行整批请求，得到完成时延与 UAV 分配能耗。候选执行结果不回写采样所用的参考历史，下一快照仍取自同一参考控制轨迹。该受控设计将“执行目标选择差异”与“历史演化导致的状态差异”解耦，使候选分配之间具备直接可比性。固定快照下的研究问题为：在自然接纳与最终批量负载均分的条件下，以最小化超时请求数为首要目标的跨节点迁移搜索，能否较仅依据单请求自身代价的启发式获得更优的集群当步分工，以及该质量余量所需的能耗与求解时间代价。本章方法由此为集群任务分配提供受控分析框架，并在相同快照上给出可达分配质量的上界参照；第五章在此基础上构建在线下层，以配额搜索与条件匹配在有限决策预算内逼近上述质量参照。

4.1.1　固定快照反事实评价模型与决策变量

记当前接纳的服务请求集合为 $\mathcal{M}$，请求总数为 $K = |\mathcal{M}|$。地面 UE 总数记为 M，活跃请求由其在当前时隙泊松或流行度到达生成。每个请求 m 包含来源 UAV u_m、请求数据量 L_m、计算程序镜像大小 B_{s_m}、所需 CPU 周期数 $C_m = \omega_{s_m} L_m$ 以及硬性截止时间 D_m。每个请求的候选执行节点集合记为 $\mathcal{C}_m$，由来源本机、MBS 以及通信拓扑上允许的机间跳步邻居构成。整批任务分配决策向量记为 $\mathbf{a} = (a_1, \cdots, a_K)$，其离散决策空间定义为：

$$\mathcal{A} = \prod_{m \in \mathcal{M}} \mathcal{C}_m, \qquad |\mathcal{A}| = \prod_{m \in \mathcal{M}} |\mathcal{C}_m|. \tag{4.1}$$

当某协作节点的转发拓扑不可达、链路处于深衰落、目标机当前电量不足以支撑回源或 MBS 回传链路中断时，对应候选执行分支被判定为不可行并从 $\mathcal{C}_m$ 中剔除。这使得候选空间在搜索之初便严格限定在硬件可行域之内。

在固定快照测试中，无人机与终端的空间几何构型、信道大尺度衰落及小尺度信噪比状态被严格冻结。请求上传时延 U_m、协作转发时延 $I_{m,u,v}$、回源传输时延 $V_{j,s}$ 以及各节点的本地缓存命中指示变量 $h_{j,s} \in \{0, 1\}$ 均取自快照冻结值。每个候选执行路径的端到端时延仅取决于所选执行节点及其最终汇聚的并发任务负载。

4.1.2　实际服务路径与端到端时延推导

给定分配决策向量 $\mathbf{a}$，请求 m 的端到端时延随所选执行位置不同而由不同分量构成。若由来源本机执行（local），时延由无线接入上传、未命中时的回源与机载计算三部分构成；若由协作无人机执行（coop v），还需计入机间中继传输以及协作机未命中时的回源；若卸载至地面 MBS，则由无线接入、基站无线回传链路与基站服务器计算构成。据此，端到端服务时延的解析模型为：

$$\begin{aligned} T_m(\text{local}; \mathbf{a}) &= U_m + (1 - h_{u_m, s_m}) V_{u_m, s_m} + \frac{C_m N_{u_m}(\mathbf{a})}{F_{u_m}}, \\ T_m(\text{coop } v; \mathbf{a}) &= U_m + I_{m, u_m, v} + (1 - h_{v, s_m}) V_{v, s_m} + \frac{C_m N_v(\mathbf{a})}{F_v}, \\ T_m(\text{MBS}; \mathbf{a}) &= U_m + \frac{8 L_m}{R^{\text{bh}}_{u_m, \text{M}}} + \frac{C_m}{F_{\text{M}}}. \end{aligned} \tag{4.2}$$

式中 F_j 为无人机 j 的机载总计算频率，$F_{\text{M}} = 200\,\text{GHz}$ 为地面 MBS 的固定计算算力，$R^{\text{bh}}_{u_m, \text{M}}$ 为无人机至 MBS 的微波回传速率。

节点 j 承接的最终分配任务总数 $N_j(\mathbf{a})$ 及对应的任务索引子集 $\mathcal{M}_j(\mathbf{a})$ 由指

示函数定义为：

$$N_j(\mathbf{a}) = \sum_{m\in\mathcal{M}} \mathbf{1}[d_m(a_m) = j], \qquad \mathcal{M}_j(\mathbf{a}) = \{m : d_m(a_m) = j\}, \tag{4.3}$$

其中 $d_m(a_m)$ 表示动作 a_m 对应的物理执行节点。机载处理器采用多核动态并发或轮转均分机制：在全批次并发执行模式下，分配至节点 j 的每个任务均分算力 $f_{m,j} = F_j/N_j(\mathbf{a})$。根据互补金属氧化物半导体（CMOS）电路功耗特性与动态电压频率调节（DVFS）模型，节点 j 在均分算力下的单任务计算时延与能耗模型为：

$$T_m^{\mathrm{cmp}} = \frac{C_m N_j(\mathbf{a})}{F_j}, \qquad E_m^{\mathrm{cmp}} = \kappa C_m \left(\frac{F_j}{N_j(\mathbf{a})}\right)^2, \qquad \kappa = 10^{-27}, \tag{4.4}$$

式中 κ 为芯片有效开关电容系数。地面 MBS 由连续电网供电且算力池充裕，其等效算力不随批次任务数波动，计算能耗也不计入无人机集群的机载电池消耗。

4.1.3 批量算力共享下的跨机迁移外部性机理

式 (4.2) 与式 (4.4) 共同刻画了均分共享带来的一个关键性质：一旦机载计算资源在整批任务间均分共享，任何单个任务的执行节点变动都会改变分母中的并发负载 $N_j(\mathbf{a})$，从而对留在该节点上的其余任务产生时延外部性。

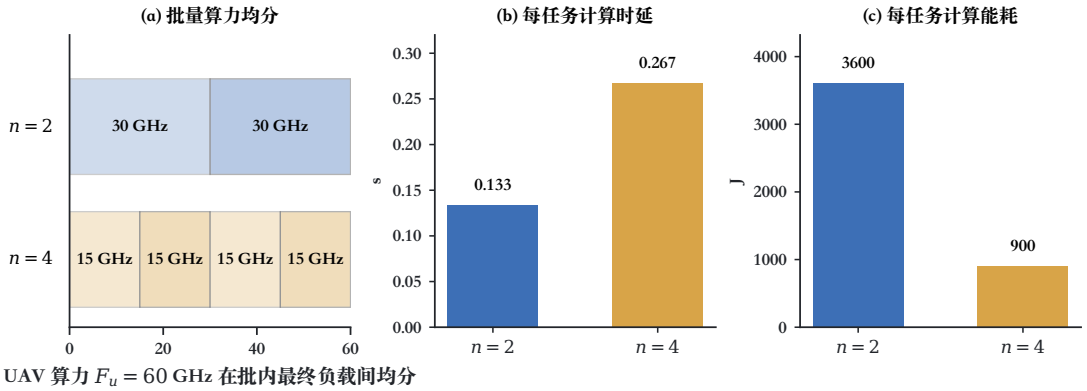


图 4.1 批量算力共享与任务迁移影响示意图

Figure 4.1 Schematic of Batch Compute Sharing and Migration Externality

注：图中数据为参数化构造示例（用于机理阐释），非实际仿真测量数据。

图 4.1 展示了这一外部性机理。考虑将任务 m 从来源节点 i 迁移至目标节点 j（$i \neq j$），迁移前两者的任务数分别为 $N_i = n_i \geqslant 1$ 与 $N_j = n_j \geqslant 0$。在两节点均为无人机的前提下，任务 m 的移出使来源节点 i 上未移动任务 $k \in \mathcal{M}_i \setminus \{m\}$ 的并发数由 n_i 减至 $n_i - 1$（当 $n_i \geqslant 2$ 时），每个任务分得的算力增加，计算时延随之缩短；相反，任务 m 的移入使目标节点 j 原有任务 $\ell \in \mathcal{M}_j$ 的并发数由 n_j 增

至 n_j+1（当 $n_j \geqslant 1$ 时），既有任务分得的算力被摊薄，计算时延随之增加。其余任务的计算时延边际变化为：

$$\Delta T_k^{\mathrm{cmp}} = -\frac{C_k}{F_i}, \quad k \in \mathcal{M}_i \setminus \{m\}; \qquad \Delta T_\ell^{\mathrm{cmp}} = \frac{C_\ell}{F_j}, \quad \ell \in \mathcal{M}_j. \tag{4.5}$$

式 (4.5) 表明：迁出给来源节点带来**正外部性**（加速未移动任务），迁入则给目标节点施加**负外部性**（延缓既有任务）。若目标节点为 MBS，其算力固定，迁入不产生负外部性；若来源节点原为 MBS，迁出也不为其他任务释放机载算力。

从机载计算能耗看，根据式 (4.4)，迁入使目标节点上既有任务的等效工作频率由 F_j/n_j 降至 $F_j/(n_j+1)$。当 $n_j > 0$ 时，既有任务 ℓ 的动态计算能耗比率为：

$$\frac{E_\ell^{\mathrm{cmp,new}}}{E_\ell^{\mathrm{cmp,old}}} = \left(\frac{F_j/(n_j+1)}{F_j/n_j}\right)^2 = \left(\frac{n_j}{n_j+1}\right)^2. \tag{4.6}$$

这反映出均分共享下能耗的非线性：任务迁入虽然延长了单任务计算时间，但降低了工作频率，单任务计算能耗反而呈平方级下降。类似地，来源节点剩余任务因工作频率升高，单任务动态能耗相应上升。

记 $Q_j = \sum_{m\in\mathcal{M}_j(\mathbf{a})} C_m$ 为节点当前时隙的总计算周期需求，则无人机节点 j 的总动态计算能耗可统一表示为算力、总周期数与并发数的函数：

$$E_j^{\mathrm{cmp}} = \psi(F_j, Q_j, N_j(\mathbf{a})), \qquad \psi(F,Q,n) = \begin{cases} \kappa F^2 Q/n^2, & n>0, \\ 0, & n=0,\ Q=0. \end{cases} \tag{4.7}$$

对于无人机节点间的 $i \to j$ 迁移，全系统动态计算能耗的净变化量为：

$$\Delta E^{\mathrm{cmp}} = \psi(F_i, Q_i - C_m, n_i - 1) - \psi(F_i, Q_i, n_i) + \psi(F_j, Q_j + C_m, n_j + 1) - \psi(F_j, Q_j, n_j). \tag{4.8}$$

进一步分析目标节点 j 迁入任务后的总能耗变化，可得到一个解析充要条件。由式 (4.7) 可知，迁入后总能耗严格小于迁入前的充要条件为：

$$\frac{\kappa F_j^2 (Q_j + C_m)}{(n_j+1)^2} < \frac{\kappa F_j^2 Q_j}{n_j^2} \iff n_j^2(Q_j + C_m) < Q_j(n_j+1)^2 \iff C_m < \frac{2n_j+1}{n_j^2} Q_j. \tag{4.9}$$

式 (4.9) 表明：当待迁入任务的计算量 C_m 低于该节点对应阈值时，向已有并发任务的节点迁入该任务不仅不会增加其总动态计算能耗，**反而会因工作频率被摊薄而使总动态能耗净下降**。这一与直觉相反的结果，源于均分共享下多机并发耦合的非线性。

从系统全局目标看，单任务迁移引起的平均归一化时延变化可分解为自身与外部性两部分：

$$\Delta F_2 = \frac{1}{K}\left[\frac{\Delta T_m}{D_m} - \sum_{k\in\mathcal{M}_i\setminus\{m\}} \frac{C_k}{F_i D_k} + \sum_{\ell\in\mathcal{M}_j} \frac{C_\ell}{F_j D_\ell}\right], \qquad K \geqslant 1, \tag{4.10}$$

式中 $\Delta T_m = T_m^{\text{new}} - T_m^{\text{old}}$ 为迁移请求自身的时延变化量。

更为关键的是第一优先级指标，即超时请求总数的变化。记请求 m 的超时指示函数为 $\mathbf{1}[T_m > D_m]$，则单任务迁移导致的超时增量为：

$$\Delta F_1 = \Delta \mathbf{1}_m - \sum_{k \in \mathcal{M}_i \setminus \{m\}} \mathbf{1}\left[T_k^{\text{old}} > D_k \geqslant T_k^{\text{old}} - \frac{C_k}{F_i}\right] + \sum_{\ell \in \mathcal{M}_j} \mathbf{1}\left[T_\ell^{\text{old}} \leqslant D_\ell < T_\ell^{\text{old}} + \frac{C_\ell}{F_j}\right]. \tag{4.11}$$

式 (4.11) 表明：即便迁移请求自身实现了由超时到成功的逆转（即 $\Delta \mathbf{1}_m = -1$），只要目标节点上因算力摊薄而新增的超时请求数比来源节点上因迁出而恢复的请求数多出 1 个以上，系统总超时数就会净增加（$\Delta F_1 > 0$）。

表 4.1 给出了一个构造的数值反例。如表 4.1 所示：待迁请求自身的时延由

表 4.1　自身改善与系统超时变化构造示例

Table 4.1　Constructed Example of Own-Request Improvement and System Deadline Misses

请求组	数量	截止期/s	迁移前时延/s	迁移后时延/s
待迁请求	1	1.25	1.30（超时）	1.22（成功）
来源其余请求	4	1.70	1.30	1.10
目标既有请求	3	1.00	0.90	1.10（超时）

1.30 s 降至 1.22 s，得以在截止期 1.25 s 前完成；而目标节点原有的 3 个紧迫请求，其时延由 0.90 s 增至 1.10 s，全部超出 1.00 s 的截止期。这使全系统超时数由 1 个增至 3 个。若算法仅依据被迁请求自身的时延或超时改善进行决策，就会落入这一外部性陷阱，导致系统整体性能劣化。这从机理上证明，自身局部改善并不等于系统全局改善，从而确立了在任务分配中实施全局重评估的必要性。

4.1.4　分配因果能耗与基准归一化

本章所关注的分配决策能耗，严格聚焦于因任务执行位置选择而引起的无线传输能耗与机载动态计算能耗之和：

$$E_{\text{assign}}(\mathbf{a}) = \sum_{m \in \mathcal{M}} E_m^{a_m}(\mathbf{a}), \tag{4.12}$$

其中单请求在来源机、协作无人机或 MBS 执行时的能耗 $E_m^{a_m}$ 包含接入上传、中继转发、镜像拉取以及机载动态计算能耗。在固定快照测试中，各无人机执行自然接入所需的固定空基接收能耗、按固定几何航向飞行的推进悬停能耗以及硬件底噪功耗，与当前任务分配动作 $\mathbf{a}$ 相互解耦，在所有候选分配方案中均属于严格等同的公共项；若将其并入目标优化，不仅会冲淡分配决策对实际电池寿命的边际影响，还会掩盖算法在节能分配上的真实性能差距。为统一各指标量纲，本

章定义归一化分配能耗指标为 $E_{\text{assign}}(\mathbf{a})/(25000\,\text{J})$，基准 25000 J 为单时隙集群机载能量基准参考。

4.2　基于全批次重评估的 MC-ITR 任务分配算法

4.2.1　严格字典序优化目标

在具有硬性截止期的边缘计算系统中，任务在截止期前的完成率是决定应急保障服务质量的绝对离散分水岭；超时时延的轻微减少并不产生边际价值。若采用固定加权和将超时数、连续时延与能耗强行混合，权重算法往往会为了追求微小的能耗节约而牺牲关键任务的截止期保障，且加权系数的选择极具主观盲目性。为此，本章构建严格字典序多目标优化框架，将超时请求总数置于最高优先级，在超时数完全相同时依次最小化平均归一化时延与归一化分配能耗：

$$F(\mathbf{a}) = \Big(\sum_{m\in\mathcal{M}} \mathbf{1}[T_m(\mathbf{a}) > D_m],\ \frac{1}{K}\sum_{m\in\mathcal{M}} \frac{T_m(\mathbf{a})}{D_m},\ \frac{E_{\text{assign}}(\mathbf{a})}{25000\,\text{J}} \Big), \qquad K \geqslant 1,\ D_m > 0. \tag{4.13}$$

对于两个候选分配方案 $\mathbf{a}'$ 与 $\mathbf{a}$，算法判定 $\mathbf{a}'$ 优于 $\mathbf{a}$（记作 $F(\mathbf{a}') <_{\text{lex}} F(\mathbf{a})$），当且仅当：

$$\exists p \in \{1,2,3\},\quad \big(\forall j < p,\ F_j(\mathbf{a}') = F_j(\mathbf{a})\big)\ \wedge\ F_p(\mathbf{a}') < F_p(\mathbf{a}). \tag{4.14}$$

该准则确保了第一目标（超时任务数）具有不可被第二、第三目标折衷的决定性优势；而在第一目标相同时，第二目标能够精细牵引未超时请求的时延裕度与超时请求的接近程度，避免搜索陷入平坦高原。

作为对比基准，定义单个请求自身的局部字典序代价为：

$$f_m(\mathbf{a}) = \left(\mathbf{1}[T_m(\mathbf{a}) > D_m],\ \frac{T_m(\mathbf{a})}{D_m},\ \frac{E_m^{\text{assign}}(\mathbf{a})}{25000\,\text{J}} \right). \tag{4.15}$$

在完全相同的候选空间与环境状态下，本章设置了四种具有代表性的分配决策方法展开对照，其核心特征归纳于表 4.2。其中，Heuristic-Control 沿用第三章启

表 4.2　四种计算卸载算法特性对比

Table 4.2　Comparison of Four Computation Offloading Methods

方法	初值	改进依据	终止与验证
Heuristic-Control	自身即初值	原启发式规则，不迭代	单次构造
Greedy-Single-Pass	Heuristic-Control	逐请求自身字典序代价	单轮顺序扫描
Iterative-Base	Greedy-Single-Pass	被迁移请求自身代价	自身无改善/环路/预算
MC-ITR	Greedy-Single-Pass	系统整体字典序目标	邻域无改善/预算退出

发式规则作为基准初值；Greedy-Single-Pass 从该初值出发，按任务顺序单轮扫

描，仅依据个体代价 f_m 贪心选择最佳执行节点；Iterative-Base 在 Greedy 基础上允许多轮迭代，但每次迭代仍仅依据个体代价 f_m 寻找改善迁移；而本章提出的 MC-ITR 算法与 Iterative-Base 具有相同的初值与 1-opt 邻域结构，唯一的核心差异在于将迁移判决依据彻底替换为全系统字典序目标 $F(\mathbf{a})$，以此严密受控地揭示“局部个体贪心”与“系统全局重评估”的本质性能分野。

4.2.2 MC-ITR 算法设计与执行流程

在当前分配方案 $\mathbf{a} = (a_1, \cdots, a_K)$ 下，改变单一任务执行节点的 1-opt 离散邻域定义为：

$$\mathcal{N}_1(\mathbf{a}) = \{\mathbf{a}^{m\to c} : m \in \mathcal{M},\ c \in C_m \setminus \{a_m\}\}, \tag{4.16}$$

其中 $\mathbf{a}^{m\to c}$ 表示将请求 m 的执行节点替换为 c、其余请求决策严格保持不变的邻居解。

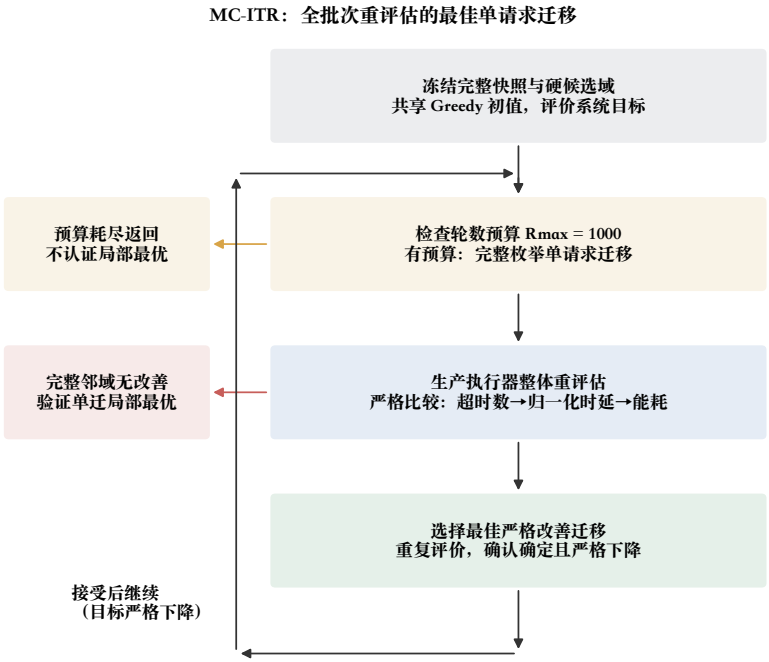


图 4.2　MC-ITR 算法流程图

Figure 4.2　Flowchart of the MC-ITR Algorithm

图 4.2 详细展示了 MC-ITR 算法的执行流程。算法从 Greedy-Single-Pass 产生的确定性分配出发，在每一轮迭代中遍历当前解的所有合法 1-opt 邻居；对于每个邻居解，调用仿真环境进行全批次反事实重评估，计算全系统字典序目标 $F(\mathbf{a}^{m\to c})$；在所有使系统目标严格改善（$<_{\text{lex}}$）的候选迁移中，选取改善幅度最大的动作实施迁移（Best-Improvement 策略）。若整个邻域内均无严格改善动作，

或达到预设最大轮数预算 $R_{\max} = 1000$，算法终止并输出最终分配向量。算法伪代码如算法 4.1 所示。

算法 4.1　MC-ITR：基于全批次重评估的最佳单请求迁移搜索

Input: 固定快照、候选域 $\{C_m\}$、共同贪心初值 $\mathbf{a}^0$、轮数预算 $R_{\max} = 1000$
Output: 分配向量、目标元组与终止原因

```
1  a ← a^0, v ← F(a);
2  for r ← 1 to R_max do
3      best ← ∅;
4      foreach m ∈ M, c ∈ C_m \ {a_m} do
5          v' = F(a^{m→c});
6          if v' <_lex v then
7              用键 (v', m, c) 更新严格改善中的最优候选;
8          end
9      end
10     if best = ∅ then
11         return 当前分配，原因“邻域无改善”;
12     end
13     接受最佳迁移并更新 a, v;
14 end
15 return 当前分配，原因“轮数预算”;
```

4.2.3　算法理论性质：严格下降、有限终止性与初值保护

在评价环境确定且无外部随机扰动的前提下，MC-ITR 具有以下完备的理论性质保证：

性质 1（字典序全序严格单调下降性）： 设算法执行过程中产生的分配序列为 $\{\mathbf{a}^r\}_{r=0}^{R}$，则对任意成功实施迁移的迭代步 r，均有：

$$F(\mathbf{a}^{r+1}) <_{\text{lex}} F(\mathbf{a}^r). \tag{4.17}$$

证明：算法第 14 行设置了显式判决门限 $\mathbf{v}' <_{\text{lex}} \mathbf{v}$。由于候选解仅在满足严格字典序更优时才被收录入 best 集合，且 Best-Improvement 选取的即为其中的最优项，因此每一次状态更新必然使系统目标在全序关系上严格下降。 ■

性质 2（有限步确定性收敛终止）： 在任意有限规模的固定快照上，MC-ITR 必在有限轮次内收敛终止于某一分配状态，绝不可能陷入无限震荡或死循环。证明：离散解空间的总状态数 $|\mathcal{A}| = \prod_{m\in\mathcal{M}} |C_m|$ 严格有限。根据性质 1，目标函数值在全序集中严格单调下降，因而同一分配向量 $\mathbf{a}$ 绝不可能在搜索序列中重复出现两次（否则将推出 $F(\mathbf{a}) <_{\text{lex}} F(\mathbf{a})$ 的自相矛盾）。由于不重复的离散状态序列长度必不超过 $|\mathcal{A}|$，且算法设有上界预算 $R_{\max}$，故算法必在有限步内终止。 ■

性质 3（初始解绝对保护）： 若算法由“邻域无改善”正常终止，则最终解

$\mathbf{a}^*$ 满足其 1-opt 邻域内的弱局部最优性：

$$\forall \mathbf{a}' \in \mathcal{N}_1(\mathbf{a}^*), \quad F(\mathbf{a}^*) \leqslant_{\text{lex}} F(\mathbf{a}'). \tag{4.18}$$

特别地，由于初值 $\mathbf{a}^0$ 处的邻域扫描亦遵循上述准则，因此最终解在字典序意义下绝不可能劣于初始解（即恒满足 $F(\mathbf{a}^*) \leqslant_{\text{lex}} F(\mathbf{a}^0)$）。

4.2.4 理论边界讨论：1-opt 局部最优为何不等同于全局最优

需要强调的是，性质 3 所确立的弱局部最优性受限于 1-opt 邻域结构，**并不等同于整个离散决策空间 $\mathcal{A}$ 上的全局最优解**。这是由于多机均分算力模型所固有的任务间强耦合性，在离散解空间中诱导出了多峰多谷的复杂拓扑。

表 4.3 单请求局部最优与全局最优抽象离散反例

Table 4.3 Abstract Discrete Counterexample Separating Local and Global Optima

分配向量	$(0,0)$	$(0,1)$	$(1,0)$	$(1,1)$
构造字典序目标	$(1, 1.00, 1)$	$(2, 1.20, 1)$	$(2, 1.20, 1)$	$(0, 0.80, 1)$
相对初始解邻域关系	初始解	单请求迁移	单请求迁移	两请求协同迁移

表 4.3 构造了一个简洁的抽象反例。设系统包含 2 个待分配任务，初始解为 $(0,0)$，其目标元组为 $(1, 1.00, 1)$。若仅迁移任务 1 到节点 1，解变为 $(1,0)$，由于算力分摊与通信开销，目标恶化为 $(2, 1.20, 1)$；类似地，单迁任务 2 得到的邻居 $(0,1)$ 亦恶化为 $(2, 1.20, 1)$。因此，在 $(0,0)$ 的 1-opt 邻域内没有任何改善解，MC-ITR 将在此直接判定收敛并终止。然而，若将两个任务**协同迁移**至 $(1,1)$，由于形成了规模效益并释放了原节点的算力，全局目标元组大幅优化至 $(0, 0.80, 1)$，总超时数清零。这表明：**由于 1-opt 搜索一次仅能翻转一个离散维度，无法跨越需多任务联合变动才能克服的离散多峰“能垒”，因而在理论上存在局部极小陷阱**。这一严谨的理论边界分析，客观界定了局部搜索算法的性能极限。

4.2.5 复杂度分析与实际调用开销

在算法复杂度方面，设单请求最大候选节点数为 $V_{\text{cand}} = \max_m |C_m| \leqslant 6$。当前解 $\mathbf{a}$ 的 1-opt 邻域规模为：

$$|\mathcal{N}_1(\mathbf{a})| = \sum_{m \in \mathcal{M}} (|C_m| - 1) \leqslant K(V_{\text{cand}} - 1). \tag{4.19}$$

在主配置 $K \approx 68$ 时，单轮迭代需重评估约 $68 \times 4 \approx 272$ 个候选状态。设算法在第 R_{term} 轮终止，则总评估次数为：

$$N_{\text{eval}} = R_{\text{term}} \cdot |\mathcal{N}_1(\mathbf{a})| \leqslant R_{\max} \cdot K(V_{\text{cand}} - 1). \tag{4.20}$$

每次全批次反事实评估需在仿真环境中重构整批请求的传输、回源与均分计算时间，单次评估耗时约为毫秒量级。在主实验中，MC-ITR 平均经历 3 到 6 轮迭代即可收敛，每快照搜索平均耗时为 2.574 s。这一分析表明：虽然 MC-ITR 通过 1-opt 贪心显著裁剪了遍历指数解空间 6^K 的组合爆炸，但秒级求解耗时依然限制了其在亚秒级在线控制环境中的直接部署。

4.3　仿真实验与结果分析

4.3.1　实验设置、基线与 410 网格统计协议

仿真场景严格继承第三章确立的应急空地协同通信与计算保障环境：5 架机动四旋翼无人机巡航于 100 m 固定高度，单机覆盖半径 100 m，感知半径 460 m，防碰撞最小水平安全间距 200 m；区域中心布设 1 座地面 MBS，配备 $F_{\mathrm{M}} = 200\,\mathrm{GHz}$ 服务器算力；地面分布 100 个 UE，按高斯随机航路点模型机动。服务请求按 $\beta = 0.8$ 的 Zipf 流行度规律动态生成，数据量在 $1 \sim 5$ MB，截止期跨度为 $0.65 \sim 2.10$ s。

为全面评测算法在不同网络工况下的有效性与稳健性，实验设计了包含 **410 个评测网格单元**（Grid Evaluation Units）的统计协议。该网格覆盖了：1. **主配置**：5 架 UAV、100 个 UE、标准算力配置；2. **UE 规模变体**：终端用户数分别扩展为 60、80、120 与 140 UE，考察网络处于欠载、标称负载与严重过载时的表现；3. **机载算力变体**：保持 100 UE 不变，将无人机计算频率统一缩放为标准值的 0.6、0.8、1.2 与 1.4 倍；4. **小规模精确验证配置（Exact-Small）**：针对 3 UE 极小规模设置穷举全局最优解（Exact）基准。

上述前 9 组配置分别对应 4 种算法（Heuristic-Control、Greedy-Single-Pass、Iterative-Base 与 MC-ITR），Exact-Small 包含额外的 Exact 穷举基准（共 5 种算法），总计构成 $9 \times 4 + 1 \times 5 = 41$ 个算法-配置实验组。每组实验配置跨越 10 个独立工作负载随机种子，每个随机种子测试包含 10 个快照，全实验集共采样处理了多达 4100 个独立测试快照。在统计组织上，所有算法在每个固定快照上均从严格等同的初始环境与状态出发，执行无状态回写的反事实评价，从而在统计学上保证了配对比较（Paired Comparison）的严密性与无偏性。

4.3.2　固定快照主配置性能对比与质量–能耗–耗时权衡

表 4.4 给出了固定快照主配置下四种卸载方法的各项性能指标统计均值。

结合表 4.4 与图 4.3 可以观察到：1. **截止期满足率的阶梯式提升**：MC-ITR 取得了最低的平均超时任务数（2.055），相较于基准 Heuristic-Control（2.908）大幅降低了 29.3%；较单轮贪心 Greedy-Single-Pass（2.243）降低了 8.4%；相较于

表 4.4　固定快照主配置下卸载方法性能对比

Table 4.4　Performance Comparison of Offloading Methods on Fixed-Snapshot Main Setting

方法	每快照平均超时数↓	归一化分配能耗	搜索耗时/s
Heuristic-Control	2.908	1.278	0.103
Greedy-Single-Pass	2.243	1.814	0.941
Iterative-Base	2.228	1.872	1.970
MC-ITR	2.055	2.128	2.574

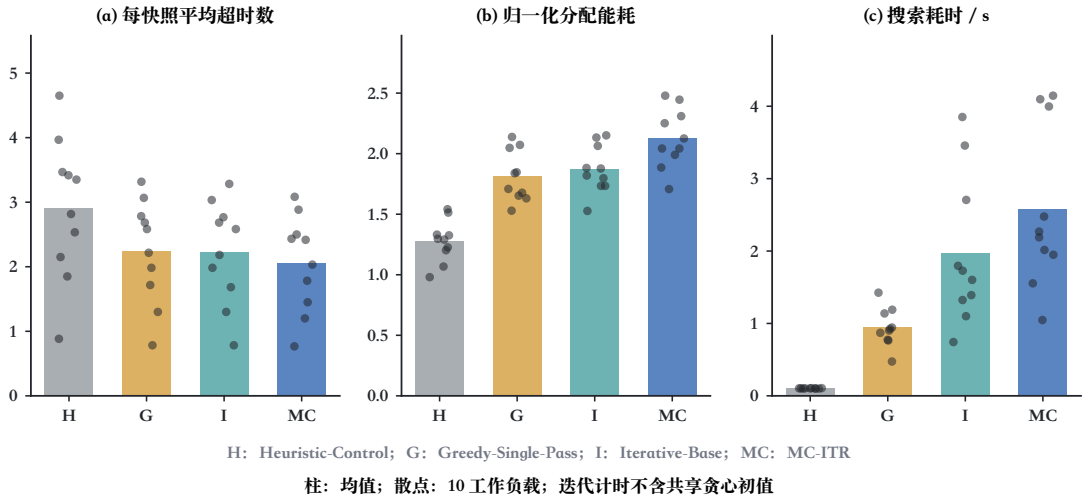


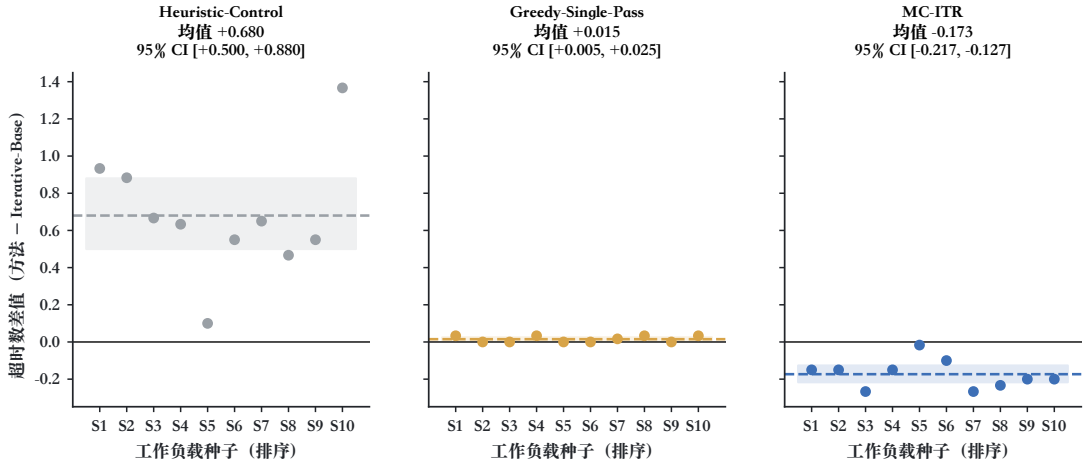
图 4.3　固定快照主配置下四种卸载方法性能对比

Figure 4.3　Performance of Four Offloading Methods on Fixed-Snapshot Main Setting

注：柱状图高度表示 10 个工作负载种子的均值，散点表示各单独种子测试值。

允许迭代但仅依据自身代价的 Iterative-Base（2.228），每快照平均超时数进一步净减少了 0.173 个（相对改善约 7.8%）。2. **局部贪心向全局重评估的演进收益**：Iterative-Base 相比 Greedy 仅有极其微弱的改善（从 2.243 到 2.228），表明在个体代价视角下，单任务由于无法预见迁入给其他任务造成的算力挤压，迭代极易被负外部性引发的“伪改善”所误导而迅速陷入局部陷阱；而 MC-ITR 依托全批次重评估，能够准确辨识出真正有利于系统全局的协同迁移动作，从而突破了个体贪心的瓶颈。3. **分配质量与机载能耗的客观权衡**：MC-ITR 超时数的显著改善并非毫无代价。随着更多原本因机载算力不足而超时的任务被积极迁移至远端协作无人机或地面 MBS，长距离无线中继与回源传输频次增加，导致 MC-ITR 的归一化分配能耗上升至 2.128，相较于 Iterative-Base（1.872）增加了约 13.7%。这符合字典序优化的数学定义：算法在第一优先级（超时数）未饱和前，会坚决动用能耗预算换取截止期达标率的提升。

为检验上述性能优势的统计显著性，图 4.4 报告了跨 10 个独立工作负载种



S1-S10：42、84、126、168、210、252、294、336、378、420；阴影：5000 次 bootstrap 的95%区间

图 4.4　相对 Iterative-Base 的每快照超时数配对差值

Figure 4.4　Paired Per-Snapshot Deadline-Miss Differences Against Iterative-Base

注：散点与虚线分别表示单种子值与均值，阴影区间表示基于 5000 次重抽样的 95% Bootstrap 置信区间。

子的 MC-ITR 相对 Iterative-Base 的每快照超时数配对差值 $\Delta_{\text{miss}} = \text{Miss}_{\text{MC-ITR}} - \text{Miss}_{\text{Iterative}}$。在所有 10 个测试种子上，配对差值均为严格负值；基于 5000 次 Bootstrap 重抽样计算得到的 95% 置信区间为 $[-0.217, -0.127]$，且单样本 t 检验的双侧 p 值远小于 0.001。这确凿证实了 MC-ITR 依靠全局重评估所取得的超时减少优势具有高度的统计可靠性，绝非随机抖动产物。

4.3.3　用户规模与无人机算力灵敏度分析

表 4.5 总结了在终端用户数与机载算力变体下，MC-ITR 相对基线 Iterative-Base 的超时数配对差值及搜索耗时。

结合图 4.5 与图 4.6，可得出以下深层次演化规律：1. **负载压力下的优势放大效应**：如图 4.5 所示，随着 UE 数量从 60 扩展至 140，网络并发任务数急剧增加，机载算力竞争更趋白热化。此时，MC-ITR 的超时优化差值从 −0.068 持续单调扩大至 −0.248。这表明系统负载越繁重，单任务盲目抢夺算力所引发的负外部性就越剧烈，而全局重评估对错峰调配算力的边际贡献也就越显著。2. **算力受限下的鲁棒防御表现**：如图 4.6 所示，当单机算力降至 0.6 倍标准值时，算力瓶颈迫使大量任务濒临超时边缘，MC-ITR 的优化差值达到峰值 −0.268；而在算力充裕（1.4 倍）时，绝大多数任务在本地即可顺利完成，外部性冲突缓和，各方法的超时数差距收窄至 −0.148。这充分证实 MC-ITR 在计算资源高度匮乏的严苛恶劣环境下具有极佳的保底价值。3. **规模扩展的计算代价非线性膨胀**：如表 4.5 右列所示，搜索耗时对用户规模呈现出超线性增长态势，UE 达 140 时单

表 4.5　各变体配置下 MC-ITR 相对基线超时数配对差值

Table 4.5　Paired Deadline-Miss Differences of MC-ITR Against Baseline Across Variants

变体	超时数差值 [95% 区间]	MC-ITR 搜索耗时/s
主配置（100 UE，标准算力）	−0.173 [−0.217,−0.127]	2.574
UE 60	−0.068 [−0.097,−0.042]	0.747
UE 80	−0.120 [−0.147,−0.092]	1.416
UE 120	−0.198 [−0.255,−0.142]	4.092
UE 140	−0.248 [−0.312,−0.183]	5.793
算力 0.6 倍	−0.268 [−0.348,−0.193]	2.744
算力 0.8 倍	−0.200 [−0.252,−0.147]	2.475
算力 1.2 倍	−0.157 [−0.207,−0.108]	2.599
算力 1.4 倍	−0.148 [−0.205,−0.102]	2.557

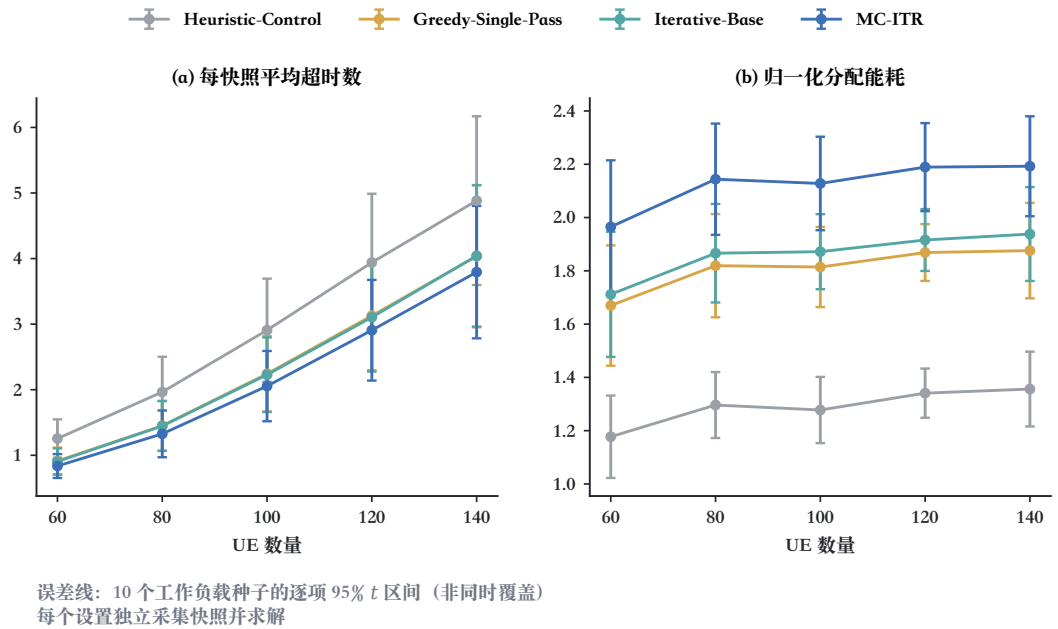


图 4.5　终端用户数量对超时数与能耗的灵敏度分析

Figure 4.5　Sensitivity of Deadline Misses and Energy Consumption to UE Count

注：误差棒表示 10 个工作负载种子的逐项 95% t 置信区间。

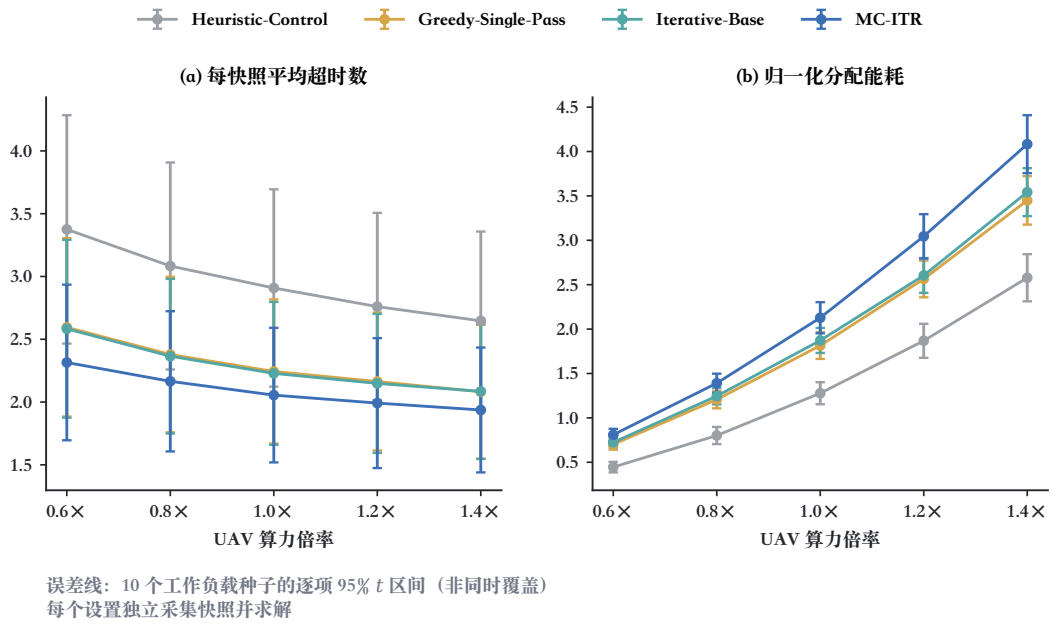


图 4.6　无人机计算能力对超时数与能耗的灵敏度分析

Figure 4.6　Sensitivity of Deadline Misses and Energy Consumption to UAV Compute Capacity

注：误差棒表示 10 个工作负载种子的逐项 95% t 置信区间。

步耗时增加到 5.793 s。这是由于候选邻域规模 $|\mathcal{N}_1(\mathbf{a})|$ 与请求数成正比，使得全批次重评估的仿真调用次数同步激增。

4.3.4　小规模精确解对比验证（Exact-Small）

为从算法实现和工程代码层面彻底排除潜在的逻辑漏洞，并严格验证离散邻域搜索对全局最优解的逼近能力，本节引入小规模精确解（Exact-Small）验证实验。在 3-UE 的极小规模场景下，候选解空间全排列规模收缩至 $|\mathcal{A}| \leqslant 6^3 = 216$ 的可遍历范围。此时可通过无放回的穷举搜索，在硬件可行域内求得真正的全系统全局最优解：

$$\mathbf{a}^{\mathrm{ex}} \in \arg\min_{\mathbf{a}\in\mathcal{A}}{}_{\mathrm{lex}} \quad F(\mathbf{a}). \tag{4.21}$$

图 4.7 展示了在 10 个随机种子、共 600 个小规模测试快照上的对比评测结果。在图 4.7(a) 所示的 600 个快照中，涵盖了单机独占、双机协作以及多机并发等多样化的拓扑构成。图 4.7(b)-(d) 结果表明：- 在第一目标平均超时数上，MC-ITR 测得值为 0.025，与 Exact 穷举基准的 0.025 **达到 100% 完全重合**；- 在第二目标平均归一化时延上，MC-ITR 均值为 0.0608，与 Exact 测得的 0.0608 严格吻合；- 在第三目标归一化能耗上，MC-ITR 测得值为 0.1542，与 Exact 亦完全相同。

在全部 600 个独立快照测试中，MC-ITR 均精准锁定了与穷举全局最优解完全相同的字典序目标向量，未发生任何一次求解发散或次优截断。这确凿证明

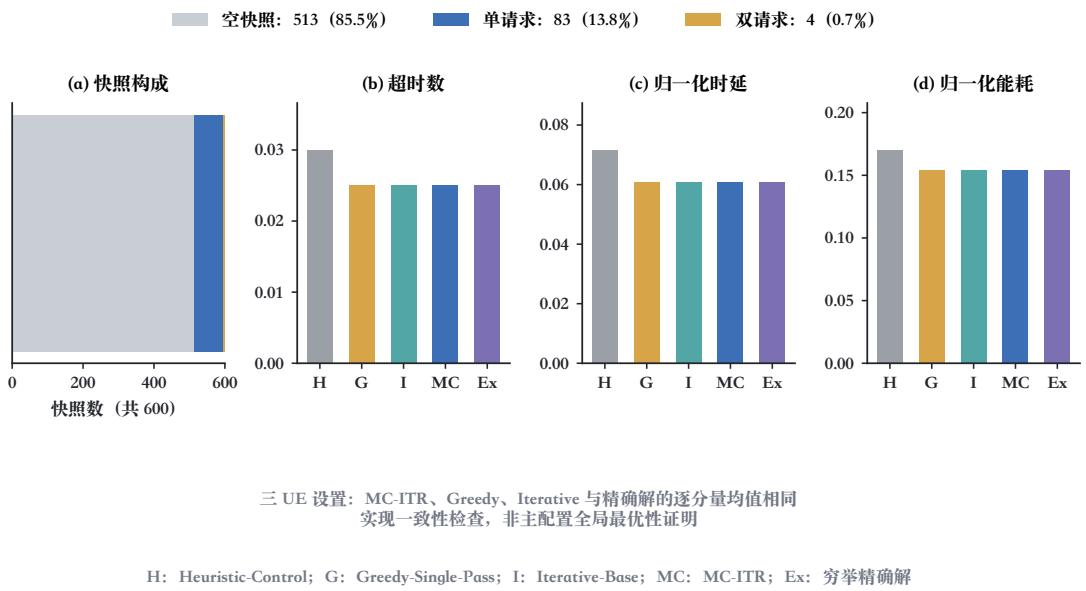


图 4.7　小规模配置下各算法与精确解性能对比

Figure 4.7　Comparison of Heuristic Algorithms and Exact Solution on Small-Scale Setting

注：(a) 600 个测试快照的构成分布；(b)-(d) 给出三用户规模下各方法在三个字典序分量上的均值表现。

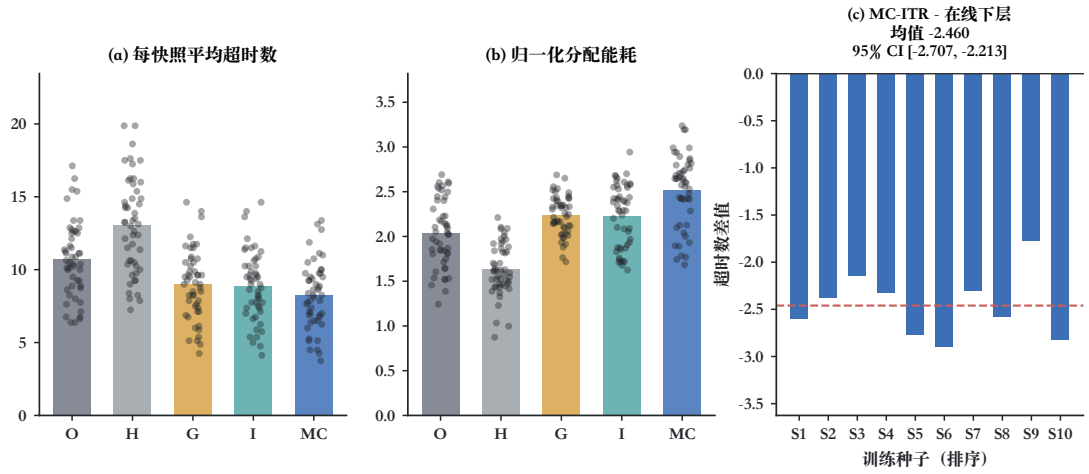
了本章构建的字典序评判函数、无副作用反事实仿真环境以及邻域状态更新逻辑在软件工程实现上具有无 Bug 的高度一致性与严谨性。同时，极小规模下启发式基线亦收敛于相同水平，说明小规模场景无法体现高维组合复杂度的挑战，从而进一步凸显了开展大规模网格仿真的必要性。

4.3.5　复杂需求感知学习轨迹下的分配余量验证与在线鸿沟

前述主实验快照均采集自 Heuristic-Control 控制器生成的参考运动轨迹。为进一步考察算法在上层强化学习智能体自主演化的复杂物理拓扑下的有效性，本节开展学习轨迹快照桥接实验。测试快照采自第三章训练得到的需求感知 Attention-MAPPO 上层轨迹（共 10 个独立训练种子，覆盖 5 种异构工作负载）。

如图 4.8 所示：在智能体动态规划的高异构空中网络状态上，MC-ITR 的平均每快照超时任务数进一步由基准的 10.771 骤降至 8.311，绝对降幅高达 2.460 个任务（相对改善幅度达 22.8%）。跨 10 个训练种子的配对 t 检验 95% 置信区间为 $[-2.707, -2.213]$，全部 10 个种子的配对差值均为严格负值。这雄辩地证实：即便在上层强化学习智能体已经优化了空间覆盖构型的前提下，下层已接纳任务的跨机分配依然蕴含着巨大的截止期质量优化余量。

然而，必须极其清醒地正视该离线算法与实际在线控制之间的**巨大时间鸿沟**：1. **反事实离线属性**：上述快照评价基于无副作用环境执行，分配结果未写回在线物理闭环的长期演化；2. **计算耗时壁垒**：计入启发式贪心初始化的 MC-ITR 完整调用均值高达 20.751 s，而在线下层神经网络单步前向推断耗时仅约为



O：在线请求级下层；H：Heuristic-Control；G：Greedy-Single-Pass；I：Iterative-Base；MC：MC-ITR

需求感知上层 + 无注意力请求级下层：50 评估任务 × 8 快照 = 400 快照
10 训练种子 × 5 工作负载；反事实分配未回写环境

图 4.8　需求感知轨迹下的固定快照分配性能对比

Figure 4.8　Fixed-Snapshot Allocation Comparison Along Demand-Aware Trajectories

注：基于 400 个固定快照测试；反事实分配结果不回写环境状态。

0.012 s，二者存在超过 **1700 倍**的巨大求解延迟差距！

在应急通信与计算保障场景中，无人机控制时隙通常为 1 s 甚至亚秒级。MC-ITR 的秒级计算开销显然无法直接充当在线实时决策器。这一深刻的计算开销矛盾揭示了离线全局搜索与在线实时决策的本质权衡：MC-ITR 可以作为衡量离线可达分配质量的上界标杆，但无法适应在线服务闭环。这为第五章构建计及软件决策开销的快速解析评分、有限预算配额匹配与能耗定价算法提供了不可替代的理论指引与工程动机。

4.4　本章小结

本章在固定历史状态的前提下，系统建立了计及机载算力均分与多机资源竞争的截止期优先计算任务分配优化问题：1. **机理揭示与数学建模**：推导了全批次算力共享下的服务路径时延与动态能耗模型，揭示了单任务迁移对未移动任务的边际外部性，从数学机理上严格证明了“单任务局部改善不等于系统全局改善”；给出了迁入任务导致节点总动态计算能耗不增反降的充要解析条件。2. **算法设计与理论保证**：提出了以全批次重评估驱动的 MC-ITR 最佳改善局部搜索算法；构建了严格字典序多目标优化准则，在无预算截断条件下严格证明了算法的字典序全序单调下降性、有限步终止性以及邻域弱局部最优性；通过离散反例深入剖析了 1-opt 局部搜索与全局最优解的理论边界。3. **多维实验与工程验证**：在涵盖 410 个评测网格单元的大规模仿真实验中，证实了 MC-ITR 在

主配置及八种物理敏感性变体下均能显著且稳健地降低平均超时任务数，但伴随着机载能耗的适度上升；Exact-Small 极小规模穷举实验在 600 个测试快照上实现了与全局最优解 100% 的完全重合，确凿排除了工程实现漏洞；需求感知轨迹桥接实验证实已接纳任务存在高达 22.8% 的分配质量优化余量。4. **承上启下**：MC-ITR 高达数十秒的求解耗时与在线控制所需的亚秒级预算构成了本质矛盾。本章方法由此确立为离线质量评估基准与理论分析工具；第五章将在此基础上引入计及决策软件开销的解析缓存混合评分、有限预算配额匹配与能耗定价机制，全面评估系统在长期动态闭环运行中的综合服务效能。

第 5 章　计及决策开销的无人机集群配额匹配与分层协同服务决策

5.1　研究问题与总体思路

第三章表明，需求感知轨迹能够增加自然覆盖形成的服务机会。接纳更多请求后，有限算力也面临更强的批量竞争：把一个请求转移到协作 UAV 会改变该节点所有请求的算力份额，其自身最短路径未必对应整个批次最多的按时完成数。第四章 MC-ITR 通过固定快照的整体重评估展示了分配质量余量，也揭示了秒级搜索与较高分配能耗的代价。该结果为在线任务组织提供动机，既不是在线性能上界，也不意味着 MC-ITR 已经接入本章系统。

调度过程本身还会消耗截止期余量。原 SF-HLM 学习配额变体在未计求解等待的十块确认中取得 34.244% DSR，共享强框架的配额随机为约 34.100%，学习额外增量约 0.143 个百分点。保留原状态与动作、事后加入逐次软件费用后，学习、强随机和贪心分别降至 29.379%、30.073% 和 32.161%。该排序反转说明，原批次分配质量不足以单独判断净服务收益；事后评分没有把费用回写状态，因而仍需另行开展计费闭环确认。原推导、十块结果及费用诊断见附录 A 和附录 B。

本章研究的问题是：自然覆盖形成服务机会之后，如何利用公开预测信息，在有限匹配预算与能耗取舍下组织整批任务，使计入决策耗时后仍有更多请求按时完成？为此，采用新训练后冻结的需求感知 Attention-MAPPO 上层，以下层解析缓存混合评分、条件匹配和开发阶段冻结的能耗价格组织当前批次。新主方法代码名为 `mixture_price`，下文称解析缓存混合＋能耗定价；原 Complete-QuotaPPO 仅作为原 SF-HLM 学习配额变体保留，不与该解析下层混称。MC-ITR 既不是在线执行器，也不是本轮方法的训练教师。

相关工作已将学习与用户关联匹配结合[34]，也已通过短尺度资源议价、卸载匹配及长尺度轨迹优化组织空地计算[35]，并有服务缓存学习与偏好匹配的联合方法[36]。本章据此把增量落实到具体执行问题：在规定的自然接纳及批量均分算力模型下，将配额条件化的请求身份指派、公开缓存分支评分和有限候选能耗选择连接起来，再以完整逐次软件费用进入反馈的闭环结果检验服务收益。这里的结构组合不构成对匹配、定价或分层思想本身的首创性主张。

统一以实际生成、接纳和按时完成服务请求数 G, A, S 定义

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A}, \qquad G > 0,\ A > 0. \tag{5.1}$$

该恒等式在一致计数口径内区分服务机会与接纳后质量；多块汇总时先在块内

计算，而不直接相乘跨块均值。本章预先指定解析主方法相对共同贪心 G、相对同框架二值价格策略的两项比较，用二十个全新上层训练块检验计费 DSR，同时报告机队能耗、MBS 依赖、公平性及软件耗时。

5.1.1 上下层分工与执行时序

上层各 UAV Actor 按规定局部观测分散推断二维轨迹动作，下层协调器集中读取当前公开请求和允许目标，输出完整任务映射。当前请求先按移动前几何接纳并执行，随后应用轨迹动作。冻结上层是冻结网络参数，不是固定空间轨迹；不同下层方法产生的缓存、电量与观测仍会影响后续上层动作。因此，同块共享检查点不能解释成所有方法始终共享同一状态。

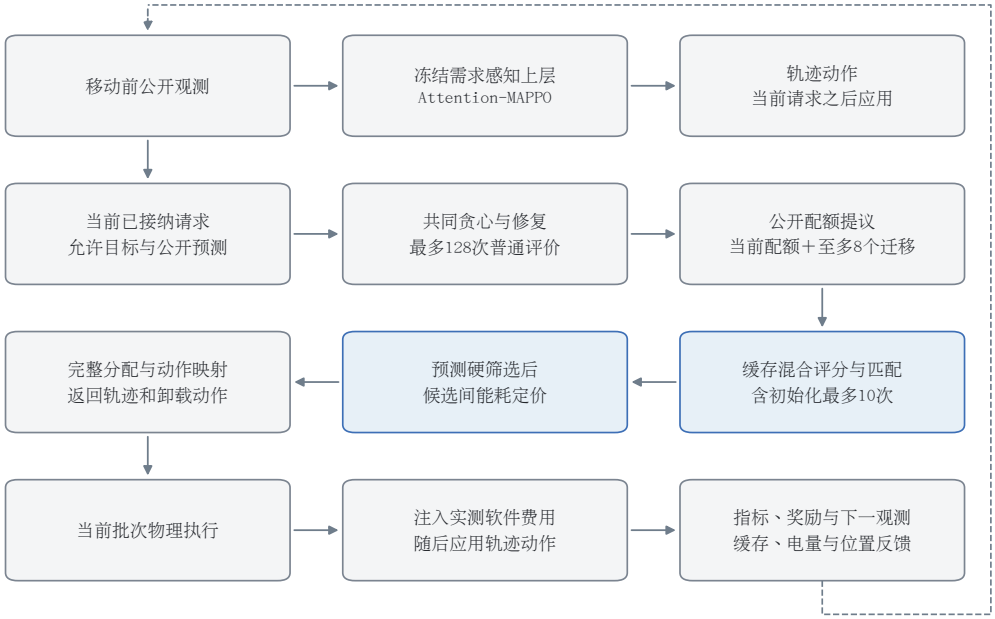


图 5.1 解析分层决策架构与软件费用反馈时序图

Figure 5.1 Analytical Hierarchical Architecture and Software Cost Feedback Timeline

注：闭环路径表示动态状态反馈机制，非上下层联合反向传播梯度。

图 5.1 给出从需求观测到任务执行的关系。每步采用规定批次模型，未完成任务不形成持续队列，下载事件也不持续占用后续时隙的资源。实际完整调用时间在物理执行之后、指标与奖励及下一观测形成之前加入当前请求时延，随后继续状态演化。该安排评价简化批次系统中的计费闭环收益，并未建立真实控制网络或连续队列模型。

5.2　分层结构与批量任务模型

5.2.1　请求集合、执行节点与质量掩码

在时隙 t，令已接纳服务请求集合为 $\mathcal{R}_t$，其规模为 R_t。为简化记号，本节省略 t。执行节点集合记作 $\mathcal{J} = \{0, 1, \cdots, 4, 5\}$，前五个编号对应 UAV，编号 5 对应 MBS。请求 m 具有输入大小 L_m、单位字节 CPU 周期数 ω_m、总计算周期 $C_m = \omega_m L_m$ 和截止时间 $D_m > 0$。服务类型索引记为 σ_m，其源 UAV 记作 u_m，允许执行节点集合记为 $\mathcal{J}_m \subseteq \mathcal{J}$。

允许集合由已有质量感知掩码生成，包含当前环境允许的本地、MBS 或协作动作。协调器将源 UAV 的动作编号映射为全局执行节点编号，以统一来自不同源节点的请求：源节点的动作 0 表示本地，而在全局表示中本地对应 u_m；动作 1 对应 MBS；协作动作对应目标 UAV 的全局编号。若不先完成这一步，来自不同 UAV 的两个“本地动作”可能被误计为同一节点，从而破坏配额守恒和算力共享计算。

请求按 UE 标识排序，各对照在相同状态下使用一致的输入顺序。所有已接纳请求均建立允许目标并参与分配；空批次直接返回空分配、零匹配调用及上层轨迹动作。

令 $x_{mj} \in \{0, 1\}$ 表示请求 m 是否被分配给节点 j。合法分配需满足

$$\sum_{j \in \mathcal{J}_m} x_{mj} = 1, \qquad x_{mj} = 0 \quad (j \notin \mathcal{J}_m), \qquad N_j = \sum_{m \in \mathcal{R}} x_{mj}. \tag{5.2}$$

其中 N_j 是节点的最终配额。式 (5.2) 同时表达不可拆分与完整分配：一个请求只能选择一个节点，每个已接纳请求都有去向。质量掩码限制允许目标，但并不保证最终共享负载下全部请求按时完成，这正是后续优化仍有必要的原因。

5.2.2　通信路径与预测量的分离

设请求 m 到其源 UAV 的上传速率为 R_m^{up}，源到目标 UAV j 的速率为 $R_{u_m,j}$，目标 j 到 MBS 的回传速率为 R_j^{bh}。字节到比特的转换必须显式保留：

$$T_m^{\mathrm{up}} = \frac{8 L_m}{R_m^{\mathrm{up}}}, \qquad T_{mj}^{\mathrm{hop}} = \frac{8 L_m}{R_{u_m,j}}, \qquad T_{mj}^{\mathrm{fetch}} = (1 - p_{mj}) \frac{8 B_{\sigma_m}}{R_j^{\mathrm{bh}}}. \tag{5.3}$$

B_{σ_m} 是服务文件大小，区别于任务输入 L_m；p_{mj} 是源节点关于执行节点服务缓存的信念。本地目标的 p_{mj} 取源节点自身缓存状态，协作目标取已有邻机缓存信念。T_{mj}^{hop} 仅在 $j \neq u_m$ 且目标为 UAV 时存在。上传链路沿用当前接纳关系和当前带宽共享规则，不能以待执行轨迹移动后的距离重算当前请求上传时间。

为使负载搜索与匹配使用同一模型，将每条合法边归纳为四个非负预测量

$b_{mj}, w_{mj}, e_{mj}, c_{mj}$。对 UAV 目标，定义

$$\begin{aligned} b_{mj} &= T_m^{\mathrm{up}} + T_{mj}^{\mathrm{hop}} + T_{mj}^{\mathrm{fetch}}, & w_{mj} &= \frac{C_m}{F_j}, \\ e_{mj} &= P_{\mathrm{bh,rx}} T_{mj}^{\mathrm{fetch}} + (P_{\mathrm{u,tx}} + P_{\mathrm{u,rx}}) T_{mj}^{\mathrm{hop}}, & c_{mj} &= \kappa C_m F_j^2. \end{aligned} \tag{5.4}$$

本地执行时令转发项为零。这里的 e_{mj} 只计 UAV 侧与分配相关的通信能耗，任务输入从 UE 上传的 UE 侧发射能耗不混入 UAV 分配能耗；来源 UAV 的共同输入接收能耗也排除，因为它不随卸载目标改变。F_j 为目标 UAV 的可用计算能力，κ 为计算能耗系数。所有合法边使用相同来源的物理参数与缓存信念，不为主候选构造更有利的预测器。

对 MBS，设源 UAV 回传任务的时间为 T_m^{bh}，MBS 算力为 F_{MBS}，则

$$b_{m5} = T_m^{\mathrm{up}} + T_m^{\mathrm{bh}} + \frac{C_m}{F_{\mathrm{MBS}}}, \quad w_{m5} = c_{m5} = 0, \quad e_{m5} = P_{\mathrm{bh,tx}} T_m^{\mathrm{bh}}. \tag{5.5}$$

MBS 计算时间直接进入 b_{m5}，没有再乘配额 N_5。因此 MBS 配额决定哪些请求走回传路径，不改变本实验规定的 MBS 单请求计算能力。该非共享规则是冻结物理模型的一部分，并不意味着现实基站总有无限并行处理能力。

5.2.3 最终负载共享下的时延与能耗

若 UAV j 最终收到 $N_j \geqslant 1$ 个请求，每个请求分得 F_j/N_j 的算力。将其代入计算时间和计算能耗模型，可以逐项得到

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{F_j/N_j} = \frac{C_m}{F_j} N_j, \qquad E_{mj}^{\mathrm{cmp}} = \kappa C_m (F_j/N_j)^2 = \frac{\kappa C_m F_j^2}{N_j^2}. \tag{5.6}$$

进而，合法边在给定最终配额下的预测完成时延与 UAV 分配能耗为

$$\widehat{T}_{mj}(N_j) = b_{mj} + w_{mj} N_j, \qquad \widehat{E}_{mj}(N_j) = e_{mj} + \frac{c_{mj}}{N_j^2}. \tag{5.7}$$

对于配额为零的节点，矩阵构造以 $\max(N_j, 1)$ 避免除零，但该节点不展开容量槽，所以没有请求实际被分配过去；MBS 在计算上述矩阵时统一使用有效负载 1，与式 (5.5) 一致。这个数值处理没有给空节点虚构请求，也没有改变守恒条件。

式 (5.7) 显示，增加一个任务会使节点上每个请求的预测计算时延增加 w_{mj}，而计算能耗项随负载平方下降。该模型中“把任务分散到更多节点”并不必然降低 UAV 计算能耗，因为更高的单请求算力份额可能增加平方能耗；同时，集中负载也可能降低能耗却增加超时。时延与能耗的这种结构性权衡使仅最小化单请求时延、仅最小化能耗或仅均衡任务数量都不足以直接解决截止期满足问题。

设分配 $\mathbf{x}$ 的预测超时数、预测分配能耗和平均归一化时延分别为

$$\begin{aligned} M(\mathbf{x}) &= \sum_{m,j} x_{mj}\mathbf{1}\{\widehat{T}_{mj}(N_j) > D_m\}, \\ E(\mathbf{x}) &= \sum_{m,j} x_{mj}\widehat{E}_{mj}(N_j), \\ Q(\mathbf{x}) &= \frac{1}{\max(R,1)}\sum_{m,j} x_{mj}\frac{\widehat{T}_{mj}(N_j)}{D_m}. \end{aligned} \tag{5.8}$$

普通修复按 (M,E,Q) 字典序比较，Q 作为其末级判别。新解析方法随后采用缓存混合评分条件匹配及候选价格选择，不继续用 (M,E) 概括其全部目标。截止期判断采用严格大于号，恰好达到截止时间计为按时。

5.3　缓存混合评分与条件匹配

5.3.1　从平均时延阈值到命中分支评分

公开缓存信念给出可能命中的权重，不能等同于当前真实命中。对于协作 UAV 边，平均预测时延低于截止期与两个分支的按时完成概率一般不同。作为示意例子，若命中和未命中时延分别为 0.4 s 与 1.4 s，命中信念为 0.8，截止期为 1 s，则平均时延加 10 ms 后仍低于截止期，二值目标记为成功；混合分数为 0.8。该例只说明阈值运算不与混合平均交换，不是实测状态，也不证明公开信念已经校准。

在给定节点配额 $\mathbf{N}$ 下，定义

$$s_{mj}(\mathbf{N}) = p_{mj}\mathbf{1}\{T^{\mathrm{hit}}_{mj}(N_j)+\delta_0 \leqslant D_m\}+(1-p_{mj})\mathbf{1}\{T^{\mathrm{miss}}_{mj}(N_j)+\delta_0 \leqslant D_m\}, \quad \delta_0 = 0.010\,\mathrm{s}. \tag{5.9}$$

δ_0 是开发阶段固定的名义软件费用，仅用于决策目标；实际评价使用当次完整实测费用 c_t^{sw}。二者不可替代，10 ms 也不是安全阈值。分数由已有预测量和公开功率解析分解，不访问当前真实缓存或尚未执行动作的反馈。它是公开模型下的成功分数，不能直接称为经校准的真实成功概率。

缓存信息的作用取决于截止期所在的位置。固定配额、名义费用和两个分支时延，记命中与未命中的按时指示为 I^{hit}_{mj} 和 I^{miss}_{mj}，式 (5.9) 可改写为

$$s_{mj} = I^{\mathrm{miss}}_{mj} + p_{mj}\left(I^{\mathrm{hit}}_{mj} - I^{\mathrm{miss}}_{mj}\right). \tag{5.10}$$

合法分解下未命中分支不快于命中分支，故只有三类情况：两个分支均按时，分数恒为 1；两个分支均超时，分数恒为 0；命中按时而未命中超时，分数等于 p_{mj}。最后一类才直接体现固定条件下信念对边成功分数的影响。因此，整体预测误差

的改善不必等量转化为截止期目标的改善；但该代数关系没有证明当前确认场景中的敏感边很少。

这一解释只针对边成功分数。缓存概率还参与预测通信能耗及候选筛选，其他边也可能改变同一批次的匹配结果，因此边分数不变不等于整批分配不变。若离线比较仅改变信念权重，应先用原公开输入解码并固定两个分支，再改变评分权重；直接替换输入概率后重新反演，会同时改变分支时延，不能解释为纯权重干预。

为说明解析分解的可识别条件，记回传接收功率为 r，两机转发的发送与接收功率和为 h，上传时间为 u，协作跳时间为 τ，平均文件获取时间为 f。已有合法边满足 $b = u + \tau + f$、$e = h\tau + rf$，从而

$$\tau = \frac{e - r(b-u)}{h-r}, \qquad f = b-u-\tau, \qquad b^{\mathrm{hit}} = u+\tau, \qquad b^{\mathrm{miss}} = b^{\mathrm{hit}} + \frac{f}{1-p} \quad (p<1). \tag{5.11}$$

上传锚点由本地边的 $b - e/r$ 或 MBS 边扣除回传时间及确定性计算时间得到，多个锚点须在实现容差内一致。命中与未命中分支再加相同的 wN_j 计算项；$p = 1$ 时须有零平均获取时间，直接使用命中分支。本地边和 MBS 边作为确定性边，沿用原预测加名义费用的阈值指示，不人为加入额外随机分支。

功率必须有限且为正，并满足 $|h - r| > 10^{-12}$；不满足可识别条件时实现拒绝该分解输入。对缺少或不一致上传锚点、负分解量、非法概率，以及 $p = 1$ 但获取时间非零的协作边，按源码回退为原平均预测时延加名义费用的二值指示，并记录原因。负量检查使用相对容差 10^{-8} 量级，容差内非负截断属于数值处理。公开解析规则避免额外拟合，但本轮确认没有单独验证信念精度是收益来源。

5.3.2 固定配额与容量槽展开

令六个执行节点的配额为 $\mathbf{N}$，则

$$\mathcal{N}_R = \{\mathbf{N} \in \mathbb{Z}^6_{\geqslant 0} : \textstyle\sum_{j=0}^{5} N_j = R\}, \qquad |\mathcal{N}_R| = \binom{R+5}{5}. \tag{5.12}$$

该数量忽略了允许域限制，是配额空间的上界。固定配额使最终批量共享项成为边的已知量，但在线预算并不允许穷举全部配额。配额控制节点接收的任务数，匹配则在同一配额内选择具体请求身份，二者承担不同任务。

对节点 j 展开 N_j 个槽，共形成 R 个容量槽。若槽 s 对应 $j(s)$，以 y_{ms} 表示请求占槽，条件指派约束为

$$\sum_{s} y_{ms} = 1, \qquad \sum_{m} y_{ms} = 1, \qquad y_{ms} = 0 \ (j(s) \notin \mathcal{J}_m), \qquad y_{ms} \in \{0,1\}. \tag{5.13}$$

每个请求恰好占据一槽，完整合法解自动满足配额守恒。仅检查各节点合法边数

还不足以确认可行，因为不同节点可能依赖同一批请求。实现调用线性指派接口[42-43]后再次核对所有请求、允许域和实际节点数量；不可行候选不进入候选池，相应调用仍计入预算。

这里求解的是给定配额与边成本下的线性指派。张秋平等基于请求和设备双方偏好构造卸载匹配[36]，TJCCT 也以多对一匹配协调设备与计算服务器[35]。这些方法的偏好及稳定性性质不能直接作为本章标量成本最小化或真实按时成功数最优的证明。

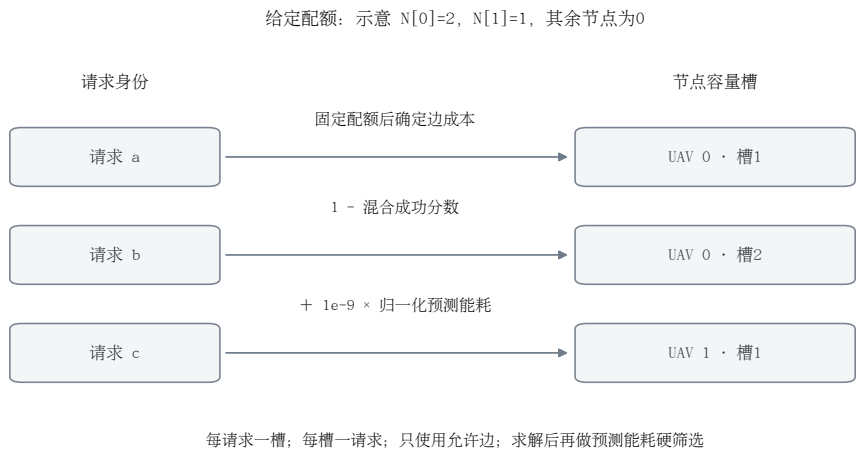


图 5.2　基于固定配额的容量槽分配示意图

Figure 5.2　Schematic of Capacity Slot Allocation under Fixed Quotas

5.3.3　实际标量成本及其条件性质

给定配额，用全部合法边的预测分配能耗最大值归一化，令

$$E_{\max}(\mathbf{N}) = \max_{m,j\in\mathcal{J}_m} \widehat{E}_{mj}(N_j), \qquad \widetilde{E}_{mj} = \frac{\widehat{E}_{mj}(N_j)}{\max(E_{\max}(\mathbf{N}), \epsilon_E)}. \tag{5.14}$$

ϵ_E 为浮点最小正正规数。实际混合指派使用

$$C_{ms} = 1 - s_{m,j(s)}(\mathbf{N}) + 10^{-9}\widetilde{E}_{m,j(s)}, \qquad \min_{\mathbf{y}} \sum_{m,s} C_{ms} y_{ms}, \tag{5.15}$$

非法边置无穷成本。10^{-9} 项是实现中的能耗微扰，不能对连续实数分数无条件解释成严格字典序。两个分配的分数差若足够小，微扰和浮点舍入可能影响排序；本章只主张给定配额、公开矩阵及已定义标量成本下的条件指派性质。

作为二值对照，`binary_price` 使用平均预测时延加 δ_0 的成功指示，指派成本为 $(R+1)(1-s)+\widetilde{E}$。二值失败数差至少为 1 而归一化能耗和差不超过 R，因此固定配额内可作失败数优先的字典序论证；该证明见附录 A，不移植到式 (5.15)。两个策略另有各自开发冻结价格，其比较也不是只改变评分组件的纯因果消融。

预测能耗硬筛选在匹配之后进行。若该配额的标量最优匹配超过共同预测上限，实现拒绝它，而不在同配额内继续寻找其他满足上限的次优分配。因此，本方法既不精确求解带能耗约束的指派问题，也不保证整个配额空间、真实缓存或真实超时数全局最优。可验证的性质限于完整分配、允许域合法、配额守恒和明确成本下的条件求解。

5.4 有限匹配预算与能耗价格

5.4.1 共同初始化与公开配额提议

共同贪心按固定请求顺序，以加入后的请求自身预测时延、能耗和动作编号依次决胜，得到原始分配 $\mathbf{x}^{\mathrm{g}}$。以其最终批量重评估能耗定义

$$E_{\mathrm{cap}} = 1.05E(\mathbf{x}^{\mathrm{g}}). \tag{5.16}$$

随后执行最多 128 次普通候选评价的单请求修复，得到共同保底 G。该 128 次上限属于修复评价预算，与线性匹配调用预算分开计数；并不表示扫描了完整迁移邻域。保底只保证存在可返回分配，不保证最终所有实际指标均不劣于 G。

搜索对象保留六节点配额结构。共同初始化先对 G 的配额进行一次原二值条件匹配，以允许域及预测上限决定起始搜索状态。在这一状态上由公开请求、节点负载、截止期余量及允许动作特征产生一次候选池，不运行 PPO Actor。动作令一个节点向另一个节点迁移 $1, 2, 4$ 个名额，扣除负配额、重复或其他非法动作。

公开提议先按源节点释放风险和目标救援信息排序，取最多四个不同源–目标对；对剩余合法动作，再用固定种子 20261017 选最多四个。以当前配额本身加这最多八个单次迁移构成至多九个待匹配配额。它不是九轮随结果自适应推进的学习搜索，也没有新入口门控网络。

5.4.2 预算内匹配、筛选与候选选择

对每个待匹配配额计算式 (5.9) 的矩阵并解式 (5.15)；仅保留完整合法且预测能耗不超过 E_{cap} 的结果。G 本身始终在候选池中。初始一次匹配加最多九次混合匹配构成 10 次总上限；空批次不调用匹配器，不可行匹配也付出调用预算。预算按本次新解析协议定义，不能解释为原 16 次 PPO 策略无损截断。

候选已生成后，才用固定价格 $\lambda \geqslant 0$ 选择最终方案：

$$\mathbf{x}^{*} = \arg\max_{\mathbf{x}\in C_t} \left[\sum_{m} s_{m,j_{\mathbf{x}}(m)}(\mathbf{N}_{\mathbf{x}}) - \lambda \frac{E(\mathbf{x})}{E_{\mathrm{norm}}} \right]. \tag{5.17}$$

同分先取更低预测能耗，再按候选原顺序决胜。λ 不进入式 (5.15) 的每条边，也

不改变配额内匹配，所以式 (5.17) 只是在已生成集合 C_t 中的选择，不能写成所有合法分配上联合求解带价格目标。

价格在既有五个开发训练块的 400 个公开状态上，使用预测成功分数与预测能耗标定。以开发 G 平均预测能耗作 E_{norm}，在非负候选价格交点中寻找使每开发块汇总预测能耗比不超过 1.05 的最小可行交点右侧值。解析主方法取 $\lambda = 0.001647731543$、$E_{\mathrm{norm}} = 32283.910075$；二值策略及两个冷启动对照的冻结价格为 0，固定 HGB 为 0.083586671957。正式二十块与新负载不参与拟合或调价。

开发公开状态的约束只描述标定目标，既不是每步完整机队能耗的硬保证，也不保证新块的预测或实际能耗比逐步低于 1.05。式 (5.16) 的逐步预测筛选参照原始贪心；正式门槛则比较候选与修复后 G 的块机队能耗比均值，二者的参照和量纲层级不同。

算法 5.1　解析缓存混合与候选间能耗定价

Input: 当前公开请求行、允许域、功率、冻结价格与上层模型
Output: 全部已接纳请求的合法分配
按移动前几何构造请求；贪心并作最多 128 次普通修复评价，保留 G;
从 G 配额初始化共同搜索状态；初始化匹配计入总调用数;
以公开特征提出最多八个合法迁移，加当前配额构成候选配额集;
解析命中/未命中分支，非法分解边回退；计算各配额混合分数;
将 G 放入候选分配池;
for 候选配额，至多九个 **do**
    解容量槽指派，调用数加一（失败亦计）；
    若完整合法且通过共同预测能耗硬筛选，则加入分配池;
end
按式 (5.17) 选择候选，映射回各源 UAV 动作;
完整调用计时含准备、反馈、上层推理和逻辑消息序列化;
环境执行当前请求；加入当次完整软件延迟，形成指标、奖励及下一观测;

5.4.3　输出合法性与计算范围

容量槽一一指派与返回前检查保证每个已接纳请求恰有一个允许目标。由于 G 合法并保留，全部新匹配不可行或被筛掉时仍能返回分配；这不等于保证每个请求按时完成。六节点下，配额集合大小由公开提议数限制，匹配调用数最多 10；若以批量规模 R 表示稠密指派规模，单次求解的常规立方复杂度给出 $O(10R^3)$ 的匹配部分量级。它不覆盖请求准备、普通修复、上层推理、矩阵构造和软件运行调度的全部常数成本。实际可执行性依赖完整调用实测，不能单凭调用数证明硬实时性。

候选间价格与固定预测上限承担不同作用：前者改变可选候选的质量–能耗

偏好，后者拒绝超过共同预测参照的匹配。模型还包含飞行、悬停、能量传输及其他机队作业能耗，这些并未全部进入分配边能耗。实验因此另行报告环境记录的完整机队能耗；软件 CPU 的物理能耗仍未模拟。

本章的 λ 是候选质量与预测分配能耗之间的固定权衡系数，没有计算资源买卖双方或议价过程，因而不同于 TJCCT 的资源交易单价[35]。Sun 等将时延、UAV 能耗与卸载量线性加权，再交替求解卸载、算力及轨迹子问题[9]；本章同样明确呈现质量与能耗取舍，但只对有限已生成分配作价格选择，不据此主张求得全局多目标最优或完整 Pareto 前沿。

5.5 实验协议与独立确认设计

5.5.1 新训练基座与数据隔离

确认场景为 $700 \times 700\,\mathrm{m}^2$ 区域内五架 UAV、100 个 UE 和一个 MBS，保持 100 m 自然服务半径、需求感知上层公开观测及移动前接纳规则。用二十个全新上层训练种子 1520001–1520020，分别对应训练负载 1540001–1540020；每个基座训练 200 回合，每回合 1000 步，固定使用最后 episode_00199 检查点，不按确认效果择优。rollout 为 1000，PPO epochs 为 8，batch size 为 256，数值线程数为 1。这里的 PPO 用于上层训练，本轮没有训练二十个新下层 PPO。

正式负载 1560001–1560005 与开发负载隔离，每负载三回合、每回合 1000 步。每训练块每方法共 15 回合、15,000 次完整调用；每方法 300 回合、300,000 次调用，九方法总计 2700 回合、2,700,000 步。同块共享上层检查点、公开信息规则和配对外生流；状态可因先前下层决策而分化，不要求各方法的实际请求分母始终完全相等。

主候选、样本量、两个主比较和晋级门槛在正式效果出现前固定。开发阶段对方法的选择不冒充独立证据，开发块、原十块和新二十块也不合并为 $n = 30$。固定 HGB 参照复用一个旧开发模型，本轮二十个独立单位来自新上层训练重复，而非二十次 HGB 拟合。完整种子和参数见附录 C。

5.5.2 九个完整方法及比较层次

表 5.1 列出全部方法。G 为共同贪心加普通修复；R10 与 R16 均在共享强框架内随机选择合法配额动作，分别支付 10 和 16 次以内的匹配预算。它们不同于原逐请求随机卸载，也不能直接与原十块的强配额随机绝对数值拼接。

两个冷启动控制在公开可见状态满足全缺失条件时，将可分解协作边的命中权重置零；其他状态分别使用原先验或半概率代理。它们不读取真实邻机缓

表 5.1　计费闭环确认实验评估方法对比

Table 5.1　Evaluation Methods in Cost-Aware Closed-Loop Confirmation Experiment

正文简称（代码名）	匹配上限	任务组织及用途
G	0	共同贪心加最多 128 次普通修复评价；主比较参照
R10	10	共享条件匹配框架的同预算强随机
R16	16	较高匹配预算强随机
二值价格（binary_price）	10	平均预测时延阈值目标及其冻结价格；主比较参照
未加价混合（mixture）	10	解析混合评分，不作候选能耗定价
混合价格（mixture_price）	10	固定主候选：解析混合、条件匹配及候选价格
冷启动先验（cold_prior_price）	10	公开冷启动规则下的先验分支权重
冷启动半概率（cold_half_proxy_price）	10	同冷启动规则下的半概率代理权重
固定 HGB（HGB_probability_price）	10	旧开发模型预测成功分数，再匹配及定价

存。固定 HGB 使用公开请求与给定配额边特征，而不是本轮重新拟合的缓存真值预测器。各有价策略沿用各自开发冻结价格，冷启动与二值的价格恰为零也仍保留原策略标识。

解析候选、二值与 R10 共享 10 次匹配上限，但九方法的总软件路径及预算并非完全相同。G 不调用匹配，R16 预算更高，HGB 另有预测开销；正式评价逐步计入各自完整费用，不能只按匹配次数等同计算成本。

5.5.3　软件计时、注入与硬件条件

完整调用从动态缓存清理开始，涵盖请求准备、方法修复与匹配、反馈、上层推理、动作映射及逻辑消息序列化；磁盘日志和离线审计不作为线上逻辑通信费用。每回合只对复制的初始状态作一次不推进环境的预热，后续调用清理动态缓存。令当次调用时间为 c_t^{sw}，实际物理路径时延为 $T_{m,t}^{\mathrm{phys}}$，计费成功判据为

$$S_{m,t}^{\mathrm{paid}} = \mathbf{1}\{m\text{已接纳}\}\,\mathbf{1}\{T_{m,t}^{\mathrm{phys}} + c_t^{\mathrm{sw}} \leqslant D_{m,t}\}. \tag{5.18}$$

费用在当前批次物理执行后、指标、奖励和下一观测形成前注入，并核对请求身份；之后环境继续演化。它没有模拟未完成任务持续排队、真实无线控制消息传输或软件 CPU 物理能耗。统计中同时保存的费用前物理 DSR，只是同状态同动作去掉当次软件费用的记账量，不是另跑零费用闭环的结果。

运行服务器为双路 EPYC 7763，共 128 物理核。本轮至多 120 个单线程进程使用互不共享 SMT 兄弟的物理核，300 个配对任务束按 120/120/60 三波执行，

同一束的九方法共享租用核心。模型加载屏障之后开始计时。该硬件执行修订在正式效果出现前登记，报告的是高并发服务器上的实际调用时间，不与旧八核或低负载计时拼接，也没有实测相对旧条件的加速倍数。

5.5.4 块聚合、主检验与预定门槛

独立推断单位为二十个上层训练块。对块 b 和方法 k，先将 15 回合内请求计数合并，再定义

$$d_{bk}=\frac{\sum_{e} S_{bek}}{\sum_{e} G_{bek}},\quad a_{bk}=\frac{\sum_{e} A_{bek}}{\sum_{e} G_{bek}},\quad q_{bk}=\frac{\sum_{e} S_{bek}}{\sum_{e} A_{bek}},\quad d_{bk}=a_{bk}q_{bk}. \tag{5.19}$$

主报告为 $\bar{d}_{k}=20^{-1}\sum_{b} d_{bk}$，而非所有请求混成一个独立样本；episode、请求和调用数均不扩大独立 n。跨块均值 $\bar{a}_{k}\bar{q}_{k}$ 一般不等于 $\bar{d}_{k}$。

两项预定主比较为主候选分别减 G 和二值价格。对块内差 Δ_{b} 报告均值及配对 t 区间

$$\bar{\Delta}\ \pm\ t_{0.975,19}\frac{s_{\Delta}}{\sqrt{20}}. \tag{5.20}$$

两个双侧 t 检验组成唯一主检验族，按 Holm 规则校正；逐项 95% 区间未作同时区间校正。精确符号翻转枚举 2^{20} 种块符号模式，仅在独立块配对效应对称性假设下作为敏感性检查，不称无假设因果随机化检验。其余六个参照的差值及资源区间作描述性报告，不另提名确认性赢家。

实用门槛预定为相对 G 均差至少 0.5 个百分点、相对二值价格至少 0.1 个百分点，两比较各至少 16/20 块为正且 Holm 双侧 $p<0.05$；候选/G 的平均块机队能耗比不超过 1.05，每块完整逐次调用 p95 小于 1 s。能耗先在块内取比再平均；时间门槛用各块 15,000 次调用的 p95，区别于每方法合并 300,000 次调用的 p95。均差超过门槛不表示真实效应区间下界必然超过同一门槛，也不表示每次调用满足硬实时限制。

5.6 服务收益、资源取舍与学习增量边界

5.6.1 两项预定比较的计费服务收益

新主候选的块平均计费 DSR 为 33.76188%，G 为 32.73360%，二值价格为 33.49945%。表 5.2 给出两项预定主比较；相对 G 二十块全部正向，相对二值十八块正向，两项 Holm 校正均通过。它支持规定主场景及冻结协议下的净服务增益，不等于所有指标或所有参照全面最优。

图 5.3 保留八个参照和全部二十块。相对二值的效应小于相对 G，且存在两块非正差，说明模型目标细化是在强结构化框架上的进一步改善。原十块的

表 5.2　计费 DSR 预定主比较结果

Table 5.2　Prespecified Primary Comparisons of Paid DSR

候选减参照	均差	95% 配对 t 区间	正向块	Holm 双侧 p
G	1.02828	[0.93660, 1.11997]	20/20	3.40157×10^{-15}
二值价格	0.26243	[0.16518, 0.35968]	18/20	1.91037×10^{-5}

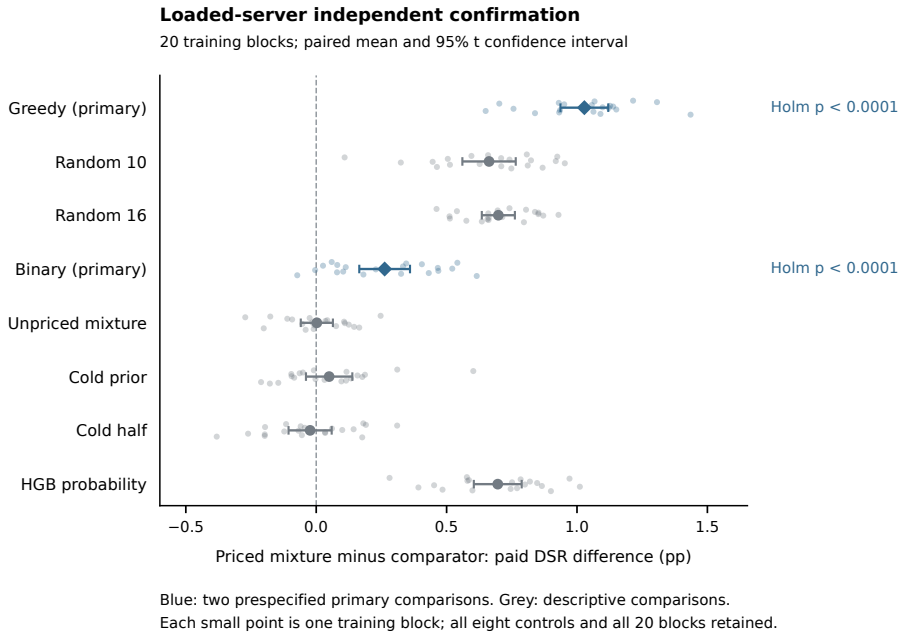


图 5.3　主候选相对各参照方法的计费 DSR 配对差值

Figure 5.3　Paired Differences in Paid DSR between Proposed Candidate and Control Methods

注：小点表示逐训练块结果，大点及线段表示均差与 95% 配对 t 置信区间；蓝色标记对应预定主比较。

34.244% 与本轮 33.76188% 不能用于跨方法优劣判断，旧事后贪心 32.161% 也不能被拿来计算本轮效应：它们的方法、样本、费用处理和硬件条件不同。

5.6.2　全部九方法与接纳后质量

表 5.3 完整列出九方法质量结果，按预定方法顺序呈现，不按均值重新提名候选。R10 和 R16 的 DSR 分别为 33.09908% 与 33.06347%，说明较多随机匹配调用未必带来更高计费 DSR；这不是匹配预算的一般单调性结论。固定旧 HGB 在新基座上为 33.06576%，其作用是保留一个已有学习近似参照，不能据此概括全部学习策略。

候选与 G 的接纳率分别为 60.01103% 和 60.00372%，配对差的描述性区间跨零；接纳后按时完成率从 54.69571% 增至 56.40046%，差为 1.70475 个百分点，描述性 95% 区间 [1.39957, 2.00994]。这与主要增益出现在接纳后的任务组织相

表 5.3　各方法服务质量与宏基站依赖度对比

Table 5.3　Comparison of Service Quality and MBS Dependence Across Methods

方法	计费 DSR	接纳率	接纳后质量	MBS/接纳
G	32.73360	60.00372	54.69571	4.06670
R10	33.09908	59.92526	55.38386	7.73998
R16	33.06347	60.06877	55.19397	9.70156
二值价格	33.49945	60.02757	55.94966	6.42691
未加价混合	33.75945	60.03984	56.38106	6.25747
混合价格（主候选）	33.76188	60.01103	56.40046	5.94387
冷启动先验	33.71228	59.84472	56.48048	6.27255
冷启动半概率	33.78529	60.02649	56.43736	6.38267
固定 HGB	33.06576	59.92804	55.31723	5.55025

符，区别于第三章以接纳扩展为主的改善。由于下层也会通过缓存、电量和后续观测影响轨迹，且未设置中介识别实验，该分解不是因果中介证明。

表中各率均为二十个块率均值；式 (5.19) 在每个块内成立。若将表中跨块均值直接相乘，所得值可能与 DSR 略有差异，这属于聚合层次差异，不能通过重写成功数消除。正式主指标始终以全部实际生成服务请求为分母。

5.6.3　机队能耗、MBS 与公平性的取舍

表 5.4 同时给出完整机队能耗和软件时间。为便于逐项对照，能耗列采用候选除以该参照的块比值均值；候选自身为 1。该列不等于各方法总能耗比或预测分配能耗比。

表 5.4　各方法机队能耗、公平性与计算耗时对比

Table 5.4　Comparison of Fleet Energy, Fairness, and Computation Time Across Methods

方法	候选/本方法能耗	Jain 公平性	调用均值/ms	合并 p95/ms
G	1.01866	0.93004	10.20854	14.62912
R10	1.11228	0.93025	13.29881	18.47330
R16	1.13630	0.92948	14.95769	20.50048
二值价格	1.08299	0.93003	17.00655	23.62004
未加价混合	0.91278	0.92972	17.71626	24.62460
混合价格（主候选）	1.00000	0.92921	17.71794	24.69118
冷启动先验	0.91296	0.92898	17.80629	24.83362
冷启动半概率	0.91537	0.92923	17.89307	24.91109
固定 HGB	0.92201	0.92878	22.23904	31.41242

候选/G 平均块机队能耗比为 1.01865745，描述性 95% 区间

[1.01468586, 1.02262905]，即均值增加约 1.87%，仍低于预定 1.05 门槛。开发五块曾观察到能耗下降，该方向不能移用到新确认。候选相对 R10、R16 和二值的能耗分别约高 11.23%、13.63% 和 8.30%，不能称相对所有参照节能。能耗门槛仅预先指定相对 G，不追认其他方法为同一节能检验族。

候选的 MBS 占接纳比例为 5.94387%，高于 G 的 4.06670%，增加约 1.877 个百分点。Jain 公平性为 0.92921，G 为 0.93004，配对差的描述性区间跨零。因此，服务增益同时伴随更高 MBS 依赖，且没有证据声称公平性改善。MBS 仍使用原非批量共享规则，真实基站排队或回传拥塞可能改变这种取舍，不能把 MBS 的计算资源解释成现实无限资源。

5.6.4　软件时间尾部与预定代价门槛

候选完整调用均值为 17.71794 ms，合并 300,000 次调用的 p95 为 24.69118 ms，最大单次为 181.36437 ms。p95 不是最大值，也不意味着每次都低于 50 ms。正式晋级所用的二十个块内 p95 均低于 1 s；它检验指定服务器条件下的经验调用分布，不能直接提升为硬实时保证。

两项 DSR 均差分别超过预定 0.5 和 0.1 个百分点，方向数达到 20/20 与 18/20，Holm 双侧检验均通过；候选/G 平均块能耗比及全部块内 p95 亦满足门槛。因而本次确认支持在给定信息、批次和硬件协议下，解析方法计入完整软件费用后的服务收益与预定代价可接受性。该结论没有测量真实机载控制消息传输、CPU 物理能耗或排队资源占用，不能等价为实际部署收益。

5.6.5　替代分母与组件归因的边界

固定潜在服务请求分母复核中，各方法共同潜在计数为 9,215,840；候选相对 G 仍提高约 1.02892 个百分点，相对二值约 0.26295 个百分点，对应区间均为正，详见附录 C。该复核保留原成功数，只替换统计分母，不改变预定计费主指标，也不模拟低电量 UE 继续产生服务请求。

主候选相对未加价混合仅高 0.00243 个百分点，描述性 95% 区间 [−0.05916, 0.06402]；其能耗相对未加价混合约低 8.72%。这可以描述质量–能耗取舍，不能写成价格提高 DSR 或“无损节能”，因为未预注册非劣效检验。冷启动半概率均值 33.78529% 略高于主候选，候选减它为 −0.02341 个百分点，区间 [−0.10614, 0.05932]；相对冷启动先验的区间也跨零。因此，本轮不能证明精确缓存信念不可替代，也没有证实胜过所有方法。

原学习配额变体在共享强框架上的小幅增量及费用反转保留在正文动机和

附录中。新二十块没有重新评价配额 PPO，故不能称解析方法已在新独立确认中战胜 PPO，也不能把新解析方法的增益归为 PPO 贡献。二值和混合还使用各自冻结价格，其差异是两套完整策略的对比，而非孤立评分组件的纯因果效应。现有结果支持方法层面的两项服务主张，缓存信念、价格与学习各自的必要性仍需对应设计。

5.6.6 已有开发诊断对组件解释的约束

历史开发试验已检查预测误差与任务决策的关系，并非尚无缓存敏感边证据。在五个历史上层块的 400 个固定快照中，条件学习缓存模型在共同 10 ms 延迟下的敏感边及所选敏感边上仍具有较低 Brier 误差，但相对冷启动半概率参照的服务差为负；按分配关系拆分时，主要负贡献出现在配额不同的状态。同池学习重排虽恢复小幅质量，仍未通过预定联合门槛；增加公开获取时延差特征也未达到预定预测改善门槛。协议、数值及停止原因见附录 C.4。

这些记录说明，应分别核对预测准确性、候选生成、分配选择和软件费用，不能只凭预测指标选择在线方法。它们采用历史开发快照及共同固定延迟，没有评价各新模型的原生软件费用与长回合反馈，也不是本轮二十块解析方法的因果分解。此外，原 400 状态中 step0 占四分之一，该权重不能代表完整 1000 步回合的时间分布。以下另以新开发负载补查这一缺口，历史记录仍按原协议保留。

5.6.7 长回合补证与零调参开发迁移

复用五个历史上层开发基座，在三个新负载上分别运行 G 与冻结解析策略，每回合 1000 步。在每个 25 步区间预先随机抽取一步，形成 1200 个主状态，另存 28 个未被主抽样覆盖的初始状态。解析方法所选配额下，各块活跃合法协作边中的截止期敏感比例为约 57.8% 至 66.3%，因此不能以关键边稀少解释缓存信息价值有限。共同价格的受控比较进一步表明，固定快照上的模块收益随源轨迹而变，闭环带价解析减带价二值为 0.251 个百分点，描述性 95% 区间 $[-0.498, 0.999]$；本轮没有建立该组件在新负载闭环中的确定优势，也未证明价格提高 DSR 或无损节能。设计、零价比较和分配关系分解见附录 C.5。

在相同冻结上层、价格与归一化常数下，对 60/100/140 UE 及 0.6/1.0/1.4 算力的五点十字开展计费开发复验。解析方法相对 G 的五场景块均差均为正，其中 100 UE、0.6 算力为 1.720 个百分点，逐项描述性 95% 区间 $[1.671, 1.770]$；各场景解析减二值的区间均跨零。该复验覆盖 300 回合，使用五个历史开发块而非新训练重复，不能替代跨场景独立确认；上层仍使用原 30 个 UE 观测槽，140

UE 场景存在排序截断限制。图 C.1 保留全部场景与块差，未检验负载与算力的交互。

5.6.8　缩减匹配预算的开发停止依据

有限预算还需按完整调用费用判断，而非按匹配次数判断。沿用五个历史开发基座及上述三个已用开发负载，另比较 0、2、4、6、10 次固定预算前缀，并将原生批量 B10 单列重计时。所有正预算前缀共享同一实现，仅计算实际访问配额的矩阵；B10 在 1200 状态上通过原策略动作与反馈回归。各缩减方案均未同时达到预定的 DSR 损失不超过 0.1 个百分点、完整时间至少减少 20% 及能耗要求，详见附录 C.6。

分项测量中，矩阵评分与条件匹配合计仅占 B10 完整时间约 11.14%，其余开销主要已在进入前缀循环前或共同调用路径中支付。这解释了当前实现下减少匹配次数的有限节时空间，不能作为所有自适应方法的理论下界。固定快照中 B6 的有利均值也未在闭环保持，故本轮停在固定预算开发，不增加自适应规则或新训练。该诊断限定当前实现及开发分布，不扩展原二十块的确认性主张。

5.7　本章小结

本章围绕自然覆盖之后的批量服务组织，连接冻结需求感知上层与解析缓存混合、有限预算条件匹配和候选间能耗定价。固定配额使最终共享算力进入容量槽边成本，最多 10 次匹配限制在线尝试数量，逐次完整软件延迟则进入当前请求反馈并继续闭环。二十个新上层训练块支持相对 G 和同框架二值价格的计费 DSR 增益，同时通过预定能耗与时间门槛。

后续开发补证表明，长回合关键协作边并不少见，组件效应依赖状态来源；五点零调参迁移提供开发层面的场景证据，缩减匹配预算则未通过质量与完整时间联合要求。上述证据用于解释适用范围和停止扩展，不替代二十块主确认。相对 G 的能耗与 MBS 依赖上升、价格和精确信念必要性未建立、PPO 独有增量未确认等边界同时保留。跨场景独立确认、连续队列、真实控制网络及软件 CPU 物理能耗仍需对应的新设计。

第 6 章　总结与展望

6.1　研究总结

本文面向具有截止时间的地面计算服务，研究无人机集群如何通过协同空间部署接纳动态需求，并通过跨节点计算任务分配提高按时完成比例。空中平台的位置决定请求能否进入服务流程，机载计算、缓存及协作传输决定接纳后的执行质量。围绕这两个相互联系的环节，本文以统一请求计数为基础，依次研究需求感知协同轨迹决策、固定快照跨机任务分配和计及决策开销的解析分层方法，形成从空间服务瓶颈到批量资源耦合再到分层决策验证的技术路线。

研究聚焦无人机集群的任务规划与资源分工：机动决策调整服务区域，任务分配组织执行节点，共同服务于时限完成目标。MEC 提供具有明确输入、截止时间和资源消耗的任务模型。方法在固定高度二维运动和规定信息条件下评价，其适用范围及进一步面向飞行执行的需求见下文。

6.1.1　需求感知的集群空间部署与服务接纳

本文把实际生成、自然接纳和按时完成的服务请求记为 G、A 和 S，以 S/G 定义端到端 DSR，同时报告 A/G 与 S/A。这一口径把未覆盖请求的损失纳入评价，使轨迹控制与卸载质量能够在同一个服务成功链条内解释。它也避免了只看接纳后完成率时忽略覆盖盲区的问题。对于多个时隙、工作负载或训练块，本文按照预定计数和聚合层次计算指标，而不直接相乘三个跨单元均值。

第三章的服务失败分析显示，未覆盖需求构成主场景中重要的失败来源。扩展上层预动作观测后，轨迹策略能够看到感知范围内尚未接纳的用户，其物理服务半径仍为 100 m。独立确认中，候选 DSR 从 0.2444 增至 0.2793，提升约 3.49 个百分点，并在十个训练种子上保持同向。接纳增加的同时，接纳后完成质量发生变化，这使“更多覆盖”与“更好的服务”之间的联系成为后续卸载研究的直接动机。固定潜在服务请求分母复核也表明，轻微实际分母变化未解释该批次的主增益。

这项研究把轨迹规划的依据从已接纳用户扩展到允许观测的尚未接纳需求，使集群空间部署能够面向后续服务机会进行调整。邻机与用户注意力组织可变的空间交互信息，位移、边界和间距修复保证规定离散状态中的几何可行性。需求信息扩展同时改变了信息条件；同信息预算的探索性替代结构比较尚未确认独立注意力优势，因此本文把需求可见性、网络聚合和环境执行约束分别解释。

这种区分保留了空间部署改善的证据，也使后续结构比较能够围绕相同信息条件进行。

6.1.2　跨机计算任务分工与批量资源耦合

第四章针对给定集群位置、请求和历史状态研究 MC-ITR，把跨机任务分工写成具有批量外部影响的分配问题。最终批量均分算力使一个请求迁移能够改变两个节点上其他请求的完成时间，因此逐请求自身代价不足以完整描述迁移影响。MC-ITR 对候选迁移重新评价整个分配，并按超时数、归一化时延与分配能耗的字典序比较接受严格改善。有限分配空间与严格改善保证相应搜索按无改善或预算条件终止，其性质属于固定快照求解过程；完整邻域扫描无改善时才认证相应邻域局部最优。

主配置中，MC-ITR 每快照平均超时数为 2.055，低于 Iterative-Base 的 2.228；主配置及八个 UE 或算力敏感性配置的配对结果支持其截止期质量改善。小规模穷举提供实现一致性检查。在需求感知上层与无注意力学习式下层产生的共享轨迹快照上，MC-ITR 相对在线下层平均每快照少 2.460 个超时请求，进一步显示固定状态下的分配余量。

固定快照实验同时显示质量改善的代价。学习轨迹快照上，MC-ITR 分配能耗约增加 23.8%，含贪心初值的完整调用路径平均约 20.751 s。反事实分配未回写环境，这些结果刻画的是给定状态下的质量–计算权衡。MC-ITR 作为离线参照，其批量资源分析为条件化匹配与有限预算在线搜索提供了设计依据。

6.1.3　计及决策开销的分层服务决策

第五章在冻结需求感知上层与批量条件匹配框架下，采用解析缓存混合评分和候选间能耗价格。前者区分公开缓存信念下的命中与未命中截止期分支，后者只在已生成候选间平衡预测成功分数与分配能耗；包含初始化在内最多 10 次匹配。实际完整软件时间在当前请求反馈中生效，随后继续状态演化，从而检验规定批次模型中的计费闭环服务收益。

20 个全新上层训练块与五个新负载的确认中，主候选计费 DSR 为 33.76188%，相对贪心修复增加 1.02828 个百分点，95% 配对 t 区间 $[0.93660, 1.11997]$，20/20 块正向；相对同框架二值价格增加 0.26243 个百分点，区间 $[0.16518, 0.35968]$，18/20 块正向。两项预定主比较均通过 Holm 双侧校正。接纳率相近而接纳后质量提高，与当前批量组织改善相符，但不作因果中介解释。

收益伴随代价：相对贪心，平均块机队能耗增加约 1.87%，MBS 占接纳比例从 4.06670% 升至 5.94387%；公平性差区间跨零。完整调用均值为 17.72 ms，合并逐次 p95 为 24.69 ms，预定相对 G 能耗与各块时间门槛通过。这是高并发服务器条件下的测量，并非机载硬实时保证。

原 SF-HLM 学习配额变体的十块结果及原轨迹事后费用排序反转保留在附录；它们不与新二十块合并。新确认没有重新评价配额 PPO，不能称解析法战胜新训练 PPO 或证明学习独有增量。相对未加价混合和两个冷启动近似参照，主候选 DSR 差区间跨零，也不能据此证明价格提高 DSR 或精确信念不可替代。

固定分支时延下，缓存信念只有在命中与未命中分支跨越截止期时才直接影响边成功分数。历史开发诊断也表明，较低预测误差未必带来较好的分配，见附录 C.4；这些记录只作组件解释。

6.2 综合认识与适用范围

两类决策具有互补作用：轨迹策略依据预动作需求信息改变未来空间服务条件，结构化下层依据已接纳请求与节点能力协调当前资源竞争。位置、缓存和能量按批次评价规则将二者连接为闭环，未完成任务和下载事件不跨步保留；DSR 分解用于描述接纳与完成质量的共同变化。完整方法的效果由独立确认评价，固定快照和探索性消融则提供结构解释。

集群采用上层分散式决策与下层集中调度。各 UAV 的 Actor 使用规定的局部观测，下层汇总当前请求和节点能力形成任务分配，因此仍需集中协调。五机仿真尚未检验大规模通信扩展性；460 m 感知范围规定观测邻居集合，200 m 最小间距规定离散几何约束。持续通信连通性与连续飞行安全需要对应的通信及运动模型验证。

原学习配额变体的固定策略稳健性评价覆盖 60/100/140 UE 与 0.6/1.0/1.4 UAV 算力的九格，属于原变体的场景证据。当前解析方法另完成五个历史开发块、三个新负载的五点十字计费迁移复验，各场景相对 G 的块均差为正，但相对二值模块的区间均跨零，且仍有负向块。两套方法的场景结果分别保留，开发迁移不替代新基座的独立确认或机载硬件验证。

固定预算开发未同时满足质量与完整时间要求，公共路径开销使匹配数不能代表整体费用，见附录 C.6。本实现据此停止预算扩展，其他入口决策或公共路径优化的效果仍未验证。

仿真中的信息与协调条件仍未覆盖需求上报、消息失真及真实网络等待。已计入反馈的软件调用费用区别于连续资源占用和无线控制通信成本。机队能耗

覆盖 UAV 飞行与作业，未包括全部地面计算及软件 CPU 物理能耗；等效频率参数也未经指定机载芯片标定，不能换算为实测续航。

6.3　后续研究方向

首先，应把任务层位移与动力学可执行轨迹连接，纳入加速度、转向、姿态、扰动及连续避碰约束。在相同请求与资源条件下比较理想位置和执行轨迹的服务及能耗，检验轨迹跟踪误差对覆盖收益的影响。

其次，应研究预接纳需求与集中协调信息的实际获取。设置上报延迟、缺失、更新频率及下发代价，统一信息条件和回退规则，在截止期与能耗结算中计入真实通信成本。无线传输、丢包、重传及机载硬件费用应与本章已确认的软件调用费用分开。

再次，应在有限续航与平台失效条件下检验任务重分工。增加返航保留量、节点不可用时刻和故障流，在同等电池预算下报告服务损失、恢复时间及能耗；机载计算与动力能耗须经目标硬件标定后再评价实测续航。

若进一步提出跨场景确认性主张，应另用新上层基座并事先固定检验族，检查观测槽截断及负载与算力交互。已有长回合和五点开发复验不因区间跨零而反复追加样本。预算扩展须先验证可节省的公共开销与公开信息价值；第三章同信息替代结构也需新训练块确认。

在改变资源与任务模型的研究扩展方面，持续队列、跨时隙占用、MBS 拥塞及非均分算力均需另定约束和费用。徐渊博等的阈值准入机制[12]提供拥塞建模参照，但主动准入改变自然接纳问题，仍须保留全部生成请求分母。贾子晔等的任务大小分布鲁棒卸载[44]可启发预测误差压力测试，不能直接证明缓存信念鲁棒性。李云等以 LSTM 处理服务请求时间依赖[45]，为历史信息建模提供参照；其决策收益仍需与已有强规则及未达门槛支线比较，并支付完整在线费用。遮挡、请求依赖及实际应急应用也需对应的新协议与独立验证。

6.4　本章小结

本文将需求感知空间部署、批量分配与计费反馈连接为分层任务规划路线。二十块确认支持规定主场景下解析方法的服务增益；长回合、迁移及预算开发诊断界定信息价值、场景范围与计算取舍。能耗、MBS 依赖及学习增量边界共同构成这一结论的适用条件。

参考文献

[1] Chung S J, Paranjape A A, Dames P, et al. A survey on aerial swarm robotics[J]. IEEE Transactions on Robotics, 2018, 34(4): 837-855.

[2] Mao Y, You C, Zhang J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2322-2358.

[3] Zeng Y, Zhang R, Lim T J. Wireless communications with unmanned aerial vehicles: opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.

[4] Mozaffari M, Saad W, Bennis M, et al. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.

[5] Hu X, Wong K K, Yang K, et al. UAV-assisted relaying and edge computing: Scheduling and trajectory optimization[J]. IEEE Transactions on Wireless Communications, 2019, 18(10): 4738-4752.

[6] Yu Z, Gong Y, Gong S, et al. Joint task offloading and resource allocation in UAV-enabled mobile edge computing[J]. IEEE Internet of Things Journal, 2020, 7(4): 3147-3159.

[7] 柴蓉, 杨泞渝, 段晓芳, 等. 多机协同自主任务规划系统研究综述[J]. 重庆邮电大学学报（自然科学版）, 2024, 36(4): 647-660.

[8] Zhang X, Jia R, Yin Q, et al. Safe and energy-efficient trajectory planning for heterogeneous multi-UAV enabled mobile edge computing[J]. IEEE Transactions on Mobile Computing, 2026, 25(4): 5648-5665.

[9] Sun G, Wang Y, Sun Z, et al. Multi-objective optimization for multi-UAV-assisted mobile edge computing[J]. IEEE Transactions on Mobile Computing, 2024, 23(12): 14803-14820.

[10] Hao H, Xu C, Zhang W, et al. Joint task offloading, resource allocation, and trajectory design for multi-UAV cooperative edge computing with task priority[J]. IEEE Transactions on Mobile Computing, 2024, 23(9): 8649-8663.

[11] 李小平, 周志星, 陈龙, 等. 异构边缘资源的任务卸载和协同调度[J]. 计算机研究与发展, 2023, 60(6): 1296-1307.

[12] 徐渊博, 任静, 王亮, 等. 面向无人机辅助边缘计算的卸载任务准入控制机制[J]. 计算机工程, 2025, 51(2): 54-64.

[13] Zhao M, Zhang R, He Z, et al. Joint optimization of trajectory, offloading, caching, and migration for UAV-assisted MEC[J]. IEEE Transactions on Mobile Computing, 2025, 24(3): 1981-1998.

[14] Sun G, Wu J, Sun Z, et al. JC5A: Service delay minimization for aerial MEC-assisted industrial

cyber-physical systems[J]. IEEE Transactions on Services Computing, 2025, 18(5): 2976-2993.

[15] Skaltsis G M, Shin H S, Tsourdos A. A review of task allocation methods for UAVs[J]. Journal of Intelligent & Robotic Systems, 2023, 109(4): 76.

[16] Yuan X, Xie Z, Tan X. Computation offloading in UAV-enabled edge computing: A Stackelberg game approach[J]. Sensors, 2022, 22(10): 3854.

[17] 曾耀平, 李怀, 陈世森, 等. 无人机部署与卸载策略优化[J]. 浙江大学学报（工学版）, 2026, 60(8): 1686-1696.

[18] 王义君, 王雅出, SHAHD Batool, 等. 无人机辅助动态权重边缘计算卸载策略研究[J]. 电子与信息学报, 2026, 48(7): 3071-3083.

[19] 李侍阳, 朱晓荣. 面向感知与 AI 协同任务的无人机巡检多维资源联合优化算法[J]. 电子与信息学报, 2026, 48(5): 2166-2177.

[20] 姜来为, 李元春, 杜雪琪, 等. 基于强化学习的无人机辅助移动边缘计算任务卸载综述[J]. 无线电通信技术, 2026, 52(2): 239-258.

[21] Zhang J, Niu Y, Lin Z, et al. Load-balancing multi-UAV collaborative MEC offloading-migration and trajectory optimization based on lyapunov MAPPO[J]. Computer Communications, 2026, 257: 108605.

[22] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[23] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256.

[24] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning [A]. 2015.

[25] Li B, Yang R, Liu L, et al. Robust computation offloading and trajectory optimization for multi-uav-assisted mec: A multi-agent drl approach[J]. IEEE Internet of Things Journal, 2024, 11 (3): 4775-4786.

[26] Tao Y, Kuang Z, Hou F, et al. Online service selection and task offloading in UAV-assisted MEC via deep reinforcement learning[J]. IEEE Transactions on Cognitive Communications and Networking, 2026, 12: 4159-4173.

[27] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 6379-6390.

[28] Yu C, Velu A, Vinitsky E, et al. The surprising effectiveness of PPO in cooperative multi-agent games[C]. Advances in Neural Information Processing Systems: Vol. 35. 2022: 24611-24624.

[29] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-

agent learning based on team reward[C]. Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems. 2018: 2085-2087.

[30] Rashid T, Samvelyan M, Schroeder de Witt C, et al. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning[C]. Proceedings of Machine Learning Research: Vol. 80 Proceedings of the 35th International Conference on Machine Learning. 2018: 4295-4304.

[31] Hady M A, Hu S, Pratama M, et al. Multi-agent reinforcement learning for resources allocation optimization: A survey[J]. Artificial Intelligence Review, 2025, 58(11): 354.

[32] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 5998-6008.

[33] Ju T, Li L, Liu S, et al. A multi-UAV assisted task offloading and path optimization for mobile edge computing via multi-agent deep reinforcement learning[J]. Journal of Network and Computer Applications, 2024, 229: 103919.

[34] Wang B, Kang H, Li J, et al. AAV-assisted joint mobile edge computing and data collection via matching-enabled deep reinforcement learning[J]. IEEE Internet of Things Journal, 2025, 12(12): 19782-19800.

[35] Sun Z, Sun G, Wu Q, et al. TJCCT: A two-timescale approach for UAV-assisted mobile edge computing[J]. IEEE Transactions on Mobile Computing, 2025, 24(4): 3130-3147.

[36] 张秋平, 孙胜, 刘敏, 等. 面向多边缘设备协作的任务卸载和服务缓存在线联合优化机制[J]. 计算机研究与发展, 2021, 58(6): 1318-1339.

[37] Chen X, Tian Y. Learning to perform local rewriting for combinatorial optimization[C]. Advances in Neural Information Processing Systems: Vol. 32. 2019.

[38] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. MIT press, 2018.

[39] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[A]. 2015.

[40] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017.

[41] Gronauer S, Diepold K. Multi-agent deep reinforcement learning: A survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.

[42] Virtanen P, Gommers R, Oliphant T E, et al. SciPy 1.0: Fundamental algorithms for scientific computing in Python[J]. Nature Methods, 2020, 17(3): 261-272.

[43] Crouse D F. On implementing 2D rectangular assignment algorithms[J]. IEEE Transactions on Aerospace and Electronic Systems, 2016, 52(4): 1679-1696.

[44] 贾子晔, 姜官旺, 崔灿, 等. 面向低空智联网的分布式鲁棒任务卸载方法[J]. 电子与信息学报, 2025, 47(5): 1450-1460.

[45] 李云, 高倩, 姚枝秀, 等. 移动边缘计算中智能服务编排和算网资源分配联合优化方法[J]. 通信学报, 2023, 44(7): 51-63.

附录 A　原学习配额变体的模型与训练

本附录保留原 SF-HLM 学习配额变体的推导。其 CompleteQuotaPPO、最多 16 次匹配和教师初始化属于原协议；第五章主方法为解析缓存混合＋能耗定价，不使用该 PPO 作为在线执行器。此处的二值超时字典序证明也不用于连续混合分数的最优性论证。共同移动前模型见第 5 章。

A.1　配额分解与条件化字典序匹配

A.1.1　配额空间与分配空间的关系

若每个请求最多有六个合法执行目标，直接分配空间至多包含 6^R 个组合。SF-HLM 首先考虑整数配额空间

$$\mathcal{N}_R=\left\{\mathbf{n}\in\mathbb{Z}_{\geqslant 0}^{6}:\sum_{j=0}^{5}N_j=R\right\},\qquad |\mathcal{N}_R|=\binom{R+5}{5}. \tag{A.1}$$

这个数量是忽略质量掩码后的配额数上界；掩码会排除某些无法由合法请求组成的配额。配额表示保留了算力共享所需的关键统计量，使负载相关项在给定 $\mathbf{N}$ 后成为已知常数。与此同时，它没有强迫同样大小的任务交换身份，也没有按配额均匀随机分配请求，具体任务依然交由条件匹配选择。

配额分解的作用并非声称整个问题已变为低复杂度精确问题。式 (A.1) 仍随批量规模增长，在线预算不允许穷举。其实际优势是把复杂的两种决策分开：图策略在配额层选择值得尝试的负载组织，确定性匹配器在该组织内利用请求差异寻找分配。学习器不必逐个生成全部请求的完整组合，也不必从回报中独立重新学习指派求解器已经能够表达的条件最优结构。

A.1.2　容量槽展开与合法指派

给定配额 $\mathbf{N}$，将每个节点 j 展开为 N_j 个容量槽。全部槽的集合为 $\mathcal{S}(\mathbf{N})$，大小恰好为 R；槽 s 对应的执行节点记为 $j(s)$。令 $y_{ms}\in\{0,1\}$ 表示请求 m 是否占据槽 s，则条件匹配满足

$$\sum_{s\in\mathcal{S}}y_{ms}=1,\qquad \sum_{m\in\mathcal{R}}y_{ms}=1,\qquad y_{ms}=0\quad\big(j(s)\notin\mathcal{J}_m\big). \tag{A.2}$$

同一节点的容量槽具有相同边成本，但分别只能接收一个请求。由一一指派得到的分配自动满足式 (5.2)，且每个节点最终恰好接收 N_j 个请求。图 A.1 展示配额、容量槽与请求身份的关系。

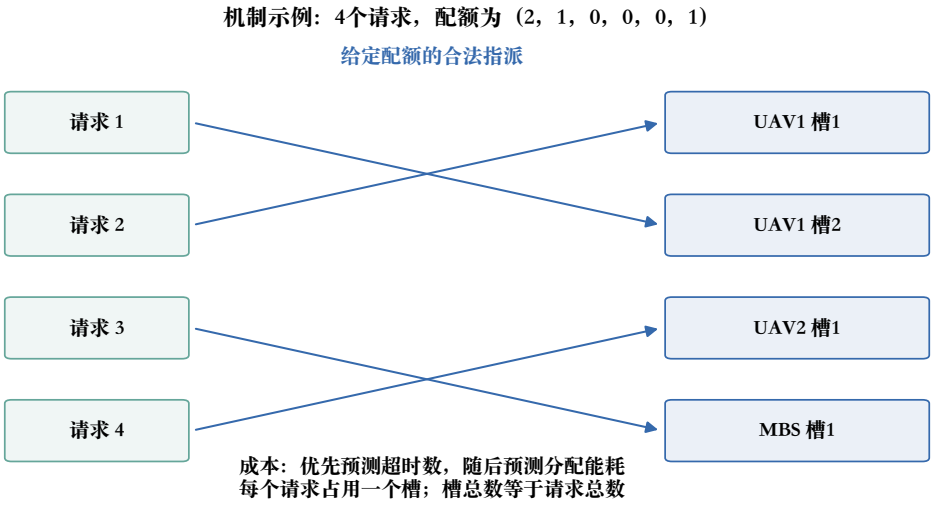


图 A.1　固定配额容量槽展开与请求匹配示意图

Figure A.1　Schematic of Capacity Slot Expansion and Request Assignment under Fixed Quotas

注：示意图用于解释容量槽构造与匹配机理，非实际环境测试分配结果。

配额可行性由完整指派确认。各节点的合法边数只是必要条件：若多节点依赖同一小部分请求，仍可能无法同时填满容量槽。非法边设无穷成本，使用 SciPy 线性指派接口[42]求解，其修改的 Jonker–Volgenant 方法背景见文献[43]。返回后检查边合法性与节点数量守恒；不可行调用同样计入预算，并保留已有最好方案。

A.1.3　字典序目标的标量化与严格等价性

给定 $\mathbf{N}$，先计算全部合法边的预测能耗，令

$$E_{\max}(\mathbf{N}) = \max_{m,j:\, j\in\mathcal{J}_m} \widehat{E}_{mj}(N_j), \qquad \widetilde{E}_{mj} = \frac{\widehat{E}_{mj}(N_j)}{\max(E_{\max}, \epsilon_E)}. \tag{A.3}$$

实现用极小正数 ϵ_E 防止所有能耗为零时除零。合法边能耗非负且 $\widetilde{E}_{mj} \leqslant 1$，因此任何完整合法指派的归一化能耗和均处于 $[0, R]$。构造容量槽成本

$$C_{ms} = (R+1)\mathbf{1}\{\widehat{T}_{m,j(s)}(N_{j(s)}) > D_m\} + \widetilde{E}_{m,j(s)}, \tag{A.4}$$

非法边成本为无穷。线性指派求解

$$\min_{\mathbf{y}} \sum_{m,s} C_{ms} y_{ms} \quad \text{满足式 (A.2).} \tag{A.5}$$

权重 $R+1$ 随当前批量规模确定，不使用任意调试的超时惩罚常数。

下面说明式 (A.5) 与固定配额下的 (M, E) 字典序最小化等价。任取两个完

整合法指派 $\mathbf{y}^a, \mathbf{y}^b$，若 $M_a \geqslant M_b + 1$，其标量目标差满足

$$C_a - C_b = (R+1)(M_a - M_b) + \widetilde{E}_a - \widetilde{E}_b \geqslant (R+1) - R = 1 > 0. \tag{A.6}$$

因此，无论能耗怎样变化，多一个预测超时的分配都不可能取得更小的标量成本。若 $M_a = M_b$，标量目标只比较归一化能耗；固定配额内归一化比例相同，故该比较与原始能耗大小完全一致。这证明求解器首先最小化预测超时数，再在最少超时的分配中最小化预测分配能耗。

上述条件最优性适用于给定配额、固定预测信息及合法指派域。能耗上限在求解后筛选：若最少预测超时的匹配超出上限，该候选被拒绝，不再搜索该配额下其他受限指派。因而，条件匹配提供可利用的精确子结构，配额搜索及能耗约束下的整体性能仍需独立评价。

A.1.4 预测能耗参照与保底方案

先按固定请求顺序构造原始贪心分配 $\mathbf{x}^{\mathrm{g}}$。处理一个请求时，贪心按已分配目标数估计加入后的自身时延，依次以自身时延、自身分配能耗和动作编号决胜。共同能耗参照由该原始贪心的最终批量重评估确定：

$$E_{\mathrm{cap}} = 1.05 E(\mathbf{x}^{\mathrm{g}}). \tag{A.7}$$

普通修复、配额学习、启发式和强随机均使用同一状态下的这个上限。它不是各方法自己的初始分配乘 1.05，从而避免某个方法由于初始方案能耗偏高而获得更宽松的筛选空间。

普通修复以一次请求迁移为邻域，在最多 128 次候选评价内寻找字典序改进。若已有学习下层提出的初始分配超出共同上限，先回到原始贪心，再开展修复；若未超限则从其提案出发。配额方法从共同贪心加修复的保底进入，并对该保底配额作一次条件匹配。候选只有在合法且预测分配能耗不超过 E_{cap} 时才能成为当前搜索状态；最好方案由所有已接受方案中的 (M, E) 决定。

由此，最终分配保持完整、质量合法且预测能耗不超过共同上限，最好预测目标不劣于共同保底。该性质涉及分配预测量；环境中的真实缓存和请求执行仍影响实际结果，飞行、悬停及无线能量传输也未包含在 $E(\mathbf{x})$ 内。因此，实验另行统计完整 UAV 机队能耗。

A.2　有限预算配额搜索与二部图策略

A.2.1　当前状态、最好状态与动作空间

搜索的内部步号记为 ℓ，区别于环境时隙 t。一个环境时隙内可以进行若干次配额迁移，但只有最终保留的分配进入环境。当前配额、当前分配与其预测目标分别记为 $\mathbf{N}^{(\ell)}, \mathbf{x}^{(\ell)}, F^{(\ell)}$；最好分配与目标记为 $\mathbf{x}^{*(\ell)}, F^{*(\ell)}$。允许搜索经过比最好方案更差的当前方案，使策略能够跨越只接受即时改进的局部限制；实际执行则不受这些较差中间方案直接影响。

完整搜索过程的状态可写为

$$S_\ell = (\mathcal{R}, \mathbf{N}^{(\ell)}, \mathbf{x}^{(\ell)}, \mathbf{x}^{*(\ell)}, \mathcal{V}_\ell, B_\ell), \tag{A.8}$$

$\mathcal{V}_\ell$ 为已尝试配额集合，B_ℓ 为剩余调用预算，请求预测量在单次搜索内固定。条件匹配与访问更新定义搜索转移。策略读取当前与最好分配的图编码及有效动作掩码，这些输入构成完整搜索状态的可计算观测。有限搜索的性能通过对应对照评价。

配额动作集合为

$$\mathcal{A} = \{\mathrm{STOP}\} \cup \{(i, j, k) : i, j \in \mathcal{J},\ i \neq j,\ k \in \{1, 2, 4\}\}, \qquad |\mathcal{A}| = 91. \tag{A.9}$$

转移动作仅改变节点任务数量：

$$\mathbf{N}' = \mathbf{N}^{(\ell)} - k\mathbf{e}_i + k\mathbf{e}_j. \tag{A.10}$$

这里的“转移 k 个任务”是配额变动，不是预先指定 k 个请求的身份。新配额的具体分配重新由条件匹配给出，可能改变多个请求的目标。因此，一次配额动作能够触发批量重组，而不是仅对一个被选中的任务作局部替换。

有效动作掩码同时要求 $N_i \geqslant k$、新配额没有访问过、各节点配额不大于其合法边数。最后一项只是必要条件，完整可行性由匹配求解检查。STOP 始终有效，使没有可行迁移时策略也能合法终止。失败的匹配配额同样加入访问集合，避免重复耗费预算。采样时掩码属于保存的搜索状态，重算概率时不得根据更新后的访问集合重新生成它。

初始条件匹配占用一次调用，整个搜索最多 16 次匹配，因此普通非空批次最多再尝试 15 次配额迁移。策略可以提前 STOP，也可能因为调用预算耗尽而终止；空批次不消耗匹配预算。搜索预算是求解器调用数，而不是动作数、成功迁移数或模型前向次数。该定义使不可行候选与超能耗候选也承担实际计算费用，便于与启发式和强随机保持共同预算。

A.2.2 请求、边与节点特征

图 A.2 表示每个搜索状态的二部图。请求是左侧节点，六个执行节点是右侧节点，质量合法动作构成边。请求输入保留截止时间、计算量、输入大小和源节点；边输入描述请求放在该目标后的预测路径和负载；节点输入同时描述当前与最好方案的服务压力。区分当前与最好状态很重要：如果只编码最好方案，策略无法知道自己正在从哪个较差入口继续迁移；如果只编码当前方案，又无法知道已经保留的执行质量和剩余改进空间。

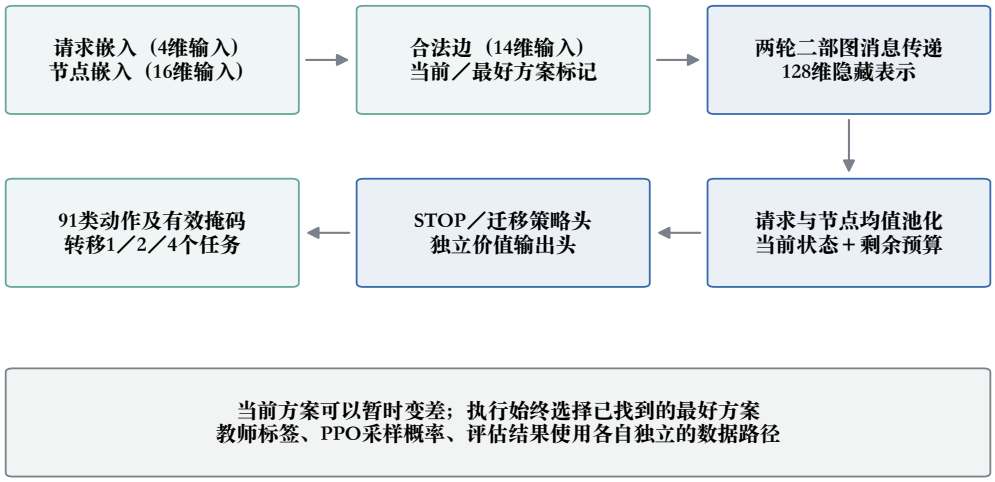


图 A.2 请求–执行节点二部图与网络状态编码结构图

Figure A.2 Request–Execution-Node Bipartite Graph and State Encoding Architecture

请求特征 $\mathbf{v}_m \in \mathbb{R}^4$ 为

$$\mathbf{v}_m = \left[\min(D_m, 10),\ \frac{\log(1+C_m)}{30},\ \frac{\log(1+L_m)}{20},\ \frac{u_m}{5}\right]. \tag{A.11}$$

秒、CPU 周期和字节数各自在进入网络前作固定尺度变换。变换用来控制数值范围，不改变指派预测器使用的原始量。尤其是网络中截止时间截断到 10 的表示，不意味着真实截止时间判断也被截断。

合法边 $\mathbf{z}_{mj} \in \mathbb{R}^{14}$ 的前十二项依次为：b_{mj}/D_m、w_{mj}/D_m、$\log(1+e_{mj})/20$、$\log(1+c_{mj})/30$、当前 N_j/R、截断后的 $\widehat{T}_{mj}/D_m$、归一化截止期余量、允许负载阈值的归一化值、MBS 标记、缓存信念、目标容量的对数表示和源节点标记。最后两项为当前分配与最好分配是否经过该边的二元标记。非法边的特征置零，并在后续聚合中屏蔽。负载阈值来自 $(D_m - b_{mj})/\max(w_{mj}, 10^{-12})$，只作为网络观测特征；最终方法没有把临界阈值扩展为新的动作集合。

令请求在指定分配中的归一化余量为 $m_m = 1 - \widehat{T}_m/D_m$。每个节点的六项服务摘要为：接收数量占批次比例、节点内预测超时比例、平均余量、最小余量、释放一个请求可能救回的请求数占批次比例、节点分配能耗占参照比例。释放救回的判定为

$$b_{mj} + w_{mj}\max(N_j - 1, 1) \leqslant D_m < b_{mj} + w_{mj}N_j, \tag{A.12}$$

且只对 UAV 目标计算。摘要既描述节点已经承担的请求，也提示减少该节点负载可能影响的其他请求；它没有读取真实执行成功标签。

当前与最好方案分别生成六项摘要，拼接当前配额比例、剩余匹配预算比例、当前和最好预测超时占批次比例，得到 $\mathbf{u}_j \in \mathbb{R}^{16}$。所有比例在空批次处理时采用正分母保护；空节点摘要为零。平均和最小余量截断到 $[-10, 1]$，边时延比上限为 10，容许负载特征截断到 $[-1, 2]$。这些固定处理约束输入数值而不改变真实请求数量、目标可行性或实际性能评价。

A.2.3　两层消息传递与置换结构

分别用 MLP 将请求、节点与边特征映射为 $h = 128$ 维嵌入，记为 $\mathbf{h}_m^{(0)}, \mathbf{g}_j^{(0)}, \mathbf{e}_{mj}$。每个 MLP 由线性层、LayerNorm、ReLU 和输出线性层组成。两轮消息传递中，第 q 层合法边消息为

$$\mathbf{m}_{mj}^{(q)} = \psi_q\big([\mathbf{h}_m^{(q)}, \mathbf{g}_j^{(q)}, \mathbf{e}_{mj}]\big), \qquad j \in \mathcal{J}_m. \tag{A.13}$$

ψ_q 在所有合法边共享参数，非法边消息恒为零。请求侧和节点侧各按合法邻居取均值，并分别更新：

$$\begin{aligned} \overline{\mathbf{m}}_m^{(q)} &= \frac{\sum_{j\in\mathcal{J}_m} \mathbf{m}_{mj}^{(q)}}{\max(|\mathcal{J}_m|, 1)}, & \mathbf{h}_m^{(q+1)} &= \rho_q([\mathbf{h}_m^{(q)}, \overline{\mathbf{m}}_m^{(q)}]), \\ \overline{\mathbf{m}}_j^{(q)} &= \frac{\sum_{m:\, j\in\mathcal{J}_m} \mathbf{m}_{mj}^{(q)}}{\max(|\{m : j \in \mathcal{J}_m\}|, 1)}, & \mathbf{g}_j^{(q+1)} &= \nu_q([\mathbf{g}_j^{(q)}, \overline{\mathbf{m}}_j^{(q)}]). \end{aligned} \tag{A.14}$$

$q = 0, 1$，两层使用各自参数。批量训练时，请求图填充到同一批中的最大请求数；填充请求嵌入与消息均屏蔽，均值分母只计算真实合法邻居。

完成两层更新后，对真实请求取均值 $\overline{\mathbf{h}}$，对六个节点取均值 $\overline{\mathbf{g}}$。转移动作 (i, j, k) 的分数由源节点、目的节点、请求池化表示和迁移量独热编码构成：

$$z_{ijk} = f_{\text{move}}([\mathbf{g}_i^{(2)}, \mathbf{g}_j^{(2)}, \overline{\mathbf{h}}, \text{onehot}(k)]), \qquad z_{\text{stop}} = f_{\text{stop}}([\overline{\mathbf{h}}, \overline{\mathbf{g}}]). \tag{A.15}$$

价值头同样使用 $[\overline{\mathbf{h}}, \overline{\mathbf{g}}]$。掩码 logits 形成分类分布，训练时采样，评估时取最大分数动作。共享边函数与均值聚合对一致的请求排列保持不变，节点身份、源编号及合法域则仍作为显式输入。

这一网络用消息传递表达“同一个请求的替代目标”和“同一个节点上可竞争请求”的关系。它不采用多头注意力加权聚合，下层所有合法邻居的消息使用均值。SF-HLM 因而由上层注意力聚合与下层二部图 MLP 两种结构组成。可变请求数量由图表示和填充掩码处理，而六节点动作头保持固定，这使模型在冻结跨 UE 数量评价时无需增加动作维数。

A.2.4 搜索奖励与最好方案不变量

一次非停止迁移后，令最好预测超时与能耗从 $(M^*_{\ell-1}, E^*_{\ell-1})$ 更新到 (M^*_{ℓ}, E^*_{ℓ})，训练奖励定义为

$$r_\ell = M^*_{\ell-1} - M^*_{\ell} + 0.1\frac{E^*_{\ell-1} - E^*_{\ell}}{\max(E_{\mathrm{cap}}, 10^{-12})} - 0.001. \tag{A.16}$$

奖励评价保留的最好方案，而非较差当前方案；一次没有改进的匹配尝试仍得到 -0.001 的计算惩罚。STOP 奖励为零。预测超时减少具有主要作用，能耗项在共同上限下表达较小的平滑偏好，调用惩罚为节约搜索提供信号。这个搜索奖励服务于单时隙组合求解，与环境中的轨迹奖励和真实 DSR 是不同对象。

采用无折扣的有限搜索回报，若本次搜索进行了 L 次非停止迁移，式 (A.16) 的差分项可望远镜求和：

$$\sum_{\ell=1}^{L} r_\ell = M^*_0 - M^*_L + 0.1\frac{E^*_0 - E^*_L}{\max(E_{\mathrm{cap}}, 10^{-12})} - 0.001L. \tag{A.17}$$

0 对应完成共同保底与初始匹配后的状态，初始匹配本身不产生一次迁移奖励。因此，训练在已有保底质量上权衡进一步改善与额外尝试，不奖励重复返回同一配额，也不把较差中间状态的真实执行结果回流到环境。

A.2.5 计算量、终止条件与实现校验

固定配额下的稠密成本矩阵为 $R \times R$，常规指派的时间量级为 $O(R^3)$、存储量级为 $O(R^2)$，实际实现与稀疏结构影响常数。图网络每轮处理至多 $6R$ 条边，在六节点与固定宽度下对请求数近似线性。完整在线时间还包括观测准备、普通修复、至多 16 次匹配、动作映射及消息序列化。

调用预算保证有限搜索终止。有效迁移消耗匹配预算，访问去重避免重复，STOP 可提前结束，最终返回共同保底或更好的预测分配。单次原子匹配须完成后才能返回，因此墙钟预算属于软截止，其实际超限在后文测量。

输入检查覆盖非负有限性、请求完整性、动作合法性与配额守恒。搜索保存采样时掩码，匹配预算包含初始调用，所有候选使用共同能耗参照。同一批搜索轨迹采用相同策略参数，完成采集后统一更新。

算法 A.1　SF-HLM 单时隙配额搜索与条件匹配

Input: 移动前请求行、质量合法域、冻结图策略 π_θ；匹配预算 16，普通修复预算 128

Output: 全部已接纳请求的合法分配

构造原始贪心 $\mathbf{x}^{\mathrm{g}}$ 并计算 $E_{\mathrm{cap}} = 1.05E(\mathbf{x}^{\mathrm{g}})$;
在共同上限内普通修复，初始化当前与最好分配;
根据保底配额执行初始条件匹配，计入一次匹配调用;
若候选合法、低于上限且目标更好，更新保留方案;
while 批次非空、匹配调用未耗尽且搜索未停止 **do**
    编码当前/最好二部图及采样时掩码;
    由图策略选择 STOP 或配额迁移 (i, j, k);
    if 选择 *STOP* **then**
        终止搜索;
    else
        生成守恒配额，记录已访问配额并计入一次匹配调用;
        求解该配额的条件字典序匹配;
        若匹配合法且满足共同能耗上限，更新当前方案;
        若当前方案优于保留目标，更新最好方案;
    end
end
将最好方案映射回各源 UAV 的请求动作，输出完整分配;

A.3　教师初始化、配额 PPO 与分层训练

A.3.1　从训练轨迹采集请求图

下层训练以共同基座产生的环境和独立下层训练负载为起点，上层保持冻结。每个训练块额外采集 25 个完整回合，每回合 1000 步，在 $0, 125, 250, 375, 500, 625, 750, 875$ 八个预定时刻记录移动前请求图，得到 200 个图实例，空批次也保留。采图期间使用共同贪心修复策略，不依据未来独立确认结果选择“更容易学习”或“更能体现优势”的快照。图数据只记录允许的观测预测信息，教师和 PPO 搜索都在这些固定输入上运行。

环境交互提供下层训练图，组合搜索则在固定图上重复采样，以提高训练数据利用率。图分布由共同基座和采集策略决定。开发评价与独立确认负载保持独立，不参与图采集、教师标注或梯度更新；重复搜索属于优化计算而非新增环境交互。

图 A.3 展示基座训练、下层采图、教师初始化、PPO 搜索和独立评价的数据流。基座负载用于轨迹策略训练，下层负载用于生成组合搜索图，确认负载仅评价训练结束时的模型。每个训练块对应共同上层及相应下层参数，各数据集按用途分离。

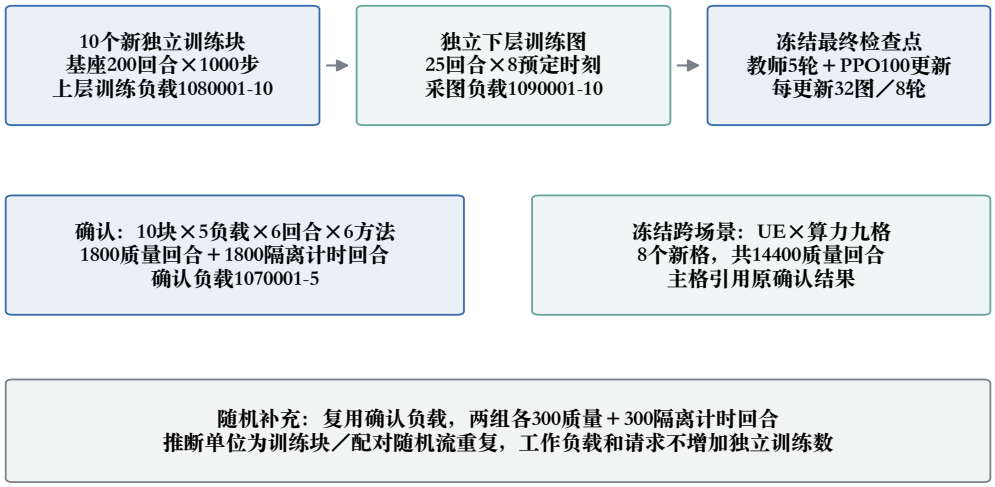


图 A.3　基座模型、下层训练图与独立确认数据集划分图
Figure A.3　Dataset Partition for Foundation Model, Lower-Layer Training, and Independent Confirmation

A.3.2　即时教师与独立监督损失

随机初始化的配额策略需要从大量无改善迁移和非法候选中学习，有限匹配预算下直接优化可能较难发现有用方向。本文先使用训练图上的即时改进教师提供可执行的动作示例。教师从同一共同保底和初始匹配出发，对当前有效迁移逐一尝试条件匹配，在合法且满足能耗上限的候选中选择优于当前目标的动作；没有找到即时改进时标记 STOP。教师总匹配预算为 128，包括初始匹配、试探候选和被选中迁移，不能把教师评价当作免费的真值查询。

教师标签是其实际找到的动作，并非穷举配额空间的全局最优标签。即时改进教师也不一定能发现需要先经过较差状态的多步路径；这一限制说明监督阶段的作用是提供初始搜索偏好，而不是替代后续强化学习。每条样本保存当时的当前/最好图、有效动作集合和教师动作。对样本集 $\mathcal{D}_{\mathrm{T}}$，监督损失为

$$\mathcal{L}_{\mathrm{BC}}(\theta) = -\frac{1}{|\mathcal{D}_{\mathrm{T}}|} \sum_{(s,a^{\mathrm{T}})\in\mathcal{D}_{\mathrm{T}}} \log \pi_\theta(a^{\mathrm{T}} \mid s). \tag{A.18}$$

监督预训练采用 5 轮、小批量 64 和梯度范数上限 0.5，动作概率在样本保存的合法域内归一化。教师样本仅用于监督初始化，随后 PPO 使用策略自身采样的动作、概率和优势更新。

监督初始化提供即时改进偏好，PPO 随后优化自身采样搜索轨迹的累计回报。允许经过较差的可行状态，使搜索能够探索多步迁移路径。其相对共享框架对照的服务增量在第 B.3 节评价。

A.3.3　有限搜索轨迹的优势估计

每次 PPO 更新前固定策略参数，从本块训练图抽取 32 个实例，各采集一条至多 16 次匹配的搜索轨迹。汇总该批轨迹后开始更新，保存搜索状态 s_ℓ、动作 a_ℓ、采样对数概率、价值估计 $V_\phi(s_\ell)$、奖励及终止标记。

令 $d_\ell^{\text{end}} \in \{0,1\}$ 为搜索终止标记，优势估计采用 GAE[39]：

$$\delta_\ell = r_\ell + \gamma(1 - d_\ell^{\text{end}})V_\phi(s_{\ell+1}) - V_\phi(s_\ell), \qquad \gamma = 1, \tag{A.19}$$

$$\widehat{A}_\ell = \delta_\ell + \gamma\lambda(1 - d_\ell^{\text{end}})\widehat{A}_{\ell+1}, \qquad \lambda = 0.95, \qquad \widehat{R}_\ell = \widehat{A}_\ell + V_\phi(s_\ell). \tag{A.20}$$

搜索终点下一状态价值取零，递推在每条图轨迹边界停止。$\gamma = 1$ 对应最多十余步的有限预算求解，而不是无限时域控制；它保留式 (A.17) 中改善与调用开销的完整权衡。价值训练目标使用未标准化的 $\widehat{R}_\ell$，策略梯度使用本次采样记录内标准化的优势。

标准化写作

$$\widetilde{A}_\ell = \frac{\widehat{A}_\ell - \overline{A}}{\max(\text{std}(\widehat{A}), 10^{-6})}. \tag{A.21}$$

若某批图没有有效搜索记录，则跳过参数更新而不是制造奖励或动作。不同图可以有不同请求数和搜索长度；填充处理的是图张量，不增加真实优势样本。请求数、搜索步或教师标签数也不能计为独立训练单位。

A.3.4　裁剪策略目标与概率一致性

配额 PPO 采用分类动作分布，其新旧策略概率比为

$$\rho_\ell(\theta) = \exp\left[\log \pi_\theta(a_\ell \mid s_\ell) - \log \pi_{\text{old}}(a_\ell \mid s_\ell)\right]. \tag{A.22}$$

裁剪目标沿用 PPO 的有限更新思想[40]：

$$\mathcal{L}_{\text{policy}} = -\mathbb{E}_\ell\left[\min\left(\rho_\ell\widetilde{A}_\ell, \text{clip}(\rho_\ell, 0.8, 1.2)\widetilde{A}_\ell\right)\right] - 0.005\,\mathbb{E}_\ell[\mathcal{H}(\pi_\theta(\cdot \mid s_\ell))]. \tag{A.23}$$

价值损失为

$$\mathcal{L}_{\text{value}} = \frac{1}{2}\mathbb{E}_\ell\left[(V_\phi(s_\ell) - \widehat{R}_\ell)^2\right]. \tag{A.24}$$

共享图编码器与动作、价值头一起最小化两项之和，Adam 学习率为 3×10^{-4}，每次采样执行 8 个 epoch、小批量 64，总计 100 次 PPO 更新，梯度范数裁剪为 0.5。最终确认使用第 100 次更新后的最后检查点，没有从开发或确认曲线中挑选最高 DSR 时刻。

PPO 的概率一致性在带访问去重的搜索中尤为重要。同一个配额在轨迹前段可能未访问、后段已经访问；如果训练时重算访问集合，动作分布的归一化域

会改变，概率比就不再对应原采样策略。本方法把采样时掩码和当前/最好图作为不可变记录保存，并在首次梯度更新前检验重算概率比接近 1。并行轨迹来自相同冻结参数，教师标签不进入这些记录，从而使比值检验具有清楚的含义。

表 A.1　配额策略训练超参数配置

Table A.1　Training Hyperparameter Settings of Quota Policy

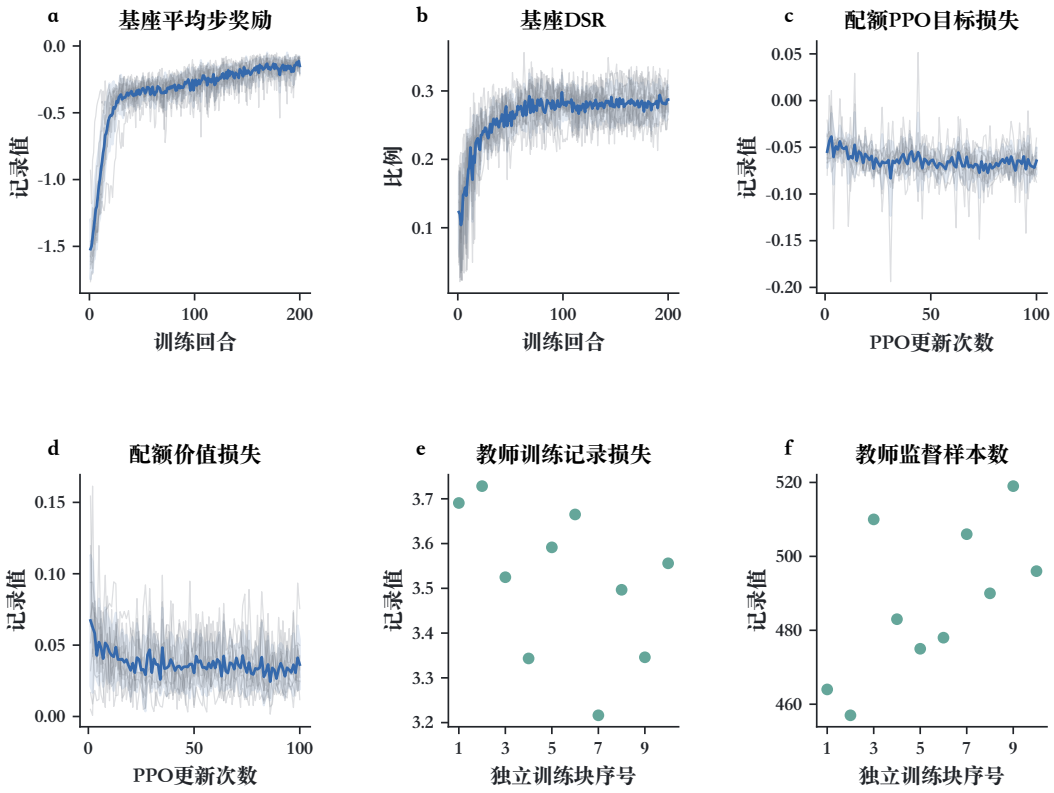
参数	数值	参数	数值
隐藏宽度	128	消息传递层数	2
请求/边/节点维数	4/14/16	动作数	91
每块采图回合	25	每块训练图数	200
教师总匹配预算/图	128	监督预训练轮数	5
PPO 更新次数	100	每更新采样图数	32
PPO epoch	8	监督/PPO 小批量	64
学习率	3×10^{-4}	梯度范数上限	0.5
PPO 裁剪范围	[0.8, 1.2]	熵系数	0.005
折扣因子	1	GAE 参数	0.95
在线匹配调用上限	16	普通修复候选上限	128

A.3.5　共同基座与交互、教师计算预算

每个独立训练块先重新训练覆盖需求分层基座 200 个回合，每回合 1000 步。共同基座包含上层与请求级 MAPPO 下层的最后参数、优化器与约束状态；确认中的六种下层方法从同一个上层基座出发。配额下层再使用 25 个回合采图及离线监督/PPO 计算；适配请求级下层则在冻结上层后继续训练 75 个回合，并恢复原优化器及 DSR、MBS 约束状态。冻结请求级下层组保留基座下层，贪心、启发式和强随机不进行额外模型训练。

另有 50 个回合用于固定策略数据采集，各方法复用相应记录。共同基座交互、配额采图、下层适配、教师匹配与网络优化具有不同计算需求，分别计量。实验比较对应这些预定训练设置下的方法表现，未将环境交互步数相同等同于总训练计算相同。

图 A.4 分别展示共同基座的环境训练与配额策略的搜索训练。两阶段具有不同横轴和奖励定义，曲线描述各自优化过程；方法的服务效果由独立确认评价。



前四面板：全部10块原始曲线；粗线为均值，带为块间±1 SD；未平滑
后两面板：每块一次教师监督记录；未保存逐轮损失，不构造教师收敛曲线

图 A.4　基座模型与配额策略训练收敛曲线

Figure A.4　Training Convergence Curves of Foundation Model and Quota Policy

注：前四幅图细线为各训练块原始曲线，粗线与阴影带为均值与标准差；后两幅图为逐块记录的教师监督损失与样本量。

附录 B　原十块确认、冻结九格及事后费用诊断

本附录的 SF-HLM 均特指原学习配额变体。原主 DSR 不计调度等待；原十块与第五章新二十块属于不同方法、样本与费用协议，不合并统计。原九格仅检验原学习变体，不能替代解析主方法的跨负载及算力确认。末节事后费用评分保持原动作及状态，费用未回写环境。以下保留原数值和比较对象。

B.1　独立确认设计与统计方法

B.1.1　场景、种子分割与最后检查点

主场景包含五架 UAV、一百 UE、一个 MBS 及 700 m × 700 m 区域，通信、请求生成、能量动态、自然接纳和奖励设置保持一致。开发使用五个训练块，独立确认使用十个未参与模型选择的训练块，并区分基座、下层训练与确认负载。候选结构、模型选择规则、检验族和性能判据均在确认前确定。

表 B.1　SF-HLM 独立确认实验数据与模型划分

Table B.1　Data and Model Partitioning for SF-HLM Independent Confirmation

用途	固定设置
独立训练块	1060001–1060010，共 10 块
基座训练负载	1080001–1080010，与各训练块一一对应
下层采图/适配负载	1090001–1090010，与各训练块一一对应
配额下层初始化	1100001–1100010，与各训练块一一对应
确认工作负载	1070001–1070005，全部方法配对复用
评价长度	每块每负载 6 回合，每回合 1000 步
模型选择	基座训练与配额更新均固定最后检查点
六方法质量评价	$6 \times 10 \times 5 \times 6 = 1800$ 回合
独立软件计时	另 1800 回合，在预留物理核心重放同一策略

所有学习、贪心、启发式和强配额随机方法在同一训练块内复用共同上层参数，工作负载与初始外生流配对。不同卸载会改变后续能量、缓存和观测，因此即使上层参数相同，长期轨迹也可能分化；本章评价是闭环运行，不是冻结几何下的反事实分配。配对只要求潜在请求、外生随机序列和模型对应关系按协议一致，并不要求每个时隙状态或生成服务请求分母完全相同。

六种核心方法的质量评价覆盖 180 万个环境步。软件计时重放相同模型与

外生流，分配及真实物理计数与质量评价一致。两类运行分别用于服务质量统计和隔离时间测量，独立训练重复数保持十个。

B.1.2　六个核心对照与两种补充随机策略

表 B.2 区分下层优化包与学习机制对照。启发式按当前合法目标的预测截止期风险选择配额迁移；强配额随机在有效迁移中随机选择，两者都拥有共同保底、条件匹配、最好保留和 16 次调用上限。它们不能与“每请求随机选一个目标”混为同一种随机基线。

表 B.2　下层与学习机制对照实验方法构成

Table B.2　Composition of Lower-Layer and Learning-Mechanism Baselines

方法	下层与比较用途
学习配额搜索	二部图 PPO 选择配额迁移，条件匹配；SF-HLM
启发式配额搜索	相同强框架与预算，按预测风险选择迁移；学习机制对照
强配额随机搜索	相同强框架与预算，在有效迁移中随机；严格学习增量对照
贪心＋普通修复	原始贪心后做最多 128 次普通修复；主要实用对照
冻结请求级下层＋修复	基座请求级 MAPPO 提案后共同修复；主要学习对照
适配请求级下层＋修复	冻结上层后继续 75 回合原下层训练，再共同修复
相同上层＋逐请求随机卸载	共同质量掩码内逐请求均匀随机；移除整个下层优化包
全随机（质量掩码内）	二维轨迹在 $[-1,1]^2$ 独立均匀采样，卸载逐请求随机

请求级 MAPPO 对照保留原始提案与采样概率，再以共同普通修复生成执行分配。适配组恢复基座优化器及自适应约束状态，继续训练已有下层；冻结组保持下层参数固定。两组均使用共同能耗参照和修复流程，与配额匹配组成完整方法对照。

确认后增加两种随机对照，复用十套固定模型和五个确认负载，每种方法运行 300 个质量回合与 300 个隔离计时回合。两者保持质量掩码、自然接纳和物理规则，移除贪心、普通修复、条件匹配、配额搜索、最好保留及预测能耗筛选。全随机评价完整系统，相同学习上层加逐请求随机卸载评价完整下层；学习搜索增量则由共享求解框架的强随机对照评价。

B.1.3　请求计数聚合与十个独立统计单位

令 $b = 1, \cdots, 10$ 为独立训练块，$w = 1, \cdots, 5$ 为工作负载，$e = 1, \cdots, 6$ 为评估回合，$t = 1, \cdots, 1000$ 为时隙。对方法 a，先合并同一块的全部请求计数：

$$G_b^a = \sum_{w,e,t} G_{bwet}^a, \qquad A_b^a = \sum_{w,e,t} A_{bwet}^a, \qquad S_b^a = \sum_{w,e,t} S_{bwet}^a. \tag{B.1}$$

再定义块级指标

$$D_b^a = \frac{S_b^a}{G_b^a}, \qquad a_b^a = \frac{A_b^a}{G_b^a}, \qquad q_b^a = \frac{S_b^a}{A_b^a}, \qquad D_b^a = a_b^a q_b^a. \tag{B.2}$$

主场景各块均有非零生成与接纳计数。空统计单元采用正分母保护，保持零成功计数。

方法的描述均值是 $\overline{D}^a = 10^{-1}\sum_b D_b^a$。这使每个独立模型块的权重相同，不让生成请求稍多的块获得更大统计权重。它也不同于先求每回合比率再平均，因为后者会让请求较少的回合与请求较多的回合占相同权重。本文使用请求计数汇总的定义，并在表、图和差值检验中保持一致。

跨块均值一般不满足 $\overline{D} = \overline{a}\,\overline{q}$，其差为

$$\overline{D} - \overline{a}\,\overline{q} = \frac{1}{10}\sum_{b=1}^{10}(a_b - \overline{a})(q_b - \overline{q}). \tag{B.3}$$

接纳率与条件完成率的跨块均值用于描述方向，精确分解则按同块计数计算，以保留块间协变。

训练块是主推断单位。五工作负载和六回合改善块内估计，单个请求提供服务计数，都不扩充独立训练样本数。强随机搜索在每块对应同一个学习上层，并具有独立策略随机流，因此其变化包含共同模型和策略随机性。全随机没有训练过程，补充评价的十个块只是与十套模型配对的独立随机流重复，不应称作十个全随机训练种子。

B.1.4 配对区间、多重比较与预定门槛

候选 a 与对手 c 的块级差值为 $\Delta_b = D_b^a - D_b^c$。其均值、标准差与双侧 95% 配对 t 区间为

$$\overline{\Delta} = \frac{1}{10}\sum_b \Delta_b, \quad s_\Delta^2 = \frac{1}{9}\sum_b(\Delta_b - \overline{\Delta})^2, \quad \mathrm{CI}_{95} = \overline{\Delta} \pm t_{0.975,9}\frac{s_\Delta}{\sqrt{10}}. \tag{B.4}$$

$t_{0.975,9}$ 约为 2.262，配对检验以十个训练块差值为数据。DSR 的绝对差异以百分点表示。

主检验族在确认前固定为学习相对贪心修复、冻结请求级下层修复和适配请求级下层修复三项。学习相对启发式与强随机属于独立的两项机制族。每族内部按 Holm 方法校正：将 K 个原始双侧 p 值升序排列，计算

$$p_{(i)}^{\mathrm{Holm}} = \min\left\{1, \max_{h\leqslant i}(K - h + 1)p_{(h)}\right\}. \tag{B.5}$$

三个主性能比较、两个机制比较和两个补充随机比较分别组成检验族，按对应评价前确定的范围校正。

每个主比较须同时满足：DSR 均值增益至少 1 个百分点、配对区间下界为正、Holm 校正 $p < 0.05$、仿真环境记录的 UAV 总能耗的块级比值平均不超过 1.05，以及候选每块完整软件 p95 小于 1 s。能耗比定义为

$$\bar{\eta}_{a/c} = \frac{1}{10} \sum_{b} \frac{E_b^a}{E_b^c}. \tag{B.6}$$

块级能耗比的平均值与两个总体能耗均值之比具有不同权重。预测能耗筛选约束单次分配，性能判据评价仿真机队总能耗；统计显著性与预定实用增益也分别报告。

学习与强随机的差值另进行精确符号翻转敏感性检验。十块配对差形成 2^{10} 种符号组合，以均值绝对值检验零假设，考察小样本推断对分布假设的敏感性。该检验要求零假设下差值符号可交换，与配对 t 推断并列报告。

B.1.5　能耗、公平性、MBS 与完整软件计时

仿真环境记录的总能耗 E_b^a 汇总五架 UAV 的飞行与作业等全部环境记录，再除以块内 30000 个时隙得到 J/步。该量不包括 MBS 计算、真实部署的新增控制通信和获取大范围需求信息的全部费用，所以 UAV 节能与全网节能是不同主张。公平性按第三章 Jain 指数逐时隙计算，再在块内平均；MBS 占比为块内送往 MBS 的请求数除以已接纳服务请求数。MBS 分母是接纳数，不是全部生成数。

主评价的请求时延包含模型规定的通信与计算路径，不计调度器求解等待。完整软件时间从移动前输入准备开始，包含观测构造、两层策略推理、共同保底、配额搜索、匹配、动作映射及逻辑消息编码，排除环境物理仿真和结果落盘。先在各训练块 30000 次策略调用上计算 p95，再跨块平均；每块最大 p95 单独用于预定门槛。隔离计时在预留物理核心运行，与共享集群上的质量评估计时区分。相同模型和外生流重放保证时间测量不改变动作及质量，硬件和软件测量条件限制其可外推范围。

逻辑上传和下载字节由请求行、动作与摘要的序列化记录计算，用于描述协调信息规模。当前评价未将其转换为实际通信等待或能源开销。进一步研究可在请求截止期判定和能耗结算中加入上报、汇总及下发成本，独立评价通信受限条件下的服务质量。

B.2　主场景性能与完整下层优化包的收益

B.2.1　代表轨迹与实际注意力记录

先以一个事先固定的评估实例展示集群在线运行形态：取首个确认训练块 1060001、首个工作负载 1070001、第 0 回合，绘制学习配额与贪心修复的五机轨迹、实际航程和最小机间距，如图 B.1。两方法起始外生条件和冻结上层参数相同，但下层执行影响电量、缓存和后续观测，轨迹随闭环状态演化可以不同。选择首实例而不是视觉上最有利的轨迹，有助于把运行示例与全样本性能推断分开。

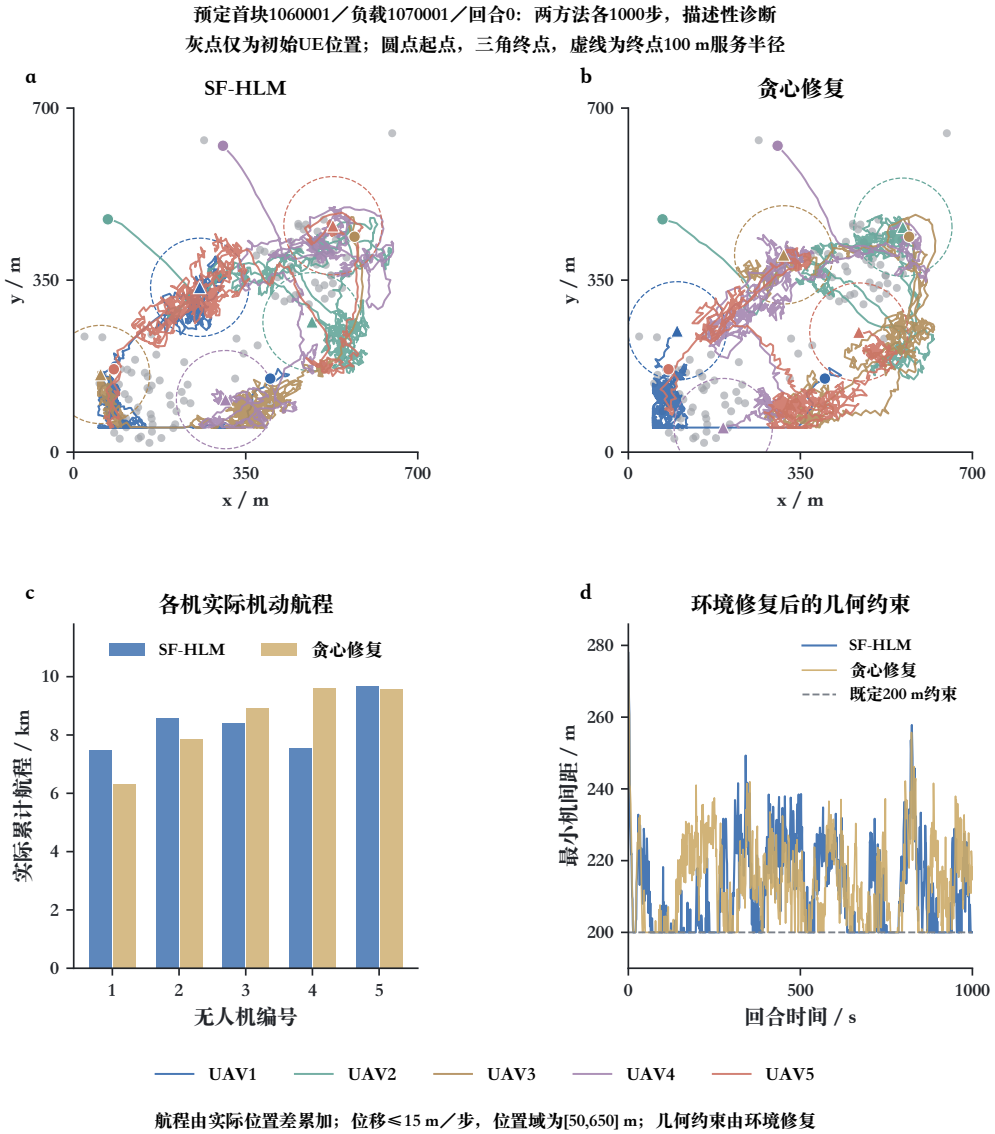


图 B.1　典型确认回合无人机集群空间机动轨迹图

Figure B.1　Spatial Trajectories and Flight Metrics of UAV Swarm in Representative Confirmation Episode

注：上排灰点表示终端初始位置，虚线表示终点服务范围；下排展示航程与最小机间距（参考线为 200 m 防撞约束）。

逐机航程由实际位置差累加，即 $\ell_u = \sum_{t=0}^{T-1} \|\mathbf{q}_u(t+1) - \mathbf{q}_u(t)\|_2$，其中 $T = 1000$，ℓ_u 的单位为 m；它不使用网络原始动作模长代替执行位移。该回合中，SF-HLM 五机航程之和约为 41.664 km，贪心修复约为 42.291 km。这些数值描述预选实例的机动分工，不代表全评估总体中的航程差异。最小机间距按 $d_*(t) = \min_{u<v} \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2$ 逐步计算；两方法的实际位置记录连续，最大单步位移不超过 15 m，最小间距为 200 m，核验采用 10^{-6} m 浮点容差。该结果检查的是修复后的离散位置，而不是学习策略独立提供的连续飞行避碰能力。

轨迹图的地面散点表示初始 UE 位置，服务圆表示终点几何，动态接纳率由完整请求计数计算。图 B.2 展示同一回合第 500 步上层 Actor 的注意力，采用该步输入、模型权重与实际前向缩放、掩码，描述可见邻机和需求的信息聚合。

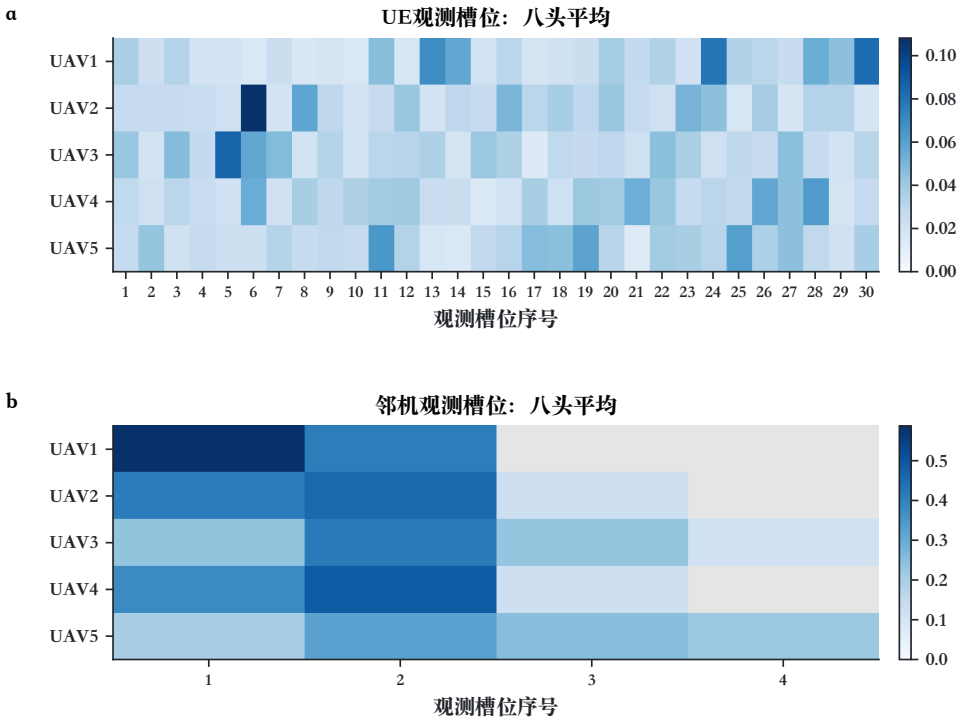


图 B.2　典型时步上层网络注意力权重热力图

Figure B.2　Attention Weights of Upper-Layer Actor at Representative Step

注意力图描述代表状态的信息聚合，独立评价则检验完整策略的服务效果。核心六组共享需求感知上层，因此本章比较集中于同一轨迹基座上的下层任务组织，上层观测及结构比较见第三章。

B.2.2 八种方法的截止期满足表现

表 B.3 和图 B.3 汇总六种核心方法的独立确认与两种补充随机评价。补充对照复用相同模型和确认负载，均以实际生成服务请求为分母并按块汇总计数。SF-HLM 的 DSR 为 34.244%，在八种方法中具有最高描述均值。以下差值均来自本章对应的配对评价。

表 B.3 100 用户主场景下各方法服务性能指标对比

Table B.3 Service Performance Metrics in 100-UE Main Setting

方法	DSR/%	接纳率/%	接纳后完成率/%
学习配额搜索	**34.244**	57.339	59.819
启发式配额搜索	33.475	57.342	58.472
强配额随机搜索	34.100	57.379	59.517
贪心＋普通修复	32.821	57.367	57.305
冻结请求级下层＋修复	32.236	57.375	56.309
适配请求级下层＋修复	32.052	57.383	55.953
全随机（质量掩码内）	15.428	33.797	45.673
相同上层＋逐请求随机卸载	23.640	57.431	41.222

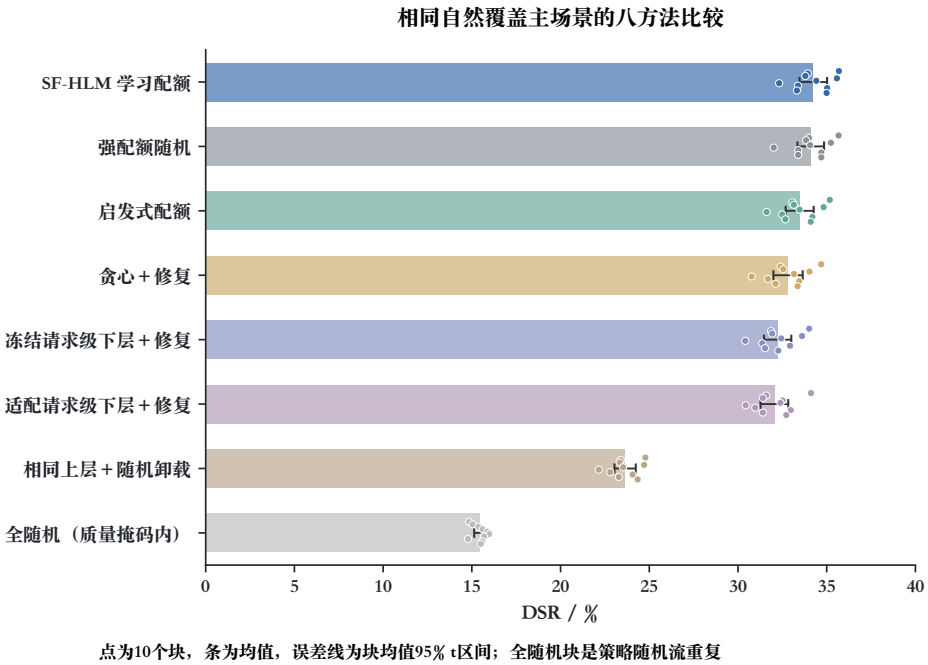


图 B.3 主场景下八种方法 DSR 性能对比

Figure B.3 DSR Comparison of Eight Methods in Main Setting

学习相对贪心修复的主增益为 1.423 个百分点，相对冻结请求级下层、适

配请求级下层修复分别为 2.008 和 2.192 个百分点，完整区间与校正检验列于表 B.4. 三项差值均在十个训练块上同向为正；图 B.4 展示这些块级配对差，说明均值优势并非由单个异常训练块独自支撑。三项均达到预定 1 个百分点实用目标，区间下界为正，并通过三比较 Holm 校正。

表 B.4　三个主对照方法的 DSR 配对差值与能耗比对比

Table B.4　Paired DSR Differences and Energy Ratios for Three Primary Controls

学习减对手	差值/百分点	95% 区间/百分点	Holm p	能耗比
贪心＋普通修复	+1.423	[1.258, 1.587]	2.22×10^{-8}	0.9094
冻结请求级下层＋修复	+2.008	[1.808, 2.208]	8.92×10^{-9}	0.9656
适配请求级下层＋修复	+2.192	[1.903, 2.481]	3.46×10^{-8}	0.9803

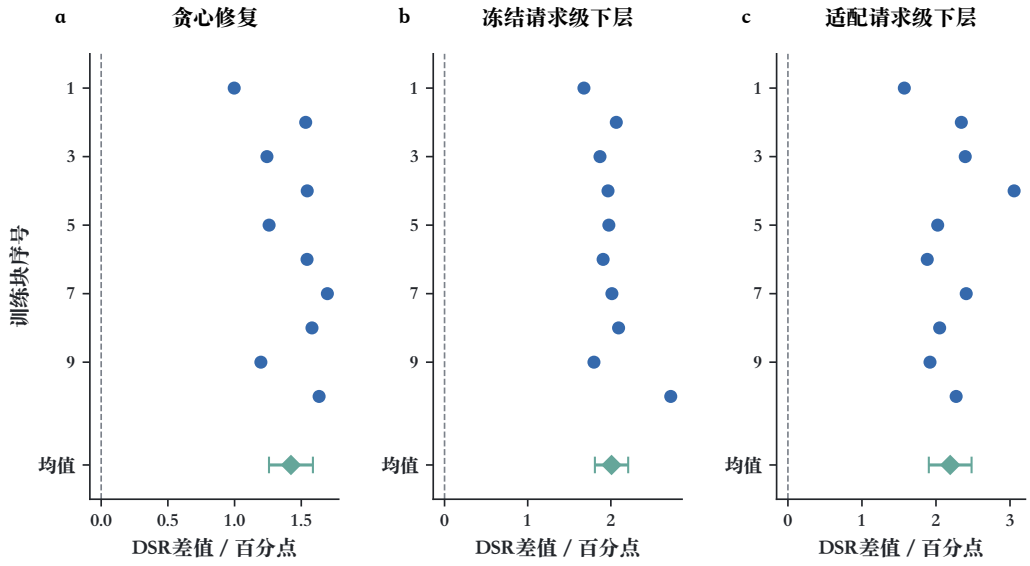


图 B.4　SF-HLM 相对三个主对照方法的逐块 DSR 配对差值

Figure B.4　Per-Block Paired DSR Differences of SF-HLM Against Three Primary Controls

两种请求级学习对照使用共同普通修复，适配组另继续训练下层。在一百 UE 主场景、十个独立训练块及预定训练设置下，三个主比较支持 SF-HLM 完整下层的端到端 DSR 改善。教师计算和不同训练流程分别记录，结构贡献由后续共享框架机制对照评价。

B.2.3　接纳与接纳后质量的请求计数分解

核心六方法的平均接纳率均约为 57.3%。SF-HLM 与贪心的接纳率分别为 57.339% 和 57.367%，接纳后完成率为 59.819% 和 57.305%。共享上层下，改善主要体现为已接纳请求的执行质量；各方法仍按自身闭环轨迹统计请求，保留状

态分化的影响。

图 B.5 将生成请求分为未接纳、接纳后超时与按时完成三个互斥部分。块内占比分别为 $(G-A)/G$、$(A-S)/G$ 和 S/G，相加为 1；跨块平均保持该线性恒等式。SF-HLM 中三个部分约为 42.661%、23.095% 和 34.244%。同上层逐请求随机卸载的按时完成率仅为 41.222%，而接纳率仍为 57.431%，显示进入服务范围后的执行质量构成主要差距。

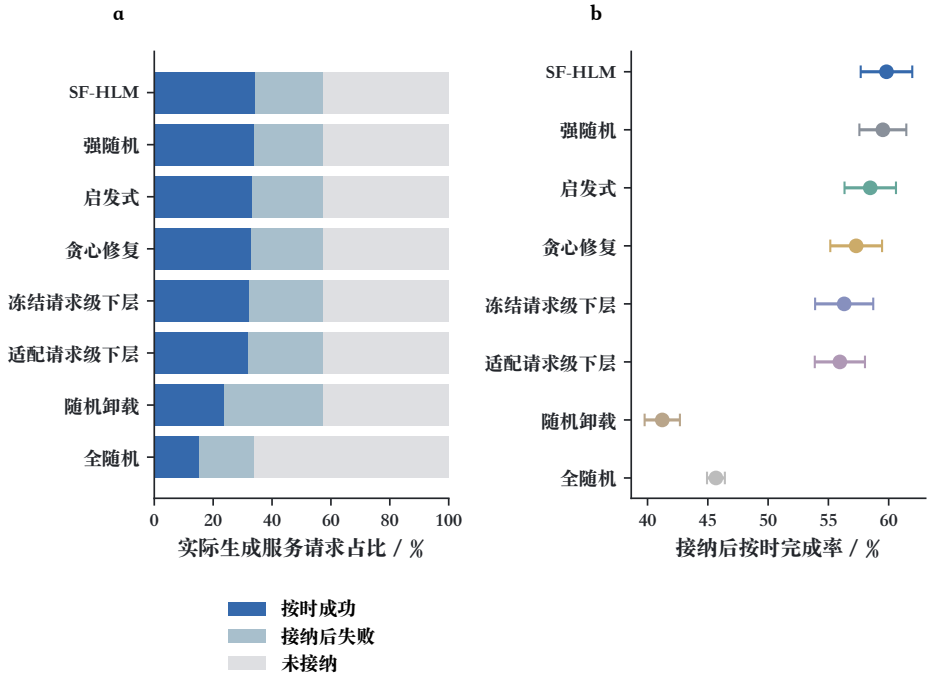


图 B.5　服务请求执行结果分解与条件完成率对比

Figure B.5　Decomposition of Request Outcomes and Conditional Completion Rate

全随机接纳率为 33.797%，明显低于采用学习上层的策略组，反映完整系统在形成服务机会方面的收益。保留学习上层之后，随机卸载的接纳后质量仍远低于配额匹配。这两个对照有助于解释覆盖与服务质量各自的作用，但不是固定状态下可相加的因果分解：全随机改变运动，随机卸载改变能量和后续观测，二者的状态轨迹不同。本文使用分解描述实际结果，不把 18.816 个百分点机械拆成几个独立组件贡献。

B.2.4　UAV 能耗与 MBS 依赖

表 B.5 和图 B.6 同时报告 UAV 机队能耗与 MBS 占比。SF-HLM 的仿真环境记录的 UAV 能耗为 30394.4 J/步，低于贪心修复的 33419.9 J/步；按块能耗比平均计，降低约 9.06%。相对冻结与适配请求级下层修复，块级能耗比为 0.9656 与 0.9803。因此三个主比较的 DSR 改善没有以超过预定机队能耗门槛为代价。

表 B.5　主场景下各方法资源开销、公平性与软件耗时对比

Table B.5　Comparison of Resource Costs, Fairness, and Software Time in Main Setting

方法	UAV 能耗/(J/步)	MBS 占比/%	公平性	块 p95 均值/ms
学习配额搜索	30394.4	9.83	0.9239	109.24
启发式配额搜索	31854.7	2.42	0.9209	78.16
强配额随机搜索	30123.1	8.17	0.9216	73.47
贪心＋普通修复	33419.9	2.92	0.9212	17.59
冻结请求级下层＋修复	31484.7	3.07	0.9207	17.19
适配请求级下层＋修复	31010.1	4.14	0.9208	17.17
全随机（质量掩码内）	59649.6	29.65	0.7874	4.70
相同上层＋随机卸载	57503.7	29.45	0.9208	6.57

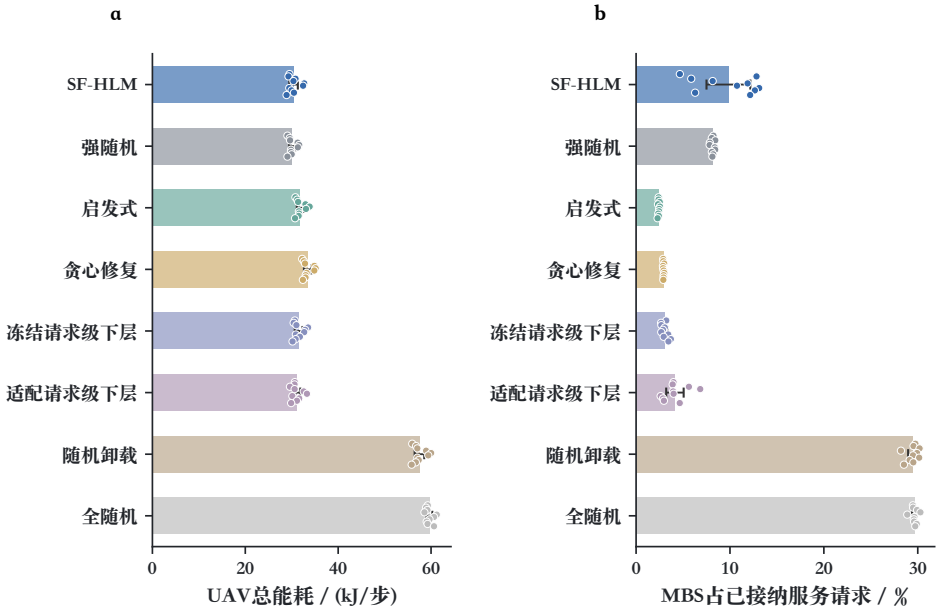


图 B.6　无人机机队能耗与宏基站依赖度对比

Figure B.6　Comparison of UAV Fleet Energy and MBS Dependence

注：能耗单位为 kJ/步，宏基站比例为分派至宏基站的请求在已接纳请求中的占比。

SF-HLM 送往 MBS 的接纳请求比例为 9.83%，高于贪心的 2.92% 和启发式的 2.42%。在 MBS 单请求算力不共享的设置下，任务转移释放 UAV 算力并改变其计算与转发能耗。因此，UAV 能耗下降需结合 MBS 依赖解释，其统计范围未包含地面计算和完整网络能源。

逐请求随机卸载的 MBS 占比接近 29.5%，却同时具有较低 DSR 和较高 UAV 能耗，说明 MBS 比例本身不是充分的性能解释。请求身份、回传路径、UAV 剩余批量和质量掩码共同影响结果。后续共同 MBS 数量快照诊断将进一步控制这一维度，检验配额匹配在固定 MBS 使用数量时仍有多少单步质量余量。

表 B.6　主场景下机队飞行与计算能耗构成

Table B.6　Components of Fleet Flight and Computation Energy in Main Setting

分项	学习/J	占比/%	强随机/J	占比/%	贪心/J	占比/%
计算	29205.1	96.079	28934.0	96.048	32232.6	96.442
飞行与悬停	1166.4	3.846	1166.7	3.878	1166.9	3.496
服务通信	2.3	0.008	2.3	0.008	2.3	0.007
回源或回传	3.4	0.011	2.9	0.010	1.0	0.003
内容服务	16.8	0.055	16.8	0.056	16.8	0.050
WPT	0.4	0.001	0.4	0.001	0.4	0.001
总计	30394.4	100.000	30123.1	100.000	33419.9	100.000

表 B.6 使用原确认记录的逐步能耗分项，重放仅补充核验。先在每块合并六回合与五负载，再对十块等权平均；分项占比按各块分项除以该块总能耗后平均。分配因果能耗与上述分项有重叠，故不另加一项。计算项占三方法总费用约 96%，说明本模型的节能排序主要受等效计算能耗影响。各项在未舍入时精确加总，总额复现原表；显示精度下的细小差异来自舍入。该模型分解不对应实测机载功率或续航。

B.2.5　公平性、计算费用与可执行性

SF-HLM 公平性均值为 0.9239，核心六方法约在 0.9207 至 0.9239 范围；全随机为 0.7874。图 B.7 展示公平性和隔离软件 p95。SF-HLM 在共享上层组中保持较高的描述公平性，同时完整软件 p95 的块均值为 109.24 ms，各块为约 103–114 ms，最大为 114.343 ms，均小于预定 1 s 阈值。该结果证明在本次隔离测量条件下，完整在线调用满足协议时间门槛。

SF-HLM 的完整时间高于强配额随机的 73.47 ms、启发式的 78.16 ms 和贪心修复的 17.59 ms。图推理减少部分匹配尝试，同时增加网络前向费用。服务质量、

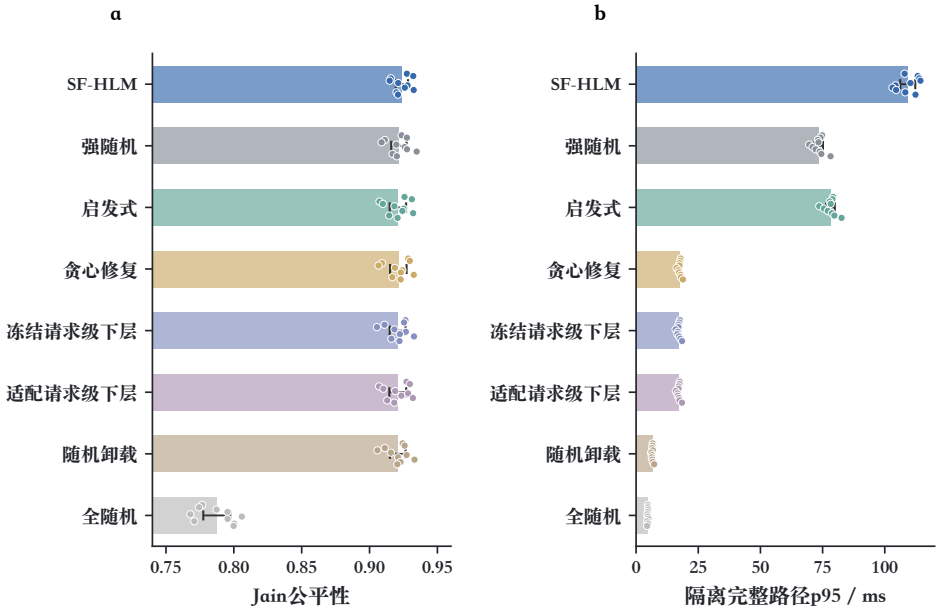


图 B.7　服务公平性与软件决策延迟分布对比

Figure B.7　Comparison of Service Fairness and Software Latency Distribution

公平性、匹配调用和全路径时间共同刻画方法收益与执行负担。

上述时间结论适用于规定服务器的隔离测量，未计入现实网络等待、MBS 排队及额外需求感知成本。当前服务指标与软件费用分别评价；满足一秒软件门槛不能直接证明计入求解等待后的截止期增益。面向机载部署仍需补充对应硬件与通信测量。

B.3　完整框架与学习机制的分层解释

B.3.1　完整系统与完整下层优化包

补充随机评价显示，SF-HLM 相对全随机 DSR 高 18.816 个百分点，95% 配对区间为 [17.840, 19.791]；相对相同上层逐请求随机卸载高 10.604 个百分点，区间为 [10.376, 10.832]。两项十块均为正，新两比较 Holm 校正通过，精确符号翻转 $p = 0.001953$。对应仿真环境记录的 UAV 能耗块级比为 0.5095 与 0.5284，即平均分别降低约 49.0% 和 47.2%。

在共同质量合法域下，SF-HLM 使用贪心初始化、普通修复、预测能耗筛选、条件指派和最好保留，相对逐请求随机的 10.604 个百分点改善评价这一完整优化框架。该结果显示，配额分解与条件匹配能够更有效地利用已形成的服务机会；学习策略在共享框架上的额外作用由下文机制对照进一步评价。

全随机的十个块对应独立随机动作流，与十套学习基座配对。补充评价复用

模型与确认负载，区间反映这些条件下的模型和随机策略变化，不增加主确认的独立训练重复数。

B.3.2 相同强框架上的学习配额增量

共享强框架中，启发式 DSR 为 33.475%，强配额随机为 34.100%，学习为 34.244%。学习相对启发式差 0.769 个百分点，95% 区间 $[0.670, 0.868]$，机制族 Holm $p = 5.56 \times 10^{-8}$。这说明按图状态学习的配额选择优于本实验采用的风险排序启发式。该判断限定于所定义的启发式，不把一个启发式的结果外推为所有手工搜索规则都不能达到同样质量。

图 B.8 展示共享框架的块级差。学习相对强随机增量为 0.143 个百分点，区间 $[0.006, 0.281]$；十块中六块为正，预定机制族 Holm $p = 0.0422$。精确符号翻转检验则为 $p \approx 0.0605$。小效应的两种推断存在差异，表明学习增量对统计方法具有敏感性。

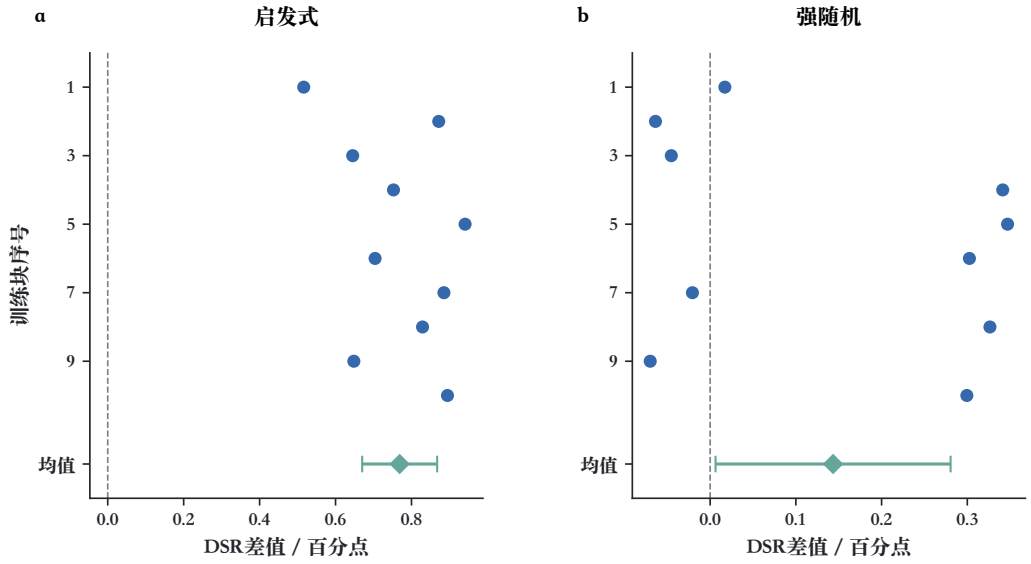


图 B.8 学习机制相对启发式与随机搜索的配对性能差值

Figure B.8 Paired Performance Differences of Learning Mechanism Against Heuristic and Random Search

强随机在相同预算内接近学习质量，显示条件匹配、共同保底和最好保留发挥了较大作用。学习的额外收益较小，软件时间更长，相对强随机的 UAV 能耗块级比为 1.0089。因此，完整方法相对贪心与请求级学习修复的改善，以及共享框架上的学习增量，分别构成两个层次的结论。

B.3.3　预测误差与实际服务验证

SF-HLM 每步预测超时数减实际接纳后超时数的均值为 −0.304 个请求，平均绝对误差为 0.366；贪心相应值约为 −0.209 和 0.321。负偏差说明观测预测总体上略低估真实超时，可能涉及缓存信念与真实状态的差别及执行细节。本文没有把预测器视为真实时延保证，所有 DSR 结果均由仿真环境的按时完成计数计算。

误差统计与条件最优证明并不矛盾。指派在给定预测量下精确优化，描述的是求解结构；预测量与实际执行之间仍存在误差，描述的是模型真实性。二者需要分别检查。如果只报告预测超时减少，可能把更乐观的预测当成性能提高；本章逐步重放实际计数，并在固定快照诊断中通过独立环境副本评价实际结果，使搜索时没有接触的执行真值用于最终验证。

B.3.4　固定潜在服务请求分母复核

相同外生随机流下，低电量 UE 会将潜在服务请求改为能量请求，因此实际生成服务请求分母有轻微策略依赖性。六个核心方法在全部确认回合中的潜在服务请求总数均为 11397280。保持原成功数不变，以共同潜在请求为分母，学习 DSR 均值为 34.235%，强配额随机为 34.091%；学习相对贪心的增益为 1.421 个百分点，与预定实际分母下 1.423 的方向和量级一致。

共同潜在分母复核仍保留三个主比较的增益，说明轻微实际分母变化不足以解释服务改善。该分析仅重新计算比率，保留原运行成功数和请求生成过程，作为实际分母 DSR 的敏感性结果。

B.3.5　教师初始化与 PPO 的开发证据

学习策略的独立确认比较教师初始化后经 PPO 更新的完整策略与共享求解框架对照，不能单独识别 PPO 更新的作用。为解释训练选择，补充五个历史训练块上的开发比较。该批次复用历史上层、训练图和开发负载，分别评价即时改进教师、多步路径教师及多步教师加动作效果特征的 BC 与 PPO 检查点。表 B.7 报告各自 PPO 减 BC 的结果，不能与十块确认当作同一次重复实验合并。

原教师配置下的开发差值与 PPO 有益的解释一致，但另外两种配置没有同样方向，说明强化学习更新的效果依赖教师、输入和搜索分布。仅五块时，前后两项精确符号翻转 p 均为 0.0625，这些开发结果只用于方法选择解释，不替换主确认或升级为新的确证。当前学习策略的主要服务收益仍建立在共同修复、条件匹配和最好方案保留之上；是否采用学习搜索需要同时判断其批次质量增量与

表 B.7　开发评估中 PPO 相对行为克隆算法的性能差值
Table B.7　Performance Differences of PPO Against Behavior Cloning in Development Evaluation

教师与输入配置	DSR 差/百分点	逐项 95% 区间/百分点	正向块数
原即时改进教师	+0.935	[+0.296, +1.573]	5/5
多步路径教师	−0.008	[−0.704, +0.689]	2/5
多步教师＋动作效果特征	−0.364	[−0.564, −0.164]	0/5

软件费用。其取舍结合第 B.5.5 节的截止期余量分析，不能仅凭开发阶段增量决定在线方法。

B.4　冻结策略的负载与算力稳健性

B.4.1　九格设置与冻结评价

独立确认完成后，冻结十套基座和配额最后检查点，在 60/100/140 UE 与 0.6/1.0/1.4 倍 UAV 算力的九格上评价。每格保持原五负载、六回合和六种核心方法，主格直接引用原 1800 回合，八个新格共完成 14400 个质量回合。权重、优化器、奖励、MBS 算力与自然接纳保持不变，只按协议调整 UE 数和 UAV 算力。这是固定策略面对新负载与资源规模的复验，不是各格重新训练后的场景适应比较。

上层保持训练时的 30 个 UE 槽，超过容量的需求按相同排序截取。图下层按实际请求数构图，请求级 MLP 下层沿用填充与分块推理，均保持训练后的网络尺寸和权重。各方法使用相同变体环境，复用原训练块与确认负载，评价整套固定策略在规定格点上的表现。

表 B.8　不同用户规模与算力配置下 SF-HLM 的 DSR 表现
Table B.8　DSR Performance of SF-HLM Across Different User Scales and Compute Capacities

UE 数量	0.6 倍算力/%	1.0 倍算力/%	1.4 倍算力/%
60	44.430	48.961	50.746
100	29.736	34.244	36.349
140	22.142	26.259	28.263

表 B.8 和图 B.9 显示，增加 UE 数量时 DSR 下降，提高 UAV 算力时 DSR 上升。相同覆盖范围和计算节点需服务更多请求，且上层可见需求槽位固定，高负载同时加剧接纳与服务质量压力；增加算力能减轻部分计算瓶颈，却不能消除未接纳和通信路径限制。因此，算力提高到 1.4 倍时 DSR 仍明显低于 100%，不能

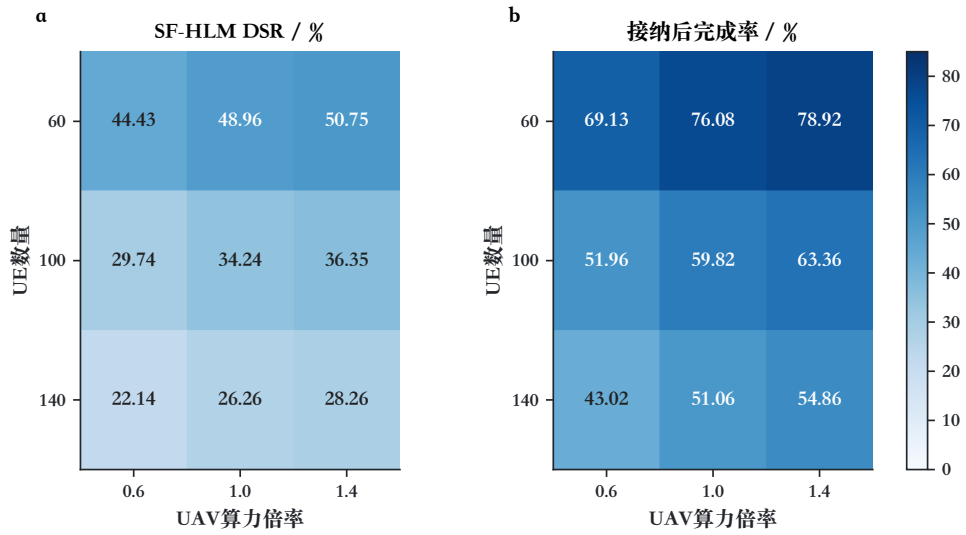


图 B.9　九种参数配置下 SF-HLM 的服务指标表现

Figure B.9　Service Metrics of SF-HLM Across Nine Parameter Configurations

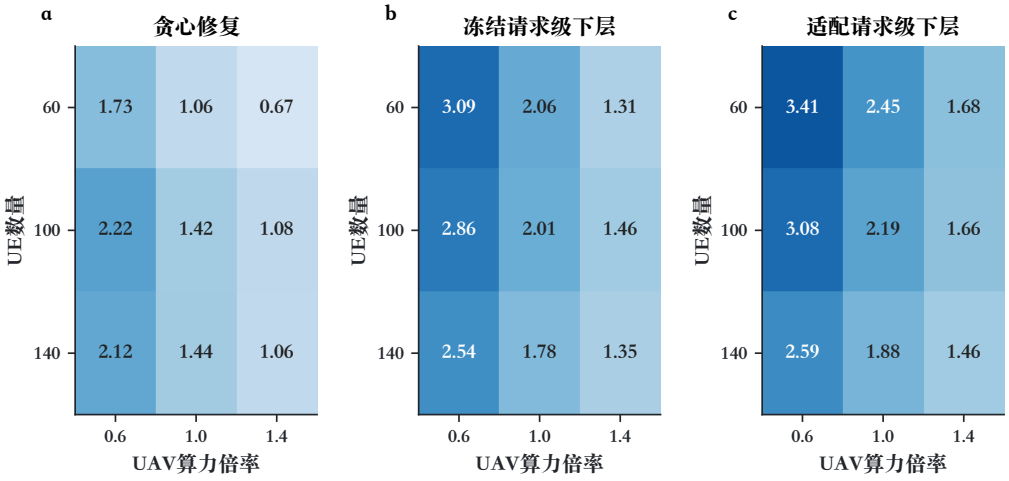
将剩余失败都归因于下层计算不足。

B.4.2　相对三个主对手的格点差值

八个新格中学习相对贪心、冻结请求级下层和适配请求级下层的 24 项比较形成一个 Holm 主族，全部通过校正。图 B.10 给出格点配对均值差；下文同时报告代表格点的逐项 95% 配对 t 区间，完整格点结果保存在冻结实验归档中。相对贪心的增益从 0.667 到 2.219 个百分点，相对冻结请求级下层从 1.310 到 3.086，相对适配请求级下层从 1.460 到 3.410。该结果支持 SF-HLM 对这些对手的优势在所考察负载与算力组合中保持正向。

低算力与高负载下，贪心修复的局部选择更容易形成截止期敏感的批量，配额匹配的改善较明显。例如 100 UE/0.6 算力下学习 DSR 为 29.736%，贪心为 27.517%，差 2.219 个百分点，区间 $[2.051, 2.387]$；140 UE/0.6 算力差 2.125，区间 $[1.931, 2.318]$。在 60 UE/1.4 算力下，学习为 50.746%，贪心为 50.078%，差 0.667，区间 $[0.493, 0.842]$。后者的差值区间为正，但未达到主确认事先采用的 1 个百分点实用目标。

仿真环境记录的 UAV 能耗比同样随格点变化。学习相对贪心的块级比约为 0.876–0.939，各新格均低于 1；相对适配请求级下层在 60 UE/0.6 算力约为 1.0078，没有节能但仍低于 1.05 门槛。能耗还受算力平方项影响，提高计算能力可以改善时间，却可能增加实际计算能耗。因此，格点分析联合评价服务率和资源费用。



数值为SF-HLM减对手的DSR差（百分点）；同10套冻结权重，各格均含五负载×六回合

图 B.10　九种参数配置下 SF-HLM 相对主对照方法的 DSR 差值
Figure B.10　DSR Differences of SF-HLM Against Primary Controls Across Nine Configurations

B.4.3　强框架机制的场景依赖

学习相对启发式与强随机的八格共 16 项比较另组成 Holm 机制族，其中 8 项通过：学习相对启发式在七个新格通过，相对强随机仅在 140 UE/0.6 算力通过。该格学习–强随机差约 0.355 个百分点，区间 $[0.150, 0.560]$，Holm $p = 0.0317$。其他格不能仅因未校正区间下界为正而宣称机制已稳定成立。

在 60 UE/1.4 算力格，强随机 DSR 为 50.772%，学习为 50.746%，差值约 −0.026 个百分点且区间跨零。结合主场景的小增量，结果表明学习额外优势依赖负载与算力，资源宽裕时强匹配框架已能取得接近学习的质量。

九格评价沿用相同观测范围和理想协调条件，刻画固定策略对规定负载与算力变化的适应程度。信息上报延迟、缺失及通信费用未随格点变化，仍是部署评价需要检验的条件。

B.5　固定快照、共同 MBS 与时间预算诊断

B.5.1　相同状态下的真实执行复核

为控制闭环状态差异，从 SF-HLM 的十块轨迹中，在五个负载的前两个回合分别于 0/250/500/750 步采集移动前状态，共 400 个快照，包含空批次。观测预测行供算法搜索，独立环境副本供最终候选分配的环境执行超时与能耗评价。两类副本保留相同几何、请求和历史状态，反事实结果不回写轨迹。

每块含 40 个快照，先在块内平均，再以十个基座作配对分析。自由 MBS 的常规调用设置下，学习、启发式、强随机和贪心每快照实际超时数分别为

10.2925、10.6450、10.3700 和 10.8275。学习–贪心差为 −0.5350 个请求，区间 [−0.6837, −0.3863]；学习–强随机为 −0.0775，区间 [−0.1989, 0.0439]。这说明共同状态下相对贪心有质量余量，相对强随机的差仍较小且不确定。

B.5.2　保持共同 MBS 请求数量

以每快照原始贪心的 MBS 请求数量为共同参照，要求初始化、修复、配额掩码、条件匹配和保底均保持这一数量，只允许改变哪些请求使用 MBS。图 B.11 对照自由和固定 MBS 结果。在固定数量下，四方法平均 MBS 请求数均为 0.6950，学习、强随机和贪心实际超时分别为 10.4075、10.4050 和 10.7875。学习–贪心仍为 −0.3800，区间 [−0.5044, −0.2556]；学习–强随机为 +0.0025，区间 [−0.0919, 0.0969]。

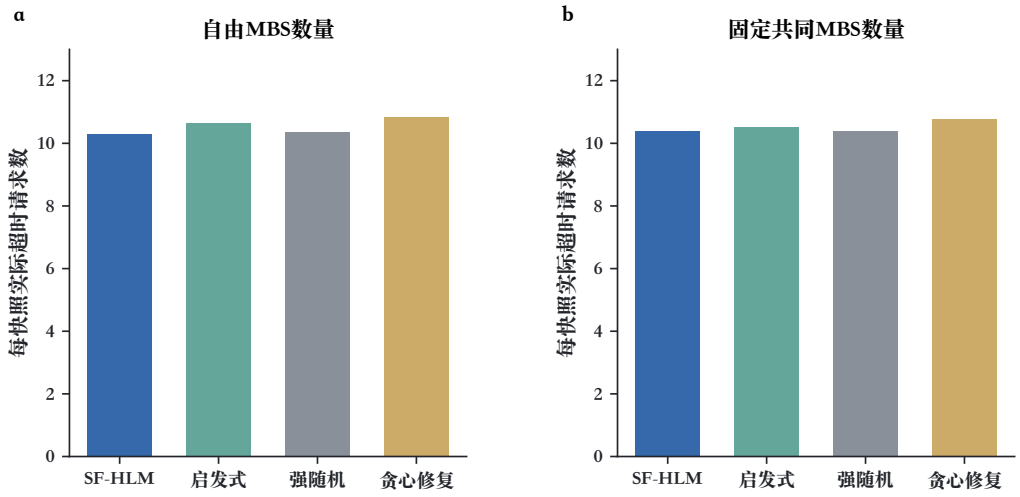


图 B.11　宏基站协同模式对任务超时影响诊断图

Figure B.11　Diagnostic Comparison of Deadline Misses under Different MBS Coordination Modes

注：基于 400 个固定快照测试；描述性均值对比，反事实分配不回写环境状态。

固定 MBS 配额时，学习的环境分配能耗为每快照 29619.2 J，强随机为 29202.0 J，贪心为 31637.5 J。相对贪心，学习在相同 MBS 数量下仍减少超时和分配能耗；相对强随机，自由 MBS 时的小幅质量差在固定配额下未保留。该诊断控制单步资源使用，结果适用于相同快照，固定 MBS 约束下的长期 DSR 尚需闭环评价。

B.5.3　软墙钟预算下的质量与超限

在同一组快照施加 20/50/100 ms 全路径软预算，时间从输入准备开始，包含模型推理、初始化、普通修复、搜索匹配、动作映射和消息编码。输入准备消耗

先从搜索可用时间扣除；预算不足时保留合法保底。各档仍保持原在线最多 16 次条件匹配与 128 次普通评价，不为了时间曲线将模型的预算特征改成未经训练的无限调用值。

图 B.12 同时展示质量、完整时间与超限比例。三档预算下学习每快照实际超时数为 10.6725、10.4250 和 10.3000，平均时间为 22.17、43.65 和 62.92 ms。预算放宽时，质量接近普通调用的 10.2925；该实验使用同一策略在固定快照上调整执行预算。

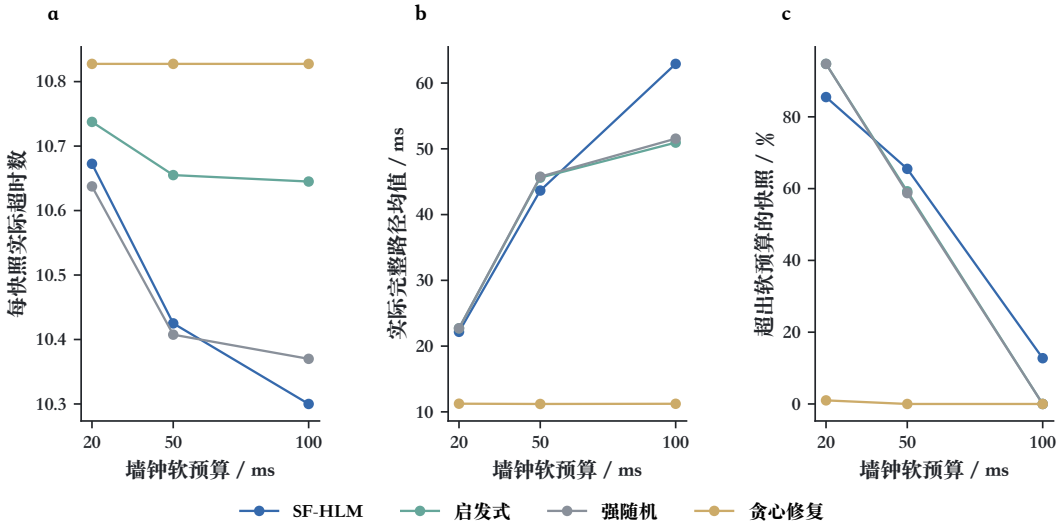


图 B.12　软时限预算下算法求解质量与超时率分析

Figure B.12　Solution Quality and Overrun Rates under Soft Wall-Clock Budgets

三档预算的超限快照比例为 85.5%、65.5% 和 12.75%，最大超限约 7.33、7.06 和 6.19 ms。时间检查发生在原子匹配前，已开始的求解、动作映射与序列化仍需完成。因此预算是软截止，实际超限量与服务质量一并报告。

B.5.4　匹配调用与停止行为

图 B.13 展示 SF-HLM 在十个训练块、共 300000 个确认评估环境步中的调用预算使用与终止记录，包含空请求批次，平均每步使用 11.737 次匹配。另在普通固定快照诊断协议下，学习平均使用 11.255 次匹配，启发式 16.000，强随机 15.990；前者汇总闭环环境步，后者汇总固定快照。预算包含初始匹配，不能把调用数理解为额外迁移数。学习可在保留当前最好方案后提前 STOP，而强随机按有效非停止动作继续直到无可尝试动作或调用耗尽。停止动作与调用惩罚共同给出节约求解机会，但实际学习前向开销仍使完整软件时间高于强随机。

普通快照中，学习完整平均时间约 63.30 ms，强随机约 51.53 ms；p95 分别约为 105.24 和 74.85 ms。这一排序与确认阶段的隔离测量一致，表明搜索效率

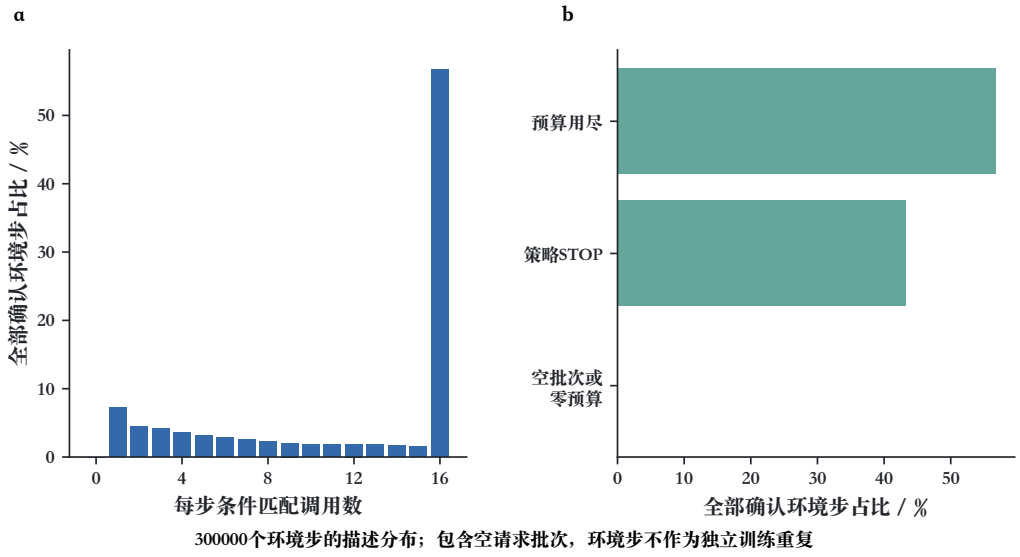


图 B.13　算法匹配调用次数与终止行为统计图

Figure B.13　Statistics of Matching Calls and Termination Behavior in Confirmation Steps

需同时考察调用数量、网络推理开销和服务质量。

B.5.5　调度延迟敏感性与软件费用事后复核

为连接路径质量与调度费用，补充学习配额、强配额随机和贪心修复三个方法的原确认轨迹复核。每方法仍为十训练块、五工作负载、每负载六回合与每回合 1000 步，即每方法 300 回合，三方法共 900 回合。重放读取原卸载动作，由冻结上层重现位置决策；在请求刷新前采集实际路径时延与截止时间。逐步指标、请求计数、外生流、检查点和模型摘要均与原记录核对。该过程未训练或筛选模型，也未把新延迟回写状态。

第一类评分对所有方法施加共同附加等待 $\delta \in \{0, 20, 50, 100, 150\}$ ms，把原成功条件替换为 $T_m + \delta \leqslant D_m$，未接纳请求仍计入原生成分母。第二类评分按训练块、负载、回合和步号配对原隔离计时记录，使用该方法每次完整软件调用时间 c_t 判断 $T_m + c_t \leqslant D_m$；不以平均或 p95 时间替代逐次费用。两类均先汇总块内成功与生成计数，再计算十块等权均值和逐项配对 t 区间。它们是原轨迹上的探索性事后评分，不扩充独立训练重复数，也不改变预定主检验族。

零附加延迟精确复现原三方法 DSR。共同等待增大后，各方法 DSR 下降，但差值并非固定平移：100 ms 时学习减贪心为 −0.329 个百分点，150 ms 时为 −0.728，说明原学习分配的截止期余量对等待更敏感。学习对强随机的差仍较小，20 和 50 ms 逐项区间跨零；该探索性分析不构成独立确认。

逐次软件费用评分下，学习、强随机和贪心的 DSR 分别为 29.379%、30.073% 和 32.161%。学习减强随机为 −0.694 个百分点，逐项区间 $[-1.272, -0.116]$；学

表 B.9　附加调度延迟及软件决策开销事后评估

Table B.9　Post-Hoc Evaluation with Added Scheduling Delay and Software Overhead

评分条件	学习	强随机	贪心	学习减强随机（95% 区间）	学习减贪心（95% 区间）
0 ms	34.244	34.100	32.821	+0.143 [0.006, 0.281]	+1.423 [1.258, 1.587]
20 ms	32.700	32.581	31.803	+0.119 [−0.013, 0.251]	+0.897 [0.748, 1.046]
50 ms	30.603	30.506	30.294	+0.097 [−0.029, 0.223]	+0.309 [0.159, 0.459]
100 ms	27.871	27.746	28.199	+0.125 [0.017, 0.232]	−0.329 [−0.498, −0.160]
150 ms	25.860	25.670	26.587	+0.190 [0.082, 0.298]	−0.728 [−0.916, −0.540]
逐次软件费用	29.379	30.073	32.161	−0.694 [−1.272, −0.116]	−2.782 [−3.374, −2.190]

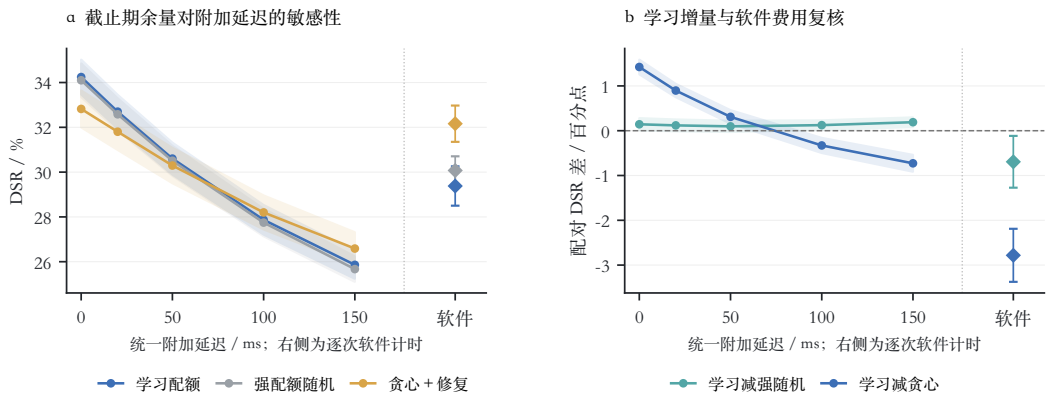


图 B.14　调度延迟对算法服务性能影响的灵敏度分析

Figure B.14　Sensitivity of Service Performance to Scheduling Delays on Confirmation Trajectories

注：阴影与误差棒表示 10 个训练块的 95% t 置信区间；菱形标记表示计入单次软件决策开销的事后评估结果。

习减贪心为 −2.782，区间 [−3.374, −2.190]。原批次质量优势在这一费用口径下发生反转。因此，指定服务器上的软件调用门槛与计入求解等待后的服务优势须分别判断，预算受限时应把较低的软件费用纳入方法选择。

已接纳请求的路径时延超过一秒比例，学习、强随机和贪心分别约为 64.06%、64.77% 和 62.52%。该事后评分保留原动作与状态，不模拟等待引起的资源占用或后续反馈，不是持续队列或真实控制网络的新闭环运行。

附录 C　计费闭环确认与开发诊断的补充材料

C.1　数据划分、参数与运行条件

新上层种子为 1520001–1520020，对应训练负载 1540001–1540020；最终检查点为 episode_00199。每块在 1560001–1560005 五个新负载上各执行三回合，每回合 1000 步。原十块与开发五块均不加入本轮独立重复。固定开发 HGB 只有一个模型，不随新上层基座重训；本轮没有新下层 PPO。

训练使用 Python 3.12.11、Torch 2.6.0+cpu、NumPy 2.0.1、SciPy 1.16.0 和 scikit-learn 1.7.1。各新基座 200 回合，rollout 为 1000，PPO 更新轮数 8，batch size 为 256，数值线程数 1。训练内部沿用 purpose=pilot 标签；外层独立确认由事前固定的样本隔离、方法及检验设计定义，不更改内部历史标签。

价格在原开发训练块 620001–620005 的 400 个公开状态上标定。共同能耗归一化常数为 32283.910075；混合价格为 0.001647731543，二值价格为 0，HGB 价格为 0.083586671957，两个冷启动价格均为 0。公开功率为回传接收 0.1 W、回传发送 0.5 W、UAV 发送 0.5 W 和接收 0.1 W。价格选择只比较已生成候选，不重求带价格边成本的匹配。

C.2　全部参照与固定潜在分母

表 C.1　计费确认实验全部参照方法的配对差值与能耗比

Table C.1　All Paired Differences and Energy Ratios in Cost Confirmation Experiment

参照	计费 DSR 差/百分点及 95% 区间	正向块	平均块能耗比
G	1.02828 [0.93660, 1.11997]	20/20	1.01866
R10	0.66280 [0.56046, 0.76513]	20/20	1.11228
R16	0.69841 [0.63499, 0.76183]	20/20	1.13630
二值价格	0.26243 [0.16518, 0.35968]	18/20	1.08299
未加价混合	0.00243 [−0.05916, 0.06402]	9/20	0.91278
冷启动先验	0.04960 [−0.03930, 0.13850]	10/20	0.91296
冷启动半概率	−0.02341 [−0.10614, 0.05932]	9/20	0.91537
固定 HGB	0.69612 [0.60433, 0.78790]	20/20	0.92201

表 C.1 中差值为主候选减参照，能耗比为候选除以参照；区间为逐项配对 t 区间，并非同时置信区间。只有 G 和二值价格属于预定两项主比较，其余六项为描述性分析。主比较精确符号翻转双侧 p 分别为 1.90735×10^{-6} 与 1.52588×10^{-5}，

依赖独立块配对效应的对称性，不能解释为无假设的因果随机化检验。

各方法共同潜在服务请求总数为 9,215,840。保留原成功数、替换分母后，候选减 G 为 1.02892 个百分点，95% 配对 t 区间 [0.93627, 1.12158]；候选减二值价格为 0.26295 个百分点，区间 [0.16552, 0.36038]。这只检验轻微实际服务分母变化，既不改变原主指标，也不模拟低电量 UE 继续生成服务请求的反事实运行。

C.3 复现入口与核验覆盖

本轮冻结统计位于仓库 `results/sf_hlm_learning_feasibility_20261016/framework_confirmation_20261018/confirmation_saturated120_v1/analysis/summary.json`；同目录的 `protocol.json`、`raw_audit.json` 分别给出冻结协议和原始核验。程序报告与 180 条块乘方法计数表位于原任务 `validation/framework_confirmation_20261018/evidence_saturated_v1/formal/` 下的 `report.md` 与 `block_metrics.csv`。源码精确执行副本为原任务 `assets/releases/framework_saturated_425716b43b76/`。历史服务器绝对路径作为溯源保留，本机相应资料按仓库相对路径同步。

全部 2,700,000 步完成请求阈值、计数、时间窗口、配额预算、预测能耗筛选及配对外生流核验；预先选定的 180 回合、180,000 步及 1,984,786 个请求另做原 Env 物理重放。后者使用原动作和原实测时钟，不重新计费。二者覆盖不同，不能称 2700 回合全部物理复现。训练直接审计检查 20 个不同上层权重指纹、全部 4000 训练回合及最终检查点。上述工作属于主代理自审，不是独立同行评审。

C.4 历史缓存学习开发诊断与停止依据

本节复述已封存的开发报告，不新增拟合或统计检验。样本来自五个历史上层训练块的 400 个固定状态，共 13,459 条协作边；私有邻机缓存仅用于离线标签和物理评分，不进入在线选择器。该条件缓存学习模型与本章正式确认中的固定 HGB 参照不是同一方法。状态、边、交叉验证折及延迟分支均不增加独立训练块数，以下只作开发描述。

在既有学习模型、冷启动半概率及冷启动先验三种方法所选配额定义的共同 10 ms 敏感边并集中，8,071 条边的学习 Brier 为 0.043477，冷启动先验和冷启动半概率分别为 0.051185、0.062105；学习已选的 1,671 条敏感边上，三者分别为 0.037617、0.046621 和 0.067472。子集沿用原状态权重，未重新归一为子集状

态等权。尽管这些预测误差较低，学习模型相对冷启动半概率的任务 DSR 仍低约 0.09992 个百分点。

表 C.2　历史开发快照任务分配关系与性能差异分解

Table C.2　Task Assignment Relationships and Performance Contributions in Development Snapshots

学习与冷启动半概率的分配关系	状态数	共同 10 ms 贡献/百分点
完全相同分配	171	0.000000
同配额、不同请求身份	125	0.007686
不同配额	104	−0.107610

表 C.2 按原报告将服务差分为互斥三类，未舍入贡献可加回原比较，不是各类自身成功率之和。负贡献主要来自不同配额状态，但没有随机化候选生成或能耗筛选，不能识别唯一失败原因。

表 C.3　缓存学习开发支线状态与终止准则

Table C.3　Completed Cache-Learning Development Branches and Termination Criteria

开发支线	封存观察	预定判定及证据范围
条件缓存匹配	共同 10/20 ms 下相对最好无标签参照分别为 −0.09992/−0.04612 个百分点	未过质量、方向及能耗联合门槛；不进入原生计时与闭环
同池学习重排	共同 10 ms 增益 0.03843 个百分点，逐项 95% t 区间 $[-0.02001, 0.09688]$；20 ms 区间也跨零	未达到 10/20 ms 均至少 0.1 个百分点等联合要求；未作独立确认
增加公开时延差特征	留出 Brier 改善 0.00013144，五块均正	小于预定 0.001 门槛；在预测阶段停止，未进行任务匹配或计时

同池重排只改变共同公开候选池中的选择；额外特征仅为公开命中与未命中基时延差的对数变换。表 C.3 的共同延迟不是各方法实测费用，五块区间为开发描述，不并入新确认主检验族。停止结论只针对相应冻结方案，不推出其他学习方法均无效。

400 状态中 100 个来自 step0，其 1,980 条协作边命中率为 0；其余 11,479 条边按原状态权重的命中率为 93.6962%。原状态等权使 step0 占预测指标的 25%，不能代表完整 1000 步回合的时间分布，也未确认当前解析方法的长回合信息价值。

复现来源为仓库 `output/sf_hlm_learning_feasibility_20261016/deliverables/` 中的 `cache_decision.md`、`cache_context.md`、`cache_regime_matching.md`、`cache_guarded_rerank.md` 及 `cache_gap.md`；各报告链接相应冻结协议、JSON 和自审记录。

C.5 当前解析方法的长回合与迁移开发补证

本节采用五个历史上层开发基座 620001–620005，以及经历史登记清单核验的新开发负载 19271001–19271003。价格和能耗归一化常数沿用原解析方法，在效果揭示前冻结。五场景四方法共 300 回合；中心场景另补二值零价、解析零价及共同价格二值各 15 回合，复用原解析方法作为共同价格解析组，实际共 345 个不同回合、345000 步。独立描述单位仍为五个上层块，各块先合并计数求率；本节所有区间均为逐项 95% 配对 t 描述区间，不加入原二十块确认的主检验族。

本轮使用最多 32 个单线程工作进程，分配至不同物理核；共享服务器另有背景负载，不是系统级独占。每步按原完整软件调用时间注入请求时延，随后形成奖励与下一观测；磁盘日志在计时外。新费用条件与原 120 核确认分开，不能拼接计算加速比。全量逐步计费、请求计数、预算、摘要和配对流核验通过；另在 1228 个抽样源状态复现原物理时延，并按原逐次费用复核成功数。

C.5.1 代表性抽样与评分–价格模块干预

G 和解析方法各 15 个 1000 步源回合，每回合分 40 个等长区间，各区间在效果前随机抽一步，共 1200 个主状态；另外 28 个 step0 只作附加冷启动，不重复计权。全部合法协作边的私有缓存标签由独立离线过程读取，候选生成与选择只接收原公开 rows。解析所选配额下五块关键边比例为 63.231%、66.306%、60.974%、57.787%、59.473%，分母为目标配额大于零的合法协作边，不能解释为关键边稀少。暖态的原先验 Brier 为 0.053057，冷启动半概率为 0.065153；全边 log loss 分别为 0.571406 与 0.510248，两类预测误差的排序并不一致，也未比较新学习模型。

四组以二值模块或解析模块执行配额内指派，再以零价或共同冻结价格选择候选。共同 $\lambda = 0.0016477315429376078$，归一化常数为 32283.91007507；各组共享初值、普通修复、提议顺序、十次总匹配预算、预测筛选与反馈。二值和混合的配额内能耗项尺度也不同，故这是评分–指派模块干预，而非仅替换概率公式。表 C.4 同时保留固定快照与闭环比较。

表中 B、M 分别指二值、解析模块；固定状态列等权合并 G 与解析源轨迹，各状态锁定同一上层 motion 并用原物理环境评价分配，不能当作原生闭环增益。共同带价模块差在 G 源状态为 -0.028 $[-0.090, 0.035]$，在解析源状态为 0.247 $[0.059, 0.435]$，显示状态来源依赖。共同价格没有改变本批固定状态的二值最终分配，闭环极小 DSR 差伴随相同接纳与能耗；不把它归为价格的任务增益。解析加价的闭环 DSR 区间跨零，能耗比仅作描述，不能据此宣称无损节能。

表 C.4　基准价格下各开发模块性能对比

Table C.4　Performance Comparison of Development Modules under Benchmark Pricing

比较	固定状态共同 10 ms	计费闭环	闭环能耗比
$M_0 - B_0$	0.196 [0.108, 0.283]	0.262 [0.028, 0.496]	1.1250
$M_\lambda - B_\lambda$	0.111 [0.026, 0.195]	0.251 [−0.498, 0.999]	1.0523
$B_\lambda - B_0$	0.000 [0.000, 0.000]	0.002 [−0.005, 0.009]	1.0000
$M_\lambda - M_0$	−0.085 [−0.125, −0.045]	−0.009 [−0.721, 0.703]	0.9356

原公开分解未由私有时延校正。主样本源策略所选协作边中，11898 条完成公开反演残差核对，9 条绝对残差大于 10^{-6} 秒，均在 $p \geqslant 1 - 10^{-10}$ 组；最大残差约 2.76×10^{-4} 秒。此处保留数值近似，不把未回退等同于物理精确。候选并集、失败筛选原因、三类分配贡献和完整概率误差另存原始结果。

C.5.2　五场景零调参迁移及边界

图 C.1 分别改变 UE 数或 UAV 算力，其余物理参数、原上层权重、价格和归一化常数不变。上层仍保留每机 30 个 UE 槽及原排序，140 UE 可能被观测截断；下层请求槽未触发容量错误。解析相对 G 的均差在五场景均为正，但高负载和高算力各有负向块；解析相对二值的五个区间均跨零。只覆盖十字而非完整交互网格，也没有新增上层训练块。

本轮在开发补证后停止，独立新基座与跨因素交互仍需新设计。协议、种子、原始记录及统计见 `results/chapter5_followup_20261027/development_v2/`；本节不与旧 400 状态或二十块主确认合并。

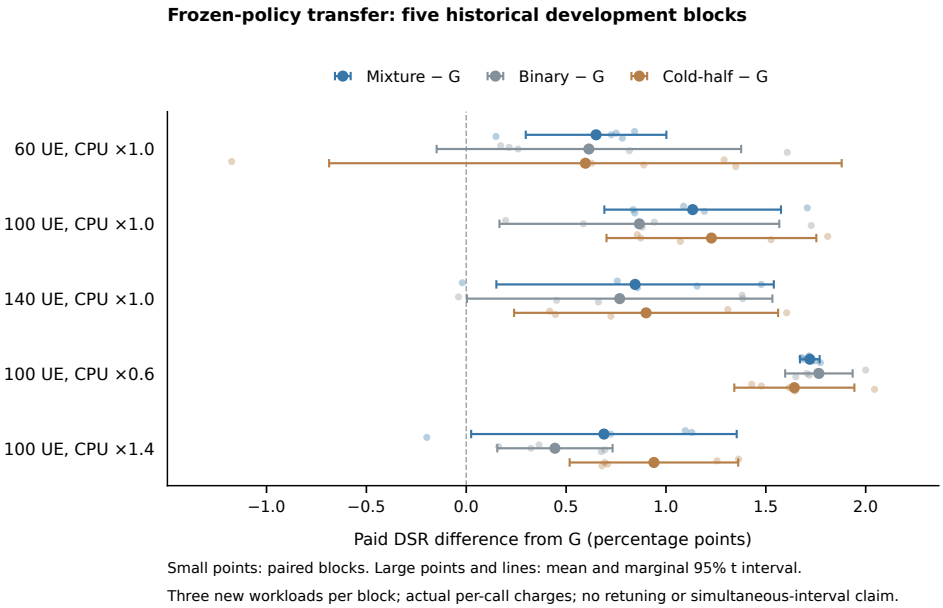


图 C.1　冻结策略在五种开发场景下的迁移性能

Figure C.1　Transfer Performance of Frozen Policies Across Five Development Settings

注：小点表示 5 个历史块配对差，大点与线段表示均差及 95% 配对 t 置信区间。

C.6　固定预算前缀的开发取舍与停止依据

本节对应 C0 固定预算开发，复用五个历史上层基座 620001–620005 和已用于上一节开发的负载 19271001–19271003，不称新负载、留出验证或独立确认。六方法每块合并三个 1000 步回合，共 90 回合、90000 步。独立描述单位仍为五个上层块；所有差值区间为逐项 95% 配对 t 描述区间，不据其跨零建立正式非劣效。

本节 B2、B4、B6 和 B10 中的数字表示含初始化的匹配调用预算，区别于上一节表示二值评分模块的 B。

预算 0 直接返回 G；正预算包括一次原二值初始化以及同一冻结序列的前 $B-1$ 个配额，不将初始化解额外加入候选池，失败匹配也计数。各前缀逐个计算已访问矩阵，原生批量 B10 另列以区分实现差异；共同实现 B10 在全部 1200 个主状态上通过候选、最终动作、预测量和反馈回归。公开信息、允许域、预测能耗筛选及 G 保底保持不变。

本轮最多 15 个单线程进程使用不同物理核，在模型加载屏障后计时，共享服务器背景负载。完整调用包括准备、修复、提议、评分、匹配、选择、反馈、上层推理、映射和逻辑序列化，也包括分项计时本身；磁盘记录与环境恢复在计时外。各方法在本轮重新计时，不能与上一节 32 核开发或原 120 核确认拼接计算加速比。

表 C.5　固定预算前缀下的计费闭环性能权衡

Table C.5　Performance Trade-Offs of Fixed Budget Prefixes in Cost-Aware Closed-Loop Evaluation

方法	DSR 差及区间	完整均值/ms	时间比	能耗比
G	−1.088 [−1.562, −0.615]	11.370	0.5728	1.0066
B2	−0.529 [−0.839, −0.220]	17.464	0.8804	1.0224
B4	−0.106 [−0.546, 0.334]	18.182	0.9161	1.0102
B6	−0.147 [−0.596, 0.303]	18.791	0.9469	1.0074
B10	0.000 [0.000, 0.000]	19.850	1.0000	1.0000
原生 B10	0.035 [−0.006, 0.077]	19.364	0.9757	1.0000

表 C.5 的参照均为共同实现 B10。DSR 按块内合并成功与生成计数计算，时间及机队能耗先取块内比值再跨块平均。效果揭示前固定的开发筛选要求 DSR 均差不低于 −0.1 个百分点、时间比不超过 0.80、能耗/B10 及能耗/G 均不超过 1.05。B2、B4、B6 的两项能耗要求均通过，但质量与时间未共同通过；B4 接近质量界值仍不弥补时间收益不足。原生 B10 与共同实现的差异属于工程路径及实际费用，不归为预算策略收益。

共同实现 B10 的完整路径中，修复及二值初始化为 4.5202 ms，冻结提议构造为 5.1553 ms，分支解码为 0.1888 ms，访问矩阵评分为 0.7008 ms，条件匹配为 1.5103 ms，候选选择为 0.0282 ms，其他完整路径为 7.7461 ms，均为五块均值。评分与匹配占完整调用的平均块内比例约 11.14%，是本实现、硬件和开发分布下的事后解释，不是理论速度下界。

固定状态另外对每方法每状态重测三次完整调用，再按封存分配、原物理时延与每次费用评分；1200 状态来自 G 和解析两种源轨迹，未重复加入额外 step0。B6 相对 B10 的固定状态计费 DSR 差为 0.034 [−0.063, 0.131] 个百分点，闭环差则为负，二者不能互换。图 C.2 保留全部方法的开发取舍。本轮据联合筛选停在 C0，未实施 C1 门控、学习器或新训练，也不推出其他自适应决策均无效。

全部 90000 步完成逐次费用、请求计数、前缀预算及预测筛选记账核验；1200 个固定状态另完成原环境物理核验，不能称 90 回合全部物理重放。协议、统计及原始记录位于 `results/chapter5_followup_20261027/c0_20261028/development_v2/`，完整包为其上级的 `c0_evidence_full.tar.gz`；详细报告见 `docs/reports/chapter5_stage_c0_20261028.md`。

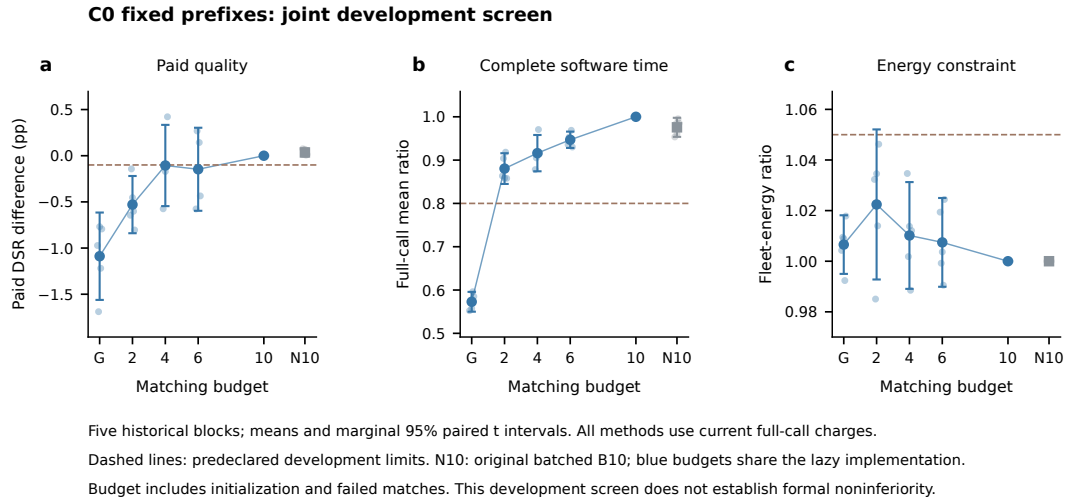


图 C.2　固定预算下求解质量、计算时间与能耗权衡分析

Figure C.2　Trade-Offs of Solution Quality, Computation Time, and Energy under Fixed Budgets

注：小点表示历史块数据，大点与线段表示均值及 95% 配对 t 描述区间；虚线表示开发筛选限值。

致谢

在此感谢导师的悉心指导，感谢实验室同学的帮助，感谢家人的支持。

在读期间取得的科研成果