

中山大學

SUN YAT-SEN UNIVERSITY

中山大学专业硕士学位论文

面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

专　　业：　YOUR_SPECIALITY

学位申请人：　YOUR_NAME

指 导 教 师：　YOUR_SUPERVISOR 教授

论文答辩委员会主席：_____

论文答辩委员会成员：_____

_____

_____

_____

2026 年 10 月

论文原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究作出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期：　　年　　月　　日

学位论文使用授权声明

本人完全了解中山大学有关保留、使用学位论文的规定，即：学校有权保留学位论文并向国家主管部门或其指定机构送交论文的电子版和纸质版；有权将学位论文用于非赢利目的的少量复制并允许论文进入学校图书馆、院系资料室被查阅；有权将学位论文的内容编入有关数据库进行检索；可以采用复印、缩印或其他方法保存学位论文；可以为建立了馆际合作关系的兄弟高校用户提供文献传递服务和交换服务。

保密论文保密期满后，适用本声明。

学位论文作者签名：　　导师签名：

日期：　　年　　月　　日　　日期：　　年　　月　　日

论文题目：面向时限服务的无人机集群协同轨迹规划与计算任务分配方法研究

专　　业：YOUR_SPECIALITY
硕 士 生：YOUR_NAME
指导教师：YOUR_SUPERVISOR 教授

摘　要

无人机（UAV）集群为动态地面请求提供时限计算服务时，需要协调空中平台的空间部署与机载资源分工。单机覆盖与计算、缓存能力有限，协同机动增加的接纳需求又可能加剧执行节点的资源竞争。本文以应急场景中的临时空地服务为应用动机，采用动态请求驱动的逐决策步批次移动边缘计算模型，研究“集群飞向哪里、任务交给谁执行、如何连接机动与分配”三个任务规划问题。自然覆盖条件下，请求须先进入物理服务范围，再经过计算任务分配按时完成。本文以全部实际生成服务请求为分母定义端到端截止期满足率（DSR），并报告接纳率、接纳后质量、UAV 能耗、公平性、宏基站（MBS）依赖与计算开销。

首先，在保持 100 m 物理服务半径不变的条件下，将感知范围内未覆盖需求纳入上层 Attention-MAPPO 的预动作观测，结合邻机与用户信息形成需求感知轨迹决策。独立确认中，DSR 从 0.2444 提高至 0.2793，接纳扩展同时伴随条件完成率下降。其次，针对跨机迁移通过批量算力共享影响其他请求的现象，提出固定快照下整体重评估的 MC-ITR 分配方法。主配置每快照平均超时数从迭代对照的 2.228 降至 2.055；需求感知上层与无注意力学习式下层产生的轨迹快照也显示分配余量，但伴随更高能耗与求解时间。MC-ITR 据此用于离线分析，在线系统采用有限预算的配额匹配。

在此基础上，构建 SF-HLM 的分层协同决策：冻结需求感知轨迹上层，独立学习下层配额搜索并结合条件化负载匹配。对自然接纳请求构建请求–节点二部图，固定节点配额后通过容量槽指派生成完整分配，CompleteQuotaPPO 在有限匹配预算内选择配额迁移与停止动作，并结合共同质量掩码、普通修复、能耗筛选和最好方案保留。上层按各 UAV 的观测分散推理，下层集中调度当前请求批次，保持原批次评价时序与奖励。五架 UAV、一百个地面用户设备（UE）主场景的十个独立训练块与五个配对工作负载确认表明，SF-HLM 的 DSR 为 34.244%，相对贪心修复、冻结请求级下层和适配请求级下层修复，分别提高 1.423、2.008

和 2.192 个百分点。相对相同学习上层加逐请求随机卸载及全随机，分别提高 10.604 和 18.816 个百分点，支持完整下层优化包与完整系统的服务收益。

共享强框架下的配额随机搜索 DSR 为约 34.100%，学习搜索额外增量约为 0.143 个百分点，其统计敏感性与较高软件开销需要同时解释。SF-HLM 各块隔离 p95 软件调用时间的均值约为 109.24 ms。冻结策略的 UE 数量与 UAV 算力九格评价、固定潜在请求分母复核以及快照预算诊断进一步检验了结果边界。主 DSR 未计调度等待；原确认轨迹事后加入逐次隔离软件费用后，学习、强随机与贪心的 DSR 分别为 29.379%、30.073% 和 32.161%，排序发生改变。计算能耗采用未标定具体芯片的等效频率模型。现有证据支持规定批次评分与简化二维运动下的任务规划比较，实际在线净收益仍需结合调度费用及资源占用检验。本文为计入运动执行、信息上报与协调成本的后续研究提供了可复核依据。

关键词：无人机集群，协同轨迹规划，计算任务分配，
多智能体强化学习，负载匹配

Title: Cooperative Trajectory Planning and Computation Task Allocation for UAV Swarms Providing Deadline-Constrained Services

Major: YOUR_SPECIALITY
Name: YOUR_NAME
Supervisor: Prof. YOUR_SUPERVISOR

ABSTRACT

An unmanned aerial vehicle (UAV) swarm providing deadline-constrained computation services must coordinate spatial deployment with the use of onboard resources. Individual coverage, computation, and caching capacity are limited, while admitting more demand through cooperative movement can increase execution-node contention. Motivated by temporary air–ground services in emergency settings, this thesis uses a dynamic-request, decision-step batch model of mobile edge computing to study three task-planning questions: where the swarm should move, which nodes should execute the tasks, and how to connect movement with allocation. Under natural coverage-based admission, requests must enter the physical service area before they can be allocated for timely completion. The end-to-end deadline satisfaction rate (DSR) uses all actually generated service requests as its denominator. Admission, conditional completion, UAV energy, fairness, macro base station (MBS) dependence, and computation cost are also reported.

First, uncovered demand within the sensing range is added to the pre-action observations of an Attention-MAPPO upper layer while retaining the 100-m physical service radius. Neighbor and user features support demand-aware trajectory decisions. Independent confirmation increases DSR from 0.2444 to 0.2793, with higher admission accompanied by lower conditional completion. Second, the fixed-snapshot MC-ITR method reevaluates complete assignments to account for the effects of task migration on other requests through batch-shared computation. It reduces the main-setting mean deadline misses per snapshot from 2.228 for an iterative comparator to 2.055. Snapshots from a demand-aware upper policy with a non-attention learned lower layer also reveal assignment-quality headroom, accompanied by higher energy and computation costs. MC-ITR provides an offline allocation reference; the online system uses quota

matching within a finite budget.

The resulting SF-HLM hierarchy combines a frozen demand-aware trajectory upper layer with independently learned quota search and conditional load matching in the lower layer. Admitted requests and execution nodes form a bipartite graph. For a fixed node-quota vector, capacity-slot assignment produces a complete placement; Complete-QuotaPPO selects quota transfers and a stop action within a finite matching budget. A common quality mask, ordinary repair, energy screening, and best-solution retention support execution. Upper-layer inference is decentralized according to each UAV's observations, whereas the lower layer centrally schedules the current request batch, preserving the original batch-evaluation timing and reward. In the main setting with five UAVs and 100 user devices (UEs), confirmation over ten independent training blocks and five paired workloads yields a DSR of 34.244%. Gains over greedy repair, a frozen request-level lower layer with repair, and its adapted counterpart are 1.423, 2.008, and 2.192 percentage points, respectively. Gains over per-request random offloading with the same learned upper layer and over fully random control are 10.604 and 18.816 percentage points, supporting the benefits of the complete lower-layer optimization package and the complete system.

Quota-random search within the same strong framework already reaches approximately 34.100% DSR. The additional learned-search gain is approximately 0.143 percentage points and requires interpretation alongside its statistical sensitivity and higher software cost. The mean of the block-level isolated p95 software-call times is approximately 109.24 ms. Nine frozen-policy UE-count and UAV-compute settings, a common potential-request denominator check, and snapshot budget diagnostics further assess the scope of the results. The primary DSR excludes scheduling wait. Post-hoc scoring of the original trajectories with recorded per-call isolated software costs yields DSRs of 29.379%, 30.073%, and 32.161% for learned search, strong random search, and greedy repair, respectively, changing their ordering. Computation energy follows an equivalent-frequency model without chip-specific calibration. The evidence supports task-planning comparisons under the specified batch scoring and planar-motion model; net online benefits require joint assessment of scheduling costs and resource occupancy. The findings provide a reproducible basis for further assessment of motion execution, reporting, and coordination costs.

KEY WORDS: UAV swarm, cooperative trajectory planning, computation task allocation,
multi-agent reinforcement learning, load matching

目　录

第 1 章　绪论 1
1.1　研究背景与意义 1
1.2　国内外研究现状 4
1.3　关键研究问题与技术路线 9
1.4　研究内容与主要贡献 10
1.5　论文组织结构 11
1.6　本章小结 12
第 2 章　相关技术与理论基础 13
2.1　无人机集群任务规划与协同服务基础 13
2.2　无人机辅助移动边缘计算基础 16
2.3　马尔可夫决策过程与长期目标 20
2.4　策略梯度与 Actor–Critic 推导 22
2.5　时序差分与广义优势估计 25
2.6　近端策略优化与动作概率一致性 27
2.7　多智能体协作与 MAPPO 29
2.8　注意力聚合与图表示 31
2.9　指派匹配与配额条件化优化 33
2.10　随机实验与证据解释基础 34
2.11　本章小结 35
第 3 章　自然覆盖约束下无人机集群的需求感知协同轨迹决策 36
3.1　研究动机与评价口径 36
3.2　系统几何、动作应用与单时隙时序 38
3.3　请求、通信、缓存与能量模型 42
3.4　上层 Dec-POMDP 与注意力策略实现 48
3.5　预接纳需求观测设计 52
3.6　瓶颈诊断、独立确认与机制解释 55
3.7　本章小结 59
第 4 章　考虑跨机资源竞争的截止期优先计算任务分配 60
4.1　固定快照问题与受控比较范围 60

4.2 全批次执行、缓存与分配代价 61
4.3 严格字典序目标与共同基线 65
4.4 MC-ITR 搜索过程与可证性质 68
4.5 Exact-Small 与反事实评价协议 71
4.6 实验设计、主结果与代价解释 72
4.7 敏感性、精确检查与搜索完成情况 75
4.8 学习轨迹下的快照分配比较与本章小结 78

第 5 章 无人机集群协同轨迹与计算任务分配的分层决策 81
5.1 研究问题与方法总体设计 81
5.2 移动前请求建模与负载相关预测 84
5.3 配额分解与条件化字典序匹配 86
5.4 有限预算配额搜索与二部图策略 89
5.5 教师初始化、配额 PPO 与分层训练 93
5.6 独立确认设计与统计方法 97
5.7 主场景性能与完整下层优化包的收益 101
5.8 完整框架与学习机制的分层解释 109
5.9 冻结策略的负载与算力稳健性 112
5.10 固定快照、共同 MBS 与时间预算诊断 114
5.11 研究联系、适用条件与本章小结 117

第 6 章 总结与展望 122
6.1 研究总结 122
6.2 综合认识与适用范围 124
6.3 后续研究方向 125
6.4 本章小结 126

参考文献 127

致谢 130

在读期间取得的科研成果 131

插图目录

图 2.1 终端、边缘与中心服务之间的通用层次关系示意 16
图 2.2 UAV 作为覆盖节点、中继与移动边缘服务器的应用关系示意 18
图 2.3 强化学习中的状态、动作、奖励与环境转移关系 20

图 3.1 系统总体布局与自然覆盖接纳示意。三角形为 UAV，实线圆为 100 m 服务覆盖范围，虚线圆为其中一架 UAV 的 460 m 感知范围；绿色圆点为被覆盖 UE，红色叉为未被覆盖 UE，其请求本时隙不被接纳。图中位置为示意性布局，非真实轨迹快照 39
图 3.2 覆盖半径与感知半径的几何关系 40
图 3.3 单时隙内的请求执行与轨迹应用时序。两层动作由当前观测计算；请求按移动前几何执行，上层轨迹动作随后应用并影响下一时隙覆盖 ... 42
图 3.4 上层 Attention-MAPPO 的网络与训练结构。实线为前向信息流，虚线为仅训练时使用的集中式评价与参数更新；执行阶段每架 UAV 仅用自身局部观测 51
图 3.5 原观测与扩展观测的槽位填充规则对照（同一几何示意）。原观测仅含已覆盖 UE，扩展观测以距离顺序补入感知范围内尚未接纳的 UE；图为规则示意，非注意力权重或真实记录 54
图 3.6 主场景实际生成服务请求的结果构成（下层无注意力强基线，瓶颈诊断批次，25 个评估单元的计数汇总） 55
图 3.7 独立确认实验的训练曲线（10 个训练种子的均值 ± 标准差）：(a) 训练 DSR；(b) 平均训练奖励 57
图 3.8 独立确认实验中候选相对强基线的逐训练种子 DSR 差值（每个种子为 5 个工作负载差值的平均；区间为配对 t 95% 区间） 58
图 3.9 确认实验中接纳率与接纳后按时完成率的配对比较（每点为一个训练种子下五个配对工作负载的均值）。两因子反向变化，DSR 增益来自接纳因子 58

图 4.1 批量算力共享与迁移外部影响的机制示例（构造参数：$F_u = 60\,\mathrm{GHz}$，$L_m = 2 \times 10^6$ 字节，$\omega_m = 2000$ 周期/字节，$\kappa = 10^{-27}$；数值按式 (4.5) 计算，非实验测量） 63

图 4.2 MC-ITR 算法流程。两个出口对应不同结论强度：无改善退出时可验证单请求迁移邻域局部最优；预算退出时不作此声称 68
图 4.3 固定快照主配置下四种卸载方法的超时数、分配能耗与搜索耗时（柱为十个工作负载种子均值，散点为逐种子值） 74
图 4.4 各方法相对 Iterative-Base 的每快照超时数配对差值（十个工作负载种子；区间为 5000 次重抽样的 95% bootstrap 区间）。散点、均值虚线与阴影区间描述该固定快照批次中的工作负载配对差异 74
图 4.5 UE 数量变化下四种方法的超时数与分配能耗（误差线为十个工作负载种子的逐项 95% t 区间，非同时覆盖） 76
图 4.6 UAV 算力倍率变化下四种方法的超时数与分配能耗（误差线口径同图 4.5） 76
图 4.7 Exact-Small 配置的快照构成与各方法逐分量均值。(a) 600 个快照的构成；(b)-(d) 三 UE 小规模下 MC-ITR、Greedy、Iterative 与穷举精确解的逐分量均值相同，仅 Heuristic-Control 存在差距 78
图 4.8 需求感知轨迹策略下的固定快照分配比较（400 个快照；反事实分配不回写环境） 79

图 5.1 无人机集群 SF-HLM 分层架构与移动前决策时序。冻结上层按局部需求及邻机观测准备轨迹动作，下层集中分配已接纳计算任务；当前批次先依据当前几何评价，随后应用轨迹动作形成下一步位置 82
图 5.2 固定配额的容量槽展开与请求匹配。示意图用于解释算法结构，不是实测任务分配 87
图 5.3 请求–执行节点二部图、当前与最好状态编码及配额动作头。非法边和填充请求在消息聚合中屏蔽 90
图 5.4 共同基座、下层训练图与独立确认的数据划分。图中回合是环境交互，配额 PPO 更新是固定训练图上的搜索训练 94
图 5.5 共同基座与配额策略的实际训练记录。前四面板依次为基座平均步奖励、基座 DSR、配额 PPO 损失和价值损失：细线为十块原始曲线，粗线和带分别为块间均值与正负一个标准差；未平滑。后两面板为每块一次教师监督损失记录和样本数；未保存逐轮损失，故不绘制教师收敛曲线。环境回合、优化更新与训练块横轴分别对应不同阶段 97

图 5.6 预选首确认回合的集群空间机动记录。上排为两方法五机轨迹，灰点仅表示初始 UE 位置，虚线为终点 100 m 服务圆；下排为逐机实际水平航程与最小机间距。200 m 间距线是既定几何约束；本图只描述各方法一个回合 …… 102
图 5.7 代表确认回合第 500 步上层 Actor 的实际前向注意力记录。权重说明该状态下的信息聚合，不作为注意力贡献的独立因果证明 …… 103
图 5.8 主场景八种方法的 DSR 比较。六种核心方法与两种补充随机对照分别标识；统计单位为十个模型或随机流配对块 …… 104
图 5.9 SF-HLM 相对三个主对手的十训练块配对差。每个块先合并五工作负载、六回合的请求计数 …… 105
图 5.10 生成请求的互斥结果分解与接纳后完成率。三种结果按同块计数计算后平均，条件完成率以接纳请求为分母 …… 106
图 5.11 仿真环境记录的 UAV 机队能耗与 MBS 依赖。图中能耗为 kJ/步，MBS 比例为 MBS 请求数除以接纳请求数；未计 MBS 全网费用 …… 107
图 5.12 块级公平性与隔离完整软件 p95。p95 先在每块全部调用上计算，再展示十块分布及其均值 …… 109
图 5.13 学习相对启发式和强配额随机的机制差。强随机共享初始化、修复、匹配、最好保留和相同调用预算 …… 110
图 5.14 SF-HLM 冻结策略在 UE 数量与 UAV 算力九格中的 DSR（左）和接纳后按时完成率（右）。主格引用独立确认，其他格不重新训练；数值为十块均值 …… 113
图 5.15 九格学习相对三个主对手的 DSR 差。八个新格的二十四项比较统一 Holm 校正，主格保留原确认族 …… 113
图 5.16 四百固定快照的自由与共同 MBS 数量诊断。两面板分别报告自由和固定共同 MBS 数量下每快照的实际超时均值；反事实分配不回写环境，描述性均值未画误差线 …… 115
图 5.17 软墙钟预算的真实质量、时间与超限率。原子匹配与完整路径开销可能越界，所有越界样本均保留 …… 116
图 5.18 确认评估环境步中的匹配调用与终止行为。调用包含初始匹配及失败候选，空批次纳入统计，停止不消耗一次匹配调用 …… 117
图 5.19 SF-HLM 十个确认训练块的计算任务执行分工。比例分母为每块本机、协作 UAV 与 MBS 三分支计数总和；显示全部训练块及等权块均值，不设置误差线或显著性检验 …… 118

图 5.20　原确认轨迹的调度延迟敏感性。左面板为 DSR，右面板为学习相对强随机和贪心的配对差；菱形单独表示逐次软件费用评分，与共同延迟曲线分开。阴影与误差线为十块逐项 95% t 区间，状态不回写 …… 120

附表目录

表 1.1 最接近研究与本文的问题及方法关系 9

表 3.1 主场景仿真参数 48
表 3.2 上层单智能体观测构成（原观测；扩展观测见第 3.5 节） 49
表 3.3 上层 MAPPO 主要超参数 52
表 3.4 覆盖观测两阶段实验协议 56
表 3.5 独立确认实验的主场景结果（10 个新训练种子 × 5 个新工作负载） 57

表 4.1 自身改善与系统超时变化的构造例（非实验数据） 65
表 4.2 四种卸载方法的差异 67
表 4.3 单请求局部最优不蕴含全局最优的离散构造 70
表 4.4 固定快照主配置的卸载方法比较（十个工作负载种子均值） 73
表 4.5 各变体配置中 MC-ITR 相对 Iterative-Base 的每快照超时数差值 77

表 5.1 SF-HLM 的在线决策设置 83
表 5.2 已确认配额策略的训练设置 96
表 5.3 SF-HLM 独立确认的数据与模型分割 98
表 5.4 完整下层与学习机制对照的组成 98
表 5.5 一百 UE 主场景的服务指标（先合并块内请求计数，再跨块平均） 104
表 5.6 三个预定主对照的配对 DSR 差值与仿真环境记录的 UAV 能耗比 .. 105
表 5.7 主场景 UAV 资源代价、公平性和完整软件时间 107
表 5.8 主场景仿真机队能耗构成（每步及等权块占比） 108
表 5.9 五训练块开发评价中的 PPO 相对 BC 差值 111
表 5.10 学习配额 SF-HLM 在九格冻结评价中的 DSR 112
表 5.11 附加延迟及逐次软件费用事后评分（DSR 为百分比，差值及区间为百分点） 119

符号说明

N, M	UAV 数量与 UE 数量
H, τ, T	UAV 飞行高度、时隙时长与 episode 时隙数
$\mathbf{q}_u(t)$	UAV u 在时隙 t 的水平位置
$\mathbf{w}_m(t)$	地面 UE m 在时隙 t 的水平位置
$\mathbf{p}_u(t)$, $\mathbf{p}_m(t)$	UAV 与 UE 的三维位置
$v_{\max}$, $d_{\min}$	UAV 最大速度与机间最小安全距离
R_c, R_s	UAV 物理服务覆盖半径与需求感知半径
G, A, S	评估单元内实际生成、自然接纳、按时完成的服务请求数
DSR	端到端截止期满足率，S/G
J, c_m	Jain 公平性指数与 UE m 的累计服务覆盖量
g, R	链路信道功率增益与传输速率（bit/s）
P^{comm}	通信发射功率
σ^2	噪声功率
B^{edge}	UE-UAV 接入链路带宽
B^{inter}	UAV 间链路带宽
B^{backhaul}	UAV-MBS 回传链路带宽
$B_{\max}$, B_{low}	UE 电池容量与低电量阈值
β	请求流行度 Zipf 指数
$\mathcal{M}_t$, $\mathcal{J}$	时隙 t 的自然接纳服务请求集合与执行节点集合
$\mathcal{C}_m$	请求 m 的合法执行节点集合
$\mathbf{a}$, x_{mj}	请求分配向量与请求 m 分配到节点 j 的二元指示
L_m, C_m	请求 m 的输入字节数与所需 CPU 总周期
ω_m	请求 m 每字节所需 CPU 周期数，$C_m = \omega_m L_m$
B_s	服务程序 s 的字节数
F_u, F_{mbs}	UAV u 与 MBS 的计算能力（周期/s）
N_j, f_{mj}	分配到节点 j 的最终请求数与请求分得的计算频率

T_m, D_m	请求 m 的完成时延与截止时间
T_m^{tx}	请求传输时延，$8L_m/R$
T_m^{cmp}, E_m^{cmp}	请求计算时延与计算能耗
κ	动态 CPU 功耗模型的有效芯片电容系数
E_{assign}	卸载分配相关的非飞行 UAV 能耗
s_t, O_t	强化学习完整状态与上层 UAV 联合观测
$o_{u,t}$, $a_{u,t}$	UAV u 的局部预动作观测与连续原始动作提案
$a_{u,t}^{\mathrm{exec}}$	环境映射后的 UAV 执行动作
π_θ, V_ϕ	参数化策略与价值估计网络
θ, ϕ	策略参数与价值网络参数
r_t, G_t	即时奖励与从时隙 t 开始的折扣回报
V_t^π, Q_t^π	状态值函数与动作值函数
A_t^π, $\widehat{A}_t$	真实优势函数与优势估计
γ	回报折扣因子
λ_{GAE}	广义优势估计的多步混合系数
b_t, c_t	价值自举掩码与优势递推连接掩码
ρ_t, ε	PPO 新旧动作概率比率与裁剪系数
Q, K, V	注意力查询、键与值矩阵（本体按上下文区分值函数）
d_k	单个注意力头的键向量维度

第 1 章　绪论

1.1　研究背景与意义

1.1.1　无人机集群协同任务规划与空地服务需求

无人机集群通过多个空中平台的机动与分工，共同完成单个平台难以独立承担的区域任务。集群能力既取决于每架飞行器的运动和载荷能力，也取决于成员如何选择服务位置、交换任务并使用有限资源。Chung 等的航空集群综述将轨迹生成、任务分配和分布式感知等列为相关研究内容，并指出空中平台的运动特性为协同设计带来额外要求[1]。因此，面向航空航天任务的集群协同可以从任务规划层展开：在给定平台和运动约束下，研究多机应部署到哪些位置、如何形成任务分工，以及这种分工能否改善集体任务完成效果。

应急场景中的临时空地服务为上述问题提供了应用动机。当地面设备分散移动、任务需求发生变化时，搭载通信与计算载荷的无人机可以将服务能力带到需求附近。多个平台需要分担空间部署和计算处理任务，避免仅由个别平台接纳大量请求而其他平台资源无法被使用。本文据此研究动态地面请求驱动的集群计算服务；仿真中明确建模的是用户移动、请求生成、通信、缓存与计算过程，并未设置灾情演化、搜救目标发现或巡检航线等特定任务流程。应用动机用于说明服务需求，实验结论则依据实际采用的请求与环境模型。

本文中的无人机（Unmanned Aerial Vehicle，UAV）同时承担移动接入节点和计算执行节点的角色，地面用户设备（User Equipment，UE）产生具有截止时间的请求，宏基站（Macro Base Station，MBS）提供另一条执行路径。移动边缘计算（Mobile Edge Computing，MEC）将计算和存储能力部署到接近数据产生位置的网络边缘，为这种计算任务载荷提供了技术基础[2]。请求需要经历接入、数据传输、程序获取和计算等环节，空中平台的位置则决定部分请求能否进入这一流程。由此，MEC 对应集群所承担的服务任务，而集群协同轨迹规划与计算任务分配对应本文的主要决策问题。

空地服务能力具有明确的空间依赖性。固定服务器的算力即使充足，也需要用户连接到可用接入点；无人机的机动性使接入节点的位置可以成为决策变量。UAV 辅助通信研究讨论了覆盖、部署、轨迹与能量之间的联系[3-4]。在本文的计算服务场景中，空间错配具有两种表现：用户距离服务 UAV 过远，请求不能被接纳；请求虽然进入覆盖，却集中到少数执行节点并竞争计算和缓存资源。前者需要集群改变未来的空间部署，后者需要调整当前批次的任务分工。只报告已接

纳请求的平均时延，容易遗漏未接纳需求，难以解释集群整体服务效果。

集群空间部署同时影响跨机资源协作。某架 UAV 接纳较多请求后，可以将部分计算任务交给其他具有可用能力的 UAV；若协作链路较弱或必要程序未缓存，迁移又会增加传输和获取时延。MBS 能够补充执行能力，其使用比例也影响对空中集群独立服务能力的解释。任务目的地还会改变当前能耗和缓存状态，进而影响后续观测与动作。因此，本文把多机位置、任务接纳和执行负载视为相互联系的任务规划变量，通过长期交互仿真评价整体效果，并用固定状态实验识别分配环节的质量余量。

本文的集群协同限定在任务规划层。仿真采用固定高度下的二维运动、单步位移限制和位置修复，Actor 根据各 UAV 允许的观测输出机动方向，下层调度器集中处理当前请求批次。邻机状态进入上层决策，任务也能够在机间迁移，由此形成空间部署与计算分工两类协作。研究未包含姿态控制、编队参考队形、六自由度动力学或实际飞行试验；轨迹规划效果应在所用简化运动与信息条件下解释。这样的层次划分使研究问题与现有实现对应，也为后续衔接航空器执行控制提供明确接口。

1.1.2 自然覆盖条件下的服务评价问题

本文关注具有明确物理服务半径的自然覆盖接纳系统。当前时隙位于 UAV 覆盖范围内的服务请求被接纳后，才能进入卸载决策；范围外请求计为未接纳。选择 MBS 或协作 UAV 只改变已接纳请求的执行目标。与强制关联全部请求的设置相比，自然覆盖将 UE–UAV 接入条件纳入优化问题，使轨迹决策承担改善后续接纳机会的作用。

为同时评价覆盖与处理质量，本文以全部实际生成服务请求中的按时完成比例定义端到端截止期满足率（Deadline Satisfaction Rate，DSR）。设一个评估单元内实际生成、自然接纳和在截止时间前完成的请求总数分别为 G、A 和 S，在 $G>0$ 且 $A>0$ 时有

$$\mathrm{DSR}=\frac{S}{G}=\frac{A}{G}\frac{S}{A}=\text{接纳率}\times\text{接纳后按时完成率}. \tag{1.1}$$

这一计数恒等式把端到端质量分为两个环节。轨迹与需求观测主要影响请求是否进入覆盖；卸载与资源竞争主要影响已接纳请求能否及时完成。不过，两环节在闭环系统中仍会互相影响，式 (1.1) 是统计分解，而不是两个独立组件收益可以直接相加的因果公式。

覆盖扩展可能带来新的服务压力。轨迹策略看到更多未覆盖需求后，可以主动移动并提高接纳比例；若新增请求计算量更高或集中到繁忙节点，接纳后的完

成比例也可能下降。因此，方法效果由端到端成功比例 S/G 评价，接纳率和接纳后完成率用于解释变化来源。该计数框架同时揭示了仅处理少量容易请求时，条件完成率较高而整体服务不足的情况。

DSR 的分母还需要与环境行为一致。本文 UE 电池状态会影响实际服务请求与能量请求的生成类别，因此不同策略的实际服务请求总数可能有轻微差异。预先配对外生随机流，能够减少用户移动和潜在需求差异带来的干扰，但不自动保证策略相关的实际分母完全相同。本文保留实际生成服务请求作为预定主指标，并以共同潜在服务请求为固定分母进行敏感性分析。这样既避免事后更换主评价目标，也检查分母变化是否解释了观察到的优势。

1.1.3　集群空间部署与计算任务分工的研究意义

从集群任务规划角度看，轨迹决策改变未来的服务条件，计算任务分配利用当前已经形成的服务条件。UAV 接近某些 UE 可以提高接纳机会，但同时可能远离其他需求区域或协作节点；任务转移到算力较高的 UAV 可以降低计算时延，却可能增加传输时延、程序获取和分配能耗。这类取舍要求策略考虑多个平台和多个请求之间的关系，使空间机动服务于集体任务目标。UAV 位置或轨迹与资源分配的联合优化研究也体现了这一联系[5-6]。本文进一步以任务是否被接纳、是否按时完成解释轨迹规划与跨机分工各自发挥作用的环节。

机间几何、程序缓存、计算共享与机动能耗共同决定集群服务能力。因此，评价同时报告服务成功、UAV 能耗、跨机分工及 MBS 依赖，刻画空间部署和执行资源的整体权衡。当前能耗模型记录运动与服务消耗，有限电池及返航约束属于进一步研究的条件。

从算法角度看，问题同时包含连续轨迹动作、离散请求目的地和时序状态变化。请求数增加时，目的地组合迅速扩大，一个节点的最终负载又影响分配到该节点的全部请求。单一网络同时输出轨迹与完整分配，需要处理动作尺度、回报来源和组合可行性。本文采用分层结构分别建模位置决策与批量分配，并通过闭环实验评价两类决策的协同效果。

从研究方法角度看，UAV-MEC 算法的性能评价应区分长期闭环结果与固定状态下的求解能力。固定快照实验能够控制位置、请求和历史状态，直接观察某个分配求解器的质量；闭环实验则把分配对电池、缓存、后续观测和轨迹的影响保留下来。前者便于分析批量外部影响和局部搜索性质，后者回答整套方法是否提高长期服务表现。本文同时使用这两种证据，但保持其统计单位与结论边界，避免把固定快照的成功数改善当作长期 DSR 增益。

1.2 国内外研究现状

1.2.1 集群协同覆盖与需求驱动的空间规划

无人机集群规划需要把整体任务目标转化为各平台的空间行动与资源分工。航空集群研究同时涉及轨迹生成、任务分配和协同信息使用，各层之间需要符合平台与任务条件[1]。对于本文的空地计算服务，整体目标是动态请求的按时完成，空间行动则影响请求能否进入物理覆盖。因而，轨迹规划既要关注用户位置，也要关注请求的时间要求和服务负载；停留在用户密集区域不必然对应最高的截止期成功比例。

本文以请求产生时的接纳及其截止期完成情况评价覆盖服务。几何覆盖面积和轨迹访问面积描述空间活动，请求级指标则保留用户移动与业务变化。两条轨迹即使经过相近位置，也可能服务不同任务集合，因而需按实际请求计数连接空间规划和执行效果。

协同覆盖还取决于策略允许使用的信息。UAV 只观察已关联用户时，未覆盖需求难以直接进入其动作依据；引入感知范围内的待接纳需求后，集群可以据此调整未来位置。但扩大观测不是扩大物理服务半径，其上报及时性和获取成本也属于另外的信息条件。本文第三章研究的是在既定信息假设下，需求可见性如何影响协同机动与接纳效果；它保留对实际部署信息来源和同信息架构对照的独立检查要求。

在 100 m 服务半径与 200 m 最小机间距下，可行部署的覆盖圆内部不重叠。这一配置使规划重点成为需求与服务位置的匹配，以及新增接纳后的负载组织。本文以接纳与截止期完成衡量空间部署收益。

1.2.2 协同计算任务分配与模型驱动资源优化

Skaltsis 等综述 UAV 任务分配方法，比较计算复杂度、最优性与可扩展性，并讨论通信与不确定性条件[7]。本文据此明确计算请求、执行节点及截止期目标，在评价分配质量的同时报告求解开销和集中协调需求。

模型驱动方法首先把通信速率、计算时延、能量或覆盖条件写成目标与约束，再根据变量结构采用交替优化、连续近似、离散搜索或博弈求解。其优点是能够明确给出信息条件和约束含义，并在满足特定假设时分析子问题性质。UAV 辅助通信综述指出，部署与轨迹会同时影响覆盖、链路质量和飞行成本[3-4]；在 MEC 场景中，还需要加入执行节点的计算和缓存条件。因此，模型是否准确描述了业务竞争，往往与求解器本身同样重要。

连续优化适合功率、带宽、频率或位置等变量，但任务目的地与缓存选择通

常具有离散性质。研究者常在固定部分变量时处理另一部分，再循环更新。该做法可以降低每个子问题的求解难度，也便于用约束表达服务要求；其代价是整体问题的非凸性和离散耦合仍可能保留。对一个子问题获得精确解，并不意味着整套联合问题获得全局最优解。对于在线场景，还必须衡量重新求解的时间是否与请求截止期和决策时隙相匹配。

博弈方法则强调不同参与者的利益与响应。Yuan、Xie 和 Tan 的研究把基站、UAV 和用户的计算资源交互表述为多层 Stackelberg 博弈，并通过各层效用和响应选择卸载策略[8]。曾耀平等在 UAV 部署与卸载联合问题中，将 UAV 与 UE 的交互表述为领导者和追随者结构，结合联盟形成与势博弈分析[9]。这些方法说明分层结构可以来自参与者之间的决策顺序与利益关系。本文的上下层则是同一协作系统中的轨迹与请求分配模块，其共享服务目标，不能因为同样存在“两层”便直接继承上述博弈的均衡结论。

缓存与卸载的联合设计进一步说明，仅按链路和算力选择节点可能不足。王义君等研究微云、边缘和本地组成的多层结构，通过协同缓存自适应的分层多元宇宙优化算法处理卸载、资源配置及动态时延–能耗权衡[10]。该工作的服务缓存与节点选择设计，为本文考虑程序获取代价提供了相关背景；其细粒度部分卸载假设与本文不可拆分请求不同，数值结果不能直接移植。李侍阳和朱晓荣针对无人机巡检中的感知与 AI 任务，将多维资源优化拆分为若干子问题并交替求解[11]，表明服务目标与任务结构改变时，合适的优化变量和分解方式也会改变。

对于本文，模型驱动方法最直接的启示是显式检查分配外部影响。若 UAV 以最终批量请求数均分算力，迁移一个请求会改变迁入与迁出节点上其他请求的计算频率和完成时间。只计算被迁移请求自身时延的局部规则，可能忽略多个请求同时跨越截止期的变化。第四章因此以整个分配的目标重评估为基础研究 MC-ITR，而不是假定逐请求代价可以无条件相加。该求解器用于明确质量余量和计算代价，不承担本文第五章的实时学习式下层。

1.2.3　动态机动与资源决策中的深度强化学习

深度强化学习（Deep Reinforcement Learning，DRL）把神经网络表示与交互式决策结合，用参数化策略或值函数近似复杂状态下的长期行为。DQN 的研究说明深度网络能够从高维输入中学习动作价值[12]；策略梯度和 Actor–Critic 方法则直接优化动作分布，为连续控制提供了基本工具[13-14]。这些经典算法为 UAV 位置、资源配置和任务调度提供了可采用的优化方式，但算法在一般基准上的有效性不是 UAV-MEC 特定服务协议下的性能证明。

强化学习建模需明确状态、动作、奖励与转移。链路、位置和负载提供即时依据，电池、缓存与移动使动作影响后续回报。策略训练后可通过网络前向快速生成动作，交互采样和参数优化则发生在离线阶段。因此，方法成本需同时说明在线推理与训练数据、教师求解的开销。

连续控制和离散选择需要不同的动作表示。轨迹控制可以由 Gaussian 等连续分布生成方向或位移；请求执行位置可以由分类分布生成离散选择。对大批量请求逐项独立采样虽然容易实现，却未必捕捉最终负载之间的耦合。一种处理办法是把连续与离散决策分开学习；另一种是用优化模块把网络提出的结构化变量转化为完整方案。本文采用后者处理第五章的配额搜索：策略选择节点任务数量的迁移方向，再由条件化匹配生成实际分配。学习模块和求解模块的作用必须分别评价。

Li 等针对多 UAV 辅助 MEC 中的不完整信道信息与任务复杂度估计误差，联合考虑轨迹、任务划分和通信计算资源，提出使用 Beta 分布的多智能体 PPO 框架[15]。该研究关注通信与计算不确定性下的鲁棒设计，采用有界动作分布。本文则研究自然覆盖下不可拆分请求的批量分配，并采用 Gaussian 原始提案与环境执行裁剪相结合的轨迹动作模型。两者的问题条件和动作概率定义各有侧重。

Tao 等研究 UAV 辅助 MEC 中在线服务选择、任务卸载、计算频率、轨迹和悬停安排的联合决策[16]。其中服务程序选择体现了缓存与业务处理之间的联系，在线决策依据当前请求和资源状态进行。本文同样关注程序可用性与请求时序，但使用多 UAV 的自然接纳规则，并以截止期成功比例评价整个服务流程。不同文献使用能效、加权能量、平均时延或服务质量等目标，各自在对应定义下成立；不能仅因均称“联合优化”就把排名拼成一条普遍结论。

学习式方法还受到观测设计限制。网络只能根据实际输入产生策略，注意力或更深的模型不能从没有提供的请求特征中恢复真实需求。如果上层只看到已经关联的用户，它的轨迹控制就可能缺少覆盖外需求的直接信号。扩展观测能够改变决策信息，但也改变方法的信息条件。因此，本文先研究需求可见性与端到端服务的联系，再通过同信息替代结构和冻结策略对照检查组件贡献。观察到整套方法优势之后，仍需要区分“看到了不同信息”与“在相同信息上用了更好的网络”。

1.2.4 多智能体协作与集中训练分散执行

多智能体强化学习（Multi-Agent Reinforcement Learning，MARL）研究多个决策主体的交互。UAV 位置改变覆盖和协作链路，转入任务改变节点共享负载。

各策略更新使单个智能体面对的经验分布变化，联合状态与动作则在相应假设下构成马尔可夫过程。协作、部分可观测与训练非平稳性共同影响方法设计。

集中式训练分散式执行（Centralized Training with Decentralized Execution，CTDE）在训练阶段使用更完整的信息估计价值或构造梯度，执行阶段由各 Actor 根据允许的局部观测选择动作。MADDPG 采用集中 Critic 处理多智能体动作相关性[17]；MAPPO 将 PPO 用于协作多智能体任务，并研究其在基准环境中的表现[18]。CTDE 区分了训练与执行的信息需求，本文据此设计轨迹策略的局部输入和联合价值估计。

同类型 UAV 共享策略参数，使各机经验共同更新网络；不同的位置、能量、邻居和用户观测仍可产生不同动作分布。本文上层采用共享 Actor 和联合观测多输出 Critic，以建模各机局部决策及联合价值。

除 Actor–Critic 外，值分解通过限定联合价值组合方式支持分散选择，VDN 和 QMIX 分别采用加性分解与单调混合[19-20]。不同结构具有相应表达能力与动作条件。本文采用连续轨迹动作与批量离散任务，选择 MAPPO 组织上层决策，以独立求解模块处理下层组合分配。

Hady 等关于资源分配优化的 MARL 综述讨论了多智能体学习在网络资源问题中的方法分类与应用条件[21]。综合这类研究，可以从三个层面审视协作方法：策略执行需要什么信息，训练阶段使用了什么额外信息，评价是否把共享数据或工作负载误当独立重复。本文使用训练块作为学习方法统计重复，以配对工作负载减少环境差异，并在主性能、机制检验与快照诊断之间保持清楚的比较对象。

1.2.5　注意力聚合与结构化优化的作用

注意力机制通过查询与键之间的相似度生成权重，并对值向量加权聚合。Transformer 的缩放点积与多头结构为这一表示方式提供了经典形式[22]。在多 UAV 场景中，自身状态可以作为查询，邻居 UAV 与 UE 槽位作为被聚合元素，使输出随位置、需求和邻居关系变化。这样能够显式表达元素之间的相对关系，也便于对空槽位使用掩码。注意力的实际收益取决于输入特征、训练信号与模型容量，其对 DSR 的影响由具体对照实验评价。

注意力和信息预算应分别讨论。若一个 Actor 得到未覆盖 UE 的请求、电量和位置，而另一个 Actor 只能看到已关联 UE，则两者比较同时包含输入信息差异。即便前者使用注意力，观察到的优势也不足以证明优势完全来自注意力架构。相反，同信息条件下注意力与 MLP 的差值区间跨零，也只能说明这次实验

没有确认结构增益，不能证明所有场景中注意力无效。本文第三章以需求可见性为研究中心，并通过同信息对照评价结构作用。

对于卸载，结构化优化提供了与直接动作输出互补的思路。已接纳请求与执行节点形成二部关系，各边包含合法性、传输代价、计算负载和程序条件。固定节点配额之后，最终计算共享条件可以被写入边成本，再通过指派生成完整方案；改变配额则继续探索不同负载状态。这样的分解把“节点接多少任务”和“具体哪些任务去这些节点”区分开，为学习搜索提供了较紧凑的控制对象。条件化子问题的可求解性不等于原整体问题全局最优，也不等于能耗筛选之后仍保持无条件最优性。

本文第五章的学习配额搜索建立在较强的共享框架上。普通修复、质量掩码、条件化匹配、能耗筛选与最好方案保留本身就可能带来明显收益，因此使用强配额随机与启发式配额搜索对照是必要的。与逐请求随机卸载相比的提升回答完整下层优化包是否有用；与共享框架下配额随机相比的提升才更接近学习搜索的额外贡献。这种比较层次能够突出方法有效的部分，同时避免把整个优化包的收益全部归给 PPO。

1.2.6 最接近研究与本文的具体增量

多 UAV 的轨迹与卸载协同已有直接研究。Ju 等采用多智能体深度确定性策略梯度联合处理路径和任务卸载，考虑 UAV 负载及用户服务公平性，以能耗和计算表现评价系统[23]。这为多机资源分工提供了相关方法背景。本文进一步在规定的自然接纳规则下保留未接纳服务请求，通过 $G/A/S$ 计数分别观察接纳损失和接纳后超时，并把固定状态分配与长期状态反馈分开评价。

学习与匹配结合也已有明确先例。Wang 等研究多 UAV 的边缘计算与数据采集，将用户关联建模为具有外部性的一对多匹配，并与 SAC 的移动和功率决策结合，以缩减动作空间[24]。本文的匹配对象是已接纳请求的计算执行目标：先固定节点任务数，使最终共享负载成为条件参数，再用容量槽指派决定请求身份。因此，区别在于子问题的条件化方式、时限目标和有限预算实现，不能把“强化学习加匹配”本身作为独有贡献。

Chen 和 Tian 提出的 NeuRewriter 使用 Actor–Critic 学习选择局部区域和改写规则，迭代改善组合解，应用包括在线作业调度和路径问题[25]。SF-HLM 延续学习搜索的基本思想，但将动作具体定义为节点配额迁移与停止，并由确定性条件匹配生成完整分配。表 1.1 汇总这些关系。文献比较用于定位问题与方法增量；不同接纳、资源和信息协议下的绝对指标不作直接排名。

表 1.1　最接近研究与本文的问题及方法关系

Table 1.1　Problem and method relationships between the closest studies and this thesis

研究	接纳与评价对象	资源耦合与决策对象	信息及搜索预算的对应关系
Ju 等[23]	多 UAV-MEC；关注系统能耗与计算表现	联合路径和卸载；考虑负载与服务公平性	公开摘要未给出与本文对应的预接纳字段及有限匹配预算；本文使用明确的自然接纳计数
Wang 等[24]	MEC 与数据采集联合系统；优化时延及采集量	有外部性的用户关联匹配，结合 SAC 移动与功率决策	关联匹配与本文计算执行目标不同；信息、任务及预算需按各自模型解释
Chen、Tian[25]	通用组合优化，含在线作业调度和路径任务	学习选择局部区域与改写规则，迭代改善已有解	不采用本文的空地需求观测和配额条件化指派；学习搜索思想为本文相关前序方法
本文	100 m 自然接纳；以全部实际生成服务请求计算 DSR	批量任务均分等效算力；整数配额与容量槽指派	460 m 预接纳观测；下层最多 16 次匹配、128 次普通评价；共享框架对照区分学习增量

1.3　关键研究问题与技术路线

本文的中心问题是：当地面任务需求随位置和时间变化、单机覆盖与机载资源有限时，无人机集群如何通过协同轨迹规划和计算任务分工，使更多请求在截止时间内完成？这一问题可以按决策过程分为三个环节。首先，集群飞向哪里，轨迹策略是否能够依据当前可获得的需求和邻机信息主动改善接纳机会；其次，任务交给谁执行，已接纳请求的最终负载如何影响整个批次的截止期质量，固定快照中是否存在可利用的分配余量；最后，如何连接空间部署和任务执行，在不改变物理接纳规则的前提下，较快的学习配额搜索能否形成长期闭环服务收益。这三项问题分别由第三、第四和第五章回答，并共享请求生成、接纳与成功计数的基本语义。

技术路线以自然覆盖和请求执行模型为基础。本文统一数据传输量纲、最终批量算力共享、缓存更新和时隙决策顺序，分析上层观测与服务失败构成，研究扩展需求观测；随后固定位置与历史状态，通过 MC-ITR 分析请求迁移的整体效果；最后结合固定参数的轨迹策略与独立训练的配额搜索，评估端到端 DSR、资源使用和软件开销。

在算法设计上，本文区分集群空间机动与计算任务分配。共享 Attention-MAPPO Actor 根据各机预动作观测给出二维方向动作，环境处理速度、边界与

机间距约束，训练采用联合观测 Critic。下层集中使用移动前几何和当前请求批次进行跨节点调度。SF-HLM 保持各训练块的上层参数固定，通过二部图表示和 CompleteQuotaPPO 独立学习配额搜索，两类决策通过环境状态反馈形成协同。

在评价设计上，独立训练块反映模型训练变化，配对负载与评估回合用于估计各块性能；非学习方法以随机流重复进行配对评价。固定快照比较控制几何和请求，反事实分配只用于评价。上述设计分别刻画模型、工作负载和求解器差异，并保持相应的独立统计单位。

1.4 研究内容与主要贡献

本文围绕五架 UAV、一百个 UE 和一个 MBS 的动态空地服务仿真主场景，形成以下三项相互关联的研究内容与贡献。

1. **自然覆盖约束下的需求感知集群空间规划**。建立实际生成、自然接纳和截止期成功的统一计数口径，明确接纳率与接纳后质量共同决定端到端 DSR。在物理服务半径不变的条件下，将感知范围内未覆盖需求纳入上层预动作观测，结合邻机与 UE 的注意力聚合研究协同轨迹决策，并使用独立确认与固定潜在分母复核支持对应结论。这一内容将空间部署的效果具体落实到请求接纳与完成，说明需求可见性对集群服务规划的作用，同时保留观测信息条件与注意力结构贡献的区别。
2. **考虑跨机资源竞争的截止期优先计算任务分配**。在给定位置、请求和历史状态下，以超时数、归一化时延和分配能耗的字典序目标研究 MC-ITR。每次候选迁移重新评价整个批次，明确任务迁入和迁出如何通过最终批量算力共享改变其他请求的完成时间。通过主配置、敏感性、小规模一致性检查以及共享轨迹快照桥接，量化跨机分配的质量余量与完整计算代价。这一内容把机载资源竞争作为集群任务分工的核心约束，并为在线方法设计提供诊断依据。
3. **冻结轨迹上层与学习配额匹配的分层协同决策**。对已接纳请求构建请求–节点关系，把计算任务分配分解为配额搜索和配额条件下的指派。结合共同质量掩码、普通修复、能耗筛选与最好方案保留，使用独立训练的 CompleteQuotaPPO 选择配额迁移和停止动作，在有限匹配预算内生成可执行分配；上层保持冻结需求感知策略和原环境语义。在十个独立训练块与五个配对工作负载上进行确认，SF-HLM 的 DSR 为 34.244%，相对贪心修复、冻结请求级下层与适配请求级下层修复分别提高 1.423、2.008 与 2.192 个百分点。全随机、相同学习上层加逐请求随机卸载、启发式配额与强配

额随机分别检验完整系统、下层优化包和学习搜索增量，冻结策略的 UE 与算力九格复验检查场景依赖性。共享强框架上的学习增量较小，结合其统计敏感性和软件耗时解释，不将完整框架收益归于学习组件。

上述研究形成从需求感知空间部署、跨机批量分配到在线闭环服务的论证链。各项结果按对应的接纳规则、训练设置和实验设计分别报告，支持简化二维运动与规定信息条件下的集群服务改进。信息获取与协调成本、飞行动力学以及同信息预算下的注意力结构贡献，构成进一步评价方法适用范围的研究问题。

1.5　论文组织结构

第一章从无人机集群协同任务规划与临时空地服务需求出发，综合协同覆盖、计算任务分配与学习决策的相关研究，提出空间部署和机载负载耦合下的研究问题、技术路线及三项贡献。

第二章说明集群任务规划的层次、简化运动与机间协作关系，介绍 UAV-MEC 的通信、计算、缓存与评价基础，推导马尔可夫决策过程、值函数、策略梯度、带终止处理的广义优势估计和 PPO 裁剪目标，进而说明 MAPPO、注意力聚合与指派匹配的基本原理，为后续算法建立统一符号和理论基础。

第三章研究自然覆盖约束下无人机集群的需求感知协同轨迹决策，建立动态请求、几何运动约束与上层观测模型，通过服务失败分解、训练动态与独立确认分析需求可见性对集群接纳和端到端服务的影响。

第四章研究考虑跨机资源竞争的截止期优先计算任务分配，在固定轨迹快照中给出 MC-ITR 的批量外部影响、字典序目标、搜索流程和有限终止性质，并报告不同负载、算力与共享快照上的质量、能耗和求解开销。

第五章研究无人机集群协同轨迹与计算任务分配的分层决策，描述 SF-HLM 的冻结轨迹上层、条件化匹配与 CompleteQuotaPPO 搜索，进行独立确认、随机补充、同预算机制比较与冻结策略稳健性评价，并通过集群机动、任务分工、软件计时和快照诊断解释完整方法的性能与代价。

第六章归纳需求感知空间规划、跨机资源分配和完整在线协同的主要发现，说明现有信息与仿真假设的适用范围，并提出飞行动力学、通信受限协同、平台故障、续航约束和跨场景评价等后续研究方向。

1.6 本章小结

本章将无人机集群协同规划具体化为两个连续的服务环节：集群通过空间机动形成自然覆盖接纳机会，再通过计算任务分工与资源使用按时完成请求。相关工作说明协同轨迹、任务分配与学习决策具有多种可行建模方式，也提示规划结构、信息条件与实测性能应分别论证。本文据此采用需求观测研究、固定快照诊断和完整方法确认相结合的技术路线，后续章节在同一任务与服务语义下逐步说明方法设计、公式推导和实验依据。

第 2 章　相关技术与理论基础

本章为无人机集群协同轨迹规划与计算任务分配建立共同的系统概念与数学基础。首先从集群任务规划的层次关系出发，说明简化机动约束、空间部署和机载资源分工如何连接，再介绍 UAV-MEC 中通信、计算、缓存和自然接纳的联系。随后从有限时域马尔可夫决策过程推导值函数与策略梯度，给出带终止处理的广义优势估计和近端策略优化，并介绍多智能体协作、MAPPO、注意力聚合，以及第五章使用的二部图与条件化指派。通用理论说明算法形式及成立条件；本文的网络结构、超参数和性能结论分别由后续章节的实现与实验证据确定。

2.1　无人机集群任务规划与协同服务基础

2.1.1　任务分工、轨迹规划与飞行执行的层次关系

无人机集群通过多个空中平台共同承担任务，研究内容包括任务分配、轨迹规划、信息交互和飞行控制等相互联系的环节[1]。任务分配确定哪些平台承担哪些工作，轨迹规划确定平台如何到达或保持有利位置，飞行执行将规划指令转化为实际运动。各层面对的时间尺度、状态信息和可行性条件不同：任务分配需要理解任务价值及资源需求，轨迹规划需要处理空间关系和机动限制，飞行执行还需要满足飞行器动力学与控制约束。区分这些层次有助于准确界定算法解决的航空集群问题。

本文聚焦任务层与规划层之间的协同。空中平台通过改变服务位置接纳地面计算请求，再通过机载计算、跨 UAV 协作和 MBS 支持完成请求。任务具有输入数据量、服务类别、截止时间和执行资源需求；其分配是在已接纳请求与执行节点之间建立对应关系。无人机任务分配文献包含多种任务类型和约束[7]，本文采用其中明确的计算服务任务，未把地面请求改写为需要无人机实体到访的侦察目标或运输订单。因此，服务覆盖承担任务接入功能，执行节点选择承担资源分工功能，两者共同决定集群的时限服务能力。

从规划对象看，第三章研究多机如何依据需求选择下一时隙的空间部署，第四章研究给定空间部署下如何调整任务执行分工，第五章连接这两个决策过程并检验闭环服务表现。这里的“集群协同”体现为多个 UAV 的位置与资源决策服务于共同的请求完成目标。任务层的协同无需预设固定编队形状；本文没有为 UAV 指定领航者、队形参考或编队稳定性目标，后续分析也不以保持特定队形作为性能指标。

2.1.2 二维机动模型与离散空间可行性

为了把注意力集中在任务需求与空间部署之间的联系，本文采用固定高度下的二维运动描述。UAV u 的水平位置为 $\mathbf{q}_u(t) \in \mathbb{R}^2$，高度保持 $H = 100\,\mathrm{m}$；时隙长度为 $\Delta t = 1\,\mathrm{s}$，最大运动速度为 $v_{\max} = 15\,\mathrm{m/s}$。在 $700 \times 700\,\mathrm{m}^2$ 场地中，环境保留 50 m 的边界距离，因而离散水平位置范围为 $\mathcal{Q} = [50\,\mathrm{m}, 650\,\mathrm{m}]^2$。五架 UAV 的位置更新满足

$$\mathbf{q}_u(t+1) = \mathbf{q}_u(t) + \boldsymbol{\delta}_u(t), \qquad \|\boldsymbol{\delta}_u(t)\|_2 \leqslant v_{\max}\Delta t = 15\,\mathrm{m}, \qquad \mathbf{q}_u(t+1) \in \mathcal{Q}. \quad (2.1)$$

$\boldsymbol{\delta}_u(t)$ 的单位为 m，表示修复后的实际位移。它与网络输出的无量纲动作提案不同；时隙平均速度模长是 $\|\boldsymbol{\delta}_u(t)\|_2/\Delta t$。这一量纲关系使轨迹长度、单步机动与能耗结算可以使用同一实际位移。

环境另要求离散位置之间满足最小水平间距 $d_{\min} = 200\,\mathrm{m}$。以联合位置集合表示，可行区域为

$$\mathcal{Q}_{\mathrm{joint}} = \left\{(\mathbf{q}_1, \cdots, \mathbf{q}_N) : \mathbf{q}_u \in \mathcal{Q},\ \|\mathbf{q}_u - \mathbf{q}_v\|_2 \geqslant d_{\min},\ \forall u \neq v\right\}. \quad (2.2)$$

各机独立输出提案并不保证联合位置属于该集合。实际执行先限制提案位移并裁剪边界，再有限次调整冲突位置，同时重新检查运动预算；若仍有间距冲突，则把相应 UAV 回退至原位置，并继续传播回退直至得到可行离散状态。由此产生的悬停属于执行映射的一部分，需要保留在轨迹和能耗记录中。实现对最终离散状态采用 $10^{-3}\,\mathrm{m}$ 数值容差。该过程是对离散位置的环境可行性修复，不是对非凸可行集求最近点的精确投影，也不构成连续飞行轨迹上的避碰或稳定性证明。

模型没有显式描述加速度、转弯半径、姿态和风场。式 (2.1) 所能支持的是具有位移预算的空间部署决策，而非满足完整飞行动力学的控制器。保持高度并限制步长，可以简化需求变化与机动选择的关系；若面向真实飞行执行，还需把规划位移交给满足具体飞行器约束的轨迹生成与跟踪模块，并重新评估执行误差对覆盖和截止期服务的影响。

2.1.3 服务覆盖、邻机关系与空间资源耦合

服务覆盖与需求观测具有不同作用。本文的物理服务半径为 $R_{\mathrm{cov}} = 100\,\mathrm{m}$，请求只有进入 UAV 的服务范围才被自然接纳；允许的感知范围为 $R_{\mathrm{sense}} = 460\,\mathrm{m}$，使轨迹策略可以使用服务范围之外的部分需求信息。邻机关系也按该感知距离筛选，由

$$\mathcal{N}_u(t) = \{v \neq u : \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2 \leqslant R_{\mathrm{sense}}\} \quad (2.3)$$

形成随位置变化的邻居集合。各 UAV 高度相同，因此 UAV 间三维距离等于水平距离。式 (2.3) 定义模型允许进入观测的邻机关系，不包含消息排队、丢包或链路连通性保证；这些信息如何在实际系统中获取仍取决于通信协议。

最小机间距满足 $d_{\min} = 2R_{\mathrm{cov}}$，使不同 UAV 的圆形覆盖内部在规定离散状态下不重叠。因此，本文轨迹优化的重点是把有限服务区域部署到有需求的位置，而不是通过学习消除本已受几何约束限制的覆盖重叠。某架 UAV 移动会改变其后续可接纳需求、与其他 UAV 的协作距离以及相应传输代价；其他 UAV 的移动也会改变整个机群的空间服务配置。评价时必须保留未覆盖请求，才能衡量这类空间协同是否转化为任务接纳改善。

空间部署的收益还取决于执行资源。服务位置更接近高需求区域，可能接纳更多请求，同时让接纳节点的共享算力承担更大批量。跨 UAV 转移能够重新分担计算负载，却需要额外传输，并可能因目标节点缺少服务文件而增加准备时间。于是，集群规划面对的是位置、任务集合和资源分工的时序耦合：机动改变可服务请求集合，任务分配改变节点负载与缓存状态，后续状态再影响下一次机动决策。本文用“接纳率 × 接纳后按时完成率”解释这一服务链条，具体计数与推导在第三章展开。

2.1.4　分散式轨迹决策与集中任务调度

本文采用上层分散式 Actor 与下层集中批量调度。各 UAV 根据自身、邻机和用户特征产生动作提案，训练时由联合观测 Critic 提供价值估计。共享参数使各机使用同一决策规则，不同局部观测则产生不同机动提案。局部信息由仿真按规定范围提供，实际获取这些信息所需的上报与通信成本属于进一步研究的系统条件。

下层的 MC-ITR 快照求解和 SF-HLM 配额匹配均需要汇总当前请求与执行节点资源，评价一个完整分配。SF-HLM 的配额策略对请求–节点图执行集中搜索，与上层多个 UAV 分别采样动作的主体不同。因而本文的集群协同需要集中任务协调条件，尚未实现所有环节完全分布式自治。该架构利用两类决策的结构差异：位置规划适合通过多智能体局部输入输出组织，批量任务分配则通过共同负载状态识别跨请求影响。

当前决策步先依据已有位置接纳请求，评价当前批次的路径时延和费用，再应用机动动作形成后续位置。任务的解析完成时间用于截止期评分，未完成工作不保留为跨步队列；缓存按批次结束规则更新，未模拟下载完成事件。上层面向未来接纳与状态变化作出机动决策，下层处理当前已接纳批次。第五章保持训练

后的上层参数固定，独立训练配额策略；两层通过该抽象环境中的状态反馈联系。强化学习、注意力和匹配分别承担空间决策、信息聚合与资源分配的作用。

2.2 无人机辅助移动边缘计算基础

2.2.1 网络层次与请求执行位置

移动边缘计算把部分计算与存储能力部署在接近用户的位置，形成终端、边缘节点与中心服务之间的协作[2]。请求的完成过程包含数据进入、必要程序准备、计算执行和结果返回。改变计算位置可以减少某些处理环节的时间，也可能增加无线传输或回传成本。因此，“边缘更近”与“请求更快完成”不是同义关系，需要把完整路径上的代价写入评价。图 2.1 给出通用层次关系；本文进一步用移动 UAV 作为可接纳请求的空中边缘节点。

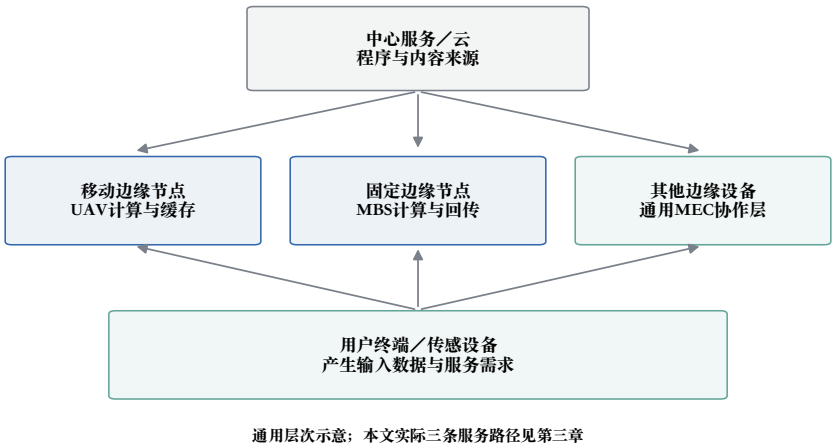


图 2.1 终端、边缘与中心服务之间的通用层次关系示意

本研究中的“本地执行”具有明确含义。通用 MEC 文献中的本地常指 UE 在自身处理器上计算，本文请求被 UAV 自然接纳之后，下层动作中的本地指接纳 *UAV* 本地计算。另两个类别是转移给协作 UAV 和卸载到 MBS。三类执行位置共享同一接纳前提，不能把选择 MBS 解释为 UE 无需进入 UAV 覆盖范围便直接得到服务。后续卸载比较均以已接纳请求为输入，而端到端 DSR 仍保留未接纳请求在分母中的影响。

设一个时隙的接纳服务请求集合为 $\mathcal{M}_t$，执行节点集合为 $\mathcal{J}$。请求 m 的输入字节数为 L_m，所需 CPU 总周期为 C_m，截止时间为 D_m，服务类别为 $s(m)$。若服务类型决定每字节所需周期数 ω_m，则

$$C_m = \omega_m L_m. \tag{2.4}$$

L_m 与 C_m 分别描述传输数据量和计算负担，其比例影响执行节点选择。本文采

用不可拆分任务模型，每个请求选择一个执行节点；允许数据切分或并行子任务的部分卸载问题具有不同的可行域。

2.2.2　位置相关的无线通信与量纲转换

UAV 的水平位置记为 $\mathbf{q}_u(t)$，地面 UE 的水平位置记为 $\mathbf{w}_m(t)$。在 UAV 高度为 H_u 的几何模型下，UE 与 UAV 的三维距离为

$$d_{mu}(t) = \sqrt{\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2^2 + H_u^2}. \tag{2.5}$$

距离变化会影响信道功率增益，进而影响数据进入与任务转移的时延。UAV 辅助通信可以采用不同的传播模型[4]；本文后续仿真使用明确的自由空间路径损耗假设，不把地形遮挡、实测衰落或现实部署可靠性自动包含在该模型中。

在一个理想噪声受限链路中，带宽为 B、发送功率为 P、信道功率增益为 g、接收噪声功率为 σ^2 时，常用速率表达为

$$R = B \log_2 \left(1 + \frac{Pg}{\sigma^2}\right). \tag{2.6}$$

这里 B 的单位为 Hz，R 的单位为 bit/s。若输入数据以 byte 记录，数据传输时间必须使用

$$T_m^{\mathrm{tx}} = \frac{8L_m}{R}, \qquad E_m^{\mathrm{tx}} = PT_m^{\mathrm{tx}}. \tag{2.7}$$

因子 8 来自一个字节包含八个比特。遗漏该转换会把传输时间缩小八倍，从而同时改变截止期判断、能耗和卸载偏好。本文所有请求大小与链路速率均按此量纲关系处理；程序下载的字节数同样需要转换。

式 (2.6) 给出瞬时链路速率，共享带宽时还需由调度规则确定各请求的有效速率。顺序传输的总时间为各段时间之和：协作卸载包含接入、机间传输和结果返回，MBS 卸载还包含回传。后续章节按完整执行路径计算请求时延。

移动带来的通信改善与飞行成本也需要共同考虑。UAV 更接近某一热点可能提高接入速率和接纳比例，但移动同时消耗能量，并改变与其他节点的距离。一个位置对当前请求有利，不一定对后续请求或协作链路有利。轨迹控制因此具有跨时隙性质，而不仅是逐时隙寻找最短通信距离。图 2.2 用通用示意说明 UAV 的通信角色；本文具体关注其中移动边缘服务和多节点协作的部分。

2.2.3　批量计算共享与缓存代价

计算节点的等效处理能力记为 F_j，单位为 CPU 周期每秒。对于分给节点 j 的最终批量请求数 N_j，若该节点采用等份共享，则每个请求获得的等效计算服务速率为 $f_{mj} = F_j/N_j$。该服务份额不直接对应物理处理器的单核时钟。请求 m

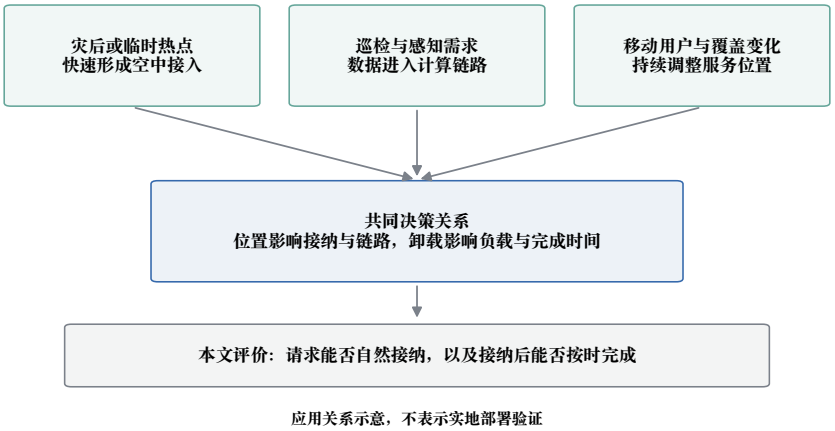


图 2.2　UAV 作为覆盖节点、中继与移动边缘服务器的应用关系示意

在节点 j 的计算时间为

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{f_{mj}} = \frac{C_m N_j}{F_j}, \qquad N_j \geqslant 1. \tag{2.8}$$

该式仅用于实际分配到节点的请求，不对 $N_j = 0$ 的空节点进行除法。本文 UAV 使用最终批量共享语义；MBS 的计算能力按环境协议处理，并不套用 UAV 的 F_j/N_j 规则。不同类型节点的差别需要在成本模型中显式保留。

本文以等效频率形式构造简化计算能耗，将任务服务速率 f 代入 $P^{\mathrm{cmp}} = \kappa f^3$，其中 κ 为模型系数。完成 C_m 个周期需要 C_m/f 的时间，故

$$E_{mj}^{\mathrm{cmp}} = \kappa f_{mj}^3 \frac{C_m}{f_{mj}} = \kappa C_m f_{mj}^2 = \kappa C_m \left(\frac{F_j}{N_j}\right)^2. \tag{2.9}$$

共享请求增多时，单请求计算时间随 N_j 增长，模型计算能耗随 N_j^{-2} 下降。这一关系依赖等份服务速率与等效功耗的共同假设，不表示真实硬件会随请求数量执行同样的频率调节。后续能耗比较据此评价规定参数下的策略费用，而非机载平台的实测节能。

设一个请求从 UAV i 迁往 UAV j。迁移不仅改变该请求的链路和处理时间，还把 N_i 减一、N_j 加一，因此改变两个节点上其他请求的 f_{mi} 或 f_{mj}。若这些请求接近截止时间，单次迁移可能使多个请求同时成功或失败。于是，整个分配的代价一般不能表示为一组与其他分配无关的固定单请求代价。这一批量外部影响是第四章整体重评估与第五章配额条件化匹配的共同动机。

缓存引入另一项执行条件。设服务程序 s 的字节数为 B_s，节点 j 对该程序的缓存指示为 $z_{js} \in \{0,1\}$。当 $z_{js} = 0$ 时，执行请求可能需要获取程序，典型顺序下载时间为 $8B_s/R_j^{\mathrm{fetch}}$。如果程序已缓存，则相应获取环节可以减少。缓存容

量约束可以一般地表示为

$$\sum_{s} z_{js} B_s \leqslant K_j, \tag{2.10}$$

其中 K_j 是节点存储容量。该式描述通用容量限制；后续实际缓存替换与提交规则以仿真实现为准。当前请求使用的缓存状态与本时隙末更新后的状态不能混淆，否则相当于提前使用未来信息。

2.2.4　覆盖、接纳与端到端指标

在水平服务半径 R_c 的模型下，请求所在 UE 满足 $\|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|_2 \leqslant R_c$，才可能由 UAV u 接纳。感知半径 R_s 则决定策略允许获得哪些需求信息，两者承担不同作用。扩大 R_s 可以改变观测，不能自动把 R_c 之外的请求纳入执行。本文使用 $R_c = 100\,\mathrm{m}$ 与 $R_s = 460\,\mathrm{m}$，后续观测实验保持物理接纳半径不变。

设评估单元的成功数为 S、接纳数为 A、实际生成数为 G。当分母非零时，DSR、接纳率与条件完成率分别为 S/G、A/G 和 S/A。聚合多个时隙时，应先合并相应计数，再计算这些比值。例如，$\sum_t S_t / \sum_t G_t$ 一般不等于 $\frac{1}{T}\sum_t S_t/G_t$，因为后者给予每个时隙相同权重，前者给予每个请求相同权重。按训练块合并请求后再跨块平均，也与直接把全部块请求混为一个比值不同。本文根据预定协议使用对应聚合方式，并在图表中说明统计单位。

公平性需要说明它评价的是哪一种累计量。对于非负的每 UE 累计服务覆盖量 c_m，Jain 指数为

$$J = \frac{\left(\sum_{m=1}^{M} c_m\right)^2}{M \sum_{m=1}^{M} c_m^2}. \tag{2.11}$$

当所有 c_m 相同且至少一个非零时，$J = 1$；服务集中到少数 UE 时，该值下降。全部为零时采用环境规定的零分母处理。该指标刻画所定义累计服务量的均衡程度，具体计数规则在第三章给出。

能源统计也必须保持主体一致。UAV 总能耗可以包含飞行、悬停、无线充电、服务计算、通信、回传或程序获取，以及内容处理等环节。分配能耗只覆盖其中与任务执行位置有关的非飞行部分。比较固定快照求解器时，位置固定，分配能耗便于观察卸载代价；比较闭环方法时，则应报告 UAV 总能耗。用前者替代后者，或把未计入的 MBS 能耗当作已经包含，会改变评价含义。

2.3 马尔可夫决策过程与长期目标

2.3.1 状态、动作与转移的定义

强化学习通过环境交互优化行为策略，其核心是动作对未来状态与回报的影响[26]。在离散时隙 t，智能体获得输入，选择动作 a_t，环境产生奖励 r_t 并转移到下一状态。图 2.3 展示基本交互关系。这里的奖励是训练信号，评价指标则是研究要报告的量；二者可以相关，但一个多项加权奖励的改善不自动证明每一项评价指标均改善。

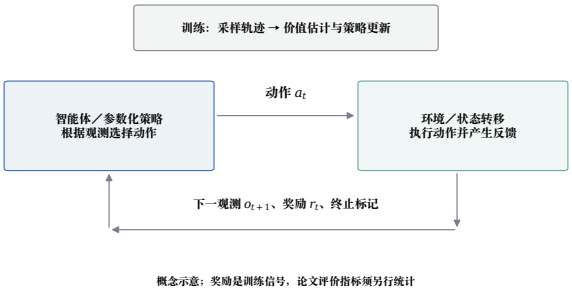


图 2.3 强化学习中的状态、动作、奖励与环境转移关系

一个有限时域 MDP 可记为 $(\mathcal{S}, \mathcal{A}, P, r, \rho_0, \gamma, T)$：$\mathcal{S}$ 为状态空间，$\mathcal{A}$ 为动作空间，$P(s' \mid s, a)$ 为转移分布，r 为奖励机制，ρ_0 为初始状态分布，$\gamma \in [0, 1)$ 为折扣因子，T 为时域长度。状态包含预测下一步所需的信息，马尔可夫条件为

$$P(s_{t+1} \mid s_0, a_0, \cdots, s_t, a_t) = P(s_{t+1} \mid s_t, a_t). \tag{2.12}$$

若请求过程显式依赖时隙序号，有限时域状态还可包含时间。该条件属于环境状态层面，并不要求每个 UAV 的局部观测都能恢复完整状态。

策略 $\pi_\theta(a \mid s)$ 给出状态下的动作概率或概率密度，参数为 θ。离散动作满足概率和为一，连续动作密度在动作空间上积分为一。为简化记号，本章写作 $\sum_a$ 的表达在连续情形对应积分。需要动作合法性掩码时，策略的有效支持集随状态改变；只要在相同状态上比较旧、新策略，并正确保存采样时掩码，仍可以按相同支持计算概率比。若修改了动作语义或合法集合，则不能不加检查地复用原有比率。

UAV-MEC 的完整状态包括位置、能量、缓存、当前请求及运行阶段，而策略使用经筛选与定长编码的局部观测 $o_{u,t}$。相同观测可以对应不同完整状态，因此上层属于部分可观测决策。历史 $h_{u,t} = (o_{u,0}, a_{u,0}, \cdots, o_{u,t})$ 可提供额外信息，有限窗口或循环网络是相应近似处理方式。本文采用当前预动作观测，其信息范围见第三章。

2.3.2　折扣回报与值函数

为避免与请求生成计数 G 混淆，本章用 $\mathcal{G}_t$ 表示从时隙 t 开始的折扣回报：

$$\mathcal{G}_t = \sum_{k=t}^{T-1} \gamma^{k-t} r_k, \qquad \mathcal{G}_T = 0. \tag{2.13}$$

折扣因子决定未来奖励的相对权重。γ 接近一时，较远未来对当前动作更重要；较小的 γ 更强调近期效果。有限时域目标可在 $\gamma = 1$ 时定义，但后文涉及无限时域有界值与收缩性质时使用 $\gamma < 1$。本文实际超参数属于实验配置，不从数学定义推导其最优数值。

有限时域状态值与动作值分别为

$$V_t^{\pi}(s) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s], \tag{2.14}$$

$$Q_t^{\pi}(s,a) = \mathbb{E}_{\pi}[\mathcal{G}_t \mid s_t = s, a_t = a]. \tag{2.15}$$

V_t^{π} 对策略实际选择的动作取平均，Q_t^{π} 则固定当前动作后再遵循策略。有限时域下，即使状态相同，剩余时间不同也可以使价值不同，因此保留下标 t。若把时间并入状态，可使用不带显式时间下标的记号。神经网络 Critic 的输出是这些量的估计，不能预先当作真实期望。

从式 (2.13) 分离第一项得到 $\mathcal{G}_t = r_t + \gamma \mathcal{G}_{t+1}$。对下一状态和下一动作依次取条件期望，得到 Bellman 关系

$$Q_t^{\pi}(s,a) = \bar{r}(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{t+1}^{\pi}(s'), \tag{2.16}$$

$$V_t^{\pi}(s) = \sum_{a} \pi(a \mid s) Q_t^{\pi}(s,a), \qquad V_T^{\pi}(s) = 0, \tag{2.17}$$

其中 $\bar{r}(s,a)$ 为给定状态与动作的奖励期望。若奖励同时依赖下一状态，该期望包含对 s' 的积分。Bellman 关系连接当前奖励和未来价值，不要求即时奖励就是最终性能指标，也不意味着可以忽略请求执行后的状态变化。

优势函数定义为

$$A_t^{\pi}(s,a) = Q_t^{\pi}(s,a) - V_t^{\pi}(s). \tag{2.18}$$

它表示相对于当前策略在该状态的平均行为，特定动作的长期回报差异。由 V_t^{π} 的定义可得

$$\sum_{a} \pi(a \mid s) A_t^{\pi}(s,a) = 0. \tag{2.19}$$

正优势动作相对平均更好，负优势动作相对平均更差；“更好”是给定奖励与策略的比较，不能直接翻译成每个物理指标都变好。后续 Actor 更新使用估计优势，需要考虑 Critic 误差和采样波动。

2.3.3 动态规划性质与函数近似的边界

在已知模型的有限时域问题中，最优值可从终端条件向前递推：

$$V_t^*(s) = \max_a \left\{ \bar{r}(s,a) + \gamma \sum_{s'} P(s' \mid s,a) V_{t+1}^*(s') \right\}. \tag{2.20}$$

该关系要求能够表示和计算状态、动作及转移。当联合动作数量巨大或转移模型复杂时，递推本身并不提供低成本的实际求解途径。深度强化学习通过样本与函数近似处理这些难点，其性质与已知有限表格模型中的精确动态规划不同。

对于有界奖励、平稳策略和无限折扣时域，定义策略 Bellman 算子 $\mathcal{T}^\pi$。任取两个有界函数 V, W，由于概率加权不会放大最大绝对差，有

$$|(\mathcal{T}^\pi V)(s) - (\mathcal{T}^\pi W)(s)| \leqslant \gamma \sum_a \pi(a \mid s) \sum_{s'} P(s' \mid s,a) |V(s') - W(s')| \tag{2.21}$$

$$\leqslant \gamma \|V - W\|_\infty, \tag{2.22}$$

从而 $\|\mathcal{T}^\pi V - \mathcal{T}^\pi W\|_\infty \leqslant \gamma \|V - W\|_\infty$。该收缩性质保证精确策略评价的唯一固定点。采用神经网络近似、有限样本和多智能体策略更新时，还存在估计与优化误差，训练行为由相应实验评价。

实际 Actor–Critic 训练会改变策略，因此 Critic 的目标也随之变化。即使网络在某次更新中更贴近采样目标，也不等于接近全局最优策略。对 UAV-MEC，还存在部分可观测、环境状态编码、奖励尺度和随机需求等因素。本文采用固定预算、最后检查点、独立训练块与配对评估来检验最终行为，不用一条看似平滑的回报曲线替代最终策略验证。

2.4 策略梯度与 Actor–Critic 推导

2.4.1 轨迹概率与似然比求导

策略梯度直接优化参数化动作分布，适用于无法方便枚举全部动作的情形[13]。记一条交互轨迹为 $\xi = (s_0, a_0, r_0, \cdots, s_T)$，策略目标为

$$J(\theta) = \mathbb{E}_{\xi \sim p_\theta} \left[\sum_{t=0}^{T-1} \gamma^t r_t \right]. \tag{2.23}$$

假设初始分布和环境转移不直接依赖 θ，且可交换求导与积分。轨迹概率中与策略相关的部分来自各时隙动作概率，因此

$$p_\theta(\xi) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_\theta(a_t \mid s_t) P(s_{t+1}, r_t \mid s_t, a_t), \tag{2.24}$$

$$\nabla_\theta \log p_\theta(\xi) = \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t). \tag{2.25}$$

第二式利用了环境项导数为零的条件。若环境本身也由同一参数控制，需要加入相应导数，不能沿用这里的简单形式。仿真奖励可以是随机量，只要其生成分布属于固定的环境条件即可。

令 $R(\xi) = \sum_t \gamma^t r_t$。使用 $\nabla p_\theta = p_\theta \nabla \log p_\theta$，得到

$$\nabla_\theta J(\theta) = \int \nabla_\theta p_\theta(\xi) R(\xi) \, \mathrm{d}\xi \tag{2.26}$$

$$= \mathbb{E}_{p_\theta} \left[R(\xi) \sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]. \tag{2.27}$$

这一表达不需要对环境转移求导。即使动作执行包含离散请求分配、位置裁剪或缓存更新，只要轨迹来自已定义的参数化策略和环境映射，也可以通过采样概率的导数构造估计。神经网络的可微性用于计算策略参数导数，并不要求仿真物理过程本身可微。

2.4.2　因果性与回报到达估计

完整轨迹回报包含动作之前的奖励，但当前动作不可能改变已经发生的事件。为形式化这一点，记动作前历史为 $\mathcal{H}_t$，对于 $k < t$，r_k 在给定 $\mathcal{H}_t$ 后已确定。对当前动作的条件期望满足

$$\mathbb{E}_{a_t \sim \pi_\theta} \left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) \mid \mathcal{H}_t \right] = \sum_a \nabla_\theta \pi_\theta(a \mid s_t) = \nabla_\theta 1 = 0. \tag{2.28}$$

所以式 (2.27) 中每个动作之前的奖励项，其梯度期望为零。删去这些只增加估计波动的项后，有

$$\nabla_\theta J(\theta) = \mathbb{E}_{p_\theta} \left[\sum_{t=0}^{T-1} \nabla_\theta \log \pi_\theta(a_t \mid s_t) \sum_{k=t}^{T-1} \gamma^k r_k \right] \tag{2.29}$$

$$= \mathbb{E}_{p_\theta} \left[\sum_{t=0}^{T-1} \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) \mathcal{G}_t \right]. \tag{2.30}$$

式中 γ^t 对应从时隙零开始的折扣，$\mathcal{G}_t$ 则从当前时隙开始累计。这一因子保持有限时域目标与梯度推导的定义一致。

再对固定 s_t, a_t 之后的未来轨迹取期望，可将 G_t 替换为 $Q_t^{\pi_\theta}(s_t, a_t)$：

$$\nabla_\theta J(\theta) = \mathbb{E}_{p_\theta}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) Q_t^{\pi_\theta}(s_t, a_t)\right]. \tag{2.31}$$

由此得到有限时域策略梯度。对于部分可观测策略，将策略条件改为可用历史或观测，仍可从轨迹概率推导得分函数估计，动作价值也取相应条件下的期望。

该推导给出期望梯度，而实际训练只拥有有限条轨迹。估计的方差可能来自随机请求、初始位置、策略采样和长期状态传播。UAV 轨迹的一个动作可能影响多个未来时隙的接纳条件，直接用整段回报更新会较为嘈杂。Actor–Critic 因此引入价值网络和优势估计，以在可控偏差与方差之间构造更有效的训练信号。

2.4.3 基线不偏性与优势形式

取一个只依赖动作前信息、而不依赖当前采样动作的基线 $b_t(s_t)$。利用式 (2.28)，其对梯度的期望贡献为

$$\mathbb{E}\left[\nabla_\theta \log \pi_\theta(a_t \mid s_t) b_t(s_t) \mid s_t\right] \tag{2.32}$$

$$= b_t(s_t) \sum_a \pi_\theta(a \mid s_t) \nabla_\theta \log \pi_\theta(a \mid s_t) \tag{2.33}$$

$$= b_t(s_t) \nabla_\theta \sum_a \pi_\theta(a \mid s_t) = 0. \tag{2.34}$$

因此，减去动作无关基线保持理想策略梯度的期望，连续动作积分得到相同结论。神经网络基线在 Actor 更新中作为固定训练信号；动作相关基线则需要额外校正才能保持该性质。

选择 $b_t(s) = V_t^\pi(s)$，可以把动作值换成优势：

$$\nabla_\theta J(\theta) = \mathbb{E}\left[\sum_t \gamma^t \nabla_\theta \log \pi_\theta(a_t \mid s_t) A_t^\pi(s_t, a_t)\right]. \tag{2.35}$$

Actor 由此依据相对于状态平均表现的差异更新策略，减少状态差异带来的波动。价值函数提供常用的不偏基线，其方差削减效果还取决于梯度尺度和价值估计精度。

Critic 用参数 ϕ 近似 V_t^π，训练目标可以来自实际回报或多步自举。若目标记为 $\widehat{V}_t$，基本均方损失为

$$L_V(\phi) = \frac{1}{2}\mathbb{E}\left[(V_\phi(s_t) - \widehat{V}_t)^2\right]. \tag{2.36}$$

Actor 与 Critic 的作用不同：前者优化动作概率，后者拟合用于估计的目标。Critic 损失降低可以意味着拟合更好，但不保证 Actor 的最终 DSR 上升；反过来，价值目标随策略变化时，损失短期升高也不必然代表策略性能恶化。后续训练图须按各自物理含义解释。

2.5　时序差分与广义优势估计

2.5.1　一步时序差分与多步自举

一步时序差分（Temporal Difference，TD）将当前奖励与下一状态价值组成目标。对非终止转移定义

$$\delta_t = r_t + \gamma V_\phi(s_{t+1}) - V_\phi(s_t). \tag{2.37}$$

如果 V_ϕ 等于真实策略值，给定当前状态和动作的 δ_t 条件期望就是 A_t^π，因为式 (2.16) 的未来期望恰好给出动作值。若 Critic 不准确，TD 目标会包含自举误差；其代价是偏差，优点是无需等待完整回合结束即可获得训练信号。

在不存在中间终止的 n 步窗口内，多步目标与优势估计可以写成

$$\widehat{V}_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l r_{t+l} + \gamma^n V_\phi(s_{t+n}), \tag{2.38}$$

$$\widehat{A}_t^{(n)} = \widehat{V}_t^{(n)} - V_\phi(s_t) = \sum_{l=0}^{n-1} \gamma^l \delta_{t+l}. \tag{2.39}$$

最后一个等号来自相邻价值项的消去：$\gamma V(s_{t+1})$ 与下一项中的 $-\gamma V(s_{t+1})$ 相抵，依次只留下窗口末端的自举值。n 增大时使用更多真实奖励，通常减少对近端 Critic 的依赖，但也引入更多随机未来变化；这构成多步估计的基本取舍。

真正终止和采样截断不能混为一类。真正终止表示目标任务已经结束，之后没有应计入回报的状态价值；采样截断只表示当前缓冲区或记录窗口到此结束，环境过程可能继续。如果为了收集固定长度 rollout 而截断，却把后续价值强行设为零，会系统性改变窗口末端的估计。另一方面，若一个回合按任务定义在第 T 步结束，则该有限时域终点本身可以是真正终止，不应因为代码称其为 time limit 就机械地自举。

2.5.2　GAE 的加权推导

广义优势估计（Generalized Advantage Estimation，GAE）将多步优势进行指数加权[27]。设当前非终止窗口剩余 K 步，$\lambda_{\mathrm{GAE}} \in [0, 1]$，有限窗口的加权形式为

$$\widehat{A}_t^{\mathrm{GAE}} = (1 - \lambda_{\mathrm{GAE}}) \sum_{n=1}^{K-1} \lambda_{\mathrm{GAE}}^{n-1} \widehat{A}_t^{(n)} + \lambda_{\mathrm{GAE}}^{K-1} \widehat{A}_t^{(K)}. \tag{2.40}$$

最后一项吸收窗口之后的剩余权重，使有限混合的权重和为一。若遗漏这一项，估计在有限窗口中会发生额外缩放。$\lambda_{\mathrm{GAE}} = 0$ 时只保留一步估计，$\lambda_{\mathrm{GAE}} = 1$ 时只保留最长窗口的多步估计，端点按相应极限理解。

将式 (2.39) 代入上述混合，观察 δ_{t+l} 的系数：它出现在所有 $n \geqslant l+1$ 的估计中，因此对应权重为

$$\gamma^l \left[(1-\lambda_{\mathrm{GAE}}) \sum_{n=l+1}^{K-1} \lambda_{\mathrm{GAE}}^{n-1} + \lambda_{\mathrm{GAE}}^{K-1} \right] \tag{2.41}$$

$$= \gamma^l \lambda_{\mathrm{GAE}}^l. \tag{2.42}$$

从而得到常用的残差和形式

$$\widehat{A}_t^{\mathrm{GAE}} = \sum_{l=0}^{K-1} (\gamma \lambda_{\mathrm{GAE}})^l \delta_{t+l}. \tag{2.43}$$

GAE 的衰减由两个因素决定：γ 表示目标对未来的折扣，λ_{GAE} 表示较长残差链的估计权重。二者分别属于优化目标与估计器参数。

若 $\lambda_{\mathrm{GAE}} = 1$，窗口内残差累加后得到实际折扣奖励加末端自举值，再减当前价值；若窗口在真实终端结束，末端价值为零，便得到回报减基线。若 $\lambda_{\mathrm{GAE}} < 1$，中间价值估计更明显地进入结果，可能降低方差，也可能保留价值近似偏差。因而，GAE 不是无条件消除偏差的技巧，应与 Critic 精度、窗口长度和任务随机性一起理解。

2.5.3 终止掩码与递推实现

为兼容不同边界，定义自举掩码 b_t 与递推连接掩码 c_t。$b_t = 0$ 表示该转移真正终止，否则为一；$c_t = 1$ 表示缓冲区下一条记录属于同一连续轨迹、可以继续累计其优势，否则为零。相应 TD 残差与反向递推为

$$\delta_t = r_t + \gamma b_t V_\phi(s_{t+1}) - V_\phi(s_t), \tag{2.44}$$

$$\widehat{A}_t = \delta_t + \gamma \lambda_{\mathrm{GAE}} c_t \widehat{A}_{t+1}. \tag{2.45}$$

在真实终端，$b_t = c_t = 0$；在仅因采样长度而截断的末端，可以取 $b_t = 1, c_t = 0$，用截断前的实际后继状态估计价值，但不跨到下一批未知记录递推；在正常连续转移中二者均为一。价值自举与优势连接的分工避免了跨回合泄漏。

递推展开为

$$\widehat{A}_t = \sum_{l=0}^{K-1} (\gamma \lambda_{\mathrm{GAE}})^l \left(\prod_{i=0}^{l-1} c_{t+i} \right) \delta_{t+l}, \tag{2.46}$$

空乘积取一。只要某个连接掩码为零，后续残差对当前优势的贡献就停止。实现时通常从缓冲区末端向前扫描，维护一个累计量；真正终止状态的后继值为零，截断状态则应使用结束前真实 observation，而不是 reset 之后的新回合初始 observation。

GAE 计算后，用 $\widehat{V}_t = V_{\phi_{\text{old}}}(s_t) + \widehat{A}_t$ 形成 Critic 目标，并在同一批次的多个 PPO epoch 中保持固定。优势标准化用于调整策略优化的数值尺度，价值目标仍保留原回报尺度。

2.6　近端策略优化与动作概率一致性

2.6.1　重要性比率与旧策略采样

策略梯度的期望由当前策略产生，但一次交互采样后，策略更新会使缓冲区来自旧策略 $\pi_{\theta_{\text{old}}}$。对于固定状态 s，若新策略支持集包含于旧策略有效支持集，则

$$\mathbb{E}_{a\sim\pi_\theta}[f(s,a)] = \mathbb{E}_{a\sim\pi_{\theta_{\text{old}}}}\left[\rho_\theta(s,a)f(s,a)\right], \qquad \rho_\theta(s,a) = \frac{\pi_\theta(a \mid s)}{\pi_{\theta_{\text{old}}}(a \mid s)}. \tag{2.47}$$

该恒等式只校正固定状态下动作分布的变化，并未自动校正新策略产生的状态分布。因此，直接在旧 rollout 上使用一次动作比率，是局部代理目标的构造，不是完整新策略回报的无偏估计。若对整条轨迹做完全重要性校正，需要多个时隙比率乘积，通常会产生较大方差。

PPO 使用旧策略状态动作样本与固定优势，构造可重复优化的目标[28]。为了数值稳定，概率比率通常由 log probability 之差计算：

$$\rho_t(\theta) = \exp\left[\log \pi_\theta(a_t \mid s_t) - \log \pi_{\theta_{\text{old}}}(a_t \mid s_t)\right]. \tag{2.48}$$

旧动作概率由采样时的参数、观测、动作和掩码确定，并在更新中保持固定。首次更新前新旧网络相同，合法样本的概率比应接近一，可用于检查概率记录的一致性。

2.6.2　裁剪目标及其分段含义

设裁剪系数为 $\varepsilon > 0$，PPO 的裁剪代理目标为

$$L_{\text{clip}}(\theta) = \mathbb{E}_{\text{old}}\left[\min\left(\rho_t(\theta)\widehat{A}_t, \text{clip}(\rho_t(\theta), 1-\varepsilon, 1+\varepsilon)\widehat{A}_t\right)\right]. \tag{2.49}$$

优势在 Actor 更新时视为固定。取最小值的目的，是在动作概率朝有利方向变化过多时移除进一步增加代理收益的激励，而不是把所有比率数值直接投影到指定区间。

对于单个样本，令 $\ell(\rho, \widehat{A})$ 为括号内的量。根据优势符号，有

$$\ell(\rho, \widehat{A}) = \begin{cases} \widehat{A}\min(\rho, 1+\varepsilon), & \widehat{A} \geqslant 0, \\ \widehat{A}\max(\rho, 1-\varepsilon), & \widehat{A} < 0. \end{cases} \tag{2.50}$$

当 $\widehat{A} > 0$ 时，增加动作概率能提高代理收益，但比率超过 $1+\varepsilon$ 后这一项进入平台；当 $\widehat{A} < 0$ 时，降低动作概率有利，但比率低于 $1-\varepsilon$ 后平台阻止该项继续受益。若变化方向使样本表现更差，目标仍保留惩罚。这是裁剪和最小操作必须共同出现的原因。

PPO 裁剪限制单个样本继续增加代理收益的方向，属于软优化机制。共享参数、其他样本及熵项仍可改变已进入平台区的动作概率，因此实际训练需结合近似 KL、裁剪比例和梯度范数观察更新幅度。

策略熵可以作为探索项。离散分布的熵为

$$\mathcal{H}(\pi) = -\sum_{a \in \mathcal{A}(s)} \pi(a \mid s) \log \pi(a \mid s). \tag{2.51}$$

Actor 通常最大化 $L_{\text{clip}} + c_H \mathbb{E}[\mathcal{H}]$，其中 $c_H \geqslant 0$，Critic 最小化均方或裁剪值损失。熵项保持训练动作的分散度，评价阶段则采用预定的动作选择规则。

2.6.3 连续提案、执行映射与离散掩码

对于二维轨迹，Actor 可输出均值 $\boldsymbol{\mu}_\theta(o)$ 与标准差 $\boldsymbol{\sigma}_\theta(o)$，从对角 Gaussian 分布采样原始动作 a。其 log probability 为

$$\log \pi_\theta(a \mid o) = -\frac{1}{2} \sum_{d=1}^{2} \left[\frac{(a_d - \mu_d)^2}{\sigma_d^2} + 2 \log \sigma_d + \log(2\pi) \right]. \tag{2.52}$$

如果环境把原始动作裁剪、缩放或进行边界与碰撞消解，实际执行动作是 $a^{\text{exec}} = \mathcal{E}(s, a)$。该映射可以多对一，并不保持 Gaussian 密度。策略梯度仍可针对原始提案策略定义，把执行映射视为环境的一部分；前提是 PPO 保存并比较同一个原始 a 的采样概率。

将裁剪后的 a^{exec} 重新代入原始 Gaussian 密度，并把它当作原始动作概率，会改变采样对象。特别是多个超出边界的提案被映射到同一边界值时，执行动作分布不再是原 Gaussian。本文后续算法描述以原始提案和原始 log probability 为准，执行可行性由环境映射处理。这种记录方法确保概率比率的含义一致，但不说明策略网络本身满足所有几何约束。

对于离散卸载或配额迁移，设网络 logits 为 z_a，状态对应的合法动作掩码为 $M_a \in \{0, 1\}$，则掩码后的分布为

$$\pi_\theta(a \mid s, \boldsymbol{M}) = \frac{M_a \exp(z_a)}{\sum_b M_b \exp(z_b)}. \tag{2.53}$$

实现需要保证至少存在一个合法动作，例如协议允许的保底动作或停止动作，否则分母为零。非法动作概率为零，合法动作之间重新归一化。训练使用采样时的 $\boldsymbol{M}$，不能在一个已改变负载的搜索状态上重建掩码后拿来比较原动作概率。

动作掩码屏蔽物理或协议不可行选择，而能耗筛选、最好方案保留或普通修复是另外的操作。它们可以改变最终执行分配，却不应事后改写策略曾采样的配额动作或其概率。第五章因此区分当前搜索状态、策略提案、候选分配和最好保留分配；这一分工既有利于处理有限预算搜索，也使 PPO rollout 对应明确的训练过程。

2.7　多智能体协作与 MAPPO

2.7.1　联合状态与局部观测

协作多智能体问题可以用分散式部分可观测马尔可夫决策过程描述。设智能体集合为 $\mathcal{U} = \{1, \cdots, N\}$，联合状态为 s_t，局部观测由 $o_{u,t} = \mathcal{O}_u(s_t)$ 或对应观测分布生成，联合动作为 $\boldsymbol{a}_t = (a_{1,t}, \cdots, a_{N,t})$。环境根据整个联合动作转移，并返回团队奖励或各智能体奖励。全局转移满足马尔可夫性时，从局部观测出发的单个智能体仍可能面对部分可观测问题；如果其他策略同步更新，其经验的生成过程还会出现训练非平稳性[29]。

条件独立的分散式 Actor 可以把联合策略因子化为

$$\boldsymbol{\pi}_\theta(\boldsymbol{a}_t \mid \boldsymbol{h}_t) = \prod_{u=1}^{N} \pi_{\theta_u}(a_{u,t} \mid h_{u,t}), \tag{2.54}$$

其中 $h_{u,t}$ 是各智能体允许使用的历史，当前观测策略是其特例。条件独立指给定各自输入后的动作采样方式，并不意味着动作对环境的影响独立。多架 UAV 的动作可以通过覆盖边界、最小间距和共享计算资源发生强耦合。

联合动作空间随智能体数量变化。若每个智能体有 K 个离散动作，联合动作数是 K^N；连续动作则形成更高维联合空间。参数共享不改变这种环境组合结构，但可以减少模型中重复的可训练参数。同类型 UAV 共享 θ 时，不同局部状态仍产生不同分布；其经验共同贡献梯度。若异质节点承担不同功能，是否共享、是否引入身份或能力特征需要根据具体实现决定，而不是将参数共享作为所有 MARL 方法的必选条件。

训练非平稳性的原因可以写得更具体。对固定智能体 u，其看到的有效转移包含其他智能体策略的平均：

$$P_u^{\pi_{-u}}(s' \mid s, a_u) = \sum_{\boldsymbol{a}_{-u}} \pi_{-u}(\boldsymbol{a}_{-u} \mid \boldsymbol{h}_{-u}) P(s' \mid s, a_u, \boldsymbol{a}_{-u}). \tag{2.55}$$

当 π_{-u} 变化时，该有效过程变化。全局状态转移模型未必因此失去马尔可夫性，但单个策略从旧样本中估计当前环境的难度增加。集中训练能够使用更多信息缓解估计困难，却不能保证完全消除这种变化或信用分配问题。

2.7.2 CTDE 与联合观测价值网络

CTDE 允许训练时 Critic 使用联合观测、全局状态或规定协作信息，执行时 Actor 使用其可获得的局部输入。MADDPG 与 MAPPO 展示了集中价值估计的不同实现[17-18]。本文轨迹策略按局部观测执行，下层汇总请求作中央分配，两者具有不同的在线信息与协调需求。

本文上层的联合观测记为 $O_t = (o_{1,t}, \cdots, o_{N,t})$，共享 Critic 的输出形式为

$$\boldsymbol{V}_\phi(O_t) = (V_{\phi,1}(O_t), \cdots, V_{\phi,N}(O_t)) \in \mathbb{R}^N. \tag{2.56}$$

每个 UAV 获得对应价值估计，网络通过联合输入建模相互关系。共享参数不要求输出只有一个全局标量，也不要求每个输出使用完全相同的局部回报。实际奖励是否共享、价值目标如何生成，需要与 rollout 数据结构一致。第三章说明本文上层输入和训练设置，第五章配额策略则以一个完整请求图作为集中搜索状态，其动作主体与上层多 UAV Actor 不同。

团队奖励下，因子化策略的 log probability 满足

$$\nabla_\theta \log \boldsymbol{\pi}_\theta(\boldsymbol{a} \mid \boldsymbol{h}) = \sum_{u=1}^{N} \nabla_\theta \log \pi_\theta(a_u \mid h_u) \tag{2.57}$$

（共享参数时）。代入策略梯度，可把各 UAV 的得分函数贡献相加。价值基线可以利用动作之前的联合信息，只要在对应条件下不依赖当前被求导动作，就保留基线不偏性的基本逻辑。实际按智能体划分的优势是近似估计，集中 Critic 提供训练信号，不构成对个体因果贡献的精确分解。

2.7.3 MAPPO 的局部比率与更新流程

MAPPO 采用 PPO 类代理目标训练协作策略[18]。对于每个 UAV 的样本，定义局部比率

$$\rho_{u,t}(\theta) = \frac{\pi_\theta(a_{u,t} \mid o_{u,t})}{\pi_{\theta_{\text{old}}}(a_{u,t} \mid o_{u,t})}. \tag{2.58}$$

常用的共享 Actor 代理目标在智能体与时隙上平均：

$$L_{\text{MAPPO}}(\theta) = \frac{1}{NT} \sum_{u,t} \min\left(\rho_{u,t}\widehat{A}_{u,t}, \text{clip}(\rho_{u,t}, 1-\varepsilon, 1+\varepsilon)\widehat{A}_{u,t}\right). \tag{2.59}$$

其中 T 在此表示采样批次包含的时隙数，实际实现还会对批次和有效样本作平均。各智能体价值目标来自对应回报和联合 Critic，Actor 则分别以局部观测重算提案概率。

联合策略概率比为 $\rho_{\text{joint},t} = \prod_u \rho_{u,t}$，逐智能体裁剪与联合比率裁剪具有不同目标。共享参数更新同时影响所有 UAV，局部比率的变化还会通过乘积累积。因此，训练通过 epoch、学习率和小批量设置控制更新，并观察实际优化行为。

完整训练循环先固定策略采集 rollout，保存各机观测、原始动作、对数概率、价值估计、奖励和终止标记；由该批样本计算 GAE 与 Critic 目标，再在旧概率固定的条件下执行多个优化 epoch。更新后重新采样。本文上层先完成训练，再在下层配额学习与评价中保持参数固定。

2.8　注意力聚合与图表示

2.8.1　查询、键和值的计算

注意力把元素间的相关性转化为聚合权重[22]。设查询、键和值矩阵分别为 $Q \in \mathbb{R}^{n_q \times d_k}$、$K \in \mathbb{R}^{n_k \times d_k}$ 和 $V \in \mathbb{R}^{n_k \times d_v}$，缩放点积注意力为

$$\mathrm{Att}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^{\mathsf{T}}}{\sqrt{d_k}} + M\right)V. \tag{2.60}$$

M 为加性掩码，合法项为零，非法项在数学表达中为负无穷；softmax 沿键的维度计算。每一行权重非负且和为一，因此输出是值向量的加权组合。查询与键决定权重，值承担被聚合的信息，三者的功能不同。

缩放因子的作用可以从点积方差说明。假设各 q_i, k_i 零均值、方差为一，同一维度内 q_i 与 k_i 相互独立，且不同维度的变量对 (q_i, k_i) 相互独立，则

$$\mathrm{Var}(q^{\mathsf{T}}k) = \mathrm{Var}\left(\sum_{i=1}^{d_k} q_i k_i\right) = d_k. \tag{2.61}$$

因此除以 $\sqrt{d_k}$ 后，点积标准差的量级不再随维度平方根增大。对于 softmax 权重 α_i，其导数 $\partial\alpha_i/\partial z_j = \alpha_i(\mathbb{I}\{i=j\} - \alpha_j)$；若 logits 差距过大，权重可能过早接近零或一，导数变小。缩放改善这种数值量级，但真实特征并不必然独立同分布，故它是合理的结构设计，不是避免所有饱和的保证。

多头注意力使用不同投影建立多个表示子空间：

$$H_h = \mathrm{Att}(QW_h^Q, KW_h^K, VW_h^V), \tag{2.62}$$

$$\mathrm{MHA}(Q, K, V) = \mathrm{Concat}(H_1, \cdots, H_H)W^O. \tag{2.63}$$

H 在本小节表示注意力头数，几何高度记为 H_u。总隐空间为 d、各头等宽时，单头键维度为 $d_k = d/H$，缩放分母为 $\sqrt{d/H}$。本文上层 $d = 64$、头数为 8，单头宽度为 8，对应缩放因子 $\sqrt{8}$。

2.8.2　局部查询、掩码与排列性质

在 UAV 上层观测中，自身状态经过嵌入后可作为查询，邻居 UAV 和 UE 槽位分别提供键和值。邻居表示包含协作几何关系，UE 表示包含位置、请求和能

量等允许信息，两个聚合结果再与自身特征融合。固定槽位中的空元素需要掩码，否则补零槽位也会参与归一化，影响有效元素权重。注意力改变的是聚合方式，并未自动减少原始观测维度，也没有自动增加感知范围。

全空键集合是一个必须处理的边界。若一行所有 logits 都为负无穷，softmax 的归一化不再有有效分母。实现可以为这种情况定义零上下文或专门空状态，并让后续网络识别“没有可见元素”。该约定应与训练和执行一致，避免出现 NaN 后再把结果无条件修成任意数值。实际 UAV 的邻居或 UE 槽位数量变化时，掩码和有效计数同样需要对应，不应把填充容量误认为实际用户数量。

对于固定查询的纯加权聚合，若键和值同时按同一置换矩阵 P 重排，$K' = PK, V' = PV$，则

$$\mathrm{softmax}(QK'^{\mathsf{T}})V' = \mathrm{softmax}(QK^{\mathsf{T}})P^{\mathsf{T}}PV = \mathrm{softmax}(QK^{\mathsf{T}})V. \tag{2.64}$$

这里省略缩放和同步重排的掩码以突出排列关系。该性质要求不额外引入与序号相关的编码；完整系统还包含排序、截断、分组和其他特征，因此不能从这一局部式子推断整个策略对所有观测处理均排列不变。UE 选择规则本身可能决定哪些需求进入有限槽位，是第三章观测研究的重要部分。

自身查询聚合 n 个元素时，权重计算约为 $O(nd_k)$；全元素自注意力的点积关系约为 n^2。线性投影、网络宽度、头数与批次进一步影响计算成本，第五章因此测量完整策略调用时间。权重热图用于描述特定输入下的聚合分布，组件对 DSR 的贡献则通过对照实验评价。

2.8.3 请求–节点二部图与消息传递

请求卸载可以表示成二部图 $\mathcal{G} = (\mathcal{M}, \mathcal{J}, \mathcal{E})$。请求节点携带数据大小、计算周期和截止时间等特征，执行节点携带能力、当前负载和配额等特征；边 (m, j) 描述请求与节点之间的合法性、通信条件、缓存信念和预测处理代价。与把全部信息平铺成一个长向量相比，二部关系保留了“某个请求在哪个节点执行”的具体结构，但其性能仍取决于特征与训练。

一种通用消息传递写法为

$$\boldsymbol{h}_m^{(l+1)} = f_{\mathcal{M}}\left(\boldsymbol{h}_m^{(l)}, \sum_{j:(m,j)\in\mathcal{E}} g_{\mathcal{M}}(\boldsymbol{h}_m^{(l)}, \boldsymbol{h}_j^{(l)}, \boldsymbol{e}_{mj})\right), \tag{2.65}$$

$$\boldsymbol{h}_j^{(l+1)} = f_{\mathcal{J}}\left(\boldsymbol{h}_j^{(l)}, \sum_{m:(m,j)\in\mathcal{E}} g_{\mathcal{J}}(\boldsymbol{h}_m^{(l)}, \boldsymbol{h}_j^{(l)}, \boldsymbol{e}_{mj})\right). \tag{2.66}$$

f 与 g 是可学习映射，聚合可采用均值或注意力。第五章在这一表示基础上给出 CompleteQuotaPPO 对请求、节点、边及当前与最好搜索状态的具体编码。

配额搜索中的当前分配决定下一次迁移的起点，最好分配决定最终执行方案，二者承担不同作用。剩余预算、已访问配额和有效动作集合也影响后续转移。因此，完整搜索状态需要联合表示请求图与搜索进度，具体策略观测及其与完整状态的关系见第五章。

2.9　指派匹配与配额条件化优化

2.9.1　不可拆分请求的指派形式

设 $x_{mj} \in \{0,1\}$ 表示请求 m 是否分配给节点 j，每个已接纳请求必须有一个目的地，且只能使用合法边。对于给定节点配额 N_j，约束为

$$\sum_{j \in \mathcal{C}_m} x_{mj} = 1, \qquad \sum_{m \in \mathcal{M}} x_{mj} = N_j, \qquad \sum_{j} N_j = |\mathcal{M}|. \tag{2.67}$$

$\mathcal{C}_m$ 表示请求的合法目的地集合，与 CPU 周期 C_m 区分。若某配额导致合法边无法形成完整指派，则该条件化问题不可行，需要按搜索协议拒绝候选或使用保底方案；不能用丢弃难请求的方式悄然恢复可行性。

在 N_j 固定后，式 (2.8) 的节点共享频率已经确定，可将预测时延与能耗写成给定条件下的边代价 $c_{mj}(\boldsymbol{N})$。把节点 j 展开成 N_j 个槽位，每个槽位继承相同的合法边及成本，问题转化为请求与槽位的一一指派：

$$\min_{x} \sum_{m,j} c_{mj}(\boldsymbol{N}) x_{mj} \quad \text{满足式 (2.67).} \tag{2.68}$$

该转化解决的是给定配额、给定预测模型下的子问题。原完整分配还需要选择配额，其边成本随配额改变；因此，条件化指派的精确性不能直接升级成原组合问题的全局最优性。

2.9.2　截止期优先的代价编码

若首要目标是减少预测超时，其次降低预测能耗，可以构造有界的字典序编码。设请求数为 n，每条合法边的缩放能耗 $\widetilde{E}_{mj} \in [0,1]$，定义

$$c_{mj} = (n+1)\mathbb{I}\{\widehat{T}_{mj} > D_m\} + \widetilde{E}_{mj}. \tag{2.69}$$

任意完整指派的缩放总能耗介于零与 n 之间。若一种指派比另一种少一个预测超时，其超时代价至少减少 $n+1$；即使能耗项增加到允许最大差 n，总编码代价仍下降至少一。因此，最小化该代价先最小化预测超时数，再在相同超时数中比较缩放能耗。

上述优先性依赖缩放区间确实有界，而且同一条件化问题内保持一致。若改用无界能耗或为不同候选任意更换尺度，就不能继续使用同一证明。真实截止期

成功还可能受缓存信念与实际执行差异影响，因此 $\widehat{T}$ 的优先优化不等于真实成功数必然改善。本文在快照与闭环评价中核对预测和实际结果，并报告偏差，而不把预测目标当作实验成功的替代指标。

共同贪心参照下的能耗上限属于候选筛选条件。先对某配额求出无能耗约束的最佳指派，再检查其是否低于上限，并不等价于直接求解带能耗约束的全局最优指派；如果该指派被拒绝，仍可能存在该配额下另一种较高超时代价但满足能耗上限的方案。第五章因此把匹配求解与能耗筛选分别说明，不赋予二者组合未经证明的最优保证。

2.9.3 配额搜索、最好保留与有限预算

配额迁移保持总请求数不变。若从节点 i 向节点 j 转移 k 个任务，候选满足

$$N_i' = N_i - k, \qquad N_j' = N_j + k, \qquad N_h' = N_h \ (h \neq i, j), \qquad N_i' \geqslant 0. \tag{2.70}$$

策略只提出负载数量的变化，实际请求身份由条件化匹配决定。这比直接枚举每个请求的全部目的地组合紧凑，但并未消除配额组合空间，也不保证有限预算能找到最优配额。不同的步长、入口、去重和停止条件决定搜索行为，应通过同预算对照评价。

最好方案保留允许访问较差的合法中间状态，同时保留已找到的执行方案。当前状态用于探索，最好状态按预定规则更新，搜索结束后执行保留方案。若初值合法，且更新仅接受合法、满足筛选条件的完整分配，该规则维持最终输出的可行性。

固定请求图内的搜索训练与长期环境训练的回报不同。搜索可以用候选预测目标或快照真实评价构造信号，长期闭环则还包含电池、缓存与未来轨迹变化。学习配额策略的额外收益必须在完整环境中确认；同时，它与随机配额策略共享的匹配、修复和保留框架应固定。这样才能把完整下层优化包有效与学习搜索有效分别检验，而不是让较弱随机动作承担所有机制解释。

2.10 随机实验与证据解释基础

强化学习实验的随机性来自模型初始化、策略采样和外生需求。独立训练块是不同训练过程产生的模型重复；同一模型上的多个工作负载、回合、时隙和请求则属于嵌套评价。增加这些评价可以更准确地估计该模型的行为，但不能把它们都视为独立训练样本。非学习方法没有训练模型，其随机流重复也需要按实际含义命名。本文以这种区分组织后续图表中的 n。

在预定配对设计中，先在训练块内聚合各方法对应的工作负载与回合，得到

块级指标 $Y_{b,1}$ 和 $Y_{b,0}$，再计算差值 $d_b = Y_{b,1} - Y_{b,0}$。均值差与样本标准差为

$$\bar{d} = \frac{1}{n}\sum_{b=1}^{n} d_b, \qquad s_d^2 = \frac{1}{n-1}\sum_{b=1}^{n}(d_b - \bar{d})^2. \tag{2.71}$$

训练块配对 t 区间为 $\bar{d} \pm t_{0.975,n-1} s_d/\sqrt{n}$。其解释依赖独立块与相应统计假设；小样本或临界结果还可以使用预定的符号翻转等敏感性检查。区间跨零表示当前数据未确认所述差异，不等于两个方法在所有条件下相同。

多个预定比较通过 Holm 校正控制家族错误率：将 p 值升序排列，依次与 $\alpha/(m-i+1)$ 比较，并在首次未通过时停止拒绝。主性能、机制和补充随机对照分别回答不同问题，各自的检验族在对应评价前确定。

本文预先规定评价负载和模型选择规则，采用训练结束时的检查点。开发数据用于方法选择，独立确认用于主要性能评价，两阶段保持分离。训练曲线描述优化过程，固定快照评价求解能力，闭环指标评价长期服务效果。

2.11　本章小结

本章建立任务规划、简化机动与集中协调的系统基础。通信、缓存、最终批量算力和自然接纳连接空间部署与执行质量；有限时域值函数、策略梯度和动作无关基线提供学习基础，GAE 通过多步残差与终止掩码构造优势估计，PPO 以固定采样概率和优势形成局部裁剪目标。后续方法在这些假设和优化条件下展开。

多智能体部分区分全局状态、局部观测与集中价值估计，说明共享 Actor 和联合观测多输出 Critic 的作用。注意力提供输入元素的加权聚合，二部图与条件化指派提供请求分配的结构表示，两者都需要通过具体协议与对照判断收益。以上基础为第三章需求观测、第四章批量迁移和第五章有限预算学习配额搜索提供了统一的理论语言，也为解释训练曲线、主比较与机制证据明确了条件。

第 3 章　自然覆盖约束下无人机集群的需求感知协同轨迹决策

3.1　研究动机与评价口径

3.1.1　从集群空间部署到可接纳需求

无人机集群承担地面计算服务时，机群空间部署决定哪些需求能够进入任务执行流程。用户设备只有进入某架无人机的服务范围，其请求才有机会上传、分配和执行。对于尚未被覆盖的请求，即使集群具有足够的总算力，任务分配层也没有可处理的输入。因此，上层轨迹决策需要安排有限的空中平台，使具有服务需求的用户进入可接纳区域，并结合邻机位置处理多机部署关系。本文把这一前置条件称为自然覆盖接纳：覆盖由真实位置和固定服务半径决定，不因请求紧急、无人机负载较低或宏基站算力充足而放宽。

在自然覆盖口径下，上层局部观测是否包含未接纳需求直接影响可学习的控制规律。若观测只列出已关联用户，策略可以比较这些用户的距离、请求大小和电量，却无法辨别附近未覆盖区域究竟存在高需求还是无人区域。低服务率的奖励能说明当前结果不理想，但不能单独提供应向何处移动的信息。这一信息缺口不同于网络容量不足：增加隐藏层或注意力头数并不会把被观测构造过程丢弃的用户重新送入网络。

本章研究固定服务半径下的需求感知协同轨迹决策。首先建立几何、通信、缓存、计算和能量模型，明确平台运动影响服务的时间路径；其次给出部分可观测的上层决策模型与 Attention-MAPPO；最后保持网络维度和接纳规则不变，将感知范围内尚未接纳的需求补入观测，通过探索与独立确认检验效果。本章评价需求可见性对空间部署的作用，第五章进一步结合固定参数的轨迹策略和配额匹配下层研究完整在线服务。

自然覆盖将物理接入作为卸载前提：未覆盖服务请求计入 DSR 分母，但不进入卸载集合。强制关联全部请求会消除未接纳类别，形成不同的优化问题。本章保持自然接纳规则，由轨迹控制改变后续位置和接纳机会。

3.1.2　统一计数与乘积分解

设一个评估单元内实际生成的服务请求总数为 G，自然覆盖接纳数为 A，满足自身截止时间的服务请求数为 S。计数满足 $0 \leqslant S \leqslant A \leqslant G$。对 $G > 0, A > 0$

的单元，定义接纳率 $\alpha = A/G$、接纳后完成率 $\eta = S/A$，则

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A} = \alpha\eta. \tag{3.1}$$

分母为零时，对应比例按实验实现取零。$G - A$ 表示因覆盖不足而无法进入执行流程的请求数，$A - S$ 表示已经接纳但未按时完成的请求数。因此，总失败数可以不重不漏地分解为

$$G - S = (G - A) + (A - S). \tag{3.2}$$

这一分解把几何接纳与接纳后的传输计算质量放在同一计数框架内，避免只在已处理请求上报告较高成功率而忽略未覆盖需求。

统计汇总必须区分“单元内求比例”和“跨单元平均”。本文的确认实验先在每个“训练种子–工作负载”评估单元内累加六个回合的请求计数，再分别求 $S/G, A/G, S/A$，随后平均各单元比例。若以 i 标记单元，则平均端到端指标为 $\overline{\mathrm{DSR}} = I^{-1}\sum_i \alpha_i\eta_i$。一般有

$$\overline{\mathrm{DSR}} = \bar{\alpha}\bar{\eta} + \frac{1}{I}\sum_{i=1}^{I}(\alpha_i - \bar{\alpha})(\eta_i - \bar{\eta}), \tag{3.3}$$

而非直接等于两个平均因子的乘积。把所有单元的计数再次合并后求 $\sum_i S_i / \sum_i G_i$，则对应按生成请求数加权的指标，亦不能替代预定的等权单元均值。

比较候选方法和基线时，可在每一配对单元内进行精确的对称分解。以下标 c, b 标记两方法，记 $\Delta\alpha_i = \alpha_{c,i} - \alpha_{b,i}$、$\Delta\eta_i = \eta_{c,i} - \eta_{b,i}$，则

$$\Delta\mathrm{DSR}_i = \Delta\alpha_i \frac{\eta_{c,i} + \eta_{b,i}}{2} + \Delta\eta_i \frac{\alpha_{c,i} + \alpha_{b,i}}{2}. \tag{3.4}$$

证明只需展开右端，两个交叉乘积相消，剩下 $\alpha_{c,i}\eta_{c,i} - \alpha_{b,i}\eta_{b,i}$。该形式无需任选一个方法作为展开基点，两个项相加精确恢复单元差值；先配对分解再平均也精确恢复平均 DSR 差值。其用途是描述指标变化的来源，不能仅凭代数分解把接纳增加解释为已被唯一识别的因果机制。

3.1.3　电池定型与实际分母

实际生成服务请求数 G 存在轻微策略依赖性。仿真为每个用户先抽取潜在请求标识、输入大小、截止时间和优先级，再依据当前电池电量确定请求类别。电量低于阈值时，潜在服务或内容请求转为能量请求。因此，方法之间即使共享相同的外生请求随机流，也可能因电池演化不同而产生不同的实际服务请求数。配对随机数控制了抽样过程，但并不使电池状态或实际分母完全相同。

本文以预定的 S/G 为主指标，同时记录潜在服务请求数。共同潜在分母复核保留原运行的成功计数，仅替换统计分母，用于检验电量相关请求类别变化对指标的影响。第五章报告对应的敏感性结果。

3.2 系统几何、动作应用与单时隙时序

3.2.1 集群协同对象与规划层次

本文的协同对象是共同服务地面请求的五架无人机。各机的水平位置、关联用户、邻机状态和机载资源通过请求接纳与任务执行相互联系：一架无人机移动会改变后续服务对象和机间链路；一个请求跨机执行会改变目标节点的计算负载、缓存和能耗，进而影响后续观测。因此，集群轨迹规划需要以整体服务结果评价各机的动作，单机通信距离或当前关联用户数量不足以概括这一目标。

上层通过逐时隙二维运动指令组织机群部署。各 Actor 根据定长局部观测推断动作，训练时由联合观测 Critic 提供回报估计，共享参数与邻机注意力表达协调关系。环境对执行位移作确定性修复，维持离散位置的速度、区域和间距约束。固定高度与位置修复构成简化运动模型，姿态、加速度和内环控制属于后续飞行执行研究。

本章所谓轨迹规划，是在该简化模型中连续生成服务位置和运动指令，不要求五机保持预设编队形状。机间距、服务半径与感知半径承担不同职责：机间距限制平台相对位置，服务半径确定任务接纳资格，感知半径确定策略可用的信息。把三者区分开，才能判断观测改进是否改变了任务信息，而非放宽了运动或服务条件。

3.2.2 网络与自然覆盖模型

主场景含 $N = 5$ 架 UAV、$M = 100$ 个 UE 和一个 MBS。地面区域为 $[0, 700] \times [0, 700]\,\mathrm{m}^2$，UAV 保持 $H = 100\,\mathrm{m}$ 高度，MBS 固定于 $(350, 350, 30)\,\mathrm{m}$。记 UAV 水平位置为 $\mathbf{q}_u(t)$、UE 水平位置为 $\mathbf{w}_m(t)$，三维位置分别为 $\mathbf{p}_u(t) = (\mathbf{q}_u(t), H)$、$\mathbf{p}_m(t) = (\mathbf{w}_m(t), 0)$。覆盖判断使用水平距离，通信增益使用三维距离，这两个距离不能混用。

用户 m 在时隙 t 的可覆盖无人机集合和接纳来源定义为

$$\mathcal{U}_m(t) = \{u : \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\| \leqslant R_c\}, \qquad u_m(t) = \arg\min_{u \in \mathcal{U}_m(t)} \|\mathbf{w}_m(t) - \mathbf{q}_u(t)\|, \quad (3.5)$$

其中 $R_c = 100\,\mathrm{m}$；$\mathcal{U}_m(t) = \varnothing$ 时不关联。该规则同时应用于服务、内容与能量请求，而非只对服务请求有效。服务接纳计数 A 只统计其中的服务请求，接入带

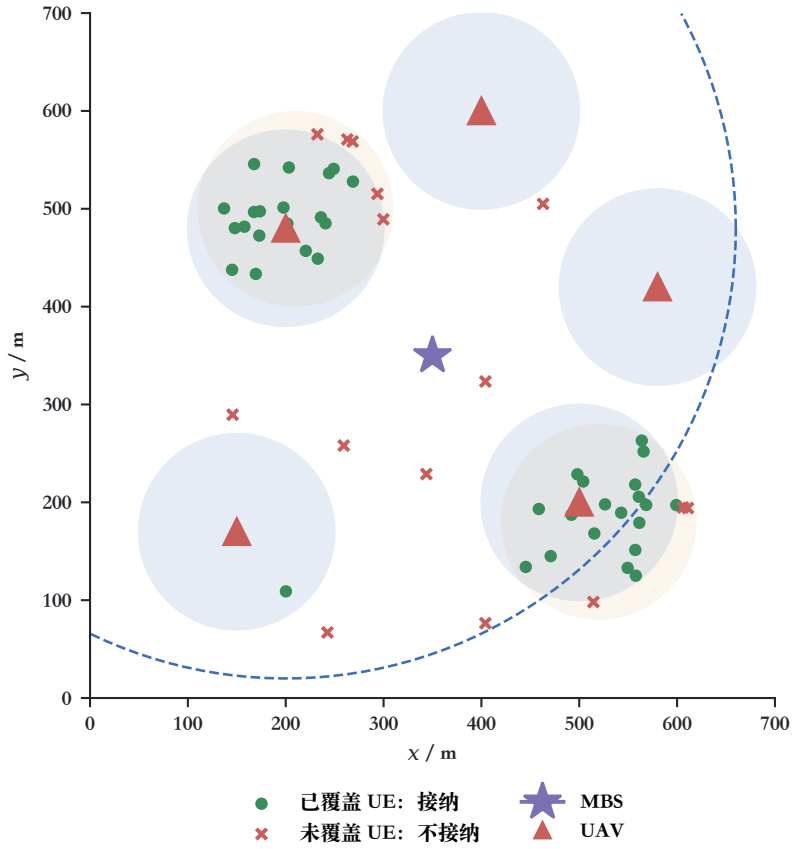


图 3.1　系统总体布局与自然覆盖接纳示意。三角形为 UAV，实线圆为 100 m 服务覆盖范围，虚线圆为其中一架 UAV 的 460 m 感知范围；绿色圆点为被覆盖 UE，红色叉为未被覆盖 UE，其请求本时隙不被接纳。图中位置为示意性布局，非真实轨迹快照

Figure 3.1　Schematic of the system layout and natural-coverage admission (illustrative positions, not a recorded trajectory snapshot)

宽的分配则统计关联的全部请求类型。若覆盖集合重叠，选择最近的覆盖 UAV，不以目标执行节点替代接纳来源。

邻居发现与扩展观测采用 $R_s = 460\,\mathrm{m}$ 的感知范围。UAV 之间按照三维距离判断邻居，由于各机高度一致，该距离等于水平机间距。UE 的预接纳可见范围与 100 m 的接纳范围分别定义。图 3.2 展示两种半径的关系：扩大可见信息不会立即赋予远处 UE 上传或计算资格，上层仍须用受速限约束的移动使其进入覆盖。

UAV 间最小水平间距为 $d_{\min} = 200\,\mathrm{m}$，与服务直径相同，因此满足约束的覆盖圆内部不相交、边界至多相切。该固定几何关系限制多机聚集于同一热点，策略需要协调热点需求、稀疏用户与相对位置。有限覆盖圆仍可能留下未接纳需求，规划效果体现为服务区域与需求的匹配程度。

用户移动采用随机航点模型。每时隙向当前航点推进，位移上限为 15 m；到

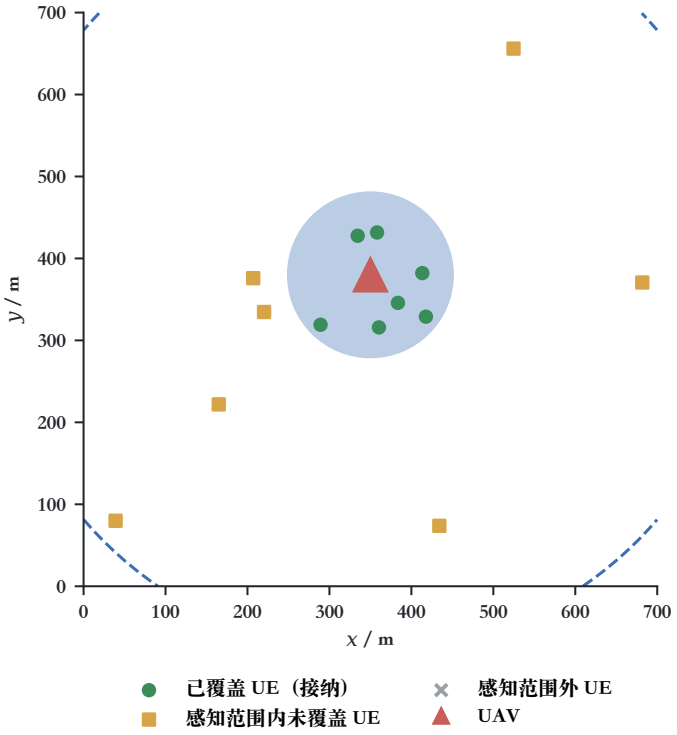


图 3.2　覆盖半径与感知半径的几何关系

Figure 3.2　Geometry of the coverage radius and the sensing radius

达航点后可等待并生成下一航点。主场景中 85% 的用户围绕两个半径为 100 m、中心间距不小于 400 m 的热点分布，其余用户分布于区域内。热点结构使“平均向中心聚集”不必然有效：不同 UAV 需避免重复追踪同一需求，同时照顾感知范围内尚未接纳的用户。

3.2.3　原始概率动作与可执行位移

策略网络生成的随机变量和环境实际执行的动作不是同一个量。记原始动作 $\mathbf{z}_u \in \mathbb{R}^2$，训练阶段按二维正态分布采样；输入环境前逐坐标裁剪为 $\mathbf{a}_u = \mathrm{clip}(\mathbf{z}_u, -1, 1)$。环境进一步按向量模长映射位移：

$$\widetilde{\Delta\mathbf{q}}_u = v_{\max}\tau \min(\|\mathbf{a}_u\|, 1)\frac{\mathbf{a}_u}{\|\mathbf{a}_u\| + \epsilon_0}, \qquad v_{\max} = 15\,\mathrm{m/s},\ \tau = 1\,\mathrm{s}. \tag{3.6}$$

$\epsilon_0 > 0$ 是数值保护常量。当模长小于一时，位移近似与动作线性对应；当模长大于一时，只保留方向并饱和到最大移动距离。逐坐标裁剪并不能独立保证速度约束，因为 $(1, 1)$ 的模长为 $\sqrt{2}$，故径向映射是必要步骤。

实际飞行位置同时满足边界、速度和机间距条件。环境采用的边界留白为服务半径的一半，故可行位置区域是 $\mathcal{Q} = [50\,\mathrm{m}, 650\,\mathrm{m}]^2$，而非整个地面服务区域。

给定当前可行位置，下一位置应属于

$$\mathcal{F}(\mathbf{q}(t)) = \left\{ \{\mathbf{q}'_u\}_{u=1}^{N} : \ \mathbf{q}'_u \in \mathcal{Q},\ \|\mathbf{q}'_u - \mathbf{q}_u(t)\| \leqslant v_{\max}\tau,\ \|\mathbf{q}'_u - \mathbf{q}'_v\| \geqslant d_{\min}\ (u \neq v) \right\}. \tag{3.7}$$

机间距约束对应圆外区域，联合可行域一般非凸。动作修复采用有限次交替调整，得到满足离散位置约束的部署，而非求解最近点投影问题。

执行过程先将建议位置裁剪至边界，再投回以当前位置为中心、半径 $v_{\max}\tau$ 的速度圆。对距离不足的 UAV 对，沿连线方向各外推一半重叠量，随后再次检查边界和速度。该交替修复最多执行配置迭代数加二十轮，在主配置中合计四十轮。若仍有冲突，最终处理将涉及冲突的 UAV 回退至原位置悬停，并传播检查回退新引起的冲突，直到联合位置满足约束。初始位置由可行初始化保证，最终校验允许 10^{-3} m 数值容差。

边界与碰撞违例依据动作提案和修复过程记录，最终位置可行后仍保留惩罚，引导策略减少对修复的依赖。例如边界附近的向外提案会被截回边界，同时产生违例惩罚。几何检查作用于相邻时隙的离散位置，连续航迹避碰与动力学可行性另需执行层模型。

3.2.4　请求执行先于轨迹移动

图 3.3 给出单时隙内的实现顺序。环境重置或上一时隙末生成当前请求，并按当前位置关联 UE、更新邻居和组装观测。两层策略从这一当前信息计算动作；进入环境步进后，先冻结移动前几何和缓存，解析整批服务请求的执行目标，预先计算最终节点负载，再执行服务请求和其他类型请求。此时所有上传、转发与回传速率均使用 $\mathbf{q}_u(t)$。

完成当前批次的时延、能耗与截止期评价后，环境应用已计算的上层轨迹动作，得到 $\mathbf{q}_u(t+1)$，并根据实际移动距离结算本步飞行、悬停和 WPT 能耗。随后计算奖励与指标，提交缓存变化、移动 UE、生成下一步请求和观测。因此，上层动作对当前奖励存在即时能耗与违例路径，对覆盖和链路质量的主要作用则出现在下一步。这一时间关系可以概括为

$$\mathbf{b}(t) \longrightarrow \{T_m(t), E_m^{\text{assign}}(t)\}, \qquad \mathbf{a}(t) \longrightarrow \mathbf{q}(t+1) \longrightarrow \mathcal{U}_m(t+1), \tag{3.8}$$

其中 $\mathbf{b}(t)$ 为请求级卸载分配。当前时隙的接纳由 $\mathcal{U}_m(t)$ 决定，不因本时隙随后移动而追溯改变。即使策略看见距 UAV 120 m 的未接纳用户，并移动到更近位置，该用户本时隙请求也不会被补处理。

本文采用逐决策步的批次服务评价模型，$\tau = 1$ s 是位置更新和决策步长。每个当前请求的完整路径时延用于截止期评分，可以超过该步长；未完成任务不以

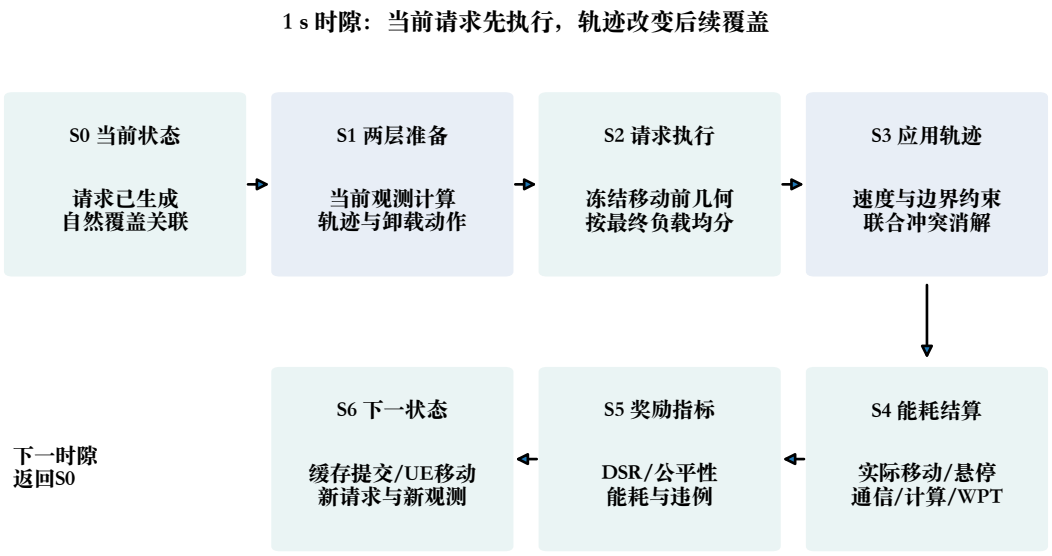


图 3.3　单时隙内的请求执行与轨迹应用时序。两层动作由当前观测计算；请求按移动前几何执行，上层轨迹动作随后应用并影响下一时隙覆盖

Figure 3.3　Decision and execution timeline within one slot, following the simulator implementation order

剩余工作量形式进入后续批次。全文的“负载”指当前批次最终分配的任务数。服务文件回源后登记的缓存变化在批次评价结束时统一提交，未模拟下载完成事件及其跨步占用。因此，闭环结果描述位置、缓存和能量状态在这一抽象转移规则下的演化，不对应持续排队系统的事件级执行过程。

3.3　请求、通信、缓存与能量模型

3.3.1　业务抽样与量纲约定

文件库含二十五类服务和五十个内容，共七十五个标识。总体流行度按 Zipf 分布生成，若标识 s 的流行度排名为 r_s，则

$$\Pr(s) = \frac{r_s^{-\beta}}{\sum_{k=1}^{75} r_k^{-\beta}}, \qquad \beta = 0.8. \tag{3.9}$$

排名与标识通过固定随机配置对应，不能假定服务编号越小就必然越热门。每个 UE 每步先抽取标识、整数输入字节数 $L_m \in [10^6, 5\times10^6)$、截止时间 $D_m \in [0.65, 2.10]$ s 和优先级 $p_m \in \{1,2,3\}$。这些抽样在低电量覆盖之前完成，因而配对方法消耗相同的潜在随机抽样次数。

当电量不低于 50 J 时，服务标识形成计算请求，内容标识形成内容请求；低电量时形成能量请求。内容请求不使用抽取的服务输入大小，而使用文件库中固定的内容文件大小。服务请求的 L_m 是用户输入，B_s 是执行服务所需的文件或镜像，两者分别抽样并具有不同通信路径。若把 B_s 当成 L_m，将混淆上传数据与

缓存回源数据，也会错误估计缓存收益。

服务 s 的每字节 CPU 周期数 $\omega_s \in [1200, 2800)$ 固定，所需总周期为

$$C_m = \omega_s L_m. \tag{3.10}$$

C_m 的单位是周期；L_m, B_s 的单位是字节；无线速率 R 的单位是比特每秒。因此，通信必须使用 $8L_m/R$ 或 $8B_s/R$，而计算使用 C_m/f，不再乘八。本文以十进制 10^6 字节解释表中的 MB，不以二进制 MiB 替代实现值。

UAV 的节点等效计算能力 F_u 从 $\{40, 45, \cdots, 85\}$ GHz 取值，此处 GHz 表示 10^9 周期每秒的等效处理能力；存储容量从 $\{120, 121, \cdots, 179\}$ MB 取值。这些能力、服务周期和文件大小是固定仿真配置，不对应某一指定芯片的核数、时钟或实测功率，也不在每回合重抽。工作负载随机流用于请求，独立移动随机流用于位置与航点；训练随机性、请求随机性与节点异质性属于不同层次，不应把三者都视为独立训练重复。

3.3.2　信道增益与带宽分配

无线链路使用自由空间平方距离衰减。对三维端点 $\mathbf{p}_i, \mathbf{p}_j$，有

$$g_{ij}(t) = \frac{G_0 g_0}{\|\mathbf{p}_i(t) - \mathbf{p}_j(t)\|^2 + \epsilon_0}, \qquad G_0 g_0 = 3.244132 \times 10^{-4}. \tag{3.11}$$

发射功率为 $P^{\mathrm{comm}} = 0.5\,\mathrm{W}$，噪声功率为 $\sigma^2 = 10^{-13}\,\mathrm{W}$，信噪比为 $P^{\mathrm{comm}} g_{ij}/\sigma^2$。对已关联用户，接入带宽在同一来源 UAV 的全部关联 UE 间等分：

$$R^{\mathrm{edge}}_{m,u}(t) = \frac{B^{\mathrm{edge}}}{n^{\mathrm{assoc}}_u(t)} \log_2\left(1 + \frac{P^{\mathrm{comm}} g_{m,u}(t)}{\sigma^2}\right), \qquad B^{\mathrm{edge}} = 40\,\mathrm{MHz}. \tag{3.12}$$

n^{assoc}_u 包含服务、内容及能量请求的关联用户。该数与最终计算负载 N_u 不同：服务可以迁往其他 UAV 或 MBS，内容与能量请求也不会加入 CPU 共享分母。关联为空时不存在需要计算接入速率的请求，不能在式中使用零分母。

机间与回传速率分别为

$$\begin{aligned} R^{\mathrm{inter}}_{u,v} &= 20 \times 10^6 \log_2\left(1 + P^{\mathrm{comm}} g_{u,v}/\sigma^2\right), \\ R^{\mathrm{bh}}_{u,\mathrm{M}} &= 0.75 \times 10^6 \log_2\left(1 + P^{\mathrm{comm}} g_{u,\mathrm{M}}/\sigma^2\right). \end{aligned} \tag{3.13}$$

机间和回传链路使用各自配置的整条带宽，噪声以固定总功率参与计算。模型采用噪声受限链路，未加入小尺度衰落、随机视距、同频干扰和回传排队；通信资源竞争主要由接入关联数及有限回传速率体现。

以上公式显示覆盖增长与服务质量之间的一个结构性联系。在距离近似不变时，接纳更多用户令 n^{assoc}_u 增加，单用户接入速率按其倒数下降，输入上传时间近似成比例上升。同时，新增服务若在本机执行又会增大计算负载。因此，覆

盖观测扩展可以提高接纳数，但并不自动保证新接纳请求按时完成。轨迹与卸载必须共同承担这一新增压力。

3.3.3 最终负载均分与三类服务路径

设当步已接纳服务集合为 $\mathcal{M}(t)$，请求 m 的来源为 $u = u_m(t)$、执行目标为 b_m。在解析全体目标后，UAV j 的最终负载为

$$N_j(\mathbf{b}) = \sum_{m \in \mathcal{M}(t)} \mathbf{1}[b_m = j], \qquad f_{m,j} = F_j / N_j(\mathbf{b}), \quad b_m = j. \tag{3.14}$$

同一节点的本地任务和其他来源迁入任务共同计数；迁往 MBS 的任务不计入任何 UAV 的分母。对实际在该节点执行的请求必有 $N_j \geqslant 1$。先确定目标、再冻结 N_j 的顺序避免“先执行的请求获得更大算力”这一非物理的遍历次序偏差。

记时隙开始的缓存状态为 $h_{j,s}(t) \in \{0,1\}$，其中 s 为服务标识。为简化书写，定义上传时间 $U_m = 8L_m / R^{\text{edge}}_{m,u}$、服务文件回源时间 $V_{j,s} = 8B_s / R^{\text{bh}}_{j,\text{M}}$ 和协作输入转发时间 $I_{m,u,v} = 8L_m / R^{\text{inter}}_{u,v}$。三条实际执行路径的时延为

$$\begin{aligned} T_m^{\text{local}} &= U_m + (1 - h_{u,s}) V_{u,s} + C_m N_u / F_u, \\ T_m^{\text{coop}}(v) &= U_m + I_{m,u,v} + (1 - h_{v,s}) V_{v,s} + C_m N_v / F_v, \\ T_m^{\text{MBS}} &= U_m + 8L_m / R^{\text{bh}}_{u,\text{M}} + C_m / F_{\text{M}}. \end{aligned} \tag{3.15}$$

MBS 总算力为 $F_{\text{M}} = 200\,\text{GHz}$，实现中每个 MBS 任务均使用该值，不按 MBS 当步任务数均分。三条路径都先经来源 UAV 接入；“本地”指接纳 UAV 执行，不指 UE 自身执行。当前模型没有服务结果下行时间，也没有把输入上传与 CPU 计算流水重叠。

在本文基于等效频率的简化计算能耗模型中，以任务的等效计算服务速率 $f_{m,j} = F_j / N_j$ 代入等效动态功率 $P^{\text{cmp}} = \kappa f^3$，再与计算时间 C_m / f 相乘：

$$E_m^{\text{cmp}} = P^{\text{cmp}} \frac{C_m}{f_{m,j}} = \kappa C_m f_{m,j}^2, \qquad \kappa = 10^{-27}. \tag{3.16}$$

系数 $\kappa = 10^{-27}$ 与上述计算能力范围作为数值研究的仿真设定保留，当前没有指定机载芯片的标定依据。$f_{m,j}$ 表示任务获得的服务份额，不能直接等同于实际 CPU 工作频率。模型使共享份额下降时计算时间增加、计算能耗降低；该负载–能耗关系来自所选等效频率假设，而非测得的多核硬件规律。第四章的迁移外部性和后续节能比较均在这一统一模型下解释，不据此换算实际续航时间。

把除计算外的路径时间记为 T_m^{comm}，当目标为 UAV j 时，截止期条件可写成

$$T_m \leqslant D_m \quad \Longleftrightarrow \quad N_j \leqslant \frac{F_j (D_m - T_m^{\text{comm}})}{C_m}, \qquad D_m \geqslant T_m^{\text{comm}}. \tag{3.17}$$

右端是给定链路与缓存下该请求允许的节点负载预算，不是可独立分配给所有请求的容量。同节点请求具有不同 C_m, D_m，需要同时检查各自限制；当通信已用尽截止期时，增加 CPU 不能使该路径可行。该式解释了缓存命中和轨迹靠近的价值：它们通过压缩通信时间给计算释放截止期余量。

3.3.4　分配能耗与完整机队能耗

所有服务路径共有来源 UAV 接收输入能耗 $P^{\mathrm{rx}}U_m$，其中 $P^{\mathrm{rx}} = 0.1\,\mathrm{W}$。为研究执行目标选择的增量代价，定义分配因果能耗为对目标敏感的 UAV 通信与计算项：

$$\begin{aligned} E_m^{\mathrm{assign,local}} &= (1-h_{u,s})P^{\mathrm{bh,rx}}V_{u,s} + \kappa C_m (F_u/N_u)^2, \\ E_m^{\mathrm{assign,coop}} &= (P^{\mathrm{tx}} + P^{\mathrm{rx}})I_{m,u,v} + (1-h_{v,s})P^{\mathrm{bh,rx}}V_{v,s} + \kappa C_m (F_v/N_v)^2, \\ E_m^{\mathrm{assign,MBS}} &= P^{\mathrm{bh,tx}} 8L_m / R_{u,\mathrm{M}}^{\mathrm{bh}}. \end{aligned} \tag{3.18}$$

$P^{\mathrm{tx}} = P^{\mathrm{bh,tx}} = 0.5\,\mathrm{W}$，$P^{\mathrm{rx}} = P^{\mathrm{bh,rx}} = 0.1\,\mathrm{W}$。协作传输由发送与接收两架 UAV 分别承担能耗，所以机队口径必须计入两端；MBS 计算能耗由地面电源承担，不计入 UAV 能耗。UE 上传能耗属于 UE 电池变化，也不混入机队能耗。

若 E^{content} 汇总内容请求导致的 UAV 通信能耗，E_u^{motion} 和 E_u^{WPT} 分别为机动与补能能耗，则完整当步机队能耗为

$$E^{\mathrm{fleet}} = \sum_{m\in\mathcal{M}} P^{\mathrm{rx}}U_m + \sum_{m\in\mathcal{M}} E_m^{\mathrm{assign}} + E^{\mathrm{content}} + \sum_{u=1}^{N}(E_u^{\mathrm{motion}} + E_u^{\mathrm{WPT}}). \tag{3.19}$$

第四章只比较固定快照的 $\sum_m E_m^{\mathrm{assign}}$，排除了共同输入接收、内容、飞行、悬停和 WPT。上层奖励与完整在线评价使用 E^{fleet}。两种量都以焦耳计，却回答不同问题：前者衡量改变分配的代价，后者衡量整套 UAV 运行代价。

3.3.5　内容服务与缓存状态更新

内容请求只传输文件，不消耗服务 CPU 周期。对文件 s、来源 UAV u，本地、协作和 MBS 获取的完成时间分别为

$$\begin{aligned} T_m^{\mathrm{content,local}} &= (1-h_{u,s})8B_s/R_{u,\mathrm{M}}^{\mathrm{bh}} + 8B_s/R_{m,u}^{\mathrm{edge}}, \\ T_m^{\mathrm{content,coop}} &= (1-h_{v,s})8B_s/R_{v,\mathrm{M}}^{\mathrm{bh}} + 8B_s/R_{v,u}^{\mathrm{inter}} + 8B_s/R_{m,u}^{\mathrm{edge}}, \\ T_m^{\mathrm{content,MBS}} &= 8B_s/R_{u,\mathrm{M}}^{\mathrm{bh}} + 8B_s/R_{m,u}^{\mathrm{edge}}. \end{aligned} \tag{3.20}$$

对应 UAV 发射和接收能耗仍按功率乘持续时间累计，用户仅支付内容接收能耗。协作内容路径的输入方向是邻机向来源机发送文件，与服务请求由来源机转发输入的方向不同。

缓存命中使用时隙开始冻结的二值状态 $h_{j,s}(t)$。即便同一时隙较早执行的请求已取回文件，之后的请求也不会立即获得新的命中状态；当步多个相同缺失请求仍分别承担回源时延。实际取回的文件先进入待提交集合，在本步末统一尝试写入缓存。协作服务把镜像缓存到执行 UAV；MBS 执行服务不会顺带使来源 UAV 缓存该镜像。协作内容在邻机取回或持有文件，来源机也实际接收文件，因而可在相应节点形成待提交项。

每个 UAV 记录当步文件请求频次 $v_{u,s}(t)$，并以指数移动平均更新热度：

$$H_{u,s}(t+1) = \beta_c v_{u,s}(t) + (1-\beta_c) H_{u,s}(t), \qquad \beta_c = 0.75, \qquad \chi_{u,s}(t+1) = H_{u,s}(t+1)/B_s. \tag{3.21}$$

待提交文件按单位大小热度 $\chi_{u,s}$ 降序放入剩余存储，平局按文件编号确定。每五十步重置缓存并依相同顺序填充，遇到首个无法容纳的文件时停止。该容量受限启发式规定缓存更新过程，周期预取的额外传输时延和能耗未纳入模型。

卸载决策前的邻机缓存只能用估计信念表示。启发式上下文对邻机文件命中的估计为

$$\widehat{h}_{v,s} = \left[1 + \exp\left(\gamma_c \left(r_s - \frac{S_v^{\text{cache}}}{\overline{B}}\right)\right)\right]^{-1}, \qquad \gamma_c = 0.5, \tag{3.22}$$

其中 S_v^{cache} 为容量、$\overline{B}$ 为文件平均大小。估计式可用于动作特征与质量筛选，实际执行式 (3.15) 使用冻结的真实二值缓存。把 $1-\widehat{h}$ 的期望回源代价写成实际实现中的路径，会夸大模型的信息一致性，也会抹去预测与真实执行的差异。

3.3.6 UE 电池、无线补能与 UAV 机动能耗

记 UE 电量为 $B_m^{\text{bat}}(t)$，本步发射与接收持续时间为 $T_m^{\text{UE,tx}}, T_m^{\text{UE,rx}}$，采集能量为 E_m^{harv}，则

$$B_m^{\text{bat}}(t+1) = \text{clip}_{[0,B_{\max}]}\left[B_m^{\text{bat}}(t) - P^{\text{static}}\tau - P^{\text{UE,tx}}T_m^{\text{UE,tx}} - P^{\text{UE,rx}}T_m^{\text{UE,rx}} + E_m^{\text{harv}}\right]. \tag{3.23}$$

$B_{\max} = 500\,\text{J}$，$P^{\text{static}} = 0.01\,\text{W}$，$P^{\text{UE,tx}} = 0.5\,\text{W}$，$P^{\text{UE,rx}} = 0.1\,\text{W}$。服务请求支付上传能耗，内容请求支付下行接收能耗，能量请求获得采集项；未关联 UE 在本步仅扣除静态项。初始电量在 300 至 500 J 间抽样。低电量比例在本步结算之后统计，以反映通信和补能对下一步请求定型的影响。

关联的能量请求采用简化 WPT 模型：

$$E_m^{\text{harv}} = \eta_{\text{W}} P^{\text{W}} G_{\text{W}} g_{u,m} \tau, \qquad \eta_{\text{W}} = 0.8,\ P^{\text{W}} = 50\,\text{W},\ G_{\text{W}} = 5\times 10^5. \tag{3.24}$$

G_{W} 是等效采集增益，不能据此反推出未建模的天线阵列或真实设备效率。只要

UAV u 本步存在至少一个关联能量请求，它便支付一次 $P^{\mathrm{W}}\tau$，即

$$E_u^{\mathrm{WPT}} = P^{\mathrm{W}}\tau\,\mathbf{1}[\text{UAV } u \text{ 存在关联能量请求}]. \tag{3.25}$$

多名能量用户分别获得式 (3.24) 的采集量，但实现不把 UAV 发射能耗乘以能量用户数。该并行补能简化必须与上述公式共同使用。

机动能耗按修复后的实际位移而非原始动作结算。设 $d_u = \|\mathbf{q}_u(t+1) - \mathbf{q}_u(t)\|$，则

$$t_u^{\mathrm{move}} = \frac{d_u}{v_{\max}}, \qquad t_u^{\mathrm{hover}} = \max(\tau - t_u^{\mathrm{move}}, 0), \qquad E_u^{\mathrm{motion}} = 300 t_u^{\mathrm{move}} + 150 t_u^{\mathrm{hover}}. \tag{3.26}$$

由速度约束可知 $t_u^{\mathrm{move}} \leqslant \tau$，悬停时间非负。模型在满速移动与悬停之间线性分配时间，不含旋翼诱导功率、加速度及转弯阻力项。UAV 能耗作为奖励和评价指标记录，当前模型未设置有限机载电池与返航终止约束。

3.3.7　公平性、时延与参数口径

环境的公平性统计覆盖全部请求类型。令 $K_m(t)$ 为至今用户被接纳且请求完成时延不超过时隙时长的次数，$c_m(t) = K_m(t)/t$。服务请求以其任务截止时间判断 DSR，但公平性使用统一的 τ 门槛；能量请求的时延按零处理，关联后也能增加该计数。于是 Jain 指数为

$$J(t) = \begin{cases} \dfrac{(\sum_m c_m(t))^2}{M \sum_m c_m^2(t)}, & \sum_m c_m^2(t) > 0, \\ 0, & \sum_m c_m^2(t) = 0. \end{cases} \tag{3.27}$$

非零时有 $1/M \leqslant J \leqslant 1$。上界由柯西–施瓦茨不等式得到；下界在仅一个用户取得非零计数时达到。该指标反映累计成功服务的均衡，而非仅服务请求的公平性，也不是当前覆盖面积的均衡。

奖励中的时延汇总包含全部 UE：已关联 UE 采用实际请求时延，未关联 UE 记 $T^{\mathrm{pen}} = 20\,\mathrm{s}$ 的非服务惩罚。归一化分母为 MT^{pen}，而非实际服务请求数。这样，未接纳内容或能量请求也会影响上层信号。DSR 和 MBS 依赖则仅以服务请求计数定义。并行记录这些口径可以避免把“时延变小”误解成所有服务任务的条件平均时延都下降。

表 3.1　主场景仿真参数

Table 3.1　Simulation parameters of the main setting

参数	取值	参数	取值
区域尺寸	$700\,\mathrm{m}\times 700\,\mathrm{m}$	时隙时长 τ	1 s
UAV 数量 N / UE 数量 M	5 / 100	episode 步数 T	1000
UAV 高度 H	100 m	UAV 最大速度 $v_{\max}$	15 m/s
最小机间距 $d_{\min}$	200 m	UE 时隙位移上限	15 m
覆盖半径 R_c	100 m	感知半径 R_s	460 m
UAV 计算能力	$40, 45, \cdots, 85$ GHz	UAV 缓存容量	$120, 121, \cdots, 179$ MB
MBS 计算能力	200 GHz	MBS 位置	$(350, 350, 30)$ m
飞行/悬停功率	300 / 150 W	WPT 功率 / 效率	50 W / 0.8
服务/内容数	25 / 50	Zipf 指数 β	0.8
请求输入大小	$1 \sim 5$ MB	截止时间	$0.65 \sim 2.10$ s
每字节周期数	$1200 \sim 2800$	请求优先级	$\{1, 2, 3\}$
电池容量 $B_{\max}$ / 阈值 B_{low}	500 / 50 J	UE 静态功耗	0.01 W
接入带宽 B^{edge}	40 MHz	机间带宽 B^{inter}	20 MHz
回传带宽 B^{backhaul}	0.75 MHz	发射功率 / 噪声	0.5 W / 10^{-13} W
热点数量 / 半径	2 / 100 m	热点内 UE 比例	85%

3.4　上层 Dec-POMDP 与注意力策略实现

3.4.1　分散观测与集中训练的职责

上层建模为 $\langle \mathcal{I}, \mathcal{S}, \{\mathcal{O}_u\}, \{\mathcal{Z}_u\}, P, \{r_u\}, \gamma \rangle$ 的 Dec-POMDP。$\mathcal{I}$ 是 UAV 智能体集合，状态含所有位置、缓存、电量、请求和统计量，局部观测由感知范围与固定槽位决定，$\mathcal{Z}_u = \mathbb{R}^2$ 是原始随机动作空间。状态转移同时受卸载执行、轨迹修复、用户移动和下一请求生成影响。不同 UAV 的移动会改变联合几何及下一步各自接纳集合，而非显式改变未建模的无线干扰。

共享策略以局部观测执行，集中价值网络在训练时看到同一时刻所有 UAV 的局部观测联合。这里的集中信息并不是任意完整物理状态：实现中的价值调用使用联合观测张量，接口传入的另一个状态参数未作为额外特权输入。若某未接纳 UE 不在任何局部槽位中，价值网络也不会自动恢复其详细请求。CTDE 可以利用联合信息减小价值估计的不确定性，但不能弥补观测生成阶段的全部信息缺失。

3.4.2　定长观测与两个不同容量

自身观测含归一化水平位置与七十五维缓存占用，共七十七维；邻机至多四槽，每槽含按 R_s 归一化的二维相对位置；UE 至多三十槽，每槽为二维相对位

置和六个业务、电量特征。单槽可写成

$$\mathbf{x}_{u,m} = \left[\frac{\mathbf{w}_m - \mathbf{q}_u}{700},\ \frac{\mathrm{type}_m}{2},\ \frac{L_m}{5\times 10^6},\ \frac{s_m}{75},\ \frac{D_m}{2.10},\ \frac{p_m}{3},\ \frac{B_m^{\mathrm{bat}}}{500} \right], \tag{3.28}$$

其中类型、大小、编号按实现使用相应请求字段，非服务请求的截止时间和优先级置零。三组拼接维度为 $77 + 4\times 2 + 30\times 8 = 325$。空槽全零，按槽内特征绝对值之和大于 10^{-5} 判定非空，并生成注意力掩码。

表 3.2　上层单智能体观测构成（原观测；扩展观测见第 3.5 节）

Table 3.2　Composition of the upper-layer single-agent observation

观测组	内容	维度	说明
自身状态	二维位置、缓存向量	77	$2 + 75$ 维
邻居 UAV	相对位置	$4\times 2 = 8$	感知范围内至多 4 架
UE 槽位	相对位置、请求特征、电量	$30\times 8 = 240$	固定槽位、零填充加掩码
合计		325	

三十槽是上层可见信息容量，不是下层能接纳或执行的服务任务上限。当前主配置的下层为每 UAV 预留一百个请求槽，每槽十四维，再加五维来源特征，共 $5 + 100\times 14 = 1405$ 维；卸载动作有七个编号，分别为本地、MBS 和五架 UAV 的协作目标，其中自身协作编号被掩蔽。超过上层三十槽的真实已接纳请求仍可进入下层执行，不会因为上层看不到而被丢弃。把两个容量混为一谈会高估观测覆盖，也会低估批量竞争。

固定槽位维持给定配置下的输入形状，注意力聚合处理其中变化的非空元素数。节点数或 UE 总数改变时，邻机槽、上层用户槽及下层容量可能随配置变化，因此跨规模性能需在明确输入与模型设置下评价。

3.4.3　共享奖励及归一化

定义当步全局质量项

$$r^{\mathrm{shared}} = W_{\mathrm{fair}} J - W_{\mathrm{lat}} \bar{T} - W_{\mathrm{energy}} \bar{E} - W_{\mathrm{off}} \rho_{\mathrm{off}} + W_{\mathrm{dsr}} S/G - 0.5\rho_{\mathrm{MBS}}, \tag{3.29}$$

其中 $\bar{T} = \sum_m T_m^{\mathrm{metric}}/(20M + \epsilon_0)$、$\bar{E} = E^{\mathrm{fleet}}/(5000N + \epsilon_0)$，$\rho_{\mathrm{off}}$ 是结算后电量低于阈值的 UE 比例，ρ_{MBS} 是回传 MBS 的服务请求数除以 G。权重为 $1, 1, 0.5, 5, 1$，依次对应公平、时延、能耗、低电量和 DSR。归一化参考是尺度设置而非硬上界，能耗项没有强行裁到 $[0, 1]$。

每架 UAV 的最终奖励还包含自身违例惩罚和统一缩放：

$$r_u = 0.1\left[r^{\mathrm{shared}} - 10\mathbf{1}[\mathrm{boundary}_u] - 10\mathbf{1}[\mathrm{collision}_u] \right]. \tag{3.30}$$

因局部违例不同，各机奖励不必完全相同。质量项鼓励联合服务，局部惩罚则把

建议动作的不可行性归因给相关 UAV。奖励系数在候选与对照间固定，本章不把权重搜索作为观测方法的性能来源。

奖励综合公平性、电量、时延与 DSR，因而训练奖励与截止期满足率反映不同目标。扩展接纳也会改变未服务惩罚和批量竞争。实验同时报告 DSR、接纳与条件完成率、机队能耗和公平性，使服务改善与资源权衡具有直接依据。

3.4.4 多头交叉注意力的实际前向计算

三类原始特征分别通过线性层、层归一化和 ReLU 嵌入到六十四维。以自身嵌入 $\mathbf{e}_u$ 为查询，分别对邻机与 UE 集合执行交叉注意力。每组注意力有八个头，每头维度 $d_h = 64/8 = 8$。对于第 h 个头和非空目标 i，有

$$\mathbf{Q}_u^h = \mathbf{e}_u W_Q^h, \quad \mathbf{K}_i^h = \mathbf{e}_i W_K^h, \quad \mathbf{V}_i^h = \mathbf{e}_i W_V^h, \quad a_{u,i}^h = \frac{\exp(\mathbf{Q}_u^h (\mathbf{K}_i^h)^\top / \sqrt{8})}{\sum_{k \in \mathcal{V}_u} \exp(\mathbf{Q}_u^h (\mathbf{K}_k^h)^\top / \sqrt{8})}. \tag{3.31}$$

$\mathcal{V}_u$ 为当前非空槽集合，空槽在 softmax 前屏蔽。前向按单头维度缩放，分母为 $\sqrt{8}$；注意力可视化采用相同缩放与掩码。

每头上下文为 $\mathbf{c}_u^h = \sum_i a_{u,i}^h \mathbf{V}_i^h$，八头拼接再经输出投影。自身、邻机上下文和 UE 上下文拼成一百九十二维，经 $192 \to 128 \to 64$ 的融合网络得到策略特征。邻机聚合为轨迹协调提供相对几何线索，UE 聚合为需求筛选提供输入；其权重反映模型内部聚合，不自动等价于用户重要性的因果解释。目标全为空时实现对上下文作特殊处理，输出投影仍可有可学习偏置，故不能笼统断言最终模块特征恒为零。

集中价值网络的处理与 Actor 不同。它先把每架 UAV 的完整三百二十五维观测编码为六十四维嵌入，再在联合观测上计算智能体间注意力，屏蔽自身对自身的注意项。自身嵌入与其他 UAV 上下文拼接为一百二十八维，经价值头输出每架 UAV 的标量估计 $V_{\phi,u}(\mathbf{o})$。这种联合评价利用其他智能体的信息解释共同奖励，而执行时 Actor 仍只需自身局部观测。共享参数提升样本利用率，但五架 UAV 在同一环境内的轨迹相关性不会因此变成五次独立实验。

3.4.5 正态策略、原始动作概率与 PPO

策略头给出 $\boldsymbol{\mu}_\theta(o_u) = \tanh(W\mathbf{f}_u + \mathbf{b})$，以及两个可学习、与状态无关的对数标准差。对数标准差限制在 $[-20, 2]$，$\boldsymbol{\sigma} = \exp(\mathrm{clip}(\log \boldsymbol{\sigma}, -20, 2))$。原始二维动作采

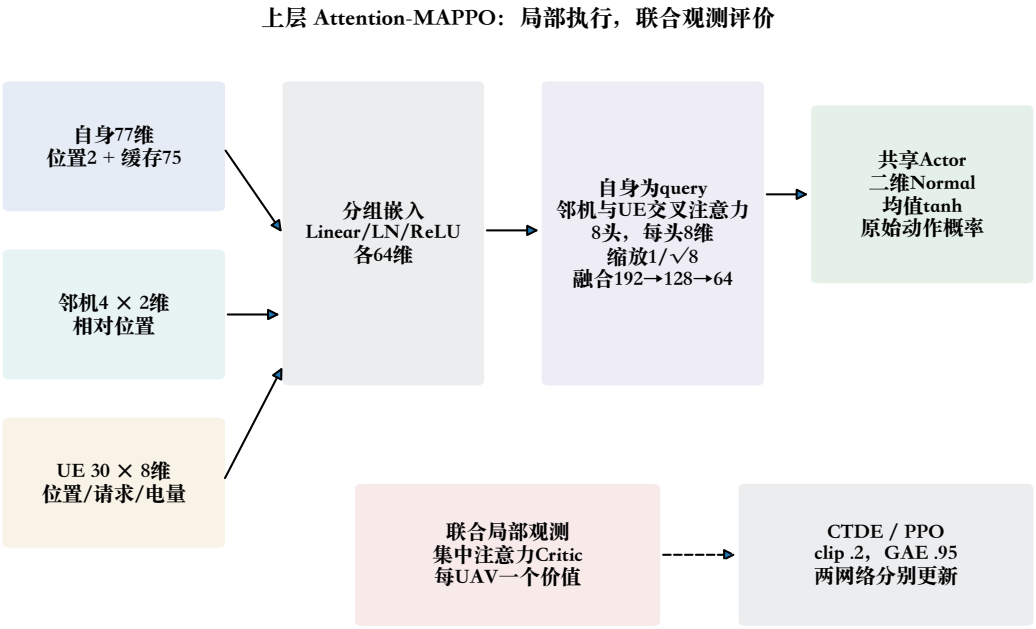


图 3.4　上层 Attention-MAPPO 的网络与训练结构。实线为前向信息流，虚线为仅训练时使用的集中式评价与参数更新；执行阶段每架 UAV 仅用自身局部观测

Figure 3.4　Network and training structure of the upper-layer Attention-MAPPO

用独立正态分布：

$$\begin{aligned} \mathbf{z}_u &\sim \mathcal{N}(\boldsymbol{\mu}_\theta(o_u), \mathrm{diag}(\boldsymbol{\sigma}^2)), \\ \log \pi_\theta(\mathbf{z}_u \mid o_u) &= -\sum_{k=1}^{2} \left[\frac{(z_{u,k} - \mu_{u,k})^2}{2\sigma_k^2} + \log \sigma_k + \frac{1}{2}\log(2\pi) \right]. \end{aligned} \tag{3.32}$$

均值的 tanh 不会把随机样本限制在 $[-1, 1]$。这是普通正态策略加执行裁剪，不是对采样变量整体作 tanh 变换的压缩正态策略。因此，缓冲区保留原始 $\mathbf{z}_u$ 和对应原始对数概率，PPO 比率在这一空间计算；不应添加压缩正态的雅可比项，也不应拿裁剪后的动作代替原始动作重算概率。

将裁剪与几何修复视为确定性环境映射，可以得到一个以原始动作驱动的有效决策过程。多个原始动作可能映射到同一执行位移，故饱和区的探索效率可能较低，但这不改变实现中的概率定义。确定性评估使用均值并裁剪后执行，结果对应不同于训练随机采样的评估策略，实验协议应固定是否启用探索。

对采集的每个智能体序列，用终止掩码 d_t 计算时序差分与 GAE：

$$\delta_{u,t} = r_{u,t} + \gamma(1-d_t)V_{\phi,u}(\mathbf{o}_{t+1}) - V_{\phi,u}(\mathbf{o}_t), \qquad \widehat{A}_{u,t} = \delta_{u,t} + \gamma\lambda_{\mathrm{GAE}}(1-d_t)\widehat{A}_{u,t+1}. \tag{3.33}$$

$\gamma = 0.99$、$\lambda_{\mathrm{GAE}} = 0.95$。递推展开得到后续 TD 残差的折扣和，终止位置不向下一回合引导。缓冲区先形成回报目标 $\widehat{R}_{u,t} = \widehat{A}^{\mathrm{raw}}_{u,t} + V^{\mathrm{old}}_{u,t}$，再对 Actor 使用的优势作整体均值和标准差归一化；若先归一化优势再构造回报，将改变 Critic 的数值目标。

记新旧原始动作概率比为 $\rho_{u,t} = \exp(\log \pi_\theta(\mathbf{z}_{u,t} \mid o_{u,t}) - \log \pi_{\theta_{\text{old}}}(\mathbf{z}_{u,t} \mid o_{u,t}))$，裁剪替代目标为

$$L^{\text{CLIP}} = \hat{\mathbb{E}}_{u,t}\left[\min\left(\rho_{u,t}\hat{A}_{u,t}, \text{clip}(\rho_{u,t}, 1-\varepsilon, 1+\varepsilon)\hat{A}_{u,t}\right)\right], \qquad \varepsilon = 0.2. \tag{3.34}$$

正、负优势分别限制动作概率向有利方向过度变化所能增加的代理收益。裁剪作用于目标函数，属于稳定训练的优化机制；真实回报与训练行为仍由实验评价。

Actor 最小化 $-L^{\text{CLIP}} - \beta_H \overline{H}$，$\beta_H = 0.005$。实现将正态熵在批次及两个动作坐标上取平均，$\overline{H} = \frac{1}{2}\sum_{k=1}^{2}\frac{1}{2}\log(2\pi e\sigma_k^2)$；对数概率则在两个坐标上求和，二者约定不同。Critic 使用裁剪值损失：

$$\begin{aligned} V_u^{\text{clip}} &= V_u^{\text{old}} + \text{clip}(V_{\phi,u} - V_u^{\text{old}}, -\varepsilon, \varepsilon), \\ L_V &= \frac{1}{2}\hat{\mathbb{E}}_{u,t}\max\left[(V_{\phi,u} - \hat{R}_{u,t})^2, (V_u^{\text{clip}} - \hat{R}_{u,t})^2\right]. \end{aligned} \tag{3.35}$$

两网络分别使用 Adam，学习率均为 3×10^{-4}，梯度范数上限为 0.5。每次收集一千步，以二百五十六小批量更新八轮，超参数见表 3.3。

表 3.3　上层 MAPPO 主要超参数

Table 3.3　Main hyperparameters of the upper-layer MAPPO

超参数	取值	超参数	取值
折扣因子 γ	0.99	GAE 系数 λ_{GAE}	0.95
裁剪系数 ε	0.2	熵系数	0.005
演员/评论家学习率	3×10^{-4}	梯度范数截断	0.5
rollout 长度	1000 步	更新轮数	8
小批量大小	256	注意力头数 / 嵌入维	8 / 64

覆盖观测方法与强基线均采用无注意力请求级 MAPPO 下层，各方法内独立训练两层参数。下层质量掩码按估计时延和算力份额筛选协作目标，允许协作时延达到截止期的 1.50 倍及最佳本地或 MBS 时延的 1.35 倍，并要求邻机算力份额比不低于 0.25；本地为合法保底，仍可能超时。违例通过自适应惩罚处理。该配置用于本章观测比较，第五章另行定义 SF-HLM 的配额匹配下层。

3.5　预接纳需求观测设计

3.5.1　缺失需求与局部可辨识性

原观测把三十个 UE 槽全部用于已经关联到自身的用户。若存在两个物理状态，其已关联用户、自身位置、缓存和邻机相同，而未覆盖用户分布不同，则原观测也相同。任何仅依赖该观测的确定性 Actor 都会给出相同动作，随机 Actor 也只能给出相同分布。由此可知，原观测不能针对这两个状态作需求方向上的区

算法 3.1　上层 Attention-MAPPO 的概率与执行一致训练流程

Input: 自然覆盖环境、训练种子、回合数 E、当前下层策略
Output: 共享 Actor 参数 θ 与集中 Critic 参数 ϕ

初始化网络、优化器和缓冲区;
for $e \leftarrow 1$ **to** E **do**
    重置环境，生成当前请求、接纳关系与观测 $\mathbf{o}_0$;
    for $t \leftarrow 0$ **to** 999 **do**
        从局部观测采样原始动作 $\mathbf{z}_{u,t}$，保存其对数概率;
        用联合观测计算 $V_{\phi,u}$，下层计算当前请求分配;
        将 $\mathrm{clip}(\mathbf{z}_{u,t}, -1, 1)$ 与分配交给环境;
        环境先执行请求，再修复并应用位移，结算奖励并生成下一观测;
        保存原始动作、旧值、奖励、终止掩码与观测;
    end
    依据式 (3.33) 形成原始优势及回报，再归一化 Actor 优势;
    for $k \leftarrow 1$ **to** 8 **do**
        以小批量 256 优化式 (3.34) 及式 (3.35);
    end
end

分；这种状态混叠是由输入定义造成的，不是优化器未充分训练所能彻底消除。

预接纳观测加入感知范围内尚未被任何 UAV 接纳的用户位置、当前请求与电量，供策略选择下一时隙的移动。用户随后继续移动并生成新请求，因此这些字段提供当前空间需求和能量状态线索。独立确认检验其对长期接纳与服务的作用。

3.5.2　确定性槽位填充与容量约束

扩展模式首先按距离升序保留自身已关联 UE，距离平局按用户编号确定；随后按距离升序补入 460 m 内尚未被任何 UAV 接纳的 UE，直到三十槽用满。已由其他 UAV 接纳的用户不作为未接纳需求重复补入。若已有三十名自身关联用户，则扩展模式没有额外槽位；若两组用户合计少于三十，则其余补零。该规则保持维度、特征归一化、掩码、Actor 和 Critic 完全相同，仅改变进入固定输入的用户集合。

以 $\mathcal{A}_u$ 标记自身关联用户、$\mathcal{V}_u^{\mathrm{un}}$ 标记感知范围内未接纳用户，槽位列表可表示为

$$\mathcal{L}_u = \mathrm{first}_{30}\left[\mathrm{sort}_{(d,\mathrm{id})}(\mathcal{A}_u) \,\|\, \mathrm{sort}_{(d,\mathrm{id})}(\mathcal{V}_u^{\mathrm{un}})\right]. \tag{3.36}$$

槽位填充优先保留自身已关联业务，再以剩余容量纳入未覆盖需求，形成确定的输入规则。其他需求排序或字段裁剪方式改变观测构造，应在各自实验设计下单独评价。

一个构造的槽位例子可以说明改动范围。若当前自身关联十二名 UE、感知

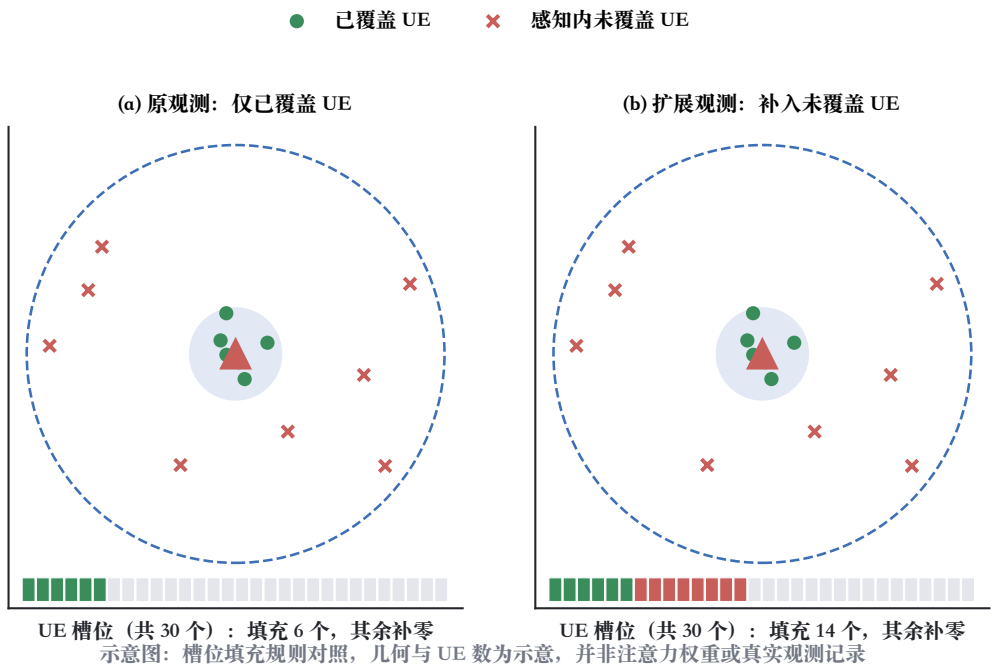


图 3.5　原观测与扩展观测的槽位填充规则对照（同一几何示意）。原观测仅含已覆盖 UE，扩展观测以距离顺序补入感知范围内尚未接纳的 UE；图为规则示意，非注意力权重或真实记录

Figure 3.5　Slot-filling rules of the original and the extended observation under the same illustrative geometry

范围另有二十五名未接纳 UE，则原观测含十二个真实槽和十八个空槽；扩展观测仍保留原十二名，并补入最近十八名未接纳 UE，其余七名仍不可见。下层只处理自然接纳的真实服务集合，不会把新增十八个观测槽直接变成十八项卸载动作。若次步移动使部分用户进入服务圆，只有那时生成且被接纳的请求才能执行。

3.5.3　从观测信息到可实现收益

扩展观测假定决策前可获得感知范围内未接纳 UE 的位置、当前请求字段和电量。确认实验未计入额外上报时延、丢失与通信能耗，其结果回答规定信息可用时的服务改善问题。感知半径表示仿真可见性范围，实际广播与协调条件需进一步验证。

基线空槽不含用户信息，扩展观测的非空槽提供当前需求字段，二者虽均为三百二十五维，信息量仍不同。本章固定网络和训练配置，以比较观测规则；同信息结构对照另用于评价聚合方式。第五章采用规定的需求信息范围，重点研究配额匹配下层。

若字段来自 $t-\ell$ 时刻，位置移动与业务更新会改变信息的新鲜度，其对下一步覆盖决策的影响需通过延迟或缺失实验评价。当前确认结果刻画理想当前

信息可用时的作用。

3.6　瓶颈诊断、独立确认与机制解释

3.6.1　由失败来源确定干预方向

为确定覆盖观测比较的下层配置，先在自然覆盖设置下评价双注意力方法与无注意力下层变体，采用五个训练种子和十个工作负载。两者 DSR 分别为 0.2428 与 0.2609，差值 −1.81 个百分点，配对交叉 bootstrap 的 95% 区间为 [−2.40, −1.17]。据此，本章以无注意力下层变体作为强基线，将观测比较集中于上层输入差异。

对强基线二十五个完整评估单元的诊断中，DSR 为 0.2459，未覆盖请求占实际生成服务请求的 48.14%、占失败请求的 63.84%。图 3.6 按式 (3.2) 分为成功、已接纳超时和未接纳三类，显示该批次中未覆盖是主要失败来源，由此确定需求观测的干预方向。

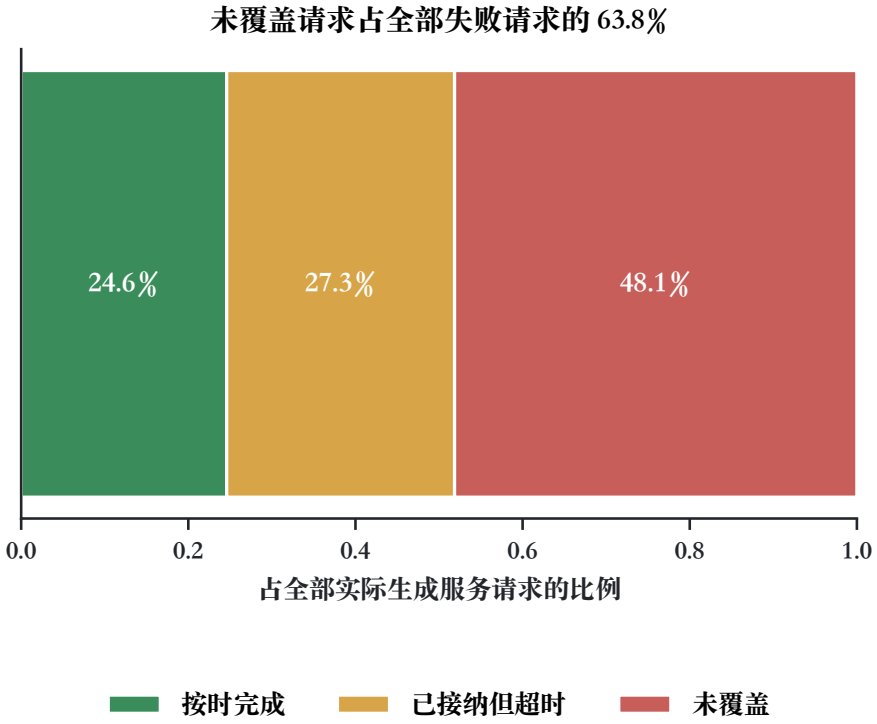


图 3.6　主场景实际生成服务请求的结果构成（下层无注意力强基线，瓶颈诊断批次，25 个评估单元的计数汇总）

Figure 3.6　Outcome composition of generated service requests in the main setting (strong baseline, diagnostic batch)

同一诊断在五十个固定快照上采用双步质量掩码局部搜索，成功数从 362 增至 441，快照分母下提升 5.13 个百分点，分配能耗增加 22.86%。反事实分配未回写环境，搜索预算也区别于在线策略。该结果显示接纳后分配仍有质量余量，并伴随能耗与计算代价，构成第四章固定快照分析和第五章有限预算在线搜索

的研究动机。

3.6.2 探索与确认使用不同种子

覆盖观测实验采用两阶段协议。探索阶段为五个训练种子乘五个工作负载，候选和强基线共十次训练、五十个评估任务、三百个回合。其目的在于筛选观测方向，不能把筛选后最高结果当作独立确认。确认阶段使用全新的十个训练种子和五个工作负载，两方法共二十次训练、一百个评估任务和六百个评估回合，每个检查点在每个工作负载上运行六回合。探索与确认的差别见表 3.4。

表 3.4 覆盖观测两阶段实验协议

Table 3.4 Two-stage protocol of the coverage-observation experiments

协议要素	探索性实验	独立确认
训练种子	5 个（与基线比较批次共用）	10 个（全新）
工作负载种子	5 个	5 个（全新）
每检查点评估	5 工作负载 × 6 episode	5 工作负载 × 6 episode
训练/评估规模	10 次训练 / 50 任务	20 次训练 / 100 任务 / 600 episode
方法差异	仅上层观测槽位填充规则；下层配置相同、分别训练	
统计单位	训练种子；工作负载配对	
结论用途	方向筛选，不独立支撑结论	本章主要结果

一百个评估任务组成五十对方法配对单元，而不是一百对。对每个训练种子 k，先平均五个工作负载的 DSR 差值 $d_{k,w}$，得到 $d_k = 5^{-1}\sum_w d_{k,w}$；十个 d_k 才是主检验中的独立训练重复。工作负载、回合和单个请求嵌套于训练结果，不能把它们当成额外训练种子扩大样本量。对训练种子差值使用配对 t 区间：

$$\bar{d} \pm t_{0.975,9}\frac{s_d}{\sqrt{10}}, \qquad s_d^2 = \frac{1}{9}\sum_{k=1}^{10}(d_k - \bar{d})^2. \tag{3.37}$$

主效应采用预定的训练种子配对区间，交叉重采样作为补充不确定性分析。

配对评估共享外生请求与移动随机流，以减少工作负载差异；两方法分别训练，使比较包含各自对观测输入的学习适应。模型与评估记录按训练种子和工作负载对应，保持数据来源及配对关系一致。

3.6.3 确认结果及训练曲线的用途

探索阶段 DSR 差值为 +3.30 个百分点，交叉 bootstrap 95% 区间为 [+1.29, +5.33]，由此进入独立确认。确认结果见表 3.5：等权评估单元平均 DSR 从 0.2444 提高至 0.2793，差值 +3.49 个百分点，训练种子配对 95% 区间为 [+2.44, +4.54]。十个训练种子的差值均为正，五十个配对单元中四十九个为正。这说明结果不仅由一个特别有利的训练种子推动，也具有较一致的配对方向。

表 3.5　独立确认实验的主场景结果（10 个新训练种子 × 5 个新工作负载）

Table 3.5　Main-setting results of the independent confirmation

指标	强基线（原观测）	候选（扩展观测）	配对差值 [95% 区间]
DSR S/G	0.2444	0.2793	+0.0349 [+0.0244,+0.0454][a]
接纳率 A/G	0.4996	0.6189	+0.1193
接纳后按时完成率 S/A	0.4919	0.4537	−0.0382 [−0.0752,−0.0012][a]
每评估单元的回合平均机队能耗差	候选相对基线		-3.50×10^6 J
Jain 公平性差	候选相对基线		+0.0786

[a] 以训练种子为独立单位的配对 t 区间。DSR 差值为本章主结论；接纳后完成率下降为机制分析指标，未单独作多重比较校正。先在每评估单元内汇总请求计数求比例，再平均 50 个单元；不以全部单元合并计数的比例替代本表均值。平均 DSR 不等于两个平均因子的乘积。

为说明不同汇总方式的量级，该确认批次基线累计生成服务 9,805,179 个、按时完成 2,395,429 个，候选相应为 9,804,541 和 2,738,233 个。合并计数所得 DSR 约为 0.24430 与 0.27928，与表中等权均值接近但不完全相同。主报告保留表中预定均值及配对区间；合并计数在此仅用于解释口径，并不增加一次独立证据。

图 3.7 展示十个训练种子的均值与标准差，描述学习走势和跨种子波动。标准差带表示训练离散程度；方法效果则依据训练结束检查点的独立配对评价。

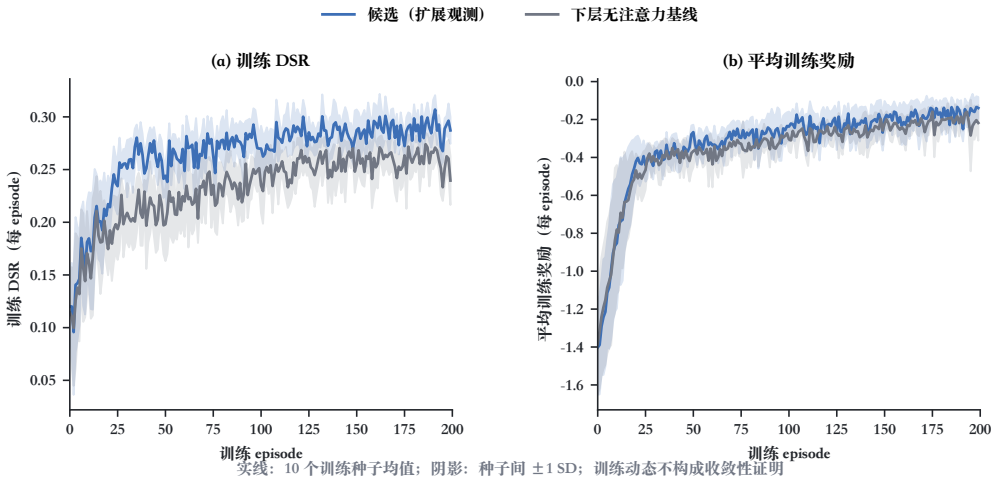


图 3.7　独立确认实验的训练曲线（10 个训练种子的均值 ± 标准差）：(a) 训练 DSR；(b) 平均训练奖励

Figure 3.7　Training curves of the independent confirmation (mean ± std over ten training seeds)

3.6.4　接纳扩展与接纳后质量的联合解释

候选的平均接纳率从 0.4996 提高至 0.6189，增加 11.93 个百分点；接纳后按时完成率从 0.4919 变为 0.4537，差值为 −3.82 个百分点，训练种子配对区间为 [−7.52, −0.12] 个百分点。图 3.9 按训练种子汇总五个工作负载展示两项指标，说明接纳扩大与条件质量变化方向不同。条件质量变化未单独作多重比较校正，

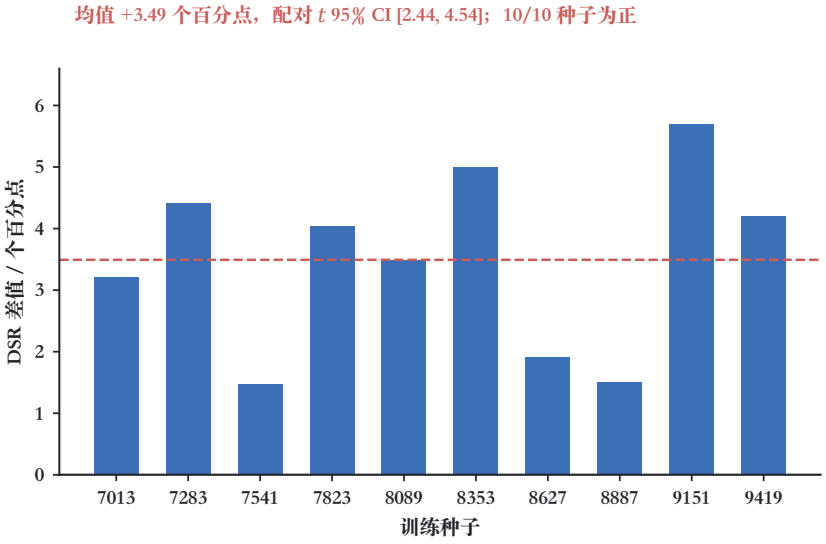


图 3.8　独立确认实验中候选相对强基线的逐训练种子 DSR 差值（每个种子为 5 个工作负载差值的平均；区间为配对 t 95% 区间）

Figure 3.8　Per-training-seed paired DSR differences of the candidate against the strong baseline

应作为机制分析指标解释。

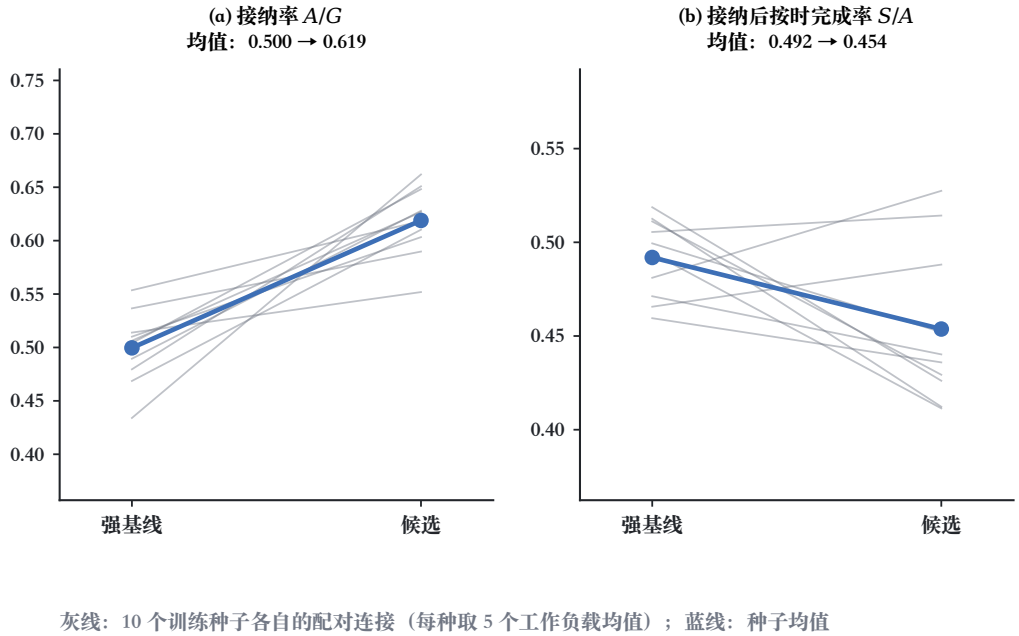


图 3.9　确认实验中接纳率与接纳后按时完成率的配对比较（每点为一个训练种子下五个配对工作负载的均值）。两因子反向变化，DSR 增益来自接纳因子

Figure 3.9　Paired comparison of the admission fraction and the deadline satisfaction among admitted requests

按式 (3.4) 在五十个配对单元内分解并平均，接纳变化项贡献约 +5.62 个百分点，条件完成率变化项贡献约 −2.13 个百分点，合计 +3.49 个百分点。扩大接纳的正向作用超过条件完成率下降的抵消。该分解描述各方法实际轨迹与请求批量下的汇总变化，单个请求的影响仍需专门的反事实比较。

更多 UE 进入覆盖后，接入带宽分摊、计算批量、缓存缺失和回传限制共同影响接纳后的质量。需求观测扩大服务机会，进一步利用这些机会依赖下层任务组织。第五章保持需求感知上层参数固定，独立训练并评价 SF-HLM 的配额匹配下层。

同一确认批次中，完整机队的回合平均能耗减少约 3.50×10^{6} J，约为基线的 6.37%；包含全部请求类型的累计公平性提高 0.0786。两项描述均值与 DSR 同向改善，刻画了所测主场景中的资源与服务权衡。信息上报能耗未纳入此次统计。

3.6.5　观测设计效果与适用条件

本章确认实验在同一注意力结构与下层配置下比较观测内容，支持在一百 UE 主场景和当前信息假设下，把可见未接纳需求送入上层能提高端到端 DSR。由于网络保持相同，它明确定位了一个可实施的输入改动，避免将改进笼统归因于“更复杂的模型”。该优势具有清楚的触发条件：原输入存在空槽或容量可用于补充未接纳用户，且这些用户信息在决策前可用。

本章结果支持规定信息可用时的需求观测改善，尚未单独确认同信息预算下的注意力结构优势或信息上报成本后的净收益。需求可见性、接纳率和接纳后质量共同构成自然覆盖系统的评价框架，进一步的结构与部署评价需保持这些条件明确。

3.7　本章小结

本章建立了自然覆盖下无人机集群协同轨迹决策的系统与学习模型。统一 *G*/*A*/*S* 计数将 DSR 分解为接纳率与接纳后质量，通信、缓存、批量算力、电池及机动结算刻画空间部署与执行的耦合。当前请求在移动前执行，轨迹主要影响下一时隙接纳。Attention-MAPPO 采用局部观测执行、联合观测评价，以及原始正态概率与确定性动作修复。

扩展观测保持三十槽和物理半径不变，将感知范围内未接纳用户纳入输入。独立确认中 DSR 增加 3.49 个百分点，接纳扩展的收益超过条件质量下降的影响。第四章进一步分析固定快照的批量分配余量与代价，第五章评价完整 SF-HLM 的闭环服务表现。

第 4 章　考虑跨机资源竞争的截止期优先计算任务分配

4.1　固定快照问题与受控比较范围

第三章研究无人机集群如何通过空间部署接纳地面需求，本章进一步研究集群如何分担已经接纳的计算任务。请求接入某架无人机后，其执行节点仍可选择来源本机、允许的协作无人机或地面 MBS。执行位置会改变回源、机间转发、机载计算负载和能耗。该问题不仅涉及为单个请求选择最快节点，还涉及选择后整批请求如何分享各机算力。一项迁移可能使目标请求提前完成，也可能同时使迁入节点上多个原有请求超时。因此，跨机任务分配需要在同一执行模型中考虑全批次影响。

这里的任务分配以不可拆分的计算请求为对象，关联无人机承担接纳与上传职责，执行节点承担计算职责。二者可以不同，因而集群具有在空间接入后继续协作分工的机会。不同无人机的算力、缓存与链路条件不同，地面 MBS 则作为六节点服务系统中的计算支撑。本章保持这些既有资源规则，研究任务从一个执行节点转移到另一个节点时的系统后果；这与为飞行器分配巡检航点、侦察目标或编队位置具有不同的任务语义。

本章固定 UAV 和 UE 的历史几何、当前缓存、电量、请求集合以及配置，对同一快照上的候选分配作独立反事实评价。每次评价从完全相同的状态开始，用仿真环境执行整批请求，得到完成时延和 UAV 分配能耗。候选执行结果不回写用于采样的参考历史，下一快照仍来自同一参考控制轨迹。通过这一受控设计，可以把“选择了不同执行目标”与“经过不同历史已产生不同状态”区分开来。

固定快照的研究问题是：在自然接纳、最终批量负载均分的条件下，以减少超时请求为第一优先级的跨节点迁移搜索，能否比自身代价启发式给出更好的集群当步分工，以及这种质量余量需要多少能耗和求解时间。该问题与在线强化学习不同。在线下层必须在很短时间内从观测产生动作，且动作会通过缓存和 UE 电池影响后续运行；快照求解器可以对大量候选逐一重评估，却不会改变后续状态。本章方法据此定位为集群任务分配的受控分析与离线质量参照。

主实验沿 Heuristic-Control 参考轨迹采集快照，本章末另在需求感知上层与无注意力学习式下层产生的轨迹上进行补充比较。两类快照分别报告，以刻画参考控制和学习控制形成的请求状态。MC-ITR 采用单请求迁移与整体重评估，作为固定快照分配参照；第五章的在线下层采用配额搜索与条件匹配。

4.1.1　变量、候选域与实际节点映射

设快照接纳服务集合为 $\mathcal{M}$，大小为 $K = |\mathcal{M}|$，请求按 UE 编号升序排列。全系统 UE 数仍记为 M，避免把快照活跃请求数与总人口混淆。请求 m 具有来源 UAV u_m、输入字节 L_m、服务文件字节 B_{s_m}、总 CPU 周期 $C_m = \omega_{s_m} L_m$、截止时间 D_m 和优先级字段 p_m。任务优先级提供给部分学习观测，但本章目标不按 p_m 加权；“截止期优先”指超时数在目标层级中优先，不能解释为优先级字段决定奖励权重。

每请求的候选集合记为 $\mathcal{C}_m$，包含来源本地、MBS 与硬可行邻机。分配向量 $\mathbf{a} = (a_1, \cdots, a_K)$ 属于

$$\mathcal{A} = \prod_{m \in \mathcal{M}} \mathcal{C}_m, \qquad |\mathcal{A}| = \prod_{m \in \mathcal{M}} |\mathcal{C}_m|. \tag{4.1}$$

使用花体 $\mathcal{C}_m$ 表示候选集，以区别总周期 C_m。实现动作编号为 0 本地、1 MBS、$2 + j$ 协作 UAV j；来源 UAV 自身的协作编号被排除，本地编号则映射到请求的来源。记 $d_m(a_m)$ 为动作对应的实际计算节点，则不同来源请求选择本地时可能到达不同 UAV，不能把动作编号零当作全系统同一个计算节点。

硬可行集合与学习策略的质量掩码不同。硬集合检查邻机可达、目标非自身、链路与算力等物理字段有效，本地和 MBS 保留为有效来源路径；邻机没有缓存也可通过回源取文件执行。本章枚举硬可行节点，不要求每条路径都预计满足截止期。若预先删除所有预计超时动作，会改变优化空间，并可能把估计误差当成严格物理约束；本章不采用这样的候选域。

4.2　全批次执行、缓存与分配代价

4.2.1　通信与真实缓存路径

第三章给出了移动前几何、信道和缓存模型，本章在同一规则下具体化分配评价。字节数据 L_m 在比特每秒速率 R 上传输的时间为

$$T_{\mathrm{tx}} = 8L_m / R. \tag{4.2}$$

输入上传以来源 UAV 的全部关联 UE 数分配接入带宽，分配目标不会更换上传来源或该分母。文件回源用 B_{s_m}，而非服务输入 L_m。因此，两个请求即使输入相同，服务文件大小、缓存位置和截止时间不同，也可能需要不同执行节点。

记 $U_m = 8L_m / R^{\mathrm{edge}}_{m,u_m}$，$V_{j,s} = 8B_s / R^{\mathrm{bh}}_{j,\mathrm{M}}$，$I_{m,u,v} = 8L_m / R^{\mathrm{inter}}_{u,v}$。缓存指示 $h_{j,s}$ 来

自快照起点真实状态，非命中概率。给定分配后，三类路径为

$$\begin{aligned} T_m(\text{local};\mathbf{a}) &= U_m + (1-h_{u_m,s_m})V_{u_m,s_m} + C_m N_{u_m}(\mathbf{a})/F_{u_m}, \\ T_m(\text{coop } v;\mathbf{a}) &= U_m + I_{m,u_m,v} + (1-h_{v,s_m})V_{v,s_m} + C_m N_v(\mathbf{a})/F_v, \\ T_m(\text{MBS};\mathbf{a}) &= U_m + 8L_m/R^{\text{bh}}_{u_m,\text{M}} + C_m/F_{\text{M}}. \end{aligned} \tag{4.3}$$

Heuristic-Control 依据邻机命中概率预测路径，快照评价则固定相同的真实缓存状态，使候选之间的实际时延可直接比较。

各分配评价均冻结快照初始缓存，因此同批次较早发生的取文件不会立即改变后续请求的命中状态。若两项任务都需要某个起点未缓存的服务文件，它们在当前评价中各自支付回源项；待提交缓存只影响该私有副本步进后的状态，不影响其他候选评价。这一处理保证分配目标与请求遍历顺序不会偷偷改写待比较问题，也防止一项候选因先被评价而享有缓存优势。

4.2.2 节点最终负载与计算推导

环境执行先解析整批目标，再冻结 UAV 最终负载：

$$N_j(\mathbf{a}) = \sum_{m\in\mathcal{M}} \mathbf{1}[d_m(a_m) = j], \qquad \mathcal{M}_j(\mathbf{a}) = \{m : d_m(a_m) = j\}. \tag{4.4}$$

本地留存与协作迁入共同计入 N_j，协作迁出和 MBS 任务不计入。只要 $m \in \mathcal{M}_j$，便有 $N_j \geqslant 1$，每请求获得等效计算服务速率 $f_{m,j} = F_j/N_j$。沿用第三章的计算时间与等效频率能耗假设，得到

$$T^{\text{cmp}}_m = C_m N_j/F_j, \qquad E^{\text{cmp}}_m = \kappa C_m (F_j/N_j)^2, \qquad \kappa = 10^{-27}. \tag{4.5}$$

MBS 的单请求等效计算能力固定为 $F_{\text{M}} = 200\,\text{GHz}$，不随任务数均分。本章沿用该仿真设置，未增加 MBS 排队容量或 CPU 能耗目标。

算力均分表示当前批次服务能力的简化分享，而非持续排队。每个请求具有不同计算周期，但均分份额不按输入大小加权；它们的计算时延因此可不同。时间超过决策步长或截止期的请求仍由本次评价计算完整路径，不保留到后续批次排队。依据初始来源服务数预估的份额只用于启发式上下文，实际 $N_j(\mathbf{a})$ 必须在所有目标确定后重新计算。忽略这一步会令请求的结果依赖先后执行顺序，破坏公平比较。

4.2.3 迁移对未移动请求的外部影响

考虑把请求 m 从 UAV i 迁往 UAV j，迁移前负载为 $N_i = n_i \geqslant 1, N_j = n_j \geqslant 0$。对仍留在来源的请求 $k \neq m$，计算时延减少 C_k/F_i；对目标既有请求 ℓ，计算时

延增加 C_ℓ/F_j：

$$\Delta T_k^{\mathrm{cmp}} = -C_k/F_i, \quad k \in \mathcal{M}_i \setminus \{m\}; \qquad \Delta T_\ell^{\mathrm{cmp}} = C_\ell/F_j, \quad \ell \in \mathcal{M}_j. \tag{4.6}$$

这些请求的通信起点、执行节点与缓存不变，所以它们的完整时延变化也等于上述计算变化。被迁移请求则同时更换计算节点、通信路径和可能的回源项，不能只用 C_m/F_j 估计其收益。

对目标原有请求的计算能耗，在 $n_j > 0$ 时有

$$\frac{E_\ell^{\mathrm{cmp,new}}}{E_\ell^{\mathrm{cmp,old}}} = \left(\frac{n_j}{n_j+1}\right)^2. \tag{4.7}$$

迁入增加它们的完成时间，却降低其计算能耗；来源剩余请求则因获得更高等效服务速率而更快、但模型计算能耗上升。这不是矛盾，而是式 (4.5) 中时延与等效服务速率倒数、能耗与其平方的直接结果。是否降低整个系统能耗，要把两节点和通信变化一起计算。

图 4.1 采用算力 $F_u = 60\,\mathrm{GHz}$、输入 $L_m = 2\times10^6$ 字节及每字节 2000 周期的构造示例，总周期为 $C_m = 4\times10^9$。二请求批次中，每请求分得 30 GHz，计算时间 0.133 s、能耗 3600 J；四请求批次中相应值为 15 GHz、0.267 s 和 900 J。这些数值由本文公式计算，用于展示批量共享关系。

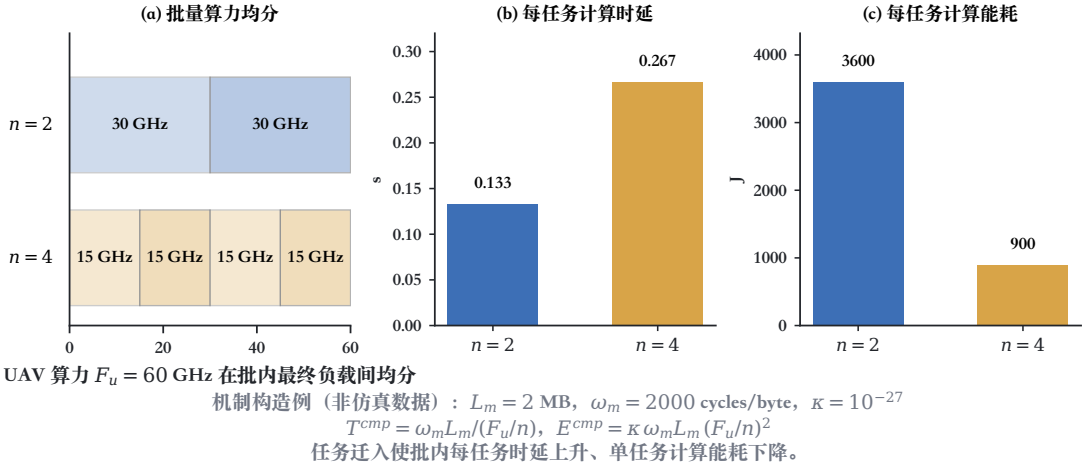


图 4.1　批量算力共享与迁移外部影响的机制示例（构造参数：$F_u = 60\,\mathrm{GHz}$，$L_m = 2\times10^6$ 字节，$\omega_m = 2000$ 周期/字节，$\kappa = 10^{-27}$；数值按式 (4.5) 计算，非实验测量）

Figure 4.1　Mechanism example of batch compute sharing and migration externality (constructed parameters, computed from Eq. (4.5))

若以 $Q_j = \sum_{m\in\mathcal{M}_j} C_m$ 表示节点周期总量，则 UAV 计算总能耗可写为

$$E_j^{\mathrm{cmp}} = \psi(F_j, Q_j, N_j), \qquad \psi(F,Q,n) = \begin{cases} \kappa F^2 Q/n^2, & n > 0, \\ 0, & n = 0,\ Q = 0. \end{cases} \tag{4.8}$$

因此，$i \to j$ 迁移的计算能耗变化为

$$\Delta E^{\mathrm{cmp}} = \psi(F_i, Q_i - C_m, n_i - 1) - \psi(F_i, Q_i, n_i) + \psi(F_j, Q_j + C_m, n_j + 1) - \psi(F_j, Q_j, n_j). \tag{4.9}$$

来源只含该请求时，其迁移后节点能耗按零定义；目标原为空时也使用零初值。该写法避免在空节点套用零分母公式，并把迁移导致的所有计算项一次计算清楚。

一个更细的结论是，增加请求不一定增加该节点总计算能耗。对非空目标，新增周期为 C_m 时，计算总能耗下降当且仅当

$$C_m < Q_j(2n_j + 1)/n_j^2. \tag{4.10}$$

该条件由 $(Q_j + C_m)/(n_j + 1)^2 < Q_j/n_j^2$ 展开得到。若全部请求周期相同，计算能耗按 $1/n_j$ 变化，新增并发请求会让理想均分模型中的节点计算能耗降低；但它们的时延同时增加，且还需通信。本文保留这一模型后果，不将其误写成真实硬件中任意增载都能节能的物理定律。

4.2.4 自身改善不等于系统改善的构造例

为说明截止期外部性，构造两个缓存均命中的 UAV，算力均为 40 GHz，每请求输入为 4×10^6 字节、每字节 2000 周期，故 $C_m = 8 \times 10^9$。把每请求的共同上传时间设为 0.30 s，一次协作输入转发设为 0.12 s。这些是用于推导的指定路径常数，不是主实验快照记录。迁移前来源有五请求、目标有三请求；其中待迁请求截止时间为 1.25 s，来源其余四请求为 1.70 s，目标三请求为 1.00 s，均处于现行截止时间范围。

迁移前来源任务时延为 $0.30 + 5 \times 0.20 = 1.30$ s，目标任务为 $0.30 + 3 \times 0.20 = 0.90$ s。待迁请求超时，其他七项均成功。迁移后两节点均为四请求：待迁请求多付转发，其时延为 $0.30 + 0.12 + 4 \times 0.20 = 1.22$ s，从超时变成功；来源其他任务变为 1.10 s，仍成功；目标三任务也变为 1.10 s，全部越过自身截止时间。表 4.1 汇总该反例。

该迁移使自身超时指示从一变零，却使系统超时数从一增至三。只依据自身字典序代价的迭代会把它视为优先改善，整体评价则应拒绝。这一构造证明的是判据之间存在逻辑差异，不表示每次自身迁移都产生负效应，也不直接量化主实验中有多少改善来自某种具体外部性。主实验的对照用于检验完整方法结果，构造例用于说明为何整体重评估是必要的算法设计。

表 4.1　自身改善与系统超时变化的构造例（非实验数据）

Table 4.1　Constructed example of own-request improvement and system deadline misses

请求组	数量	截止时间/s	迁移前时延/s	迁移后时延/s
待迁请求	1	1.25	1.30（超时）	1.22（成功）
来源其余请求	4	1.70	1.30	1.10
目标既有请求	3	1.00	0.90	1.10（超时）

4.2.5　分配因果能耗与共同项排除

本章能耗项定义为随卸载目标变化的 UAV 通信和计算代价：

$$
\begin{aligned}
E_m^{\mathrm{local}} &= (1-h_{u,s})P^{\mathrm{bh,rx}}V_{u,s} + \kappa C_m (F_u/N_u)^2,\\
E_m^{\mathrm{coop}} &= (P^{\mathrm{tx}}+P^{\mathrm{rx}})I_{m,u,v} + (1-h_{v,s})P^{\mathrm{bh,rx}}V_{v,s} + \kappa C_m (F_v/N_v)^2,\\
E_m^{\mathrm{MBS}} &= P^{\mathrm{bh,tx}} 8L_m/R_{u,\mathrm{M}}^{\mathrm{bh}}, \qquad E_{\mathrm{assign}} = \sum_{m\in\mathcal{M}} E_m^{a_m}.
\end{aligned}
\tag{4.11}
$$

其中 $u=u_m, s=s_m$，功率沿用第三章。协作能耗计入发送 UAV 和接收 UAV 两端；MBS 网格供电计算不计入机队。每个服务路径共有的来源 UAV 输入接收 $P^{\mathrm{rx}}U_m$ 被排除，不能把所有非飞行 UAV 能耗都统称为分配能耗。

固定轨迹下飞行、悬停和 WPT 不随服务分配变化，内容处理也不属于服务目标优化项。将这些共同项加入每个候选只会改变显示尺度，不改变同快照分配之间的能耗差，因此本章把它们与分配目标分开。UE 电池的上传消耗在快照中也不作为 UAV 能耗计入。完整运行能耗与分配能耗的联系在第三章式 (3.19) 中给出，二者比较时必须保持分母与求和范围一致。

本章归一化能耗为整个快照 $E_{\mathrm{assign}}/(25000\,\mathrm{J})$，不再除以 UAV 数。学习下层奖励中的机队平均归一化可使用 $N\times 25000\,\mathrm{J}$，上层则使用 $N\times 5000\,\mathrm{J}$，三者不是同一数值。这里的 25000 J 是固定参照，指标可以大于一，不是禁止超越的能量预算。以明确口径报告，可以解释后文 2.128 的意义，而不会把它误读为能耗百分比或超出电池容量。

4.3　严格字典序目标与共同基线

4.3.1　为何优先比较超时请求数

对于具有任务截止期的边缘服务，是否按时完成是离散的质量界限，而缩短已成功任务的时延只是连续改善。若把超时、平均时延和能耗直接作固定加权和，算法可能通过降低很多成功任务的能耗抵消一个新增超时，也可能因单位改变而改变偏好。本文的目标先满足截止期优先的设计意图，再在第一层相同时比

较其他代价。

严格字典序目标为

$$F(\mathbf{a}) = \Big(\sum_{m\in\mathcal{M}} \mathbf{1}[T_m(\mathbf{a}) > D_m], \\ \frac{1}{\max(K,1)} \sum_{m\in\mathcal{M}} \frac{T_m(\mathbf{a})}{\max(D_m, 10^{-9}\,\mathrm{s})}, \\ \frac{E_{\mathrm{assign}}(\mathbf{a})}{25000\,\mathrm{J}} \Big). \tag{4.12}$$

记三个分量为 F_1, F_2, F_3。对 $F(\mathbf{a}')$ 与 $F(\mathbf{a})$，从第一分量开始找到首个不相等的位置，该处较小者为较优分配。实现不取整、不设置字典序容差、不加 MBS 独立惩罚，也不将请求优先级乘入超时计数。$T_m = D_m$ 视为成功；空快照 $K = 0$ 时三个分量均为零。

例如，$(2, 0.91, 2.80)$ 比 $(3, 0.70, 1.20)$ 更优，因为少一个超时；在超时数同为二时，$(2, 0.89, 3.10)$ 又比 $(2, 0.91, 2.80)$ 更优；只有前两个分量完全相等，第三分量才决定顺序。这些示例是目标比较的构造数字，不是某次实验结果。它们说明字典序严格下降并不要求时延与能耗同时下降，更不支持把算法描述为所有指标一致改善。

第二分量使用每请求的 T_m/D_m，能区分在不同截止时间下的相对压力。它并非仅超时任务的平均延误，也不是所有请求共享一个截止阈值。对于同一快照，K 和能耗参照在方法间相同，对每一层乘以正数不会改变字典序排序；但跨快照平均 F_2, F_3 是结果汇总，不能理解为对整个历史一次性求得了字典序最优。

4.3.2 边际目标如何包含批量外部性

对 $i \to j$ 迁移，只有待迁请求以及两节点的原有任务计算负载发生变化。在快照通信固定的条件下，第二分量的精确变化可分解为

$$\Delta F_2 = \frac{1}{K}\left[\frac{\Delta T_m}{D_m} - \sum_{k\in\mathcal{M}_i\setminus\{m\}} \frac{C_k}{F_i D_k} + \sum_{\ell\in\mathcal{M}_j} \frac{C_\ell}{F_j D_\ell} \right], \qquad K > 0. \tag{4.13}$$

第一项是自身变化，后两项分别是来源释放和目标竞争的外部影响。若目的地是 MBS，不存在目标 UAV 均分外部项；若来源原为 MBS，也没有来源 UAV 释放项。实际评价器不依赖人工简化导数，而执行完整仿真模型，但该式帮助解释为何仅计算自身代价一般不等于系统边际代价。

第一分量更加不平滑。对受影响集合 $\mathcal{H} = \{m\} \cup (\mathcal{M}_i \setminus \{m\}) \cup \mathcal{M}_j$，有

$$\Delta F_1 = \sum_{k\in\mathcal{H}} \left(\mathbf{1}[T_k + \Delta T_k > D_k] - \mathbf{1}[T_k > D_k] \right). \tag{4.14}$$

接近截止边界的原有请求，即使只延长很少时间，也可改变超时数；远离边界的请求延长相同时间则不改变第一层。单看目标平均负载或被迁移请求的时延，无法识别这种离散门槛。整体重评估把真实缓存、最终均分和每请求截止时间共同纳入判据。

第三分量由式 (4.9) 结合迁移请求的通信及回源变化，并除以固定参照得到。超时减少，或超时不变但归一化时延降低时，字典序允许接受能耗上升。因此，截止期改善需与分配能耗共同评价。

4.3.3　四种方法保持相同问题与初值

本章比较四个共享候选域和环境评价器的方法，见表 4.2。Heuristic-Control 按参考启发式构造执行目标，其上下文可使用估计缓存和初始来源负载，而完成结果仍按最终批量模型评估。它既提供参考历史，也作为固定快照上的简单对照。方法之间不更换通信模型、截止期、硬候选集合或缓存状态，避免用较有利的物理假设替代算法改进。

表 4.2　四种卸载方法的差异

Table 4.2　Differences among the four offloading methods

方法	初值	改进依据	终止与验证
Heuristic-Control	自身即初值	原启发式规则，不迭代	单次构造
Greedy-Single-Pass	Heuristic-Control	逐请求自身字典序代价	单轮顺序扫描
Iterative-Base	Greedy-Single-Pass	被迁移请求自身代价	自身无改善/环路/预算
MC-ITR	Greedy-Single-Pass	系统整体字典序目标	邻域无改善/预算退出

Greedy-Single-Pass 从启发式结果出发，按 UE 编号升序逐请求扫描候选节点。定义请求自身目标

$$f_m(\mathbf{a}) = \left(\mathbf{1}[T_m(\mathbf{a}) > D_m],\ T_m(\mathbf{a})/\max(D_m, 10^{-9}\,\mathrm{s}),\ E_m^{\mathrm{assign}}(\mathbf{a})/(25000\,\mathrm{J})\right). \quad (4.15)$$

每次只选 f_m 严格下降的目标并固定选择，完成一轮后不回看前面请求。各请求结果来自完整批量评价，所以它能知道自身在当前负载下的完成代价；它忽略的是评价产生的其他请求变化，而不是完全不使用共享算力模型。严格改善之外的平局保持当前选择。

Iterative-Base 从共同贪心分配出发，枚举自身代价严格改善的单请求迁移，按自身差值元组、请求编号和目标编号择优。自身改善仍可能使整批目标变差，算法通过已访问分配检测环路，并按无自身改善、环路或轮数预算终止。

MC-ITR 同样从贪心初值出发，以 $F(\mathbf{a})$ 的完整变化作判据，使比较集中于自身代价与整体代价的选择差异。两种搜索可能到达不同终点；MC-ITR 的严格

下降性质相对于自身初值成立，其与其他方法的性能差异由实验评价。

4.4 MC-ITR 搜索过程与可证性质

4.4.1 完整单请求迁移邻域

对当前分配 $\mathbf{a}$，定义改变一个请求执行目标的邻域

$$\mathcal{N}_1(\mathbf{a}) = \{\mathbf{a}^{m\to c} : m \in \mathcal{M},\ c \in C_m \setminus \{a_m\}\}, \tag{4.16}$$

其中 $\mathbf{a}^{m\to c}$ 仅把第 m 个分量替换为 c。MC-ITR 每轮完整扫描该邻域，选择所有严格改善选项中系统目标最小的一个，平局按请求序号、目标编号确定。它是最佳改善搜索，区别于发现第一项改善就立即执行的首次改善策略。

每项候选均从独立快照副本评价，缓存、随机状态和统计量保持相同初值。选定迁移后再次评价，核对目标元组与扫描结果一致且严格改善；若复核失败则停止并报告错误。该过程使接受规则与固定状态下的确定评价一致。

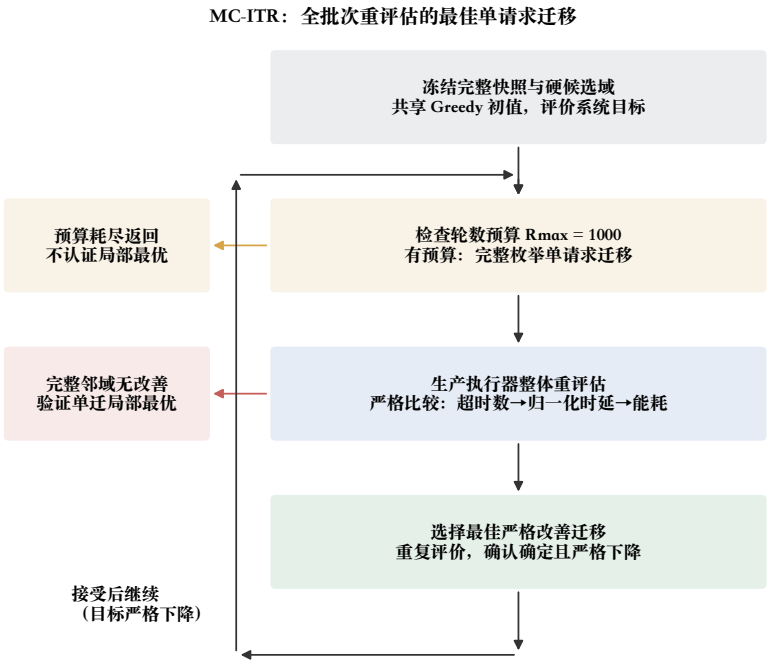


图 4.2 MC-ITR 算法流程。两个出口对应不同结论强度：无改善退出时可验证单请求迁移邻域局部最优；预算退出时不作此声称

Figure 4.2 Flowchart of MC-ITR with two distinct exits

算法 4.1　MC-ITR：全批次重评估的最佳单请求迁移搜索

Input: 固定快照、候选域 $\{C_m\}$、共同贪心初值 $\mathbf{a}^0$、轮数预算 $R_{\max} = 1000$
Output: 分配、目标、终止原因与局部最优验证标记

$\mathbf{a} \leftarrow \mathbf{a}^0$，$\mathbf{v} \leftarrow F(\mathbf{a})$;
for $r \leftarrow 1$ **to** $R_{\max}$ **do**
　best $\leftarrow \varnothing$;
　foreach $m \in \mathcal{M}$, $c \in C_m \setminus \{a_m\}$ **do**
　　从原快照评价 $\mathbf{v}' = F(\mathbf{a}^{m\to c})$;
　　if $\mathbf{v}' <_{\text{lex}} \mathbf{v}$ **then**
　　　用键 $(\mathbf{v}', m, c)$ 更新严格改善中的最优候选;
　　end
　end
　if best $= \varnothing$ **then**
　　return 当前分配，原因“邻域无改善”，验证标记为真;
　end
　重新评价最佳分配，检查元组相同且严格改善;
　接受最佳迁移并更新 $\mathbf{a}, \mathbf{v}$;
end
return 当前分配，原因“轮数预算”，验证标记为假;

4.4.2　严格下降、有限终止及初值保证

① 命题一：每项接受迁移使系统字典序目标严格下降。

算法仅把满足 $F(\mathbf{a}') <_{\text{lex}} F(\mathbf{a})$ 且复核通过的候选写入当前解，因此接受后的目标严格更小。设第 r 次接受后的分配为 $\mathbf{a}^r$，则

$$F(\mathbf{a}^{r+1}) <_{\text{lex}} F(\mathbf{a}^r), \qquad F(\mathbf{a}^r) \leqslant_{\text{lex}} F(\mathbf{a}^0). \tag{4.17}$$

第一层为整数超时数，所以它不会在接受过程中增加；它不变时第二层必须下降或不变，前两层都不变时第三层下降。这是按层级的保证，不是三分量各自始终单调下降。

② 命题二：无预算限制且评价确定时，搜索在有限次接受后终止。

每请求候选集合有限且非空，$\mathcal{A}$ 因而有限。若某个分配重复访问，确定评价会给出相同目标；但由严格下降链的传递性，后一次目标必须比前一次更小，产生矛盾。所以接受的分配不重复，最多接受 $|\mathcal{A}| - 1$ 次迁移，随后必然无严格改善邻居。该上界可能很大，仅用于证明有限性，不能解释为实际运行高效。

有限 $R_{\max}$ 使算法在预算内返回。无改善出口经过当前状态的完整邻域检查，可认证局部最优；预算出口只表示搜索停止。特别地，$R_{\max} = 0$ 时仅评价初值，局部最优标记保持未验证。

③ 命题三：无改善出口认证单请求邻域的弱局部最优。

在某轮完成全部候选评价且未发现严格改善时，返回解 $\mathbf{a}^*$ 满足

$$F(\mathbf{a}^*) \leqslant_{\text{lex}} F(\mathbf{a}'), \qquad \forall \mathbf{a}' \in \mathcal{N}_1(\mathbf{a}^*). \tag{4.18}$$

证明来自完整枚举与无改善条件。允许邻居具有完全相同目标，因此是不存在严格更优邻居的局部最优，而非唯一最优。该命题依赖候选域完整、评价确定、没有提前截断邻域，以及终止原因为无改善；触发轮数上限时不适用。

式 (4.17) 保证 MC-ITR 相对于自身贪心初值非劣。Heuristic-Control 和 Iterative-Base 具有不同的初始处理或搜索判据，终点之间的相对表现需在共同快照上比较。

4.4.3 局部最优为何仍可不同于全局最优

一个最小离散例子说明单请求邻域的局限。设两个请求各有两个执行编号 $0, 1$，构造目标如表 4.3。初始 $(0, 0)$ 的超时数为一，两个单迁邻居 $(0, 1), (1, 0)$ 的超时数均为二，故搜索没有可接受单迁；但同时改动两项到 $(1, 1)$ 可令超时数为零。该表是搜索性质的抽象构造，非实际系统某个快照的测量。

表 4.3 单请求局部最优不蕴含全局最优的离散构造

Table 4.3 Discrete construction separating one-request local and global optima

分配	$(0, 0)$	$(0, 1)$	$(1, 0)$	$(1, 1)$
构造字典序目标	$(1, 1.00, 1)$	$(2, 1.20, 1)$	$(2, 1.20, 1)$	$(0, 0.80, 1)$
初始解邻域关系	初值	单请求迁移	单请求迁移	两请求联合迁移

需要多请求协同调整才能改善的分配可能成为单迁搜索的局部停点。批量问题包含来源释放、目标竞争及缓存路径变化，当前问题未具备使局部最优等于全局最优的结构条件。扩展交换或多迁邻域可探索其他解，但会增加评价成本。本章研究现有单请求迁移邻域。

4.4.4 评价量、复杂度与实际调用开销

令平均候选数为 $\bar{c} = K^{-1} \sum_m |C_m|$。每轮不同单请求迁移数为

$$H = \sum_m (|C_m| - 1) = K(\bar{c} - 1). \tag{4.19}$$

主配置中每请求至多本地、MBS 和另外四架 UAV，共六种硬候选，故 $H \leqslant 5K$。这说明单轮候选数随活跃请求数线性增加，不说明整个算法耗时线性，因为每候选评价要处理完整批次和环境状态，接受轮数也依赖问题实例。

若实际扫描 R 轮、接受 r_{acc} 项迁移，搜索核心评价量为

$$Q_{\mathrm{eval}} = 1 + RH + r_{\mathrm{acc}}, \qquad 0 \leqslant r_{\mathrm{acc}} \leqslant R \leqslant R_{\max}. \tag{4.20}$$

起始的一次为初值目标，每轮完整邻域贡献 H 次，每项接受迁移再贡献一次确定性复核。无改善出口一般还含最后一轮的完整扫描，不能把接受次数当作扫描轮数。该式描述搜索函数本身，不包括共享初值构造及结果打包所需的额外调用。

设一次完整环境评价成本为 C_{eval}，则主要时间复杂度为 $O(RK(\bar{c}-1)C_{\mathrm{eval}})$。$C_{\mathrm{eval}}$ 包含私有环境重建、解析全批目标、服务与其他请求处理及指标计算，随总用户数和数据结构规模变化，不可直接视为单位常数时间的单请求代价。空间包括快照、候选域和搜索轨迹；穷举解空间虽然用于有限性证明，但 MC-ITR 不需要把全部分配同时存储。

四种方法的实测时间包含各自评价路径：自身代价基线复用有限容量的候选缓存，MC-ITR 则进行未缓存的完整扫描和复核。两个迭代方法的搜索计时均不含共同贪心初始化。因此，时间比较反映当前实现与测量条件下的调用成本。

4.5　Exact-Small 与反事实评价协议

4.5.1　完整穷举参照的定义

Exact-Small 在完整 $\mathcal{A}$ 上穷举，每个分配交给相同环境评价器，取字典序最小目标，平局按分配向量编号确定。由于枚举了所有硬可行分配，只要空间大小不超过事先预算、所有评价有效且枚举完成，便可认证该固定快照的全局最优：

$$\mathbf{a}^{\mathrm{ex}} \in \arg\min_{\mathbf{a}\in\mathcal{A}}{}_{\mathrm{lex}} \; F(\mathbf{a}). \tag{4.21}$$

冻结实验计划的枚举预算为 10^4 个分配。空间超过预算时，在评价前标记跳过，不从已枚举的子集结果宣称精确完成。通用函数默认预算与实验覆盖值可能不同，正文以实际冻结运行计划为准。

穷举时间为 $O(|\mathcal{A}|C_{\mathrm{eval}})$，候选数乘积使大批次难以使用。三 UE 配置从整个环境规模上定义小问题，而不是从一百 UE 快照中删掉大多数任务。后者会改变最终均分 N_j、接入关联数及请求间外部性，剩余任务的目标已不同，不能作为原大问题的精确验证。Exact-Small 的作用是核验小规模实现与比较逻辑，不证明大问题搜索没有全局差距。

4.5.2 快照冻结与无副作用执行

快照保存完整环境状态、请求索引、来源映射、硬候选域及配置。请求按 UE 编号升序搜索，再按来源距离与用户编号映射回执行槽位。候选评价使用相同 CPU、带宽和接纳规则，并由私有环境副本隔离可变缓存和统计量。

评价时从序列化快照重建私有环境，注入显式卸载分配，采用统一固定移动动作，执行一个仿真环境步。为了保留当前请求记录，评价器阻止该私有步末的新请求覆盖，但当前请求处理、缓存提交及其他私有更新仍按仿真路径进行。它们的结果只用于该候选，不回写参考历史，也不传给下一候选。执行中如果发生卸载回退，评价器拒绝把它当作原目标分配的有效结果。

分配能耗由环境执行记录累计。先解析全部目标并确定节点最终负载，再逐个处理请求，使候选评价包含完整批量外部性。本文据此使用统一通信和计算模型生成所有方法的实验结果。

4.5.3 评价的确定性与实现一致性

实现检查覆盖相同分配的重复评价、候选集合非空、动作合法性和目标有限性。迭代方法共享贪心初值，MC-ITR 的接受目标严格下降；局部最优标记对应完整邻域无改善，精确参照对应预算内完成的穷举。

4.6 实验设计、主结果与代价解释

4.6.1 410 个评估单元的组成

主配置为五 UAV、一百 UE。负载敏感性使用六十、八十、一百二十、一百四十 UE，算力敏感性使用主配置 UAV 算力的 $0.6, 0.8, 1.2, 1.4$ 倍，其他协议保持对应冻结设置；再加三 UE Exact-Small，共十种配置。每配置十个工作负载，每工作负载六回合，每回合在 $0, 100, \cdots, 900$ 步采集十快照，因而每配置六百快照，总计六千快照。

九个正常规模配置各比较四个方法，构成 $9 \times 10 \times 4 = 360$ 个“配置–工作负载–方法”单元；Exact-Small 配置包含第五个穷举方法，构成 $1 \times 10 \times 5 = 50$ 单元，两部分合计四百一十。该计数说明评估完整性，不把同快照重复评价的四或五个方法当作独立状态。空接纳快照保留，其目标为零，反映自然覆盖参考历史中确实可能没有待卸载服务。

对每个工作负载种子，先求其六十个快照的指标平均，再在十个工作负载之间比较。主要指标为每快照平均超时数、平均 F_2、平均归一化分配能耗和平均

搜索耗时。对于方法 c 和参照 b，设种子 w 的快照平均差为

$$d_w = \frac{1}{60}\sum_{h=1}^{60}\left(Y_{c,w,h} - Y_{b,w,h}\right), \qquad \bar{d} = \frac{1}{10}\sum_{w=1}^{10} d_w. \tag{4.22}$$

置信区间以十个配对工作负载单元进行五千次 bootstrap。相邻快照共享参考历史，回合与请求嵌套于工作负载，因此重采样在工作负载层进行。

本章不训练新模型，独立统计单位为工作负载种子。敏感性配置各自采样参考历史并重新求解，评价对应环境中的快照求解器表现。

4.6.2　主配置的截止期优势

表 4.4 与图 4.3 给出一百 UE 主配置结果。MC-ITR 每快照平均超时数为 2.055，低于 Iterative-Base 的 2.228、Greedy-Single-Pass 的 2.243 和 Heuristic-Control 的 2.908。共同贪心初值之后的整体重评估，因而在该批次取得了更好的第一优先级结果。相对迭代基线的 0.173 个请求差值约为其平均超时数的 7.8%；这一相对量由表中均值计算，不表示所有快照都减少相同比例。

表 4.4　固定快照主配置的卸载方法比较（十个工作负载种子均值）

Table 4.4　Offloading methods on the fixed-snapshot main setting

方法	每快照平均超时数 ↓	归一化分配能耗	搜索耗时/s
Heuristic-Control	2.908	1.278	0.103
Greedy-Single-Pass	2.243	1.814	0.941
Iterative-Base	2.228	1.872	1.970
MC-ITR	2.055	2.128	2.574

MC-ITR 相对 Iterative-Base 的平均超时差为 -0.173，95% bootstrap 区间为 $[-0.217, -0.127]$，十个工作负载均为负；相对 Greedy-Single-Pass 的差值为 -0.188，区间 $[-0.233, -0.137]$；相对 Heuristic-Control 为 -0.853，区间 $[-1.068, -0.643]$。图 4.4 显示共同快照上的配对方向与区间，支持 MC-ITR 改善每快照的平均截止期表现。

整体判据允许接受释放其他紧迫请求算力的迁移，并拒绝使整批超时数增加的自身改善。这与前文外部性推导和构造例相符。汇总结果评价完整算法的平均效果，各类迁移对改善量的贡献尚未单独统计。

4.6.3　第二、第三目标的联合报告

MC-ITR 相对 Iterative-Base 的归一化时延差为 $+0.0004$，区间 $[-0.0019, +0.0031]$ 跨零，该批次未确认其平均变化方向。字典序目标允许

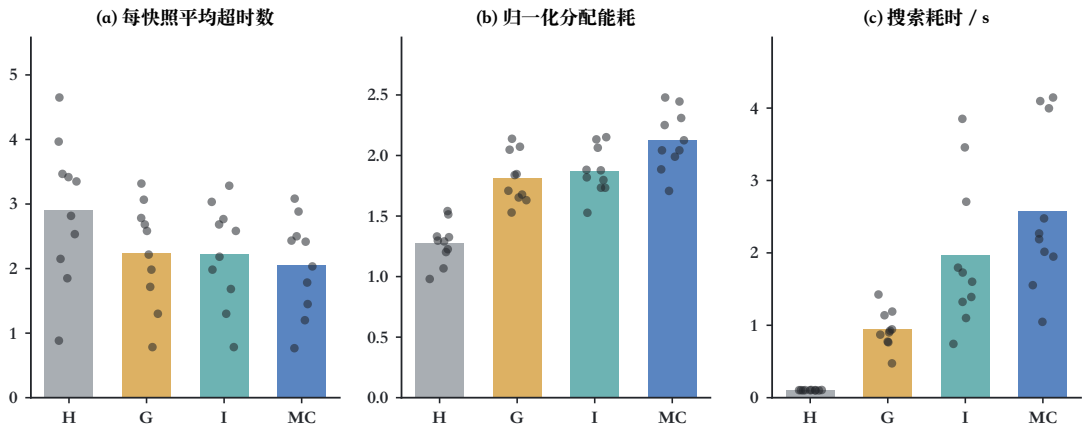


图 4.3　固定快照主配置下四种卸载方法的超时数、分配能耗与搜索耗时（柱为十个工作负载种子均值，散点为逐种子值）

Figure 4.3　Deadline misses, assignment energy and solver time of the four methods on the main setting

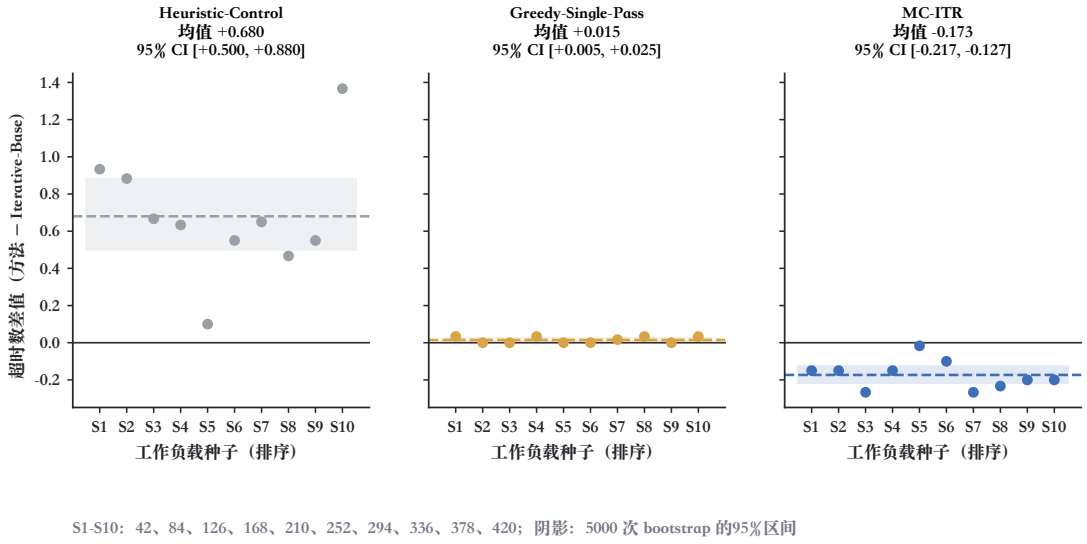


图 4.4　各方法相对 Iterative-Base 的每快照超时数配对差值（十个工作负载种子；区间为 5000 次重抽样的 95% bootstrap 区间）。散点、均值虚线与阴影区间描述该固定快照批次中的工作负载配对差异

Figure 4.4　Paired per-snapshot deadline-miss differences against Iterative-Base

通过第二分量上升换取第一分量改善，因此减少超时与时延代价需分别报告。

MC-ITR 归一化分配能耗为 2.128，高于 Iterative-Base 的 1.872，差值 +0.256，区间 [+0.214, +0.298]。按固定能量参照换算，每快照平均增加约 6400 J，约为对照均值的 13.7%。该统计覆盖分配相关能耗，不含共同输入接收和机动等项。

截止期优先可能将任务安排到成本较高但及时的路径，也可能通过释放节点负载增加其剩余请求的计算份额，从而提高计算能耗。实验呈现了这种质量–能耗权衡：平均超时数减少，同时分配能耗上升。

4.6.4　搜索时间与在线预算

MC-ITR 平均搜索耗时为 2.574 s，Iterative-Base 为 1.970 s，Greedy-Single-Pass 为 0.941 s，Heuristic-Control 为 0.103 s。两种迭代方法均不计共同贪心初始化；含初始化的完整路径另在学习轨迹快照实验中测量。

仿真时隙为一秒，快照评价的求解耗时未计入请求时延 T_m，因此上述结果提供离线分配质量参照。面向在线执行，需要将求解、信息收集和下发延迟纳入服务流程，或另行评价有限预算的近似方法。第五章研究具有明确调用预算的在线下层。

4.7　敏感性、精确检查与搜索完成情况

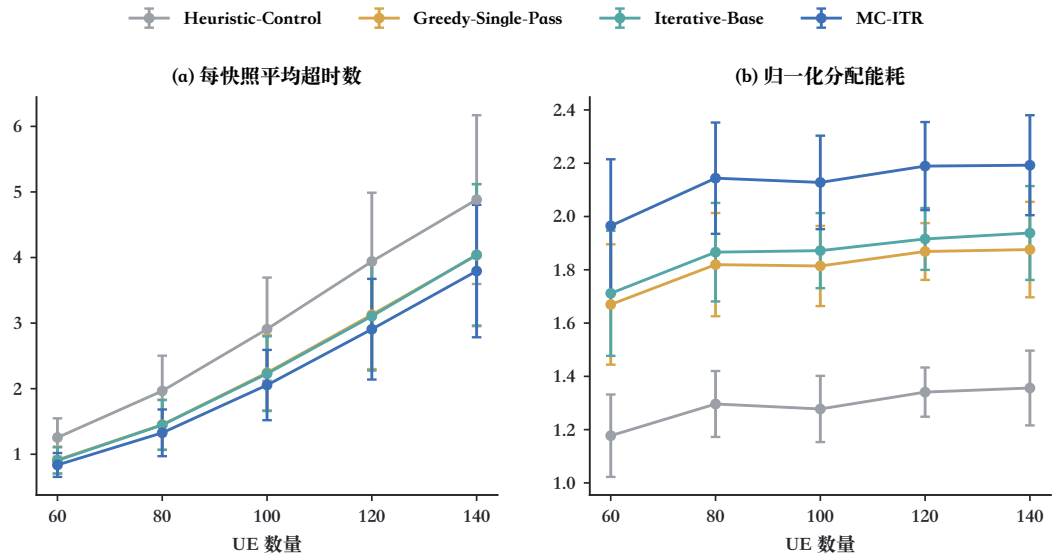
4.7.1　负载与算力变化

图 4.5、图 4.6 与表 4.5 展示一个主配置及八个敏感性配置。九种配置中，MC-ITR 相对 Iterative-Base 的超时差区间均低于零，逐配置比较支持所测负载与算力范围内的一致改善方向。

UE 数从六十增加到一百四十时，平均超时差依次为 $-0.068, -0.120, -0.173, -0.198, -0.248$。主系统有限覆盖和计算资源面对更高人口，可能出现更多活跃服务竞争与截止门槛，因此整体重评估的绝对余量增加与模型预期相容。不过，UE 总数不直接等于每快照接纳请求数，快照难度也随参考轨迹和请求类型改变；不能仅据这一序列证明改善幅度严格由人口单一因素决定。

算力为 0.6 倍时超时差为 -0.268，0.8 倍为 -0.200，标准为 -0.173，1.2 倍为 -0.157，1.4 倍为 -0.148。较低算力增加计算时间与迁移外部变化 C_m/F_j，使更多请求接近截止门槛；较高算力减轻竞争。该结果显示固定快照分配改善在所测试算力点上保持负向超时差。

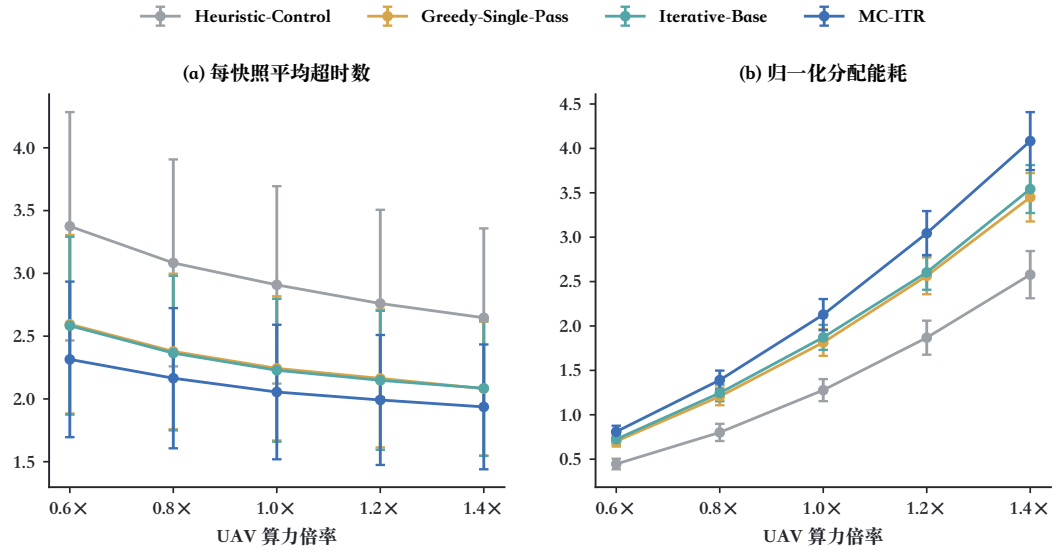
算力变化同时影响时延与能耗。式 (4.5) 中固定负载的能耗与算力平方正相



误差线：10 个工作负载种子的逐项 95% t 区间（非同时覆盖）
每个设置独立采集快照并求解

图 4.5　UE 数量变化下四种方法的超时数与分配能耗（误差线为十个工作负载种子的逐项 95% t 区间，非同时覆盖）

Figure 4.5　Sensitivity to the UE count



误差线：10 个工作负载种子的逐项 95% t 区间（非同时覆盖）
每个设置独立采集快照并求解

图 4.6　UAV 算力倍率变化下四种方法的超时数与分配能耗（误差线口径同图 4.5）

Figure 4.6　Sensitivity to the UAV compute capacity scale

表 4.5　各变体配置中 MC-ITR 相对 Iterative-Base 的每快照超时数差值

Table 4.5　Paired deadline-miss difference (MC-ITR minus Iterative-Base) across variants

变体	超时数差值 [95% 区间]	MC-ITR 搜索耗时/s
主配置（100 UE，标准算力）	−0.173 [−0.217,−0.127]	2.574
UE 60	−0.068 [−0.097,−0.042]	0.747
UE 80	−0.120 [−0.147,−0.092]	1.416
UE 120	−0.198 [−0.255,−0.142]	4.092
UE 140	−0.248 [−0.312,−0.183]	5.793
算力 0.6 倍	−0.268 [−0.348,−0.193]	2.744
算力 0.8 倍	−0.200 [−0.252,−0.147]	2.475
算力 1.2 倍	−0.157 [−0.207,−0.108]	2.599
算力 1.4 倍	−0.148 [−0.205,−0.102]	2.557

关，而时延与算力反比；不同方法又会改变节点负载。因而曲线中的能耗趋势不是简单的“算力越大越省电”。统一功率模型和任务集合下的比较反映了服务质量与能耗之间的权衡。

4.7.2　Exact-Small 的结果与问题规模

三 UE 验证配置包含六百快照，其中五百一十三为空，八十三有单请求，四个有双请求，空快照比例 85.5%。图 4.7 展示这一分布以及方法的三个目标均值。小规模枚举器在完整硬可行域完成穷举，MC-ITR 的平均超时数 0.025、归一化时延 0.0608、归一化分配能耗 0.1542 与精确参照逐项相同；Greedy 与 Iterative 的对应均值也相同。

空快照的所有方法目标天然为 $(0,0,0)$，所以大量空状态会稀释非空差异。单请求快照没有同节点其他服务的批量外部性，最佳自身选择与全局选择接近同一个问题；仅四个双请求快照才可能体现更复杂的耦合。由此，该配置对评价和比较逻辑有价值，却不具备区分高维搜索能力的充分难度。均值相同也应与逐快照完成标记和精确比较记录结合，不能只看保留四位小数的柱图就推断每个解向量完全相同。

相同最优目标可以对应不同分配，确定性平局规则不同也会产生不同解向量。因此，小规模精确参照比较目标值与硬可行性，用于检查评价和搜索逻辑的一致性；主配置的求解质量仍由其自身实验评价。

MC-ITR 在此配置平均求解时间为 8.2 ms，穷举为 5.2 ms。当非空空间极小，完整邻域扫描、接受复核和框架调用可比直接枚举更费时，局部搜索不必在最小

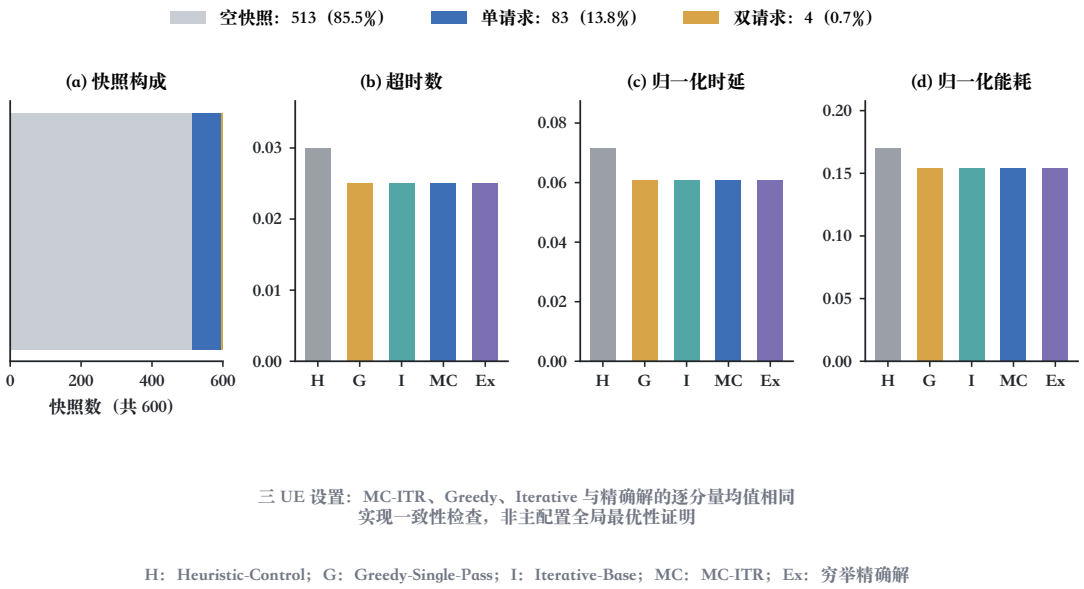


图 4.7　Exact-Small 配置的快照构成与各方法逐分量均值。(a) 600 个快照的构成；(b)-(d) 三 UE 小规模下 MC-ITR、Greedy、Iterative 与穷举精确解的逐分量均值相同，仅 Heuristic-Control 存在差距

Figure 4.7　Snapshot composition and per-component means on the Exact-Small setting

问题上最快。两者相同量级也不能外推大问题，穷举的分配空间随请求数呈乘积增长，只有明确空间预算下的完成才具备精确意义。

4.7.3　搜索完成标记与规模代价

十种配置的 MC-ITR 邻域局部最优验证比例均为 100%，本批次没有轮数预算退出。每个快照均经完整邻域检查后从无改善出口返回，满足命题三的条件。更大请求规模下预算是否充分，仍取决于邻域大小与改善轮数。

平均搜索时间在六十 UE 时为 0.747 s，八十 UE 时为 1.416 s，主配置为 2.574 s，一百二十 UE 时为 4.092 s，一百四十 UE 时为 5.793 s。实测时间随规模上升，活跃请求、候选数量、改善轮数和环境评价成本共同影响这一变化。

实际时间包含整体评价、确定性复核、基线缓存复用与环境复制等环节。分阶段计时和候选复用率可进一步确定实现瓶颈。本批次完整邻域搜索验证了局部最优条件，秒级计算开销则限制了其在当前时隙中的在线使用。

4.8　学习轨迹下的快照分配比较与本章小结

4.8.1　桥接设计与来源限定

为检验学习轨迹上的批量分配余量，采用需求感知 Attention-MAPPO 上层与无注意力请求级 MAPPO 下层产生的轨迹，从十个训练种子和五个工作负载的五

十个在线评估任务中采集四百个快照。在相同状态上比较在线下层与 MC-ITR，反事实分配不回写环境。该轨迹策略用于本节受控比较，第五章另行评价配额匹配下层组成的 SF-HLM。

补充实验改变快照采样的轨迹来源，保持候选之间的请求、缓存与最终负载模型一致，评价学习策略经过的状态中是否存在分配改善空间。反事实结果仅用于同状态比较，长期服务表现则需要闭环运行评价。

4.8.2　质量余量与完整调用时间

图 4.8 中，MC-ITR 每快照平均超时数为 8.235，在线下层为 10.695，配对差 −2.460；训练种子配对 t 的 95% 区间为 $[-2.707, -2.213]$，十个种子均为负。归一化分配能耗分别为 2.519 和 2.035，MC-ITR 约高 23.8%。学习轨迹上的固定状态比较同样显示截止期质量余量及相应能耗代价。

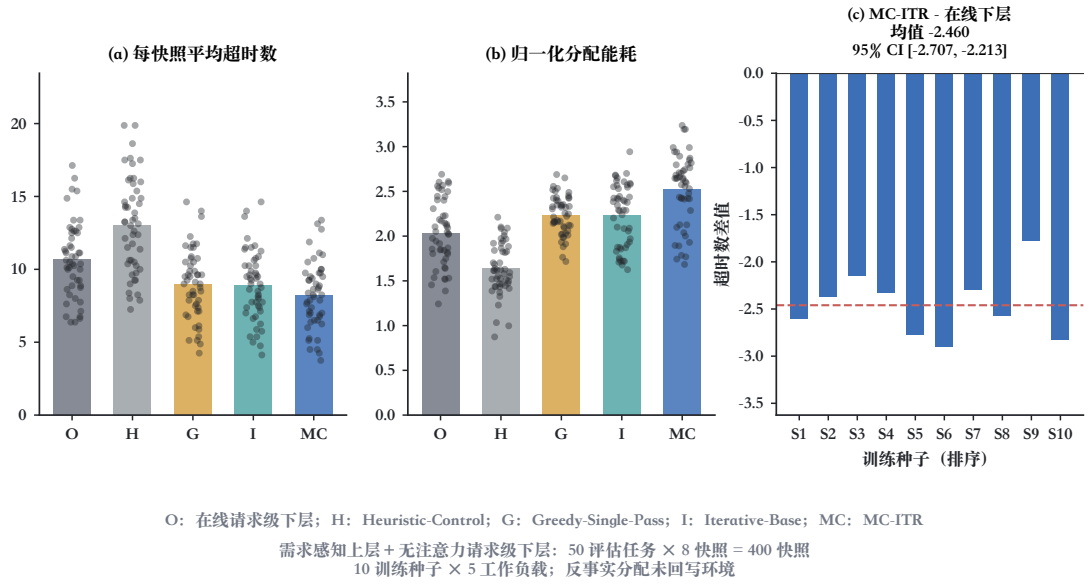


图 4.8　需求感知轨迹策略下的固定快照分配比较（400 个快照；反事实分配不回写环境）
Figure 4.8　Fixed-snapshot allocation comparison along demand-aware policy trajectories; counterfactual assignments do not alter the environment

含贪心初值的 MC-ITR 完整调用平均为 20.751 s，在线下层约为 0.012 s。本节采用学习轨迹状态且计入初始化，与主实验 2.574 s 的搜索计时具有不同输入和测量范围。该对照揭示完整离线搜索与在线推断之间的质量–计算权衡。

本节先在每个训练种子内汇总五个工作负载，再以十个训练种子进行配对分析；主快照实验则以十个工作负载种子作为独立单位。两批实验按各自设计分别报告，四百快照和五十评估任务均属于训练结果内的嵌套评价。

4.8.3 本章结论与后续在线方法的关系

本章以固定历史状态为条件，建立了机载批量算力均分下的截止期优先计算任务分配问题。跨机迁移外部性推导说明，自身请求改善与集群整批目标改善一般不同；MC-ITR 因而完整枚举单请求迁移，并用环境执行模型重评估系统字典序目标。在评价确定、候选完整且无预算退出时，算法有限终止并认证单请求邻域局部最优；该性质不蕴含主配置全局最优。

四百一十个评估单元显示，MC-ITR 在主配置及八个敏感性配置中减少平均超时请求，同时增加分配能耗并付出秒级搜索代价。Exact-Small 提供小规模一致性检查，学习轨迹快照比较进一步显示已接纳请求的分配余量。第五章结合固定需求感知上层与有限预算配额匹配下层，评价长期闭环服务和在线计算开销。

第 5 章　无人机集群协同轨迹与计算任务分配的分层决策

5.1　研究问题与方法总体设计

5.1.1　从覆盖接纳到批量服务质量

第三章研究需求感知轨迹对服务接纳的作用，第四章分析已接纳请求中的跨机批量算力竞争。本章将空间部署与任务执行连接为在线闭环，研究有限计算预算下的跨节点分配。为此，本文提出面向可服务覆盖的分层学习与负载匹配方法，记为 SF-HLM。上层采用需求感知 Attention-MAPPO，下层通过请求–节点二部图学习配额迁移，并在给定配额下求解条件匹配。训练时保持上层参数固定，独立优化配额策略；独立确认评价该完整方法的端到端服务效果。

这一区分对应两个相互联系但不同的困难。第一，未进入物理服务范围的请求无法由卸载算法补救，轨迹策略必须及时感知未接纳需求。第二，进入服务范围并不意味着请求一定能按时完成；一个节点接收更多任务会摊薄每个任务的算力，迁移一个任务还会影响迁入与迁出节点上其他任务。若每个请求仅按自身当前预测时延独立选择节点，最终形成的批量负载可能与选择时的局部预测不一致。因而，本章并不把覆盖量最大化直接等同于端到端服务优化，而是把覆盖形成的请求集合与该集合的负载组织一起考察。

设一段评估过程实际生成 G 个服务请求，其中 A 个被自然覆盖接纳，S 个按时完成。其端到端截止期满足率仍按第三章的定义计算：

$$\mathrm{DSR} = \frac{S}{G} = \frac{A}{G}\frac{S}{A}. \tag{5.1}$$

式 (5.1) 给出方法设计的直接依据：上层负责形成服务机会，下层负责利用服务机会。上层观测范围为 460 m，物理接纳半径保持 100 m；扩大观测没有放宽物理服务范围。下层也不通过删除困难请求提高指标，所有已接纳请求都必须分配到质量掩码允许的执行目标，未接纳或超时请求均保留在 DSR 的统计中。

5.1.2　方法组成与信息流

图 5.1 展示无人机集群的分层在线结构。五架 UAV 的轨迹决策仍由 Attention-MAPPO 实现，各 Actor 根据所供给的局部需求与邻机观测准备二维动作；训练共同基座后，上层参数在下层训练、独立确认和冻结策略复验期间保持不变。下层协调器集中收集当前已接纳请求的允许目标及预测信息，先以共同贪心和普通修复生成合法保底，再由图策略网络选择节点间的整数配额迁移，最后在给定配额下求解条件匹配。该结构以分散轨迹推断组织机群空间部署，以

集中批量调度组织计算任务分工，两类决策共同影响服务过程。

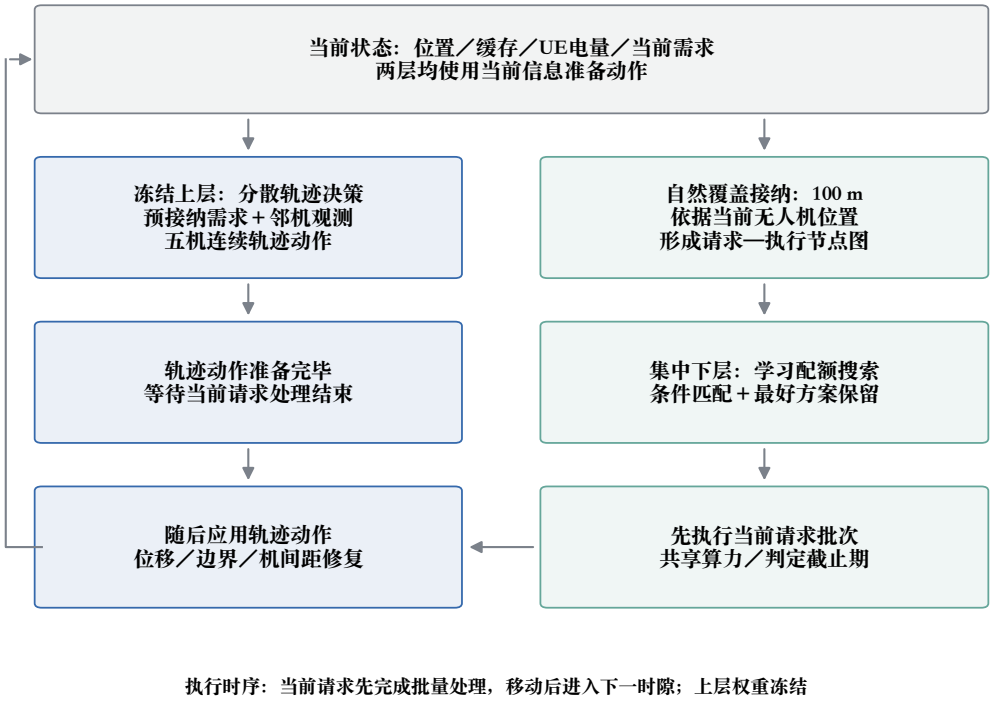


图 5.1　无人机集群 SF-HLM 分层架构与移动前决策时序。冻结上层按局部需求及邻机观测准备轨迹动作，下层集中分配已接纳计算任务；当前批次先依据当前几何评价，随后应用轨迹动作形成下一步位置

Figure 5.1　Hierarchical SF-HLM architecture for UAV swarm services: decentralized frozen trajectory inference and centralized task allocation, with batch service evaluation before movement

本章方法的接口由三个对象组成：请求行、配额向量和分配向量。请求行包含请求标识、源 UAV、截止时间、输入字节数、所需 CPU 周期，以及每个允许执行目标的时延与能耗预测量。配额向量记录六个执行节点最终接收的请求数量；分配向量则为每个请求给出一个允许动作。两种表示不能互相替代：相同配额可以对应许多不同分配，而相同节点数量只有在进一步决定哪些请求进入该节点后才能计算准确的批量目标。SF-HLM 的核心是先学习如何调整配额，再对该配额下的具体请求分配进行条件求解。

集中协调器使用移动前位置、当前请求和源节点可获得的缓存信息。源 UAV 读取自身缓存，并通过邻机缓存信念预测协作路径；搜索阶段只评价观测预测模型。确定分配后，环境按第三章的批次规则评价路径时延与能耗，再更新位置、缓存和电量。下文的环境执行值区别于搜索预测值，均为仿真记录；超过决策步长的任务不作为未完成队列进入下一批次。

5.1.3　空间部署与计算分工的协同关系

两层分解对应不同的决策对象。轨迹层改变五架无人机的未来服务位置，进而改变后续可接纳请求、邻机关系及链路；任务层在当前已经形成的接纳集合中选择计算执行节点，进而改变各机批量负载、缓存与能耗。一次地面请求在空间上由来源 UAV 接纳，在计算上可以由另一架 UAV 执行，因此“谁覆盖需求”与“谁执行任务”相互联系但不要求相同。MBS 是既有系统中的地面计算支撑，其使用量属于集群协作结果需要同时报告的资源指标。

协同通过环境状态反馈形成。先训练需求感知轨迹基座，再保持上层参数固定，训练并评价配额匹配下层。不同卸载改变后续缓存、能量和观测，固定上层也会据此产生不同轨迹。实验分别评价完整框架、学习搜索增量、MBS 使用及软件开销，刻画服务收益与资源代价。

表 5.1　SF-HLM 的在线决策设置

Table 5.1　Online decision settings of SF-HLM

环节	固定定义
上层	覆盖需求 Attention-MAPPO；五个二维动作；最终确认期间参数冻结
请求接纳	100 m 自然覆盖；未接纳请求计入实际生成服务请求分母
执行节点	五个 UAV 与一个 MBS；任务不可拆分；MBS 不按批量任务数共享算力
共同保底	逐请求贪心初始化，至多 128 次普通修复候选评价
配额搜索	STOP 或节点间转移 1/2/4 个请求；共 91 个动作
条件匹配	包含初始匹配在内至多 16 次；固定配额下优化预测超时数与分配能耗
能耗筛选	同状态原始贪心预测分配能耗的 1.05 倍；搜索后筛选
策略网络	两层、宽度 128 的请求–节点二部图 MLP 消息传递
参数学习	5 轮教师监督预训练；100 次 PPO 更新，每次 32 图、8 轮更新

5.1.4　本章研究假设与验证层级

方法验证分为完整下层优化包、共享强框架上的学习增量和冻结策略跨场景表现三个层级。完整下层优化包包括贪心、修复、能耗筛选、配额搜索、条件匹配和最好方案保留；其比较对象是同上层的逐请求随机卸载以及已有学习下层。学习增量则要求启发式和随机对照也使用相同初始化、匹配器、普通修复、能耗参照与调用上限，只改变配额动作选择方式。跨场景表现进一步检验已确

认权重在 UE 数量和 UAV 算力变化后是否仍能工作。这三个问题使用不同对照，避免用容易战胜的随机策略代替严格的机制验证。

5.2 移动前请求建模与负载相关预测

5.2.1 请求集合、执行节点与质量掩码

在时隙 t，令已接纳服务请求集合为 $\mathcal{R}_t$，其规模为 R_t。为简化记号，本节省略 t。执行节点集合记作 $\mathcal{J} = \{0, 1, \cdots, 4, 5\}$，前五个编号对应 UAV，编号 5 对应 MBS。请求 m 具有输入大小 L_m、单位字节 CPU 周期数 ω_m、总计算周期 $C_m = \omega_m L_m$ 和截止时间 $D_m > 0$。服务类型索引记为 σ_m，其源 UAV 记作 u_m，允许执行节点集合记为 $\mathcal{J}_m \subseteq \mathcal{J}$。

允许集合由已有质量感知掩码生成，包含当前环境允许的本地、MBS 或协作动作。协调器将源 UAV 的动作编号映射为全局执行节点编号，以统一来自不同源节点的请求：源节点的动作 0 表示本地，而在全局表示中本地对应 u_m；动作 1 对应 MBS；协作动作对应目标 UAV 的全局编号。若不先完成这一步，来自不同 UAV 的两个“本地动作”可能被误计为同一节点，从而破坏配额守恒和算力共享计算。

请求按 UE 标识排序，各对照在相同状态下使用一致的输入顺序。所有已接纳请求均建立允许目标并参与分配；空批次直接返回空分配、零匹配调用及上层轨迹动作。

令 $x_{mj} \in \{0, 1\}$ 表示请求 m 是否被分配给节点 j。合法分配需满足

$$\sum_{j \in \mathcal{J}_m} x_{mj} = 1, \qquad x_{mj} = 0 \quad (j \notin \mathcal{J}_m), \qquad N_j = \sum_{m \in \mathcal{R}} x_{mj}. \tag{5.2}$$

其中 N_j 是节点的最终配额。式 (5.2) 同时表达不可拆分与完整分配：一个请求只能选择一个节点，每个已接纳请求都有去向。质量掩码限制允许目标，但并不保证最终共享负载下全部请求按时完成，这正是后续优化仍有必要的原因。

5.2.2 通信路径与预测量的分离

设请求 m 到其源 UAV 的上传速率为 R_m^{up}，源到目标 UAV j 的速率为 $R_{u_m,j}$，目标 j 到 MBS 的回传速率为 R_j^{bh}。字节到比特的转换必须显式保留：

$$T_m^{\mathrm{up}} = \frac{8L_m}{R_m^{\mathrm{up}}}, \qquad T_{mj}^{\mathrm{hop}} = \frac{8L_m}{R_{u_m,j}}, \qquad T_{mj}^{\mathrm{fetch}} = (1 - p_{mj}) \frac{8B_{\sigma_m}}{R_j^{\mathrm{bh}}}. \tag{5.3}$$

B_{σ_m} 是服务文件大小，区别于任务输入 L_m；p_{mj} 是源节点关于执行节点服务缓存的信念。本地目标的 p_{mj} 取源节点自身缓存状态，协作目标取已有邻机缓存信

念。T_{mj}^{hop} 仅在 $j \neq u_m$ 且目标为 UAV 时存在。上传链路沿用当前接纳关系和当前带宽共享规则，不能以待执行轨迹移动后的距离重算当前请求上传时间。

为使负载搜索与匹配使用同一模型，将每条合法边归纳为四个非负预测量 $b_{mj}, w_{mj}, e_{mj}, c_{mj}$。对 UAV 目标，定义

$$\begin{aligned} b_{mj} &= T_m^{\mathrm{up}} + T_{mj}^{\mathrm{hop}} + T_{mj}^{\mathrm{fetch}}, & w_{mj} &= \frac{C_m}{F_j}, \\ e_{mj} &= P_{\mathrm{bh,rx}} T_{mj}^{\mathrm{fetch}} + (P_{\mathrm{u,tx}} + P_{\mathrm{u,rx}}) T_{mj}^{\mathrm{hop}}, & c_{mj} &= \kappa C_m F_j^2. \end{aligned} \tag{5.4}$$

本地执行时令转发项为零。这里的 e_{mj} 只计 UAV 侧与分配相关的通信能耗，任务输入从 UE 上传的 UE 侧发射能耗不混入 UAV 分配能耗；来源 UAV 的共同输入接收能耗也排除，因为它不随卸载目标改变。F_j 为目标 UAV 的可用计算能力，κ 为计算能耗系数。所有合法边使用相同来源的物理参数与缓存信念，不为学习组构造更有利的预测器。

对 MBS，设源 UAV 回传任务的时间为 T_m^{bh}，MBS 算力为 F_{MBS}，则

$$b_{m5} = T_m^{\mathrm{up}} + T_m^{\mathrm{bh}} + \frac{C_m}{F_{\mathrm{MBS}}}, \quad w_{m5} = c_{m5} = 0, \quad e_{m5} = P_{\mathrm{bh,tx}} T_m^{\mathrm{bh}}. \tag{5.5}$$

MBS 计算时间直接进入 b_{m5}，没有再乘配额 N_5。因此 MBS 配额决定哪些请求走回传路径，不改变本实验规定的 MBS 单请求计算能力。该非共享规则是冻结物理模型的一部分，并不意味着现实基站总有无限并行处理能力。

5.2.3　最终负载共享下的时延与能耗

若 UAV j 最终收到 $N_j \geqslant 1$ 个请求，每个请求分得 F_j/N_j 的算力。将其代入计算时间和计算能耗模型，可以逐项得到

$$T_{mj}^{\mathrm{cmp}} = \frac{C_m}{F_j/N_j} = \frac{C_m}{F_j} N_j, \qquad E_{mj}^{\mathrm{cmp}} = \kappa C_m (F_j/N_j)^2 = \frac{\kappa C_m F_j^2}{N_j^2}. \tag{5.6}$$

进而，合法边在给定最终配额下的预测完成时延与 UAV 分配能耗为

$$\widehat{T}_{mj}(N_j) = b_{mj} + w_{mj} N_j, \qquad \widehat{E}_{mj}(N_j) = e_{mj} + \frac{c_{mj}}{N_j^2}. \tag{5.7}$$

对于配额为零的节点，矩阵构造以 $\max(N_j, 1)$ 避免除零，但该节点不展开容量槽，所以没有请求实际被分配过去；MBS 在计算上述矩阵时统一使用有效负载 1，与式 (5.5) 一致。这个数值处理没有给空节点虚构请求，也没有改变守恒条件。

式 (5.7) 显示，增加一个任务会使节点上每个请求的预测计算时延增加 w_{mj}，而计算能耗项随负载平方下降。该模型中“把任务分散到更多节点”并不必然降低 UAV 计算能耗，因为更高的单请求算力份额可能增加平方能耗；同时，集中负载也可能降低能耗却增加超时。时延与能耗的这种结构性权衡使仅最小化单请求时延、仅最小化能耗或仅均衡任务数量都不足以直接解决截止期满足问题。

设分配 $\mathbf{x}$ 的预测超时数、预测分配能耗和平均归一化时延分别为

$$\begin{aligned} M(\mathbf{x}) &= \sum_{m,j} x_{mj}\mathbf{1}\{\widehat{T}_{mj}(N_j) > D_m\}, \\ E(\mathbf{x}) &= \sum_{m,j} x_{mj}\widehat{E}_{mj}(N_j), \\ Q(\mathbf{x}) &= \frac{1}{\max(R,1)}\sum_{m,j} x_{mj}\frac{\widehat{T}_{mj}(N_j)}{D_m}. \end{aligned} \tag{5.8}$$

普通修复按 (M,E,Q) 字典序比较，条件匹配与最好方案更新则以 (M,E) 为目标；Q 仅作为普通修复的次级判别。截止期判断采用严格大于号，恰好达到截止时间计为按时。

5.3 配额分解与条件化字典序匹配

5.3.1 配额空间与分配空间的关系

若每个请求最多有六个合法执行目标，直接分配空间至多包含 6^R 个组合。SF-HLM 首先考虑整数配额空间

$$\mathcal{N}_R = \left\{ \mathbf{n} \in \mathbb{Z}^6_{\geqslant 0} : \sum_{j=0}^{5} N_j = R \right\}, \qquad |\mathcal{N}_R| = \binom{R+5}{5}. \tag{5.9}$$

这个数量是忽略质量掩码后的配额数上界；掩码会排除某些无法由合法请求组成的配额。配额表示保留了算力共享所需的关键统计量，使负载相关项在给定 $\mathbf{N}$ 后成为已知常数。与此同时，它没有强迫同样大小的任务交换身份，也没有按配额均匀随机分配请求，具体任务依然交由条件匹配选择。

配额分解的作用并非声称整个问题已变为低复杂度精确问题。式 (5.9) 仍随批量规模增长，在线预算不允许穷举。其实际优势是把复杂的两种决策分开：图策略在配额层选择值得尝试的负载组织，确定性匹配器在该组织内利用请求差异寻找分配。学习器不必逐个生成全部请求的完整组合，也不必从回报中独立重新学习指派求解器已经能够表达的条件最优结构。

5.3.2 容量槽展开与合法指派

给定配额 $\mathbf{N}$，将每个节点 j 展开为 N_j 个容量槽。全部槽的集合为 $\mathcal{S}(\mathbf{N})$，大小恰好为 R；槽 s 对应的执行节点记为 $j(s)$。令 $y_{ms} \in \{0,1\}$ 表示请求 m 是否占据槽 s，则条件匹配满足

$$\sum_{s\in\mathcal{S}} y_{ms} = 1, \qquad \sum_{m\in\mathcal{R}} y_{ms} = 1, \qquad y_{ms} = 0 \quad \big(j(s) \notin \mathcal{J}_m\big). \tag{5.10}$$

同一节点的容量槽具有相同边成本，但分别只能接收一个请求。由一一指派得到的分配自动满足式 (5.2)，且每个节点最终恰好接收 N_j 个请求。图 5.2 展示配额、容量槽与请求身份的关系。

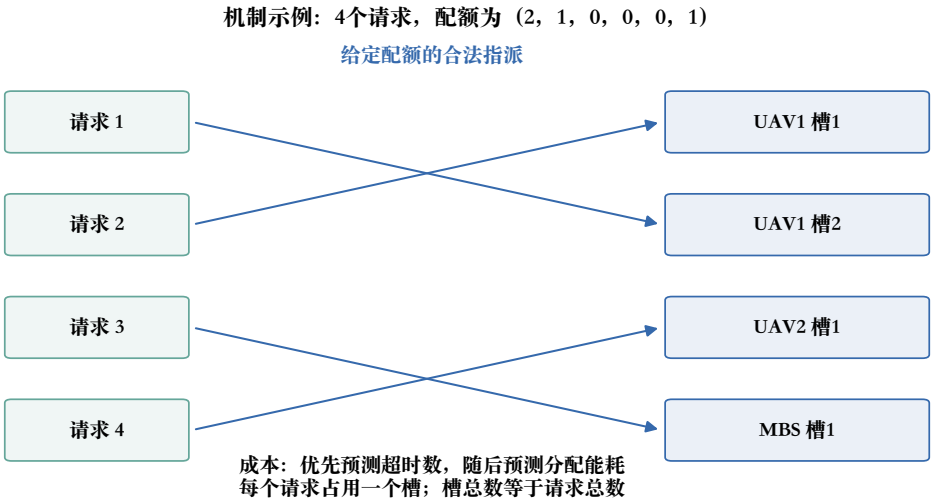


图 5.2　固定配额的容量槽展开与请求匹配。示意图用于解释算法结构，不是实测任务分配
Figure 5.2　Capacity-slot expansion and request assignment under fixed quotas; a conceptual illustration

配额可行性由完整指派确认。各节点的合法边数只是必要条件：若多节点依赖同一小部分请求，仍可能无法同时填满容量槽。非法边设无穷成本，使用 SciPy 线性指派接口[30]求解，其修改的 Jonker–Volgenant 方法背景见文献[31]。返回后检查边合法性与节点数量守恒；不可行调用同样计入预算，并保留已有最好方案。

5.3.3　字典序目标的标量化与严格等价性

给定 $\mathbf{N}$，先计算全部合法边的预测能耗，令

$$E_{\max}(\mathbf{N}) = \max_{m,j:\, j\in\mathcal{J}_m} \widehat{E}_{mj}(N_j), \qquad \widetilde{E}_{mj} = \frac{\widehat{E}_{mj}(N_j)}{\max(E_{\max}, \epsilon_E)}. \tag{5.11}$$

实现用极小正数 ϵ_E 防止所有能耗为零时除零。合法边能耗非负且 $\widetilde{E}_{mj} \leqslant 1$，因此任何完整合法指派的归一化能耗和均处于 $[0, R]$。构造容量槽成本

$$C_{ms} = (R+1)\mathbf{1}\{\widehat{T}_{m,j(s)}(N_{j(s)}) > D_m\} + \widetilde{E}_{m,j(s)}, \tag{5.12}$$

非法边成本为无穷。线性指派求解

$$\min_{\mathbf{y}} \sum_{m,s} C_{ms} y_{ms} \quad \text{满足式 (5.10).} \tag{5.13}$$

权重 $R+1$ 随当前批量规模确定，不使用任意调试的超时惩罚常数。

下面说明式 (5.13) 与固定配额下的 (M, E) 字典序最小化等价。任取两个完整合法指派 $\mathbf{y}^a, \mathbf{y}^b$，若 $M_a \geqslant M_b + 1$，其标量目标差满足

$$C_a - C_b = (R+1)(M_a - M_b) + \widetilde{E}_a - \widetilde{E}_b \geqslant (R+1) - R = 1 > 0. \tag{5.14}$$

因此，无论能耗怎样变化，多一个预测超时的分配都不可能取得更小的标量成本。若 $M_a = M_b$，标量目标只比较归一化能耗；固定配额内归一化比例相同，故该比较与原始能耗大小完全一致。这证明求解器首先最小化预测超时数，再在最少超时的分配中最小化预测分配能耗。

上述条件最优性适用于给定配额、固定预测信息及合法指派域。能耗上限在求解后筛选：若最少预测超时的匹配超出上限，该候选被拒绝，不再搜索该配额下其他受限指派。因而，条件匹配提供可利用的精确子结构，配额搜索及能耗约束下的整体性能仍需独立评价。

5.3.4 预测能耗参照与保底方案

先按固定请求顺序构造原始贪心分配 $\mathbf{x}^{\mathrm{g}}$。处理一个请求时，贪心按已分配目标数估计加入后的自身时延，依次以自身时延、自身分配能耗和动作编号决胜。共同能耗参照由该原始贪心的最终批量重评估确定：

$$E_{\mathrm{cap}} = 1.05\,E(\mathbf{x}^{\mathrm{g}}). \tag{5.15}$$

普通修复、配额学习、启发式和强随机均使用同一状态下的这个上限。它不是各方法自己的初始分配乘 1.05，从而避免某个方法由于初始方案能耗偏高而获得更宽松的筛选空间。

普通修复以一次请求迁移为邻域，在最多 128 次候选评价内寻找字典序改进。若已有学习下层提出的初始分配超出共同上限，先回到原始贪心，再开展修复；若未超限则从其提案出发。配额方法从共同贪心加修复的保底进入，并对该保底配额作一次条件匹配。候选只有在合法且预测分配能耗不超过 E_{cap} 时才能成为当前搜索状态；最好方案由所有已接受方案中的 (M, E) 决定。

由此，最终分配保持完整、质量合法且预测能耗不超过共同上限，最好预测目标不劣于共同保底。该性质涉及分配预测量；环境中的真实缓存和请求执行仍影响实际结果，飞行、悬停及无线能量传输也未包含在 $E(\mathbf{x})$ 内。因此，实验另行统计完整 UAV 机队能耗。

5.4　有限预算配额搜索与二部图策略

5.4.1　当前状态、最好状态与动作空间

搜索的内部步号记为 ℓ，区别于环境时隙 t。一个环境时隙内可以进行若干次配额迁移，但只有最终保留的分配进入环境。当前配额、当前分配与其预测目标分别记为 $\mathbf{N}^{(\ell)}, \mathbf{x}^{(\ell)}, F^{(\ell)}$；最好分配与目标记为 $\mathbf{x}^{*(\ell)}, F^{*(\ell)}$。允许搜索经过比最好方案更差的当前方案，使策略能够跨越只接受即时改进的局部限制；实际执行则不受这些较差中间方案直接影响。

完整搜索过程的状态可写为

$$S_\ell = (\mathcal{R}, \mathbf{N}^{(\ell)}, \mathbf{x}^{(\ell)}, \mathbf{x}^{*(\ell)}, \mathcal{V}_\ell, B_\ell), \tag{5.16}$$

$\mathcal{V}_\ell$ 为已尝试配额集合，B_ℓ 为剩余调用预算，请求预测量在单次搜索内固定。条件匹配与访问更新定义搜索转移。策略读取当前与最好分配的图编码及有效动作掩码，这些输入构成完整搜索状态的可计算观测。有限搜索的性能通过对应对照评价。

配额动作集合为

$$\mathcal{A} = \{\mathrm{STOP}\} \cup \{(i, j, k) : i, j \in \mathcal{J},\ i \neq j,\ k \in \{1, 2, 4\}\}, \qquad |\mathcal{A}| = 91. \tag{5.17}$$

转移动作仅改变节点任务数量：

$$\mathbf{N}' = \mathbf{N}^{(\ell)} - k\mathbf{e}_i + k\mathbf{e}_j. \tag{5.18}$$

这里的“转移 k 个任务”是配额变动，不是预先指定 k 个请求的身份。新配额的具体分配重新由条件匹配给出，可能改变多个请求的目标。因此，一次配额动作能够触发批量重组，而不是仅对一个被选中的任务作局部替换。

有效动作掩码同时要求 $N_i \geqslant k$、新配额没有访问过、各节点配额不大于其合法边数。最后一项只是必要条件，完整可行性由匹配求解检查。STOP 始终有效，使没有可行迁移时策略也能合法终止。失败的匹配配额同样加入访问集合，避免重复耗费预算。采样时掩码属于保存的搜索状态，重算概率时不得根据更新后的访问集合重新生成它。

初始条件匹配占用一次调用，整个搜索最多 16 次匹配，因此普通非空批次最多再尝试 15 次配额迁移。策略可以提前 STOP，也可能因为调用预算耗尽而终止；空批次不消耗匹配预算。搜索预算是求解器调用数，而不是动作数、成功迁移数或模型前向次数。该定义使不可行候选与超能耗候选也承担实际计算费用，便于与启发式和强随机保持共同预算。

5.4.2 请求、边与节点特征

图 5.3 表示每个搜索状态的二部图。请求是左侧节点，六个执行节点是右侧节点，质量合法动作构成边。请求输入保留截止时间、计算量、输入大小和源节点；边输入描述请求放在该目标后的预测路径和负载；节点输入同时描述当前与最好方案的服务压力。区分当前与最好状态很重要：如果只编码最好方案，策略无法知道自己正在从哪个较差入口继续迁移；如果只编码当前方案，又无法知道已经保留的执行质量和剩余改进空间。

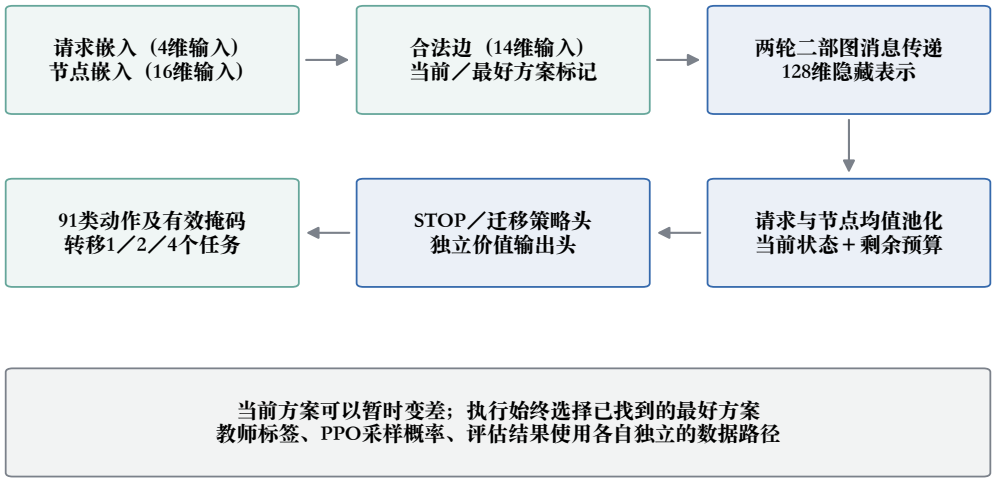


图 5.3 请求–执行节点二部图、当前与最好状态编码及配额动作头。非法边和填充请求在消息聚合中屏蔽

Figure 5.3 Request–execution-node graph, current/best state encoding and quota action heads

请求特征 $\mathbf{v}_m \in \mathbb{R}^4$ 为

$$\mathbf{v}_m = \left[\min(D_m, 10),\ \frac{\log(1+C_m)}{30},\ \frac{\log(1+L_m)}{20},\ \frac{u_m}{5}\right]. \tag{5.19}$$

秒、CPU 周期和字节数各自在进入网络前作固定尺度变换。变换用来控制数值范围，不改变指派预测器使用的原始量。尤其是网络中截止时间截断到 10 的表示，不意味着真实截止时间判断也被截断。

合法边 $\mathbf{z}_{mj} \in \mathbb{R}^{14}$ 的前十二项依次为：b_{mj}/D_m、w_{mj}/D_m、$\log(1+e_{mj})/20$、$\log(1+c_{mj})/30$、当前 N_j/R、截断后的 $\widehat{T}_{mj}/D_m$、归一化截止期余量、允许负载阈值的归一化值、MBS 标记、缓存信念、目标容量的对数表示和源节点标记。最后两项为当前分配与最好分配是否经过该边的二元标记。非法边的特征置零，并在后续聚合中屏蔽。负载阈值来自 $(D_m - b_{mj})/\max(w_{mj}, 10^{-12})$，只作为网络观测

特征；最终方法没有把临界阈值扩展为新的动作集合。

令请求在指定分配中的归一化余量为 $m_m = 1 - \widehat{T}_m/D_m$。每个节点的六项服务摘要为：接收数量占批次比例、节点内预测超时比例、平均余量、最小余量、释放一个请求可能救回的请求数占批次比例、节点分配能耗占参照比例。释放救回的判定为

$$b_{mj} + w_{mj}\max(N_j - 1, 1) \leqslant D_m < b_{mj} + w_{mj}N_j, \tag{5.20}$$

且只对 UAV 目标计算。摘要既描述节点已经承担的请求，也提示减少该节点负载可能影响的其他请求；它没有读取真实执行成功标签。

当前与最好方案分别生成六项摘要，拼接当前配额比例、剩余匹配预算比例、当前和最好预测超时占批次比例，得到 $\mathbf{u}_j \in \mathbb{R}^{16}$。所有比例在空批次处理时采用正分母保护；空节点摘要为零。平均和最小余量截断到 $[-10, 1]$，边时延比上限为 10，容许负载特征截断到 $[-1, 2]$。这些固定处理约束输入数值而不改变真实请求数量、目标可行性或实际性能评价。

5.4.3　两层消息传递与置换结构

分别用 MLP 将请求、节点与边特征映射为 $h = 128$ 维嵌入，记为 $\mathbf{h}_m^{(0)}, \mathbf{g}_j^{(0)}, \mathbf{e}_{mj}$。每个 MLP 由线性层、LayerNorm、ReLU 和输出线性层组成。两轮消息传递中，第 q 层合法边消息为

$$\mathbf{m}_{mj}^{(q)} = \psi_q\big([\mathbf{h}_m^{(q)}, \mathbf{g}_j^{(q)}, \mathbf{e}_{mj}]\big), \qquad j \in \mathcal{J}_m. \tag{5.21}$$

ψ_q 在所有合法边共享参数，非法边消息恒为零。请求侧和节点侧各按合法邻居取均值，并分别更新：

$$\begin{aligned} \overline{\mathbf{m}}_m^{(q)} &= \frac{\sum_{j\in\mathcal{J}_m}\mathbf{m}_{mj}^{(q)}}{\max(|\mathcal{J}_m|, 1)}, & \mathbf{h}_m^{(q+1)} &= \rho_q([\mathbf{h}_m^{(q)}, \overline{\mathbf{m}}_m^{(q)}]), \\ \overline{\mathbf{m}}_j^{(q)} &= \frac{\sum_{m:\, j\in\mathcal{J}_m}\mathbf{m}_{mj}^{(q)}}{\max(|\{m : j \in \mathcal{J}_m\}|, 1)}, & \mathbf{g}_j^{(q+1)} &= \nu_q([\mathbf{g}_j^{(q)}, \overline{\mathbf{m}}_j^{(q)}]). \end{aligned} \tag{5.22}$$

$q = 0, 1$，两层使用各自参数。批量训练时，请求图填充到同一批中的最大请求数；填充请求嵌入与消息均屏蔽，均值分母只计算真实合法邻居。

完成两层更新后，对真实请求取均值 $\overline{\mathbf{h}}$，对六个节点取均值 $\overline{\mathbf{g}}$。转移动作 (i, j, k) 的分数由源节点、目的节点、请求池化表示和迁移量独热编码构成：

$$z_{ijk} = f_{\text{move}}([\mathbf{g}_i^{(2)}, \mathbf{g}_j^{(2)}, \overline{\mathbf{h}}, \text{onehot}(k)]), \qquad z_{\text{stop}} = f_{\text{stop}}([\overline{\mathbf{h}}, \overline{\mathbf{g}}]). \tag{5.23}$$

价值头同样使用 $[\overline{\mathbf{h}}, \overline{\mathbf{g}}]$。掩码 logits 形成分类分布，训练时采样，评估时取最大分数动作。共享边函数与均值聚合对一致的请求排列保持不变，节点身份、源编号及合法域则仍作为显式输入。

这一网络用消息传递表达“同一个请求的替代目标”和“同一个节点上可竞争请求”的关系。它不采用多头注意力加权聚合，下层所有合法邻居的消息使用均值。SF-HLM 因而由上层注意力聚合与下层二部图 MLP 两种结构组成。可变请求数量由图表示和填充掩码处理，而六节点动作头保持固定，这使模型在冻结跨 UE 数量评价时无需增加动作维数。

5.4.4 搜索奖励与最好方案不变量

一次非停止迁移后，令最好预测超时与能耗从 $(M^*_{\ell-1}, E^*_{\ell-1})$ 更新到 (M^*_{ℓ}, E^*_{ℓ})，训练奖励定义为

$$r_\ell = M^*_{\ell-1} - M^*_{\ell} + 0.1\frac{E^*_{\ell-1} - E^*_{\ell}}{\max(E_{\text{cap}}, 10^{-12})} - 0.001. \tag{5.24}$$

奖励评价保留的最好方案，而非较差当前方案；一次没有改进的匹配尝试仍得到 -0.001 的计算惩罚。STOP 奖励为零。预测超时减少具有主要作用，能耗项在共同上限下表达较小的平滑偏好，调用惩罚为节约搜索提供信号。这个搜索奖励服务于单时隙组合求解，与环境中的轨迹奖励和真实 DSR 是不同对象。

采用无折扣的有限搜索回报，若本次搜索进行了 L 次非停止迁移，式 (5.24) 的差分项可望远镜求和：

$$\sum_{\ell=1}^{L} r_\ell = M^*_0 - M^*_L + 0.1\frac{E^*_0 - E^*_L}{\max(E_{\text{cap}}, 10^{-12})} - 0.001L. \tag{5.25}$$

0 对应完成共同保底与初始匹配后的状态，初始匹配本身不产生一次迁移奖励。因此，训练在已有保底质量上权衡进一步改善与额外尝试，不奖励重复返回同一配额，也不把较差中间状态的真实执行结果回流到环境。

5.4.5 计算量、终止条件与实现校验

固定配额下的稠密成本矩阵为 $R \times R$，常规指派的时间量级为 $O(R^3)$、存储量级为 $O(R^2)$，实际实现与稀疏结构影响常数。图网络每轮处理至多 $6R$ 条边，在六节点与固定宽度下对请求数近似线性。完整在线时间还包括观测准备、普通修复、至多 16 次匹配、动作映射及消息序列化。

调用预算保证有限搜索终止。有效迁移消耗匹配预算，访问去重避免重复，STOP 可提前结束，最终返回共同保底或更好的预测分配。单次原子匹配须完成后才能返回，因此墙钟预算属于软截止，其实际超限在后文测量。

输入检查覆盖非负有限性、请求完整性、动作合法性与配额守恒。搜索保存采样时掩码，匹配预算包含初始调用，所有候选使用共同能耗参照。同一批搜索轨迹采用相同策略参数，完成采集后统一更新。

算法 5.1　SF-HLM 单时隙配额搜索与条件匹配

Input: 移动前请求行、质量合法域、冻结图策略 π_θ；匹配预算 16，普通修复预算 128

Output: 全部已接纳请求的合法分配

构造原始贪心 $\mathbf{x}^{\mathrm{g}}$ 并计算 $E_{\mathrm{cap}} = 1.05E(\mathbf{x}^{\mathrm{g}})$;
在共同上限内普通修复，初始化当前与最好分配;
根据保底配额执行初始条件匹配，计入一次匹配调用;
若候选合法、低于上限且目标更好，更新保留方案;
while 批次非空、匹配调用未耗尽且搜索未停止 **do**
    编码当前/最好二部图及采样时掩码;
    由图策略选择 STOP 或配额迁移 (i, j, k);
    if 选择 *STOP* **then**
        终止搜索;
    else
        生成守恒配额，记录已访问配额并计入一次匹配调用;
        求解该配额的条件字典序匹配;
        若匹配合法且满足共同能耗上限，更新当前方案;
        若当前方案优于保留目标，更新最好方案;
    end
end
将最好方案映射回各源 UAV 的请求动作，输出完整分配;

5.5　教师初始化、配额 PPO 与分层训练

5.5.1　从训练轨迹采集请求图

下层训练以共同基座产生的环境和独立下层训练负载为起点，上层保持冻结。每个训练块额外采集 25 个完整回合，每回合 1000 步，在 $0, 125, 250, 375, 500, 625, 750, 875$ 八个预定时刻记录移动前请求图，得到 200 个图实例，空批次也保留。采图期间使用共同贪心修复策略，不依据未来独立确认结果选择“更容易学习”或“更能体现优势”的快照。图数据只记录允许的观测预测信息，教师和 PPO 搜索都在这些固定输入上运行。

环境交互提供下层训练图，组合搜索则在固定图上重复采样，以提高训练数据利用率。图分布由共同基座和采集策略决定。开发评价与独立确认负载保持独立，不参与图采集、教师标注或梯度更新；重复搜索属于优化计算而非新增环境交互。

图 5.4 展示基座训练、下层采图、教师初始化、PPO 搜索和独立评价的数据流。基座负载用于轨迹策略训练，下层负载用于生成组合搜索图，确认负载仅评价训练结束时的模型。每个训练块对应共同上层及相应下层参数，各数据集按用途分离。

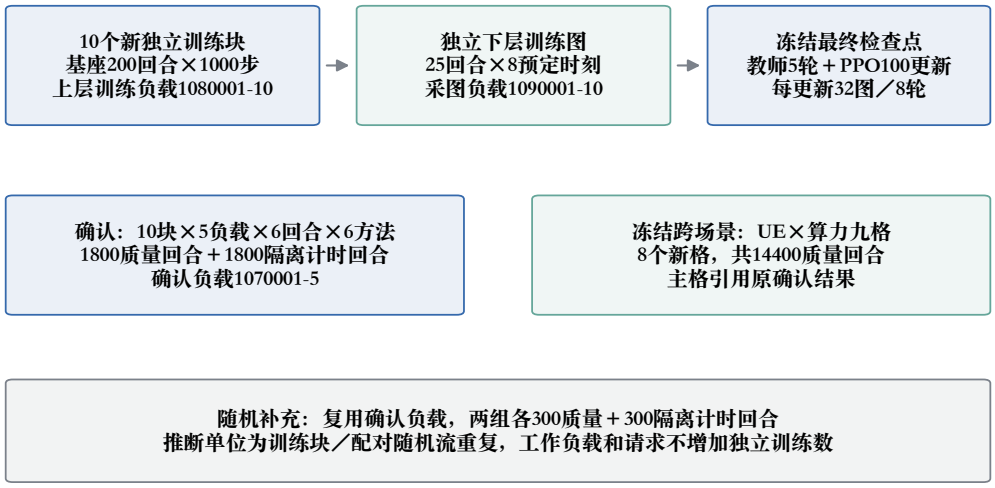


图 5.4　共同基座、下层训练图与独立确认的数据划分。图中回合是环境交互，配额 PPO 更新是固定训练图上的搜索训练

Figure 5.4　Data split for shared foundations, lower-layer training graphs and independent confirmation

5.5.2　即时教师与独立监督损失

随机初始化的配额策略需要从大量无改善迁移和非法候选中学习，有限匹配预算下直接优化可能较难发现有用方向。本文先使用训练图上的即时改进教师提供可执行的动作示例。教师从同一共同保底和初始匹配出发，对当前有效迁移逐一尝试条件匹配，在合法且满足能耗上限的候选中选择优于当前目标的动作；没有找到即时改进时标记 STOP。教师总匹配预算为 128，包括初始匹配、试探候选和被选中迁移，不能把教师评价当作免费的真值查询。

教师标签是其实际找到的动作，并非穷举配额空间的全局最优标签。即时改进教师也不一定能发现需要先经过较差状态的多步路径；这一限制说明监督阶段的作用是提供初始搜索偏好，而不是替代后续强化学习。每条样本保存当时的当前/最好图、有效动作集合和教师动作。对样本集 $\mathcal{D}_{\mathrm{T}}$，监督损失为

$$\mathcal{L}_{\mathrm{BC}}(\theta) = -\frac{1}{|\mathcal{D}_{\mathrm{T}}|} \sum_{(s,a^{\mathrm{T}})\in\mathcal{D}_{\mathrm{T}}} \log \pi_\theta(a^{\mathrm{T}} \mid s). \tag{5.26}$$

监督预训练采用 5 轮、小批量 64 和梯度范数上限 0.5，动作概率在样本保存的合法域内归一化。教师样本仅用于监督初始化，随后 PPO 使用策略自身采样的动作、概率和优势更新。

监督初始化提供即时改进偏好，PPO 随后优化自身采样搜索轨迹的累计回报。允许经过较差的可行状态，使搜索能够探索多步迁移路径。其相对共享框架

对照的服务增量在第 5.8 节评价。

5.5.3　有限搜索轨迹的优势估计

每次 PPO 更新前固定策略参数，从本块训练图抽取 32 个实例，各采集一条至多 16 次匹配的搜索轨迹。汇总该批轨迹后开始更新，保存搜索状态 s_ℓ、动作 a_ℓ、采样对数概率、价值估计 $V_\phi(s_\ell)$、奖励及终止标记。

令 $d_\ell^{\mathrm{end}} \in \{0,1\}$ 为搜索终止标记，优势估计采用 GAE[27]：

$$\delta_\ell = r_\ell + \gamma(1-d_\ell^{\mathrm{end}})V_\phi(s_{\ell+1}) - V_\phi(s_\ell), \qquad \gamma = 1, \tag{5.27}$$

$$\widehat{A}_\ell = \delta_\ell + \gamma\lambda(1-d_\ell^{\mathrm{end}})\widehat{A}_{\ell+1}, \qquad \lambda = 0.95, \qquad \widehat{R}_\ell = \widehat{A}_\ell + V_\phi(s_\ell). \tag{5.28}$$

搜索终点下一状态价值取零，递推在每条图轨迹边界停止。$\gamma = 1$ 对应最多十余步的有限预算求解，而不是无限时域控制；它保留式 (5.25) 中改善与调用开销的完整权衡。价值训练目标使用未标准化的 $\widehat{R}_\ell$，策略梯度使用本次采样记录内标准化的优势。

标准化写作

$$\widetilde{A}_\ell = \frac{\widehat{A}_\ell - \overline{A}}{\max(\mathrm{std}(\widehat{A}), 10^{-6})}. \tag{5.29}$$

若某批图没有有效搜索记录，则跳过参数更新而不是制造奖励或动作。不同图可以有不同请求数和搜索长度；填充处理的是图张量，不增加真实优势样本。请求数、搜索步或教师标签数也不能计为独立训练单位。

5.5.4　裁剪策略目标与概率一致性

配额 PPO 采用分类动作分布，其新旧策略概率比为

$$\rho_\ell(\theta) = \exp\left[\log \pi_\theta(a_\ell \mid s_\ell) - \log \pi_{\mathrm{old}}(a_\ell \mid s_\ell)\right]. \tag{5.30}$$

裁剪目标沿用 PPO 的有限更新思想[28]：

$$\mathcal{L}_{\mathrm{policy}} = -\mathbb{E}_\ell\left[\min\left(\rho_\ell\widetilde{A}_\ell, \mathrm{clip}(\rho_\ell, 0.8, 1.2)\widetilde{A}_\ell\right)\right] - 0.005\,\mathbb{E}_\ell[\mathcal{H}(\pi_\theta(\cdot \mid s_\ell))]. \tag{5.31}$$

价值损失为

$$\mathcal{L}_{\mathrm{value}} = \frac{1}{2}\mathbb{E}_\ell\left[(V_\phi(s_\ell) - \widehat{R}_\ell)^2\right]. \tag{5.32}$$

共享图编码器与动作、价值头一起最小化两项之和，Adam 学习率为 3×10^{-4}，每次采样执行 8 个 epoch、小批量 64，总计 100 次 PPO 更新，梯度范数裁剪为 0.5。最终确认使用第 100 次更新后的最后检查点，没有从开发或确认曲线中挑选最高 DSR 时刻。

PPO 的概率一致性在带访问去重的搜索中尤为重要。同一个配额在轨迹前段可能未访问、后段已经访问；如果训练时重算访问集合，动作分布的归一化域会改变，概率比就不再对应原采样策略。本方法把采样时掩码和当前/最好图作为不可变记录保存，并在首次梯度更新前检验重算概率比接近 1。并行轨迹来自相同冻结参数，教师标签不进入这些记录，从而使比值检验具有清楚的含义。

表 5.2　已确认配额策略的训练设置

Table 5.2　Training settings of the confirmed quota policy

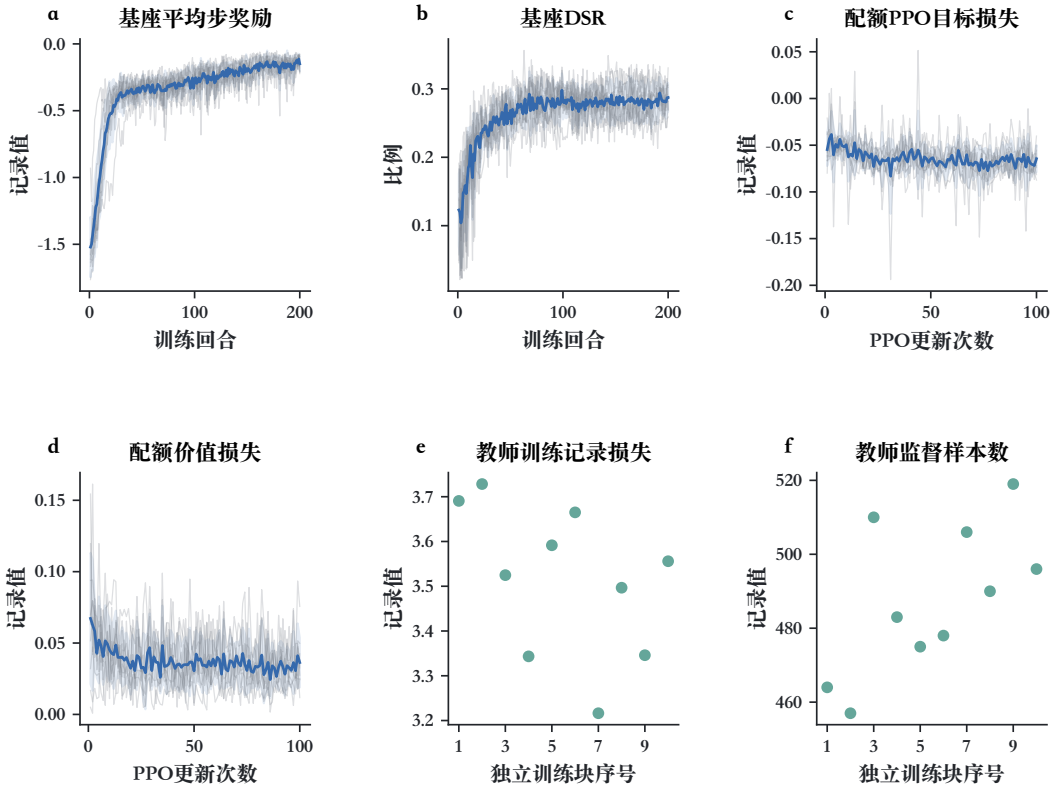
参数	数值	参数	数值
隐藏宽度	128	消息传递层数	2
请求/边/节点维数	4/14/16	动作数	91
每块采图回合	25	每块训练图数	200
教师总匹配预算/图	128	监督预训练轮数	5
PPO 更新次数	100	每更新采样图数	32
PPO epoch	8	监督/PPO 小批量	64
学习率	3×10^{-4}	梯度范数上限	0.5
PPO 裁剪范围	[0.8, 1.2]	熵系数	0.005
折扣因子	1	GAE 参数	0.95
在线匹配调用上限	16	普通修复候选上限	128

5.5.5　共同基座与交互、教师计算预算

每个独立训练块先重新训练覆盖需求分层基座 200 个回合，每回合 1000 步。共同基座包含上层与请求级 MAPPO 下层的最后参数、优化器与约束状态；确认中的六种下层方法从同一个上层基座出发。配额下层再使用 25 个回合采图及离线监督/PPO 计算；适配请求级下层则在冻结上层后继续训练 75 个回合，并恢复原优化器及 DSR、MBS 约束状态。冻结请求级下层组保留基座下层，贪心、启发式和强随机不进行额外模型训练。

另有 50 个回合用于固定策略数据采集，各方法复用相应记录。共同基座交互、配额采图、下层适配、教师匹配与网络优化具有不同计算需求，分别计量。实验比较对应这些预定训练设置下的方法表现，未将环境交互步数相同等同于总训练计算相同。

图 5.5 分别展示共同基座的环境训练与配额策略的搜索训练。两阶段具有不同横轴和奖励定义，曲线描述各自优化过程；方法的服务效果由独立确认评价。



前四面板：全部10块原始曲线；粗线为均值，带为块间±1 SD；未平滑
后两面板：每块一次教师监督记录；未保存逐轮损失，不构造教师收敛曲线

图 5.5　共同基座与配额策略的实际训练记录。前四面板依次为基座平均步奖励、基座 DSR、配额 PPO 损失和价值损失：细线为十块原始曲线，粗线和带分别为块间均值与正负一个标准差；未平滑。后两面板为每块一次教师监督损失记录和样本数；未保存逐轮损失，故不绘制教师收敛曲线。环境回合、优化更新与训练块横轴分别对应不同阶段

Figure 5.5　Actual training records of the foundation and quota policy; curves show ten blocks, and teacher panels show one recorded summary per block

5.6　独立确认设计与统计方法

5.6.1　场景、种子分割与最后检查点

主场景包含五架 UAV、一百 UE、一个 MBS 及 700 m × 700 m 区域，通信、请求生成、能量动态、自然接纳和奖励设置保持一致。开发使用五个训练块，独立确认使用十个未参与模型选择的训练块，并区分基座、下层训练与确认负载。候选结构、模型选择规则、检验族和性能判据均在确认前确定。

所有学习、贪心、启发式和强配额随机方法在同一训练块内复用共同上层参数，工作负载与初始外生流配对。不同卸载会改变后续能量、缓存和观测，因此即使上层参数相同，长期轨迹也可能分化；本章评价是闭环运行，不是冻结几何下的反事实分配。配对只要求潜在请求、外生随机序列和模型对应关系按协议一致，并不要求每个时隙状态或生成服务请求分母完全相同。

表 5.3　SF-HLM 独立确认的数据与模型分割

Table 5.3　Data and model split for independent SF-HLM confirmation

用途	固定设置
独立训练块	1060001–1060010，共 10 块
基座训练负载	1080001–1080010，与各训练块一一对应
下层采图/适配负载	1090001–1090010，与各训练块一一对应
配额下层初始化	1100001–1100010，与各训练块一一对应
确认工作负载	1070001–1070005，全部方法配对复用
评价长度	每块每负载 6 回合，每回合 1000 步
模型选择	基座训练与配额更新均固定最后检查点
六方法质量评价	$6 \times 10 \times 5 \times 6 = 1800$ 回合
独立软件计时	另 1800 回合，在预留物理核心重放同一策略

六种核心方法的质量评价覆盖 180 万个环境步。软件计时重放相同模型与外生流，分配及真实物理计数与质量评价一致。两类运行分别用于服务质量统计和隔离时间测量，独立训练重复数保持十个。

5.6.2　六个核心对照与两种补充随机策略

表 5.4 区分下层优化包与学习机制对照。启发式按当前合法目标的预测截止期风险选择配额迁移；强配额随机在有效迁移中随机选择，两者都拥有共同保底、条件匹配、最好保留和 16 次调用上限。它们不能与“每请求随机选一个目标”混为同一种随机基线。

表 5.4　完整下层与学习机制对照的组成

Table 5.4　Components of complete lower-layer and learning-mechanism controls

方法	下层与比较用途
学习配额搜索	二部图 PPO 选择配额迁移，条件匹配；SF-HLM
启发式配额搜索	相同强框架与预算，按预测风险选择迁移；学习机制对照
强配额随机搜索	相同强框架与预算，在有效迁移中随机；严格学习增量对照
贪心＋普通修复	原始贪心后做最多 128 次普通修复；主要实用对照
冻结请求级下层＋修复	基座请求级 MAPPO 提案后共同修复；主要学习对照
适配请求级下层＋修复	冻结上层后继续 75 回合原下层训练，再共同修复
相同上层＋逐请求随机卸载	共同质量掩码内逐请求均匀随机；移除整个下层优化包
全随机（质量掩码内）	二维轨迹在 $[-1,1]^2$ 独立均匀采样，卸载逐请求随机

请求级 MAPPO 对照保留原始提案与采样概率，再以共同普通修复生成执

行分配。适配组恢复基座优化器及自适应约束状态，继续训练已有下层；冻结组保持下层参数固定。两组均使用共同能耗参照和修复流程，与配额匹配组成完整方法对照。

确认后增加两种随机对照，复用十套固定模型和五个确认负载，每种方法运行 300 个质量回合与 300 个隔离计时回合。两者保持质量掩码、自然接纳和物理规则，移除贪心、普通修复、条件匹配、配额搜索、最好保留及预测能耗筛选。全随机评价完整系统，相同学习上层加逐请求随机卸载评价完整下层；学习搜索增量则由共享求解框架的强随机对照评价。

5.6.3　请求计数聚合与十个独立统计单位

令 $b=1,\cdots,10$ 为独立训练块，$w=1,\cdots,5$ 为工作负载，$e=1,\cdots,6$ 为评估回合，$t=1,\cdots,1000$ 为时隙。对方法 a，先合并同一块的全部请求计数：

$$G_b^a=\sum_{w,e,t} G_{bwet}^a,\qquad A_b^a=\sum_{w,e,t} A_{bwet}^a,\qquad S_b^a=\sum_{w,e,t} S_{bwet}^a. \tag{5.33}$$

再定义块级指标

$$D_b^a=\frac{S_b^a}{G_b^a},\qquad a_b^a=\frac{A_b^a}{G_b^a},\qquad q_b^a=\frac{S_b^a}{A_b^a},\qquad D_b^a=a_b^a q_b^a. \tag{5.34}$$

主场景各块均有非零生成与接纳计数。空统计单元采用正分母保护，保持零成功计数。

方法的描述均值是 $\overline{D}^a=10^{-1}\sum_b D_b^a$。这使每个独立模型块的权重相同，不让生成请求稍多的块获得更大统计权重。它也不同于先求每回合比率再平均，因为后者会让请求较少的回合与请求较多的回合占相同权重。本文使用请求计数汇总的定义，并在表、图和差值检验中保持一致。

跨块均值一般不满足 $\overline{D}=\overline{a}\,\overline{q}$，其差为

$$\overline{D}-\overline{a}\,\overline{q}=\frac{1}{10}\sum_{b=1}^{10}(a_b-\overline{a})(q_b-\overline{q}). \tag{5.35}$$

接纳率与条件完成率的跨块均值用于描述方向，精确分解则按同块计数计算，以保留块间协变。

训练块是主推断单位。五工作负载和六回合改善块内估计，单个请求提供服务计数，都不扩充独立训练样本数。强随机搜索在每块对应同一个学习上层，并具有独立策略随机流，因此其变化包含共同模型和策略随机性。全随机没有训练过程，补充评价的十个块只是与十套模型配对的独立随机流重复，不应称作十个全随机训练种子。

5.6.4 配对区间、多重比较与预定门槛

候选 a 与对手 c 的块级差值为 $\Delta_b = D_b^a - D_b^c$。其均值、标准差与双侧 95% 配对 t 区间为

$$\bar{\Delta} = \frac{1}{10}\sum_b \Delta_b, \quad s_\Delta^2 = \frac{1}{9}\sum_b (\Delta_b - \bar{\Delta})^2, \quad \mathrm{CI}_{95} = \bar{\Delta} \pm t_{0.975,9}\frac{s_\Delta}{\sqrt{10}}. \tag{5.36}$$

$t_{0.975,9}$ 约为 2.262，配对检验以十个训练块差值为数据。DSR 的绝对差异以百分点表示。

主检验族在确认前固定为学习相对贪心修复、冻结请求级下层修复和适配请求级下层修复三项。学习相对启发式与强随机属于独立的两项机制族。每族内部按 Holm 方法校正：将 K 个原始双侧 p 值升序排列，计算

$$p_{(i)}^{\mathrm{Holm}} = \min\left\{1, \max_{h\leqslant i}(K-h+1)p_{(h)}\right\}. \tag{5.37}$$

三个主性能比较、两个机制比较和两个补充随机比较分别组成检验族，按对应评价前确定的范围校正。

每个主比较须同时满足：DSR 均值增益至少 1 个百分点、配对区间下界为正、Holm 校正 $p < 0.05$、仿真环境记录的 UAV 总能耗的块级比值平均不超过 1.05，以及候选每块完整软件 p95 小于 1 s。能耗比定义为

$$\bar{\eta}_{a/c} = \frac{1}{10}\sum_b \frac{E_b^a}{E_b^c}. \tag{5.38}$$

块级能耗比的平均值与两个总体能耗均值之比具有不同权重。预测能耗筛选约束单次分配，性能判据评价仿真机队总能耗；统计显著性与预定实用增益也分别报告。

学习与强随机的差值另进行精确符号翻转敏感性检验。十块配对差形成 2^{10} 种符号组合，以均值绝对值检验零假设，考察小样本推断对分布假设的敏感性。该检验要求零假设下差值符号可交换，与配对 t 推断并列报告。

5.6.5 能耗、公平性、MBS 与完整软件计时

仿真环境记录的总能耗 E_b^a 汇总五架 UAV 的飞行与作业等全部环境记录，再除以块内 30000 个时隙得到 J/步。该量不包括 MBS 计算、真实部署的新增控制通信和获取大范围需求信息的全部费用，所以 UAV 节能与全网节能是不同主张。公平性按第三章 Jain 指数逐时隙计算，再在块内平均；MBS 占比为块内送往 MBS 的请求数除以已接纳服务请求数。MBS 分母是接纳数，不是全部生成数。

主评价的请求时延包含模型规定的通信与计算路径，不计调度器求解等待。完整软件时间从移动前输入准备开始，包含观测构造、两层策略推理、共同保底、

配额搜索、匹配、动作映射及逻辑消息编码，排除环境物理仿真和结果落盘。先在各训练块 30000 次策略调用上计算 p95，再跨块平均；每块最大 p95 单独用于预定门槛。隔离计时在预留物理核心运行，与共享集群上的质量评估计时区分。相同模型和外生流重放保证时间测量不改变动作及质量，硬件和软件测量条件限制其可外推范围。

逻辑上传和下载字节由请求行、动作与摘要的序列化记录计算，用于描述协调信息规模。当前评价未将其转换为实际通信等待或能源开销。进一步研究可在请求截止期判定和能耗结算中加入上报、汇总及下发成本，独立评价通信受限条件下的服务质量。

5.7　主场景性能与完整下层优化包的收益

5.7.1　代表轨迹与实际注意力记录

先以一个事先固定的评估实例展示集群在线运行形态：取首个确认训练块 1060001、首个工作负载 1070001、第 0 回合，绘制学习配额与贪心修复的五机轨迹、实际航程和最小机间距，如图 5.6。两方法起始外生条件和冻结上层参数相同，但下层执行影响电量、缓存和后续观测，轨迹随闭环状态演化可以不同。选择首实例而不是视觉上最有利的轨迹，有助于把运行示例与全样本性能推断分开。

逐机航程由实际位置差累加，即 $\ell_u = \sum_{t=0}^{T-1} \|\mathbf{q}_u(t+1) - \mathbf{q}_u(t)\|_2$，其中 $T = 1000$，ℓ_u 的单位为 m；它不使用网络原始动作模长代替执行位移。该回合中，SF-HLM 五机航程之和约为 41.664 km，贪心修复约为 42.291 km。这些数值描述预选实例的机动分工，不代表全评估总体中的航程差异。最小机间距按 $d_*(t) = \min_{u<v} \|\mathbf{q}_u(t) - \mathbf{q}_v(t)\|_2$ 逐步计算；两方法的实际位置记录连续，最大单步位移不超过 15 m，最小间距为 200 m，核验采用 10^{-6} m 浮点容差。该结果检查的是修复后的离散位置，而不是学习策略独立提供的连续飞行避碰能力。

轨迹图的地面散点表示初始 UE 位置，服务圆表示终点几何，动态接纳率由完整请求计数计算。图 5.7 展示同一回合第 500 步上层 Actor 的注意力，采用该步输入、模型权重与实际前向缩放、掩码，描述可见邻机和需求的信息聚合。

注意力图描述代表状态的信息聚合，独立评价则检验完整策略的服务效果。核心六组共享需求感知上层，因此本章比较集中于同一轨迹基座上的下层任务组织，上层观测及结构比较见第三章。

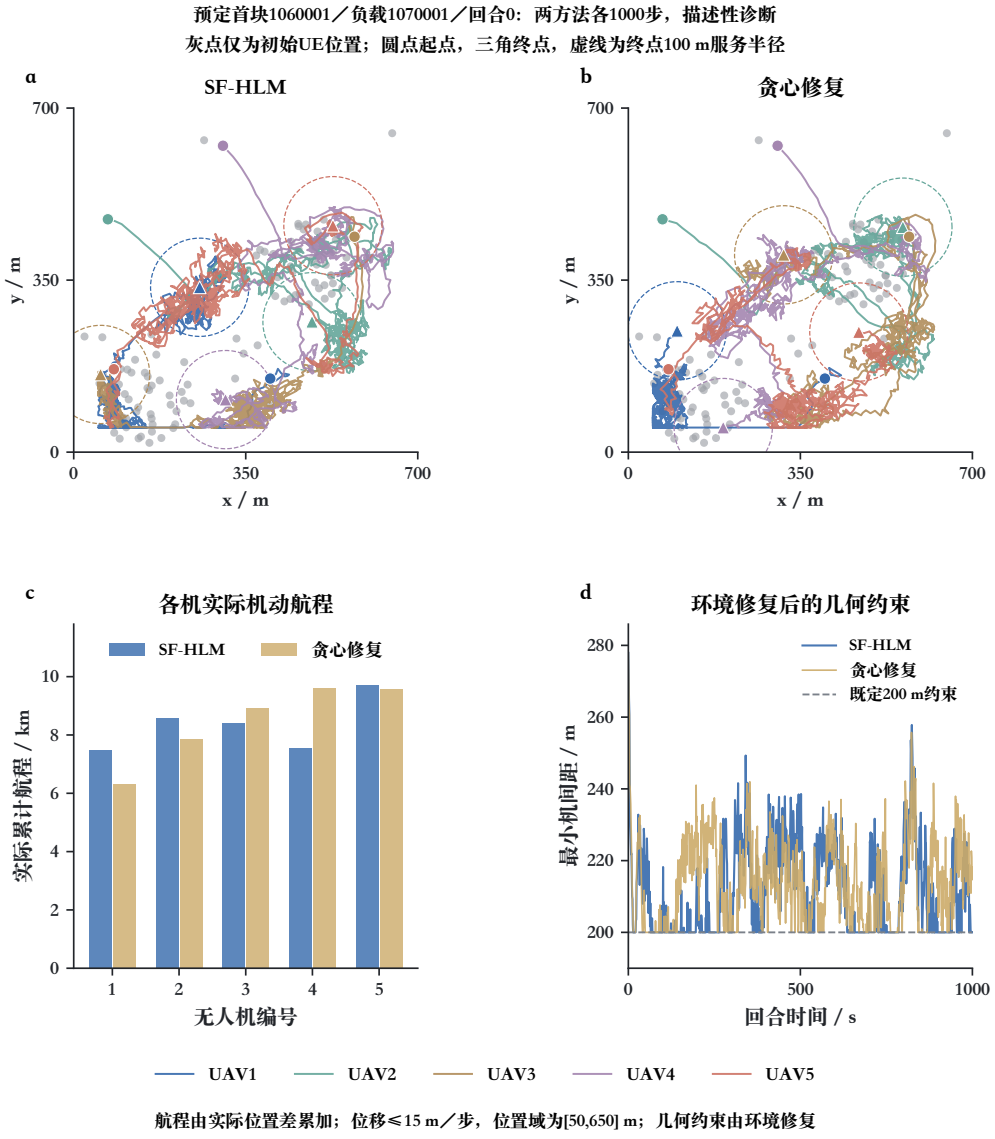


图 5.6　预选首确认回合的集群空间机动记录。上排为两方法五机轨迹，灰点仅表示初始 UE 位置，虚线为终点 100 m 服务圆；下排为逐机实际水平航程与最小机间距。200 m 间距线是既定几何约束；本图只描述各方法一个回合

Figure 5.6　Swarm trajectories, per-UAV horizontal path lengths and minimum separation in one preselected episode per method; UE markers show initial positions only

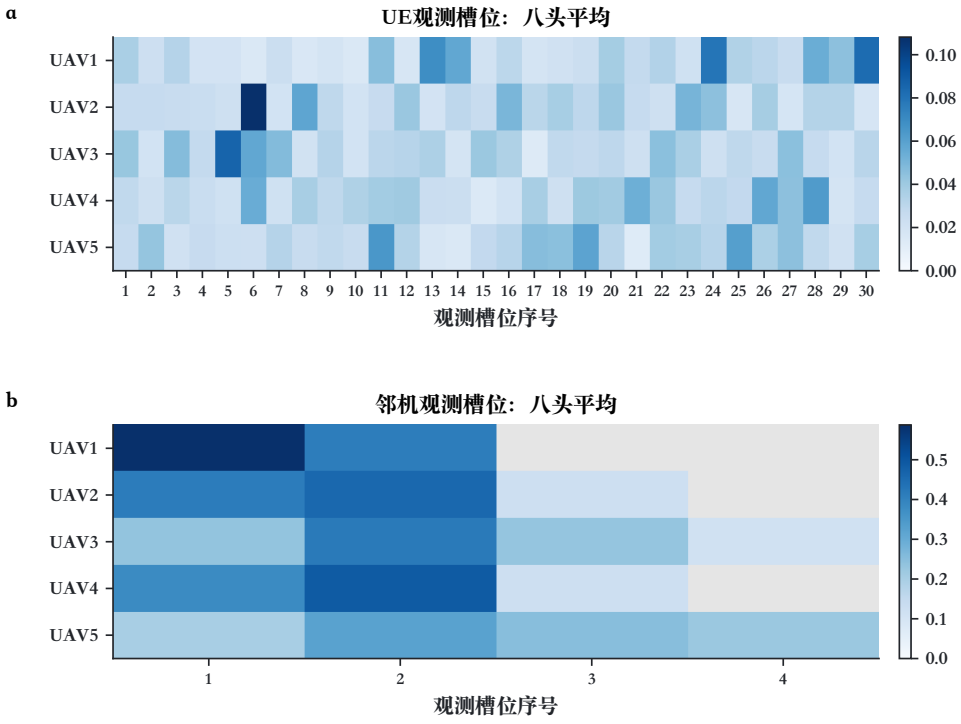


图 5.7　代表确认回合第 500 步上层 Actor 的实际前向注意力记录。权重说明该状态下的信息聚合，不作为注意力贡献的独立因果证明

Figure 5.7　Actual upper-Actor attention at step 500 of the representative episode; a descriptive forward-pass diagnostic

5.7.2　八种方法的截止期满足表现

表 5.5 和图 5.8 汇总六种核心方法的独立确认与两种补充随机评价。补充对照复用相同模型和确认负载，均以实际生成服务请求为分母并按块汇总计数。SF-HLM 的 DSR 为 34.244%，在八种方法中具有最高描述均值。以下差值均来自本章对应的配对评价。

学习相对贪心修复的主增益为 1.423 个百分点，相对冻结请求级下层、适配请求级下层修复分别为 2.008 和 2.192 个百分点，完整区间与校正检验列于表 5.6. 三项差值均在十个训练块上同向为正；图 5.9 展示这些块级配对差，说明均值优势并非由单个异常训练块独自支撑。三项均达到预定 1 个百分点实用目标，区间下界为正，并通过三比较 Holm 校正。

两种请求级学习对照使用共同普通修复，适配组另继续训练下层。在一百 UE 主场景、十个独立训练块及预定训练设置下，三个主比较支持 SF-HLM 完整下层的端到端 DSR 改善。教师计算和不同训练流程分别记录，结构贡献由后续共享框架机制对照评价。

表 5.5　一百 UE 主场景的服务指标（先合并块内请求计数，再跨块平均）

Table 5.5　Service metrics in the 100-UE setting, obtained from within-block request counts and between-block averaging

方法	DSR/%	接纳率/%	接纳后完成率/%
学习配额搜索	**34.244**	57.339	59.819
启发式配额搜索	33.475	57.342	58.472
强配额随机搜索	34.100	57.379	59.517
贪心＋普通修复	32.821	57.367	57.305
冻结请求级下层＋修复	32.236	57.375	56.309
适配请求级下层＋修复	32.052	57.383	55.953
全随机（质量掩码内）	15.428	33.797	45.673
相同上层＋逐请求随机卸载	23.640	57.431	41.222

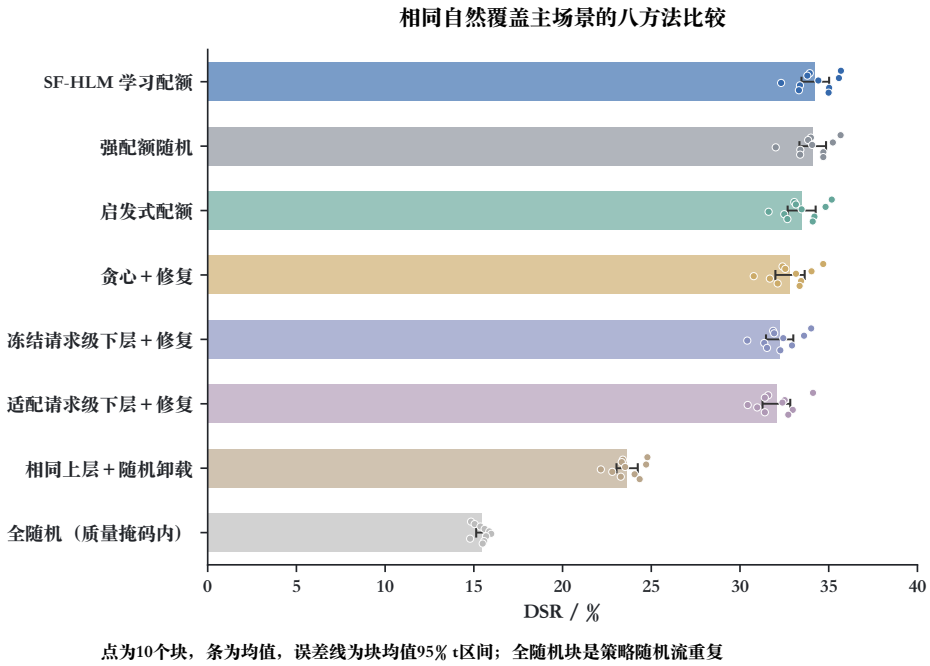


图 5.8　主场景八种方法的 DSR 比较。六种核心方法与两种补充随机对照分别标识；统计单位为十个模型或随机流配对块

Figure 5.8　DSR comparison of eight methods in the main setting, with core and supplementary controls identified; ten paired model or random-stream blocks

表 5.6　三个预定主对照的配对 DSR 差值与仿真环境记录的 UAV 能耗比
Table 5.6　Paired DSR effects and simulated UAV energy ratios for the three prespecified primary controls

学习减对手	差值/百分点	95% 区间/百分点	Holm p	能耗比
贪心＋普通修复	+1.423	[1.258, 1.587]	2.22×10^{-8}	0.9094
冻结请求级下层＋修复	+2.008	[1.808, 2.208]	8.92×10^{-9}	0.9656
适配请求级下层＋修复	+2.192	[1.903, 2.481]	3.46×10^{-8}	0.9803

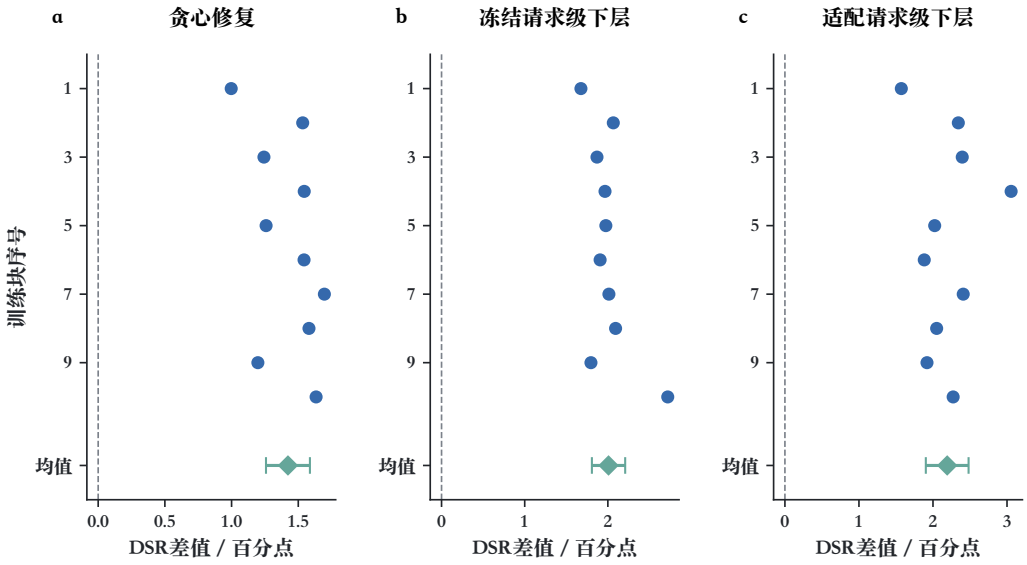


图 5.9　SF-HLM 相对三个主对手的十训练块配对差。每个块先合并五工作负载、六回合的请求计数
Figure 5.9　Per-training-block DSR differences against the three primary controls, based on pooled requests within each block

5.7.3　接纳与接纳后质量的请求计数分解

核心六方法的平均接纳率均约为 57.3%。SF-HLM 与贪心的接纳率分别为 57.339% 和 57.367%，接纳后完成率为 59.819% 和 57.305%。共享上层下，改善主要体现为已接纳请求的执行质量；各方法仍按自身闭环轨迹统计请求，保留状态分化的影响。

图 5.10 将生成请求分为未接纳、接纳后超时与按时完成三个互斥部分。块内占比分别为 $(G-A)/G$、$(A-S)/G$ 和 S/G，相加为 1；跨块平均保持该线性恒等式。SF-HLM 中三个部分约为 42.661%、23.095% 和 34.244%。同上层逐请求随机卸载的按时完成率仅为 41.222%，而接纳率仍为 57.431%，显示进入服务范围后的执行质量构成主要差距。

全随机接纳率为 33.797%，明显低于采用学习上层的策略组，反映完整系统

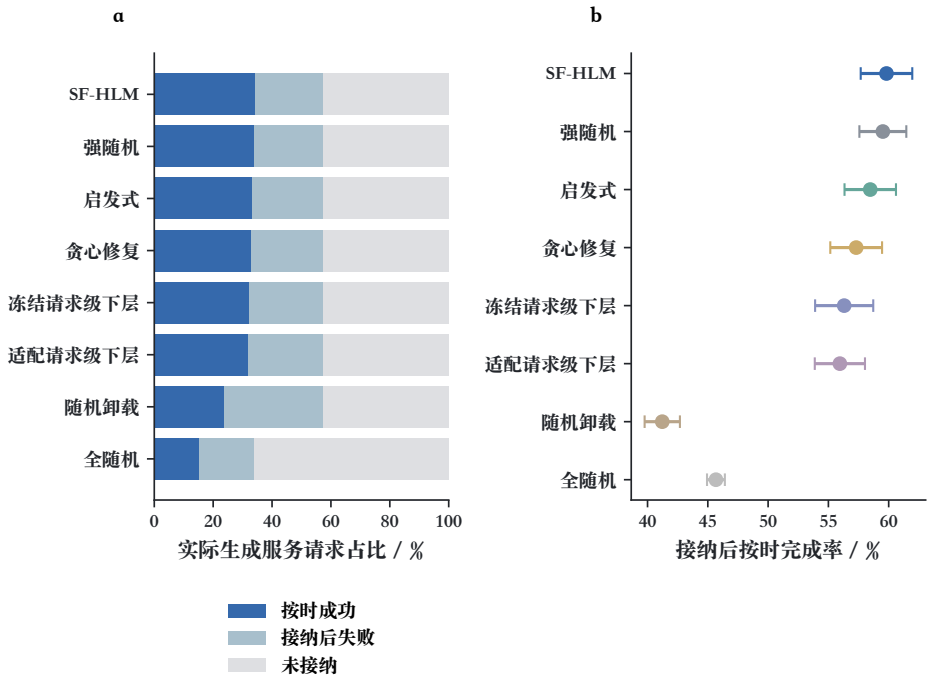


图 5.10　生成请求的互斥结果分解与接纳后完成率。三种结果按同块计数计算后平均，条件完成率以接纳请求为分母

Figure 5.10　Mutually exclusive request outcomes and deadline completion conditional on admission

在形成服务机会方面的收益。保留学习上层之后，随机卸载的接纳后质量仍远低于配额匹配。这两个对照有助于解释覆盖与服务质量各自的作用，但不是固定状态下可相加的因果分解：全随机改变运动，随机卸载改变能量和后续观测，二者的状态轨迹不同。本文使用分解描述实际结果，不把 18.816 个百分点机械拆成几个独立组件贡献。

5.7.4　UAV 能耗与 MBS 依赖

表 5.7 和图 5.11 同时报告 UAV 机队能耗与 MBS 占比。SF-HLM 的仿真环境记录的 UAV 能耗为 30394.4 J/步，低于贪心修复的 33419.9 J/步；按块能耗比平均计，降低约 9.06%。相对冻结与适配请求级下层修复，块级能耗比为 0.9656 与 0.9803。因此三个主比较的 DSR 改善没有以超过预定机队能耗门槛为代价。

SF-HLM 送往 MBS 的接纳请求比例为 9.83%，高于贪心的 2.92% 和启发式的 2.42%。在 MBS 单请求算力不共享的设置下，任务转移释放 UAV 算力并改变其计算与转发能耗。因此，UAV 能耗下降需结合 MBS 依赖解释，其统计范围未包含地面计算和完整网络能源。

逐请求随机卸载的 MBS 占比接近 29.5%，却同时具有较低 DSR 和较高 UAV 能耗，说明 MBS 比例本身不是充分的性能解释。请求身份、回传路径、UAV 剩

表 5.7　主场景 UAV 资源代价、公平性和完整软件时间

Table 5.7　UAV resource costs, fairness and full-policy software timing in the main setting

方法	UAV 能耗/(J/步)	MBS 占比/%	公平性	块 p95 均值/ms
学习配额搜索	30394.4	9.83	0.9239	109.24
启发式配额搜索	31854.7	2.42	0.9209	78.16
强配额随机搜索	30123.1	8.17	0.9216	73.47
贪心＋普通修复	33419.9	2.92	0.9212	17.59
冻结请求级下层＋修复	31484.7	3.07	0.9207	17.19
适配请求级下层＋修复	31010.1	4.14	0.9208	17.17
全随机（质量掩码内）	59649.6	29.65	0.7874	4.70
相同上层＋随机卸载	57503.7	29.45	0.9208	6.57

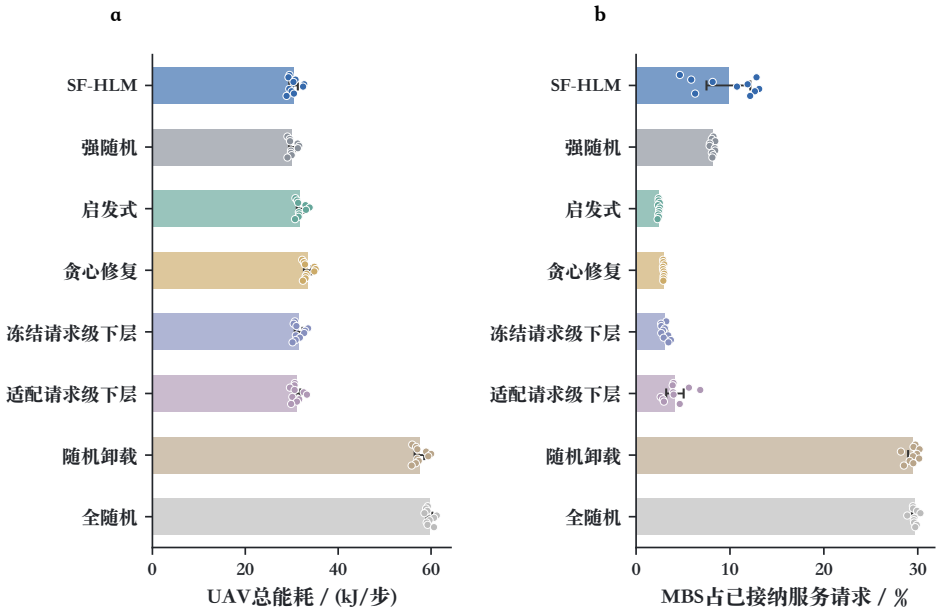


图 5.11　仿真环境记录的 UAV 机队能耗与 MBS 依赖。图中能耗为 kJ/步，MBS 比例为 MBS 请求数除以接纳请求数；未计 MBS 全网费用

Figure 5.11　Simulated UAV fleet energy in kJ per step and MBS fraction among admitted requests, excluding whole-network MBS costs

余批量和质量掩码共同影响结果。后续共同 MBS 数量快照诊断将进一步控制这一维度，检验配额匹配在固定 MBS 使用数量时仍有多少单步质量余量。

表 5.8　主场景仿真机队能耗构成（每步及等权块占比）

Table 5.8　Simulated fleet energy components per step and equal-block shares

分项	学习/J	占比/%	强随机/J	占比/%	贪心/J	占比/%
计算	29205.1	96.079	28934.0	96.048	32232.6	96.442
飞行与悬停	1166.4	3.846	1166.7	3.878	1166.9	3.496
服务通信	2.3	0.008	2.3	0.008	2.3	0.007
回源或回传	3.4	0.011	2.9	0.010	1.0	0.003
内容服务	16.8	0.055	16.8	0.056	16.8	0.050
WPT	0.4	0.001	0.4	0.001	0.4	0.001
总计	30394.4	100.000	30123.1	100.000	33419.9	100.000

表 5.8 使用原确认记录的逐步能耗分项，重放仅补充核验。先在每块合并六回合与五负载，再对十块等权平均；分项占比按各块分项除以该块总能耗后平均。分配因果能耗与上述分项有重叠，故不另加一项。计算项占三方法总费用约 96%，说明本模型的节能排序主要受等效计算能耗影响。各项在未舍入时精确加总，总额复现原表；显示精度下的细小差异来自舍入。该模型分解不对应实测机载功率或续航。

5.7.5　公平性、计算费用与可执行性

SF-HLM 公平性均值为 0.9239，核心六方法约在 0.9207 至 0.9239 范围；全随机为 0.7874。图 5.12 展示公平性和隔离软件 p95。SF-HLM 在共享上层组中保持较高的描述公平性，同时完整软件 p95 的块均值为 109.24 ms，各块为约 103–114 ms，最大为 114.343 ms，均小于预定 1 s 阈值。该结果证明在本次隔离测量条件下，完整在线调用满足协议时间门槛。

SF-HLM 的完整时间高于强配额随机的 73.47 ms、启发式的 78.16 ms 和贪心修复的 17.59 ms。图推理减少部分匹配尝试，同时增加网络前向费用。服务质量、公平性、匹配调用和全路径时间共同刻画方法收益与执行负担。

上述时间结论适用于规定服务器的隔离测量，未计入现实网络等待、MBS 排队及额外需求感知成本。当前服务指标与软件费用分别评价；满足一秒软件门槛不能直接证明计入求解等待后的截止期增益。面向机载部署仍需补充对应硬件与通信测量。

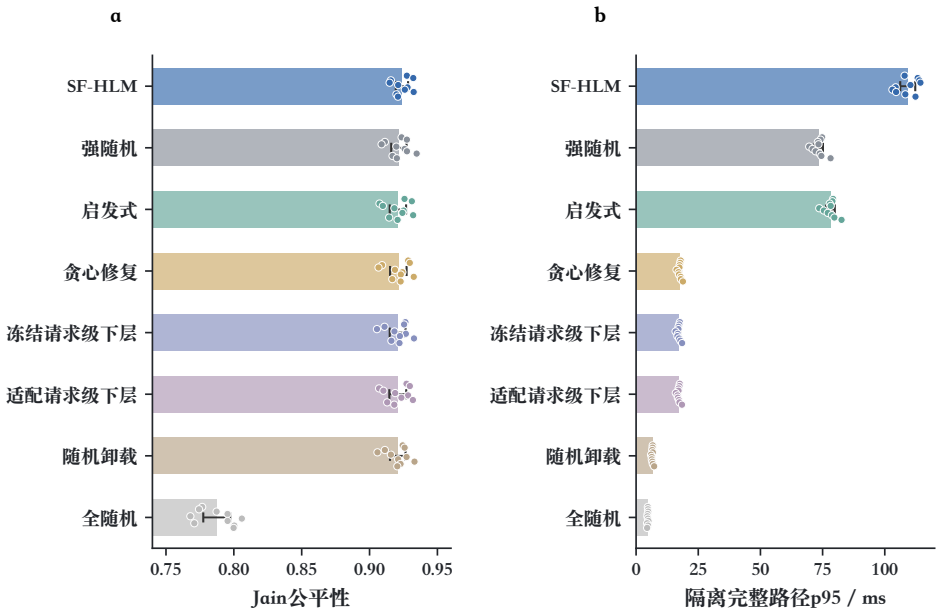


图 5.12　块级公平性与隔离完整软件 p95。p95 先在每块全部调用上计算，再展示十块分布及其均值

Figure 5.12　Block-level fairness and isolated full-policy p95, computed within each block before summarizing

5.8　完整框架与学习机制的分层解释

5.8.1　完整系统与完整下层优化包

补充随机评价显示，SF-HLM 相对全随机 DSR 高 18.816 个百分点，95% 配对区间为 [17.840, 19.791]；相对相同上层逐请求随机卸载高 10.604 个百分点，区间为 [10.376, 10.832]。两项十块均为正，新两比较 Holm 校正通过，精确符号翻转 $p = 0.001953$。对应仿真环境记录的 UAV 能耗块级比为 0.5095 与 0.5284，即平均分别降低约 49.0% 和 47.2%。

在共同质量合法域下，SF-HLM 使用贪心初始化、普通修复、预测能耗筛选、条件指派和最好保留，相对逐请求随机的 10.604 个百分点改善评价这一完整优化框架。该结果显示，配额分解与条件匹配能够更有效地利用已形成的服务机会；学习策略在共享框架上的额外作用由下文机制对照进一步评价。

全随机的十个块对应独立随机动作流，与十套学习基座配对。补充评价复用模型与确认负载，区间反映这些条件下的模型和随机策略变化，不增加主确认的独立训练重复数。

5.8.2 相同强框架上的学习配额增量

共享强框架中，启发式 DSR 为 33.475%，强配额随机为 34.100%，学习为 34.244%。学习相对启发式差 0.769 个百分点，95% 区间 [0.670, 0.868]，机制族 Holm $p = 5.56 \times 10^{-8}$。这说明按图状态学习的配额选择优于本实验采用的风险排序启发式。该判断限定于所定义的启发式，不把一个启发式的结果外推为所有手工搜索规则都不能达到同样质量。

图 5.13 展示共享框架的块级差。学习相对强随机增量为 0.143 个百分点，区间 [0.006, 0.281]；十块中六块为正，预定机制族 Holm $p = 0.0422$。精确符号翻转检验则为 $p \approx 0.0605$。小效应的两种推断存在差异，表明学习增量对统计方法具有敏感性。

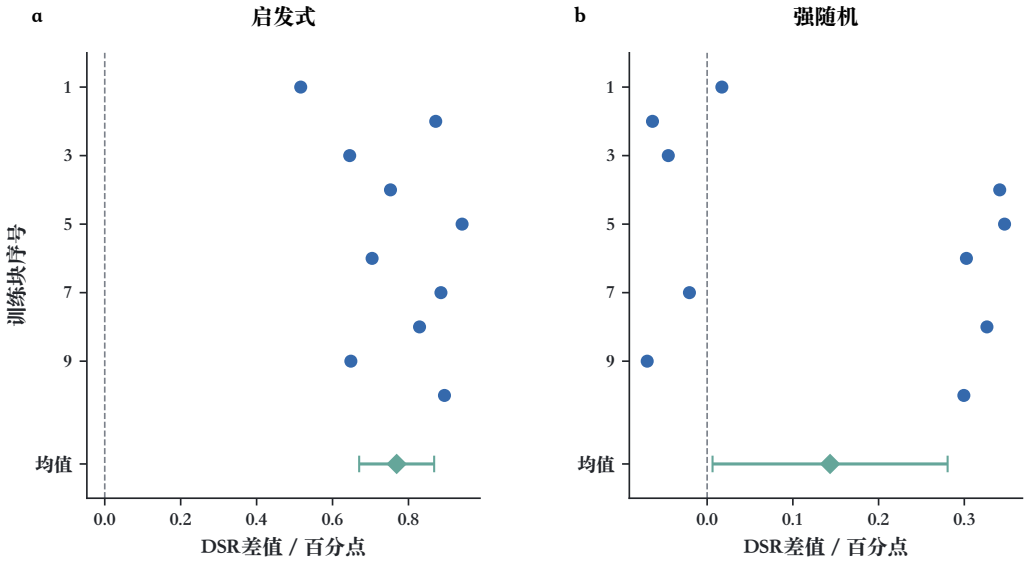


图 5.13 学习相对启发式和强配额随机的机制差。强随机共享初始化、修复、匹配、最好保留和相同调用预算

Figure 5.13 Mechanism differences against heuristic and strong random quota search sharing the same optimization framework

强随机在相同预算内接近学习质量，显示条件匹配、共同保底和最好保留发挥了较大作用。学习的额外收益较小，软件时间更长，相对强随机的 UAV 能耗块级比为 1.0089。因此，完整方法相对贪心与请求级学习修复的改善，以及共享框架上的学习增量，分别构成两个层次的结论。

5.8.3 预测误差与实际服务验证

SF-HLM 每步预测超时数减实际接纳后超时数的均值为 −0.304 个请求，平均绝对误差为 0.366；贪心相应值约为 −0.209 和 0.321。负偏差说明观测预测总体上略低估真实超时，可能涉及缓存信念与真实状态的差别及执行细节。本文没

有把预测器视为真实时延保证，所有 DSR 结果均由仿真环境的按时完成计数计算。

误差统计与条件最优证明并不矛盾。指派在给定预测量下精确优化，描述的是求解结构；预测量与实际执行之间仍存在误差，描述的是模型真实性。二者需要分别检查。如果只报告预测超时减少，可能把更乐观的预测当成性能提高；本章逐步重放实际计数，并在固定快照诊断中通过独立环境副本评价实际结果，使搜索时没有接触的执行真值用于最终验证。

5.8.4　固定潜在服务请求分母复核

相同外生随机流下，低电量 UE 会将潜在服务请求改为能量请求，因此实际生成服务请求分母有轻微策略依赖性。六个核心方法在全部确认回合中的潜在服务请求总数均为 11397280。保持原成功数不变，以共同潜在请求为分母，学习 DSR 均值为 34.235%，强配额随机为 34.091%；学习相对贪心的增益为 1.421 个百分点，与预定实际分母下 1.423 的方向和量级一致。

共同潜在分母复核仍保留三个主比较的增益，说明轻微实际分母变化不足以解释服务改善。该分析仅重新计算比率，保留原运行成功数和请求生成过程，作为实际分母 DSR 的敏感性结果。

5.8.5　教师初始化与 PPO 的开发证据

学习策略的独立确认比较教师初始化后经 PPO 更新的完整策略与共享求解框架对照，不能单独识别 PPO 更新的作用。为解释训练选择，补充五个历史训练块上的开发比较。该批次复用历史上层、训练图和开发负载，分别评价即时改进教师、多步路径教师及多步教师加动作效果特征的 BC 与 PPO 检查点。表 5.9 报告各自 PPO 减 BC 的结果，不能与十块确认当作同一次重复实验合并。

表 5.9　五训练块开发评价中的 PPO 相对 BC 差值

Table 5.9　PPO-minus-BC effects in the five-block development evaluation

教师与输入配置	DSR 差/百分点	逐项 95% 区间/百分点	正向块数
原即时改进教师	+0.935	[+0.296, +1.573]	5/5
多步路径教师	−0.008	[−0.704, +0.689]	2/5
多步教师＋动作效果特征	−0.364	[−0.564, −0.164]	0/5

原教师配置下的开发差值与 PPO 有益的解释一致，但另外两种配置没有同样方向，说明强化学习更新的效果依赖教师、输入和搜索分布。仅五块时，前后两项精确符号翻转 p 均为 0.0625，这些开发结果只用于方法选择解释，不替换主

确认或升级为新的确证。当前学习策略的主要服务收益仍建立在共同修复、条件匹配和最好方案保留之上；是否采用学习搜索需要同时判断其批次质量增量与软件费用。其取舍结合第 5.11.4 节的截止期余量分析，不能仅凭开发阶段增量决定在线方法。

5.9 冻结策略的负载与算力稳健性

5.9.1 九格设置与冻结评价

独立确认完成后，冻结十套基座和配额最后检查点，在 60/100/140 UE 与 0.6/1.0/1.4 倍 UAV 算力的九格上评价。每格保持原五负载、六回合和六种核心方法，主格直接引用原 1800 回合，八个新格共完成 14400 个质量回合。权重、优化器、奖励、MBS 算力与自然接纳保持不变，只按协议调整 UE 数和 UAV 算力。这是固定策略面对新负载与资源规模的复验，不是各格重新训练后的场景适应比较。

上层保持训练时的 30 个 UE 槽，超过容量的需求按相同排序截取。图下层按实际请求数构图，请求级 MLP 下层沿用填充与分块推理，均保持训练后的网络尺寸和权重。各方法使用相同变体环境，复用原训练块与确认负载，评价整套固定策略在规定格点上的表现。

表 5.10　学习配额 SF-HLM 在九格冻结评价中的 DSR

Table 5.10　DSR of the learned quota method across the nine frozen-policy settings

UE 数量	0.6 倍算力/%	1.0 倍算力/%	1.4 倍算力/%
60	44.430	48.961	50.746
100	29.736	34.244	36.349
140	22.142	26.259	28.263

表 5.10 和图 5.14 显示，增加 UE 数量时 DSR 下降，提高 UAV 算力时 DSR 上升。相同覆盖范围和计算节点需服务更多请求，且上层可见需求槽位固定，高负载同时加剧接纳与服务质量压力；增加算力能减轻部分计算瓶颈，却不能消除未接纳和通信路径限制。因此，算力提高到 1.4 倍时 DSR 仍明显低于 100%，不能将剩余失败都归因于下层计算不足。

5.9.2 相对三个主对手的格点差值

八个新格中学习相对贪心、冻结请求级下层和适配请求级下层的 24 项比较形成一个 Holm 主族，全部通过校正。图 5.15 给出格点配对均值差；下文同时报

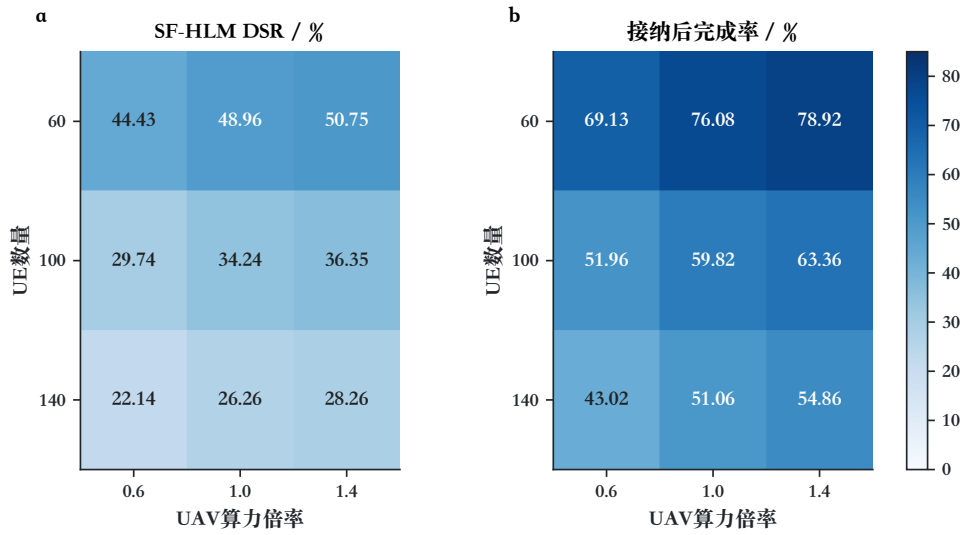


图 5.14　SF-HLM 冻结策略在 UE 数量与 UAV 算力九格中的 DSR（左）和接纳后按时完成率（右）。主格引用独立确认，其他格不重新训练；数值为十块均值

Figure 5.14　DSR and conditional completion rate of the frozen SF-HLM policy across nine UE/compute settings; cells show ten-block means

告代表格点的逐项 95% 配对 t 区间，完整格点结果保存在冻结实验归档中。相对贪心的增益从 0.667 到 2.219 个百分点，相对冻结请求级下层从 1.310 到 3.086，相对适配请求级下层从 1.460 到 3.410。该结果支持 SF-HLM 对这些对手的优势在所考察负载与算力组合中保持正向。

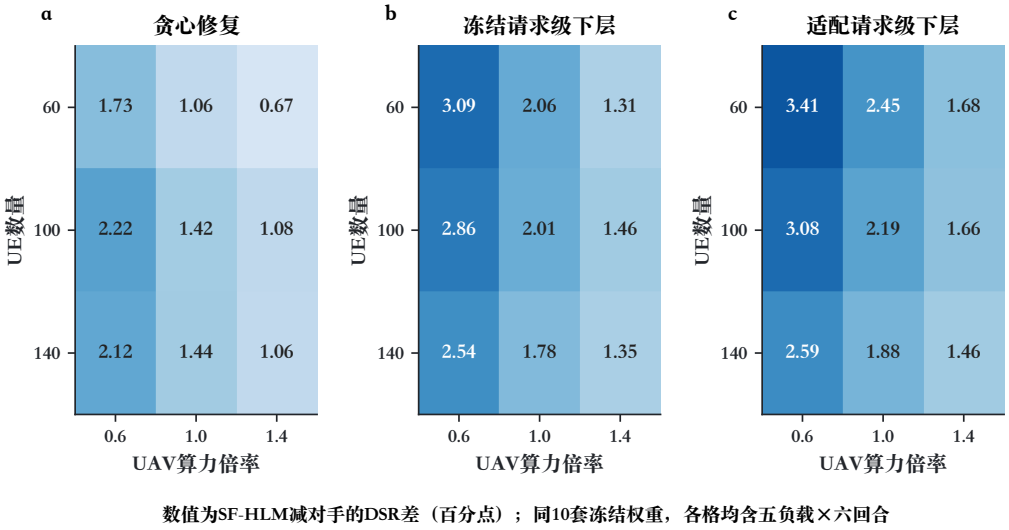


图 5.15　九格学习相对三个主对手的 DSR 差。八个新格的二十四项比较统一 Holm 校正，主格保留原确认族

Figure 5.15　DSR differences against three primary controls across nine settings, with the new 24-comparison Holm family separated from nominal confirmation

低算力与高负载下，贪心修复的局部选择更容易形成截止期敏感的批量，配额匹配的改善较明显。例如 100 UE/0.6 算力下学习 DSR 为 29.736%，贪心为

27.517%，差 2.219 个百分点，区间 [2.051, 2.387]；140 UE/0.6 算力差 2.125，区间 [1.931, 2.318]。在 60 UE/1.4 算力下，学习为 50.746%，贪心为 50.078%，差 0.667，区间 [0.493, 0.842]。后者的差值区间为正，但未达到主确认事先采用的 1 个百分点实用目标。

仿真环境记录的 UAV 能耗比同样随格点变化。学习相对贪心的块级比约为 0.876–0.939，各新格均低于 1；相对适配请求级下层在 60 UE/0.6 算力约为 1.0078，没有节能但仍低于 1.05 门槛。能耗还受算力平方项影响，提高计算能力可以改善时间，却可能增加实际计算能耗。因此，格点分析联合评价服务率和资源费用。

5.9.3 强框架机制的场景依赖

学习相对启发式与强随机的八格共 16 项比较另组成 Holm 机制族，其中 8 项通过：学习相对启发式在七个新格通过，相对强随机仅在 140 UE/0.6 算力通过。该格学习–强随机差约 0.355 个百分点，区间 [0.150, 0.560]，Holm $p = 0.0317$。其他格不能仅因未校正区间下界为正而宣称机制已稳定成立。

在 60 UE/1.4 算力格，强随机 DSR 为 50.772%，学习为 50.746%，差值约 −0.026 个百分点且区间跨零。结合主场景的小增量，结果表明学习额外优势依赖负载与算力，资源宽裕时强匹配框架已能取得接近学习的质量。

九格评价沿用相同观测范围和理想协调条件，刻画固定策略对规定负载与算力变化的适应程度。信息上报延迟、缺失及通信费用未随格点变化，仍是部署评价需要检验的条件。

5.10 固定快照、共同 MBS 与时间预算诊断

5.10.1 相同状态下的真实执行复核

为控制闭环状态差异，从 SF-HLM 的十块轨迹中，在五个负载的前两个回合分别于 0/250/500/750 步采集移动前状态，共 400 个快照，包含空批次。观测预测行供算法搜索，独立环境副本供最终候选分配的环境执行超时与能耗评价。两类副本保留相同几何、请求和历史状态，反事实结果不回写轨迹。

每块含 40 个快照，先在块内平均，再以十个基座作配对分析。自由 MBS 的常规调用设置下，学习、启发式、强随机和贪心每快照实际超时数分别为 10.2925、10.6450、10.3700 和 10.8275。学习–贪心差为 −0.5350 个请求，区间 [−0.6837, −0.3863]；学习–强随机为 −0.0775，区间 [−0.1989, 0.0439]。这说明共同状态下相对贪心有质量余量，相对强随机的差仍较小且不确定。

5.10.2　保持共同 MBS 请求数量

以每快照原始贪心的 MBS 请求数量为共同参照，要求初始化、修复、配额掩码、条件匹配和保底均保持这一数量，只允许改变哪些请求使用 MBS。图 5.16 对照自由和固定 MBS 结果。在固定数量下，四方法平均 MBS 请求数均为 0.6950，学习、强随机和贪心实际超时分别为 10.4075、10.4050 和 10.7875。学习–贪心仍为 −0.3800，区间 $[-0.5044, -0.2556]$；学习–强随机为 +0.0025，区间 $[-0.0919, 0.0969]$。

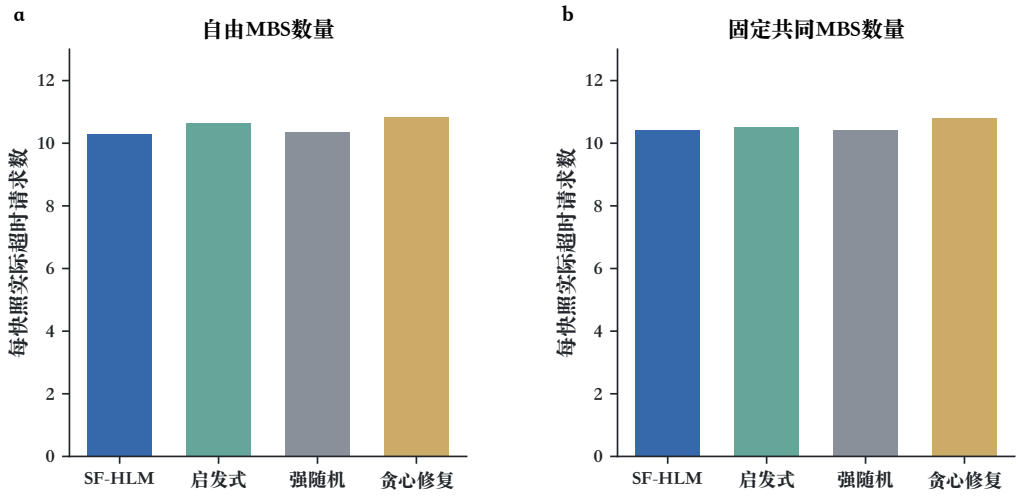


图 5.16　四百固定快照的自由与共同 MBS 数量诊断。两面板分别报告自由和固定共同 MBS 数量下每快照的实际超时均值；反事实分配不回写环境，描述性均值未画误差线

Figure 5.16　Mean actual deadline misses with free and common MBS counts on 400 snapshots; descriptive means without closed-loop write-back

固定 MBS 配额时，学习的环境分配能耗为每快照 29619.2 J，强随机为 29202.0 J，贪心为 31637.5 J。相对贪心，学习在相同 MBS 数量下仍减少超时和分配能耗；相对强随机，自由 MBS 时的小幅质量差在固定配额下未保留。该诊断控制单步资源使用，结果适用于相同快照，固定 MBS 约束下的长期 DSR 尚需闭环评价。

5.10.3　软墙钟预算下的质量与超限

在同一组快照施加 20/50/100 ms 全路径软预算，时间从输入准备开始，包含模型推理、初始化、普通修复、搜索匹配、动作映射和消息编码。输入准备消耗先从搜索可用时间扣除；预算不足时保留合法保底。各档仍保持原在线最多 16 次条件匹配与 128 次普通评价，不为了时间曲线将模型的预算特征改成未经训练的无限调用值。

图 5.17 同时展示质量、完整时间与超限比例。三档预算下学习每快照实际超时数为 10.6725、10.4250 和 10.3000，平均时间为 22.17、43.65 和 62.92 ms。预算放宽时，质量接近普通调用的 10.2925；该实验使用同一策略在固定快照上调整执行预算。

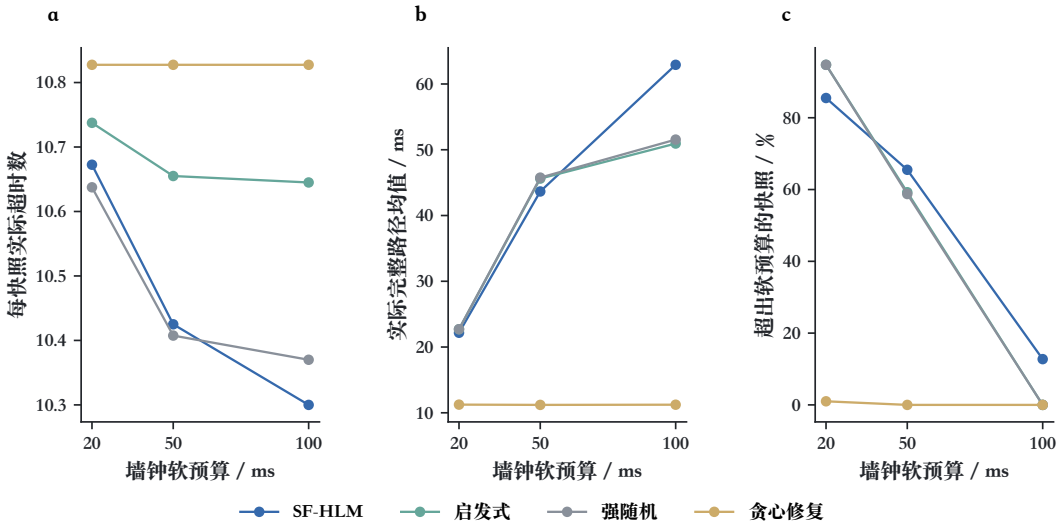


图 5.17　软墙钟预算的真实质量、时间与超限率。原子匹配与完整路径开销可能越界，所有越界样本均保留

Figure 5.17　Actual quality, time and overrun rates under soft wall-clock budgets, with all overruns retained

三档预算的超限快照比例为 85.5%、65.5% 和 12.75%，最大超限约 7.33、7.06 和 6.19 ms。时间检查发生在原子匹配前，已开始的求解、动作映射与序列化仍需完成。因此预算是软截止，实际超限量与服务质量一并报告。

5.10.4　匹配调用与停止行为

图 5.18 展示 SF-HLM 在十个训练块、共 300000 个确认评估环境步中的调用预算使用与终止记录，包含空请求批次，平均每步使用 11.737 次匹配。另在普通固定快照诊断协议下，学习平均使用 11.255 次匹配，启发式 16.000，强随机 15.990；前者汇总闭环环境步，后者汇总固定快照。预算包含初始匹配，不能把调用数理解为额外迁移数。学习可在保留当前最好方案后提前 STOP，而强随机按有效非停止动作继续直到无可尝试动作或调用耗尽。停止动作与调用惩罚共同给出节约求解机会，但实际学习前向开销仍使完整软件时间高于强随机。

普通快照中，学习完整平均时间约 63.30 ms，强随机约 51.53 ms；p95 分别约为 105.24 和 74.85 ms。这一排序与确认阶段的隔离测量一致，表明搜索效率需同时考察调用数量、网络推理开销和服务质量。

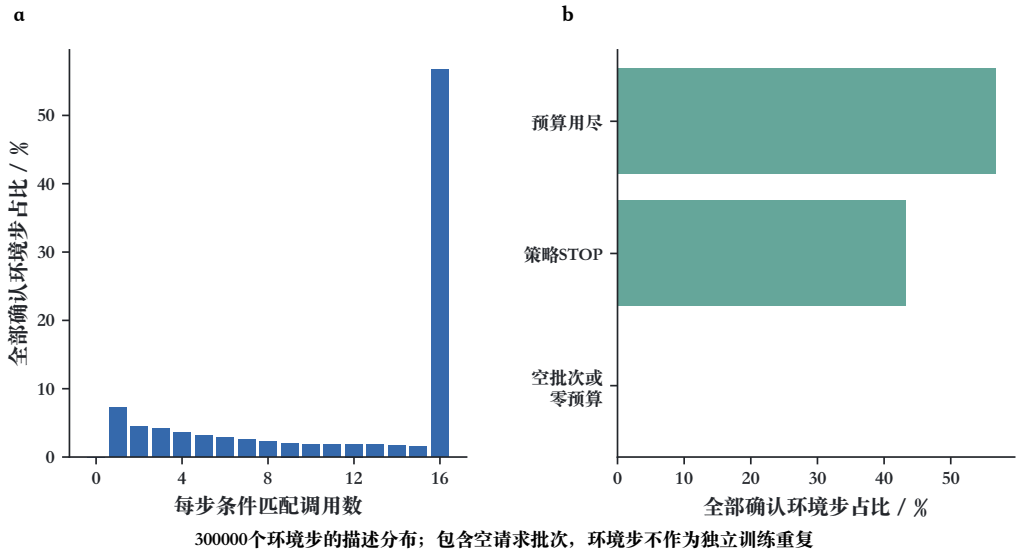


图 5.18　确认评估环境步中的匹配调用与终止行为。调用包含初始匹配及失败候选，空批次纳入统计，停止不消耗一次匹配调用

Figure 5.18　Matching-call usage and termination behavior across confirmation evaluation steps, including initialization, failed candidates and empty batches

5.11　研究联系、适用条件与本章小结

5.11.1　与第四章固定快照求解的联系

MC-ITR 在固定快照中使用环境执行评价整体分配，SF-HLM 在移动前观测预测模型中进行有限预算在线搜索。两者共享不可拆分请求与批量算力竞争的动机，具有不同的目标次序、信息范围和求解接口。SF-HLM 独立构造即时改进教师，在线执行采用配额匹配下层。

第四章在需求感知上层与无注意力请求级下层产生的轨迹上进行固定快照比较，显示离线分配余量及其能耗、计算代价。该分析为低预算任务组织提供动机，本章则通过 SF-HLM 自身的闭环实验评价端到端服务效果。两章在批量资源结构和质量–计算权衡上相互联系。

5.11.2　主要贡献与仍需验证的条件

本章建立了三项彼此支撑的结果：配额固定后，可用严格字典序标量化得到预测超时优先的条件匹配；有限预算搜索通过共同保底与最好保留始终输出完整合法分配；在独立训练块上，完整下层相对三种预定实用对手取得稳定服务增益，并在规定隔离时间内满足软件门槛。冻结跨场景复验进一步说明该优势在所测试 UE 与算力格点上保持正向。其技术意义是把已经能够确定性求解的指派结构交给求解器，把有限学习能力集中用于节点负载组织。

共享框架的随机搜索已接近学习质量，表明确定性匹配与保留机制承担重

要作用，学习增量较小且依赖场景。当前训练保持上层固定，理想协调与大范围需求信息的获取条件仍需通信费用及信息受损实验检验。UAV 节能也需结合 MBS 使用解释，这些条件界定了已测服务收益的适用范围。

进一步研究可在相同信息预算下比较强方法，并将上报延迟、字段缺失及协调费用纳入环境，检验收益对信息条件的敏感性。配额学习的改进则需在共享框架与相同预算上评价，经开发数据选择后使用新的独立训练块确认增量。

5.11.3 集群计算任务的执行分工

集群协作除空间机动之外，还体现在已接纳计算请求的执行分工。图 5.19 从 SF-HLM 的十个确认训练块原始记录中，分别累加来源本机、其他 UAV 和 MBS 三条服务执行分支的计数。每块包含五个工作负载、每负载六个回合，分支标识取自环境的服务卸载记录；这里的“本机”指请求接纳 UAV，而非 UE 自身处理器。“协作 UAV”指另一个允许执行目标，MBS 则是地面计算支撑。

记块 k 的三类计数为 $n_{k,\mathrm{L}}$、$n_{k,\mathrm{C}}$ 和 $n_{k,\mathrm{M}}$，本图的分母明确取 $n_k = n_{k,\mathrm{L}} + n_{k,\mathrm{C}} + n_{k,\mathrm{M}}$，各分支比例为 $\rho_{k,j} = n_{k,j}/n_k$。三类比例在块内之和为一，统计对象是已记录的执行分支，不是按时成功请求或各 UAV 的单机负载。跨块摘要采用 $10^{-1}\sum_k \rho_{k,j}$；将全部计数池化得到的 $\sum_k n_{k,j}/\sum_k n_k$ 属于另一种加权方式，不代替图中的块均值。

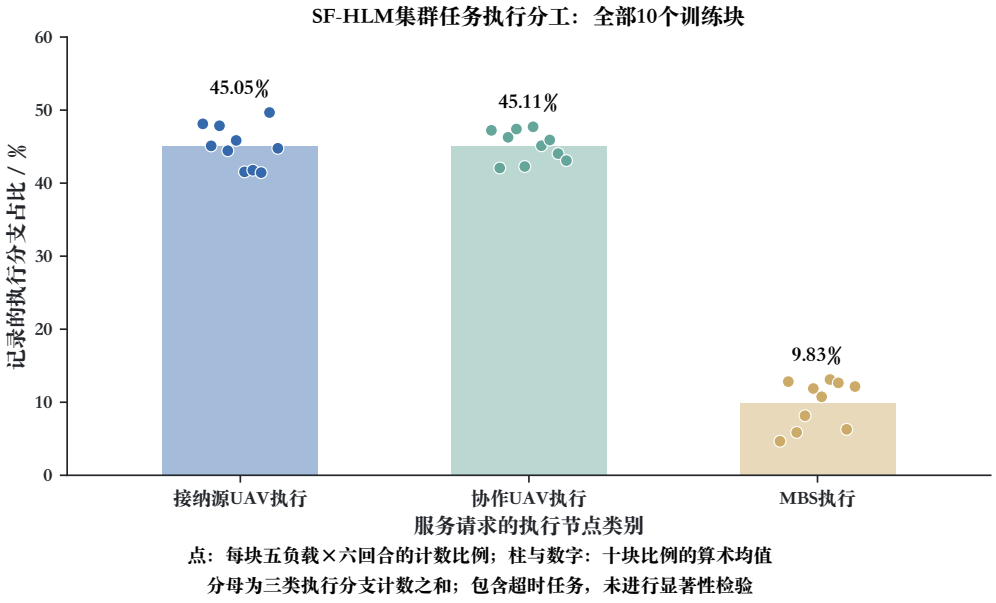


图 5.19 SF-HLM 十个确认训练块的计算任务执行分工。比例分母为每块本机、协作 UAV 与 MBS 三分支计数总和；显示全部训练块及等权块均值，不设置误差线或显著性检验

Figure 5.19 Computation-task execution branches across all ten SF-HLM confirmation blocks, normalized by each block's three-branch total; descriptive block fractions and their arithmetic means

按等权块均值，本机、协作 UAV 和 MBS 的执行比例依次约为 45.054%、45.112% 和 9.834%。三分支总计记录 6 533 312 次，其中本机 2 945 929 次、协作 UAV 2 946 812 次、MBS 640 571 次；池化比例依次约为 45.091%、45.104% 和 9.805%。该分布说明跨 UAV 执行在这批已记录计算请求中占据较大部分，空间接纳平台与计算执行平台确实可以分离。它没有识别单独关闭跨机协作后的性能效应，也不能由较低 MBS 比例推断无需地面支持。协作分支还包含传输与资源竞争代价，服务质量与能耗仍需结合前述独立比较解释。

5.11.4　调度延迟敏感性与软件费用事后复核

为连接路径质量与调度费用，补充学习配额、强配额随机和贪心修复三个方法的原确认轨迹复核。每方法仍为十训练块、五工作负载、每负载六回合与每回合 1000 步，即每方法 300 回合，三方法共 900 回合。重放读取原卸载动作，由冻结上层重现位置决策；在请求刷新前采集实际路径时延与截止时间。逐步指标、请求计数、外生流、检查点和模型摘要均与原记录核对。该过程未训练或筛选模型，也未把新延迟回写状态。

第一类评分对所有方法施加共同附加等待 $\delta \in \{0, 20, 50, 100, 150\}$ ms，把原成功条件替换为 $T_m + \delta \leqslant D_m$，未接纳请求仍计入原生成分母。第二类评分按训练块、负载、回合和步号配对原隔离计时记录，使用该方法每次完整软件调用时间 c_t 判断 $T_m + c_t \leqslant D_m$；不以平均或 p95 时间替代逐次费用。两类均先汇总块内成功与生成计数，再计算十块等权均值和逐项配对 t 区间。它们是原轨迹上的探索性事后评分，不扩充独立训练重复数，也不改变预定主检验族。

表 5.11　附加延迟及逐次软件费用事后评分（DSR 为百分比，差值及区间为百分点）

Table 5.11　Post-hoc scoring with added delay and per-call software costs

评分条件	学习	强随机	贪心	学习减强随机（95% 区间）	学习减贪心（95% 区间）
0 ms	34.244	34.100	32.821	+0.143 [0.006, 0.281]	+1.423 [1.258, 1.587]
20 ms	32.700	32.581	31.803	+0.119 [−0.013, 0.251]	+0.897 [0.748, 1.046]
50 ms	30.603	30.506	30.294	+0.097 [−0.029, 0.223]	+0.309 [0.159, 0.459]
100 ms	27.871	27.746	28.199	+0.125 [0.017, 0.232]	−0.329 [−0.498, −0.160]
150 ms	25.860	25.670	26.587	+0.190 [0.082, 0.298]	−0.728 [−0.916, −0.540]
逐次软件费用	29.379	30.073	32.161	−0.694 [−1.272, −0.116]	−2.782 [−3.374, −2.190]

零附加延迟精确复现原三方法 DSR。共同等待增大后，各方法 DSR 下降，但差值并非固定平移：100 ms 时学习减贪心为 −0.329 个百分点，150 ms 时为 −0.728，说明原学习分配的截止期余量对等待更敏感。学习对强随机的差仍较小，20 和 50 ms 逐项区间跨零；该探索性分析不构成独立确认。

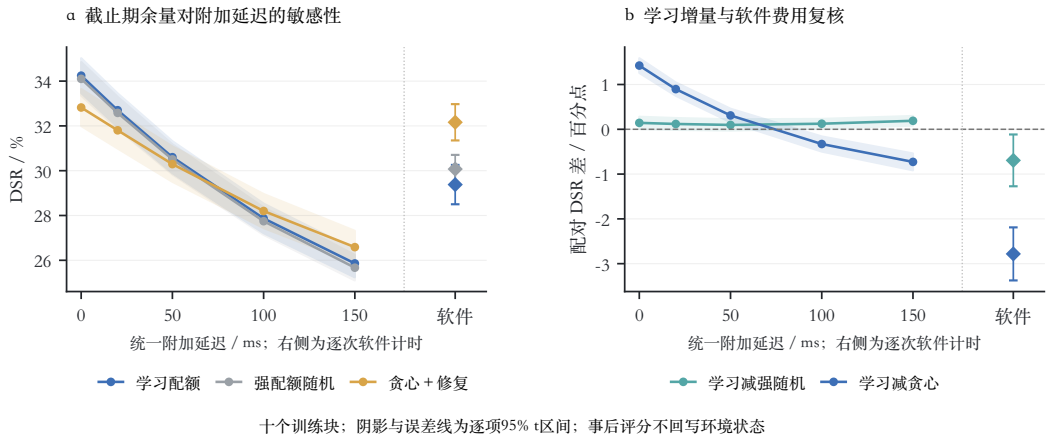


图 5.20　原确认轨迹的调度延迟敏感性。左面板为 DSR，右面板为学习相对强随机和贪心的配对差；菱形单独表示逐次软件费用评分，与共同延迟曲线分开。阴影与误差线为十块逐项 95% t 区间，状态不回写

Figure 5.20　Scheduling-delay sensitivity on original confirmation trajectories; diamonds denote per-call software scoring, with pointwise ten-block t intervals and no state write-back

逐次软件费用评分下，学习、强随机和贪心的 DSR 分别为 29.379%、30.073% 和 32.161%。学习减强随机为 −0.694 个百分点，逐项区间 $[-1.272, -0.116]$；学习减贪心为 −2.782，区间 $[-3.374, -2.190]$。原批次质量优势在这一费用口径下发生反转。因此，指定服务器上的软件调用门槛与计入求解等待后的服务优势须分别判断，预算受限时应把较低的软件费用纳入方法选择。

已接纳请求中，路径时延超过一秒的比例在学习、强随机和贪心中分别约为 64.06%、64.77% 和 62.52%，进一步说明决策步长与解析完成时间并不等价。上述评分保留原动作、缓存、电量和位置轨迹，没有模拟等待引起的资源占用或后续状态改变；它能够界定原请求的截止期余量，但不是通信受限或持续排队环境的新闭环结果。

5.11.5　本章小结

本章把无人机集群的需求感知空间部署与跨节点计算任务分工连接起来，形成冻结上层、学习配额和条件匹配的 SF-HLM 在线方法。上层分散轨迹推断与下层集中批量分配具有清楚的输入、输出和训练阶段，任务执行通过状态反馈影响后续机动。详细推导了移动前时延与分配能耗预测、整数配额守恒、容量槽指派、字典序等价性、二部图消息传递和配额 PPO；共同贪心参照、能耗筛选与最好保留明确了有限预算方法的输出性质。原批次评分的独立确认表明，该方法相对贪心修复和两种请求级下层修复具有 DSR 优势，仿真环境记录的 UAV 能耗与完整软件时间同时达到预定门槛。事后计入逐次软件费用改变了学习、强随机和贪心的质量排序，故这一原评分优势限定于未计求解等待的口径。

补充随机、冻结九格、共同 MBS 和软墙钟诊断进一步区分完整优化框架的收益、学习选择的额外贡献及其资源代价。完整下层对逐请求随机具有较大改善，而共享强框架上的学习增量较小；更高 MBS 依赖与额外推理时间需要和 UAV 节能一起报告。由此，本章形成的是有明确信息条件、实测预算和独立重复支持的仿真方法结论，为后续验证通信可得性和部署费用提供可复现基础。

第 6 章　总结与展望

6.1　研究总结

本文面向具有截止时间的地面计算服务，研究无人机集群如何通过协同空间部署接纳动态需求，并通过跨节点计算任务分配提高按时完成比例。空中平台的位置决定请求能否进入服务流程，机载计算、缓存及协作传输决定接纳后的执行质量。围绕这两个相互联系的环节，本文以统一请求计数为基础，依次研究需求感知协同轨迹决策、固定快照跨机任务分配和 SF-HLM 完整在线方法，形成从空间服务瓶颈到批量资源耦合再到分层决策验证的技术路线。

研究聚焦无人机集群的任务规划与资源分工：机动决策调整服务区域，任务分配组织执行节点，共同服务于时限完成目标。MEC 提供具有明确输入、截止时间和资源消耗的任务模型。方法在固定高度二维运动和规定信息条件下评价，其适用范围及进一步面向飞行执行的需求见下文。

6.1.1　需求感知的集群空间部署与服务接纳

本文把实际生成、自然接纳和按时完成的服务请求记为 G、A 和 S，以 S/G 定义端到端 DSR，同时报告 A/G 与 S/A。这一口径把未覆盖请求的损失纳入评价，使轨迹控制与卸载质量能够在同一个服务成功链条内解释。它也避免了只看接纳后完成率时忽略覆盖盲区的问题。对于多个时隙、工作负载或训练块，本文按照预定计数和聚合层次计算指标，而不直接相乘三个跨单元均值。

第三章的服务失败分析显示，未覆盖需求构成主场景中重要的失败来源。扩展上层预动作观测后，轨迹策略能够看到感知范围内尚未接纳的用户，其物理服务半径仍为 100 m。独立确认中，候选 DSR 从 0.2444 增至 0.2793，提升约 3.49 个百分点，并在十个训练种子上保持同向。接纳增加的同时，接纳后完成质量发生变化，这使“更多覆盖”与“更好的服务”之间的联系成为后续卸载研究的直接动机。固定潜在服务请求分母复核也表明，轻微实际分母变化未解释该批次的主增益。

这项研究把轨迹规划的依据从已接纳用户扩展到允许观测的尚未接纳需求，使集群空间部署能够面向后续服务机会进行调整。邻机与用户注意力组织可变的空间交互信息，位移、边界和间距修复保证规定离散状态中的几何可行性。需求信息扩展同时改变了信息条件；同信息预算的探索性替代结构比较尚未确认独立注意力优势，因此本文把需求可见性、网络聚合和环境执行约束分别解释。

这种区分保留了空间部署改善的证据，也使后续结构比较能够围绕相同信息条件进行。

6.1.2　跨机计算任务分工与批量资源耦合

第四章针对给定集群位置、请求和历史状态研究 MC-ITR，把跨机任务分工写成具有批量外部影响的分配问题。最终批量均分算力使一个请求迁移能够改变两个节点上其他请求的完成时间，因此逐请求自身代价不足以完整描述迁移影响。MC-ITR 对候选迁移重新评价整个分配，并按超时数、归一化时延与分配能耗的字典序比较接受严格改善。有限分配空间与严格改善保证相应搜索按无改善或预算条件终止，其性质属于固定快照求解过程；完整邻域扫描无改善时才认证相应邻域局部最优。

主配置中，MC-ITR 每快照平均超时数为 2.055，低于 Iterative-Base 的 2.228；主配置及八个 UE 或算力敏感性配置的配对结果支持其截止期质量改善。小规模穷举提供实现一致性检查。在需求感知上层与无注意力学习式下层产生的共享轨迹快照上，MC-ITR 相对在线下层平均每快照少 2.460 个超时请求，进一步显示固定状态下的分配余量。

固定快照实验同时显示质量改善的代价。学习轨迹快照上，MC-ITR 分配能耗约增加 23.8%，含贪心初值的完整调用路径平均约 20.751 s。反事实分配未回写环境，这些结果刻画的是给定状态下的质量–计算权衡。MC-ITR 作为离线参照，其批量资源分析为条件化匹配与有限预算在线搜索提供了设计依据。

6.1.3　协同轨迹与计算任务分配的分层决策

第五章提出并验证 SF-HLM，连接需求感知空间部署与接纳后的计算资源分工。给定执行节点配额后，将请求分配到容量槽位，通过条件化指派处理请求身份与最终共享算力之间的关系；CompleteQuotaPPO 选择配额迁移与停止动作。共同质量掩码、普通修复、能耗筛选和最好方案保留，使有限预算搜索输出完整分配。训练时保持上层参数固定，独立优化配额策略，在线执行沿用自然接纳和请求处理时序。

十个独立训练块与五个配对工作负载的确认中，SF-HLM 的 DSR 为 34.244%，相对贪心加普通修复、冻结请求级下层加修复、适配请求级下层加修复，分别提高 1.423、2.008 和 2.192 个百分点。相对相同学习上层加逐请求随机卸载与全随机，分别提高 10.604 和 18.816 个百分点。上述对照评价完整下层优化框架和完整系统的收益；学习搜索的增量由共享框架对照进一步刻画。SF-HLM 接纳后按

时完成率约为 59.82%，显示下层任务组织对服务质量的作用。

共享强框架下，配额随机搜索已经达到约 34.100% DSR，学习搜索的额外差值约为 0.143 个百分点。配对区间约为 [0.006, 0.281] 个百分点，机制族 Holm 校正通过，而精确符号翻转敏感性结果接近临界。这一较小增量及其统计敏感性表明，完整框架构成了主要收益来源。SF-HLM 各块隔离 p95 软件调用时间的均值约为 109.24 ms，高于强配额随机的约 73.47 ms；学习搜索提供小幅服务质量增益，同时增加软件开销。

逐次软件费用的事后复核进一步限定了学习增量的用途。原确认轨迹中，加入各方法实际记录的软件等待后，学习 DSR 为 29.379%，低于强随机的 30.073% 和贪心的 32.161%。该评分没有改变轨迹或跨步资源状态，但表明原未扣除调度等待的服务优势不能直接转化为在线净收益。当前方法的主要贡献是批量结构化求解及其质量–费用分析；选择学习搜索时，需要同时考虑请求余量和求解成本。

6.2 综合认识与适用范围

两类决策具有互补作用：轨迹策略依据预动作需求信息改变未来空间服务条件，结构化下层依据已接纳请求与节点能力协调当前资源竞争。位置、缓存和能量按批次评价规则将二者连接为闭环，未完成任务和下载事件不跨步保留；DSR 分解用于描述接纳与完成质量的共同变化。完整方法的效果由独立确认评价，固定快照和探索性消融则提供结构解释。

集群采用上层分散式决策与下层集中调度。各 UAV 的 Actor 使用规定的局部观测，下层汇总当前请求和节点能力形成任务分配，因此仍需集中协调。五机仿真尚未检验大规模通信扩展性；460 m 感知范围规定观测邻居集合，200 m 最小间距规定离散几何约束。持续通信连通性与连续飞行安全需要对应的通信及运动模型验证。

固定策略稳健性评价覆盖 60/100/140 UE 与 0.6/1.0/1.4 UAV 算力的九格设置，检验相同模型在负载与算力变化下的表现。相对三个主对照，完整下层优化保持正向增益；相对强配额随机的学习增量则具有场景依赖。固定 MBS 配额和墙钟预算诊断进一步刻画相同快照上的匹配行为与计算限制，与长期闭环评价相互补充。

研究采用仿真信息与理想协调条件，尚未计入预接纳需求上报、通信排队、消息失真和现实网络等待。软件计时包含输入准备、推理与搜索路径，能耗统计覆盖 UAV 飞行与作业，未覆盖全部地面计算及新增控制通信费用。节点能力和

计算能耗采用等效频率假设，参数没有指定机载芯片的标定。所报告能耗改善仅适用于这一模型，不换算为实测续航收益；服务主指标未计求解等待，部署净收益仍需在完整通信与能源模型中检验。

6.3　后续研究方向

首先，可把任务层机动决策与具有飞行动力学约束的轨迹执行连接。当前位移模型限制速度模长、边界和离散机间距，但没有描述加速度、转向、姿态及环境扰动。后续需要检查这些约束如何改变可到达服务位置，并把轨迹跟踪误差纳入覆盖判定。在相同请求与资源条件下，比较理想位置更新和动力学可执行轨迹的接纳率、按时完成率及实际飞行能耗，可以判断现有任务层收益在执行约束下保留多少。连续避碰能力也应由对应轨迹验证与控制分析确认。

其次，可研究预接纳信息与集中协调信息的实际获取条件。分别设置请求上报延迟、字段缺失、更新频率和控制消息代价，并在截止期判定与能耗结算中计入请求汇总、分配下发等开销。各方法使用相同信息条件和回退规则，比较信息陈旧或通信受限时的服务质量，由此确定当前理想协调收益的保留程度。

再次，可研究平台失效与有限续航条件下的集群任务重分工。在现有能耗模型基础上，增加剩余能源、返航保留量和失效时刻；执行节点不可用时重新确定配额、任务映射和空间部署，并记录任务丢失与恢复时间。在固定故障流和相同电池预算下评价服务恢复能力，使续航与失效适应具有直接的实验依据。

在决策模型方面，可扩大同信息结构比较与场景训练设计。第三章已有同信息替代结构的探索性证据，后续可以用新的训练块和负载进行确认，检查注意力聚合、需求排序与观测容量各自的作用。对于 UE 与算力变化，也应区分冻结策略泛化和重新训练适配：前者关注已有模型是否仍可用，后者关注在新场景下投入额外训练能达到什么表现。这样的分开设计能够为模型选择和集群服务预算提供更清楚的依据。

在任务调度方面，可研究更有效的有限预算搜索。当前强配额随机已具有较高服务质量，说明条件化匹配与保留框架提供了坚实基座；学习策略的下一步应针对请求临界程度、负载变化和调用成本形成更准确的停止与入口选择。在相同匹配预算和墙钟预算下，比较不同学习信号与教师路径，报告在线收益以及离线标注成本。任何由开发结果筛选的新策略，应使用新的独立确认，而不直接替换当前主结果。

上述扩展还可以结合传播遮挡、请求依赖和缓存不确定性，逐步检验更丰富的物理与业务条件。扩展模型时应保持单位、时序与成功计数一致，并继续保留

强非学习对照。实际执行轨迹、注意力权重和搜索过程的可视化可以帮助解释行为，但应来自冻结模型与完整记录，不能替代独立性能检验。对于应急临时服务等应用，还需使用相应的地理环境、任务流和平台参数独立验证，才能把本文的仿真服务收益转化为具有明确机动、能源与信息成本的集群系统设计依据。

6.4 本章小结

本文围绕需求感知空间部署、跨机批量任务分配和 SF-HLM 分层决策，建立了从服务接纳到截止期完成的集群规划方法。原批次评分的独立确认支持完整下层优化框架在所测主场景中的 DSR 改善，强随机对照则显示学习搜索增量较小。事后软件费用复核显示方法排序可能反转，进一步界定了这一改善的适用口径。后续结合动力学执行、通信受限协调、平台失效与有限续航模型，可进一步检验该方法的适用范围。

参考文献

[1] Chung S J, Paranjape A A, Dames P, et al. A survey on aerial swarm robotics[J]. IEEE Transactions on Robotics, 2018, 34(4): 837-855.

[2] Mao Y, You C, Zhang J, et al. A survey on mobile edge computing: The communication perspective[J]. IEEE Communications Surveys & Tutorials, 2017, 19(4): 2322-2358.

[3] Zeng Y, Zhang R, Lim T J. Wireless communications with unmanned aerial vehicles: opportunities and challenges[J]. IEEE Communications Magazine, 2016, 54(5): 36-42.

[4] Mozaffari M, Saad W, Bennis M, et al. A tutorial on UAVs for wireless networks: Applications, challenges, and open problems[J]. IEEE Communications Surveys & Tutorials, 2019, 21(3): 2334-2360.

[5] Hu X, Wong K K, Yang K, et al. UAV-assisted relaying and edge computing: Scheduling and trajectory optimization[J]. IEEE Transactions on Wireless Communications, 2019, 18(10): 4738-4752.

[6] Yu Z, Gong Y, Gong S, et al. Joint task offloading and resource allocation in UAV-enabled mobile edge computing[J]. IEEE Internet of Things Journal, 2020, 7(4): 3147-3159.

[7] Skaltsis G M, Shin H S, Tsourdos A. A review of task allocation methods for UAVs[J]. Journal of Intelligent & Robotic Systems, 2023, 109(4): 76.

[8] Yuan X, Xie Z, Tan X. Computation offloading in UAV-enabled edge computing: A Stackelberg game approach[J]. Sensors, 2022, 22(10): 3854.

[9] 曾耀平, 李怀, 陈世森, 等. 无人机部署与卸载策略优化[J]. 浙江大学学报（工学版）, 2026, 60(8): 1686-1696.

[10] 王义君, 王雅出, SHAHD Batool, 等. 无人机辅助动态权重边缘计算卸载策略研究[J]. 电子与信息学报, 2026, 48(7): 3071-3083.

[11] 李侍阳, 朱晓荣. 面向感知与 AI 协同任务的无人机巡检多维资源联合优化算法[J]. 电子与信息学报, 2026, 48(5): 2166-2177.

[12] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.

[13] Williams R J. Simple statistical gradient-following algorithms for connectionist reinforcement learning[J]. Machine Learning, 1992, 8(3-4): 229-256.

[14] Lillicrap T P, Hunt J J, Pritzel A, et al. Continuous control with deep reinforcement learning [A]. 2015.

[15] Li B, Yang R, Liu L, et al. Robust computation offloading and trajectory optimization for multi-uav-assisted mec: A multi-agent drl approach[J]. IEEE Internet of Things Journal, 2024, 11

(3): 4775-4786.

[16] Tao Y, Kuang Z, Hou F, et al. Online service selection and task offloading in UAV-assisted MEC via deep reinforcement learning[J]. IEEE Transactions on Cognitive Communications and Networking, 2026, 12: 4159-4173.

[17] Lowe R, Wu Y, Tamar A, et al. Multi-agent actor-critic for mixed cooperative-competitive environments[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 6379-6390.

[18] Yu C, Velu A, Vinitsky E, et al. The surprising effectiveness of PPO in cooperative multi-agent games[C]. Advances in Neural Information Processing Systems: Vol. 35. 2022: 24611-24624.

[19] Sunehag P, Lever G, Gruslys A, et al. Value-decomposition networks for cooperative multi-agent learning based on team reward[C]. Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems. 2018: 2085-2087.

[20] Rashid T, Samvelyan M, Schroeder de Witt C, et al. Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning[C]. Proceedings of Machine Learning Research: Vol. 80 Proceedings of the 35th International Conference on Machine Learning. 2018: 4295-4304.

[21] Hady M A, Hu S, Pratama M, et al. Multi-agent reinforcement learning for resources allocation optimization: A survey[J]. Artificial Intelligence Review, 2025, 58(11): 354.

[22] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]. Advances in Neural Information Processing Systems: Vol. 30. 2017: 5998-6008.

[23] Ju T, Li L, Liu S, et al. A multi-UAV assisted task offloading and path optimization for mobile edge computing via multi-agent deep reinforcement learning[J]. Journal of Network and Computer Applications, 2024, 229: 103919.

[24] Wang B, Kang H, Li J, et al. UAV-assisted joint mobile edge computing and data collection via matching-enabled deep reinforcement learning[A]. 2025. arXiv: 2502.07388.

[25] Chen X, Tian Y. Learning to perform local rewriting for combinatorial optimization[C]. Advances in Neural Information Processing Systems: Vol. 32. 2019.

[26] Sutton R S, Barto A G. Reinforcement learning: An introduction[M]. 2nd ed. MIT press, 2018.

[27] Schulman J, Moritz P, Levine S, et al. High-dimensional continuous control using generalized advantage estimation[A]. 2015.

[28] Schulman J, Wolski F, Dhariwal P, et al. Proximal policy optimization algorithms[A]. 2017.

[29] Gronauer S, Diepold K. Multi-agent deep reinforcement learning: A survey[J]. Artificial Intelligence Review, 2022, 55(2): 895-943.

[30] Virtanen P, Gommers R, Oliphant T E, et al. SciPy 1.0: Fundamental algorithms for scientific

computing in Python[J]. Nature Methods, 2020, 17(3): 261-272.

[31] Crouse D F. On implementing 2D rectangular assignment algorithms[J]. IEEE Transactions on Aerospace and Electronic Systems, 2016, 52(4): 1679-1696.

致谢

在此感谢导师的悉心指导，感谢实验室同学的帮助，感谢家人的支持。

在读期间取得的科研成果